4장 추정

- 4.1 적률추정법
- 4.2 최대가능도 추정법
- 4.3 추정의 기준
- 4.4 최소분산 비편향추정량
- 4.5 추정량의 점근적 성질
- 4.6 구간추정
- 4.7 베이즈 추정

이 장에서 다룰 추정이론(estimation theory)은 다음 5장에서 다룰 검정이론(testing theory)과 함께 통계적 추론(statistical inference)의 가장 중요한 분야로 여겨진다. 먼저 추정론의 개요를 살펴보면 다음과 같다. 연구나 관찰의 대상인 확률변수 X의 확률분포를 $P_\theta(x)$, $\theta \in \Omega$로 표현하자. 물론 확률분포 $P_\theta(x), \theta \in \Omega$를 확률밀도함수 $f(x;\theta)$, $\theta \in \Omega$로도 표현할 수 있다. 일반적으로 미지의 모수 θ를 제외하고는 확률분포의 유형이 결정되어 있다고 가정하기로 하자. 모수모형(parametric model)이라고 불리는 이런 경우에 모수 θ는 $\theta = (\theta_1, \theta_2, \cdots, \theta_k)$로 표현되는 벡터일 수도 있으며, Ω는 모수가 가질 수 있는 값의 집합, 즉 모수공간을 뜻한다. 이제 확률분포 $P_\theta(x)$, $\theta \in \Omega$로부터 크기가 n인 랜덤표본 $X_1, X_2, \cdots, X_n$을 얻었다고 하자(편의상 $X = (X_1, X_2, \cdots, X_n)$으로 표기한다). 이때 우리가 관심이 있는 문제는 확률분포 $P_\theta(x), \theta \in \Omega$를 특징짓는 모수 θ 또는 θ의 함수인 $g(\theta)$의 추정이다(예: $g(\theta) = e^\theta$, $g(\theta) = \theta^2$ 등). 많은 경우에 우리는 모수인 θ 자체에 흥미를 가지게 되지만, 일반성을 잃지 않기 위하여 모수의 함수인 $g(\theta)$의 추정에 대해 고려하기로 한다.

$g(\theta)$에 대한 추정방법에는 크게 표본에 근거한 통계량 $T(X) = T(X_1, X_2, \cdots, X_n)$을 사용하여 하나의 값으로 $g(\theta)$를 추정하는 **점추정**(point estimation)과, 두 개의 통계량 $T_1(X) = T_1(X_1, X_2, \cdots, X_n)$과 $T_2(X) = T_2(X_1, X_2, \cdots, X_n)$을 사용하여 구간 $[T_1(X), T_2(X)]$에 $g(\theta)$가 포함될 확률을 고려하는 **구간추정**(interval estimation)의 두 가지 방법이 있다. 두 가지 방법 가운데 좀 더 많은 정보를 제공할 수 있다는 이유로 흔히 구간추정이 선호되지만, 추정이론의 많은 부분은 점추정에 관한 것이다. 그 이유는 일반적으로 구간추정은 점추정값에 오차한계를 더해놓은 꼴로 표현되므로, 좋은 점추정량을 찾는 것이 좋은 구간추정을 가능케 하기 때문이다. 이러한 맥락에서, 이 장의 많은 부분도 점추정의 이론을 다루는 데 할애될 것이다.

점추정의 과정에는, 기본적인 접근방법을 정하는 것과 또 주어진 기준에 의해 여러 가지 가능한 추정방법 중에서 가장 뛰어난 것을 선택하는 두 가지 요소가 들어있다. 여기에서는 기본적인 접근방법으로서, 적률과 가능도의 원리를 고려할 것이며 추정량의 선택기준으로는 평균제곱오차(mean square error)의 최소화를 사용할 것이다. 평균제곱오차를 기준으로 추정량을 선택함에 있어서는 비편향추정량들 중에서 분산을 최소화하는 최소분산 비편향추정량을 주로 다루게 된다. 그리고 구간추정에서는 추축변량(pivotal quantity)을 사용하는 방법을 다루고, 마지막 절에서는 베이즈(Bayes) 추정방법을 고려하도록 한다. 이제 추정에 필요한 추정량을 정의하면 다음과 같다.

정의 4.1

미지의(unknown) 모수를 포함하지 않는 랜덤표본 $X_1, X_2, \cdots, X_n$ 의 함수를 통계량(statistic)이라고 한다. 나아가, 모수 θ의 함수 $g(\theta)$를 추정하기 위해 사용되는 통계량 $T(X) = T(X_1, \cdots, X_n)$을 $g(\theta)$의 **추정량**(estimator)이라고 하며, 주어진 표본값 $X_1 = x_1, X_2 = x_2, \cdots, X_n = x_n$을 대입해서 구해진 추정량의 특정값, $T(x) = T(x_1, x_2, \cdots, x_n)$ 을 **추정값**(estimate)이라고 한다.

주 모수 θ와 그의 추정량을 구별하기 편리하도록, 많은 경우에 추정량을 $\hat{\theta}_n$ 또는 $\hat{\theta}$으로 표기하기로 한다. $\hat{\theta}_n$에서 첨자 n은 추정량을 구하는 데 사용된 표본의 크기가 n임을 강조하기 위해 쓴 것이다.

예 4.1

$X_1, X_2, \cdots, X_n$을 $N(\mu, \sigma^2)$으로부터 얻은 랜덤표본이라고 하자. 모평균 μ와 모분산 σ^2을 추정하고자 할 때, 표본평균

$$\hat{\mu} = T_1(X_1, X_2, \cdots, X_n) = \frac{\sum_{i=1}^{n} X_i}{n}$$

와 표본분산

$$\hat{\sigma}^2 = T_2(X_1, X_2, \cdots, X_n) = \frac{\sum_{i=1}^{n} (X_i - \overline{X}_n)^2}{n-1}$$

을 추정량으로 사용할 수 있으며, 표본이 주어졌을 때 그들의 값

$$T_1(x_1, x_2, \cdots, x_n) = \frac{\sum_{i=1}^{n} x_i}{n}, \quad T_2(x_1, x_2, \cdots, x_n) = \frac{\sum_{i=1}^{n} (x_i - \overline{x}_n)^2}{n-1}$$

을 추정값이라 한다.

모수를 추정하는 데 있어서 가능한 여러 가지 접근방법들 중에, 적률(moment)을

사용하는 방법과 가능도원리(likelihood principle)를 사용하는 방법을 우선 고려해 보자. 그 외에도 선형모형의 모수추정에 많이 사용되는 최소제곱추정법(least square method)이 있으나, 이는 6장의 분산분석과 7장의 회귀분석에서 별도로 다루기로 한다.

4.1 적률추정법

모수벡터 $\boldsymbol{\theta} = (\theta_1, \cdots, \theta_k)$를 갖는 확률분포에서 $X_1, \cdots, X_n$ 의 표본을 뽑는다고 하자. 2.8절에서 모분포의 r차 적률(rth population moment)을

$$\mu_r{}' = E(X^r) \tag{4.1}$$

으로, r차 표본적률(rth sample moment)을

$$m_r{}' = \frac{\sum_{i=1}^{n} X_i^r}{n} \tag{4.2}$$

으로 표기하기로 했었다. 일반적으로 모적률 $\mu_r{}'$은 모수벡터 $\boldsymbol{\theta} = (\theta_1, \theta_2, \cdots, \theta_k)$의 함수이므로 k개의 연립방정식

$$m_j{}' = \mu_j{}' (\theta_1, \theta_2, \cdots, \theta_k) , \qquad j = 1, 2, \cdots, k$$

를 풀면 해 $(\hat{\theta}_1, \hat{\theta}_2, \cdots, \hat{\theta}_k)$를 구할 수 있을 것이며, 이를 $(\theta_1, \cdots, \theta_k)$에 대한 적률추정량이라고 한다. 이는 대수의 법칙에 의하여 r차 모적률이 존재할 때, r차 표본적률이 r차 모적률로 표본의 크기가 커짐에 따라 확률적으로 수렴한다는 사실에 기초한 방법으로서, n이 크다면 표본적률이 확률적으로 모적률에 매우 가깝게 되므로 표본적률을 이용하여 모적률을 추정하는 것은 합리적인 방법이라고 할 수 있다. 이에 대한 몇 가지 예를 들어보자.

예 4.2

$X_1, X_2, \cdots, X_n$ 을 $N(\mu, \sigma^2)$으로부터 얻은 랜덤표본이라고 할 때, μ와 σ^2을 적률을 사용하는 방법으로 추정해 보자. 추정할 모수가 두 개이므로 1, 2차 표본적률을

구하여 1, 2차 모적률과 같다고 놓는다. 즉,

$$m_1' = \frac{\sum_{i=1}^{n} X_i}{n}$$
$$= \mu_1'(\mu, \sigma^2) = \mu$$
$$m_2' = \frac{\sum_{i=1}^{n} X_i^2}{n}$$
$$= \mu_2'(\mu, \sigma^2) = \sigma^2 + \mu^2$$

의 연립방정식을 풀면 다음과 같은 추정량을 구할 수 있다.

$$\hat{\mu} = \frac{\sum_{i=1}^{n} X_i}{n}$$
$$\hat{\sigma}^2 = m'_2 - (\hat{\mu})^2 = \sum_{i=1}^{n} \frac{X_i^2}{n} - (\sum_{i=1}^{n} \frac{X_i}{n})^2$$
$$= \frac{1}{n}(\sum_{i=1}^{n} X_i^2 - n(\overline{X}_n)^2) = \frac{\sum_{i=1}^{n} (X_i - \overline{X}_n)^2}{n}.$$

예 4.3

$X_1, X_2, \cdots, X_n$ 을 GAM(k, θ)로부터 얻은 랜덤표본이라고 하자. 1, 2차 표본적률과 모수벡터 (k, θ)에 대한 두 개의 방정식

$$m_1' = \frac{\sum_{i=1}^{n} X_i}{n}$$
$$= \mu_1'(k, \theta) = k\theta$$
$$m_2' = \frac{\sum_{i=1}^{n} X_i^2}{n}$$
$$= \mu_2'(k, \theta) = k\theta^2 + k^2\theta^2$$

을 풀면, (k, θ)에 대한 추정량

$$\hat{\theta} = (\frac{\sum_{i=1}^{n} X_i^2}{n} - \overline{X}_n^2)/\overline{X}_n = \frac{\sum_{i=1}^{n}(X_i - \overline{X}_n)^2}{n\overline{X}_n},$$

$$\hat{k} = \frac{\overline{X}_n}{\hat{\theta}} = \frac{n(\overline{X}_n)^2}{\sum_{i=1}^{n}(X_i - \overline{X}_n)^2}$$

을 구할 수 있다.

이와 같이 적률을 사용하여 추정량을 구하는 방법은 비교적 그 과정이 간단하나 때로는 유일하지 않은 경우도 있다(연습문제 4.3 참조).

4.2 최대가능도 추정법

성공률이 p인 베르누이 분포에서 크기가 10인 랜덤표본을 뽑는다고 가정해 보자. 또, 이 분포의 성공률은 0.1이거나 0.9 둘 중에 하나라는 것을 알고 있으며, 관측된 표본을 통해 성공률을 추정하려고 한다고 가정하자. 만약 10개의 관측치의 합이 8이었다면 성공률을 0.1이라고 하는 것이 좋을까, 아니면 0.9라고 하는 것이 좋을까? 이 경우 성공률을 0.9로 추정하는 데에 별다른 이견이 없을 것이다. 그렇다면 우리는 왜 0.9를 0.1보다 선호하게 된 것일까? 아마도 0.9가 참일 경우 합이 8인 관측치를 얻을 확률이 0.1이 참일 경우보다 높기 때문일 것이다. 이러한 생각이 가능도원리를 사용하는 최대가능도 추정법의 간단한 예라고 할 수 있다.

확률변수 $X_1, X_2, \cdots, X_n$의 결합 확률밀도함수가 $f(x_1, x_2, \cdots, x_n ; \theta)$라고 하자. 결합 확률밀도함수 $f(x_1, x_2, \cdots, x_n ; \theta)$는 고정된 모수 θ에 대하여 $(x_1, x_2, \cdots, x_n)$의 함수로 사용된다. 그러나 반대로 $f(x_1, x_2, \cdots, x_n ; \theta)$를 관측치 $X_1 = x_1, X_2 = x_2, \cdots, X_n = x_n$이 주어졌을 때 모수 $\theta(\in \Omega)$의 함수로 생각해 볼 수도 있다. 즉, 다음과 같이

$$L(\theta) = L(\theta ; x_1, x_2, \cdots, x_n) = f(x_1, x_2, \cdots, x_n ; \theta)$$

로 표기하고 이를 $X_1, X_2, \cdots, X_n$의 **가능도함수**(likelihood function)라고 한다. 다

시 말하면, 가능도함수 $L(\theta)$는 주어진 자료 $(x_1, x_2, \cdots, x_n)$에 대하여, $(x_1, x_2, \cdots, x_n)$이 얻어질 가능성을 모수 θ에 대한 함수로 나타낸 것이라고 할 수 있다. 특정한 θ의 값과 $x_1, \cdots, x_n$이 주어진 상태에서 확률밀도함수와 가능도함수는 같은 함수값을 갖는다. 그러나 예를 들어 $y = x^2 + z$를 $f(x) = x^2 + z$와 같이 x의 함수로 볼 수도 있고, $g(z) = x^2 + z$처럼 z의 함수로 볼 수도 있지만 $f(x)$와 $g(z)$는 다른 함수이듯이, 가능도함수와 확률밀도함수는 함수로서는 서로 다르며, 특히 가능도함수는 θ의 함수이므로 확률밀도함수가 아니라는 점을 유의하자.

이제 확률변수 $X_1, X_2, \cdots, X_n$이 서로 독립적이고 X_i가 확률밀도함수 $f_i(x_i ; \theta)$를 갖는다고 하면, $X_1, X_2, \cdots, X_n$의 결합 확률밀도함수는

$$\prod_{i=1}^{n} f_i(x_i ; \theta) = f_1(x_1 ; \theta) f_2(x_2 ; \theta) \cdots f_n(x_n ; \theta)$$

이며, 가능도함수는

$$\begin{aligned} L(\theta ; x_1, x_2, \cdots, x_n) &= \prod_{i=1}^{n} f_i(x_i ; \theta) \\ &= f_1(x_1 ; \theta) f_2(x_2 ; \theta) \cdots f_n(x_n ; \theta) \end{aligned}$$

로 나타내어진다. 따라서 $X_1, X_2, \cdots, X_n$이 확률밀도함수 $f(x ; \theta)$로부터의 랜덤표본이라고 하면 $f_i(x_i;\theta) = f(x_i;\theta)$ 이므로, 가능도함수는

$$L(\theta ; x_1, x_2, \cdots, x_n) = \prod_{i=1}^{n} f(x_i ; \theta) \tag{4.3}$$

가 된다. 이제 모수를 추정하는 방법으로 가능도함수를 최대화하는 통계량에 대한 정의는 다음과 같다.

정의 4.2

랜덤표본의 가능도함수 $L(\theta ; x_1, x_2, \cdots, x_n)$을 최대화하는 θ의 값을 $\hat{\theta} = \hat{\theta}(x_1, x_2, \cdots, x_n) \in \Omega$라고 할 때, $\hat{\theta} = \hat{\theta}(X_1, X_2, \cdots, X_n)$을 모수 θ의 **최대가능도 추정량**(maximum likelihood estimator)이라고 한다.

이러한 최대가능도 추정량의 의미는 '실제로 관측된' 자료가 얻어질 확률을 가장 높게

만드는(즉, 주어진 관측값을 가장 잘 설명하는) θ의 값을 모수 θ의 추정량으로 삼는 것이다. 이제, 몇 개의 예들을 살펴봄으로써 그 의미를 분명히 하자.

예 4.4

$X_1, X_2, \cdots, X_5$가 서로 독립인 베르누이(p) 확률변수라고 하자. 이때 $Y=\sum_{i=1}^{5} X_i$는 $B(5, p)$ 분포를 따르며, Y의 확률밀도함수는 몇 가지 다른 p에 대해서 다음과 같이 주어진다.

Y \ p	0.1	0.2	0.3	0.4	0.5	0.6	0.7	0.8	0.9	1.0
0	0.59050	0.32768	0.16807	0.07776	0.03125	0.01024	0.00243	0.00032	0.00005	0.0
1	0.32800	0.40960	0.36015	0.25920	0.15625	0.07680	0.02835	0.00640	0.00045	0.0
2	0.07290	0.20480	0.30870	0.34560	0.31250	0.23040	0.13230	0.05120	0.00810	0.0
3	0.00810	0.05120	0.13230	0.23040	0.31250	0.34560	0.30870	0.20480	0.07290	0.0
4	0.00045	0.00640	0.02835	0.07680	0.15625	0.25920	0.36015	0.40960	0.32800	0.0
5	0.00005	0.00032	0.00243	0.01024	0.03125	0.07776	0.16807	0.32768	0.59050	1.0

그런데 가능도함수는 $Y=y$로 주어졌을 때 모수 p에 대한 함수이므로 위의 표를 가로로 읽어서 구할 수 있다. 가령 $Y=3$이 주어지면, 위 가능도함수표에서 $Y=3$인 행을 살펴보아 $p=0.6$에서 가능도가 0.34560으로 최대가 되는 것을 알 수 있다. 따라서 최대가능도 추정값은 0.6이다. 반면, $Y=1$이라면 0.2가 최대가능도 추정값이 된다. 두 경우를 비교해 보면, p가 성공률이므로 Y의 값이 1보다는 3으로 클 때 p도 클 것이라고 추측하는 것이 합리적이다. 물론 p에 대하여 0과 1 사이의 모든 값을 고려하여야 하나 편의상 생략하였다.

그런데 가능도함수 $L(\theta\,; x_1, x_2, \cdots, x_n)$을 최대화하는 θ의 값을 찾는 문제는 로그가능도함수

$$\log L(\theta\,; x_1, x_2, \cdots, x_n) = \log \prod_{i=1}^{n} f_i(x_i\,; \theta) \qquad (4.4)$$
$$= \sum_{i=1}^{n} \log f_i(x_i\,; \theta)$$

를 최대화하는 θ를 찾는 것과 같다. 왜냐하면, 로그함수가 단조증가함수이므로 $L(\theta)$

를 최대로 만드는 θ의 값에서 $\log L(\theta)$도 최대가 되고, 그 반대도 성립하기 때문이다. 뿐만 아니라, 랜덤표본의 가능도함수는 주변 확률밀도함수의 곱으로 표현되는데, 여기에 로그를 취하면 각 주변 확률밀도함수에 로그를 취한 것의 합이 되므로 미분을 통해 최댓값을 찾는 계산이 훨씬 쉬워질 수 있다. 이런 이유로, 최대가능도 추정량을 찾을 때 로그가능도함수를 많이 이용한다. 또한, 많은 경우에 로그가능도함수를 최대화하는 문제는

$$\frac{d}{d\theta}\log L(\theta\,;x_1,\,x_2,\,\cdots,\,x_n)=0$$

의 해를 구하는 문제로 귀착된다(물론 위의 식을 만족하는 값이 곧 로그가능도함수를 최대화한다는 보장은 없으며, 엄밀한 의미에서의 최대화 여부를 2차 미분 등을 통해서 가려야 한다). 참고로, 우리가 사용하는 log는 다른 설명이 없는 한 자연로그이다.

예 4.5

$X_1,\,X_2,\,\cdots,\,X_n$을 $\mathrm{EXP}(\theta)$에서 추출된 랜덤표본이라고 할 때, θ의 최대가능도 추정량을 구해 보자. 이 표본의 가능도함수는 $x_i>0,\ i=1,\cdots,n$일 때

$$\begin{aligned}L(\theta;x_1,\,x_2,\,\cdots,\,x_n)&=\prod_{i=1}^{n}f(x_i;\theta)\\&=(\frac{1}{\theta})^n\exp(-\sum_{i=1}^{n}x_i/\theta)\end{aligned}$$

가 되며, 로그가능도함수는

$$\log L(\theta\,;x_1,\,x_2,\,\cdots,\,x_n)=-n\log\theta-\sum_{i=1}^{n}x_i/\theta$$

가 된다. 이를 θ에 대해 미분하면 $\frac{d}{d\theta}\log L(\theta)=-\frac{n}{\theta}+\sum_{i=1}^{n}x_i/\theta^2$이고, 이를 0으로 만드는 θ의 값은 $\overline{x}_n$이다. $\theta=\overline{x}_n$일 때의 이차 미분값은 0보다 작으므로 이 값에서 로그가능도함수가 최대가 된다. 즉, θ의 최대가능도 추정량은 $\overline{X}_n$이다.

예 4.6

$X_1,\,X_2,\,\cdots,\,X_n$을 포아송(λ) 분포로부터 구한 랜덤표본이라고 하자. 이때 가능도함

수는

$$L(\lambda\,;x_1,\,x_2,\,\cdots,\,x_n)=\prod_{i=1}^{n}f(x_i\,;\lambda)$$
$$=\frac{\exp(-n\lambda)\lambda^{\Sigma x_i}}{\prod_{i=1}^{n}x_i!}$$

이며, 따라서 로그가능도함수는

$$\log L(\lambda\,;x_1,\,x_2,\,\cdots,\,x_n)=-n\lambda+\sum_{i=1}^{n}x_i\log\lambda-\log\left(\prod_{i=1}^{n}x_i!\right)$$

이다. 그런데,

$$\frac{d}{d\lambda}\log L(\lambda\,;x_1,\,x_2,\,\cdots,\,x_n)=-n+\sum_{i=1}^{n}\frac{x_i}{\lambda}=0$$

을 만족하는 $\hat{\lambda}=\bar{x}_n$은

$$\frac{d^2}{d\lambda^2}\log L(\lambda\,;x_1,\,x_2,\,\cdots,\,x_n)|_{\lambda=\bar{x}_n}=-\sum_{i=1}^{n}\frac{x_i}{\lambda^2}|_{\lambda=\bar{x}_n}=-\frac{n}{\bar{x}_n}<0$$

을 만족시키므로($\bar{x}_n>0$을 가정) 가능도함수를 최대화하는 최대가능도 추정량은 $\bar{X}_n$이다($\bar{x}_n=0$의 경우는 예 4.10 참조).

주 경우에 따라서 2차 미분을 확인하지 않아도 극값에서 가능도함수가 최대가 됨이 쉽게 보여질 수 있다. 위의 포아송 예제에서 $\lambda\to0$에서 $\log L(\theta)\to-\infty$이고, $\lambda\to\infty$에서 $\log L(\theta)\to-\infty$이면서 극값은 단 하나만 존재하므로 그 극값이 함수를 최대로 만드는 값일 수밖에 없음을 알 수 있다.

그런데 정의 4.2는 모수가 두 개 이상인 벡터 $\theta=(\theta_1,\,\theta_2,\cdots,\,\theta_k)$로 표현되는 경우에도 성립한다. 이러한 경우, k개의 연립방정식

$$\frac{d}{d\theta_i}\log L(\theta_1,\,\theta_2,\cdots,\,\theta_k)=0,\;\;i=1,\;2,\;\cdots,\;k$$

을 풀어서 구한 해가 로그가능도함수를 최대화하는지의 여부를 가려 최대가능도 추정

량 $(\hat{\theta}_1, \hat{\theta}_2, \cdots, \hat{\theta}_k)$을 구할 수 있다.

예 4.7

$X_1, X_2, \cdots, X_n$을 $N(\mu, \sigma^2)$으로부터 얻은 랜덤표본이라고 하자. 이때 가능도함수는

$$L(\mu, \sigma^2 ; x_1, x_2, \cdots, x_n) = \prod_{i=1}^{n} f(x_i ; \mu, \sigma^2)$$
$$= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left[-\sum_{i=1}^{n} (x_i - \mu)^2 / 2\sigma^2 \right]$$

이며, 따라서 로그가능도함수는

$$\log L(\mu, \sigma^2 ; x_1, x_2, \cdots, x_n) = -(n/2)\log(2\pi\sigma^2) - \sum_{i=1}^{n} (x_i - \mu)^2 / 2\sigma^2$$

이다. 이 로그가능도함수를 최대화하는 (μ, σ^2)값은

$$\frac{d}{d\mu} \log L(\mu, \sigma^2 ; x_1, x_2, \cdots, x_n) = \sum_{i=1}^{n} \frac{(x_i - \mu)}{\sigma^2} = 0$$

$$\frac{d}{d\sigma^2} \log L(\mu, \sigma^2 ; x_1, x_2, \cdots, x_n) = -\frac{n}{2\sigma^2} + \frac{\sum_{i=1}^{n} (x_i - \mu)^2}{2\sigma^4} = 0$$

의 두 연립방정식의 해를 구하고, 이들이 로그가능도함수를 최대화함을 2차 미분을 사용하여 확인함으로써 구할 수 있다. 이렇게 구한 최대가능도 추정량은

$$(\hat{\mu}, \hat{\sigma}^2) = \left(\overline{X}_n, \sum_{i=1}^{n} (X_i - \overline{X}_n)^2 / n \right)$$

이 된다. 로그가능도함수의 2차 미분은 2×2 행렬이 되므로 이 행렬이 주어진 극값에서 음정치행렬인지 확인하여 함수가 최댓값을 가지는지 확인할 수 있지만, 다음과 같은 방법을 사용할 수도 있다. $\sum_{i=1}^{n} (x_i - \mu)^2 = \sum_{i=1}^{n} (x_i - \overline{x}_n)^2 + n(\overline{x}_n - \mu)^2$이므로, $\mu \neq \overline{x}_n$라면 $\sum_{i=1}^{n} (x_i - \mu)^2 > \sum_{i=1}^{n} (x_i - \overline{x}_n)^2$가 된다. 그러므로 임의의 σ^2의 값에서 $\log L(\mu, \sigma^2)$가 $\hat{\mu} = \overline{x}_n$에서 최대화됨을 알 수 있다. μ를 $\overline{x}_n$으로 치환하고 나면

$\log L(\bar{x}_n, \sigma^2)$는 $n^{-1}\sum_{i=1}^{n}(x_i - \bar{x}_n)^2$에서 최대가 된다. 그러므로 $(\hat{\mu}, \hat{\sigma}^2)$에서 로그가능도함수가 최대가 된다.

예 4.8

$X_1, X_2, \cdots, X_n$을 로지스틱 분포로부터 얻은 랜덤표본이라고 하자. 로지스틱 확률밀도함수는 $f(x;\theta) = \dfrac{\exp\{-(x-\theta)\}}{(1+\exp\{-(x-\theta)\})^2}$, $-\infty < x < \infty$, $-\infty < \theta < \infty$ 이므로 로그가능도함수는

$$\log L(\theta) = \sum_{i=1}^{n} \log f(x_i;\theta) = n\theta - n\bar{x}_n - 2\sum_{i=1}^{n} \log(1+\exp(-(x_i-\theta)))$$

가 된다. $\dfrac{d}{d\theta}\log L(\theta) = n - 2\sum_{i=1}^{n}\dfrac{\exp(-(x_i-\theta))}{1+\exp(-(x_i-\theta))} = 0$의 해는 간단한 폐쇄형이 존재하지 않으나, $\dfrac{d}{d\theta}\log L(\theta)$이 θ에 대해 단조감소하며($\dfrac{d^2}{d\theta^2}\log L(\theta) < 0$) θ가 $-\infty$로 갈 때 n으로 그리고 θ가 $+\infty$로 갈 때 $-n$으로 접근하므로 유일해를 가진다는 것을 알 수 있다. 그리고 이 해는 수치적 방법을 통해 구할 수 있다.

가능도함수가 미분 가능하면 위의 예제들에서와 같은 방법으로 최대가능도 추정량을 구할 수 있으나, 가능도함수가 언제나 미분 가능한 것은 아니며, 따라서 최대가능도 추정량이 언제나 가능도함수의 미분과정을 통해서만 구해지는 것은 아니다. 다음의 예를 살펴보자.

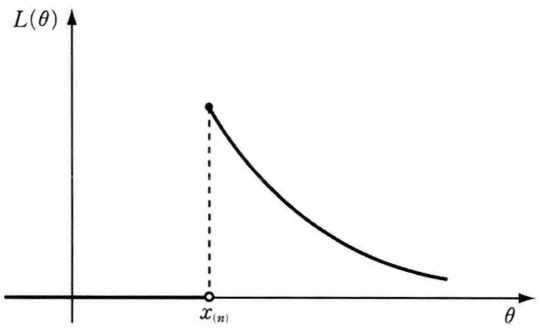
예 4.9

$X_1, X_2, \cdots, X_n$을 $U(0, \theta)$로부터 얻은 랜덤표본이라고 하자. 이때 가능도함수는

$$L(\theta\,;x_1, x_2, \cdots, x_n) = \prod_{i=1}^{n} f(x_i;\theta)$$
$$= \begin{cases} \dfrac{1}{\theta^n}, & 0 \le x_i \le \theta \text{인 경우} \\ 0, & \text{그 외의 경우} \end{cases}$$

이 되며, 모든 θ에 대해 연속이 아니므로 모수 θ에 대하여 미분 가능하지 않다. 이 경우, 미분을 하는 대신 가능도함수의 형태를 살펴보면 쉽게 최대가능도 추정량을 구

할 수 있다.



이제 최대가능도 추정량이 표본최댓값 $X_{(n)}$인 것은 위 그래프로부터 자명하다.

또한, 최대가능도 추정량이 언제나 존재한다는 보장은 없으며 유일하지 않을 수도 있다.

예 4.10

$X_1, X_2, \cdots, X_n$을 $\lambda > 0$인 포아송(λ) 분포로부터 구한 랜덤표본이라고 하자. 예 4.6에서

$$\frac{d}{d\lambda} \log L(\lambda\,; x_1, x_2, \cdots, x_n) = -n + \sum_{i=1}^{n} \frac{x_i}{\lambda} = 0$$

이고, $\bar{x}_n > 0$일 때 λ의 최대가능도 추정량이 $\bar{X}_n$임을 보였다. 그런데 랜덤표본에서 얻은 관측치 $\bar{x}_n$의 값이 공교롭게도 0이었다고 하자. 이 경우 로그가능도함수의 1차 미분은 항상 음의 값을 가지게 되는데, λ값의 범위는 개구간이므로 최대가능도 추정량은 존재하지 않는다.

예 4.11

$X_1, X_2, \cdots, X_n$을 $U[\theta - 1, \theta + 1]$로부터 얻은 랜덤표본이라고 하자. 이때 가능도함수는

$$L(\theta\,;x_1,x_2,\cdots,x_n)=\prod_{i=1}^{n}\frac{1}{2}I_{[\theta-1,\theta+1]}(x_i)=2^{-n}I_{[\theta-1\le x_{(1)},x_{(n)}\le\theta+1]}$$
$$=2^{-n}I_{[x_{(n)}-1,x_{(1)}+1]}(\theta)$$

이 되고, 이 함수는 구간 $[x_{(n)}-1,x_{(1)}+1]$의 모든 점에서 최댓값 2^{-n}을 가지므로 구간 $[X_{(n)}-1,X_{(1)}+1]$ 내의 모든 점이 최대가능도 추정량이 된다. 즉, 최대가능도 추정량이 유일하지 않다.

예 4.12

3가지 타입의 개체들로 구성된 모집단에서 크기가 n인 랜덤표본을 추출했을 때, 다음의 Hardy-Weinberg 모형을 고려하자.

$$(N_1,N_2,N_3)\sim \mathrm{MULT}(n,p_1,p_2,p_3).$$

여기에서 $p_1=\theta^2$, $p_2=2\theta(1-\theta)$, $p_3=(1-\theta)^2$, $0<\theta<1$이다. 이때, θ의 최대가능도 추정량을 구해 보자. $N_1=n_1$, $N_2=n_2$, $N_3=n_3$이 주어졌을 때 이 랜덤표본의 가능도함수는

$$L(\theta)=\frac{n!}{n_1!n_2!n_3!}\theta^{2n_1}(2\theta(1-\theta))^{n_2}(1-\theta)^{2n_3}$$

이 되며, 로그가능도함수는

$$\log L(\theta)=\log\frac{n!}{n_1!\,n_2!\,n_3!}+2n_1\log\theta+n_2\log 2\theta+n_2\log(1-\theta)+2n_3\log(1-\theta)$$

가 된다. 이를 미분하면,

$$\frac{d}{d\theta}\log L(\theta)=\frac{2n_1}{\theta}+\frac{n_2}{\theta}-\frac{n_2}{1-\theta}-\frac{2n_3}{1-\theta}$$

이고 $n_1\neq n$이고 $n_3\neq n$인 경우 이 1차 미분은 $\theta=\dfrac{2n_1+n_2}{2n}$에서 0의 값을 가진다. 2차 미분이 $\dfrac{d^2}{d\theta^2}\log L(\theta)=-\dfrac{2n_1+n_2}{\theta^2}-\dfrac{n_2+2n_3}{(1-\theta)^2}<0$이므로, θ의 최대가능도 추정량은 $n_1\neq n$이고 $n_3\neq n$일 때, $\hat{\theta}=\dfrac{2N_1+N_2}{2n}$이 된다. (단, $n=N_1+N_2+N_3$이다.)

최대가능도 추정량의 불변성

최대가능도 추정량의 장점 중의 하나는, 다음의 정리에서 나타나는 불변성 원리(invariance property)이다. θ를 추정하는 어떤 추정량이 $T(X)$일 때 θ^2의 추정량이 $T(X)^2$이 되고, $\theta+c$(c는 상수)의 추정량이 $T(X)+c$가 되는 등, θ의 함수 $g(\theta)$의 추정량이 $g(T(X))$가 되는 성질을 불변성 원리라고 한다. 이는 상당히 논리적이고 직관적인 성질로서, 최대가능도 추정량의 경우 이 원리가 성립하기 때문에 θ의 추정량을 얻고 나면 다른 어떤 함수 $g(\theta)$에 대해서도 다시 복잡한 계산을 거치지 않고 쉽게 추정량을 구할 수 있다. 최대가능도 추정량을 얻기 위해서는 일반적으로 미분의 과정을 거쳐야 하므로, 미분을 쉽게 만드는 모수를 선택하여 추정량을 구한 다음, 다른 형태의 모수에 대한 추정량은 불변성 원리를 이용하여 구하면 된다. 예를 들어 정규분포에서 얻어진 랜덤표본으로 표준편차 σ의 최대가능도 추정량을 구할 때, σ^2을 모수로 두는 것이 미분이 좀 더 쉽다고 한다면 σ^2의 최대가능도 추정량을 먼저 구하고, 여기에 제곱근을 취하여 σ의 최대가능도 추정량을 구할 수 있다.

정리 4.1

(최대가능도 추정량의 불변성) $X_1, \cdots, X_n$을 확률밀도함수 $f(x;\theta)$, $\theta \in \Omega$를 갖는 분포에서 얻은 랜덤표본이라고 하자. $\hat{\theta}_n$이 모수 θ의 최대가능도 추정량이면, θ의 함수인 $g(\theta)$에 대하여, $g(\hat{\theta}_n)$이 $g(\theta)$의 최대가능도 추정량이 된다.

증명 $\eta = g(\theta)$ 라고 놓자. 불변성 원리는 일반적인 함수 g에 대해 성립하나, 여기에서는 증명의 편의를 위하여 g를 일대일 함수라고 가정하도록 하자. θ를 모수로 하는 표본의 가능도함수를 $L(\theta)$라고 하고 η를 모수로 하는 표본의 가능도함수를 $L^*(\eta)$라고 하자. 그러면,

$$L^*(g(\theta)) = L^*(\eta) = \prod_{i=1}^{n} f(x_i; g^{-1}(\eta)) = L(g^{-1}(\eta)) = L(\theta)$$

이고,

$$\max_{\eta \in g(\Omega)} L^*(\eta) = \max_{\eta \in g(\Omega)} L(g^{-1}(\eta)) = \max_{\theta \in \Omega} L(\theta)$$

이므로

$$L^*(\hat{\eta}) = \max_{\eta \in g(\Omega)} L^*(\eta) = \max_{\theta \in \Omega} L(\theta) = L(\hat{\theta}_n) = L^*(g(\hat{\theta}_n))$$

이 되어, $\hat{\eta} = g(\hat{\theta}_n)$이다. ■

예 4.13

앞의 예 4.7에서 σ^2의 최대가능도 추정량으로 $\widehat{\sigma^2} = \sum_{i=1}^{n} (X_i - \overline{X}_n)^2/n$을 구하였다. 이제, $g(\sigma^2) = \sigma$의 최대가능도 추정량은 불변성에 의하여 $g(\widehat{\sigma^2}) = \hat{\sigma}$가 된다.

예 4.14

$X_1, X_2, \cdots, X_n$을 EXP(λ)로부터 얻은 랜덤표본이라고 하자. 이때 로그가능도함수는

$$\log L(\lambda\,;\, x_1, x_2, \cdots, x_n) = -n \log \lambda - \sum_{i=1}^{n} x_i/\lambda$$

가 되며, 따라서

$$\frac{d}{d\lambda} \log L(\lambda\,;\, x_1, x_2, \cdots, x_n) = -n/\lambda + \sum_{i=1}^{n} x_i/\lambda^2 = 0$$

으로부터 최대가능도 추정량 $\hat{\lambda} = \overline{X}_n$를 얻게 된다. 만약 이 분포에서 나온 확률변수가 1보다 클 확률을 추정하는 데에 관심이 있다면, $g(\lambda) = P(X \geq 1) = \exp(-1/\lambda)$에 대한 추정량이 필요하고, 이것의 최대가능도 추정량은 불변성에 의하여 $g(\hat{\lambda}) = \exp(-1/\overline{X}_n)$ 이 된다.

주 최대가능도 추정량의 불변성은 모수가 2개 이상인 경우로도 확장 가능하여, $\hat{\theta} = (\hat{\theta}_1, \hat{\theta}_2, \cdots, \hat{\theta}_k)$가 모수벡터 $\theta = (\theta_1, \theta_2, \cdots, \theta_k)$의 최대가능도 추정량이면, $g(\hat{\theta}_1, \hat{\theta}_2, \cdots, \hat{\theta}_k)$도 $g(\theta_1, \theta_2, \cdots, \theta_k)$의 최대가능도 추정량이 된다.

4.3 추정의 기준

추정의 기준을 다룸에 있어서, 표본의 함수인 추정량이 확률변수임을 재차 확인할 필요가 있다. 어떤 확률변수도 상응하는 확률분포를 가지므로 추정량도 그의 확률분포가 있고, 확률분포를 살피는 것은 추정량의 성격을 파악하는 데 도움이 된다. 아래의 예를 보자.

예 4.15

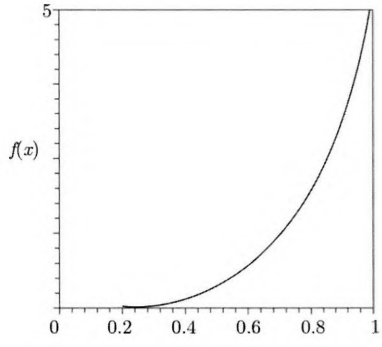
$X_1, X_2, \cdots, X_n$을 $U(0, \theta)$로부터 얻은 랜덤표본이라고 하자. 이때 모수 θ의 최대가능도 추정량은 표본최댓값 $X_{(n)}$이다(참조: 예 4.9). 추정량 $X_{(n)}$의 확률밀도함수는 $\theta = 1$, $n = 5$인 경우

$$\begin{aligned} F_{X_{(5)}}(x) &= P(X_{(5)} \le x) \\ &= P(X_1 \le x, X_2 \le x, \cdots, X_5 \le x) \\ &= \{P(X \le x)\}^5 \\ &= \{F_X(x)\}^5 \\ &= x^5, \quad 0 < x < 1 \end{aligned}$$

이므로,

$$f(x) = 5x^4 \quad (0 < x < 1)$$

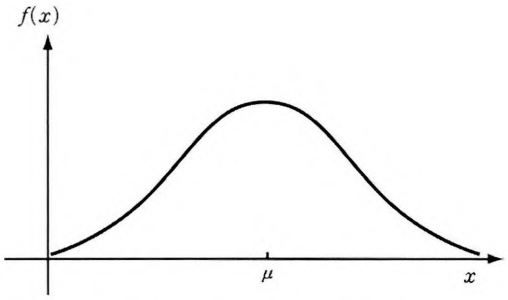
로서 다음 그림과 같이 주어진다. 두 번째 등식은 표본최댓값이 x보다 작으면 모든 관측값들이 x보다 작아야 하고, 모든 관측값들이 x보다 작으면 표본최댓값도 x보다 작다는 성질을 이용하여 얻는다.



▸ **그림 4.1** ◂ 추정량 $X_{(n)}$의 확률밀도함수

예 4.16

$X_1, X_2, \cdots, X_n$을 $N(\mu, \sigma^2)$으로부터 얻은 랜덤표본이라고 하자. 모평균 μ를 표본평균 $\overline{X}_n$로 추정할 때 추정량 $\overline{X}_n$의 확률분포는 모수(모평균)에 중심을 둔 $N(\mu, \sigma^2/n)$ 분포를 따른다. 즉, 추정량 $\overline{X}_n$의 확률밀도함수는 다음 그림과 같이 주어진다.



▸ **그림 4.2** ◂ 추정량 $\overline{X}_n$의 확률밀도함수

위의 두 예에서 보면, 예 4.15에서는 최대가능도 추정량 $X_{(n)}$이 모수 $\theta = 1$의 근방에 있을 확률은 높지만 $\theta = 1$에 대하여 비대칭적인 분포를 갖고 있는 반면에 예 4.16에서는 추정량 $\overline{X}_n$이 모수 μ에 대해 대칭이며, 또한 그 근방에 있을 확률이 높다는 것을 알 수 있다.

모수의 함수인 $g(\theta)$의 추정에서(물론 $g(\theta) = \theta$인 경우를 포함), 우리가 원하는 바는 추정량 $T(X) = T(X_1, X_2, \cdots, X_n)$이 추정하고자 하는 $g(\theta)$에 '가까운' 것이다. 추정량이 언제나 추정대상인 $g(\theta)$와 같은 값을 가진다면 제일 좋겠지만, 추정량은 확률변수로서 표본에 따라 값이 달라지므로 언제나 $g(\theta)$의 값을 가질 수는 없다. 대신 추정량이 $g(\theta)$에 가까운 값을 제공한다면 그것으로 훌륭한 추정량이라고 할 것이다. 그렇다면 "가깝다"라는 것을 어떻게 정의할 수 있을까? 이것은 사용하는 기준(criterion)에 따라 다르게 결정될 것이다. 몇 가지 가능한 기준의 예로는

1. 절대오차(absolute error)

$$| T(X) - g(\theta) |,$$

2. 제곱오차(squared error)

$$(T(X)-g(\theta))^2,$$

또는

3. $w(\theta)$로 가중값을 준 가중제곱오차(weighted squared error)

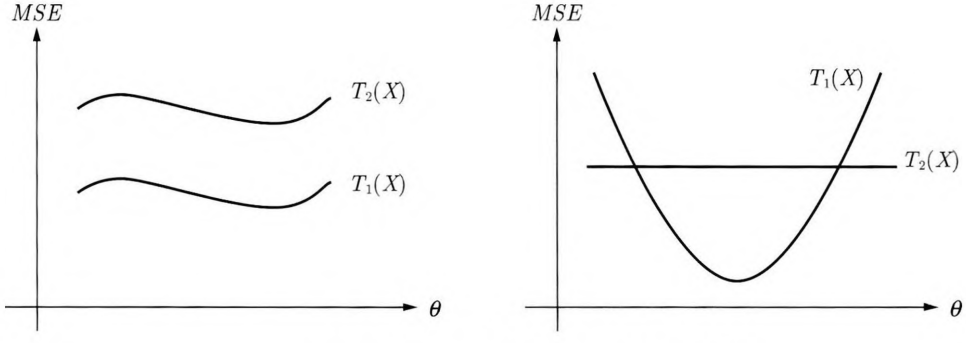
$$(T(X)-g(\theta))^2 w(\theta)$$

등을 들 수 있는데, 이들을 흔히 **손실함수**(loss function)라고 한다. 그러나 위의 손실함수들은 확률변수이기 때문에 이들을 최소화하는 추정량 $T(X)$를 찾아내는 것은 불가능하며, 따라서 위 손실함수의 기댓값(long term average)을 기준으로 삼는다. 일반적으로, 제곱오차의 기댓값인 **평균제곱오차**(Mean Square Error, MSE)

$$MSE = E(T(X)-g(\theta))^2 \tag{4.5}$$

이 추정의 기준으로 많이 사용되며, 여기에서도 이 MSE를 기준으로 삼도록 한다. 이 기준하에서 우리가 원하는 추정량은 평균제곱오차를 최소화하는 $T(X)$가 된다.

그런데 평균제곱오차는 모수 θ에 대한 함수이기 때문에 이를 최소화하는 추정량을 찾는 것이 항상 가능하지는 않다. 다음 그림을 보자. $g(\theta)$에 대한 두 개의 추정량 $T_1(X)$와 $T_2(X)$에 대한 평균제곱오차를 구하였을 때, 그림 4.3의 첫 번째 경우에서는



▸ **그림 4.3** ◂ 두 추정량의 평균제곱오차(MSE) 비교

$T_1(X)$의 평균제곱오차가 $T_2(X)$의 그것보다 모든 θ값에 대하여 작으므로 우리는 $T_1(X)$를 선호하게 되지만, 두 번째 경우에서는 θ의 값에 따라 평균제곱오차를 작게 만드는 추정량이 달라져 어떤 추정량을 사용해야 할지 명확하지 않게 된다. 이와 같이 평균제곱오차를 모든 $\theta \in \Omega$에 대하여 균일하게 최소화하는 추정량 $T(X)$는 일반적으로 존재하지 않는다. 예를 들어, θ를 추정하기 위한 어떤 추정량이 $T(X) \equiv \theta_0$(어떤

정해진 상수)이라고 하자. 즉, 표본에서 어떤 값을 관측하든 추정값을 θ_0으로 하겠다는 뜻이다. 만약 미지의 모수값이 실제로 θ_0이라면, 이 추정량의 평균제곱오차는 0이 되며, $\theta = \theta_0$에서 이것보다 더 작은 평균제곱오차를 갖는 추정량은 없다. 그러나 이러한 표본과 무관한 추정방법은 θ가 θ_0로부터 멀리 떨어져 있을수록 평균제곱오차를 크게 만들 것이며 매우 비과학적이고 비상식적인 방법이 된다. 따라서 이러한 비과학적인 추정량들을 고려대상에서 제외하는 것이 합리적일 것이다. 이런 편협된 부적절한 추정량들을 제외하는 하나의 방법으로 아래에 정의된 비편향추정량(unbiased estimator)들의 집합을 고려하고, 그 안에서 평균제곱오차를 최소화하는 추정방법을 찾을 수 있다. 자세한 방법은 다음 절에서 다루어진다.

정의 4.3

$T(X)$를 $g(\theta)$의 추정량이라고 할 때, $E[T(X)] - g(\theta)$를 $T(X)$의 **편향**(bias)이라고 하며 $E[T(X)] = g(\theta)$(즉 편향 $= 0$)이면 $T(X)$를 $g(\theta)$의 **비편향추정량**이라고 한다. 추정량 $T(X)$의 분산은 $E[T(X) - E[T(X)]]^2$이다.

즉, 비편향추정량은 그 기댓값이 추정하고자 하는 모수와 같기 때문에, 추정대상을 과대추정하거나 과소추정하는 경향이 없이 평균적으로 목표치를 잘 맞추고 있다는 뜻이 된다.

예 4.17

$X_1, X_2, \cdots, X_{10}$을 $N(\mu, \sigma_0^2)$ (σ_0^2은 알려진 값)으로부터 얻은 랜덤표본이라 할 때, $T_1(X) = \overline{X}_{10}$와 $T_2(X) = (X_1 + X_2)/2$는 $E[T_1(X)] = E[T_2(X)] = \mu$이므로 모두 모평균 μ의 비편향추정량이다.

예 4.18

앞의 예 4.9에서 고려한, $U(0, \theta)$에서의 θ의 추정량 $X_{(n)}$에 대해 생각해 보자. 이 분포에서 나오는 X의 값은 모두 0에서 θ 사이에 있으므로 표본최댓값 $X_{(n)}$도 θ보다 클 수 없다. θ보다 작을 수는 있으나 클 수는 없으므로 그 기댓값은 당연히 θ보다 작게 된다. 즉, 표본최댓값은 비편향추정량이 아니다. 표본최댓값의 기댓값은

$$E(X_{(n)}) = \int_0^\theta t \frac{nt^{n-1}}{\theta^n} dt$$

$$= \frac{nt^{n+1}}{(n+1)\theta^n}\Big|_0^\theta$$

$$= \frac{n}{n+1}\theta$$

으로 예상한 바와 같이 θ보다 작다. 따라서,

$$T_1(X) = \left(\frac{n+1}{n}\right) X_{(n)}$$

이라고 하면

$$E(T_1(X)) = \frac{n+1}{n} \cdot \frac{n}{n+1} \cdot \theta = \theta$$

이므로 $T_1(X)$은 θ의 비편향추정량이다.

그런데 추정의 기준이 되는 평균제곱오차(MSE)는 다음 정리와 같이 분산과 편향(bias)의 제곱의 합으로 구성할 수 있다.

정리 4.2

모수의 함수 $g(\theta)$의 추정량 $T(X)$의 평균제곱오차(MSE)는

$$\text{MSE} = Var(T(X)) + (\text{bias})^2$$

을 만족한다.

증명 $\text{MSE} = E[T(X) - g(\theta)]^2$

$$= E[\{T(X) - E(T(X))\} + \{E(T(X)) - g(\theta)\}]^2$$
$$= E\{T(X) - E(T(X))\}^2 + \{E(T(X)) - g(\theta)\}^2$$
$$+ 2E\{T(X) - E(T(X))\}\{E(T(X)) - g(\theta)\}$$
$$= Var(T(X)) + [E(T(X)) - g(\theta)]^2$$
$$+ 2\{E(T(X)) - g(\theta)\}\{E(T(X)) - E(T(X))\}$$

$$= Var(T(X)) + (\text{bias})^2 \qquad \blacksquare$$

정리 4.2에 의하면, 평균제곱오차를 기준으로 추정하는 데에는 분산과 편향의 두 요소가 존재함을 알 수 있다. 즉, 평균제곱오차를 작게 하는 추정량은 편향의 절댓값과 분산, 둘 다 작은 값을 가져야 한다는 것이다. 나아가 비편향추정량들만의 집합을 고려할 때는, 평균제곱오차를 최소화하는 추정량을 구하기 위해 분산을 (가능하면 모든 θ에 대하여 균일하게) 최소화하는 추정량을 구하면 된다.

과대 또는 과소추정하는 경향이 없도록 비편향추정량을 사용하기로 하는 경우에도, 때로는 여러 개의 비편향추정량이 존재하기 때문에 그중에 가장 좋은 것을 골라야 하며, 그러기 위해 평균제곱오차를 비교해야 하는데, 이때 다음의 정의에서와 같이 분산의 비(variance ratio)를 이용하면 편리하다.

정의 4.4

$T_1(X)$와 $T_2(X)$가 $g(\theta)$의 비편향추정량일 때 그 분산의 비, 즉 $\dfrac{Var[T_2(X)]}{Var[T_1(X)]}$를 추정량 $T_1(X)$의 $T_2(X)$에 대한 **상대효율**(relative efficiency)이라고 한다.

$T_1(X)$의 분산이 $T_2(X)$의 분산보다 작으면 평균제곱오차의 기준에 따라 $T_1(X)$가 더 좋은 추정량이며, 이때 $T_1(X)$의 $T_2(X)$에 대한 상대효율은 1보다 큰 값을 갖게 된다.

예 4.19

위의 예 4.17에서, $T_1(X) = \overline{X}_{10}$와 $T_2(X) = (X_1 + X_2)/2$의 분산은 각각 $Var(T_1(X)) = \sigma_0^2/10$, $Var(T_2(X)) = \sigma_0^2/2$이다. 따라서 추정량 $T_2(X)$의 $T_1(X)$에 대한 상대효율은 $2/10 = 0.2$이며, $T_2(X)$가 $T_1(X)$보다 효율이 낮은 추정량임을 알 수 있다.

예 4.20

예 4.18에서 $U(0, \theta)$의 θ에 대한 비편향추정량으로 고려한

$$\hat{\theta} = T_1(X) = \left(\frac{n+1}{n}\right) X_{(n)}$$

의 확률밀도함수는

$$f_{T_1}(t) = \left(\frac{n}{n+1}\right)^n \times \frac{nt^{n-1}}{\theta^n}, \qquad 0 < t < \left(\frac{n+1}{n}\right)\theta$$

이다. 이제 반대로 표본최솟값 $X_{(1)}$에 근거한 θ의 비편향추정량을 고려해 보자.

$$f_{X_{(1)}}(t\,;\theta) = \frac{n}{\theta}\left(1-\frac{t}{\theta}\right)^{n-1}, \qquad 0 < t < \theta$$

이므로

$$E(X_{(1)}) = \int_0^\theta \frac{nt}{\theta}\left(1-\frac{t}{\theta}\right)^{n-1} dt$$

$$= \left(\frac{1}{n+1}\right)\theta$$

가 되고, θ의 비편향추정량으로

$$T_2(X) = (n+1)X_{(1)}$$

을 생각할 수 있다. 이제 두 추정량 $T_1(X)$와 $T_2(X)$의 분산을 비교해 보면

$$E(T_1^2) = \int_0^{(n+1)\theta/n} \left(\frac{n}{n+1}\right)^n \times \frac{nt^{n+1}}{\theta^n}\, dt = \frac{(n+1)^2}{n(n+2)}\theta^2$$

이므로

$$Var(T_1(X)) = E(T_1(X)^2) - [\,E(T_1(X))\,]^2$$

$$= \frac{(n+1)^2}{n(n+2)}\theta^2 - \theta^2$$

$$= \frac{\theta^2}{n(n+2)}$$

이다. 마찬가지 방법으로

$$Var(T_2(X)) = \frac{n\theta^2}{n+2}$$

이 계산된다. 따라서

$$\frac{Var(T_2(X))}{Var(T_1(X))} = \frac{n\theta^2/(n+2)}{\theta^2/n(n+2)} = n^2$$

이 되어 $n > 1$일 때 $T_2(X)$에 비해 $T_1(X)$가 더 좋은 효율을 가졌다고 할 수 있으며, 표본의 크기가 크면 $T_1(X)$의 효율이 $T_2(X)$에 비해 훨씬 높아진다.

여기에서 상대효율의 실질적인 의미를 살펴보자. $T_1(X)$와 $T_2(X)$가 $g(\theta)$의 비편향 추정량이고, $Var(T_1(X)) = \nu_1/n$, $Var(T_2(X)) = \nu_2/n$라고 하면 $T_1(X)$의 $T_2(X)$에 대한 상대효율은 ν_2/ν_1이 된다. 그런데 두 추정방법이 같은 분산을 갖기 위한 표본의 크기를 n_1, n_2라고 하면 $\nu_1/n_1 = \nu_2/n_2$로부터 $\nu_2/\nu_1 = n_2/n_1$의 관계를 얻게 된다. 즉, 상대효율이 같은 분산을 갖기 위한 표본크기의 비로 해석될 수 있다는 것을 말한다.

두 개의 주어진 비편향추정량은 이와 같이 상대효율로 비교할 수 있으나, 비편향추정량은 여러 개 존재할 수 있고 모든 비편향추정량을 한꺼번에 고려하기는 어렵다. 그렇다면 어떻게 효율이 가장 높은 비편향추정량을 찾을 수 있을까?

$T^*(X)$를 $g(\theta)$의 비편향추정량이라고 할 때, $g(\theta)$의 모든 비편향추정량 $T(X)$에 대하여

$$\frac{Var(T^*(X))}{Var(T(X))} \leq 1 \tag{4.6}$$

이 성립하면 $T^*(X)$는 100%의 효율이 있다고 말한다. 이제 우리가 원하는 바는 100% 효율을 가지는 비편향추정량, 즉 최소분산 비편향추정량을 찾는 것이다.

4.4 최소분산 비편향추정량

이제 비편향추정량들 중에서 평균제곱오차, 즉 이 경우에는 분산을 최소화하는 최소분산 비편향추정량(Minimum Variance Unbiased Estimator, MVUE)에 대해 다루기로 한다.

정의 4.5

확률변수 $X_1, X_2, \cdots, X_n$ 의 결합 확률밀도함수가 $f(x_1, x_2, \cdots, x_n; \theta)$ 라고 하자. 함수 $g(\theta)$의 추정량 $T^*(X)$가 다음의 조건 (1), (2)를 만족시키면 이를 $g(\theta)$의 **최소분산 비편향추정량**(Minimum Variance Unbiased Estimator, MVUE)이라고 한다.

(1) $T^*(X)$는 $g(\theta)$의 비편향추정량이다(즉 $E[T^*(X)] = g(\theta)$).

(2) $g(\theta)$의 임의의 비편향추정량 $T(X)$에 대해서

$$Var(T^*(X)) \leq Var(T(X))$$

를 만족한다.

$g(\theta)$의 최소분산 비편향추정량을 구하는 데는 다음의 두 가지 방법이 가능하다. 하나는 $g(\theta)$의 비편향추정량 $T(X)$의 분산이 적절한 조건하에서 비편향추정량이 가질 수 있는 분산의 하한값인 '크래머-라오 하한값(Cramer-Rao lower bound)'을 갖는지 확인하는 방법이고, 다른 하나는 완비 충분통계량을 활용하여 라오-블랙웰(Rao-Blackwell)의 정리와 레만-쉐페(Lehmann-Scheffé)의 정리를 사용하는 방법이다.

● 크래머-라오의 방법

우선, 역사적으로 먼저 나왔던 크래머-라오 방법에 대해서 논하기로 하겠다. 크래머-라오의 정보부등식(Cramer-Rao's information inequality)은 적절한 조건하에서 비편향추정량이 가질 수 있는 분산의 하한값을 제공하고 있으며, 이 하한값을 크래머-라오 하한값(Cramer-Rao lower bound)이라고 한다. 어떠한 비편향추정량도 이보다 작은 분산을 가질 수 없다는 뜻으로, 어떤 비편향추정량이 주어진 조건하에서 이 하한값을 분산으로 가지면 이 추정량이 최소분산 비편향추정량이 된다. 단, 이 방법으로 최소분산 비편향추정량의 유일성을 보이기는 어렵다.

우선 정보부등식에 사용되는 **피셔의 정보**(Fisher's information) $I(\theta)$는 확률변수 X의 확률밀도함수가 $f(x;\theta)$일 때 다음과 같이 정의된다.

$$I(\theta) = E[(\frac{\partial}{\partial\theta}\log f(X;\theta))^2] \tag{4.7}$$

예 4.21

$X \sim N(\mu, \sigma_0^2)$ (σ_0^2은 알려진 값)이라고 할 때, 확률밀도함수는

$$f(x\,;\mu) = (\sqrt{2\pi}\,\sigma_0)^{-1}\exp\left[-(x-\mu)^2/2\sigma_0^2\right]$$

이며, 따라서

$$\begin{aligned} I(\mu) &= E\left[(\partial/\partial\mu)\log f(X\,;\mu)\right]^2 \\ &= E\left[\frac{X-\mu}{\sigma_0^2}\right]^2 \\ &= \frac{1}{\sigma_0^2} \end{aligned}$$

로 주어진다.

위의 예 4.21에서 주목할 바는, 우선 σ_0^2가 크면 클수록 하나의 관찰값 X가 모평균 μ에 대하여 가지는 정보는 작아진다는 점과, $I(\mu)$가 μ의 값에 의존하지 않는다는 사실이다. $X \sim N(\mu, \sigma_1^2)$, $Y \sim N(\mu, \sigma_2^2)$이고, $\sigma_1^2 < \sigma_2^2$ 이라고 하자. μ를 추정하기 위해 X나 Y를 이용할 수 있다면, X를 쓰는 것이 더 나을 것이다. 왜냐하면 X의 분산이 작기 때문에 관측값이 μ에 가까이 있을 확률이 더 높기 때문이다. 이와 같이 정규분포의 경우 분산이 작으면 관측값이 모평균에 대하여 가지는 정보가 커진다는 것이 타당해 보인다. 또한 관측값이 모평균에 대하여 가지는 정보는 모평균의 위치에 의존하지 않는데, 이는 모평균이 어디에 있든지 관측값이 모평균과 가까이 있을 확률이 분산에만 의존한다는 것으로, 정규분포의 형태적 특성을 생각할 때 당연한 일이 될 것이다.

예 4.22

X가 '성공' 확률이 p인 베르누이 확률변수라고 하자. 그러면,

$$f_X(x\,;p) = p^x(1-p)^{1-x}, \qquad (x=0,\,1,\;\; 0<p<1)$$
$$\log f_X(X\,;p) = X\log p + (1-X)\log(1-p)$$

이므로

$$\frac{\partial \log f_X(X;p)}{\partial p} = \frac{X}{p} - \frac{1-X}{1-p} = \frac{(X-p)}{p(1-p)}$$

가 된다. 따라서 피셔의 정보는

$$I(p) = E\left[\frac{\partial \log f_X(X;p)}{\partial p}\right]^2$$
$$= \frac{E(X-p)^2}{p^2(1-p)^2} = \frac{1}{p(1-p)}$$

로 계산된다. 여기에서 p가 1/2일 때 피셔의 정보가 가장 작음을 알 수 있다. 베르누이(p) 분포의 분산은 $p(1-p)$로서, 피셔의 정보는 분산의 역수이므로, 정규분포와 마찬가지로 분산이 작은 베르누이 확률변수가 그 평균에 대한 정보를 더 많이 가지고 있다고 할 수 있다.

이제, $X_1, X_2, \cdots, X_n$이 확률밀도함수가 $f(x;\theta)$, $\theta \in \Omega$인 분포로부터 얻은 랜덤표본이라고 하자. 그러면 $g(\theta)$의 비편향추정량 $T(X) = T(X_1, X_2, \cdots, X_n)$의 분산에 대한 부등식은 다음과 같이 주어진다.

정리 4.3

정보부등식(Information Inequality): 우선 확률밀도함수 $f(x;\theta)$와 통계량 $T(X)$에 대해 다음과 같은 가정을 한다.

(1) 모수가 다르면 확률밀도함수가 다르다. 즉, $\theta \neq \theta'$이면 $f(x;\theta) \neq f(x;\theta')$.

(2) 집합 $A = \{x : f(x;\theta) > 0\}$는 모수 θ에 의존하지 않으며, 모든 $x \in A$, $\theta \in \Omega$에 대하여 $\log f(x;\theta)$는 θ에 대해 두 번 미분 가능하고 도함수가 연속이다.

(3) 통계량 $T(X)$가 모든 $\theta \in \Omega$에 대하여 $E(T(X)) < \infty$이면,

$$\frac{\partial}{\partial \theta}\int_{-\infty}^{\infty}\cdots\int_{-\infty}^{\infty} T(x_1, \cdots, x_n)\prod_{i=1}^{n} f(x_i;\theta)\,dx_1 \cdots dx_n$$
$$= \int_{-\infty}^{\infty}\cdots\int_{-\infty}^{\infty} T(x_1, \cdots, x_n)\frac{\partial}{\partial \theta}\prod_{i=1}^{n} f(x_i;\theta)\,dx_1 \cdots dx_n$$

이다.

이제 모든 $\theta \in \Omega$에 대하여 $Var(T(X)) < \infty$, $E(T(X)) = g(\theta)$, $0 < I(\theta) < \infty$라고 하면, $g(\theta)$는 미분 가능하며

$$Var(T(X)) \geq \frac{[g'(\theta)]^2}{nI(\theta)}$$

이 성립한다.

증명 $T(X) = T(X_1, X_2, \cdots, X_n)$은 $g(\theta)$의 비편향추정량이므로,

$$\begin{aligned} g'(\theta) &= \frac{\partial}{\partial\theta} g(\theta) = \frac{\partial}{\partial\theta} \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} T(x_1, \cdots, x_n) \prod_{i=1}^{n} f(x_i;\theta)\, dx_1 \cdots dx_n \\ &= \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} T(x_1, \cdots, x_n) \frac{\partial}{\partial\theta} \left[\prod_{i=1}^{n} f(x_i;\theta) \right] dx_1 \cdots dx_n \\ &= \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} T(x_1, \cdots, x_n) \frac{\partial}{\partial\theta} \left[\prod_{i=1}^{n} f(x_i;\theta) \right] dx_1 \cdots dx_n \\ &\quad - g(\theta) \frac{\partial}{\partial\theta} \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} \prod_{i=1}^{n} f(x_i;\theta)\, dx_1 \cdots dx_n \end{aligned}$$

$$\left(\because \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} \prod_{i=1}^{n} f(x_i;\theta)\, dx_1 \cdots dx_n = 1 \text{이므로} \right.$$

$$\left. \frac{\partial}{\partial\theta} \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} \prod_{i=1}^{n} f(x_i;\theta)\, dx_1 \cdots dx_n = 0 \right)$$

$$\begin{aligned} &= \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} [\, T(x_1, \cdots, x_n) - g(\theta)\,] \frac{\partial}{\partial\theta} \left[\prod_{i=1}^{n} f(x_i;\theta) \right] dx_1 \cdots dx_n \\ &= \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} [\, T(x_1, \cdots, x_n) - g(\theta)\,] \left[\frac{\partial}{\partial\theta} \log \prod_{i=1}^{n} f(x_i;\theta) \right] \\ &\qquad \times \prod_{i=1}^{n} f(x_i;\theta)\, dx_1 \cdots dx_n \\ &= E\left[(\, T(X) - g(\theta)) \left(\frac{\partial}{\partial\theta} \log \prod_{i=1}^{n} f(X_i;\theta) \right) \right] \end{aligned}$$

이 성립한다. 이제 코시-쉬바르츠 정리에 의하여,

$$[g'(\theta)]^2 \le E\left[\left\{T(X)-g(\theta)\right\}^2\right]\cdot E\left[\left(\frac{\partial}{\partial\theta}\log\prod_{i=1}^{n}f(X_i;\theta)\right)^2\right]$$
$$= Var(T(X))\times E\left[\left(\frac{\partial}{\partial\theta}\log\prod_{i=1}^{n}f(X_i;\theta)\right)^2\right]$$

또는

$$Var(T(X)) \ge \frac{[g'(\theta)]^2}{E\left[\left(\frac{\partial}{\partial\theta}\log\prod_{i=1}^{n}f(X_i;\theta)\right)^2\right]}$$

이 성립한다. 그런데,

$$E\left[\frac{\partial}{\partial\theta}\log f(X_i;\theta)\right] = \int_{-\infty}^{\infty}\left[\frac{\partial}{\partial\theta}\log f(x;\theta)\right]f(x;\theta)\,dx$$
$$= \int_{-\infty}^{\infty}\frac{\partial}{\partial\theta}f(x;\theta)\,dx = \frac{\partial}{\partial\theta}\int_{-\infty}^{\infty}f(x;\theta)\,dx$$
$$= \frac{\partial}{\partial\theta}(1) = 0$$

이므로

$$E\left[\left(\frac{\partial}{\partial\theta}\log\prod_{i=1}^{n}f(X_i;\theta)\right)^2\right] = E\left[\left(\sum_{i=1}^{n}\frac{\partial}{\partial\theta}\log f(X_i;\theta)\right)^2\right]$$
$$= \sum_{i=1}^{n}\sum_{j=1}^{n}E\left[\left(\frac{\partial}{\partial\theta}\log f(X_i;\theta)\right)\left(\frac{\partial}{\partial\theta}\log f(X_j;\theta)\right)\right]$$
$$= nE\left[\left(\frac{\partial}{\partial\theta}\log f(X;\theta)\right)^2\right]$$

에 의하여 부등식의 결과가 얻어진다. 마지막 등식은 i와 j가 서로 다를 때 X_i와 X_j가 독립이므로

$$E\left[\left(\frac{\partial}{\partial\theta}\log f(X_i;\theta)\right)\left(\frac{\partial}{\partial\theta}\log f(X_j;\theta)\right)\right]$$
$$= E\left[\frac{\partial}{\partial\theta}\log f(X_i;\theta)\right]E\left[\frac{\partial}{\partial\theta}\log f(X_j;\theta)\right]$$

임을 이용하였다. ■

$T(X)$가 θ의 비편향추정량이라고 하면, 위 정리 4.3으로부터,

$$Var(T(X)) \geq \frac{1}{nI(\theta)} \tag{4.8}$$

을 얻을 수 있다. 그러므로 어떤 비편향추정량 $T(X)$가 $Var(T(X)) = 1/nI(\theta)$을 만족한다면, 이 추정량은 비편향추정량 가운데 가장 작은 분산을 갖는 것이고, 때문에 이를 θ의 최소분산 비편향추정량(Minimum Variance Unbiased Estimator)이라고 한다.

예 4.23

$X_1, X_2, \cdots, X_n$을 포아송(λ) 분포로부터 구한 랜덤표본이라고 하자. 우선 피셔의 정보 $I(\lambda)$를 계산하면 다음과 같다.

$$\begin{aligned} I(\lambda) &= E\left[\frac{\partial}{\partial \lambda}\log f(X;\lambda)\right]^2 \\ &= E\left[-1+\frac{X}{\lambda}\right]^2 \\ &= E\left[\frac{X-\lambda}{\lambda}\right]^2 \\ &= \frac{1}{\lambda} \end{aligned}$$

그런데 $Var(\overline{X}_n) = \lambda/n$이므로 식 (4.8)에 의하여 표본평균 $\overline{X}_n$는 최소분산 비편향추정량이다.

예 4.24

$X_1, X_2, \cdots, X_n$을 $N(\mu, \sigma^2)$으로부터 얻은 랜덤표본이라고 하자. 이때 피셔의 정보는 $I(\mu) = 1/\sigma^2$이고, $Var(\overline{X}_n) = \sigma^2/n$이므로, 역시 식 (4.8)에 의해서 $\overline{X}_n$는 최소분산 비편향추정량이다.

주 위와 같은 크래머-라오 방법의 사용에는 몇 가지 유의할 점이 있다. 우선, 정보부등식이 제공하는 분산의 하한값을 갖지 않더라도 최소분산 비편향추정량이 될 수 있다는 점이다. 즉, 정보부등식의 하한이 너무 작아서 그 값을 갖는 추정량이 없을 경우 어떤 비편향

추정량이 정보부등식이 제공하는 분산의 하한값을 갖지 않더라도 가장 뛰어난 추정량이 될 수 있다. 또한 정보부등식이 성립하는 가정들을 어기는 경우 정보부등식에서 주어지는 분산의 하한값보다 더 작은 분산을 가지는 비편향추정량도 존재할 수 있다(참조: 연습문제 4.26).

● 완비충분 통계량 방법

최소분산 비편향추정량을 구하는 두 번째 방법으로 완비충분 통계량의 활용을 다루어 보기로 한다. 우선, 충분통계량(sufficient statistic)의 정의는 다음과 같다.

정의 4.6

확률벡터 $\boldsymbol{X}=(X_1, X_2, \cdots, X_n)$의 결합 확률밀도함수가 $f(x_1,\cdots,x_n;\theta_1,\cdots,\theta_k)$일 때 $\boldsymbol{S}(\boldsymbol{X})=(S_1(\boldsymbol{X}),\cdots, S_l(\boldsymbol{X}))$를 l개 통계량의 벡터라고 하자. 이때 조건부 확률변수 $(X_1, X_2, \cdots, X_n)\,|\,\boldsymbol{S}(\boldsymbol{X})$의 분포가 모수 $\theta=(\theta_1, \theta_2,\cdots, \theta_k)$에 의존하지 않으면 통계량 $\boldsymbol{S}(\boldsymbol{X})$를 **결합 충분통계량**(jointly sufficient statistic)이라고 한다. 일변량의 경우($l=1$)에는 $S(\boldsymbol{X})$가 θ의 **충분통계량**이라고 한다.

위 정의는, 일단 충분통계량의 값이 주어지면 표본의 결합분포는 모수에 의존하지 않으므로 표본이 더 이상 모수에 대한 아무런 정보를 가지고 있지 않다는 것을 의미한다. 표본이 모수의 추정에 사용되는 이유는 확률변수 $X_1,\cdots,X_n$ 각각은 모수의 함수가 아니지만 그 분포가 모수에 의존하기 때문인데, 이제 충분통계량의 값이 알려지면 표본의 조건부 분포가 모수에 의존하지 않으므로 모수추정에 이용될 근거를 잃어버리게 되며, 모수추정과 관계없는 정보만이 남는다는 것이다. 따라서 $(X_1, X_2, \cdots, X_n)$이 관찰되었을 때, 모수 θ에 대한 정보는 모두 충분통계량 $\boldsymbol{S}(\boldsymbol{X})$에 포함되어 있다고 할 수 있다. 이것은 자료의 축소(data reduction)를 가능하게 하는데, 모수 θ의 추정이 목적이라면 대규모 자료를 모두 저장할 필요가 없이 충분통계량만 가지고도 같은 효율을 갖는 추정값을 얻을 수 있기 때문이다.

예 4.25

$X_1, X_2, \cdots, X_n$을 베르누이(p)로부터 구한 랜덤표본이라고 할 때 $S=\sum_{i=1}^{n} X_i$의 확률밀도함수는

$$f(s;p)=\binom{n}{s}p^s(1-p)^{n-s} \qquad (s=0,\,1,\cdots,\,n)$$

로 주어진다. 여기에서 $S=\sum_{i=1}^{n}X_i$가 p에 대한 충분통계량임을 보이고자 한다. $S(=\sum_{i=1}^{n}X_i)=s$의 값이 주어졌을 때, $X_1,\ X_2,\ \cdots,\ X_n$의 조건부 확률밀도함수는

$$\begin{aligned} f(x_1,\,x_2,\cdots,x_n|\,s) &= P(X_1=x_1,\cdots,\,X_n=x_n|\,S=s) \\ &= \frac{P(X_1=x_1,\cdots,\,X_n=x_n,\,S=s)}{P(S=s)} \\ &= \begin{cases} \dfrac{P(X_1=x_1,\cdots,\,X_n=x_n)}{P(S=s)}, & s=\sum_{i=1}^{n}x_i \\ 0, & \text{그 외의 경우} \end{cases} \end{aligned}$$

이다. 예를 들어 $n=3$이고 $x_1=1, x_2=0, x_3=1$이라면 $s=2$일 때 $P(X_1=1,\ X_2=0,\ X_3=1,\ S=2)=P(X_1=1,\ X_2=0,\ X_3=1)$이지만 $s=1$이라면 $P(X_1=1,\ X_2=0,\ X_3=1,\ S=1)=0$이 된다. $S\sim B(n,p)$임을 이용하여,

$$\begin{aligned} f(x_1,\,x_2,\cdots,x_n|\,s) &= \frac{f(x_1,\,x_2,\cdots,x_n;p)}{f_S(s;p)}, \quad s=\sum_{i=1}^{n}x_i \\ &= \frac{p^s(1-p)^{n-s}}{\binom{n}{s}p^s(1-p)^{n-s}}, \quad s=\sum_{i=1}^{n}x_i \\ &= \frac{1}{\binom{n}{s}}, \quad s=\sum_{i=1}^{n}x_i \end{aligned}$$

이 되며, 이는 모수 p에 의존하지 않으므로 $S=\sum_{i=1}^{n}X_i$는 p의 충분통계량이다.

주 $(S_1,\cdots,\,S_l)$이 결합 충분통계량이면 $(S_1,\cdots,\,S_l)$의 1 : 1 함수도 역시 결합 충분통계량이다. 즉, $(S_1,\cdots,\,S_l)$이 표본이 갖는 모수에 대한 정보를 모두 갖고 있다면 그의 1 : 1 함수도 그 정보를 모두 갖고 있다는 것이다.

주 정의 4.6과 그 이하 설명에서 $l>1$인 경우 $\boldsymbol{S}$를 이용하여 $(S_1,\cdots,\,S_l)$을 나타내고, $\boldsymbol{X}$를 이용하여 $(X_1,\cdots,X_n)$를 나타내는 등 굵은 문자체로 벡터를 표현하였으나, 이후 혼동이 없다면 굳이 굵은 문자체를 쓰지 않고 S와 X 등을 사용하도록 하겠다.

이와 같은 충분통계량은 모수모형$(P_\theta(x), \theta \in \Omega)$에 있어서 모수에 대한 모든 정보를 가지고 있기 때문에, 자료의 축소(reduction)라는 실제적인 의미뿐 아니라 최소분산 비편향추정량을 찾는 데 중요한 역할을 한다. 그러나 주어진 통계량 $S(X)$가 '충분'한가의 여부를 위의 정의에 의해 파악하는 것은 조건부 확률밀도함수를 구하는 복잡한 과정을 필요로 하며, 다음의 인수분해 정리(factorization theorem)를 사용하면 보다 간단히 확인할 수 있다. 인수분해 정리를 통해 주어진 통계량의 충분성을 확인할 수 있을 뿐만 아니라 어떤 통계량이 충분통계량일지를 결합 확률밀도함수로부터 찾을 수 있다.

정리 4.4

(인수분해 정리) $X_1, X_2, \cdots, X_n$ 의 결합 확률밀도함수가 $f(x_1, x_2, \cdots, x_n ; \theta)$일 때 $S(X) = (S_1(X), \cdots, S_k(X))$ 를 k개의 통계량이라고 하자. 이때 S가 결합 충분통계량일 필요충분조건은 결합 확률밀도함수가 s와 θ만의 함수인 g와, $(x_1, x_2, \cdots, x_n)$만의 함수인 h와의 곱의 꼴로 다음과 같이 나타내어지는 것이다.

$$f(x_1, x_2, \cdots, x_n ; \theta) = g(s(x) ; \theta) \times h(x_1, x_2, \cdots, x_n)$$

증명 여기에서는 이산형인 경우에 대해서 증명하여 본다. S가 결합 충분통계량이고, S의 확률밀도함수를 $f_S(s;\theta)$로 표기하면,

$$\begin{aligned} f(x_1, x_2, \cdots, x_n ; \theta) &= f_S(s ; \theta) f_{X|S}(x_1, x_2, \cdots, x_n \mid s) \\ &= g(s ; \theta) h(x_1, x_2, \cdots, x_n) \end{aligned}$$

와 같이 나타내어진다. 왜냐하면, 충분성의 정의에 의해 조건부 확률밀도함수 $f_{X|s}$는 모수 θ에 의존하지 않기 때문이다. 역으로 $f(x_1, x_2, \cdots, x_n;\theta) = g(s;\theta)$ $h(x_1, x_2, \cdots, x_n)$라고 하면, S의 확률밀도함수는 $f_S(s ; \theta) = P(S = s ; \theta) = \sum f(x_1, \cdots, x_n ; \theta) = \sum g(s ; \theta) h(x_1, x_2, \cdots, x_n) = g(s ; \theta) \sum h(x_1, x_2, \cdots, x_n) = g(s;\theta) c(x)$의 꼴로 표현된다(단, $\sum$은 $s(x_1, x_2, \cdots, x_n) = s$를 만족하는 $x_1, x_2, \cdots, x_n$에 대한 합임). 따라서 $S = s$가 주어졌을 때, $X_1, X_2, \cdots, X_n$의 조건부 확률밀도함수

$$f(x_1, x_2, \cdots, x_n | s) = \frac{f(x_1, x_2, \cdots, x_n; \theta)}{f_S(s; \theta)}$$
$$= h(x_1, x_2, \cdots, x_n)/c(x)$$

는 모수 θ에 의존하지 않으므로 S는 결합 충분통계량이다. ■

예 4.26

$X_1, X_2, \cdots, X_n$을 베르누이(p)로부터 구한 랜덤표본이라고 하면, 이들의 결합 확률밀도함수는

$$f(x_1, x_2, \cdots, x_n; p) = p^{\sum_{i=1}^{n} x_i} (1-p)^{n - \sum_{i=1}^{n} x_i} \prod_{i=1}^{n} I_{\{0,1\}}(x_i)$$

이다. 따라서 $S = \sum_{i=1}^{n} X_i$일 때,

$$h(x_1, x_2, \cdots, x_n) = \begin{cases} 1, & x_i = 0, 1, \quad i = 1, \cdots, n \\ 0, & \text{그 외의 경우} \end{cases}$$

과

$$g(s; p) = p^{\sum_{i=1}^{n} x_i} (1-p)^{n - \sum_{i=1}^{n} x_i} = p^s (1-p)^{n-s}$$

를 택하면

$$f(x_1, x_2, \cdots, x_n; p) = g(s; p) h(x_1, x_2, \cdots, x_n)$$

의 꼴로 표현할 수 있다. 그러므로 $\sum_{i=1}^{n} X_i$는 충분통계량이다.

예 4.27

$X_1, X_2, \cdots, X_n$을 $U(\theta_1, \theta_2)$로부터 구한 랜덤표본이라고 하면 이들의 결합 확률밀도함수는

$$f(x_1, \cdots, x_n; \theta_1, \theta_2) = \prod_{i=1}^{n} \frac{1}{\theta_2 - \theta_1} I_{(\theta_1, \theta_2)}(x_i)$$

$$= \frac{1}{(\theta_2-\theta_1)^n}\prod_{i=1}^{n} I_{(\theta_1,\theta_2)}(x_i)$$

$$= \frac{1}{(\theta_2-\theta_1)^n}\, I_{(\theta_1, x_{(n)})}(x_{(1)})\, I_{[x_{(1)},\theta_2)}(x_{(n)})$$

으로 주어진다. 왜냐하면 모든 X_i들이 구간 (θ_1,θ_2)에 포함된다는 것은, 그것의 표본최솟값이 θ_1보다 크거나 같고, 표본최댓값이 θ_2보다 작거나 같다는 것과 동치이기 때문이다. 물론 표본최댓값이 표본최솟값보다 크거나 같음을 만족해야 함은 자명한 사실이다. 따라서 결합 확률밀도함수는 $x_{(1)}$과 $x_{(n)}$을 통해서만 $x_1, x_2, \cdots, x_n$ 에 의존하므로 $h(x_1, x_2, \cdots, x_n)=1$ 이라고 하면, 정리 4.4에 의하여 표본최솟값 $X_{(1)}$과 표본최댓값 $X_{(n)}$은 결합 충분통계량이 된다.

예 4.28

$X_1, X_2, \cdots, X_n$ 이 $N(\mu, \sigma^2)$으로부터 구한 랜덤표본이라고 할 때 이들의 결합 확률밀도함수는

$$f(x_1, x_2, \cdots, x_n; \mu, \sigma^2) = (\sqrt{2\pi}\,\sigma)^{-n}\exp\left[-\frac{\sum_{i=1}^{n}(x_i-\mu)^2}{2\sigma^2}\right]$$

으로 주어진다. 그런데 이는

$$f(x_1, x_2, \cdots, x_n; \mu, \sigma^2) = (\sqrt{2\pi}\,\sigma)^{-n}\exp\left[-\frac{\sum_{i=1}^{n}x_i^2 - 2\mu\sum_{i=1}^{n}x_i + n\mu^2}{2\sigma^2}\right]$$

와 같이 표현되므로, 위 정리 4.4로부터 $S_1=\sum_{i=1}^{n}X_i$와 $S_2=\sum_{i=1}^{n}X_i^2$은 결합 충분통계량이다. 나아가 S_1과 S_2의 1 : 1 함수인 $\overline{X}_n$과 $\sum_{i=1}^{n}(X_i-\overline{X}_n)^2$도 역시 결합 충분통계량이다.

예 4.29

$X_1, X_2, \cdots, X_n$ 이 확률밀도함수가 $f(x;\theta)$인 연속분포로부터의 랜덤표본이라고 하

면, 순서통계량은 결합 충분통계량이다. 왜냐하면, 주어진 $x_{(1)}, x_{(2)}, \cdots, x_{(n)}$ 에 대하여 $(X_1, X_2, \cdots, X_n)$ 이 가질 수 있는 값은 $n!$ 개의 벡터 $(x_{(i_1)}, x_{(i_2)}, \cdots, x_{(i_n)})$ 이며, 이들은 대칭이기에 각각 조건부확률 $1/n!$을 가지므로 모수 θ에 의존하지 않기 때문이다. 여기에서 $(i_1, i_2, \cdots, i_n)$는 $(1, 2, \cdots, n)$의 순열(permutation)이다.

충분통계량의 의미는 모수에 대한 정보를 잃지 않고 자료를 축소하는 데 있었다. 그 의미를 생각해 보면, 표본이 가지고 있는 모수에 대한 정보를 고스란히 가지고 있는 통계량은 모두 충분통계량이 될 수 있다. 즉, 충분통계량은 유일하지 않다는 것이다. 가령 $X_1, X_2, \cdots, X_n$이 $N(\mu, \sigma^2)$으로부터의 랜덤표본일 때 예 4.28에서 보듯이 $(\overline{X}_n, S_n^2)$이 (μ, σ^2)에 대한 충분통계량이지만, 예 4.29에서처럼 순위통계량 $X_{(1)}, X_{(2)}, \cdots, X_{(n)}$도 충분통계량이며, 표본 $X_1, X_2, \cdots, X_n$ 자체는 당연히 충분통계량이다. 많은 충분통계량 가운데 어떤 통계량을 사용하면 좋을지 결정해야 하는 경우, 자료의 축소라는 충분통계량의 의미를 생각할 때, 모수에 관한 정보를 잃지 않으면서 자료를 가장 많이 축소시키는 충분통계량을 선호하게 된다. 즉, 모수의 추정에 필요 없는 정보를 가장 적게 가지고 있는 충분통계량이 좋다는 것이다. 그러한 충분통계량을 **최소충분통계량**(minimal sufficient statistic)이라고 하는데, 이를 수리적으로 표현하자면, 어떤 충분통계량 S가 임의의 다른 충분통계량의 함수일 때 이 S가 최소 충분통계량이 된다. S가 다른 충분통계량 U의 함수이면 U의 값을 알 때 S를 계산할 수 있고, 즉 U의 정보만 가지고 S를 알 수 있기에 U가 적어도 S보다 크거나 같은 정보량을 갖는다고 할 수 있다. S와 U가 모두 충분통계량이라고 했으므로, S는 모수에 관한 정보를 모두 갖고 있으면서 자료를 더 많이 축소시킨다고 할 수 있다. 앞의 예에서 $(\overline{X}_n, S_n^2)$는 주어진 충분통계량 $(X_1, X_2, \cdots, X_n)$ 또는 $(X_{(1)}, X_{(2)}, \cdots, X_{(n)})$는 물론이고 다른 임의의 충분통계량의 함수이므로 최소 충분통계량이다. 이에 대한 증명이나 최소 충분통계량을 찾는 일반적인 방법은 생략하기로 한다.

나아가, 모수에 대한 모든 정보를 갖고 있는 충분통계량을 활용하는 추정 방법의 원리는 다음의 라오-블랙웰 정리에서 드러난다.

정리 4.5

(라오-블랙웰 정리) 모수의 함수 $g(\theta)$에 대하여 S가 충분통계량이고, $T(X)$가 그의 한 비편향추정량이라고 하자. 이때 $\delta(S) = E(T(X) \mid S)$ 라고 하면 $\delta(S)$도

역시 $g(\theta)$의 비편향추정량이며, 모든 θ에 대하여

$$\begin{aligned} Var(\delta(S)) &= E\left[(\delta(S)-g(\theta))^2\right] \\ &\le E\left[(T(X)-g(\theta))^2\right] \\ &= Var(T(X)) \end{aligned}$$

가 성립한다.

증명 우선, S의 충분성에 의하여 $\delta(S)$는 모수 θ에 의존하지 않으므로 그 자체로 추정량이 될 수 있으며, 이중기댓값 정리에 의하면 $E(\delta(S)) = E(T(X)) = g(\theta)$ 이므로 $\delta(S)$는 $g(\theta)$의 비편향추정량이다. 한편, 정리 2.13에서 $Y = T(X)$, $X = S$라고 놓으면,

$$\begin{aligned} Var(T(X)) &= E(Var(T(X)|S)) + Var(E(T(X)|S)) \\ &= E[E((T(X)-\delta(S))^2|S)] + Var(\delta(S)) \\ &\ge Var(\delta(S)) \end{aligned}$$

가 성립한다. 이때 등호는 $Var(T(X)\,|\,S) = 0$, 즉 $T(X) = \delta(S)$인 경우에 성립하게 된다. ■

위 정리의 내용은 어떤 비편향추정량 $T(X)$가 존재하면 충분통계량 S에 대한 조건부 기댓값 $E[T(X)|S]$ 역시 비편향추정량이며, $T(X)$보다 작거나 같은 분산을 가진다는 것이다. 따라서 비편향추정량 가운데 가장 작은 분산을 가지는 추정량을 찾음에 있어서 그 후보를 충분통계량의 함수 꼴로 국한시킬 수 있다는 의미를 가지고 있다.

예 4.30

$X_1, X_2, \cdots, X_n$을 베르누이(p)로부터 구한 랜덤표본이라고 하자. 이 경우 X_1은 모수 p에 대한 비편향추정량이다. 이제 충분통계량인 $S = \sum_{i=1}^{n} X_i$가 주어졌을 때, X_1의 조건부 확률분포를 살펴봄으로써 이보다 작은 분산을 갖는 비편향추정량을 찾아보자. X_1의 조건부 분포는

$$P\left(X_1=0 \,\middle|\, \sum_{i=1}^{n} X_i = s\right) = \frac{P\left(X_1=0,\ \sum_{i=1}^{n} X_i = s\right)}{P\left(\sum_{i=1}^{n} X_i = s\right)}$$

$$= \frac{P\left(X_1=0,\ \sum_{i=2}^{n} X_i = s\right)}{P\left(\sum_{i=1}^{n} X_i = s\right)}$$

$$= \frac{P(X_1=0)\,P\left(\sum_{i=2}^{n} X_i = s\right)}{P\left(\sum_{i=1}^{n} X_i = s\right)}$$

$$= \frac{(1-p)\cdot\binom{n-1}{s}p^s(1-p)^{n-1-s}}{\binom{n}{s}p^s(1-p)^{n-s}}$$

$$= \frac{n-s}{n},$$

$$P\left(X_1=1 \,\middle|\, \sum_{i=1}^{n} X_i = s\right) = \frac{P\left(X_1=1,\ \sum_{i=1}^{n} X_i = s\right)}{P\left(\sum_{i=1}^{n} X_i = s\right)}$$

$$= \frac{P\left(X_1=1,\ \sum_{i=2}^{n} X_i = s-1\right)}{P\left(\sum_{i=1}^{n} X_i = s\right)}$$

$$= \frac{P(X_1=1)\cdot P\left(\sum_{i=2}^{n} X_i = s-1\right)}{P\left(\sum_{i=1}^{n} X_i = s\right)}$$

$$= \frac{p\cdot\binom{n-1}{s-1}p^{s-1}(1-p)^{n-1-s+1}}{\binom{n}{s}p^s(1-p)^{n-s}}$$

$$= \frac{s}{n}$$

으로 구해지는데, 예상했던 바와 같이 조건부 확률변수 $X_1 \left| \sum_{i=1}^{n} X_i = s \right.$ 의 분포가 모수 p에 의존하지 않는다. 위 확률을 이용하면

$$E\left(X_1 \left| \sum_{i=1}^{n} X_i = s \right. \right) = 0 \times (1 - \frac{s}{n}) + 1 \times \frac{s}{n} = \frac{s}{n}$$

이며, $E(T(X)|S) = S/n$ 는 p의 새로운 비편향추정량이 된다. 라오-블랙웰 정리에 의하면 이것은 X_1보다 분산이 작거나 같은데, 실제로 X_1의 분산은 $p(1-p)$이며 $E(T(X)|S) = \sum_{i=1}^{n} X_i/n$의 분산은 $p(1-p)/n$이다.

앞의 라오-블랙웰 정리를 이용하면 충분통계량의 함수로서의 비편향추정량이 유일한 경우 그것이 바로 최소분산 비편향추정량이 됨을 알 수 있다. 어떤 충분통계량 S가 있어서 이 충분통계량의 함수로서의 비편향추정량이 $\delta^*(S)$로 유일하다고 해 보자. 또, 이 $\delta^*(S)$보다 더 좋은 비편향추정량이 있는지 확인하기 위해 어떤 비편향추정량 $T(X)$를 가정하자. 만약 $T(X)$가 S의 함수가 아니라면, 라오-블랙웰 정리에 의해 $E(T(X)|S)$가 더 좋은 비편향추정량이 될 것이고, 그것은 가정된 유일성에 의해 $\delta^*(S)$와 같게 된다. 만약 $T(X)$가 S의 함수라면 그 자체가 $\delta^*(S)$와 같을 수밖에 없다. 즉, $\delta^*(S)$가 모든 비편향추정량 중에 가장 분산이 작은 추정량이 된다.

이제 이 유일성(uniqueness)을 다루는 데 있어 중요한 도구가 되는 '완비성(completeness)'에 대해 살펴보자.

정의 4.7

랜덤표본 $X_1, \cdots, X_n$으로부터 계산된 통계량 $S = S(X_1, \cdots, X_n)$에 대하여, $E(g(S)) = 0$을 모든 $\theta \in \Omega$에 대해 만족하는 θ에 무관한 함수 g가 $g(\cdot) \equiv 0$ 뿐이라면, S를 **완비통계량**(complete statistic)이라고 한다. 만약 S가 θ에 대한 충분통계량이라면, 이를 완비 **충분통계량**이라고 한다.

예 4.31

$X_1, X_2, \cdots, X_n$ 을 베르누이(p)로부터 구한 랜덤표본이라고 하자. 이 경우, 예를 들어 $X_1 - X_2$는 완비통계량이 아니다. 왜냐하면, $E(X_1 - X_2) = 0$이지만 $X_1 - X_2$가

항상 0인 것은 아니기 때문이다. 이제 $T=\sum_{i=1}^{n} X_i$가 완비통계량임을 보이고자 한다. 그런데 $T\sim B(n, p)$이므로

$$E[g(T)] = \sum_{t=0}^{n} g(t)\binom{n}{t}p^t(1-p)^{n-t}$$
$$= (1-p)^n \sum_{i=0}^{n} g(t)\binom{n}{t}\left(\frac{p}{1-p}\right)^t$$

이다.

그러므로 $E[g(T)]=0$이 모든 $0<p<1$에 대하여 성립한다는 것은

$$\sum_{t=0}^{n} g(t)\binom{n}{t}\left(\frac{p}{1-p}\right)^t = 0$$

을 의미한다. 그런데 위 식의 좌변은 $p/(1-p)$에 대한 다항식이며, 다항식이 $\frac{p}{1-p}$의 값에 상관없이 0이 되기 위해서는 $p/(1-p)$에 대한 모든 계수가 0이 되어야 한다. 즉, $g(t)\equiv 0$이다.

예 4.32

$X_1, X_2, \cdots, X_n$을 $U(0, \theta)$로부터 구한 랜덤표본이라고 하자. 이때 표본최대통계량 $X_{(n)}$은 완비통계량인 것이 다음과 같이 보여진다. 예 4.18에서와 같이 $f_{X_{(n)}}(y)=\frac{ny^{n-1}}{\theta^n}$, $0<y<\theta$이므로,

$$E[g(X_{(n)})] = \frac{n}{\theta^n}\int_0^{\theta} g(y)y^{n-1}dy$$

이다. 따라서 $\theta>0$인 모든 θ에 대하여 $E[g(X_{(n)})]=0$이라는 것은

$$\int_0^{\theta} g(y)y^{n-1}dy = 0$$

과 동등하다. 이제 위 식의 양변을 θ에 대하여 미분하면 $g(\theta)\theta^{n-1}=0$이 모든 $\theta>0$에 대하여 성립하는 것을 뜻하고, 이는 $g(\cdot)\equiv 0$과 같다. 즉, $X_{(n)}$은 완비통계량이며, 동시에 충분통계량이기도 하므로 θ에 대한 완비 충분통계량이다.

추정의 이론에 있어서 완비성의 의미를 살펴보면 다음과 같다. $S(X)$가 완비통계량이면 $S(X)$의 서로 다른 두 함수가 같은 기댓값을 가지지 못한다. 즉, $E[g_1(S(X))] = g(\theta)$, $E[g_2(S(X))] = g(\theta)$로 서로 같다고 하면, $E[g_1(S(X)) - g_2(S(X))] = 0$이 되고 완비성에 의해 $g_1(S(X)) = g_2(S(X))$가 되므로 완비통계량의 함수로서의 비편향추정량은 유일하게 된다. 따라서 어떤 비편향추정량이 또한 완비 충분통계량의 함수이면 라오-블랙웰 정리에 의하여 이는 유일한(unique) 최소분산 비편향추정량이 되는 것이다. 다음의 정리 4.6은 최소분산 비편향추정량을 구함에 있어서 완비 충분통계량의 활용을 보여 준다.

정리 4.6

(레만-쉐페 정리) 모수 θ에 대하여 S가 완비 충분통계량이고, $T(X)$가 $g(\theta)$의 비편향추정량이라고 하자. 이때 $\delta(S) = E(T(X) \mid S)$는 $g(\theta)$의 유일한 최소분산 비편향추정량(MVUE)이다.

증명 먼저, $\delta(S)$는 이중기댓값 정리에 의하여 $g(\theta)$의 비편향추정량이다. 이제 임의의 비편향추정량 $\eta(X_1, \cdots, X_n)$을 생각해 보자. 이것이 통계량 S의 함수라면 $\delta^*(S) = \eta(X, \cdots, X_n)$으로 표기하자. 그러면 모든 θ에 대해 $E[\delta(S) - \delta^*(S)] = 0$이고 $\delta(S) - \delta^*(S)$가 S의 함수이므로, 완비성에 의해 $P[\delta(S) = \delta^*(S)] \equiv 1$이 성립한다. $\eta(X_1, \cdots, X_n)$이 S의 함수가 아니라면 라오-블랙웰 정리에 의해 $E(\eta(X_1, \cdots, X_n)|S)$가 $\eta(X_1, \cdots, X_n)$보다 분산이 더 작은 비편향추정량이 되고 이것은 S의 함수이므로 $\delta(S)$와 동일하게 된다. 따라서 $\delta(S)$가 $g(\theta)$의 유일한 최소분산 비편향추정량이다. ■

주 위의 정리 4.6은 모수 θ에 대하여 S가 완비 충분통계량이고, $E(S(X)) = g(\theta)$이면 $S(X)$가 $g(\theta)$의 유일한 최소분산 비편향추정량(MVUE)이라는 것을 의미한다. 그러므로 모수 θ에 대한 최소분산 비편향추정량을 찾기 위해서는 (i) 완비 충분통계량의 함수 가운데 비편향추정량을 찾거나, (ii) 다루기 쉬운 비편향추정량을 골라서 완비 충분통계량으로 조건부 기댓값을 취하면 된다.

예 4.33

$X_1, X_2, \cdots, X_n$ 을 $U(0, \theta)$로부터 구한 랜덤표본이라고 하자. 표본최댓값 $X_{(n)}$이 완비 충분통계량임은 이미 보였다(참조: 예 4.27과 4.32). 그런데 예 4.18로부터 $E[(n+1)X_{(n)}/n] = \theta$이므로

$$\frac{(n+1)X_{(n)}}{n}$$

은 모수 θ의 유일한 최소분산 비편향추정량이다.

이와 같이 완비 충분통계량의 존재는 점추정에 매우 유용한 역할을 하는 반면, 통계량의 완비충분성(특히 완비성)에 대한 입증은 때로 복잡한 계산과정을 수반한다. 그러나 다음에 정의되는 **지수족**(exponential family)에 대해서는 완비충분성이 보장되며, 더구나 자주 사용되는 많은 확률분포가 지수족에 속하므로 이를 쉽게 활용할 수 있다.

정의 4.8

확률밀도함수가 적절한 함수 $a,\ b,\ c_i,\ t_i (i = 1, \cdots, k)$에 대하여,

$$f(x;\theta) = a(\theta)b(x)\exp\left[\sum_{i=1}^{k} c_i(\theta)t_i(x)\right],\ -\infty < x < \infty$$

$\theta = (\theta_1, \cdots, \theta_k)$로 표현되면 이를 k개의 모수 $\theta_1, \cdots, \theta_k$를 가진 지수족에 속한다고 한다. 여기에서 집합 $\{x : f(x;\theta) > 0\}$은 모수 θ에 의존하지 않는다.

예 4.34

'성공' 확률이 p인 베르누이 확률변수 X의 확률밀도함수는

$$\begin{aligned} f(x;p) &= p^x(1-p)^{1-x}, \qquad x = 0, 1 \\ &= (1-p)\exp\left[x \cdot \log\left(\frac{p}{1-p}\right)\right] \end{aligned}$$

로 표현되므로

$$a(p) = 1-p,\ b(x) = 1,\ c(p) = \log\left(\frac{p}{1-p}\right),\ t(x) = x$$

로 잡을 수 있으며, $\{x : f(x;p) > 0\}$은 $\{0,1\}$로서 모수에 의존하지 않는다. 따라서 베르누이 분포는 모수가 하나인 지수족에 속한다.

포아송 확률변수 $X \sim \mathrm{POI}(\lambda)$의 확률밀도함수는

$$f(x;\lambda) = \frac{e^{-\lambda}\lambda^x}{x!}, \quad x = 0, 1, 2, \cdots$$
$$= e^{-\lambda}\frac{1}{x!}\exp(x\log\lambda)$$

로 표현되므로

$$a(\lambda) = e^{-\lambda},\ b(x) = \frac{1}{x!},\ c(\lambda) = \log\lambda,\ t(x) = x$$

로 잡으면 지수족에 속함을 알 수 있다. $\{x : f(x;\lambda) > 0\} = \{0, 1, 2, \cdots\}$로 모수에 의존하지 않는다.

또한 정규확률변수 $X \sim N(\mu, \sigma^2)$의 확률밀도함수도

$$f(x;\mu,\sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}}\exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right]$$
$$= \frac{1}{\sqrt{2\pi\sigma^2}}\exp\left(-\frac{\mu^2}{2\sigma^2}\right)\exp\left(-\frac{1}{2\sigma^2}x^2 + \frac{\mu}{\sigma^2}x\right)$$

단, $a(\mu,\sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}}\exp\left(-\frac{\mu^2}{2\sigma^2}\right)$, $b(x) = 1$,

$$c_1(\mu,\sigma^2) = -\frac{1}{2\sigma^2},\ c_2(\mu,\sigma^2) = \frac{\mu}{\sigma^2},\ t_1(x) = x^2,\ t_2(x) = x$$

로 표현되므로 지수족에 속한다. 여기에서 $\{x : f(x;\mu,\sigma^2) > 0\}$은 실수 전체이므로 모수에 의존하지 않는다.

이외에도 지수족에 속하는 확률분포들로는 지수분포, 베타분포, 감마분포, 음이항분포 등이 있다. 그러나 $U(0,\theta)$ 분포나, 확률밀도함수가 $f(x;\theta) = \exp(-(x-\theta))$, $\theta < x < \infty$인 이동지수(shifted exponential)분포와 같이 $f(x;\theta) > 0$인 x값의 영역이 모수 θ에 의존하는 경우 이들은 지수족에 속하지 않는다. 한편, 지수족에 대해서는 다음의 정리 4.7에 의하여 완비충분성이 갖추어지므로 최소분산 비편향추정량을 구하는

나 정리 4.7의 증명은 매우 복잡하므로 여기에서는 생략하기로 한다).

정리 4.7

지수족에 속하는 확률밀도함수 $f(x;\theta)=a(\theta)b(x)\exp\left[\sum_{i=1}^{k}c_i(\theta)t_i(x)\right]$ 로부터 랜덤표본 $X_1, X_2, \cdots, X_n$ 을 얻었다면, 통계량 $S_1=\sum_{i=1}^{n}t_1(X_i), \cdots, S_k=\sum_{i=1}^{n}t_k(X_i)$는 모수 $\theta_1, \cdots, \theta_k$ 에 대한 결합 완비 충분통계량이다.

정리 4.7에 의하면 $(S_1, \cdots, S_k)$ 의 함수로 만들어지는 $(\theta_1, \cdots, \theta_k)$ 의 비편향 추정량은 $(\theta_1, \cdots, \theta_k)$ 의 최소분산 비편향추정량이 된다.

주 완비 충분통계량의 1:1 함수도 완비 충분통계량이 된다.

예 4.35

$X_1, X_2, \cdots, X_n$ 을 베르누이(p)로부터 구한 랜덤표본이라고 하면 결합 확률밀도함수는

$$f(x_1, x_2, \cdots, x_n; p)=p^{\sum_{i=1}^{n}x_i}(1-p)^{n-\sum_{i=1}^{n}x_i} \qquad (x_i=0, 1, \quad 0<p<1)$$

이며, 예 4.34와 정리 4.7에 의하여 $S=\sum_{i=1}^{n}X_i$는 모수 p에 대한 완비 충분통계량이다(정리 4.7을 사용하지 않고도 이미 예 4.26과 4.31에서 충분성과 완비성을 보였다). 이제 $Var(X)=p(1-p)$에 대한 최소분산 비편향추정량을 구하고자 한다. 이에 완비 충분통계량의 함수인 $\overline{X}_n(1-\overline{X}_n)$을 시도해 보면

$$\begin{aligned}E[\overline{X}_n(1-\overline{X}_n)] &= E(\overline{X}_n)-E(\overline{X}_n^{\,2})\\ &= p-[p^2+Var(\overline{X}_n)]\\ &= p-p^2-\frac{p(1-p)}{n}\\ &= p(1-p)\left[1-\frac{1}{n}\right]\end{aligned}$$

이 되므로, $\dfrac{\overline{X}_n(1-\overline{X}_n)}{\left[1-\dfrac{1}{n}\right]}=\dfrac{n\overline{X}_n(1-\overline{X}_n)}{n-1}$ 는 완비 충분통계량의 함수이면서 비편향추정량이므로 $Var(X)=p(1-p)$의 최소분산 비편향추정량이다.

예 4.36

$X_1, X_2, \cdots, X_n$을 $\mathrm{POI}(\lambda)$ 분포로부터 구한 랜덤표본이라고 하면, 이들의 결합 확률밀도함수는

$$\prod_{i=1}^{n} f(x_i;\lambda)=\frac{\exp(-n\lambda)\lambda^{\sum_{i=1}^{n}x_i}}{\prod_{i=1}^{n}x_i!}, \qquad (x_i=0, 1, 2, \cdots)$$

가 되고, 예 4.34와 정리 4.7에 의하여 $\sum_{i=1}^{n} X_i$은 완비 충분통계량이며 그의 $1:1$ 함수인 $\overline{X}_n$도 완비 충분통계량이다. 이제 모수 λ에 대한 추정량으로 표본평균 $\overline{X}_n$를 사용한다면, $E(\overline{X}_n)=\lambda$이므로 이는 최소분산 비편향추정량이 된다.

예 4.37

$X_1, X_2, \cdots, X_n$이 $N(\mu, \sigma^2)$으로부터 구한 랜덤표본이라고 할 때 이들의 결합 확률밀도함수는

$$f(x_1, x_2, \cdots, x_n;\mu, \sigma^2)=(2\pi\sigma^2)^{-n/2}\exp\left(-\sum_{i=1}^{n}(x_i-\mu)^2/2\sigma^2\right)$$

로 주어진다. 그런데 $\sum_{i=1}^{n}(x_i-\mu)^2=\sum_{i=1}^{n}x_i^2-2\mu\sum_{i=1}^{n}x_i+n\mu^2$으로 표현되므로

$$\begin{aligned} &f(x_1, x_2, \cdots, x_n;\mu, \sigma^2)\\ &\quad=(2\pi\sigma^2)^{-n/2}\exp\left(-\sum_{i=1}^{n}x_i^2/2\sigma^2+(\mu/\sigma^2)\sum_{i=1}^{n}x_i-n\mu^2/2\sigma^2\right)\end{aligned}$$

으로 나타낼 수 있다. 따라서 예 4.34와 정리 4.7로부터 $S_1=\sum_{i=1}^{n}X_i$와 $S_2=$

$\sum_{i=1}^{n} X_i^2$은 각각 결합 완비 충분통계량이다. 이들의 함수인 표본평균 $\overline{X}_n$와 표본분산 $\sum_{i=1}^{n}(X_i-\overline{X}_n)^2/(n-1)$은 $E(\overline{X}_n)=\mu$, $E\left(\sum_{i=1}^{n}(X_i-\overline{X}_n)^2/(n-1)\right)=\sigma^2$으로 μ와 σ^2의 비편향추정량이므로, 이들은 최소분산 비편향추정량이다. 또한 만일 모평균 μ의 값이 알려져 있다면, 모수의 숫자 $k=1$이고 $\sum_{i=1}^{n}(X_i-\mu)^2$은 완비 충분통계량이며 $E\left(\sum_{i=1}^{n}(X_i-\mu)^2/n\right)=\sigma^2$이므로 $\sum_{i=1}^{n}(X_i-\mu)^2/n$이 모분산 σ^2의 최소분산 비편향추정량이 된다. 이 경우 모분산 σ^2의 최대가능도 추정량도 $\sum_{i=1}^{n}(X_i-\mu)^2/n$이므로 두 추정량이 동일하지만, 모평균 μ를 모르는 경우에는 σ^2의 최대가능도 추정량이 $\sum_{i=1}^{n}(X_i-\overline{X}_n)^2/n$이 되어, 최소분산 비편향추정량 $\sum_{i=1}^{n}(X_i-\overline{X}_n)^2/(n-1)$과 다름을 볼 수 있다.

나아가, 완비 충분통계량의 성질을 나타내는 바수(Basu)의 정리를 살펴보자.

정리 4.8

(바수 정리) 통계량 $S=(S_1,\cdots,S_k)$가 모수 $\theta=(\theta_1,\cdots,\theta_k)$에 대한 결합 완비 충분통계량이라고 하자. 이때 어떤 통계량 T의 분포가 모수 $\theta=(\theta_1,\cdots,\theta_k)$에 의존하지 않으면, S와 T는 서로 독립이다.

증명 이산형인 경우를 고려하자. $f_T(t)$, $f_S(s;\theta)$, 그리고 $f(t|s)$를 각각 T, S의 확률밀도함수와 $S=s$일 때 T의 조건부 확률밀도함수라고 하면,

$$\begin{aligned} E_\theta[f_T(t)-f(t|S)] &= f_T(t)-\sum_s f(t|s)f(s;\theta) \\ &= f_T(t)-\sum_s f(s,t;\theta) \\ &= f_T(t)-f_T(t) \\ &= 0 \end{aligned}$$

이 성립한다. S의 충분성에 의해 $f_T(t)-f(t|S)$는 θ에 의존하지 않고 S의 완비성에 의하여 모든 s에 대해 $f(t|s)=f_T(t)$가 성립하므로 S와 T는 서로 독

립이다. 연속형 확률변수에 대해서도 마찬가지 방법으로 증명될 수 있다. ■

위의 정리에서와 같이 확률밀도함수가 θ에 의존하지 않는 통계량 T를 θ에 대한 보조통계량(ancillary statistic)이라고 한다. 바수의 정리를 이용하면, 두 통계량의 독립을 보이는 데 있어서 때로는 두 통계량의 복잡한 결합분포를 구하지 않아도 된다는 장점이 있다. 다음의 예를 살펴보자.

예 4.38

$X_1, \cdots, X_n$을 $N(\mu, \sigma^2)$로부터의 랜덤표본일 때, $\widehat{\sigma^2} = \sum_{i=1}^{n}(X_i - \overline{X}_n)^2/n$과 $\hat{\mu} = \overline{X}_n$를 생각해 보자. 고정된 σ^2에 대하여 표본평균 $\overline{X}_n$은 μ에 대한 완비 충분통계량이고, $\frac{n\widehat{\sigma^2}}{\sigma^2}$은 $\chi^2(n-1)$ 분포를 따르며 이는 μ에 의존하지 않는다. 즉, $\frac{n\widehat{\sigma^2}}{\sigma^2}$은 μ에 대한 보조통계량이 되고, 바수의 정리 4.8에 따라 $\hat{\mu} = \overline{X}_n$와 $\widehat{\sigma^2} = \sum_{i=1}^{n}(X_i - \overline{X}_n)^2/n$은 서로 독립이다.

4.5 추정량의 점근적 성질

앞에서 다루었던 추정량의 비편향성 또는 최소분산성 등은 고정된 표본의 크기(n)에 대해 정의된 성질들이었다. 여기에서는 표본의 크기가 커짐에 따라 가지는 추정량의 점근적(asymptotic) 성질에 대해 살펴보기로 한다. 즉, 점점 더 많은 관측치를 갖는 표본을 뽑는다고 가정하고 궁극에는 어떤 일이 일어날 것인지에 대해 살펴보는 것이다.

정의 4.9

모수의 함수 $g(\theta)$의 추정량 $T_n(X) = T(X_1, X_2, \cdots, X_n)$이, 임의의 $\varepsilon > 0$에 대하여

$$\lim_{n\to\infty} P(|T_n(X) - g(\theta)| \le \varepsilon) = 1$$

을 만족하면 추정량 $T_n(X)$는 **일치성**(consistency)이 있다고 한다.

정의 4.9는 표본의 크기가 커짐에 따라 $T_n(X)$가 $g(\theta)$에 확률적으로 수렴한다는 것으로(참조: 정의 3.5), 표본의 크기가 매우 클 때, 추정량 $T_n(X)$로부터 계산된 추정값은 높은 확률로 참모수값에 매우 가까이 있다는 뜻이다.

예 4.39

$X_1, X_2, \cdots, X_n$을 평균이 μ이고 분산이 $\sigma^2 < \infty$인 확률분포로부터 얻은 랜덤표본이라고 하자. 모평균 μ의 추정량으로서 표본평균 $T_n(X) = \overline{X}_n$가 일치성이 있음은 정리 3.12의 대수의 법칙에서 이미 보여졌다.

예 4.40

$X_1, X_2, \cdots, X_n$을 $U(0, \theta)$로부터 얻은 랜덤표본이라고 하자. 이때 최대가능도추정량은 표본최댓값 $X_{(n)}$이다(참조: 예 4.9). 이제 모수 θ의 추정량 $X_{(n)}$의 일치성에 대해 살펴보기로 한다. 임의의 $\varepsilon > 0$에 대하여,

$$\begin{aligned} P[\,|X_{(n)} - \theta| \le \varepsilon\,] &= P[\,\theta - \varepsilon \le X_{(n)} \le \theta\,] \\ &= \int_{\theta-\varepsilon}^{\theta} \frac{n(x_{(n)})^{n-1}}{\theta^n}\, dx_{(n)} \\ &= \frac{(x_{(n)})^n}{\theta^n}\Bigg|_{\theta-\varepsilon}^{\theta} \\ &= 1 - \left[\frac{\theta-\epsilon}{\theta}\right]^n \end{aligned}$$

이 성립한다. $0 < \varepsilon < \theta$이면 n이 커질 때 $\left(\frac{\theta-\varepsilon}{\theta}\right)^n \to 0$이므로 $P[\,|X_{(n)} - \theta| \le \varepsilon\,] \to 1$이 되고, $\varepsilon \ge \theta$이면 모든 n에 대해 $P[\,|X_{(n)} - \theta| \le \varepsilon\,] = 1$이 된다. 그러므로 표본최댓값 $X_{(n)}$은 θ의 일치추정량이다.

다음의 정리는 추정량이 일치성을 가질 조건을 평균제곱오차(MSE)를 이용하여 표현하고 있다.

정리 4.9

$T_n(X)$를 $g(\theta)$의 추정량이라고 할 때, 모든 $\theta \in \Omega$에 대하여

$$\lim_{n\to\infty} E[T_n(X)-g(\theta)]^2 = 0$$

이 성립하면, $T_n(X)$는 일치성이 있다.

증명 식 (2.16)의 확률부등식에 의하면, $X = T_n(X)-g(\theta)$, $r=2$, $c=\varepsilon$으로 놓을 때

$$P[\,|T_n(X)-g(\theta)| \le \varepsilon\,] \ge 1-\frac{E[T_n(X)-g(\theta)]^2}{\varepsilon^2}$$

이 성립하므로 일치성이 성립한다. ■

참고 그런데 $\mathrm{MSE}(T_n) = Var(T_n)+[E(T_n)-g(\theta)]^2$이므로 T_n이 $g(\theta)$의 비편향추정량인 경우 $\lim_{n\to\infty} Var(T_n)=0$이 성립하면, 정리 4.9로부터, 추정량 T_n의 일치성이 보장된다.

예 4.41

$X_1, X_2, \cdots, X_n$을 $\mathrm{EXP}(\lambda)$로부터 얻은 랜덤표본이라고 하자. 이때 λ의 추정량으로 $\overline{X}_n$는 비편향추정량이며 $\lim_{n\to\infty}\mathrm{MSE}(\overline{X}_n) = \lim_{n\to\infty} Var(\overline{X}_n)=0$이므로 $\overline{X}_n$는 일치성이 있다. 한편, $nX_{(1)} \sim \mathrm{EXP}(\lambda)$이므로(참조: 예 3.14), $nX_{(1)}$은 λ의 비편향추정량이다. 하지만 $\epsilon < \lambda$인 $\epsilon > 0$에 대해 $P(|nX_{(1)}-\lambda| \le \epsilon) = e^{-1}(e^{\epsilon/\lambda}-e^{-\epsilon/\lambda})$으로 n이 커질 때 1로 수렴하지 않으므로 일치추정량이 아니다.

정리 4.10

T_n이 모수 θ의 일치추정량이라고 하자. 만일 $g(x)$가 θ에서 연속인 함수이면 $g(T_n)$은 $g(\theta)$의 일치추정량이다.

증명 $g(x)$가 θ에서 연속이므로, 임의의 $\varepsilon > 0$에 대하여 $|x-\theta| < \delta$이면 $|g(x)-g(\theta)| < \varepsilon$을 만족하는 $\delta > 0$가 존재한다. 그러므로

$$\lim_{n\to\infty} P[\,|\,g(T_n)-g(\theta)\,|\le \varepsilon\,] \ge \lim_{n\to\infty} P[\,|\,T_n-\theta\,|<\delta\,]=1$$

로부터 $g(T_n)$의 일치성이 구해진다. ■

다음의 정리는 추정량의 일치성을 보이기 위해 유용한 것으로, 증명은 연습문제로 남기기로 한다.

정리 4.11

T_n이 모수 θ_1의 일치추정량이고, S_n이 모수 θ_2의 일치추정량이라고 하자. 그러면 $c_n\to c$이고 $d_n\to d$인 실수열 c_n과 d_n에 대해, $c_nT_n+d_nS_n \xrightarrow{p} c\theta_1+d\theta_2$이고, $T_n/S_n \xrightarrow{p} \theta_1/\theta_2$, $\theta_2\neq 0$, $T_nS_n \xrightarrow{p} \theta_1\theta_2$이다.

예 4.42

3장에서 살펴본 예 3.7에서, 모분산 $g(p)=p(1-p)$는 모수 p의 연속함수이며, 표본비율 p_n은 모비율 p로 확률적으로 수렴한다. 따라서 정리 4.10에 의하여 $g(p_n)=p_n(1-p_n)$도 역시 모분산 $g(p)=p(1-p)$의 일치추정량이다.

예 4.43

$X_1, X_2, \cdots, X_n$이 분산이 유한인 분포에서 뽑힌 랜덤표본이라고 할 때, 표본분산

$$S^2=\sum_{i=1}^{n}(X_i-\overline{X}_n)^2/(n-1)$$

은 모분산 σ^2의 일치추정량이다. 왜냐하면 $S^2=\frac{n}{n-1}\times\frac{1}{n}\sum_{i=1}^{n}X_i^2-\frac{n}{n-1}\overline{X}_n^2$으로 쓸 수 있고, 대수의 법칙에 의해 $\frac{1}{n}\sum_{i=1}^{n}X_i^2 \xrightarrow{p} E(X^2)$, $\overline{X}_n \xrightarrow{p} E(X)$이며 $\frac{n}{n-1}\to 1$이므로 정리 4.11에 의해 $S^2 \xrightarrow{p} E(X^2)-(E(X))^2=\sigma^2$이다. 이제, $g(S^2)=\sqrt{S^2}=S$는 $g(\cdot)$가 연속함수이므로 $g(\sigma^2)=\sqrt{\sigma^2}=\sigma$의 일치추정량이다.

최대가능도 추정량은 불변성 원리와 같이 다루기 편리한 성질도 가지고 있지만, 때로 복잡한 형태를 갖게 되어 직접적으로 일치성을 입증하기 어려운 경우도 있고 심지어 폐쇄형(closed-form)으로 존재하지 않아서 수치적으로밖에 구할 수 없는 경우도 있다. 이럴 때는 최대가능도 추정량에 근거를 둔 구간추정을 하거나 검정을 하는 데에 어려움이 발생할 수 있는데, 적절한 정칙조건이 만족되는 경우에는 점근적 성질을 이용하면 편리하다. 적절한 조건하에서 최대가능도 추정량은 일치성을 가질 뿐 아니라 점근적으로 정규분포를 따르기 때문에 쉽게 근사적 구간추정과 검정을 할 수 있게 된다. 이제, 이러한 최대가능도 추정량의 점근적 성질에 대해 간단히 다루어 보자.

$X_1, \cdots, X_n$이 확률밀도함수 $f(x;\theta)$를 갖는 확률분포로부터의 랜덤표본이고 $\hat{\theta}_n$이 θ의 최대가능도 추정량이라고 하자. 로그가능도함수 (4.4)의 θ에 대한 1차 도함수는 $\hat{\theta}_n$에서 0이 되므로 $\sum_{i=1}^{n} \frac{d}{d\theta} \log f(x_i;\theta)\Big|_{\theta=\hat{\theta}_n} = 0$이며, 대수의 법칙에 의해

$$\frac{1}{n}\sum_{i=1}^{n} \frac{d}{d\theta} \log f(X_i;\theta) \xrightarrow{p} E\left(\frac{d}{d\theta} \log f(X;\theta)\right) \tag{4.9}$$

가 성립한다(단, 우변의 기댓값이 존재한다는 조건이 있을 때). 그런데 식 (4.9)의 왼쪽과 오른쪽을 0으로 하는 해는 각각 최대가능도 추정량 $\hat{\theta}_n$과 모수의 참값인 θ_0이다(참조: 연습문제 4.51). 따라서 적절한 조건에서 $\hat{\theta}_n$이 θ_0으로 수렴할 것으로 기대할 수 있다(여기에서 '적절한 조건'이란 모수의 값이 달라지면 확률밀도함수가 달라지고, 확률밀도함수가 0이 아닌 집합이 모수에 의존하지 않으며, 모수공간이 열려 있고, 로그가능도함수가 두 번 미분 가능하며, 그리고 모수에 대한 미분과 기댓값을 취하기 위한 적분의 순서를 바꿀 수 있는 것을 말한다. 이 책의 수준에서는 θ에 대해 여러 번 미분 가능한 지수족의 경우 이 조건이 만족된다고 간주할 수 있다). 다음의 정리는 적절한 조건이 만족될 때, 최대가능도 추정량이 모수의 일치추정량이 됨을 말하고 있다. 엄밀한 증명은 이 책의 수준을 넘으므로 생략하기로 한다.

정리 4.12

$X_1, X_2, \cdots, X_n$이 확률밀도함수 $f(x;\theta)$를 갖는 랜덤표본일 때 적절한 조건하에서 최대가능도 추정량 $\hat{\theta}_n$은 θ의 일치추정량이다. 즉, $\hat{\theta}_n \xrightarrow{p} \theta$이다.

나아가, 최대가능도 추정량이 가지는 점근적 정규성을 살펴보겠다. 가능도함수를

$L(\theta)$, 로그가능도함수를 $l(\theta)=\log L(\theta)$라고 하고, $L(\theta)=\prod_{i=1}^{n} f(X_i;\theta)$로 $L(\theta)$가 확률변수 X_i들의 함수로서 그 자체가 확률변수라고 생각하자. 그러면 $l(\theta)=\sum_{i=1}^{n}\log f(X_i;\theta)$는 서로 독립이고 분포가 같은 n개의 확률변수의 합으로 표현된다. 모수의 참값이 θ_0일 때, 로그가능도함수를 미분한 $l'(\theta)$를 θ_0에서 테일러 전개하여 $\hat{\theta}_n$을 대입하고 처음 두 항만을 취하면 $l'(\hat{\theta}_n)\approx l'(\theta_0)+l''(\theta_0)(\hat{\theta}_n-\theta_0)$로 나타낼 수 있다. $\hat{\theta}_n$이 θ_0의 일치추정량이므로 n이 커질 때 두 값이 확률적으로 매우 가까우므로 테일러 전개에서 고차항들은 무시할 수 있는 값일 것이다. $l'(\hat{\theta}_n)=0$이므로,

$$\hat{\theta}_n-\theta_0\approx -\frac{l'(\theta_0)}{l''(\theta_0)}$$

과 같은 근사식을 얻을 수 있고, 이로부터

$$\sqrt{n}(\hat{\theta}_n-\theta_0)\approx \frac{\frac{1}{\sqrt{n}}l'(\theta_0)}{-\frac{1}{n}l''(\theta_0)}$$

을 얻는다. 그런데 적절한 조건하에서 대수의 법칙에 의해

$$-\frac{1}{n}l''(\theta_0)=-\frac{1}{n}\sum_{i=1}^{n}\frac{d^2}{d\theta^2}\log f(X_i;\theta)\Big|_{\theta=\theta_0}\xrightarrow{p}-E\left(\frac{d^2}{d\theta^2}\log f(X;\theta)\Big|_{\theta=\theta_0}\right)=I(\theta_0)$$

이며 $\frac{1}{\sqrt{n}}l'(\theta_0)\xrightarrow{d}N(0,I(\theta_0))$이 성립한다(참조: 연습문제 4.52, 4.53). 여기에서 $I(\theta_0)$은 4.3절에서 정의된 피셔의 정보를 θ_0에서 측정한 값이다. 이제 정리 3.15의 슬럿츠키 정리를 이용하면 다음과 같은 최대가능도 추정량의 점근적 정규성을 보일 수 있다.

정리 4.13

$X_1, X_2, \cdots, X_n$이 확률밀도함수 $f(x;\theta)$를 갖는 랜덤표본이고 모수의 참값이 θ_0일 때, 적절한 조건하에서 최대가능도 추정량 $\hat{\theta}_n$에 대해

$$\sqrt{n}(\hat{\theta}_n-\theta_0)\xrightarrow{d}N\left(0,\frac{1}{I(\theta_0)}\right)$$

이 성립한다.

예 4.44

$X_1, \cdots, X_n$이 EXP(θ)에서 관측되는 랜덤표본이라고 하자. θ의 최대가능도 추정량은

$$l(\theta; x_1, \cdots, x_n) = -n\log\theta - \frac{\sum_{i=1}^{n} x_i}{\theta}, \quad l'(\theta) = -\frac{n}{\theta} + \frac{\sum_{i=1}^{n} x_i}{\theta^2}$$

으로부터 $\hat{\theta}_n = \overline{X}_n$이고, $\frac{\partial^2}{\partial\theta^2}\log f(x;\theta) = \frac{1}{\theta^2} - \frac{2x}{\theta^3}$ 이므로 $I(\theta) = E_\theta\left(\frac{2X}{\theta^3} - \frac{1}{\theta^2}\right)$ $= \frac{1}{\theta^2}$이다. 그러므로 정리 4.13에 의해,

$$\sqrt{n}\,(\overline{X}_n - \theta) \xrightarrow{d} N(0, \theta^2)$$

가 되고, 이것은 중심극한정리에서 얻는 결과와 동일하다.

4.6 구간추정

지금까지 비편향성(unbiasedness), 적률(moments), 가능도(likelihood) 등의 기준하에서 모수 또는 모수의 함수에 대한 최적추정량들을 고려하였으나 이들은 점추정 문제여서 통계적 정확도(statistical accuracy)를 표현하지 못한다는 결점이 있다. 예를 들면, 포아송(λ)의 경우 모수 λ의 추정량으로서 표본평균 $\overline{X}_n$는 좋은 추정량이지만 정확성에 관한 아무런 정보를 포함하고 있지 않다. 표본평균은 확률변수이므로, 실제 관측된 자료로부터 계산된 표본평균의 값이 정확히 모수와 같을 것으로 생각할 수는 없다. 그렇다면 이 값은 모수로부터 어느 정도 떨어져 있을까? 이러한 정보를 포함하도록 추정결과를 제시하는 방법이 구간추정이며, 구간추정에서는 랜덤표본 X_1, X_2, $\cdots$, X_n에 근거하여 모수에 대한 신뢰구간을 정의하고 그 구간 내에 모수가 포함될 확률로써 통계적 정확도를 표현할 것이다.

정의 4.10

랜덤표본 X_1, X_2, $\cdots$, X_n의 확률밀도함수가 $f(x;\theta)$, $\theta \in \Omega$라고 하자. 확률구

간 $[L(X_1, X_2, \cdots, X_n), U(X_1, X_2, \cdots, X_n)]$이, $0 < \alpha < 1$에 대하여

$$P[L(X_1, X_2, \cdots, X_n) \leq \theta \leq U(X_1, X_2, \cdots, X_n)] = 1 - \alpha$$

를 만족시키면 이를 모수 θ의 $100(1-\alpha)\%$ **신뢰구간**(confidence interval)이라고 한다. 또한 $L(X_1, X_2, \cdots, X_n)$과 $U(X_1, X_2, \cdots, X_n)$을 각각 신뢰구간의 **하한**(lower limit)과 **상한**(upper limit)이라고 한다.

정의 4.10에서 구한 신뢰구간은 표본에 따라 그 결과가 달라지는 확률구간(random interval)이다. 따라서 $(1-\alpha)$는 랜덤표본 $X_1, X_2, \cdots, X_n$의 구체적인 관찰값이 주어지기 이전에 해당하는 확률이다. 즉, 수많은 랜덤표본을 뽑아서 각 표본에 대해 같은 방법으로 신뢰구간을 구하면, 구해진 많은 신뢰구간들 가운데 $100(1-\alpha)\%$ 만큼의 신뢰구간들이 모수를 포함하게 된다는 뜻이다. 이제 크기 n의 표본을 직접 관측했다고 가정하자. 주어진 관찰값 $x = (x_1, \cdots, x_n)$을 $U(X_1, \cdots, X_n)$과 $L(X_1, \cdots, X_n)$에 대입하면 두 개의 고정된 값이 계산될 것이다. 그러면, $[L(x_1, \cdots, x_n), U(x_1, \cdots, x_n)]$은 고정된 구간이 된다. 그리고 모수 θ는 구간 $[L(x_1, \cdots, x_n), U(x_1, \cdots, x_n)]$에 포함되거나 되지 않거나 둘 중의 하나일 뿐이다(이는 점추정에 있어서 추정량과 추정값의 차이와 같다). 즉, 이 고정된 구간이 모수를 포함하게 되는 확률이 $1-\alpha(0 < \alpha < 1)$가 될 수 없다는 것이다. 우리가 관측한 표본에 의해 계산된 신뢰구간은 모수를 포함할 수도 있지만 포함하지 않을 수도 있다. 운이 나쁜 경우에는 모수와 동떨어진 구간을 얻을 수도 있으나, 이러한 구간을 얻을 확률을 $100\alpha\%$로 한정시키게 된다. α가 매우 작은 값, 예를 들어 0.01이라면 우리의 신뢰구간이 '성공'일 확률이 99%라는 것이다. 확률 $1-\alpha$는 **신뢰계수**(confidence coefficient) 또는 **신뢰도**(confidence level)라고 한다. 또한 때로는 신뢰구간이 실직선상의 반구간이 되는 수도 있으며, 이를 다음과 같이 정의한다.

정의 4.11

랜덤표본 $X_1, X_2, \cdots, X_n$의 확률밀도함수가 $f(x;\theta)$, $\theta \in \Omega$라고 하자. 통계량 $L(X_1, X_2, \cdots, X_n)$이 $0 < \alpha < 1$에 대하여

$$P[L(X_1, X_2, \cdots, X_n) \leq \theta] = 1 - \alpha$$

를 만족시키면 $[L(X_1, X_2, \cdots, X_n), +\infty)$를 모수 θ의 $100(1-\alpha)\%$ **단측 하**

한신뢰구간이라고 한다. 또, 통계량 $U(X_1, X_2, \cdots, X_n)$이 $0 < \alpha < 1$에 대하여

$$P[\theta \leq U(X_1, X_2, \cdots, X_n)] = 1 - \alpha$$

를 만족시키면 $(-\infty, U(X_1, X_2, \cdots, X_n)]$를 모수 θ의 $100(1-\alpha)\%$ **단측 상 한신뢰구간**이라고 한다.

예 4.45

$X_1, X_2, \cdots, X_n$을 $N(\mu, 25)$로부터 얻은 랜덤표본이라고 하자. 이때 $L(X_1, X_2, \cdots, X_n) = \overline{X}_n - \frac{10}{\sqrt{n}}$, $U(X_1, X_2, \cdots, X_n) = \overline{X}_n + \frac{10}{\sqrt{n}}$ 이라고 하면, $[L(X_1, X_2, \cdots, X_n), U(X_1, X_2, \cdots, X_n)]$은 확률구간이 되고, 이는 곧 모평균 μ에 대한 신뢰도가

$$\begin{aligned} & P[L(X_1, X_2, \cdots, X_n) \leq \mu \leq U(X_1, X_2, \cdots, X_n)] \\ &= P\left[\overline{X}_n - \frac{10}{\sqrt{n}} \leq \mu \leq \overline{X}_n + \frac{10}{\sqrt{n}}\right] \\ &= P\left[\left|\frac{\sqrt{n}(\overline{X}_n - \mu)}{5}\right| \leq 2\right] \\ &= \Phi(2) - \Phi(-2) \\ &= 0.9544 \end{aligned}$$

인 신뢰구간이다.

그런데 신뢰구간을 구하는 방법으로는 **추축변량**(pivotal quantity)을 사용하는 방법과 추축변량을 구하기 힘든 경우에 사용되는 일반적인 접근방법을 생각할 수 있다. 먼저 추축변량의 사용에 대해 알아보기로 한다. 이 방법은 특히 랜덤표본이 따르는 분포가 연속형일 때 신뢰구간을 구하는 데 유용하다.

정의 4.12

랜덤표본 $X_1, X_2, \cdots, X_n$의 분포가 확률밀도함수 $f(x;\theta)$, $\theta \in \Omega$를 따른다고 하자. 이때 표본과 모수 θ의 함수인 확률변량 $T(X_1, X_2, \cdots, X_n; \theta)$의 분포가 모수 θ에 의존하지 않으면 이를 **추축변량**이라고 한다.

예 4.46

$X_1, X_2, \cdots, X_n$이 $N(\mu, \sigma^2)$에서의 랜덤표본이고 $S_n^2 = \sum_{i=1}^{n}(X_i - \overline{X}_n)^2/(n-1)$일 때, $\sqrt{n}(\overline{X}_n - \mu)/S_n$의 분포는 $t(n-1)$로 모수 (μ, σ^2)에 의존하지 않으므로 추축변량이다.

추축변량을 활용하여 모수의 신뢰구간을 구하는 방법은 다음과 같다. $T = T(X_1, \cdots, X_n ; \theta)$가 추축변량이면, 고정된 $0 < \alpha < 1$에 대하여 $P(t_1 < T < t_2) = 1 - \alpha$를 만족하는 t_1, t_2를 구한다. T의 분포가 모수에 의존하지 않으므로 t_1과 t_2는 α의 값이 주어지면 상수값이 될 것이다. 다음으로 부등식 $t_1 < T(x_1, \cdots, x_n ; \theta) < t_2$를 $L(x_1, \cdots, x_n) < \theta < U(x_1, \cdots, x_n)$의 꼴로 바꿔쓸 수 있다면,

$$P(L(X_1, \cdots, X_n) < \theta < U(X_1, \cdots, X_n)) = 1 - \alpha$$

가 되므로 $[L(X_1, \cdots, X_n),\ U(X_1, \cdots, X_n)]$은 θ에 대한 $100(1-\alpha)\%$ 신뢰구간이 된다. 그런데 추축변량이 언제나 존재한다든가 또는 유일하다는 보장은 없고, 사용하는 추축변량에 따라 서로 다른 신뢰구간들을 얻게 된다. 따라서 우리가 구한 신뢰구간의 성능을 가늠하고 비교하는 기준이 필요하게 되며, 고정된 신뢰도에 대하여 신뢰구간의 길이 등을 그 기준으로 사용할 수 있다.

이제 정규분포로부터 구한 랜덤표본에 근거하여 모수들의 신뢰구간을 구해본다.

정규분포의 모평균에 대한 신뢰구간

$X_1, X_2, \cdots, X_n$을 $N(\mu, \sigma^2)$으로부터의 랜덤표본이라고 하고, 모평균 μ에 대한 신뢰구간을 구해 보자. 이 경우, 모분산 σ^2이 알려져 있으면 변량 $\sqrt{n}(\overline{X}_n - \mu)/\sigma$의 분포는 $N(0, 1)$으로서 모수 (μ, σ^2)에 의존하지 않으므로 추축변량이다. 따라서

$$\begin{aligned} & P\left[-z_{\alpha/2} \le \frac{\sqrt{n}(\overline{X}_n - \mu)}{\sigma} \le z_{\alpha/2} \right] \\ &= P\left[\overline{X}_n - z_{\alpha/2}\frac{\sigma}{\sqrt{n}} \le \mu \le \overline{X}_n + z_{\alpha/2}\frac{\sigma}{\sqrt{n}} \right] \\ &= 1 - \alpha \end{aligned}$$

에 의하여 모평균 μ에 대한 $100(1-\alpha)\%$ 신뢰구간

$$\left[\overline{X}_n - z_{\alpha/2}\frac{\sigma}{\sqrt{n}},\ \overline{X}_n + z_{\alpha/2}\frac{\sigma}{\sqrt{n}} \right] \tag{4.10}$$

을 구할 수 있다(z_α는 표준정규분포의 임계값(critical value)으로서, $100(1-\alpha)\%$ 백분위수이다). 그러나 모분산 σ^2이 알려져 있지 않은 경우에는, 위의 구간 (4.10)이 모르는 모수인 σ^2의 값에 의존하기 때문에 사용할 수 없다. 따라서 σ^2를 $S_n^2 = \sum_{i=1}^{n}(X_i - \overline{X}_n)^2/(n-1)$으로 추정한 추축변량 $\sqrt{n}(\overline{X}_n - \mu)/S_n$이 자유도가 $(n-1)$인 t 분포를 가지는 점을 이용하여 다음과 같이 구할 수 있다.

$$\begin{aligned} & P\left[-t_{\alpha/2}(n-1) \le \frac{\sqrt{n}(\overline{X}_n - \mu)}{S_n} \le t_{\alpha/2}(n-1) \right] \\ &= P\left[\overline{X}_n - t_{\alpha/2}(n-1)\frac{S_n}{\sqrt{n}} \le \mu \le \overline{X}_n + t_{\alpha/2}(n-1)\frac{S_n}{\sqrt{n}} \right] \\ &= 1-\alpha \end{aligned}$$

에 의하여 모평균 μ에 대한 $100(1-\alpha)\%$ 신뢰구간

$$\left[\overline{X}_n - t_{\alpha/2}(n-1)\frac{S_n}{\sqrt{n}},\ \overline{X}_n + t_{\alpha/2}(n-1)\frac{S_n}{\sqrt{n}} \right] \tag{4.11}$$

이 구해진다($t_\alpha(n)$은 자유도가 n인 t 분포의 임계값으로서, $100(1-\alpha)\%$ 백분위수이다).

이와 같이 구한 신뢰구간의 의미를 다시 한 번 살펴보기로 하자. 관찰값이 $X_1 = x_1$, $X_2 = x_2$, $\cdots$, $X_n = x_n$으로 주어지면, 이들의 평균을 $\overline{x}_n$라고 했을 때, 식 (4.10)의 신뢰구간은 $[\overline{x}_n - z_{\alpha/2}(\sigma/\sqrt{n}),\ \overline{x}_n + z_{\alpha/2}(\sigma/\sqrt{n})]$의 값이 알려진 구간이 된다. 이는 $\overline{x}_n$에 대해 대칭이며, 구간의 길이는 모분산 σ^2이 작을수록 또 표본의 크기 n이 커질수록 짧아짐을 볼 수 있다. 실제로 위에서 구한 신뢰구간 (4.10)과 (4.11)은 주어진 신뢰도에 대하여 구간의 길이를 가장 짧게 하는 최적성도 가지고 있다. 그런데 어떤 주어진 표본에 대해 모수(여기에서는 모평균)의 신뢰구간은 그 모수를 포함하거나 포함하지 않거나 둘 중의 하나이다. 즉, 모수는 고정된 숫자이므로, 고정된 구간이 모수를 90% 포함하거나 하는 일은 없다. 그러나 독립된 여러 개의 표본에 근거하여 모수의 $100(1-\alpha)\%$ 신뢰구간들을 구해 보면 그 신뢰구간들의 $100(1-\alpha)\%$ 정도가 모수를 포함한다. 가령, 100개의 독립표본에 근거하여 모수 θ에 대한 100개의 90% 신

뢰구간들을 구하면 그들 중 약 90개 정도에 모수가 포함된다. 이는 성공확률이 $p=0.9$인 베르누이 시행을 독립적으로 100회 반복시행했을 때 얻는 성공횟수와 동일한 개념이다. 따라서 신뢰구간의 신뢰도에 대해서는 상대도수(relative frequency)에 의한 해석이 가능하다. 이와 같은 내용은 이 책에서 구하는 모든 신뢰구간(다음 절에서 다룰 베이즈 신뢰구간 제외)에 해당된다.

정규분포의 모분산에 대한 신뢰구간

$X_1, X_2, \cdots, X_n$을 $N(\mu, \sigma^2)$으로부터의 랜덤표본이라고 할 때, 모분산 σ^2에 대한 신뢰구간을 구해 보기로 하자. 이때에는, 장애모수인 모평균 μ를 아는 경우와 그렇지 않은 경우가 있다. 모평균 μ가 알려진 경우에는 $\sum_{i=1}^{n}(X_i-\mu)^2/\sigma^2$이 자유도가 n인 카이제곱분포를 따르는 추축변량인 점에 근거하여 σ^2에 대한 신뢰구간을 다음과 같이 구할 수 있다.

$$
\begin{aligned}
& P\left[\chi^2_{1-\alpha/2}(n) \le \frac{\sum_{i=1}^{n}(X_i-\mu)^2}{\sigma^2} \le \chi^2_{\alpha/2}(n)\right] \\
&= P\left[\frac{\sum_{i=1}^{n}(X_i-\mu)^2}{\chi^2_{\alpha/2}(n)} \le \sigma^2 \le \frac{\sum_{i=1}^{n}(X_i-\mu)^2}{\chi^2_{1-\alpha/2}(n)}\right] \\
&= 1-\alpha
\end{aligned}
$$

이므로

$$
\left[\frac{\sum_{i=1}^{n}(X_i-\mu)^2}{\chi^2_{\alpha/2}(n)}, \quad \frac{\sum_{i=1}^{n}(X_i-\mu)^2}{\chi^2_{1-\alpha/2}(n)}\right] \tag{4.12}
$$

이 모분산 σ^2에 대한 $100(1-\alpha)\%$ 신뢰구간이 된다.

한편, 모평균 μ가 알려지지 않은 경우에는 μ를 표본평균 $\overline{X}_n$로 추정한 통계량 $(n-1)S_n^2/\sigma^2 = \sum_{i=1}^{n}(X_i-\overline{X}_n)^2/\sigma^2$이 자유도가 $n-1$인 카이제곱분포를 따르는 추축변량인 점에 근거하여 다음과 같이 구할 수 있다. 카이제곱분포는 대칭이 아니나 양쪽 꼬리부분에서 $\alpha/2$씩의 확률을 고려하면,

$$P\left[\chi^2_{1-\alpha/2}(n-1) \le \frac{\sum_{i=1}^{n}(X_i-\overline{X}_n)^2}{\sigma^2} \le \chi^2_{\alpha/2}(n-1)\right]$$
$$= P\left[\frac{\sum_{i=1}^{n}(X_i-\overline{X}_n)^2}{\chi^2_{\alpha/2}(n-1)} \le \sigma^2 \le \frac{\sum_{i=1}^{n}(X_i-\overline{X}_n)^2}{\chi^2_{1-\alpha/2}(n-1)}\right]$$
$$= 1-\alpha$$

가 성립한다($\chi^2_\alpha(n)$은 자유도가 n인 χ^2분포의 임계값으로서 $100(1-\alpha)\%$ 백분위수이다). 따라서,

$$\left[\frac{\sum_{i=1}^{n}(X_i-\overline{X}_n)^2}{\chi^2_{\alpha/2}(n-1)}, \quad \frac{\sum_{i=1}^{n}(X_i-\overline{X}_n)^2}{\chi^2_{1-\alpha/2}(n-1)}\right] \tag{4.13}$$

가 모분산 σ^2에 대한 $100(1-\alpha)\%$ 신뢰구간이 된다.

두 정규분포의 모평균의 차이에 대한 신뢰구간

독립인 두 개의 랜덤표본 $X_1, X_2, \cdots, X_n$과 $Y_1, Y_2, \cdots, Y_m$의 분포가 각각 $N(\mu_X, \sigma_X^2)$과 $N(\mu_Y, \sigma_Y^2)$일 때, 두 모평균의 차이 $\mu_X-\mu_Y$에 대한 신뢰구간을 구하는 방법에 대해서 논해보자. 표본평균의 차이 $(\overline{X}_n-\overline{Y}_m)$는 $N(\mu_X-\mu_Y, \sigma_X^2/n+\sigma_Y^2/m)$ 분포를 따른다. 두 모평균 각각의 값이 아닌 차이에만 관심이 있으므로 $\mu_X-\mu_Y$를 하나의 모수로 취급하고, 일표본인 경우와 마찬가지로 σ_X^2과 σ_Y^2을 아는 경우와 그렇지 않은 경우를 나누어 고려하기로 한다.

경우 1 모분산 σ_X^2과 σ_Y^2을 아는 경우:

표본평균의 차이를 표준화한 변량

$$Z=\frac{(\overline{X}_n-\overline{Y}_m)-(\mu_X-\mu_Y)}{\sqrt{\sigma_X^2/n+\sigma_Y^2/m}}$$

는 표준정규분포 $N(0, 1)$을 따르므로 $\mu_X-\mu_Y$의 추정에서 추축변량으로 사용될 수 있다. 따라서,

$$P\left[-z_{\alpha/2} \le \frac{(\overline{X}_n - \overline{Y}_m) - (\mu_X - \mu_Y)}{\sqrt{\sigma_X^2/n + \sigma_Y^2/m}} \le z_{\alpha/2} \right]$$

$$= P\left[(\overline{X}_n - \overline{Y}_m) - z_{\alpha/2}\sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}} \le \mu_X - \mu_Y \right.$$

$$\left. \le (\overline{X}_n - \overline{Y}_m) + z_{\alpha/2}\sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}} \right]$$

$$= 1 - \alpha$$

로부터 모평균의 차 $\mu_X - \mu_Y$에 대한 $100(1-\alpha)\%$ 신뢰구간은

$$\left[(\overline{X}_n - \overline{Y}_m) - z_{\alpha/2}\sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}},\quad (\overline{X}_n - \overline{Y}_m) + z_{\alpha/2}\sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}} \right] \qquad (4.14)$$

으로 주어진다.

경우 2 모분산 σ_X^2과 σ_Y^2을 모르는 경우:

우선, $\sigma_X^2 = \sigma_Y^2 (= \sigma^2)$인 경우에는 공통 모분산 σ^2에 대한 추정방법으로 합동추정량 (pooled estimator)

$$S_p^{\,2} = \frac{(n-1)S_X^2 + (m-1)S_Y^2}{n+m-2}$$

을 사용한다(단, $S_X^2 = \sum_{i=1}^{n}(X_i - \overline{X}_n)^2/(n-1)$, $S_Y^2 = \sum_{i=1}^{m}(Y_i - \overline{Y}_m)^2/(m-1)$). 합동추정량 S_p^2은 S_X^2과 S_Y^2의 하나의 가중평균으로서 σ^2의 비편향추정량이 되며, 가중평균형태의 추정량 가운데 가장 분산이 작음을 보일 수 있다.

이제,

$$T = \frac{(\overline{X}_n - \overline{Y}_m) - (\mu_X - \mu_Y)}{S_p\sqrt{1/n + 1/m}}$$

로 정의하면 $\dfrac{(n+m-2)S_p^2}{\sigma^2}$이 자유도가 $n+m-2$인 카이제곱분포를 따르고 $\overline{X}_n - \overline{Y}_m$와 S_p^2이 독립이라는 사실을 이용하여 T의 분포가 $t(n+m-2)$임을 보일 수 있고, 따라서 T는 추축변량이 된다. 그러므로,

$$P\left[-t_{\alpha/2}(n+m-2) \le \frac{(\overline{X}_n-\overline{Y}_m)-(\mu_X-\mu_Y)}{S_p\sqrt{1/n+1/m}} \le t_{\alpha/2}(n+m-2)\right]$$
$$= P\left[(\overline{X}_n-\overline{Y}_m)-t_{\alpha/2}(n+m-2)\,S_p\sqrt{1/n+1/m} \le \mu_X-\mu_Y \right.$$
$$\left. \le (\overline{X}_n-\overline{Y}_m)+t_{\alpha/2}(n+m-2)\,S_p\sqrt{1/n+1/m}\right]$$
$$= 1-\alpha$$

로부터 모평균의 차 $\mu_X-\mu_Y$에 대한 $100(1-\alpha)\%$ 신뢰구간은

$$\left[(\overline{X}_n-\overline{Y}_m)-t_{\alpha/2}(n+m-2)\,S_p\sqrt{1/n+1/m}\,,\right.$$
$$\left.(\overline{X}_n-\overline{Y}_m)+t_{\alpha/2}(n+m-2)\,S_p\sqrt{1/n+1/m}\right] \tag{4.15}$$

로 주어진다.

한편, $\sigma_X^2 \neq \sigma_Y^2$인 경우에는 σ_X^2과 σ_Y^2을 각각 S_X^2과 S_Y^2로 추정한 형태의 변량 $T=\dfrac{\overline{X}_n-\overline{Y}_m-(\mu_X-\mu_Y)}{\sqrt{S_X^2/n+S_Y^2/m}}$를 생각할 수 있으나, 그 정확한 분포는 구할 수 없다. 유력한 방법들 중에 웰치(Welch)에 의해 제안된 방법은 T의 분포를 자유도가

$$\frac{(S_X{}^2/n+S_Y{}^2/m)^2}{\left[(S_X{}^2/n)^2/(n-1)\right]+\left[(S_Y{}^2/m)^2/(m-1)\right]} \tag{4.16}$$

인 t 분포로 근사하여 이로부터 신뢰구간을 구하게 된다.

● 두 정규분포의 모분산의 비에 대한 신뢰구간

두 개의 독립인 랜덤표본 $X_1, X_2, \cdots, X_n$과 $Y_1, Y_2, \cdots, Y_m$의 분포가 각각 $N(\mu_X, \sigma_X^2)$과 $N(\mu_Y, \sigma_Y^2)$이라고 할 때, 두 모분산의 비 σ_X^2/σ_Y^2에 대한 신뢰구간을 모평균을 아는 경우와 그렇지 않은 경우로 나누어 고려해 보자.

경우 1 모평균 μ_X와 μ_Y를 아는 경우:

서로 독립인 확률변량 $\sum_{i=1}^{n}(X_i-\mu_X)^2/\sigma_X^2$과 $\sum_{i=1}^{m}(Y_i-\mu_Y)^2/\sigma_Y^2$가, 각각 자유도가 n과 m인 카이제곱분포를 따르는 점에 근거하여 다음을 알 수 있다.

$$\frac{\sum_{i=1}^{n}(X_i-\mu_X)^2/(n\sigma_X^2)}{\sum_{i=1}^{m}(Y_i-\mu_Y)^2/(m\sigma_Y^2)} \sim F(n,m). \tag{4.17}$$

F 분포도 카이제곱분포와 같이 대칭이 아니지만, 대칭인 분포에서와 마찬가지로 양쪽 꼬리부분에서 $\alpha/2$씩의 확률을 고려하면

$$P\left[F_{1-\alpha/2}(n,m) \le \frac{\widetilde{S_X^2}/\sigma_X^2}{\widetilde{S_Y^2}/\sigma_Y^2} \le F_{\alpha/2}(n,m)\right] = 1-\alpha$$

가 만족된다(단, $\widetilde{S_X^2}=\sum_{i=1}^{n}(X_i-\mu_X)^2/n$, $\widetilde{S_Y^2}=\sum_{i=1}^{m}(Y_i-\mu_Y)^2/m$). $F_\alpha(n,m)$은 자유도가 (n,m)인 F 분포의 임계값으로서 $100(1-\alpha)\%$ 백분위수이다. 이제, 모분산의 비 σ_X^2/σ_Y^2에 대한 $100(1-\alpha)\%$ 신뢰구간은

$$\left[\left(\frac{\widetilde{S_X^2}}{\widetilde{S_Y^2}}\right)F_{1-\alpha/2}(m,n),\ \left(\frac{\widetilde{S_X^2}}{\widetilde{S_Y^2}}\right)F_{\alpha/2}(m,n)\right] \tag{4.18}$$

이 된다. 식 (4.18)에서 $F_\alpha(n,m)=(F_{1-\alpha}(m,n))^{-1}$의 성질을 이용하였다.

경우 2 모평균 μ_X와 μ_Y를 모르는 경우:

$\sum_{i=1}^{n}(X_i-\mu_X)^2/\sigma_X^2$과 $\sum_{i=1}^{m}(Y_i-\mu_Y)^2/\sigma_Y^2$에서 μ_X와 μ_Y를 각각 표본평균 $\overline{X}_n$과 $\overline{Y}_m$으로 추정한 확률변수 $\sum_{i=1}^{n}(X_i-\overline{X}_n)^2/\sigma_X^2$과 $\sum_{i=1}^{m}(Y_i-\overline{Y}_m)^2/\sigma_Y^2$을 생각했을 때, 이들이 서로 독립이고 각각 자유도가 $(n-1)$과 $(m-1)$인 카이제곱분포를 따르는 점에 근거하여 다음과 같이 구할 수 있다. 즉,

$$\frac{S_X^2/\sigma_X^2}{S_Y^2/\sigma_Y^2} \sim F(n-1,\ m-1) \tag{4.19}$$

에 의하여(단, $S_X^2=\sum_{i=1}^{n}(X_i-\overline{X}_n)^2/(n-1)$, $S_Y^2=\sum_{i=1}^{m}(Y_i-\overline{Y}_m)^2/(m-1)$),

$$P\left[F_{1-\alpha/2}(n-1, m-1) \le \frac{S_X^2/\sigma_X^2}{S_Y^2/\sigma_Y^2} \le F_{\alpha/2}(n-1, m-1) \right]$$
$$= 1-\alpha$$

이므로, 모분산의 비 σ_X^2/σ_Y^2에 대한 신뢰도 $100(1-\alpha)\%$ 신뢰구간은

$$\left[\left(\frac{S_X^2}{S_Y^2}\right) F_{1-\alpha/2}(m-1, n-1),\ \left(\frac{S_X^2}{S_Y^2}\right) F_{\alpha/2}(m-1, n-1) \right] \tag{4.20}$$

이 된다.

근사신뢰구간

앞 절에서 다루어진 신뢰구간은 모분포의 정규성을 전제로 하였다. 그러나 모분포가 정규분포를 따르지 않더라도 중심극한정리를 사용하여 모수에 대한 신뢰구간을 근사적으로 다음과 같이 구할 수 있다.

랜덤표본 $X_1, X_2, \cdots, X_n$의 분포의 평균과 분산이 각각 μ, σ^2이라고 할 때 모평균 μ에 대한 신뢰구간을 고려해 보자. 이 경우, 표본분산의 제곱근인 S_n이 σ로 수렴한다는 사실(참조: 예 4.43)과 중심극한정리, 그리고 슬럿츠키의 정리(정리 3.15)에 의해, 표본의 크기가 커짐에 따라 확률변량

$$Z_n = \frac{\sqrt{n}\,(\overline{X}_n - \mu)}{S_n}$$

의 분포는 표준정규분포 $N(0, 1)$로 수렴한다. 따라서 이를 활용한 신뢰계수가 $1-\alpha$인 모평균 μ에 대한 근사신뢰구간은

$$P\left[-z_{\alpha/2} \le Z_n \le z_{\alpha/2} \right]$$
$$= P\left[\overline{X}_n - z_{\alpha/2} \cdot \frac{S_n}{\sqrt{n}} \le \mu \le \overline{X}_n + z_{\alpha/2} \cdot \frac{S_n}{\sqrt{n}} \right]$$
$$\fallingdotseq 1-\alpha$$

에 의하여

$$\left[\overline{X}_n - z_{\alpha/2} \cdot \frac{S_n}{\sqrt{n}},\quad \overline{X}_n + z_{\alpha/2} \cdot \frac{S_n}{\sqrt{n}} \right] \tag{4.21}$$

으로 주어진다. 물론, 모분산 σ^2이 알려진 경우에는 식 (4.21)에서 S_n 대신 σ를 사용

하면 된다.

예 4.47

모분포가 포아송(λ)일 때 랜덤표본 $X_1, X_2, \cdots, X_n$에 근거하여 모평균 λ에 대한 95% 근사신뢰구간을 구해본다. 표본의 크기가 커질 때 대수의 법칙에 따라 표본평균 $\overline{X}_n$는 λ에 확률적으로 수렴하고 중심극한정리에 따라 $\dfrac{\sqrt{n}(\overline{X}_n-\lambda)}{\sqrt{\lambda}}$는 표준정규분포로 수렴하므로, 슬럿츠키의 정리에 의해

$$Z_n=\frac{\sqrt{n}(\overline{X}_n-\lambda)}{\sqrt{\overline{X}_n}}$$

의 분포도 표준정규분포 $N(0, 1)$로 수렴한다. 따라서 식 (4.21)과 마찬가지로, 모수 λ에 대한 95%의 근사신뢰구간

$$\left[\overline{X}_n-1.96\sqrt{\frac{\overline{X}_n}{n}},\quad \overline{X}_n+1.96\sqrt{\frac{\overline{X}_n}{n}}\right]$$

를 구할 수 있다.

예 4.48

$X_1, X_2, \cdots, X_n$이 베르누이(p)로부터의 랜덤표본일 때, 모수 p에 대한 신뢰구간을 중심극한정리를 이용하여 다음과 같이 근사적으로 구할 수 있다. $\hat{p}=\overline{X}_n$로 추정하면 $\hat{p}$가 p로 확률적으로 수렴하고 $\dfrac{\hat{p}-p}{\sqrt{p(1-p)/n}}$이 표준정규분포로 분포수렴하므로, 슬럿츠키의 정리에 의해 $\dfrac{\hat{p}-p}{\sqrt{\hat{p}(1-\hat{p})/n}}$도 표준정규분포로 분포수렴한다. 이를 이용하면 $\hat{p}\pm z_{\alpha/2}\sqrt{\hat{p}(1-\hat{p})/n}$이 p의 $100(1-\alpha)\%$ 근사신뢰구간이 된다.

두 독립인 랜덤표본 $X_1, X_2, \cdots, X_n$과 $Y_1, Y_2, \cdots, Y_m$의 분포가 각각 μ_X, σ_X^2 그리고 μ_Y, σ_Y^2의 평균과 분산을 가질 때, 두 모평균의 차 $\mu_X-\mu_Y$에 대한 신뢰구간을 구해 보자. $N=n+m$이라고 하고, n과 m이 커짐에 따라 $n/N\to c_1$이고 $m/N\to c_2$라고 가정하자. 그러면 $c_1+c_2=1$이 된다. 중심극한정리에 의해, n과 m이 커질 때

$\frac{\overline{X}_n-\mu_X}{\sigma_X/\sqrt{n}} \xrightarrow{d} N(0,1)$이고 $\frac{\overline{Y}_m-\mu_Y}{\sigma_Y/\sqrt{m}} \xrightarrow{d} N(0,1)$이다. 그러면, $\sqrt{N}(\overline{X}_n-\mu_X)=\sqrt{N/n}\,\sqrt{n}(\overline{X}_n-\mu_X) \xrightarrow{d} N(0,\sigma_X^2/c_1)$이 되고 비슷하게, $\sqrt{N}(\overline{Y}_m-\mu_Y) \xrightarrow{d} N(0,\sigma_Y^2/c_2)$이 성립한다. 따라서

$$\frac{\sqrt{N}(\overline{X}_n-\overline{Y}_m-(\mu_X-\mu_Y))}{\sqrt{\sigma_X^2/c_1+\sigma_Y^2/c_2}} \xrightarrow{d} N(0,1) \tag{4.22}$$

이 된다. 또, S_X^2와 S_Y^2이 각각 σ_X^2와 σ_Y^2의 일치추정량이므로

$$\frac{\sqrt{\sigma_X^2/c_1+\sigma_Y^2/c_2}}{\sqrt{N}\sqrt{S_X^2/n+S_Y^2/m}} \xrightarrow{p} 1$$

이 성립하기에 슬럿츠키의 정리를 사용하면

$$T_n=\frac{(\overline{X}_n-\overline{Y}_m)-(\mu_X-\mu_Y)}{\sqrt{S_X^2/n+S_Y^2/m}} \xrightarrow{d} N(0,1)$$

이 된다. 따라서 이를 활용한 신뢰도 $100(1-\alpha)\%$ 근사신뢰구간은

$$\begin{aligned}
&P\left[-z_{\alpha/2} \le T_n \le z_{\alpha/2}\right] \\
&= P\Big[(\overline{X}_n-\overline{Y}_m)-z_{\alpha/2}\sqrt{S_X^2/n+S_Y^2/m} \le \mu_X-\mu_Y \le \\
&\qquad (\overline{X}_n-\overline{Y}_m)+z_{\alpha/2}\sqrt{S_X^2/n+S_Y^2/m}\Big] \\
&\fallingdotseq 1-\alpha
\end{aligned}$$

에 의하여

$$\left[(\overline{X}_n-\overline{Y}_m)-z_{\alpha/2}\sqrt{\frac{S_X^2}{n}+\frac{S_Y^2}{m}},\ (\overline{X}_n-\overline{Y}_m)+z_{\alpha/2}\sqrt{\frac{S_X^2}{n}+\frac{S_Y^2}{m}}\right] \tag{4.23}$$

으로 주어진다.

예 4.49

$X_1, X_2, \cdots, X_n$이 베르누이(p_X), 그리고 $Y_1, Y_2, \cdots, Y_m$이 베르누이(p_Y)로부터 얻은 랜덤표본이라고 하자. 모비율의 차 p_X-p_Y에 대한 신뢰도 $100(1-\alpha)\%$ 근사

신뢰구간은 다음과 같이 구해진다. 모비율 p_X와 p_Y를 각각 표본비율 $\hat{p}_X = \overline{X}_n$와 $\hat{p}_Y = \overline{Y}_m$로 추정하면, (4.22)에서,

$$\frac{(\hat{p}_X - \hat{p}_Y) - (p_X - p_Y)}{\sqrt{p_X(1-p_X)/n + p_Y(1-p_Y)/m}} \xrightarrow{d} N(0,1)$$

를 얻는다. $\hat{p}_X$와 $\hat{p}_Y$가 p_X와 p_Y의 일치추정량이므로 분모에 있는 p_X와 p_Y 대신 추정량을 대입하면 $\frac{(\hat{p}_X - \hat{p}_Y) - (p_X - p_Y)}{\sqrt{\hat{p}_X(1-\hat{p}_X)/n + \hat{p}_Y(1-\hat{p}_Y)/m}} \xrightarrow{d} N(0,1)$를 얻고 이를 이용한 $p_X - p_Y$에 대한 $100(1-\alpha)\%$ 근사신뢰구간은

$$\left[(\hat{p}_X - \hat{p}_Y) - z_{\alpha/2}\sqrt{\frac{\hat{p}_X(1-\hat{p}_X)}{n} + \frac{\hat{p}_Y(1-\hat{p}_Y)}{m}}, \right.$$
$$\left. (\hat{p}_X - \hat{p}_Y) + z_{\alpha/2}\sqrt{\frac{\hat{p}_X(1-\hat{p}_X)}{n} + \frac{\hat{p}_Y(1-\hat{p}_Y)}{m}} \right]$$

으로 구해진다.

표본의 크기

모분산 σ^2이 알려진 경우에 모평균 μ의 추정량 $\hat{\mu} = \overline{X}$에 대한 $100(1-\alpha)\%$ 오차한계를 d 이하로 하려면, 표본크기 n은

$$z_{\alpha/2}\frac{\sigma}{\sqrt{n}} \le d, \text{ 즉 } n \ge (z_{\alpha/2}\sigma/d)^2$$

을 만족해야 함을 알 수 있다. 물론, 이는 μ에 대한 $100(1-\alpha)\%$ 신뢰구간의 길이가 $2d$ 이하이도록 하는 것과 마찬가지이다. 이는 모집단의 분포가 정규분포인 경우에는 정확한 것이고, 표본크기가 큰 경우에는 임의의 모집단에 대하여 근사적으로 적용될 수 있다.

또한, 표본크기가 큰 경우에 모비율 p의 추정량인 표본비율 $\hat{p}$의 $100(1-\alpha)\%$ 오차한계는 $z_{\alpha/2}\sqrt{p(1-p)/n}$으로 주어지므로, $100(1-\alpha)\%$ 오차한계를 d 이하로 하려면 필요한 표본의 크기는

$$z_{\alpha/2}\sqrt{p(1-p)/n} \le d \text{ 즉, } n \ge p(1-p)(z_{\alpha/2}/d)^2$$

이다. 그러나 이 방법을 이용하여 표본크기를 정하는 것은 모비율을 추정하기 위한 표본을 뽑기 전에 모비율의 값인 p를 미리 알아야 한다는 문제점이 있다. p에 대한 정보가 전혀 없는 경우에는 $p(1-p)$를 최대로 만드는 p값인 $1/2$를 대입하여, $n \geq \frac{1}{4}(z_{\alpha/2}/d)^2$로 표본의 크기를 구할 수 있다. 이 방법은 보수적인 방법으로서, 이렇게 표본의 크기를 구하면 모비율의 참값이 어떤 값이든 상관없이 오차한계가 d 이하가 된다. 만약 예전 자료에서의 추정값 등에 의해 p에 대한 적당한 값의 범위를 알고 있다면 그 중에 가장 $1/2$에 가까운 값을 대입하여 표본의 크기를 구할 수 있다.

4.7 베이즈 추정

어떤 제조업체로부터 기계부품을 오랜 기간 동안 수입해 오는 회사에서 정기적으로 수입제품의 성능을 점검한다고 하자. 이 제품의 성능의 측정값은 확률밀도함수가 $f(x;\mu)$인 분포를 따르고 μ는 그 평균이며 우리는 이 평균에 관심이 있다. 그런데 오랜 거래기간 동안의 경험에 의하면 성능의 측정값의 평균 μ는 $N(100, 3^2)$의 분포를 따른다는 사전 정보가 있다고 하자. 모수 μ가 어떤 범위에 들어가는 값이라는 것 이상의 사전 정보가 있다면 이를 모수의 추정에 활용하는 것은 바람직하다고 볼 수 있다. 그러나 지금까지의 추정방법은 모수의 값을 고정된 것으로 생각하기 때문에 이러한 사전 정보를 사용할 수 없다. 랜덤표본 $X_1, X_2, \cdots, X_n$의 확률밀도함수가 $f(x;\theta)$, $\theta \in \Omega$이고 θ가 어떤 범위에 들어가는 값($\theta \in \Omega$)이라는 것 이상의 정보가 존재할 때, 베이지안(Bayesian) 방법은 이러한 사전정보를 사용하여 θ를 추정하게 된다.

베이지안 통계(Bayesian Statistics)는 통계학에서 큰 부분을 차지하는 방법론으로서, 모수 θ를 확률변수로 생각하여 그에 대한 사전정보를 활용할 수 있게 한다. 이 절에서는 베이지안 추정의 기본적인 접근방법에 대해 다루어 보도록 하겠다. 베이즈 추정량(Bayesian estimator)의 기본 아이디어는 베이즈 정리를 통해 알아볼 수 있다. 정리 1.3에서 다루었던 베이즈 정리를 다시 살펴보면, 사건 $B_1, B_2, \cdots, B_k$가 상호배반이며 $\bigcup_{i=1}^{k} B_i = S$일 때 사건 A가 일어났다는 조건하에서 사건 B_j가 일어날 확률은

$$P(B_j \mid A) = \frac{P(B_j)P(A \mid B_j)}{\sum_{i=1}^{k} P(B_i)P(A \mid B_i)}$$

로 주어진다. 이 정리는 $B_1, B_2, \cdots$의 무한열에 대해서도 성립한다. 이 베이즈 정리를 이 절에서의 목적에 맞게 표현하면 다음과 같이 될 수 있다. 두 확률변수 X와 Y에 대하여 $f_X(x)$, $f_Y(y)$가 각각의 주변 확률밀도함수, $f_{X|Y}(x|y)$가 $Y=y$가 주어졌을 때 X의 조건부 확률밀도함수이고 $f_{X,Y}(x,y)$가 결합 확률밀도함수일 때,

$$f_{Y|X}(y|x)=\frac{f_{X,Y}(x,y)}{f_X(x)}=\frac{f_{X,Y}(x,y)}{\int_{-\infty}^{\infty}f_{X,Y}(x,y)dy}$$
$$=\frac{f_{X|Y}(x|y)f_Y(y)}{\int_{-\infty}^{\infty}f_{X|Y}(x|y)f_Y(y)dy}.$$

이제, 확률밀도함수 $f(x;\theta)$, $\theta\in\Omega$를 갖는 확률변수 X를 생각해 보자. 이전까지는 θ를 미지의 상수로 간주하였지만 베이즈 추정에서는 이를 Ω 위에서 정의되는 확률변수 Θ의 한 실현값으로 볼 것이다. 확률변수 X의 한 실현값을 x로 표현하듯이, 확률변수 Θ의 한 실현값이 θ가 된다. Θ의 확률밀도함수를 $\pi(\theta)$로 표기하자. 이를 θ의 **사전 확률밀도함수**(prior probability density function)라고 한다. Θ의 실현값인 θ가 주어졌을 때, X의 확률밀도함수는 θ의 값이 주어진 조건부 확률밀도함수가 되고, $f(x\mid\theta)$로 나타낸다. 확률변수 X와 모수 θ의 결합 확률밀도함수는

$$f(x,\theta)=\pi(\theta)\,f(x\mid\theta)$$

가 되고 랜덤표본 $X_1, X_2, \cdots, X_n$과 θ의 결합 확률밀도함수는

$$f(x_1, x_2, \cdots, x_n, \theta)=\pi(\theta)\prod_{i=1}^{n}f(x_i\mid\theta)$$

가 된다. θ의 사전 확률밀도함수에서 '사전'의 의미는 표본을 관측하기 전이라는 것이고, θ에 대한 사전 정보가 이를 통해 반영된다. 이제 표본이 관측되고 나면, θ에 대한 사전 믿음(prior belief)을 표본에서 얻은 정보를 반영하여 수정하는 것이 합리적일 것이다. 그렇다면 표본 정보를 어떻게 반영할 수 있을까? θ에 대하여 가지고 있던 사전 정보에 표본이 갖고 있는 정보를 더하여 θ에 대한 사후(posterior) 정보를 얻기 위해 다음과 같이 베이즈 정리를 사용하게 된다.

랜덤표본 $X_1=x_1, \cdots, X_n=x_n$이 주어졌을 때 θ의 조건부 확률밀도함수는

$$k(\theta \mid x_1, x_2, \cdots, x_n) = \frac{\pi(\theta)\prod_{i=1}^{n} f(x_i \mid \theta)}{\int_{-\infty}^{\infty}\left[\prod_{i=1}^{n} f(x_i \mid \theta)\right]\pi(\theta)d\theta}$$

로 주어지며, 이를 모수 θ의 **사후 확률밀도함수**(posterior probability density function)라고 한다. 만약 θ의 분포가 이산형이라면 적분 대신 합의 기호로 표현될 것이다.

예 4.50

$X_1, \cdots, X_n$이 동전던지기와 같은 베르누이(θ)에서 나온 랜덤표본이라고 하면,

$$f(x_1, \cdots, x_n|\theta) = \theta^{\sum_{i=1}^{n} x_i}(1-\theta)^{n-\sum_{i=1}^{n} x_i}, \quad x \in \{0, 1\}$$

이 된다. 만약 이 동전이 앞면과 뒷면이 나올 확률이 동일한 동전일 가능성이 높긴 하지만 이 정보가 정확하지는 않아서 θ가 0.5일 가능성이 가장 높고 0.5로부터 멀어질수록 가능성이 낮아진다고 가정해 보자. 이러한 사전정보를 반영하는 한 가지 방법으로 다음과 같은 θ의 사전분포를 생각할 수 있다.

$$\pi(\theta) = 6\theta(1-\theta), \quad 0 < \theta < 1.$$

이는 $BETA(2, 2)$ 분포의 확률밀도함수로서, 그 형태가 우리가 원하는 내용을 반영하면서 상당히 간단하고 다루기 쉬운 확률밀도함수이므로 사전분포로서 적당해 보인다. 사후 확률밀도함수를 구하기 위해 $\int_{-\infty}^{\infty}\left[\prod_{i=1}^{n} f(x_i \mid \theta)\right]\pi(\theta)d\theta$를 계산해 보자.

$$\begin{aligned}
\int_{-\infty}^{\infty} f(x_1, \cdots, x_n|\theta)\pi(\theta)d\theta &= \int_0^1 \theta^{n\bar{x}_n}(1-\theta)^{n-n\bar{x}_n} 6\theta(1-\theta)d\theta \\
&= 6\int_0^1 \theta^{n\bar{x}_n+1}(1-\theta)^{1+n(1-\bar{x}_n)}d\theta \\
&= 6\frac{\Gamma(n\bar{x}_n+2)\Gamma(n-n\bar{x}_n+2)}{\Gamma(n+4)} \\
&= 6\frac{(n\bar{x}_n+1)!(n-n\bar{x}_n+1)!}{(n+3)!}
\end{aligned}$$

이므로,

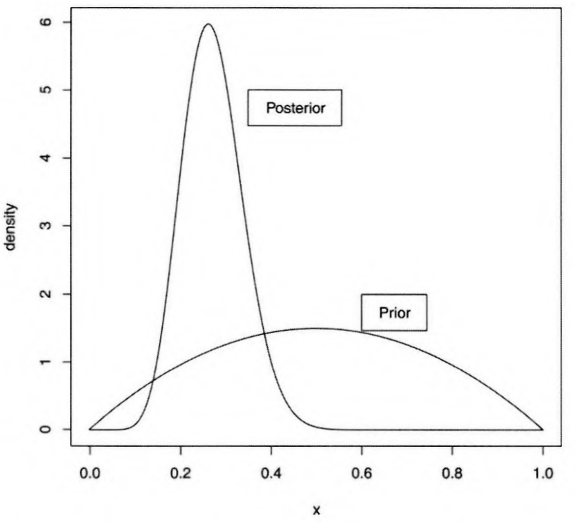
$$k(\theta|x_1,\cdots,x_n)=\frac{\Gamma(n+4)}{\Gamma(n\bar{x}_n+2)\Gamma(n-n\bar{x}_n+2)}\theta^{n\bar{x}_n+1}(1-\theta)^{n-n\bar{x}_n+1}$$

가 되어 θ의 사후분포는 $BETA(n\bar{x}_n+2,\ n-n\bar{x}_n+2)$가 된다.

만약 θ가 $0<\theta<1$이라는 것 외에 사전정보가 전혀 없는 경우 사전분포를 균일분포 $U(0,1)$로 잡을 수 있고, 이 경우 사후분포는

$$k(\theta|x_1,\cdots,x_n)=\frac{\Gamma(n+2)\theta^{n\bar{x}_n}(1-\theta)^{n-n\bar{x}_n}}{\Gamma(n\bar{x}_n+1)\Gamma(n-n\bar{x}_n+1)}$$

가 되어 $BETA(n\bar{x}_n+1,\ n-n\bar{x}_n+1)$이 된다.



▸ **그림 4.4** ◂ 예 4.50에서의 사전분포와 사후분포($n=40,\ \bar{x}_n=0.25$일 때)

사후분포의 산포는 θ에 대한 추정의 정확도에 대해 정보를 줄 수 있다. 그림 4.4에서 자료가 어느 정도의 정보를 더해주는지 사전분포와 사후분포의 확률밀도함수를 비교함으로써 알 수 있다.

예 4.51

알려진 상수 α, β에 대하여 θ의 사전분포가 $\Theta \sim \mathrm{GAM}(\alpha,\beta)$라고 하고 $X_1,\cdots,X_n$이 $\mathrm{POI}(\theta)$에서 나온 랜덤표본이라고 하면, $X_1,\cdots,X_n$과 Θ의 결합 확률밀도함수는

$$\prod_{i=1}^{n} f(x_i \mid \theta)\times\pi(\theta) = \frac{\theta^{\sum x_i}e^{-n\theta}}{x_1!\cdots x_n!}\times\frac{\theta^{\alpha-1}e^{-\theta/\beta}}{\Gamma(\alpha)\beta^{\alpha}},$$
$$\theta>0,\ x_i=0,1,2,\cdots,\ \text{for } i=1,\cdots,n$$

이 된다. 사후 확률밀도함수를 구하기 위해 $\int_{-\infty}^{\infty}\left[\prod_{i=1}^{n} f(x_i\mid\theta)\right]\pi(\theta)\,d\theta$를 계산해 보자.

$$\int_0^{\infty}\frac{\theta^{\sum x_i}e^{-n\theta}}{x_1!\cdots x_n!}\times\frac{\theta^{\alpha-1}e^{-\theta/\beta}}{\Gamma(\alpha)\beta^{\alpha}}d\theta$$
$$=\frac{1}{x_1!\cdots x_n!\Gamma(\alpha)\beta^{\alpha}}\int_0^{\infty}\theta^{\alpha+\sum x_i-1}e^{-\theta(n+\frac{1}{\beta})}d\theta$$
$$=\frac{\Gamma(\alpha+\sum x_i)}{x_1!\cdots x_n!\Gamma(\alpha)\beta^{\alpha}(n+\frac{1}{\beta})^{\alpha+\sum x_i}}$$

가 되므로 사후 확률밀도함수는

$$k(\theta\mid x_1,\cdots,x_n)=\frac{\dfrac{\theta^{\sum x_i}e^{-n\theta}}{x_1!\cdots x_n!}\times\dfrac{\theta^{\alpha-1}e^{-\theta/\beta}}{\Gamma(\alpha)\beta^{\alpha}}}{\dfrac{\Gamma(\alpha+\sum x_i)}{x_1!\cdots x_n!\Gamma(\alpha)\beta^{\alpha}(n+\frac{1}{\beta})^{\alpha+\sum x_i}}}$$
$$=\frac{\theta^{\alpha+\sum x_i-1}e^{-\theta(n+\frac{1}{\beta})}}{\Gamma(\alpha+\sum x_i)(n+\frac{1}{\beta})^{-\alpha-\sum x_i}}$$

가 되어 사후분포가 $\mathrm{GAM}(\alpha+\sum x_i,\ (n+\frac{1}{\beta})^{-1})$을 따르게 된다.

위 예제에서 보듯이, 베이지안 추정을 위해 θ의 사후 확률분포를 구하는 것은 보통 긴 계산을 필요로 한다. 하지만 $\int_{-\infty}^{\infty}\left[\prod_{i=1}^{n} f(x_i\mid\theta)\right]\pi(\theta)\,d\theta$를 따로 계산할 필요가

없음을 인식한다면 과정이 조금은 간단해진다. 실제로,

$$k(\theta \mid x_1, x_2, \cdots, x_n) = \frac{\pi(\theta)\prod_{i=1}^{n} f(x_i \mid \theta)}{\int_{-\infty}^{\infty}\left[\prod_{i=1}^{n} f(x_i \mid \theta)\right]\pi(\theta)\,d\theta}$$

에서 분모는 θ에 의존하지 않고, 사후 확률밀도함수는 $x_1, \cdots, x_n$만의 함수와 θ를 포함하는 부분의 곱으로 표현될 수 있다. 즉, 이 예제에서는 $x_1, \cdots, x_n$의 함수 $c(x_1, \cdots, x_n)$에 대해

$$k(\theta | x_1, \cdots, x_n) = c(x_1, \cdots, x_n) \times \theta^{\alpha + \sum x_i - 1} e^{-\theta(n + \frac{1}{\beta})}$$

이고, 이는 확률밀도함수이므로 θ에 대해 적분했을 때 그 값이 1이어야 한다. 즉, $c(x_1, \cdots, x_n)$이 $\dfrac{1}{\Gamma(\alpha + \sum x_i)(n + \frac{1}{\beta})^{-\alpha - \sum x_i}}$이어야만 하므로, 사후 확률분포가 $\mathrm{GAM}(\alpha + \sum x_i,\ (n + \frac{1}{\beta})^{-1})$임을 쉽게 알 수 있다. 일반적으로,

$$k(\theta | x_1, \cdots, x_n) \propto \pi(\theta) f(x_1, \cdots, x_n | \theta)$$

가 성립하므로 이를 이용하면 사후 확률밀도함수를 보다 간편하게 계산할 수 있다.

베이지안 방법으로 모수를 추정하는 경우, 사전분포를 어떻게 결정하느냐에 대한 중요한 문제를 먼저 해결해야 한다. 만약 θ에 대한 사전 정보가 전혀 없다면 균일분포와 같이 평평한(flat) 사전분포를 사용할 수 있다. θ에 대한 어떤 사전 정보가 있는 경우에는 그 정보를 잘 표현해 줄 수 있는 분포를 골라야 한다. 이때 계산을 쉽게 해 주는 사전분포를 택하는 것이 하나의 방법이 될 것이다. 이를 위해 소위 켤레 사전분포(conjugate prior distribution)를 사용할 수 있다. 많은 경우, 켤레 사전분포의 모수를 변화시킴으로써 우리가 가지고 있는 θ에 대한 사전 정보를 적절히 설명할 수 있는 분포를 찾을 수 있다.

정의 4.13

확률밀도함수 $f(x|\theta)$, $\theta \in \Omega$에 대해 사후분포가 사전분포와 같은 분포족에 들어가게 하는 사전분포의 모임을 $f(x|\theta)$에 대한 **켤레 사전분포족**(conjugate family of prior distributions)이라고 한다.

위의 예제들에서 베타 분포족이 베르누이(또는 이항) 분포에 대한 켤레 사전분포족

이고, 감마 분포족이 포아송 분포에 대한 켤레 사전분포족임을 알 수 있다. 켤레 사전분포족을 사용하였기 때문에 사후분포가 상대적으로 쉽게 계산되었다. 켤레 사전분포족을 사용하면 사후분포가 같은 분포족에 들어가기 때문에 자료를 통해 사전 정보를 업데이트 하는 것이 모수를 업데이트 하는 형태를 띠게 된다.

베이지안 방법에서 θ에 대한 정보는 사후 확률분포에 모두 담겨 있다고 할 수 있다. 지금까지 사후 확률분포를 구하는 것을 다루었으므로, 이제는 이 사후 확률분포를 이용하여 어떻게 추정량을 얻을 것인지에 대해 생각해 보자.

θ는 확률변수 Θ의 한 실현값이므로 θ에 대한 추정은 확률변수의 실현값을 예측하는 문제가 된다. 어떤 확률변수의 실현값을 예측(predict)하려고 할 때, 우리는 예측값과 실제 관측값이 최대한 비슷하기를 원할 것이다. 이를 위해, 예측값과 실제 관측값이 얼마나 가까운지를 측정할 수 있는 방법이 필요한데 이는 적절한 손실함수(loss function)를 정의함으로써 가능하다. 손실함수 $L(\theta, u(x_1, \cdots, x_n))$은 θ값과 그에 대한 추정값 $u(x_1, \cdots, x_n)$ 사이의 거리를 재는 측도로서, 차이의 심각도를 나타내는 함수라고 할 수 있다. 가장 일반적으로 사용되는 것은 제곱오차(squared error) 손실함수이지만 절대오차(absolute error) 손실함수나 0-1 손실함수 등을 생각할 수도 있다. 제곱오차 손실함수를 사용하는 경우 추정값이 모수의 참값에서 멀어질수록 그 차이의 심각도가 커지게 된다. 이 손실함수의 값을 최소화하는 $u(x_1, \cdots, x_n)$ 을 θ에 대한 추정값으로 사용하면 좋을텐데, θ는 Θ의 하나의 실현값이므로 모든 가능한 θ의 값과 그 확률분포를 고려해야 할 것이다. 그래서 베이즈 추정방법은 다음과 같이 손실함수의 기댓값을 최소화하는 $u(x_1, \cdots, x_n)$을 고르게 되고, 기댓값을 구할 때는 θ의 사후 확률분포를 사용한다:

$$E(L(\Theta, u(x_1, \cdots, x_n))|x_1, \cdots, x_n)$$
$$= \int_{-\infty}^{\infty} L(\theta, u(x_1, \cdots, x_n))k(\theta|x_1, \cdots, x_n)d\theta$$

여기에서 Θ의 분포는 연속으로 가정하였다.

정의 4.14

손실함수 L이 주어졌을 때의 베이즈 추정량은

$$E[L(\Theta, u(x_1, \cdots, x_n))|x_1, \cdots, x_n) = \int_{-\infty}^{\infty} L(\theta, u(x_1, \cdots, x_n))k(\theta|x_1, \cdots, x_n)d\theta$$

를 최소화하는 $u(x_1, \cdots, x_n)$에 대응되는 $u(X_1, \cdots, X_n)$이다.

표기의 편의상 $X=(X_1,\cdots,X_n)$, $x=(x_1,\cdots,x_n)$으로 쓰도록 하자. 위에서 구한 손실함수의 기댓값은 x의 함수이므로 X의 결합 확률밀도함수, $f(x)=\int \pi(\theta)f(x|\theta)d\theta$를 가지고 다시 기댓값을 취하면, $g(\theta|x)f(x)=f(x|\theta)\pi(\theta)$이므로

$$\begin{aligned} E(E(L(\Theta,u(X))|X=x)) &= \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} L(\theta,u(x))g(\theta|x)d\theta\, f(x)dx \\ &= \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} L(\theta,u(x))f(x|\theta)dx\pi(\theta)d\theta \\ &= \int_{-\infty}^{\infty} R(\theta,u)\pi(\theta)d\theta \end{aligned}$$

로 쓸 수 있다. 여기에서 $R(\theta,u)=E[L(\theta,u(X_1,\cdots,X_n))|\theta]$는 위험함수(risk function)라고 불리며, X에 대한 손실함수의 기댓값이다. 이는 주어진 θ의 값에서 θ와 추정값 사이의 평균거리 개념이라고 할 수 있다. $E[E(L(\Theta,u(X))|X=x)]$를 위험함수의 평균값, 즉 기대위험(expected risk)이라고 하면, 베이즈 추정량 $u(X_1,\cdots,X_n)$은 모든 x의 값에서 $\int_{-\infty}^{\infty} L(\theta,u(x))k(\theta|x)d\theta$를 최소화하므로 기대위험을 최소화하는 통계량이 된다. 특히, 손실함수가 제곱오차인 경우 위험함수는 평균제곱오차(MSE)가 되고, 베이즈 추정량은 평균제곱오차의 θ에 대한 기댓값을 최소로 만드는 추정량이다.

제곱오차 손실함수를 사용하는 경우 베이즈 추정량이 사후 확률분포의 평균이고, 절대오차 손실함수를 사용하는 경우 베이즈 추정량이 사후 확률분포의 중앙값임을 어렵지 않게 확인할 수 있다. 위의 논리는 추정하고자 하는 것이 θ의 함수, 말하자면 $g(\theta)$인 경우에 대해서도 쉽게 확장된다.

예 4.52

예 4.50에서와 같이 X_1, X_2, $\cdots$, X_n이 베르누이(p)로부터의 랜덤표본이고 모수 p의 사전 확률밀도함수가 $\pi(p)=6p(1-p)$, $0<p<1$로 주어진다고 하자. 예 4.50에서 본 것과 같이 p의 사후 확률분포는 $BETA(n\bar{x}_n+2, n-n\bar{x}_n+2)$가 된다. 제곱오차 손실함수를 사용한다면 p에 대한 베이즈 추정량은 사후 확률분포의 평균값인 $\dfrac{n\bar{X}_n+2}{n+4}=\dfrac{\sum X_i+2}{n+4}$이다. 이 문제에 있어서 최대가능도 추정량, 적률 추정량, 그

리고 최소분산 비편향추정량은 모두 $\frac{\sum X_i}{n}$인 데 반해, 베이즈 추정량은 기존의 추정량의 분모에 4, 분자에 2를 더한 꼴이다. 말하자면, 4번의 가상적인 추가 시행이 있었고 그중에 2번은 성공, 2번은 실패였다고 가정하는 것으로 생각할 수 있다. 이는 기존의 추정량을 $\frac{1}{2}$쪽으로 약간 기울이는 효과를 가져오는데, 때로 매우 유용하다. $0 < p < 1$을 가정했으므로 우리는 p가 0이거나 1의 값은 가질 수 없다는 것을 알고 있다. 그렇지만 만약 p가 아주 작은 값이면, n번의 시행 중에 성공이 한 번도 나오지 않는 경우가 생길 수 있다. 이런 경우 기존의 추정량은 p의 추정값으로 p가 가질 수 없는 값인 0을 제공하게 되지만, 베이즈 추정량은 $2/(n+4)$를 추정값으로 제공하므로 보다 합리적이라고 할 수 있다.

예 4.53

$X_1, X_2, \cdots, X_n$을 베르누이(p)로부터 구한 랜덤표본이고, 모수 p의 사전분포가 $BETA(\alpha,\beta)$라고 하자. 모수 p의 사후 확률밀도함수는

$$k(p \mid x_1, \cdots, x_n) \propto \pi(p)\, f(x_1, \cdots, x_n \mid p) \propto p^{\sum_{i=1}^{n} x_i + \alpha - 1} (1-p)^{n - \sum_{i=1}^{n} x_i + \beta - 1}$$

로부터 $BETA\ (\sum_{i=1}^{n} x_i + \alpha, n - \sum_{i=1}^{n} x_i + \beta)$이다. 따라서 제곱오차를 사용한 모수 p에 대한 베이즈 추정량은 사후분포의 평균인 $\hat{p} = \frac{\sum_{i=1}^{n} X_i + \alpha}{n + \alpha + \beta}$가 된다. 나아가,

$$\hat{p} = \frac{\sum_{i=1}^{n} X_i + \alpha}{n + \alpha + \beta} = \frac{n}{n + \alpha + \beta}\left(\overline{X}_n\right) + \frac{\alpha + \beta}{n + \alpha + \beta}\left(\frac{\alpha}{\alpha + \beta}\right)$$

로 표현될 수 있으며, 이를 통해 베이즈 추정량이 사전분포의 평균 $\frac{\alpha}{\alpha+\beta}$와 표본평균 $\overline{X}_n$의 가중평균임을 알 수 있다. n이 커질 때, 사전분포의 평균은 매우 작은 가중치를 갖게 되고 대부분의 가중치는 표본평균이 갖는다. 반면에 n이 작다면, 사전분포의 평균이 갖는 가중치가 상대적으로 클 것이다. 표본의 크기가 클수록 자료에서 얻는 정보에 보다 많이 의존하게 되고, 표본이 작으면 추정에 대한 사전 정보의 영향력이 상대적으로 클 것이므로 이는 매우 합리적인 성질이라고 할 수 있다.

예 4.54

$X_1, X_2, \cdots, X_n$을 $N(\mu, \sigma^2)$으로부터 얻은 랜덤표본이라고 하자. 모분산 σ^2은 알려져 있을 때, μ의 사전 확률밀도함수가 $N(\mu_0, \sigma_0^2)$, 즉

$$\pi(\mu) = \frac{1}{\sqrt{2\pi}\,\sigma_0} \exp\left[-\frac{1}{2}\left(\frac{\mu-\mu_0}{\sigma_0}\right)^2\right]$$

이라고 하면, $X_1, X_2, \cdots, X_n$과 μ의 결합 확률밀도함수는

$$\begin{aligned} f(x, \mu) &= \frac{1}{\sqrt{2\pi}\,\sigma_0} \exp\left[-\frac{1}{2}\left(\frac{\mu-\mu_0}{\sigma_0}\right)^2\right] \\ &\times \frac{1}{(2\pi)^{n/2}\,\sigma^n} \exp\left[-\frac{1}{2}\sum_{i=1}^{n}\left(\frac{x_i-\mu}{\sigma}\right)^2\right] \\ &\propto \exp\left(-\frac{1}{2}(\frac{\mu-\mu_0}{\sigma_0})^2 - \frac{1}{2}\frac{\sum_{i=1}^{n}(x_i-\mu)^2}{\sigma^2}\right) \\ &\propto \exp\{-\frac{1}{2}S(\mu)\} \end{aligned}$$

의 꼴이 된다. 단,

$$S(\mu) = \frac{\sigma^2+\sigma_0^2 n}{\sigma_0^2\sigma^2}\left[\mu - \frac{\sigma^2\mu_0 + \sigma_0^2 n\,\bar{x}_n}{\sigma^2+\sigma_0^2 n}\right]^2$$

이다. 따라서 μ의 사후 확률밀도함수는

$$\begin{aligned} k(\mu \mid x) &= \frac{f(x, \mu)}{\int_{-\infty}^{\infty} f(x, \mu)\, d\mu} \\ &= \frac{\exp[-(1/2)S(\mu)]}{\int_{-\infty}^{\infty} \exp[-(1/2)S(\mu)]\, d\mu} \\ &= \frac{\exp\left[-\frac{\sigma^2+\sigma_0^2 n}{2\sigma_0^2\sigma^2}\left[\mu - \frac{\sigma^2\mu_0+\sigma_0^2 n\,\bar{x}_n}{\sigma^2+\sigma_0^2 n}\right]^2\right]}{\sqrt{\frac{2\pi\sigma^2\sigma_0^2}{\sigma^2+\sigma_0^2 n}}} \end{aligned}$$

이 되는데, 이는 평균이 $\frac{\sigma^2\mu_0+\sigma_0^2 n\bar{x}_n}{\sigma^2+\sigma_0^2 n}$이고 분산이 $\frac{\sigma_0^2\sigma^2}{\sigma^2+\sigma_0^2 n}$인 정규분포의 확률밀도함수이다. 즉, 정규 사전분포는 정규분포에 대한 켤레 사전분포족임을 알 수 있다. 제곱오차를 사용한 μ의 베이즈 추정량은 이 사후 확률분포의 평균인

$$E(\mu \mid X) = \frac{\sigma^2\mu_0+\sigma_0^2 n\overline{X}_n}{\sigma^2+\sigma_0^2 n}$$
$$= \frac{\delta}{1+\delta}\mu_0 + \frac{1}{1+\delta}\overline{X}_n$$

이고(단, $\delta = \sigma^2/n\sigma_0^2$), 이는 사전분포의 평균 μ_0와 표본평균 $\overline{X}_n$의 가중평균이다. 여기에서 μ_0와 $\overline{X}_n$에 대한 가중치는 표본의 크기 n과 사전분포의 분산 σ_0^2에 의해 결정되는데, 그 타당성을 음미해 볼 필요가 있다. 표본의 크기가 커질 때 $\overline{X}_n$의 가중치가 커지고, 사전 정보가 모호할수록(μ의 사전분포의 분산이 클수록) $\overline{X}_n$의 가중치가 커진다. 만약 사전분포의 분산이 매우 크거나 표본의 크기가 아주 크다면 베이즈 추정량은 $\overline{X}_n$와 거의 같아지고 사전분포의 분산이 매우 작다면 베이즈 추정량은 사전분포의 평균과 거의 같아질 것이다.

한편, 고정된 α에 대하여

$$\int_l^u k(\theta \mid x_1, \cdots, x_n)\, d\theta = 1-\alpha$$

를 만족하는 $[l, u] = [l(x_1, \cdots, x_n),\ u(x_1, \cdots, x_n)]$을 모수 θ에 대한 $100(1-\alpha)\%$ **베이즈 신뢰구간**(credible interval)이라고 한다. 베이즈 신뢰구간의 의미는 θ가 이 구간에 들어갈 확률이 $1-\alpha$가 된다는 것으로, 사전분포를 가정하지 않는 신뢰구간의 의미와 사뭇 다르다. 베이즈 신뢰구간에 대해 '상대도수적' 의미를 부여하는 것은 타당하지 않다.

베이즈 신뢰구간을 구할 때 같은 α의 값을 가진다면 가장 짧은 구간을 구하는 것이 자연스럽다. 이러한 생각으로부터 나온 것이 **최고 사후밀도**(highest posterior density, HPD) 구간인데, 이것은 $[l, u] = \{\theta : g(\theta \mid x_1, \cdots, x_n) \geq c\}$의 형태를 가지며, c의 값은 $\int_l^u k(\theta \mid x_1, \cdots, x_n)\, d\theta = 1-\alpha$를 만족하면서 가장 큰 값으로 찾으면

된다.

예 4.55

$X_1, X_2, \cdots, X_n$을 $N(\mu, \sigma^2)$으로부터 얻은 랜덤표본이고 모분산 σ^2은 알려져 있으며, μ의 사전 확률밀도함수는 $N(\mu_0, \sigma_0^2)$라 가정하자. 예 4.54에서처럼 사후분포는

$$\Theta|(X_1 = x_1, \cdots, X_n = x_n) \sim N(\frac{\sigma^2\mu_0 + \sigma_0^2 n\,\overline{x}_n}{\sigma^2 + \sigma_0^2 n},\ \frac{\sigma_0^2\sigma^2}{\sigma^2 + \sigma_0^2 n})$$

이고, θ에 대한 95% 베이즈 신뢰구간(HPD)은

$$\frac{\sigma^2\mu_0 + \sigma_0^2 n\,\overline{x}_n}{\sigma^2 + \sigma_0^2 n} \pm 1.96 \times \sqrt{\frac{\sigma_0^2\sigma^2}{\sigma^2 + \sigma_0^2 n}}$$

이 된다.

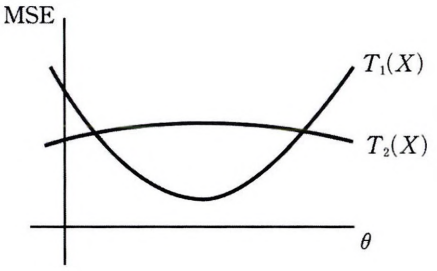
최소분산 비편향추정량을 구할 때, 평균제곱오차를 최소로 만드는 추정량을 일반적으로 찾을 수 없기 때문에 비편향추정량 가운데에서 평균제곱오차를 최소로 만드는 최소분산 비편향추정량을 찾았었다. 평균제곱오차를 최소로 만드는 추정량을 일반적으로 찾을 수 없는 한 가지 이유는 평균제곱오차가 모수에 의존하기 때문이라고 할 수 있는데, 제곱오차를 사용하는 베이즈 추정량은 θ에 대해 평균제곱오차(MSE)의 기댓값을 취함으로써 평균제곱오차가 θ에 의존하는 것을 방지하였다고 볼 수 있다. 평균제곱오차가 θ에 의존하지 않게 되면, 그 값으로 추정량을 비교하여 이를 최소로 하는 추정량을 찾는 절차가 쉬워진다. 이외에, 평균제곱오차가 모수 θ에 의존하지 않도록 하는 방법으로, 평균제곱오차의 모든 가능한 모수 θ의 영역에서의 최댓값을 고려하여 이 최댓값을 최소화하는 추정방법을 생각할 수 있다. 즉, 가능한 시나리오 중에서 가장 나쁜 시나리오를 골라 이 때의 손실을 최소로 만드는 추정량을 고르는 것이다.

이에 대한 내용을 간략히 소개하면, 모수의 함수 $g(\theta)$의 추정량 $T^*(X)$가 모든 가능한 모수 θ의 영역에서 임의의 다른 추정량 $T(X)$에 대하여

$$\max_\theta MSE(T^*(X)) \le \max_\theta MSE(T(X))$$

을 만족할 때, $T^*(X)$를 θ의 **미니맥스**(minimax) 추정량이라고 한다. 다음의 그림에서 $g(\theta)$에 대한 두 개의 추정량 $T_1(X)$와 $T_2(X)$에 대한 평균제곱오차를 비교하면,

$T_1(X)$가 대부분의 θ 영역에서 $T_2(X)$보다 더 작은 평균제곱오차를 가지고 있으나 $\max_\theta MSE(T_1(X)) \geq \max_\theta MSE(T_2(X))$이므로 $T_2(X)$가 미니맥스 추정량이 된다.



연습문제 4장

01 $X_1, X_2, \cdots, X_n$이 $U(\mu-\sqrt{3}\sigma, \mu+\sqrt{3}\sigma)$로부터 구한 랜덤표본이라고 하자. 이때 적률을 이용하여 μ와 σ를 추정하라.

02 $X_1, X_2, \cdots, X_n$이 확률밀도함수 $f_X(x;\theta)=(\theta+1)x^\theta$, $0<x<1$로부터의 랜덤표본이라고 할 때, 적률을 이용한 θ의 추정량이 $(2\overline{X}_n-1)/(1-\overline{X}_n)$이 됨을 보여라.

03 랜덤표본 $X_1, X_2, \cdots, X_n$의 모분포가 평균이 λ인 포아송 분포라고 한다. 이때 모수 λ에 대한 적률추정량을 일차 또는 이차적률을 사용하여 구하고, 따라서 적률추정량이 유일하지 않음을 보여라.

04 $X_1, X_2, \cdots, X_n$이 $U(0, \theta)$로부터의 랜덤표본이라고 할 때, 적률을 이용한 θ의 추정량을 구하고 최대가능도 추정량과 비교하라.

05 랜덤표본 $X_1, X_2, \cdots, X_n$의 모분포가 평균이 λ인 포아송 분포라고 한다.

(1) 적률추정방법에 의하여 $g(\lambda)=1/\lambda$를 추정하라.

(2) 최대가능도방법에 의하여 $g(\lambda)=1/\lambda$를 추정하라.

06 $X_1, X_2, \cdots, X_n$이 확률밀도함수 $f(x;\theta_1, \theta_2)=(1/\theta_2)\exp(-(x-\theta_1)/\theta_2)$, $x>\theta_1$, $\theta_2>0$으로부터의 랜덤표본이라고 할 때, 모수 θ_1과 θ_2의 최대가능도 추정량을 구하라.

07 확률변수 X의 분포가 $P(X=1)=\theta^2$, $P(X=2)=2\theta(1-\theta)$, $P(X=3)=(1-\theta)^2$ (단, $0<\theta<1$)이라고 하자. 이제 세 개의 관찰값 2, 2, 3을 얻었을 때 모수 θ의 최대가능도 추정값을 구하라.

08 확률벡터 $(X_1, X_2, \cdots, X_k)$가 모수가 $(n, p_1, p_2, \cdots, p_k)$인 다항분포를 따른다고 하자. 이때, 모수 $(p_1, p_2, \cdots, p_k)$의 최대가능도 추정량이 $(X_1/n, X_2/n, \cdots, X_k/n)$이 됨을 보여라.

09 서로 독립인 두 확률변수 $X \sim B(n, p)$와 $Y \sim B(m, p)$의 공통된 '성공' 확률 p의 최대가능도 추정량을 구하라.

10 $X_1, X_2, \cdots, X_n$이 $U(\theta-1/2,\ \theta+1/2)$로부터의 랜덤표본이라고 할 때 가능도함수를 구하고, 이에 근거하여 θ의 최대가능도 추정량이 유일하지 않음을 보여라.

11 $E(X^2) < \infty$일 때 $E(X-a)^2$는 상수 a의 값이 $E(X)$일 때 최소화됨을 보여라.

12 $X_1, X_2, \cdots, X_n$은 $f_X(x;\theta) = \dfrac{3\theta^3}{x^4}$ $(\theta < x < \infty)$로부터의 랜덤표본이다.

(1) 적률추정법을 사용하여 θ의 추정량을 구하라.

(2) θ의 최대가능도 추정량을 구하라.

(3) (1)과 (2)의 추정량의 평균제곱오차를 비교하라.

13 $X_1, X_2, \cdots, X_n$을 확률밀도함수 $f(x;\theta)$로부터 얻은 랜덤표본이라고 하자. 이때 어떤 상수 θ_0에 대하여 $T(X) = \theta_0$가 모수 θ의 비편향추정량이 아님을 보여라.

14 $X_1, X_2, \cdots, X_n$이 평균이 μ이고 분산이 σ^2인 분포로부터 얻은 랜덤표본이라고 할 때 모평균 μ가 알려져 있다면, $(1/n)\sum_{i=1}^{n}(X_i-\mu)^2$이 σ^2의 비편향추정량임을 보여라.

15 $X \sim U(0, \theta)$일 때 θ^2의 비편향추정량을 구하라.

16 $X_1, X_2, \cdots, X_n$이 $U(-\theta, \theta)$, $\theta > 0$로부터 얻은 랜덤표본이라고 할 때 $c(X_{(n)} - X_{(1)})$이 모수 θ의 비편향추정량이 되기 위한 상수 c의 값을 구하라.

17 $f(x;\theta) = 1/\theta$, $0 \le x \le \theta$, $\hat{\theta} = cX$가 θ의 비편향추정량이 되는 상수 c의 값을 구하라.

18 $X_1, X_2, \cdots, X_n$이 정규분포 $N(\mu, \sigma^2)$으로부터 추출한 랜덤표본이라고 하자. $cS = c\sqrt{\dfrac{\sum (X_i - \overline{X}_n)^2}{n-1}}$이 σ의 비편향추정량이 되도록 상수 c의 값을 구하라(힌트: $Y = (n-1)(S^2/\sigma^2)$이 카이제곱분포를 따르는 확률변수임을 이용하여 $E(\sqrt{Y})$을 구하라).

19 $X \sim$ 베르누이(p)일 때, p에 대한 추정량으로 $T_1(X) = X$와 $T_2(X) = 1/2$을 고려하였다.

(1) $T_1(X)$와 $T_2(X)$의 비편향성을 점검하라.

(2) $T_1(X)$와 $T_2(X)$의 평균제곱오차를 비교하라.

20 $X_1, X_2, \cdots, X_n$이 EXP(λ)로부터 얻은 랜덤표본이라고 하자. 모수 λ에 대한 추정량으로 $\hat{\lambda}_1 = \overline{X}_n$과 $\hat{\lambda}_2 = n\overline{X}_n/(n+1)$을 비교할 때,

(1) $\hat{\lambda}_1$과 $\hat{\lambda}_2$의 분산을 구하라.

(2) $\hat{\lambda}_1$과 $\hat{\lambda}_2$의 평균제곱오차를 구하라.

21 모수 θ에 대한 n개의 서로 독립인 비편향추정량 $\hat{\theta}_i (i = 1, 2, \cdots, n)$이 존재하며 $Var(\hat{\theta}_i) = \sigma_i^2$이라고 한다. 이들을 이용한 결합추정량 $\sum_{i=1}^{n} a_i \hat{\theta}_i$ (단, $\sum_{i=1}^{n} a_i = 1$)를 고려하자.

(1) 결합추정량 $\sum_{i=1}^{n} a_i \hat{\theta}_i$는 비편향추정량임을 보여라.

(2) $Var\left(\sum_{i=1}^{n} a_i \hat{\theta}_i\right)$는 $a_i = (1/\sigma_i^2)/\sum_{j=1}^{n}(1/\sigma_j^2)$일 때 최소화됨을 $n = 2$인 경우에 대해 증명하라.

22 모수 θ를 추정함에 있어 두 개의 독립인 비편향추정량 $\hat{\theta}_1$과 $\hat{\theta}_2$을 사용할 수 있고, $Var(\hat{\theta}_1) = 4\,Var(\hat{\theta}_2)$이라고 한다. 이제 $\hat{\theta}_1$과 $\hat{\theta}_2$의 선형결합꼴인 $\hat{\theta} = a_1\hat{\theta}_1 + a_2\hat{\theta}_2$를 θ의 추정량으로 택할 때, $E(\hat{\theta}) = \theta$를 만족시키는 비편향성의 조건하에서, 분산을 최소화하는 상수 a_1과 a_2를 구하라.

23 X_1, X_2, X_3이 $f_X(x;\theta)=(1/\theta)\exp(-x/\theta)$, $x>0$으로부터 얻은 랜덤표본이라고 하자. 모수 θ를 추정함에 있어 $(X_1+2X_2+X_3)/4$의 $\overline{X}_3$에 대한 효율을 구하라.

24 X_1, X_2, $\cdots$, X_n이 평균이 $k\theta$이고 분산이 $k\theta^2$인 감마분포로부터 추출된 크기 n인 랜덤표본이라고 하자.

(1) 적률추정법을 사용하여 k와 θ의 추정량을 구하라.

(2) k와 θ의 최대가능도 추정량을 찾아보고, 여기에서 파생하는 어려움에 대하여 논하라.

(3) k의 값이 알려져 있을 때 θ의 비편향추정량의 분산이 가질 수 있는 하한값을 결정하라.

25 X_1, X_2, $\cdots$, X_n이 베르누이(p)로부터 얻은 랜덤표본이라고 하자.

(1) 분산 $p(1-p)$에 대한 비편향추정량의 크래머-라오 하한값을 구하라.

(2) 분산 $p(1-p)$에 대한 최소분산 비편향추정량을 구하라.

(3) p^2에 대한 최소분산 비편향추정량을 구하라.

26 X_1, X_2, $\cdots$, X_n을 확률밀도함수 $U(0,\theta)$로부터 얻은 랜덤표본이라고 하자.

(1) 식 (4.7)의 피셔의 정보를 이용하여 $\dfrac{1}{nI(\theta)}$를 계산하라.

(2) θ에 대한 비편향추정량 $[(n+1)/n]X_{(n)}$의 분산이 (1)에서 계산한 하한값보다 작음을 보이고, 정리 4.3과 관련하여 이에 대한 적절한 설명을 하여라.

27 크기가 2인 랜덤표본 X_1, X_2가 확률밀도함수 $f_X(x;\theta)=(1/\theta)\exp(-x/\theta)$, $x>0$로부터 추출되었다고 하자.

(1) $Y_1=X_1+X_2$가 θ에 대한 충분통계량임을 보여라.

(2) $Y_1=X_1+X_2$와 $Y_2=X_2$의 결합 확률밀도함수를 구하라.

(3) Y_2는 θ의 비편향추정량이며 분산 θ^2을 가짐을 보여라.

(4) $Y_1=y_1$이 주어져 있을 때 Y_2의 조건부 확률밀도함수가 θ를 포함하지 않음을 보여라.

28 $X \sim \mathrm{POI}(\lambda)$일 때, $g(\lambda) = P(X=0) = \exp(-\lambda)$라고 하자.

(1) $\exp(-X)$는 $g(\lambda)$의 비편향추정량인가?

(2) 함수 u가 다음과 같이 정의될 때, $u(X)$는 $g(\lambda)$의 비편향추정량이 됨을 보여라.

$$u(x) = \begin{cases} 1, & x = 0 \\ 0, & x = 1, 2, \cdots \end{cases}$$

(3) $g(\lambda)$의 두 추정량 $\exp(-X)$와 $u(X)$의 평균제곱오차를 비교하라.

29 모분포 $N(0, \sigma^2)$으로부터 1개의 관찰값 X를 얻었다고 하자.

(1) σ^2에 대한 충분통계량을 구하라.

(2) σ^2의 비편향추정량을 구하라.

(3) 모표준편차 σ의 최대가능도 추정량을 구하라.

30 $X_1, X_2, \cdots, X_n$이 $f_X(x;\theta) = \exp(-(x-\theta))$ $(\theta < x < \infty)$로부터의 랜덤표본이라고 할 때, 표본최솟값 $X_{(1)}$이 충분통계량임을 보여라.

31 $X_1, X_2, \cdots, X_n$이 $U(0, \theta)$, $\theta > 0$로부터 얻은 랜덤표본이라고 하자.

(1) $Y = X_{(n)}$이 θ에 대한 완비 충분통계량임을 보여라.

(2) $E(X_{(n)}) \neq \theta$임을 보여라.

(3) θ에 대한 최소분산 비편향추정량을 구하라.

32 $X_1, X_2, \cdots, X_n$이 $f(x) = 1/(\theta_2 - \theta_1)$, $\theta_1 < x < \theta_2$로부터 얻은 랜덤표본이라고 하자.

(1) $(X_{(1)}, X_{(n)})$이 (θ_1, θ_2)에 대한 완비 충분통계량임을 보여라.

(2) $(\theta_1 + \theta_2)/2$에 대한 최소분산 비편향추정량을 구하라.

33 $X_1, X_2, \cdots, X_n \sim N(\mu, \mu^2)$일 때 $(\overline{X}_n, S^2)$이 완비성이 없음을 보여라.

34 $X_1, X_2, \cdots, X_n$이 $f(x;\theta)=\theta x^{\theta-1}$, $(0<x<1,\ \theta>0)$로부터 얻은 랜덤표본이라고 하자.

(1) 모수의 값 $\theta=1/2$, $\theta=1$, $\theta=2$ 각각에 대하여 모확률밀도함수 $f(x;\theta)$를 그려 보라.

(2) θ의 적률추정량을 구하고 이 추정량이 θ에 대한 완비충분통계량의 함수가 아님을 보여라.

(3) θ의 최대가능도 추정량을 구하라.

(4) $1/\theta$의 최소분산 비편향추정량을 구하라(힌트: $E[-\log X]=1/\theta$).

(5) θ의 최소분산 비편향추정량을 구하라.

35 $X_1, X_2, \cdots, X_n$이 기하확률밀도함수 $f(x;p)=p(1-p)^{x-1}$, $(0<p<1,\ x=1,\ 2,\ 3,\cdots)$로부터 얻은 랜덤표본이라고 하자.

(1) 적률추정방법에 의하여 p를 추정하라.

(2) p의 최대가능도 추정량을 구하라.

(3) $E(X_1)$의 최대가능도 추정량을 구하라.

(4) p의 비편향추정량에 대한 크래머-라오 하한값을 구하라.

36 모분포 $N(\mu, \sigma^2)$으로부터 랜덤표본 $X_1, X_2, \cdots, X_n$을 얻었다고 할 때, $P(X>0)$의 최대가능도 추정량을 구하라.

37 모수벡터 $(\theta_1, \cdots, \theta_k)$에 대한 최대가능도 추정량 $(\hat{\theta}_1, \cdots, \hat{\theta}_k)$는 결합 충분통계량 $(S_1, \cdots, S_k)$의 함수임을 보여라.

38 $T_n(X)$가 모수 θ의 비편향추정량일 때, 모든 $\theta \in \Omega$에 대해 $\lim_{n\to\infty} Var(T_n(X))=0$이면 $T_n(X)$는 일치성을 가짐을 보여라(힌트: 체비세프 정리를 사용할 것).

39 $X_1, X_2, \cdots, X_n$이 $f(x;\theta)=e^{-(x-\theta)}$, $x>\theta$로부터 얻은 랜덤표본이라고 하자.

(1) θ의 최대가능도 추정량을 구하라.

(2) 95백분위수의 최대가능도 추정량을 구하라.

40 $X_1, X_2, \cdots, X_{16}$이 $N(\mu, \mu^2)$로부터 구한 랜덤표본이라고 하자. 적절한 추축변량을 구하고, 그에 근거하여 모수 μ에 대한 90% 신뢰구간을 구하라.

41 주사위에서 6이 나올 확률을 변경하기 위해 주사위를 조작하였다. 이 조작된 주사위에서 6이 나올 확률이 p라고 하자. 여기에서 99%의 신뢰도를 가지고 p의 추정량과 p 사이의 최대오차가 0.02가 되게 하려면 얼마나 많은 횟수의 주사위를 던져야 하겠는가?

42 어느 모집단에서 무작위추출한 $n = 500$명의 유권자 중에서 K씨를 지지하는 사람수는 154명이었다. K씨를 지지하는 유권자의 비율 p에 대한 95% 근사신뢰구간을 구하라.

43 $X_1, X_2, \cdots, X_{16}$이 $N(\mu, \sigma^2)$으로부터 구한 랜덤표본이라고 하자.

(1) 모분산 $\sigma^2 = 9$이며 표본평균이 $\overline{X}_{16} = 18.5$일 때, 모평균 μ에 대한 90% 신뢰구간을 구하라.

(2) 또한 (1)의 자료에 근거하여 모평균 μ에 대한 90% 단측신뢰상한을 구하라.

44 $X_1, X_2, \cdots, X_n$이 $f(x;\theta) = \theta \exp(-\theta x)$ $(\theta > 0,\ x > 0)$로부터 구한 랜덤표본이라고 하자.

(1) θ에 대한 90% 신뢰구간을 구하라.

(2) θ^2에 대한 90% 신뢰구간을 구하라.

(3) $\exp(-\theta) = P(X > 1)$에 대한 90% 신뢰구간을 구하라.

45 $X_1, X_2, \cdots, X_n$이 $U(\theta - 1/2,\ \theta + 1/2)$로부터 구한 랜덤표본이라고 하자. 이때

(1) 확률구간 $[X_{(1)}, X_{(n)}]$이 모수 θ를 포함할 확률을 구하라.

(2) 모수 θ에 대한 95% 근사신뢰구간을 구하라.

46 두 개의 관찰값 X_1과 X_2를 모분포 $N(\mu, 1)$로부터 얻을 때,

(1) $P(X_{(1)} < \mu < X_{(2)}) = 1 - \alpha$를 만족하는 α를 계산하라.

(2) $X_2 - \mu$가 추축변량인 점을 이용하여 신뢰도가 (1)에서 구한 $1 - \alpha$와 같은 신뢰구간을 구하고, 그 길이를 $[X_{(1)}, X_{(2)}]$와 비교하라.

47 $X_1, X_2, \cdots, X_n$과 $Y_1, Y_2, \cdots, Y_m$이 각각 $\mathrm{EXP}(\theta_1)$과 $\mathrm{EXP}(\theta_2)$로부터 구한 서로 독립인 랜덤표본이라고 하자.

(1) $(\theta_2/\theta_1)(\overline{X}_n/\overline{Y}_m) \sim F(2n, 2m)$임을 보여라.

(2) θ_2/θ_1에 대한 90% 신뢰구간을 구하라.

48 두 개의 독립인 랜덤표본 $X_1, X_2, \cdots, X_n$과 $Y_1, Y_2, \cdots, Y_m$의 모분포가 각각 $N(\mu_X, \sigma^2)$과 $N(\mu_Y, \sigma^2)$이라고 할 때, 두 모평균의 차이에 대한 $100(1-\alpha)\%$ 신뢰구간을 유도하라(단, 공통분산 σ^2은 알려지지 않았음).

49 $X_1, X_2, \cdots, X_n$이 $U(0, \theta)$로부터 구한 랜덤표본이라고 하자. 이때 충분통계량 $X_{(n)}$에 근거하여 모수 θ에 대한 $100(1-\alpha)\%$ 신뢰구간을 유도하라.

50 모분포 $N(\mu, \sigma^2)$으로부터 랜덤표본 $X_1, X_2, \cdots, X_n$을 얻었다고 할 때, 모수벡터 (μ, σ^2)의 $100(1-\alpha)\%$ '동시' 신뢰영역을 구하라.

51 $X_1, X_2, \cdots, X_n$이 확률밀도함수 $f(x;\theta)$를 갖는 확률분포로부터의 랜덤표본이라고 하자. 식 (4.9)에서와 같이, 모수의 참값인 $\theta = \theta_0$에서 $E\left(\frac{d}{d\theta}\log f(X;\theta)\right) = 0$이 성립하는 것을 보여라.

52 $X_1, X_2, \cdots, X_n$이 확률밀도함수 $f(x;\theta)$를 갖는 확률분포로부터의 랜덤표본일 때, 로그가능도함수를 $l(\theta)$로 표시하자. 모수의 참값이 θ_0일 때 $-\frac{1}{n}l''(\theta_0)$은 피셔의 정보, $I(\theta_0)$로 확률수렴함을 확인하기 위해, 적절한 조건하에서 다음을 보여라.

$$E\left(\frac{d}{d\theta}\log f(X;\theta)\Big|_{\theta=\theta_0}\right)^2 = -E\left(\frac{d^2}{d\theta^2}\log f(X;\theta)\Big|_{\theta=\theta_0}\right)$$

53 $X_1, X_2, \cdots, X_n$이 확률밀도함수 $f(x;\theta)$를 갖는 확률분포로부터의 랜덤표본일 때, 로그가능도함수를 $l(\theta)$로 표시하자. 모수의 참값이 θ_0일 때 적절한 조건하에서 $\frac{1}{\sqrt{n}} l'(\theta_0) \xrightarrow{d} N(0, I(\theta_0))$이 성립함을 보여라.

54 베이즈 추정량이 충분통계량의 함수임을 보여라(힌트: 인수분해 정리를 사용할 것).

55 $X_1, \cdots, X_n$이 베르누이(θ)에서 나온 랜덤표본이고 Θ는 다음 표와 같은 사전분포를 따른다고 하자. θ의 사후 확률분포를 구하라.

θ	0.25	0.5	0.75
$\pi(\theta)$	0.25	0.5	0.25

56 $X_1, \cdots, X_n$이 $N(\mu, \frac{1}{\theta})$(μ는 알려진 상수)에서 나온 랜덤표본이고 $\Theta \sim \mathrm{GAM}(\alpha, \beta)$ (α, β는 알려진 상수)일 때, θ의 사후 확률분포를 구하라.

57 $X_1, \cdots, X_n$이 $\mathrm{EXP}(\frac{1}{\theta})$에서 나온 랜덤표본이고 $\Theta \sim \mathrm{EXP}(\frac{1}{\beta})$ (β는 알려진 상수)일 때, 제곱오차를 사용한 θ의 베이즈 추정량을 구하라.

58 $X_1, \cdots, X_n$이 베르누이(θ)에서 나온 랜덤표본이고 Θ의 사전분포가 $\mathrm{BETA}(\alpha, \beta)$라고 하자. $n = 40$, $\sum_{i=1}^{n} x_i = 15$, $\alpha = \beta = 2$일 때, θ에 대한 94.3% 베이즈 신뢰구간(HPD)을 구하라.