7장 선형 회귀분석

- 7.1 상관계수
- 7.2 선형 회귀모형
- 7.3 회귀모수의 추정
- 7.4 가설검정 및 신뢰구간
- 7.5 다중선형 회귀모형

과학적 실험이나 자연 또는 사회현상의 관찰결과에 대한 분석의 중요한 목적 중 하나는 연구대상을 구성하는 변수들 사이의 관계를 규명하는 일이다. 화학실험에서 실험온도(X)와 화학반응 속도(Y) 사이의 관계라든가, 수학능력시험성적(X)과 대학평점(Y)과의 관계라든가, 또는 부모의 키(X)와 자녀의 키(Y) 사이의 관계 등 여러 분야에 걸쳐 변수들 간의 관계규명에 대한 많은 예를 찾아볼 수 있다. 이에 대한 통계적 분석방법인 회귀분석은 단순히 변수들 사이의 연관관계를 보이는 것 이상으로 변수들 간에 어떤 함수관계가 있는지를 살펴봄으로써 미래의 관측값에 대한 예측이나 조절 등의 문제에 효율적으로 대처하게 하는 방법이다. 7장에서는 확률변수들 사이의 관계를 설명하는 데 있어서 가장 기본이 되는 선형 회귀분석을 다루기로 한다. 선형 회귀분석에서는 변수들 간에 선형함수 관계를 가정하게 된다. 이러한 과정에는 일반적으로 두 개 이상의 변수들이 관련되지만, 여기에서는 두 개의 변수 사이의 관계를 다루는 단순선형 회귀분석을 중점적으로 살펴보겠다. 다행스럽게도, 두 개의 변수에 대한 이론이나 개념들은 세 개 이상의 변수들의 관계를 설명하는 데도 별 무리없이 확장될 수 있다.

7.1 상관계수

변수 사이의 선형함수식을 추정하기 이전에, 두 변수 사이의 선형관계가 유의한지, 어느 정도의 선형관계가 존재하는지 등을 상관계수를 통해 알아볼 수 있다. 상관계수의 추정과 검정은 **상관분석**(correlation analysis)이라고 한다.

2.4절에서 두 확률변수 X와 Y 사이의 흩어진 관계를 측정하는 통계량으로 공분산을 고려했었다. 그런데 공분산은 변수의 측정단위(measurement unit)에 의존하게 되는 단점이 있다. 즉, X와 Y의 측정단위를 바꾸면 변수 사이의 관계가 변하는 것이 아닌 데도 공분산의 값은 바뀐다는 것이다. 그렇기 때문에 공분산의 값만으로 관계의 정도를 가늠하는 것이 어려워진다. 그래서 단위에 의존하지 않도록, 공분산을 두 변수의 표준편차의 곱으로 나누어 이를 **상관계수**(correlation coefficient)라고 정의하고, 이것을 두 변수 사이의 선형관계를 측정하는 단위로 주로 사용한다.

정의 7.1

두 변수 X와 Y 사이의 선형관계를 측정하는 **상관계수**는

$$\rho(X, Y) = \frac{Cov(X, Y)}{SD(X) \cdot SD(Y)}$$

로 정의된다.

참고 $X^* = (X - \mu_X)/SD(X)$, $Y^* = (Y - \mu_Y)/SD(Y)$라고 하면 $\rho(X, Y) = Cov(X^*, Y^*)$가 성립한다. 즉, 두 변수 사이의 상관계수는 표준화된 두 변수 사이의 공분산과 같다.

이렇게 정의된 상관계수는 다음과 같은 성질들을 가지고 있다.

정리 7.1

두 확률변수 X와 Y 사이의 상관계수 $\rho(X, Y)$는 다음과 같은 성질들을 만족한다.

(1) $\rho(X, Y) = \rho(Y, X)$

(2) $\rho(X, Y) = \rho(aX + b, cY + d)$ (a와 c는 0이 아닌 동부호이며, b와 d는 임의의 상수)

(3) $|\rho(X, Y)| \leq 1$

(4) $|\rho(X, Y)| = 1$의 필요충분조건은 $Y = aX + b$이다($a \neq 0$, b는 임의의 상수)

(5) 확률변수 X와 Y가 서로 독립이면 $\rho(X, Y) = 0$이다(단, 역은 성립하지 않는다).

증명 (1) $Cov(X, Y) = Cov(Y, X)$이므로 정의에 의해서 자명하다.

(2) $$\rho(aX + b, cY + d) = \frac{Cov(aX + b, cY + d)}{SD(aX + b) \cdot SD(cY + d)}$$

$$= \frac{ac\, Cov(X, Y)}{|a|\, SD(X) \cdot |c|\, SD(Y)}$$

$$= \rho(X, Y)$$

여기에서, a와 c가 동부호이므로 $ac = |ac|$이다.

(3) X와 Y를 표준화하여 $X^* = (X - \mu_X)/\sigma_X$, $Y^* = (Y - \mu_Y)/\sigma_Y$라 하자. 그러면,

$$0 \leq Var(X^* \pm Y^*) = Var(X^*) \pm 2Cov(X^*, Y^*) + Var(Y^*)$$

$$= 1 \pm 2\rho(X, Y) + 1$$

$$= 2[1 \pm \rho(X, Y)]$$

이 성립한다. 그런데 $1 \pm \rho(X, Y) \geq 0$이므로 $|\rho(X, Y)| \leq 1$이 성립한다.

(4) (3)의 증명에서, $\rho(X, Y) = 1$이면 $Var(X^* - Y^*) = 0$이다. 따라서 $X^* - Y^*$는 1의 확률로 상수이며, Y는 X의 선형함수가 된다. 역은 (2)에 의해 성립한다.

(5) X와 Y가 서로 독립이면 $Cov(X, Y) = 0$이므로 $\rho(X, Y) = 0$이 성립한다.

■

예 7.1

이차원 평면상에서의 이산형 확률벡터 (X, Y)는 5개의 점 $\{(-2, 2), (-1, 1), (0, 0), (1, 1), (2, 2)\}$에서 동일한 확률 1/5을 가진다고 한다. 이때 두 확률변수 X와 Y 사이의 관계를 살펴보면

$$\frac{1}{5} = P(X=1,\ Y=1) \neq P(X=1)\,P(Y=1) = \frac{1}{5} \cdot \frac{2}{5} = \frac{2}{25}$$

이므로 X와 Y가 서로 독립이 아닌 것은 분명하다. 그러나

$$E(XY) = (-4-1+0+1+4)/5 = 0, \quad E(X) = 0$$

이므로 $Cov(X, Y) = E(XY) - E(X)E(Y) = 0$은 성립한다. 즉, 정리 7.1에서 (5)의 역이 성립하지 않음을 확인할 수 있다.

$Cov(X, Y) = E(XY) - E(X)E(Y)$이므로 상관계수는

$$\rho(X, Y) = \frac{E(XY) - E(X)\,E(Y)}{SD(X)\,SD(Y)} \tag{7.1}$$

로 나타낼 수도 있다.

예 7.2

확률변수 X, Y의 결합 확률밀도함수가

$$f_{X,Y}(x, y) = \begin{cases} x + y, & 0 < x,\ y < 1\text{인 경우} \\ 0, & \text{그 외의 경우} \end{cases}$$

으로 주어질 때, X와 Y 사이의 상관계수를 구해 보자. 먼저 X, Y의 주변 확률밀도함수는

$$f_X(x) = \int_0^1 f_{X,Y}(x,y)\,dy = \int_0^1 (x+y)\,dy = x + \frac{1}{2}$$

$$f_Y(y) = \int_0^1 f_{X,Y}(x,y)\,dx = \int_0^1 (x+y)\,dx = y + \frac{1}{2}$$

로 구해진다. 따라서,

$$E(X) = \int_0^1 x\left(x+\frac{1}{2}\right)dx = \frac{7}{12}$$

$$E(X^2) = \int_0^1 x^2\left(x+\frac{1}{2}\right)dx = \frac{5}{12}$$

이며, $Var(X) = E(X^2) - [E(X)]^2 = \frac{11}{144}$이다. 마찬가지 방법으로 $Var(Y) = \frac{11}{144}$이고,

$$E(XY) = \int_0^1\int_0^1 xy\,f_{X,Y}(x,y)\,dxdy = \int_0^1\int_0^1 xy(x+y)\,dxdy = \frac{1}{3}$$

이다. 그러므로 두 변수 X, Y 사이의 상관계수는

$$\rho(X,Y) = \frac{Cov(X,Y)}{SD(X)\cdot SD(Y)} = \frac{E(XY)-E(X)E(Y)}{\sqrt{11/144}\cdot\sqrt{11/144}} = -\frac{1}{11}$$

이 된다.

이제 표본상관계수를 통한 상관계수의 추론에 대해 간단히 살펴보자. 크기가 n인 이변량 랜덤표본 $(X_1, Y_1), (X_2, Y_2), \cdots, (X_n, Y_n)$에 대한 **표본상관계수**(sample correlation coefficient)는

$$R = \frac{\sum_{i=1}^{n}\{(X_i-\overline{X}_n)(Y_i-\overline{Y}_n)/n\}}{\sqrt{\sum_{i=1}^{n}(X_i-\overline{X}_n)^2/n}\cdot\sqrt{\sum_{i=1}^{n}(Y_i-\overline{Y}_n)^2/n}} \tag{7.2}$$

$$= \frac{\sum_{i=1}^{n}(X_iY_i)/n - \overline{X}_n\overline{Y}_n}{\sqrt{\sum_{i=1}^{n}(X_i-\overline{X}_n)^2/n} \cdot \sqrt{\sum_{i=1}^{n}(Y_i-\overline{Y}_n)^2/n}}$$

$$= \frac{\sum_{i=1}^{n}X_iY_i - n\overline{X}_n\overline{Y}_n}{\sqrt{\sum_{i=1}^{n}(X_i-\overline{X}_n)^2\sum_{i=1}^{n}(Y_i-\overline{Y}_n)^2}}$$

로 표현된다. 이변량 정규성(2.6.4절 참조)하에서 표본상관계수 R의 분포이론은 다음과 같다.

정리 7.2

랜덤표본 $(X_1, Y_1), (X_2, Y_2), \cdots, (X_n, Y_n)$의 모분포를 모수벡터가 $(\mu_X, \mu_Y, \sigma_X^2, \sigma_Y^2, \rho)$인 이변량 정규분포라고 하자. 이때 $\rho(X, Y) = 0$이면 표본상관계수 R의 함수인 통계량

$$T = \frac{R\sqrt{n-2}}{\sqrt{1-R^2}}$$

는 자유도가 $(n-2)$인 t 분포를 따른다.

증명 먼저,

$$S_X^2 = \sum_{i=1}^{n}(X_i-\overline{X}_n)^2/(n-1)$$

$$S_Y^2 = \sum_{i=1}^{n}(Y_i-\overline{Y}_n)^2/(n-1)$$

$$S_{XY} = \sum_{i=1}^{n}(X_i-\overline{X}_n)(Y_i-\overline{Y}_n)/(n-1)$$

이라고 하면, $R = S_{XY}/S_XS_Y$이며

$$T=\frac{R\sqrt{n-2}}{\sqrt{1-R^2}}=\frac{\frac{S_Y}{\sigma_Y}R}{\sqrt{\frac{1}{n-2}\left[\frac{S_Y^2}{\sigma_Y^2}(1-R^2)\right]}}$$

$$=\frac{\frac{RS_Y/S_X}{\sigma_Y/(\sqrt{n-1}\,S_X)}}{\sqrt{\frac{1}{n-2}\left[(n-1)S_Y^2(1-R^2)/\sigma_Y^2\right]}}$$

로 쓸 수 있다. 그런데 두 정규확률변수 X와 Y는 $\rho(X,Y)=0$이면 서로 독립이므로 $X_1=x_1,\ \cdots,\ X_n=x_n$이 주어졌을 때, Y의 조건부 확률분포는 주변확률분포와 동일한 $N(\mu_Y,\sigma_Y^2)$이고,

$$RS_Y/S_X=\frac{\sum_{i=1}^{n}(x_i-\bar{x}_n)Y_i}{\sum_{i=1}^{n}(x_i-\bar{x}_n)^2}\sim N(0,\ \sigma_Y^2/(n-1)S_X^2)$$

이며, 또한

$$\frac{(n-1)S_Y^2(1-R^2)}{\sigma_Y^2}=\frac{1}{\sigma_Y^2}\sum_{i=1}^{n}[(Y_i-\bar{Y}_n)-(S_{XY}/S_X^2)(x_i-\bar{x}_n)]^2$$

는 $RS_Y/S_X=S_{XY}/S_X^2$와 서로 독립이며 자유도가 $(n-2)$인 카이제곱분포를 따른다(연습문제 7.4). 따라서 T의 조건부 확률분포는 자유도가 $(n-2)$인 t 분포이다. 그런데 $X_1=x_1,\ X_2=x_2,\ \cdots,\ X_n=x_n$이 주어졌을 때 T의 조건부 확률분포가 $x_1, x_2, \cdots, x_n$에 의존하지 않으므로 $T\sim t(n-2)$가 성립한다. ■

위 정리 7.2는 이변량 정규성하에서 상관계수에 관한 가설 $\rho(X,Y)=0$의 검정에 활용될 수 있다. 즉, $H_0\colon \rho=0$ 대 $H_1\colon \rho\neq 0$의 검정에서, $|T|\geq t_{\alpha/2}(n-2)$가 관측되었을 때 귀무가설을 유의수준 α에서 기각하는 것이다. 그러나 $\rho(X,Y)\neq 0$인 경우 표본상관계수 R의 분포는 그리 간단하지 않기 때문에, $H_0\colon \rho=\rho_0(\neq 0)$와 같은 귀무가설을 검정할 경우에는 다른 방법을 사용해야 한다. 이런 경우에 이용될 수 있는 근사적인 분포이론으로, 피셔(Fisher)에 의해 제안된 아래의 Z-변환을 생각할 수 있다.

즉,

$$Z=\frac{1}{2}\log\frac{(1+R)}{(1-R)}$$

이라고 할 때, Z 통계량은 표본의 크기가 충분히 클 경우에 평균과 분산이 각각

$$E(Z)=\frac{1}{2}\log\frac{(1+\rho)}{(1-\rho)},\quad Var(Z)=\frac{1}{(n-3)}$$

인 정규분포를 근사적으로 따른다. 이에 근거하여 모상관계수 ρ에 관한 근사검정법과 근사신뢰구간을 구축할 수 있다.

7.2 선형 회귀모형

두 확률변수 X와 Y 사이의 관계를 알아보고자 할 때, 선형관계의 정도를 측정하는 상관계수를 구하는 것에서 한 단계 더 나아가서 두 변수 사이의 함수관계를 파악할 수 있다면 매우 유용할 것이다. 이 절에서는 X와 Y 사이에 선형 함수관계가 있는지, 있다면 그 함수를 어떻게 찾을 것인지 살펴보기로 한다. 우선, 두 변수 사이의 관계를 알기 위해서는 그들의 결합분포 형태를 통한 이해가 필요하다. $X=x$가 주어졌을 때 $Y|x$의 조건부 확률밀도함수 $f_{Y|x}(\cdot|x)$는 x에 대한 함수이며, 두 변수 사이의 관계를 설명하는 데에 유용하게 사용된다. 나아가, 조건부분포인 $Y|x$가 x의 값이 변함에 따라 어떻게 변하는지를 x에 대한 함수로 표현하고자 한다면, 조건부분포의 대푯값으로서 그 평균인 $E[Y|x]=\int_{-\infty}^{\infty} y f_{Y|x}(y|x)dy$(연속형인 경우)를 고려할 수 있다. 이 조건부 기댓값 $E(Y|x)$는 조건부 확률변수 $Y|x$의 평균제곱오차를 최소화하게 되는데, 이는 $E[(Y-a)^2|X=x]$를 a에 대한 함수로 생각했을 때, $a=E[Y|x]=\int_{-\infty}^{\infty} y f_{Y|x}(y|x)dy$에서 이 함수가 최솟값을 취한다는 뜻이다. 이와 같이 주어진 변수 X의 값에 의해 변수 Y를 설명 또는 예측하고자 할 때 X를 **설명변수**(explanatory variable), **독립변수**(independent variable) 또는 **예측변수**(predictor), 그리고 Y를 **반응변수**(response variable) 또는 **종속변수**(dependent variable)라고 한다.

예 7.3

(예 2.11 참조) 두 확률변수 X와 Y의 결합 확률밀도함수가

$$f_{X,Y}(x,y)=x^2e^{-x(y+1)}, \qquad x>0, \quad y>0$$

으로 주어졌다고 하자. 이때 조건부 확률밀도함수는

$$f_{Y|x}(y|x)=\frac{x^2e^{-x(y+1)}}{\int_0^\infty x^2e^{-x(y+1)}dy}$$
$$=xe^{-xy}$$

으로 계산되며, 따라서 조건부 기댓값은

$$E(Y|x)=\int_0^\infty yxe^{-xy}dy$$
$$=\frac{1}{x}$$

이 된다.

일반적으로 조건부 기댓값 $E(Y|x)$와 x의 관계를 회귀문제라 일컬으며, $E(Y|x)$를 x에 대한 Y의 **회귀함수**(regression function)라고 한다. 여기에서 우리가 고려할 회귀함수는 조건부 기댓값 $E(Y|x)$가 독립변수의 주어진 값 x에 대해 선형인 경우, 즉

$$E(Y|x)=\beta_0+\beta_1x \tag{7.3}$$

인 경우로 제한하기로 한다. 물론 상당히 제한적인 모형이지만 많은 실제 자료들의 처리에 활용될 수 있으며, 당장 보기에는 부적합한 자료도 적절한 변환을 통하여 선형관계로 바꿀 수 있는 경우가 많다(7.4절 참조).

예 7.4

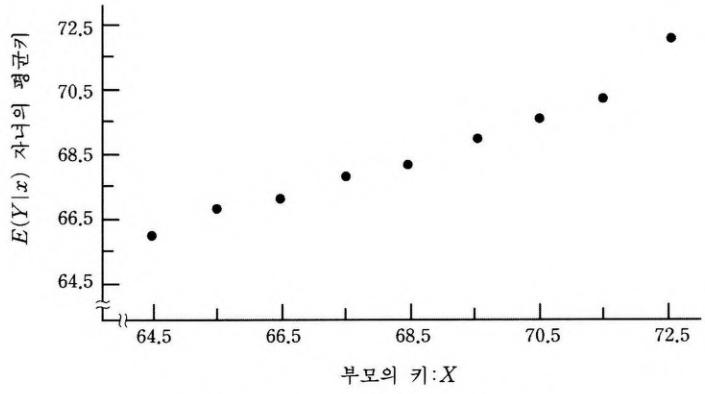
(갈톤(Galton)의 자료) 아래 표에 주어진 자료는 19세기 후반 갈톤(Sir Francis Galton)에 의해 다루어진 부모의 키와 자녀의 키에 대한 것으로, 회귀분석에 있어서 역사적으로 유명한 자료이다. 이를 살펴봄으로써 선형 회귀모형에 대한 동기를 찾아보기로 한다. 이 자료는 해당하는 경우에 대한 도수(frequency)를 나타낸 것으로,

예를 들어 부모의 키가 72.5인치이고 자녀의 키가 72.2인치인 경우는 7개 있었다. 실제 자료는 좀 더 자세한 키를 다루고 있으나 여기에서는 도수분포표만 제공하도록 한다. 도수의 합은 928(205쌍의 부모와 928명의 자녀가 있음)이었으며, 부모의 키는 아버지의 키와 어머니의 키를 대표할 수 있는 하나의 값(아버지의 키와 1.08×어머니의 키의 평균)으로 주어졌다.

부모의 키 (단위: 인치)	성인 자녀의 키(단위: 인치)														도수의 합
	이하	62.2	63.2	64.2	65.2	66.2	67.2	68.2	69.2	70.2	71.2	72.2	73.2	이상	
72.5	–	–	–	–	–	–	–	–	–	–	–	1	3	–	4
72.5	–	–	–	–	–	–	–	1	2	1	2	7	2	4	19
71.5	–	–	–	–	1	3	4	3	5	10	4	9	2	2	43
70.5	1	–	1	–	1	1	3	12	18	14	7	4	3	3	68
69.5	–	–	1	16	4	17	27	20	33	25	20	11	4	5	183
68.5	1	–	7	11	16	25	31	34	48	21	18	4	3	–	219
67.5	–	3	5	14	15	36	38	28	38	19	11	4	–	–	211
66.5	–	3	3	5	2	17	17	14	13	4	–	–	–	–	78
65.5	1	–	9	5	7	11	11	7		5	2	1	–	–	66
64.5	1	1	4	4	1	5	5	–	2	–	–	–	–	–	23
64.5	1	–	2	4	1	2	2	1	1	–	–	–	–	–	14
합	5	7	32	59	48	117	138	120	167	99	64	41	17	14	928

도수분포표를 통한 두 변수의 분포를 살펴보면, X를 부모의 키 그리고 Y를 성인이 된 자녀의 키라고 할 때, 다음과 같은 가정들을 무리없이 받아들일 수 있다.

1. 두 변수 X, Y의 결합 확률밀도함수가 이변량 정규분포를 따른다.
2. 조건부 기댓값 $E(Y|x)$는 선형꼴이다(참조: 그림 7.1).
3. 조건부 분산 $Var(Y|x)$가 x값에 대해 상수이다.



▸ **그림 7.1** ◂ 조건부 기댓값 $E(Y|X=x)$

단순선형 회귀모형

갈톤의 자료에서 고려한 가정들을 도입하여, 설명변수 X의 값이 x일 때 반응변수 Y에 대해 다음과 같은 **단순선형 회귀모형**(simple linear regression model)을 정의하기로 한다. 용어 '단순'은 설명변수가 하나 있음을 의미한다.

$$Y=\beta_0+\beta_1 x+\varepsilon \tag{7.4}$$

여기에서 β_0와 β_1은 알려져 있지 않은 상수로 **회귀모수**(또는 **회귀계수**)라고 하며, ε는 확률변수로서 평균이 0이고 분산이 σ^2인 정규분포를 따른다.

주 위의 모형 (7.4)는 조건부 기댓값 $E(Y|X=x)$가 절편이 β_0이고 기울기는 β_1인 x에 대한 선형함수가 되게 한다. 여기에서 x에 대한 Y의 회귀함수인 $E(Y|X=x)$를 선형 회귀직선이라고 한다. 그리고 랜덤오차 ε의 분산 σ^2이 x에 의존하지 않음을 등분산성(homoscedasticity)이라고 한다. 또한, 위 모형은 $X=x$일 때 조건부 확률변수 $Y|x$의 분포가 $N(\beta_0+\beta_1 x, \sigma^2)$인 것과 동등하다.

주 X와 Y 사이의 상관계수에 대한 추론에서는 X와 Y의 역할이 대칭적이지만, 회귀모형에서는 두 변수의 역할이 다르다. X는 설명변수로서 주로 그 값이 미리 주어지고, X의 값이 고정되었을 때 Y의 조건부 분포가 고려된다.

이제 X와 Y 사이의 선형관계를 측정하는 상관계수 ρ의 선형 회귀모형에서의 역할은 다음 정리 7.3에서 뚜렷이 드러난다.

정리 7.3

두 확률변수 X, Y에 대하여, 모든 $X=x$에서 $E(Y|x)=\beta_0+\beta_1 x$이면,

$$E(Y|X=x)=\mu_Y+\frac{\rho\sigma_Y}{\sigma_X}(x-\mu_X)$$

가 성립한다(단, 모수 μ_X, σ_X, μ_Y, σ_Y는 각각 X, Y의 평균과 표준편차이고 ρ는 X와 Y의 상관계수이다).

증명 $\displaystyle\int_{-\infty}^{\infty} E(Y|x)f_X(x)\,dx=\int_{-\infty}^{\infty}\left[\int_{-\infty}^{\infty} y\frac{f_{X,Y}(x,y)}{f_X(x)}dy\right]f_X(x)\,dx$

$$= \int_{-\infty}^{\infty} y \left[\int_{-\infty}^{\infty} f_{X,Y}(x,y)\,dx \right] dy$$
$$= \int_{-\infty}^{\infty} y f_Y(y)\,dy$$

이므로,

$$\int_{-\infty}^{\infty} E(Y|x) f_X(x)\,dx = \mu_Y \tag{7.5}$$

가 성립한다. 또, $E(Y|x) = \beta_0 + \beta_1 x$의 양변에 $f_X(x)$를 곱한 다음 적분하면

$$\int_{-\infty}^{\infty} E(Y|x) f_X(x)\,dx = \int_{-\infty}^{\infty} \beta_0 f_X(x)dx + \int_{-\infty}^{\infty} \beta_1 x f_X(x)\,dx$$

이므로

$$\mu_Y = \beta_0 + \beta_1 \mu_X$$

를 얻는다. 따라서 $E(Y|x) = \beta_0 + \beta_1 x$에 $\beta_0 = \mu_Y - \beta_1 \mu_X$를 대입하면

$$E(Y|x) - \mu_Y = \beta_1 (x - \mu_X)$$

를 얻게 된다. 양변에 $(x-\mu_X) f_X(x)$를 곱하면

$$[E(Y|x) - \mu_Y](x-\mu_X) f_X(x) = \beta_1 (x-\mu_X)^2 f_X(x)$$

이며, 이는

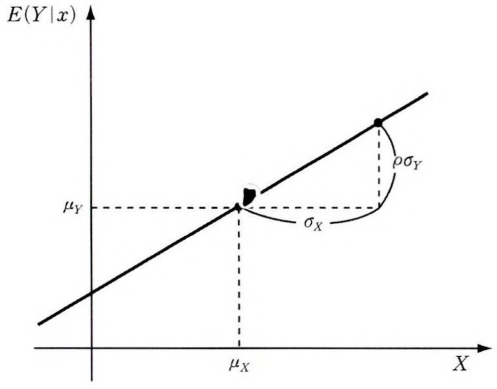
$$\int_{-\infty}^{\infty} (y-\mu_Y)(x-\mu_X)\, f_{X,Y}(x,y)\,dy = \beta_1 (x-\mu_X)^2 f_X(x)$$

와 동등하다. 이제 양변을 x에 대해 적분하면

$$Cov(X, Y) = \beta_1 \sigma_X^2$$
$$\beta_1 = \frac{Cov(X, Y)}{\sigma_X^2} = \frac{\rho \sigma_Y}{\sigma_X}$$

를 구할 수 있다. ■

정리 7.3으로부터, 회귀선이 직선이면 이 직선은 (X, Y)의 평균점 (μ_X, μ_Y)를 통과하며 기울기는 $\rho\sigma_Y / \sigma_X$임을 알 수 있다. 이를 그림을 통해 표현하면 다음과 같다 (단, $\rho > 0$인 경우이며 $\rho < 0$이면 회귀직선의 기울기는 음이 된다.)



▸ **그림 7.2** ◂ 회귀직선 방정식 $E(Y|X=x) = \mu_Y + \dfrac{\rho\sigma_Y}{\sigma_X}(x-\mu_X)$

따라서 $E(Y|x) = \beta_0 + \beta_1 x$라고 할 때 회귀모수를 μ_X, μ_Y, σ_X, σ_Y, ρ를 사용하여 나타내면

$$\beta_0 = \mu_Y - \frac{\rho\mu_X\sigma_Y}{\sigma_X}, \quad \beta_1 = \frac{\rho\sigma_Y}{\sigma_X} \tag{7.6}$$

가 된다.

그림 7.2로부터 회귀(regression)라는 용어의 의미를 살펴보자. 예 7.4의 자료를 통해 갈톤(Galton)이 '평균으로의 회귀(regression towards the mean)'라는 표현을 씀으로써 이 용어가 사용되기 시작하였는데, 이는 평균적으로 보았을 때, 부모의 키가 아주 큰 경우 자녀의 키는 큰 편이긴 하지만 부모만큼 크지는 않고 부모의 키가 아주 작은 경우 자녀의 키는 작은 편이지만 부모만큼 작지는 않다는 관찰에서 나온 것이었다. 실제로 키는 완전히 유전으로만 결정되는 것이 아니기 때문에, 부모의 키가 매우 큰 경우에도 다른 환경적 요인들의 효과에 의해 자녀의 키는 좀 더 평균에 가까워질 가능성이 높게 된다. 다른 예로, 어떤 대규모 집단의 학생들에게 공인영어시험을 치르게 한 후에 상위 1% 안에 드는 학생들의 집단과 하위 1% 안에 드는 학생들의 집단을 따로 뽑아 비슷한 시험을 다시 치르게 한다고 해 보자. 이 경우 평균적으로 상위 1% 학생들의 성적은 낮아지고, 하위 1% 학생들의 성적은 높아질 것으로 예상된다. 시험

성적에는 지식적인 요인뿐 아니라 운과 같은 다른 요인도 함께 작용하기 때문에, 첫 번째 시험에서 아주 좋은 성적이 나온 것이 모든 요인이 좋은 방향으로 작용한 결과라면, 두 번째 시험에서는 처음보다 약간 낮은 성적이 나올 것으로 예상하는 것이 합리적이다. 이러한 현상을 평균으로의 회귀현상이라고 한다. 이제 그림 7.2에서 상관계수가 양수라고 가정해 보자. $|\rho| < 1$이므로 ρ는 1보다 작은 값을 가진다. 그림으로부터, 설명변수의 값이 $1SD$(표준편차)만큼 커질 때, 반응변수의 기댓값은 $\rho \times 1SD < 1SD$만큼 커져서 평균으로의 회귀현상을 보여줌을 알 수 있다. 다시 말해, 설명변수의 값을 μ_X에서 $\mu_X + \sigma_X$로 1 표준편차만큼 증가시켰다면 반응변수의 기댓값은 μ_Y에서 $\mu_Y + \rho\sigma_Y$로 변하여 1 표준편차보다 작은 만큼 증가한다는 것이다. 예를 들어, 갈톤의 자료에서 부모의 키가 매우 커서 $\mu_X + 3\sigma_X$의 값을 가지는 경우 자녀의 키의 기댓값은 $\mu_Y + 3\rho\sigma_Y$로 부모의 키에 비해 평균 쪽에 좀 더 가까이 있게 된다. 만약 $\rho = 0$이라면 회귀직선이 X축과 평행하게 되며, 이때는 X의 주어진 값이 Y의 값을 예측하는 데에 전혀 도움이 되지 않는다. 이 경우 Y의 조건부 분포가 주변분포와 동일하게 됨을 알 수 있다.

한편, 모수벡터가 $(\mu_X,\ \mu_Y,\ \sigma_X,\ \sigma_Y,\ \rho)$인 이변량 정규확률벡터 (X, Y)가 있을 때, 조건부 확률변수 $Y|x$의 확률밀도함수 $f_{Y|x}(y|x)$는 다음과 같이 주어진다(2.6.4절 참조).

$$f_{Y|x}(y|x) = \frac{1}{\sqrt{2\pi}\,\sigma_Y\sqrt{1-\rho^2}} \exp\left\{ \frac{-1}{2\sigma_Y^2(1-\rho^2)} \left[y - \mu_Y - \frac{\rho\sigma_Y}{\sigma_X}(x-\mu_X) \right]^2 \right\}$$

이로부터 $Y|x$의 기댓값과 분산은

$$E(Y|x) = \mu_Y + \frac{\rho\sigma_Y}{\sigma_X}(x-\mu_X) \tag{7.7}$$

$$Var(Y|x) = (1-\rho^2)\sigma_Y^2$$

으로 주어짐을 알 수 있다. ρ가 0이 아니면 X와 Y의 선형관계에 의해 조건부 분포의 평균과 분산이 주변분포의 그것과 같지 않게 된다. 즉, X의 주어진 값이 Y를 예측하는 데에 영향을 끼치게 된다는 것이다. 특히, 선형관계가 강하여 $|\rho|$의 값이 매우 크면 Y의 조건부 분산이 매우 작아져서 Y값을 예측하는 것이 훨씬 쉬워진다. 또한 위 식에서 $Y|x$의 조건부 기댓값이 x에 대한 선형함수로 표현됨을 볼 수 있는데, 이에 따

라 두 변수 (X, Y)가 이변량 정규분포를 따르는 경우 선형 회귀모형 (7.4)가 타당한 모형임을 알 수 있다.

7.3 회귀모수의 추정

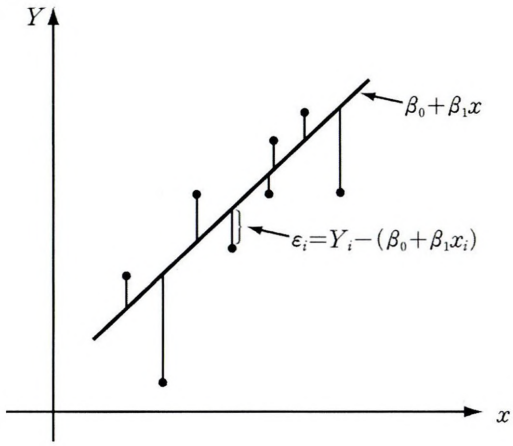
이 절에서는 주어진 이변량 자료 (X_i, Y_i) $i = 1, 2, \cdots, n$에 대해 선형모형 (7.4)를 고려하여, 회귀모수 β_0, β_1과 Y의 분산 σ^2을 추정하는 문제를 살펴보도록 한다. 추정방법으로는 크게 최소제곱 추정방법과 정규성 가정하에서의 최대가능도 추정방법의 두 가지가 있다.

7.3.1 최소제곱 추정방법

이 방법은 $X = x_i$에서의 반응변수의 값 Y_i와 회귀함수의 값 $\beta_0 + \beta_1 x_i$의 차이로 표현되는 오차(error)의 제곱합을 최소화하는 β_0와 β_1을 구하여 모수를 추정하는 방법이다. $\beta_0 + \beta_1 x_i$가 Y_i의 조건부 기댓값이므로 이것이 주어진 x_i값에서 Y_i에 대한 예측값이라 볼 수 있고, 관측된 Y_i값과 예측된 값 사이의 차이 $Y_i - \beta_0 - \beta_1 x_i$가 오차로 정의된다. 오차는 부호에 상관없이 그 절댓값이 작은 것이 중요하므로 오차를 제곱하고, 모든 관찰값에서 작은 오차의 값을 갖는 추정치를 찾아야 하므로 모든 오차의 제곱을 더하여, 이 제곱합을 최소화하는 β_0와 β_1을 찾게 된다. 이와 같이 β_0와 β_1에 관한 식

$$SSE(\beta_0, \beta_1) = \sum_{i=1}^{n} (Y_i - \beta_0 - \beta_1 x_i)^2 \tag{7.8}$$

을 최소화하는 β_0와 β_1을 회귀모수 β_0와 β_1의 **최소제곱 추정량**(least square estimator)이라고 한다. 이는 그림 7.3에서 $\varepsilon_i^2 = (Y_i - \beta_0 - \beta_1 x_i)^2$ $(i = 1, 2, \cdots, n)$의 합을 최소화하는 β_0와 β_1을 의미한다.



▸ **그림 7.3** ◂ 회귀직선과 오차

이제 최소제곱 추정량은 정리 7.4와 같이 주어진다.

정리 7.4

오차제곱합 $SSE(\beta_0, \beta_1)=\sum_{i=1}^{n}(Y_i-\beta_0-\beta_1 x_i)^2$을 최소화하는 β_0와 β_1의 최소제곱 추정량은 다음과 같다.

$$\hat{\beta}_1=\frac{\sum_{i=1}^{n}(x_i-\overline{x}_n)(Y_i-\overline{Y}_n)}{\sum_{i=1}^{n}(x_i-\overline{x}_n)^2}$$

$$\hat{\beta}_0=\overline{Y}_n-\hat{\beta}_1\overline{x}_n$$

증명 오차제곱합 $SSE(\beta_0, \beta_1)$을 β_0와 β_1에 대하여 미분한 식을 0으로 놓으면

$$\frac{\partial SSE}{\partial \beta_0}=-2\sum_{i=1}^{n}(Y_i-\beta_0-\beta_1 x_i)=0$$

$$\frac{\partial SSE}{\partial \beta_1}=-2\sum_{i=1}^{n}(Y_i-\beta_0-\beta_1 x_i)x_i=0$$

을 얻게 되는데, 이는 다음의 두 식과 동등하다.

$$\beta_0 n+\beta_1\sum_{i=1}^{n}x_i=\sum_{i=1}^{n}Y_i$$

$$\beta_0 \sum_{i=1}^{n} x_i + \beta_1 \sum_{i=1}^{n} x_i^2 = \sum_{i=1}^{n} x_i Y_i$$

이제, β_0와 β_1에 대한 위의 두 연립방정식을 풀어 구한 해

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{n} (x_i - \bar{x}_n)(Y_i - \bar{Y}_n)}{\sum_{i=1}^{n} (x_i - \bar{x}_n)^2}$$

$$\hat{\beta}_0 = \bar{Y}_n - \hat{\beta}_1 \bar{x}_n$$

가 $SSE(\beta_0, \beta_1)$을 최소화함을 확인할 수 있다. 따라서 $\hat{\beta}_0$와 $\hat{\beta}_1$는 최소제곱 추정량이다. ■

최소제곱 추정방법은 랜덤오차 ε에 대한 분포가정이 없어도 사용할 수 있는 방법으로 분산분석 등에서도 활용된다. 그런데 위의 최소제곱 추정량 $\hat{\beta}_0$과 $\hat{\beta}_1$은 식 (7.6)에서 모수벡터 $(\mu_X, \sigma_X, \mu_Y, \sigma_Y, \rho)$를 해당하는 표본값 $(\bar{x}_n, S_X, \bar{Y}_n, S_Y, R)$로 대치한 것과 동일하다.

예 7.5

어떤 화학실험에 있어서 실험온도 x_i에서의 결과량 $Y_i (i = 1, 2, \cdots, 10)$가 다음 표와 같이 관찰되었다.

x_i	30	35	40	45	50	55	60	65	70	75
Y_i	25	32	34	43	42	48	55	56	72	70

주어진 자료에 대해 회귀모형 $E(Y|x) = \beta_0 + \beta_1 x$를 고려했을 때 회귀모수 β_0와 β_1의 최소제곱 추정량을 구하면 다음과 같다.

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{10} (x_i - \bar{x}_{10})(Y_i - \bar{Y}_{10})}{\sum_{i=1}^{10} (x_i - \bar{x}_{10})^2} = \frac{\sum_{i=1}^{10} x_i Y_i - 10\bar{x}_{10}\bar{Y}_{10}}{\sum_{i=1}^{10} x_i^2 - 10\bar{x}_{10}^2} = 1.015$$

$$\hat{\beta}_0 = \overline{Y}_{10} - \hat{\beta}_1 \overline{x}_{10} = -5.564$$

따라서 추정된 회귀직선은

$$y = -5.564 + 1.015x$$

이다.

7.3.2 최대가능도 추정방법

선형 회귀모형 (7.4)는 $X = x$가 주어질 때 반응변수 Y가 $N(\beta_0 + \beta_1 x, \sigma^2)$ 분포를 따른다는 것과 동일하다. 이제, 서로 독립인 조건부 확률변수 $Y_i | x_i$가 각각 $N(\beta_0 + \beta_1 x_i, \sigma^2)$ 분포를 따른다고 할 때 $(i = 1, 2, \cdots, n)$, 모수 β_0, β_1, σ^2에 대한 최대가능도 추정량을 구해 보자.

정리 7.5

서로 독립인 확률변수 $Y_1, Y_2, \cdots, Y_n$이 각각 $N(\beta_0 + \beta_1 x_i, \sigma^2)$ 분포를 따른다고 하자. 이때 모수 β_0, β_1, σ^2에 대한 최대가능도 추정량은

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{n} (x_i - \overline{x}_n)(Y_i - \overline{Y}_n)}{\sum_{i=1}^{n} (x_i - \overline{x}_n)^2}$$

$$\hat{\beta}_0 = \overline{Y}_n - \hat{\beta}_1 \overline{x}_n$$

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^{n} (Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$$

이다.

증명 모수 β_0, β_1, σ^2의 최대가능도 추정량을 구하기 위한 로그 가능도함수는

$$\log\left[\prod_{i=1}^{n} f(y_i | x_i)\right] = (-n/2)\log(2\pi\sigma^2) - (1/2\sigma^2) \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i)^2$$

으로 주어진다. 위 가능도함수를 β_0, β_1, σ^2에 대하여 미분한 결과를 0으로 놓

으면,

$$\frac{1}{\sigma^2}\sum_{i=1}^{n}(y_i-\beta_0-\beta_1 x_i)=0$$

$$\frac{1}{\sigma^2}\sum_{i=1}^{n}(y_i-\beta_0-\beta_1 x_i)x_i=0$$

$$\frac{n}{\sigma^2}-\frac{1}{(\sigma^2)^2}\sum_{i=1}^{n}(y_i-\beta_0-\beta_1 x_i)^2=0$$

이다. 그런데 위의 세 개의 식 중에서 처음 두 개의 식은 정리 7.4에서 β_0와 β_1의 최소제곱 추정량을 구할 때와 같은 형태이며, 따라서 동일한 해를 구할 수 있다. 세 번째 식에 대한 해를 마저 구하여 가능도함수를 최대화함을 2차 미분을 통하여 확인하면, 모수 β_0, β_1, σ^2의 최대가능도 추정량은

$$\hat{\beta}_1=\frac{\sum_{i=1}^{n}(x_i-\overline{x}_n)(Y_i-\overline{Y}_n)}{\sum_{i=1}^{n}(x_i-\overline{x}_n)^2}$$

$$\hat{\beta}_0=\overline{Y}_n-\hat{\beta}_1\overline{x}_n$$

$$\hat{\sigma}^2=\frac{1}{n}\sum_{i=1}^{n}(Y_i-\hat{\beta}_0-\hat{\beta}_1 x_i)^2$$

으로 주어진다. ■

예 7.6

(예 7.5 계속) 앞의 예 7.5의 자료를 사용하면, 회귀모수 β_0, β_1의 최대가능도 추정량은 최소제곱 추정량과 동일하다. 또한 σ^2의 최대가능도 추정량의 값은

$$\begin{aligned}\hat{\sigma}^2&=\frac{1}{10}\sum_{i=1}^{10}(Y_i-\hat{\beta}_0-\hat{\beta}_1 x_i)^2\\&=\frac{1}{10}\sum_{i=1}^{10}(Y_i-\overline{Y}_{10}+\hat{\beta}_1\overline{x}_{10}-\hat{\beta}_1 x_i)^2\\&=\frac{1}{10}\sum_{i=1}^{10}\{(Y_i-\overline{Y}_{10})-\hat{\beta}_1(x_i-\overline{x}_{10})\}^2\end{aligned}$$

$$= 9.116$$

으로 계산된다.

7.3.3 추정량의 성질

이제, 회귀모형의 성능을 가늠하는 데 필요한 회귀모수 추정량들의 성질과 분포이론을 살펴보자. 이는 앞으로 다룰 회귀모수에 대한 가설검정 및 신뢰구간의 추정에 중요하게 활용될 것이다.

정리 7.6

서로 독립인 확률변수 $Y_i (i = 1, 2, \cdots, n)$가 각각 $N(\beta_0 + \beta_1 x_i, \sigma^2)$ 분포를 따른다고 하자. 이때 β_0과 β_1에 대한 최대가능도 추정량 $\hat{\beta}_0$와 $\hat{\beta}_1$의 분포는 각각 다음과 같다.

$$\hat{\beta}_0 \sim N\left[\beta_0, \frac{\sigma^2 \sum_{i=1}^{n} x_i^2}{n \sum_{i=1}^{n} (x_i - \overline{x}_n)^2}\right]$$

$$\hat{\beta}_1 \sim N\left[\beta_1, \frac{\sigma^2}{\sum_{i=1}^{n} (x_i - \overline{x}_n)^2}\right]$$

증명 정리 7.5로부터 모수 β_1의 최대가능도 추정량은

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{n} (x_i - \overline{x}_n)(Y_i - \overline{Y}_n)}{\sum_{i=1}^{n} (x_i - \overline{x}_n)^2} = \frac{\sum_{i=1}^{n} (x_i - \overline{x}_n) Y_i}{\sum_{i=1}^{n} (x_i - \overline{x}_n)^2}$$

이고, 이는 서로 독립인 정규확률변수 Y_i들의 선형결합이기에, $\hat{\beta}_1$은 정규분포를 따른다. 나아가,

$$
\begin{aligned}
E(\hat{\beta}_1) &= E\left(\frac{\sum_{i=1}^{n} (x_i - \bar{x}_n) Y_i}{\sum_{i=1}^{n} (x_i - \bar{x}_n)^2} \right) \\
&= \frac{\sum_{i=1}^{n} (x_i - \bar{x}_n)(\beta_0 + \beta_1 x_i)}{\sum_{i=1}^{n} (x_i - \bar{x}_n)^2} \\
&= \frac{\beta_1 \sum_{i=1}^{n} (x_i - \bar{x}_n)\, x_i}{\sum_{i=1}^{n} (x_i - \bar{x}_n)^2} \\
&= \beta_1
\end{aligned}
$$

이고,

$$
\begin{aligned}
Var(\hat{\beta}_1) &= \frac{\sum_{i=1}^{n} (x_i - \bar{x}_n)^2 \, Var(Y_i)}{\left(\sum_{i=1}^{n} (x_i - \bar{x}_n)^2 \right)^2} \\
&= \frac{\sigma^2}{\sum_{i=1}^{n} (x_i - \bar{x}_n)^2}
\end{aligned}
$$

이다. 또한, $\hat{\beta}_0 = \sum_{i=1}^{n} \left(\frac{1}{n} - \frac{\bar{x}_n (x_i - \bar{x}_n)}{\sum_{i=1}^{n} (x_i - \bar{x}_n)^2} \right) Y_i$도 Y_i들의 선형결합으로 표현되므로 정규분포를 따르며

$$
\begin{aligned}
E(\hat{\beta}_0) &= E(\bar{Y}_n) - \bar{x}_n \cdot E(\hat{\beta}_1) \\
&= \beta_0 + \beta_1 \bar{x}_n - \beta_1 \bar{x}_n \\
&= \beta_0
\end{aligned}
$$

이 성립한다. $Var(\hat{\beta}_0)$를 구하기 위해서는 약간의 준비가 필요하다. 먼저,

$$Cov(\hat{\beta}_1,\ Y_i) = Cov\left(\frac{\sum_{i=1}^{n}(x_i - \bar{x}_n)\ Y_i}{\sum_{i=1}^{n}(x_i - \bar{x}_n)^2},\ Y_i \right)$$

$$= \frac{\sum_{i=1}^{n}(x_i - \bar{x}_n)\sigma^2}{\sum_{i=1}^{n}(x_i - \bar{x}_n)^2} = 0$$

이므로,

$$Cov(\hat{\beta}_1,\ \bar{Y}_n) = \frac{1}{n}\sum_{i=1}^{n} Cov(\hat{\beta}_1,\ Y_i)$$

$$= 0$$

이 성립한다. 이제,

$$Var(\hat{\beta}_0) = Var(\bar{Y}_n - \hat{\beta}_1 \bar{x}_n)$$

$$= Var(\bar{Y}_n) + Var(\hat{\beta}_1 \bar{x}_n) + 2\,Cov(\bar{Y}_n,\ -\hat{\beta}_1 \bar{x}_n)$$

$$= \frac{\sigma^2}{n} + \frac{\bar{x}_n^2 \sigma^2}{\sum_{i=1}^{n}(x_i - \bar{x}_n)^2}$$

$$= \frac{\sigma^2 \sum_{i=1}^{n} x_i^2}{n\sum_{i=1}^{n}(x_i - \bar{x}_n)^2}$$

을 구할 수 있다. ■

참고 7.5절에서 다루어질 가우스-마코프(Gauss-Markov) 정리에 의하면, 최소제곱 추정량 $\hat{\beta}_0$과 $\hat{\beta}_1$은 최적 선형 비편향추정량(Best Linear Unbiased Estimator)의 성질을 가진다. 즉, 회귀모수 β_0와 β_1에 대해, Y_i들의 선형결합꼴로 된 비편향추정량들만을 고려하면, $\hat{\beta}_0$과 $\hat{\beta}_1$이 그 가운데 분산을 최소로 하는 추정량이라는 것이다.

다음의 정리 7.7은 회귀모수에 대한 통계적 가설검정 등의 추론을 할 때 사용되는

추정량의 성질을 포함하고 있다.

정리 7.7

서로 독립인 확률변수 $Y_i (i = 1, 2, \cdots, n)$가 각각 $N(\beta_0 + \beta_1 x_i, \sigma^2)$ 분포를 따른다고 하자. 이때,

(1) $\hat{\beta}_1$, $\overline{Y}_n$와 $\hat{\sigma}^2$은 서로 독립이다.

(2) $\dfrac{n\hat{\sigma}^2}{\sigma^2}$은 자유도가 $(n-2)$인 카이제곱분포를 따른다.

증명 편의상 $W_i = Y_i - \beta_0 - \beta_1 x_i (i = 1, 2, \cdots, n)$, 그리고

$$\overline{W}_n = \frac{1}{n}\sum_{i=1}^{n} W_i = \overline{Y}_n - \beta_0 - \beta_1 \overline{x}_n$$

라 놓기로 한다. 그러면,

$$\hat{\beta}_1 - \beta_1 = \frac{\sum_{i=1}^{n}(x_i - \overline{x}_n)(Y_i - \overline{Y}_n)}{\sum_{i=1}^{n}(x_i - \overline{x}_n)^2} - \beta_1$$

$$= \frac{\sum_{i=1}^{n}(x_i - \overline{x}_n)(Y_i - \overline{Y}_n) - \beta_1 \sum_{i=1}^{n}(x_i - \overline{x}_n)^2}{\sum_{i=1}^{n}(x_i - \overline{x}_n)^2}$$

$$= \frac{\sum_{i=1}^{n}(x_i - \overline{x}_n)(Y_i - \overline{Y}_n) - \beta_1 \sum_{i=1}^{n}(x_i - \overline{x}_n)(x_i - \overline{x}_n)}{\sum_{i=1}^{n}(x_i - \overline{x}_n)^2}$$

$$= \frac{\sum_{i=1}^{n}(x_i - \overline{x}_n)[(Y_i - \beta_0 - \beta_1 x_i) - (\overline{Y}_n - \beta_0 - \beta_1 \overline{x}_n)]}{\sum_{i=1}^{n}(x_i - \overline{x}_n)^2}$$

$$= \frac{\sum_{i=1}^{n}(x_i - \bar{x}_n)(W_i - \overline{W}_n)}{\sum_{i=1}^{n}(x_i - \bar{x}_n)^2} \tag{7.9}$$

가 성립한다. 나아가,

$$\begin{aligned} Y_i - \hat{Y}_i &= Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i = Y_i - \overline{Y}_n + \hat{\beta}_1 \bar{x}_n - \hat{\beta}_1 x_i \\ &= (Y_i - \beta_0 - \beta_1 x_i) - (\overline{Y}_n - \beta_0 - \beta_1 \bar{x}_n) - (x_i - \bar{x}_n)(\hat{\beta}_1 - \beta_1) \\ &= (W_i - \overline{W}_n) - (x_i - \bar{x}_n)(\hat{\beta}_1 - \beta_1) \end{aligned}$$

이 성립하므로

$$\begin{aligned} n\hat{\sigma}^2 &= \sum_{i=1}^{n}(Y_i - \hat{Y}_i)^2 = \sum_{i=1}^{n}[(W_i - \overline{W}_n) - (x_i - \bar{x}_n)(\hat{\beta}_1 - \beta_1)]^2 \\ &= \sum_{i=1}^{n}(W_i - \overline{W}_n)^2 + \sum_{i=1}^{n}(x_i - \bar{x}_n)^2(\hat{\beta}_1 - \beta_1)^2 \\ &\quad - 2\sum_{i=1}^{n}(W_i - \overline{W}_n)(x_i - \bar{x}_n)(\hat{\beta}_1 - \beta_1) \end{aligned}$$

이다. 이제 앞에서 구한 $(\hat{\beta}_1 - \beta_1)$에 관한 식 (7.9)를 이용하면,

$$\begin{aligned} -2\sum_{i=1}^{n}(W_i - \overline{W}_n)(x_i - \bar{x}_n)(\hat{\beta}_1 - \beta_1) &= -2(\hat{\beta}_1 - \beta_1)\sum_{i=1}^{n}(x_i - \bar{x}_n)(W_i - \overline{W}_n) \\ &= -2(\hat{\beta}_1 - \beta_1)(\hat{\beta}_1 - \beta_1)\sum_{i=1}^{n}(x_i - \bar{x}_n)^2 \\ &= -2\sum_{i=1}^{n}(x_i - \bar{x}_n)^2(\hat{\beta}_1 - \beta_1)^2 \end{aligned}$$

이며, 따라서

$$\begin{aligned} n\hat{\sigma}^2 &= \sum_{i=1}^{n}(W_i - \overline{W}_n)^2 - \sum_{i=1}^{n}(x_i - \bar{x}_n)^2(\hat{\beta}_1 - \beta_1)^2 \\ &= \sum_{i=1}^{n} W_i^2 - n\overline{W}_n^2 - \sum_{i=1}^{n}(x_i - \bar{x}_n)^2(\hat{\beta}_1 - \beta_1)^2 \end{aligned}$$

이 성립된다. 여기에서, 첫 번째 행과 두 번째 행이 각각

$$\left(\frac{x_1-\bar{x}_n}{\sqrt{\sum_{i=1}^{n}(x_i-\bar{x}_n)^2}},\ \cdots,\ \frac{x_n-\bar{x}_n}{\sqrt{\sum_{i=1}^{n}(x_i-\bar{x}_n)^2}}\right)$$

$$\left(\frac{1}{\sqrt{n}},\ \cdots,\ \frac{1}{\sqrt{n}}\right)$$

인 $(n\times n)$ 정규직교행렬(orthonormal matrix) M에 의한 $W=(W_1,\cdots,W_n)$의 변환을 $Z=(Z_1,\cdots,Z_n)$이라 하자.

$$\begin{pmatrix}Z_1\\ \vdots\\ Z_n\end{pmatrix}=M\begin{pmatrix}W_1\\ \vdots\\ W_n\end{pmatrix}$$

그러면 정리 2.25와 직교변환의 성질을 활용하면 증명될 수 있는, 직교행렬에 의해 변환된 서로 독립인 n개의 정규확률변수도 역시 서로 독립인 정규확률변수라는 사실에 의하여 Z_i들은 서로 독립이고, 각각이 $N(0,\sigma^2)$ 분포를 따르며,

$$\sum_{i=1}^{n}Z_i^2=\sum_{i=1}^{n}W_i^2$$

을 만족한다. 그런데 $Z_1^2=\sum_{i=1}^{n}(x_i-\bar{x}_n)^2(\hat{\beta}_1-\beta_1)^2$, $Z_2^2=n\overline{W}_n{}^2$이므로

$$n\hat{\sigma}^2=\sum_{i=1}^{n}Z_i{}^2-Z_1{}^2-Z_2{}^2=\sum_{i=3}^{n}Z_i^2$$

이다. 그러므로 $\hat{\beta}_1$은 Z_1의 함수이며, $\overline{Y}_n$는 Z_2의 함수이고, $\hat{\sigma}^2$은 $Z_3,\cdots,Z_n$의 함수임을 알 수 있다. 따라서 $\hat{\beta}_1$, $\overline{Y}_n$와 $\hat{\sigma}^2$은 서로 독립이다. 마지막으로

$$\frac{n\hat{\sigma}^2}{\sigma^2}=\sum_{i=3}^{n}\left(\frac{Z_i}{\sigma}\right)^2$$

이므로 $\frac{n\hat{\sigma}^2}{\sigma^2}$는 자유도가 $(n-2)$인 카이제곱분포를 따른다. ■

위의 정리 7.7로부터 $n\hat{\sigma}^2/\sigma^2\sim\chi^2(n-2)$이므로, $E(n\hat{\sigma}^2/\sigma^2)=n-2$이다. 따라서 $E(\hat{\sigma}^2)=\frac{(n-2)\sigma^2}{n}$이 되어 최대가능도 추정량 $\hat{\sigma}^2$은 편향되어 있음을 알 수 있으며,

$\hat{\sigma}^2$의 최소분산 비편향추정량은

$$\tilde{\sigma}^2 = \frac{1}{n-2}\sum_{i=1}^{n}(Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2 \tag{7.10}$$

이다. 한편, 정리 7.6과 7.7의 결과로부터 회귀모수 β_1에 대한 가설검정 및 신뢰구간에 활용되는 $\hat{\beta}_1$의 스튜던트화 확률변량의 분포는 다음과 같다.

정리 7.8

서로 독립인 확률변수 $Y_i (i = 1, 2, \cdots, n)$가 각각 $N(\beta_0 + \beta_1 x_i, \sigma^2)$ 분포를 따른다고 하자. 이때 확률변량

$$\frac{(\hat{\beta}_1 - \beta_1)\sqrt{\sum_{i=1}^{n}(x_i - \bar{x}_n)^2}}{\tilde{\sigma}}$$

는 자유도가 $(n-2)$인 t 분포를 따른다.

증명 여기에서 분모에 사용되는 σ의 추정량은 최대가능도 추정량 $\hat{\sigma}^2$의 제곱근이 아닌 최소분산 비편향추정량 $\tilde{\sigma}^2$의 제곱근임을 유의하자. $\hat{\beta}_1 - \beta_1$은 $N(0, \sigma^2/\sum_{i=1}^{n}(x_i - \bar{x}_n)^2)$ 분포를 따르며 $\tilde{\sigma}^2$과 서로 독립이다. 또한, $\frac{n\hat{\sigma}^2}{\sigma^2} = \frac{(n-2)\tilde{\sigma}^2}{\sigma^2}$은 자유도가 $(n-2)$인 카이제곱분포를 따르므로 t 분포의 정의에 의하여 자명하다. ■

7.4 가설검정 및 신뢰구간

앞 절에서는 $\beta_0, \beta_1, \sigma^2$의 추정량들의 분포와 그들 간의 관계를 살펴보았다. 여기에서는 이 결과들을 활용하여 회귀모수에 대한 가설검정과 신뢰구간 추정의 문제를 다루기로 한다.

먼저, 모수 β_1에 대한 가설

$$H_0 : \beta_1 = \beta_{10} \quad \text{대} \quad H_1 : \beta_1 \neq \beta_{10} \tag{7.11}$$

을 고려하여 보자. 정리 7.8로부터, 확률변량

$$\frac{(\hat{\beta}_1-\beta_{10})\sqrt{\sum_{i=1}^{n}(x_i-\bar{x}_n)^2}}{\tilde{\sigma}}$$

은 귀무가설하에서 자유도가 $(n-2)$인 t 분포를 따른다. 따라서,

$$\frac{(\hat{\beta}_1-\beta_{10})\sqrt{\sum_{i=1}^{n}(x_i-\bar{x}_n)^2}}{\tilde{\sigma}} \leq -t_{\alpha/2}(n-2) \quad \text{또는} \quad \geq t_{\alpha/2}(n-2) \tag{7.12}$$

는 가설 (7.11)에 대한 유의수준 α인 검정방법의 기각영역이 된다.

한편, 모수 β_1에 대한 가설이

$$H_0 : \beta_1 = \beta_{10} \quad \text{대} \quad H_1 : \beta_1 > \beta_{10} \tag{7.13}$$

으로 대립가설이 단측인 경우에는, 마찬가지 방법으로 유의수준 α인 기각영역이

$$\frac{1}{\tilde{\sigma}}(\hat{\beta}_1-\beta_{10})\sqrt{\sum_{i=1}^{n}(x_i-\bar{x}_n)^2} \geq t_{\alpha}(n-2) \tag{7.14}$$

로 주어진다. 흔히, 선형 회귀모형에서 가장 관심 있는 가설검정은 $H_0 : \beta_1 = 0$ 대 $H_1 : \beta_1 \neq 0$이 된다. 왜냐하면 β_1이 0이면 X와 Y 사이에 아무런 선형관계가 성립하지 않기 때문이다. 이에 비해 β_0에 대한 검정은 현실적으로 큰 관심사가 아닌 경우가 많다.

다음으로 모수 β_1에 대한 $100(1-\alpha)\%$ 신뢰구간은

$$P\left[-t_{\alpha/2}(n-2) \leq \frac{1}{\tilde{\sigma}}(\hat{\beta}_1-\beta_1)\sqrt{\sum_{i=1}^{n}(x_i-\bar{x}_n)^2} \leq t_{\alpha/2}(n-2)\right] = 1-\alpha$$

로부터

$$\left[\hat{\beta}_1 - t_{\alpha/2}(n-2)\cdot\frac{\tilde{\sigma}}{\sqrt{\sum_{i=1}^{n}(x_i-\bar{x}_n)^2}},\ \hat{\beta}_1 + t_{\alpha/2}(n-2)\cdot\frac{\tilde{\sigma}}{\sqrt{\sum_{i=1}^{n}(x_i-\bar{x}_n)^2}}\right] \tag{7.15}$$

로 주어진다. β_0에 대한 가설검정 방법 및 신뢰구간 추정도 같은 방법으로 쉽게 구할 수 있으며, 연습문제로 남기도록 한다.

(7.11)에 주어진 가설검정에서 $H_1 : \beta_1 \neq \beta_{10}$에 대한 유의수준 α인 t 검정법의 검정력을 살펴보자. 검정력함수는

$$\pi(\beta_1) = P\left(\frac{1}{\tilde{\sigma}}\left|(\hat{\beta}_1 - \beta_{10})\sqrt{\sum_{i=1}^{n}(x_i - \bar{x}_n)^2}\right| \geq t_{\alpha/2}(n-2)|\beta_1\right)$$
$$= P\left(\frac{1}{\tilde{\sigma}}\left|(\hat{\beta}_1 - \beta_1)\sqrt{\sum_{i=1}^{n}(x_i - \bar{x}_n)^2} + (\beta_1 - \beta_{10})\sqrt{\sum_{i=1}^{n}(x_i - \bar{x}_n)^2}\right| \geq t_{\alpha/2}(n-2)|\beta_1\right)$$

이 되고 회귀모수의 참값이 β_1일 때 $\frac{1}{\tilde{\sigma}}(\hat{\beta}_1 - \beta_{10})\sqrt{\sum_{i=1}^{n}(x_i - \bar{x}_n)^2}$의 분포는 5.3절에서 살펴본 바와 같이 비중심모수가 $\delta = \frac{1}{\sigma}(\beta_1 - \beta_{10})\sqrt{\sum_{i=1}^{n}(x_i - \bar{x}_n)^2}$인 비중심 t 분포를 따른다. 즉, 검정력의 계산을 위해 비중심 t 분포가 필요하며, 실제 계산은 복잡하므로 생략하기로 한다. 물론, σ의 추정을 통해 δ를 추정한 후 컴퓨터를 이용하여 계산하면 쉽게 검정력의 추정값과 추정곡선을 얻을 수 있다.

예 7.7

다음은 미국의 천문학자 허블(Hubble)이 사용한 11개의 은하계에 대한 거리(X)와 후퇴속도(Y: recession velocity)에 관한 자료이다. 이 자료에 대한 선형 회귀모형 $Y = \beta_0 + \beta_1 x + \varepsilon$, $\varepsilon \sim N(0, \sigma^2)$을 고려했을 때, 회귀모수 β_1에 대한 가설

$$H_0 : \beta_1 = 0 \quad \text{대} \quad H_1 : \beta_1 > 0$$

을 검정하여 보면 다음과 같다. 우선, 회귀모수의 최소제곱 추정량은

은하계	거리(백만광년)	속도(마일/초)
1	22	750
2	68	2400
3	108	3200
4	137	4700
5	255	9300
6	315	12000
7	390	13400
8	405	14400
9	685	24500
10	700	26000
11	1100	38000

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{11}(x_i - \bar{x}_{11})(Y_i - \bar{Y}_{11})}{\sum_{i=1}^{11}(x_i - \bar{x}_{11})^2} = \frac{\sum_{i=1}^{11} x_i Y_i - 11 \times \bar{x}_{11}\bar{Y}_{11}}{\sum_{i=1}^{11} x_i^2 - 11 \times \bar{x}_{11}^2} = 35.324$$

$$\hat{\beta}_0 = \bar{Y}_{11} - \hat{\beta}_1 \bar{x}_{11} = 13513.636 - 35.324 \times 380.455 = 74.444$$

가 되며, 분산 σ^2의 최소분산 비편향추정량은

$$\tilde{\sigma}^2 = \frac{1}{11-2}\sum_{i=1}^{11}(Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2 = 420183.7$$

이 된다. 따라서,

$$\widehat{Var(\hat{\beta}_1)} = \frac{\tilde{\sigma}^2}{\sum_{i=1}^{11}(x_i - \bar{x}_{11})^2} = 0.3844$$

로부터

$$\frac{(\hat{\beta}_1 - 0)\sqrt{\sum_{i=1}^{11}(x_i - \bar{x}_{11})^2}}{\tilde{\sigma}} = 56.974 \geq t_{0.05}(9) = 1.833$$

을 얻게 되며, 유의수준 0.05에서 귀무가설 $H_0 : \beta_1 = 0$을 기각한다. 나아가, 회귀모수 β_1에 대한 90% 신뢰구간은

$$\begin{aligned}&[35.324 - 1.833 \times \sqrt{0.3844},\ \ 35.324 + 1.883 \times \sqrt{0.3844}\,] \\ &= [34.188,\ \ 36.460]\end{aligned}$$

으로 계산된다.

선형 회귀모형 (7.4)를 사용하는 경우, 독립변수의 값이 $X = x^*$가 주어졌을 때, 조건부 기댓값 $E(Y \mid x^*) = \beta_0 + \beta_1 x^*$의 추정량으로

$$\begin{aligned}\hat{\mu}_{Y|x^*} &= \hat{\beta}_0 + \hat{\beta}_1 x^* \\ &= \bar{Y}_n - \hat{\beta}_1 \bar{x}_n + \hat{\beta}_1 x^* \\ &= \sum_{i=1}^{n}\left[\frac{1}{n} + \frac{(x^* - \bar{x}_n)(x_i - \bar{x}_n)}{\sum_{i=1}^{n}(x_i - \bar{x}_n)^2}\right] Y_i\end{aligned}$$

를 사용할 수 있다. 이 추정량 $\hat{\mu}_{Y|x^*}$은 서로 독립인 정규확률변수 Y_i들의 선형결합꼴이므로 정규분포를 따른다. 평균과 분산을 구해 보면,

$$\begin{aligned} E(\hat{\mu}_{Y|x^*}) &= E(\hat{\beta}_0 + \hat{\beta}_1 x^*) \\ &= \beta_0 + \beta_1 x^* \end{aligned}$$

이고, 정리 7.6에 의하여

$$\begin{aligned} Var(\hat{\mu}_{Y|x^*}) &= Var(\hat{\beta}_0 + \hat{\beta}_1 x^*) \\ &= Var(\overline{Y}_n - \hat{\beta}_1 \overline{x}_n + \hat{\beta}_1 x^*) \\ &= Var(\overline{Y}_n) + (x^* - \overline{x}_n)^2 \, Var(\hat{\beta}_1) \quad (\because \overline{Y}_n \text{와 } \hat{\beta}_1 \text{이 독립이므로}) \\ &= \sigma^2 \left[\frac{1}{n} + \frac{(x^* - \overline{x}_n)^2}{\sum_{i=1}^{n} (x_i - \overline{x}_n)^2} \right] \end{aligned}$$

이다. 따라서

$$\begin{aligned} \hat{\mu}_{Y|x^*} &= \hat{\beta}_0 + \hat{\beta}_1 x^* \\ &\sim N\left(\beta_0 + \beta_1 x^*, \ \sigma^2 \left[\frac{1}{n} + \frac{(x^* - \overline{x}_n)^2}{\sum_{i=1}^{n} (x_i - \overline{x}_n)^2} \right] \right) \end{aligned} \tag{7.16}$$

이 성립한다. 나아가,

$$S^{*2} = \tilde{\sigma}^2 \left[\frac{1}{n} + \frac{(x^* - \overline{x}_n)^2}{\sum_{i=1}^{n} (x_i - \overline{x}_n)^2} \right]$$

으로 표기하면, 확률변량

$$T = \frac{\hat{\beta}_0 + \hat{\beta}_1 x^* - (\beta_0 + \beta_1 x^*)}{S^*}$$

는 자유도가 $(n-2)$인 t 분포를 가지므로 $E(Y|x^*) = \beta_0 + \beta_1 x^*$에 대한 신뢰수준 $100(1-\alpha)\%$ 신뢰구간을

$$\left[\hat{\beta}_0+\hat{\beta}_1 x^*-t_{\alpha/2}(n-2)\cdot S^*,\ \ \hat{\beta}_0+\hat{\beta}_1 x^*+t_{\alpha/2}(n-2)\cdot S^*\right] \qquad (7.17)$$

로 구할 수 있다.

예 7.8

다음 자료는 어떤 연령계층 집단에서 랜덤추출한 16명의 몸무게(X)와 수축기 혈압(Y)의 측정값이다.

개체	몸무게	혈압	개체	몸무게	혈압
1	74.5	150	9	58.0	128
2	75.0	148	10	65.2	130
3	76.3	151	11	67.3	135
4	68.2	145	12	69.6	136
5	76.8	146	13	80.3	152
6	80.5	160	14	75.6	158
7	72.1	149	15	85.8	170
8	67.2	133	16	59.1	124

위 자료에 대해 선형 회귀모형 (7.4)를 고려했을 때, 회귀모수의 최소제곱 추정량은

$$\hat{\beta}_1=\frac{\sum_{i=1}^{16}(x_i-\bar{x}_{16})(Y_i-\bar{Y}_{16})}{\sum_{i=1}^{16}(x_i-\bar{x}_{16})^2}=\frac{\sum_{i=1}^{16}x_i Y_i-16\times\bar{x}_{16}\bar{Y}_{16}}{\sum_{i=1}^{16}x_i^2-16\times\bar{x}_{16}^2}=1.56$$

$$\hat{\beta}_0=\bar{Y}_{16}-\hat{\beta}_1\bar{x}_{16}=32.302$$

가 되며, 분산 σ^2의 최소분산 비편향추정량은

$$\tilde{\sigma}^2=\frac{1}{16-2}\sum_{i=1}^{16}(Y_i-\hat{\beta}_0-\hat{\beta}_1\bar{x}_{16})^2=21.357$$

이 된다. 이제 설명변수의 값이 $X=75$일 때, 조건부 기댓값 $E(Y\mid X=75)=\beta_0+75\beta_1$의 95% 신뢰구간을 구해 보면 다음과 같다. $E(Y\mid X=75)$의 추정값은

$$\hat{\mu}_{Y\mid X=75}=\hat{\beta}_0+75\hat{\beta}_1=149.452$$

가 되고, $t_{0.025}(14)=2.145$,

$$S^{*2} = 21.357\left[\frac{1}{16} + \frac{(75-\bar{x}_{16})^2}{\sum_{i=1}^{n}(x_i-\bar{x}_{16})^2}\right] = 1.559$$

이므로 $E(Y|X=75)$의 95% 신뢰구간은

$$[32.302 + 1.562\times 75 - 2.145\times S^*,\ \ 32.302 + 1.562\times 75 + 2.145\times S^*]$$
$$= [146.774,\ 152.130]$$

으로 주어진다.

예측구간

선형모형 (7.4)에서, 주어진 이변량 자료 $(x_i,\ Y_i)(i=1,\ 2,\cdots,\ n)$와 독립인 새로운 관찰값 $(x^*,\ Y)$에 대하여 Y의 **예측구간**(prediction interval)을 구해 보기로 한다. 이는 추후에 관측될 자료에 대한 예측을 위한 것이므로 (x^*, Y)가 기존의 자료에 독립임을 가정하는 것은 타당하다고 할 수 있다. 예측구간은 $X=x^*$가 주어졌을 때 그에 상응하는 반응변수 Y값 자체에 대한 확률구간을 의미하는 것으로, 조건부 기댓값 $E(Y|x^*)$에 대한 신뢰구간과는 다르다. 조건부 기댓값의 경우에는 추정량으로 $\hat{\mu}_{Y|x^*} = \hat{\beta}_0 + \hat{\beta}_1 x^*$를 고려하고, 추정값과 참값의 차이인 $\hat{\mu}_{Y|x^*} - (\beta_0 + \beta_1 x^*)$의 분포를 이용하여 신뢰구간을 구하지만, 이 경우에는 $\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 x^*$가 반응변수 Y의 예측값으로 사용되고, $\hat{Y} - Y$의 분포를 이용하여 예측구간을 구하게 된다. 물론, $\hat{\mu}_{Y|x^*} = \hat{Y}$이다. 우선, $E(\hat{Y} - Y) = E(\hat{\beta}_0 + \hat{\beta}_1 x^*) - (\beta_0 + \beta_1 x^*) = 0$이며, $\hat{Y}$과 Y는 독립이므로

$$\begin{aligned} Var(\hat{Y} - Y) &= Var(\hat{Y}) + Var(Y) \\ &= \sigma^2\left[\frac{1}{n} + \frac{(x^*-\bar{x}_n)^2}{\sum_{i=1}^{n}(x_i-\bar{x}_n)^2}\right] + \sigma^2 \\ &= \sigma^2\left[1 + \frac{1}{n} + \frac{(x^*-\bar{x}_n)^2}{\sum_{i=1}^{n}(x_i-\bar{x}_n)^2}\right] \end{aligned}$$

이 된다.

$$S^2(Y) = \tilde{\sigma}^2 \left[1 + \frac{1}{n} + \frac{(x^* - \bar{x}_n)^2}{\sum_{i=1}^{n} (x_i - \bar{x}_n)^2} \right]$$

으로 표기하면, 설명변수의 값이 x^*일 때 새로운 관찰값 Y에 대한 $100(1-\alpha)\%$ 예측구간은

$$\left[\hat{\beta}_0 + \hat{\beta}_1 x^* - t_{\alpha/2}(n-2) \cdot S(Y), \quad \hat{\beta}_0 + \hat{\beta}_1 x^* + t_{\alpha/2}(n-2) \cdot S(Y) \right] \qquad (7.18)$$

로 주어진다. x^*가 주어졌을 때 조건부 기댓값의 신뢰구간과 Y값에 대한 예측구간을 비교해 보면, 구간의 중앙은 $\hat{\beta}_0 + \hat{\beta}_1 x^*$로 같지만 $S^2(Y)$가 S^{*2}에 비해 $\tilde{\sigma}^2$만큼 항상 크기 때문에 예측구간이 신뢰구간보다 길어진다. 이는 확률분포의 평균을 추정하는 것에 비해 확률변수의 값 자체를 예측하는 것이 더 어렵다는 것을 보여 준다. 실제로 조건부 기댓값을 추정하는 데에는 $Y|x^*$의 분포의 중심위치(평균)에 대한 변동만이 관련되나, 예측에 있어서는 그 변동에 더하여 평균이 주어졌을 때 Y값이 가질 수 있는 변동 또한 관련된다.

예 7.9

(예 7.7의 계속) 예 7.7의 자료에 대하여, 거리가 5000만 광년($X = 50$) 되는 곳에 어떤 은하계가 발견되었다고 가정하고, 속도(Y)에 대한 95% 예측구간을 구해 보자. 회귀모수의 최소제곱 추정량은 $\hat{\beta}_0 = 74.444$, $\hat{\beta}_1 = 35.324$, 그리고 분산 σ^2의 최소분산 비편향추정량은 $\tilde{\sigma}^2 = 420183.7$로 구해졌으므로,

$$S^2(Y) = \tilde{\sigma}^2 \left[1 + \frac{1}{11} + \frac{(x^* - \bar{x}_{11})^2}{\sum_{i=1}^{11} (x_i - \bar{x}_{11})^2} \right] = 500364.7$$

로부터,

$$\begin{aligned} &\left[\hat{\beta}_0 + \hat{\beta}_1 x^* - t_{0.025}(11-2) \cdot S(Y), \quad \hat{\beta}_0 + \hat{\beta}_1 x^* + t_{0.025}(11-2) \cdot S(Y) \right] \\ &= [1840.644 - 2.262 \times 707.365, \quad 1840.644 + 2.262 \times 707.365] \\ &= [240.585, \quad 3440.703] \end{aligned}$$

으로 주어진다.

변환에 의한 선형모형

여태까지 다루어 온 선형 회귀모형은 두 변수 X와 Y 사이에 선형관계가 있는 경우 효율적으로 사용될 수 있다. 그러나 두 변수 X와 Y 사이에 직접적인 선형관계가 없더라도 적절한 변환을 통하여 선형관계로 바꿀 수 있는 경우가 있으며, 이런 경우 변환된 자료에 대해 선형 회귀모형을 활용할 수 있다. 몇 가지 예를 들면 다음과 같다.

예 7.10

회귀선이 $y = \beta_0 x^{\beta_1}$인 경우 로그(log)변환을 하면

$$\log y = \log \beta_0 + \beta_1 \log x$$

를 얻게 된다. 이제 $y' = \log y$, $\beta_0' = \log \beta_0$, $\beta_1' = \beta_1$, $x' = \log x$라고 놓으면, 회귀직선

$$y' = \beta_0' + \beta_1' x'$$

을 얻게 된다.

예 7.11

회귀선이 $y = 1/\{1 + \exp(\beta_0 + \beta_1 x)\}$의 형태일 때는 $(1-y)/y = \exp(\beta_0 + \beta_1 x)$를 만족하므로 양변에 로그(log)를 취하여

$$\log\left(\frac{1-y}{y}\right) = \beta_0 + \beta_1 x$$

를 얻게 된다. 이제 $y' = \log\{(1-y)/y)\}$라고 놓으면, 회귀직선

$$y' = \beta_0 + \beta_1 x$$

를 얻게 된다.

앞의 예들을 살펴보면, '선형'이라는 표현의 의미는 설명변수에 대해 선형이라기보다 회귀계수들에 대해 선형인 것을 알 수 있다. 그런데 때로는 $y = \beta_0 + e^{\beta_1 x}$처럼 선형관계로의 변환이 가능치 않으며 이런 경우에 비선형(nonlinear) 모형을 사용할 수 있

으나, 그 내용은 이 책에서는 다루지 않기로 한다.

선형 회귀모형 $Y=\beta_0+\beta_1 x+\varepsilon$에서 랜덤오차 ε의 분산이 설명변수의 값에 의존하지 않는다는 등분산성의 가정은 회귀모수의 추정 등에 있어서 결정적인 역할을 한다. 여기에서는 이러한 등분산성의 가정이 성립하지 않는 경우에 적절한 변환에 의해 선형 회귀모형을 활용할 수 있음을 보이고자 한다. $X=x_i$에서 랜덤오차 ε_i의 분산을

$$Var(\varepsilon_i)=\sigma_i{}^2$$

이라고 하자(이는 $Var(Y_i)=\sigma_i{}^2$과 동일하다). 이제 표준편차의 역수 $w_i=1/\sigma_i$를 각 Y_i값에 곱하여 $Y_i{}'=w_iY_i$라고 변환하면 $Var(Y_i{}')=Var(w_iY_i)=1$ $(i=1,\ 2,\ \cdots,\ n)$이 된다. 그러므로 변환된 모형

$$Y_i{}'=w_iY_i=w_i\beta_0+w_i(\beta_1x_i)+w_i\varepsilon_i \tag{7.19}$$

는 $Var(w_i\varepsilon_i)=1$로서 등분산성을 만족하며, 회귀모수 β_0와 β_1의 최소제곱 추정량은 가중 오차제곱합

$$\sum_{i=1}^{n}\{w_iY_i-w_i\beta_0-w_i(\beta_1x_i)\}^2$$
$$=\sum_{i=1}^{n}w_i{}^2(Y_i-\beta_0-\beta_1x_i)^2$$

을 최소화하여

$$\hat{\beta}_1=\frac{\sum_{i=1}^{n}u_i(x_i-\overline{x}_u)(Y_i-\overline{Y}_u)}{\sum_{i=1}^{n}u_i(x_i-\overline{x}_u)^2} \tag{7.20}$$
$$\hat{\beta}_0=\sum_{i=1}^{n}u_iY_i-\hat{\beta}_1\sum_{i=1}^{n}u_ix_i,\quad \text{단, } u_i=\frac{w_i^2}{\sum w_i^2}$$

으로 구할 수 있다(연습문제 7.15 참조). 여기에서 $\overline{x}_u=\sum_{i=1}^{n}u_ix_i$이고 $\overline{Y}_u=\sum_{i=1}^{n}u_iY_i$이다. 위와 같은 추정량 $\hat{\beta}_0$과 $\hat{\beta}_1$을 **가중 최소제곱 추정량**(weighted least square estimator)이라고 한다.

주 7.3절부터 7.5절에서 살펴본 추정과 검정의 방법들은 선형 회귀모형 (7.4)에 기반한 것이고, 모형 (7.4)는 오차에 몇 가지 가정을 포함한다. 정규성과 등분산성, 그리고 평균이 0이기에 조건부 기댓값 $E(Y|X=x)$가 x에 대한 선형함수라는 것이다. 회귀분석의 유효성을 위하여 사용한 자료가 이러한 가정들을 만족하는지 살펴볼 필요가 있으며, 이러한 과정을 회귀진단(regression diagnostics)이라고 한다. 회귀진단을 통해 가정에 맞지 않는 점이 발견되면 여러 가지 방법으로 가정에 맞도록 수정하거나, 다른 모형을 고려하게 된다. 앞서 살펴본 자료의 변환이나 가중 최소제곱법 등은 모형의 가정을 만족시키기 위한 몇 가지 처방이라고 할 수 있다.

회귀모형에 대한 분산분석

회귀모형에 대한 분산분석은 회귀선의 적합정도를 아는 데 도움을 줄 수 있다. 총변동은

$$\begin{aligned}\sum_{i=1}^{n}(Y_i-\overline{Y}_n)^2 &= \sum_{i=1}^{n}\{(Y_i-\hat{Y}_i)+(\hat{Y}_i-\overline{Y}_n)\}^2 \\ &= \sum_{i=1}^{n}(Y_i-\hat{Y}_i)^2+\sum_{i=1}^{n}(\hat{Y}_i-\overline{Y}_n)^2+2\sum_{i=1}^{n}(Y_i-\hat{Y}_i)(\hat{Y}_i-\overline{Y}_n) \\ &= \sum_{i=1}^{n}(Y_i-\hat{Y}_i)^2+\sum_{i=1}^{n}(\hat{Y}_i-\overline{Y}_n)^2 \qquad (7.21)\end{aligned}$$

로 분해된다. 세 번째 등식에는 $\overline{Y}_n=\frac{1}{n}\sum_{i=1}^{n}Y_i=\frac{1}{n}\sum_{i=1}^{n}\hat{Y}_i$임과 $\sum_{i=1}^{n}(Y_i-\hat{Y}_i)x_i$ $=\sum_{i=1}^{n}(x_i-\overline{x}_n)(Y_i-\overline{Y}_n)-\hat{\beta}_1\sum_{i=1}^{n}(x_i-\overline{x}_n)^2=0$임을 이용하였다. 이러한 분해는, 변수 Y의 총변동 $\sum_{i=1}^{n}(Y_i-\overline{Y}_n)^2$이 오차에 의한 변동인 $\sum_{i=1}^{n}(Y_i-\hat{Y}_i)^2=\sum_{i=1}^{n}(Y_i-\hat{\beta}_0-\hat{\beta}_1x_i)^2$과 회귀직선 자체에 의한 변동인 $\sum_{i=1}^{n}(\hat{Y}_i-\overline{Y}_n)^2=\hat{\beta}_1\sum_{i=1}^{n}(x_i-\overline{x}_n)^2$으로 구성된다는 것을 보여 준다. $\sum_{i=1}^{n}(\hat{Y}_i-\overline{Y}_n)^2$은 x의 변동과 $\hat{\beta}_1$으로 표현되므로 회귀직선에 의한 변동임을 알 수 있다. 특히 $\hat{\beta}_1=0$으로 회귀모형이 의미가 없으면 이 변동은 0이 된다. 이를 다음과 같이 표로 요약할 수 있다.

요인	제곱합	자유도	평균제곱합
회귀	$\sum_{i=1}^{n}(\hat{Y}_i-\overline{Y}_n)^2$	1	$\sum_{i=1}^{n}(\hat{Y}_i-\overline{Y}_n)^2$
오차	$\sum_{i=1}^{n}(Y_i-\hat{Y}_i)^2$	$n-2$	$\sum_{i=1}^{n}(Y_i-\hat{Y}_i)^2/(n-2)$
합	$\sum_{i=1}^{n}(Y_i-\overline{Y}_n)^2$	$n-1$	

이때 회귀제곱합의 전체제곱합에 대한 비

$$R^2=\frac{\sum_{i=1}^{n}(\hat{Y}_i-\overline{Y}_n)^2}{\sum_{i=1}^{n}(Y_i-\overline{Y}_n)^2} \tag{7.22}$$

을 **결정계수**(coefficient of determination)라고 하는데, 이는 전체 변동에 대한 회귀직선의 설명비율을 의미하며 회귀직선의 성능을 가늠하는 지표(index)가 되기도 한다. 즉, 결정계수 R^2의 값이 1에 가까울수록 회귀모형의 설명비율이 커진다. 만약 결정계수가 0.27이라면 $Y_1,\cdots,Y_n$에서 나타나는 변동의 27%가 회귀직선, 즉 X와의 선형관계에 의해 설명되고 나머지는 모형에 포함되지 않은 다른 요인들에 의해 설명된다는 뜻이다. R^2은 Y와 $\hat{Y}$의 표본 상관계수의 제곱이고, 단순선형 회귀모형의 경우 반응변수와 설명변수 간 표본 상관계수의 제곱과 같다. 단순선형 회귀모형에서 이 관계를 살펴보면,

$$\begin{aligned}\sum_{i=1}^{n}(Y_i-\hat{Y}_i)(\hat{Y}_i-\overline{Y}_n)&=\hat{\beta}_1\sum_{i=1}^{n}(Y_i-\hat{Y}_i)(x_i-\overline{x}_n)\\&=\hat{\beta}_1\sum_{i=1}^{n}(Y_i-\overline{Y}_n+\overline{Y}_n-\hat{Y}_i)(x_i-\overline{x}_n)\\&=\hat{\beta}_1\sum_{i=1}^{n}(Y_i-\overline{Y}_n)(x_i-\overline{x}_n)-\hat{\beta}_1^2\sum_{i=1}^{n}(x_i-\overline{x}_n)^2\\&=0\end{aligned}$$

이므로

$$\sum_{i=1}^{n}(\hat{Y}_i-\overline{Y}_n)^2=\sum_{i=1}^{n}(\hat{Y}_i-Y_i+Y_i-\overline{Y}_n)(\hat{Y}_i-\overline{Y}_n)=\sum_{i=1}^{n}(Y_i-\overline{Y}_n)(\hat{Y}_i-\overline{Y}_n)$$

이고,

$$R^2 = \frac{\sum_{i=1}^{n}(\hat{Y}_i - \overline{Y}_n)^2}{\sum_{i=1}^{n}(Y_i - \overline{Y}_n)^2}$$
$$= \frac{[\sum_{i=1}^{n}(\hat{Y}_i - \overline{Y}_n)^2]^2}{\sum_{i=1}^{n}(Y_i - \overline{Y}_n)^2 \sum_{i=1}^{n}(\hat{Y}_i - \overline{Y}_n)^2}$$
$$= \frac{[\sum_{i=1}^{n}(Y_i - \overline{Y}_n)(\hat{Y}_i - \overline{Y}_n)]^2}{\sum_{i=1}^{n}(Y_i - \overline{Y}_n)^2 \sum_{i=1}^{n}(\hat{Y}_i - \overline{Y}_n)^2}$$

이다. $\frac{1}{n}\sum_{i=1}^{n}\hat{Y}_i = \overline{Y}_n$의 성질을 이용하면 결정계수가 Y와 $\hat{Y}$의 표본 상관계수의 제곱임을 쉽게 알 수 있다. 또,

$$R^2 = \frac{\sum_{i=1}^{n}(\hat{Y}_i - \overline{Y}_n)^2}{\sum_{i=1}^{n}(Y_i - \overline{Y}_n)^2} = \frac{\hat{\beta}_1^2 \sum_{i=1}^{n}(x_i - \overline{x}_n)^2}{\sum_{i=1}^{n}(Y_i - \overline{Y}_n)^2}$$
$$= \frac{\left([\sum_{i=1}^{n}(x_i - \overline{x}_n)(Y_i - \overline{Y}_n)]^2 / [\sum_{i=1}^{n}(x_i - \overline{x}_n)^2]^2\right)\sum_{i=1}^{n}(x_i - \overline{x}_n)^2}{\sum_{i=1}^{n}(Y_i - \overline{Y}_n)^2}$$
$$= \frac{[\sum_{i=1}^{n}(x_i - \overline{x}_n)(Y_i - \overline{Y}_n)]^2}{\sum_{i=1}^{n}(x_i - \overline{x}_n)^2 \sum_{i=1}^{n}(Y_i - \overline{Y}_n)^2}$$

이므로 이는 X와 Y의 표본 상관계수의 제곱과 같다.

주 위의 표에서 회귀제곱합(Sum of Squares Regression, SSR)과 오차제곱합(Sum of Squares Error, SSE)을 해당하는 자유도 1과 $n-2$로 나누어 각각 MSR, MSE라고 하면 통계량 $F = MSR/MSE$는 회귀모수 β_1이 0이라는 가설, 즉, 회귀모형이 Y를 설명하는 데에 의미가 없다는 가설하에서 자유도가 $(1, n-2)$인 F 분포를 따른다. 이 F 통계량은 모형의 적합에 대한 검정통계량으로 사용될 수 있다. 가령, 관찰된 F의 값이 F분포의 임계값인 $F_\alpha(1, n-2)$보다 크면 가설이 기각되어 회귀모형이 Y를 설명하는 데에 도움이 된다

고 할 수 있다. 이러한 방법은 앞에서 다룬 가설 $H_0: \beta_1 = 0$ 대 $H_1: \beta_1 \neq 0$대한 t 검정법과 동일한 결과를 제공한다. 이는 t 분포와 F분포의 관계로부터 유래된다(3.2절 참조).

예 7.12

(예 7.8의 계속) 예 7.8의 몸무게와 혈압의 자료에 대한 선형 회귀모형의 분산분석은 다음 표와 같다.

요인	제곱합	자유도	평균제곱합	F값
회귀	2134.438	1	2134.438	99.94
오차	298.999	14	21.357	
합	2433.438	15		

전체제곱합과 회귀제곱합의 비인 결정계수는

$$R^2 = 2134.438/2433.438 = 0.877$$

로 회귀직선의 비교적 높은 설명력을 말해주고 있다. 또한, $F = 99.94 > F_{0.01}(1,14) = 8.862$이므로 유의수준 0.01에서 X와 Y 사이의 선형관계가 유의하다.

7.5 다중선형 회귀모형

앞서 고려한 선형모형은 설명변수가 하나인 경우였으나, 일반적으로 설명변수가 두 개 이상인 경우에도 그 이론이 자연스럽게 연장될 수 있다. 설명변수가 하나인 경우를 단순선형 회귀모형, 그리고 두 개 이상인 경우를 **다중선형 회귀모형**(multiple linear regression)이라고 한다. 이제 k개의 설명변수의 값 $x_1, x_2, \cdots, x_k$에 대한 회귀함수를

$$E(Y|x_1, x_2, \cdots, x_k) = \beta_0 + \beta_1 x_1 + \cdots \beta_k x_k \tag{7.23}$$

라 가정하고 $Var(Y|x_1, x_2, \cdots, x_k) = \sigma^2$이라고 했을 때 n개의 서로 독립인 관찰값 $\{(x_{i1}, x_{i2}, \cdots, x_{ik}, Y_i); i = 1, \cdots, n\}$에 대하여 다중선형 회귀모형을 고려해 보자. 다중선형 회귀모형은 행렬(matrix)을 활용하면 간편한 꼴로 표현된다.

행렬에 의한 표현

이제 식 (7.23)의 다중 회귀함수에 대해

$$\boldsymbol{Y} = \begin{bmatrix} Y_1 \\ \vdots \\ Y_n \end{bmatrix} \qquad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \vdots \\ \beta_k \end{bmatrix} \qquad \boldsymbol{X} = \begin{bmatrix} 1 & x_{11} & \cdots & x_{1k} \\ \cdots & \cdots & \cdots & \cdots \\ 1 & x_{n1} & \cdots & x_{nk} \end{bmatrix}$$

와 같은 행렬을 고려하자. 이때 회귀모형에 함축된 $E(Y_i) = \sum_{j=0}^{k} \beta_j x_{ij}$, $Var(Y_i) = \sigma^2$, 그리고 $i \neq j$에 대해 $Cov(Y_i, Y_j) = 0$이라는 사실은 (모든 i에서 $x_{i0} = 1$이라 하자) 행렬을 이용하여

$$E(\boldsymbol{Y}) = \boldsymbol{X}\boldsymbol{\beta}, \quad \boldsymbol{V} = \{Cov(Y_i, Y_j)\}_{1 \le i \le n, 1 \le j \le n} = \sigma^2 \boldsymbol{I} \tag{7.24}$$

와 같이 간단하게 표현된다(단, I는 $n \times n$ 단위행렬). 이제, 오차제곱합은

$$\begin{aligned} &SSE(\beta_0, \beta_1, \beta_2, \cdots, \beta_k) \\ &\qquad = \sum_{i=1}^{n} (Y_i - \beta_0 - \beta_1 x_{i1} - \cdots - \beta_k x_{ik})^2 \\ &\qquad = (\boldsymbol{Y} - \boldsymbol{X}\boldsymbol{\beta})'(\boldsymbol{Y} - \boldsymbol{X}\boldsymbol{\beta}) \end{aligned} \tag{7.25}$$

로 표현되며, 행렬의 미분을 이용하면 최소제곱 추정량은 정규방정식

$$(\boldsymbol{Y} - \boldsymbol{X}\boldsymbol{\beta})'\boldsymbol{X} = 0$$

의 해로

$$\hat{\boldsymbol{\beta}} = (\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'\boldsymbol{Y} \tag{7.26}$$

와 같이 주어진다. $\boldsymbol{Y}'$는 $\boldsymbol{Y}$의 전치행렬(transpose matrix)을 의미한다. 랜덤오차 ϵ이 $N(0, \sigma^2)$ 분포를 따르는 경우 회귀모수에 대한 최소제곱 추정량은 $\hat{\boldsymbol{\beta}} \sim N(\boldsymbol{\beta}, (\boldsymbol{X}'\boldsymbol{X})^{-1}\sigma^2)$를 따르게 된다. 나아가, 이 최소제곱 추정량 $\hat{\boldsymbol{\beta}}$은 다음의 가우스-마코프 정리에 설명되는 바와 같이 선형추정량 가운데 최적 비편향의 성질을 갖는다. 다음의 정리는 증명 없이 받아들이기로 한다. 여기에서 선형추정량이란 Y_i들의 선형결합으로 표현되는 추정량을 의미하고, 최적이란 임의의 상수 $r_0, \cdots, r_k$로 $\sum_{i=0}^{k} r_i\beta_i$의 추정을 고려했을 때 임의의 선형 비편향추정량 $\tilde{\boldsymbol{\beta}}$에 대하여 $\sum_{i=0}^{k} r_i\hat{\beta}_i$의 분산이 항상 $\sum_{i=0}^{k} r_i\tilde{\beta}_i$의 분산보다 작거나 같다는 것을 의미한다. 즉, $\sum_{i=0}^{k} r_i\hat{\beta}_i$이 $\sum_{i=0}^{k} r_i\beta_i$의 최소분산 선형 비

편향추정량이 된다는 것이다. 이때 V를 분산-공분산행렬이라 하면, $V(\tilde{\beta}) - V(\hat{\beta})$가 양정치행렬이 된다.

정리 7.9

(가우스-마코프 정리)

선형모형 $E(\boldsymbol{Y}|\boldsymbol{X}) = \boldsymbol{X}\beta$, $\boldsymbol{V} = \{Cov(Y_i, Y_j)\} = \sigma^2 \boldsymbol{I}$가 성립하면, 임의의 상수벡터 $\boldsymbol{r}$에 대하여 $\boldsymbol{r}'\hat{\beta}$이 $\boldsymbol{r}'\beta$의 최적 비편향 선형추정량이다. 즉, 회귀계수 β_i의 선형결합에 대한 최적 비편향 선형추정량은 β_i를 그의 최소제곱 추정량으로 대체함으로써 구할 수 있다.

예 7.13

아래의 자료

x_1	1	2	3	4	5	6	7
x_2	0	0	1	1	2	2	2
Y	10.3	9.5	8.0	11.0	14.0	13.5	15.2

에 대해 회귀모형

$$E(Y|x_1, x_2) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 \tag{7.27}$$

를 고려할 때 회귀모수의 최소제곱 추정량을 구하는 과정을 행렬을 이용하여 살펴보기로 하자.

우선,

$$\boldsymbol{X}' = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 & 6 & 7 \\ 0 & 0 & 1 & 1 & 2 & 2 & 2 \end{bmatrix}$$

이므로

$$\boldsymbol{X}'\boldsymbol{X} = \begin{bmatrix} 7 & 28 & 8 \\ 28 & 140 & 43 \\ 8 & 43 & 14 \end{bmatrix}$$

이고

$$(\boldsymbol{X}'\boldsymbol{X})^{-1}=\begin{bmatrix} 37/35 & -16/35 & 4/5 \\ -16/35 & 34/105 & -11/15 \\ 4/5 & -11/15 & 28/15 \end{bmatrix},\ \boldsymbol{X}'\boldsymbol{Y}=\begin{bmatrix} 81.5 \\ 354.7 \\ 104.4 \end{bmatrix}$$

의 계산을 통하여 회귀모수벡터는

$$\hat{\boldsymbol{\beta}}=\begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \hat{\beta}_2 \end{bmatrix}=(\boldsymbol{X}'\boldsymbol{X})^{-1}\boldsymbol{X}'\boldsymbol{Y}=\begin{bmatrix} 7.529 \\ 1.038 \\ -0.033 \end{bmatrix}$$

으로 구해진다.

분산분석표

이제, 최소제곱 추정량 $\hat{\boldsymbol{\beta}}$을 사용하여 예측값

$$\hat{\boldsymbol{Y}}=\boldsymbol{X}\hat{\boldsymbol{\beta}}=\begin{bmatrix} \hat{\beta}_0+\hat{\beta}_1 x_{11}+\cdots+\hat{\beta}_k x_{1k} \\ \vdots \\ \hat{\beta}_0+\hat{\beta}_1 x_{n1}+\cdots+\hat{\beta}_k x_{nk} \end{bmatrix}$$

를 구하고,

$$SSE=\sum_{i=1}^{n}(Y_i-\hat{Y}_i)^2$$

$$SSR=\sum_{i=1}^{n}(\hat{Y}_i-\overline{Y}_n)^2$$

$$SST=\sum_{i=1}^{n}(Y_i-\overline{Y}_n)^2$$

라고 하면, 분산분석표를 다음과 같이 작성하여 다중 회귀직선의 적합도를 살펴볼 수 있다.

요인	제곱합	자유도	평균제곱합
회귀	SSR	k	$MSR=SSR/k$
오차	SSE	$n-k-1$	$MSE=SSE/(n-k-1)$
합	SST	$n-1$	

나아가 모형의 적합도(goodness of fit)를 재는 척도로, 전체제곱합과 회귀제곱합의 비인 결정계수

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$$

를 고려할 수 있다. 단순회귀모형에서처럼 결정계수는 Y와 $\hat{Y}$의 표본 상관계수의 제곱임을 보일 수 있고, 이에 대한 통계적 의미는 단순회귀모형에서와 같다.

● 모형에 대한 가설검정

여기에서는 다중선형모형에서 회귀모수 β_j 에 대한 일반적인 검정방법을 설명하기로 한다. 우선 식 (7.23)과 같은 원래의 다중선형 회귀모형을 완전모형(FM: Full Model)이라고 하고, 귀무가설에 가정된 내용을 완전모형에 대입해서 얻은 모형을 축소모형(RM: Reduced Model)이라고 하자. 물론 축소모형에서 추정해야 되는 회귀모수들의 개수는 완전모형에서의 그것보다 적을 것이다. 예를 들어, 다섯 개의 설명변수가 있는 다중 선형모형에서 첫 번째와 두 번째 설명변수가 의미 없다고 의심되는 경우, $H_0: \beta_1 = \beta_2 = 0$ 대 H_1 : 둘 중 적어도 하나는 0이 아님의 가설을 검정할 수 있다. 이때 완전모형은 $E(Y|x_1, \cdots, x_5) = \beta_0 + \beta_1 x_1 + \cdots + \beta_5 x_5$가 되고 축소모형은 $E(Y|x_3, x_4, x_5) = \beta_0 + \beta_3 x_3 + \beta_4 x_4 + \beta_5 x_5$가 된다. 이때 검정방법은 완전모형을 사용했을 때의 적합도와 축소모형에서의 적합도를 비교하는 것에 근간을 둔다. 즉, 완전모형이 더 많은 모수를 사용하므로 적합도가 더 높겠지만, 축소모형에서의 적합도가 완전모형에 비해 상대적으로 많이 떨어지지 않는 경우에는 축소모형을 가정하는 귀무가설을 기각할 수 없게 된다. 이에 대한 구체적인 처리과정은 다음과 같다.

$\hat{Y}_i$과 $\hat{Y}_i^*$ 를 각각 완전모형과 축소모형에서의 Y_i 에 대한 예측값이라고 하자. 그러면 완전모형하에서의 오차제곱합은

$$SSE(FM) = \sum_{i=1}^{n} (Y_i - \hat{Y}_i)^2 \tag{7.28}$$

이며, 축소모형에서의 오차제곱합은

$$SSE(RM) = \sum_{i=1}^{n} (Y_i - \hat{Y}_i^*)^2 \tag{7.29}$$

으로 쓸 수 있다. 완전모형에는 $(p+1)$ 개의 회귀계수 $(\beta_0, \beta_1, \beta_2, \cdots, \beta_p)$가 있는 반면,

축소모형에는 $k+1(<p+1)$개의 회귀계수가 있다고 하자. 이때 축소모형이 적절한 지의(즉, 축소모형이 참모형이라는 귀무가설이 지지되는지의) 여부는 $[SSE(RM)-SSE(FM)]$과 $SSE(FM)$의 비교를 통해 이루어진다. $SSE(RM)$과 $SSE(FM)$의 차이가 $SSE(FM)$에 비해 상대적으로 크다면 축소모형이 적합하다고 볼 수 없고, 그러기에 귀무가설은 기각될 것이다. 보다 자세하게는, 이 두 변량이 가지는 분포관계를 감안하여 이들을 각각에 대응되는 자유도로 나눈 다음($SSE(RM)-SSE(FM)$의 자유도는 $SSE(RM)$의 자유도에서 $SSE(FM)$의 자유도를 뺀 것, 즉 완전모형과 축소모형의 설명변수 개수의 차이와 같다.) 통계량

$$\frac{SSE(RM)-SSE(FM)}{p-k} \text{와} \quad \frac{SSE(FM)}{n-p-1}$$

의 비인 검정통계량

$$F=\frac{[SSE(RM)-SSE(FM)]/(p-k)}{SSE(FM)/(n-p-1)} \tag{7.30}$$

은 검정하고자 하는 귀무가설이 참일 때 자유도가 $(p-k, n-p-1)$ 인 F분포를 따른다는 사실을 이용하게 된다. 따라서 관측된 F값이 $F>F_{\alpha}(p-k, n-p-1)$이면 유의수준 α에서 해당하는 귀무가설을 기각한다. 이러한 모형의 적합도에 관한 가설검정은 변수선택을 위한 일련의 과정에도 사용된다.

변수선택 방법

주어진 자료에 근거하여 모형을 구축함에 있어, 일반적으로 모형의 간결성 및 효율성 등을 보장하기 위하여 필요한 변수들만 선택하여 사용하는 것이 매우 바람직하다. 이제 다중선형회귀모형에서 반응변수 Y에 영향을 미칠 것으로 예상되는 p개의 설명변수 $x_1, x_2, \cdots, x_p$들 중에서 k개의 설명변수를 선택하는 방법을 살펴보자.

앞서 설명한 완전모형과 축소모형에 대한 가설검정 과정의 한 형태로서 변수선택을 다룰 수 있다. 설명변수들 중에 $j-1$개와 j개의 설명변수를 사용하였을 때의 분산분석의 결과는, 편의상 첨자를 사용하여 제곱합을 표기하면,

$$SST_{j-1}=SSR_{j-1}+SSE_{j-1}$$
$$SST_j=SSR_j+SSE_j$$

가 성립하며 전체제곱합 SST는 사용한 설명변수의 개수와 상관없이 동일하기에

$SST_{j-1} = SST_j$를 만족하므로

$$SSE_{j-1} - SSE_j = SSR_j - SSR_{j-1} \tag{7.31}$$

이 된다. 식 (7.31)의 좌변 $SSE_{j-1} - SSE_j$은 j개에서 하나의 설명변수를 제거하여 $j-1$개 설명변수를 사용했을 때 오차제곱합의 증가분을, 그리고 우변 $SSR_j - SSR_{j-1}$은 $j-1$개 설명변수에 하나의 설명변수를 추가하여 j개의 설명변수를 사용했을 때의 회귀제곱합의 증가분을 의미한다. 따라서, 충분히 큰

$$SSE_{j-1} - SSE_j = SSR_j - SSR_{j-1}$$

는 $j-1$개 설명변수에 하나의 설명변수를 추가하여 j개의 설명변수를 사용하기로 결정하는 근거가 되며, 이러한 결과의 통계적 유의성 여부는 검정통계량

$$F = \frac{SSR_j - SSR_{j-1}}{MSE_j} \sim F(1, n-j-1)$$

을 바탕으로 구할 수 있다. 즉, 관측된 F값이 $F > F_\alpha(1, n-j-1)$이면 $j-1$개 설명변수에 하나의 설명변수를 추가할 필요가 없다는 가설을 유의수준 α에서 기각한다[4]. 이러한 방법을 사용하여 실제 변수를 선택하는 데에는 다음과 같은 방법들이 있다.

- **전진적 도입**(forward selection): 설명변수들 중 가장 유의한 것으로 판단되는 변수부터 하나씩 선택해 가면서 더 이상 유의한 변수가 없을 때 변수선택을 중단한다.
- **후진적 제거**(backward elimination): 설명변수들 중에서 가장 유의하지 않은 변수를 하나씩 제거하면서 더 이상 유의하지 않은 변수가 없을 때 변수제거를 중단하는 방법이다.
- **단계적 선택**(stepwise): 전진적 도입에 후진적 제거 방법을 가미한 것으로서, 전진적 도입을 통해 변수를 선택한 후, 다음 변수가 선택되었을 때 후진적 제거를 적용한다. 즉 새로운 변수가 추가되면서 이미 선택된 변수가 유의성을 상실하여 제거될 수 있는지를 단계별로 검토한다.

4) 실제 통계 패키지를 통해 모형을 선택할 때는 F검정 대신 AIC(Akaike information criterion)나 BIC(Bayesian information criterion) 등이 사용되기도 한다.

연습문제 7장

01 X와 Y가 다음과 같은 결합 확률밀도함수를 가질 때, X와 Y의 공분산을 구하라. 또한 X와 Y의 상관계수 $\rho(X, Y)$를 구하라.

$$f_{X,Y}(x,y)=\begin{cases}8xy, & 0 \le x \le y \le 1\\ 0, & \text{그 외의 경우}\end{cases}$$

02 X와 Y가 다음과 같은 결합 확률밀도함수를 따르는 이산형 확률변수라 했을 때, X와 Y의 상관계수를 구하라.

(x,y)	$f_{X,Y}(x,y)$
(1, 2)	1/2
(1, 3)	1/4
(2, 1)	1/8
(2, 4)	1/8

03 아래의 (x,y)의 자료에 대하여,

x	0	0	0	1	1	1	2	2	2
y	0	1	2	0	1	2	0	1	2

(1) 표본상관계수를 계산하라.

(2) 회귀직선 $E(Y|x)=\beta_0+\beta_1 x$를 추정하라.

(3) (2)에서 구한 회귀직선의 타당성을 상관계수를 사용하여 설명하라.

(4) 정리 7.2를 이용하여 상관계수 $\rho(X, Y)$가 0인지 아닌지를 유의수준 0.05에서 검정하라.

04 정리 7.7의 증명을 참조하여 정리 7.2의 증명 가운데 나오는 $\dfrac{(n-1)S_Y^2(1-R^2)}{\sigma_Y^2}$이 RS_Y/S_X와 서로 독립이며 자유도가 $(n-2)$인 카이제곱분포를 따름을 증명하라.

05 X와 Y가 삼항분포를 따를 때, 즉, 음이 아닌 정수 $x, y, n-x-y$와 양수 p_X, $p_Y, 1-p_X-p_Y$에 대해 (X, Y)의 결합 확률밀도함수가

$$f_{X,Y}(x, y) = \frac{n!}{x!\,y!(n-x-y)!} p_X^x p_Y^y (1-p_X-p_Y)^{n-x-y}$$

일 때 X에 대한 Y의 회귀직선을 구하라.

06 X와 Y가 다음과 같은 결합 확률밀도함수를 가질 때,

$$f_{X,Y}(x, y) = \begin{cases} 2, & 0 < x < y, \quad 0 < y < 1 \\ 0, & \text{그 외의 경우} \end{cases}$$

$E(Y \mid x)$를 구하라.

07 X와 Y가 $\mu_X = 3$, $\mu_Y = 5$, $\sigma_X^2 = 5$, $\sigma_Y^2 = 9$, $\rho = 3/4$인 이변량 정규분포를 따를 때,

(1) $\mathrm{P}(4 < Y < 6)$을 구하라.

(2) $\mathrm{P}(4 < Y < 6 \mid X = 4)$를 구하라.

08 다음과 같은 (x, y)의 자료에 대하여,

x	42	39	36	40	41	34	37	39	40	37
y	39	29	31	43	42	30	35	34	35	38

식 (7.4)에 있는 선형 회귀모형을 고려할 때,

(1) 모수 β_0, β_1, σ^2의 최대가능도 추정량을 각각 구하라.

(2) $\beta_0 + 35\beta_1$의 최소분산 비편향추정량을 구하라.

(3) 모수 β_0, β_1, σ^2의 90% 신뢰구간을 각각 구하라.

(4) $\beta_1 + \sigma^2$의 최대가능도 추정량을 구하라.

09 다음의 자료는 8개국의 저축률(x)과 투자이익부담률(y)에 관한 자료이다. 식 (7.4)에 있는 선형 회귀모형을 고려할 때 가설 $H_0: \beta_1 = -1$ 대 $H_1: \beta_1 \neq -1$을 유의수준 5%에서 검정하라.

국 가	저축률	이익부담률
이탈리아	23.1	6.4
일 본	21.5	14.4
프 랑 스	17.2	7.3
서 독	14.5	11.8
영 국	12.2	32.5
캐 나 다	10.3	30.0
스 웨 덴	9.1	52.7
미 국	6.3	33.5

10 서로 독립인 확률변수 $Y_i\ (i = 1, 2, \cdots, n)$가 각각 $N(\beta_0 + \beta_1 x_i, \sigma^2)$ 분포를 따른다고 하자. 이때 β_0에 대한 $100(1-\alpha)\%$ 신뢰구간을 구하라.

11 다음은 어떤 교육 프로그램에서 14명의 교육대상을 무작위 추출하여 얻은 중간 성적과 마지막 성적에 관한 자료이다. 중간 성적과 마지막 성적 사이의 상관계수를 구하고, 가설 $H_0: \rho = 0$ 대 $H_1: \rho > 0$에 대한 검정을 유의수준 5%에서 시행하라. 중간 성적과 마지막 성적은 이변량 정규분포를 따른다고 가정한다.

개체	중간 성적	마지막 성적
1	142	280
2	146	283
3	141	287
4	140	288
5	141	288
6	143	289
7	149	289
8	146	290
9	144	290
10	149	290
11	144	292
12	147	293
13	145	293
14	149	293

12 음주가 신체적 반응에 미치는 영향을 조사하기 위하여 음주량(x)과 반응시간(y)을 10명을 대상으로 측정한 결과가 다음과 같다.

대상	1	2	3	4	5	6	7	8	9	10
음주량	2	2	2	3	3	4	4	4	5	5
반응시간	3	4	4	4	5	6	6	7	6	8

(1) 음주량과 반응시간 사이의 상관계수를 구하라.

(2) 식 (7.4)의 회귀모형을 이용하여, 음주량이 많아짐에 따라 반응속도가 늘어난다는 가설에 대한 검정을 5% 유의수준에서 시행하라.

(3) 선형 회귀모형에 대한 분산분석을 시행하고 결정계수의 값을 구하라.

13 다음은 부동산 판매광고의 길이(y=사용단어의 수)와 부동산매출가격(x)에 대한 자료이다. 식 (7.4)에 있는 선형 회귀모형을 고려할 때,

(1) $E(Y \mid x = 100)$을 구하고, 그에 대한 90% 신뢰구간을 구하라.

(2) $x = 100$일 때 Y값에 대한 90% 예측구간을 구하고, 그 결과를 (1)과 비교하라.

매출가격(x)	광고의 길이(y)
50	24
65	29
120	42
30	20
48	30
76	36
84	40
140	54
58	32
63	25

14 $H_0 : \beta_1 = 0$ 대 $H_1 : \beta_1 \neq 0$에 대한 식 (7.11)의 검정이 정리 7.2를 이용한 X와 Y의 상관계수에 대한 $H_0 : \rho = 0$의 검정과 동치임을 보여라.

15 식 (7.19)의 변환된 회귀모형으로부터 식 (7.20)에 주어진 회귀모수의 가중 최소제곱 추정량을 유도하라.

16 식 (7.21)의 계산을 확인하라.

17 다음의 자료는 1960년도 20개 OECD 회원국의 농업취업률(X)과 개인소득(Y) 자료에 대하여 3가지 회귀모형을 고려한 결과이다. 3가지 회귀모형에는 각각 Linear, SQRT, Expon이라는 이름이 붙어 있는데, Linear는 $E(Y|x)=\beta_0+\beta_1 x$, SQRT은 $E(Y|x)=\beta_0+\beta_1\sqrt{x}$, Expon은 $E(Y|x)=\beta_0\cdot\beta_1^x$의 회귀함수를 사용하였고, Linear, SQRT, Expon 열의 값들은 주어진 X값에 대한 Y의 예측값들이다. 분석의 결과에 대하여 세 가지 회귀모형을 비교 검토하라.

국 가	Y	X	Linear	SQRT	Expon
캐 나 다	1536	13	1073	1078	1048
스 웨 덴	1644	14	1054	1050	1016
스 위 스	1361	11	1110	1138	1117
룩셈부르크	1242	15	1035	1023	984
영 국	1105	4	1242	1410	1396
덴 마 크	1059	18	978	946	894
서 독	1035	15	1035	1023	984
프 랑 스	1013	20	941	899	839
벨 기 에	1005	6	1205	1317	1310
노 르 웨 이	977	20	941	899	839
아이슬랜드	839	25	846	790	716
네 덜 란 드	810	11	1110	1138	1117
오스트리아	681	23	884	832	763
아 일 랜 드	529	36	639	583	505
이 탈 리 아	504	27	809	749	672
일 본	344	33	696	636	555
그 리 스	324	56	262	276	267
스 페 인	290	42	526	483	417
포 르 투 갈	238	44	488	452	391
터 키	177	79	−172	−15	129
$\hat{\beta}_0$			1317.9	1823.6	1584.7
$\hat{\beta}_1$			−18.8576	−206.816	0.96872
결정계수(R^2)			0.6315	0.6477	0.6579

18 다음의 등식을 증명하라. 둘째 줄의 식은 특히 계산상의 목적에 유용하다.

$$n\hat{\sigma}^2=\sum_{i=1}^{n}(Y_i-\overline{Y}_n)^2-\hat{\beta}_1\sum_{i=1}^{n}(x-\overline{x}_n)(Y_i-\overline{Y}_n)$$

$$=\sum_{i=1}^{n}Y_i^2-\frac{\left(\sum_{i=1}^{n}Y_i\right)^2}{n}-\hat{\beta}_1\left[\sum_{i=1}^{n}x_iY_i-\frac{\left(\sum_{i=1}^{n}x_i\right)\left(\sum_{i=1}^{n}Y_i\right)}{n}\right]$$

$$=\sum_{i=1}^{n}Y_i^2-\hat{\beta}_0\sum_{i=1}^{n}Y_i-\hat{\beta}_1\sum_{i=1}^{n}x_iY_i$$

19 식 (7.4)의 선형모형에서 회귀모수를 추정하고자 한다. 10개의 x값이 $[-1, 1]$ 사이에서 선택된다고 할 때, $Var(\hat{\beta}_1)$를 최소화하기 위해서 어떤 방법으로 x가 뽑혀야 하는가?

20 서로 독립인 확률변수 $Y_i (i = 1, 2, \cdots, n)$가 각각 $N(\beta_0 + \beta_1 x_i, \sigma^2)$ 분포를 따르며 또 다른 서로 독립인 확률변수 $V_i (i = 1, 2, \cdots, m)$가 각각 $N(\gamma_0 + \gamma_1 u_i, \sigma^2)$ 분포를 따른다고 하자. 이때 $H_0 : \beta_1 = \gamma_1$ 대 $H_1 : \beta_1 \neq \gamma_1$에 대한 검정법을 제시하라.

21 서로 독립인 확률변수 $Y_i (i = 1, 2, \cdots, n)$가 각각 $N(\beta_0 + \beta_1 x_i, \sigma^2)$ 분포를 따를 때, $S_1 = \sum_{i=1}^{n} Y_i$, $S_2 = \sum_{i=1}^{n} Y_i^2$, $S_3 = \sum_{i=1}^{n} x_i Y_i$가 $(\beta_0, \beta_1, \sigma^2)$에 대한 결합 충분통계량임을 보여라.

22 두 변수 x와 y에 대한 관계가 $y = x/(a + bx)$라는 함수로 주어졌다고 하자. 이때 두 변수 사이의 선형변환을 유도하라.

23 자료 (x_i, y_i) $(i = 1, 2, \cdots, n)$이 주어졌을 때,

$$E(Y \mid x) = \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3$$

으로 표현된 '일반 선형모형'에 대하여 행렬을 활용하여 모수 β_0, β_1, β_2, β_3의 최소제곱 추정량을 구하라.

24 관측된 $n = 20$개의 자료, $\{(x_i, y_i); i = 1, \cdots, n\}$에서 얻은 요약통계량의 값이 $\sum_{i=1}^{n} x_i = 320$, $\sum_{i=1}^{n} y_i = 640$, $\sum_{i=1}^{n} x_i^2 = 6600$, $\sum_{i=1}^{n} y_i^2 = 26200$, $\sum_{i=1}^{n} x_i y_i = 13100$으로 주어졌다고 하자.

(1) $E(Y|x) = \beta_0 + \beta_1 x$의 선형모형을 고려할 때 β_0와 β_1의 최소제곱 추정량을 구하라.

(2) 결정계수의 값은 얼마인가? 그 의미는 무엇인가?

(3) σ^2의 비편향추정량 $\tilde{\sigma}^2$의 값을 구하라.

25 설명변수가 세 개인 다중선형 회귀함수 $E(Y|x_1, x_2, x_3) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3$을 생각해 보자. 이때 귀무가설 H_0: $\beta_2 = \beta_3 = 0$을 검정하는 방법을 제시하라.

26 다음 내용은 'Quick-R by DataCamp'로부터의 사례이다. 주어진 자료는 반응변수로 Y=주가지수 그리고 설명변수로는 X_1 =이자율과 X_2 =실업률을 고려하였다.

(1) 다중회귀 모형을 구축하라.

(2) $X_1 = 0.5$, $X_2 = 5.8$로 주어졌을 때, Y=주가지수를 예측하라.

연도	월	이자율	실업률	주가지수
2017	12	2.75	5.3	1464
2017	11	2.5	5.3	1394
2017	10	2.5	5.3	1357
2017	9	2.5	5.3	1293
2017	8	2.5	5.4	1256
2017	7	2.5	5.6	1254
2017	6	2.5	5.5	1234
2017	5	2.25	5.5	1195
2017	4	2.25	5.5	1159
2017	3	2.25	5.6	1167
2017	2	2	5.7	1130
2017	1	2	5.9	1075
2016	12	2	6	1047
2016	11	1.75	5.9	965
2016	10	1.75	5.8	943
2016	9	1.75	6.1	958
2016	8	1.75	6.2	971
2016	7	1.75	6.1	949
2016	6	1.75	6.1	884
2016	5	1.75	6.1	866
2016	4	1.75	5.9	876
2016	3	1.75	6.2	822
2016	2	1.75	6.2	704
2016	1	1.75	6.1	719