9장 범주형 자료의 분석

- 9.1 적합도 검정
- 9.2 분할표에 의한 독립성 검정
- 9.3 다항분포의 동질성 검정

1장에서 살펴본 바와 같이 어떤 현상의 관찰결과를 얻기 위한 실험에서 얻어지는 모든 관찰 가능한 결과의 집합을 표본공간이라고 하고, 이 표본공간은 수치적으로 또는 비수치적으로 표현될 수 있다. 즉, 어떤 실험에서 얻어지는 자료는 수치로서의 양적 개념을 가질 수도 있지만 때로는 실험결과가 몇 가지 범주 가운데 어떤 범주에 속하는지를 표현하여 양적 개념을 가지지 않을 수도 있다. 자료가 사칙연산이 가능하도록 수치적으로 표현되는 경우 양적(quantitative) 자료라고 하고, 몇 가지 범주 가운데 어느 범주에 속하는지를 표현하는 경우 범주형(categorical) 자료라고 한다. 자료의 종류에 따라 요약하는 방법이나 분석하는 방법이 달라지는데, 범주형 자료는 주로 각각의 범주에 속하는 관측치의 개수를 표나 그림을 통해 나타내는 방법으로 요약하게 된다. 양적 자료는 크게 연속형과 이산형으로 나뉘고, 범주형 자료는 범주 간에 순서가 있는 순서형과 순서가 없는 명목형 자료로 나뉜다. 6장의 분산분석이나 7장의 회귀분석 등은 양적 자료에 대한 분석이었고, 이제 이 장에서는 자료가 범주형으로 주어졌을 때의 분석방법에 대해 카이제곱검정을 중심으로 다루도록 한다. 우선, 카이제곱검정으로 할 수 있는 분포의 적합도 검정에 대해 다루고, 다음에는 범주형 자료가 분할표로 주어졌을 때의 검정에 대해 다루어 보도록 하겠다.

9.1 적합도 검정

지금까지 다루어 온 통계적 추론방법은 주로 모분포의 확률밀도함수 $f(x;\theta)$의 형태가 알려진 경우이다. 더욱이 앞서 다룬 통계방법들(예를 들면, 최대가능도 추정량 또는 최강력검정법 등)의 대부분은 정규분포, 이항분포 등의 특정한 확률모형하에서 유도된 것들이다. 그런데 이러한 특정한 확률모형의 가정이 맞지 않다면 그것을 근거로 개발된 추론방법이 정확하지 않을 것이고 그에 따라 추론의 결과를 신뢰할 수 없을 것이므로, 주어진 표본자료가 어떤 특정모형(예를 들면 정규분포)에 얼마나 잘 부합하는가를 검정하여 보는 것은 중요하고도 의미있는 일이라고 하겠다. 이와 같은 검정방법을 **적합도 검정**(goodness-of-fit test)이라고 한다.

적합도 검정에서 우선 생각할 수 있는 가장 간단한 경우는 표본자료 $X_1, X_2, \cdots, X_n$이 완전히 결정지어진 어떤 확률모형으로부터 왔는지 아닌지를 검정하는 경우이다. 예를 들면, 자료 X_i들이 평균이 6인 포아송 분포로부터 얻어졌다든지, 또는 평균이 100이고 분산이 25인 정규분포로부터 얻어졌다든지 하는 등이다. 이 경우 검정대상이 되

는 가설은

$$H_0 : f_X(x) = f_0(x) \quad \text{대} \quad H_1 : f_X(x) \neq f_0(x) \tag{9.1}$$

로 표현된다(단, $f_X(x)$와 $f_0(x)$는 각각 모확률밀도함수와 가정된 확률밀도함수를 각각 의미한다). 이는 앞서 8장에서 다룬 비모수 통계방법의 콜모고로프-스미르노프 검정법의 가설과 동일하다. 콜모고로프-스미르노프 검정에서는 연속형 누적 확률분포함수와 경험적 누적 확률분포함수의 차이의 최댓값을 검정통계량으로 하여 적합도를 검정하였다. 그러나 많은 경우, 변수가 가질 수 있는 값의 영역을 k개의 겹치지 않는 구간으로 나누어 그에 대한 확률을 고려하는 다항분포로써 적합도를 검정하는 것이 편리하다. 즉, 연속형 확률변수 X에 대해서는 $(-\infty, a_1)$, $[a_1, a_2)$, $\cdots$, $[a_{k-1}, \infty)$의 k개 구간을 고려하는데, $a_0 = -\infty$, $a_k = \infty$, 그리고 $p_i = \int_{a_{i-1}}^{a_i} f_X(x)\,dx$, $i = 1, 2, \cdots, k$(또는 이산형 확률변수에 대해서는 $p_i = P\{X \in [a_{i-1}, a_i)\}$)라고 놓으면, 위의 가설 (9.1)을 검정하기 위해

$$H_0 : p_1 = p_{10}, \cdots, p_k = p_{k0} \quad \text{대} \quad H_1 : H_0\text{가 아님} \tag{9.2}$$

을 사용할 수 있다.

2장에서 소개한 이항확률변수는 '성공' 또는 '실패' 중의 하나로 귀결되는 독립된 베르누이 시행을 반복했을 때 성공이 나오는 횟수로 표현되었다. 이와 같은 이항확률변수는 다음과 같이 k개의 다른 결과를 가질 수 있는 경우로 일반화될 수 있다(2.5.2절 참조). 이제, $a_1, a_2, \cdots, a_k$의 $k(>2)$가지 다른 값을 가질 수 있는 변수 Y에 대해 $P(Y = a_j) = p_j$, $j = 1, \cdots, k$, $\sum_{j=1}^{k} p_j = 1$이라고 하자. 이러한 시행을 n회 독립적으로 반복하여 $Y_1, Y_2, \cdots, Y_n$을 얻었을 때

$$X_j = \text{확률변수 } Y\text{의 값이 } a_j\text{인 경우의 수 } (j = 1, \cdots, k)$$

라고 하면, 확률벡터 $(X_1, X_2, \cdots, X_k)$의 결합 확률밀도함수는

$$f(x_1, x_2, \cdots, x_k) = \frac{n!}{x_1!\, x_2! \cdots x_k!} p_1^{x_1} p_2^{x_2} \cdots p_k^{x_k}$$

$$(\text{단, } x_j = 0, 1, \cdots, n;\ j = 1, \cdots, k;\ \sum_{j=1}^{k} x_i = n)$$

으로 주어지며, 이때 $(X_1, X_2, \cdots, X_k)$는 모수가 $n, p_1, p_2, \cdots, p_k$인 다항분포

(multinomial distribution)를 따른다고 한다. 이때 편의상 $(X_1, X_2, \cdots, X_k) \sim$ MULT$(n; p_1, p_2, \cdots, p_k)$로 표기하도록 하자. 이제, 다음의 정리 9.1을 통해 다항분포에 근거한 적합도 검정을 볼 수 있다.

정리 9.1

확률벡터 $(X_1, X_2, \cdots, X_k)$가 모수가 $(n, p_1, p_2, \cdots, p_k)$인 다항분포를 따른다고 하자. 그러면,

(1) 확률변량

$$\sum_{i=1}^{k} \frac{(X_i - np_i)^2}{np_i}$$

는 자유도가 $(k-1)$인 카이제곱분포를 근사적으로 따른다.

(2) 귀무가설 $H_0 : p_1 = p_{10}, \cdots, p_k = p_{k0}$ 대 대립가설 $H_1 : H_0$이 아님에 대한 유의수준 α인 근사 기각영역은

$$\sum_{i=1}^{k} \frac{(X_i - np_{i0})^2}{np_{i0}} \geq \chi_{\alpha}^2(k-1)$$

로 주어진다.

증명 (1) 여기에서는 $k=2$인 경우만 증명하기로 한다. k가 더 큰 경우의 증명은 복잡하므로 생략한다. $k=2$이면,

$$\begin{aligned}
&\frac{(X_1 - np_1)^2}{np_1} + \frac{(X_2 - np_2)^2}{np_2} \\
&= \frac{(X_1 - np_1)^2}{np_1} + \frac{(n - X_1 - n(1-p_1))^2}{n(1-p_1)} \\
&= \frac{(X_1 - np_1)^2(1-p_1) + (-X_1 + np_1)^2 p_1}{np_1(1-p_1)} \\
&= \frac{(X_1 - np_1)^2}{np_1(1-p_1)}
\end{aligned}$$

이 성립하며, $(X_1 - np_1) / \sqrt{np_1(1-p_1)}$의 분포는 중심극한정리에 의해

표본의 크기가 커짐에 따라 표준정규분포로 수렴한다. 따라서 확률변량 $\sum_{i=1}^{2}\frac{(X_i-np_i)^2}{np_i}$은 자유도가 $1(=k-1)$인 카이제곱분포를 따른다.

(2) (1)의 결과에 의해 자명하다. ■

위 정리 9.1에서 검정통계량

$$\sum_{i=1}^{k}\frac{(X_i-np_{i0})^2}{np_{i0}} \tag{9.3}$$

은 관찰값(X_i)과 귀무가설하에서 기대하는 바(np_{i0})의 차이를 측정한 것으로, 그 차이가 크면 관찰값이 귀무가설을 뒷받침하지 않는 것을 의미한다. 이와 같은 검정법을 **카이제곱 적합도 검정법**(chi-square goodness-of-fit test)이라고 하는데 이는 매우 직관적인 검정법이라고 하겠다. 정리 9.1의 증명에서 보듯이 이는 중심극한정리를 활용하는 것이기 때문에 근사적인 검정이며 np_{i0}와 $n(1-p_{i0})$의 값이 어느 정도 클 때(보통 적어도 5 이상이 필요) 사용할 수 있다.

같은 가설검정에 대해, 앞서 다룬 일반화 가능도비 검정통계량을 구해 보고 통계량 (9.3)과의 관계를 살펴보자. 먼저, 관찰값이 $Y_1=y_1,\ Y_2=y_2,\ \cdots,\ Y_n=y_n$으로 주어졌을 때의 가능도함수는, $x_i=\sum_{j=1}^{n}I_{\{y_j=a_i\}},\ i=1,\cdots,k$일 때

$$L(p_1,\ p_2,\ \cdots,\ p_k;y_1,\cdots,y_n)=p_1^{x_1}p_2^{x_2}\cdots\ p_k^{x_k} \tag{9.4}$$

이 된다. 여기에서 $I_{\{y_j=a_i\}}$는 y_j가 a_i라는 값을 가질 때에만 1이고 아니면 0의 값을 갖는 지시함수이고, 따라서 x_i는 n개의 관찰값 가운데 a_i가 나온 횟수이다. 만약 $X_1=x_1,\cdots,X_k=x_k$를 관찰값으로 하여 가능도함수를 구하면,

$$L(p_1,\ p_2,\ \cdots,\ p_k;x_1,\cdots,x_k)=\left(\frac{n!}{x_1!\cdots x_k!}\right)p_1^{x_1}p_2^{x_2}\cdots\ p_k^{x_k}$$

으로 쓸 수 있고, 이것은 (9.4)의 가능도함수에 상수를 곱한 형태이다. 즉, 로그를 취한 후 p_i들에 대해 미분하게 되면 식 (9.4)와 같은 결과를 주게 된다. $\sum_{i=1}^{k}p_i=1$이므로, $k-1$개의 모수 p_i들만이 서로 독립이기 때문에, 최대가능도 추정량을 구함에 있어 $p_k=1-\sum_{i=1}^{k-1}p_i$로 치환하기로 한다. 가능도함수 (9.4)에 로그를 취하고 p_i에 대하

여 편미분하면

$$\log L = \sum_{i=1}^{k-1} x_i \log p_i + x_k \log\left(1 - \sum_{i=1}^{k-1} p_i\right)$$

$$\frac{\partial \log L}{\partial p_i} = \frac{x_i}{p_i} - \frac{x_k}{1 - \sum_{i=1}^{k-1} p_i} = \frac{x_i}{p_i} - \frac{x_k}{p_k},\ i = 1, 2, \cdots, k-1$$

로 계산된다. 이제 미분한 값들을 0이라고 놓으면,

$$p_i = \frac{p_k}{x_k} x_i,\ i = 1, \cdots, k \tag{9.5}$$

가 구해지며, 양변을 i에 대하여 합하면 좌변은 1이 되고 우변은 np_k / x_k가 되므로 $p_k = x_k / n$을 구할 수 있다. 그러므로 모수 $(p_1, p_2, \cdots, p_k)$의 최대가능도 추정량은 $\left(\frac{X_1}{n}, \frac{X_2}{n}, \cdots, \frac{X_k}{n}\right)$가 된다. 따라서 일반화 가능도비는

$$\Lambda(X_1, X_2, \cdots, X_k) = \frac{p_{10}^{X_1} \cdots p_{k0}^{X_k}}{\left(\frac{X_1}{n}\right)^{X_1} \cdots \left(\frac{X_k}{n}\right)^{X_k}} = \left(\frac{np_{10}}{X_1}\right)^{X_1} \cdots \left(\frac{np_{k0}}{X_k}\right)^{X_k}$$

이다. 정리 5.3에 의하면

$$-2\log\Lambda(X_1, X_2, \cdots, X_n) = -2\sum_{i=1}^{k} X_i \log(np_{i0} / X_i)$$

가 자유도 $(k-1)$인 카이제곱분포를 근사적으로 따르게 되므로, 유의수준 α인 일반화 가능도비 검정법의 근사 기각영역은 $-2\sum_{i=1}^{k} X_i \log(np_{i0} / X_i) \geq \chi_\alpha^2(k-1)$로 주어진다. 그런데 테일러 전개를 이용하면 x가 x_0에 가까울 때 근사관계 $x\log\left(\frac{x}{x_0}\right) \approx 0 + (x - x_0) + \frac{1}{2}(x - x_0)^2 \frac{1}{x_0}$ 이 성립함을 알 수 있다. 이 관계를 이용하면 n이 커질 때 귀무가설하에서 X_i/n이 p_{i0}로 확률적으로 수렴하므로,

$$X_i \log(X_i / np_{i0}) \approx (X_i - np_{i0}) + \frac{1}{2}\frac{(X_i - np_{i0})^2}{np_{i0}}$$

으로 쓸 수 있다. 따라서

$$-2\log\Lambda(X_1,\ X_2,\ \cdots,\ X_n)=2\sum_{i=1}^{k}X_i\log(X_i/np_{i0})$$

$$\approx 2\sum_{i=1}^{k}(X_i-np_{i0})+\sum_{i=1}^{k}\frac{(X_i-np_{i0})^2}{np_{i0}}\approx\sum_{i=1}^{k}\frac{(X_i-np_{i0})^2}{np_{i0}}$$

와 같은 근사관계를 구할 수 있다. 마지막 근사는 $X_i/n\xrightarrow{p}p_{i0}$로부터 나온다. 따라서 $-2\log\Lambda(X_1,\cdots,X_n)$이 $\chi_\alpha^2(k-1)$보다 클 때 귀무가설을 기각하는 일반화 가능도비 검정방법과 $\sum_{i=1}^{k}\frac{(X_i-np_{i0})^2}{np_{i0}}$이 $\chi_\alpha^2(k-1)$보다 클 때 귀무가설을 기각하는 카이제곱 적합도 검정법은 근사적으로 동등하다고 말할 수 있다. 수렴속도 등을 고려한 보다 엄밀한 증명은 여기서 다루지 않기로 한다.

예 9.1

주사위를 60회 던졌을 때 나오는 눈의 횟수가 다음 표와 같았다.

눈	1	2	3	4	5	6
관찰횟수	12	10	9	8	13	8
기대횟수	10	10	10	10	10	10

(단, 기대횟수는 이 주사위의 각 눈이 나올 확률이 동일하다는 귀무가설하에서의 것임)

이제 주어진 자료에 근거하여 주사위가 '공정(fair)'한가 여부에 대한 검정을 하고자 한다. 이에 대한 통계적 모형은 다음과 같다. 주사위를 1회 던졌을 때 주사위 눈의 수를 Y라고 하고, $P(Y=i)=p_i\ (i=1,\ 2,\ 3,\ 4,\ 5,\ 6)$라면, 우리가 관심 있는 통계적 가설은

$$H_0:\ p_1=\cdots=p_6=\frac{1}{6}\qquad 대\qquad H_1:\ H_0가\ 아님 \tag{9.6}$$

으로 표현할 수 있다. 이제, X_i='60회의 독립반복시행에서 주사위 눈의 개수가 i인 횟수'$(i=1,\ 2,\cdots,\ 6)$라고 하면 확률벡터 $(X_1,\ X_2,\ \cdots,\ X_6)$는 다항분포를 따르며, 앞의 정리 9.1을 아래와 같이 사용할 수 있다. 주어진 자료에 대한 카이제곱 검정통계량의 값은

$$\frac{(12-10)^2}{10}+\frac{(10-10)^2}{10}+\frac{(9-10)^2}{10}+\frac{(8-10)^2}{10}+\frac{(13-10)^2}{10}+\frac{(8-10)^2}{10}$$

$$=2.2<\chi^2_{0.05}(6-1)=11.07$$

이므로, 유의수준 0.05에서 주사위의 모든 눈이 나올 확률이 동일하다는 위 귀무가설 H_0는 기각되지 않는다.

실제자료에 대한 적합도 검정에 있어서는, 확률모형이 완전히 결정된 경우보다는 일부만이 결정된 경우를 다룰 때가 많다. 가령, 모분포가 정규분포를 따르는지를 검정하는 경우에 모수의 값은 정하지 않고 단지 정규성의 여부만을 고려하는, 복합(composite) 귀무가설을 생각할 수 있다. 이때의 적합도 검정은 모든 미지의 모수가 최대가능도 추정량으로 대치된 카이제곱 검정통계량의 사용이 다음 정리 9.2와 같이 제안되고 있다. 모르는 모수를 추정하는 대신 자유도의 감소를 통해 그 값을 치르게 된다.

정리 9.2

확률밀도함수 $f_0(x)$가 r개의 알려져 있지 않은 모수를 가지고 있다고 하자. 이때

귀무가설 $H_0: f_X(x)=f_0(x)$ 대 대립가설 $H_1: f_X(x)\neq f_0(x)$

에 대한 다항분포를 이용한 유의수준 α인 근사 기각영역은

$$\sum_{i=1}^{k}(X_i-n\hat{p}_{i0})^2/n\hat{p}_{i0}\geq\chi^2_\alpha(k-1-r)$$

로 주어진다. 단, 여기에서 확률변수 $X_i(i=1,\cdots,k)$는 f_X에서 크기가 n인 표본을 얻었을 때 관찰값이 i번째 범주에 들어가는 횟수이며, $n\hat{p}_{i0}$는 미지의 r개 모수를 귀무가설하에서의 최대가능도 추정량으로 추정하여 구한 X_i의 기댓값이다.

예 9.2

시간이 지남에 따라 일어난 어떤 특정사건의 발생건수에 대한 결과가 다음과 같이 주어졌다고 하자.

발생건수	0	1	2	3	4	5	6	7	8	≥9
관찰횟수	6	20	36	50	52	40	25	12	4	5
기대횟수	5.4	20.6	39.5	50.7	48.7	37.4	24.0	13.2	6.3	9.6

(단, 총 관찰횟수는 $n=250$이며 기대횟수는 다음 식 (9.8)에서 주어진 $\hat{p}_{i0}$을 사용하여 $n\hat{p}_{i0}$으로 계산한 것임.)

이제 이 사건의 발생건수가 POI(λ)를 따르는지에 대한 통계적 가설검정을 고려하기로 한다. 이에 대한 통계적 모형은 다음과 같다. Y_j = 발생건수, $j=1,\cdots,250$, $P(Y_j=i)=p_i$로 표기하고, X_i, $i=0,1,\cdots,9$를 발생건수가 i인 Y의 관찰횟수라고 하자. 검정하고자 하는 통계적 가설은

$$H_0: p_i=\exp(-\lambda)\lambda^i/i! \quad \text{대} \quad H_1: H_0\text{가 아님} \tag{9.7}$$

으로 놓을 수 있다. 그런데 위의 가설에서는 모수 λ의 값이 주어져 있지 않으며, 이는 귀무가설하에서의 최대가능도 추정량인 평균발생건수 $\hat{\lambda}=(0\times 6+1\times 20+\cdots+9\times 5)/250=3.844$로 대치된다. 따라서

$$\hat{p}_{i0}=\frac{\exp(-\hat{\lambda})(\hat{\lambda})^i}{i!}=\frac{\exp(-3.844)\cdot(3.844)^i}{i!} \tag{9.8}$$

을 사용한 카이제곱 검정통계량의 값은

$$\sum_{i=0}^{9}\frac{(X_i-n\hat{p}_{i0})^2}{n\hat{p}_{i0}}=4.044<\chi^2_{0.05}(10-1-1)=15.51$$

이므로 유의수준 $\alpha=0.05$에서 위 귀무가설 H_0는 기각되지 않는다.

주 예 9.2에서 실제로 가능한 발생건수는 이론적으로 무한개이나 편의상 발생건수가 9회 이상인 것들을 하나로 묶었으며, 평균발생건수 $\hat{\lambda}$의 계산에서도 9회로 간주하였다. 이는 각 방 (cell)에 해당하는 관찰횟수가 4~5회 이상인 경우라야 카이제곱 검정의 성능이 믿을 만하다는 사실에 근거한 것이다. 또한, 자유도의 계산에서 한 개의 모수 λ를 추정한 것이 고려되었음을 유의할 필요가 있다.

9.2 분할표에 의한 독립성 검정

여기에서는 두 개의 범주형 변수, 변수 Ⅰ과 변수 Ⅱ의 관계에 대한 통계적 가설검정을 살펴보기로 한다. 랜덤표본 $Y_1, Y_2, \cdots, Y_n$에 대해, X_{ij}를 변수 Ⅰ의 i번째와 변수 Ⅱ의 j번째 범주에 해당하는 Y의 개수(또는 발생횟수)라고 하자($i=1, 2, \cdots, r$; $j=1, 2, \cdots, c$). 이때 우리가 얻을 수 있는 다음과 같은 이원표(two-way table)를 통상적으로 **분할표**(contingency table)라고 한다. 이제, 분할표의 형태로 주어진 자료에 대해 많이 응용되는 통계적 추론인 범주형 변수 사이의 독립에 대한 가설검정(test of independence)을 고려하기로 한다.

		변수 Ⅱ				
		1	2	……	c	합
변수 Ⅰ	1	X_{11}	X_{12}	… …	X_{1c}	$X_{1\cdot}$
	2	X_{21}	X_{22}	… …	X_{2c}	$X_{2\cdot}$
	⋮	⋮	⋮	… …	⋮	⋮
	r	X_{r1}	X_{r2}	… …	X_{rc}	$X_{r\cdot}$
	합	$X_{\cdot 1}$	$X_{\cdot 2}$	… …	$X_{\cdot c}$	n

여기에서 $X_{i\cdot} = \sum_{j=1}^{c} X_{ij}$, $X_{\cdot j} = \sum_{i=1}^{r} X_{ij}$, $n = \sum_{i=1}^{r}\sum_{j=1}^{c} X_{ij}$이다. 이제,

$$p_{ij} = P[Y\text{가 변수 Ⅰ의 } i\text{번째와 변수 Ⅱ의 } j\text{번째 범주에 속함}]$$

이라고 하면 이는 $n, p_{11}, p_{12}, \cdots, p_{1c}, p_{21}, \cdots, p_{rc}$인 다항분포로 생각할 수 있으며, 정리 9.1에 의해 확률변량

$$\sum_{i=1}^{r}\sum_{j=1}^{c} \frac{(X_{ij} - np_{ij})^2}{np_{ij}}$$

는 자유도가 $(rc-1)$인 카이제곱분포를 근사적으로 따른다. 편의상

$$p_{i\cdot} = \sum_{j=1}^{c} p_{ij} = P[\text{변수 Ⅰ의 } i\text{번째 범주에 해당하는 사건의 발생}]$$

$$p_{\cdot j} = \sum_{i=1}^{r} p_{ij} = P[\text{변수 Ⅱ의 } j\text{번째 범주에 해당하는 사건의 발생}]$$

이라고 표기하면, 두 변수의 독립여부는

$$H_0 : p_{ij} = p_{i.}p_{.j} \quad i = 1, \cdots, r ; \quad j = 1, \cdots, c \quad \text{대} \quad H_1 : H_0\text{가 아님} \qquad (9.9)$$

과 같은 통계적 가설로 표현할 수 있다. 이제 $p_{i.}$과 $p_{.j}$의 최대가능도 추정량은 $i = 1, \cdots, r, j = 1, \cdots, c$에 대해 각각

$$\hat{p}_{i.} = \frac{\sum_{j=1}^{c} X_{ij}}{n}, \quad \hat{p}_{.j} = \frac{\sum_{i=1}^{r} X_{ij}}{n} \qquad (9.10)$$

으로 주어진다(참조: 연습문제 9.10). 여기에서 정리 9.2를 이용하면,

$$\sum_{i=1}^{r}\sum_{j=1}^{c} \frac{(X_{ij} - n\hat{p}_{i.}\hat{p}_{.j})^2}{n\hat{p}_{i.}\hat{p}_{.j}} \qquad (9.11)$$

을 검정통계량으로 사용할 수 있다. 이를 위해 $\hat{p}_{i.}$과 $\hat{p}_{.j}$을 추정해야 하는데,

$$\sum_{i=1}^{r} \hat{p}_{i.} = \sum_{j=1}^{c} \hat{p}_{.j} = 1$$

이라는 제한조건이 있으므로 $(r-1)+(c-1)$개의 모수의 추정이 필요하기에, 검정통계량 (9.11)은 자유도가

$$(rc-1) - \{(r-1)+(c-1)\} = (r-1)(c-1)$$

인 카이제곱 분포를 따른다. 그러므로 가설 (9.9)에 대한 유의수준 α인 근사 기각영역은

$$\sum_{i=1}^{r}\sum_{j=1}^{c} \frac{(X_{ij} - n\hat{p}_{i.}\hat{p}_{.j})^2}{n\hat{p}_{i.}\hat{p}_{.j}} \geq \chi_{\alpha}^{2}((r-1)(c-1))$$

로 구할 수 있다.

예 9.3

어떤 도시에서 500명의 고등학생을 랜덤하게 뽑아 이 학생들의 학교가 속한 학군과 대학입학 성적의 자료를 분할표로 다음과 같이 나타내었다. 자료에 근거하여 범주형 변수인 학군과 성적 사이의 독립여부를 검정하고자 한다.

구분		고등학교 학군					
		1	2	3	4	5	합
성적	상	23	33	50	20	24	150
	중	18	35	45	39	63	200
	하	19	37	45	21	28	150
	합	60	105	140	80	115	500

주어진 자료에 대해, $p_{i.}$과 $p_{.j}(i=1, 2, 3,\ j=1, 2, 3, 4, 5)$의 최대가능도 추정량은 각각

$$\hat{p}_{1.} = 150/500,\ \hat{p}_{2.} = 200/500,\ \hat{p}_{3.} = 150/500$$

$$\hat{p}_{.1} = 60/500,\ \hat{p}_{.2} = 105/500,\ \hat{p}_{.3} = 140/500,\ \hat{p}_{.4} = 80/500,\ \hat{p}_{.5} = 115/500$$

로 계산된다. 이제, 식 (9.11)에 의한 카이제곱 검정통계량에 대하여

$$\sum_{i=1}^{3}\sum_{j=1}^{5}\frac{(X_{ij}-500\,\hat{p}_{i.}\hat{p}_{.j})^2}{500\,\hat{p}_{i.}\hat{p}_{.j}} = 22.327 \geq \chi^2_{0.05}(8) = 15.51$$

이 성립하므로, 유의수준 $\alpha = 0.05$에서 귀무가설을 기각하고, 주어진 자료로부터 학군과 성적이 서로 독립이 아니라는 증거가 있다고 결론내릴 수 있다.

9.3 다항분포의 동질성 검정

여기에서는 c개의 범주를 가진 하나의 분류변수에 대한 r개의 모집단의 동질성에 관한 검정법(test of homogeneity)을 고려하기로 한다. r개의 모집단으로부터 각각 랜덤표본을 구했을 때, X_{ij}를 i번째 표본에 대한 분류변수의 j 번째 범주에 해당하는 개체의 개수(또는 발생횟수)라고 하자($i=1, 2, \cdots, r\,; j=1, 2, \cdots, c$). 이에 대한 결과를 다음 표와 같이 표현한다(9.2절의 독립성 검정의 경우에는 하나의 랜덤표본에 근거하였으나, 여기에서는 r개의 독립인 랜덤표본에 근거한 표임을 주지할 필요가 있다).

표본	범주				
	1	2	……	c	합
1	X_{11}	X_{12}	… …	X_{1c}	n_1
2	X_{21}	X_{22}	… …	X_{2c}	n_2
· · ·	· · ·	· · ·	… … … … … …	· · ·	· · ·
r	X_{r1}	X_{r2}	… …	X_{rc}	n_r
합	$X_{\cdot 1}$	$X_{\cdot 2}$	… …	$X_{\cdot c}$	$n=\sum_{i=1}^{r} n_i$

여기에서 $P(Y=j)$를 임의의 개체 Y가 분류변수의 j 번째 범주에 속할 확률, $P(Y=j \mid \text{표본 } i)$를 임의의 개체 Y가 표본 i(즉, 모집단 i)로부터 왔을 때 j 번째 범주에 속할 조건부 확률이라고 하고,

$$p_j = P(Y=j),\ p_{j|i} = P(Y=j \mid \text{표본 } i) \qquad (i=1, 2, \cdots, r;\ j=1, 2, \cdots, c)$$

이라 표기하자. 그러면,

$$\begin{gathered}(X_{11}, \cdots, X_{1c}) \sim \mathrm{MULT}(n_1; p_{1|1}, \cdots, p_{c|1}) \\ \vdots \\ (X_{i1}, \cdots, X_{ic}) \sim \mathrm{MULT}(n_i; p_{1|i}, \cdots, p_{c|i}) \\ \vdots \\ (X_{r1}, \cdots, X_{rc}) \sim \mathrm{MULT}(n_r; p_{1|r}, \cdots, p_{c|r})\end{gathered}$$

가 되고, 각 표본이 독립이므로, 정리 9.1로부터 $\sum_{i=1}^{r}\sum_{j=1}^{c} \frac{(X_{ij}-n_i p_{j|i})^2}{n_i p_{j|i}}$가 자유도가 $r(c-1)$인 카이제곱 분포를 근사적으로 따른다. 이제 r개의 모집단의 동질성에 대한 통계적 가설은

$$H_0 : \text{임의의 } i, j\text{에 대하여 } p_{j|i}=p_j \quad \text{대} \quad H_1 : H_0\text{가 아님} \tag{9.12}$$

으로 표현되고, 이는 표본에 관계없이 분류변수에 대한 분포가 동일하다는 것을 뜻한다. 그러므로 귀무가설하에서는 $(X_{\cdot 1}, \cdots, X_{\cdot c}) \sim \mathrm{MULT}(n; p_1, \cdots, p_c)$가 되고, $\sum_{i=1}^{r}\sum_{j=1}^{c} \frac{(X_{ij}-n_i p_j)^2}{n_i p_j}$가 자유도가 $r(c-1)$인 카이제곱분포를 근사적으로 따르게 된다. 귀무가설하에서 모수 p_j의 최대가능도 추정량이

$$\hat{p}_j = \frac{\sum_{i=1}^{r} X_{ij}}{n} = \frac{X_{\cdot j}}{n} \tag{9.13}$$

로 주어지므로, 정리 9.2에 따라, 검정통계량

$$\sum_{i=1}^{r}\sum_{j=1}^{c} \frac{(X_{ij} - n_i \hat{p}_j)^2}{n_i \hat{p}_j} \tag{9.14}$$

이 귀무가설하에서 카이제곱분포를 가진다는 사실을 활용할 수 있다. X_{ij}는 i번째 표본에서 범주 j에 들어가는 개체수의 관찰값이고 $n_i\hat{p}_j$는 귀무가설하에서 X_{ij}의 기댓값의 최대가능도 추정량이다. 즉, 식 (9.14)는 표본에서의 관찰값과 귀무가설하에서의 기댓값과의 차이를 측정한 것이라고 할 수 있다. 이 값이 크면 관찰값과 기댓값과의 차이가 커서 귀무가설에 대한 반증이 되므로 귀무가설을 기각하게 된다. 그런데 $\sum_{j=1}^{c} p_j = 1$이므로 $(c-1)$개 모수의 추정이 필요하므로 검정통계량 (9.14)의 자유도는

$$r(c-1) - (c-1) = (r-1)(c-1)$$

이 된다. 그러므로 가설 (9.12)에 대한 유의수준 α인 근사 기각영역은

$$\sum_{i=1}^{r}\sum_{j=1}^{c} \frac{(X_{ij} - n_i \hat{p}_j)^2}{n_i \hat{p}_j} \geq \chi_{\alpha}^2((r-1)(c-1))$$

로 구할 수 있다.

예 9.4

흙에서 사는 네 종류의 벌레에 대한 생태를 조사하기 위하여, 모래, 찰흙, 진흙의 세 종류의 흙에서 각각 100마리의 벌레를 채취한 결과가 아래 표와 같다.

구분	종류1	종류2	종류3	종류4	합
모래	27	24	23	26	100
찰흙	20	32	18	30	100
진흙	13	37	16	34	100
합	60	93	57	90	300

이제, 주어진 자료에 근거하여 흙의 종류에 따라 벌레의 분포가 같은가에 대한 검정을 살펴보기로 한다. 이를 통계적 가설로 바꾸면,

$$H_0 : p_{j|i} = p_j \quad i = 1, 2, 3 ; \ j = 1, 2, 3, 4 \qquad \text{대} \qquad H_1 : H_0\text{가 아님}$$

이 된다. 여기에서 p_j의 최대가능도 추정량은 식 (9.13)에 의하여

$$\hat{p}_1 = \frac{60}{300}, \quad \hat{p}_2 = \frac{93}{300}, \quad \hat{p}_3 = \frac{57}{300}, \quad \hat{p}_4 = \frac{90}{300}$$

이며, 이에 따른 카이제곱 검정통계량이

$$\sum_{i=1}^{3}\sum_{j=1}^{4} \frac{(X_{ij} - n_i \hat{p}_j)^2}{n_i \hat{p}_j} = 10.11 < \chi^2_{0.05}(6) = 12.59$$

이므로 유의수준 $\alpha = 0.05$에서 귀무가설을 기각하지 않는다. 즉, 유의수준 0.05에서 흙의 종류에 따라 벌레의 분포가 같지 않다고 할 수 없다.

연습문제 9장

01 주사위를 600회 던졌을 때 나오는 눈의 횟수가 다음 표와 같았다.

눈	1	2	3	4	5	6
관찰횟수	120	100	90	80	130	80

예 9.1과 비교하면 시행횟수는 10배가 늘었지만 각 눈이 나온 상대비율은 같다. 유의수준 0.05에서 주사위의 공정성을 검정하고, 그 결과를 예 9.1과 비교하라.

02 유전법칙에 의하면 어떤 식물의 품종이 4종류로 나타나는데 그 비가 9 : 3 : 3 : 1로 된다고 한다. 어떤 실험에서 4가지 품종이 각각 150, 80, 70, 20으로 나타났을 때, 이 실험결과가 유전법칙에 부합되는지를 결정하라.

03 이항확률변수 $Y \sim B(4, p)$에 대하여 아래와 같은 자료를 구하였다. 이항모형의 적합도를 검정하라.

Y	0	1	2	3	4
관찰횟수	12	44	60	40	14

04 다음의 자료가 표준정규분포에서 나왔는지 유의수준 0.05에서 적합도 검정을 행하라.

X	$(-\infty,-2)$	$[-2,-1)$	$[-1,0)$	$[0,1)$	$[1,2)$	$[2,\infty)$
관찰횟수	1	33	118	195	121	32

05 다음의 자료가 평균이 3인 지수분포에서 나왔는지 유의수준 0.05에서 적합도 검정을 행하라.

X	$(0,1)$	$[1,2)$	$[2,4)$	$[4,7)$	$[7,10)$	$[10,\infty)$
관찰횟수	16	16	20	23	14	11

06 다음의 자료가 지수분포에서 뽑힌 랜덤표본인지 알아보려고 한다. 아래 표에서와 같은 그룹화를 이용하여 유의수준 0.05에서 지수분포의 적합도를 검정하라.

0.36 0.01 0.18 1.10 0.08 0.33 0.04 0.30 0.41 0.14
0.03 1.01 1.78 1.07 0.22 0.88 0.53 0.08 1.73 0.25
0.68 0.07 0.13 1.24 0.75 0.20 0.24 0.97 0.83 0.85

X	$(0,0.1)$	$[0.1,0.3)$	$[0.3,0.7)$	$[0.7,1)$	$[1,\infty)$
관찰횟수					

07 다음의 자료는 1500년부터 1931년까지 432년 동안의 전쟁발발횟수(Y)에 관한 것이다. 이 자료가 평균이 0.6921인 포아송 분포를 따르는지 적합도를 검정하라(발발횟수 5 이상은 관찰값이 없으므로 4회 이상을 묶어서 관찰값 4 이상의 한 범주로 간주할 것).

1500~1931년 사이의 전쟁발발			
발발횟수	연도 수	포아송 분포	
		확률	기대횟수
0	223	0.5005	216.2160
1	142	0.3464	149.6448
2	48	0.1200	51.8400
3	15	0.0277	11.9664
4	4	0.0048	2.0736
5		0.0007	0.3024
6			
7			
합계	432	1.0001	432.0432
평균	0.6921		

08 어떤 질병에 대한 약품의 효력을 알아보기 위하여 다음과 같은 실험을 하였다. 400명의 환자를 200명씩 무작위로 두 집단으로 나누어 그중 한 집단에는 투약을 하고 다른 한 집단에는 위약(placebo)을 주었다. 일정한 투약기간이 지난 후 질병의 상태에 대하여 다음과 같은 결과를 얻었다.

구분	투약 환자집단	위약 환자집단
호전됨	118	75
변화없음	82	125

(1) 투약효과여부에 대하여 카이제곱검정을 유의수준 5%에서 실시하라.

(2) 두 모집단의 비율에 대한 근사검정법을 사용하여, 투약효과여부에 대한 검정을 유의수준 5%에서 실시하고 유의확률의 값을 (1)의 결과와 비교하라.

09 다음은 자동차 사고와 연령에 대한 분할표이다.

연령	사고횟수		
	0	1 또는 2	3 이상
20 이하	10	20	18
21~30	18	24	32
31~50	21	18	15
50 이상	11	8	5

이 자료에 근거하여 자동차 사고횟수와 연령 간의 독립여부를 $\alpha = 0.05$에서 결정하라.

10 이원분할표에서, $p_{i.}$과 $p_{.j}$의 최대가능도 추정량은 식 (9.10)에 주어진 바와 같이 각각

$$\hat{p}_{i.} = \frac{\sum_{j=1}^{c} X_{ij}}{n}, \quad \hat{p}_{.j} = \frac{\sum_{i=1}^{r} X_{ij}}{n} \qquad (i = 1, \cdots, r; \quad j = 1, \cdots, c)$$

로 주어짐을 보여라.

11 다음의 자료는 최종학교 졸업 후 일정기간이 지난 후의 월수입과 학력의 관계를 알아보기 위하여 구한 750명으로 이루어진 표본에 근거한 것이다.

학력	재산정도		
	상	중	하
고졸	50	50	100
전문대졸	70	200	50
대졸	120	60	50

이제 월수입과 학력 사이의 독립성 여부에 관해 유의수준 $\alpha = 0.10$인 검정방법을 제시하라.

12 다음 자료는 호흡기 질환에 관한 치료방법의 효과에 대한 것이다. 특정한 호흡기 질환을 앓고 있는 환자 100명을 50명씩 두 집단으로 나누어 한 집단에는 새로운 치료약을

주고 다른 집단에는 위약(placebo)을 주었다. 이때 증상이 완화되었다고 느끼는 환자의 수와 그렇지 않은 환자의 수를 조사하여 다음의 표에 나타내었다.

구분	증상완화	완화되지 않음	합
위약	14	36	50
신약	33	17	50

이제 위약을 받은 집단과 신약을 받은 집단의 분포가 동질적인지 유의수준 $\alpha = 0.05$에서 검정하라.

13 어떤 학교에서 농촌출신과 도시출신 학생의 전공선택의 차이에 대해 알아보기 위하여 200명으로 이루어진 표본에 근거한 다음과 같은 분할표를 구하였다.

구분	사회과학계	자연과학계	인문과학계
도시	40	30	30
농촌	40	20	40

이제, 도시와 농촌 간에 전공선택에 대하여 독립성이 있는지 여부를 유의수준 α에서 검정하는 방법을 상세히 제시하라.

14 어떤 서비스에 대한 만족도가 연령별로 차이가 있는지 조사한 자료가 다음과 같다. 20대, 30대, 40대 이상의 세 집단에서 만족도의 분포가 동질적인지 유의수준 $\alpha = 0.05$에서 검정하라.

연령대	만족도				
	매우 만족	만족	보통	불만족	매우 불만족
20대	10	20	30	30	10
30대	15	30	25	20	10
40대 이상	10	15	35	20	20