Chap 2. 확률밀도함수 및 확률분포함수

2.1 확률변수

[정의 2.1] 확률변수 X는 표본공간 S에 정의된 실함수(real-valued function)이다. 확률분포는 확률변수가 나타날 가능성을 정리한 것이다.

- 표본공간은 수치적 또는 비수치적으로 표현될 수 있음.
  - [예] 동전 3번을 독립적으로 던지는 실험 : 표본공간은?

    [풀이]

    동전의 앞면을 H, 뒷면을 T라 하면, 표본공간은

    $$S = \{HHH,\ HHT,\ HTH,\ THH,\ HTT,\ THT,\ TTH,\ TTT\}.$$

    총 $2^3 = 8$개의 표본점이 있다.

  - 하지만 많은 경우, 표본공간 자체가 아니라 표본공간에서 정의된 수치적인 값이 관심이 됨.
    - [예] : 동전 3번던지기 실험의 표본공간에서 정의된 앞면의 수 (X).
    - 즉, 실험결과를 표현하는 이 숫자값(수치적인 양)을 X라 정의한다면 X는 확률변수(random variable)가 됨.
    - 확률변수의 값은 랜덤한 실험결과에 따라 정해지므로, 그 값들이 나올 가능성은 다 다름[예, X가 1이 나올 가능성과 2가 나올 가능성이 같을까?].

$\Rightarrow$ 확률변수(X)의 확률분포(probability distribution)

- [예] 앞면이 나올 확률이 p로 동일할 경우, X의 확률분포는?

[풀이]

X를 앞면의 개수라고 하면 $X \in \{0, 1, 2, 3\}$이다. 각 시행이 독립이고 앞면이 나올 확률이 p이므로

$$P(X = k) = \binom{3}{k} p^k (1-p)^{3-k}, \qquad k = 0, 1, 2, 3.$$

따라서 각 확률은 차례대로

$$P(X = 0) = (1-p)^3, \qquad P(X = 1) = 3p(1-p)^2,$$
$$P(X = 2) = 3p^2(1-p), \quad P(X = 3) = p^3.$$

- 확률변수는 보통 영문 대문자를 표기함. 보통 확률변수가 가질 수 있는 값은?
  - {0, 1, 2, 3}과 같이 유한개(finite)일 수 있고,
  - {0, 1, 2, 3, ...}과 같이 셀 수 있는 무한개(countable infinite)일 수 있고,
  - 셀 수 없는 무한개(uncountable infinite)일 수 있다.
    : 확률변수 X가 어떤 특정 사건이 일어날 때까지 걸리는 시간
    : $S = \{ x; x > 0 \}$

- 이산형(discrete) 확률변수 : 확률변수가 유한하거나 가산유한인 경우
- 연속형(continuous) 확률변수 : 확률변수의 범위가 실직선상의 어떤 구간인 경우

2.2 확률밀도함수(probability density function; PDF) 및 확률분포함수(probability distribution function)

- 확률변수의 확률분포 : 확률밀도함수
- 이산형과 연속형으로 나누어 설명함.

- **이산형 확률밀도함수[$f(x)$]의 조건**

(1) 모든 실수 x에 대하여 $f(x) \geq 0$이다.

(2) 확률변수 X가 가질 수 있는 유한 또는 가산무한개의 값 $x_1, x_2, \cdots$에 대하여 $f(x_i) > 0$이며 $\sum_{\text{모든}x_i} f(x_i) = 1$이다.

  - 이산형 확률변수 X의 pdf $f(x)$는 $P(X=x) = f(x)$를 만족하며, 이를 확률질량함수(probability mass function; pmf)이라고도 함.

- (예제) 주사위 2개 던지기 - X: 두 눈의 합

[풀이]

두 주사위의 눈을 각각 U, V라 하고 $X = U + V$라 하자. (U, V)의 가능한 결과는 $6 \times 6 = 36$가지이며 모두 같은 확률을 갖는다. X가 취할 수 있는 값은 $2, 3, \ldots, 12$이다.

x	2	3	4	5	6	7	8	9	10	11	12
$36\,P(X=x)$	1	2	3	4	5	6	5	4	3	2	1

따라서 확률질량함수는

$$\boxed{P(X=x) = \frac{6 - |7-x|}{36}, \quad x = 2, 3, \ldots, 12.}$$

그 밖의 x에서 확률은 0이다.

- 연속형 확률변수는 가질 수 있는 값이 셀 수 없는 무한대이기 때문에, pdf가 가능한 값 하나하나에 확률을 부여하지 않고, 구간에 확률을 부

여하게 됨.

- 따라서 모든 실수 x에 대하여 $P(X=x)=0$이 됨.

- **연속형 pdf[$f(x)$]의 조건**

(1) 모든 실수 x에 대하여 $f(x) \geq 0$이다.

(2) $\int_{-\infty}^{\infty} f(x)dx = 1$이라는 조건을 만족하며,

$-\infty < a < b < \infty$일 때, $\int_a^b f(x)dx = P(a \leq X \leq b)$로 확률이 주어짐.

- 확률변수 X의 pdf가 $f(x)$일 때, 변수 X의 어떤 집합 A에 속할 확률은

$$P(X \in A) = \begin{cases} \sum_{x_i \in A} f(x_i) & X\text{가 이산형인 경우} \\ \int_A f(x)dx & X\text{가 연속형인 경우} \end{cases}$$

- (예제) 주사위 2개 던지는 실험에서 두 눈의 합이 4에서 7사이에 존재할 확률은?

[풀이]

앞의 두 주사위 합의 확률분포를 이용한다. 양 끝을 포함하면

$$P(4 \leq X \leq 7) = \frac{3+4+5+6}{36} = \boxed{\frac{1}{2}}.$$

양 끝을 제외하면

$$P(4 < X < 7) = \frac{4+5}{36} = \boxed{\frac{1}{4}}.$$

따라서 문제의 '사이'가 양 끝을 포함하는지 확인해야 한다.

- (예제 2.1) $f(x) = x^2/9, \quad 0 < x < 3, \qquad f(y) = 1, \quad 0 < y < 1$

$P(0 < X < 1), \quad P(2 < X < 3)$ $P(0.1 < Y < 0.3) \quad P(0.7 < Y < 0.9)$

[풀이]

연속형 확률변수의 확률은 밀도를 구간에서 적분하여 얻는다.

$$P(0 < X < 1) = \int_0^1 \frac{x^2}{9}\, dx = \boxed{\frac{1}{27}},$$
$$P(2 < X < 3) = \int_2^3 \frac{x^2}{9}\, dx = \boxed{\frac{19}{27}},$$
$$P(0.1 < Y < 0.3) = \int_{0.1}^{0.3} 1\, dy = \boxed{0.2},$$
$$P(0.7 < Y < 0.9) = \int_{0.7}^{0.9} 1\, dy = \boxed{0.2}.$$

- **[정의 2.2]** 확률변수 X에 대한 확률분포함수 $F(x)$는 $F(x) = P(X \le x)$로 정의됨. 또는 누적분포함수(cumulative distribution function; CDF)라 부름.

- CDF는 다음과 같이 정의됨. $F(x) = \begin{cases} \sum_{x_i \le x} f(x_i) & X\text{가 이산형인 경우} \\ \int_{-\infty}^{x} f(t)dt & X\text{가 연속형인 경우} \end{cases}$

- (예제 2.2) 동전 3번 던지기

[풀이]

공정한 동전을 세 번 던지면 $X \sim \text{Bin}(3, 1/2)$이고, $X = 0, 1, 2, 3$에서 확률은 각각 $1/8, 3/8, 3/8, 1/8$이다. 따라서 누적분포함수 $F_X(x) = P(X \le x)$는

$$\boxed{F_X(x) = \begin{cases} 0, & x < 0, \\ 1/8, & 0 \le x < 1, \\ 1/2, & 1 \le x < 2, \\ 7/8, & 2 \le x < 3, \\ 1, & x \ge 3. \end{cases}}$$

각 점에서 오른쪽 연속인 계단함수가 된다.

- (예제 2.3) $f(x) = \begin{cases} c(1+x)^{-2}, & x > 0 \\ 0, & x \le 0 \end{cases}$, 상수 c는? $F(x)$는?

[풀이]

밀도의 적분값이 1이라는 조건에서

$$1 = \int_0^\infty c(1+x)^{-2}\, dx = c, \qquad \boxed{c = 1}.$$

따라서 누적분포함수는

$$\boxed{F_X(x) = \begin{cases} 0, & x \le 0, \\ 1 - (1+x)^{-1} = x/(1+x), & x > 0. \end{cases}}$$

예를 들어 $P(1 < X < 2) = F_X(2) - F_X(1) = \frac{1}{6}$이다.

[정리 2.2] 연속형확률변수 X의 pdf가 $f(x)$이고 cdf가 $F(x)$이라면,

$f(x)=\frac{d}{dx}F(x)$를 만족한다.

[증명] : [생략, P 38] - 미분과 적분의 관계

- (예제 2.4) $F(x)=1-\exp(-x/\lambda), \quad x>0,\ \lambda>0$

  [풀이]

  $x>0$에서 $F_X(x)=1-\exp(-x/\lambda), \lambda>0$이다 .$x\le 0$에서는 $F_X(x)=0$으로 정의한다.

  따라서 $f_X(x)=F_X'(x)=(1/\lambda)\exp(-x/\lambda)(x>0)$, 그 밖에는 0이다.

  $\int_0^\infty (1/\lambda)\exp(-x/\lambda)dx=1$ 이므로 올바른 밀도이다.

2.3 결합 및 조건분 분포

2.3.1 결합분포

- 관심있는 확률변수가 두 개 이상인 경우, 이들이 동시에 나타날 가능성을 나타난 분포

- **[정의 2.3]** 두 확률변수 X와 Y의 결합 확률밀도함수(joint pdf) $f_{X,Y}(x,y)$는 X와 Y가 이산형인 경우

$$f_{X,Y}(x,y)=P(X=x,\ Y=y)$$

로 정의되며, 연속형인 경우 이차평면상의 임의의 영역 A에 대하여

$$P[(X,Y)\in A]=\int\int_{A} f_{X,Y}(x,y)dxdy$$

를 만족하는 $f_{X,Y}(x,y)$로 정의됨.

- **joint pdf의 조건**

  (1) $f_{X,Y}(x,y)\geq 0$

  (2) $\sum_{\text{모든 } x,y}\sum f_{X,Y}(x,y)=1$: X와 Y가 이산형인 경우

  $\int_{-\infty}^{\infty}\int_{-\infty}^{\infty} f_{X,Y}(x,y)dxdy=1$: X와 Y가 연속형인 경우

[예제 2.5] 주머니에 빨간공 4개, 하얀공 3, 검은공 2개가 들어있는 경우 3개의 공을 뽑았을 때, X : 하얀공의 수, Y : 검은공의 수

[풀이]

흰 공 3개, 검은 공 2개, 빨간 공 4개 중에서 3개를 복원 없이 추출한다. 흰 공의 개수를 X, 검은 공의 개수를 Y로 놓는다. 전체 추출 방법은 $\binom{9}{3}=84$ 가지이므로,

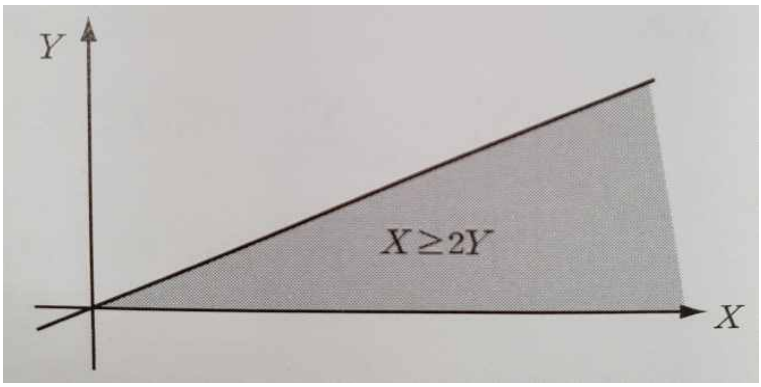
$$\boxed{P(X=x,Y=y)=\frac{\binom{3}{x}\binom{2}{y}\binom{4}{3-x-y}}{\binom{9}{3}}.}$$

단, $x=0,1,2,3$, $y=0,1,2$, $0\leq x+y\leq 3$이고, 그 밖에서는 확률이 0이다. 예를 들어 $P(X=1,Y=1)=\frac{3\cdot 2\cdot 4}{84}=\frac{24}{84}$이다. 표의 열을 합하면 X의 주변분포는 $(20,45,18,1)/84$이고, 행을 합하면 Y의 주변분포는 $(35,42,7)/84$이다.

		x				합계
		0	1	2	3	
y	0	4/84	18/84	12/84	1/84	35/84
	1	12/84	24/84	6/84	0	42/84
	2	4/84	3/84	0	0	7/84
합계		20/84	45/84	18/84	1/84	1

▪ (예제 2.6) 연속형 : X(TV 시청시간), Y(숙제시간) $[P(X \geq 2Y)]$

$$f_{X,Y}(x,y) = xye^{-(x+y)}, \quad x > 0,\ y > 0$$



$$\{(x,y);\ x > 0.\ 0 < y \leq x/2\}$$

$$P(X \geq 2Y) = \int_0^\infty \int_0^{x/2} f(x,y)dydx = \int_0^\infty \int_0^{x/2} xye^{-(x+y)}dydx$$

[풀이]

$f(x,y) = xy$

$exp[-(x+y)](x > 0, y > 0).X \geq 2Y$ 의 영역은 $x > 0, 0 < y \leq x/2$ 이다.

$P(X \geq 2Y) = \int_0^\infty xe^{-x}\int_0^{x/2} ye^{-y}dydx$

$= \int_0^\infty xe^{-x}1 - (1 + x/2)e^{-x/2}dx$

$= 1 - \int_0^\infty xe^{-3x/2}dx - (1/2)\int_0^\infty x^2e^{-3x/2}dx$

$= 1 - 4/9 - 8/27 = 7/27.$

마지막 줄에는 $\int_0^\infty x^m e^{-ax}dx = m!/a^{m+1}$ 을 사용했다.

■ 결합 확률분포함수(joint cdf) : 일차원 CDF를 다차원으로 확장

▪ **[정의 2.4]** 확률변수 $X_1,\cdots,X_k$의 결합 cdf는

$$F(x_1,x_2,\cdots,x_k)=P(X_1\le x_1,X_2\le x_2,\cdots,X_k\le x_k)$$

으로 정의됨.

$$F(x_1,x_2,\cdots,x_k)=\begin{cases}\sum\cdots\sum\limits_{\text{모든}t_i\le x_i} f(t_1,t_2,\cdots,t_k)\\ \int_{-\infty}^{x_k}\cdots\int_{-\infty}^{x_1} f(t_1,\cdots,t_k)dt1\cdots dt_k\end{cases}$$

- **특히, 연속형의 경우**

  - $f(x_1,x_2,\cdots,x_n)=\dfrac{\partial^k}{\partial x_1\cdots\partial x_k}F(x_1,\cdots,x_k)$

- [예제 2.7] $F_{X,Y}(x,y)=xy,\quad 0<x<1.\ 0<y<1$

  $P(X^2<Y)=?$

$$f_{X,Y}(x,y)=\frac{\partial^2}{\partial x\partial y}F_{X,Y}(x,y)=1,\quad 0<x<1,\ 0<y<1$$

[풀이]

$0<x<1, 0<y<1$ 에서 $F_X,Y(x,y)=xy$ 이므로 $f_{X,Y}(x,y)=\partial^2F/\partial x\partial y=1.$

$P(X^2<Y)=\int_0^1\int_{x^2}^1 1dydx=\int_0^1(1-x^2)dx=1-1/3=2/3.$

두 변수는 (0,1)에서 독립적인 균등분포를 따른다.

2.3.2 주변 확률밀도함수(marginal pdf)

- 결합분포에서 각 변수만의 분포 [구슬 ex : Handout 6 페이지]

- **[정리 2.4] 두 확률변수 X, Y의 joint pdf가 $f_{X,Y}(x,y)$로 주어졌을 때, X와 Y의 marginal pdf는 다음과 같이 구해진다.**

  - $f_X(x)=\sum\limits_{\text{모든 }y} f_{X,Y}(x,y),\quad f_Y(y)=\sum\limits_{\text{모든 }x} f_{X,Y}(x,y)$: X, Y가 이산형

- $f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x,y)dy, \quad f_Y(y) = \int_{-\infty}^{\infty} f_{X,Y}(x,y)dx$: X, Y가 연속형

[증명] : [생략, P45]

- [예제 2.9] 주사위를 n번 독립적으로 던지는 실험

  [X_1 : 1인 횟수, X_2 : 2, 3이 나온 횟수, X_3 : 4, 5, 6이 나온 횟수]

  - X_1의 주변부 확률분포는? [Hint(이항정리) : $(a+b)^n = \sum_{k=0}^{n} a^k b^{n-k}$]

$$f(x_1,x_2,x_3) = \frac{n!}{x_1!x_2!x_3!}(1/6)^{x_1}(2/6)^{x_2}(3/6)^{x_3}$$

$$[x_1,x_2,x_3 = 0,1,\cdots,n,\ \ x_1+x_2+x_3 = n]$$

$$\Rightarrow \quad f(x_1,x_2) = \frac{n!}{x_1!x_2!(n-x_1-x_2)!}(1/6)^{x_1}(2/6)^{x_2}(3/6)^{n-x_1-x_2}$$

$$[x_1,x_2 = 0,1,\cdots,n,\ \ x_1+x_2 \le n]$$

  - $f(x_1) = \sum_{x_2=0}^{n-x_1} \frac{n!}{x_1!x_2!(n-x_1-x_2)!}(1/6)^{x_1}(2/6)^{x_2}(3/6)^{n-x_1-x_2}$

$$= \frac{n!}{x_1!(n-x_1!)}(1/6)^{x_1}\sum_{x_2=0}^{n-x_1}\frac{(n-x_1!)}{x_2!(n-x_1-x_2)!}(2/6)^{x_2}(3/6)^{n-x_1-x_2}$$

$$= \frac{n!}{x_1!(n-x_1!)}(1/6)^{x_1}\ (2/6+3/6)^{n-x_1}$$

$$= \frac{n!}{x_1!(n-x_1!)}(1/6)^{x_1}\ (5/6)^{n-x_1}, \quad x_1 = 0,\cdots,n$$

[풀이]

X1은 한 번 던질 때 눈 1이 나오는 횟수이므로 $X_1 \sim \text{Bin}(n,1/6)$ 이다.

$P(X_1 = x) = \binom{n}{x}(1/6)^x(5/6)^{n-x}, x = 0,1,\cdots,n.$

$E(X_1) = n/6, \text{Var}(X_1) = 5n/36$ 이고 , $X_2 \sim \text{Bin}(n,1/3), X_3 \sim \text{Bin}(n,1/2)$ 이다.

2.3.3 조건부 확률변수

- 여러 개의 확률변수 중 몇 개의 변수값이 주어졌다는 조건하에서 나머지 확률변수들의 분포

[정의 2.5] $X=x$가 주어졌을 때, $Y|x$의 조건부 pdf는 다음과 같이 정의됨

$$f_{Y|X}(y|x)=\frac{f_{X,Y}(x,y)}{f_X(x)},\quad (\text{단},\ f_X(x)>0).$$

- 조건부 확률의 정의에 부합함.

$$P(Y=y|X=x)=\frac{P(X=x,Y=y)}{P(X=x)},\quad (\text{단},\ P(X=x)>0)$$

- [예제 2.11] [예제 2.5 계속] 주머니에 빨간공 4개, 하얀공 3, 검은공 2개가 들어있는 경우 3개의 공을 뽑았을 때, X : 하얀공의 수, Y : 검은공의 수

		X				Sum
		0	1	2	3	
Y	0	4/84	18/84	12/84	1/84	35/84
	1	12/84	24/84	6/84	0	42/84
	2	4/84	3/84	0	0	7/84
Sum		20/84	45/84	18/84	1/84	1

$$f_{Y|X}(y|x=0)=\frac{f_{X,Y}(0,y)}{f_X(0)}$$

[풀이]

결합확률표의 열 합계로부터 X의 주변확률분포는 $P(X = 0, 1, 2, 3) = (20, 45, 18, 1)/84$이다. 조건부확률의 정의에 따라

$$P(Y = y \mid X = x) = \frac{P(X = x, Y = y)}{P(X = x)}.$$

이를 각 열에 적용하면 $Y \mid X = x$의 조건부확률표는

$x \backslash y$	0	1	2
0	$\frac{1}{5}$	$\frac{3}{5}$	$\frac{1}{5}$
1	$\frac{2}{5}$	$\frac{8}{15}$	$\frac{1}{15}$
2	$\frac{2}{3}$	$\frac{1}{3}$	0
3	1	0	0

각 행의 확률 합계가 1임을 확인할 수 있다.

- [예제 2.12] $f_{X,Y}(x,y) = x^2 e^{-x(y+1)},\ x > 0,\ y > 0$

[풀이]

주변밀도는 $x > 0$에서

$$\begin{aligned} f_X(x) &= \int_0^\infty x^2 e^{-x(y+1)}\, dy \\ &= x^2 e^{-x} \int_0^\infty e^{-xy}\, dy = x e^{-x}. \end{aligned}$$

따라서

$$\boxed{f_{Y|X}(y \mid x) = \frac{f_{X,Y}(x,y)}{f_X(x)} = x e^{-xy}, \quad y > 0.}$$

즉 $Y \mid X = x$는 모수가 x인 지수분포를 따른다.

2.3.4 독립확률변수

- **[정의 2.6]** 두 확률변수 X와 Y는 임의의 실구간 A와 B에 대하여

$$P(X \in A, Y \in B) = P(X \in A) \cdot P(Y \in B)$$

가 성립할 때 서로 독립(independent)이라 한다.

- **[정리 2.5] 두 확률변수가 서로 독립일 필요충분조건은 다음과 같다.**

$$f_{X,Y}(x,y) = f_X(x) \cdot f_Y(y)$$

[증명] : [생략, P 51]

- [예제 2.13]

(1) $f_{X,Y}(x,y) = \dfrac{2^{x+y}e^{-4}}{x!y!}, \quad x,y = 0,1,\cdots$

(2) $f_{X,Y}(x,y) = \begin{cases} \dfrac{1}{2}, & 0 < x < y < 2 \\ 0, & otherwise \end{cases}$

[풀이]

(1) $x, y = 0, 1, ...$일 때

$$f_{X,Y}(x,y) = \frac{2^{x+y}e^{-4}}{x!y!} = \left(\frac{2^x e^{-2}}{x!}\right)\left(\frac{2^y e^{-2}}{y!}\right).$$

결합확률질량함수가 주변확률질량함수의 곱이므로 X, Y는 서로 독립이며, 둘 다 Poi(2)를 따른다.

(2) $0 < x < y < 2$에서 $f_{X,Y}(x,y) = \frac{1}{2}$이므로

$$f_X(x) = \int_x^2 \frac{1}{2}\,dy = \frac{2-x}{2}, \qquad f_Y(y) = \int_0^y \frac{1}{2}\,dx = \frac{y}{2}.$$

$\frac{2-x}{2} \cdot \frac{y}{2}$는 해당 영역에서 $\frac{1}{2}$와 같지 않으므로 X, Y는 서로 독립이 아니다.

- 확률변수 독립의 확장(다차원으로)
  - $X_1, X_2, \cdots, X_k$가 서로 독립일 필요충분조건
    : $f(x_1, x_2, \cdots, x_k) = f_{X_1}(x_1) f_{X_2}(x_2) \cdots f_{X_k}(x_k)$
  - 따라서 pdf $f(x)$를 갖는 모집단에서 크기가 n인 랜덤표본 $X_1, X_2, \cdots, X_n$을 뽑으면, 이들의 joint pdf는 다음과 같이 구해짐.
    : $f(x_1, x_2, \cdots, x_k) = f(x_1) f(x_2) \cdots f(x_n)$

- (예제 2.14) 서로 독립인 3개의 확률변수 X_1, X_2, X_3의 공통된 확률밀도함수가 $f(x) = 3x^2, \quad 0 < x < 1$이라 하자.
  - X_1, X_2, X_3의 joint PDF는?

[풀이]

각 변수는 같은 밀도 $f(x) = 3x^2\ (0 < x < 1)$를 갖고 서로 독립이므로 결합밀도는 주변밀도의 곱이다.

$$\boxed{f_{X_1,X_2,X_3}(x_1,x_2,x_3) = 27x_1^2x_2^2x_3^2, \quad 0 < x_1, x_2, x_3 < 1.}$$

이 범위 밖에서는 0이다. 또 $\int_0^1 3x^2\,dx = 1$이므로 정규화조건을 만족한다.

2.4 기댓값(Expected Value)

- 확률변수의 성질을 몇 개의 수치로 요약 (기대값, 분산)

- **[정의 2.7]** 확률변수 X의 pdf가 $f(x)$일 때 X의 기댓값은

$$E(X) = \begin{cases} \sum_{\text{모든}x_i} x_i f(x_i) \\ \int_{-\infty}^{\infty} x f(x)dx \end{cases}$$

  - 단 $E(|X|) < \infty$. $E(X)$가 유한하지 않은 경우도 있음. 이 경우 기댓값이 존재하지 않는다고 말함
  - 기대값은 X가 가지는 값에 해당하는 확률가중을 사용한 가중평균 (weighted mean)

- (예제) 모집단이 1이 4개, 2개 2개, 3이 3개, 4가 1개 등 총 10개의 원소로 이루어진 경우. 이 모집단에서 하나를 뽑아 나오는 수를 X

[풀이]

모집단의 값 1,2,3,4의 빈도가 각각 4,2,3,1이라면 $P(X = 1,2,3,4) = (4,2,3,1)/10.$

$E(X) = (1 \cdot 4 + 2 \cdot 2 + 3 \cdot 3 + 4 \cdot 1)/10 = 21/10 = 2.1.$

$E(X^2) = (1^2 \cdot 4 + 2^2 \cdot 2 + 3^2 \cdot 3 + 4^2 \cdot 1)/10 = 55/10 = 5.5,$

Var$(X) = 5.5 - (2.1)^2 = 1.09.$

■ (예제 2.16) $f(x) = x^2/9, \quad 0 < x < 3$

[풀이]

$E(X) = \int_0^3 x \cdot x^2/9 dx = (1/9)[x^4/4]_0^3 = 9/4.$

$E(X^2) = \int_0^3 x^4/9 dx = (1/9)[x^5/5]_0^3 = 27/5.$

따라서 Var$(X) = 27/5 - (9/4)^2 = 27/80.$

■ 확률변수 X의 함수인 $g(X)$의 기댓값 ($E[g(X)]$) - 2가지 방법

(1) $Y = g(X)$로 변환한 후, Y의 pdf를 유도한 후, $E[Y]$를 계산함.

$$E_X[g(X)] = E_Y(Y) = \begin{cases} \sum_{\text{모든} y_i} y_i f(y_i) \\ \int_{-\infty}^{\infty} y f(y) dy \end{cases}$$

(예제) 동전 3번 던지기 $Y = X^2$의 확률분포 및 기대값

[풀이]

공정한 동전에서 $P(X=0,1,2,3)=(1,3,3,1)/8$ 이다.

$Y=X^2$ 이면 Y의 가능한 값은 0,1,4,9이고 확률은 순서대로 (1,3,3,1)/8.

$E(Y)=0\cdot 1/8+1\cdot 3/8+4\cdot 3/8+9\cdot 1/8=24/8=3.$

직접 계산해도 $E(X^2)=\sum_{x=0}^{3}x^2\binom{3}{x}/8=3.$

(2) 반면, X**의 pdf만 이용하여** $g(X)$**의 기댓값 계산가능**

$$E_X[g(X)]=\begin{cases}\sum_{\text{모든}x_i} g(x_i)f(x_i)\\ \int_{-\infty}^{\infty} g(x)f(x)dx\end{cases}$$

(예제) 동전 3번 던지기 $Y=X^2$의 기대값

- (예제 2.16 계속) $Y=2X+3$의 기댓값은?

  [풀이]

  X의 밀도가 $x^2/9(0<x<3)$ 이므로 $E(X)=9/4$ 이다.

  $E(Y)=E(2X+3)=2E(X)+3=2\cdot 9/4+3=15/2.$

  Y의 분포까지 필요하면 $f_Y(y)=f_X((y-3)/2)/2=(y-3)^2/72(3<y<9).$

2.4.1 기댓값의 성질

- **[정리 2.6] 확률변수** X**의 함수에 대한 기댓값은 상수** $a,\ b,\ c$**에 대하여 다음과 같이 구해진다.**

$$E(c)=c, \qquad E(aX+b)=aE(X)+b$$

[증명] : [생략, P 56-57]

■ 기댓값의 확장. n개의 확률변수 $X_1,\cdots,X_n$의 함수 $g(X_1,\cdots,X_n)$의 기댓값은?

$$E[g(X_1,\cdots,X_n)]=\begin{cases}\sum\cdots\sum\limits_{\text{모든}x_1,\cdots,x_n} g(x_1,\cdots,x_n)f(x_1,x_2,\cdots,x_n)\\ \int_{-\infty}^{\infty}\cdots\int_{-\infty}^{\infty} g(x_1,\cdots,x_n)f(x_1,x_2,\cdots,x_n)dx_1\cdots dx_n\end{cases}$$

■ **기댓값의 성질(확장) - (증명 : 생략)**

1) $E(aX+bY)=aE(X)+bE(Y)$, (단, a, b는 상수)

2) $E(a_1X_1+\cdots+a_nX_n+b)=a_1E(X_1)+\cdots+a_nE(X_n)+b$,

(단, $a_1,\cdots,a_n$, b는 상수)

■ 다변수의 함수에 대한 기댓값 $Z=g(X,\ Y)$의 기댓값은?

$$E[g(X,\ Y)]=E[Z]=\begin{cases}\sum\limits_{\text{모든}z_i} z_i f_Z(z_i)\\ \int_{-\infty}^{\infty} z f_Z(z)dz\end{cases}', \qquad f_Z(z)\ :\ Z=g(X,\ Y)\text{의 pdf}$$

또는 $$E[g(X,\ Y)]=\begin{cases}\sum\limits_{\text{모든}x_i}\sum\limits_{\text{모든}y_i} g(x_i,y_i)f_{X,Y}(x_i,y_i)\\ \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} g(x,y)f_{X,Y}(x,y)dxdy\end{cases}'$$

[풀이]

결합밀도 f_(X,Y)가 주어지면 새로운 변수 $Z = g(X,Y)$ 의 분포를 따로 구하지 않아도 된다.

$E[g(X,Y)] = \sum_x \sum_y g(x,y) f_{X,Y}(x,y)$(이산형),

$E[g(X,Y)] = \int \int g(x,y) f_{X,Y}(x,y) dxdy$(연속형).

이는 Z의 분포를 먼저 구하여 $E(Z)$ 를 계산한 결과와 같다.

- [예제 2.19] (예제 2.11) 주머니에서 공 꺼내는 예제, $g(X,Y) = XY$

		X				Sum
		0	1	2	3	
Y	0	4/84	18/84	12/84	1/84	35/84
	1	12/84	24/84	6/84	0	42/84
	2	4/84	3/84	0	0	7/84
Sum		20/84	45/84	18/84	1/84	1

- $Z = XY$라 하면 Z의 pdf는? $E(Z) = ?$

[풀이]

$Z = XY$로 놓는다. $Z = 0, 1, 2$의 확률은 결합표에서

$$P(Z=0) = P(X=0 \text{ 또는 } Y=0) = \frac{51}{84},$$
$$P(Z=1) = P(X=1, Y=1) = \frac{24}{84},$$
$$P(Z=2) = P(X=1, Y=2) + P(X=2, Y=1) = \frac{9}{84}.$$

따라서 Z의 기댓값은

$$\boxed{E(Z) = 0 \cdot \frac{51}{84} + 1 \cdot \frac{24}{84} + 2 \cdot \frac{9}{84} = \frac{1}{2}.}$$

직접 $E(XY) = \sum_x \sum_y xy f_{X,Y}(x,y)$로 계산해도 같은 값이 나온다.

- 직접 $E(XY)$를 계산하면

■ (예) $f(x,y) = \frac{1}{2}, \quad \text{if } 0 < x < y < 2, \qquad g(X,Y) = XY$

[풀이]

$f(x,y) = 1/2(0 < x < y < 2)$ 라면 $E(XY) = \int_0^2 \int_0^y xy/2 dx dy$

$= (1/4) \int_0^2 y^3 dy = 1.$

주변밀도 $f_X(x) = (2-x)/2, f_Y(y) = y/2.$

$E(X) = \int_0^2 x(2-x)/2 dx = 2/3, E(Y) = \int_0^2 y^2/2 dy = 4/3.$

$E(X)E(Y) = 8/9 \neq E(XY) = 1$ 이므로 독립이 아니다 . $\text{Cov}(X,Y) = 1/9.$

- **[정리 2.7] 두 확률변수 X와 Y가 서로 독립이면 다음이 성립한다.**

$$E(XY) = E(X)E(Y)$$

확장 : $E[g(X)h(Y)] = E[g(X)]E[h(Y)]$

- **[증명] 생략(P 59)**

- (예제) $f(x,y) = \frac{1}{2}, \quad \text{if } 0 < x < y < 2, \; g(X,Y) = XY$

2.4.2 분산(Variance)과 공분산(Covariance)

- 확률변수 X의 변동을 나타내는 측도
- 확률변수가 기댓값으로부터 흩어진 정도 $[g(X) = [X - E(X)]^2$ 의 기댓값] $\rightarrow$ 분산, $Var(X)$, σ_X^2
- 표준편차(SD) : 분산의 양의 제곱근 값 $\sigma_X = \sqrt{Var(X)}$, $SD(X)$

- **[정의 2.8]** 확률변수 X의 흩어짐을 재는데 사용되는 분산과 표준편차는 다음과 같이 정의한다.

$$Var(X) = E[X - E(X)]^2 = E(X^2) - [E(X)]^{2,} \quad \sigma_X = \sqrt{Var(X)}$$

※ 참고사항 : 표준화(standardization) 변환

$$Z = \frac{X - E(X)}{\sigma_X}$$

- $E(Z) = 0, \quad Var(Z) = 1$

- **[정리 2.8] (분산의 성질)**

  (1) 확률변수 $X, \quad Y$에 대하여 $Y = aX + b$이면 $V(Y) = a^2 V(X)$이다.

  (2) 확률변수 $X_1, \cdots, X_n$가 서로 독립이면 $V(\sum_{i=1}^{n} X_i) = \sum_{i=1}^{n} V(X_i)$가 성립한다.

- **[증명]**

  [증명]

  (1) $Y = aX + b$이면 $E(Y) = aE(X) + b$이므로,

$$\begin{aligned} \text{Var}(Y) &= E[\{Y - E(Y)\}^2] \\ &= E[a^2\{X - E(X)\}^2] \\ &= a^2 \text{Var}(X). \end{aligned}$$

  (2) 일반적으로 분산의 합 공식은

$$\text{Var}\left(\sum_{i=1}^{n} X_i\right) = \sum_{i=1}^{n} \text{Var}(X_i) + 2\sum_{i<j} \text{Cov}(X_i, X_j).$$

  $X_1, \ldots, X_n$이 서로 독립이라면 공분산이 전부 0이므로,

$$\boxed{\text{Var}\left(\sum_{i=1}^{n} X_i\right) = \sum_{i=1}^{n} \text{Var}(X_i).}$$

- [예제 2.22] $f(x,y) = 3e^{-3x}e^{-y}, \quad 0 < x, y < \infty, \quad g(X,Y) = 3X + Y$의 분산은?

[풀이]

$f_{X,Y}(x,y) = 3e^{-3x}e^{-y}(x,y > 0)$ 이므로 $X \sim$ exp(rate3), $Y \sim$ exp(rate1) 이며 독립이다.

Var$(X) = 1/9$, Var$(Y) = 1$ 이고 Var$(3X+Y) = 9Var(X) +$ Var$(Y) = 1+1 = 2.$

- [예제] $f(x,y) = \frac{1}{2}, \quad \text{if } 0 < x < y < 2, \ V(X+Y) = V(X) + V(Y)$?

[풀이]

$0 < x < y < 2$에서 $f_{X,Y}(x,y) = 1/2$이므로 $E(X) = 2/3$, $E(Y) = 4/3$이고

$$E(X^2) = \frac{2}{3}, \quad E(Y^2) = 2, \quad E(XY) = 1.$$

이에 따라

$$V(X) = \frac{2}{3} - \left(\frac{2}{3}\right)^2 = \frac{2}{9},$$
$$V(Y) = 2 - \left(\frac{4}{3}\right)^2 = \frac{2}{9},$$
$$\text{Cov}(X,Y) = 1 - \frac{2}{3}\cdot\frac{4}{3} = \frac{1}{9}.$$

그러므로

$$\boxed{V(X+Y) = V(X) + V(Y) + 2\,\text{Cov}(X,Y) = \frac{2}{3}.}$$

독립이 아니므로 단순히 두 분산을 더하면 안 된다.

■ 공분산(Covariance)

- 두 확률변수 사이의 흩어진 관계를 측정하는 측도
- X와 Y가 선형적으로 함께 움직이는 정도를 표현해 주는 측도

- **[정의 2.9]** 두 확률변수의 공분산은 다음과 같이 정의된다.

$$Cov(X, Y) = E[(X - E(X))(Y - E(Y))] = E(XY) - E(X)E(Y)$$

(1) $Cov(X, X) = Var(X)$

(2) 두 확률변수가 독립이면 $Cov(X, Y) = 0$가 된다.

- **[정리 2.10] (공분산의 성질) 두 확률변수 X, Y의 공분산은 상수 a, b, c, d에 대하여 다음이 성립한다.**

$$Cov(aX + b, cY + d) = ac\,Cov(X, Y)$$

- **[증명] : [생략, P 64]**

- **[정리 2.11] (확률변수의 합의 분산 – 일반적인 경우)**

  확률변수 $X_1, \cdots, X_n$가 있을 때, 다음이 성립한다.

$$V(\sum_{i=1}^{n} X_i) = \sum_{i=1}^{n} V(X_i) + 2\sum\sum_{j<k} Cov(X_j, X_k)$$

- **[증명]**

[증명]

$S = \sum_{i=1}^{n} X_i, \mu_i = E(X_i)$ 로 두면

$\mathrm{Var}(S) = E[(\sum(X_i - \mu_i))^2]$

$= \sum E[(X_i - \mu_i)^2] + 2\sum_{i<j} E[(X_i - \mu_i)(X_j - \mu_j)]$

$= \sum \mathrm{Var}(X_i) + 2\sum_{i<j} \mathrm{Cov}(X_i, X_j).$

2.4.3 조건부 기댓값

- **[정의 2.10]** 조건부 확률변수 $Y|X = x$의 조건부 기댓값은 다음과 같이 정의된다.

$$E[Y|X = x] = \begin{cases} \sum_{\text{모든}\, y_i} y_i f_{Y|x}(y_i|x) \\ \int_{-\infty}^{\infty} y f_{Y|x}(y|x)dy \end{cases}$$

- [예제 2.23] $f_{X,Y}(x,y) = x^2 e^{-x(y+1)},\ x>0,\ y>0$

$$E[Y|X=x] = \int_0^\infty y f(y|x)dy$$

[풀이]

앞에서 $f_{Y|X}(y|x) = x\exp(-xy), y>0$ 을 구했다.

따라서 $E(Y|X=x) = \int_0^\infty yx\exp(-xy)dy = 1/x.$

적분을 부분적분하거나 매개변수가 x인 지수분포의 평균을 적용한다.

- 조건부 기댓값 $E[Y|X=x]$는 x에 대한 함수, $g(x) = E[Y|X=x]$

  - 확률변수 Y의 값에 대하여 조건부 확률과의 가중평균

- 만일 x 대신 확률변수 X를 사용한다면, $g(X) = E[Y|X]$도 확률변수가 됨.

- **[정리 2.11] (이중기대값 정리) 두 확률변수 $Y,\ X$에 대하여 다음이 성립한다.**

$$E[E(Y|X)] = E(Y), \qquad E[E(X|Y)] = E(X)$$

$$E[g(X,\ Y)] = E_X[E[g(X,Y)|X]$$

- **[증명]**

[증명]

이산형의 경우 $E[E(Y|X)] = \sum xE(Y|X=x)P(X=x)$

$= \sum x \sum yyP(Y=y|X=x)P(X=x)$

$= \sum yy \sum xP(X=x, Y=y) = \sum yyP(Y=y) = E(Y).$

연속형은 위의 합을 적분으로 바꾸어 동일하게 증명한다.

일반적인 g(X,Y)에 대해서도 $E[g(X,Y)] = E_X E[g(X,Y)|X]$ 이다.

- [예제 2.24] $f_{X,Y}(x,y) = \begin{cases} \frac{1}{2}, & 0 < x < y < 2 \\ 0, & otherwise \end{cases}$

$$f(x) = \int_x^2 1/2dy = \frac{1}{2}(2-x),\ 0 < x < 2$$

$$f(y) = \int_0^y 1/2dy = \frac{y}{2},\ 0 < y < 2$$

$$f(y|x) = \frac{f(x,y)}{f(x)} = \frac{1}{2-x}, \quad x < y < 2$$

$E(Y|X=x) =$

[풀이]

$f(x,y) = 1/2(0 < x < y < 2)$ 일 때 $f_X(x) = (2-x)/2$ 이므로

$f_{Y|X}(y|x) = [1/2]/[(2-x)/2] = 1/(2-x)(x < y < 2).$

$E(Y|X=x) = \int_x^2 y/(2-x)dy = (4-x^2)/[2(2-x)] = (x+2)/2.$

이중기댓값으로 $E(Y) = E[(X+2)/2] = (2/3+2)/2 = 4/3.$

- **[정리 2.12] 확률변수 X와 Y가 독립이면 다음이 성립한다.**

$$E(Y|x)] = E(Y), \qquad E(X|y) = E(X)$$

- **[증명]**

  [증명]

  X,Y 독립이면 $f_{Y|X}(y|x) = f_{X,Y}(x,y)/f_X(x) = f_Y(y)$.

  따라서 $E(Y|X=x) = \sum yyf_Y(y)$ 또는 $\int yf_Y(y)dy = E(Y)$ 이며, X에 무관하다.

  마찬가지로 $E(X|Y=y) = E(X)$.

※ 조건부 분산(conditional variance)

- **[정의 2.11]** $X=x$가 주어졌을 때, 확률변수 Y의 조건부 분산(conditional variance)은 다음과 같이 정의된다.

$$V(Y|x)] = E\left[\{Y-E(Y|x)\}^2|x\right] = E(Y^2|x) - [E(Y|x)]^2$$

- **[정리 2.13] (조건부 분산과 무조건부 분산) 두 확률변수 X, Y에 대하여 다음이 성립한다.**

$$V(Y) = E[V(Y|X)] + V[E(Y|X)]$$

- **[증명 : 생략] P 70**

2.4.4 확률부등식

- **[정리 2.14] (마코프 확률부등식) 실함수 $u(x) > 0$이라 할 때, 확률변수 X는 임의의 상수 $c > 0$에 대하여 다음을 만족한다.**

$$P[u(X) \geq c] \leq \frac{E[u(X)]}{c}$$

$u(x) = |x|^r \ (r > 0)$를 고려한다면 다음이 성립.

$$P[|X| \geq c] \leq \frac{E[|X|^r]}{c^r}$$

- **[증명]**

- **[정리 2.15] (체비셰프 부등식) 확률변수 X의 평균이 μ이고 분산이 $\sigma^2 < \infty$이면, 임의의 $k > 0$에 대하여 다음이 성립한다.**

[증명]

$Z = u(X) \geq 0$ 이라 두고 $c > 0$ 이라고 하자.

$E(Z) = E[Z1(Z < c)] + E[Z1(Z \geq c)] \geq cP(Z \geq c).$

따라서 $P(u(X) \geq c) \leq E[u(X)]/c.$

$u(X) = |X|^r$, 문턱값 c^r 을 대입하면 $P(|X| \geq c) \leq E|X|^r/c^r.$

$$P[|X-\mu| \geq k\sigma] \leq \frac{1}{k^2}$$

$$P[|X-\mu| < k\sigma] \geq 1 - \frac{1}{k^2}$$

- **[증명]**

- [예제 2.27] 확률변수 X의 평균이 25이고, 분산이 16이라 하자. X가 17과 33사이의 값을 가질 확률의 하한은?

- **[정리 2.16] (코시-쉬바르쯔 부등식) 두 확률변수 X, Y에 대하여 $E(X^2) < \infty$, $E(X^2) < \infty$가 만족된다면 다음이 성립한다.**

$$[E(XY)]^2 \leq E(X^2)E(Y^2)$$

등식은 어떤 상수 c에 대하여 $P(Y = cX) = 1$인 경우 성립한다.

- **증명 [생략, P 73]**

[증명]

마코프 부등식을 비음수 변수 $(X-\mu)^2$ 에 적용한다.

$P(|X-\mu| \geq k\sigma) = P((X-\mu)^2 \geq k^2\sigma^2)$

$\leq E[(X-\mu)^2]/(k^2\sigma^2) = \sigma^2/(k^2\sigma^2) = 1/k^2.$

여사건을 취하면 $P(|X-\mu| < k\sigma) \geq 1 - 1/k^2$ 이다.

[풀이]

표준편차 $\sigma = 4$ 이고 $17 \leq X \leq 33$ 은 $|X-25| \leq 8$, 즉 대략 2σ 이내이다.

체비셰프 부등식에서 $P(|X-25| < 8) \geq 1 - 1/2^2 = 3/4.$

따라서 [17,33]에 들어갈 확률의 보장된 하한은 0.75 이다.

Chap 2. 확률밀도함수 및 확률분포함수

2.5 이산형 확률분포

- 이산형 확률변수의 대표적인 확률분포

1) 베르누이 분포

- 실험의 결과가 오직 두 가지 가능한 결과("성공", "실패")만 나오는 시행. 성공의 확률이 p
  - ◇ 예) 동전던지기, 정책에 대한 찬성/반대 조사
- pdf는? 기댓값과 분산은?

[풀이]

X~Bernoulli(p)이면 $P(X=x)=p^x(1-p)^{1-x}(x=0,1).$

$E(X)=0(1-p)+1\cdot p=p, E(X^2)=p$ 이므로 Var$(X)=p-p^2=p(1-p).$

독립인 베르누이 변수 Xi의 합 $Y=\sum_{i=1}^{n}X_i \sim$ Bin$(n,p).$

$P(Y=k)=\binom{n}{k}p^k(1-p)^{n-k}, E(Y)=np,$ Var$(Y)=np(1-p).$

동전을 3번 공정하게 던질 경우 $E(Y)=3/2,$ Var$(Y)=3/4$ 이다.

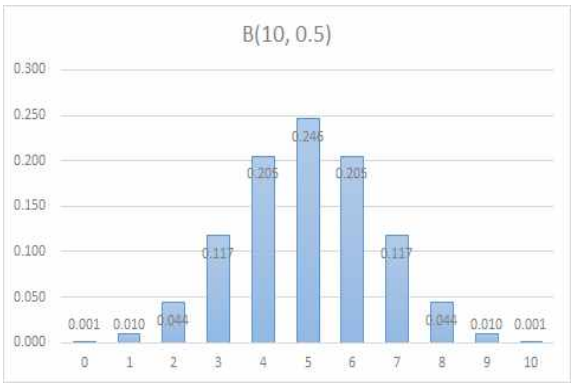
2) 이항분포 [베르누이 분포의 확장]

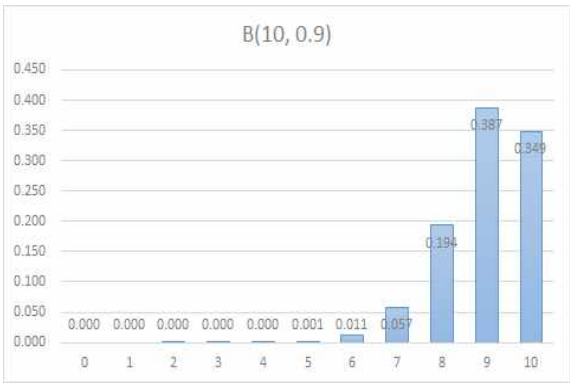
- 성공의 확률이 p인 베르누이 시행을 독립적으로 n번 반복 시행하였을 때 얻어지는 성공의 횟수 X. $X=\sum_{i=1}^{n}X_i \sim B(n,p)$

$$f(x)=\binom{n}{x}p^x(1-p)^{n-x},\ x=0,1,\cdots,n$$

- [예제 2.2] 동전 3번 던지는 실험에서 앞 면의 횟수 X

■ 기댓값과 분산은?





■ 이항분포의 확장 → 다항분포(Multinomial distribution)

■ 한 번의 실험(또는 관찰)에 있어서, $k(\geq 2)$개의 상호배반적인 사건 A_i가 관찰될 수 있는데, $\bigcup_{i=1}^{k} A_i = S$이며 $P(A_i) = p_i \ \ (i = 1, \cdots, k)$라고

[풀이]

(X1,X2,X3)~Multinomial(n;p1,p2,p3)라고 하자. 각 시행 j에서 범주 i의 지시변수를 I_(ji)로 두면 $X_i = \sum j I_{ji}$.

하나의 시행에서 $I_{j1} I_{j2} = 0, E(I_{j1}) = p1, E(I_{j2}) = p2$ 이므로

Cov$(I_{j1}, I_{j2}) = 0 - p1p2 = -p1p2$.

서로 다른 시행 간 공분산은 0. 따라서 Cov$(X_1, X_2) = -np1p2$.

각 Xi는 Bin(n,pi)을 따르므로 Var$(X_i) = npi(1 - pi)$ 이다.

가정하자.

■ 이런 실험을 n회 독립 반복시행했을 때 사건 A_i가 발생한 횟수를

X_i라 정의하면 $(X_1, X_2, \cdots, X_k) \sim Multi(n; p_1, p_2, \cdots, p_k)$라 정의.

■ joint pdf

$$f(x_1, \cdots, x_k) = \frac{n!}{x_1! \cdots x_k!} p_1^{x_1} \cdots p_k^{x_k}, \quad p_i > 0, \ \sum_{i=1}^{k} p_i = 1, \ \sum_{i=1}^{k} X_i = n$$

▪ (예제 2.31) $(X_1, X_2, X_3) \sim Multi(n; p_1, p_2, p_3)$, $Cov(X_1, X_2) = ?$

[P 77, conditional expectation, double expectation]

3) 포아송 분포

■ 단위시간동안 발생하는 어떤 특정 사건의 발생횟수에 대한 확률분포

■ 사건 A의 발생횟수는 다음과 같은 세 가지 성질이 성립

(1) $\lim_{h \to 0} P$(길이가 h인 구간내에서 사건 A가 1회 일어남)$/h = \lambda$

- 충분히 짧은 구간 h에서 한 번의 사건이 발생할 확률은 거의 λh이다.

(2) $\lim_{h \to 0} P$(길이가 h인 구간내에서 사건 A가 2회 일어남)$/h = 0$

- 충분히 짧은 구간 h에서 두 번 이상의 사건이 발생할 확률은 거의 0이다.

(3) 서로 겹치지 않는 두 구간내에서 사건 A의 발생횟수는 서로 독립

■ 구간 $[0, t]$를 n개의 부분구간으로 나눔.

$P[X(t) = x] = P[X(t) = x$이고 각 부분구간에서 1회 이하의 사건 A가 발생$]$

\+ $P[X(t) = x$이고 최소한 1개의 부분구간에서 2회 이상의 사건 A가 발생$]$

- [정의] $o\left(\frac{t}{n}\right)$: $n\to\infty$에 따라 $\frac{t}{n}$보다 빨리 0으로 수렴하는 수

- 특정 부분구간(t/n)에서 1회의 사건이 발생할 확률 $=\frac{\lambda t}{n}+o\left(\frac{t}{n}\right)$
- 특정 부분구간(t/n)에서 2회 이상의 사건이 발생할 확률 $=o\left(\frac{t}{n}\right)$

■ $P[X(t)=x$이고 각 부분구간에서 1회 이하의 사건 A가 발생]

= $P[x$개의 부분구간에서 꼭 1회씩 사건이 발생하고 나머지 $(n-x)$개의 부분구간에서는 사건 A가 발생하지 않음]

$$= \binom{n}{x}\left[\frac{\lambda t}{n}+o\left(\frac{t}{n}\right)\right]^x\left[1-\frac{\lambda t}{n}-o\left(\frac{t}{n}\right)\right]^{n-x}$$

$$\to \frac{\exp(-\lambda t)(\lambda t)^x}{x!}, \quad as\ n\to\infty$$

■ $P[X(t)=x$이고 최소한 1개의 부분구간에서 2회 이상의 사건 A가 발생]

$\le P$[최소 1개의 부분구간에서 2회 이상 발생]

$=P[\bigcup_{i=1}^{n} i$번째 부분구간에서 2회 이상 발생]

$$\le \sum_{i=1}^{n} P[i\text{번째 부분구간에서 2회 이상 발생}] = n\,o\left(\frac{t}{n}\right)$$

$$\to 0 \quad as \quad n\to\infty$$

- $P[X(t)=x]$는 부분구간의 개수에 상관없이 같은 값을 갖으며,

$P[X(t)=x]=\binom{n}{x}\left[\frac{\lambda t}{n}+o\left(\frac{t}{n}\right)\right]^x\left[1-\frac{\lambda t}{n}-o\left(\frac{t}{n}\right)\right]^{n-x}+\ n\,o\left(\frac{t}{n}\right)$이 되므로,

$n\to\infty$일 때의 극한값을 $P[X(t)=x]$로 볼 수 있다.

- 또한 $n \to \infty$ 일 때 $\binom{n}{x}\left[\frac{\lambda t}{n}+o\left(\frac{t}{n}\right)\right]^x\left[1-\frac{\lambda t}{n}-o\left(\frac{t}{n}\right)\right]^{n-x}$의 극한은 $\frac{\exp(-\lambda t)(\lambda t)^x}{x!}$이고 [정리 2.17 참조], $n\, o\left(\frac{t}{n}\right)$의 극한은 0이 되므로, 확률변수 $X(t)$의 pdf는 다음과 같이 구해진다.

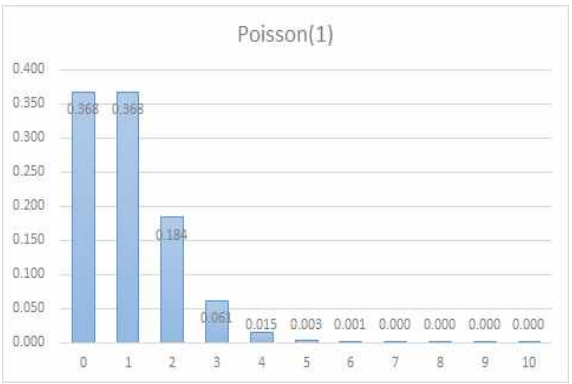
$$f(x)=\frac{\exp(-\lambda t)(\lambda t)^x}{x!},\ x=0,1,2,\cdots$$

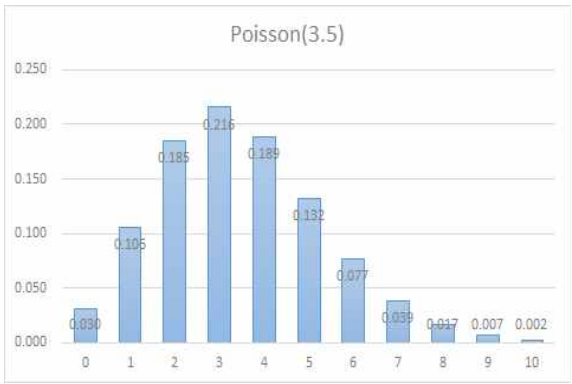
- 만일 $t=1$인 경우, X를 발생건수라 정의하면 $X \sim POI(\lambda)$로 표기함.

$$f(x)=\frac{\exp(-\lambda)\lambda^x}{x!},\ x=0,1,2,\cdots$$

- 기댓값과 분산은?

- $X \sim POI(\lambda)$인 경우



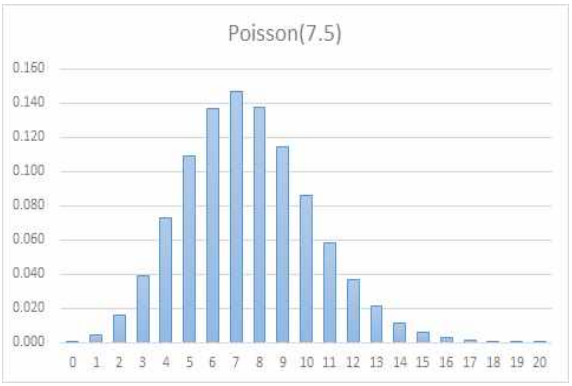


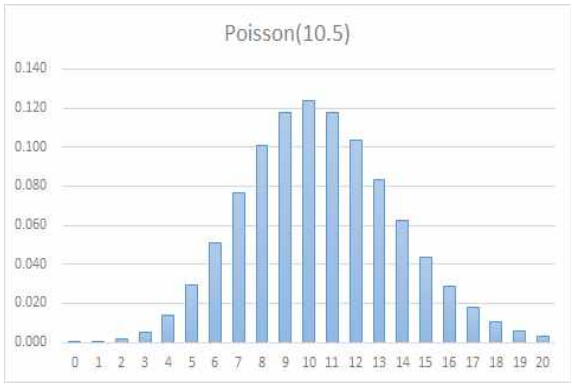
[풀이]

$X \sim$ Poi(λ) 이면 $P(X=x) = e^{-\lambda}\lambda^x/x!(x=0,1,\cdots).$

$E(X) = \sum_{x\geq 1} xe^{-\lambda}\lambda^x/x! = \lambda\sum_{x\geq 1} e^{-\lambda}\lambda^{x-1}/(x-1)! = \lambda.$

$E[X(X-1)] = \lambda^2$ 이므로 $E(X^2) = \lambda^2+\lambda,$ Var$(X) = \lambda.$





- [예제 2.32] 매분 평균적으로 2건의 전화. 3분동안 5번이상의 통화가

[풀이]

1분 평균 2건인 포아송 과정에서 3분간 건수 $N \sim$ Poi$(6).$

$P(N \geq 5) = 1 - P(N \leq 4)$

$= 1 - e^{-6}1 + 6 + 6^2/2! + 6^3/3! + 6^4/4!$

$= 1 - 115e^{-6} \approx 0.71494.$

이루어질 확률은?

- **[정리 2.17] 이항분포의 포아송분포 근사**

  확률변수 X가 $B(n,\ p)$분포를 따른다고 하자. 이때 n이 커짐에 따라 p가 0으로 수렴하되 $np=\lambda$를 만족하면, $x=0,1,2,\cdots$에 대하여 다음이 성립한다.

$$\lim_{n\to\infty}\binom{n}{x}p^x(1-p)^{n-x} = \frac{\exp(-\lambda)\lambda^x}{x!}$$

- **[증명]**

[증명]

$p = \lambda/n$ 으로 놓으면 고정된 자연수 x에 대해

$P(X = x) = \binom{n}{x}(\lambda/n)^x(1 - \lambda/n)^{n-x}$

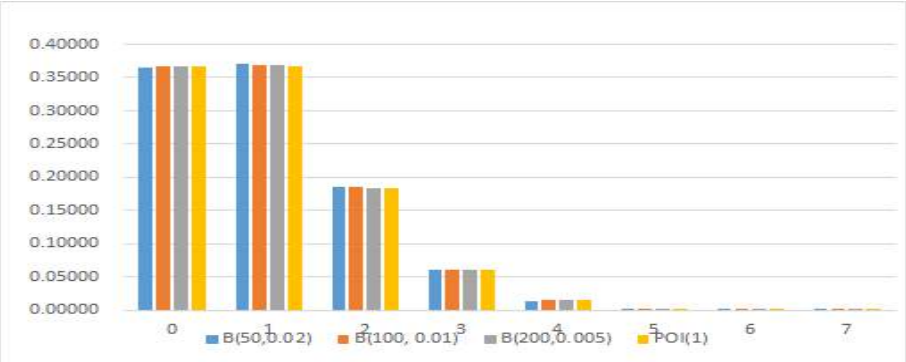
$= [n(n-1)\cdots(n-x+1)/n^x] \cdot (\lambda^x/x!) \cdot (1 - \lambda/n)^n \cdot (1 - \lambda/n)^{-x}.$

$n \to \infty$ 에서 앞의 곱은 1, 세 번째는 $e^{-\lambda}$, 마지막은 1로 수렴한다.

따라서 $P(X = x) \to e^{-\lambda}\lambda^x/x!$ 이다.

- [예제 2.33] 이항분포의 포아송 근사

x	B(50,0.02)	B(100, 0.01)	B(200,0.005)	POI(1)
0	0.36417	0.36603	0.36696	0.36788
1	0.37160	0.36973	0.36880	0.36788
2	0.18580	0.18486	0.18440	0.18394
3	0.06067	0.06100	0.06116	0.06131
4	0.01455	0.01494	0.01514	0.01533
5	0.00273	0.00290	0.00298	0.00307
6	0.00042	0.00046	0.00049	0.00051
7	0.00005	0.00006	0.00007	0.00007
계	0.99999	0.99999	0.99999	0.99999



[풀이]

교재 예 2.33 은 $\lambda = np = 1$ 을 고정하여 $(n,p) = (50, 0.02), (100, 0.01), (200, 0.005)$ 를 비교한다.

예를 들어 $P_Bin(X=0) = (1-1/n)^n$ 은 각각 약 $0.36417, 0.36603, 0.36696$ 이고,

$P_Poi(1)(X=0) = e^{-1} \approx 0.36788$ 이다.

$P(X=1) = n(1/n)(1-1/n)^{n-1}$ 도 n이 커질수록 e^{-1} 에 접근한다.

일반적으로 n이 크고 p가 작을수록 근사가 개선되지만 정확도는 x, λ 에도 의존한다.

4) 기하분포

- 성공의 확률이 p인 베르누이 시행을 독립적으로 반복할 때, 첫 번째 "성공"이 발생할 때까지 걸리는 시행횟수를 X라 하면 X의 pdf.

$$f(x) = p(1-p)^{x-1}, \ x = 1,2,\cdots \quad \rightarrow \quad X \sim GEO(p)$$

- 기댓값과 분산은?

- **[정리 2.18] [기하분포의 무기억성질(memoryless property)], $X \sim GEO(p)$이면, 임의의 자연수 j, k에 대하여 다음이 성립한다.**

$$P(X > j+k | X > j) = P(X > k)$$

[풀이]

$X \sim$ Geo(p)(성공할 때까지의 시행 횟수 , $X = 1, 2, \cdots$) 라면 $q = 1 - p$ 를 써서

$P(X = x) = pq^{x-1}, E(X) = \sum_{x \geq 1} xpq^{x-1} = 1/p.$

$E[X(X-1)] = 2q/p^2$ 이므로 Var$(X) = E[X(X-1)] + E(X) - [E(X)]^2$

$= 2q/p^2 + 1/p - 1/p^2 = q/p^2 = (1-p)/p^2.$

- **[증명]**

[증명]

$P(X > m) = q^m (m = 0, 1, 2, \cdots)$ 이므로

$P(X > j + k | X > j) = P(X > j + k)/P(X > j)$

$= q^{j+k}/q^j = q^k = P(X > k).$

이 식은 j번의 실패가 발생한 뒤에도 앞으로 k번 더 실패할 확률이 처음부터 k번 실패할 확률과 같다는 뜻이다.

5) 음이항분포(negative binomial dist.)

- 성공의 확률이 p인 베르누이 시행을 독립적으로 반복할 때, r개의 "성공"을 얻을 때까지 필요한 시행횟수를 X라 하면 X의 pdf.

$$f(x; r, p) = \binom{x-1}{r-1} p^r (1-p)^{x-r}, \quad x = r, r+1, \cdots \quad \rightarrow \quad X \sim NB(r, p)$$

- 음이항분포 : r개의 서로 독립인 기하분포를 따르는 확률변수의 합

  - $X_1, \cdots, X_r \sim_{iid} GEO(p), \quad X = X_1 + \cdots + X_n \sim NB(r, p)$

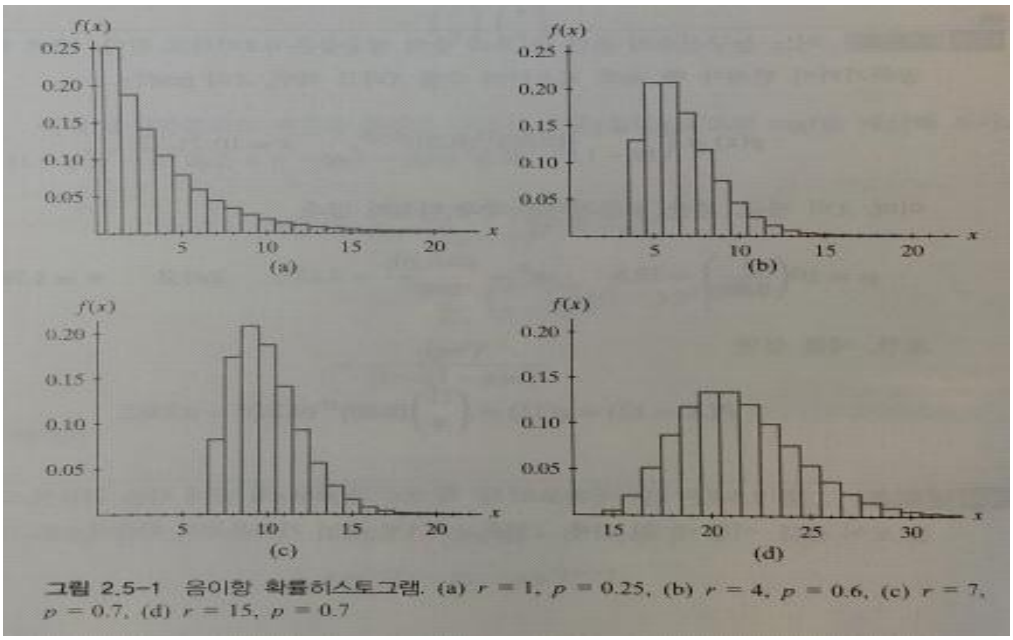


그림 2.5-1 음이항 확률히스토그램. (a) $r = 1$, $p = 0.25$, (b) $r = 4$, $p = 0.6$, (c) $r = 7$, $p = 0.7$, (d) $r = 15$, $p = 0.7$

- 음이항 분포의 평균과 분산 :

[풀이]

$X \sim$ NB(r, p) 를 r번째 성공을 얻을 때까지의 총 시행횟수로 정의하자.

$X = X_1 + \cdots + Xr(X_i$ 는 독립인 Geo(p))로 표현할 수 있다.

$E(X) = \sum E(X_i) = r/p, \text{Var}(X) = \sum \text{Var}(X_i) = r(1-p)/p^2.$

X의 확률질량함수는 $P(X = x) = C(x-1, r-1)p^r(1-p)^{x-r}, x = r, r+1, \cdots$ 이다.

2.6 연속형 확률분포

- 연속형 확률변수의 대표적인 확률분포
- 균일분포, 지수분포, 정규분포, 감마분포, 베타분포...

1) 균일(Uniform)분포

- 확률변수 X가 실구간 (a, b)상에 균일(uniform)하게 분포되어 있을 때 그의 pdf는 다음과 같음.

$$f(x) = \begin{cases} \frac{1}{b-a}, & a \le x \le b\text{인 경우} \\ 0 & otherwise \end{cases}$$

- CDF

$$f(x) = \begin{cases} 0 & x < a\text{인 경우} \\ \frac{x-a}{b-a}, & a \le x < b\text{인 경우} \\ 1 & x \ge b\text{인 경우} \end{cases}$$

- 기대값과 분산은?

[풀이]

$f(x) = 1/(b-a)(a < x < b).E(X) = (a+b)/2.$

$E(X^2) = \int_a^b x^2/(b-a)dx = (a^2+ab+b^2)/3.$

따라서 Var$(X) = E(X^2) - [E(X)]^2 = (b-a)^2/12.$

누적분포함수 표기의 'f'는 해당 페이지에서 'F'로 이해하면 된다.

2) 지수분포(exponential dist.)

- 포아송 확률변수를 고려할 때, 특정한 사건 A가 일어나고 난 다음 또 다시 같은 사건이 일어날 때까지 걸리는 시간 W를 고려하면, W는 음이 아닌 값을 갖는 연속형 확률변수임.
- $X(w)$: $[0,w)$ 구간에서 발생한 사건의 수, $X(w) \sim P(\lambda w)$
- W의 CDF [평균발생건수가 λ인 포아송 과정을 고려], $w \ge 0$

$$F(w) = P(W \le w) = 1 - P(W > w)$$

$$= 1 - P[\text{구간}[0, w)\text{에서 사건 } A\text{가 일어나지 않음}]$$

$$= 1 - P[X(w) = 0]$$

$$= 1 - \exp(-\lambda w)$$

- W의 PDF

$$f_W(w) = \lambda exp(-\lambda w),\ w > 0 \qquad \text{(A)}$$

- $\theta = 1/\lambda$라는 모수변환을 하여 구한 지수분포 $[X \sim exp(\theta)]$

$$f(x) = \frac{1}{\theta}\exp(-x/\theta),\ x > 0 \qquad \text{(B)}$$

- $X \sim exp(\theta)$일 때
  - $E(X) = \theta, \quad V(X) = \theta^2$ **: [check !! p 91]**

■ 덧붙임

- 지수분포의 형태로 (A)와 (B) 둘 모두 사용됨.
- 단위구간내에서 평균발생횟수가 λ인 포아송 과정의 사건 사이의 소요시간의 평균은 $\theta = \frac{1}{\lambda}$가 됨.
- 포아송 분포에서 λ가 크면 특정사건의 발생횟수가 평균적으로 많아지는 반면, 특정사건 사이의 소요시간은 작아짐.
- 포아송 확률변수의 모수 λ와 지수 확률변수의 평균인 모수 θ는 역의 관계

- **[정리 2.19] [지수분포의 무기억 성질(memoryless property)]**
  $X \sim EXP(\theta)$이면, 양의 실수 a와 t에 대하여 다음이 성립한다.

$$P(X > a + t \mid X > a) = P(X > t)$$

- 시점 a까지 기계부품의 고장이 없을 때, 최소한 t시간 만큼 고장이 없을 확률이 시점 t까지 기계부품의 고장이 없을 확률과 같음.

- 확률변수 X가 시점 a에서 고장이 없다는 조건을 기억하지 않고, 앞으로 시점 t까지 고장이 없을 것만 고려함.

[풀이]

$X \sim \exp(\theta)(\theta$ 는 평균, 생존함수 $P(X > t) = e^{-t/\theta})$ 이면

$P(X > a + t | X > a) = e^{(} - (a + t)/\theta)/e^{-a/\theta}$

$= e^{-t/\theta} = P(X > t).$

이와 같이 사건이 발생하지 않은 경과시간이 추가 대기시간의 분포에 영향을 주지 않는다.

3) 정규분포(normal dist.)

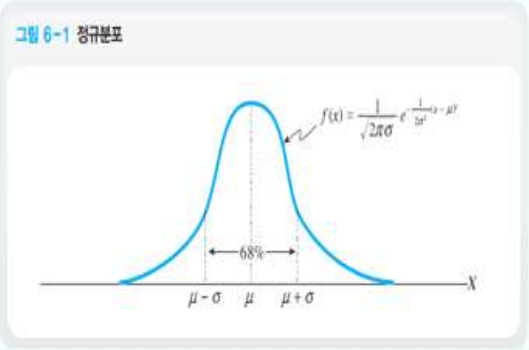
- 통계학에서 가장 많이 활용되는 확률분포
  - 중심극한정리, 정규분포로부터 파생되는 확률분포(카이제곱, t, F)

- 확률변수 X의 pdf [$X \sim N(\mu, \sigma^2)$]

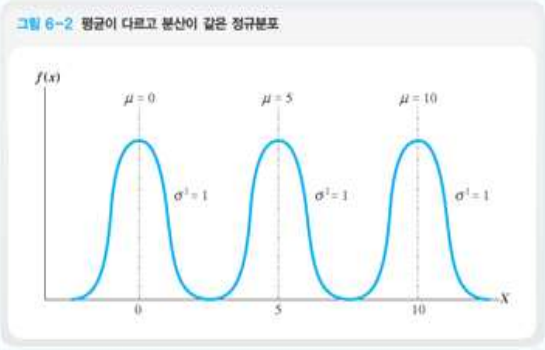
$$f(x) = \frac{1}{\sqrt{2\pi\sigma}} \exp\left[- \frac{(x-\mu)^2}{2\sigma^2} \right], \quad -\infty < x < \infty$$

- 다양한 정규분포의 모습

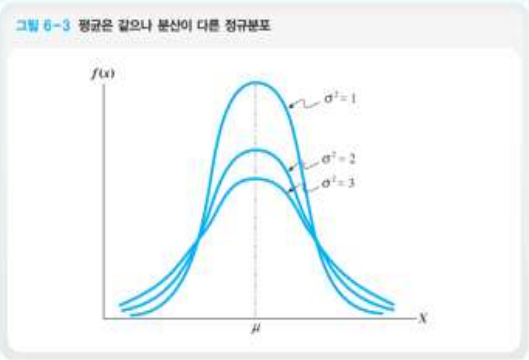
① 정규분포의 일반적 형태



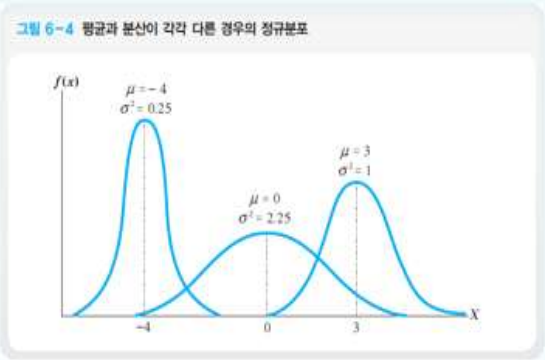
② 평균이 다르고 분산이 같은 정규분포



③ 평균은 같으나 분산이 다른 정규분포



④ 평균과 분산이 각각 다른 경우의 정규분포



- **정규분포의 성질**
  - 평균을 중심으로 대칭인 종 모양의 모습
  - 평균중심으로 확률의 밀집이 크고 평균에서 멀리 떨어질수록 확률의 밀집정도가 낮다.

■ 정규분포의 중요한 특징

- 정규확률변수는 선형변환을 하여도 역시 정규분포를 따름.
- $X \sim N(\mu, \sigma^2)$일 경우, $Y = aX + b (a > 0, b$는 상수)와 같은 선형변환을 하는 경우 $Y \sim N(a\mu + b, a^2\sigma^2)$를 따름. **[p 93-94] check!! 또는 추후 MGF 이용**

■ 표준정규분포(Standard Normal dist.)

- 평균이 0, 표준편차가 1인 정규분포
- $X \sim N(\mu, \sigma^2)$일 경우, 다음과 같은 표준화 변환을 통해 항상 표준정규분포를 얻을 수 있음.

$$Z = \frac{X-\mu}{\sigma} \sim N(0, 1)$$

- 또는 $Z \sim N(0, 1) \rightarrow X = \sigma Z + \mu \sim N(\mu, \sigma^2)$

- 표준정규분포의 pdf $[Z \sim N(0, 1)]$

$$f(z) = \frac{1}{\sqrt{2\pi}} \exp\left[-\frac{z^2}{2}\right], \quad -\infty < z < \infty \quad \rightarrow \phi(z)$$

- $\phi(z)$가 pdf인가?

1) $\phi(z) > 0$?, $\quad -\infty < z < \infty$

2) $\int_{-\infty}^{\infty} \phi(z)dz = 1$? $\quad \rightarrow$ **극좌표변환이용 (2.7장의 결합변환)**

[풀이]

$I = \int_{-\infty}^{\infty} \exp(-z^2/2)dz$ 라 하자. 그러면

$I^2 = \int\int$

$exp[-(x^2+y^2)/2]dxdy.$

극좌표 $(x, y) = (rcos\varphi, rsin\varphi), |J| = r$ 로 바꾸면

$I^2 = \int_0^{2\pi} \int_0^{\infty} e^{-r^2/2} r dr d\varphi = 2\pi.$

따라서 $I = \sqrt{2\pi}$ 이고 $\varphi(z) = (1/\sqrt{2\pi})e^{-z^2/2}$ 는 전체 적분이 1이다.

■ $X \sim N(\mu, \sigma^2)$일 때 기댓값과 분산은? **[check!! p95, 2.8 MGF이용]**

- $E(X) = \int_{-\infty}^{\infty} x \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right] dx$

$= \int_{-\infty}^{\infty} (\mu + \sigma z)\phi(z) dz \quad [(x-\mu)/\sigma = z\text{로 치환}]$

$= \mu \int_{-\infty}^{\infty} \phi(z) dz + \sigma \int_{-\infty}^{\infty} z\phi(z) dz$

$= \mu$

- $V(X) = E(X^2) - [E(X)]^2 = \sigma^2$

■ 표준정규분포의 누적분포

$$\Phi(z) = P(Z \le z) = \int_{-\infty}^{z} \phi(t) dt$$

- p 479 <표 3> 표준정규분포표

(예) $P[-1.25 < Z < 2.5] = \Phi(2.5) - \Phi(-1.25)$

$= 0.9938 - 0.1056 = 0.8882$

- $\phi(z)$가 0에 대하여 대칭이므로 $\Phi(z) = 1 - \Phi(-z)$가 성립

- **[정리 2.20]** $X \sim N(\mu, \sigma^2)$**이면** X**의 CDF는 다음과 같다.**

$$F(x) = \Phi\left(\frac{x-\mu}{\sigma}\right)$$

- **[증명 : 생략, P 96]**

[풀이]

$X = \mu + \sigma Z, Z \sim N(0,1)$ 이므로 $E(X) = \mu + \sigma E(Z) = \mu.$

$E(Z) = 0$ 은 표준정규밀도의 대칭성으로 얻는다.

$E(Z^2) = \int z^2 \varphi(z) dz = 1$(부분적분으로 확인), 따라서

$\mathrm{Var}(X) = \mathrm{Var}(\mu + \sigma Z) = \sigma^2 \mathrm{Var}(Z) = \sigma^2.$

4) 감마분포(gamma dist.)

- **[정의 2.13]** $\Gamma(k)$로 표기되는 감마함수는 다음과 같이 정의된다.

$$\Gamma(k) = \int_0^\infty t^{k-1} e^{-t} dt, \qquad (k > 0)$$

- **감마함수의 성질**

1) $\Gamma(1) = \int_0^\infty e^{-t} dt = 1$

2) $\Gamma(k) = (k-1)\Gamma(k-1), \qquad (k > 1)$

3) $\Gamma(n) = (n-1)!, \qquad (n$은 자연수)

4) $\Gamma\left(\frac{1}{2}\right) = \sqrt{\pi}$

- **감마확률변수의 pdf** $[X \sim GAM(k, \theta)]$

$$f(x\,;\theta,k) = \frac{1}{\theta^k \Gamma(k)} x^{k-1} \exp(-x/\theta), \quad x > 0,\ \theta > 0, k > 0$$

  - $\int f(x)dx$=1 ? **[check!! 변수변환 ($y = x/\theta$)을 이용하여]**

■ 다양한 모수값에 따른 감마분포의 모습 $[\alpha = k]$

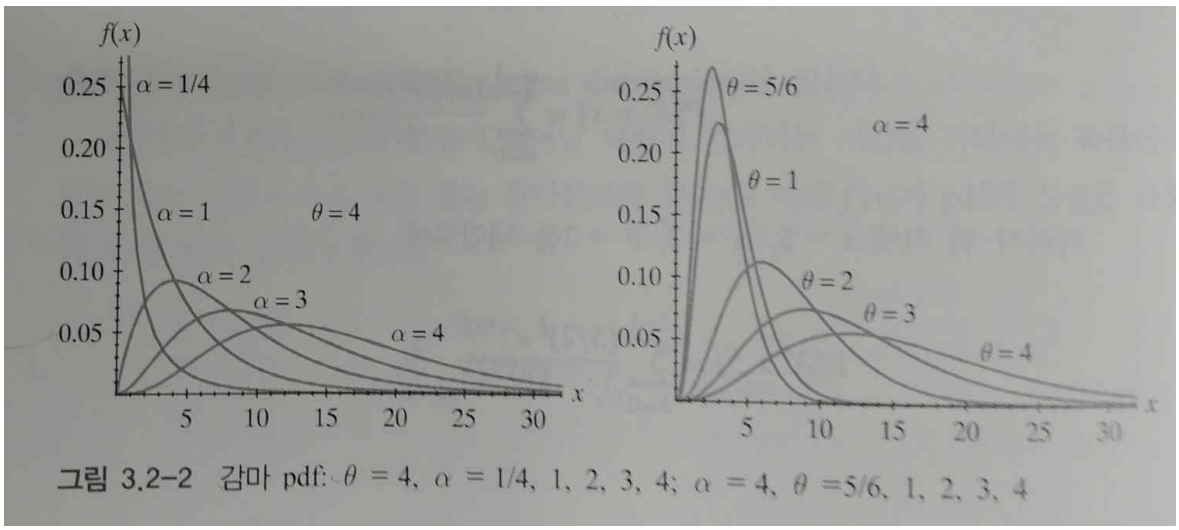


그림 3.2-2 감마 pdf: $\theta = 4$, $\alpha = 1/4, 1, 2, 3, 4$; $\alpha = 4$, $\theta = 5/6, 1, 2, 3, 4$

[풀이]

$X \sim$ Gamma$(k, \theta)(shapek, scale\theta)$,

$f(x) = x^{k-1}e^{-x/\theta}/(\Gamma(k)\theta^k), x > 0.$

$u = x/\theta$ 를 대입하면 $\int_0^\infty f(x)dx = [1/\Gamma(k)] \int_0^\infty u^{k-1}e^{-u}du = 1.$

$E(X^r) = \theta^r\Gamma(k + r)/\Gamma(k)$, 특히 $E(X) = k\theta$,

Var$(X) = k\theta^2(E(X^2) = k(k + 1)\theta^2$ 을 이용).

■ 감마확률변수의 기대값과 분산 [P 100]

■ **감마분포의 특성**

- $k=1$인 경우 $GAM(1,\theta) \rightarrow \exp(\theta)$
- 평균이 λ인 포아송 분포에서 특정한 사건이 k번 발생할 때까지 걸리는 시간 W, W의 확률분포는? 감마분포를 따름.

- W의 cdf

$$F(w) = P(W \le w) = 1 - P(W > w)$$

$$= 1 - P[\text{구간}[0,w)\text{에서 } k\text{개보다 작은 개수의 사건이 발생}]$$

$$= 1 - \sum_{t=0}^{k-1} \frac{(\lambda w)^t e^{-\lambda w}}{t!}$$

[풀이]

사건 발생률이 λ 이면 $N(w) \sim$ Poi(λw).k 번째 사건 시각 Wk에 대해

$P(Wk \le w) = P(N(w) \ge k) = 1 - e^{-\lambda w} \sum_{j=0}^{k-1} (\lambda w)^j / j!$.

이를 w에 대해 미분하면

$f_W k(w) = \lambda^k w^{k-1} e^{-\lambda w} / (k-1)! (w > 0)$.

따라서 $Wk \sim$ Gamma$(k, 1/\lambda)$, 평균 k/λ, 분산 k/λ^2 이다.

- $X_1, \cdots, X_k \sim_{iid} \exp(\theta), \quad Y = X_1 + \cdots + X_n \sim GAM(k, \theta)$

5) 베타분포(beta dist.)

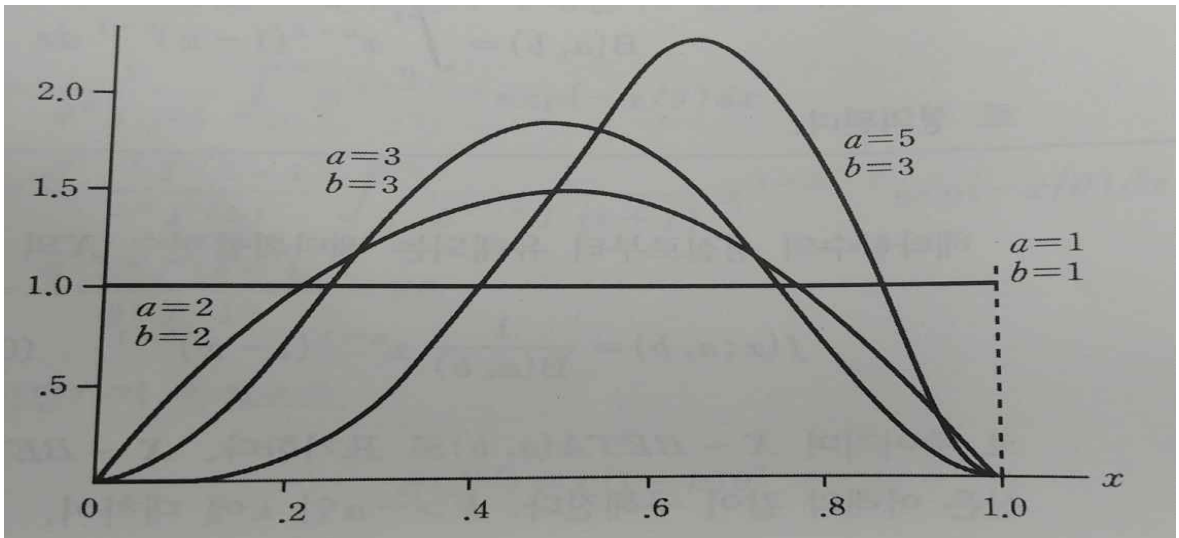
- 구간 (0, 1)상의 연속형 확률변수의 분포

- **[정의 2.14]** $B(a, b)$**로 표기되는 베타함수(beta function)은 다음과 같이 정의된다.**

$$B(a, b) = \int_0^1 x^{a-1}(1-x)^{b-1} dx = \frac{\Gamma(a)\Gamma(b)}{\Gamma(a+b)}$$

- **베타확률변수의 pdf [**$X \sim BETA(a, b)$**]**

$$f(x; a, b) = \frac{1}{B(a, b)} x^{a-1}(1-x)^{b-1}, \quad 0 < x < 1$$



▸ 그림 2.5 ◂ $X \sim BETA(a, b)$의 확률밀도함수

- 베타확률변수의 기댓값

$E(X^k) =$

[풀이]

$X \sim Beta(a, b)$ 이면

$E(X^r) = \int_0^1 x^{a+r-1}(1-x)^{b-1}/B(a,b)dx$

$= B(a+r, b)/B(a,b) = \Gamma(a+r)\Gamma(a+b)/[\Gamma(a)\Gamma(a+b+r)].$

특히 $E(X) = a/(a+b), E(X^2) = a(a+1)/[(a+b)(a+b+1)].$

따라서 Var$(X) = ab/[(a+b)^2(a+b+1)].$

5) 그 밖의 연속형 확률분포들

■ 와이블 분포

$$f(x\,;\theta,\,\beta) = \frac{\beta}{\theta^\beta}x^{\beta-1}\exp[-(x/\theta)^\beta], \quad x>0,\ \beta>0,\ \theta>0$$

- 공학이나 생물통계 등에서 많이 사용
- β : 형태(shape)모수

■ **코쉬분포(Cauchy dist)**

$$f(x\,;\alpha,\,\beta)=\frac{1}{\pi\beta\left[1+\{(x-\alpha)/\beta\}^2\right]},\qquad -\infty<x<\infty,\ \beta>0,\ -\infty<\alpha<\infty$$

- α에 대하여 대칭이지만 평균과 그 이상의 적률이 존재하지 않음

■ **log-normal, double exponential, logistic,...**

Chap 2. 확률밀도함수 및 확률분포함수 Part 3

2.7 확률변수들의 함수

- 관심사항이 확률변수 X뿐 아니라 $Y=g(X)$에 있는 경우, 예들 들어 두 확률변수 X와 Y를 구했을 때, 그들의 합 $Z=g(X,\ Y)=X+Y$의 분포를 알고자 함.
- 섭씨로 측정한 온도(X)의 분포가 주어졌을 때, 화씨($Y=9X/5+32$)의 분포는?
- 특히 4장 이후 다루게 될 통계적 추론에서는 실험이나 관측에서 얻은 확률변수들의 함수의 분포를 알아야 함.

[풀이]

X가 공정한 주사위의 눈(1,…,6)이라면 $Y=(X-3)^2$ 의 값은

$X=1\rightarrow 4, X=2\rightarrow 1, X=3\rightarrow 0, X=4\rightarrow 1, X=5\rightarrow 4, X=6\rightarrow 9.$

그러므로 $P(Y=0)=1/6, P(Y=1)=2/6, P(Y=4)=2/6, P(Y=9)=1/6.$

서로 다른 X값이 동일한 Y를 만드는 경우에는 확률을 합한다.

[1] 확률변수 X가 이산형인 경우

(1) **이산형 확률변수가 1개인 경우의 변수변환** : 간단히 직접 대입하는 방법으로 $Y=g(X)$의 분포를 구할 수 있음.

- $f_Y(y_i)=P(Y=y_i)=P[g(X)=y_i]=\sum_{\{i:g(x_i)=y_i\}} P(X=x_i)$
  - □ 주사위를 던져 나온 눈을 X : $Y=(X-3)^2$의 확률분포는?

(2) **이산형 확률변수의 결합변환** [P 108-110]

- n차원 이산형 확률벡터 $\underline{X}=(X_1,\cdots,X_n)$의 변환된 $k(\leq n)$개의 확률변수 $Y_1=g_1(X_1,\cdots,X_n),\cdots,Y_k=g_k(X_1,\cdots,X_n)$이 존재함.

  $\rightarrow$ $\underline{Y}=g(\underline{X})$

[정리 2.24] 이산형 확률벡터 $\underline{X}$의 pdf를 $f(\underline{x})$라 했을 때, $Y=g(\underline{X})$가 1:1 변환이면 확률벡터 $\underline{Y}$의 joint pdf는 다음과 같이 구해진다.

$$f_{\underline{Y}}(y_1,\cdots,y_n)=f_{\underline{X}}(x_1,\cdots,x_n)$$

여기서 $x_1,\cdots,x_n$은 $\underline{y}=g(\underline{x})$의 해로써 $y_1,\cdots,y_n$에 의존함.

[증명] $Y=g(\underline{X})$가 1:1 변환이므로 자명함.

- **[예제 2.43]**

(x_1,x_2)	(0, 0)	(0, 1)	(1,0)	(1, 1)
$f(x_1,x_2)$	1/4	1/4	1/4	1/4

[A] $Y_1=g_1(X_1,X_2)=X_1+X_2,\quad Y_2=g_2(X_1,X_2)=X_1-X_2$

- $\underline{Y}=g(\underline{X})$가 1 : 1 변환
- $f_{Y_1,Y_2}(0,0)=f_{X_1,X_2}(0,0)=1/4$,...

[B] $Y_1=g_1(X_1,X_2)=X_1+X_2,\quad Y_2=g_2(X_1,X_2)=X_1X_2$

[풀이]

X1,X2는 각 0 · 1을 가지며 네 조합의 확률이 각각 $1/4$ 이다.

$Y_1 = X_1 + X_2, Y_2 = X1X2$ 로 변환하면

$(X_1, X_2) = (0,0) \to (Y_1, Y_2) = (0,0) : 1/4;$

(0,1) 또는 $(1,0) \to (1,0)$: 합계 $1/2;$

$(1,1) \to (2,1) : 1/4.$

이는 일대일 변환이 아니므로 같은 결과값으로 가는 원래 사건들의 확률을 합한다.

- $\underline{Y} = g(\underline{X})$가 1 : 1 변환이 아님. 어떻게?

■ 만일 $\underline{Y} = g(\underline{X})$가 1 : 1 변환이 아니라면?

□ 간단히 직접 대입하는 방법으로 $P[Y_1 = y_1, Y_2 = y_2]$를 계산할 수 있음

[풀이]

$Y = (9/5)X + 32$ 는 단조증가 함수이고 역함수는 $X = 5(Y - 32)/9$ 이다.

$F_Y(y) = F_X(5(y-32)/9), f_Y(y) = (5/9) f_X(5(y-32)/9).$

$E(Y) = (9/5)E(X) + 32, \mathrm{Var}(Y) = (9/5)^2 \mathrm{Var}(X).$

[B] $Y_1 = g_1(X_1, X_2) = X_1 + X_2, \qquad Y_2 = g_2(X_1, X_2) = X_1 X_2$

[2] 확률변수 X가 연속형인 경우

2.7.1 단일변수에 대한 함수변환 [누적분포함수를 이용하는 방법]

- 확률변수 X가 연속형인 경우, X가 CDF $F_X(x)$를 갖으며, $Y=g(X)$의 확률분포에 관심이 있음.
  - 영역 $\{Y=g(X)\le y\}$를 $\{X\in R_y\}$, 단 $R_y=\{x\,;g(x)\le y\}$라 하면 Y의 CDF는 다음과 같이 구해짐.

$$F_Y(y)=P[g(X)\le y]=P[X\in R_y]$$

  - $P[X\in R_y]$는 X의 CDF $F_X(x)$를 이용하여 구할 수 있음.
  - 따라서 Y의 CDF $F_Y(y)$를 X의 CDF로부터 계산할 수 있고, 이의 미분을 통해 Y의 PDF $f_Y(y)$를 구할 수 있음.

[예 2.39] $Y=\frac{9}{5}X+32$의 확률분포는?

[예제 2.40] $Y=X^2$의 확률분포는?

[풀이]

$Y=X^2$ 이고 X가 연속형이며 $P(X=0)=0$ 이면 , $y>0$ 에 대하여

$F_Y(y)=P(-\sqrt{y}\le X\le\sqrt{y}=F_X(\sqrt{y}-F_X(-\sqrt{y}.$

따라서 $f_Y(y)=[f_X(\sqrt{y}+f_X(-\sqrt{y}]/(2\sqrt{y},y>0.$

X의 구체적 분포가 정해졌다면 그 밀도를 대입하고 지지집합을 별도로 확인한다.

[예제 2.41] X가 $U(0,1)$을 따를 때, $Y=-\lambda logX\ (\lambda>0)$의 pdf는?

[풀이]

$X\sim U(0,1), \lambda>0, Y=-\lambda logX$ 라 두면 $y>0$ 에서

$F_Y(y)=P(-\lambda logX\le y)=P(X\ge e^{-y/\lambda})=1-e^{-y/\lambda}.$

따라서 $f_Y(y)=(1/\lambda)e^{-y/\lambda}, y>0.$

즉 $Y\sim$ Exp(scale λ) 이며 $E(Y)=\lambda$ 이다.

[예제 2.42] X와 Y가 $U(0,1)$을 따를 때, $Z=X+Y$의 pdf는?

[풀이]

X,Y가 서로 독립인 U(0,1)이고 $Z=X+Y$ 라 하자.

$f_Z(z)=\int f_X(x)f_Y(z-x)dx$ 로 계산한다.

적분 가능한 x의 길이는 $0<z<1$ 일 때 $z, 1\le z<2$ 일 때 2-z이다.

따라서 $f_Z(z)=z(0<z<1), 2-z(1\le z<2)$, 나머지는 0이다.

$F_Z(z)=z^2/2(0\le z<1); 1-(2-z)^2/2(1\le z<2)$ 로 확인할 수 있다.

■ **[정리 2.23] 확률변수 X의 pdf가 $f_X(x)$일 때, $Y=g(X)$라는 변환을 고려하자. 단 g는 $A=\{x\,;f_X(x)>0\}$에서 $B=\{y\,;f_Y(y)>0\}$으로의 1:1 함수이며, 그의 역함수를 $x=g^{-1}(y)$라 하자. 만일 B상에서 $dg^{-1}(y)/dy\neq 0$이면 Y의 pdf는 다음과 같이 구해진다.**

$$f_Y(y)=f_X[g^{-1}(y)]\left|\frac{dg^{-1}(y)}{dy}\right|, \quad y\in B.$$

a) 만일 g가 A영역에서 증가함수이면 $F_Y(y) = F_X[g^{-1}(y)] \quad y \in B$

- $\{x\,;\, g(x) \le y\} = \{x\,;\, g^{-1}g(x) \le g^{-1}(y)\} = \{x\,;\, x \le g^{-1}(y)\}$

b) 만일 g가 A영역에서 감소함수이면 $F_Y(y) = 1 - F_X[g^{-1}(y)]$ 이다.

- $\{x\,;\, g(x) \le y\} = \{x\,;\, g^{-1}g(x) \ge g^{-1}(y)\} = \{x\,;\, x \ge g^{-1}(y)\}$

■ [예제 2.39]와 [예제 2.41](1:1 함수) 은 [정리 2.23]을 이용하여 구할 수 있음.

[풀이]

$y = g(x)$ 가 단조미분가능하고 역함수 $h(y) = g^{-1}(y)$ 이면

$F_Y(y) = F_X[h(y)](g$ 증가 $), 1 - F_X[h(y)](g$ 감소**).**

각각을 y로 미분하면 밀도는 항상 $f_Y(y) = f_X[h(y)] \cdot |h'(y)|$ 이다.

예컨대 $Y = aX + b(a \ne 0)$ 에서는 $f_Y(y) = f_X((y-b)/a)/|a|$ 이다.

■ 반면 [예제 2.40]은 (1:1함수가 아님)? 어떻게?

- 정의역을 $g(x)$가 1:1 대응이 되도록 몇 개의 영역으로 나누어 [정리 2.23]을 적용함.

[풀이]

$y > 0$ 에서 양의 역상 $\sqrt{y}$ 는 $y < 9$ 일 때 존재하고 음의 역상 $-\sqrt{y}$ 는 $y < 1$ 일 때만 존재한다.

따라서 $f_Y(y) = 1/(4\sqrt{y}(0 < y < 1), 1/(8\sqrt{y}(1 < y < 9), 0($ 나머지).

정규화 : $\int_0^1 [1/(4\sqrt{y}]dy + \int_1^9 [1/(8\sqrt{y}]dy = 1/2 + 1/2 = 1.$

경계값에서는 밀도를 임의의 값으로 정해도 분포는 같다.

[예제 2.40] $A_1 = (-\infty, 0), \quad g_1(x) = x^2, \quad g_1^{-1}(y) = -\sqrt{y}$

$A_2 = (0, \infty), \quad g_2(x) = x^2, \quad g_2^{-1}(y) = \sqrt{y}$

[예제] X의 pdf가 $f(x) = 1/4, \quad -1 < x < 3$ 일 때 $Y = X^2$의 pdf는?

2.7.2 연속형 확률변수의 결합변환 [n차원 연속형] - $\underline{Y} = g(\underline{X})$

- n차원 확률벡터 $\underline{X} = (X_1, \cdots, X_n)$의 변환된 $k(\leq n)$개의 확률변수 $Y_1 = g_1(X_1, \cdots, X_n), \cdots, Y_k = g_k(X_1, \cdots, X_n)$이 존재함. $\rightarrow$ $\underline{Y} = g(\underline{X})$

- $A = \{(x_1, \cdots, x_n) ; f_{X_1, \cdots, X_n}(x_1, \cdots, x_n) > 0\}$이라 정의

(1) 만일 $k = n$인 경우, n차원에서 n차원 변환 (1:1 변환) 이용

- 만일 n차원에서 n차원 변환이 1:1 변환이 아니라면? 앞 절의 1차원에서 변수변환[예, $Y = g(X) = X^2$]과 마찬가지로 결합변환에서

도 1:1 변환이 되도록 정의역을 나눠준 후 Y의 joint pdf를 유도

[풀이]

X1,X2가 독립 U(0,1)일 때 $Z = X_1 + X_2, W = X_1$ 로 놓는다.

역변환은 $X_1 = W, X_2 = Z - W$ 이며 $|J| = 1$.

결합밀도 $f_{Z,W}(z,w) = 1$ 은 $0 < w < 1$ 및 $0 < z - w < 1$ 에서 성립한다.

W를 적분하면 $f_Z(z) = \int_{(} max(0, z-1))^{(} min(1,z))dw$ 이며,

결과는 $f_Z(z) = z(0 < z < 1), 2 - z(1 < z < 2)$ 이다.

함.

(2) 만일 $k < n$인 경우, $[X_1, X_2 \sim U(0,1), \quad Y = X_1 + X_2$의 분포는?]

- $n-k$개의 새로운 변수 $Y_{k+1} = g_{k+1}(X_1, \cdots, X_n), \cdots, g_n(X_1, \cdots, X_n)$를 추가하여 n차원에서 n차원 변환 (1:1 변환)을 고려하여 $Y_1, \cdots, Y_n$의 joint pdf를 구한 후, $Y_1, \cdots, Y_k$의 marginal pdf를 유도함.

- 연속형의 결합변환은 1차원 변환에서 사용한 역함수의 미분값을 여러 개의 변수로 일반화한 자코비안(Jacobian)을 사용

- n차원 변환에서의 자코비안 $[\underline{y} = g(\underline{x})$의 변환이 일대일 변환]

$$J = \begin{vmatrix} \frac{\partial x_1}{\partial y_1} & \frac{\partial x_1}{\partial y_2} & \cdots & \frac{\partial x_1}{\partial y_n} \\ \frac{\partial x_2}{\partial y_1} & \frac{\partial x_2}{\partial y_2} & \cdots & \frac{\partial x_2}{\partial y_n} \\ \vdots & \vdots & \vdots & \vdots \\ \frac{\partial x_n}{\partial y_1} & \frac{\partial x_n}{\partial y_2} & \cdots & \frac{\partial x_n}{\partial y_n} \end{vmatrix}$$

- **[정리 2.25] n개의 연속형 확률변수로 구성되어 있는 확률벡터 $\underline{X} = (X_1, \cdots, X_n)$에 대하여 $Y_i = g_i(\underline{X}), i = 1, \cdots, n$라는 결합변환된 확률변수를 고려하자.**

- $\underline{X}$는 결합 pdf $f_{\underline{X}}(x_1,\cdots,x_n)$를 갖는데 전체영역 A상에서 이 결합 pdf는 양(>0)의 값을 갖는다. 또한 $(g_1,\cdots,g_n)$은 A상에서 정의된 일대일 변환이며 유일해 $x_i = h_i(y_1,\cdots,y_n),\ i=1,\cdots,n$를 갖는다고 가정한다.
- 이제 자코비안 J 가 변환의 범위에서 0이 아니면, 확률벡터 $\underline{Y}$의 결합 pdf는 다음과 같이 구해진다.

$$f_{\underline{Y}}(y_1,\cdots,y_n) = f_{\underline{X}}(h_1(y_1,\cdots,y_n),\cdots,h_n(y_1,\cdots,y_n))|J|$$

- [증명 : 생략]

- [예제 2.45] $X_1, X_2 \sim \exp(1)$

[풀이]

X1,X2가 독립 Exp(scale 1)이므로 $f_X 1, X_2(x1,x2) = e^{-x1-x2}, x1, x2 > 0.$

역변환 $x1 = y1, x2 = y2 - y1, |J| = 1$ 이다.

따라서 $f_Y 1, Y_2(y1,y2) = e^{-y2}, 0 < y1 < y2.$

주변밀도는 $f_Y 1(y1) = e^{-y1}, f_Y 2(y2) = y2e^{-y2}(y1, y2 > 0).$

즉 Y2는 Gamma(shape 2,scale 1)을 따른다.

(1) $Y_1 = X_1 \quad Y_2 = X_1 + X_2$

(2) $Y_1 = X_1 - X_2 \quad Y_2 = X_1 + X_2$

[풀이]

$Y_1 = X_1 - X_2, Y_2 = X_1 + X_2$. 역변환은 $x1 = (y2 + y1)/2, x2 = (y2 - y1)/2$ 이다.

역자코비안의 절대값은 $1/2$, 지지영역은 $y2 > |y1|$ 이다.

따라서 $f_Y 1, Y_2(y1, y2) = (1/2)e^{-y2}(y2 > |y1|)$, 그 밖에서 0.

Y1의 주변밀도는 $f_Y 1(y1) = (1/2)e^{-|y1|}$(라플라스분포)이다.

- [예제 2.46] $X_1, X_2 \sim N(0,1)$: 풀어볼 것 !!!

[풀이]

교재 예 2.46 의 변환은 $Y_1 = X_1 + X_2, Y_2 = X_1/X_2$ 이다(독립 표준정규 X1,X2).

역변환 $x1 = y1y2/(1+y2), x2 = y1/(1+y2)$ 이고 $|J| = |y1|/(1+y2)^2$ 이다.

따라서 $f_Y1, Y_2(y1, y2) = |y1|/[2\pi(1+y2)^2] \cdot exp - y1^2(y2^2+1)/[2(1+y2)^2], y2 \neq -1.$

$Y_1 \sim N(0,2)$ 이고 , $Y_2 = X_1/X_2$ 는 표준 코시분포:

$f_Y2(y2) = 1/[\pi(1+y2^2)], -\infty < y2 < \infty.$

- **만일 $\underline{Y} = g(\underline{X})$가 1 : 1 변환이 아니라면?**
  - **$\underline{X}$의 전체 영역을 몇 개의 겹치지 않는 부분영역 $A_1, A_2, \cdots, A_k$로 나누어 각 영역 A_j상에서 $\underline{y} = g(\underline{x})$가 유일해 $x_1 = h_{1j}(y_1, \cdots, y_n), \cdots, x_n = h_{nj}(y_1, \cdots, y_n)$를 갖도록 한 후 $Y = g(\underline{X})$의 joint pdf는 다음과 같이 구함.**

$$f_{\underline{Y}}(y_1, \cdots, y_n) = \sum_{j=1}^{k} f_{\underline{X}}\left(h_{1j}(y_1, \cdots, y_n), \cdots, h_{nj}(y_1, \cdots, y_n)\right) |J_j|$$

- [예제 3.13] $X_1, X_2, X_3 \sim f(x), \quad f(x) = 3x^2, \quad 0 < x < 1$일 때

  $X_{(1)} < X_{(2)} < X_{(3)}$가 순서통계량이라 하면, 이들의 확률분포는?

[풀이]

각 Xi의 밀도가 $f(x) = 3x^2(0 < x < 1)$, 누적분포는 $F(x) = x^3$ 이다.

순서통계량 $U = X_1 < V = X_2 < W = X_3$ 의 결합밀도는

$3!f(u)f(v)f(w) = 162u^2v^2w^2(0 < u < v < w < 1)$ 이다.

예를 들어 최댓값의 밀도는 $f_W(w) = 3[F(w)]^2 f(w) = 9w^8(0 < w < 1)$ 이다.

■ **만일 변환과정에서 $k < n$인 경우,**

- $n-k$개의 새로운 변수 $Y_{k+1} = g_{k+1}(X_1,\cdots,X_n),\cdots,\ g_n(X_1,\cdots,X_n)$ 를 추가하여 n차원에서 n차원 변환 (1:1 변환)을 고려하여 joint pdf를 구한 후 이들의 marignal pdf를 구하는 방식

- [예제 2.42, 2.47] $X, Y \sim U(0,1)$ $Z = X + Y$의 확률분포

[풀이]

$Z = X + Y(X, Y \overset{\text{iid}}{\sim} U(0,1))$ 의 CDF는 $0 < z < 1$ 에서 정사각형 아래 삼각형 넓이 $z^2/2$,

$1 < z < 2$ 에서는 $1-(2-z)^2/2$이다.

미분하면 $f_Z(z) = z(0 < z < 1), 2 - z(1 < z < 2)$, 그 밖에서 0.

합성곱을 쓰든 결합변환의 자코비안을 쓰든 동일한 결과가 나온다.

■ 예제 [정규분포의 극좌표 변환을 통한 pdf check] [P 94-95]

[풀이]

$I = \int_{-\infty}^{\infty} e^{-x^2/2}dx$ 를 두면

$I^2 = \int\int e^(-(x^2+y^2)/2)dxdy = \int_0^{2\pi}\int_0^{\infty} e^{-r^2/2}rdrd\varphi = 2\pi.$

따라서 $\varphi(x) = e^{-x^2/2}/\sqrt{2\pi}$ 는 정상적인 확률밀도이다.

이 계산은 이변량 독립 정규밀도를 극좌표로 바꾼 뒤 정규화하는 것으로도 이해할 수 있다.

Chap 2. 확률밀도함수 및 확률분포함수 Part 4

2.8 적률생성함수(Moment Generating Function; MGF)

- 확률변수의 적률(moment)은 X의 r차 함수 X^r에 대한 기대값 $E(X^r)$로서, 확률변수의 분포형태를 결정하는데 중요한 역할
- 평균, 분산, 왜도, 첨도 등이 적률의 함수
- 적률생성함수 – 확률변수의 형태를 결정하며 특히 확률변수들의 합의 분포를 알아내는데 유용함.

■ **[정의 2.15]** 확률변수 X의 함수 $g(X)=X^r$에 대하여 다음과 같이 정의함.

- X의 r차 적률 : 확률변수 X의 함수 $g(X)=X^r$에 대한 기댓값

$$\mu_r{}' = E[X^r]$$

- $\mu = E(X)$에 대한 X의 r차 중심적률(r^{th} central moment) :

$$\mu_r = E[(X-\mu)^r]$$

■ **적률의 성질**

- $\mu_1{}' = E(X) = \mu$
- $\mu_2 = E[(X-\mu)^2] = \sigma^2 = E[X^2] - [E(X)]^2 = \mu_2{}' - \mu_1{}'^2$
- $\mu_3 = E(X^3)$: 왜도(skewness) - 비대칭성을 측정
  - 단위에 의존하므로 단위를 없앤 μ_3/σ^3 : 왜도계수
- $\mu_4 = E(X^4)$: 첨도(kurtosis) - 뾰족한 정도를 측정
  - 단위에 의존하므로 단위를 없앤 $\mu_4/\sigma^4 - 3$: 첨도계수
  - why –3? 정규분포의 μ_4/σ^4 값이 항상 3이 되므로 정규분포와 뾰족한 정도를 비교하기 위하여
- 만약 k차 적률이 존재하면 k보다 작은 차수의 적률은 항상 존재.

■ **[정의 2.16] 적률생성함수(Moment Generating Function : MGF)**

▪ 어떤 $h>0$에 대하여 $-h<t<h$를 만족하는 모든 t에서 $E(e^{tX})<\infty$일 때, 확률변수 X의 MGF는 다음과 같다.

$$M_X(t)=E[\exp(tX)]$$

▪ [예제 2.48] $X\sim B(n,p)$

[풀이]

$X\sim$ Bin(n,p) 이면

$M_X(t)=\sum_{x=0}^{n}\binom{n}{x}p^x(1-p)^{n-x}e^{tx}$

$=[(1-p)+pe^t]^n$(이항정리).

$M'(0)=np, M''(0)=n(n-1)p^2+np$ 이므로 Var$(X)=np(1-p)$.

▪ [예제 2.49, 2.51] $X\sim exp(\theta)$, $X\sim GAM(k,\theta)$

[풀이]

$X\sim$ Exp(scale θ) : $M_X(t)=\int_0^\infty e^{tx}(1/\theta)e^{-x/\theta}dx=(1-\theta t)^{-1}, t<1/\theta.$

$X\sim$ Gamma(k,θ) : $M_X(t)=(1-\theta t)^{-k}, t<1/\theta.$

미분하여 $E(X)=k\theta$, Var$(X)=k\theta^2$ 를 얻는다(지수분포는 $k=1$).

- [예제 2.50] $Z \sim N(0,1)$

[풀이]

$Z \sim N(0,1)$ 이면

$M_Z(t) = (1/\sqrt{2\pi}) \int \exp(tz - z^2/2)dz$

$= e^{t^2/2}(1/\sqrt{2\pi}) \int$

$exp[-(z-t)^2/2]dz = e^{t^2/2}.$

따라서 Z의 평균은 $M'(0) = 0$, 분산은 $M''(0) = 1$ 이다.

- **[정리 2.27] 확률변수 X의 MGF를 $M_X(t)$라 하면, $E(X^r)$이 존재하는 경우, 다음이 성립한다.**

$$M_X^{(r)}(0) = E(X^r)$$

- **proof (r=1인 경우)**

- [예제 2.52] $X \sim B(n,p)$

[증명]

적절한 적분 · 미분 교환 조건하에서

$M_X(t) = E(e^{tX})$ 이므로 $M_X^{'}(t) = E(Xe^{tX})$.

$t = 0$ 으로 놓으면 $M_X^{'}(0) = E(X)$.

반복 미분하면 $M_X^{r}(t) = E(X^r e^{tX})$, 따라서 $M_X^{r}(0) = E(X^r)$.

[풀이]

$M(t) = (q + pe^t)^n (q = 1 - p)$.

$M^{'}(t) = npe^t(q + pe^t)^{n-1}$ 이므로 $M^{'}(0) = np$.

$M^{''}(0) = np + n(n-1)p^2$.

$\mathrm{Var}(X) = M^{''}(0) - [M^{'}(0)]^2 = np(1-p)$.

- **[정리 2.28] (MGF와 pdf의 관계) 확률변수 X와 Y가 같은 MGF를 갖으면 두 확률변수는 같은 pdf를 갖는다.**

- **[증명] 생략**

- [예제 2.53] $X \sim EXP(\theta)$, $Y = aX$의 MGF는? Y의 pdf는?

[풀이]

$X \sim$ Exp(scale θ), $Y = aX (a > 0)$.

$M_Y(t) = M_X(at) = (1 - a\theta t)^{-1}, t < 1/(a\theta)$.

따라서 $Y \sim$ Exp(scale $a\theta$), 밀도는 $f_Y(y) = (1/(a\theta))e^(-y/(a\theta))(y > 0)$.

$a < 0$ 이면 지지집합이 음수 영역으로 바뀌므로 위의 지수분포 표기는 $a > 0$ 에서만 성립한다.

- [예제 2.54] $X \sim N(0,1)$, $Y = X^2$의 MGF는? 이를 통해 구해본 Y의 pdf는?

[풀이]

$Z \sim N(0,1), Y = Z^2$ 이면

$M_Y(t) = (1/\sqrt{2\pi}) \int$
$exp[-(1-2t)z^2/2]dz = (1-2t)^{-1/2}, t < 1/2.$

이것은 자유도 1인 카이제곱분포 $\chi^2(1)$ 의 MGF이다.

변수변환으로 직접 구하면 $f_Y(y) = e^{-y/2}/\sqrt{2\pi y}, y > 0$ 이다.

▪ [예제 2.55] $X \sim GAM(k,\theta)$일 때 $Y=2X/\theta$의 분포는?

[풀이]

$X \sim \text{Gamma}(k,\theta), Y = 2X/\theta$ 라면

$M_Y(t) = M_X(2t/\theta) = (1-2t)^{-k}.$

$\chi^2(\nu)$ 의 MGF가 $(1-2t)^{-\nu/2}$ 이므로 $\nu = 2k$:

$Y \sim \chi^2(2k), E(Y) = 2k, \text{Var}(Y) = 4k.$

■ **[정리 2.29] (독립확률변수들의 합의 분포)**

(1) 확률변수 X의 MGF가 $M_X(t)$이면, 확률변수 $Y=aX+b$의 MGF는 $M_Y(t)=e^{bt}M_X(at)$이다.

(2) 확률변수 $X_i(i=1,2,\cdots,n)$들이 서로 독립이고 각각 MGF $M_{X_i}(t)$를 갖는다고 할 때, $Y=X_1+X_2+\cdots+X_n$의 MGF는 $M_Y(t)=M_{X_1}(t)\times M_{X_2}(t)\times\cdots\times M_{X_n}(t)$로 주어진다.

■ **Proof**

[증명]

$Y = aX + b$ 일 때 $M_Y(t) = E(e^(t(aX+b))) = e^{bt}M_X(at).$

$Y = \sum_{i=1}^{n} X_i$ 이고 Xi가 서로 독립이면

$M_Y(t) = E[\prod e^{tXi}] = \prod E[e^{tXi}] = \prod M_X i(t).$

이 성질과 MGF의 유일성이 독립 확률변수들의 합 분포를 찾는 근거다.

- [예제 2.57] $X_1,\cdots,X_n \sim_{iid} Poi(\lambda_i)$, $Y = X_1 + \cdots + X_n$의 확률분포는?

[풀이]

$X_i \sim$ Poi(λ_i) 가 서로 독립이면 $M_X i(t) =$ exp$[\lambda_i(e^t - 1)]$.

따라서 $Y = \sum X_i$ 에 대해 $M_Y(t) =$ exp$[(\sum \lambda_i)(e^t - 1)]$.

이는 Poi$(\sum \lambda_i)$ 의 MGF이므로 $Y \sim$ Poi$(\lambda 1 + \cdots + \lambda_n)$.

각 Xi의 λ_i 가 달라도 위 결과는 성립한다.

- [예 2.59] $X_1,\cdots,X_n \sim_{iid} N(\mu_i, \sigma_i^2)$, $Y = \sum_{i=1}^{n} a_i X_i$의 MGF는?

[풀이]

서로 독립인 $X_i \sim N(\mu_i, \sigma_i^2), Y = \sum aiXi$ 라고 하자.

$M_Y(t) = \prod$ exp$(ai\mu_i t + ai^2\sigma_i^2 t^2/2)$

$=$ exp$[(\sum ai\mu_i)t + (\sum ai^2\sigma_i^2)t^2/2]$.

따라서 $Y \sim N(\sum ai\mu_i, \sum ai^2\sigma_i^2)$ 이다.

▪ **[정의 2.17] (결합 MGF)** 확률벡터 $\underline{X}=(X_1,\cdots,X_k)$의 결합 MGF는 다음과 같이 정의된다.

$$M_{\underline{X}}(\boldsymbol{t})=E\left[\exp\left(\sum_{i=1}^{k}t_iX_i\right)\right]$$

단 $\boldsymbol{t}=(t_1,\cdots,t_k)$이고 $i=1,\cdots,k$에 대하여 $-h_i<t_i<h_i$에서 $E\left[\exp\left(\sum_{i=1}^{k}t_iX_i\right)\right]<\infty$이 되는 $h_i>0$들이 존재한다.

■ **참고 사항:**

(1) $E(X_i^rX_j^s)$: $M_{\underline{X}}(\boldsymbol{t})$를 t_i, t_j에 대하여 각각 r, s번 미분한 결과에 모든 $t_i=0$을 대입함으로서 얻을 수 있음.

(2) 두 확률변수 X와 Y의 결합 MGF가 $M_{X,Y}(t_1,t_2)$라 하면 X와 Y 각각의 MGF는 각각 다음과 같이 구해진다.

$$M_X(t_1)=M_{X,Y}(t_1,0),\qquad M_Y(t_2)=M_{X,Y}(0,t_2)$$

▪ [예제 2.60] $\underline{X}=(X_1,X_2,X_3)\sim MULTI(n\,;p_1,p_2,p_3)$

[풀이]

(X1,X2,X3)~Multinomial(n;p1,p2,p3)이면

$M_X(t1,t2,t3) = E[\exp(t1X1 + t2X2 + t3X3)]$

$= [p1e^{t1} + p2e^{t2} + p3e^{t3}]^n.$

이 식을 ti에 대해 미분하면 $E(X_i) = npi, \mathrm{Cov}(X_i, X_j) = -npipj(i \neq j)$ 이다.

- **[정리 2.30] (MGF와 확률변수의 독립성) 두 확률변수 X와 Y가 독립일 필요충분조건은 결합 MGF가 각각의 MGF의 곱과 같다는 것이다. 즉**

$$M_{X,Y}(t_1,t_2) = M_X(t_1)M_Y(t_2)$$

이면 X와 Y가 서로 독립이고. 그 역도 성립한다.

- **[proof] 생략. 정리 2.5로부터 자명함.**

- [예제 2.57 계속] $X_1 \sim P(\lambda_1), X_2 \sim P(\lambda_2)$ X_1 과 X_2가 독립인 경우

[풀이]

$X_1 \sim$ Poi$(\lambda 1), X_2 \sim$ Poi$(\lambda 2)$ 의 합 $S = X_1 + X_2$ 는 Poi$(\lambda 1 + \lambda 2)$.

따라서 $P(S = s) = e^(- (\lambda 1 + \lambda 2))(\lambda 1 + \lambda 2)^s / s!$.

또한 합 $S = s$ 가 주어졌을 때 $X_1 | S = s \sim$ Bin$(s, \lambda 1/(\lambda 1 + \lambda 2))$ 로 계산할 수 있다.

- [예제 2.60 계속] $\underline{X} = (X_1, X_2, X_3) \sim MULTI(n ; p_1, p_2, p_3)$

[풀이]

결합 MGF$[p1e^{t1} + p2e^{t2} + p3e^{t3}]^n$ 에서 $t2 = t3 = 0$ 으로 놓으면

$M_X 1(t1) = [(1 - p1) + p1e^{t1}]^n$; 따라서 $X_1 \sim$ Bin$(n, p1)$.

$Y = X_1 + X_2$ 라 하면 $t1 = t2 = t, t3 = 0$ 으로 놓아

$M_Y(t) = [(p1 + p2)e^t + p3]^n$ 이므로 $Y \sim$ Bin$(n, p1 + p2)$.

Chap 3. 표본분포(Sampling Distribution) 및 그의 근사

Part 1

- 통계이론의 주된 활용은
  - 연구대상에 대한 실험이나 관찰 등을 통해 구한 자료로부터 연구대상의 성격을 규명하는 것.

- 연구대상의 전체를 조사하는 것은 불가능.
  - 통계적 방법은 그 총체의 일부를 조사함으로서 총체에 대한 성격을 귀납적(Inductive)을 추론함.
  - 귀납적 추론은 어떤 표본을 사용했는가에 따라 달라지며 불확실성을 내포하기 때문에 불확실성을 계량하기 위하여 확률을 사용함.
- 이번 장에서는 확률분포이론을 통계이론에 적용하는데 중요한 다리 역할을 하는 표본분포이론을 다룸
  - 특히 정규분포로부터 추출한 랜덤표본에 근거한 함수의 분포로 카이제곱, t, F분포 등을 다루고
  - 정확한 표본분포를 얻기 어려운 경우 사용할 수 있는 근사적 분포에 대하여 다룸 (중심극한정리 및 대수의 법칙 등).
- 아울러 랜덤표본에서 순서가 존재하는 순서통계량의 확률분포에 대해서도 다룸.

3.1 모집단과 표본

- **[정의 3.1] 모집단(Popultion)**
  - 연구 또는 관찰의 대상이 되는 총체(totality)를 모집단이라 한다.

- **[정의 3.2] 랜덤표본(Random Sample)**
  - 확률변수 $X_1,\cdots,X_n$의 joint pdf $f(x_1,\cdots,x_n)$이 다음과 같이 나타나면 $X_1,\cdots,X_n$을 모확률밀도함수가 $f(\cdot)$인 크기가 n인 랜덤표본(random sample) 또는 임의표본이라 한다.

$$f(x_1,\cdots,x_n)=f(x_1)f(x_2)\cdots f(x_n),$$

여기서 $f(\cdot)$는 각 X_i의 공통 pdf이다. 또한 랜덤표본을 표현할 때, "확률변수 $X_1,\cdots,X_n$이 iid(indenpedent and identically distributed)이다" 라고도 표현한다.

※ 랜덤표본 $X_1,\cdots,X_n$은 확률변수이다. 즉, X_i는 i번째 관찰변수가 **가질 값**을 뜻함.

※ 반면 일단 관찰된 알려진 값은 $x_1,x_2,\cdots,x_n$으로 소문자로 표기함. 이는 관찰된 값이기 때문에 확률변수가 아님.

- [예제 3.1] 서로 독립인 베르누이 시행을 10회 반복.

[풀이]

Xi~Bernoulli(p), i=1,…,10이 서로 독립이면

$f(x1,\cdots,x10)=\prod_{i=1}^{10}p^{xi}(1-p)^{1-xi}$

$=p^{\sum xi}(1-p)^{10-\sum xi}, xi\in 0,1.$

통계량 $T=\sum X_i$ 는 Bin(10,p), 표본평균 $\bar{X}=T/10$ 이다.

따라서 $E(\bar{X})=p$, Var$(\bar{X})=p(1-p)/10$ 이다.

$X_1,\cdots,X_{10}\ \sim\ B(1,p)$

- **[정의 3.3] 통계량(Statistic)과 표본분포(Sampling Distribution)**

  - 미지의 모수를 포함하지 않는 랜덤표본의 함수 $T=T(X_1, X_2, \cdots, X_n)$을 통계량(Statistic)이라 한다. 물론 통계량 자체도 확률변수이다.

  - 일반적으로 통계량의 확률분포를 표본분포라 함.

- [예제 3.2] 통계량의 예 $X_1,\cdots,X_n\sim f(x;\theta)$

[풀이]

랜덤표본 X1,…,Xn에서 $\bar{X}=(\sum X_i)/n, S^2=\sum(X_i-\bar{X})^2/(n-1)$, 최대값 X_(n), 최소값 X_(1)은 모두 통계량이다.

반면 모수 θ 가 미지수일 때 $\bar{X}-\theta$ 나 $\sum(X_i-\theta)^2$ 처럼 θ 를 포함하는 식은 통계량이 아니다.

추정량은 추정할 대상을 정하여 선택한 통계량이라는 점을 구별한다.

- **[정의 3.4] 표본적률(sample moment)과 표본중심적률(central sample moment)**
  - 확률밀도함수 $f(x;\theta)$로부터 크기가 n인 랜덤표본 $X_1,\cdots,X_n$을 얻었다. 이때 r차 표본적률(sample moment)과 r차 표본중심적률(central sample moment)은 다음과 같이 정의된다.

$$m_r' = \frac{1}{n}\sum_{i=1}^{n} X_i^r, \qquad m_r = \frac{1}{n}\sum_{i=1}^{n}(X_i - \overline{X_n})^r,$$

  여기서 $\overline{X_n} = \sum_{i=1}^{n}/n$이다.

- **표본적률의 특성**
  - 모수를 포함하지 않는 랜덤표본의 함수이므로 통계량 임.
  - r차 표본적률 m_r'의 기댓값은 r차 모적률 $\mu_r' = E(X^r)$이 됨.
  - 4장의 추정에서 모수추정에 활용되기도 함.

- **[정리 3.1] 표본평균과 표본분산의 성질**
  - **평균과 분산이 각각 μ와 σ^2인 pdf $f(x)$로부터 랜덤표본 $X_1,\cdots,X_n$을 얻었다. 이제 표본평균과 표본분산을 각각 다음과 같이 표기하자.**

$$\overline{X_n} = \frac{1}{n}\sum_{i=1}^{n} X_i, \qquad S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X_n})^2.$$

- **표본평균과 표분분산에 대하여 다음이 성립한다.**

$$E(\overline{X_n}) = \mu, \qquad Var(\overline{X_n}) = \frac{\sigma^2}{n}$$
$$E(S^2) = \sigma^2, \qquad Var(S^2) = \frac{1}{n}\left(\mu_4 - \frac{n-3}{n-1}\sigma^4\right), \quad n > 1$$

- **[Proof]**

[증명]

$X_1, \dots, X_n$이 서로 독립이고 동일한 분포를 가지며, $E(X_i) = \mu$, $\mathrm{Var}(X_i) = \sigma^2$라고 하자. 선형성 및 독립성에 의해

$$E(\bar{X}) = \mu, \qquad \mathrm{Var}(\bar{X}) = \frac{\sigma^2}{n}.$$

표본분산의 항등식

$$(n-1)S^2 = \sum_{i=1}^{n}(X_i - \mu)^2 - n(\bar{X} - \mu)^2$$

양변에 기댓값을 취하면

$$(n-1)E(S^2) = n\sigma^2 - n\frac{\sigma^2}{n} = (n-1)\sigma^2.$$

따라서 $E(S^2) = \sigma^2$이다. 네 번째 중심적률 $\mu_4 = E[(X_i - \mu)^4]$가 유한하면, 위 제곱합을 전개하고 독립성에 의해 교차항을 정리하여

$$\boxed{\mathrm{Var}(S^2) = \frac{1}{n}\left(\mu_4 - \frac{n-3}{n-1}\sigma^4\right), \quad n \geq 2.}$$

을 얻는다.

3.2 정규분포와 관련된 분포들

3.2.1 카이제곱분포

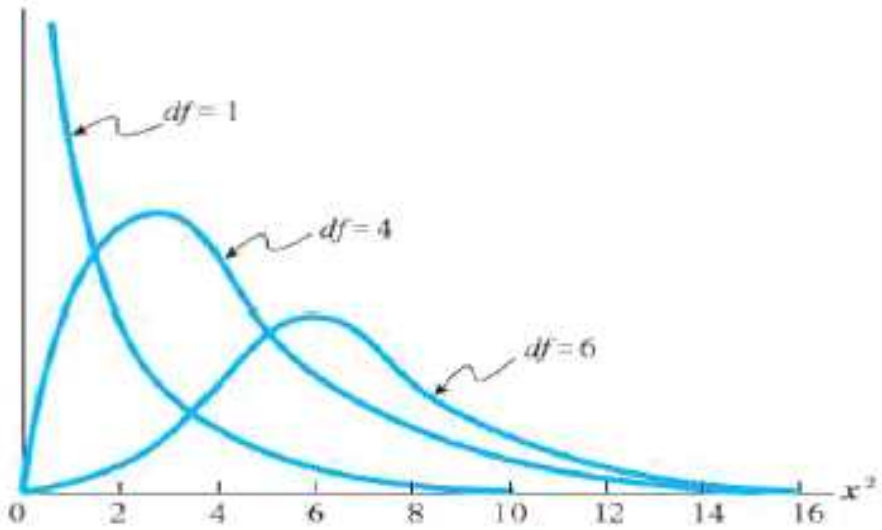
- 카이제곱분포는 추후 4장에서 모분산 σ^2의 추정량으로 표본분산

$S^2 = \sum_{i=1}^{n}(X_i - \overline{X})^2/(n-1)$의 표본분포를 이해하는데 중요한 역할을 함

- 모수가 $(k,\ \theta)$인 감마분포에서 $k = n/2,\ \theta = 2$인 확률변수 X, 즉 $X \sim GAM(n/2,\ 2)$는 자유도(degree of freedom; df)가 n인 카이제곱 분포(chi-squared distribution)를 따른다고 한다. 따라서 $X \sim \chi^2(n)$의 pdf는 다음과 같다.

$$f_X(x) = \frac{1}{\Gamma(n/2)}\left(\frac{1}{2}\right)^{n/2} x^{n/2-1}e^{-x/2}, \quad x > 0$$

- 자유도에 따른 카이제곱 분포



- **[정리 3.2] $X \sim \chi^2(n)$일 때, X의 MGF, 평균과 분산은 다음과 같다.**

$$M_X(t) = (1-2t)^{-n/2}, \quad (t < 1/2)$$

$$E(X) = n, \qquad Var(X) = 2n$$

- **[Proof] 일반적인 $GAM(k,\ \theta)$확률변수의 성질 이용**

- **[정리 3.3] 서로 독립인 확률변수 $X_i (i=1,\cdots,n)$등이 각각 자유도가 k_i인 카이제곱분포를 따르면, 그들의 합인 $Y=\sum_{i=1}^{n} X_i$는 자유도가 $\sum_{i=1}^{n} k_i$인 카이제곱분포를 따른다.**

  [증명]

  $X \sim \chi^2(n)$ 은 Gamma(shape n/2, scale 2)와 같다.

  감마 MGF$(1-\theta t)^{-k}$ 에 $k=n/2, \theta=2$ 를 대입하면

  $M_X(t)=(1-2t)^{-n/2}, t<1/2.$

  $E(X)=k\theta=n$, Var$(X)=k\theta^2=2n$ 이다.

- **[Proof] 카이제곱분포의 MGF의 성질을 이용하면 쉽게 증명 가능.**

- 정리 3.3으로부터 자유도가 n인 카이제곱분포는 서로 독립인 n개의 자유도가 1인 카이제곱 확률변수의 합으로 표현 가능.
- 한편 앞의 그림[그림 3.1]로부터 자유도가 커짐에 따라 카이제곱분포의 pdf는 평균에 대하여 대칭형에 가까움 → 중심극한정리의 이론과 합치함.
- 카이제곱분포의 누적분포확률 : <부록 : 표 5>

[증명]

독립인 $X_i \sim \chi^2(ki)$ 라면 $M_X i(t) = (1-2t)^{-ki/2}$ 이다.

합 $Y = \sum X_i$ 의 MGF는 $\prod M_X i(t) = (1-2t)^{-[\sum ki]/2}$.

그러므로 $Y \sim \chi^2(k1 + \cdots + kn)$.

- **[정리 3.4] 확률변수 Z가 $N(0,1)$분포를 따를 때, $Y = Z^2$은 $\chi^2(1)$의 분포를 따른다.**

- **[Proof] [예제 2.54] 풀이과정 – MGF 이용**

[증명]

$Z \sim N(0,1)$ 이라고 하면 $M_{Z^2}(t) = E[e^{tZ^2}] = (1-2t)^{-1/2}$ 이다 $(t < 1/2)$.

이는 자유도 1인 카이제곱분포의 MGF이므로 $Z^2 \sim \chi^2(1)$ 이다.

이제 서로 독립인 $X_i \sim N(\mu_i, \sigma_i^2)$ 에 대해 $Z_i = (X_i - \mu_i)/\sigma_i \sim N(0,1)$

이며 Zi끼리도 독립이다.

$V = \sum_{i=1}^{k} Z_i^2$ 라 두면 $M_V(t) = \prod_{i=1}^{k} (1-2t)^{-1/2} = (1-2t)^{-k/2}$.

따라서 $V \sim \chi^2(k)$ 이다.

- **[정리 3.5] 서로 독립인 확률변수 $X_i (i = 1, \cdots, n)$들이 각각 정규분포 $N(\mu_i, \sigma_i^2)$를 따른다고 하면,**

$$V = \sum_{i=1}^{k} \left(\frac{X_i - \mu_i}{\sigma_i} \right)^2$$

은 자유도가 k인 카이제곱분포를 따른다.

- **[Proof]**

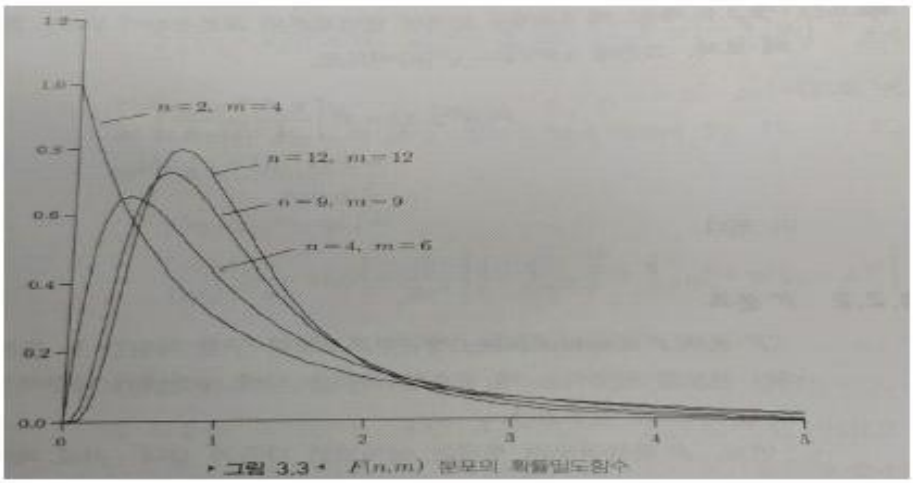
3.2.2 F 분포

- F 분포는 정규분포로부터 구한 서로 독립인 두 표본의 분산비에 대한 분포를 설명하는데 중요한 역할.
- 6장에서 다루게 될 분산분석과 7장의 회귀분석 등에서도 필수적으로 활용되는 확률분포
- 서로 독립인 카이제곱 확률변수 U와 V의 자유도가 각각 n, m이라고 할 때, 그들의 함수꼴인 변수 $X = \frac{U/n}{V/m}$은 자유도가 (n, m)인 F 분포를 따르며[$X \sim F(n, m)$], X의 pdf는 다음과 같이 구해진다.

$$f(x) = \frac{\Gamma[(n+m)/2]}{\Gamma(n/2)\Gamma(m/2)} \left(\frac{n}{m}\right)^{n/2} \frac{x^{(n-2)/2}}{[1+nx/m]^{(n+m)/2}}, \quad x > 0$$

- F 분포의 분포형태는 자유도 (n,m)에 의해 결정됨. 특히 자유도의 순서에 주의 (n: 분자자유도, m: 분모자유도)

- 자유도에 따른 F 분포의 pdf



▸그림 3.3 ◂ $F(n,m)$ 분포의 확률밀도함수

- F 분포의 누적확률분포 : <부록 : 표 6>

[풀이]

$U \sim \chi^2(n), V \sim \chi^2(m)$ 가 독립이고 $F = (U/n)/(V/m)$ 로 둔다.

$W = V$ 를 보조변수로 정하면 $U = nFW/m, V = W$ 이고 자코비안 $|J| = nW/m$ 이다.

두 카이제곱 밀도를 대입해 $W > 0$ 에서 적분하면

$f_F(x) = [\Gamma((n+m)/2)/(\Gamma(n/2)\Gamma(m/2))](n/m)^{n/2}$

$\times x^{n/2-1}[1 + (n/m)x]^{(} - (n+m)/2), x > 0.$

이 적분은 감마 적분공식을 사용한다.

- **[정리 3.6]** $X \sim F(n, m)$**일 때, X의 평균과 분산은 아래와 같다.**

$$E(X) = \frac{m}{m-2}, \quad m > 2$$

$$Var(X) = \frac{2m^2(m+n-2)}{n(m-2)^2(m-4)}, \quad m > 4$$

- **[Proof]**

[증명]

$F = (U/n)/(V/m)$ 이고 U,V는 독립 $\chi^2(n), \chi^2(m)$ 이다.

$E(U) = n, E(U^2) = n(n+2), E(V^{-1}) = 1/(m-2)(m>2),$

$E(V^{-2}) = 1/[(m-2)(m-4)](m>4).$

그러므로 $E(F) = (m/n)E(U)E(1/V) = m/(m-2).$

$E(F^2) = m^2(n+2)/[n(m-2)(m-4)].$

Var$(F) = E(F^2) - [E(F)]^2 = 2m^2(n+m-2)/[n(m-2)^2(m-4)].$

- **[Note] F 분포의 추가 성질**
  - $X \sim F(n, m)$이면 $1/X$는 자유도가 (m,n)인 F 분포를 따른다.
  - F 분포의 $100(1-\alpha)\%$ 백분위수 $F_\alpha(n, m)$은 다음과 같은 관계가 성립한다.

$$\alpha = P[X \geq F_\alpha(n, m)] = P\left[\frac{1}{X} \leq \frac{1}{F_a(n,m)}\right] = 1 - P\left[\frac{1}{X} \geq \frac{1}{F_a(n,m)}\right]$$

  - 따라서 $\frac{1}{F_\alpha(n, m)} = F_{1-\alpha}(m, n)$의 관계가 성립함.

- [예제 3.3] $X \sim F(5, 10)$에 대하여 $P(X \leq a) = 0.01$을 만족하는 상수 a는? $X \sim F(6,12)$일 때, $P(X > 0.25)$는?

[풀이]

$F \sim F(n,m)$ 의 CDF는 $I_z(n/2, m/2), z = nx/(nx+m)$(정규화 불완전 베타함수).

따라서 $F(5,10)$ 의 1% 분위수 a는 $F_{\text{CDF}}(a;5,10) = 0.01$ 을 풀면 $a \approx 0.09949$ 이다.

$F(6,12)$ 에 대하여 $P(F > 0.25) = 1 - I_($6 $\cdot 0.25/(6 \cdot 0.25 + 12))(3,6)$

$= 1 - I_{1/9}(3,6) \approx 0.95000$ 이다. 교재의 F 분포표를 이용하면 같은 값을 얻는다.

3.2.3 t 분포

- t 분포는 정규모집단에서 분산이 알려지지 않은 경우, 표본평균의 확률분포로부터 시작(Student's t 분포). 정규분포의 모평균에 대한 가설검정, 구간추정 등 모평균에 대한 추론에 사용되는 확률분포.

- t **분포의 정의 :** 확률변수 Z가 표준정규분포를 따르고, U는 자유도가 k인 카이제곱분포를 따른다고 하자. 이제 U와 Z가 독립이라면 확률변수 $X = \dfrac{Z}{\sqrt{U/k}}$는 자유도가 k인 t 분포[$X \sim t(k)$]를 따르며, 그의 pdf는 다음과 같이 구해진다.

$$f_X(x) = \frac{\Gamma((k+1)/2)}{\Gamma(k/2)} \frac{1}{\sqrt{k\pi}} \frac{1}{(1+x^2/k)^{(k+1)/2}}, \quad -\infty < x < \infty$$

- **[Proof]**

[증명]

$Z \sim N(0,1), U \sim \chi^2(k)$ 가 독립이며 $T = Z/\sqrt{U/k}$ 라 하자.

$(U,T) = (u,t)$ 의 역변환 $z = t\sqrt{u/k}, |\partial z/\partial t| = \sqrt{u/k}$ 이다.

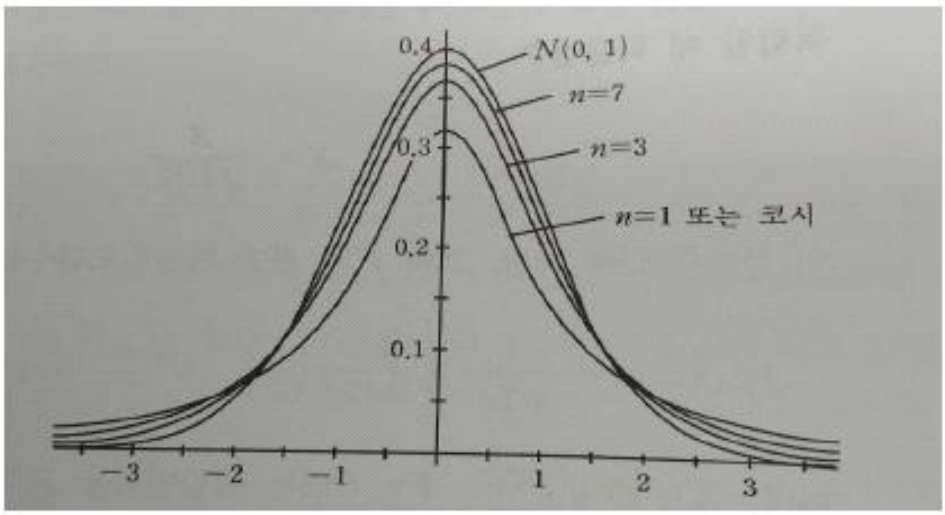
$f_T(t) = \int_0^\infty \varphi(t\sqrt{u/k}) f_U(u)\sqrt{u/k}du.$

상수를 정리하고 감마 적분을 적용하면

$f_T(t) = \Gamma((k+1)/2)/[\sqrt{k\pi}\Gamma(k/2)] \cdot (1+t^2/k)^(-(k+1)/2), -\infty < t < \infty.$

이는 자유도 k인 Student t 밀도이다.

- 자유도에 따른 t 분포와 표준정규분포의 그래프



- **t 분포의 성질**
  - 0에 대하여 대칭이며 자유도에 의존함
  - 자유도 k에 의하여 꼬리부분의 두터움이 결정되며, $k=1$인 경우에는 코쉬분포와 동일함.
  - $X \sim t(n)$일 때, X^2은 자유도가 $(1,n)$인 F 분포를 따름.

- **[정리 3.7]** $X \sim t(n)$**일 때,** X**의 평균과 분산은 아래와 같이 계산된다.**

$$E(X) = 0 \quad (n > 1), \quad Var(X) = \frac{n}{n-2}, \quad (n > 2)$$

- **[Proof] 생략**

※ 참고사항 : 각 분포의 임계값(Critical Value)

- 표준정규분포, 카이제곱분포, F 분포, t 분포의 임계값은 추후 구간 추정과 검정이론에서 흔히 나타남.
- 임계값의 표기는 저자에 따라 다르게 정의함.
- 임계값은 백분위수와 밀접한 관련이 있음. 이 교재에서는 상방 α분위수를 임계값으로 사용함. 즉 z_α는 표준정규분포의 $100(1-\alpha)$백분위수가 됨.

- 각 분포에 따른 임계값
  - z_α : $Z \sim N(0, 1)$일 때, $P(Z > z) = \alpha$를 만족하는 z의 값
  - $t_\alpha(n)$: $T \sim t(n)$일 때, $P(T > t) = \alpha$를 만족하는 t의 값
  - $\chi^2_\alpha(n)$: $X \sim \chi^2(n)$일 때, $P(X > x) = \alpha$를 만족하는 x의 값
  - $F_\alpha(n, m)$: $F \sim F(n, m)$일 때, $P(F > f) = \alpha$를 만족하는 f의 값

- 표준정규분포와 t분포는 0에 대하여 다음이 성립함.

$$z_{1-\alpha} = -z_\alpha, \qquad t_{1-\alpha}(n) = -t_\alpha(n)$$

3.3 정규분포로부터의 표본추출

- 통계적 추정이론이나 방법, 가설걸점 등에서 정규분포의 역할은 지대함.
  - 일례로 모분포를 모르는 경우, 그 모분포로부터 얻은 표본평균은 중심극한정리에 의하여 정규분포로 수렴함. [3.4장에서 설명]

    → 모분포를 모르는 경우에도 모평균에 대한 추론이 가능해짐.
  - 모분포에 대한 정규성 가정은 통계적 추론에 필요한 분포이론에의 수리적 접근을 용이하게 함.

    → 정규분포에서 얻어진 표본과 그의 함수들에 대한 성질을 파악하는 것은 향후 통계적 추론에서 매우 필요한 사항임.

- **[정리 3.8] 서로 독립인 정규분포를 따르는 확률변수들의 합의 분포**
  - **서로 독립인 확률변수 $X_i\,(i=1,\cdots,n)$들이 정규분포 $N(\mu_i,\,\sigma_i^2)$를 따르면, 그들의 합 $\sum_{i=1}^{n}X_i$는 정규분포 $N\left(\sum_{i=1}^{n}\mu_i,\,\sum_{i=1}^{n}\sigma_i^2\right)$을 따른다.**
- **[Proof] 생략 : MGF 이용 (정리 2.29, 예제 2.59)**

- **[정리 3.9] 표본평균과 표분분산의 관계파악과 S^2의 표본분포**
  - **$X_1,\cdots,X_n$을 평균이 μ이고 분산이 σ^2인 정규분포 $N(\mu,\,\sigma^2)$으로부터의 크기가 n인 랜덤표본이라고 하면,**

  (0) $\overline{X_n}=\sum_{i=1}^{n}X_i \sim N(\mu,\sigma^2/n)$라 하면 $X_i-\overline{X_n}\,(i=1,\cdots,n)$는 정규분포를 따르지만 서로 독립은 아님.

(1) $\overline{X_n} = \sum_{i=1}^{n} X_i$**와** $S_n^2 = \sum_{i=1}^{n} (X_i - \overline{X_n})^2/(n-1)$**은 서로 독립이며,**

(2) $(n-1)S_n^2/\sigma^2$**은 자유도가** $n-1$**인 카이제곱분포를 따른다.**

- **[Proof]**

  [증명]

  $Z_i = (X_i - \mu)/\sigma$ 로 표준화하면 $Z = (Z_1, \cdots, Z_n)$ 은 n차원 표준정규벡터이다.

  첫 좌표를 $\sqrt{n}(\bar{X} - \mu)/\sigma$ 로 잡고 나머지 n-1 좌표를 표본평균 방향에 수직인 직교정규기저로 잡아 회전한다.

  회전된 좌표도 서로 독립 표준정규이며, 남은 n-1개의 제곱합은

  $\sum (X_i - \bar{X})^2/\sigma^2 = (n-1)S^2/\sigma^2$ 이다.

  따라서 X와 S^2가 서로 독립이고 $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$ 이다(코크란 정리의 구성적 증명).

- **[정리 3.10] 두 표본 분산비의 분포**

  - **평균이** μ_X**이고 분산이** σ_X^2**인 정규분포로부터 크기가** n**인 랜덤표본** $X_1, \cdots, X_n$**을 추출하고, 이와는 독립적으로 평균이** μ_Y**이고 분산이** σ_Y^2**인 정규분포로부터 크기가** m**인 랜덤표본** $Y_1, \cdots, Y_m$**을 얻었다.**

(1) 이때 확률변량 $F = \dfrac{S_X^2/\sigma_X^2}{S_Y^2/\sigma_Y^2}$**은 자유도가** $(n-1, m-1)$**인** F**분포를 따른다.**

(2) 만일 $\sigma_X^2 = \sigma_Y^2$**이라면(두 표본이 동일한 분산을 갖는다면) (1)의** F**는** $F = S_X^2/S_Y^2 \sim F(n-1, m-1)$**이 된다.**

- **[Proof]**

  [증명]

  정규모집단에서 두 표본은 독립이고

  $U=(n-1)S_X^2/\sigma_X^2 \sim \chi^2(n-1), V=(m-1)S_Y^2/\sigma_Y^2 \sim \chi^2(m-1)$ 이다.

  따라서 정의에 의해 $(U/(n-1))/(V/(m-1))=(S_X^2/\sigma_X^2)/(S_Y^2/\sigma_Y^2)$

  $\sim F(n-1, m-1).$

  특히 $\sigma_X^2=\sigma_Y^2$ 이면 S_X^2/S_Y^2 자체가 $F(n-1, m-1)$ 를 따른다.

- **[정리 3.11] 분산이 알려지지 않은 경우 표준화한 표본평균의 확률분포**

  - **$X_1, \cdots, X_n$을 평균이 μ이고 분산이 σ^2인 정규분포 $N(\mu, \sigma^2)$으로부터의 크기가 n인 랜덤표본이라고 하면,**

$$T=\frac{\sqrt{n}(\overline{X_n}-\mu)}{S}=\frac{\sqrt{n}(\overline{X_n}-\mu)}{\sqrt{\sum_{i=1}^{n}(X_i-\overline{X_n})^2/(n-1)}}$$

  는 자유도가 $(n-1)$인 t분포를 따른다.

- **[Proof]**

※ t 분포와 관련한 참고사항

- 정리 3.11에 나타난 확률변량 T는 μ의 값이 알려진 경우라면 통계량이 되며, 이를 스튜던트화 t통계량(Studentized t statistic)이라 함.

- 만일 μ가 알려지지 않은 경우라면, 확률변량 T는 t분포를 따르지만 미지의 모수 μ에 의존하므로 통계량은 아님. 하지만 μ를 제외한 나머지 통계량들은 알 수 있으므로, μ에 대한 구간추정이나 가설검정 등 통계적 추론에 확률변량 T가 유용하게 사용됨.
- 표준정규분포와 t분포의 차이는 정리 3.11에서 분모 부분이 모표

[증명]

정규표본에서 $Z = \sqrt{n}(\bar{X} - \mu)/\sigma \sim N(0,1), U = (n-1)S^2/\sigma^2 \sim \chi^2(n-1)$ 이다.

정리 3.9 에 따라 Z와 U는 서로 독립이다.

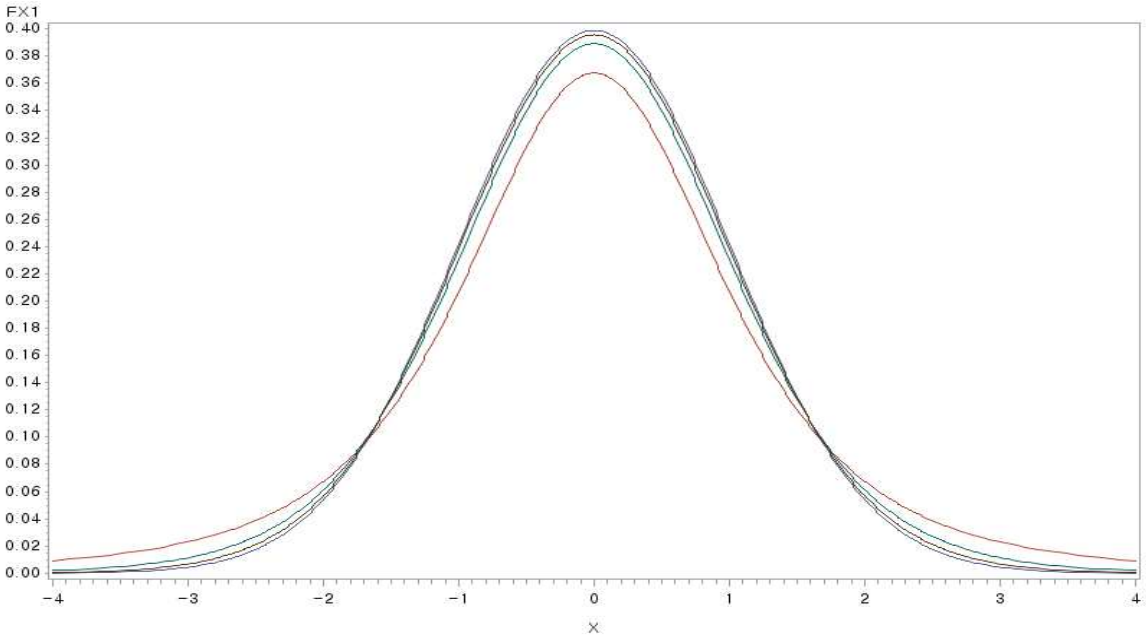
따라서 $T = Z/\sqrt{U/(n-1)} = \sqrt{n}(\bar{X} - \mu)/S \sim t(n-1).$

모분산을 몰라도 S로 나누어 자유도 n-1의 t 분포를 얻는다.

준편차 σ로 표현되느냐 또는 미지의 모수 σ(장애모수)를 표본표준편차로 추정하여 사용하는가에 있음.

- 한편 t분포는 자유도에 의존하며, 자유도가 커짐에 따라 표준정규분포로 수렴한다. 이는 T의 분모인 S가 σ로 확률적으로 수렴함에 따라 T의 분포가 표준정규분포로 수렴하기 때문임. [3.4 확률적 수렴, 슬러스키정리(정리 3.15)]

- 표준정규분포와 자유도에 따른 t분포(자유도가 3, 10, 30)



- 자유도에 따른 t분포의 백분위수 : P495, <부록 : 표 4>
  - P 493-494, <부록 : 표 3>의 표준정규분포의 백분위수와 비교해볼 것.
  - 자유도가 커짐에 따라 t분포의 백분위수는 표준정규분포의 백분위수와 가까워 짐.

Chap 3. 표본분포(Sampling Distribution) 및 그의 근사

Part 2

3.4 대수의 법칙과 중심극한정리

- 앞 절에서는 모분포의 정규성 가정하에서 널리 사용되는 통계량(표본평균, 표본분산)의 표본분포를 다루었음.
- 그러나 주어진 자료에 정규분포 가정과 같이 특정 분포를 가정하는 것이 어려울 경우가 있음. 따라서 표본의 크기가 큰 경우, 통계량의 점근적 성질을 파악해야 함.
- 특히 확률변수의 수렴중 확률적 수렴과 분포수렴에 대하여 다루고자 함.

3.4.1 대수의 법칙(Law of Large Numbers)

- **[정의 3.5] 확률적 수렴(Converge in Probability)**
  - ▫ 확률변수의 열(sequence) $X_1,\cdots,X_n,\cdots$과 확률변수 X가 같은 확률공간에서 정의된다고 하자. 만약 임의의 $\epsilon>0$에 대하여 $\lim_{n\to\infty}P(|X_n-X|\geq\epsilon)=0$ 또는 $\lim_{n\to\infty}P(|X_n-X|<\epsilon)=1$을 만족한다면, X_n이 X로 확률적으로 수렴한다고 말하고, $X_n\xrightarrow{p}X$로 표기한다.

- [예제] $X_n=\frac{n-1}{n}X,\ n=1,2,\cdots$

[풀이]

X가 고정된 유한한 확률변수이고 $X_n = anX, an \to 0$ 인 결정적 수열이면 $X_n \to 0$(확률수렴).

실제로 임의 $\epsilon > 0$ 에서 $P(|anX| > \epsilon) = P(|X| > \epsilon/|an|) \to 0$ 이다.

강의노트의 예에서 Xn의 배율이 n에 따라 0으로 간다면 이 원리를 적용한다.

- **[정리 3.12] 대수의 법칙(Weak Law of Large Number; WLLN)**
  - **평균이 $\mu < \infty$ 이고 분산이 $\sigma^2 < \infty$ 인 pdf $f(x)$ 로부터 랜덤표본 $X_1, \cdots, X_n$ 을 얻었다면, $\overline{X_n} \xrightarrow{p} \mu$ 가 성립한다.**
  - **표본의 크기가 커짐에 따라 표본평균이 모평균으로 확률적 수렴함.**
- **[Proof] 체비셰프 부등식 이용**

- [예제 3.7] $X_1, \cdots, X_n \sim B(1, p)$

[증명]

iid Xi의 평균 μ, 분산 $\sigma^2 < \infty$ 이면 $E(\bar{X}n) = \mu, \text{Var}(\bar{X}n) = \sigma^2/n.$

체비셰프 부등식에 의해 임의 $\epsilon > 0$ 에서

$P(|\bar{X}n - \mu| \geq \epsilon) \leq \sigma^2/(n\epsilon^2) \to 0.$

따라서 Xn은 μ 로 확률적으로 수렴한다.

■ **[정의 3.5 확장 – 정리 4.10]**

- $X_1, X_2, \cdots$ 이 확률변수 X로 확률적 수렴한다고 하자. 이때 h가 연속함수라 하면, $h(X_1), h(X_2), \cdots$는 $h(X)$로 확률적 수렴한다..

■ **[PROOF] : 생략**

■ [예제] $\hat{p}^2$, $\hat{p}(1-\hat{p})$의 확률적 수렴

[풀이]

Xi~Bernoulli(p) (iid)이고 $\hat{p} = \sum X_i/n$ 이라 하면 $E(\hat{p}) = p, \text{Var}(\hat{p}) = p(1-p)/n.$

약한 대수의 법칙으로 $\hat{p} \to p($ 확률수렴)이다.

연속함수 사상정리에 따라 $\hat{p}^2 \to p^2,$

$\hat{p}(1-\hat{p}) \to p(1-p)$ 역시 확률적으로 수렴한다.

3.4.2 중심극한정리(Central Limit Theorem)

■ **[정의 3.6] 분포수렴(Converge in distribution)**

- 확률변수의 열 $X_1, X_2, \cdots$ 이 CDF $F_{X_1}, F_{X_2}, \cdots, F_{X_n}, \cdots$를 각각 갖고, 확률변수 X가 CDF F_X를 갖는다고 하자.
- 만약 함수 F_X가 연속인 모든 점 x에서 $\lim_{n\to\infty} F_{X_n}(x) = F_X(x)$가 만족된다면 X_n이 X로 분포수렴한다고 말하고, $X_n \xrightarrow{d} X$로 표기한다.

■ [예제] $X_1, \cdots, X_n \sim U(0,1)$, $n(1-Y)$, $Y = X_{(n)}$의 극한분포

[풀이]

$X_i \overset{\text{iid}}{\sim} U(0,1), Y = X_n = max(X_1, \cdots, X_n)$ 라 하자.

$0 < y < 1$ 에서 $P(Y \le y) = y^n$ 이다.

$Tn = n(1-Y)$ 로 두면 $t \ge 0$ 에 대해

$P(Tn > t) = P(Y < 1 - t/n) = (1 - t/n)^n \to e^{-t}.$

따라서 $P(Tn \le t) \to 1 - e^{-t} (t \ge 0) : Tn$ 은 평균 1인 지수분포로 분포수렴한다.

■ **[정리 3.13] 적률생성함수의 극한과 확률분포의 관계**

- **확률변수 $X_1, X_2, \cdots$의 누적분포함수가 $F_1, F_2, \cdots$이고, 적률생성함수가 $M_1(t),\ M_2(t),\ \cdots$라고 하자.**
- **이때 어떤 t의 개구간 $-h < t < h$에 대하여 $\lim_{n\to\infty} M_n(t) = M(t)$가 성립하며, $M(t)$가 누적분포함수 $F(x)$를 갖는 어떤 확률분포의 MGF라고 하면, $F(x)$가 연속인 모든 점에서 $\lim_{n\to\infty} F_n(x) = F(x)$가 성립한다.**

■ **[증명] : 생략 (중심극한정리의 증명 방법)**

■ **[정리 3.14] 중심극한정리(Central Limit Theorem; CLT)**

- **평균이 유한하고 분산이 $\sigma^2 < \infty$인 pdf $f(x)$로부터 랜덤표본 $X_1, \cdots, X_n$을 얻었다. 이때 확률변량**

$$Z_n = \frac{\sum_{i=1}^{n} X_i - E\left(\sum_{i=1}^{n} X_i\right)}{\sqrt{Var\left(\sum_{i=1}^{n} X_i\right)}} = \frac{\sum_{i=1}^{n} (X_i - \mu)}{\sqrt{n}\,\sigma} = \frac{\sqrt{n}\,(\overline{X_n} - \mu)}{\sigma}$$

의 분포는 표본의 크기 n이 무한대로 접근함에 따라 표준정규분포 $N(0,\ 1)$으로 수렴한다.

■ **[증명]**

[증명]

$Y_i = (X_i - \mu)/\sigma$ 라 두면 $E(Y_i) = 0, \mathrm{Var}(Y_i) = 1$ 이고 $Z_n = (\sum Y_i)/\sqrt{n}$ 이다.

MGF가 0 부근에서 존재한다면 테일러 전개로

$M_Y(t) = 1 + t^2/2 + o(t^2)(t \to 0).$

서로 독립이므로 $M_Z n(t) = [M_Y(t/\sqrt{n})]^n$

$= [1 + t^2/(2n) + o(1/n)]^n \to \exp(t^2/2).$

이는 N(0,1)의 MGF이므로 MGF 수렴정리에 의해 Zn⇒N(0,1).

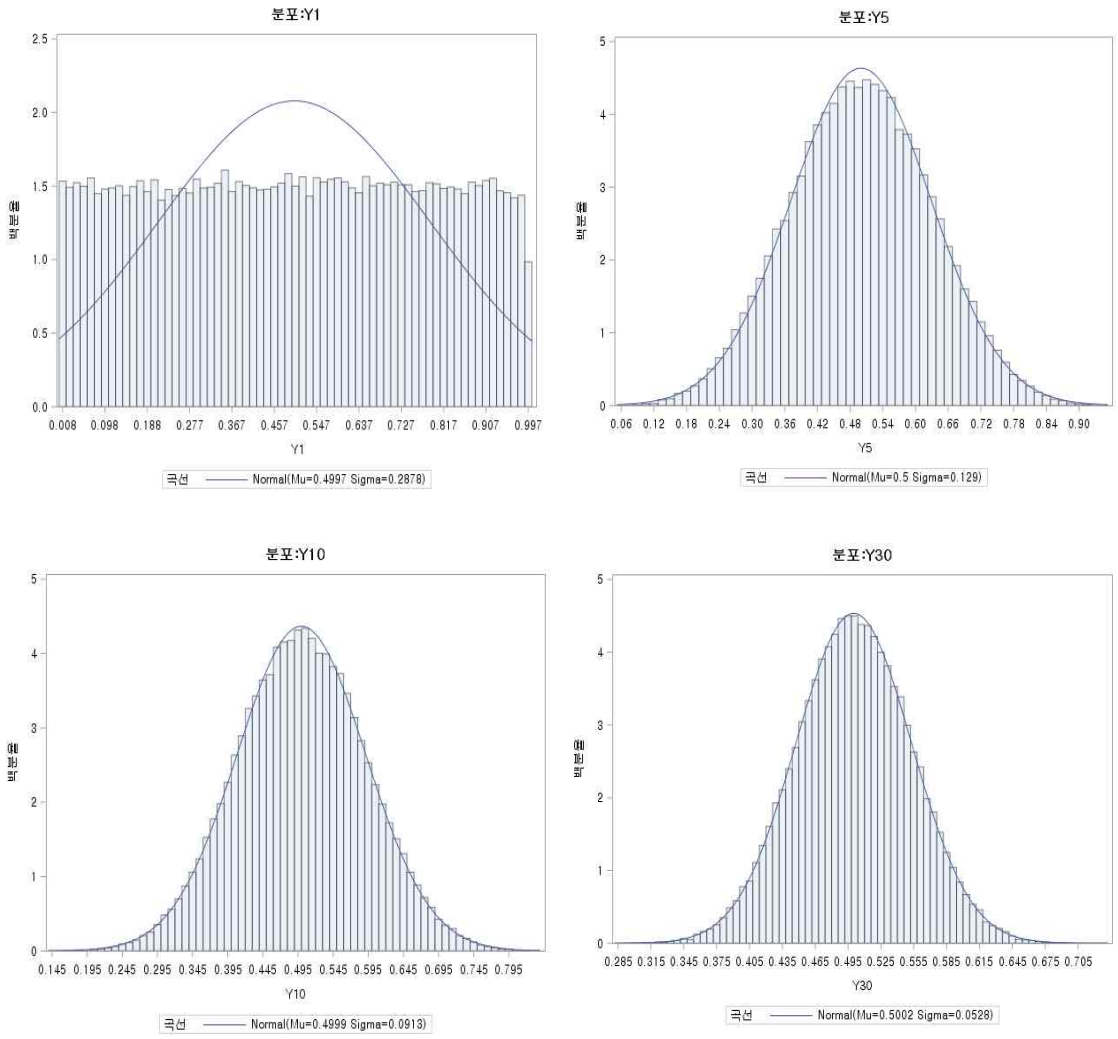
이 증명은 MGF 존재를 추가 가정하는 경우이다. 일반적인 유한분산 CLT에는 특성함수 등의 논증이 필요하다.

※ 중심극한정리의 중요한 점

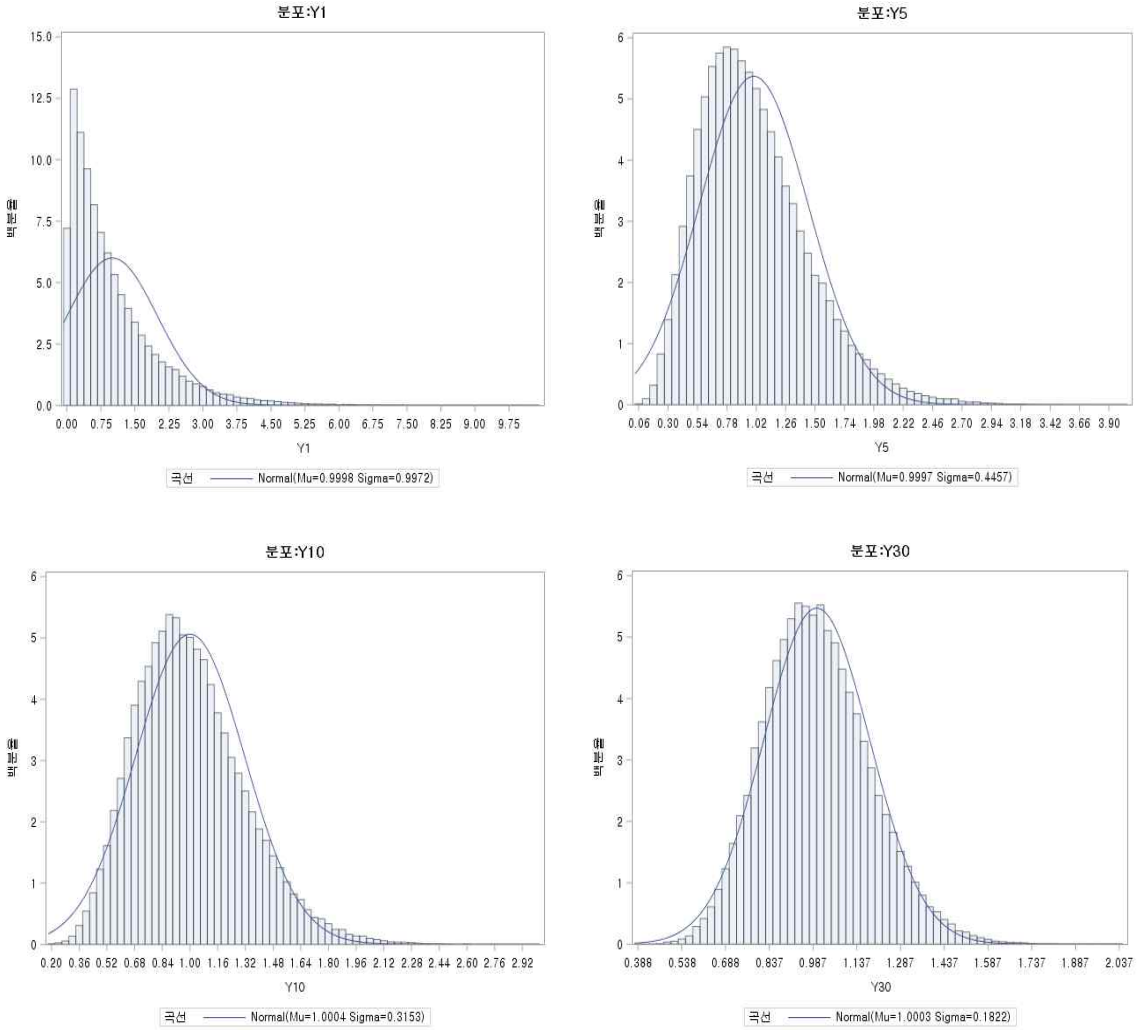
- 모분포의 형태에 관계없이 유한한 평균과 분산만 존재한다면 확률변량 Z_n의 분포가 표준정규분포로 수렴함. 따라서 평균이 존재하지 않는 코쉬분포는 CLT가 성립하지 않음.
- Z_n은 표본평균 $\overline{X}$로 표현할 수 있으므로, CLT를 통해 모분포를 모르더라도 표본평균의 분포는 정규분포로 수렴함을 알 수 있음.
- 따라서 모분포를 모르는 경우에도 모평균에 관한 추론은 표본크기가 커지는 경우 표본평균이 정규분포로 수렴한다는 사실을 이용하여 실시할 수 있음.

- 표본평균의 정규분포로의 근사의 정확성은 표본의 크기와 모확률밀도함수 $f(x)$에 의존함.

- U(0, 1)에서 100000번 난수발생후 표본평균에 대한 히스토그램
(표본크기 n=1, 5, 10, 30인 표본의 표본평균의 분포)



- EXP(1)에서 100000번 난수발생후 표본평균에 대한 히스토그램
(표본크기 n=1, 5, 10, 30인 표본의 표본평균의 분포)



※ 중심극한정리에 대한 두 모의실험을 통해 알 수 있는 사실

- 모집단의 분포가 대칭형[U(0,1)]인 분포인 경우, 표본의 크기가 그리 많지 않아도(n=10) 표본평균이 정규분포로 수렴하는데에는 큰 무리가 없음.
- 반면, 평균이 1인 지수분포와 같이 모집단의 분포가 비대칭인 경우, 표본평균이 정규분포로 수렴하기 위해서는 많은 수의 표본이 필요함(표본크기가 30개 이상이어야 함).

- [예제 3.9] $X \sim B(n,p)$, 연속성 수정. $P(a \le X \le b)$, $P(a < X < b)$

[풀이]

$X \sim$ Bin$(n,p), q = 1-p$ 에서 np와 nq가 충분히 크면 X≈N(np,npq)이다.

정수 $a \le b$ 에 대해 $P(a \le X \le b) \approx \Phi[(b+0.5-np)/\sqrt{npq}] - \Phi[(a-0.5-np)/\sqrt{npq}]$.

$P(a < X < b)$ 처럼 양 끝을 제외하면

$\approx \Phi[(b-0.5-np)/\sqrt{npq}] - \Phi[(a+0.5-np)/\sqrt{npq}]$.

끝점을 ± 0.5 보정하는 것이 연속성 수정이다.

3.4.3 그 외의 관련내용

■ **[정리 3.15] 슬러츠키(Slutsky)의 정리**

▪ **확률변수의 열 $X_1, X_2, \cdots, X_n$이 상수 c로 확률적 수렴(즉, $X_n \xrightarrow{p} c$) 하며, 확률변수의 열 $Y_1, \cdots, Y_n$은 확률변수 Z로 분포수렴(즉, $Y_n \xrightarrow{d} Z$)한다고 하면, 다음이 성립한다.**

$$\text{(1) } A_n X_n \xrightarrow{d} aX, \quad \text{(2) } A_n + X_n \xrightarrow{d} a + X$$

■ **[PROOF] : 생략**

■ [예제 3.10] 스튜던트화(Studentized)된 표본평균의 분포

[풀이]

$X_1, \dots, X_n$이 독립이고 동일한 분포를 가지며, $E(X_i) = \mu$, Var$(X_i) = \sigma^2 \in (0, \infty)$라 하자. 중심극한정리와 표본분산의 일치성에 의해

$$\frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \xrightarrow{d} N(0,1), \qquad \frac{S}{\sigma} \xrightarrow{p} 1.$$

따라서 슬러츠키 정리에 의해

$$\boxed{\frac{\sqrt{n}(\bar{X} - \mu)}{S} \xrightarrow{d} N(0,1).}$$

정규모집단이면 유한한 n에서도 이 통계량은 정확히 t_{n-1}분포를 따른다.

■ **[정리 3.16] 델타방법**

- **확률변수의 열 $X_1, X_2, \cdots, X_n, \cdots$에 대하여 $\sqrt{n}(X_n - \theta) \xrightarrow{d} N(0, \sigma^2)$ 이러고 하자.**
- **이때 $g(\theta)$의 연속인 도함수 $g'(\theta)$가 존재하고 0이 아니면 $\sqrt{n}(g(X_n) - g(\theta)) \xrightarrow{d} N(0, \sigma^2[g'(\theta)]^2)$이 성립한다.**

■ **[증명]**

[증명]

g가 θ 에서 미분가능하고 $g'(\theta) \neq 0$ 이라면 테일러 전개로

$g(Tn) = g(\theta) + g'(\theta)(Tn - \theta) + rn, rn = o_p(|Tn - \theta|).$

$\sqrt{n}(Tn - \theta) \Rightarrow N(0, \sigma^2)$ 이므로 $\sqrt{n} \cdot rn = o_p(1)$ 이다.

따라서 $\sqrt{n}[g(Tn) - g(\theta)] = g'(\theta)\sqrt{n}(Tn - \theta) + o_p(1)$

$\Rightarrow N(0, \sigma^2[g'(\theta)]^2)$(슬러츠키 정리).

- [예제 3.11] $X_1, \cdots, X_n \sim P(\lambda)$, $g(\overline{X}) = \sqrt{\overline{X}}$

[풀이]

$X_i \overset{\text{iid}}{\sim}$ Poi(λ)이면

$$\sqrt{n}\,(\bar{X} - \lambda) \xrightarrow{d} N(0, \lambda).$$

$g(x) = \sqrt{x}$이므로 $g'(\lambda) = 1/(2\sqrt{\lambda})$이고, 델타 방법에 의해

$$\boxed{\sqrt{n}\,(\sqrt{\bar{X}} - \sqrt{\lambda}) \xrightarrow{d} N(0, 1/4).}$$

따라서 큰 n에서 Var$(\sqrt{\bar{X}}) \approx 1/(4n)$이다.

- [예제] $X_1, X_2, \cdots \sim exp(\theta), \quad g(\overline{X}) = \log(\overline{X})$

[풀이]

$X_i \overset{\text{iid}}{\sim}$ Exp(scale θ)이면 $E(X_i) = \theta$, Var$(X_i) = \theta^2$이다. 중심극한정리에 의해

$$\sqrt{n}\,(\bar{X} - \theta) \xrightarrow{d} N(0, \theta^2).$$

$g(x) = \log x$에서 $g'(\theta) = 1/\theta$이므로 델타 방법을 적용하면

$$\boxed{\sqrt{n}\,(\log \bar{X} - \log \theta) \xrightarrow{d} N(0, 1).}$$

즉, $\log \bar{X}$의 점근분산은 $1/n$이다.

3.5 순서통계량

- **연속형 확률변수에서 주로 정의됨.** 랜덤샘플 $X_1, \cdots, X_n$이 주어졌을 때 이들을 크기순으로 정렬하여 얻는 통계량 :

$$X_{(1)} \le X_{(2)} \le \cdots \le X_{(n)}$$

- 비모수적 방법(8장)에서 많은 활용

※ 순서통계량과 관련한 중요한 사항

- 연속형 확률변수 $X_1, \cdots, X_n$의 순서통계량 $X_{(1)}, X_{(2)}, \ldots, X_{(n)}$은 일대일 변환이 아님.
- $X_1, \cdots, X_n$의 영역을 1:1 변환이 되도록 나누고, 순서통계량의 결합 pdf 를 구함. [정리 2.25의 확장]

■ 연속형 확률변수에서 만일 $\underline{Y} = g(\underline{X})$가 1 : 1 변환이 아니라면?

- **$\underline{X}$의 전체 영역을 몇 개의 겹치지 않는 부분영역 $A_1, A_2, \cdots$로 나누어 각 영역 A_j상에서 $\underline{y} = g(\underline{x})$가 유일해 $\underline{x} = \underline{x_j} = (x_{1j}, \cdots, x_{nj})$를 갖**

도록 한 후, $Y=g(\underline{X})$의 joint pdf는 다음과 같이 구함.

$$f_{\underline{Y}}(y_1,\cdots,y_n) = P[g(\underline{X})=\underline{y}] = \sum_j P[g(\underline{X})=\underline{y},\ \underline{X}\in A_j]$$

$$= \sum_j P[X_1=x_{1j},\cdots,X_n=x_{nj}] = \sum_j f_{\underline{X}}(x_{1j},\cdots,x_{nj})$$

- **[예] $n=3$인 경우**

$$A=\{(x_1,x_2,x_3);\ -\infty<x_1,x_2,x_3<\infty\},$$

$$B=\{(x_{(1)},x_{(2)},x_{(3)});\ -\infty<x_{(1)}\le x_{(2)}\le x_{(3)}\le\infty\}$$

$$A_1=\{(x_1,x_2,x_3);\ <x_1<x_2<x_3<\infty\} \Rightarrow X_{(1)}=X_1,\ X_{(2)}=X_2,\ X_{(3)}=X_3$$

$$A_2=\{(x_1,x_2,x_3);\ <x_1<x_3<x_2<\infty\} \Rightarrow X_{(1)}=X_1,\ X_{(2)}=X_3,\ X_{(3)}=X_2$$

$$A_3=\{(x_1,x_2,x_3);\ <x_2<x_1<x_3<\infty\} \Rightarrow X_{(1)}=X_2,\ X_{(2)}=X_1,\ X_{(3)}=X_3$$

$$A_4=\{(x_1,x_2,x_3);\ <x_2<x_3<x_1<\infty\} \Rightarrow X_{(1)}=X_2,\ X_{(2)}=X_3,\ X_{(3)}=X_1$$

$$A_5=\{(x_1,x_2,x_3);\ <x_3<x_1<x_2<\infty\} \Rightarrow X_{(1)}=X_3,\ X_{(2)}=X_1,\ X_{(3)}=X_2$$

$$A_6=\{(x_1,x_2,x_3);\ <x_3<x_2<x_1<\infty\} \Rightarrow X_{(1)}=X_3,\ X_{(2)}=X_2,\ X_{(3)}=X_1$$

  - 이 경우, 각 영역 A_i에서 (X_1,X_2,X_3)에서 $(X_{(1)},X_{(2)},X_{(3)})$로의 변환은 1:1변환이 됨.
  - 또한 각 변환에서 자코비안 J_i의 절대값은 1이 됨.

- 그러므로 순서통계량 $X_{(1)},X_{(2),\cdots,}X_{(n)}$의 결합 pdf는 다음과 같이 구해짐.

$$g(x_{(1)},x_{(2)},\cdots,x_{(n)}) = \begin{cases} n!f(x_{(1)})f(x_{(2)})\cdots f(x_{(n)}), & x_{(1)}<\cdots<x_{(n)} \\ 0, & otherwise \end{cases}$$

▪ [예 3.10] $f(x)=3x^2 \ \ (0<x<1)$

[풀이]

$F(x)=x^3(0<x<1)$ 이고 $n=3$ 이다.

$f_{X(1},X(2),X(3))(u,v,w)=3!\cdot(3u^2)(3v^2)(3w^2)$

$=162u^2v^2w^2, 0<u<v<w<1.$

순열 $3!=6$ 개 각각이 변환영역의 한 부분을 차지한다.

▪ [정리 3.17] k번째 순서통계량의 확률분포

(1) 랜덤표본 $X_1,\cdots,X_n$을 pdf가 $f(x)$이고 CDF가 $F(x)$인 모집단으로부터 얻었다고 하자. 이제 $a<x<b$에 대하여 $f(x)>0$이라고 하면, k 번째 순서통계량 $X_{(k)}$의 확률밀도함수는 다음과 같이 구해진다.

$$f_{X_{(K)}}(x_{(k)})=\frac{n!}{(k-1)!(n-k)!}[F(x_{(k)})]^{k-1}[1-F(x_{(k)})]^{n-k}f(x_{(k)}), \qquad a<x_{(k)}<b$$

(2) i번째 순서통계량 $X_{(i)}$와 j번째 순서통계량 $X_{(j)}$의 결합 pdf는 다음과 같이 구해진다.

$$f_{X_{(i)},X_{(j)}}(x_{(i)},x_{(j)})=\frac{n!}{(i-1)!(j-i-1)!(n-j)!}[F(x_{(i)})]^{i-1}f(x_{(i)})$$

$$\times[F(x_{(j)})-F(x_{(i)})]^{j-i-1}f(x_{(j)})[1-F(x_{(j)})]^{n-j}, \qquad a<x_{(i)}<x_{(j)}<b$$

▪ **[Proof] : 직관적 이해**

[증명]

X_(k)가 x와 x+dx 사이에 있으려면, 나머지 n-1개 중 k-1개는 x 이하, n-k 개는 x 초과이어야 한다.

그 선택 방법은 n! / [(k-1)!(n-k)!]이고, 해당 확률의 일차항은

$[F(x)]^{k-1}[1-F(x)]^{n-k}f(x)dx$ 이다.

따라서 $f_{X(k)}(x) = n!/[(k-1)!(n-k)!][F(x)]^{k-1}[1-F(x)]^{n-k}f(x).$

두 순서통계량의 결합밀도도 세 구간 $(-\infty, u), (u, v), (v, \infty)$ 의 배치 개수를 세어 얻는다.

■ 특별한 형태의 순서통계량 [$X_{(1)},\ X_{(n)}$]

□ $G_1(x_{(1)}) = P[X_{(1)} \le x_{(1)}] = 1 - P[X_{(1)} > x_{(1)}] = 1 - P[\text{모든 } X_i > x_{(1)}]$

$$= 1 - P[X_1 > x_{(1)}] \cdots P[X_n > x_{(1)}] = 1 - [1 - F(x_{(1)})]^n$$

$$f_{X_{(1)}}(x_{(1)}) = \frac{d}{dx_{(1)}} G_1(x_{(1)}) = \frac{d}{dx_{(1)}} \left[1 - [1 - F(x_{(1)})]^n\right]$$

$$= n[1 - F(x_{(1)})]^{n-1} f(x_{(1)}), \quad -\infty < x_{(1)} < \infty$$

□ $G_n(x_{(n)}) = P[X_{(n)} \le x_{(n)}] = P[\text{모든 } X_i \le x_{(n)}]$

$$= 1 - P[X_1 \le x_{(n)}] \cdots P[X_n \le x_{(n)}] = [F(x_{(n)})]^n$$

$$f_{X_{(n)}}(x_{(n)}) = \frac{d}{dx_{(n)}} G_n(x_{(n)}) = \frac{d}{dx_{(n)}} [F(x_{(n)})]^n$$

$$= n[F(x_{(n)})]^{n-1} f(x_{(n)}), \quad -\infty < x_{(n)} < \infty$$

▪ [예제 3.14] $X_1, \cdots, X_n \sim^{iid} \exp(\theta)$

[풀이]

$X_i \overset{\text{iid}}{\sim}$ Exp(scale θ) 라 하면 $P(X_i > x) = e^{-x/\theta}$ 이다.

최솟값 $M = X_1$ 에 대해 $P(M > x) = \prod P(X_i > x) = e^{-nx/\theta}$.

따라서 $f_M(x) = (n/\theta)e^{-nx/\theta}(x > 0)$,

$M \sim$ Exp(scale θ/n), $E(M) = \theta/n$ 이다.

- [예제] $X_1, \cdots, X_n \sim U(0, 1)$, $R = X_{(n)} - X_{(1)}$의 확률분포는?

[풀이]

$n \geq 2$ 이고 $0 < u < v < 1$ 에서 (최솟값 U, 최댓값 V)의 결합밀도는

$f_{U,V}(u, v) = n(n-1)(v-u)^{n-2}$ 이다.

$R = V - U = r$ 로 두고 U를 0부터 1-r까지 적분하면

$f_R(r) = \int_0^{1-r} n(n-1)r^{n-2}du$

$= n(n-1)r^{n-2}(1-r), 0 < r < 1.$

CDF는 $F_R(r) = nr^{n-1} - (n-1)r^n$, 기대값은 $E(R) = (n-1)/(n+1)$ 이다.

Chap 4. 추정이론

- 추정이론(estimation theory)은 5장의 검정이론(testing theory)와 함께 통계적 추론(statistical inference)의 가장 중요한 분야
- 연구나 관찰의 대상인 확률변수 X의 pdf가 $f(x;\theta),\ \theta\in\Omega$라 정의. 일반적으로 미지의 모수 θ를 제외한 확률분포의 유형은 결정된 것으로 가정함. → 모수모형(parametric model)
  - ∘ θ는 $\theta=(\theta_1,\cdots,\theta_k)$로 표현되는 벡터일 수도 있으며, Ω는 모수공간을 나타냄.

- 이제 $X_1,X_2,\cdots,X_n$[편의상 $X=(X_1,\cdots,X_n)$라 표기]을 $f(x;\theta),\ \theta\in\Omega$에서 추출한 랜덤샘플이라 하면, 주요 관심사항은
  - $f(x;\theta)$를 특징짓는 모수 θ 또는 θ의 함수인 $g(\theta)$(예, $g(\theta)=e^{\theta}$, $g(\theta)=\theta^2$, $\cdots$)의 추정에 있음.
  - 보통 모수인 θ자체에 흥미를 갖게 되지만, 일반성을 잃지 않기 위해서 모수의 함수인 $g(\theta)$의 추정을 고려함.

- $g(\theta)$의 추정방법으로는 크게 점추정과 구간추정의 두 가지 방법
  - 점추정(point estimation) : 표본에 근거한 통계량 $T(X_1,\cdots,X_n)$을 이용하여 하나의 값으로 $g(\theta)$를 추정하는 방법
  - 구간추정(interval estimation) : 두 개의 구간 $[T_1(\underline{X}),T_2(\underline{X})]$ 사이에 모수가 포함될 확률을 나타내어 추정하는 방법
- 구간추정이 좀 더 많은 정보를 제공한다는 관점에서 선호되는 추정

방법.

- 하지만 대부분의 추정이론은 점추정에 관한 부분임.
- 그 이유는 구간추정은 점추정 값에 오차한계를 더해놓은 형태로 표현되므로, 좋은 점추정량을 찾는 것이 좋은 구간추정을 가능하게 하기 때문임. 따라서 4장 추정이론의 많은 부분도 점추정의 이론을 다룸.

- 점 추정량을 찾는 방법
  - 적률이용 추정법 (Methods of Moments)
  - 최대가능도 추정법(Maximum Likelihood, ML)
  - Bayes 추정법
  - 최소제곱 추정법(Least Squares, LS)

- 점 추정량의 평가 방법
  - 추정량 평가의 기준(MSE)
  - 최소분산불편추정량(UMVUE)
    - Rao-Cramer의 정보부등식을 이용하는 방법
    - 충분통계량과 완비통계량의 성질을 이용하는 방법

- 구간추정의 과정
  - 추축변량(pivotal quantity)를 사용하는 방법

- **[정의] 랜덤표본**
  - 모집단 분포가 확률밀도함수 $f(x;\theta),\ \theta\in\Omega$인 모집단에서의 랜덤

표본 $X_1, X_2, \cdots, X_n$이란 $X_1, X_2, \cdots, X_n \sim^{iid} f(x;\theta),\ \theta \in \Omega$을 뜻한다.

- **[정의 4.1] 통계량(Statistic), 추정량(Estimator)과 추정치(estimate)**
  - 미지의 모수를 포함하지 않는 랜덤표본 $X_1, \cdots, X_n$의 함수를 통계량이라 함. $T(X) = T(X_1, X_2, \cdots, X_n)$.

    (예제) $X_1, \cdots, X_n \sim f(x;\theta),\ \overline{X},\ S^2$

  - 모수 θ의 함수 $g(\theta)$를 추정하기 위하여 사용되는 통계량 $T(X) = T(X_1, X_2, \cdots, X_n)$를 $g(\theta)$의 추정량(estimator)이라 함.
  - $X_1, \cdots, X_n$의 주어진 표본값 $x_1, \cdots, x_n$를 대입하여 구해진 추정량의 특정값 $T(x) = T(x_1, \cdots, x_n)$을 추정값(estimate)(추정치)이라 함.

- (예제 4.1) $X_1, \cdots, X_n$을 $N(\mu, \sigma^2)$에서 얻은 랜덤표본이라 하자.

[풀이]

$X_i \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$ 에서 표본평균 $\bar{X} = \sum X_i/n$ 은 μ 의 불편추정량이고,

$S^2 = \sum (X_i - \bar{X})^2/(n-1)$ 은 σ^2 의 불편추정량이다.

관측 후에는 $x = \sum xi/n, s^2 = \sum (xi - x)^2/(n-1)$ 을 계산해 추정값으로 사용한다.

분산의 최대가능도 추정량은 $S^2_{\text{ML}} = \sum (X_i - \bar{X})^2/n$ 으로, 불편표본분산 S^2와 분모가 다르다.

- μ와 σ^2에 대한 점 추정량
  - $\hat{\mu} = T_1(X_1, \cdots, X_n) = \sum_{i=1}^{n} X_i/n,$
  - $\widehat{\sigma^2} = T_2(X_1, \cdots, X_n) = \sum_{i=1}^{n} (X_i - \overline{X})^2/(n-1)$
- 표본이 주어졌을 때, μ와 σ^2에 대한 점 추정값

- $T_1(x_1,\cdots,x_n)=\sum_{i=1}^{n}x_i/n,$
- $T_2(x_1,\cdots,x_n)=\sum_{i=1}^{n}(x_i-\overline{x})^2/(n-1)$

4.1 적률이용 추정법(Method of Moments Estimation; MME)

- 랜덤표본을 이용하여 모평균 $\mu=E(X)$를 추정할 때, 표본평균 $\overline{X}=(X_1+\cdots+X_n)/n$를 이용하는 것과 마찬가지로 모집단 적률 $E(X^r)$을 추정할 때 표본적률 $\widehat{m_r}=\frac{1}{n}(X_1^r+\cdots,X_n^r)$을 이용하는 것이 자연스럽다는 전제하에서 출발.

- 표본적률과 모적률
  - $\mu_r{}'=E(X^r)$: r차 모집단 적률,
  - $m_r{}'=\frac{1}{n}(X_1^r+\cdots,X_n^r)=\frac{1}{n}\sum_{i=1}^{n}X_i^r$: r차 표본 적률

- 일반적으로 모적률 $\mu_r{}'$은 모수벡터 $\theta=(\theta_1,\cdots,\theta_k)'$의 함수 $[\mu_r{}'=g(\theta_1,\cdots,\theta_k)]$ 이므로 k개의 연립방정식

$$m_j{}'=\mu_j{}'(\theta_1,\theta_2,\cdots,\theta_k),\quad j=1,\cdots,k$$

를 풀면 해 $(\widehat{\theta_1},\cdots,\widehat{\theta_k})$를 구할 수 있으며, 이를 $\theta=(\theta_1,\cdots,\theta_k)'$에 대한 적률추정량이라 함.

- **(예제) 미지의 모수가 2개인 경우**
  - $\overline{X}=m_1{}'=\mu_1{}'(\theta_1,\theta_2)=E(X)$
  - $\sum_{i=1}^{2}X_i^2/n=m_2{}'=\mu_2{}'(\theta_1,\theta_2)=E(X^2)$

- 두 식을 θ_1과 θ_2에 대하여 풀면 MME를 구할 수 있음.

[풀이]

$\theta = (\theta 1, \theta 2)$ 를 갖는 분포에서 모적률 $m1(\theta) = E_\theta(X), m2(\theta) = E_\theta(X^2)$ 를 먼저 구한다.

표본적률 $m'1 = \bar{X}, m'2 = (1/n)\sum X_i^2$ 를 대응시켜

$m1(\theta 1, \theta 2) = \bar{X}, m2(\theta 1, \theta 2) = (1/n)\sum X_i^2$ 를 동시에 푼다.

얻은 해를 $\hat{\theta}_MOM$ 이라고 한다. 식의 해가 여러 개면 적률추정이 유일하지 않을 수 있다.

- MME는 대수의 법칙에 의하여 r차 모적률이 존재할 때, r차 표본적률은 표본의 크기가 커짐에 따라 r차 모적률로 확률적 수렴한다는 사실에 기초한 방법.
- n이 크다면 표본적률이 확률적으로 모적률에 매우 가깝게 되므로 표본적률을 이용하여 모적률을 추정하는 것은 합리적인 방법이며, 비교적 쉽게 얻을 수 있는 추정량

- [예제 4.2] $X_1, \cdots, X_n \sim N(\mu, \sigma^2)$

  [풀이]

  $X \sim N(\mu, \sigma^2)$ 이면 $E(X) = \mu, E(X^2) = \mu^2 + \sigma^2$ 이다.

  첫 모적률 = 표본적률로 $\hat{\mu} = \bar{X}$.

  둘째 식에서 $\hat{\sigma}^2 = (1/n)\sum X_i^2 - \bar{X}^2 = (1/n)\sum(X_i - \bar{X})^2$.

  이는 정규분포 σ^2 의 MLE와 같고, 불편표본분산과는 다르다.

- [예제 4.3] 감마분포에서 적률추정, $X_1, \cdots, X_n \sim GAM(k, \theta)$

  [풀이]

  $X \sim \text{Gamma}(k, \theta)(shapek, scale\theta)$ 이면 $E(X) = k\theta, \text{Var}(X) = k\theta^2$.

  표본분산의 분모를 n으로 둔 $v_n = (1/n)\sum(X_i - \bar{X})^2$ 라 할 때

  $\bar{X} = \hat{k}\hat{\theta}, v_n = \hat{k}\hat{\theta}^2$ 를 풀면

  $\hat{k}_M OM = \bar{X^2}/v_n, \hat{\theta}_M OM = v_n/\bar{X}$.

  두 모수는 표본평균과 표본 2차 중심적률에서 구한다.

- [연습문제 4.3] MME의 비유일성 (포아송 분포 모수 추정)

  [풀이]

  $X \sim \text{Poi}(\lambda)$ 에서 $E(X) = \lambda$ 이고 $E(X^2) = \lambda + \lambda^2$ 이다.

  1차 적률을 사용하면 $\hat{\lambda}_1 = \bar{X}$ 이다.

  2차 적률만 사용하면 $m'2 = (1/n)\sum X_i^2$ 에 대해 $\hat{\lambda}_2 = (-1 + \sqrt{1 + 4m'2})/2$ 이다.

  둘 다 적률을 일치시키는 방식이지만 일반적으로 값이 다르다. 따라서 어떤 적률을 사용할지 지정하지 않으면 적률추정법의 결과가 유일하지 않을 수 있다.

- [예제] 다차원 MME(모상관계수의 적률추정량)

[풀이]

두 확률변수 (X,Y)의 상관계수 $\rho = \text{Cov}(X,Y)/(\sigma_X \sigma_Y)$ 를 표본적률로 추정한다.

$\mu X, \mu Y$ 를 X, Y로 대체하고 Cov를 $(1/n)\sum(X_i - \bar{X})(Y_i - \bar{Y})$, 분산들을 각 2차 중심표본적률로 대체하면

$\hat{\rho} = \sum(X_i - \bar{X})(Y_i - \bar{Y}) / \sqrt{[\sum(X_i - \bar{X})^2][\sum(Y_i - \bar{Y})^2]}.$

이는 일반적인 피어슨 표본상관계수이다.

4.2 최대가능도 추정법 [Maximum Likelihood Estimation; MLE]

- [예제] 성공의 확률이 p인 베르누이 분포에서 크기가 10인 랜덤표본을 뽑아 관측된 표본을 통해 성공률을 추정하고자 함.
  - 이때 성공률을 0.1과 0.9 둘 중에 하나라고 가정
  - 만약 10개의 관측치 합이 8이라면, 성공률이 0.1이라고 하는 것이 좋을까? 아니면 0.9라고 하는 것이 합리적일까?

    - 왜 성공률을 0.9로 추정하는 것이 0.1로 추정하는 것보다 합리적일까?

[풀이]

합 $K = 8$ 이 관측되면 (특정 표본배열에 대한) 가능도는 $L(p) = p^8(1-p)^2$ 이다.

따라서 $L(0.9)/L(0.1) = (0.9/0.1)^8(0.1/0.9)^2 = 9^6 = 531,441.$

성공률 0.9 의 가능도가 0.1 의 가능도보다 훨씬 크다.

최대가능도 추정값은 $\hat{p} = K/10 = 0.8$ 이다 (0.1 과 0.9 중에서만 고르면 0.9).

- 아마도 표본에서 합이 8인 관측치를 얻을 확률이 성공률 0.9가 참일 경우가 성공률 0.1이 참일 경우에 비하여 높기 때문.

- **결합확률밀도함수(joint pdf)와 가능도 함수(Likelihood Function)**
  - $X_1,\cdots,X_n$의 joint pdf가 $f(x_1,\cdots,x_n;\theta)$라고 하자.
    - 이는 고정된 θ하에서 $(x_1,\cdots,x_n)$이 나타날 가능성으로 $(x_1,\cdots,x_n)$의 함수로 표현됨.
  - 가능도 함수(Likelihood function; LF) : 이제 관점을 달리하여 $f(x_1,\cdots,x_n;\theta)$를 관측치 $X_1 = x_1,\cdots,X_n = x_n$이 주어졌을 때, **모수 ($\theta \in \Omega$)의 함수로 생각할 수 있음.**

$$L(\theta) = L(\theta; x_1,\cdots,x_n) = f(x_1,\cdots,x_n;\theta)$$

    - 가능도 함수 $L(\theta)$는 주어진 자료 $(x_1,\cdots,x_n)$에 대하여 $(x_1,\cdots,x_n)$이 나타날 가능성을 모수 θ의 함수로 나타냄.
  - 특정한 θ의 값과 $(x_1,\cdots,x_n)$가 주어진 상태에서 joint pdf와 가능도함수는 같은 함수값을 갖음.
    - 하지만 가능도 함수와 joint pdf는 함수로서는 서로 다른 함수

임.

- joint pdf : θ가 주어졌을 때 표본값 $(x_1,\cdots,x_n)$이 나타날 가능성을 나타내는 함수로 $(x_1,\cdots,x_n)$**의 함수**이며, 확률밀도함수임.
- 반면 가능도 함수는 표본값 $(x_1,\cdots,x_n)$이 얻어졌을 때, 이 표본값이 가능성을 모수 θ**의 함수**로 표현한 것으로 pdf가 아님.

- 만일 $X_1,\cdots,X_n$이 $f(x;\theta)$로부터 얻어진 랜덤샘플이라 하면, 이 경우 $X_1,\cdots,X_n$의 joint pdf는 다음과 같이 구해짐.

$$f(x_1,x_{2,}\cdots,x_n\,;\theta)=\prod_{i=1}^{n}f(x_i;\theta).$$

- 마찬가지로 가능도함수는 다음과 같이 구해짐.

$$L(\theta)=L(\theta\,;x_1,x_{2,}\cdots,x_n)=\prod_{i=1}^{n}f(x_i;\theta)$$

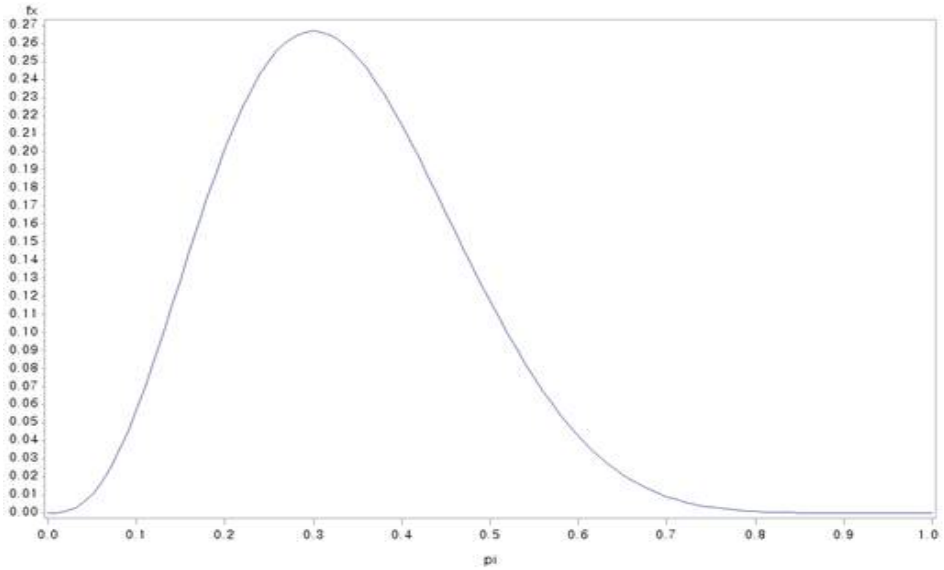
- **[정의 4.2] 최대가능도(Maximum Likelihood) 추정량(ML estimator)**
  - 랜덤표본의 가능도함수 $L(\theta;x_1,\cdots,x_n)$을 최대화하는 θ의 값을 $\hat{\theta}=\hat{\theta}(x_1,\cdots,x_n)\in\Omega$라고 할 때, $\hat{\theta}=\hat{\theta}(X_1,\cdots,X_n)$을 모수 θ의 최대가능도 추정량이라 함.
  - 주어진 $x=(x_1,\cdots,x_n)$에 대하여, 다음을 만족시키는 $\hat{\theta}(x)$를 θ의 최대가능도 추정값이라 함.

$$L(\hat{\theta}(x);\ x)=\max_{\theta\in\Omega}\ L(\theta;\ x)$$

- 각각의 관측 결과 $x=(x_1,\cdots,x_n)'$에 대하여 최대가능도 추정값 $\hat{\theta}(x)$가 정의될 때, 통계량 $\hat{\theta}_{ML}=\hat{\theta}(X)=\hat{\theta}(X_1,\cdots,X_n)$를 최대가능도 추정량이라 함. [주어진 자료에서 얻어진 추정값을 랜덤인 상황으로 확장]

  - $\hat{\theta}(x)$: 실제 관측된 자료 $x=(x_1,\cdots,x_n)'$가 얻어질 확률을 가장 크게 만드는 θ의 값.
  - $\hat{\theta}_{ML}=\hat{\theta}(X)=\hat{\theta}(X_1,\cdots,X_n)$: θ에 대한 추정량. 추정량은 랜덤샘플의 함수이므로 통계량 : 확률변수 $\Leftrightarrow$ 확률분포

- (예제) $X_1,\cdots,X_n \sim B(1,p)$, $n=10,\ \sum_{i=1}^{10}x_i=3$, 가능도 함수



[풀이]

X1,…,X10 iid Bernoulli(p), $\sum$xi=3이면

$L(p) = p^3(1-p)^7 (0 \le p \le 1).$

로그가능도 $\ell(p) = 3logp + 7log(1-p)$, 도함수는 $\ell^{'}(p) = 3/p - 7/(1-p).$

$\ell^{'}(p) = 0$ 에서 $\hat{p} = 3/10 = 0.3,$

$\ell^{''}(p) = -3/p^2 - 7/(1-p)^2 < 0$ 이므로 유일한 최대이다.

- $\sum_{i=1}^{10} x_i = 3$이 나타날 가능성을 p의 함수로 표현하고, 이를 그래프로 나타낸 것.
  - $p = 0.3$에서 $\sum_{i=1}^{10} x_i = 3$이 나타날 가능성이 가장 큼.
  - 따라서 p에 대한 ML 추정값은 $\hat{p} = 0.3 = \sum_{i=1}^{n} x_i/10$이 됨.
- 이를 추정량의 형태로 만들면, $\hat{p}_{ML} = \sum_{i=1}^{n} X_i/n$이 p에 대한 ML 추정량이 됨.

■ [예제 4.4] $Y \sim B(5,p)$

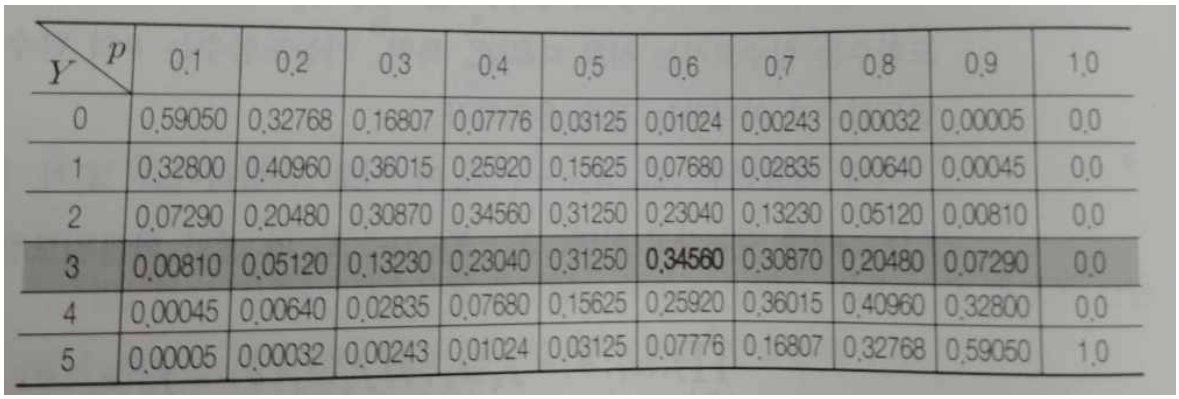
[풀이]

$Y \sim$ Bin$(5,p), Y = y$ 가 관측되었다면 $L(p) = \binom{5}{y} p^y (1-p)^{5-y}.$

$\ell^{'}(p) = y/p - (5-y)/(1-p) = 0$ 을 풀면 $\hat{p} = y/5$ 이다.

$y = 3$ 이면 $\hat{p} = 3/5 = 0.6$ 이며 이때 최대확률은

$\binom{5}{3}(0.6)^3(0.4)^2 = 0.3456$ 이다.



Y \ p	0.1	0.2	0.3	0.4	0.5	0.6	0.7	0.8	0.9	1.0
0	0.59050	0.32768	0.16807	0.07776	0.03125	0.01024	0.00243	0.00032	0.00005	0.0
1	0.32800	0.40960	0.36015	0.25920	0.15625	0.07680	0.02835	0.00640	0.00045	0.0
2	0.07290	0.20480	0.30870	0.34560	0.31250	0.23040	0.13230	0.05120	0.00810	0.0
3	0.00810	0.05120	0.13230	0.23040	0.31250	0.34560	0.30870	0.20480	0.07290	0.0
4	0.00045	0.00640	0.02835	0.07680	0.15625	0.25920	0.36015	0.40960	0.32800	0.0
5	0.00005	0.00032	0.00243	0.01024	0.03125	0.07776	0.16807	0.32768	0.59050	1.0

- $Y = y(=3)$이 얻어진 경우, $p = 0.6$에서 가능도가 0.3456으로 최대가 됨.
  - $\hat{p}(y) = 0.6 = y/5$가 p에 대한 ML 추정값이 됨.
- 따라서 p에 대한 ML 추정량은 이를 통계량의 형태로 확장시킨 $\hat{p}_{ML} = Y/n$이 됨.

■ ML 추정량을 찾는 방법

- **가능도 함수가 미분이 가능하면 미분을 이용(가장 흔히 사용되는 방법)**
  - 로그가능도함수[$\log L(\theta;\ x_1,\cdots,x_n) = \sum_{i=1}^{n} \log f(x_i;\ \theta)$]를 최대화함. 로그가능도함수에 대한 미분을 적용함.
- **가능도 함수가 미분이 가능하지 않은 경우**
  - 가능도함수 $L(\theta)$를 θ의 모수공간 Ω에서 직접 그래프로 그리고, $L(\theta)$를 최대로 만드는 θ의 값을 직접 찾으면 됨.

4.2.1 가능도함수가 미분가능한 경우 ML 추정

- 로그함수가 단조증가함수이므로 $L(\theta)$를 최대로 만드는 θ의 값에서 $\log L(\theta)$도 최대가 되고, 그 반대도 성립함.

$$\hat{\theta} = \max_{\theta} L(\theta; x_1, \cdots, x_n) \quad \Leftrightarrow \quad \hat{\theta} = \max_{\theta} \log L(\theta; x_1, \cdots, x_n)$$

- 주로 제 1차 미분을 0으로 놓고 해를 구함.

$$\frac{d}{d\theta} \log L(\theta;\ x_1, \cdots, x_n) = 0$$

  - 위 식을 만족하는 값이 곧 로그가능도함수를 최대화한다는 보장은 없음.
  - 엄밀한 의미에서 최대화 여부는 2차 미분 등 다른 방법으로 보여야 함.

■ **[예제 4.5]** 지수분포에서 ML 추정

[풀이]

$X_i \overset{\text{iid}}{\sim}$ Exp(scale θ), $\theta > 0$ 라 하면

$L(\theta) = \theta^{-n}$ exp$[-(\sum xi)/\theta]$,

$\ell(\theta) = -nlog\theta - (\sum xi)/\theta.$

$\ell'(\theta) = -n/\theta + (\sum xi)/\theta^2 = 0$ 에서 $\hat{\theta} = \bar{X}.$

θ 가 평균(척도) 대신 발생률 $\lambda = 1/\theta$ 로 정의된 경우에는 $\hat{\lambda} = 1/\bar{X}$ 이다.

■ **[예제 4.6]** $X_1, \cdots, X_n \sim P(\lambda)$

[풀이]

$X_i \overset{\text{iid}}{\sim}$ Poi(λ)일 때

$$L(\lambda) = \frac{e^{-n\lambda}\lambda^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n x_i!}.$$

따라서 로그가능도의 미분은

$$\ell'(\lambda) = -n + \frac{\sum_i x_i}{\lambda}, \qquad \ell''(\lambda) = -\frac{\sum_i x_i}{\lambda^2}.$$

$\sum_i x_i > 0$이면 $\ell'' < 0$이고 $\ell' = 0$의 해는

$$\boxed{\hat{\lambda}_{\text{MLE}} = \bar{X}.}$$

표본합이 0이면 $\lambda = 0$이 허용되는 모수공간에서 경계 추정값은 0이다.

■ 수치적인 방법에 의한 ML 추정

- 제 1차 미분이 폐쇄적인 형태로 표현되지 않는 경우

※ 참고사항 [정리] 순오목함수

- **수직선 위의 열린구간 Ω_0에서 정의된 함수 $l(\theta)$가 두 번 미분가능하고 이차도함수가 연속함수일 때**

$$\frac{\partial^2 l(\theta)}{\partial \theta^2} < 0, \quad \forall \theta \in \Omega_0 \text{이고} \quad \lim_{\theta \to \pm\infty} l(\theta) = -\infty$$

이면 방정식 $\frac{\partial l(\theta)}{\partial \theta} = 0$의 근 $\hat{\theta}$는 존재하고, 그러한 근은 유일하다.

- **[예제 4.8]** 로지스틱 분포

  [풀이]

  교재의 로지스틱 밀도를 $f(x;\theta) = e^{\theta - x}/[1 + e^{\theta - x}]^2$ 로 쓴다.

  $\ell(\theta) = \sum(\theta - xi) - 2\log[1 + e^{\theta - xi}]$.

  $\ell'(\theta) = n - 2\sum e^{\theta - xi}/[1 + e^{\theta - xi}]$.

  $\ell''(\theta) = -2\sum e^{\theta - xi}/[1 + e^{\theta - xi}]^2 < 0$ 이므로 우도방정식의 해는 유일한 최대이다.

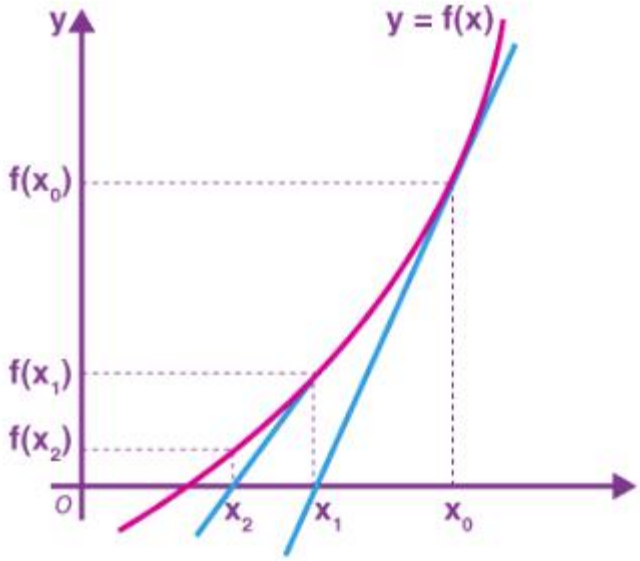
  일반 표본에서는 닫힌 해가 없으므로 수치해법을 적용한다.

- **수치적인 방법으로 ML추정량을 구하는 방법(Newton-Raphson method)**

  - 로그가능도 함수에 대한 1차 미분을 테일러 전개 방식에 의하여 근사하고, 1차 미분=0이 되는 값을 수치적으로 구함.

  - $g(\theta) = \frac{d\log L(\theta)}{d\theta}$라 정의하면, $g(\theta) = 0$가 되는 θ가 ML 추정량이 됨

$$\hat{\theta}_{r+1} = \hat{\theta}_r + \left[-g'(\hat{\theta}_r)\right]^{-1} g(\hat{\theta}_r), \quad (r = 0,1,2,\cdots)$$



- **[예제 4.8]** 로지스틱 분포(계속)

  [풀이]

  로지스틱 위치모수 θ 의 점수함수를 $g(\theta) = \ell^{'}(\theta)$ 로 두면

  $\theta_{r+1} = \theta_r - g(\theta_r)/g^{'}(\theta_r)$

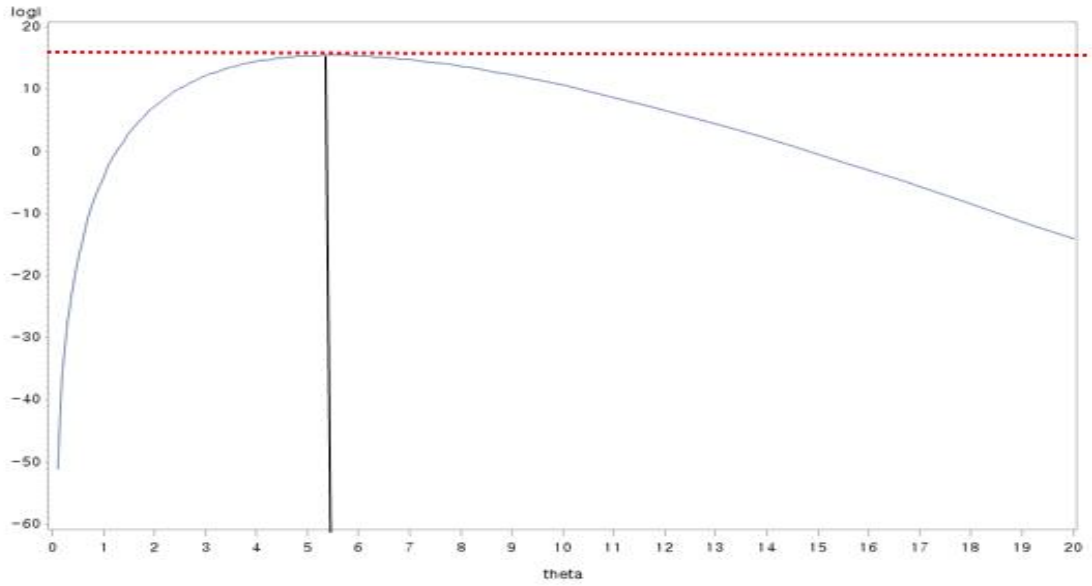
  $= \theta_r + [n - 2\sum s_i(\theta_r)]/[2\sum s_i(\theta_r)(1 - s_i(\theta_r))],$

  여기서 $s_i(\theta) = e^{\theta - xi}/[1 + e^{\theta - xi}]$ 이다.

  초기값 θ_0 을 표본중앙값으로 두고 변화가 충분히 작아질 때까지 반복한다.

  구체적인 관측값이 없는 강의노트에는 일반 반복식을 채운다.

- [예제] Poisson 분포에서 ML 추정 $(n = 4, \quad \sum_{i=1}^{4} x_i = 22)$



ITER	THETA	NEWTHETA	FIRST	SECOND	LOGL
1	4	5.0909091	1.5	-1.375	14.498476

ITER	THETA	NEWTHETA	FIRST	SECOND	LOGL
2	5.0909091	5.4695718	0.3214286	-0.848852	15.440405

ITER	THETA	NEWTHETA	FIRST	SECOND	LOGL
3	5.4695718	5.4998317	0.0222527	-0.735387	15.50412

ITER	THETA	NEWTHETA	FIRST	SECOND	LOGL
4	5.4998317	5.5	0.0001224	-0.727317	15.504458

ITER	THETA	NEWTHETA	FIRST	SECOND	LOGL
5	5.5	5.5	3.7473E-9	-0.727273	15.504458

[풀이]

$X_i \overset{\text{iid}}{\sim} \text{Poi}(\lambda), n = 4, \sum xi = 22$ 이면

$\ell(\lambda) = -4\lambda + 22 \log \lambda - \sum \log(xi!).$

$\ell'(\lambda) = -4 + 22/\lambda = 0$ 이므로 $\hat{\lambda} = 22/4 = 5.5.$

$\ell''(5.5) = -22/(5.5)^2 < 0$ 이어서 최대값이다.

4.2.2 가능도함수가 미분 불가능한 경우 또는 불연속인 경우 ML 추정

- 가능도 함수의 증가, 감소를 조사하여 최대가능도 추정값을 찾음

- [예제 4.9] 균등분포에서 ML 추정

[풀이]

$X_i \overset{\text{iid}}{\sim} U(0,\theta), \theta > 0$ 라 하면 $L(\theta) = \theta^{-n} \cdot 1\theta \geq max(x1, \cdots, xn).$

허용영역 $\theta \geq x_n$ 에서 $L(\theta) = \theta^{-n}$ 은 θ 가 증가하면 감소한다.

따라서 $\hat{\theta}_{\text{ML}} = X_n = max(X_1, \cdots, X_n).$

지지집합이 모수에 의존하므로 미분 방정식만 풀어서는 안 된다.

4.2.3 다차원 모수의 ML 추정 [정규분포, 감마분포 …]

- **[정의] 다차원 모수의 ML추정량**
  - 모수가 2개이상인 벡터 $\theta = (\theta_1, \cdots, \theta_k)' \in \Omega$ 인 경우 가능도 함수 $L(\theta_1, \cdots, \theta_k ; x_1, \cdots, x_n)$를 최대로하는 $\hat{\theta}(x) = (\hat{\theta}_1(x), \cdots, \hat{\theta}_k(x))$이라 할

때, $\hat{\theta}_{ML}(X) = (\hat{\theta}_{1,ML}(X), \cdots, \hat{\theta}_{k,ML}(X))$을 ML 추정량이라 정의함.

- **첫 번째 방법 :**
  - k개의 연립방정식

$$\frac{d}{d\theta_i} \log L(\theta_1, \cdots, \theta_k) = 0, \quad i = 1, \cdots, k$$

을 풀어서 구한 해가 로그가능도함수를 최대로 하는지 여부를 체크하여 ML 추정량을 구할 수 있음.

  - [2차 미분 (2X2 행렬) : 음정치행렬인지 체크]

- **또다른 방법 :** 순차적으로 MLE를 유도함.

$$\max_{\theta_1, \theta_2} L(\theta_1, \theta_2) = \max_{\theta_1} [\max_{\theta_2} L(\theta_1, \theta_2)] = \max_{\theta_1} L(\theta_1, \widehat{\theta_2})]$$

- **[예제 4.7]** 정규분포

[풀이]

$X_i \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$ 에서

$\ell(\mu, \sigma^2) = -nlog(2\pi)/2 - (n/2)log\sigma^2 - \sum(xi - \mu)^2/(2\sigma^2).$

$\partial\ell/\partial\mu = \sum(xi - \mu)/\sigma^2 = 0 \rightarrow \hat{\mu} = \bar{X}.$

$\hat{\mu}$ 를 대입하고 $\partial\ell/\partial\sigma^2 = 0$ 을 풀면 $\hat{\sigma}^2 = (1/n)\sum(X_i - \bar{X})^2.$

이는 μ 와 σ^2 의 동시 최대가능도 추정량이다.

- **[예제-연습문제 4.6]** $X_1, \cdots, X_n \sim f(x; \theta_1, \theta_2)$,

$$f(x; \theta_1, \theta_2) = \frac{1}{\theta_2} \exp\left(-\frac{1}{\theta_2}(x - \theta_1) \right), \quad x \geq \theta_1, \theta_2 > 0$$

4.2.4 MLE의 불변성(invariance property)

- **[정리 4.1] ML 추정량의 불변성**

[풀이]

$f(x;\theta 1,\theta 2)=\theta 2^{-1}\exp[-(x-\theta 1)/\theta 2], x\geq\theta 1,\theta 2>0.$

관측 후 $m=min(x1,\cdots,xn), x=(\sum xi)/n$ 이면

$L(\theta 1,\theta 2)=\theta 2^{-n}\exp[-n(x-\theta 1)/\theta 2]\cdot 1\theta 1\leq m.$

고정된 $\theta 2$ 에서 가능도는 $\theta 1$ 에 대해 증가하므로 $\hat{\theta}1=m.$

이를 대입하면 $\hat{\theta}2=x-m($ 표본에 서로 다른 값이 있을 때).

모든 관측값이 같으면 $\theta 2\rightarrow 0$ 으로 우도가 발산하므로 보통의 내부 MLE가 존재하지 않는다.

  - **$X_1,\cdots,X_n$이 pdf $f(x;\theta),\ \theta\in\Omega$에서 얻은 랜덤표본이라 하자. $\widehat{\theta_n}$ 이 모수 θ의 MLE이라면 θ의 함수인 $g(\theta)$에 대하여, $g(\widehat{\theta_n})$이 $g(\theta)$의 MLE가 된다.**

- **[증명] θ의 일대일 변환인 경우**

[증명]

$\eta = g(\theta)$ 가 일대일이면 역함수 $\theta = h(\eta)$ 가 존재한다.

η에 대한 가능도는 $L_\eta(\eta; x) = L_\theta(h(\eta); x)$ 이다.

$\hat{\theta}$ 가 L_θ 를 최대화하면 $\hat{\eta} = g(\hat{\theta})$ 가 L_η를 최대화한다.

일대일이 아니면 $L_\eta(\eta; x) = sup_{\theta: g(\theta)=\eta} L_\theta(\theta; x)$ 로 정의하여 같은 결론을 얻는다.

따라서 θ 의 MLE를 먼저 구한 뒤 함수 g를 대입하면 된다.

- 정규분포에서 모분산인 σ^2을 모수로 하거나 모표준편차인 $\sigma = \sqrt{\sigma^2}$를 모수로 하거나 확률밀도함수가 변하지 않는다. 즉, 모수의 일대일 변환에 따라 pdf는 변하지 않는다.

- 따라서 σ^2을 모수로 두는 것이 미분이 좀 더 쉽다고 한다면, σ^2의 MLE를 먼저 구하고, 여기에 제곱근을 취하여 σ의 MLE를 구할 수 있음.

- [예제 4.14] 지수분포에서 λ에 대한 MLE,

  [풀이]

  $X_i \overset{\text{iid}}{\sim}$ Exp(scale λ) 라 하고 $g(\lambda) = P(X > 1) = e^{-1/\lambda}$.

  $\hat{\lambda}_{\text{ML}} = \bar{X}$ 이므로 불변성에 의해

  $\hat{g}_{\text{ML}} = e^{-1/\bar{X}}$ 이다.

  미지의 척도모수 대신 표본평균을 대입하면 된다.

  $g(\lambda) = P(X > 1) = \exp(-1/\lambda)$의 MLE

- [예제] $X_1,\cdots,X_n \sim B(1,p),\ 0<p<1$

  $\eta(p)=\frac{p}{1-p}$의 MLE?

  $\eta(p)=p(1-p)$의 MLE?

  [풀이]

  Xi iid Bernoulli(p), p̂=X이다.

  승산 $(odds)\eta(p)=p/(1-p)$ 의 MLE는 $\hat{p}/(1-\hat{p})(0<\hat{p}<1).$

  $\eta(p)=p(1-p)$ 의 MLE는 p̂(1-p̂)이다.

  함수 p(1-p)는 일대일이 아니지만 최대가능도 추정량의 불변성은 여전히 성립한다.

5장 가설검정 part 1

■ 검정이론

- 모집단 성질에 대한 어떤 가설을 받아들일 것인지 아니면 기각할 것인지 결정
  - 어떤 질병을 치료하는데 있어서 기존 방법과 새로운 방법 사이의 효과차이 존재여부
  - 기계부품의 평균수명이 얼마 이상
  - 초등학교 6학년 남학생의 키의 평균이 과거 10년전과 동일하게 150cm인가? 아니면 더 커졌는가?

■ 어떻게?

- 점추정과 마찬가지로 확률밀도함수 $f(x;\theta)$로부터 랜덤표본 $X_1,\cdots,X_n$을 얻

  [풀이]

  예를 들어 과거 평균키가 150cm였고 현재 평균키가 더 커졌는지 판단하려면,

  $H_0 : \mu = 150, H_1 : \mu > 150$ 으로 가설을 세운 뒤 랜덤표본의 표본평균을 구한다.

  미리 정한 유의수준 α에서 기각역과 검정통계량을 정하고, 관측 통계량의 p-value가 α 이하이면 H0를 기각한다.

  기각하지 못한다는 것은 '평균이 동일함을 증명했다'는 뜻이 아니다.

  어서 가설검정 실시.

- 검정의 대상은 표본이 추출된 모집단의 분포에 관함.

5.1 검정의 기본 요소

■ [정의 5.1] 통계적 가설

- 관심있는 모집단의 성질에 대한 단정이나 추측 등의 표현(statement)을 통계적 가설(statistical hypothesis)이라 한다.
- 단순가설(simple hypothesis) : 어떤 가설이 확률분포를 완전히 결정하는 경우
- 복합가설(composite hypothesis) : 어떤 가설이 확률분포를 완전히 결정하지 못하는 경우

- **[예 5.1]** $X_1, \cdots, X_n$이 $N(\mu, \sigma^2)$을 따르는 랜덤샘플이라 할 때 , 모분포의 성격을 표시하는 모수벡터 (μ, σ^2)에 대한 가설을 고려함.
  - (예) $(\mu, \sigma^2) = (0, 1)$이라는 가설을 고려. 이 가설이 참이라는 가정 하에서 모집단의 분포는 $N(0, 1)$이 됨. 즉, 모집단의 분포가 완전히 결정됨.
    $\rightarrow$ 단순가설
  - (예) $\mu > \mu_0$이라는 가설. 이 가설이 참이라는 가정 하에서도 모집단의 분포는 정확히 결정되지 않음 $\rightarrow$ 복합가설

- **[정의] 귀무가설(null hypothesis)과 대립가설(alternative hypothesis)**
  - 귀무가설(null hypothesis, H_0) : 현재까지 알려진 사실 또는 주장. 특별한 사유가 없다면 일반적으로 받아들이는 가설.
    (예) 차이가 없다. 키의 평균은 150이다. 등

- 대립가설(alternative hypothesis, H_1) : 지금까지 알려져 있는 것과 다른 주장. 이를 뒷받침하는 증거가 있어야만 받아들이는 가설

  (예) 두 약의 효과 차이가 있다. 키의 평균은 150보다 크다. 등등

- **통계적 가설검정 :** 기존의 사실을 귀무가설(H_0), 연구자가 보이고자 하는 가설을 대립가설(H_1)로 택하여 귀무가설을 기각할만한 증거가 있는지를 실험 또는 관찰을 통하여 얻은 통계자료에 근거하여 찾아보는 것이 일반적인 방법

- 귀무가설을 기각하거나 기각하지 않는 결정을 내리는데 사용할 수 있는 좋은 검정법을 찾고자 함.
  - 표본에 근거하기 때문에 언제나 옳은 결정을 내리지는 못함.
  - 잘못된 결정을 내릴 확률이 작은 검정법을 찾을려고 노력함. 이를 위해서 다음과 같이 기각영역을 설정하여 오류의 확률을 계산함.

- **[정의] 검정통계량(test statistic)과 기각역(rejection region)**

  - **검정통계량(Test Statistic)** : 주어진 표본 $X_1,\cdots,X_n$에 근거하여 통계적 가설에 대한 증거를 살펴볼 때 사용되는 통계량. 즉, 귀무가설과 대립가설 중에서 결정하는 데 사용되는 통계량.
  - 기각영역(Rejection region) : 귀무가설을 기각하게 되는 검정통계량의 값을 가지는 표본공간의 부분집합. Reject H_0 if $\{(x_1,\cdots,x_n)\in C\}$
  - 채택영역(Acceptance region) : 기각영역의 여집합. 귀무가설을 기각하지 못하는 표본공간의 부분집합.

- **[예 5.2]** $X_1,\cdots,X_{25} \sim_{iid} N(\mu,10^2),\quad [H_0:\mu=100 \quad vs \quad H_1:\mu=105]$
  - 검정통계량 : 어떤 통계량을 이용하여 위 가설을 검정할까?
    - 모평균에 대한 가설검정이므로 표본평균 $\overline{X}$를 사용하여 검정하는 것이 타당함.
  - 어떨 때 귀무가설을 기각하고 대립가설을 채택할까?
    - 표본평균 $\overline{X}$가 큰 값을 가지는 경우, 즉 $\{(x_1,\cdots,x_n)\ ;\ \overline{x}>c\}$이면 귀무가설을 기각함 $\rightarrow$ $\{(x_1,\cdots,x_n)\ ;\ \overline{x}>c\}$: 기각영역

- **[예제 5.4] 예 5.2에서 계속**
  - 구체적으로 기각영역을 $C=\{(x_1,\cdots,x_{25});\ \overline{x}_{25}\geq 104\}$라 정의.
    - 즉 25개 표본의 표본평균이 104보다 크거나 같으면 귀무가설을 기각하고 대립가설을 채택.
    - 채택영역은 $C^c=\{(x_1,\cdots,x_{25});\ \overline{x}_{25}<104\}$이 됨.

- **[정의] 제 1종 오류와 제 2종 오류**

  [풀이]

  $X_i \overset{\text{iid}}{\sim} N(\mu,10^2), n=25$ 에서 $H_0:\mu=100$ 대 $H_1:\mu>100$ 이라고 하자.

  X의 표준오차는 $10/\sqrt{25}=2$ 이다.

  기각영역 $\bar{X}\geq 104$ 는 $Z=(\bar{X}-100)/2\geq 2$ 와 같다.

  따라서 제1종 오류확률 $\alpha=P(Z\geq 2)=0.0228$ 이며,

  실제 평균이 $\mu=105$ 라면 제2종 오류확률 $\beta=P_105(\bar{X}<104)=\Phi(-0.5)\approx 0.3085$ 이다.

- **[정의] 유의수준(α)과 β**

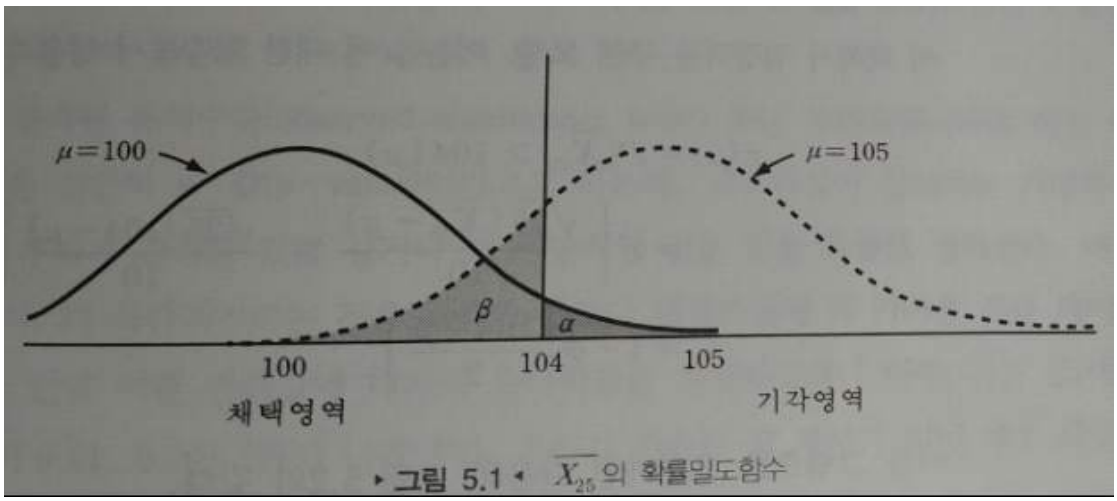
- $\alpha = P(\text{제1종 오류}) = P[H_0\text{를 기각함}|H_0]$
  - $\alpha = P[(X_1,\cdots,X_n)\in C|\,H_0] = \int\cdots\int_C f(x_1,\cdots,x_n|H_0)dx_1dx_2\cdots dx_n$
  - 또는 다른 책에서는 귀무가설 H_0가 참일 때 기각하는 오류의 최대허용 한계를 유의수준이라 함.
- $\beta = P(\text{제2종 오류}) = P[H_0\text{를 기각하지 않음}|H_1]$
  - $\beta = P[(X_1,\cdots,X_n)\notin C|\,H_1] = \int\cdots\int_{C^c} f(x_1,\cdots,x_n|H_1)dx_1dx_2\cdots dx_n$

- **[예 5.4 계속]** $X_1,\cdots,X_{25} \sim_{iid} N(\mu,10^2)$, **[**$H_0:\mu=100 \quad vs \quad H_1:\mu=105$**]**
  - $\alpha = P(\overline{X}_{25}\geq 104|H_0) = P\left(\dfrac{\sqrt{25}(\overline{X}_{25}-100)}{10} \geq \dfrac{\sqrt{25}(104-100)}{10}\,|\;\mu=100\right)$

$$= P(Z\geq 2) = 0.0228$$

  - $\beta = P(\overline{X}_{25}\leq 104|H_1) = P\left(\dfrac{\sqrt{25}(\overline{X}_{25}-105)}{10} \leq \dfrac{\sqrt{25}(104-105)}{10}\,|\;\mu=105\right)$

$$= P(Z\leq -0.5) = 1-0.6015 = 0.3085$$



▸그림 5.1◂ $\overline{X}_{25}$의 확률밀도함수

- 따라서 기각역이 $C=\{(x_1,\cdots,x_{25});\,\overline{x}_{25}\geq 104\}$인 검정은 $\alpha=0.0228$인 가설검정임.

■ 통계적 가설검정

- 표본을 통해 귀무가설에 대한 충분한 반증을 찾기 전까지는 귀무가설이 참이라고 가정
- 귀무가설에 대한 충분한 반증을 찾지 못해 기각하지 못하게 되는 경우, 이것은 표본으로부터 귀무가설이 맞다는 증거를 찾은 것이 아니라 귀무가설이 틀렸다는 충분한 증거를 찾지 못한 것임.

- 통계적 가설검정에서는 일반적으로 제 1종 오류를 좀 더 중요하게 생각함.
  - 제 1종 오류를 범하게 되면, 지금까지 믿어온 일반적 믿음이 참임에도 불구하고 새로운 변화를 인정하게 되므로 불필요한 대체가 이루어짐. 따라서 제 1종 오류가 크다면 연구의 결과가 신뢰받기 어렵다.
  - 그래서 제 1종 오류를 범할 확률, 즉 유의수준이 항상 작은 값이 되도록 관리함.

- 만일 $\alpha = 0.05$인 검정을 찾고 싶다면?
  - $\alpha = 0.05 = P\left[\overline{X}_{25} > c \mid \mu = 100\right]$인 c를 찾으면 됨.
    - $P\left(\overline{X}_{25} \geq c | H_0\right) = P\left(\dfrac{\sqrt{25}\,(\overline{X}_{25} - 100)}{10} \geq \dfrac{\sqrt{25}\,(c-100)}{10} \mid \ \mu = 100\right)$

$$= P\left(Z \geq \frac{c-100}{2}\right) = 0.05$$

    - $\dfrac{c-100}{2} = 1.645 \quad \rightarrow \quad c = 103.29$
  - 즉, 기각역을 $C^* = \left\{(x_1, \cdots, x_{25});\, \overline{x}_{25} \geq 103.29\right\}$로 바꾸면 $\alpha = 0.05$인 검정

을 만들 수 있음.

- 이 경우 β값은 어떻게 될까?

[풀이]

같은 정규모형 $(n=25, \sigma=10)$ 에서 $\alpha=0.05$ 이면

$c = 100 + z_{0.05} \cdot (10/5) = 100 + 1.64485 \cdot 2 \approx 103.29.$

실제 평균 $\mu=105$ 일 때 $\beta = P_1 05(\bar{X} < 103.29)$

$= \Phi[(103.29-105)/2] \approx \Phi(-0.855) \approx 0.1963.$

검정력은 $1-\beta \approx 0.8037$ 로, 기존 기준 104의 검정력 0.6915 보다 높다.

- **[정의 5.2] 검정력 함수(power function)**
  - 랜덤표본 $X_1, \cdots, X_n$을 얻은 모집단의 분포가 모수 θ에 의해 특징지어질 때
    - 귀무가설 H_0에 대한 기각영역이 C인 검정의 **검정력 함수(power function)**는 특정한 θ에서 귀무가설을 기각하는 확률로 다음과 같이 정의된다.

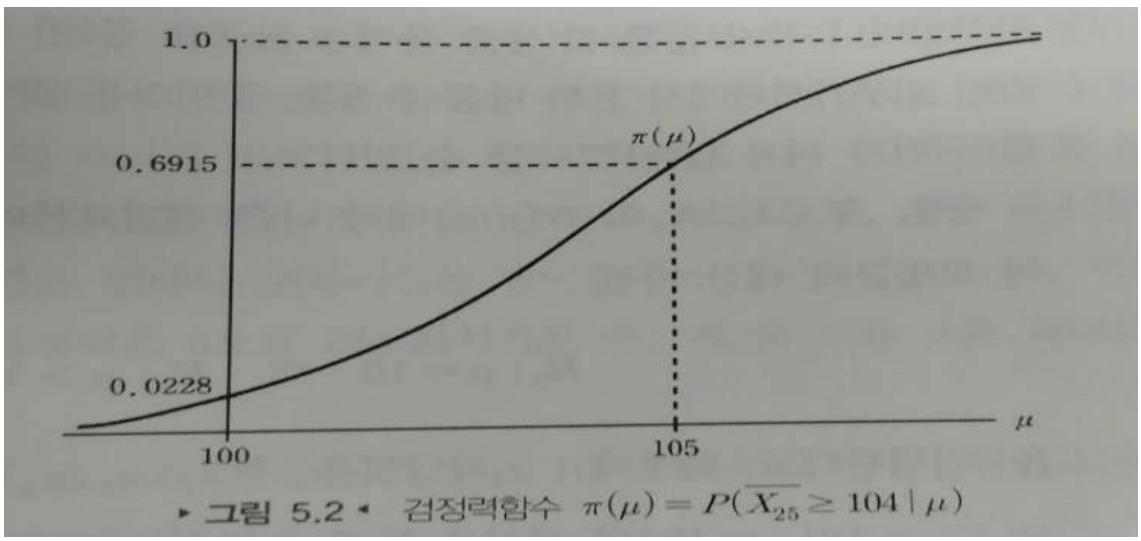
$$\pi(\theta) = P\big[(X_1, \cdots, X_n) \in C \mid \theta\big]$$

  - 검정력 함수는 모수 θ의 참값이 무엇이냐에 따라 다른 값을 가지므로 θ의 함수이고, 주어진 θ에서 $\pi(\theta)$를 θ에서의 검정력이라 함.
    - 검정력은 귀무가설을 기각할 확률이므로 θ가 대립가설에 속하는 값이면 검정력이 큰 것이 좋고, θ가 귀무가설에 속하는 값이면 작을수록 좋다.
    - 대립가설이 단순가설인 경우, 그 모수에서 검정력은 $1-\beta$와 동일한 값. 즉, $\pi(\theta_1) = 1-\beta$
    - 모수 θ가 단순귀무가설 H_0에서의 값 θ_0(예 5.2, $\mu=100$)을 가질 때 검

정력은 유의수준 α와 같다. 즉, $\pi(\theta_0)=\alpha$

- **[예 5.5]** 예제 5.4 계속,
  - 기각영역을 $C=\{(x_1,\cdots,x_{25});\ \bar{x}_{25}\geq 104\}$라 했을 때 $\mu=105$에서의 검정력을 계산 $\rightarrow$ $\pi(105)=P[\overline{X}_{25}\geq 104|\mu=105]=1-\beta$
  - $\mu>100$인 모든 μ에서 검정력을 구하면?
    - $\pi(\mu)=P(\overline{X}_{25}\geq 104|\ \mu)=P\left(\dfrac{\sqrt{25}\,(\overline{X}_{25}-\mu)}{10}\geq\dfrac{\sqrt{25}\,(104-\mu)}{10}|\ \ \mu\right)$

$$=P\left(Z\geq\frac{104-\mu}{2}\right)=1-\Phi\left(\frac{104-\mu}{2}\right)$$



▸ 그림 5.2 ◂ 검정력함수 $\pi(\mu)=P(\overline{X_{25}}\geq 104\,|\,\mu)$

[풀이]

$\bar{X}\sim N(\mu,4)$, 기각영역 $C=\bar{X}\geq 104$ 일 때

$\pi(\mu)=P_\mu(\bar{X}\geq 104)=1-\Phi[(104-\mu)/2]$.

$\mu=100$ 에서는 $\pi(100)=1-\Phi(2)=0.0228$(제1종 오류확률),

$\mu=105$ 에서는 $\pi(105)=1-\Phi(-0.5)=\Phi(0.5)\approx 0.6915$ 이다.

기준을 $c=103.29$ 로 바꾸면 $\pi_c(\mu)=1-\Phi[(103.29-\mu)/2]$ 이다.

- **[정의] 유의확률(p-value)**

- 실제 관측값(d_0)이 얻어진 경우(예 5.2, $\bar{x}_{25} = 104.6$), 귀무가설이 참이라는 가정하에서 현재 얻어진 관측값보다 더 극단적인 값을 얻을 확률. (관측값이 귀무가설을 기각하는 방향으로 나타날 확률)

- $H_0 : \mu = 100 \quad vs \quad H_1 : \mu < 100$
  - 귀무가설을 기각하는 방향 : $\overline{X}$가 작을수록 기각함.
  - 관측값으로 $\bar{x} = 98$이 얻어진 경우,

$$p - value = P\left[\overline{X} < 98 \mid H_0\right] = P\left[\overline{X} < 98 \mid \mu = 100\right]$$

- $H_0 : \mu = 100 \quad vs \quad H_1 : \mu > 100$
  - 귀무가설을 기각하는 방향 : $\overline{X}$가 클수록 기각함.
  - 관측값으로 $\bar{x} = 98$이 얻어진 경우,

$$p - value = P\left[\overline{X} > 98 \mid H_0\right] = P\left[\overline{X} > 98 \mid \mu = 100\right]$$

- 유의확률 p-value가 아주 작은 값이 나왔다면(예, p=0.01, 0.001), 우리가 관측한 값은 귀무가설이 참이라는 가정하에서는 나타날 가능성이 매우 희박한 값이므로, 귀무가설을 기각하는 것이 타당함.
- 반면 유의확률 p-value가 큰 값이 나왔다면(예, p=0.40, 0.50), 우리가 관측한 값은 귀무가설이 맞다는 가정하에서도 흔하게 나타날 수 있는 값. 따라서 귀무가설을 기각하지 않는 것이 타당한 의사결정.
- 보통 p-value와 사전에 결정한 유의수준 α를 비교하여 가설검정을 실시함.
  - $p - value \le \alpha$: 유의수준 α에서 H_0를 기각함.

- $p-value > \alpha$: 유의수준 α에서 H_0를 기각하지 못함.

- **[예제 5.2 계속]** 실제 25개 표본의 표본평균 $\overline{x}_{25} = 104.6$으로 나타났다면,

$$p = P\left(\overline{X}_{25} \geq 104.6 | H_0\right)$$

$$= P\left(\frac{\sqrt{25}\,(\overline{X}_{25} - 100)}{10} \geq \frac{\sqrt{25}\,(104.6 - 100)}{10} \mid \mu = 100\right)$$

$$= P(Z \geq 2.3) = 0.0107$$

- **[예제] 표본크기에 따른 검정력 함수 [**$X_1, \cdots, X_n \sim N(\mu, 10^2)$**]**

  - 가설 $H_0 : \mu = \mu_0 (= 60) \quad vs \quad H_1 : \mu > \mu_0 (= 60)]$

  - 기각역 :

$$C = \left\{(x_1, \cdots, x_n);\ \overline{x} \geq \mu_0 + z_\alpha \sigma / \sqrt{n}\right\} = \left\{(x_1, \cdots, x_n);\ \overline{x} \geq 60 + 1.645 * 10 / \sqrt{n}\right\}$$

[풀이]

$X_i \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$, 알려진 $\sigma = 10, H_0 : \mu = 60$ 대 $H_1 : \mu > 60$, 유의수준 $\alpha = 0.05$.

기각영역은 $\bar{X} \geq 60 + 1.645 \cdot 10/\sqrt{n}$ 이다.

검정력은 $\pi_n(\mu) = 1 - \Phi[1.645 + \sqrt{n}(60 - \mu)/10]$.

예를 들어 $\mu = 63$ 이면 $n = 25$ 의 검정력은 $1 - \Phi(0.145) \approx 0.442$,

$n = 100$ 이면 $1 - \Phi(-1.355) \approx 0.912$ 이다. 같은 평균 차이에서 n이 클수록 검정력이 커진다.

- 검정력 함수

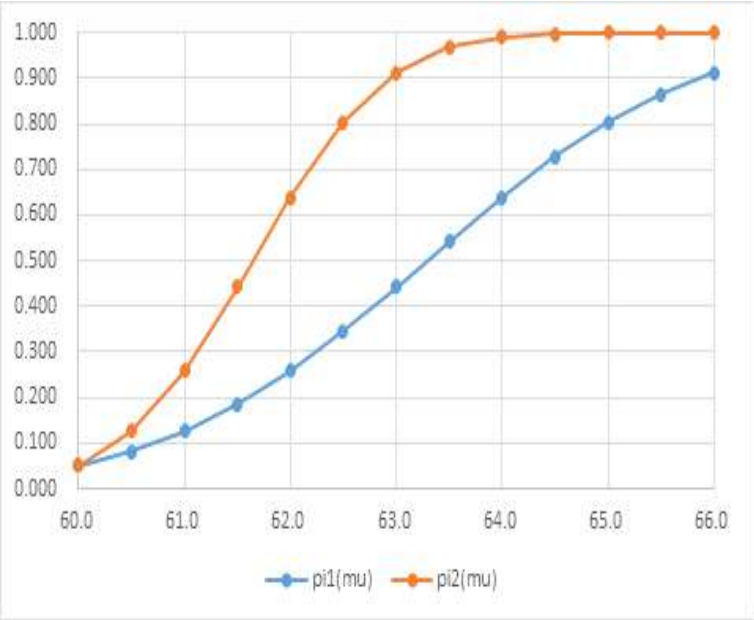
$$\pi(\mu) = P\left[\overline{X} \geq \mu_0 + z_\alpha \sigma/\sqrt{n}\right] = P\left(\frac{\overline{X} - \mu}{\sigma/\sqrt{n}} \geq \frac{\mu_0 + z_\alpha \sigma/\sqrt{n} - \mu}{\sigma/\sqrt{n}}\right)$$

$$= P\left(Z \geq \frac{\mu_0 - \mu}{\sigma/\sqrt{n}} + z_\alpha\right) = 1 - \Phi\left(\frac{\sqrt{n}(\mu_0 - \mu)}{\sigma} + z_\alpha\right)$$

- $n = 25, \quad \pi_1(\mu) = 1 - \Phi\left(\frac{5(60-\mu)}{10} + 1.645\right) = 1 - \Phi\left(\frac{(60-\mu)}{2} + 1.645\right)$

- $n = 100, \ \pi_2(\mu) = 1 - \Phi\left(\frac{10(60-\mu)}{10} + 1.645\right) = 1 - \Phi(60 - \mu + 1.645)$

mu	pi1(mu)	pi2(mu)
60.0	0.050	0.050
60.5	0.082	0.126
61.0	0.126	0.259
61.5	0.185	0.442
62.0	0.259	0.639
62.5	0.346	0.804
63.0	0.442	0.912
63.5	0.542	0.968
64.0	0.639	0.991
64.5	0.727	0.998
65.0	0.804	1.000
65.5	0.865	1.000
66.0	0.912	1.000



5장 가설검정 Part 2 – LRT

5.3 일반화 가능도비 검정(Generalized Likelihood Ratio Test)

■ **일반적인 상황에서의 가설검정**

- 대립가설이 양측가설인 경우
- 검정의 직접대상이 아닌 장애모수(nuisance parameter)가 존재하는 경우

→ Neyman-Pearson원리에 의한 UMP test는 적용할 수 없음.

- 따라서 점추정에서 최대가능도 원리를 사용하는 것과 비슷한 방법으로 일반화 가능도비 검정을 사용함. 실제 문제에서 사용되는 대부분의 검정법은 일반화 가능도비 검정이거나 그의 변형임.

■ **[정의 5.6] 일반화 가능도비**

- 랜덤표본 $X_1,\cdots,X_n$의 결합 pdf가 $f(x_1,x_2,\cdots,x_n;\theta)$로 주어졌다고 하자. 이제 가설 $H_0 : \theta\in\Omega_0$ vs $H_1 : \theta\in\Omega_1(=\Omega-\Omega_0)$를 고려할 때, 일반화 가능도비는 다음과 같이 정의된다.

$$\Lambda(x_1,x_2,\cdots,x_n)=\frac{\max_{\theta\in\Omega_0}L(\theta;x_1,\cdots,x_n)}{\max_{\theta\in\Omega}L(\theta;x_1,\cdots,x_n)}=\frac{L(\widehat{\theta_0})}{L(\widehat{\theta_n})}$$

여기서 $\widehat{\theta_n}$은 모든 parameter space(Ω)에서 얻은 모수 θ의 ML 추정량을 나타내며, $\widehat{\theta_0}$은 귀무가설이 참이라는 조건하에서 가능도함수를 최대로 만드는 θ의 ML 추정량이다.

- [예제] $X_1,\cdots,X_n\sim N(\mu,\,\sigma^2)$, $\Omega_0,\,\Omega_1$ 및 Ω는?

1) $H_0 : \mu = 0 \quad vs \quad H_1 : \mu \neq 0$

2) $H_0 : \mu \leq 0 \quad vs \quad H_1 : \mu > 0$

[풀이]

$X_i \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$이고 모수공간은 $\Omega = R \times (0, \infty)$이다.

(1) $H_0 : \mu = 0$ 대 $H_1 : \mu \neq 0$이면

$$\Omega_0 = \{(0, s) : s > 0\}, \quad \Omega_1 = \{(m, s) : m \neq 0,\ s > 0\}.$$

(2) $H_0 : \mu \leq 0$ 대 $H_1 : \mu > 0$이면

$$\Omega_0 = \{(m, s) : m \leq 0,\ s > 0\}, \quad \Omega_1 = \{(m, s) : m > 0,\ s > 0\}.$$

여기서 s는 모분산 σ^2의 가능한 값을 뜻한다.

■ 일반화 가능도비의 성질

- 항상 0과 1사이의 값을 갖음[Ω_0은 전체모수공간 Ω의 부분집합이기 때문]

- $\Lambda(x_1, \cdots, x_n) \approx 1$인 경우, 귀무가설하에서 얻어진 최대가능도 값과 전체 모수공간에서 얻어진 최대가능도 값이 비슷한 값.

  → 귀무가설하에서 얻어진 ML추정량과 전체 모수공간에서 얻어진 ML추정량이 비슷한 값. 관측된 자료를 가장 잘 설명하는 모수값이 귀무가설에 포함됨.

  → 따라서 귀무가설을 기각하기 어렵다.

- 반면 $\Lambda(x_1, \cdots, x_n) \to 0$인 경우, 귀무가설하에서 얻어진 최대가능도 값이 전체 모수공간에서 얻어진 최대가능도 값보다 매우 작음.

  → 귀무가설하에서 얻어진 ML추정량은 전체 모수공간에서 얻어진 ML 추정량으

로부터 멀리 떨어져 나타남.

→ 귀무가설에서 관측된 자료를 설명하는 것보다 대립가설이 관측된 자료를 잘 설명함.

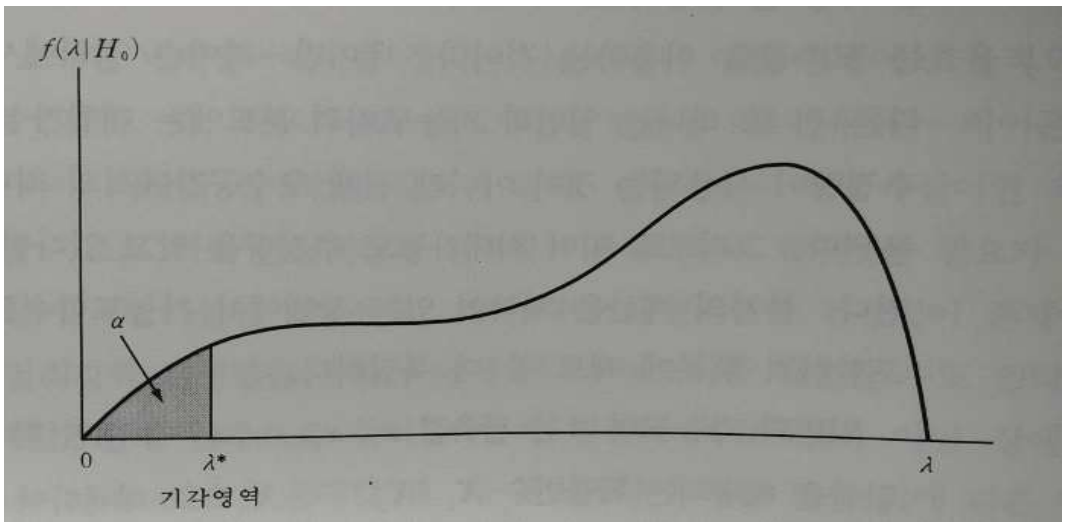
→ 따라서 귀무가설을 기각하는 증거로 판단 가능함.

■ **[정의 5.7] (일반화 가능도비 검정)**

▪ 유의수준이 α인 일반화 가능도비 검정법은 $0 < \Lambda \leq \lambda^*$인 경우 H_0를 기각한다. 단 λ^*는 $\max P(0 < \Lambda \leq \lambda^* \mid H_0) = \alpha$를 만족하는 상수이며, $0 < \lambda^* < 1$이다.

■ **λ^*는 어떻게 찾을까?**

▪ 만일 귀무가설하에서 확률변수 Λ의 pdf를 아는 경우, 즉 $f(\lambda \mid H_0)$인 경우 $\lambda^* = \int_0^{\lambda^*} f(\lambda \mid H_0) d\lambda$를 풀어서 λ^*를 구함.



▪ Λ의 분포가 알려지지 않은 경우(보통의 경우), Λ의 단조변환꼴로 표현되는 통계량

의 귀무가설하에서의 분포를 이용하여 기각영역을 구함.

[풀이]

일반화 가능도비는 $\Lambda = \dfrac{\sup_{\theta\in\Omega_0} L(\theta)}{\sup_{\theta\in\Omega} L(\theta)}$이며, $0 \le \Lambda \le 1$이다. Λ가 작을수록 귀무가설에 불리하다. 귀무가설하 통계량 Λ의 누적분포함수가 $F_{\Lambda|H_0}$라면, 유의수준 α에 대해 $F_{\Lambda|H_0}(\lambda^*) = \alpha$인 임곗값 λ^*를 정하고 $\Lambda \le \lambda^*$일 때 기각한다. 밀도가 있다면

$$\alpha = \int_0^{\lambda^*} f_{\Lambda|H_0}(u)\,du.$$

실제 검정에서는 $-2\log\Lambda$나 그 단조변환을 이용할 수도 있다.

- [예제 5.24] $H_0 : \sigma^2 = \sigma_0^2 \quad vs \quad H_1 : \sigma^2 \neq \sigma_0^2$

$$\Lambda = W^{n/2}\exp\left(-\frac{n}{2}W + \frac{n}{2}\right) \le \lambda^*, \quad \text{여기서} \quad W = \sum_{i=1}^{n}(X_i - \overline{X})^2$$

$$\Leftrightarrow \quad \frac{\sum_{i=1}^{n}(X_i-\overline{X})^2}{\sigma_0^2} \le \chi^2_{1-\alpha/2}(n-1) \quad \text{or} \quad \frac{\sum_{i=1}^{n}(X_i-\overline{X})^2}{\sigma_0^2} \ge \chi^2_{\alpha/2}(n-1)$$

[풀이]

정규표본 $X_1, \dots, X_n$에서 모평균은 미지이고 $H_0 : \sigma^2 = \sigma_0^2$를 검정한다고 하자. $W = \sum_{i=1}^{n}(X_i - \bar{X})^2 = (n-1)S^2$라 두면 귀무가설하 검정통계량은

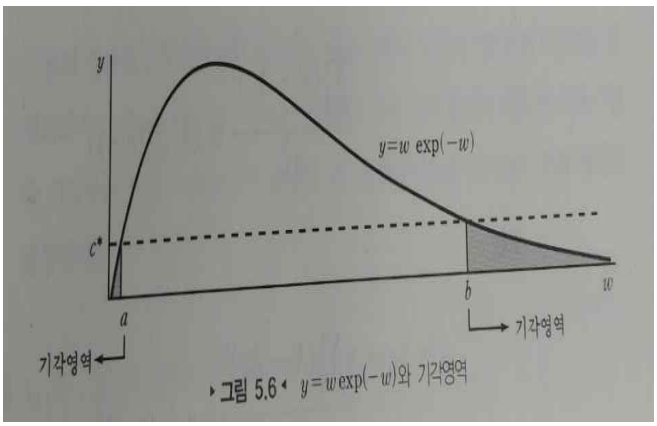
$$\boxed{Q = \frac{(n-1)S^2}{\sigma_0^2} \sim \chi^2_{n-1}.}$$

양측 등꼬리 검정에서 유의수준 α의 기각역은

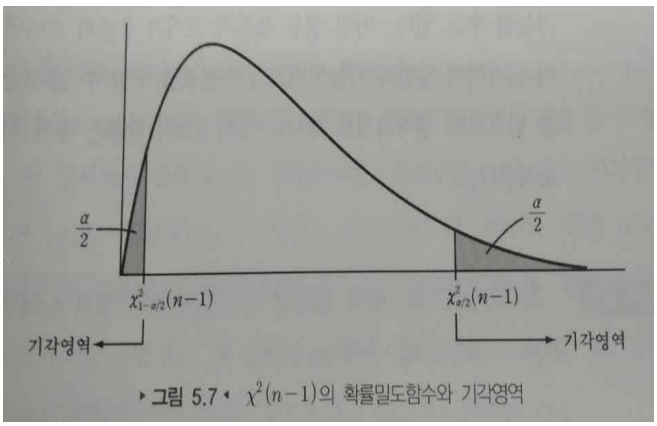
$$\boxed{Q \le \chi^2_{n-1,\alpha/2} \quad \text{또는} \quad Q \ge \chi^2_{n-1,1-\alpha/2}.}$$

여기서 $\chi^2_{\nu,q}$는 누적확률 q에 해당하는 χ^2_ν의 분위수이다. 양 끝 임계값의 표기를 교재의 분포표 방식에 맞추어 확인하면 된다.

교재의 주의점. 양쪽 꼬리에서 각각 $\alpha/2$를 택하는 카이제곱 검정은 유의수준 α의 편리한 양측검정이다. 엄밀한 일반화 가능도비 검정의 두 경계는 $w\exp(-w)$가 같은 임곗값을 갖게 하는 두 점으로 결정되며, 반드시 양쪽 꼬리 확률이 정확히 $\alpha/2$씩인 것은 아니다.



▸그림 5.6◂ $y = w\exp(-w)$와 기각영역



▸그림 5.7◂ $\chi^2(n-1)$의 확률밀도함수와 기각영역

[LR 검정의 그래프적 표현]

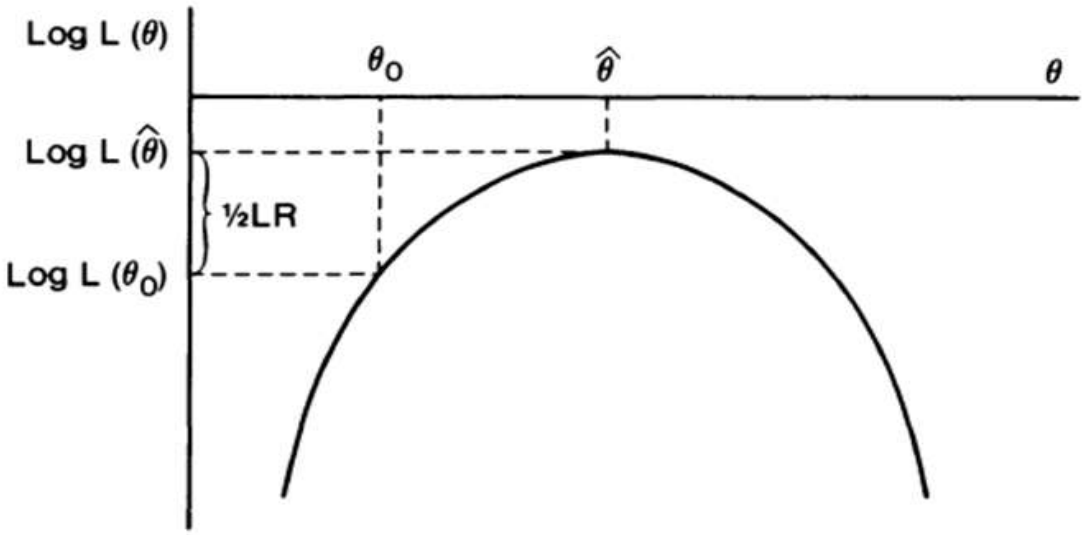


Figure 1. The Likelihood Ratio Test

- **[예제 5.22]** $X_1,\cdots,X_n \sim N(\mu,\sigma^2), \quad \sigma^2$: known

[풀이]

$X_i \overset{\text{iid}}{\sim} N(\mu,\sigma^2)$이고 모분산 σ^2가 알려져 있다고 하자. $H_0 : \mu = \mu_0$ 대 $H_1 : \mu \neq \mu_0$에서 전체 최대가능도 추정값은 $\hat{\mu} = \bar{X}$이다. 귀무가설하 최대가능도는 $L(\mu_0)$이므로

$$\Lambda = \frac{L(\mu_0)}{L(\bar{X})} = \exp\left[-\frac{n(\bar{X}-\mu_0)^2}{2\sigma^2}\right].$$

따라서

$$-2\log\Lambda = Z^2, \qquad Z = \frac{\sqrt{n}(\bar{X}-\mu_0)}{\sigma}.$$

귀무가설하 $Z \sim N(0,1)$이므로 양측 유의수준 α의 기각역은

$$\boxed{|Z| \geq z_{1-\alpha/2}.}$$

$$H_0 : \mu = \mu_0 \quad vs \quad H_1 : \mu \neq \mu_0$$

- **[예제 5.23]** $X_1,\cdots,X_n \sim N(\mu,\sigma^2), \quad \sigma^2$: unknown

[풀이]

$X_i \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$이고 모분산은 알려져 있지 않다고 하자. $H_0 : \mu = \mu_0$ 대 $H_1 : \mu \neq \mu_0$에서 전체 최대가능도 추정량은

$$\hat{\mu} = \bar{X}, \quad \hat{\sigma}^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - \bar{X})^2.$$

귀무가설하 최대가능도 추정량은

$$\hat{\sigma}_0^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - \mu_0)^2.$$

따라서

$$\Lambda = \left[\frac{\sum_i (X_i - \bar{X})^2}{\sum_i (X_i - \mu_0)^2}\right]^{n/2} = \left(1 + \frac{T^2}{n-1}\right)^{-n/2},$$

여기서 $T = \sqrt{n}\,(\bar{X} - \mu_0)/S$이다. 귀무가설하 $T \sim t_{n-1}$이므로

$$\boxed{|T| \geq t_{n-1,1-\alpha/2}}$$

일 때 기각한다.

$$H_0 : \mu = \mu_0 \quad vs \quad H_1 : \mu \neq \mu_0$$

- **[예제 5.24]** $X_1, \cdots, X_n \sim N(\mu, \sigma^2)$ $H_0 : \sigma^2 = \sigma_0^2$ vs $H_1 : \sigma^2 \neq \sigma_0^2$

[생략 – 풀어볼 것]

- **[예제]** $X_1, \cdots, X_n \sim \exp(\theta)$ $H_0 : \theta = \theta_0$ vs $H_1 : \theta \neq \theta_0$

[풀이]

$X_i \overset{\text{iid}}{\sim}$ Exp(scale θ)이고 $H_0 : \theta = \theta_0$ 대 $H_1 : \theta \neq \theta_0$를 검정하자. $\hat{\theta} = \bar{X}$이므로 일반화 가능도비는

$$\Lambda = \left(\frac{\bar{X}}{\theta_0}\right)^n \exp\left[n\left(1 - \frac{\bar{X}}{\theta_0}\right)\right].$$

따라서

$$-2\log\Lambda = 2n\left[\frac{\bar{X}}{\theta_0} - 1 - \log\left(\frac{\bar{X}}{\theta_0}\right)\right].$$

귀무가설하 $2\sum_i X_i/\theta_0 \sim \chi^2_{2n}$이다. 즉, $\bar{X}$가 지나치게 작거나 큰 영역에서 귀무가설을 기각한다.

- **[예제 5.25]** $X_1, \cdots, X_n \sim B(1, p), \quad H_0 : p = p_0 \quad vs \quad H_1 : p \neq p_0$

  [풀이]

  Xi iid Bernoulli(p), K=∑Xi, p̂=K/n이라 하면

  $L(p) = p^K(1-p)^{n-K}.$

  $H_0 : p = p0$ 대 H1: p≠p0에서

  $\Lambda = p0^K(1-p0)^{n-K}/[\hat{p}^K(1-\hat{p})^{n-K}]$

  (0^0 이 나타나는 경계에서는 해당 인자를 1로 정의한다).

  $-2\log\Lambda = 2n[\hat{p}\log(\hat{p}/p0) + (1-\hat{p})\log((1-\hat{p})/(1-p0))].$

  귀무가설하 $K \sim$ Bin$(n, p0)$; 작은 K와 큰 K 양쪽에 기각역이 놓인다.

■ [정리 5.3] (일반화가능도비검정의 카이제곱분포 근사)

- **최대가능도 추정량의 점근적 정규성을 보인 정리 4.14에서와 같은 적절한 조건이 만족될 때, $-2\log\Lambda(X_1, \cdots, X_n)$는 귀무가설하에서 자유도가 k인 카이제곱분포를 근사적으로 따른다.**
- **단, 자유도 k는 모수공간 Ω와 Ω_0에서 제약조건없이 자유로이 움직일 수 있는 모수 개수들의 차이이다.**

- **[Proof]** $k=1$**인 경우**

  [증명]

  정규성 조건이 성립하고 자유모수의 개수 차이가 k이면, 귀무가설하 $-2\log\Lambda \Rightarrow \chi^2(k)$.

  한 모수 θ 의 경우 로그가능도를 θ_0 주변에서 2차 테일러 전개한다:

  $$\ell(\hat{\theta}) \approx \ell(\theta_0) + U_n(\theta_0)(\hat{\theta}-\theta_0) - (1/2)I_n(\theta_0)(\hat{\theta}-\theta_0)^2.$$

  우도방정식으로 $\hat{\theta}-\theta_0 \approx U_n(\theta_0)/I_n(\theta_0)$ 이므로

  $$2[\ell(\hat{\theta}) - \ell(\theta_0)] \approx [U_n(\theta_0)]^2/I_n(\theta_0).$$

  귀무가설하 표준화 점수 $U_n(\theta_0)/\sqrt{I_n(\theta_0)} \Rightarrow N(0,1)$ 이므로 그 제곱은 $\chi^2(1)$ 로 수렴한다.

  여러 모수에서는 점수벡터의 정보행렬에 의한 이차형식 중 제약 k개의 부분이 $\chi^2(k)$ 가 된다. 경계모수 등의 비정규 상황에서는 이 근사가 성립하지 않을 수 있다.

- **[예제 5.25 계속]** 베르누이 분포

[풀이]

서로 독립인 표본 $X_1, \dots, X_n \sim$ Bernoulli(p)에서 $K = \sum_{i=1}^{n} X_i$이고, 표본비율은 $\hat{p} = K/n$이다. 귀무가설이 $H_0 : p = p_0$라면 중심극한정리에 의해

$$\boxed{Z = \frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)/n}} \overset{H_0}{\approx} N(0,1).}$$

유의수준 α에서 양측 근사 기각역은

$$\boxed{|Z| \geq z_{1-\alpha/2}}$$

이다. 같은 조건을 표본비율로 쓰면

$$\hat{p} \leq p_0 - z_{1-\alpha/2}\sqrt{\frac{p_0(1-p_0)}{n}} \quad \text{또는} \quad \hat{p} \geq p_0 + z_{1-\alpha/2}\sqrt{\frac{p_0(1-p_0)}{n}}.$$

표본크기가 충분히 크면 일반화가능도비통계량 $-2\log\Lambda$를 $Z^2 \sim \chi^2_1$로 근사하여 검정할 수 있다.

- **[예제 5.26]** 양측 t 검정

[풀이]

$X_1, \dots, X_n$이 서로 독립이고 $X_i \sim N(\mu, \sigma^2)$, σ^2는 미지수라고 하자. 양측 가설은

$$H_0 : \mu = \mu_0, \qquad H_1 : \mu \neq \mu_0.$$

표본표준편차 S를 쓰면 검정통계량은

$$\boxed{T = \frac{\sqrt{n}\,(\bar{X} - \mu_0)}{S} \overset{H_0}{\sim} t_{n-1}.}$$

가능도비통계량 Λ는

$$-2\log\Lambda = n\log\left(1 + \frac{T^2}{n-1}\right).$$

따라서 Λ가 작을수록 $|T|$가 커지고, 유의수준 α에서 정확한 기각역은

$$\boxed{|T| \geq t_{n-1,1-\alpha/2}}$$

이다. 표본크기가 클 때 $-2\log\Lambda$를 χ^2_1과 비교할 수도 있다.