4.1 통계량의 분포

모집단의 개수가 유한개일 경우에 비복원추출에 의한 표본을 이용하여 모집단에 대한 추측을 하는 방법의 타당성과 효율성을 연구하려면 비복원추출로 인한 추출 결과의 종속성에서 야기되는 어려움이 많다. 한편 복원추출에 의한 표본의 경우에는 추출 결과 사이의 독립성이 있기 때문에 추측 방법의 성질을 연구하는 것이 용이하다. 또한, 초기하분포의 이항분포 근사에서 알 수 있듯이 모집단 크기가 커짐에 따라 비복원추출에 따른 추측 방법의 성질이 복원추출에 의한 방법의 성질과 거의 같게 된다.

이러한 용이성과 근사성 때문에 통계적 추측 방법의 성질을 연구할 때에는 흔히 유한모집단에서의 복원추출을 개념화 하여 동일한 모집단을 독립적으로 관측하는 것을 전제로 한다.

이러한 이유에서 앞으로는 랜덤표본(random sample)이란 서로 독립이고 동일한 분포를 따르는 확률변수들을 뜻한다. 또한, 이러한 연구에서 가능한 모집단의 분포들을 모형으로 설정할 때 모형의 설정에 사용되는 매개변수를 모수(母數, population parameter)라고 하며, 가능한 모수 전체의 집합을 모수공간(母數空間, parameter space)이라고 한다.

예 4.1.1

(a) 공정의 불량률에 대한 통계 조사의 경우에 모집단분포는 베르누이분포 $\mathrm{Bernoulli}(p)$로 나타낼 수 있고, 불량률 p가 모수이고 미지인 불량률의 집합 $\Omega = \{p : 0 \le p \le 1\}$가 모수공간이다.

(b) 하천의 오염도를 조사할 때 하천 물의 단위 부피당 부유생물의 수에 대한 모형으로 포아송분포 $\mathrm{Poisson}(\lambda)$를 설정한다면, 평균 부유생물의 수 λ가 모수이고 미지인 λ의 집합 $\Omega = \{\lambda : \lambda \ge 0\}$가 모수공간이다.

(c) 많은 과학 실험에서 오차의 분포에 대한 모형으로 정규분포 $\mathrm{N}(\mu, \sigma^2)$을 모형으로 설정한다. 이 경우에는 평균과 분산을 나타내는 $\theta = (\mu, \sigma^2)^t$가 모수이고, 미지의 평균과 분산의 집합 $\Omega = \{(\mu, \sigma^2)^t : -\infty < \mu < +\infty,\ \sigma^2 > 0\}$가 모수공간이다.

이들 예에서 알 수 있듯이, 모수는 모집단 분포를 결정짓는 미지의 특성치로서 흔히 θ로 나타내고 모수공간은 Ω로 나타내며 모집단 분포는 확률밀도함수 $f(x;\theta)$로

나타낸다. 이러한 미지의 모집단 분포 또는 모수에 대한 추측을 목적으로 사용하는 랜덤표본의 관측 가능한 함수를 통계량(統計量, statistic)이라고 한다.

랜덤표본과 통계량:

모집단 분포가 확률밀도함수 $f(x;\theta)$, $\theta\in\Omega$인 모집단에서의 랜덤표본 $X_1, X_2, \cdots, X_n$이란

$$X_1, X_2, \cdots, X_n \overset{iid}{\sim} f(x;\theta),\ \theta\in\Omega$$

을 뜻하고, 통계량 $u(X_1, X_2, \cdots, X_n)$이란 랜덤표본의 함수로서 랜덤표본의 값이 주어지면 그 값이 정해지는 함수를 뜻한다.

예 4.1.2

(a) 불량률 p를 모수로 하는 베르누이분포 Bernoulli(p)에서의 랜덤표본을 $X_1, X_2, \cdots, X_n$이라고 할 때, 표본 중 불량개수의 합계 $X_1+X_2+\cdots+X_n$와 표본에서의 불량률을 나타내는 표본비율(標本比率, sample proportion)

$$\hat{p}=(X_1+X_2+\cdots+X_n)/n$$

은 모두 통계량이다.

(b) 랜덤표본 $X_1, X_2, \cdots, X_n$의 함수로서

$$\overline{X}=\frac{1}{n}(X_1+X_2+\cdots+X_n),\ S^2=\frac{1}{n-1}\sum_{i=1}^{n}(X_i-\overline{X})^2$$

을 각각 표본평균(標本平均, sample mean), 표본분산(標本分散, sample variance)이라고 하며, 모평균과 모분산의 추측에 사용되는 통계량이다.

(c) 모집단 분포가 연속형인 경우에 이 모집단에서의 랜덤표본 $X_1, X_2, \cdots, X_n$을 크기 순서로 늘어놓은 것을 $X_{(1)}<X_{(2)}<\cdots<X_{(n)}$이라고 할 때, 이들을 순서통계량(順序統計量, order statistics)이라고 한다. 또한 이들 크기의 가운데를 나타내는 통계량

$$\underset{1\le i\le n}{med}\ X_i=\begin{cases}X_{(m+1)}, & n=2m+1\text{일 때}\\ (X_{(m)}+X_{(m+1)})/2, & n=2m\text{일 때}\end{cases}$$

을 표본중앙값(標本中央값, sample median)이라고 하며, 모집단 분포의 중심부분에 대한 추측에 사용되는 통계량이다.

랜덤표본 $X_1, X_2, \cdots, X_n$의 함수인 통계량 $u(X_1, X_2, \cdots, X_n)$은 확률변수로서 분포를 가지며, 이는 모집단 분포에 따라 결정된다. 이러한 통계량의 분포를 일반적으로 표본분포(標本分布, sampling distribution)라고 한다.

예 4.1.3

(a) 불량률 p를 모수로 하는 베르누이분포 Bernoulli(p)에서의 랜덤표본을 $X_1, X_2, \cdots, X_n$이라고 할 때, 표본 중 불량품의 개수인 $X_1 + \cdots + X_n$은 이항분포 Bin(n,p)를 갖는다. 따라서 표본비율 $\hat{p} = (X_1 + \cdots + X_n)/n$은

$$P(\hat{p} = k/n) = \binom{n}{k} p^k (1-p)^{n-k}, \; k = 0, 1, \cdots, n$$

으로 주어지는 분포를 가지며 그 평균과 분산은 각각

$$E(\hat{p}) = p, \; Var(\hat{p}) = p(1-p)/n$$

이다. 즉 표본비율 $\hat{p}$은 표본크기가 커짐에 따라 모비율 p 주위에 집중되는 분포를 갖는다.

(b) 단위 부피당 평균 부유생물의 수가 λ인 포아송분포 Poisson(λ)에서의 랜덤표본을 $X_1, X_2, \cdots, X_n$이라고 할 때, <정리 3.4.1>로부터 표본 중 부유 생물의 합계 $X_1 + X_2 + \cdots + X_n$은 포아송분포 Poisson$(n\lambda)$를 갖는다. 따라서 표본평균 $\overline{X}$는

$$P(\overline{X} = k/n) = e^{-n\lambda} (n\lambda)^k / k!, \; k = 0, 1, \cdots$$

으로 주어지는 분포를 가지며 그 평균과 분산은 각각

$$E(\overline{X}) = \lambda, \; Var(\overline{X}) = \lambda/n$$

이다. 즉 표본평균 $\overline{X}$는 표본크기가 커짐에 따라 모평균 λ 주위에 집중되는 분포를 갖는다.

이제 랜덤표본의 함수인 통계량의 분포를 일반적인 경우에 구하는 방법을 알아보자. 일반적으로 확률변수 $X = (X_1, \cdots, X_n)^t$의 분포로부터 X의 함수인 $Y = u(X) = u(X_1, \cdots, X_n)$의 분포를 구하려면 Y에 관한 확률을 대응하는 X에 관한 확률로 바꾸어 계산해야 한다.

변수 변환과 확률밀도함수의 기본 관계:

(a) 이산형 경우

$$P(Y=y)=P(u(X)=y)=\sum_{x:u(x)=y}P(X=x)$$

$$\therefore\ pdf_Y(y)=\sum_{x:u(x)=y}pdf_X(x)$$

(b) 연속형 경우

$$P(Y\in y\pm|\Delta y|)=P(u(X)\in y\pm|\Delta y|)\approx\sum_{x:u(x)=y}P(X\in x\pm|\Delta x|)$$

$$\therefore\ pdf_Y(y)|\Delta y|\approx\sum_{x:u(x)=y}pdf_X(x)|\Delta x|,\ \text{즉}\ pdf_Y(y)\approx\sum_{x:u(x)=y}pdf_X(x)|\Delta y/\Delta x|^{-1}$$

예 4.1.4

(a) 서로 독립이고 각각 이항분포 $\mathrm{Bin}(n_1,p)$, $\mathrm{Bin}(n_2,p)$를 따르는 확률변수 X_1, X_2에 대하여 $Y=X_1+X_2$의 확률밀도함수는 다음과 같이 구할 수 있다.

$$\begin{aligned}pdf_Y(y)&=\sum_{x:x_1+x_2=y}\binom{n_1}{x_1}p^{x_1}(1-p)^{n_1-x_1}\binom{n_2}{x_2}p^{x_2}(1-p)^{n_2-x_2}\\&=\left\{\sum_{x_1=0}^{y}\binom{n_1}{x_1}\binom{n_2}{y-x_1}\right\}p^y(1-p)^{n_1+n_2-y}\\&=\binom{n_1+n_2}{y}p^y(1-p)^{n_1+n_2-y},\quad y=0,1,\cdots,n_1+n_2\end{aligned}$$

즉 $Y=X_1+X_2$의 분포는 이항분포 $\mathrm{Bin}(n_1+n_2,p)$로서 <정리 3.2.1>의 결과와 일치한다.

(b) 서로 독립이고 각각 포아송분포 $\mathrm{Poisson}(\lambda_1)$, $\mathrm{Poisson}(\lambda_2)$를 따르는 확률변수 X_1, X_2에 대하여 $Y=X_1+X_2$의 확률밀도함수는 다음과 같이 구할 수 있다.

$$\begin{aligned}pdf_Y(y)&=\sum_{x:x_1+x_2=y}\frac{e^{-\lambda_1}\lambda_1^{x_1}}{x_1!}\frac{e^{-\lambda_2}\lambda_2^{x_2}}{x_2!}\\&=\left\{\sum_{x_1=0}^{y}\binom{y}{x_1}\lambda_1^{x_1}\lambda_2^{y-x_1}\right\}\frac{e^{-\lambda_1-\lambda_2}}{y!}\\&=\frac{e^{-\lambda_1-\lambda_2}(\lambda_1+\lambda_2)^y}{y!},\quad y=0,1,\cdots\end{aligned}$$

즉 $Y=X_1+X_2$의 분포는 포아송분포 $\mathrm{Poisson}(\lambda_1+\lambda_2)$로서 <정리 3.4.1>의 결과와 일치한다.

(c) 표준정규분포를 따르는 확률변수 X에 대하여 $Y = X^2$의 확률밀도함수는 누적분포함수를 미분하여 다음과 같이 구할 수 있다.

$$\frac{d}{dy} cdf_Y(y) = \frac{d}{dy}\{P(X \le \sqrt{y}) - P(X \le -\sqrt{y})\}$$

$$= \frac{1}{2} y^{-1/2}\{pdf_X(\sqrt{y}) + pdf_X(-\sqrt{y})\}$$

$$\therefore pdf_Y(y) = \frac{d}{dy} cdf_Y(y) = \sum_{x : x^2 = y} pdf_X(x) \left| \frac{dy}{dx} \right|^{-1} = \frac{1}{\sqrt{2\pi}} y^{-1/2} e^{-y/2}, \ y > 0$$

그런데 $\Gamma(1/2) = \sqrt{\pi}$이므로, $Y = X^2$의 분포는 Gamma$(1/2, 2)$분포임을 알 수 있다.

정리 4.1.1 연속형 변수의 일대일 변환과 확률밀도함수

연속형의 k차원 확률변수 $X = (X_1, \cdots, X_k)^t$와 함수 $u = (u_1, \cdots, u_k)^t : \mathscr{X} \to \mathscr{Y}$에 대하여 다음이 성립한다고 하자.

(a) $P(X \in \mathscr{X}) = 1$

(b) 벡터값 함수 $u = (u_1, \cdots, u_k)^t : \mathscr{X} \to \mathscr{Y}$는 정의역이 $\mathscr{X}$이고 치역이 $\mathscr{Y}$인 일대일 함수이다.

(c) 함수 $u = (u_1, \cdots, u_k)^t$의 정의역 $\mathscr{X}$는 k차원 공간 R^k에서 열린집합이고, 함수 u가 미분가능하며 1차 편도함수가 연속함수로서 0이 아닌 야코비안(Jacobian) 행렬식을 갖는다. 즉

$$J_u(x) = \det\left(\frac{\partial}{\partial x_i} u_j(x)\right) \neq 0 \ \ \forall x \in \mathscr{X}$$

이 때, 확률변수 $X = (X_1, \cdots, X_k)^t$와 함수 u를 이용하여 정의된 k차원 확률변수

$$Y = u(X), \text{ 즉 } Y = (Y_1, \cdots, Y_k)^t = (u_1(X), \cdots, u_k(X))^t$$

의 확률밀도함수는 다음과 같이 주어진다.

$$pdf_Y(y) = pdf_X(u^{-1}(y)) |J_{u^{-1}}(y)|, \ y \in \mathscr{Y}$$

즉

$$pdf_Y(y) = pdf_X(x) \left| \det\left(\frac{\partial y}{\partial x}\right) \right|^{-1}, \ y = u(x) \in \mathscr{Y}$$

[증명] 부록 I의 치환적분법으로부터 $\mathscr{Y}$의 임의의 부분 집합 B에 대하여 다음이 성립함을 알 수 있다. 따라서 $Y = u(X)$의 확률밀도함수가 위에서와 같이 주어진다.

$$\begin{aligned} \mathrm{P}(\mathrm{Y}\in\mathrm{B}) &= \mathrm{P}(u(\mathrm{X})\in\mathrm{B}) \\ &= \int_{x\in u^{-1}(\mathrm{B})} pdf_{\mathrm{X}}(x)dx \\ &= \int_{y\in\mathrm{B}} pdf_{\mathrm{X}}(u^{-1}(y))|J_{u^{-1}}(y)|dy \ (\because x = u^{-1}(y)\text{로 치환}) \end{aligned}$$

예 4.1.5 위치모수와 척도모수를 이용한 확률분포

연속형 확률변수 Z의 확률밀도함수가 $f(z)$일 때, 양수 σ와 실수 μ에 대하여

$$\mathrm{X} = \sigma\mathrm{Z} + \mu$$

로 정의된 확률변수 X의 확률밀도함수는

$$\begin{aligned} pdf_{\mathrm{X}}(x) &= f(z)\left|\frac{dx}{dz}\right|^{-1}, \ x = \sigma z + \mu \\ &= \frac{1}{\sigma} f\left(\frac{x-\mu}{\sigma}\right) \end{aligned}$$

로 주어진다. 이러한 꼴의 확률밀도함수에서 μ와 σ를 각각 위치모수(位置母數, location parameter)와 척도모수(尺度母數, scale parameter)라고 한다.

(a) 정규분포 $\mathrm{N}(\mu,\sigma^2)$, $\mathrm{N}(\mu,\sigma^2) \overset{d}{\equiv} \sigma\mathrm{N}(0,1) + \mu$

$$pdf_{\mathrm{X}}(x) = \frac{1}{\sigma}\phi\left(\frac{x-\mu}{\sigma}\right), \ \phi(z) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}z^2} \mathrm{I}_{(-\infty < z < +\infty)}$$

$$\mathrm{X} \sim \mathrm{N}(\mu,\sigma^2) \Leftrightarrow \mathrm{X} \overset{d}{\equiv} \sigma\mathrm{Z} + \mu, \ \mathrm{Z} \sim \mathrm{N}(0,1)$$

(b) 로지스틱(logistic)분포 $\mathrm{L}(\mu,\sigma)$, $\mathrm{L}(\mu,\sigma) \overset{d}{\equiv} \sigma\mathrm{L}(0,1) + \mu$

$$pdf_{\mathrm{X}}(x) = \frac{1}{\sigma} f\left(\frac{x-\mu}{\sigma}\right), \ f(z) = \frac{e^z}{(1+e^z)^2} \mathrm{I}_{(-\infty < z < +\infty)}$$

$$\mathrm{X} \sim \mathrm{L}(\mu,\sigma) \Leftrightarrow \mathrm{X} \overset{d}{\equiv} \sigma\mathrm{Z} + \mu, \ \mathrm{Z} \sim \mathrm{L}(0,1)$$

(c) 이중지수(double exponential)분포 $\mathrm{DE}(\mu,\sigma)$, $\mathrm{DE}(\mu,\sigma) \overset{d}{\equiv} \sigma\mathrm{DE}(0,1) + \mu$

$$pdf_{\mathrm{X}}(x) = \frac{1}{\sigma} f\left(\frac{x-\mu}{\sigma}\right), \ f(z) = \frac{1}{2} e^{-|z|} \mathrm{I}_{(-\infty < z < +\infty)}$$

$$\mathrm{X} \sim \mathrm{DE}(\mu,\sigma) \Leftrightarrow \mathrm{X} \overset{d}{\equiv} \sigma\mathrm{Z} + \mu, \ \mathrm{Z} \sim \mathrm{DE}(0,1)$$

(d) 코쉬(Cauchy)분포 $\mathrm{C}(\mu,\sigma)$, $\mathrm{C}(\mu,\sigma) \overset{d}{\equiv} \sigma\mathrm{C}(0,1) + \mu$

$$pdf_{\mathrm{X}}(x) = \frac{1}{\sigma} f\left(\frac{x-\mu}{\sigma}\right), \ f(z) = \frac{1}{\pi}\frac{1}{1+z^2} \mathrm{I}_{(-\infty < z < +\infty)}$$

$$\mathrm{X} \sim \mathrm{C}(\mu,\sigma) \Leftrightarrow \mathrm{X} \overset{d}{\equiv} \sigma\mathrm{Z} + \mu, \ \mathrm{Z} \sim \mathrm{C}(0,1)$$

(e) 지수분포 $\mathrm{Exp}(\sigma)$, $\mathrm{Exp}(\sigma) \overset{d}{\equiv} \sigma \mathrm{Exp}(1)$

$$pdf_{\mathrm{X}}(x) = \frac{1}{\sigma} f\left(\frac{x}{\sigma}\right),\ f(z) = e^{-z} \mathrm{I}_{(0 \le z < +\infty)}$$

$$\mathrm{X} \sim \mathrm{Exp}(\sigma) \Leftrightarrow \mathrm{X} \overset{d}{\equiv} \sigma \mathrm{Z},\ \mathrm{Z} \sim \mathrm{Exp}(1)$$

(f) 감마분포 $\mathrm{Gamma}(\alpha,\beta)$, $\mathrm{Gamma}(\alpha,\beta) \overset{d}{\equiv} \beta \mathrm{Gamma}(\alpha,1)$

$$pdf_{\mathrm{X}}(x) = \frac{1}{\beta} f\left(\frac{x}{\beta}\right),\ f(z) = \frac{1}{\Gamma(\alpha)} z^{\alpha-1} e^{-z} \mathrm{I}_{(0 \le z < +\infty)}$$

$$\mathrm{X} \sim \mathrm{Gamma}(\alpha,\beta) \Leftrightarrow \mathrm{X} \overset{d}{\equiv} \beta \mathrm{Z},\ \mathrm{Z} \sim \mathrm{Gamma}(\alpha,1)$$

예 4.1.6

서로 독립이고 각각 감마분포 $\mathrm{Gamma}(\alpha_1,\beta)$, $\mathrm{Gamma}(\alpha_2,\beta)$를 따르는 확률변수 X_1, X_2에 대하여

$$\mathrm{Y}_1 = \frac{\mathrm{X}_1}{\mathrm{X}_1 + \mathrm{X}_2},\ \mathrm{Y}_2 = \mathrm{X}_1 + \mathrm{X}_2$$

라고 할 때, Y_1, Y_2의 결합확률밀도함수와 각각의 주변확률밀도함수를 구하여라.

[풀이] X_1, X_2의 결합확률밀도함수는

$$pdf_{\mathrm{X}_1,\mathrm{X}_2}(x_1,x_2) = \frac{1}{\Gamma(\alpha_1)\Gamma(\alpha_2)\beta^{\alpha_1+\alpha_2}} x_1^{\alpha_1-1} x_2^{\alpha_2-1} e^{-(x_1+x_2)/\beta} \mathrm{I}_{(\mathrm{X}_1>0,\,\mathrm{X}_2>0)}$$

이므로, 정의역이

$$\mathscr{X} = \left\{(x_1,x_2)^t : pdf_{\mathrm{X}_1,\mathrm{X}_2}(x_1,x_2) > 0\right\} = \left\{(x_1,x_2)^t : x_1 > 0, x_2 > 0\right\}$$

인 함수 $u(x_1,x_2) = \left(\frac{x_1}{x_1+x_2}, x_1+x_2\right)^t$가 <정리 4.1.1>의 조건을 만족시키는가 확인해보자.

함수 u의 값을 $(y_1,y_2)^t$라고 할 때 다음이 성립하는 것을 알 수 있다.

$$u : \begin{cases} y_1 = \dfrac{x_1}{x_1+x_2} \\ y_2 = x_1 + x_2 \end{cases} \qquad u^{-1} : \begin{cases} x_1 = y_1 y_2 \\ x_2 = y_2(1-y_1) \end{cases}$$

$$\mathscr{Y} = \left\{(y_1,y_2)^t : y_1 y_2 > 0, y_2(1-y_1) > 0\right\} = \left\{(y_1,y_2)^t : 0 < y_1 < 1, y_2 > 0\right\}$$

이로부터 함수 u는 $\mathscr{X}$에서 $\mathscr{Y}$로의 일대일 함수로서 <정리 4.1.1>의 조건을 만족시키고 그 역함수 u^{-1}의 야코비안 행렬식이 다음과 같이 주어지는 것을 알 수 있다.

$$J_{u^{-1}} = \det\begin{pmatrix} y_2 & -y_2 \\ y_1 & 1-y_1 \end{pmatrix} = y_2$$

따라서 <정리 4.1.1>로부터 Y_1, Y_2의 결합확률밀도함수는

$$\begin{aligned} & pdf_{Y_1,Y_2}(y_1,y_2) \\ &= \frac{1}{\Gamma(\alpha_1)\Gamma(\alpha_2)\beta^{\alpha_1+\alpha_2}}(y_1y_2)^{\alpha_1-1}(y_2(1-y_1))^{\alpha_2-1}e^{-y_2/\beta}I_{(0,1)}(y_1)I_{(0,\infty)}(y_2)|y_2| \\ &= \frac{1}{\Gamma(\alpha_1)\Gamma(\alpha_2)\beta^{\alpha_1+\alpha_2}}y_1^{\alpha_1-1}(1-y_1)^{\alpha_2-1}I_{(0,1)}(y_1)y_2^{\alpha_1+\alpha_2-1}e^{-y_2/\beta}I_{(0,\infty)}(y_2) \end{aligned}$$

로 주어진다. 이는 y_1만의 함수와 y_2만의 함수의 곱이므로 Y_1, Y_2는 서로 독립이고 각각의 주변확률밀도함수는 다음과 같이 주어진다.

$$\begin{aligned} pdf_{Y_1}(y_1) &= \int_{-\infty}^{+\infty} pdf_{Y_1,Y_2}(y_1,y_2)dy_2 \\ &= \frac{\Gamma(\alpha_1+\alpha_2)}{\Gamma(\alpha_1)\Gamma(\alpha_2)}y_1^{\alpha_1-1}(1-y_1)^{\alpha_2-1}I_{(0,1)}(y_1) \end{aligned}$$

$$pdf_{Y_2}(y_2) = \frac{1}{\Gamma(\alpha_1+\alpha_2)\beta^{\alpha_1+\alpha_2}}y_2^{\alpha_1+\alpha_2-1}e^{-y_2/\beta}I_{(0,\infty)}(y_2)$$

<예 4.1.6>에서 구한 Y_1의 분포를 베타분포[56]라고 하며 기호로는 $\mathrm{Beta}(\alpha_1,\alpha_2)$로 나타낸다.

베타분포의 정의:

$$\mathrm{Beta}(\alpha_1,\alpha_2) \overset{d}{\equiv} \mathrm{Gamma}(\alpha_1)/(\mathrm{Gamma}(\alpha_1,\beta)\oplus\mathrm{Gamma}(\alpha_2,\beta))$$

$$X \sim \mathrm{Beta}(\alpha_1,\alpha_2) \Leftrightarrow X \overset{d}{\equiv} Z_1/(Z_1+Z_2),\ Z_i \sim \mathrm{Gamma}(\alpha_i,\beta)(i=1,2)\text{이고 서로 독립}$$

$$\Leftrightarrow pdf_X(x) = \frac{\Gamma(\alpha_1+\alpha_2)}{\Gamma(\alpha_1)\Gamma(\alpha_2)}x^{\alpha_1-1}(1-x)^{\alpha_2-1}I_{(0,1)}(x)$$

---

56) <예 4.1.6>에서 Y_1의 확률밀도함수의 적분 값은 1이므로, 양수 α_1, α_2에 대하여

$$\int_0^1 x^{\alpha_1-1}(1-x)^{\alpha_2-1}dx = \frac{\Gamma(\alpha_1)\Gamma(\alpha_2)}{\Gamma(\alpha_1+\alpha_2)}$$

임을 알 수 있다. 이러한 정적분으로 정의된 함수를 베타함수라고 하며 $B(\alpha_1,\alpha_2)$로 나타내기도 한다.

예 4.1.7

확률변수 X_1, X_2이 서로 독립이고 동일한 확률밀도함수

$$f(x) = I_{(0,1)}(x)$$

를 가질 때, $Y = (X_1 + X_2)/2$ 의 확률밀도함수를 구하여라.

[풀이] 이차원 확률변수 사이의 일대일 변환을 생각하기 위하여

$$Y = (X_1 + X_2)/2,\ Z = (X_1 - X_2)/2$$

라고 하면, 다음과 같이 함수 u와 그 정의역 $\mathscr{X}$, 치역 $\mathscr{Y}$, 역함수 u^{-1}를 생각할 수 있다.

$$u : \begin{cases} y = (x_1 + x_2)/2 \\ z = (x_1 - x_2)/2 \end{cases} \qquad u^{-1} : \begin{cases} x_1 = y + z \\ x_2 = y - z \end{cases}$$

$$\mathscr{X} = \left\{(x_1, x_2)^t : pdf_{X_1, X_2}(x_1, x_2) > 0\right\} = \left\{(x_1, x_2)^t : 0 < x_1 < 1,\ 0 < x_2 < 1\right\}$$

$$\mathscr{Y} = \left\{(y, z)^t : 0 < y + z < 1,\ 0 < y - z < 1\right\}$$

이로부터 함수 u는 $\mathscr{X}$에서 $\mathscr{Y}$로의 일대일 함수로서 <정리 4.1.1>의 조건을 만족시키고 그 역함수 u^{-1}의 야코비안 행렬식이 다음과 같이 주어지는 것을 알 수 있다.

$$J_{u^{-1}} = \det \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix} = -2$$

따라서 <정리 4.1.1>로부터 Y, Z의 결합확률밀도함수는

$$pdf_{Y,Z}(y, z) = I_{(0 < y+z < 1,\ 0 < y-z < 1)} |-2|$$

이로부터 Y의 주변확률밀도함수를 구하기 위하여, 지표함수의 연립부등식을 z에 대한 부등식으로 나타내면

$$-y < z < 1 - y,\ y - 1 < z < y$$

즉 $a \vee b = \max(a, b)$, $a \wedge b = \min(a, b)$이라고 하면

$$(-y) \vee (y - 1) < z < (1 - y) \wedge y$$

그러므로 $y \leq 1/2$ 인 경우와 $y > 1/2$인 경우로 나누어 Y의 주변확률밀도함수를 구하면 다음과 같다.

(i) $y \leq 1/2$ 인 경우에, $(-y) \vee (y - 1) = -y$, $(1 - y) \wedge y = y$이고 $-y < y \Leftrightarrow y > 0$이므로

$$pdf_Y(y) = \int_{-\infty}^{+\infty} pdf_{Y,Z}(y, z) dz = \int_{-y}^{y} 2dz\, I_{(0,1/2]}(y) = 4y\, I_{(0,1/2]}(y)$$

(ii) $y > 1/2$ 인 경우에, $(-y)\vee(y-1) = y-1$, $(1-y)\wedge y = 1-y$이고 $y-1 < 1-y \Leftrightarrow y < 1$이므로

$$pdf_{\mathrm{Y}}(y) = \int_{-\infty}^{+\infty} pdf_{\mathrm{Y},\mathrm{Z}}(y,z)dz = \int_{y-1}^{1-y} 2dz\, \mathrm{I}_{(1/2,1)}(y) = 4(1-y)\mathrm{I}_{(1/2,1)}(y)$$

따라서 Y의 주변확률밀도함수를 하나의 식으로 나타내면 <예 1.4.3>에서와 같이

$$pdf_{\mathrm{Y}}(y) = (2-4|y-1/2|)\mathrm{I}_{(0\ 1)}(y)$$

임을 알 수 있다.

<예 4.1.7>에서 서로 독립인 $\mathrm{X}_1, \mathrm{X}_2$의 공통 분포를 구간 (0,1)에서의 균등분포(均等分布, uniform distribution)라고 하며, 이들의 평균인 $\mathrm{Y} = (\mathrm{X}_1 + \mathrm{X}_2)/2$의 분포를 구간 (0,1)에서의 삼각분포(三角分布, triangular distribution)라고 한다.

한편, 일반적인 구간 (a,b)에서의 균등분포는 다음과 같이 정의한다.

균등분포의 정의:

$$\mathrm{U}(a,b) \overset{d}{\equiv} (b-a)\mathrm{U}(0,1) + a$$

$$\mathrm{X} \sim \mathrm{U}(a,b) \Leftrightarrow pdf_{\mathrm{X}}(x) = \frac{1}{b-a}\mathrm{I}_{(a,b)}(x)$$

$$\Leftrightarrow \mathrm{X} \overset{d}{\equiv} (b-a)\mathrm{Z} + a,\ \mathrm{Z} \sim \mathrm{U}(0,1)$$

그림 4.1.1 균등분포

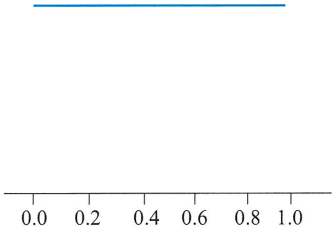

$f(x) = \mathrm{I}_{(0,1)}(x)$

그림 4.1.2 삼각분포

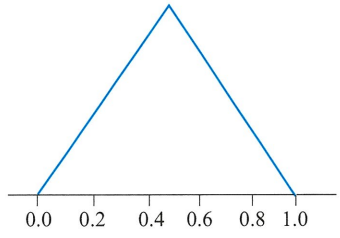

$f(y) = (2-4|y-1/2|)\mathrm{I}_{(0,1)}(y)$

예 4.1.8

서로 독립이고 표준정규분포 $\mathrm{N}(0,1)$를 따르는 확률변수 X, Y에 대하여, 극좌표 변환인

$$\begin{cases} \mathrm{X} = \mathrm{R}\cos\Theta \\ \mathrm{Y} = \mathrm{R}\sin\Theta, \ 0 \le \mathrm{R} < +\infty, \ 0 \le \Theta < 2\pi \end{cases}$$

를 만족시키는 R, Θ의 결합확률밀도함수를 구하여라.

[풀이] X, Y 결합확률밀도함수는

$$pdf_{\mathrm{X},\mathrm{Y}}(x,y) = \frac{1}{2\pi} e^{-\frac{1}{2}(x^2+y^2)} \mathrm{I}_{(-\infty < x < +\infty, \ -\infty < y < +\infty)}$$

이고, 주어진 극좌표 변환

$$w : \begin{cases} x = r\cos\theta \\ y = r\sin\theta, \ 0 \le r < +\infty, \ 0 \le \theta < 2\pi \end{cases}$$

는 정의역이

$$\mathscr{Y} = \{(r,\theta) : 0 \le r < +\infty, \ 0 \le \theta < 2\pi\}$$

이고 치역이

$$\mathscr{X} = \{(x,y) : -\infty < x < +\infty, \ -\infty < y < +\infty\}$$

인 일대일 함수로서, 미분가능하고 그 야코비안 행렬식이

$$J_w(y) = \det\begin{pmatrix} \frac{\partial x}{\partial r} & \frac{\partial y}{\partial r} \\ \frac{\partial x}{\partial \theta} & \frac{\partial y}{\partial \theta} \end{pmatrix}$$

$$= \det\begin{pmatrix} \cos\theta & \sin\theta \\ -r\sin\theta & r\cos\theta \end{pmatrix} = r$$

임을 알 수 있다. 따라서 극좌표 변환 w의 역함수를 $u = w^{-1}$라고 하면 역함수 정리로부터 함수 $u(x,y)$가 <정리 4.1.1>의 조건을 만족시키는 것을 알 수 있다.

그림 4.1.3 직교좌표와 극좌표

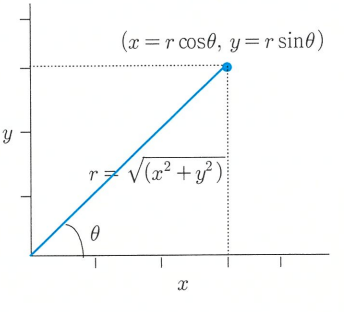

그러므로 <정리 4.1.1>로부터 R, Θ의 결합확률밀도함수는

$$pdf_{\mathrm{R},\Theta}(r,\theta) = \frac{1}{2\pi} e^{-\frac{1}{2}r^2(\cos^2\theta + \sin^2\theta)} \mathrm{I}_{[0,+\infty)}(r)\mathrm{I}_{[0,2\pi)}(\theta)|r|$$

$$= re^{-\frac{1}{2}r^2} \mathrm{I}_{[0,+\infty)}(r)\frac{1}{2\pi}\mathrm{I}_{[0,2\pi)}(\theta)$$

로 주어진다. 즉 R, Θ는 서로 독립이고

$$R^2/2 \sim \mathrm{Exp}(1),\ \Theta \sim \mathrm{U}[0,2\pi)$$

예 4.1.9

서로 독립이고 각각 감마분포 $\mathrm{Gamma}(\alpha_i,\beta)$를 따르는 확률변수 $X_i\,(i=1,\ \cdots,\ k+1)$들에 대하여

$$Y_1=\frac{X_1}{X_1+\cdots+X_{k+1}},\ \cdots\cdots,Y_k=\frac{X_k}{X_1+\cdots+X_{k+1}}$$

라고 할 때, $Y_1,\ \cdots,\ Y_k$의 결합확률밀도함수를 구하여라.

[풀이] $X_1,\ \cdots,\ X_{k+1}$의 결합확률밀도함수는

$$pdf_{1,\cdots,k+1}(x_1,\cdots,x_{k+1})=\prod_{i=1}^{k+1}\left\{\frac{1}{\Gamma(\alpha_i)\beta^{\alpha_i}}x_i^{\alpha_i-1}e^{-x_i/\beta}I_{(0,+\infty)}(x_i)\right\}$$

이고, $(k+1)$개 확률변수 사이의 일대일 변환을 생각하기 위하여 다음 변수를 생각해보자.

$$Y_{k+1}=X_1+\cdots+X_{k+1}$$

이로부터 다음과 같이 함수 u와 그 정의역 $\mathscr{X}$, 치역 $\mathscr{Y}$, 역함수 u^{-1}를 생각할 수 있다.

$$u:\begin{cases}y_1=x_1/(x_1+\cdots+x_{k+1})\\ \quad\vdots\\ y_k=x_k/(x_1+\cdots+x_{k+1})\\ y_{k+1}=x_1+\cdots+x_{k+1}\end{cases}\qquad u^{-1}:\begin{cases}x_1=y_1y_{k+1}\\ \quad\vdots\\ x_k=y_ky_{k+1}\\ x_{k+1}=y_{k+1}(1-y_1-\cdots-y_k)\end{cases}$$

$$\mathscr{X}=\left\{(x_1,\cdots,x_{k+1})^t:x_i>0(i=1,\cdots,k+1)\right\}$$

$$\mathscr{Y}=\left\{(y_1,\cdots,y_k,y_{k+1})^t:y_i>0(i=1,\cdots,k),\ y_1+\cdots+y_k<1,\ y_{k+1}>0\right\}$$

이로부터 함수 u는 $\mathscr{X}$에서 $\mathscr{Y}$로의 일대일 함수로서 <정리 4.1.1>의 조건을 만족시키고 그 역함수 u^{-1}의 야코비안 행렬식이 다음과 같이 주어지는 것을 알 수 있다.

$$J_{u^{-1}}=\det\begin{pmatrix}y_{k+1}&\cdots&0&-y_{k+1}\\ \vdots&\vdots&\vdots&-y_{k+1}\\ 0&\cdots&y_{k+1}&-y_{k+1}\\ y_1&\cdots&y_k&(1-y_1-\cdots-y_k)\end{pmatrix}=y_{k+1}^k$$

따라서 $Y_1,\ \cdots,\ Y_k,\ Y_{k+1}$의 결합확률밀도함수는

$$pdf_{Y_1,\cdots,Y_k,Y_{k+1}}(y_1,\cdots,y_k,y_{k+1})$$

$$=\left\{\prod_{i=1}^{k+1}\frac{1}{\Gamma(\alpha_i)\beta^{\alpha_i}}\right\}\times\left\{\prod_{i=1}^{k}(y_i y_{k+1})^{\alpha_i-1}\right\}\times\{y_{k+1}(1-y_1-\cdots-y_k)\}^{\alpha_{k+1}-1}$$

$$\times e^{-y_{k+1}/\beta}|y_{k+1}^{k}|,\ (y_1,\cdots,y_{k+1})^t\in\mathscr{Y}$$

$$\therefore\ pdf_{Y_1,\cdots,Y_k,Y_{k+1}}$$

$$=\left\{\prod_{i=1}^{k}\frac{1}{\Gamma(\alpha_i)}y_i^{\alpha_i-1}\right\}(1-y_1-\cdots-y_k)^{\alpha_{k+1}-1}\mathrm{I}_{(y_1>0,\cdots,y_k>0,y_1+\cdots+y_k<1)}$$

$$\times\left\{\frac{1}{\Gamma(\alpha_{k+1})\beta^{\alpha_1+\cdots+\alpha_{k+1}}}y_{k+1}^{\alpha_1+\cdots+\alpha_{k+1}-1}e^{-y_{k+1}/\beta}\mathrm{I}_{(y_{k+1}>0)}\right\}$$

그런데

$$\int_0^{+\infty}\frac{1}{\beta^{\alpha_1+\cdots+\alpha_{k+1}}}y_{k+1}^{\alpha_1+\cdots+\alpha_{k+1}-1}e^{-y_{k+1}/\beta}dy_{k+1}=\Gamma(\alpha_1+\cdots+\alpha_{k+1})$$

이므로 $Y_1,\ \cdots,\ Y_k,\ Y_{k+1}$ 의 결합확률밀도함수를 y_{k+1}에 대하여 적분하면

$$pdf_{Y_1,\cdots,Y_k}(y_1,\cdots,y_k)$$

$$=\int_{-\infty}^{+\infty}pdf_{Y_1,\cdots,Y_k,Y_{k+1}}(y_1,\cdots,y_k,y_{k+1})\,dy_{k+1}$$

$$=\frac{\Gamma(\alpha_1+\cdots+\alpha_{k+1})}{\Gamma(\alpha_1)\cdots\Gamma(\alpha_{k+1})}\left\{\prod_{i=1}^{k}y_i^{\alpha_i-1}\right\}(1-y_1-\cdots-y_k)^{\alpha_{k+1}-1}\mathrm{I}_{(y_1>0,\cdots,y_k>0,y_1+\cdots+y_k<1)}$$

<예 4.1.9>에서 구한 $Y_1,\ \cdots,\ Y_k$ 의 결합분포는 베타분포를 다차원으로 일반화한 분포로서 디리클레(Dirichlet)분포라고 하며, 기호로는 $(Y_1,\cdots,Y_k)^t\sim\mathrm{Dirichlet}(\alpha_1,\cdots,\alpha_k,\alpha_{k+1})$로 나타낸다.

디리클레분포의 정의:

$$\mathrm{Dirichlet}(\alpha_1,\cdots,\alpha_k,\alpha_{k+1})\overset{d}{\equiv}\left(\frac{\mathrm{Gamma}(\alpha_i)}{\mathrm{Gamma}(\alpha_1,\beta)\oplus\cdots\oplus\mathrm{Gamma}(\alpha_{k+1},\beta)}\right)_{1\le i\le k}$$

$$Y=(Y_1,\cdots,Y_k)^t\sim\mathrm{Dirichlet}(\alpha_1,\cdots,\alpha_k,\alpha_{k+1})$$

$$\Leftrightarrow Y\overset{d}{\equiv}\left(\frac{X_1}{X_1+\cdots+X_{k+1}},\ \cdots,\ \frac{X_k}{X_1+\cdots+X_{k+1}}\right),$$

$X_i\sim\mathrm{Gamma}(\alpha_i,\beta)$이고 서로 독립$(i=1,\cdots,k+1)$

$$\Leftrightarrow pdf_{Y_1,\cdots,Y_k}(y_1,\cdots,y_k)$$

$$=\frac{\Gamma(\alpha_1+\cdots+\alpha_{k+1})}{\Gamma(\alpha_1)\cdots\Gamma(\alpha_{k+1})}\left\{\prod_{i=1}^{k}y_i^{\alpha_i-1}\right\}(1-y_1-\cdots-y_k)^{\alpha_{k+1}-1}\mathrm{I}_{(y_1>0,\cdots,y_k>0,y_1+\cdots+y_k<1)}$$

[증명] <정리 4.1.1>의 증명에서와 같이 분할된 각각의 정의역 $\mathscr{X}_r\,(r=1,\cdots,m)$에서의 일대일 함수 $y=u^r(x)\,(r=1,\cdots,m)$의 역함수 $x=(u^r)^{-1}(y)$를 이용한 치환적분법을 적용하면 $\mathscr{Y}$의 임의의 부분 집합 B에 대하여 다음이 성립함을 알 수 있다.

$$\begin{aligned}
\mathrm{P}(\mathrm{Y}\in\mathrm{B}) &= \mathrm{P}(u(\mathrm{X})\in\mathrm{B}) \\
&= \sum_{r=1}^{m}\mathrm{P}(u^r(\mathrm{X})\in\mathrm{B},\,\mathrm{X}\in\mathscr{X}_r) \\
&= \sum_{r=1}^{m}\int_{x\in(u^r)^{-1}(\mathrm{B})} pdf_{\mathrm{X}}(x)dx \\
&= \int_{y\in\mathrm{B}}\sum_{r=1}^{m} pdf_{\mathrm{X}}((u^r)^{-1}(y))|J_{(u^r)^{-1}}(y)|\,dy \quad (\because x=(u^r)^{-1}(y))
\end{aligned}$$

$$\therefore\ pdf_{\mathrm{Y}}(y)=\sum_{r=1}^{m} pdf_{\mathrm{X}}((u^r)^{-1}(y))|J_{(u^r)^{-1}}(y)|,\ y\in\mathscr{Y}$$

따라서 $$pdf_{\mathrm{Y}}(y)=\sum_{x\,:\,u(x)=y} pdf_{\mathrm{X}}(x)\left|\det\left(\frac{\partial u(x)}{\partial x}\right)\right|^{-1},\ y\in\mathscr{Y}$$

예 4.1.10

(−1, 1)에서 균등분포를 따르는 확률변수 X에 대하여 $\mathrm{Y}=\mathrm{X}^2$의 확률밀도함수를 구하여라.

[풀이] 함수 $y=x^2$은 $\mathscr{X}=(-1,0)\cup(0,1)$에서 $\mathscr{Y}=(0,1)$로의 이대일 함수이고, <정리 4.1.2>의 조건을 만족시킨다. 따라서

$$\begin{aligned}
pdf_{\mathrm{Y}}(y) &= \sum_{x\,:\,x^2=y} pdf_{\mathrm{X}}(x)|dx^2/dx|^{-1}\mathrm{I}_{(0,1)}(y) \\
&= \sum_{x\,:\,x^2=y}\frac{1}{2}|2x|^{-1}\mathrm{I}_{(0,1)}(y) \\
&= \frac{1}{2\sqrt{y}}\mathrm{I}_{(0,1)}
\end{aligned}$$

예 4.1.11

확률변수 $\mathrm{X}=(\mathrm{X}_1,\mathrm{X}_2)^t$의 결합확률밀도함수가

$$pdf_{\mathrm{X}}(x_1,x_2)=\frac{1}{\pi}\mathrm{I}_{(0<x_1^2+x_2^2<1)}$$

일 때, 다음과 같이 정의된 $\mathrm{Y}=(\mathrm{Y}_1,\,\mathrm{Y}_2)^t$의 결합확률밀도함수를 구하여라.

$$\mathrm{Y}_1=\mathrm{X}_1^2+\mathrm{X}_2^2,\ \mathrm{Y}_2=\frac{\mathrm{X}_1^2}{\mathrm{X}_1^2+\mathrm{X}_2^2}$$

[풀이] 함수

$$\begin{cases} y_1=x_1^2+x_2^2 \\ y_2=\dfrac{x_1^2}{x_1^2+x_2^2} \end{cases}$$

의 표현에서 $x_1,\ x_2$를 $y_1,\ y_2$로 나타내면

$$\begin{cases} x_1^2=y_1y_2 \\ x_2^2=y_1-y_1y_2 \end{cases} \quad\therefore\quad \begin{cases} x_1=\pm\sqrt{y_1y_2} \\ x_2=\pm\sqrt{y_1(1-y_2)} \end{cases}$$

따라서 위에서 정의된 함수는 다음과 같이 정의된 $\mathscr{X}$에서 $\mathscr{Y}$로의 사대일 함수이다.

$$\mathscr{X}=\left\{(x_1,x_2)^t:0<x_1^2+x_2^2<1,\ x_1\neq 0,\ x_2\neq 0\right\},$$

$$\mathscr{Y}=\left\{(y_1,y_2)^t:0<y_1<1,\ 0<y_2<1\right\}$$

또한, 이 함수의 야코비안 행렬식의 절대값은

$$\left|\det\left(\frac{\partial y}{\partial x}\right)\right|=\left|\det\begin{pmatrix} 2x_1 & 2x_2 \\ \dfrac{2x_1x_2^2}{(x_1^2+x_2^2)^2} & \dfrac{-2x_1^2x_2}{(x_1^2+x_2^2)^2} \end{pmatrix}\right|=\left|\frac{-4x_1x_2}{x_1^2+x_2^2}\right|=4\sqrt{y_2(1-y_2)}$$

$$\begin{aligned} \therefore\ pdf_{\mathrm{Y}}(y_1,y_2)&=\sum_{\substack{x\,:\,x_1^2+x_2^2=y_1\\ x_1^2/(x_1^2+x_2^2)=y_2}}\frac{1}{\pi}\left|\det\left(\frac{\partial y}{\partial x}\right)\right|^{-1}\mathrm{I}_{(0<y_1<1,\,0<y_2<1)} \\ &=\frac{4}{\pi}(4\sqrt{y_2(1-y_2)})^{-1}\mathrm{I}_{(0,1)}(y_1)\mathrm{I}_{(0,1)}(y_2) \\ &=\mathrm{I}_{(0,1)}(y_1)\frac{1}{\pi}y_2^{-1/2}(1-y_2)^{-1/2}\mathrm{I}_{(0,1)}(y_2) \end{aligned}$$

그런데 $\Gamma(1/2)=\sqrt{\pi}$이므로 $\mathrm{Y}_1,\ \mathrm{Y}_2$는 서로 독립이고 $\mathrm{Y}_1\sim\mathrm{U}(0,1)$, $\mathrm{Y}_2\sim\mathrm{Beta}(1/2,1/2)$임을 알 수 있다.

4.2 대표적인 표본분포

모집단의 분포가 정규분포임을 가정하는 경우에 사용되는 통계량인 표본평균, 표본분산의 분포를 나타내는 대표적인 표본분포에 대하여 알아보자.

예 4.2.1

서로 독립이고 표준정규분포 $N(0,1)$를 따르는 확률변수들 $X_1, \cdots, X_r$에 대하여

$$Y = X_1^2 + \cdots + X_r^2$$

의 확률밀도함수를 구하여라.

[풀이] <예 4.1.4>의 (c)로부터 $X_i^2 (i = 1, \cdots, r)$은 각각 $Gamma(1/2, 2)$분포를 따르고 이들이 서로 독립이므로, <정리 3.5.2>에 주어진 감마분포의 성질로부터

$$Y = X_1^2 + \cdots + X_r^2 \sim Gamma(r/2, 2)$$

$$\therefore pdf_Y(y) = \frac{1}{\Gamma(r/2)2^{r/2}} y^{r/2-1} e^{-y/2} I_{(0,\infty)}(y)$$

<예 4.2.1>에서의 분포인 $Gamma(r/2, 2)$분포를 자유도(自由度, degrees of freedom)가 r인 카이제곱분포(chi-squared distribution)라고 하며 기호로는 $Y \sim \chi^2(r)$로 나타낸다.

카이제곱분포의 정의:

$$\chi^2(r) \overset{d}{\equiv} N_1(0,1)^2 \oplus \cdots \oplus N_r(0,1)^2 \overset{d}{\equiv} Gamma(r/2, 2)$$

$$Y \sim \chi^2(r) (r > 0) \Leftrightarrow Y \sim Gamma(r/2, 2)$$

$$\Leftrightarrow pdf_Y(y) = \frac{1}{\Gamma(r/2)2^{r/2}} y^{r/2-1} e^{-y/2} I_{(0,\infty)}(y)$$

$$\Leftrightarrow Y \overset{d}{\equiv} X_1^2 + \cdots + X_r^2,\ X_i \overset{iid}{\sim} N(0,1) (i = 1, \cdots, r) (r\text{이 자연수인 경우})$$

카이제곱분포의 확률밀도함수나 누적확률은 부록 III에 소개되어 있는 패키지 R을 이용하여 계산할 수 있으며, 이를 이용하여카이제곱분포의 형태를 그려보면 <그림 4.2.1>과 같다. 또한 표준정규분포의 경우와 같이, $Y \sim \chi^2(r)$일 때

$$P(Y > \chi^2{}_\alpha(r)) = \alpha \ (0 < \alpha < 1)$$

그림 4.2.1 카이제곱분포 $\chi^2(r)$의 형태와 상방 α 분위수

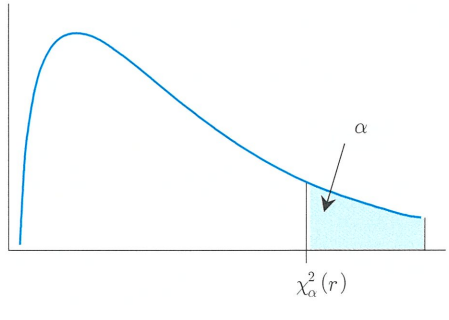

를 만족시키는 값 $\chi^2_\alpha(r)$를 자유도 r인 카이제곱분포 $\chi^2(r)$의 상방 α 분위수라고 한다.

이러한 카이제곱분포의 상방 분위수는 부록 Ⅳ에 주어진 카이제곱분포의 누적확률 분포표로부터 구하거나 패키지 R을 이용하여 구할 수 있다. 예를 들면,

$$\chi^2_{0.990}(5)=0.554,\ \chi^2_{0.975}(5)=0.831,\ \chi^2_{0.025}(5)=12.833,\ \chi^2_{0.010}(5)=15.086$$

또한, <예 4.1.5>의 (f)에서 알 수 있듯이

$$X\sim \mathrm{Gamma}(\nu,\beta)\Leftrightarrow X/\beta\sim \mathrm{Gamma}(\nu,1)\Leftrightarrow 2X/\beta\sim \mathrm{Gamma}(\nu,2)=\chi^2(2\nu)$$

이므로 감마분포의 상방 분위수를 카이제곱분포의 상방 분위수로 나타낼 수 있다. 즉

$$P(X>\beta\chi^2_\alpha(2\nu)/2)=P(2X/\beta>\chi^2_\alpha(2\nu))=\alpha$$

이므로 감마분포 $\mathrm{Gamma}(\nu,\beta)$ 의 상방 α 분위수는 $\beta\chi^2_\alpha(2\nu)/2$로 주어진다.

예 4.2.2

감마분포 $\mathrm{Gamma}(2,3)$의 상방 0.05 분위수는 $3\chi^2_{0.05}(4)/2$로서, 부록 Ⅳ에 주어진 카이제곱분포의 누적확률 분포표로부터

$$3\chi^2_{0.05}(4)/2=3\times 9.488/2=14.232$$

정리 4.2.1 카이제곱분포의 성질

(a) $Y\sim\chi^2(r)$이면

$$E(X)=r,\ \mathrm{Var}(X)=2r$$

(b) $Y\sim\chi^2(r)$이면 그 적률생성함수는

$$mgf_Y(t)=(1-2t)^{-r/2},\ t<1/2$$

(c) $Y_1\sim\chi^2(r_1)$, $Y_2\sim\chi^2(r_2)$이고 Y_1, Y_2가 서로 독립이면

$$Y_1+Y_2\sim\chi^2(r_1+r_2)$$

[증명] 카이제곱분포 $\chi^2(r)$는 감마분포 $\mathrm{Gamma}(r/2,2)$이므로 이 정리는 <정리 3.5.2>에 주어진 감마분포의 성질을 특별한 경우에 정리해 놓은 것이다.

예 4.2.3

두 확률변수 Z와 V가 서로 독립이고, $Z \sim N(0,1)$, $V \sim \chi^2(r)$일 때

$$X = \frac{Z}{\sqrt{V/r}}$$

의 확률밀도함수를 구하여라.

[풀이] $Y = V$라고 하면, (Z, V)에서 (X, Y)로의 변환은 그 역변환이

$$\begin{cases} Z = X\sqrt{Y/r} \\ V = Y \end{cases}$$

로 주어지는 일대일 변환이므로 X, Y의 결합확률밀도함수는 다음과 같이 주어진다.

$$pdf_{X,Y}(x,y) = pdf_{Z,V}(z,v)\left|\det\left(\frac{\partial(z,v)}{\partial(x,y)}\right)\right|$$

$$= \frac{1}{\sqrt{2\pi}}e^{-z^2/2}\frac{1}{\Gamma(r/2)2^{r/2}}v^{r/2-1}e^{-v/2}I_{(v>0)}\left|\det\begin{pmatrix}\sqrt{y/r} & 0\\ xy^{-1/2}/2\sqrt{r} & 1\end{pmatrix}\right|$$

$$= \frac{1}{\Gamma(1/2)\Gamma(r/2)2^{(r+1)/2}\sqrt{r}}y^{(r+1)/2-1}e^{-(1+x^2/r)y/2}I_{(y>0)}$$

이로부터 X의 주변확률밀도함수를 구하면

$$pdf_X(x) = \int_{-\infty}^{+\infty} pdf_{X,Y}(x,y)dy$$

$$= \frac{1}{\Gamma(1/2)\Gamma(r/2)2^{(r+1)/2}\sqrt{r}}\int_0^{+\infty} y^{(r+1)/2-1}e^{-(1+x^2/r)y/2}dy$$

여기에서 $(1+x^2/r)y/2 = t$로 치환하여 적분하면

$$pdf_X(x) = \frac{1}{\Gamma(1/2)\Gamma(r/2)2^{(r+1)/2}\sqrt{r}}$$

$$\int_0^{+\infty} t^{(r+1)/2-1}e^{-t}dt\,((1+x^2/r)/2)^{-(r+1)/2}$$

$$= \frac{\Gamma((r+1)/2)}{\Gamma(1/2)\Gamma(r/2)\sqrt{r}}(1+x^2/r)^{-(r+1)/2}$$

<예 4.2.3>에서의 분포를 자유도가 r인 t 분포(t distribution)라고 하며 기호로는 $X \sim t(r)$로 나타낸다.

$$\left[\overline{X}-t_{\alpha/2}(n-1)S/\sqrt{n},\ \overline{X}+t_{\alpha/2}(n-1)S/\sqrt{n}\right]$$

을 신뢰수준(信賴水準, confidence level) $(1-\alpha)$의 신뢰구간(信賴區間, confidence interval)이라고 하며, 이 때 신뢰수준이란 표본으로부터 계산되는 구간이 미지의 모수 μ를 포함하게 되는 경우가 전체의 $100(1-\alpha)\%$일 것이라는 적중률을 의미한다.

모집단의 분포가 정규분포인 경우에 평균에 관한 신뢰구간과 마찬가지로 모집단의 분산에 관한 신뢰구간도 다음과 같이 주어진다.

정리 4.2.4 정규모집단에서 모분산의 추론

정규분포 $N(\mu,\sigma^2)$에서의 랜덤표본을 $X_1, X_2, \cdots, X_n$이라고 할 때, 다음이 성립한다.

$$P\left\{\frac{n-1}{\chi^2_{\alpha/2}(n-1)}S^2 \le \sigma^2 \le \frac{n-1}{\chi^2_{1-\alpha/2}(n-1)}S^2\right\}=1-\alpha$$

[증명] <정리 4.2.2>로부터 $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$이므로, 분위수의 정의에 따라

$$P\left\{\chi^2_{1-\alpha/2}(n-1) \le (n-1)S^2/\sigma^2 \le \chi^2_{\alpha/2}(n-1)\right\}=1-\alpha$$

이고 부등식을 σ^2에 관하여 정리하여 신뢰구간을 나타낸 것이다.

예 4.2.4

두 확률변수 V_1과 V_2가 서로 독립이고 $V_1 \sim \chi^2(r_1)$, $V_2 \sim \chi^2(r_2)$일 때

$$X=\frac{V_1/r_1}{V_2/r_2}$$

의 확률밀도함수를 구하여라.

[풀이] $Y=V_2$라고 하면, (V_1, V_2)에서 (X, Y)로의 변환은 그 역변환이

$$\begin{cases} V_1 = r_1 XY/r_2 \\ V_2 = Y \end{cases}$$

로 주어지는 일대일 변환이므로 X, Y의 결합확률밀도함수는 다음과 같이 주어진다.

$$
\begin{aligned}
&pdf_{\mathrm{X},\mathrm{Y}}(x,y)\\
&= pdf_{\mathrm{V}_1,\mathrm{V}_2}(v_1,v_2)\left|\det\left(\frac{\partial(v_1,v_2)}{\partial(x,y)}\right)\right|\\
&= \prod_{i=1}^{2}\left\{\frac{1}{\Gamma(r_i/2)2^{r_i/2}}v_i^{r_i/2-1}e^{-v_i/2}\mathrm{I}_{(v_i>0)}\right\}\left|\det\begin{pmatrix} r_1y/r_2 & 0\\ r_1x/r_2 & 1\end{pmatrix}\right|\\
&= \frac{1}{\Gamma(r_1/2)\Gamma(r_2/2)2^{(r_1+r_2)/2}}\left(\frac{r_1}{r_2}xy\right)^{r_1/2-1}y^{r_2/2-1}e^{-(1+r_1x/r_2)y/2}\left(\frac{r_1}{r_2}y\right)\mathrm{I}_{(x>0,\,y>0)}
\end{aligned}
$$

이로부터 X의 주변확률밀도함수를 구하면

$$
\begin{aligned}
pdf_{\mathrm{X}}(x) &= \int_{-\infty}^{+\infty} pdf_{\mathrm{X},\mathrm{Y}}(x,y)dy\\
&= \frac{1}{\Gamma(r_1/2)\Gamma(r_2/2)2^{(r_1+r_2)/2}}\left(\frac{r_1}{r_2}\right)^{r_1/2}x^{r_1/2-1}\mathrm{I}_{(x>0)}\\
&\quad\times\int_0^{+\infty} y^{(r_1+r_2)/2-1}e^{-(1+r_1x/r_2)y/2}dy
\end{aligned}
$$

여기에서 $(1+r_1x/r_2)y/2=t$로 치환하여 적분하면

$$
\begin{aligned}
pdf_{\mathrm{X}}(x) &= \frac{1}{\Gamma(r_1/2)\Gamma(r_2/2)2^{(r_1+r_2)/2}}\left(\frac{r_1}{r_2}\right)^{r_1/2}x^{r_1/2-1}\mathrm{I}_{(x>0)}\\
&\quad\times\int_0^{+\infty} t^{(r_1+r_2)/2-1}e^{-t}dt\,((1+r_1x/r_2)/2)^{-(r_1+r_2)/2}\\
&= \frac{\Gamma((r_1+r_2)/2)}{\Gamma(r_1/2)\Gamma(r_2/2)}\left(\frac{r_1}{r_2}\right)^{r_1/2}x^{r_1/2-1}(1+r_1x/r_2)^{-(r_1+r_2)/2}\mathrm{I}_{(x>0)}
\end{aligned}
$$

<예 4.2.4>에서의 분포를 자유도가 (r_1,r_2)인 F 분포(F distribution)라고 하며 기호로는 $\mathrm{X}\sim\mathrm{F}(r_1,r_2)$로 나타낸다.

F 분포의 정의:

$$
\begin{aligned}
&\mathrm{F}(r_1,r_2)\overset{d}{\equiv}\frac{\chi^2(r_1)/r_1}{\chi^2(r_2)/r_2},\ \chi^2(r_1)\perp\chi^2(r_2)\\
&\quad\mathrm{X}\sim\mathrm{F}(r_1,r_2)(r_i>0,\,i=1,2)\\
&\Leftrightarrow \mathrm{X}\overset{d}{\equiv}\frac{\mathrm{V}_1/r_1}{\mathrm{V}_2/r_2},\ \mathrm{V}_i\sim\chi^2(r_i)(i=1,2),\ \mathrm{V}_1\text{과 }\mathrm{V}_2\text{는 서로 독립}\\
&\Leftrightarrow pdf_{\mathrm{X}}(x)=\frac{\Gamma((r_1+r_2)/2)}{\Gamma(r_1/2)\Gamma(r_2/2)}\left(\frac{r_1}{r_2}\right)^{r_1/2}x^{r_1/2-1}(1+r_1x/r_2)^{-(r_1+r_2)/2}\mathrm{I}_{(x>0)}
\end{aligned}
$$

F 분포의 확률밀도함수나 누적확률은 부록 Ⅲ에 소개되어 있는 패키지 R을 이용하여 계산할 수 있으며, 이를 이용하여 F 분포의 형태를 그려보면 <그림 4.2.3>과 같다. 또한 카이제곱분포의 경우와 같이, $X \sim F(r_1, r_2)$일 때

$$P(X > F_\alpha(r_1, r_2)) = \alpha \quad (0 < \alpha < 1)$$

를 만족시키는 값 $F_\alpha(r_1, r_2)$을 자유도가 (r_1, r_2)인 F 분포의 상방 α 분위수라고 한다.

그림 4.2.3 F 분포 $F(r_1, r_2)$의 형태와 상방 α 분위수

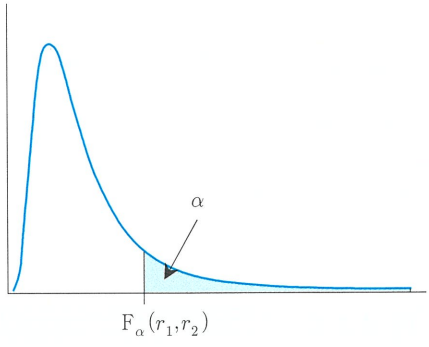

이러한 F 분포의 상방 분위수는 부록 Ⅳ에 주어진 F 분포의 누적확률 분포표로부터 구하거나 패키지 R을 이용하여 구할 수 있다. 예를 들면,

$$F_{0.05}(5,10) = 3.330,\ F_{0.025}(5,10) = 4.240,\ F_{0.01}(5,10) = 5.640$$

정리 4.2.5 F 분포의 성질

(a) $X \sim F(r_1, r_2)$이면 $1/X \sim F(r_2, r_1)$이다. 따라서

$$F_{1-\alpha}(r_1, r_2) = 1/F_\alpha(r_2, r_1)$$

(b) $X \sim t(r)$이면 $X^2 \sim F(1, r)$이다. 따라서

$$t^2_{\alpha/2}(r) = F_\alpha(1, r)$$

[증명] (a) F 분포의 정의로부터

$$X \sim F(r_1, r_2) \Leftrightarrow X \overset{d}{\equiv} \frac{V_1/r_1}{V_2/r_2},\ V_i \sim \chi^2(r_i)(i=1,2),\ V_1\text{과 } V_2\text{는 서로 독립}$$

$$\therefore 1/X \overset{d}{\equiv} \frac{V_2/r_2}{V_1/r_1},\ V_i \sim \chi^2(r_i)(i=1,2),\ V_1\text{과 } V_2\text{는 서로 독립}$$

$$\therefore 1/X \sim F(r_2, r_1)$$

한편 분위수 사이의 관계는 다음 등식으로부터 알 수 있다.

$$1-\alpha = P\{X \geq F_{1-\alpha}(r_1, r_2)\},\ \alpha = P\{1/X \geq F_\alpha(r_2, r_1)\}$$

$$\therefore \alpha = P\{X \leq F_{1-\alpha}(r_1, r_2)\} = P\{X \leq 1/F_\alpha(r_2, r_1)\}$$

(b) t 분포의 정의로부터

$$X \sim t(r) \Leftrightarrow X \overset{d}{\equiv} \frac{Z}{\sqrt{V/r}},\ Z \sim N(0,1),\ V \sim \chi^2(r),\ Z\text{와 } V\text{는 서로 독립}$$

$$\therefore X^2 \overset{d}{\equiv} \frac{Z^2}{V/r},\ Z \sim N(0,1),\ V \sim \chi^2(r),\ Z\text{와 } V\text{는 서로 독립}$$

그런데 $Z^2 \sim \chi^2(1)$이고 Z^2과 V가 서로 독립이므로 $X^2 \sim F(1,r)$이다. 한편 분위수 사이의 관계는 다음 등식으로부터 알 수 있다.

$$\alpha = P\{X^2 \geq F_\alpha(1,r)\},\ \alpha = P\{|X| \geq t_{\alpha/2}(r)\} = P\{X^2 \geq t^2_{\alpha/2}(r)\}$$

예 4.2.5

부록 Ⅳ의 분포표로부터

$$F_{0.975}(5,10) = 1/F_{0.025}(10,5) = 1/6.620 = 0.151$$

$$t^2_{0.025}(5) = 2.571^2 = 6.610,\ F_{0.05}(1,5) = 6.610$$

정리 4.2.6 두 정규모집단에서 모분산의 비교

두 정규분포 $N(\mu_1, \sigma_1^2)$, $N(\mu_2, \sigma_2^2)$에서의 랜덤표본이 각각 $X_{11}, X_{12}, \cdots, X_{1n_1}$과 $X_{21}, X_{22}, \cdots, X_{2n_2}$이고 두 랜덤표본이 서로 독립일 때,

$$\overline{X_i} = \sum_{j=1}^{n_i} X_{ij}/n_i,\ S_i^2 = \sum_{j=1}^{n_i} (X_{ij} - \overline{X_i})^2/(n_i - 1)\ (i = 1,2)$$

라고 하면

$$\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$$

$$P\left\{\frac{S_1^2}{S_2^2}\frac{1}{F_{\alpha/2}(n_1-1,n_2-1)} \leq \frac{\sigma_1^2}{\sigma_2^2} \leq \frac{S_1^2}{S_2^2}F_{\alpha/2}(n_2-1,n_1-1)\right\} = 1-\alpha$$

[증명] 표본분포에 관한 기본 정리인 <정리 4.2.2>로부터

$$(n_1 - 1)S_1^2/\sigma_1^2 \sim \chi^2(n_1 - 1),\ (n_2 - 1)S_2^2/\sigma_2^2 \sim \chi^2(n_2 - 1)$$

이고 두 랜덤표본이 독립이므로 S_1^2, S_2^2은 서로 독립이다. 따라서 F 분포의 정의로부터

$$\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1-1, n_2-1)$$

$$\therefore P\left\{F_{1-\alpha/2}(n_1-1, n_2-1) \le \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \le F_{\alpha/2}(n_1-1, n_2-1)\right\} = 1-\alpha$$

이 확률 표현에서 부등식을 σ_1^2/σ_2^2에 관하여 정리하면

$$\frac{S_1^2}{S_2^2}\frac{1}{F_{\alpha/2}(n_1-1, n_2-1)} \le \frac{\sigma_1^2}{\sigma_2^2} \le \frac{S_1^2}{S_2^2}\frac{1}{F_{1-\alpha/2}(n_1-1, n_2-1)}$$

이고, <정리 4.2.5>에 주어진 F 분포의 분위수에 관한 성질을 이용하면 정리에 주어진 σ_1^2/σ_2^2에 관한 신뢰구간의 표현을 얻게 된다.

여러 개의 모집단을 비교할 때 각 모집단의 분산이 동일하다는 전제 하에서 모평균의 비교를 하는 경우가 많다. 이러한 비교를 목적으로 가장 흔히 사용되는 모형이 다음의 일원분류모형(一元分類模型, one way classification model)이다. 이는 분산이 동일한 여러 개의 정규모집단 $N(\mu_i, \sigma^2)$에서 서로 독립인 랜덤표본 $X_{i1}, \cdots, X_{in_i}$ $(i=1, \cdots, k)$을 관측한다는 뜻이다.

일원분류모형:

$$\begin{cases} X_{ij} = \mu_i + e_{ij} \\ e_{ij} \overset{iid}{\sim} N(0, \sigma^2), \ i=1, \cdots, k; \ j=1, \cdots, n_i \end{cases}$$

정리 4.2.7 여러 개의 정규모집단에서 모평균의 비교

일원분류모형

$$\begin{cases} X_{ij} = \mu_i + e_{ij} \\ e_{ij} \overset{iid}{\sim} N(0, \sigma^2), \ i=1, \cdots, k; \ j=1, \cdots, n_i \end{cases}$$

에서

$$\overline{X}_i = \sum_{j=1}^{n_i} X_{ij}/n_i, \ \overline{X} = \sum_{i=1}^{k}\sum_{j=1}^{n_i} X_{ij}/n, \ \overline{\mu} = \sum_{i=1}^{k} n_i\mu_i/n, \ n = n_1 + \cdots + n_k$$

라고 할 때 다음이 성립한다.

(a) $\sum_{i=1}^{k} n_i(\overline{X}_i - \overline{X} - (\mu_i - \overline{\mu}))^2/\sigma^2 \sim \chi^2(k-1)$

(b) $\sum_{i=1}^{k}\sum_{j=1}^{n_i}(X_{ij} - \overline{X}_i)^2/\sigma^2 \sim \chi^2(n-k)$

(c) $\sum_{i=1}^{k} n_i(\overline{X}_i - \overline{X} - (\mu_i - \overline{\mu}))^2$과 $\sum_{i=1}^{k}\sum_{j=1}^{n_i}(X_{ij} - \overline{X}_i)^2$ 은 서로 독립이다.

따라서 $\hat{\sigma^2} = \sum_{i=1}^{k}\sum_{j=1}^{n_i}(X_{ij} - \overline{X}_i)^2/(n-k)$ 라고 하면

$$\frac{1}{k-1}\sum_{i=1}^{k} n_i(\overline{X}_i - \overline{X} - (\mu_i - \overline{\mu}))^2/\hat{\sigma^2} \sim F(k-1, n-k)$$

$$P\left\{\sum_{i=1}^{k} n_i(\mu_i - \overline{\mu} - (\overline{X}_i - \overline{X}))^2 \le (k-1)\hat{\sigma^2} F_\alpha(k-1, n-k)\right\} = 1-\alpha$$

[증명] $N(\mu_i, \sigma^2)$에서의 랜덤표본 $X_{i1}, \cdots, X_{in_i}$에 표본분포의 기본 <정리 4.2.2>를 적용하면

$$\begin{cases} \overline{X}_i \sim N(\mu_i, \sigma^2/n_i),\ (n_i-1)S_i^2/\sigma^2 = \sum_{j=1}^{n_i}(X_{ij} - \overline{X}_i)^2/\sigma^2 \sim \chi^2(n_i-1) \\ \overline{X}_i \text{와 } S_i^2 \text{은 서로 독립} \end{cases}$$

이고 각 랜덤표본이 서로 독립이므로, $\overline{X}_1, \cdots, \overline{X}_k, S_1^2, \cdots, S_k^2$은 서로 독립이다. 따라서 $\overline{X}_1, \cdots, \overline{X}_k$의 함수와 $\sum_{i=1}^{k}(n_i-1)S_i^2 = \sum_{i=1}^{k}\sum_{j=1}^{n_i}(X_{ij} - \overline{X}_i)^2$은 서로 독립이고, (c)가 성립한다.

또한 <정리 4.2.1>의 (c)에 주어진 카이제곱분포의 성질로부터

$$\sum_{i=1}^{k}\sum_{j=1}^{n_i}(X_{ij} - \overline{X}_i)^2/\sigma^2 = \sum_{i=1}^{k}(n_i-1)S_i^2/\sigma^2 \sim \chi^2\left(\sum_{i=1}^{k}(n_i-1)\right) = \chi^2(n-k)$$

이므로 (b)가 성립하는 것을 알 수 있다.

(a)의 일반적 증명은 4장 4절에서 다룰 것이고 여기에서는 표본크기가 같은 경우, 즉 $n_1 = \cdots = n_k = n$인 경우에 국한하여 증명하기로 한다. 이 경우에

$$Z_i = (\overline{X}_i - \mu_i)/(\sigma/\sqrt{n}) = \sqrt{n}(\overline{X}_i - \mu_i)/\sigma \quad (i = 1, \cdots, k)$$

는 서로 독립이고 각각 $N(0,1)$을 따르는 확률변수이다. 따라서 $Z_1, \cdots, Z_k$에 <정리 4.2.2>를 적용하면 다음이 성립하는 것을 알 수 있다.

$$\sum_{i=1}^{k} n(\overline{X}_i - \overline{X} - (\mu_i - \overline{\mu}))^2/\sigma^2 = \sum_{i=1}^{k}(Z_i - \overline{Z})^2 \sim \chi^2(k-1)$$

마지막으로

$$\frac{1}{k-1}\sum_{i=1}^{k} n_i(\overline{X}_i-\overline{X}-(\mu_i-\overline{\mu}))^2/\widehat{\sigma^2}=\frac{\sum_{i=1}^{k} n_i(\overline{X}_i-\overline{X}-(\mu_i-\overline{\mu}))^2/(k-1)\sigma^2}{\sum_{i=1}^{k}\sum_{j=1}^{n_i}(X_{ij}-\overline{X}_i)^2/(n-k)\sigma^2}$$

이므로 (a), (b), (c)와 F 분포의 정의로부터

$$\frac{1}{k-1}\sum_{i=1}^{k} n_i(\overline{X}_i-\overline{X}-(\mu_i-\overline{\mu}))^2/\widehat{\sigma^2}\sim F(k-1,n-k)$$

임을 알 수 있다. 따라서 다음과 같은 확률 표현이 성립한다.

$$P\left\{\frac{1}{k-1}\sum_{i=1}^{k} n_i(\overline{X}_i-\overline{X}-(\mu_i-\overline{\mu}))^2/\widehat{\sigma^2}\le F_\alpha(k-1,n-k)\right\}=1-\alpha$$

이 확률 표현에서 부등식을 $\mu_i-\overline{\mu}(i=1,\cdots,k)$에 관한 타원체 내부의 방정식 형태로 바꾸어 나타내면 다음과 같이 정리에 주어진 표현을 얻게 된다.

$$P\left\{\sum_{i=1}^{k} n_i(\mu_i-\overline{\mu}-(\overline{X}_i-\overline{X}))^2\le(k-1)\widehat{\sigma^2}F_\alpha(k-1,n-k)\right\}=1-\alpha$$

<정리 4.2.7>에 주어진 $\mu_i-\overline{\mu}\,(i=1,\cdots,k)$에 관한 집합은 신뢰수준 $100(1-\alpha)\%$의 신뢰집합(信賴集合, confidence set)이라고 하며 이는 신뢰구간을 일반화한 것이다. 이의 이해를 위하여 두 모평균의 비교를 하는 경우인 $k=2$인 경우를 생각해보자. $k=2$인 경우에는

$$\begin{cases}\mu_1-\overline{\mu}=\dfrac{n_2}{n_1+n_2}(\mu_1-\mu_2), & \mu_2-\overline{\mu}=\dfrac{n_1}{n_1+n_2}(\mu_2-\mu_1)\\ \overline{X}_1-\overline{X}=\dfrac{n_2}{n_1+n_2}(\overline{X}_1-\overline{X}_2), & \overline{X}_2-\overline{X}=\dfrac{n_1}{n_1+n_2}(\overline{X}_2-\overline{X}_1)\end{cases}$$

이므로

$$\frac{1}{k-1}\sum_{i=1}^{k} n_i(\overline{X}_i-\overline{X}-(\mu_i-\overline{\mu}))^2=\frac{n_1n_2}{n_1+n_2}(\overline{X}_2-\overline{X}_1-(\mu_2-\mu_1))^2$$

$$\therefore\ \frac{1}{k-1}\sum_{i=1}^{k} n_i(\overline{X}_i-\overline{X}-(\mu_i-\overline{\mu}))^2/\widehat{\sigma^2}=\left\{\frac{\overline{X}_2-\overline{X}_1-(\mu_2-\mu_1)}{\sqrt{n_1^{-1}+n_2^{-1}}\,\hat{\sigma}}\right\}^2$$

또한 <정리 4.2.5>로부터

$$F_\alpha(k-1,n-k)=F_\alpha(1,n_1+n_2-2)=t^2_{\alpha/2}(n_1+n_2-2)$$

이므로, $k=2$인 경우에 위에서의 확률 표현은 다음과 같이 나타낼 수 있다.

$$P\left\{\left|\frac{\overline{X}_2-\overline{X}_1-(\mu_2-\mu_1)}{\sqrt{n_1^{-1}+n_2^{-1}}\,\hat{\sigma}}\right| \le t_{\alpha/2}(n_1+n_2-2)\right\}=1-\alpha$$

그러므로 $k=2$인 경우에 신뢰집합은 $\mu_2-\mu_1$에 관한 신뢰구간

$$\left[\overline{X}_2-\overline{X}_1-t_{\alpha/2}(n_1+n_2-2)\sqrt{n_1^{-1}+n_2^{-1}}\,\hat{\sigma},\right.$$
$$\left.\overline{X}_2-\overline{X}_1+t_{\alpha/2}(n_1+n_2-2)\sqrt{n_1^{-1}+n_2^{-1}}\,\hat{\sigma}\right]$$

으로 주어지는 것을 알 수 있다.

이러한 신뢰구간 또는 <정리 4.2.7>의 신뢰집합이 원점을 포함하는가에 따라 여러 개의 모평균의 동일성 여부에 대한 추론을 할 수 있다.

4.3 순서통계량의 분포

모집단 분포가 연속형인 경우에 모집단의 중심 부분에 대한 추론에는 표본평균과 더불어 표본중앙값도 많이 사용된다. 이러한 표본중앙값은 랜덤표본 $X_1, X_2, \cdots, X_n$을 크기 순서로 늘어놓은 순서통계량 $X_{(1)} < X_{(2)} < \cdots < X_{(n)}$ 중의 하나이다. 이러한 순서통계량의 분포에 대하여 알아보자.

예 4.3.1

표준지수분포 $\mathrm{Exp}(1)$에서의 랜덤표본 X_1, X_2, X_3을 크기 순서로 늘어놓은 순서통계량을 $X_{(1)} < X_{(2)} < X_{(3)}$이라고 할 때 $Y=(X_{(1)}, X_{(2)}, X_{(3)})^t$의 결합확률밀도함수를 구하여라.

[풀이] 순서통계량을 나타내는 함수를 $u(X_1, X_2, X_3)=(X_{(1)}, X_{(2)}, X_{(3)})^t$라고 하면, 함수 u는

$$\mathscr{X}=\left\{(x_1,x_2,x_3)^t : x_i>0\,(i=1,2,3),\ x_1\neq x_2,\ x_2\neq x_3,\ x_3\neq x_1\right\}$$

에서

$$\mathscr{Y}=\left\{(y_1,y_2,y_3)^t : 0<y_1<y_2<y_3\right\}$$

로의 3!대일 함수로서 다대일 변환에 관한 <정리 4.1.2>의 조건을 만족하는 것을 알 수 있다.

구체적으로 $\{1,2,3\}$에서의 치환(置換, permutation)을 π로 나타내고

$$\mathscr{X}_\pi=\{(x_1,x_2,x_3)^t : 0 < x_{\pi 1} < x_{\pi 2} < x_{\pi 3}\}$$

라고 하면 함수 u에서 정의역을 $\mathscr{X}_\pi$로 제한한 함수

$$u^\pi(x_1,x_2,x_3)=(x_{\pi 1},x_{\pi 2},x_{\pi 3})^t,\ x\in\mathscr{X}_\pi$$

는 각각 $\mathscr{X}_\pi$에서 $\mathscr{Y}$로의 일대일 함수로서 미분가능하며

$$J_{u^\pi}(x)=\det\left(\frac{\partial x_{\pi j}}{\partial x_i}\right)=\pm 1\quad \forall x\in\mathscr{X}_\pi$$

임을 알 수 있다. 예를 들어 $(\pi 1,\pi 2,\pi 3)=(3,2,1)$인 경우에

$$J_{u^\pi}(x)=\det\begin{pmatrix}0&0&1\\0&1&0\\1&0&0\end{pmatrix}=-1$$

따라서 <정리 4.1.2>의 공식으로부터 $\mathrm{Y}=(\mathrm{X}_{(1)},\mathrm{X}_{(2)},\mathrm{X}_{(3)})^t$의 결합확률밀도함수는 다음과 같이 주어진다.

$$\begin{aligned}pdf_{\mathrm{Y}}(y)&=\sum_\pi pdf_{\mathrm{X}}((u^\pi)^{-1}(y))|J_{(u^\pi)^{-1}}(y)|,\ y\in\mathscr{Y}\\&=\sum_\pi pdf_{\mathrm{X}}(y_{\pi^{-1}1},y_{\pi^{-1}2},y_{\pi^{-1}3})|\pm 1|,\ y\in\mathscr{Y}\end{aligned}$$

한편 $\mathrm{X}=(\mathrm{X}_1,\mathrm{X}_2,\mathrm{X}_3)^t$의 결합확률밀도함수는

$$pdf_{\mathrm{X}}(x_1,x_2,x_3)=e^{-(x_1+x_2+x_3)}\mathrm{I}_{(x_1>0,\,x_2>0,\,x_3>0)}$$

이고 치환 π의 개수는 3!=6개이므로

$$\begin{aligned}pdf_{\mathrm{Y}}(y_1,y_2,y_3)&=\sum_\pi e^{-(y_{\pi^{-1}1}+y_{\pi^{-1}2}+y_{\pi^{-1}3})},\ y\in\mathscr{Y}\\&=6e^{-(y_1+y_2+y_3)}\mathrm{I}_{(0<y_1<y_2<y_3)}\end{aligned}$$

정리 4.3.1 순서통계량의 결합확률밀도함수

모집단 분포가 연속형이고 그 확률밀도함수가 $f(x)$일 때, 랜덤표본 X_1, X_2, $\cdots$, X_n을 크기 순서로 늘어놓은 순서통계량을 $\mathrm{X}_{(1)}<\mathrm{X}_{(2)}<\cdots<\mathrm{X}_{(n)}$이라고 하면 $\mathrm{Y}=(\mathrm{X}_{(1)},\mathrm{X}_{(2)},\cdots,\mathrm{X}_{(n)})^t$의 결합확률밀도함수는 다음과 같이 주어진다.

$$pdf_{\mathrm{Y}}(y_1,\cdots,y_n)=n!f(y_1)\cdots f(y_n)\mathrm{I}_{(y_1<\cdots<y_n)}$$

[증명] 순서통계량을 나타내는 함수를 $u(\mathrm{X}_1,\cdots,\mathrm{X}_n)=(\mathrm{X}_{(1)},\cdots,\mathrm{X}_{(n)})^t$이라고 하면, 함수 u는

$\mathscr{X} = \{ (x_1, \cdots, x_n)^t : f(x_i) > 0 \, (i = 1, \cdots, n), \; x_1, \cdots, x_n$은 서로 다른 실수$\}$

에서

$$\mathscr{Y} = \left\{ (y_1, \cdots, y_n)^t : f(y_i) > 0 (i = 1, \cdots, n), \; y_1 < \cdots < y_n \right\}$$

로의 $n!$대일 함수로서 다대일 변환에 관한 <정리 4.1.2>의 조건을 만족하는 것을 알 수 있다.

구체적으로 $\{1, \cdots, n\}$에서의 치환을 π로 나타내고

$$\mathscr{X}_\pi = \left\{ (x_1, \cdots, x_n)^t : f(x_i) > 0 \, (i = 1, \cdots, n), \; x_{\pi 1} < \cdots < x_{\pi n} \right\}$$

라고 하면 함수 u에서 정의역을 $\mathscr{X}_\pi$로 제한한 함수

$$u^\pi (x_1, \cdots, x_n) = (x_{\pi 1}, \cdots, x_{\pi n})^t, \; x \in \mathscr{X}_\pi$$

는 각각 $\mathscr{X}_\pi$에서 Y로의 일대일 함수로서 미분가능하며 일차편도함수의 행렬 $\left(\frac{\partial x_{\pi j}}{\partial x_i} \right)$은 단위행렬의 행과 열을 치환해놓은 행렬인 것을 알 수 있다. 따라서

$$J_{u^\pi}(x) = \det \left(\frac{\partial x_{\pi j}}{\partial x_i} \right) = \pm 1 \quad \forall x \in \mathscr{X}_\pi$$

이고 <정리 4.1.2>의 공식으로부터 $\mathrm{Y} = (\mathrm{X}_{(1)}, \cdots, \mathrm{X}_{(n)})^t$의 결합확률밀도함수는

$$\begin{aligned} pdf_{\mathrm{Y}}(y) &= \sum_\pi pdf_{\mathrm{X}} ((u^\pi)^{-1}(y)) |J_{(u^\pi)^{-1}}(y)|, \; y \in \mathscr{Y} \\ &= \sum_\pi pdf_{\mathrm{X}} (y_{\pi^{-1}1}, \cdots, y_{\pi^{-1}n}) |\pm 1|, \; y \in \mathscr{Y} \end{aligned}$$

한편 $\mathrm{X} = (\mathrm{X}_1, \cdots, \mathrm{X}_n)^t$의 결합확률밀도함수는

$$pdf_{\mathrm{X}} (x_1, \cdots, x_n) = f(x_1) \cdots f(x_n)$$

이고 치환 π의 개수는 $n!$개이므로

$$\begin{aligned} pdf_{\mathrm{Y}} (y_1, \cdots, y_n) &= \sum_\pi f(y_{\pi^{-1}1}) \cdots f(y_{\pi^{-1}n}), \; y \in \mathscr{Y} \\ &= n! f(y_1) \cdots f(y_n) \mathrm{I}_{(y_1 < \cdots < y_n)} \end{aligned}$$

순서통계량의 주변확률밀도함수는 <정리 4.3.1>의 결합확률밀도함수를 적분하여 구할 수 있으나 우선 직관적으로 그 분포에 대하여 생각해보자.

$\mathrm{X}_{(r)}$이 x 근방에 있을 사건 $(x < \mathrm{X}_{(r)} \leq x + |\triangle x|)$은 $\mathrm{X}_1, \cdots, \mathrm{X}_n$들 중에서 $(r-1)$개는 x 이하이고 1개는 x와 $x + |\triangle x|$ 사이에, 그리고 나머지 $(n-r)$개는 $x + |\triangle x|$를 초과하는 사건으로 나타내어진다. 그런데 $\mathrm{X}_1, \cdots, \mathrm{X}_n$은 서로 독립이고

동일한 분포를 따르므로 이러한 사건의 확률은 다음과 같이 나타낼 수 있다.

$$\begin{aligned}&\mathrm{P}(x < \mathrm{X}_{(r)} \le x + |\Delta x|)\\ &\approx c_r [\mathrm{P}(\mathrm{X}_1 \le x)]^{r-1} \mathrm{P}(x < \mathrm{X}_1 \le x + |\Delta x|)[\mathrm{P}(\mathrm{X}_1 > x + |\Delta x|)]^{n-r}\end{aligned}$$

여기에서 c_r은 서로 다른 n개 중에서 $(r-1)$개, 1개, $(n-r)$개를 뽑아서 각각 세 개의 구간 $(-\infty, x]$, $(x, x+|\Delta x|]$, $(x+|\Delta x|, +\infty)$에 넣는 방법의 수를 나타내는 상수이다. 즉

$$c_r = \frac{n!}{(r-1)!1!(n-r)!}$$

따라서 모집단의 확률밀도함수와 누적분포함수를 각각 f 와 F라고 하면

$$pdf_{\mathrm{X}_{(r)}}(x)|\Delta x| \approx c_r [\mathrm{F}(x)]^{r-1} f(x)|\Delta x|[1-\mathrm{F}(x)]^{n-r}$$

정리 4.3.2 순서통계량의 주변확률밀도함수

모집단 분포가 연속형이고 그 확률밀도함수가 $f(x)$이고 누적분포함수가 $\mathrm{F}(x)$일 때, 랜덤표본 $\mathrm{X}_1, \cdots, \mathrm{X}_n$을 크기 순서로 늘어놓은 순서통계량을 $\mathrm{X}_{(1)} < \cdots < \mathrm{X}_{(n)}$이라고 하면 이들의 일차원 또는 이차원 주변확률밀도함수가 다음과 같이 주어진다.

(a) ($\mathrm{X}_{(r)}$의 확률밀도함수) $(1 \le r \le n)$

$$pdf_{\mathrm{X}_{(r)}}(x) = \frac{n!}{(r-1)!(n-r)!}[\mathrm{F}(x)]^{r-1} f(x)[1-\mathrm{F}(x)]^{n-r}$$

(b) ($(\mathrm{X}_{(r)}, \mathrm{X}_{(s)})^t$의 확률밀도함수) $(1 \le r < s \le n)$

$$\begin{aligned}&pdf_{\mathrm{X}_{(r)},\mathrm{X}_{(s)}}(x,y)\\ &= \frac{n!}{(r-1)!(s-1-r)!(n-s)!}[\mathrm{F}(x)]^{r-1} f(x)[\mathrm{F}(y)-\mathrm{F}(x)]^{s-1-r} f(y)[1-\mathrm{F}(y)]^{n-s}\end{aligned}$$

[증명] <정리 4.3.1>에 주어진 $(\mathrm{X}_{(1)}, \cdots, \mathrm{X}_{(n)})^t$의 결합확률밀도함수를 $f_{1,\cdots,n}(y_1, \cdots, y_n)$으로 나타내고, $\mathrm{X}_{(r)}$과 $(\mathrm{X}_{(r)}, \mathrm{X}_{(s)})^t$의 주변확률밀도함수를 각각 $f_r(x)$, $f_{r,s}(x,y)$로 나타내면

$$f_r(x) = \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} f_{1,\cdots,n}(y_1, \cdots, x, \cdots, y_n) dy_1 \cdots dy_{r-1} dy_{r+1} \cdots dy_n$$

$$\begin{aligned}f_{r,s}(x,y) = \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} &f_{1,\cdots,n}(y_1, \cdots, x, \cdots, y, \cdots y_n)\\ &\times dy_1 \cdots dy_{r-1} dy_{r+1} \cdots dy_{s-1} dy_{s+1} \cdots dy_n\end{aligned}$$

(a) 이 경우에 피적분함수인 $f_{1,\cdots,n}(y_1,\cdots,x,\cdots,y_n)$에서 $f(y_1)\cdots f(y_{r-1})$은 $y_1, \cdots, y_{r-1}$의 치환에 변함이 없고 $f(y_{r+1})\cdots f(y_n)$은 $y_{r+1}, \cdots, y_n$의 치환에 변함이 없으므로

$$\int_{-\infty}^{+\infty}\cdots\int_{-\infty}^{+\infty} f(y_1)\cdots f(y_{r-1})\mathrm{I}_{(y_1<\cdots<y_{r-1}<x)}dy_1\cdots dy_{r-1}$$

$$=\frac{1}{(r-1)!}\int_{-\infty}^{x}\cdots\int_{-\infty}^{x} f(y_1)\cdots f(y_{r-1})dy_1\cdots dy_{r-1}$$

$$=\frac{1}{(r-1)!}[\mathrm{F}(x)]^{r-1}$$

이고

$$\int_{-\infty}^{+\infty}\cdots\int_{-\infty}^{+\infty} f(y_{r+1})\cdots f(y_n)\mathrm{I}_{(x<y_{r+1}<\cdots<y_n)}dy_{r+1}\cdots dy_n$$

$$=\frac{1}{(n-r)!}\int_{x}^{+\infty}\cdots\int_{x}^{+\infty} f(y_{r+1})\cdots f(y_n)dy_{r+1}\cdots dy_n$$

$$=\frac{1}{(n-r)!}[1-\mathrm{F}(x)]^{n-r}$$

$$\therefore f_r(x)=n!f(x)\frac{1}{(r-1)!}[\mathrm{F}(x)]^{r-1}\frac{1}{(n-r)!}[1-\mathrm{F}(x)]^{n-r}$$

(b) 이 경우에는 피적분함수 $f_{1,\cdots,n}(y_1,\cdots,x,\cdots y,\cdots,y_n)$에서 $f(y_1)\cdots f(y_{r-1})$은 $y_1,\cdots,y_{r-1}$의 치환에, $f(y_{r+1})\cdots f(y_{s-1})$은 $y_{r+1},\cdots,y_{s-1}$의 치환에, $f(y_{s+1})\cdots f(y_n)$은 $y_{s+1},\cdots,y_n$의 치환에 변함이 없으므로 (a)와 같은 방법으로 적분을 할 수 있다. 예를 들면

$$\int_{-\infty}^{+\infty}\cdots\int_{-\infty}^{+\infty} f(y_{r+1})\cdots f(y_{s-1})\mathrm{I}_{(x<y_{r+1}<\cdots<y_{s-1}<y)}dy_{r+1}\cdots dy_{s-1}$$

$$=\frac{1}{(s-1-r)!}\int_{x}^{y}\cdots\int_{x}^{y} f(y_{r+1})\cdots f(y_{s-1})dy_{r+1}\cdots dy_{s-1}$$

$$=\frac{1}{(s-1-r)!}[\mathrm{F}(y)-\mathrm{F}(x)]^{s-1-r}$$

$$\therefore f_{r,s}(x,y)=n!f(x)f(y)\frac{1}{(r-1)!}[\mathrm{F}(x)]^{r-1}$$

$$\times\frac{1}{(s-1-r)!}[\mathrm{F}(y)-\mathrm{F}(x)]^{s-1-r}\frac{1}{(n-s)!}[1-\mathrm{F}(y)]^{n-s}$$

예 4.3.2 균등분포에서의 순서통계량

균등분포 $\mathrm{U}(0,1)$에서의 랜덤표본 n개에 기초한 순서통계량을 $\mathrm{X}_{(1)} < \cdots < \mathrm{X}_{(n)}$이라고 할 때 다음을 밝혀라.

(a) $\mathrm{X}_{(r)} \sim \mathrm{Beta}(r, n-r+1)$, 즉 $\mathrm{X}_{(r)}$의 확률밀도함수는

$$f_r(x) = \frac{n!}{(r-1)!(n-r)!} x^{r-1}(1-x)^{n-r} \mathrm{I}_{(0,1)}(x)$$

(b) $\mathrm{Z} = (\mathrm{X}_{(1)}, \mathrm{X}_{(2)} - \mathrm{X}_{(1)}, \cdots, \mathrm{X}_{(n)} - \mathrm{X}_{(n-1)})^t \sim \mathrm{Dirichlet}(1, \cdots, 1)$, 즉 Z의 확률밀도함수는

$$pdf_{\mathrm{Z}}(z_1, \cdots, z_n) = \frac{\Gamma(n+1)}{\Gamma(1)\cdots\Gamma(1)} \mathrm{I}_{(z_1>0,\ \cdots,\ z_n>0,\ z_1+\cdots+z_n<1)}$$

[풀이] 균등분포 $\mathrm{U}(0,1)$의 확률밀도함수와 누적분포함수는 각각

$$f(x) = \mathrm{I}_{(0,1)}(x),\ \mathrm{F}(x) = \begin{cases} 0, & x \le 0 \\ x, & 0 \le x \le 1 \\ 1, & x \ge 1 \end{cases}$$

이므로 (a)는 <정리 4.3.2>로부터 명백하다. 또한 <정리 4.3.1>로부터 $\mathrm{Y} = (\mathrm{X}_{(1)}, \cdots, \mathrm{X}_{(n)})^t$의 결합확률밀도함수는

$$pdf_{\mathrm{Y}}(y_1, \cdots, y_n) = n! \mathrm{I}_{(0<y_1<\cdots<y_n<1)}$$

한편 $\mathrm{Z} = (\mathrm{X}_{(1)}, \mathrm{X}_{(2)} - \mathrm{X}_{(1)}, \cdots, \mathrm{X}_{(n)} - \mathrm{X}_{(n-1)})^t$와 $\mathrm{Y} = (\mathrm{X}_{(1)}, \cdots, \mathrm{X}_{(n)})^t$에 대하여

$$\mathrm{Z} = (\mathrm{Z}_1, \cdots, \mathrm{Z}_n)^t = u((\mathrm{Y}_1, \cdots, \mathrm{Y}_n)^t) = u(\mathrm{Y})$$

라고 하면 다음과 같이 함수 u와 그 정의역 $\mathscr{Y}$, 치역 $\mathscr{Z}$, 역함수 u^{-1}를 생각할 수 있다.

$$u: \begin{cases} z_1 = y_1 \\ z_2 = y_2 - y_1 \\ \quad\vdots \\ z_n = y_n - y_{n-1} \end{cases} \qquad u^{-1}: \begin{cases} y_1 = z_1 \\ y_2 = z_1 + z_2 \\ \quad\vdots \\ y_n = z_1 + z_2 + \cdots + z_n \end{cases}$$

$$\mathscr{Y} = \{(y_1, \cdots, y_n)^t : 0 < y_1 < \cdots < y_n < 1\}$$

$$\mathscr{Z} = \{(z_1, \cdots, z_n)^t : z_i > 0 (i = 1, \cdots, n),\ z_1 + \cdots + z_n < 1\}$$

함수 u는 $\mathscr{Y}$에서 $\mathscr{Z}$로의 일대일 함수로서 <정리 4.1.1>의 조건을 만족시키고 그 역함수 u^{-1}의 야코비안 행렬식은 1이므로 $\mathrm{Z} = (\mathrm{X}_{(1)}, \mathrm{X}_{(2)} - \mathrm{X}_{(1)},$

$\cdots, X_{(n)} - X_{(n-1)})^t$의 결합확률밀도함수는

$$pdf_Z(z_1,\cdots,z_n) = n!\, I_{(z_1>0,\ \cdots,\ z_n>0,\ z_1+\cdots+z_n<1)}$$

예 4.3.3 지수분포에서의 순서통계량

지수분포 Exp(1)에서의 랜덤표본 n개에 기초한 순서통계량 $X_{(1)} <\cdots< X_{(n)}$에 대하여

$$Z_1 = nX_{(1)},\ Z_2 = (n-1)(X_{(2)} - X_{(1)}),\ \cdots,\ Z_n = X_{(n)} - X_{(n-1)}$$

이라고 할 때 $Z_1, Z_2, \cdots, Z_n$은 서로 독립이고 각각 지수분포 Exp(1)를 따르는 것을 밝혀라.

[풀이] $Y = (Y_1, Y_2, \cdots, Y_n) = (X_{(1)}, X_{(2)}, \cdots, X_{(n)})^t$ 이라고 하면 <정리 4.3.1>로부터

$$pdf_Y(y_1,\cdots,y_n) = n!\, e^{-(y_1+\cdots+y_n)} I_{(0<y_1<\cdots<y_n)}$$

한편 $Z = (nX_{(1)}, (n-1)(X_{(2)} - X_{(1)}), \cdots, X_{(n)} - X_{(n-1)})^t$와 $Y = (X_{(1)}, X_{(2)}, \cdots, X_{(n)})^t$ 에 대하여

$$Z = (Z_1,\cdots,Z_n)^t = u((Y_1,\cdots,Y_n)^t) = u(Y)$$

라고 하면 다음과 같이 함수 u와 그 정의역 $\mathcal{Y}$, 치역 $\mathcal{Z}$, 역함수 u^{-1}를 생각할 수 있다.

$$u: \begin{cases} z_1 = ny_1 \\ z_2 = (n-1)(y_2 - y_1) \\ \quad\vdots \\ z_n = y_n - y_{n-1} \end{cases} \qquad u^{-1}: \begin{cases} y_1 = \frac{1}{n} z_1 \\ y_2 = \frac{1}{n} z_1 + \frac{1}{n-1} z_2 \\ \quad\vdots \\ y_n = \frac{1}{n} z_1 + \frac{1}{n-1} z_2 + \cdots + \frac{1}{1} z_n \end{cases}$$

$$\mathcal{Y} = \{(y_1,\cdots,y_n)^t : 0 < y_1 <\cdots< y_n\}$$

$$\mathcal{Z} = \{(z_1,\cdots,z_n)^t : z_1 > 0,\cdots,z_n > 0\}$$

함수 u는 $\mathcal{Y}$에서 $\mathcal{Z}$로의 일대일 함수로서 <정리 4.1.1>의 조건을 만족시키고 그 역함수 u^{-1}의 야코비안 행렬식은 $1/n!$, $y_1 +\cdots+ y_n = z_1 +\cdots+ z_n$이므로 Z의 결합확률밀도함수는

$$pdf_Z(z_1,\cdots,z_n) = n!\, e^{-(z_1+\cdots+z_n)} I_{(z_1>0,\ \cdots,\ z_n>0)} \frac{1}{n!} = \prod_{i=1}^{n} \{e^{-z_i} I_{(0,\infty)}(z_i)\}$$

지수분포에서의 순서통계량 분포의 대의적 정의:

지수분포 $\mathrm{Exp}(1)$에서의 랜덤표본 n개에 기초한 순서통계량을 $\mathrm{X}_{(1)} < \cdots < \mathrm{X}_{(n)}$이라고 하면

$$(\mathrm{X}_{(r)})_{1 \le r \le n} \overset{d}{\equiv} \left(\frac{1}{n}\mathrm{Z}_1 + \cdots + \frac{1}{n-r+1}\mathrm{Z}_r \right)_{1 \le r \le n}, \quad \mathrm{Z}_r \overset{iid}{\sim} \mathrm{Exp}(1)\ (r = 1, \cdots, n)$$

정리 4.3.3 **확률적분변환(確率積分變換, probability integral transformation)[58]**

확률변수 X가 연속형이고 그 누적분포함수 F가 순증가함수, 즉

$$x_1 < x_2 \text{이면 } \mathrm{F}(x_1) < \mathrm{F}(x_2)$$

일 때 그 역함수를 F^{-1}라고 하면 다음이 성립한다.

(a) $\mathrm{F}(\mathrm{X}) \sim \mathrm{U}(0,1)$, 즉 $\mathrm{F}(\mathrm{X})$는 균등분포 $\mathrm{U}(0,1)$을 따른다.

(b) 균등분포 $\mathrm{U}(0,1)$을 따르는 확률변수 U에 대하여

$$\mathrm{F}^{-1}(\mathrm{U}) \overset{d}{\equiv} \mathrm{X}$$

즉 $\mathrm{F}^{-1}(\mathrm{U})$의 누적분포함수는 F로서 $\mathrm{F}^{-1}(\mathrm{U})$와 X는 같은 분포를 갖는다.

[증명] 주어진 조건하에서 역함수 F^{-1}도 순증가하고 다음이 성립하는 것을 알 수 있다.

$$\mathrm{F}(x) \le u \Leftrightarrow x \le \mathrm{F}^{-1}(u),\ \mathrm{F}^{-1}(u) \le x \Leftrightarrow u \le \mathrm{F}(x),\ \mathrm{F}(\mathrm{F}^{-1}(u)) = u$$

(a) $\mathrm{P}(\mathrm{F}(\mathrm{X}) \le u) = \mathrm{P}(\mathrm{X} \le \mathrm{F}^{-1}(u)) = \mathrm{F}(\mathrm{F}^{-1}(u)) = u \ \forall u : 0 \le u \le 1$

$$\therefore \mathrm{F}(\mathrm{X}) \sim \mathrm{U}(0,1)$$

(b) $\mathrm{P}(\mathrm{F}^{-1}(\mathrm{U}) \le x) = \mathrm{P}(\mathrm{U} \le \mathrm{F}(x)) = \mathrm{F}(x) \ \ \forall x : -\infty < x < +\infty$

$$\therefore \mathrm{F}^{-1}(\mathrm{U}) \overset{d}{\equiv} \mathrm{X}$$

예 4.3.4 **균등분포와 지수분포에서의 순서통계량**

균등분포 $\mathrm{U}(0,1)$에서의 랜덤표본 n개에 기초한 순서통계량을 $\mathrm{U}_{(1)} < \cdots < \mathrm{U}_{(n)}$이라고 하고 지수분포 $\mathrm{Exp}(1)$에서의 랜덤표본 n개에 기초한 순서통계량을 $\mathrm{Y}_{(1)} < \cdots < \mathrm{Y}_{(n)}$이라고 하면

---

58) 누적분포함수가 순증가는 아닌 증가함수인 경우에는 F의 역변환을

$$\mathrm{F}^{-1}(u) = inf\{x : \mathrm{F}(x) \ge u\}\ (0 \le u \le 1)$$

로 정의하고, 이 역변환에 대하여 정리의 (b)가 일반적인 확률변수에 대하여도 성립한다.

$$(U_{(r)})_{1 \le r \le n} \overset{d}{\equiv} (1 - e^{-Y_{(r)}})_{1 \le r \le n}$$

[풀이] 지수분포 $\mathrm{Exp}(1)$에서의 랜덤표본을 $Y_1, Y_2, \cdots, Y_n$이라고 할 때, 지수분포의 누적분포함수가

$$G(y) = \begin{cases} 1 - e^{-y}, & y \ge 0 \\ 0, & y < 0 \end{cases}$$

이므로 <정리 4.3.3>으로부터

$$G(Y_i) \overset{iid}{\sim} U(0,1)$$

또한 누적분포함수는 증가함수이므로

$$(G(Y_{(r)}))_{1 \le r \le n} \overset{d}{\equiv} (U_{(r)})_{1 \le r \le n}$$

정리 4.3.4 순서통계량 분포의 대의적 정의

모집단 분포가 연속형이고 그 누적분포함수가 $F(x)$일 때 랜덤표본 n개에 기초한 순서통계량을 $X_{(1)} < \cdots < X_{(n)}$이라고 하면 $h(y) = F^{-1}(1 - e^{-y}) I_{(0,+\infty)}(y)$로 정의된 함수 h에 대하여

$$(X_{(r)})_{1 \le r \le n} \overset{d}{\equiv} \left(h\left(\frac{1}{n} Z_1 + \cdots + \frac{1}{n-r+1} Z_r \right) \right)_{1 \le r \le n}, \quad Z_r \overset{iid}{\sim} \mathrm{Exp}(1) \; (r = 1, \cdots, n)$$

[증명] 균등분포 $U(0,1)$에서의 랜덤표본 n개에 기초한 순서통계량을 $U_{(1)} < \cdots < U_{(n)}$이라고 하면 <정리 4.3.3>으로부터

$$(X_{(r)})_{1 \le r \le n} \overset{d}{\equiv} (F^{-1}(U_{(r)}))_{1 \le r \le n}$$

한편 지수분포 $\mathrm{Exp}(1)$에서의 랜덤표본 n개에 기초한 순서통계량을 $Y_{(1)} < \cdots < Y_{(n)}$이라고 하면 <예 4.3.4>로부터

$$(U_{(r)})_{1 \le r \le n} \overset{d}{\equiv} (1 - e^{-Y_{(r)}})_{1 \le r \le n}$$

$$\therefore (X_{(r)})_{1 \le r \le n} \overset{d}{\equiv} (h(Y_{(r)}))_{1 \le r \le n}$$

또한 <예 4.3.3>으로부터

$$(Y_{(r)})_{1 \le r \le n} \overset{d}{\equiv} \left(\frac{1}{n} Z_1 + \cdots + \frac{1}{n-r+1} Z_r \right)_{1 \le r \le n}, \quad Z_r \overset{iid}{\sim} \mathrm{Exp}(1) \; (r = 1, \cdots, n)$$

따라서 정리에 주어진 대의적 정의를 얻게 된다.

4.4 다변량 정규분포

통계 조사에서는 조사 대상의 한 가지 특성보다는 서로 연관을 가지고 있는 여러 개의 특성을 동시에 관측하고 이들에 기초하여 추론을 하게 된다. 이러한 다차원 자료를 이용하는 경우에 추론을 위한 기본 모형으로서는 일차원 정규분포를 다차원으로 확장한 다변량 정규분포(多變量 正規分布, multivariate normal distribution) 모형이 흔히 이용된다.

정리 4.4.1

표준정규분포 $N(0,1)$을 따르고 서로 독립인 확률변수 $Z_1, Z_2, \cdots, Z_n$과 상수의 행렬과 벡터

$$A=(a_{ij})_{\substack{1\le i\le n\\ 1\le j\le n}},\ \mu=(\mu_1,\mu_2,\cdots,\mu_n)^t$$

에 대하여

$$\begin{cases} X_1 = a_{11}Z_1+\cdots+a_{1n}Z_n+\mu_1 \\ \qquad\vdots \\ X_n = a_{n1}Z_1+\cdots+a_{nn}Z_n+\mu_n \end{cases}$$

즉, $X=AZ+\mu$, $X=(X_1,\cdots,X_n)^t$, $Z=(Z_1,\cdots,Z_n)^t$

이라고 할 때, 다음이 성립한다.

(a) 행렬 A가 정칙행렬(正則行列, nonsingular matrix)이면 $X=AZ+\mu$의 확률밀도함수는

$$pdf_X(x)=(\det(2\pi\Sigma))^{-1/2}\exp\{-(x-\mu)^t\Sigma^{-1}(x-\mu)/2\},\ x\in R^n\ (\Sigma=AA^t)$$

(b) $X=AZ+\mu$의 적률생성함수는

$$mgf_X(t)=\exp\left(\mu^t t+\frac{1}{2}t^t\Sigma t\right),\ t\in R^n$$

[증명] <정리 3.6.1>로부터 $Z=(Z_1,Z_2,\cdots,Z_n)^t$의 확률밀도함수와 적률생성함수는 각각

$$pdf_Z(z)=(2\pi)^{-\frac{n}{2}}e^{-\frac{1}{2}(z_1^2+\cdots+z_n^2)}=(2\pi)^{-\frac{n}{2}}e^{-\frac{1}{2}z^tz},\ z\in R^n$$

$$mgf_Z(s)=e^{\frac{1}{2}(s_1^2+\cdots+s_n^2)}=e^{\frac{1}{2}s^ts},\ s\in R^n$$

(a) $X=u(Z)=AZ+\mu$라고 할 때 A가 정칙행렬이면 함수 u는 R^n에서 R^n으로의 일대일 함수로서 <정리 4.1.1>의 조건을 만족시키고, 그 역함수

$u^{-1}(x) = A^{-1}(x-\mu)$의 야코비안 행렬식은

$$J_{u^{-1}} = \det(A^{-1}) = (\det(A))^{-1}$$

로 주어진다. 따라서

$$pdf_X(x) = pdf_Z(u^{-1}(x))|J_{u^{-1}}(x)|$$
$$= (2\pi)^{-n/2}\exp\left\{-\frac{1}{2}(A^{-1}(x-\mu))^t A^{-1}(x-\mu)\right\}(\det(A))^{-1}$$

여기에서 $\Sigma = AA^t$라고 하면

$$\det(2\pi\Sigma) = (2\pi)^n(\det(A))^2$$

이므로

$$pdf_X(x) = (\det(2\pi\Sigma))^{-1/2}\exp\left\{-\frac{1}{2}(x-\mu)^t\Sigma^{-1}(x-\mu)\right\}$$

(b) $mgf_X(t) = \mathrm{E}[\exp\{t^t(AZ+\mu)\}] = mgf_Z(A^t t)\exp(t^t\mu)$

$$\therefore\ mgf_X(t) = \exp\left\{\mu^t t + \frac{1}{2}(A^t t)^t(A^t t)\right\} = \exp\left(\mu^t t + \frac{1}{2}t^t\Sigma t\right)$$

<정리 4.4.1>에서 구한 X의 분포를 다변량 정규분포라고 하며 기호로는 $X \sim N_n(\mu,\Sigma)$ 또는 변수의 개수를 생략하고 간략히 $X \sim N(\mu,\Sigma)$로 나타낸다. 특히 (a)의 경우와 같이 Σ가 역행렬을 갖는 정칙행렬인 경우에는 X의 분포를 정칙 다변량 정규분포(正則 多變量 正規分布, nonsingular multivariate normal distribution)라고 한다.

정리 4.4.2

(a) $X \sim N(\mu,\Sigma)$이면 $\mathrm{E}(X) = \mu$, $\mathrm{Var}(X) = \Sigma$

(b) 분산행렬 Σ에 대하여 $AA^t = \Sigma$, $A = A^t$인 행렬 A를 $\Sigma^{1/2}$이라고 하면[59]

$$X \sim N_n(\mu,\Sigma) \Leftrightarrow X \overset{d}{\equiv} \Sigma^{1/2}Z + \mu,\ Z \sim N_n(0,I)$$

[증명] (a) 2장 5절에서 밝혔듯이 다차원 확률변수의 평균벡터와 분산행렬은 누율생성함수를 편미분하여 구할 수 있다. 그런데 $N(\mu,\Sigma)$의 누율생성함수는

$$C(t) = \log mgf_X(t) = \mu^t t + \frac{1}{2}t^t\Sigma t$$

59) <정리 2.5.4>로부터 분산행렬 Σ는 음이 아닌 정부호의 행렬이고, 부록 II에서 이러한 행렬에 대하여 $\Sigma^{1/2}\Sigma^{1/2} = \Sigma$인 대칭행렬 $\Sigma^{1/2}$이 존재하는 것을 밝히고 있다.

따라서 이 누율생성함수를 편미분하여 평균벡터와 분산행렬을 구하면

$$\mathrm{E}(\mathrm{X}) = \dot{C}(0) = \mu \quad \mathrm{Var}(\mathrm{X}) = \ddot{C}(0) = \Sigma$$

(b) <정리 4.4.1>의 (b)에서와 같은 방법으로 $\Sigma^{1/2}\Sigma^{1/2} = \Sigma$인 대칭행렬 $\Sigma^{1/2}$에 대하여

$$mgf_{\Sigma^{1/2}\mathrm{Z}+\mu}(t) = \exp\left(\mu^t t + \frac{1}{2}t^t \Sigma t\right), \ t \in R^n$$

임을 밝힐 수 있으므로 $\mathrm{X} \sim \mathrm{N}_n(\mu, \Sigma)$이다.

다변량 정규분포의 정의:

$\mathrm{Z} \sim \mathrm{N}_n(0,\mathrm{I}) \Leftrightarrow \mathrm{Z} = (\mathrm{Z}_1, \cdots, \mathrm{Z}_n)^t, \quad \mathrm{Z}_i \overset{iid}{\sim} \mathrm{N}(0,1) \ (i = 1, \cdots, n)$

$\mathrm{X} \sim \mathrm{N}_n(\mu, \Sigma) \Leftrightarrow$ (1)[60] $\mathrm{X} \overset{d}{\equiv} AZ + \mu, \ \mathrm{Z} \sim \mathrm{N}(0,\mathrm{I}), \ AA^t = \Sigma$

$\Leftrightarrow$ (2) $\mathrm{X} \overset{d}{\equiv} \Sigma^{1/2}\mathrm{Z} + \mu, \ \mathrm{Z} \sim \mathrm{N}_n(0,\mathrm{I}), \ \Sigma^{1/2}\Sigma^{1/2} = \Sigma, \ \Sigma^{1/2} = (\Sigma^{1/2})^t$

$\Leftrightarrow$ (3) $mgf_{\mathrm{X}}(t) = \exp\left(\mu^t t + \frac{1}{2}t^t \Sigma t\right), \ t \in R^n$

$\Leftrightarrow$ (4) (분산행렬 Σ가 정칙행렬인 경우)

$$pdf_{\mathrm{X}}(x) = (\det(2\pi\Sigma))^{-1/2} \exp\left\{-\frac{1}{2}(x-\mu)^t \Sigma^{-1}(x-\mu)\right\}, \ x \in R^n$$

예 4.4.1 이변량 정규분포 $\mathrm{N}\left(\begin{pmatrix}\mu_1\\ \mu_2\end{pmatrix}, \begin{pmatrix}\sigma_1^2 & \rho\sigma_1\sigma_2\\ \rho\sigma_1\sigma_2 & \sigma_2^2\end{pmatrix}\right)$ 또는 $\mathrm{N}(\mu_1, \mu_2; \sigma_1^2, \sigma_2^2, \rho)$

분산행렬 Σ에 대하여 $\det(\Sigma) = \sigma_1^2\sigma_2^2(1-\rho^2)$이므로, $\sigma_1 > 0$, $\sigma_2 > 0$, $-1 < \rho < 1$이면

$$\Sigma^{-1} = \frac{1}{\sigma_1^2\sigma_2^2(1-\rho^2)}\begin{pmatrix}\sigma_2^2 & -\rho\sigma_1\sigma_2\\ -\rho\sigma_1\sigma_2 & \sigma_1^2\end{pmatrix}$$

따라서 $\sigma_1 > 0$, $\sigma_2 > 0$, $-1 < \rho < 1$이면 확률밀도함수가 다음과 같이 주어진다.

$$f(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} e^{-\frac{1}{2}Q}$$

$$Q = \frac{1}{1-\rho^2}\left\{\left(\frac{x_1-\mu_1}{\sigma_1}\right)^2 - 2\rho\left(\frac{x_1-\mu_1}{\sigma_1}\right)\left(\frac{x_2-\mu_2}{\sigma_2}\right) + \left(\frac{x_2-\mu_2}{\sigma_2}\right)^2\right\}$$

60) 정의 (1)에서 A가 $n \times n$ 정방행렬이어야만 하는 것은 아니며 $AA^t = \Sigma$인 $n \times m$ 행렬이어도 무방하다.

한편 $\sigma_1 > 0,\ \sigma_2 > 0,\ \rho = \pm 1$인 경우에는 분산행렬의 역행렬이 존재하지 않고 <정리 2.2.3>으로부터 다음과 같이 두 변수 사이에 선형 관계가 성립하는 것을 알 수 있다.

$$\rho = 1 \Leftrightarrow \mathrm{P}\left(\frac{\mathrm{X}_2 - \mu_2}{\sigma_2} = \frac{\mathrm{X}_1 - \mu_1}{\sigma_1}\right) = 1,\ \rho = -1 \Leftrightarrow \mathrm{P}\left(\frac{\mathrm{X}_2 - \mu_2}{\sigma_2} = -\frac{\mathrm{X}_1 - \mu_1}{\sigma_1}\right) = 1$$

정리 4.4.3 다변량 정규분포의 성질

(a) $\mathrm{X} \sim \mathrm{N}(\mu, \Sigma)$이면 상수의 행렬과 벡터 A와 b에 대하여

$$A\mathrm{X} + b \sim \mathrm{N}(\mathrm{A}\mu + \mathrm{b}, \mathrm{A}\Sigma\mathrm{A}^{\mathrm{t}})$$

(b) $\begin{pmatrix}\mathrm{X}_1 \\ \mathrm{X}_2\end{pmatrix} \sim \mathrm{N}\left(\begin{pmatrix}\mu_1 \\ \mu_2\end{pmatrix}, \begin{pmatrix}\Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22}\end{pmatrix}\right)$일 때, $\mathrm{Cov}(\mathrm{X}_1, \mathrm{X}_2) = \Sigma_{12} = 0$이면 X_1과 X_2는 서로 독립이다.

(c) $\mathrm{X} \sim \mathrm{N}(\mu, \Sigma)$이고 A, B가 상수의 행렬일 때, $\mathrm{Cov}(A\mathrm{X}, B\mathrm{X}) = A\Sigma B^t = 0$이면 $A\mathrm{X}$와 $B\mathrm{X}$는 서로 독립이다.

[증명] (a) 다변량 정규분포의 정의 (2)로부터

$$\mathrm{X} \overset{d}{\equiv} \Sigma^{1/2}\mathrm{Z} + \mu,\ \mathrm{Z} \sim \mathrm{N}(0, \mathrm{I}),\ \Sigma^{1/2}\Sigma^{1/2} = \Sigma,\ \Sigma^{1/2} = (\Sigma^{1/2})^t$$

$$\therefore\ A\mathrm{X} + b \overset{d}{\equiv} (A\Sigma^{1/2})\mathrm{Z} + (A\mu + b),\ \mathrm{Z} \sim \mathrm{N}(0, \mathrm{I}),\ (A\Sigma^{1/2})(A\Sigma^{1/2})^t = A\Sigma A^t$$

따라서 다변량 정규분포의 정의 (1)로부터

$$A\mathrm{X} + b \sim \mathrm{N}(A\mu + b, A\Sigma A^t)$$

(b) 다변량 정규분포의 정의 (3)으로부터 X_1과 X_2의 결합적률생성함수는

$$mgf_{\mathrm{X}_1, \mathrm{X}_2}(t_1, t_2) = \exp\left\{\begin{pmatrix}\mu_1 \\ \mu_2\end{pmatrix}^t \begin{pmatrix}t_1 \\ t_2\end{pmatrix} + \frac{1}{2}\begin{pmatrix}t_1 \\ t_2\end{pmatrix}^t \begin{pmatrix}\Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22}\end{pmatrix}\begin{pmatrix}t_1 \\ t_2\end{pmatrix}\right\}$$

여기에서 $\mathrm{Cov}(\mathrm{X}_1, \mathrm{X}_2) = \Sigma_{12} = 0$이면 $\Sigma_{21} = (\Sigma_{12})^t = 0$이므로 결합적률생성함수가

$$mgf_{\mathrm{X}_1, \mathrm{X}_2}(t_1, t_2) = \exp\left\{\mu_1^t t_1 + \frac{1}{2}t_1^t \Sigma_{11} t_1\right\}\exp\left\{\mu_2^t t_2 + \frac{1}{2}t_2^t \Sigma_{22} t_2\right\}$$

로서 t_1만의 함수와 t_2만의 함수의 곱으로 주어진다. 따라서 X_1과 X_2는 서로 독립이다.

(c) (a)로부터

$$\begin{pmatrix} AX \\ BX \end{pmatrix} = \begin{pmatrix} A \\ B \end{pmatrix} X \sim N\left(\begin{pmatrix} A\mu \\ B\mu \end{pmatrix}, \begin{pmatrix} A\Sigma A^t & A\Sigma B^t \\ B\Sigma A^t & B\Sigma B^t \end{pmatrix} \right)$$

따라서 (b)로부터 $\mathrm{Cov}(AX, BX) = A\Sigma B^t = 0$이면 AX와 BX는 서로 독립이다.

예 4.4.2 이변량 정규분포에서의 독립성

<정리 2.4.4>와 <예 2.4.3>으로부터 두 확률변수 X_1과 X_2가 서로 독립이면

$$\mathrm{Cov}(X_1, X_2) = 0$$

이지만 그 역이 항상 성립하는 것은 아니라는 것을 알고 있다. 그러나 이변량 정규분포를 따르는 $(X_1, X_2)^t$의 경우에는 $\mathrm{Cov}(X_1, X_2) = 0$이면 X_1과 X_2가 서로 독립이다.

정리 4.4.4 다변량 정규분포의 주변분포와 조건부분포

(a) (주변분포) $\begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \sim N\left(\begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix} \right)$이면

$$X_1 \sim N(\mu_1, \Sigma_{11})$$

(b) (조건부분포) $\begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \sim N\left(\begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix} \right)$이고 분산행렬이 정칙행렬이면

$$X_{2|X_1 = x_1} \sim N(\mu_2 + \Sigma_{21}\Sigma_{11}^{-1}(x_1 - \mu_1), \Sigma_{22} - \Sigma_{21}\Sigma_{11}^{-1}\Sigma_{12})$$

[증명] (a) $X_1 = (I, 0)\begin{pmatrix} X_1 \\ X_2 \end{pmatrix}$이므로, <정리 4.4.3>의 (a)로부터

$$X_1 \sim N\left((I,0)\begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, (I,0)\begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}\begin{pmatrix} I \\ 0 \end{pmatrix} \right), \quad \therefore X_1 \sim N(\mu_1, \Sigma_{11})$$

(b) 이 경우의 분산행렬과 같이 부분행렬로 분할되어 있는 정칙행렬에 대하여

$$\det\left[\begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix} \right] = \det(\Sigma_{11})\det(\Sigma_{22} - \Sigma_{21}\Sigma_{11}^{-1}\Sigma_{12})$$

이고 $\Sigma_{22 \cdot 1} = \Sigma_{22} - \Sigma_{21}\Sigma_{11}^{-1}\Sigma_{12}$ 라고 하면

$$\begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}^{-1} = \begin{pmatrix} \Sigma_{11}^{-1} + \Sigma_{11}^{-1}\Sigma_{12}\Sigma_{22 \cdot 1}^{-1}\Sigma_{21}\Sigma_{11}^{-1} & -\Sigma_{11}^{-1}\Sigma_{12}\Sigma_{22 \cdot 1}^{-1} \\ -\Sigma_{22 \cdot 1}^{-1}\Sigma_{21}\Sigma_{11}^{-1} & \Sigma_{22 \cdot 1}^{-1} \end{pmatrix}$$

임이 알려져 있다.[61] 이 사실을 이용하여 조건부분포의 확률밀도함수

61) 부분행렬로 분할된 행렬에 관한 이러한 사실은 부록 II에 증명되어 있다.

$$pdf_{X_2|X_1=x_1}(x_2|x_1) = pdf_{X_1,X_2}(x_1,x_2)/pdf_{X_1}(x_1)$$

를 계산하여 (b)를 밝힐 수 있다. 또는 (b)와

$$X_2 - \mu_2 - \Sigma_{21}\Sigma_{11}^{-1}(X_1-\mu_1)_{|X_1=x_1} \sim N(0, \Sigma_{22}-\Sigma_{21}\Sigma_{11}^{-1}\Sigma_{12})$$

가 동등한 것을 이용하여 다음과 같이 (b)를 밝힐 수도 있다.

$$\begin{pmatrix} X_1-\mu_1 \\ X_2-\mu_2-\Sigma_{21}\Sigma_{11}^{-1}(X_1-\mu_1)\end{pmatrix} = \begin{pmatrix} I & 0 \\ -\Sigma_{21}\Sigma_{11}^{-1} & I\end{pmatrix}\begin{pmatrix} X_1-\mu_1 \\ X_2-\mu_2\end{pmatrix}$$

$$\begin{pmatrix} I & 0 \\ -\Sigma_{21}\Sigma_{11}^{-1} & I\end{pmatrix}\begin{pmatrix}\Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22}\end{pmatrix}\begin{pmatrix} I & 0 \\ -\Sigma_{21}\Sigma_{11}^{-1} & I\end{pmatrix}^t = \begin{pmatrix}\Sigma_{11} & 0 \\ 0 & \Sigma_{22}-\Sigma_{21}\Sigma_{11}^{-1}\Sigma_{12}\end{pmatrix}$$

따라서 <정리 4.4.3>의 (a)로부터

$$\begin{pmatrix} X_1-\mu_1 \\ X_2-\mu_2-\Sigma_{21}\Sigma_{11}^{-1}(X_1-\mu_1)\end{pmatrix} \sim N\left(\begin{pmatrix}0\\0\end{pmatrix}, \begin{pmatrix}\Sigma_{11} & 0 \\ 0 & \Sigma_{22}-\Sigma_{21}\Sigma_{11}^{-1}\Sigma_{12}\end{pmatrix}\right)$$

그러므로 <정리 4.4.3>의 (b)로부터 $X_1-\mu_1$과 $X_2-\mu_2-\Sigma_{21}\Sigma_{11}^{-1}(X_1-\mu_1)$은 서로 독립이고

$$X_2-\mu_2-\Sigma_{21}\Sigma_{11}^{-1}(X_1-\mu_1) \sim N(0, \Sigma_{22}-\Sigma_{21}\Sigma_{11}^{-1}\Sigma_{12})$$

이다. 따라서 (b)의 조건부분포가 성립한다.

예 4.4.3 이변량 정규분포 $N(\mu_1,\mu_2;\sigma_1^2,\sigma_2^2,\rho)$에서의 조건부분포

$$X_{2|X_1=x_1} \sim N(\mu_2+\rho\sigma_2(x_1-\mu_1)/\sigma_1, \sigma_2^2(1-\rho^2))$$

정리 4.4.5 이차형식의 분포

(a) $X \sim N_k(\mu,\Sigma)$이고 분산행렬 Σ가 정칙행렬이면

$$(X-\mu)^t\Sigma^{-1}(X-\mu) \sim \chi^2(k)$$

(b) $Z \sim N(0,I)$일 때, $A^2=A$이면 $Z^tAZ \sim \chi^2(r)$이고 자유도는 $r=trace(A)$이다.[62]

---

62) 일반적으로 $x^tAx = x^t\left(\frac{A+A^t}{2}\right)x$이므로 이차형식 Z^tAZ에서 행렬 A는 언제나 대칭행렬인 것으로 가정되어 있으며, (b)에서의 조건 $A^2=A$는 $Z^tAZ \sim \chi^2(r)$이기 위한 충분조건일 뿐만 아니라 필요조건인 것도 알려져 있다. 여기에서 $trace(A)$는 행렬 A의 모든 대각원소의 합이다.

[증명] (a) $\Sigma^{1/2}\Sigma^{1/2}=\Sigma$인 대칭행렬 $\Sigma^{1/2}$의 역행렬을 $\Sigma^{-1/2}$이라고 하면

$$\Sigma^{-1/2}\Sigma(\Sigma^{-1/2})^t=\Sigma^{-1/2}\Sigma^{1/2}\Sigma^{1/2}\Sigma^{-1/2}=\mathrm{I}$$

이므로 <정리 4.4.3>의 (a)로부터

$$\Sigma^{-1/2}(\mathrm{X}-\mu)\sim \mathrm{N}_k(0,\mathrm{I})$$

따라서 $Z=(Z_1,\cdots,Z_k)^t=\Sigma^{-1/2}(\mathrm{X}-\mu)$라고 하면

$$(\mathrm{X}-\mu)^t\Sigma^{-1}(\mathrm{X}-\mu)=Z^tZ=Z_1^2+\cdots+Z_k^2,\ Z_i\overset{iid}{\sim}\mathrm{N}(0,1)(i=1,\cdots,k)$$

그러므로 카이제곱분포의 대의적 정의로부터

$$(\mathrm{X}-\mu)^t\Sigma^{-1}(\mathrm{X}-\mu)\sim\chi^2(k)$$

(b) 행렬 A는 원소가 실수인 대칭행렬이므로 다음과 같이 대각화가 가능하다.[63]

$$A=P^t\begin{bmatrix}\lambda_1 & 0 & \cdots & 0\\ 0 & \lambda_2 & \cdots & 0\\ \vdots & \vdots & \ddots & \vdots\\ 0 & 0 & \cdots & \lambda_n\end{bmatrix}P,\ P^tP=PP^t=\mathrm{I}$$

여기에서 $\lambda_1,\ \cdots,\ \lambda_n$은 $\det(A-\lambda\mathrm{I})=0$을 만족하는 λ 값들로서, $A^2=A$인 경우에는 $\lambda_i^2=\lambda_i$이어야 하므로 λ_i는 0 또는 1임을 알 수 있다. 이들 중 r개만 1이고 나머지는 0이라고 하면 $\lambda_1=\cdots=\lambda_r=1,\ \lambda_{r+1}=\cdots=\lambda_n=0$이라고 가정할 수 있다. 따라서 $r\times r$인 단위행렬을 I_r이라고 하면

$$Z^tAZ=(PZ)^t\begin{bmatrix}\mathrm{I}_r & 0\\ 0 & 0\end{bmatrix}(PZ)$$

그러므로 $\mathrm{X}=(\mathrm{X}_1,\cdots,\mathrm{X}_n)^t=PZ$라고 하면

$$Z^tAZ=\mathrm{X}^t\begin{bmatrix}\mathrm{I}_r & 0\\ 0 & 0\end{bmatrix}\mathrm{X}=\mathrm{X}_1^2+\cdots+\mathrm{X}_r^2,\ \mathrm{X}\sim\mathrm{N}_n(0,PP^t)=\mathrm{N}_n(0,\mathrm{I})$$

$$\therefore\ Z^tAZ=\mathrm{X}_1^2+\cdots+\mathrm{X}_r^2,\ \mathrm{X}_i\overset{iid}{\sim}\mathrm{N}(0,1)(i=1,\cdots,r)$$

그러므로 카이제곱분포의 대의적 정의로부터

$$Z^tAZ\sim\chi^2(r)$$

---

63) 원소가 실수인 대칭행렬의 대각화에 대한 정리는 부록 Ⅱ에 주어져 있으며, $\det(A-\lambda\mathrm{I})=0$을 만족하는 λ 값은 행렬 A의 고유값(固有값, eigen value)이라고 한다.

예 4.4.4 일원분류모형에서의 표본분포

<정리 4.2.7>의 (a)에서는 일원분류모형에서 정규분포 $\mathrm{N}(\mu_i, \sigma^2/n_i)$를 따르고 서로 독립인 표본평균 $\overline{\mathrm{X}}_i (i=1,\cdots,k)$에 관한 다음의 표본분포를 소개하고 있다.

$$\sum_{i=1}^{k} n_i(\overline{\mathrm{X}}_i - \overline{\mathrm{X}} - (\mu_i - \overline{\mu}))^2/\sigma^2 \sim \chi^2(k-1)$$

이제 <정리 4.4.5>를 이용하여 이 결과를 밝히기 위하여

$$\mathrm{Y}_i = \overline{\mathrm{X}}_i - \overline{\mathrm{X}} - (\mu_i - \overline{\mu}) \ (i=1,\cdots,k), \ \mathrm{Y} = (\mathrm{Y}_1,\cdots,\mathrm{Y}_r)^t, \ r = k-1$$

라고 하면,

$$\overline{\mathrm{X}} = \sum_{i=1}^{k} n_i \overline{\mathrm{X}}_i/n, \ \overline{\mu} = \sum_{i=1}^{k} n_i\mu_i/n, \ n = n_1 + \cdots + n_k$$

로부터 Y_i들의 평균, 분산, 공분산을 다음과 같이 구할 수 있다.

$$\mathrm{E}(\mathrm{Y}_i) = 0, \ \mathrm{Var}(\mathrm{Y}_i) = (n_i^{-1} - n^{-1})\sigma^2$$
$$\mathrm{Cov}(\mathrm{Y}_i, \mathrm{Y}_j) = -n^{-1}\sigma^2 \ (i,j=1,\cdots,k)(i \neq j)$$

따라서

$$\mathrm{Y} = (\mathrm{Y}_1,\cdots,\mathrm{Y}_r)^t \sim \mathrm{N}_r(0, \Sigma), \ \Sigma = [D(n_i^{-1}) - n^{-1}11^t]\sigma^2$$

$$D(n_i^{-1}) = \begin{bmatrix} n_1^{-1} & 0 & \cdots & 0 \\ 0 & n_2^{-1} & \cdots & 0 \\ \vdots & \vdots & \ddots & 0 \\ 0 & 0 & \cdots & n_r^{-1} \end{bmatrix}, \ 1 = (1,\cdots,1)^t$$

한편 부록 II의 특수한 형태의 행렬에 관한 연산[64]으로부터

$$[D(n_i^{-1}) - n^{-1}11^t]^{-1} = [\mathrm{I} - n^{-1}D^{-1}(n_i^{-1})11^t]^{-1}D^{-1}(n_i^{-1})$$
$$= D(n_i) + n_k^{-1}(n_1,\cdots,n_r)^t(n_1,\cdots,n_r)$$

$$D(n_i) = \begin{bmatrix} n_1 & 0 & \cdots & 0 \\ 0 & n_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & 0 \\ 0 & 0 & \cdots & n_r \end{bmatrix}$$

$$\therefore \ \mathrm{Y}^t\Sigma^{-1}\mathrm{Y} = \sum_{i=1}^{r} n_i\mathrm{Y}_i^2/\sigma^2 + n_k^{-1}\left(\sum_{i=1}^{r} n_i\mathrm{Y}_i\right)^2/\sigma^2 = \sum_{i=1}^{k} n_i\mathrm{Y}_i^2/\sigma^2$$

또한 <정리 4.4.5>의 (a)로부터 $\mathrm{Y}^t\Sigma^{-1}\mathrm{Y} \sim \chi^2(r)$이므로

$$\sum_{i=1}^{k} n_i(\overline{\mathrm{X}}_i - \overline{\mathrm{X}} - (\mu_i - \overline{\mu}))^2/\sigma^2 \sim \chi^2(k-1)$$

---

64) 벡터 a, b에 대하여 $1 + b^t a \neq 0$이면

$$(\mathrm{I} + ab^t)^{-1} = \mathrm{I} + cab^t, \ c = -1/(1 + b^t a)$$

예 4.4.5 표본분산의 표본분포

정규분포 $N(\mu,\sigma^2)$에서의 랜덤표본을 $X_1, X_2, \cdots, X_n$이라고 할 때, 표본평균 $\overline{X}$와 표본분산 $S^2=\sum_{i=1}^{n}(X_i-\overline{X})^2/(n-1)$은 서로 독립이고 $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$인 것을 <정리 4.2.2>로부터 이미 알고 있다. 이제 다변량 정규분포에 관한 정리들을 이용하여 이를 밝히는 방법을 알아보자. 이를 위하여 $X=(X_1,\cdots,X_n)^t$라고 하면

$$X \sim N_n(\mu 1, \sigma^2 I),\ 1=(1,\cdots,1)^t$$

$$\overline{X}=n^{-1}1^tX,\ (n-1)S^2=\sum_{i=1}^{n}(X_i-\overline{X})^2=X^t(I-n^{-1}11^t)X$$

한편 $I-n^{-1}11^t$은 대칭행렬이고 $1^t(I-n^{-1}11^t)=0$이므로

$$Cov(1^tX,(I-n^{-1}11^t)X)=1^t(\sigma^2 I)(I-n^{-1}11^t)^t=0$$

따라서 <정리 4.4.3>의 (c)로부터 $\overline{X}=n^{-1}1^tX$와 $(I-n^{-1}11^t)X$은 서로 독립이다. 그런데

$$(I-n^{-1}11^t)^2=I-n^{-1}11^t$$

이므로

$$X^t(I-n^{-1}11^t)X=[(I-n^{-1}11^t)X]^t[(I-n^{-1}11^t)X]$$

그러므로 $\overline{X}$와 $(n-1)S^2=X^t(I-n^{-1}11^t)X$은 서로 독립이다. 또한

$$X^t(I-n^{-1}11^t)X/\sigma^2=(X-\mu 1)^t(I-n^{-1}11^t)(X-\mu 1)/\sigma^2$$

이고

$$(X-\mu 1)/\sigma \sim N_n(0,I),\ (I-n^{-1}11^t)^2=I-n^{-1}11^t,\ trace(I-n^{-1}11^t)=n-1$$

이므로 <정리 4.4.5>의 (b)로부터

$$(n-1)S^2/\sigma^2=X^t(I-n^{-1}11^t)X/\sigma^2 \sim \chi^2(n-1)$$

통계 조사에서 변수 사이의 함수관계를 파악하고자 하는 경우가 많이 있다. 이러한 함수관계 조사를 목적으로 가장 기본적으로 사용되는 모형이 다음의 선형회귀모형(線型回歸模型, linear regression model)이다. 이는 설명변수(說明變數, explanatory variable) $x_0, x_1, \cdots, x_p$와 오차항 e에 의해 반응변수(反應變數, response variable) Y가 정해진다는 전제 하에 그 관계가 선형이라고 가정하고 반복 관측된 Y 값을 이용하여 선형관계의 구체적 형태를 추측하고자 하는 것이다.

선형회귀모형(정규 오차항을 갖는 경우):

$$\begin{cases} Y_i = x_{i0}\beta_0 + x_{i1}\beta_1 + \cdots + x_{ip}\beta_p + e_i \\ e_i \overset{iid}{\sim} N(0,\sigma^2),\ i = 1,\cdots,n \end{cases}$$

이러한 선형회귀모형을 벡터와 행렬을 사용하여 나타내기 위하여

$$Y = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix},\ X = \begin{pmatrix} x_{10} & x_{11} & \cdots & x_{1p} \\ \vdots & \vdots & & \vdots \\ x_{n0} & x_{n1} & \cdots & x_{np} \end{pmatrix},\ \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix},\ e = \begin{pmatrix} e_1 \\ \vdots \\ e_n \end{pmatrix}$$

라고 하면 위의 모형을 다음과 같이 간략하게 나타낼 수 있다.

$$\begin{cases} Y = X\beta + e \\ e \sim N_n(0,\sigma^2 I) \end{cases}$$

여기에서 설명변수의 행렬 X는 주어진 상수의 행렬로서 $n\times(p+1)$의 계수(計數, rank)[65]가 $(p+1)$인 것으로 가정하고, 선형관계의 구체적 형태를 나타내는 $\beta = (\beta_0, \beta_1, \cdots, \beta_p)^t$를 회귀계수(回歸係數, regression coefficient)라고 하며, 이의 추측 값으로는 흔히

$$\hat{\beta} = (X^tX)^{-1}X^tY$$

로 정의되는 표본회귀계수(標本回歸係數, sample regression coefficient)를 사용한다.

예 4.4.6 단순선형회귀모형에서 표본회귀계수

선형회귀모형에서 $p = 1$이고 $x_0 = 1$인 경우, 즉

$$\begin{cases} Y_i = \beta_0 + x_{i1}\beta_1 + e_i \\ e_i \overset{iid}{\sim} N(0,\sigma^2),\ i = 1,\cdots,n \end{cases}$$

로 나타내어지는 모형을 단순(單純, simple)선형회귀모형이라고 한다. 이 경우에는

$$X = \begin{pmatrix} 1 & x_{11} \\ \vdots & \vdots \\ 1 & x_{n1} \end{pmatrix},\ X^tX = \begin{pmatrix} n & \sum_{i=1}^n x_{i1} \\ \sum_{i=1}^n x_{i1} & \sum_{i=1}^n x_{i1}^2 \end{pmatrix},\ X^tY = \begin{pmatrix} \sum_{i=1}^n Y_i \\ \sum_{i=1}^n x_{i1}Y_i \end{pmatrix}$$

$$(X^tX)^{-1} = \frac{1}{n\sum_{i=1}^n x_{i1}^2 - \left(\sum_{i=1}^n x_{i1}\right)^2} \begin{pmatrix} \sum_{i=1}^n x_{i1}^2 & -\sum_{i=1}^n x_{i1} \\ -\sum_{i=1}^n x_{i1} & n \end{pmatrix}$$

65) 행렬의 계수에 대한 정의와 설명은 부록 II에 주어져 있다.

이므로 표본회귀계수 $\hat{\beta} = (\hat{\beta_0}, \hat{\beta_1})^t$는 다음과 같이 주어진다.

$$\hat{\beta_1} = \frac{S_{xY}}{S_{xx}},\ S_{xY} = \sum_{i=1}^{n}(x_{i1} - \overline{x_1})Y_i,\ S_{xx} = \sum_{i=1}^{n}(x_{i1} - \overline{x_1})^2,\ \overline{x_1} = \sum_{i=1}^{n} x_{i1}/n$$

$$\hat{\beta_0} = \overline{Y} - \overline{x_1}\hat{\beta_1},\ \text{즉}\ \hat{\beta_0} + x_{i1}\hat{\beta_1} = \overline{Y} + (x_{i1} - \overline{x_1})\hat{\beta_1}$$

선형회귀모형에서 오차항의 분산 σ^2의 추측값으로는 흔히

$$\hat{\sigma^2} = (Y - X\hat{\beta})^t(Y - X\hat{\beta})/(n-p-1)$$
$$= \sum_{i=1}^{n}(Y_i - \hat{\beta_0}x_{i0} - \hat{\beta_1}x_{i1} - \cdots - \hat{\beta_p}x_{ip})^2/(n-p-1)$$

로 정의되는 평균오차제곱합(平均誤差제곱합, mean squared error sum of squares)을 사용한다.

예 4.4.7 단순선형회귀모형에서 평균오차제곱합

<예 4.4.6>의 단순선형회귀모형에서 평균오차제곱합은

$$\hat{\sigma^2} = \sum_{i=1}^{n}(Y_i - \hat{\beta_0} - \hat{\beta_1}x_{i1})^2/(n-2) = \sum_{i=1}^{n}(Y_i - \overline{Y} - \hat{\beta_1}(x_{i1} - \overline{x_1}))^2/(n-2)$$

정리 4.4.6 선형회귀모형에서 표본분포에 관한 기본 정리

선형회귀모형

$$\begin{cases} Y = X\beta + e \\ e \sim N_n(0, \sigma^2 I) \end{cases}$$

에서 주어진 상수의 행렬 X는 $n \times (p+1)$ 행렬로서 계수가 $(p+1)$인 것으로 가정할 때 다음이 성립한다.

(a) $\hat{\beta} \sim N_{p+1}(\beta, \sigma^2(X^tX)^{-1})$

(b) 표본회귀계수 $\hat{\beta}$와 평균오차제곱합 $\hat{\sigma^2}$은 서로 독립이다.

(c) $(n-p-1)\hat{\sigma^2}/\sigma^2 \sim \chi^2(n-p-1)$

[증명] (a) $Y \sim N(X\beta, \sigma^2 I)$이므로 <정리 4.4.3>의 (a)로부터

$$\hat{\beta} = (X^tX)^{-1}X^tY \sim N((X^tX)^{-1}X^tX\beta, \sigma^2[(X^tX)^{-1}X^t][(X^tX)^{-1}X^t]^t)$$
$$\therefore\ \hat{\beta} \sim N(\beta, \sigma^2((XX)^{-1}))$$

(b) $\Pi = X(X^tX)^{-1}X^t$라고 하면 Π는 대칭행렬로서

$\Pi^2 = X(X^tX)^{-1}X^tX(X^tX)^{-1}X^t = \Pi,\ \Pi X = X(X^tX)^{-1}X^tX = X$

인 것을 알 수 있다. 한편

$$\mathrm{Y} - X\hat{\beta} = \mathrm{Y} - \Pi\mathrm{Y} = (\mathrm{I} - \Pi)\mathrm{Y}$$

$$\therefore\ \mathrm{Cov}((X^tX)^{-1}X^t\mathrm{Y},\ (\mathrm{I}-\Pi)\mathrm{Y}) = (X^tX)^{-1}X^t(\sigma^2\mathrm{I})(\mathrm{I}-\Pi)^t = 0$$

따라서 <정리 4.4.3>의 (c)로부터 $\hat{\beta} = (X^tX)^{-1}X^t\mathrm{Y}$ 와 $\mathrm{Y} - X\hat{\beta} = (\mathrm{I}-\Pi)\mathrm{Y}$는 서로 독립이고, 이로부터 $\hat{\beta}$와 $\widehat{\sigma^2} = (\mathrm{Y}-X\hat{\beta})^t(\mathrm{Y}-X\hat{\beta})/(n-p-1)$이 서로 독립임을 알 수 있다.

(c) (b)에서의 행렬 Π에 대하여

$$(\mathrm{I}-\Pi)^2 = \mathrm{I}-\Pi,\ (\mathrm{I}-\Pi)X = 0$$

이므로

$$\begin{aligned}(\mathrm{Y}-X\hat{\beta})^t(\mathrm{Y}-X\hat{\beta}) &= \mathrm{Y}^t(\mathrm{I}-\Pi)^t(\mathrm{I}-\Pi)\mathrm{Y}\\ &= (\mathrm{Y}-X\beta)^t(\mathrm{I}-\Pi)(\mathrm{Y}-X\beta)\end{aligned}$$

$$\therefore\ (n-p-1)\widehat{\sigma^2}/\sigma^2 = (\mathrm{Y}-X\hat{\beta})^t(\mathrm{Y}-X\hat{\beta})/\sigma^2 = (\mathrm{Y}-X\beta)^t(\mathrm{I}-\Pi)(\mathrm{Y}-X\beta)/\sigma^2$$

여기에서

$(\mathrm{Y}-X\beta)/\sigma \sim \mathrm{N}_n(0,\mathrm{I}),\ (\mathrm{I}-\Pi)^2 = (\mathrm{I}-\Pi),\ trace(\mathrm{I}-\Pi) = n-p-1$[66]

이므로 <정리 4.4.5>의 (b)로부터

$$(n-p-1)\widehat{\sigma^2}/\sigma^2 = (\mathrm{Y}-X\beta)^t(\mathrm{I}-\Pi)(\mathrm{Y}-X\beta)/\sigma^2 \sim \chi^2(n-p-1)$$

예 4.4.8 단순선형회귀모형에서의 표본분포

<예 4.4.6>, <예 4.4.7>과 <정리 4.4.6>으로부터 단순선형회귀모형에서는

$$\hat{\beta} = \begin{pmatrix}\hat{\beta}_0\\ \hat{\beta}_1\end{pmatrix} \sim \mathrm{N}\left(\begin{pmatrix}\beta_0\\ \beta_1\end{pmatrix}, \frac{\sigma^2}{\mathrm{S}_{xx}}\begin{pmatrix}\sum_{i=1}^{n}x_{i1}^2/n & -\overline{x_1}\\ -\overline{x_1} & 1\end{pmatrix}\right)$$

$$(n-2)\widehat{\sigma^2}/\sigma^2 = \sum_{i=1}^{n}(\mathrm{Y}_i - \overline{\mathrm{Y}} - \hat{\beta}_1(x_{i1}-\overline{x_1}))^2/\sigma^2 \sim \chi^2(n-2)$$

이고 $\hat{\beta}$과 $\widehat{\sigma^2}$이 독립이다. 따라서 t 분포의 대의적 정의로부터

---

66) 행렬의 덧셈과 곱셈의 정의로부터 대각합에 대한 다음 성질이 성립하는 것은 명백하다.

$trace(A+B) = trace(A) + trace(B),\ trace(AB) = trace(BA)$

$\therefore\ trace(\mathrm{I}_{n\times n} - X(X^tX)^{-1}X) = n - trace((X^tX)^{-1}X^tX) = n-p-1$

$$\frac{\hat{\beta}_1-\beta_1}{\sqrt{\hat{\sigma}^2/S_{xx}}}=\frac{(\hat{\beta}_1-\beta_1)/\sqrt{\sigma^2/S_{xx}}}{\sqrt{(n-2)(\hat{\sigma}^2/\sigma^2)/(n-2)}}\sim t(n-2)$$

이 경우에 평균오차제곱합은 다음의 공식을 이용하여 계산할 수 있다.

$$\hat{\sigma}^2=\sum_{i=1}^{n}(Y_i-\overline{Y}-\hat{\beta}_1(x_{i1}-\overline{x_1}))^2/(n-2)=\{S_{YY}-(S_{xY})^2/S_{xx}\}/(n-2)$$

$$S_{YY}=\sum_{i=1}^{n}(Y_i-\overline{Y})^2$$

다변량 정규분포의 성질 :

(1) $N(\mu,\Sigma)\overset{d}{\equiv}\Sigma^{1/2}N(0,I)+\mu$

(2) $AN(\mu,\Sigma)+b\overset{d}{\equiv}N(A\mu+b,A\Sigma A^t)$

(3) $N(\mu_1,\Sigma_1)\oplus N(\mu_2,\Sigma_2)\overset{d}{\equiv}N(\mu_1+\mu_2,\Sigma_1+\Sigma_2)$

(4) $X\sim N(\mu,\Sigma)$일 때,

$$AX\perp BX\Leftrightarrow Cov(AX,BX)=A\Sigma B^t=0$$

(5) $\begin{pmatrix}X_1\\X_2\end{pmatrix}\sim N\left(\begin{pmatrix}\mu_1\\\mu_2\end{pmatrix},\begin{pmatrix}\Sigma_{11}&\Sigma_{12}\\\Sigma_{21}&\Sigma_{22}\end{pmatrix}\right)$

$\Leftrightarrow$ (a) $X_1\sim N(\mu_1,\Sigma_{11})$ and

(b) $X_{2|X_1=x_1}\sim N(\mu_2+\Sigma_{21}\Sigma_{11}^{-1}(x_1-\mu_1),\Sigma_{22}-\Sigma_{21}\Sigma_{11}^{-1}\Sigma_{12})$

(6) $N(0,I)^tAN(0,I)\sim\chi^2(r)\Leftrightarrow A^2=A,\ r=trace(A)$

연습문제

4.11 균등분포 $U(-\pi/2, \pi/2)$를 따르는 확률변수 X에 대하여 $Y = \tan X$의 확률밀도함수를 구하여라.

4.2 확률변수 X_1, X_2의 결합확률밀도함수가

$$f(x_1, x_2) = 2e^{-x_1 - x_2} I_{(0 < x_1 < x_2)}$$

일 때 $Y_1 = X_1, Y_2 = X_2 - X_1$의 결합확률밀도함수를 구하고, Y_1과 Y_2가 서로 독립인가를 판단하여라.

4.3 확률변수 X_1, X_2의 결합확률밀도함수가

$$f(x_1, x_2) = 8x_1 x_2 I_{(0 < x_1 < x_2 < 1)}$$

일 때 $Y_1 = X_1/X_2, Y_2 = X_2$의 결합확률밀도함수를 구하고, Y_1과 Y_2가 서로 독립인가를 판단하여라.

4.4 확률변수 X_1, X_2, X_3의 결합확률밀도함수가

$$f(x_1, x_2, x_3) = 6e^{-x_1 - x_2 - x_3} I_{(0 \le x_1 \le x_2 \le x_3)}$$

일 때 $Y_1 = X_1, Y_2 = X_2 - X_1, Y_3 = X_3 - X_2$의 결합확률밀도함수를 구하고, Y_1, Y_2, Y_3가 서로 독립인가를 판단하여라.

4.5 확률변수 X_1, X_2, X_3가 서로 독립이고 각각의 주변확률밀도함수가

$$f(x) = e^{-x} I_{(0, \infty)}(x)$$

일 때 다음에 답하여라.

(a) $Y_1 = X_1, Y_2 = X_1 + X_2, Y_3 = X_1 + X_2 + X_3$의 결합확률밀도함수를 구하여라.

(b) Y_1, Y_3의 결합확률밀도함수를 구하여라.

4.6 확률변수 X_1, X_2 의 결합확률밀도함수가

$$f_{1,2}(x_1,x_2) = 2e^{-x_1-x_2} I_{(0<x_1<x_2<\infty)}$$

이고, $Y_1 = X_1/X_2$, $Y_2 = X_2$라고 할 때 다음에 답하여라.

(a) Y_1의 확률밀도함수를 구하여라.

(b) $E(Y_2|Y_1)$와 $Var(Y_2|Y_1)$을 구하여라.

4.7 확률변수 X_1, X_2의 결합확률밀도함수가

$$f(x_1,x_2) = 2e^{-x_1-x_2} I_{(0<x_1<x_2)}$$

일 때 $Y = X_1 + X_2$의 확률밀도함수를 구하여라.

4.8 확률변수 X의 확률밀도함수가 다음과 같은 경우에 $Y = X^2$의 확률밀도함수를 구하여라.

(a) $f(x) = \frac{1}{4} I_{(-2,2)}(x)$ (b) $f(x) = \frac{1}{4} I_{(-1,3)}(x)$

4.9 확률변수 X_1, X_2의 결합확률밀도함수가

$$f(x_1,x_2) = \frac{1}{\pi} I_{(x_1^2+x_2^2<1)}$$

일 때 다음에 답하여라.

(a) 극좌표 형식인 $X_1 = R\cos\Theta$, $X_2 = R\sin\Theta$, $R \geq 0$, $0 \leq \Theta < 2\pi$로 정의되는 R, Θ의 결합확률밀도함수를 구하여라.

(b) $Y_1 = \sqrt{X_1^2+X_2^2}$, $Y_2 = \dfrac{X_1}{\sqrt{X_1^2+X_2^2}}$ 일 때 Y_1, Y_2의 결합확률밀도함수를 구하여라.

4.10 발생률이 λ인 포아송과정 $\{N_t : t \geq 0\}$에서 r번째 현상이 발생할 때까지의 시간을

$$W_r = \min\{t : N_t \geq r\} \ (r = 1,2,\cdots)$$

이라고 할 때 다음에 답하여라.

(a) $(Y_1, Y_2, \cdots, Y_k)'$

$= (W_1/W_{k+1}, (W_2 - W_1)/W_{k+1}, \cdots, (W_k - W_{k-1})/W_{k+1})'$의 결합확률밀도함수를 구하여라.

(b) $(X, Y)' = (W_2/W_5, W_4/W_5)'$의 결합확률밀도함수를 구하여라.

4.11 확률변수 X가 $F(r_1, r_2)$ 분포를 따를 때

$$Y = \frac{(r_1/r_2)X}{1 + (r_1/r_2)X}$$

는 $Beta(r_1/2, r_2/2)$ 분포를 따르는 것을 밝혀라.

4.12 확률변수 $X_1, X_2, \cdots, X_n$이 서로 독립이고 동일한 주변확률밀도함수

$$f(x) = 3x^2 I_{(0,1)}(x)$$

를 따를 때 다음에 답하여라.

(a) $Y = \min_{1 \le i \le n} X_i$ 의 누적분포함수를 구하고, 그 도함수로서 확률밀도함수를 구하여라.

(b) $Y = \max_{1 \le i \le n} X_i$ 의 누적분포함수를 구하고, 그 도함수로서 확률밀도함수를 구하여라.

4.13 확률밀도함수

$$f(x) = 2x I_{(0,1)}(x)$$

를 따르는 세 확률변수에 기초한 순서통계량을 $X_{(1)} < X_{(2)} < X_{(3)}$이라고 할 때 다음에 답하여라.

(a) $Y_1 = X_{(1)}/X_{(2)}$, $Y_2 = X_{(2)}/X_{(3)}$, $Y_3 = X_{(3)}$가 서로 독립임을 밝혀라.

(b) 조건부기댓값 $E(X_{(2)}|X_{(3)})$을 구하여라.

4.14 $U_{(1)} < U_{(2)} < \cdots < U_{(n)}$이 균등분포 $U(0,1)$로부터의 랜덤표본 $U_1, U_2, \cdots, U_n$에 기초한 순서통계량일 때 다음에 답하여라.

(a) $Y_1 = U_{(1)}/U_{(2)}, \cdots, Y_{n-1} = U_{(n-1)}/U_{(n)}$의 결합확률밀도함수를 구하여라.

(b) $Y_r (1 \le r \le n-1)$의 주변확률밀도함수를 구하여라.

4.15 $U_{(1)} < U_{(2)} < \cdots < U_{(n)}$이 균등분포 $U(0,1)$로부터의 랜덤표본 U_1, U_2, …, U_n에 기초한 순서통계량일 때

$$(U_{(r)} > p) = \left(\sum_{i=1}^{n} I_{(0,p]}(U_i) \le r-1 \right)$$

임을 설명하고, 이를 이용하여 다음 등식이 성립함을 밝혀라.

$$\int_p^1 \frac{n!}{(r-1)!(n-r)!} u^{r-1}(1-u)^{n-r} du = \sum_{k=0}^{r-1} \binom{n}{k} p^k (1-p)^{n-k}, \quad 0 < p < 1$$

4.16 $U_{(1)} < U_{(2)} < \cdots < U_{(n)} (n \ge 2)$이 균등분포 $U(0,1)$로부터의 랜덤표본 U_1, U_2, …, U_n에 기초한 순서통계량일 때, $Y = U_{(n)} - U_{(1)}$의 확률밀도함수를 구하여라.

4.17 $X_{(1)} < X_{(2)} < \cdots < X_{(n)} (n \ge 2)$이 지수분포 $Exp(1)$로부터의 랜덤표본 X_1, …, X_n에 기초한 순서통계량일 때, $Y = X_{(n)} - X_{(1)}$의 확률밀도함수를 구하여라.

4.18 균등분포 $U(0,1)$를 따르는 확률변수 U에 대하여

$$X = \beta(-\log(1-U))^{1/\alpha}, \quad \alpha > 0, \quad \beta > 0$$

라고 할 때 다음에 답하여라.

(a) X의 확률밀도함수가 다음과 같이 주어지는 것을 밝혀라.

$$f(x) = \frac{\alpha}{\beta^\alpha} x^{\alpha-1} \exp(-x^\alpha/\beta^\alpha) I_{(0,+\infty)}(x)$$

이 분포를 와이불(Weibull)분포라고 하며 기호로는 $X \sim Weibull(\alpha,\beta)$로 나타낸다.

(b) X의 확률밀도함수와 누적분포함수를 각각 $f(x)$, $F(x)$라고 할 때

$$\frac{f(x)}{1-F(x)} = \frac{\alpha}{\beta^\alpha} x^{\alpha-1}, \quad \alpha > 0$$

임을 밝혀라. 확률변수 X가 수명을 나타낼 때 이러한 함수는 수명이 x 인 순간에서의 사망률(mortality rate)을 나타내는 함수로서 흔히 위험률(危險率, hazard rate) 함수라고 불리운다.

4.19_ 균등분포 $U(0,1)$을 따르는 확률변수 U에 대하여

$$X = \log\left(\frac{U}{1-U}\right)$$

라고 할 때 X가 로지스틱분포 $L(0,1)$을 따르는 것을 밝혀라.

4.20 균등분포 $U(0,1)$을 따르는 확률변수 U에 대하여

$$X = \tan((U-1/2)\pi)$$

라고 할 때 X가 코쉬분포 $C(0,1)$을 따르는 것을 밝혀라.

4.21 $U_{(1)} < U_{(2)} < \cdots < U_{(n)}$이 균등분포 $U(0,1)$로부터의 랜덤표본 U_1, U_2, $\cdots$, U_n에 기초한 순서통계량일 때 다음을 밝혀라.

(a) $(U_{(r)})_{1 \le r \le n} \overset{d}{\equiv} (1-U_{(n-r+1)})_{1 \le r \le n}$,

$(-\log U_{(r)})_{1 \le r \le n} \overset{d}{\equiv} (-\log(1-U_{(n-r+1)}))_{1 \le r \le n}$

(b) $(-\log U_{(r)})_{1 \le r \le n} \overset{d}{\equiv} \left(\frac{1}{n}Z_1 + \cdots + \frac{1}{r}Z_{n-r+1}\right)_{1 \le r \le n}$, $Z_r \overset{iid}{\sim} \mathrm{Exp}(1)$

(c) $U_{(n+1)} = 1$이라고 할 때

$(-\log[U_{(r)}/U_{(r+1)}]^r)_{1 \le r \le n} \overset{d}{\equiv} (Z_{n-r+1})_{1 \le r \le n}$, $Z_r \overset{iid}{\sim} \mathrm{Exp}(1)$

(d) $U_{(n+1)} = 1$이라고 할 때 $(U_{(r)}/U_{(r+1)})^r \overset{iid}{\sim} U(0,1)$, $r = 1, \cdots, n$

4.22 함수

$$f(x,y) = \frac{1}{2\pi}\exp\left[-\frac{1}{2}(x^2+y^2)\right]\left\{1 + xy\exp\left[-\frac{1}{2}(x^2+y^2-2)\right]\right\}$$

가 확률밀도함수임을 밝히고, 이 함수가 확률변수 X, Y의 결합확률밀도함수일 때 X, Y의 주변분포가 각각 $N(0,1)$임을 밝혀라. 이로부터 주변분포가 일차원의 정규분포이면서도 결합분포는 이변량 정규분포가 아닐 수 있음을 알 수 있다.

4.23 확률변수 X_1, X_2, X_3가 서로 독립이고 각각이 $N(0,1)$을 따를 때, 다음과 같이 이들을 구면좌표로 나타내는 R, Θ_1, Θ_2의 결합확률밀도함수를 구하여라.

$$\begin{cases} X_1 = R\cos\Theta_1\sin\Theta_2,\ X_2 = R\sin\Theta_1\sin\Theta_2,\ X_3 = R\cos\Theta_2 \\ 0 \le R < +\infty,\ 0 \le \Theta_1 < 2\pi,\ 0 \le \Theta_2 < \pi \end{cases}$$

4.24 $\mathrm{X}=(\mathrm{X}_1,\mathrm{X}_2,\mathrm{X}_3)' \sim \mathrm{N}(\mu,\Sigma)$이고 μ와 Σ가 아래와 같을 때 다음에 답하여라.

$$\mu=\begin{pmatrix}1\\2\\3\end{pmatrix},\quad \Sigma=\begin{pmatrix}1 & -1 & 0\\ -1 & 2 & 1\\ 0 & 1 & 2\end{pmatrix}$$

(a) $\mathrm{Y}=(\mathrm{X}_1-\mathrm{X}_2+\mathrm{X}_3,\ 2\mathrm{X}_1+\mathrm{X}_2-\mathrm{X}_3)'$의 분포를 구하여라.

(b) $\mathrm{X}_3=x_3$이 주어진 조건에서, $(\mathrm{X}_1,\mathrm{X}_2)'$의 조건부분포를 구하여라.

4.25 <예 4.4.6>과 <예 4.4.7>에서의 단순선형회귀모형에서 다음이 성립하는 것을 밝혀라.

$$\frac{\hat{\beta}_0+\hat{\beta}_1 x_1-(\beta_0+\beta_1 x_1)}{\sqrt{\hat{\sigma}^2\left(\frac{1}{n}+\frac{(x_1-\overline{x_1})^2}{\mathrm{S}_{xx}}\right)}} \sim t(n-2)$$

4.26 $(\mathrm{X}_1,\mathrm{Y}_1)', \cdots, (\mathrm{X}_n,\mathrm{Y}_n)'\ (n>2)$이 이변량 정규분포

$$N_2\left(\begin{pmatrix}\mu_1\\ \mu_2\end{pmatrix},\begin{pmatrix}\sigma_1^2 & \rho\sigma_1\sigma_2\\ \rho\sigma_1\sigma_2 & \sigma_2^2\end{pmatrix}\right),\ \sigma_1^2>0,\ \sigma_2^2>0,\ -1<\rho<1$$

에서의 랜덤표본이고, r이 표본상관계수 즉

$$r=\frac{\sum_1^n(\mathrm{X}_i-\overline{\mathrm{X}})(\mathrm{Y}_i-\overline{\mathrm{Y}})}{\sqrt{\sum_1^n(\mathrm{X}_i-\overline{\mathrm{X}})^2}\sqrt{\sum_1^n(\mathrm{Y}_i-\overline{\mathrm{Y}})^2}}$$

이라고 하자. 또한,

$$\mathrm{Z}_i=(\mathrm{X}_i-\mu_1)/\sigma_1$$
$$\mathrm{W}_i=\{(\mathrm{Y}_i-\mu_2)/\sigma_2-\rho(\mathrm{X}_i-\mu_1)/\sigma_1\}/\sqrt{1-\rho^2}\ (i=1,\cdots,n)$$

이라고 할 때, 다음에 답하여라.

(a) $$\frac{r}{\sqrt{1-r^2}}=\frac{S_{\mathrm{ZZ}}\,\rho/\sqrt{1-\rho^2}+S_{\mathrm{ZW}}}{\sqrt{S_{\mathrm{ZZ}}S_{\mathrm{WW}}-S_{\mathrm{ZW}}^2}}$$

임을 밝혀라. 여기에서

$$S_{\mathrm{ZZ}}=\sum_1^n(\mathrm{Z}_i-\overline{\mathrm{Z}})^2,\ S_{\mathrm{WW}}=\sum_1^n(\mathrm{W}_i-\overline{\mathrm{W}})^2,\ S_{\mathrm{ZW}}=\sum_1^n(\mathrm{Z}_i-\overline{\mathrm{Z}})(\mathrm{W}_i-\overline{\mathrm{W}})$$

(b) $\mathrm{T}=((\mathrm{Z}_1-\overline{\mathrm{Z}})/\sqrt{S_{\mathrm{ZZ}}},\cdots,(\mathrm{Z}_n-\overline{\mathrm{Z}})/\sqrt{S_{\mathrm{ZZ}}})'$라고 할 때, 다음을 밝혀라.

$$\left\{S_{\mathrm{WW}}-S_{\mathrm{ZW}}^2/S_{\mathrm{ZZ}}=\mathrm{W}'\{I-1(1'1)^{-1}1'-\mathrm{T}(\mathrm{T}'\mathrm{T})^{-1}\mathrm{T}'\}\mathrm{W}\right.$$

(c) $(\mathrm{Z}_1,\cdots,\mathrm{Z}_n)'$과 $(\mathrm{W}_1,\cdots,\mathrm{W}_n)'$이 서로 독립임을 밝히고, 이를 이용하여 다음을 밝혀라.

$(i)\,S_{\mathrm{WW}}-S_{\mathrm{ZW}}^2/S_{\mathrm{ZZ}}\sim\chi^2(n-2)$이고, $(\mathrm{Z}_1,\cdots,\mathrm{Z}_n)'$과는 독립이다.

$(ii)\,S_{\mathrm{ZW}}/\sqrt{S_{\mathrm{ZZ}}}\sim\mathrm{N}(0,1)$ 이고 $(\mathrm{Z}_1,\cdots,\mathrm{Z}_n)'$과는 독립이다.

$(iii)S_{\mathrm{WW}}-S_{\mathrm{ZW}}^2/S_{\mathrm{ZZ}}$, $S_{\mathrm{ZW}}/\sqrt{S_{\mathrm{ZZ}}}$, S_{ZZ}는 서로 독립이다.

(d) 다음이 성립함을 밝혀라.

$$\frac{r}{\sqrt{1-r^2}}\overset{d}{\equiv}\frac{\sqrt{\mathrm{V}_1}\rho/\sqrt{1-\rho^2}+\mathrm{U}}{\sqrt{\mathrm{V}_2}}$$

$\mathrm{V}_1\sim\chi^2(n-1),\ \mathrm{V}_2\sim\chi^2(n-2),\ \mathrm{U}\sim\mathrm{N}(0,1)$ 이고 $\mathrm{V}_1,\mathrm{V}_2,\mathrm{U}$는 서로 독립.