5.1 중심극한정리

이항분포의 누적확률의 근사값을 표준정규분포의 확률로 나타내는 근사식

$$\sum_{x\,:\,a\le\frac{x-np}{\sqrt{np(1-p)}}\le b}\binom{n}{x}p^x(1-p)^{n-x}\sim\int_a^b\frac{1}{\sqrt{2\pi}}e^{-\frac{1}{2}z^2}dz,\ n\to\infty$$

은 3장 6절에서 소개되었다. 한편, 불량률 p를 모수로 하는 베르누이분포 $\mathrm{Bernoulli}(p)$에서의 랜덤표본을 $\mathrm{X}_1, \mathrm{X}_2, \cdots, \mathrm{X}_n$이라고 할 때, 표본 중 불량품의 개수인 $\mathrm{X}_1+\cdots+\mathrm{X}_n$은 이항분포 $\mathrm{B}(n,p)$를 갖는다. 따라서 표준정규분포를 따르는 확률변수 Z에 대하여

$$\lim_{n\to\infty}\mathrm{P}\left(a\le\frac{\mathrm{X}_1+\cdots+\mathrm{X}_n-np}{\sqrt{np(1-p)}}\le b\right)=\mathrm{P}(a\le\mathrm{Z}\le b)$$

즉 표본비율 $\hat{p}=(\mathrm{X}_1+\mathrm{X}_2+\cdots+\mathrm{X}_n)/n$에 관한 확률의 근사식을 다음과 같이 나타낼 수 있다.

$$\lim_{n\to\infty}\mathrm{P}\left(a\le\frac{\hat{p}-p}{\sqrt{p(1-p)/n}}\le b\right)=\mathrm{P}(a\le\mathrm{Z}\le b)$$

이와 같이 통계량에 관한 확률의 근사식이 표준정규분포에 관한 확률로 주어지는 경우가 많이 있다. 이러한 근사식이 성립할 수 있는 통계량 중에서 가장 기본이 되고 유용한 통계량이 표본평균이다. 다음의 중심극한정리(中心極限整理, central limit theorem)는 그와 같은 근사식을 소개하고 있으며, 모든 확률의 근사식에서 가장 중요한 역할을 하고 있다.

정리 5.1.1 중심극한정리

확률변수 $\mathrm{X}_1, \cdots, \mathrm{X}_n$이 서로 독립이고 동일한 분포를 따르며 $\mathrm{Var}(\mathrm{X}_1)$이 양의 실수일 때

$$\mathrm{E}(\mathrm{X}_1)=\mu,\ \mathrm{Var}(\mathrm{X}_1)=\sigma^2\ (0<\sigma<+\infty)$$

이라고 하면, 표준정규분포 $\mathrm{N}(0,1)$을 따르는 확률변수 Z에 대하여 다음이 성립한다.

$$\lim_{n\to\infty}\mathrm{P}\left(\frac{(\mathrm{X}_1+\cdots+\mathrm{X}_n)/n-\mu}{\sigma/\sqrt{n}}\le x\right)=\mathrm{P}(\mathrm{Z}\le x)\ \ \forall x:-\infty<x<+\infty$$

[증명] 이 정리는 주어진 조건하에서 일반적으로 성립하지만 그 증명은 이 책의 수준을 넘으므로 여기에서는 추가적인 조건으로서 X_1의 적률생성함수가 존재하는 경우만을 다루기로 한다. 또한, 정리에 주어진 것과 같이 표준화된 표본평균인

$$\sqrt{n}(\overline{X}_n-\mu)/\sigma=\frac{(X_1+\cdots+X_n)/n-\mu}{\sigma/\sqrt{n}}$$

의 누적확률의 근사 대신 그 적률생성함수가 Z의 적률생성함수 $mgf_Z(t)=\exp(t^2/2)$로 근사될 수 있는 것을 밝히기로 한다.[67] 즉 다음의 근사식을 밝히기로 한다.

$$\lim_{n\to\infty} mgf_{\sqrt{n}(\overline{X}_n-\mu)/\sigma}(t)=mgf_Z(t)=\exp(t^2/2)$$

적률생성함수의 정의와 <정리 2.5.11>에 주어진 서로 독립인 확률변수의 합의 성질로부터

$$\begin{aligned} mgf_{\sqrt{n}(\overline{X}_n-\mu)/\sigma}(t)&=\mathrm{E}[\exp(t\sqrt{n}(\overline{X}_n-\mu)/\sigma)]\\ &=\mathrm{E}\left[\exp\left\{\frac{t}{\sqrt{n}}\left(\frac{X_1-\mu}{\sigma}+\cdots+\frac{X_n-\mu}{\sigma}\right)\right\}\right]\\ &=\left\{\mathrm{E}\left[\exp\left(\frac{t}{\sqrt{n}}\frac{X_1-\mu}{\sigma}\right)\right]\right\}^n\\ &=[mgf_{(X_1-\mu)/\sigma}(t/\sqrt{n})]^n \end{aligned}$$

여기에서 $m(s)=mgf_{(X_1-\mu)/\sigma}(s)$라고 하면 적률생성함수의 성질과 테일러 정리로부터

$$\begin{aligned} m\left(\frac{t}{\sqrt{n}}\right)&=m(0)+\frac{m^{(1)}(0)}{1!}\frac{t}{\sqrt{n}}+\frac{m^{(2)}(0)}{2!}\left(\frac{t}{\sqrt{n}}\right)^2+R_{n,t}\\ &=1+\mathrm{E}\left(\frac{X_1-\mu}{\sigma}\right)\frac{t}{\sqrt{n}}+\mathrm{E}\left[\left(\frac{X_1-\mu}{\sigma}\right)^2\right]\frac{t^2}{2n}+R_{n,t},R_{n,t}/\left(\frac{t}{\sqrt{n}}\right)^2\underset{n\to\infty}{\to}0\\ \therefore\ m\left(\frac{t}{\sqrt{n}}\right)&=1+\frac{1}{2}\frac{t^2}{n}+R_{n,t},\ \lim_{n\to\infty}nR_{n,t}=0 \end{aligned}$$

따라서[68]

---

67) 일반적으로, Z의 누적분포함수가 연속함수일 때 다음이 성립하는 것이 알려져 있다.
$\lim_{n\to\infty} mgf_{Z_n}(t)=mgf_Z(t)\ \forall t:|t|<h(\exists h>0)$이면 $\lim_{n\to\infty}\mathrm{P}(Z_n\le x)=\mathrm{P}(Z\le x)\ \forall x$

68) 이 근사 계산의 과정에서는 다음과 같은 전개 공식을 사용하고 있다.

$$\log mgf_{\sqrt{n}(\overline{X}_n-\mu)/\sigma}(t) = n\log\left(1+\frac{1}{2}\frac{t^2}{n}+R_{n,t}\right),\ \lim_{n\to\infty} nR_{n,t}=0$$

$$= n\left\{\frac{1}{2}\frac{t^2}{n}+r_{n,t}\right\},\ \lim_{n\to\infty} nr_{n,t}=0$$

$$\therefore\ \lim_{n\to\infty} mgf_{\sqrt{n}(\overline{X}_n-\mu)/\sigma}(t) = \exp(t^2/2)$$

예 5.1.1

(a) (포아송분포의 정규근사)

서로 독립이고 포아송분포 $\mathrm{Poisson}(\lambda)$를 따르는 $X_1, \cdots, X_n$에 대하여

$$E(X_1) = \mathrm{Var}(X_1) = \lambda\ (0<\lambda<+\infty)$$

이므로

$$\lim_{n\to\infty} P\left(\frac{(X_1+\cdots+X_n)/n-\lambda}{\sqrt{\lambda/n}} \le x\right) = P(Z\le x),\ Z\sim N(0,1)$$

한편 포아송분포의 성질로부터 $X_1+\cdots+X_n \sim \mathrm{Poisson}(n\lambda)$이므로

$$\lim_{n\to\infty} \sum_{k:\,\frac{k-n\lambda}{\sqrt{n\lambda}}\le x} \frac{e^{-n\lambda}(n\lambda)^k}{k!} = \int_{-\infty}^{x} \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}z^2} dz$$

따라서 $Y_n \sim \mathrm{Poisson}(n)$이고 n이 충분히 크면 표준정규분포의 누적분포함수 Φ를 이용하여 다음과 같이 근사계산을 할 수 있다.[69]

$$P(a<Y_n\le b) \simeq \Phi\left(\frac{b-n}{\sqrt{n}}\right)-\Phi\left(\frac{a-n}{\sqrt{n}}\right)$$

(b) (감마분포 또는 카이제곱분포의 정규근사)

서로 독립이고 감마분포 $\mathrm{Gamma}(\alpha,\beta)$를 따르는 $X_1, \cdots, X_n$에 대하여

$$E(X_1)=\alpha\beta,\ \mathrm{Var}(X_1)=\alpha\beta^2\ (\alpha>0,\beta>0)$$

이므로

$$\lim_{n\to\infty} P\left(\frac{(X_1+\cdots+X_n)/n-\alpha\beta}{\sqrt{\alpha\beta^2/n}} \le x\right) = P(Z\le x),\ Z\sim N(0,1)$$

$$\log(1+x) = x-\frac{1}{2}x^2+\frac{1}{3}x^3-\cdots = x+R(x),\ \lim_{x\to 0} R(x)/x = 0$$

69) 이러한 근사계산은 중심극한정리에서 정규분포로의 수렴이 균등수렴(연습문제 (5.9) 참조)이기 때문에 가능한 것이다.

한편 $Y_n \sim \chi^2(n)$이면

$$Y_n \overset{d}{\equiv} X_1 + \cdots + X_n,\ X_i \overset{iid}{\sim} \chi^2(1) = \mathrm{Gamma}(1/2, 2)\ (i = 1, \cdots, n)$$

이므로

$$\lim_{n\to\infty} P\left(\frac{Y_n - n}{\sqrt{2n}} \le x\right) = P(Z \le x),\ Z \sim N(0,1)$$

따라서 $Y_n \sim \chi^2(n)$이고 n이 충분히 크면 (a)에서와 마찬가지로

$$P(a < Y_n \le b) \simeq \Phi\left(\frac{b-n}{\sqrt{2n}}\right) - \Phi\left(\frac{a-n}{\sqrt{2n}}\right)$$

중심극한정리는 다차원 확률변수의 경우에도 성립하며 많은 통계량의 표본분포를 근사하는 데에 핵심적인 역할을 한다. 그 증명은 일차원의 경우와 마찬가지이므로 생략하기로 한다.

정리 5.1.2 다차원 경우의 중심극한정리

다차원 확률변수 $X_1 = (X_{11}, \cdots, X_{1k})^t$, $\cdots$, $X_n = (X_{n1}, \cdots, X_{nk})^t$이 서로 독립이고 동일한 분포를 따르며 분산행렬 $\mathrm{Var}(X_1)$이 존재할 때

$$E(X_1) = \mu,\ \mathrm{Var}(X_1) = \Sigma$$

라고 하면, $N_k(0, \Sigma)$를 따르는 $Z = (Z_1, \cdots, Z_k)^t$에 대하여 다음이 성립한다.[70]

$$\lim_{n\to\infty} P\left\{\sqrt{n}((X_{1j} + \cdots + X_{nj})/n - \mu_j) \le x_j,\ j = 1, \cdots, k\right\}$$
$$= P(Z_1 \le x_1, \cdots, Z_k \le x_k)\ \ \forall x_j$$

예 5.1.2 다항분포의 다변량 정규근사

다항분포의 대의적 정의로부터 $X_n = (X_{n1}, \cdots, X_{nk})^t \sim \mathrm{Multi}(n, (p_1, p_2, \cdots, p_k)^t)$이면

$$X_n \overset{d}{\equiv} Z_1 + \cdots + Z_n,\ Z_i = (Z_{i1}, Z_{i2}, \cdots, Z_{ik})^t \overset{iid}{\sim} \mathrm{Multi}(1, (p_1, p_2, \cdots, p_k)^t)\ (i = 1, \cdots, n)$$

한편 p_1, $\cdots$, p_k를 대각원소로 하는 대각행렬을 $D(p_j)$라고 하면 <정리 3.2.2>로부터

70) 다차원 확률변수에 관한 이러한 결합확률을 간략히 다음과 같이 나타내기도 한다.
$$\lim_{n\to\infty} P\left\{\sqrt{n}((X_1 + \cdots + X_n)/n - \mu) \le x\right\} = P(Z \le x),\ \forall x \in R^k,\ Z \sim N_k(0, \Sigma)$$

$$\mathrm{E}(\mathrm{X}_1) = p = (p_1, \cdots, p_k)^t,\ \mathrm{Var}(\mathrm{X}_1) = D(p_j) - pp^t$$

따라서 중심극한정리로부터

$$\lim_{n\to\infty} \mathrm{P}\left\{(\mathrm{X}_n - np)/\sqrt{n} \le x\right\} = \mathrm{P}(\mathrm{Z} \le x),\ \mathrm{Z} \sim \mathrm{N}_k(0, D(p_j) - pp^t)$$

이 때 분산행렬 $D(p_j) - pp^t$ 은 특이행렬로서 역행렬을 갖지 않는 점에 유의하여야 한다.

5.2 극한분포와 확률적 수렴

중심극한정리에서 근사에 이용되는 분포가 정규분포로서 그 누적분포함수가 연속함수이다.

그러나 이항확률의 포아송근사에서와 같이 근사에 이용되는 분포의 누적분포함수가 연속이 아닐 수도 있다. 이제 일반적인 경우, 분포의 근사에 대하여 생각해보자.

예 5.2.1

동전을 던져서 앞면이 나오면 0부터 $1+n^{-1}$ 사이의 수를 랜덤하게 선택하여 보여주고, 뒷면이 나오면 $1+n^{-1}$을 보여주는 실험에서 보게 될 숫자를 $\mathrm{X}_n (n = 1,2,\cdots)$이라고 하자.

확률변수 $\mathrm{X}_n (n = 1,2,\cdots)$의 누적분포함수가 다음과 같은 경우에 분포의 근사를 생각해보자.

$$cdf_{\mathrm{X}_n}(x) = \mathrm{P}(\mathrm{X}_n \le x) = \begin{cases} 0, & x < 0 \\ \frac{1}{2}\frac{1}{1+n^{-1}}x, & 0 \le x < 1+n^{-1} \\ 1, & x \ge 1+n^{-1} \end{cases}$$

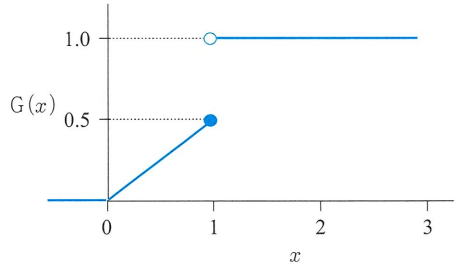
이러한 누적분포함수들의 극한으로 정의되는 함수는

$$\mathrm{G}(x) = \lim_{n\to\infty} cdf_{\mathrm{X}_n}(x)$$

$$= \begin{cases} 0, & x < 0 \\ \frac{1}{2}x, & 0 \le x \le 1 \\ 1, & x > 1 \end{cases}$$

로서, $x=1$의 오른쪽에서 연속이 아닌 함수이다. 따라서 <정리 1.5.1>로부터 이 함수는 누적분포함수가 아니다.

그림 5.1.1 누적분포함수의 극한이 연속이 아닌 경우



<예 5.2.1>에서 극한 함수가 연속이 아닌 점 $x=1$의 오른쪽에서 연속이도록 수정한 함수를

$$F(x)=\begin{cases}0, & x<0\\ \frac{1}{2}x, & 0\le x<1\\ 1, & x\ge 1\end{cases}$$

라고 하면 함수 $F(x)$는 누적분포함수이고, <예 5.2.1>의 확률변수들 $X_n(n=1,2,\cdots)$에 대하여

$$\lim_{n\to\infty} cdf_{X_n}(x)=F(x)\ \ \forall x: x\neq 1$$

임을 알 수 있다. 이 경우에 동전을 던져서 앞면이 나오면 0부터 1 사이의 수를 랜덤하게 선택하여 보여주고, 뒷면이 나오면 1을 보여주는 실험에서 보게 될 숫자를 X라고 하면 함수 $F(x)$는 확률변수 X의 누적분포함수이다. 따라서

$$\lim_{n\to\infty} cdf_{X_n}(x)=cdf_X(x)\ \ \forall x: x\neq 1$$

이고 $X_n(n=1,2,\cdots)$의 분포가 X의 분포로 근사된다고 할 수 있을 것이다.

<예 5.2.1>의 경우와 같이 극한으로 주어지는 분포의 누적분포함수가 연속이 아닌 경우까지도 다루기 위하여 극한분포(極限分布, limiting distribution)를 다음과 같이 정의한다.

극한분포:

확률변수의 열 $X_n(n=1,2,\cdots)$과 Z에 대하여

$$\lim_{n\to\infty} P(X_n\le x)=P(Z\le x)$$

가 Z의 누적분포함수 cdf_Z가 연속인 모든 점 x에서 성립할 때, Z의 분포를 X_n 분포들의 극한분포 또는 점근분포(漸近分布, asymptotic distribution)라고 하며 기호로는

$$X_n \xrightarrow[n\to\infty]{d} Z$$

로 나타낸다. 즉 cdf_Z가 연속인 점들의 집합을 $Conti(cdf_Z)$라고 하면

$$X_n \xrightarrow[n\to\infty]{d} Z \Leftrightarrow \lim_{n\to\infty} cdf_{X_n}(x)=cdf_Z(x)\ \ \forall x: x\in Conti(cdf_Z)$$

예 5.2.2 이항분포의 포아송근사

이항분포 $B(n, \lambda/n)\,(0 < \lambda/n < 1)$을 따르는 확률변수 X_n과 포아송분포 $Poisson(\lambda)$를 따르는 확률변수 X에 대하여 다음이 성립하는 것은 3장 4절에서 소개되었다.

$$P(X_n = k) = \binom{n}{k}\left(\frac{\lambda}{n}\right)^k\left(1-\frac{\lambda}{n}\right)^{n-k} \underset{n\to\infty}{\to} \frac{1}{k!}\lambda^k e^{-\lambda} = P(X=k),\ k=1,2,\cdots$$

한편 이들 확률변수들은 0 또는 자연수의 값만을 가지므로 모든 점 x에서

$$cdf_{X_n}(x) = \sum_{k:0\le k\le x} P(X_n = k) \underset{n\to\infty}{\to} \sum_{k:0\le k\le x} P(X=k) = cdf_X(x)$$

임을 알 수 있다. 따라서 X의 분포 $Poisson(\lambda)$는 X_n의 분포 $B(n, \lambda/n)$의 극한분포이고 이를 기호로 다음과 같이 나타내기도 한다.

$$B(n, \lambda/n) \approx Poisson(\lambda),\ n\to\infty$$

예 5.2.3

균등분포 $U(0,1)$에서의 랜덤표본 n개에 기초한 순서통계량을 $U_{(1)} < \cdots < U_{(n)}$이라고 할 때

$$P\{n(1-U_{(n)}) \le x\} = 1 - P\left\{U_{(n)} < 1 - \frac{x}{n}\right\}$$

이고

$$P\left\{U_{(n)} < 1-\frac{x}{n}\right\} = \begin{cases} 0, & 1-x/n < 0 \text{ 즉 } x > n \\ \left(1-\frac{x}{n}\right)^n, & 0 \le 1-x/n < 1 \text{ 즉 } 0 < x \le n \\ 1, & 1 \le 1-x/n \text{ 즉 } x \le 0 \end{cases}$$

$$\lim_{n\to\infty} P\left\{U_{(n)} < 1-\frac{x}{n}\right\} = \begin{cases} e^{-x}, & 0 < x < +\infty \\ 1, & x \le 0 \end{cases}$$

이므로 $n(1-U_{(n)})$의 극한분포를 다음과 같이 구할 수 있다.

$$\lim_{n\to\infty} P\{n(1-U_{(n)}) \le x\} = \begin{cases} 1-e^{-x}, & x \ge 0 \\ 0, & x < 0 \end{cases}$$

$$\therefore\ n(1-U_{(n)}) \underset{n\to\infty}{\overset{d}{\to}} Z,\ Z \sim Exp(1)$$

정리 5.2.1 극한분포가 상수의 분포인 경우

확률변수의 열 $X_n\ (n=1,2,\cdots)$의 극한분포가 상수 c의 분포일 조건은 다음과 같다.

$$X_n \xrightarrow[n\to\infty]{d} X,\ P(X=c)=1 \Leftrightarrow \lim_{n\to\infty} P(|X_n-c|\geq\epsilon)=0\ \ \forall\epsilon>0$$

[증명] $P(X=c)=1$인 경우에 그 누적분포함수는

$$cdf_X(x)=\begin{cases}0, & x<c\\ 1, & x\geq c\end{cases}$$

이므로 cdf_X는 $x=c$ 이외의 모든 점에서 연속인 함수이다.

($\Rightarrow$) 극한분포의 정의에 따라

$$\lim_{n\to\infty} cdf_{X_n}(x)=cdf_X(x)\ \ \forall x: x\neq c$$

따라서 임의의 양수 ϵ에 대하여 다음이 성립하는 것을 알 수 있다.

$$\lim_{n\to\infty} P(X_n\leq c-\epsilon)=cdf_X(c-\epsilon)=0$$

$$0\leq \lim_{n\to\infty} P(X_n\geq c+\epsilon)\leq \lim_{n\to\infty} P(X_n>c+\epsilon/2)=1-cdf_X(c+\epsilon/2)=0$$

$$\therefore \lim_{n\to\infty} P(|X_n-c|\geq\epsilon)=0$$

($\Leftarrow$) 주어진 조건이 성립한다면, 임의의 양수 ϵ에 대하여 다음이 성립하게 된다.

$$0\leq cdf_{X_n}(c-\epsilon)=P(X_n\leq c-\epsilon)\leq P(|X_n-c|\geq\epsilon)\xrightarrow[n\to\infty]{}0$$

$$0\leq 1-cdf_{X_n}(c+\epsilon)=P(X_n>c+\epsilon)\leq P(|X_n-c|\geq\epsilon)\xrightarrow[n\to\infty]{}0$$

$$\therefore \lim_{n\to\infty} cdf_{X_n}(x)=cdf_X(x)\ \ \forall x: x\neq c$$

확률수렴:

〈정리 5.2.1〉의 조건이 성립할 때, 확률변수 X_n이 상수 c로 확률수렴(確率收斂, converge in probability)한다고 하며, 기호로는 $X_n \xrightarrow[n\to\infty]{P} c$ 또는 $\operatorname{plim}_{n\to\infty} X_n=c$와 같이 나타낸다. 즉

$$\operatorname{plim}_{n\to\infty} X_n=c \Leftrightarrow \lim_{n\to\infty} P(|X_n-c|\geq\epsilon)=0\ \ \forall\epsilon>0$$

정리 5.2.2 **대수의 법칙(大數의 法則, law of large numbers)**

확률변수 $X_1, \cdots, X_n$이 서로 독립이고 동일한 분포를 따르며 $E(X_1)$이 실수로 정의되면[71]

$$\operatorname{plim}_{n\to\infty} \frac{1}{n}\sum_{i=1}^{n} X_i = E(X_1)$$

[증명] 이 정리는 주어진 조건하에서 일반적으로 성립하지만 그 증명은 이 책의 수준을 넘으므로 여기에서는 추가적인 조건으로서 $Var(X_1) < +\infty$인 경우만을 다루기로 한다.

체비셰프의 부등식을 표본평균 $\overline{X_n} = (X_1 + \cdots + X_n)/n$에 적용하면, 임의의 양수 ϵ에 대하여

$$0 \le P(|\overline{X_n} - E(X_1)| \ge \epsilon) \le Var(\overline{X_n})/\epsilon^2$$

$$= Var(X_1)/n\epsilon^2$$

$$\therefore \lim_{n\to\infty} P(|\overline{X_n} - E(X_1)| \ge \epsilon) = 0$$

랜덤표본 $X_1, \cdots, X_n$을 관측할 때 관측값이 A에 속하는 상대도수는

$$\frac{1}{n}\sum_{i=1}^{n} I_A(X_i)$$

로 주어진다. 이 상대도수에 대수의 법칙을 적용하면 다음이 성립하는 것을 알 수 있다.

$$\operatorname{plim}_{n\to\infty} \frac{1}{n}\sum_{i=1}^{n} I_A(X_i) = E(I_A(X_1)) = P(X_1 \in A)$$

즉 시행 횟수가 많아짐에 따라 상대도수가 확률에 한없이 가까이 가는 것을 뜻한다.

대수의 법칙의 의미를 통계적 추론의 관점에서 생각해보자. 표본크기가 커짐에 따라 추측에 사용되는 표본평균이 추측 대상인 모평균에 한없이 가까이 가는 것을 뜻하는 것이 대수의 법칙이다. 이러한 확률수렴의 개념을 많은 통계량에 적용하려면 그 정의를 다차원 확률변수의 경우로 확장시킬 필요가 있다.

---

71) 기댓값의 정의에 따라 이는 $E(|X_1|) < +\infty$임을 뜻한다.

다차원 경우의 확률수렴:

다차원 확률변수 $X_n=(X_{n1},\cdots,X_{nk})^t$과 상수의 벡터 $c=(c_1,\cdots,c_k)^t$에 대하여

$$\|X_n-c\|=\sqrt{(X_{n1}-c_1)^2+\cdots+(X_{nk}-c_k)^2}$$

라고 할 때 다음이 성립하면 $X_n=(X_{n1},\cdots,X_{nk})^t$이 $c=(c_1,\cdots,c_k)^t$로 확률수렴한다고 하며 일차원 경우와 마찬가지로 기호로는 $X_n \xrightarrow[n\to\infty]{P} c$ 또는 $\operatorname{plim}_{n\to\infty} X_n=c$로 나타낸다.

$$\lim_{n\to\infty} P(\|X_n-c\|\geq\epsilon)=0 \quad \forall\epsilon>0$$

정리 5.2.3

다차원 확률변수 $X_n=(X_{n1},\cdots,X_{nk})^t$이 상수의 벡터 $c=(c_1,\cdots,c_k)^t$로 확률수렴하는 것, 즉 $\operatorname{plim}_{n\to\infty} X_n=c$와 다음의 조건들은 같은 뜻이다.

(a) $\lim_{n\to\infty} P(\max_{1\leq i\leq k}|X_{ni}-c_i|\geq\epsilon)=0$

(b) $\operatorname{plim}_{n\to\infty} X_{n1}=c_1,\cdots,\operatorname{plim}_{n\to\infty} X_{nk}=c_k$

[증명] (a) 다차원의 경우에 주어진 $\|X_n-c\|$의 정의로부터

$$\max_{1\leq i\leq k}|X_{ni}-c_i| \leq \|X_n-c\| \leq k\max_{1\leq i\leq k}|X_{ni}-c_i|$$

$$\therefore P(\max_{1\leq i\leq k}|X_{ni}-c_i|\geq\epsilon)\leq P(\|X_n-c\|\geq\epsilon)\leq P(\max_{1\leq i\leq k}|X_{ni}-c_i|\geq\epsilon/k)$$

이로부터 확률수렴의 정의와 조건 (a)가 같은 뜻임을 알 수 있다.

(b) 포함 관계

$$(|X_{ni}-c_i|\geq\epsilon)\subseteq(\max_{1\leq i\leq k}|X_{ni}-c_i|\geq\epsilon)=\bigcup_{i=1}^{k}(|X_{ni}-c_i|\geq\epsilon)(i=1,\cdots,k)$$

로부터 다음의 부등식이 성립한다.

$$\max_{1\leq i\leq k}P(|X_{ni}-c_i|\geq\epsilon)\leq P(\max_{1\leq i\leq k}|X_{ni}-c_i|\geq\epsilon)\leq\sum_{i=1}^{k}P(|X_{ni}-c_i|\geq\epsilon)$$

따라서 (a)와 (b)가 같은 뜻임을 알 수 있다.

정리 5.2.4

다차원 확률변수 $X_1=(X_{11},\cdots,X_{1k})^t,\ \cdots,X_n=(X_{n1},\cdots,X_{nk})^t$이 서로 독립이고 동일한 분포를 따르며 $E(X_1)=(E(X_{11}),\cdots,E(X_{1k}))^t$이 정의될 수 있으면[72]

$$\operatorname{plim}_{n\to\infty}\frac{1}{n}\sum_{i=1}^{n}X_i = E(X_1)$$

[증명] 일차원 경우에 대수의 법칙과 <정리 5.2.3>으로부터 이 정리는 명백히 성립한다.

예 5.2.4 표본적률 벡터의 확률수렴

랜덤표본 $X_1, \cdots, X_n$의 함수로서

$$\widehat{m_r} = \frac{1}{n}\sum_{i=1}^{n}X_i^r$$

을 r차 표본적률(標本積率, sample moment)이라고 하며, 이는 모집단 적률인 $m_r = E(X_1^r)$의 추론에 사용된다. 한편 <정리 1.6.2>로부터 $E(|X_1^k|) < +\infty$이면, 즉 k차 적률 $E(X_1^k)$가 실수로 정의될 수 있으면 더 낮은 차의 적률이 모두 실수로 정의될 수 있는 것을 알고 있다. 따라서 대수의 법칙으로부터 $E(|X_1^k|) < +\infty$이면

$$\operatorname{plim}_{n\to\infty}\frac{1}{n}\sum_{i=1}^{n}(X_i,\cdots,X_i^k)^t = (E(X_1),\cdots,E(X_1^k))^t$$

이로부터 표본적률의 벡터인

$$(\widehat{m_1},\cdots,\widehat{m_k})^t = \left(\frac{1}{n}\sum_{i=1}^{n}X_i,\cdots,\frac{1}{n}\sum_{i=1}^{n}X_i^k\right)^t = \frac{1}{n}\sum_{i=1}^{n}(X_i,\cdots,X_i^k)^t$$

은 표본크기가 커짐에 따라 그 추측 대상인 모집단의 적률벡터에 한없이 가까이 간다는 것을 알 수 있다.

정리 5.2.5 연속함수와 확률수렴

다차원 확률변수 $X_n = (X_{n1},\cdots,X_{nk})^t$이 상수의 벡터 $c = (c_1,\cdots,c_k)^t$로 확률수렴하고 실수값 함수 g가 c에서 연속이면 $g(X_n)$이 $g(c)$로 확률수렴한다. 즉 함수 g가 c에서 연속일 때

$$\operatorname{plim}_{n\to\infty}X_n = c \text{이면 } \operatorname{plim}_{n\to\infty}g(X_n) = g(c)$$

---

72) 기댓값의 정의에 따라 이는 $E(|X_{11}|) < +\infty, \cdots, E(|X_{1k}|) < +\infty$임을 뜻한다.

[증명] 함수 g가 c에서 연속이므로, 다음이 성립한다.

$$\forall \epsilon > 0,\ \exists \delta > 0 : (\| x - c \| < \delta \Rightarrow |g(x) - g(c)| < \epsilon)$$

따라서 임의의 양수 ϵ에 대하여 이러한 양수 δ를 선택하면

$$(\| X_n - c \| < \delta) \subseteq (|g(X_n) - g(c)| < \epsilon)$$

$$\therefore (|g(X_n) - g(c)| \geq \epsilon) \subseteq (\| X_n - c \| \geq \delta)$$

$$\therefore P(|g(X_n) - g(c)| \geq \epsilon) \leq P(\| X_n - c \| \geq \delta)$$

그런데 $\operatorname{plim}_{n\to\infty} X_n = c$이므로

$$0 \leq \lim_{n\to\infty} P(|g(X_n) - g(c)| \geq \epsilon) \leq \lim_{n\to\infty} P(\| X_n - c \| \geq \delta) = 0$$

정리 5.2.6 확률수렴과 사칙연산[73]

확률변수 $X_n, Y_n (n = 1,2,\cdots)$이 각각 실수 a, b로 확률수렴할 때 다음이 성립한다.

(a) $\operatorname{plim}_{n\to\infty}(X_n + Y_n) = \operatorname{plim}_{n\to\infty} X_n + \operatorname{plim}_{n\to\infty} Y_n = a + b$

(b) $\operatorname{plim}_{n\to\infty}(X_n - Y_n) = \operatorname{plim}_{n\to\infty} X_n - \operatorname{plim}_{n\to\infty} Y_n = a - b$

(c) $\operatorname{plim}_{n\to\infty}(X_n \times Y_n) = \operatorname{plim}_{n\to\infty} X_n \times \operatorname{plim}_{n\to\infty} Y_n = a \times b$

(d) $\operatorname{plim}_{n\to\infty}(X_n \div Y_n) = \operatorname{plim}_{n\to\infty} X_n \div \operatorname{plim}_{n\to\infty} Y_n = a \div b\ (b \neq 0)$

[증명] <정리 5.2.3>으로부터 이차원 확률변수 $(X_n, Y_n)^t$가 벡터$(a,b)^t$로 확률수렴한다. 즉

$$\operatorname{plim}_{n\to\infty}(X_n, Y_n)^t = (a,b)^t$$

따라서 <정리 5.2.5>에 의해 연속인 이변수 함수를 적용하면 확률수렴성이 보존된다.

한편 사칙연산은 이변수 함수로서 그 정의역에서 연속인 함수이므로 이 정리가 성립한다. 구체적으로는 <정리 5.2.5>를 다음 함수들에 적용하면 이 정리의 결과를 얻게 된다.

$$g_1(x,y) = x + y,\ g_2(x,y) = x - y,\ g_3(x,y) = x \times y,\ g_4(x,y) = x \div y$$

---

73) 이 정리에서 확률변수 X_n이나 Y_n이 각각 상수 x_n이나 $y_n (n = 1,2,\cdots)$인 경우에도 그 결과가 성립한다. 이는 X_n이나 Y_n이 하나의 값만 갖는 상수의 확률변수들인 경우로 생각할 수 있기 때문이다.

예 5.2.5 표본분산과 표본표준편차의 확률수렴

랜덤표본 $X_1, X_2, \cdots, X_n (n \geq 2)$을 이용하여 모분산에 관한 추론에 사용되는 표본분산

$$S_n^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X})^2$$

은 다음과 같이 두 표본적률 $\left(\sum_{i=1}^{n} X_i/n, \sum_{i=1}^{n} X_i^2/n\right)^t$의 함수로 나타낼 수 있다.

$$S_n^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X})^2 = \frac{n}{n-1}\left\{\frac{1}{n}\sum_{i=1}^{n}X_i^2 - \left(\frac{1}{n}\sum_{i=1}^{n}X_i\right)^2\right\}$$

한편 <예 5.2.4>에서와 같이 대수의 법칙으로부터, $E(X_1^2) < +\infty$ 이면

$$\operatorname{plim}_{n\to\infty}\frac{1}{n}\sum_{i=1}^{n}X_i^2 = E(X_1^2),\ \operatorname{plim}_{n\to\infty}\frac{1}{n}\sum_{i=1}^{n}X_i = E(X_1)$$

따라서 <정리 5.2.6>으로부터

$$\operatorname{plim}_{n\to\infty} S_n^2 = \operatorname{plim}_{n\to\infty}\frac{n}{n-1}\left\{\frac{1}{n}\sum_{i=1}^{n}X_i^2 - \left(\frac{1}{n}\sum_{i=1}^{n}X_i\right)^2\right\} = 1\times\left\{E(X_1^2) - [E(X_1)]^2\right\}$$

그러므로 모분산 $\sigma^2 = \mathrm{Var}(X_1)$이 양의 실수일 때

$$\operatorname{plim}_{n\to\infty} S_n^2 = \sigma^2$$

또한 표본표준편차는 $S_n = \sqrt{S_n^2}$ 이고 제곱근함수는 연속함수이므로 <정리 5.2.5>로부터

$$\operatorname{plim}_{n\to\infty} S_n = \sqrt{\operatorname{plim}_{n\to\infty} S_n^2} = \sqrt{\sigma^2} = \sigma$$

다음 정리는 대수의 법칙을 적용하기 어려운 경우에 확률수렴을 밝히는 데 유용하다.

정리 5.2.7

분산이 실수로 정의될 수 있는 확률변수 $X_n (n = 1, 2, \cdots)$에 대하여 다음이 성립한다.

$$\lim_{n\to\infty}\mathrm{Var}(X_n) = 0,\ \lim_{n\to\infty}E(X_n) = a \text{ 이면 } \operatorname{plim}_{n\to\infty} X_n = a$$

[증명] <정리 1.6.3>의 마코프 부등식으로부터, 임의의 양수 ϵ에 대하여 다음이 성립한다.

$$P(|X_n - a| \geq \epsilon) \leq E[(X_n - a)^2]/\epsilon^2$$

한편

$$E[(X_n - a)^2] = Var(X_n) + \{E(X_n) - a\}^2$$

이므로, $\lim_{n\to\infty} Var(X_n) = 0$, $\lim_{n\to\infty} E(X_n) = a$이면

$$0 \leq \lim_{n\to\infty} P(|X_n - a| \geq \epsilon) \leq \lim_{n\to\infty} E[(X_n - a)^2]/\epsilon^2 = 0$$

예 5.2.6

균등분포 $U(0,1)$에서의 랜덤표본 n개에 기초한 순서통계량을 $U_{(1)} < \cdots < U_{(n)}$이라고 할 때 $U_{(n)}$의 확률밀도함수가

$$pdf_{U_{(n)}}(x) = n x^{n-1} I_{(0,1)}(x)$$

이므로

$$E(U_{(n)}) = \frac{n}{n+1},\ Var(U_{(n)}) = \frac{n}{n+2} - \left(\frac{n}{n+1}\right)^2$$

따라서

$$\lim_{n\to\infty} Var(U_{(n)}) = 0,\ \lim_{n\to\infty} E(U_{(n)}) = 1$$

$$\therefore\ p\lim_{n\to\infty} U_{(n)} = 1$$

예 5.2.7 표본분위수의 확률수렴

모집단 분포가 연속형이고 그 누적분포함수 $F(x)$가 순증가함수[74]일 때 누적확률이 α가 되는 값 $F^{-1}(\alpha)(0 < \alpha < 1)$를 모집단의 α 분위수(分位數, quantile)라고 한다. 한편 랜덤표본 n개에 기초한 순서통계량을 $X_{(1)} < \cdots < X_{(n)}$이라고 할 때

$$r_n \sim \alpha n,\ 즉\ \lim_{n\to\infty} r_n/n = \alpha\ \ (0 < \alpha < 1)$$

---

74) 확률적분변환에 관한 <정리 4.3.3>에서와 마찬가지로 누적분포함수가 순증가가 아닌 경우에는 F의 역변환을

$$F^{-1}(u) = inf\{x : F(x) \geq u\}(0 \leq u \leq 1)$$

로 정의하고, 일반적으로는 이 역변환을 이용하여 분위수를 정의한다.

를 만족하는 자연수 r_n에 대하여 $X_{(r_n)}$을 표본분위수(標本分位數, sample quantile)[75]라고 한다. 이러한 표본분위수의 분포는 <정리 4.3.4>로부터

$$X_{(r_n)} \overset{d}{\equiv} h\left(\frac{1}{n}Z_1 + \cdots + \frac{1}{n-r_n+1}Z_{r_n}\right),\ Z_i \overset{iid}{\sim} \mathrm{Exp}(1)\ (i=1,\cdots,n)$$

와 같이 나타낼 수 있다. 여기에서 h는 $h(y) = \mathrm{F}^{-1}(1-e^{-y})\ (y>0)$로 정의된 함수이다.

한편 표준지수분포의 평균과 분산은 1이므로

$$Y_n = \frac{1}{n}Z_1 + \cdots + \frac{1}{n-r_n+1}Z_{r_n}$$

이라고 하면

$$\mathrm{E}(Y_n) = \frac{1}{n} + \cdots + \frac{1}{n-r_n+1},\ \mathrm{Var}(Y_n) = \frac{1}{n^2} + \cdots + \frac{1}{(n-r_n+1)^2}$$

그런데 이들 합을 적분으로 근사하면

$$\frac{1}{n} + \cdots + \frac{1}{n-r_n+1} = \frac{1}{n}\sum_{k=1}^{r_n-1}\frac{1}{1-k/n} \sim \int_0^{\alpha}\frac{1}{1-x}dx = -\log(1-\alpha)$$

$$\frac{1}{n^2} + \cdots + \frac{1}{(n-r_n+1)^2} = \frac{1}{n}\frac{1}{n}\sum_{k=0}^{r_n-1}\frac{1}{(1-k/n)^2} \sim \frac{1}{n}\int_0^{\alpha}\frac{1}{(1-x)^2}dx = \frac{1}{n}\frac{\alpha}{1-\alpha}$$

따라서

$$\lim_{n\to\infty}\mathrm{Var}(Y_n) = \lim_{n\to\infty}\frac{1}{n}\frac{\alpha}{1-\alpha} = 0,\ \lim_{n\to\infty}\mathrm{E}(Y_n) = -\log(1-\alpha)$$

$$\therefore\ \mathrm{plim}_{n\to\infty} Y_n = \mathrm{plim}_{n\to\infty}\left(\frac{1}{n}Z_1 + \cdots + \frac{1}{n-r_n+1}Z_{r_n}\right) = -\log(1-\alpha)$$

그러므로 함수 $h(y) = \mathrm{F}^{-1}(1-e^{-y})\ (y>0)$가 연속인 경우에 <정리 5.2.5>로부터

$$\mathrm{plim}_{n\to\infty} h\left(\frac{1}{n}Z_1 + \cdots + \frac{1}{n-r_n+1}Z_{r_n}\right) = h(-\log(1-\alpha)) = \mathrm{F}^{-1}(\alpha)$$

이고, <정리 5.2.1>의 필요조건으로부터 이러한 경우에

$$h\left(\frac{1}{n}Z_1 + \cdots + \frac{1}{n-r_n+1}Z_{r_n}\right) \underset{n\to\infty}{\overset{d}{\to}} \mathrm{F}^{-1}(\alpha)$$

---

75) 표본분위수에 대한 이러한 정의는 표본크기가 충분히 큰 경우에 사용하는 정의이며, 이는 <예 4.1.2>의 표본 중앙값의 정의와 다른 것을 알 수 있다. 이러한 정의는 확률수렴과 같은 극한 성질을 간략히 밝히기 위한 것이며, 일반적인 정의에 따른 표본분위수의 경우에도 모집단의 분위수로 확률수렴하는 것이 알려져 있다.

그런데 $X_{(r_n)} \overset{d}{\equiv} h\left(\frac{1}{n}Z_1 + \cdots + \frac{1}{n-r_n+1}Z_{r_n}\right)$이므로 이러한 경우에

$$X_{(r_n)} \underset{n\to\infty}{\overset{d}{\to}} F^{-1}(\alpha)$$

따라서 누적분포함수의 역함수 F^{-1}이 연속일 때 <정리 5.2.1>의 충분조건으로부터

$$\operatorname{plim}_{n\to\infty} X_{(r_n)} = F^{-1}(\alpha)$$

5.3 극한분포의 계산

정리 5.3.1 슬럿츠키(Slutsky)의 정리

확률변수 X_n, $Y_n (n=1,2,\cdots)$, Z와 실수의 상수 c에 대하여

$$X_n \underset{n\to\infty}{\overset{d}{\to}} Z, \quad \operatorname{plim}_{n\to\infty} Y_n = c$$

이면 다음이 성립한다.

(a) $X_n + Y_n \underset{n\to\infty}{\overset{d}{\to}} Z + c$

(b) $X_n - Y_n \underset{n\to\infty}{\overset{d}{\to}} Z - c$

(c) $Y_n X_n \underset{n\to\infty}{\overset{d}{\to}} cZ$

(d) $X_n / Y_n \underset{n\to\infty}{\overset{d}{\to}} Z/c \quad (c \neq 0)$

[증명] 이 정리는 일반적인 경우에 성립하지만 여기에서는 Z의 누적분포함수가 연속함수인 경우만 증명하기로 한다.

(a) 임의의 양수 ϵ에 대하여

$$\begin{aligned} P(X_n + Y_n \le z) &= P(X_n + Y_n \le z, |Y_n - c| < \epsilon) \\ &\quad + P(X_n + Y_n \le z, |Y_n - c| \ge \epsilon) \\ &\le P(X_n \le z - c + \epsilon) + P(|Y_n - c| \ge \epsilon) \end{aligned}$$

그런데 $X_n \underset{n\to\infty}{\overset{d}{\to}} Z$, $\operatorname{plim}_{n\to\infty} Y_n = c$이므로

$$\overline{\lim_{n\to\infty}} P(X_n + Y_n \le z) \le P(Z \le z - c + \epsilon) \underset{\epsilon \downarrow 0}{\to} P(Z + c \le z)$$

한편 같은 방법으로 부등식

$$P(X_n+Y_n>z)=P(X_n+Y_n>z,|Y_n-c|<\epsilon)+P(X_n+Y_n>z,|Y_n-c|\geq\epsilon)$$
$$\leq P(X_n>z-c-\epsilon)+P(|Y_n-c|\geq\epsilon)$$

으로부터 주어진 조건하에서

$$\overline{\lim_{n\to\infty}}P(X_n+Y_n>z)\leq P(Z>z-c-\epsilon)$$

따라서 Z의 누적분포함수가 연속함수라는 추가 조건하에서

$$\underline{\lim_{n\to\infty}}P(X_n+Y_n\leq z)\geq P(Z\leq z-c-\epsilon)\underset{\epsilon\downarrow 0}{\to}P(Z+c\leq z)$$

그러므로 $X_n\underset{n\to\infty}{\overset{d}{\to}}Z$, $\operatorname{plim}_{n\to\infty}Y_n=c$이면 Z의 누적분포함수가 연속함수라는 추가 조건하에서

$$\lim_{n\to\infty}P(X_n+Y_n\leq z)=P(Z+c\leq z),\ \text{즉}\ X_n+Y_n\underset{n\to\infty}{\overset{d}{\to}}Z+c$$

(b) $\operatorname{plim}_{n\to\infty}Y_n=c$이면 $\operatorname{plim}_{n\to\infty}(-Y_n)=-c$이고 (a)가 성립하므로 (b)도 성립한다.

(c) 첫째로 $c=0$인 경우를 먼저 생각해보자. 이 경우에는 임의의 양수 ϵ에 대하여

$$P(|Y_nX_n|\geq\epsilon)=P(|Y_nX_n|\geq\epsilon,|X_n|>k)+P(|Y_nX_n|\geq\epsilon,|X_n|\leq k)$$
$$\leq P(|X_n|>k)+P(k|Y_n|\geq\epsilon)$$
$$\leq P(X_n>k)+P(X_n\leq -k)+P(|Y_n|\geq\epsilon/k),\ \forall k>0$$

따라서 $X_n\underset{n\to\infty}{\overset{d}{\to}}Z$, $\operatorname{plim}_{n\to\infty}Y_n=0$이면 Z의 누적분포함수가 연속함수라는 추가 조건하에서

$$0\leq\lim_{n\to\infty}P(|Y_nX_n|\geq\epsilon)\leq P(Z>k)+P(Z\leq -k)\underset{k\uparrow\infty}{\to}0\ \therefore\ \operatorname{plim}_{n\to\infty}Y_nX_n=0$$

다음에는 일반적인 c의 경우를 생각해보자. 이 경우에는 주어진 조건이

$$\operatorname{plim}_{n\to\infty}(Y_n-c)=0,\ X_n\underset{n\to\infty}{\overset{d}{\to}}Z$$

이므로 첫 번째 경우의 증명에 따라 주어진 조건이 성립하면

$$\operatorname{plim}_{n\to\infty}(Y_n-c)X_n=0$$

또한 Z의 누적분포함수에 대한 추가 조건하에서 명백히 $cX_n\underset{n\to\infty}{\overset{d}{\to}}cZ$이므로 (a)로부터

$$Y_nX_n=(Y_n-c)X_n+cX_n\underset{n\to\infty}{\overset{d}{\to}}0+cZ=cZ$$

(d) $\operatorname{plim}_{n\to\infty} Y_n = c\,(c \neq 0)$이면 $\operatorname{plim}_{n\to\infty} 1/Y_n = 1/c$이고 (c)가 성립하므로 (d)도 성립한다.

예 5.3.1 스튜던트화 된 표본평균의 극한분포

모평균이 μ이고 모표준편차가 $\sigma\,(0<\sigma<+\infty)$인 모집단에서의 랜덤표본 n개로부터의 표본평균과 표본표준편차를 각각 $\overline{X_n}$, S_n이라고 할 때

$$\frac{\overline{X_n}-\mu}{S_n/\sqrt{n}}$$

를 스튜던트화(Studentized) 된 표본평균이라고 한다. 한편 중심극한정리와 <예 5.2.5>로부터

$$\frac{\overline{X_n}-\mu}{\sigma/\sqrt{n}} \xrightarrow[n\to\infty]{d} Z,\ Z\sim N(0,1)\text{이고 } \operatorname{plim}_{n\to\infty} S_n = \sigma$$

이므로 슬럿츠키의 정리로부터

$$\frac{\overline{X_n}-\mu}{S_n/\sqrt{n}} = \frac{\overline{X_n}-\mu}{\sigma/\sqrt{n}} \Big/ \frac{S_n}{\sigma} \xrightarrow[n\to\infty]{d} Z/1 = Z,\ Z\sim N(0,1)$$

특히, 모집단의 분포가 정규분포인 경우에는 스튜던트화 된 표본평균은 자유도가 $n-1$인 t 분포를 따르므로 위의 결과는 자유도가 충분히 큰 t 분포는 표준정규분포로 근사된다는 것을 뜻하며 이를 기호로 다음과 같이 나타내기도 한다.

$$t(n-1) \approx N(0,1),\ n\to\infty$$

또한 모집단의 분포가 무엇이든 양수의 분산이 정의될 수만 있으면

$$\lim_{n\to\infty} P\left(-z_{\alpha/2} < \frac{\overline{X_n}-\mu}{S_n/\sqrt{n}} \le z_{\alpha/2}\right) = 1-\alpha$$

$$\therefore P\left\{\overline{X_n} - z_{\alpha/2} S_n/\sqrt{n} \le \mu < \overline{X_n} + z_{\alpha/2} S_n/\sqrt{n}\right\} \simeq 1-\alpha,\ n\to\infty$$

이므로, 모평균 μ에 관한 $100(1-\alpha)\%$ 점근(漸近, asymptotic) 신뢰구간이 다음과 같이 주어진다.

$$\mu \in [\overline{X_n} - z_{\alpha/2} S_n/\sqrt{n},\ \overline{X_n} + z_{\alpha/2} S_n/\sqrt{n})$$

예 5.3.2 표본분산의 극한분포

모평균이 μ이고 모표준편차가 $\sigma\,(0<\sigma<+\infty)$인 모집단에서의 랜덤표본 n개로부터의 표본분산 S_n^2의 표본분포에 대하여 생각해보자. 표본평균을 $\overline{X_n}$라고 하면

$$S_n^2=\frac{1}{n-1}\sum_{i=1}^{n}[(X_i-\mu)-(\overline{X_n}-\mu)]^2=\frac{n}{n-1}\left\{\frac{1}{n}\sum_{i=1}^{n}(X_i-\mu)^2-(\overline{X_n}-\mu)^2\right\}$$

한편 $Y_i=(X_i-\mu)^2\,(i=1,\cdots,n)$이라고 하면 이들은 서로 독립이고 동일한 분포를 따르므로, 중심극한정리로부터 $\mathrm{Var}(Y_1)<+\infty$일 때

$$\sqrt{n}\left(\frac{1}{n}\sum_{i=1}^{n}Y_i-\mathrm{E}(Y_1)\right)\underset{n\to\infty}{\overset{d}{\to}}W,\ W\sim N(0,\mathrm{Var}(Y_1))$$

그런데

$$\mathrm{E}(Y_1)=\sigma^2,\ \mathrm{Var}(Y_1)=\mathrm{E}(Y_1^2)-(\mathrm{E}Y_1)^2=\mathrm{E}[(X_1-\mu)^4]-\sigma^4$$

이므로 $\mathrm{E}[(X_1-\mu)^4]<+\infty$일 때

$$\sqrt{n}\left\{\frac{1}{n}\sum_{i=1}^{n}(X_i-\mu)^2-\sigma^2\right\}\underset{n\to\infty}{\overset{d}{\to}}W,\ W\sim N(0,\mathrm{E}[(X_1-\mu)^4]-\sigma^4)$$

임을 알 수 있다.

또한 중심극한정리와 대수의 법칙으로부터

$$\sqrt{n}(\overline{X_n}-\mu)\underset{n\to\infty}{\overset{d}{\to}}Z,\ Z\sim N(0,\sigma^2),\ \operatorname*{plim}_{n\to\infty}(\overline{X_n}-\mu)=0$$

이므로 슬럿츠키의 정리와 <정리 5.2.1>로부터

$$\sqrt{n}(\overline{X_n}-\mu)(\overline{X_n}-\mu)\underset{n\to\infty}{\overset{d}{\to}}0\times Z=0,\ Z\sim N(0,\sigma^2)$$

$$\therefore\ \operatorname*{plim}_{n\to\infty}\sqrt{n}(\overline{X_n}-\mu)^2=0$$

따라서 $\mathrm{E}[(X_1-\mu)^4]<+\infty$일 때, $W\sim N(0,\mathrm{E}[(X_1-\mu)^4]-\sigma^4)$라고 하면

$$\sqrt{n}\left(\frac{1}{n}\sum_{i=1}^{n}(X_i-\overline{X_n})^2-\sigma^2\right)$$

$$=\sqrt{n}\left\{\frac{1}{n}\sum_{i=1}^{n}(X_i-\mu)^2-\sigma^2\right\}-\sqrt{n}(\overline{X_n}-\mu)^2\underset{n\to\infty}{\overset{d}{\to}}W-0=W$$

그러므로 $\mathrm{E}[(X_1-\mu)^4]<+\infty$일 때 $\rho_4=\mathrm{E}\left[\left(\frac{X_1-\mu}{\sigma}\right)^4\right]-3$이라고 하면[76]

$$\sqrt{n}(S_n^2-\sigma^2)$$
$$=\sqrt{n}\left\{\frac{1}{n}\sum_{i=1}^{n}(X_i-\overline{X})^2-\sigma^2\right\}+\frac{1}{\sqrt{n}}S_n^2\xrightarrow[n\to\infty]{d}W,\ W\sim N(0,(\rho_4+2)\sigma^4)$$

통계량의 극한분포를 구할 때 많은 경우에 <예 5.3.1>과 <예 5.3.2>에서와 같이 중심극한정리를 이용하게 된다. 이러한 경우에 흔히 <정리 5.1.2>에 주어진 다차원 확률변수에 대한 중심극한정리를 이용하게 된다. 이와 같은 다차원 확률변수에 대한 극한분포의 정의는 다음과 같다.

다차원 경우의 극한분포:

다차원 확률변수의 열 $X_n=(X_{n1},\cdots,X_{nk})^t$ $(n=1,2,\cdots)$과 $Z=(Z_1,\cdots,Z_k)^t$ 에 대하여

$$\lim_{n\to\infty}P(X_{n1}\le x_1,\cdots,X_{nk}\le x_k)=P(Z_1\le x_1,\cdots,Z_k\le x_k)^{77)}$$

가 $Z=(Z_1,\cdots,Z_k)^t$의 결합누적분포함수 $cdf_Z(x_1,\cdots,x_k)$가 연속인 모든 점 $x=(x_1,\cdots,x_k)^t$에서 성립할 때, $Z=(Z_1,\cdots,Z_k)^t$ 의 분포를 $X_n=(X_{n1},\cdots,X_{nk})^t$분포들의 극한분포 또는 점근분포라고 하며 기호로는 일차원의 경우와 마찬가지로 다음과 같이 나타낸다.

$$X_n\xrightarrow[n\to\infty]{d}Z \text{ 또는 } (X_{n1},\cdots,X_{nk})^t\xrightarrow[n\to\infty]{d}(Z_1,\cdots,Z_k)^t$$

정리 5.3.2 연속함수와 극한분포

다차원 확률변수 $X_n=(X_{n1},\cdots,X_{nk})^t$ $(n=1,2\cdots)$과 $Z=(Z_1,\cdots,Z_k)^t$에 대하여

$$(X_{n1},\cdots,X_{nk})^t\xrightarrow[n\to\infty]{d}(Z_1,\cdots,Z_k)^t$$

일 때, 연속함수 g에 대하여

$$g(X_n)\xrightarrow[n\to\infty]{d}g(Z)$$

[증명] 이 정리의 증명은 이 책의 수준을 넘으므로 생략한다.

---

76) 여기에서 정의된 ρ_4를 모집단의 첨예도(尖銳度, kurtosis)라고 하며 이는 모집단 분포가 평균 부근에 밀집되어 있는 정도를 나타내는 측도이고, 모집단의 분포가 정규분포인 경우에 첨예도는 0이다.

77) 이러한 결합확률을 간략히 $P(Z_1\le x_1,\cdots,Z_k\le x_k)=P(Z\le x)$ 로 나타내기로 한다.

예 5.3.3 이항분포와 카이제곱근사

이항분포의 정규근사로부터 $X_n \sim B(n,p)\,(0<p<1)$일 때

$$\frac{X_n - np}{\sqrt{np(1-p)}} \xrightarrow[n\to\infty]{d} Z,\ Z \sim N(0,1)$$

또한 제곱 함수는 연속함수이므로 <정리 5.3.2>로부터

$$\left(\frac{X_n - np}{\sqrt{np(1-p)}}\right)^2 \xrightarrow[n\to\infty]{d} Z^2,\ Z \sim N(0,1)$$

$$\therefore \frac{(X_n - np)^2}{np(1-p)} \xrightarrow[n\to\infty]{d} W,\ W \sim \chi^2(1)$$

한편, $X_{n1} = X_n,\ X_{n2} = n - X_n,\ p_1 = p,\ p_2 = 1-p$라고 하면

$$(X_{n1}, X_{n2})^t \sim \text{Multi}(n, (p_1, p_2)^t)$$

이고 다음 등식이 성립함을 알 수 있다.

$$\frac{(X_{n1} - np_1)^2}{np_1} + \frac{(X_{n2} - np_2)^2}{np_2} = \frac{(X_n - np)^2}{np} + \frac{(n - X_n - n(1-p))^2}{n(1-p)}$$

$$= \frac{(X_n - np)^2}{np(1-p)}$$

따라서 $(X_{n1}, X_{n2})^t \sim \text{Multi}(n, (p_1, p_2)^t)$이고

$$\sum_{j=1}^{2} \frac{(X_{nj} - np_j)^2}{np_j} \xrightarrow[n\to\infty]{d} W,\ W \sim \chi^2(1)$$

예 5.3.4 다항분포와 카이제곱근사

<예 5.3.3>을 일반화 하여

$(X_{n1}, \cdots, X_{nk})^t \sim \text{Multi}(n, (p_1, \cdots, p_k)^t)\,(p_1 + \cdots + p_k = 1,\ p_i > 0,\ i = 1, \cdots, k)$

일 때 다음과 같은 카이제곱근사가 성립하는 것을 알아보자.

$$\sum_{j=1}^{k} \frac{(X_{nj} - np_j)^2}{np_j} \xrightarrow[n\to\infty]{d} W,\ W \sim \chi^2(k-1)$$

여기에서 $X_n = (X_{n1}, \cdots, X_{nk})^t,\ p = (p_1, \cdots, p_k)^t$라고 하면 <예 5.1.2>에서와 같이 다차원 경우의 중심극한정리로부터

$$(X_n - np)/\sqrt{n} \xrightarrow[n\to\infty]{d} X,\ X \sim N_k(0, D(p_j) - pp^t)$$

이제 <정리 5.3.2>를 이용하여 이 결과를 밝히기 위하여

$$Y_{nj} = X_{nj},\ \mu_j = p_j\,(j = 1,\cdots,r),\ Y_n = (Y_{n1},\cdots,Y_{nr})^t,$$
$$\mu = (\mu_1,\cdots,\mu_r)^t,\ r = k-1$$

이라고 하고, μ_1, $\cdots$, μ_r을 대각원소로 하는 대각행렬을 $D(\mu_j)$라고 하면

$$(Y_n - n\mu)/\sqrt{n} \xrightarrow[n\to\infty]{d} Z,\ Z \sim N_r(0,\Sigma),\ \Sigma = D(\mu_j) - \mu\mu^t$$

또한 이차형식 $z^t\Sigma^{-1}z$은 연속함수이므로 <정리 5.3.2>로부터

$$\{(Y_n - n\mu)/\sqrt{n}\}^t\Sigma^{-1}\{(Y_n - n\mu)/\sqrt{n}\} \xrightarrow[n\to\infty]{d} Z^t\Sigma^{-1}Z,\ Z \sim N_r(0,\Sigma)$$

<정리 4.4.5>로부터 $Z \sim N_r(0,\Sigma)$이면 $Z^t\Sigma^{-1}Z \sim \chi^2(r)$, $r = k-1$이므로

$$\{(Y_n - n\mu)/\sqrt{n}\}^t\Sigma^{-1}\{(Y_n - n\mu)/\sqrt{n}\} \xrightarrow[n\to\infty]{d} W,\ W \sim \chi^2(k-1)$$

한편 <예 4.4.5>에서와 같이 특수한 형태의 행렬에 관한 연산[78]을 이용하여 계산하면

$$\Sigma^{-1} = (D(\mu_j) - \mu\mu^t)^{-1} = (I - D^{-1}(\mu_j)\mu\mu^t)^{-1}D^{-1}(\mu_j) = D^{-1}(\mu_j) + \frac{1}{p_k}11^t$$

이므로

$$\{(Y_n - n\mu)/\sqrt{n}\}^t\Sigma^{-1}\{(Y_n - n\mu)/\sqrt{n}\} = \sum_{j=1}^{k-1}\frac{(Y_{nj} - n\mu_j)^2}{n\mu_j} + \frac{(X_{nk} - np_k)^2}{np_k}$$
$$\therefore \sum_{j=1}^{k}\frac{(X_{nj} - np_j)^2}{np_j} \xrightarrow[n\to\infty]{d} W,\ W \sim \chi^2(k-1)$$

정리 5.3.3 일차근사를 이용한 극한분포 계산

다차원 확률변수 $X_n = (X_{n1},\cdots,X_{nk})^t\,(n = 1,2,\cdots)$, $Z = (Z_1,\cdots,Z_k)^t$와 벡터 $\theta = (\theta_1,\cdots,\theta_k)^t$에 대하여

$$\sqrt{n}\,(X_n - \theta) \xrightarrow[n\to\infty]{d} Z$$

이고 함수 $g(\theta)$의 일차편도함수[79] $\dot{g}(\theta)$가 연속함수이면 다음이 성립한다.

$$\sqrt{n}\,(g(X_n) - g(\theta)) \xrightarrow[n\to\infty]{d} (\dot{g}(\theta))^t Z$$

---

78) (부록 Ⅱ 참조) 벡터 a, b에 대하여 $1 + b^t a \neq 0$이면

$$(I + ab^t)^{-1} = I + cab^t,\ c = -1/(1 + b^t a)$$

79) 일차원 경우에는 $\dot{g}(\theta) = dg(\theta)/d\theta$, 다차원 경우에는 $\dot{g}(\theta) = (\partial g(\theta)/\partial\theta_1,\cdots,\partial g(\theta)/\partial\theta_k)^t$

[증명] 다차원의 경우도 일차원 경우와 마찬가지이므로 일차원의 경우만 증명하기로 한다.

함수 $g(\theta)$가 미분가능하므로 다음을 만족하는 $r(x)(=r_\theta(x))$가 존재한다.

$$g(x)=g(\theta)+\{\dot{g}(\theta)+r(x)\}(x-\theta),\ r(x)\underset{x\to\theta}{\to}0$$

여기에서 잉여항의 $r(x)$에 대한 조건으로부터 다음이 성립하는 것을 알 수 있다.

$$\forall\epsilon>0,\ \exists\delta>0:(|x-\theta|<\delta\Rightarrow|r(x)|<\epsilon)$$

따라서 임의의 양수 ϵ에 대하여 이러한 양수 δ를 선택하면

$$(|\mathrm{X}_n-\theta|<\delta)\subseteq(|r(\mathrm{X}_n)|<\epsilon),\ 즉\ (|r(\mathrm{X}_n)|\geq\epsilon)\subseteq(|\mathrm{X}_n-\theta|\geq\delta)$$

$$\therefore\ \mathrm{P}(|r(\mathrm{X}_n)|\geq\epsilon)\leq\mathrm{P}(|\mathrm{X}_n-\theta|\geq\delta)$$

한편 $\sqrt{n}(\mathrm{X}_n-\theta)\underset{n\to\infty}{\overset{d}{\to}}\mathrm{Z}$이므로 슬럿츠키의 정리와 <정리 5.2.1>로부터

$$\mathrm{X}_n-\theta=\frac{1}{\sqrt{n}}\times\sqrt{n}(\mathrm{X}_n-\theta)\underset{n\to\infty}{\overset{d}{\to}}0\times\mathrm{Z}=0$$

$$\therefore\ \operatorname*{plim}_{n\to\infty}\mathrm{X}_n=\theta,\ 즉\ \lim_{n\to\infty}\mathrm{P}(|\mathrm{X}_n-\theta|\geq\delta)=0$$

$$\therefore\ 0\leq\lim_{n\to\infty}\mathrm{P}(|r(\mathrm{X}_n)|\geq\epsilon)\leq\lim_{n\to\infty}\mathrm{P}(|\mathrm{X}_n-\theta|\geq\delta)=0,\ 즉\ \operatorname*{plim}_{n\to\infty}r(\mathrm{X}_n)=0$$

따라서

$$\sqrt{n}(g(\mathrm{X}_n)-g(\theta))=(\dot{g}(\theta)+r(\mathrm{X}_n))\sqrt{n}(\mathrm{X}_n-\theta),\ \operatorname*{plim}_{n\to\infty}(\dot{g}(\theta)+r(\mathrm{X}_n))=\dot{g}(\theta)$$

그러므로 슬럿츠키의 정리로부터 $\sqrt{n}(g(\mathrm{X}_n)-g(\theta))\underset{n\to\infty}{\overset{d}{\to}}\dot{g}(\theta)\mathrm{Z}$

예 5.3.5 표본표준편차의 극한분포

모평균이 μ이고 모표준편차가 $\sigma\ (0<\sigma<+\infty)$인 모집단에서의 랜덤표본 n개로부터의 표본분산을 S_n^2이라고 할 때, $\mathrm{E}[(\mathrm{X}_1-\mu)^4]<+\infty$라는 조건하에서 다음과 같이 표본분산의 극한분포가 주어지는 것은 <예 5.3.2>에서 알아보았다.

$$\sqrt{n}(\mathrm{S}_n^2-\sigma^2)\underset{n\to\infty}{\overset{d}{\to}}\mathrm{W},\ \mathrm{W}\sim\mathrm{N}(0,(\rho_4+2)\sigma^4),\ \rho_4=\mathrm{E}\left[\left(\frac{\mathrm{X}_1-\mu}{\sigma}\right)^4\right]-3$$

표본표준편차 S_n은 표본분산의 제곱근 $\sqrt{\mathrm{S}_n^2}$이고 제곱근함수 $g(x)=\sqrt{x}$의 도함수가 $\dot{g}(x)=1/(2\sqrt{x})$이므로, <정리 5.3.3>으로부터 $\mathrm{E}[(\mathrm{X}_1-\mu)^4]<+\infty$라는 조건하에서

$$\sqrt{n}\,(\sqrt{S_n^2}-\sqrt{\sigma^2}) \xrightarrow[n\to\infty]{d} \frac{1}{2\sqrt{\sigma^2}}\,W,\ W\sim N(0,(\rho_4+2)\sigma^4)$$

$$\therefore\ \sqrt{n}\,(S_n-\sigma) \xrightarrow[n\to\infty]{d} Z,\ Z\sim N(0,(\rho_4+2)\sigma^2/4)$$

예 5.3.6 표본상관계수의 극한분포

모평균이 각각 μ_1, μ_2이고 모분산이 각각 σ_1^2, $\sigma_2^2(0<\sigma_1<+\infty,\ 0<\sigma_2<+\infty)$이며 모상관계수가 $\rho\,(-1<\rho<1)$인 이변량의 모집단에서의 랜덤표본을 $(X_1,Y_1)^t,\ \cdots,\ (X_n,Y_n)^t\,(n>2)$이라고 할 때, 모상관계수의 추측에 사용되는 표본상관계수(標本相關係數, sample correlation coefficient)는 다음과 같이 정의된다.

$$\hat{\rho}_n=\frac{\sum_{i=1}^{n}(X_i-\overline{X})(Y_i-\overline{Y})}{\sqrt{\sum_{i=1}^{n}(X_i-\overline{X})^2}\sqrt{\sum_{i=1}^{n}(Y_i-\overline{Y})^2}}$$

이러한 표본상관계수의 표현에서 X_i, Y_i 대신 각각 $\frac{X_i-\mu_1}{\sigma_1}$, $\frac{Y_i-\mu_2}{\sigma_2}$를 대입하여도 그 값에 변화가 없는 것을 알 수 있다. 따라서 표본상관계수의 표본분포를 구할 때에는

$$\mu_1=0,\ \mu_2=0,\ \sigma_1=1,\ \sigma_2=1$$

이라고 가정해도 좋다. 또한 간략한 표현을 위하여

$$\overline{X}_n=\sum_{i=1}^{n}X_i/n,\ \overline{Y}_n=\sum_{i=1}^{n}Y_i/n,\ \overline{(XY)}_n=\sum_{i=1}^{n}X_iY_i/n$$

$$\overline{(X^2)}_n=\sum_{i=1}^{n}X_i^2/n,\ \overline{(Y^2)}_n=\sum_{i=1}^{n}Y_i^2/n$$

라고 하면, 함수 $g(t_1,t_2,t_3,t_4,t_5)=(t_3-t_1t_2)(t_4-t_1^2)^{-1/2}(t_5-t_2^2)^{-1/2}$에 대하여

$$\hat{\rho}_n=\frac{\overline{(XY)}_n-\overline{X}_n\overline{Y}_n}{\sqrt{\overline{(X^2)}_n-(\overline{X}_n)^2}\sqrt{\overline{(Y^2)}_n-(\overline{Y}_n)^2}}=g(\overline{X}_n,\overline{Y}_n,\overline{(XY)}_n,\overline{(X^2)}_n,\overline{(Y^2)}_n)$$

와 같이 표본상관계수를 $(X_i,Y_i,X_iY_i,X_i^2,Y_i^2)^t\,(i=1,\cdots,n)$의 평균의 함수로 나타낼 수 있다.

또한 $Z_i=(X_i,Y_i,X_iY_i,X_i^2,Y_i^2)^t\,(i=1,\cdots,n)$이라고 하면 $Z_i\,(i=1,\cdots,n)$는

서로 독립이고 동일한 분포를 따르는 5차원의 확률변수이므로 그 분산행렬이 존재할 때 다음이 성립한다.

$$\sqrt{n}\left(\frac{1}{n}\sum_{i=1}^{n} Z_i - E(Z_1)\right) \xrightarrow[n\to\infty]{d} V,\ V \sim N_5(0, Var(Z_1))$$

한편 추가된 가정으로부터

$$E(Z_1) = (0,0,\rho,1,1)^t,\ \rho = g(0,0,\rho,1,1) = g(E(Z_1))$$

이고 함수 $g(t_1,t_2,t_3,t_4,t_5) = (t_3 - t_1t_2)(t_4 - t_1^2)^{-1/2}(t_5 - t_2^2)^{-1/2}$의 편도함수들이 연속이므로, <정리 5.3.3>으로부터 분산행렬 $Var(Z_1)$이 존재할 때[80] $\theta = E(Z_1) = (0,0,\rho,1,1)^t$라고 하면

$$\sqrt{n}(\hat{\rho}_n - \rho) = \sqrt{n}\left(g\left(\frac{1}{n}\sum_{i=1}^{n} Z_i\right) - g(\theta)\right) \xrightarrow[n\to\infty]{d} (\dot{g}(\theta))^t V,\ V \sim N_5(0, Var(Z_1))$$

여기에서 함수 g의 일차편도함수를 구하여 계산하면

$$\dot{g}(\theta) = \dot{g}(0,0,\rho,1,1) = (0, 0, 1, -\rho/2, -\rho/2)^t$$

이고

$$(\dot{g}(\theta))^t V \sim N(0, (\dot{g}(\theta))^t Var(Z_1)(\dot{g}(\theta))) = N(0, Var[(\dot{g}(\theta))^t Z_1])$$

$$(\dot{g}(\theta))^t Z_1 = X_1Y_1 - \frac{\rho}{2}X_1^2 - \frac{\rho}{2}Y_1^2$$

이므로, $E(X_1^4) < +\infty$, $E(Y_1^4) < +\infty$일 때

$$\sqrt{n}(\hat{\rho}_n - \rho) \xrightarrow[n\to\infty]{d} W,\ W \sim N\left(0, Var\left(X_1Y_1 - \frac{\rho}{2}X_1^2 - \frac{\rho}{2}Y_1^2\right)\right)$$

예 5.3.7 표본상관계수와 분산안정변환

<예 5.3.6>에서 이변량 정규분포 $N(\mu_1,\mu_2;\sigma_1^2,\sigma_2^2,\rho)$ $(\sigma_1 > 0,\ \sigma_2 > 0,\ -1 < \rho < 1)$가 모집단의 분포일 때 표본상관계수의 극한분포에 대하여 알아보자. 이 경우에는 <예 4.4.3>으로부터

$$Y_1 - \rho X_{1|X_1 = x_1} \sim N(0, 1-\rho^2)$$

으로서 조건부분포가 조건 $X_1 = x_1$에 의존하지 않으므로 $Y_1 - \rho X_1$은 X_1과 서로 독립이다. 따라서 $\mu_1 = \mu_2 = 0, \sigma_1 = \sigma_2 = 1$ 인 경우에

---

80) $Z_1 = (X_1, Y_1, X_1Y_1, X_1^2, Y_1^2)^t$이므로 <정리 1.6.2>로부터 $E(X_1^4) < +\infty$, $E(Y_1^4) < +\infty$이면 Z_1의 분산행렬이 존재하는 것을 알 수 있다.

$$T = \frac{Y_1 - \rho X_1}{\sqrt{1-\rho^2}}$$

이라고 하면, X_1과 T는 서로 독립이고 각각 표준정규분포 $N(0,1)$을 따른다.

한편 $Y_1 = \rho X_1 + \sqrt{1-\rho^2}\,T$를 대입하여 정리하면

$$X_1 Y_1 - \frac{\rho}{2}X_1^2 - \frac{\rho}{2}Y_1^2 = \frac{\rho}{2}(1-\rho^2)X_1^2 + (1-\rho^2)^{3/2}X_1 T - \frac{\rho}{2}(1-\rho^2)T^2$$

이고, 이 표현을 이용하여 계산하면 $\mu_1 = \mu_2 = 0, \sigma_1 = \sigma_2 = 1$인 경우에

$$\mathrm{Var}\left(X_1 Y_1 - \frac{\rho}{2}X_1^2 - \frac{\rho}{2}Y_1^2\right) = (1-\rho^2)^2$$

$$\therefore \sqrt{n}(\hat{\rho}_n - \rho) \xrightarrow[n\to\infty]{d} W,\ W \sim N(0, (1-\rho^2)^2)$$

여기에서 표본상관계수 $\hat{\rho}_n$의 함수 $g(\hat{\rho}_n)$의 극한분포를 구해보면 <정리 5.3.3>으로부터

$$\sqrt{n}(g(\hat{\rho}_n) - g(\rho)) \xrightarrow[n\to\infty]{d} \dot{g}(\rho)W,\ \dot{g}(\rho)W \sim N(0, [\dot{g}(\rho)]^2(1-\rho^2)^2)$$

이 때 극한분포의 분산을 ρ에 의존하지 않게 하는 $g(\hat{\rho}_n)$을 $\hat{\rho}_n$의 분산안정변환(分散安定變換, variance syabilizing transformation)이라고 한다. 특히

$$g(\hat{\rho}_n) = \frac{1}{2}\log\frac{1+\hat{\rho}_n}{1-\hat{\rho}_n}$$

은 피셔의 변환이라고 불리우며 $[\dot{g}(\rho)]^2(1-\rho^2)^2 = 1$이 되어 극한분포가 $N(0,1)$이 된다. 즉

$$\sqrt{n}(g(\hat{\rho}_n) - g(\rho)) \xrightarrow[n\to\infty]{d} Z,\ Z \sim N(0,1)$$

예 5.3.8 표본분위수의 극한분포

<예 5.2.7>에서는 표본분위수 $X_{(r_n)}(r_n \underset{n\to\infty}{\sim} \alpha n, 0 < \alpha < 1)$의 확률수렴에 대하여 알아보았다. 여기에서는 <예 5.2.7>에서의 조건이 만족될 때에 표본분위수의 극한분포에 대하여 생각해보자.

모집단의 누적분포함수의 역함수를 F^{-1}이라 하고 $h(y) = F^{-1}(1-e^{-y})(y>0)$라고 하면 표본분위수의 분포는 <정리 4.3.4>로부터

$$X_{(r_n)} \overset{d}{\equiv} h\left(\frac{1}{n}Z_1 + \cdots + \frac{1}{n-r_n+1}Z_{r_n}\right),\ Z_i \overset{iid}{\sim} \mathrm{Exp}(1)\ (i = 1, \cdots, n)$$

한편

$$Y_n = \frac{1}{n}Z_1 + \cdots + \frac{1}{n-r_n+1}Z_{r_n}$$

이라고 하면 그 평균과 분산이 다음과 같이 근사되는 것을 알고 있다.

$$E(Y_n) = \frac{1}{n} + \cdots + \frac{1}{n-r_n+1} \underset{n\to\infty}{\sim} -\log(1-\alpha)$$

$$Var(Y_n) = \frac{1}{n^2} + \cdots + \frac{1}{(n-r_n+1)^2} \underset{n\to\infty}{\sim} \frac{1}{n}\frac{\alpha}{1-\alpha}$$

이를 이용하여

$$W_n = \sqrt{n}\,\frac{Y_n - (-\log(1-\alpha))}{\sqrt{\alpha/(1-\alpha)}}$$

의 적률생성함수를 근사해보면[81] 다음이 성립하는 것을 알 수 있다.

$$\lim_{n\to\infty} mgf_{W_n}(t) = \exp\left(\frac{1}{2}t^2\right) = mgf_W(t)\ ,\ W \sim N(0,1)$$

$$\therefore\ W_n \underset{n\to\infty}{\overset{d}{\to}} W,\ W \sim N(0,1)$$

$$\therefore\ \sqrt{n}(Y_n - (-\log(1-\alpha))) \underset{n\to\infty}{\overset{d}{\to}} \sqrt{\alpha/(1-\alpha)}\,W$$

따라서 <정리 5.3.3>으로부터 함수 h가 미분가능할 때[82]

$$\sqrt{n}\{h(Y_n) - h(-\log(1-\alpha))\} \underset{n\to\infty}{\overset{d}{\to}} \dot{h}(-\log(1-\alpha))\sqrt{\alpha/(1-\alpha)}\,W$$

그런데 이러한 조건하에서 $\dot{h}(-\log(1-\alpha)) = (1-\alpha)/f(F^{-1}(\alpha))$, $f = \dot{F}$ 이므로

$$\sqrt{n}\left\{X_{(r_n)} - F^{-1}(\alpha)\right\} \underset{n\to\infty}{\overset{d}{\to}} Z,\ Z \sim N(0, \alpha(1-\alpha)/[f(F^{-1}(\alpha))]^2)$$

5.4 모의실험을 이용한 근사

이 절에서는 랜덤표본의 관측값을 이용하여 통계량의 분포를 근사하거나 그 특성을 연구하는 방법을 알아보기로 한다. 특정한 분포를 따르는 확률변수의 관측값을 흔히 난수(亂數, random number)라고 부르고, 최근에는 이러한 난수들을 생성할 수 있는 기능이 많은 통계패키지에 주어져 있다.

---

81) 연습문제 (5.15)에 이러한 적률생성함수를 근사하는 과정이 소개되어 있다.

82) 확률밀도함수가 $f(x) = dF(x)/dx$로 주어지고 $f(F^{-1}(\alpha)) > 0$이면 이 조건이 만족된다.

이러한 난수의 생성에 기본이 되는 것은 균등분포 $\mathrm{U}(0,1)$에서의 관측값으로서 이를 균등난수(均等亂數, uniform random number)라고 하며, 부록 Ⅲ에서는 패키지 R에서 균등난수를 생성하는 기능이 소개되어 있다. 또한 이러한 균등난수로부터 확률적분변환에 관한 <정리 4.3.3>을 이용하여 임의의 분포로부터의 난수를 생성할 수 있다.

예 5.4.1 로지스틱분포에서의 난수 생성

<예 4.1.5>에서 소개된 로지스틱분포 $\mathrm{L}(0,1)$의 확률밀도함수와 누적분포함수는 각각

$$f(z)=\frac{e^z}{(1+e^z)^2},\ \mathrm{F}(z)=1-\frac{1}{(1+e^z)},\ -\infty<z<+\infty$$

로 주어진다. 이로부터 누적분포함수의 역함수는 다음과 같이 주어지는 것을 알 수 있다.

$$\mathrm{F}^{-1}(u)=\log\frac{u}{1-u}$$

따라서 <정리 4.3.3>으로부터 균등분포 $\mathrm{U}(0,1)$을 따르는 확률변수 U에 대하여

$$\mathrm{Z}=\log\frac{\mathrm{U}}{1-\mathrm{U}}\sim\mathrm{L}(0,1)$$

임을 알 수 있고, 이를 이용하여 로지스틱분포 $\mathrm{L}(0,1)$에서의 난수를 구할 수 있다. 또한

$$\sigma\mathrm{Z}+\mu=\sigma\log\frac{\mathrm{U}}{1-\mathrm{U}}+\mu\sim\mathrm{L}(\mu,\sigma)$$

임을 이용하여 일반적인 로지스틱분포 $\mathrm{L}(\mu,\sigma)$에서의 난수를 생성할 수 있다.

<예 5.4.1>에서와 마찬가지로, 균등분포 $\mathrm{U}(0,1)$을 따르는 확률변수 U에 대하여

$$-\log(1-\mathrm{U})\sim\mathrm{Exp}(1),\ \sigma\{-\log(1-\mathrm{U})\}\sim\mathrm{Exp}(\sigma)$$

임을 이용하여 지수분포 $\mathrm{Exp}(\sigma)$에서의 난수를 생성할 수 있고, 표준정규분포의 누적분포함수의 역함수 $\Phi^{-1}(u)$에 대하여

$$\Phi^{-1}(\mathrm{U})\sim\mathrm{N}(0,1),\ \sigma\Phi^{-1}(\mathrm{U})+\mu\sim\mathrm{N}(\mu,\sigma^2)$$

임을 이용하여 정규분포 $\mathrm{N}(\mu,\sigma^2)$에서의 난수를 생성할 수 있다. 이러한 방법을 이용하여 여러 가지 분포에서의 난수를 생성하는 기능이 부록 Ⅲ에 소개된 R에 패키지화 되어 있다.

정리 5.4.1 **난수를 이용한 정적분의 근사**

서로 독립이고 균등분포 $\mathrm{U}(0,1)$을 따르는 $\mathrm{U}_1, \cdots, \mathrm{U}_n$과 구간 $[a,b]$에서 연속인 함수 $g(x)$에 대하여 다음이 성립한다.

$$\mathrm{X}_i = (b-a)\mathrm{U}_i + a \overset{iid}{\sim} \mathrm{U}(a,b)(i=1,\cdots,n)$$

$$\operatorname{plim}_{n\to\infty} \frac{b-a}{n}\sum_{i=1}^{n} g(\mathrm{X}_i) = \int_a^b g(x)dx$$

[증명] $\mathrm{X}_1, \cdots, \mathrm{X}_n$이 서로 독립이고 확률밀도함수가

$$pdf_{\mathrm{X}_1}(x) = \frac{1}{b-a}\mathrm{I}_{(a,b)}(x)$$

로 주어지는 균등분포 $\mathrm{U}(a,b)$를 따르고

$$\mathrm{E}[g(\mathrm{X}_1)] = \frac{1}{(b-a)}\int_a^b g(x)\,dx$$

로 주어진다. 따라서 대수의 법칙으로부터

$$\operatorname{plim}_{n\to\infty} \frac{b-a}{n}\sum_{i=1}^{n} g(\mathrm{X}_i) = (b-a)\mathrm{E}[g(\mathrm{X}_1)] = \int_a^b g(x)dx$$

<정리 5.4.1>에서의 확률수렴을 이용하여 정적분의 근사값을 구하는 방법을 몬테칼로적분(Monte Carlo integration)이라고 한다. 즉 서로 독립적으로 생성된 균등난수 $u_1, \cdots, u_n$을 이용하여

$$y_i = (b-a)g((b-a)u_i + a)(i=1,\cdots,n)$$

$$\int_a^b g(x)dx \simeq \frac{1}{n}\sum_{i=1}^{n} y_i,\ n\to\infty$$

와 같이 정적분의 근사값을 구하는 방법을 몬테칼로적분이라고 한다. 이는

$$\mathrm{Y}_i = (b-a)g((b-a)\mathrm{U}_i + a)(i=1,\cdots,n)$$

의 관측값을 이용하여 $\mathrm{E}(\mathrm{Y}_1)$에 대한 추측을 하는 것이므로 $\mathrm{E}(\mathrm{Y}_1)$에 대한 점근신뢰구간으로 이러한 근사의 정밀도를 나타낼 수 있다.

예 5.4.2

적분 공식을 이용하면 정적분 $\int_1^3 x^2 dx$의 값이 26/3임은 잘 알고 있다. 한편 독립적으로 생성된 U(0,1)에서의 난수 $u_1, \cdots, u_n$에 대하여

$$x_i = 2u_i + 1,\ y_i = 2x_i^2\ (i = 1, \cdots, n)$$

이라고 하여

$$\int_1^3 x^2 dx \simeq \frac{2}{n}\sum_{i=1}^{n} x_i^2 = \frac{1}{n}\sum_{i=1}^{n} y_i$$

와 같이 정적분의 근사값을 구할 수 있다.

R 패키지를 이용하여 생성된 난수들을 이용하여 이 정적분의 근사값과 95% 점근신뢰구간을 구해보면 다음과 같이 주어진다. 이 결과에서 볼 수 있듯이 난수의 개수 n이 커질수록 이러한 근사의 정밀도가 좋아진다.

표 5.4.1 몬테칼로적분에 의한 정적분 $\int_1^3 x^2 dx\ (=8.666\cdots)$의 근사값과 95% 오차한계

n	100	1000	10000	100000
$\bar{y}$	8.7612	8.5633	8.6515	8.6473
$\bar{y} - 1.96 s_y/\sqrt{n}$	7.8241	8.2728	8.5604	8.6185
$\bar{y} + 1.96 s_y/\sqrt{n}$	9.6983	8.8538	8.7426	8.6762

예 5.4.3 로지스틱분포의 분산

로지스틱분포 L(0,1)은 $x = 0$에 관해 대칭인 분포로서 그 분산은[83]

$$\int_{-\infty}^{+\infty} x^2 \frac{e^x}{(1+e^x)^2} dx = \frac{\pi^2}{3}$$

임이 알려져 있다. 한편 <예 5.4.1>로부터 균등분포 U(0,1)을 따르는 확률변수 U에 대하여

$$\mathrm{X} = \log\frac{\mathrm{U}}{1-\mathrm{U}} \sim \mathrm{L}(0,1)$$

---

83) 부분적분을 이용하고 무한급수로 나타내어 적분하면

$$\int_{-\infty}^{+\infty} x^2 \frac{e^x}{(1+e^x)^2} dx = 4\int_0^{+\infty} \frac{e^{-x}}{1+e^{-x}} x\, dx = 4\int_0^{+\infty} \sum_{n=1}^{\infty} (-e^{-x})^{n-1} e^{-x} x\, dx = 4\sum_{n=1}^{\infty} \frac{(-1)^{n-1}}{n^2}$$

한편 후리에급수를 이용한 다음의 항등식에서 $x = 0$을 대입하면 위의 무한급수의 값을 얻을 수 있다.

$$x^2 = \frac{1}{3}\pi^2 + 4\sum_{n=1}^{\infty} \frac{(-1)^n}{n^2} \cos(nx)\ (-\pi \le x \le \pi)$$

따라서 독립적으로 생성된 $\mathrm{U}(0,1)$에서의 난수 $u_1, \cdots, u_n$에 대하여

$$x_i = \log \frac{u_i}{1-u_i},\ y_i = x_i^2\ (i=1,\cdots,n)$$

이라고 하여 다음과 같이 로지스틱분포 $\mathrm{L}(0,1)$의 분산의 근사값을 구할 수 있다.

$$\int_{-\infty}^{+\infty} x^2 \frac{e^x}{(1+e^x)^2} dx = \mathrm{E}(\mathrm{X}^2) \simeq \frac{1}{n}\sum_{i=1}^{n} x_i^2 = \frac{1}{n}\sum_{i=1}^{n} y_i$$

R 패키지를 이용하여 생성된 난수들을 이용하여 이 정적분의 근사값과 95% 점근신뢰구간을 구해보면 다음과 같이 주어진다.

표 5.4.2 로지스틱분포 $\mathrm{L}(0,1)$ 의 분산 $\pi^2/3(=3.289\cdots)$의 근사값과 95% 오차한계

n	100	1000	10000	100000
$\bar{y}$	2.9775	3.3375	3.3201	3.2949
$\bar{y} - 1.96 s_y/\sqrt{n}$	2.0043	2.9799	3.2034	3.2584
$\bar{y} + 1.96 s_y/\sqrt{n}$	3.9506	3.6951	3.4369	3.3313

예 5.4.4 표본비율의 극한분포

모비율이 $p\,(0<p<1)$인 베르누이시행을 독립적으로 n번 관측한 결과를 $\mathrm{X}_1, \cdots, \mathrm{X}_n$이라고 할 때, 대수의 법칙과 중심극한정리로부터 표본비율 $\hat{p_n} = (\mathrm{X}_1 + \cdots + \mathrm{X}_n)/n$에 대하여 다음이 성립하는 것을 알고 있다.

$$\mathrm{p}\lim_{n\to\infty} \hat{p_n} = p,\ \frac{\hat{p_n} - p}{\sqrt{p(1-p)/n}} \xrightarrow[n\to\infty]{d} \mathrm{Z},\ \mathrm{Z} \sim \mathrm{N}(0,1)$$

따라서 슬럿츠키의 정리와 <정리 5.3.2>로부터 $\dfrac{\hat{p_n} - p}{\sqrt{\hat{p_n}(1-\hat{p_n})/n}} \xrightarrow[n\to\infty]{d} \mathrm{Z}$, $\mathrm{Z} \sim \mathrm{N}(0,1)$이므로

$$\lim_{n\to\infty} \mathrm{P}\left(-z_{\alpha/2} \le \frac{\hat{p_n} - p}{\sqrt{\hat{p_n}(1-\hat{p_n})/n}} \le z_{\alpha/2} \right) = 1-\alpha$$

$$\therefore \lim_{n\to\infty} \mathrm{P}\left\{ \hat{p_n} - z_{\alpha/2}\sqrt{\hat{p_n}(1-\hat{p_n})/n} \le p \le \hat{p_n} + z_{\alpha/2}\sqrt{\hat{p_n}(1-\hat{p_n})/n} \right\} = 1-\alpha$$

이로부터 모비율 p에 관한 $100(1-\alpha)\%$ 점근(漸近, asymptotic)신뢰구간을 다음과 같이 나타낼 수 있다.

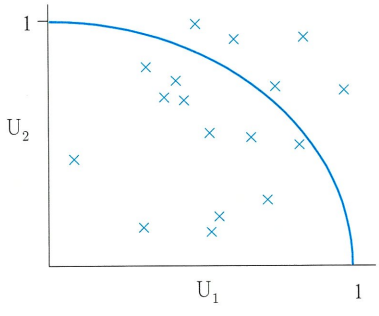
$$p \in \left[\hat{p_n} - z_{\alpha/2}\sqrt{\hat{p_n}(1-\hat{p_n})/n},\ \hat{p_n} + z_{\alpha/2}\sqrt{\hat{p_n}(1-\hat{p_n})/n} \right]$$

예 5.4.5 표본비율의 극한분포를 이용한 원주율 π의 근사

서로 독립이고 균등분포 $U(0,1)$을 따르는 두 확률변수 U_1, U_2에 대하여 이들을 좌표로 하는 점 (U_1, U_2)을 관측한다는 것은 각 변의 길이가 1인 정사각형 내에 한 점을 랜덤하게 떨어뜨리는 것으로 생각할 수 있다. 이 실험에서 떨어뜨린 점이 사분원 내에 떨어질 확률은

$$P(U_1^2 + U_2^2 \le 1) = \pi/4$$

그림 5.4.1 랜덤하게 떨어뜨린 점들 (u_{i1}, u_{i2})



이제 이러한 실험을 독립적으로 반복하여 랜덤하게 떨어뜨린 점들이 사분원 내에 떨어지는 상대도수가 이 사건의 확률 $\pi/4$에 가까워진다는 것이 대수의 법칙의 뜻이다. 따라서 독립적으로 생성된 $U(0,1)$에서의 난수 $u_{11}, u_{12}; \cdots ; u_{n1}, u_{n2}$에 대하여

$$x_i = u_{i1}^2 + u_{i2}^2 \quad (i = 1, \cdots, n)$$

이라고 하면 표본비율의 관측값

$$\hat{p_n} = \frac{1}{n} \sum_{i=1}^{n} I_{(x_i \le 1)}$$

은 확률 $p = P(U_1^2 + U_2^2 \le 1) = \pi/4$의 근사값이며 $4\hat{p_n}$을 $4p = \pi$의 근사값으로 사용할 수 있다. 또한 <예 5.4.4>로부터 $4p$에 관한 점근신뢰구간으로 근사의 정밀도를 나타낼 수 있다. R 패키지를 이용하여 생성된 난수들을 이용하여 $4p = \pi$의 근사값과 95% 점근신뢰구간을 구해보면 다음과 같이 주어진다.

표 5.4.3 $4p = \pi (= 3.14159\cdots)$의 근사값과 95% 오차한계

n	100	1000	10000	100000
$4\hat{p_n}$	3.3600	3.1320	3.1344	3.1452
$4\hat{p_n} - 4 \times 1.96\sqrt{\hat{p_n}(1-\hat{p_n})/n}$	3.0755	3.0308	3.1024	3.1351
$4\hat{p_n} + 4 \times 1.96\sqrt{\hat{p_n}(1-\hat{p_n})/n}$	3.6445	3.2331	3.1664	3.1552

연습문제

5.1 확률변수 X가 자유도 32인 카이제곱분포 $\chi^2(32)$를 따를 때 중심극한정리를 이용하여 확률 $P(20 < X < 40)$의 근사값을 구하고, R을 이용하여 구한 값과 비교하여라.

5.2 확률변수 X가 포아송분포 Poisson(25)를 따를 때 중심극한정리를 이용하여 다음 확률의 근사값을 구하고, R을 이용하여 구한 값과 비교하여라.

(a) $P(19 < X \leq 33)$ (b) $P(19.5 < X < 33.5)$

5.3 확률밀도함수가

$$f(x;\theta) = e^{-(x-\theta)} I_{(\theta, +\infty)}(x) \quad (\theta\text{는 실수})$$

인 모집단으로부터의 랜덤표본 $X_1, \cdots, X_n$에 대하여 $Y_n = \min_{1 \leq i \leq n} X_i$이라고 할 때

$$\operatorname{plim}_{n \to \infty} Y_n = \theta$$

임을 밝혀라.

5.4 베타분포 Beta$(1, \alpha)$로부터의 랜덤표본 $X_1, \cdots, X_n$에 대하여 $Y_n = \max_{1 \leq i \leq n} X_i$ 이라고 할 때 $n^{1/\alpha}(1 - Y_n)$의 극한분포를 구하여라.

5.5 확률밀도함수가

$$f(x) = \alpha x^{-\alpha - 1} I_{[1, \infty)}(x)$$

인 모집단으로부터의 랜덤표본 $X_1, \cdots, X_n$에 대하여 $Y_n = \max_{1 \leq i \leq n} X_i$이라고 할 때 $n^{-1/\alpha} Y_n$의 극한분포를 구하여라.

5.6 표준지수분포 Exp(1)로부터의 랜덤표본 $X_1, \cdots, X_n$에 대하여 $Y_n = \max_{1 \leq i \leq n} X_i$ 이라고 할 때 $Y_n - \log n$의 극한분포를 구하여라.

5.7 베타분포 $\mathrm{Beta}(\alpha,1)(\alpha>0)$로부터의 랜덤표본 $X_1,\cdots,X_n$에 대하여 $Y_n=\min_{1\le i\le n} X_i$이라고 할 때 $n^r Y_n(r>0)$의 극한분포가 존재하기 위한 r의 값을 구하고, 그 극한분포를 구하여라.

5.8 균등분포 $U(0,1)$로부터의 랜덤표본 $U_1,\cdots,U_n$에 대하여

$$X_n=\min_{1\le i\le n} U_i,\ Y_n=\max_{1\le i\le n} U_i,\ R_n=Y_n-X_n$$

이라고 할 때 다음에 답하여라.

(a) $\operatorname{plim}_{n\to\infty}(X_n,Y_n)^t=(0,1)^t$임을 밝혀라.

(b) $n(1-R_n)$의 극한분포를 구하여라.

5.9 확률변수 X_n과 Z에 대하여

$$X_n \xrightarrow[n\to\infty]{d} Z$$

이고, Z의 누적분포함수가 모든 실수에서 연속인 함수일 때 다음이 성립함을 밝혀라.[84]

$$\lim_{n\to\infty}\sup_x |P(X_n\le x)-P(Z\le x)|=0$$

5.10 확률변수의 열 $X_n(n=1,2,\cdots)$에 대하여

$$\lim_{k\to\infty}\sup_n P(|X_n|>k)=0$$

이 성립하면 $X_n(n=1,2,\cdots)$이 확률적으로 유계(bounded in probability)라고 하고 기호로는

$$X_n=O_P(1),\ n\to\infty$$

로 나타낸다. 한편 $\operatorname{plim}_{n\to\infty} Z_n=0$인 $Z_n(n=1,2,\cdots)$에 대하여는

$$Z_n=o_P(1),\ n\to\infty$$

와 같이 나타낸다. 이제

$$X_n=O_P(1),\ Y_n=O_P(1),\ Z_n=o_P(1),\ n\to\infty$$

일 때 다음이 성립함을 밝혀라.

---

84) 이러한 균등수렴의 결과로부터 $P(X_n\le x_n)\simeq P(Z\le x_n)$과 같이 n에 의존하는 값 x_n까지의 누적확률의 근사계산이 가능한 것이다.

(a) $X_n + Y_n = O_P(1),\ n \to \infty$ (b) $X_n Y_n = O_P(1),\ n \to \infty$

(c) $Z_n X_n = o_P(1),\ n \to \infty$ (d) $Z_n = O_P(1),\ n \to \infty$

5.11 확률변수 X_n과 Z의 누적분포함수가 모든 실수에서 연속인 경우에

$$X_n \underset{n \to \infty}{\overset{d}{\to}} Z$$

이면 $X_n = O_P(1),\ n \to \infty$ 임을 밝혀라.

5.12 포아송분포 Poisson(λ)로부터의 랜덤표본 $X_1, \cdots, X_n$을 이용한 표본평균 $\overline{X_n}$에 대하여

$$\sqrt{n}(g(\overline{X_n}) - g(\lambda)) \underset{n \to \infty}{\overset{d}{\to}} Z,\ Z \sim N(0,1)$$

가 성립하는 분산안정변환 g를 구하고, 이 결과를 이용하여 λ에 관한 점근신뢰구간을 구하는 방법을 설명하여라.

5.13 베르누이분포 Bernoulli(p)로부터의 랜덤표본 $X_1, \cdots, X_n$을 이용한 표본비율 $\hat{p_n} = \sum_{i=1}^{n} X_i / n$에 대하여

$$\sqrt{n}(g(\hat{p_n}) - g(p)) \underset{n \to \infty}{\overset{d}{\to}} Z,\ Z \sim N(0,1)$$

가 성립하는 분산안정변환 g를 구하고, 이 결과를 이용하여 p에 관한 점근신뢰구간을 구하는 방법을 설명하여라.

5.14 서로 독립이고 성공률이 $p\ (0 < p < 1)$인 베르누이시행 $X_1, \cdots, X_n, \cdots$에서 r 번째 성공까지의 시행횟수를 W_r 이라고 할 때

$$\hat{p_r} = r / W_r$$

에 대한 다음 질문에 답하여라.

(a) r이 한없이 커질 때 $\sqrt{r}(\hat{p_r} - p)$의 극한분포를 구하여라.

(b) r이 한없이 커질 때

$$\sqrt{r}(g(\hat{p_r}) - g(p)) \xrightarrow[n \to \infty]{d} N(0,1)$$

이 성립하는 분산안정변환 g를 구하고, 이 결과를 이용하여 r이 클 때 p에 관한 95% 근사신뢰구간을 구하는 방법을 설명하여라.

5.15 <예 5.3.8>에서 표본분위수의 극한분포를 구하는 과정에서

$$Y_n = \frac{1}{n}Z_1 + \cdots + \frac{1}{n-r_n+1}Z_{r_n},\ Z_i \overset{iid}{\sim} \mathrm{Exp}(1)(i=1,\cdots,n)$$

$$W_n = \sqrt{n}\,\frac{Y_n - (-\log(1-\alpha))}{\sqrt{\alpha/(1-\alpha)}}$$

으로 정의된 확률변수들에 대하여 다음이 성립함을 설명하여라.

(a) Y_n의 누율생성함수 $cgf_{Y_n}(s)$에 대하여

$$cgf_{Y_n}(s) \underset{n\to\infty}{\sim} -s\log(1-\alpha) + \frac{s^2}{2n}\frac{\alpha}{1-\alpha}$$

(b) W_n의 누율생성함수 $cgf_{W_n}(t)$에 대하여

$$cgf_{W_n}(t) = cgf_{Y_n}(\sqrt{n}\,t/\sqrt{\alpha/(1-\alpha)}) + \sqrt{n}\,t\log(1-\alpha)/\sqrt{\alpha/(1-\alpha)}$$

(c) $cgf_{W_n}(t) \underset{n\to\infty}{\sim} \frac{1}{2}t^2$

5.16 <예 5.3.8>에서와 같은 가정하에서 $r_n \underset{n\to\infty}{\sim} \alpha n,\ s_n \underset{n\to\infty}{\sim} \beta n (0<\alpha<\beta<1)$인 경우에 표본분위수 $X_{(r_n)}$과 $X_{(s_n)}$의 결합분포에 대한 극한분포를 유도하고, 이로부터 표본 사분위수범위인

$$X_{(s_n)} - X_{(r_n)} (r_n \underset{n\to\infty}{\sim} n/4,\ s_n \underset{n\to\infty}{\sim} 3n/4)$$

의 극한분포를 유도하여라.

5.17 확률밀도함수가

$$f(x;\mu,\sigma) = \frac{1}{\sigma}\frac{e^{-(x-\mu)/\sigma}}{(1+e^{-(x-\mu)/\sigma})^2} I_{(-\infty,+\infty)}(x)$$

인 로지스틱분포 $L(\mu,\sigma), -\infty<\mu<+\infty, \sigma>0$ 모형에서의 랜덤표본 $X_1,\cdots,X_n (n\geq 2)$에 기초한 표본사분위수 $X_{([n/4])}, X_{([n/2])}, X_{([3n/4])}$ 들로부터 정의되는 다음과 같은 통계량들을 이용하여 μ,σ에 대한 추론을 하려고한다.

$$\widehat{\mu_n} \equiv X_{([n/2])},\ \widehat{\sigma_n} \equiv (X_{([3n/4])} - X_{([n/4])})/(2\log 3)$$

표본 크기 n이 한없이 커질 때 $\sqrt{n}\dfrac{\widehat{\mu_n}-\mu}{\widehat{\sigma_n}}$의 극한분포를 구하고, 이 결과를 이용하여 μ에 관한 95%근사신뢰구간을 구하는 방법을 설명하여라.

5.18 확률밀도함수가

$$f(x;\mu,\sigma)=\frac{1}{2\sigma}e^{-|x-\mu|/\sigma}\mathrm{I}_{(-\infty,+\infty)}(x),-\infty<\mu<+\infty,\sigma>0$$

인 이중지수분포 $\mathrm{DE}(\mu,\sigma)$ 모형에서의 랜덤표본 $\mathrm{X}_1,\cdots,\mathrm{X}_n(n\geq 2)$에 기초한 표본중앙값과 표본평균절대편차(mean absolute deviation)를 각각

$$\widehat{\mu_n}\equiv \mathrm{X}_{([n/2])},\widehat{\sigma_n}\equiv \frac{1}{n}\sum_{i=1}^{n}|\mathrm{X}_i-\mathrm{X}_{([n/2])}|$$

이라고 하자.

(a) $\widehat{\sigma_n}\underset{n\to\infty}{\overset{\mathrm{P}}{\to}}\sigma$ 임을 밝혀라.

(b) 표본 크기 n이 한없이 커질 때 $\sqrt{n}\dfrac{\widehat{\mu_n}-\mu}{\widehat{\sigma_n}}$의 극한분포를 구하고, 이 결과를 이용하여 μ에 관한 95% 근사신뢰구간을 구하는 방법을 설명하여라.