6.1 적률이용 추정법

랜덤표본을 이용하여 모평균 $\mu = \mathrm{E}(\mathrm{X}_1)$에 관한 추측을 하는 경우에 표본평균

$$\overline{\mathrm{X}} = (\mathrm{X}_1 + \cdots + \mathrm{X}_n)/n$$

를 이용하는 것과 마찬가지로 모집단 적률 $m_r = \mathrm{E}(\mathrm{X}_1^r)$에 관한 추측을 할 때에는 표본적률

$$\widehat{m_r} = \frac{1}{n}(\mathrm{X}_1^r + \cdots + \mathrm{X}_n^r)$$

을 이용하는 것이 자연스럽다.

일반적으로 모집단 적률의 함수로 표현되는 모수 $\eta = g(m_1, \cdots, m_k)$에 관한 추측을 할 때 대응하는 표본적률의 함수

$$\hat{\eta} = g(\widehat{m_1}, \cdots, \widehat{m_k}), \quad \widehat{m_r} = \frac{1}{n}(\mathrm{X}_1^r + \cdots + \mathrm{X}_n^r) \ (r = 1, \cdots, k)$$

를 이용하는 방법을 적률이용법이라고 하며, 모수 η의 추측에 사용하는 통계량 $\hat{\eta} = g(\widehat{m_1}, \cdots, \widehat{m_k})$을 적률이용추정량(積率利用推定量, method of moments estimator(MME))이라고 한다.

예 6.1.1 모분산과 모표준편차의 적률이용추정량

모분산이 $\sigma^2 (0 \le \sigma^2 < +\infty)$인 모집단에서의 랜덤표본을 $\mathrm{X}_1, \cdots, \mathrm{X}_n$이라고 하면

$$\sigma^2 = \mathrm{Var}(\mathrm{X}_1) = \mathrm{E}(\mathrm{X}_1^2) - (\mathrm{E}\mathrm{X}_1)^2 = m_2 - m_1^2, \quad \sigma = \sqrt{m_2 - m_1^2}$$

이므로 모분산과 모표준편차의 적률이용추정량은 각각

$$\widehat{\sigma^{2}}^{MME} = \widehat{m_2} - (\widehat{m_1})^2 = \frac{1}{n}\sum_{i=1}^{n}\mathrm{X}_i^2 - (\overline{\mathrm{X}})^2 = \frac{1}{n}\sum_{i=1}^{n}(\mathrm{X}_i - \overline{\mathrm{X}})^2$$

$$\widehat{\sigma}^{MME} = \sqrt{\widehat{m_2} - (\widehat{m_1})^2} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(\mathrm{X}_i - \overline{\mathrm{X}})^2}$$

예 6.1.2 적률이용추정량의 비유일성

포아송분포 $\mathrm{Poisson}(\lambda) (\lambda > 0)$에서의 랜덤표본을 $\mathrm{X}_1, \cdots, \mathrm{X}_n$이라고 하면, 이 경우에는 모평균과 모분산이 모두 λ이므로

$$\lambda = \mathrm{E}(\mathrm{X}_1) = m_1, \quad \lambda = \mathrm{Var}(\mathrm{X}_1) = m_2 - m_1^2$$

따라서 λ를 어떤 적률의 함수로 나타내는가에 따라

$$\hat{\lambda}_1^{MME} = \hat{m}_1 = \overline{X}, \ \hat{\lambda}_2^{MME} = \hat{m}_2 - (\hat{m}_1)^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - \overline{X})^2$$

와 같은 두 가지의 적률이용추정량을 얻게 된다.

<예 6.1.2>에서 알 수 있듯이 모집단을 특정한 분포로 가정하는 경우에는 적률 사이에 함수 관계가 성립하게 되어 하나의 모수에 대해 여러 가지의 적률이용추정량이 정의될 수 있다.

모집단이 다차원일 경우에도 모집단의 결합적률에 대응하여 표본적률을 이용하는 적률이용추정량을 생각할 수 있다. 예를 들어 이차원의 경우에 랜덤표본을 $(X_1, Y_1)^t$, $\cdots$, $(X_n, Y_n)^t$ 이라고 할 때 모집단의 결합적률 $m_{r,s} = E(X_1^r Y_1^s)$ 대신 표본적률

$$\hat{m}_{r,s} = \frac{1}{n}\sum_{i=1}^{n} X_i^r Y_i^s$$

을 대입하여 적률이용추정량을 얻을 수 있다.

예 6.1.3 모상관계수의 적률이용추정량

모평균이 각각 μ_1, μ_2이고 모분산이 각각 σ_1^2, $\sigma_2^2 (0 < \sigma_1^2 < +\infty, \ 0 < \sigma_2^2 < +\infty)$이며 모상관계수가 $\rho \ (-1 < \rho < 1)$인 이차원 모집단에서의 랜덤표본을 $(X_1, Y_1)^t$, $\cdots$, $(X_n, Y_n)^t \ (n > 2)$이라고 할 때, 모상관계수를 모집단의 결합적률로 나타내면 다음과 같다.

$$\rho = \frac{Cov(X_1, Y_1)}{\sqrt{Var(X_1)}\sqrt{Var(Y_1)}} = \frac{E(X_1 Y_1) - E(X_1)E(Y_1)}{\sqrt{E(X_1^2) - [E(X_1)]^2}\sqrt{E(Y_1^2) - [E(Y_1)]^2}}$$

여기에서 모집단의 결합적률에 표본결합적률을 대응시키면 ρ의 적률이용추정량은

$$\hat{\rho}_n^{MME} = \frac{\frac{1}{n}\sum_{i=1}^{n} X_i Y_i - \overline{X}\,\overline{Y}}{\sqrt{\frac{1}{n}\sum_{i=1}^{n} X_i^2 - (\overline{X})^2}\sqrt{\frac{1}{n}\sum_{i=1}^{n} Y_i^2 - (\overline{Y})^2}}$$

$$= \frac{\sum_{i=1}^{n}(X_i - \overline{X})(Y_i - \overline{Y})}{\sqrt{\sum_{i=1}^{n}(X_i - \overline{X})^2}\sqrt{\sum_{i=1}^{n}(Y_i - \overline{Y})^2}}$$

즉 모상관계수의 적률이용추정량은 표본상관계수인 것을 알 수 있다.

예 6.1.4 모분산의 적률이용추정량의 일치성

모분산 $\sigma^2 (0 \le \sigma^2 < +\infty)$을 적률로 나타내면

$$\sigma^2 = g(m_1, m_2) = m_2 - m_1^2$$

이고 함수 g가 연속함수이므로 <정리 6.1.1>로부터 <예 6.1.1>에서의 적률이용추정량

$$\widehat{\sigma_n^2}^{MME} = \frac{1}{n}\sum_{i=1}^{n}(\mathrm{X}_i - \overline{\mathrm{X}})^2$$

은 일치성을 갖는다. 한편 표본분산을 이러한 적률이용추정량으로 나타내면

$$\mathrm{S}_n^2 = \frac{1}{n-1}\sum_{i=1}^{n}(\mathrm{X}_i - \overline{\mathrm{X}})^2 = \frac{n}{n-1}\widehat{\sigma_n^2}^{MME}$$

이므로 표본분산도 일치성을 갖는 σ^2의 추정량인 것을 알 수 있고 이는 <예 5.2.5>의 결과와 일치하는 것임을 알 수 있다.

<정리 6.1.1>은 일차원 경우에 적률이용추정량의 일치성을 밝힌 것이고, 다차원의 경우에도 같은 정리가 성립하는 것은 명백하다. 예를 들면 모상관계수의 적률이용추정량인 표본상관계수가 일치성을 갖는 것은 <예 5.3.6>으로부터 명백하다. 따라서 일치성을 갖는 추정량을 찾을 때 우선적으로 생각할 수 있는 것이 적률이용추정량이다.

또한 적률이용추정량은 다음과 같은 극한분포를 갖는 것이 알려져 있다. 이는 표본적률들에 대한 다차원 경우의 중심극한정리와 <정리 5.3.3>을 이용하여 밝힐 수 있다.

정리 6.1.2 적률이용추정량의 극한분포

랜덤표본 $\mathrm{X}_1, \cdots, \mathrm{X}_n$을 이용한 모수 $\eta = g(m_1, \cdots, m_k)$의 적률이용추정량

$$\widehat{\eta_n} = g\left(\sum_{i=1}^{n}\mathrm{X}_i/n, \cdots, \sum_{i=1}^{n}\mathrm{X}_i^k/n\right)$$

에 대하여, $\mathrm{E}(\mathrm{X}_1^{2k}) < +\infty$이고 함수 $g(m) = g(m_1, \cdots, m_k)$의 일차편도함수 $\dot{g}(m)$이 연속함수이면

$$\sqrt{n}(\widehat{\eta_n} - \eta) \xrightarrow[n\to\infty]{d} \mathrm{Z},\ \mathrm{Z} \sim \mathrm{N}(0, \sigma^2),\ \sigma^2 = (\dot{g}(m))^t \Sigma \dot{g}(m),\ \Sigma = (m_{r+s} - m_r m_s)$$

---

86) 확률이나 기댓값을 나타낼 때 모집단 분포가 모수 $\theta \in \Omega$에 따라 정해지는 것을 나타내기 위하여 $\mathrm{P}(\mathrm{X} \in A)$, $\mathrm{E}(\mathrm{X})$, … 대신 $\mathrm{P}_\theta(\mathrm{X} \in A)$, $\mathrm{E}_\theta(\mathrm{X})$, …와 같은 표현을 사용한다.

각각의 관측 결과 $x=(x_1,\cdots,x_n)^t$에 대하여 최대가능도 추정값 $\hat{\theta}^{MLE}(x)$가 정의될 때 통계량 $\hat{\theta}^{MLE}=\hat{\theta}^{MLE}(\mathrm{X})$를 최대가능도 추정량 또는 최대우도 추정량이라고 한다.

한편 가능도함수를 최대로 하기 위하여는 주로 미분을 하게 되는데 곱의 꼴보다는 합의 꼴로 주어진 경우의 미분이 용이하므로 가능도함수의 로그를 취한 함수로서

$$l(\theta;x)=\log L(\theta;x)=\sum_{i=1}^{n}\log f(x_i;\theta)$$

로 정의된 로그가능도함수(log likelihood function)를 사용한다. 이 때 고정된 관측 결과 $x=(x_1,\cdots,x_n)^t$를 생략하고 이들을 간략히 $L(\theta)$ 또는 $l(\theta)$로 나타내기도 한다.

예 6.2.1 포아송분포에서의 최대가능도 추정

포아송분포 $\mathrm{Poisson}(\lambda)\,(\lambda\geq 0)$[88]에서의 랜덤표본을 $\mathrm{X}_1,\ \cdots,\ \mathrm{X}_n$이라고 할 때 λ의 최대가능도 추정량을 구하여라.

[풀이] 랜덤표본의 결합확률밀도함수가

$$pdf_{\mathrm{X}_1,\cdots,\mathrm{X}_n}(x_1,\cdots,x_n;\lambda)=\prod_{i=1}^{n}\frac{e^{-\lambda}\lambda^{x_i}}{x_i!}$$

이므로, 가능도함수는 다음과 같이 주어진다.

$$L(\lambda;x_1,\cdots,x_n)=e^{-n\lambda}\lambda^{x_1+\cdots+x_n}/(x_1!\cdots x_n!),\ \lambda\geq 0$$

따라서 $\lambda>0$일 때 로그가능도함수는

$$l(\lambda)=-n\lambda+\sum_{i=1}^{n}x_i\log\lambda-\log(x_1!\cdots x_n!)$$

이고, 로그가능도함수의 일차도함수와 이차도함수는 각각 다음과 같다.

---

87) 추정값 $\hat{\theta}(x)$란 관측결과가 x인 경우에 대응하는 추정량 $\hat{\theta}=\hat{\theta}(\mathrm{X})$의 관측값을 뜻하고, 최대가능도 추정값의 정의는 가능도함수를 최대로 하는 $\theta\in\Omega$의 값이 존재하는 것을 전제로 하고 있다.

88) 이러한 표현은 모수공간이 $\Omega=\{\lambda:\lambda\geq 0\}$임을 뜻하는 것이다. 한편 $\lambda=0$인 경우의 포아송분포 $\mathrm{Poisson}(\lambda)$는 상수 0에 집중된 분포를 뜻하고, 이러한 분포가 모형에 포함되어 있으므로 관측 결과에 관계 없이 최대가능도 추정값이 존재하게 되고 최대가능도 추정량을 정의할 수 있는 것이다.

$$\dot{l}(\lambda) = -n + n\bar{x}/\lambda,\ \bar{x} = \sum_{i=1}^{n} x_i/n$$

$$\ddot{l}(\lambda) = -n\bar{x}/\lambda^2,\ \lambda > 0$$

이로부터 로그가능도함수의 증가, 감소를 조사하면 다음이 성립하는 것을 알 수 있다.

(i) $\bar{x} > 0$이면 $\max_{\lambda > 0} l(\lambda) = l(\bar{x})$

(ii) $\bar{x} = 0$이면 $l(\lambda) = -n\lambda - \log(x_1! \cdots x_n!)$ $\therefore \sup_{\lambda > 0} l(\lambda) = \lim_{\lambda \to 0} l(\lambda)$

그런데 가능도함수는 $\lambda = 0$에서 정의되어 있고 연속함수이므로, 어느 경우에나

$$\sup_{\lambda > 0} L(\lambda; x_1, \cdots, x_n) = L(\bar{x}; x_1, \cdots, x_n)$$

$$\therefore \max_{\lambda \geq 0} L(\lambda; x_1, \cdots, x_n) = L(\bar{x}; x_1, \cdots, x_n)\ \ \forall x = (x_1, \cdots, x_n)^t$$

그러므로 λ의 최대가능도 추정량은 $\hat{\lambda}^{MLE} = \bar{X}$로 주어진다.

<예 6.2.1>에서와 같이 로그가능도함수 $l(\theta; x) = \log L(\theta; x)$의 증가, 감소를 조사하는 데에는 그 도함수들을 이용한다. 특히 그 일차도함수를 0으로 하는 모수 값을 찾는 방정식

$$\dot{l}(\theta; x) = 0$$

을 가능도방정식(可能度方程式, likelihood equation)이라고 하며, 이 방정식의 근 $\hat{\theta}(x)$ 중에서 최대가능도 추정값을 찾으면 된다. 이와 관련하여 다음의 정리들은 매우 유용하다.

정리 6.2.1

수직선 위의 열린구간 Ω_o에서 정의된 함수 $l(\theta)$가 두 번 미분가능하고 이차도함수가 연속함수일 때,

$$\ddot{l}(\theta) < 0,\ \forall \theta \in \Omega_o \text{이고 } \dot{l}(\hat{\theta}) = 0,\ \hat{\theta} \in \Omega_o$$

이면

$$\max_{\theta \in \Omega_o} l(\theta) = l(\hat{\theta})$$

[증명] 부록 I의 테일러 정리로부터

$$l(\theta) = l(\hat{\theta}) + \dot{l}(\hat{\theta})(\theta - \hat{\theta}) + \frac{1}{2}\ddot{l}(\theta^*)(\theta - \hat{\theta})^2,\ \exists \theta^* \in \Omega_o$$

따라서 주어진 조건으로부터

$$l(\theta) = l(\hat{\theta}) + \frac{1}{2}\ddot{l}(\theta^*)(\theta - \hat{\theta})^2 < l(\hat{\theta}), \quad \forall \theta \in \Omega_o : \theta \neq \hat{\theta}$$

예 6.2.2 이항분포에서의 최대가능도 추정

베르누이분포 Bernoulli(p) $(0 \le p \le 1)$로부터의 랜덤표본을 $X_1, \cdots, X_n$이라고 할 때 p의 최대가능도 추정량을 구하여라.

[풀이] 이 경우에 가능도함수는

$$L(p; x_1, \cdots, x_n) = \prod_{i=1}^{n} p^{x_i}(1-p)^{1-x_i}, \quad 0 \le p \le 1$$

이므로, $0 < p < 1$일 때 로그가능도함수는 다음과 같이 주어진다.

$$l(p) = \sum_{i=1}^{n} x_i \log p + \left(n - \sum_{i=1}^{n} x_i\right)\log(1-p)$$

이로부터 로그가능도함수의 일차도함수와 이차도함수는 각각 다음과 같다.

$$\dot{l}(p) = \frac{1}{p}\sum_{i=1}^{n} x_i - \frac{1}{1-p}\left(n - \sum_{i=1}^{n} x_i\right) = \frac{n\hat{p}}{p} - \frac{n(1-\hat{p})}{1-p}, \quad \hat{p} = \sum_{i=1}^{n} x_i / n$$

$$\ddot{l}(p) = -n\hat{p}/p^2 - n(1-\hat{p})/(1-p)^2, \quad 0 < p < 1$$

이로부터 $0 < p < 1$ 일 때 <정리 6.2.1>을 이용하고 로그가능도함수의 증가, 감소를 조사하면 다음이 성립하는 것을 알 수 있다.

(i) $0 < \hat{p} < 1$이면 $\dot{l}(\hat{p}) = 0$, $\ddot{l}(p) < 0 \ \forall p : 0 < p < 1$

$\therefore \max_{0<p<1} l(p) = l(\hat{p})$

(ii) $\hat{p} = 0$이면 $l(p) = n\log(1-p)$ $\therefore \sup_{0<p<1} l(p) = \lim_{p \to 0} l(p)$

(iii) $\hat{p} = 1$이면 $l(p) = n\log p$ $\therefore \sup_{0<p<1} l(p) = \lim_{p \to 1} l(p)$

그런데 가능도함수는 $p = 0, p = 1$에서 정의되고 연속함수이므로, 어느 경우에나

$$\sup_{0<p<1} L(p; x_1, \cdots, x_n) = L(\hat{p}; x_1, \cdots, x_n)$$

또한 $p = 0$인 경우는 $x_1 = \cdots = x_n = 0$이고, $p = 1$인 경우는 $x_1 = \cdots = x_n = 1$이므로

$$\therefore \max_{0 \le p \le 1} L(p;x_1,\cdots,x_n) = L(\hat{p};x_1,\cdots,x_n) \quad \forall x = (x_1,\cdots,x_n)^t$$

그러므로 p의 최대가능도 추정량은 $\hat{p}^{MLE} = \frac{1}{n}\sum_{i=1}^{n} X_i$로 주어진다.

<정리 6.2.1>에서의 조건

$$\ddot{l}(\theta) < 0, \quad \forall \theta \in \Omega_o$$

은 함수 $l(\theta)$가 순오목함수(strictly concave function) 즉

$$l(\alpha\theta_1 + (1-\alpha)\theta_2) > \alpha l(\theta_1) + (1-\alpha) l(\theta_2) \quad \forall \alpha : 0 < \alpha < 1,$$
$$\forall \theta_i \in \Omega_o (i = 1,2)(\theta_1 \neq \theta_2)$$

이기 위한 충분조건으로서 이는 선분의 내분점에서의 함수 값이 선분의 양 끝점에서의 값들의 내분 값보다 커지는 것을 뜻하는 조건이다.

로그가능도함수가 이러한 조건을 만족하는 경우에는 <예 6.2.2>에서와 같이 가능도방정식의 근을 찾기만 하면 <정리 6.2.1>로부터 그 근이 최대가능도 추정값이 된다. 그러나 가능도방정식의 구체적 풀이가 어려울 때도 많이 있으며 그러한 경우에는 순오목함수에 관한 다음의 정리가 매우 유용하다.

정리 6.2.3 분산 0의 의미

수직선 위의 열린구간 Ω_o에서 정의된 함수 $l(\theta)$가 두 번 미분가능하고 이차도함수가 연속함수일 때

$$\ddot{l}(\theta) < 0, \quad \forall \theta \in \Omega_o \text{이고} \lim_{\theta \to \partial(\Omega_o)} l(\theta) = -\infty$$ [89]

이면 방정식 $\dot{l}(\theta) = 0, \theta \in \Omega_o$의 근 $\hat{\theta}$이 존재하고 그러한 근은 하나뿐이다.

[증명] 정의역이 무한구간으로서 $\Omega_o = (-\infty, +\infty)$인 경우에 증명하기로 한다.

이 경우에

$$\lim_{\theta \to -\infty} l(\theta) = -\infty, \quad \lim_{\theta \to +\infty} l(\theta) = -\infty$$

이고 $l(\theta)$가 연속함수이므로 $l(\theta)$는 최대값을 갖는다. 즉

$$l(\hat{\theta}) = \max_{\theta \in \Omega_o} l(\theta), \quad \hat{\theta} \in \Omega_o$$

89) 여기에서 $\partial(\Omega_o)$는 수직선 위의 구간 Ω_o의 경계(境界, boundary)를 나타내는 기호이고, $\theta \to \partial(\Omega_o)$가 뜻하는 것은 유한구간의 경우에는 구간의 끝점으로 가까이 가고, 무한구간의 경우에는 무한히 커지거나 작아지는 것을 뜻한다.

인 $\hat{\theta}$이 존재한다. 만약 $l(\theta)$가 서로 다른 두 점 $\hat{\theta_1}$, $\hat{\theta_2}$에서 최대가 된다면

$$l(\hat{\theta_1}) = l(\hat{\theta_2}) = \max_{\theta \in \Omega_o} l(\theta),\ \hat{\theta_1} < \hat{\theta_2}$$

그런데 $l(\theta)$가 순오목함수이므로

$$l\left(\frac{1}{2}\hat{\theta_1} + \frac{1}{2}\hat{\theta_2}\right) > \frac{1}{2}l(\hat{\theta_1}) + \frac{1}{2}l(\hat{\theta_2}) = \max_{\theta \in \Omega_o} l(\theta),\ \frac{1}{2}\hat{\theta_1} + \frac{1}{2}\hat{\theta_2} \in \Omega_o$$

가 성립하게 되어 모순이다. 따라서 $l(\theta)$는 한 점 $\hat{\theta} \in \Omega_o$에서만 최대가 된다. 이러한 점 $\hat{\theta}$에 대하여 $\dot{l}(\hat{\theta}) = 0$ 임은 명백하므로 $\hat{\theta}$은 가능도방정식의 하나뿐인 근이다.

가능도방정식의 근이 존재하는 것을 알지만 구체적 풀이가 어려울 때에는 테일러 정리를 이용하여 일차방정식으로 근사한 방정식[90]

$$0 = \dot{l}(\hat{\theta}^1) \simeq \dot{l}(\hat{\theta}^0) + \ddot{l}(\hat{\theta}^0)(\hat{\theta}^1 - \hat{\theta}^0)$$

을 반복적으로 적용하여 근을 구하고, 초기값인 $\hat{\theta}^0$로는 흔히 적률이용 추정값을 사용한다.

일단계 반복법(one step iteration)에 의한 가능도방정식의 풀이:

$$\hat{\theta}^{r+1} = \hat{\theta}^r + [-\ddot{l}(\hat{\theta}^r)]^{-1}\dot{l}(\hat{\theta}^r),\ (r = 0,1,\cdots),\ \hat{\theta}^0 = \hat{\theta}^{MME}$$

예 6.2.3 로지스틱분포에서의 최대가능도 추정

<예 4.1.5>의 로지스틱분포 $L(\theta,1)\,(-\infty < \theta < +\infty)$로부터의 랜덤표본을 $X_1, \cdots, X_n$이라고 할 때 θ의 최대가능도 추정값을 찾는 알고리즘을 구하여라.

[풀이] 로지스틱분포 $L(\theta,1)$의 확률밀도함수는

$$pdf(x;\theta) = \frac{e^{x-\theta}}{(1+e^{x-\theta})^2} = \frac{e^{-x+\theta}}{(1+e^{-x+\theta})^2},\ -\infty < x < +\infty$$

이므로 로그가능도함수와 그 도함수들은 다음과 같이 주어진다.

90) 이러한 반복법을 뉴톤-랩슨(Newton-Raphson) 방법이라고 하며 많은 패키지에 함수화 되어 있다.

$$l(\theta)=n\bar{x}-n\theta-2\sum_{i=1}^{n}\log(1+e^{x_i-\theta})=-n\bar{x}+n\theta-2\sum_{i=1}^{n}\log(1+e^{-x_i+\theta})$$

$$\dot{l}(\theta)=n-2\sum_{i=1}^{n}e^{-x_i+\theta}/(1+e^{-x_i+\theta}),\quad \ddot{l}(\theta)=-2\sum_{i=1}^{n}e^{-x_i+\theta}/(1+e^{-x_i+\theta})^2$$

$$\therefore\ \ddot{l}(\theta)<0,\ \forall\theta:-\infty<\theta<+\infty,\quad \lim_{\theta\to-\infty}l(\theta)=-\infty,\quad \lim_{\theta\to+\infty}l(\theta)=-\infty$$

그러므로 <정리 6.2.2>로부터 θ의 최대가능도 추정값은 가능도방정식

$$\dot{l}(\theta)=n-2\sum_{i=1}^{n}e^{-x_i+\theta}/(1+e^{-x_i+\theta})=0$$

의 하나뿐인 근으로 주어진다. 한편 로지스틱분포 $\mathrm{L}(\theta,1)$의 평균은 θ이므로 θ의 적률이용 추정값은 $\hat{\theta}^{MME}=\bar{x}$이다. 따라서 다음과 같은 반복법을 이용하여 최대가능도 추정값을 구할 수 있다.

$$\hat{\theta}^{r+1}=\hat{\theta}^{r}+[-\ddot{l}(\hat{\theta}^{r})]^{-1}\dot{l}(\hat{\theta}^{r}),\quad (r=0,1,\cdots),\quad \hat{\theta}^{0}=\bar{x}$$

정리 6.2.3 모수의 일대일 변환과 최대가능도 추정

모수 θ의 최대가능도 추정량이 존재할 때, θ의 일대일 변환으로서

$$\eta=g(\theta),\ \theta\in\Omega$$

로 정의된 새로운 모수의 최대가능도 추정량은 다음과 같이 주어진다.

$$\hat{\eta}^{MLE}=g(\hat{\theta}^{MLE})$$

[증명] 정규분포 $\mathrm{N}(0,\sigma^2)$에서 모분산인 σ^2을 모수로 하거나 모표준편차인 $\sigma=\sqrt{\sigma^2}$를 모수로 하거나 확률밀도함수가 변하지 않는 것과 같이 랜덤표본의 확률밀도함수는 모수의 일대일 변환에 따라 변하지 않는다. 즉, θ의 일대일 변환인 $\eta=g(\theta),\ \theta\in\Omega$에 대하여

$$pdf(x_1,\cdots,x_n;\theta)=pdf(x_1,\cdots,x_n;g^{-1}(\eta)),\quad \eta\in g(\Omega)$$

따라서 $\eta=g(\theta)$를 모수로 할 때의 가능도함수는 다음과 같이 주어진다.

$$L(g^{-1}(\eta);x_1,\cdots,x_n)=pdf(x_1,\cdots,x_n;g^{-1}(\eta))$$

한편

$$\max_{\eta\in g(\Omega)}L(g^{-1}(\eta);x_1,\cdots,x_n)=\max_{\theta\in\Omega}L(\theta;x_1,\cdots,x_n)=L(\hat{\theta}^{MLE})=L[g^{-1}(g(\hat{\theta}^{MLE}))]$$

이므로 이 가능도함수는 $g(\hat{\theta}^{MLE})$에서 최대가 된다. 즉

$$\hat{\eta}^{MLE}=g(\hat{\theta}^{MLE})$$

예 6.2.4 지수분포에서의 최대가능도 추정

지수분포 $\mathrm{Exp}(\theta)\,(0<\theta<+\infty)$로부터의 랜덤표본을 $\mathrm{X}_1, \cdots, \mathrm{X}_n$이라고 할 때 θ의 최대가능도 추정량을 구하여라.

[풀이] 지수분포 $\mathrm{Exp}(\theta)$의 확률밀도함수는

$$pdf(x;\theta)=\frac{1}{\theta}e^{-x/\theta},\ x>0$$

이므로 로그가능도함수와 그 도함수들은 다음과 같이 주어진다.

$$l(\theta)=-n\log\theta-n\bar{x}/\theta,\ \dot{l}(\theta)=-n/\theta+n\bar{x}/\theta^2,\ \ddot{l}(\theta)=n/\theta^2-2n\bar{x}/\theta^3$$

이로부터 이 로그가능도함수는 순오목함수가 아니어서 <정리 6.2.2>를 적용할 수 없고, 다른 방법으로 그 증가, 감소를 조사하여야 한다.

한편 $\lambda=1/\theta$를 모수로 하는 경우에 로그가능도함수와 그 도함수들은

$$l(\lambda)=n\log\lambda-n\bar{x}\lambda,\ \dot{l}(\lambda)=n/\lambda-n\bar{x},\ \ddot{l}(\lambda)=-n/\lambda^2$$

으로 주어지고 다음이 성립하는 것을 알 수 있다.

$$\ddot{l}(\lambda)=-n/\lambda^2<0,\ \forall\lambda:0<\lambda<+\infty,$$

$$\lim_{\lambda\to0}l(\lambda)=-\infty,\ \lim_{\lambda\to\infty}l(\lambda)=-\lim_{\lambda\to\infty}n\lambda\left(\bar{x}-\frac{\log\lambda}{\lambda}\right)=-\infty$$

그러므로 $\lambda=1/\theta$를 모수로 하는 경우에는 로그가능도함수가 순오목함수이고 <정리 6.2.2>를 적용할 수 있다. 가능도방정식 $\dot{l}(\lambda)=0$을 풀면 λ의 최대가능도 추정량은

$$\hat{\lambda}^{MLE}=1/\overline{\mathrm{X}}$$

따라서 <정리 6.2.3>으로부터 $\theta=1/\lambda$의 최대가능도 추정량은

$$\hat{\theta}^{MLE}=1/\hat{\lambda}^{MLE}=\overline{\mathrm{X}}$$

<예 6.2.4>에서와 같이 모수의 일대일 변환을 하여 로그가능도함수가 순오목함수가 되면 최대가능도 추정량을 찾는 것이 용이해진다. 다음의 정리에서는 이러한 성질을 가지고 있는 특정한 형태의 확률 모형에서의 최대가능도 추정을 소개하고 있다.

정리 6.2.4 **지수족에서의 최대가능도 추정**

확률밀도함수가

$$pdf(x;\eta)=\exp\{\eta \mathrm{T}(x)-\mathrm{A}(\eta)+\mathrm{S}(x)\},\ x\in \mathscr{X},\ \eta\in N$$

의 꼴로 주어지고 다음 조건 (i), (ii), (iii)을 만족하는 모집단[91]에서의 랜덤 표본을 $\mathrm{X}_1, \mathrm{X}_2, \cdots, \mathrm{X}_n$이라고 할 때, 가능도방정식

$$\dot{\mathrm{A}}(\eta)=\frac{1}{n}\sum_{i=1}^{n}\mathrm{T}(x_i),\ \text{또는}\ \mathrm{E}_\eta[\mathrm{T}(\mathrm{X}_1)]=\frac{1}{n}\sum_{i=1}^{n}\mathrm{T}(x_i),\ \eta\in N$$

이 근 $\hat{\eta}=\hat{\eta}(x_1,\cdots,x_n)$을 갖는다면, $\hat{\eta}$은 η의 최대가능도 추정값이다.

(i) 분포의 토대 $\mathscr{X}=\{x : pdf(x;\eta)>0\}$가 모수에 따라 변하지 않으며,

(ii) 모수공간 N이 수직선 위의 열린구간이고,

(iii) $\mathrm{Var}(\mathrm{T}(\mathrm{X}_1))>0$, 즉 $\mathrm{T}(x)$는 상수가 아니다.

[증명] 이 정리 증명의 핵심은 다음과 같은 누율생성함수에 관한 사실이다.

$$cgf_{\mathrm{T}(\mathrm{X}_1);\eta}(s)=\log mgf_{\mathrm{T}(\mathrm{X}_1);\eta}(s)=\log \mathrm{E}_\eta(e^{s\mathrm{T}(\mathrm{X}_1)})=\mathrm{A}(s+\eta)-\mathrm{A}(\eta)\ ,$$

$$-\epsilon<s<\epsilon\ (\exists\, s>0)$$

$$\mathrm{E}_\eta[\mathrm{T}(\mathrm{X}_1)]=\dot{\mathrm{A}}(\eta),\ \mathrm{Var}_\eta[\mathrm{T}(\mathrm{X}_1)]=\ddot{\mathrm{A}}(\eta),\ \eta\in N$$

이러한 누율생성함수에 관한 사실을 밝히기 위하여 연속형의 경우를 생각하면 다음과 같고 이산형의 경우도 같은 방법으로 밝힐 수 있다.

$$\begin{aligned}\mathrm{E}(e^{s\mathrm{T}(\mathrm{X}_1)})&=\int_{-\infty}^{+\infty}e^{s\mathrm{T}(x)}pdf(x;\eta)dx\\&=\int_{-\infty}^{+\infty}pdf(x;s+\eta)\,dx\ \exp\{\mathrm{A}(s+\eta)-\mathrm{A}(\eta)\}\\&=\exp\{\mathrm{A}(s+\eta)-\mathrm{A}(\eta)\},\ s+\eta\in N,\ \eta\in N,\ |s|<\epsilon\ (\exists\,\epsilon>0)\end{aligned}$$

여기에서 s의 범위가 원점이 포함된 열린구간으로 정해질 수 있는 것은 조건 (ii) 때문이다.

$$\therefore\ cgf_{\mathrm{T}(\mathrm{X}_1);\eta}(s)=\log \mathrm{E}_\eta(e^{s\mathrm{T}(\mathrm{X}_1)})=\mathrm{A}(s+\eta)-\mathrm{A}(\eta),\ |s|<\epsilon\ (\exists\,\epsilon>0)$$

한편 2장에서 밝혔듯이 일차, 이차 누율이 각각 평균과 분산이므로

---

91) 이러한 조건을 만족하는 <정리 6.2.4>에 주어진 형태의 확률밀도함수의 집합을 단일모수 지수족(指數族, single parameter exponential family of pdf's)이라고 한다.

$$E_\eta[T(X_1)] = \left[\frac{d}{ds} cgf_{T(X_1);\eta}(s)\right]_{s=0} = \dot{A}(\eta)$$

$$Var_\eta[T(X_1)] = \left[\frac{d^2}{ds^2} cgf_{T(X_1);\eta}(s)\right]_{s=0} = \ddot{A}(\eta),\ \eta \in N$$

따라서 조건 (iii)과 <정리 1.6.4>로부터

$$\ddot{A}(\eta) > 0 \quad \forall \eta \in N$$

그러므로 이 경우의 로그가능도함수

$$l(\eta) = \eta \sum_{i=1}^{n} T(x_i) - nA(\eta) + \sum_{i=1}^{n} S(x_i)$$

에 대하여 다음이 성립하게 되어 로그가능도함수는 순오목함수이다.

$$\ddot{l}(\eta) = -n\ddot{A}(\eta) < 0 \quad \forall \eta \in N$$

따라서 <정리 6.2.1>로부터 가능도방정식의 근 $\hat{\eta} = \hat{\eta}(x_1, \cdots, x_n)$이 존재하면, 즉

$$\dot{l}(\hat{\eta}) = \sum_{i=1}^{n} T(x_i) - n\dot{A}(\hat{\eta}) = 0$$

인 $\hat{\eta}$이 존재하면 $\hat{\eta}$은 η의 최대가능도 추정값이다.

<정리 6.2.4>를 이용하는 많은 경우에 지수족의 표현에 사용되는 모수 η는

$$\eta = g(\theta),\ \theta \in \Omega$$

와 같은 일대일 변환을 통하여 정의되는 모수이다. 즉 <정리 6.2.4>의 확률밀도함수가

$$pdf(x;\theta) = \exp\{g(\theta)T(x) - A(g(\theta)) + S(x)\},\ x \in \mathcal{X},\ \theta \in \Omega$$

의 꼴로 모수 $\theta \in \Omega$를 이용하여 주어지는 것을 뜻한다. 따라서 <정리 6.2.4>의 조건이 만족되는 경우에 θ의 최대가능도 추정값은 <정리 6.2.3>으로부터 모수 θ를 이용한 가능도방정식

$$E_\theta[T(X_1)] = \frac{1}{n}\sum_{i=1}^{n} T(x_i),\ \theta \in \Omega$$

의 근 $\hat{\theta} = \hat{\theta}(x_1, \cdots, x_n)$으로 주어진다.

지수족에서 모수의 일대일 변환과 가능도방정식:

$$pdf(x;\theta) = \exp\{g(\theta)T(x) - A(g(\theta)) + S(x)\},\ x \in \mathcal{X},\ \theta \in \Omega$$

이고 $\eta = g(\theta)$로 모수화하여 〈정리 6.2.4〉의 조건이 만족되면 θ를 이용한 가능도방정식은

$$E_\theta[T(X_1)] = \frac{1}{n}\sum_{i=1}^{n} T(x_i),\ \theta \in \Omega$$

예 6.2.5 정리 6.2.4의 조건을 만족시키는 지수족의 예

(a) 베르누이분포 모형 $\mathrm{Bernoulli}(p)$, $0<p<1$:

$$f(x;p)=p^x(1-p)^{1-x}=\exp\left\{\left(\log\frac{p}{1-p}\right)x+\log(1-p)\right\},\ x=0,1$$

$\eta=\log\frac{p}{1-p}$ 로 모수의 변환을 하면

$$pdf(x;\eta)=\exp\{\eta x-\log(1+e^{\eta})\},\ x=0,1,\ -\infty<\eta<+\infty$$

크기 n인 랜덤표본에 기초한 가능도방정식의 근 $\hat{\eta}$과 대응하는 $\hat{p}$은

$$\frac{1}{n}\sum_{i=1}^{n}x_i=\dot{A}(\hat{\eta})=\frac{e^{\hat{\eta}}}{1+e^{\hat{\eta}}}=\hat{p},\ 0<\hat{p}<1$$

임을 알 수 있다. 한편 모수 p를 이용한 가능도방정식은

$$\frac{1}{n}\sum_{i=1}^{n}x_i=\mathrm{E}_p(\mathrm{X}_1)=p,\ 0<p<1$$

로 주어지고 이는 η를 이용한 가능도방정식과 일치하는 것을 알 수 있다.

이로부터 <예 6.2.2>의 (i)의 경우와 같이 $0<\sum_{i=1}^{n}x_i/n<1$인 경우에

$$\hat{p}^{MLE}=\frac{1}{n}\sum_{i=1}^{n}x_i$$

(b) 포아송분포 모형 $\mathrm{Poisson}(\lambda)$, $\lambda>0$:

$$f(x;\lambda)=\frac{e^{-\lambda}\lambda^x}{x!},\ x=0,1,\cdots$$

$\eta=\log\lambda$ 로 모수의 변환을 하면

$$pdf(x;\eta)=\exp(\eta x-e^{\eta}-\log x!),\ x=0,1,\cdots,\ -\infty<\eta<+\infty$$

크기 n인 랜덤표본에 기초한 가능도방정식을 모수 λ를 이용하여 나타내면

$$\frac{1}{n}\sum_{i=1}^{n}x_i=\mathrm{E}_{\lambda}(\mathrm{X}_1)=\lambda,\ \lambda>0$$

이로부터 <예 6.2.1>의 (i)의 경우와 같이 $\sum_{i=1}^{n}x_i>0$인 경우에

$$\hat{\lambda}^{MLE}=\frac{1}{n}\sum_{i=1}^{n}x_i$$

(c) 기하분포 모형 $\mathrm{Geo}(p)$, $0<p<1$:

$$f(x;p)=(1-p)^{x-1}p,\ x=1,2,\cdots$$

$\eta = \log(1-p)$로 모수의 변환을 하면

$pdf(x;\eta) = \exp(\eta x - \eta + \log(1-e^{\eta}))$, $x = 0,1,\cdots$, $-\infty < \eta < +\infty$

크기 r인 랜덤표본에 기초한 가능도방정식을 모수 p를 이용하여 나타내면

$$\frac{1}{r}\sum_{i=1}^{r} x_i = \mathrm{E}_p(\mathrm{X}_1) = 1/p,\ 0 < p < 1$$

이로부터 $\sum_{i=1}^{r} x_i/r > 1$인 경우에 $\hat{p}^{MLE} = 1/\frac{1}{r}\sum_{i=1}^{r} x_i$

(d) 지수분포 모형 $\mathrm{Exp}(\theta)$, $\theta > 0$:

$$f(x;\theta) = \frac{1}{\theta} e^{-x/\theta},\ x > 0$$

$\eta = -1/\theta$로 모수의 변환을 하면

$$pdf(x;\eta) = \exp\{\eta x + \log(-\eta)\},\ x > 0,\ \eta < 0$$

크기 n인 랜덤표본에 기초한 가능도방정식을 모수 θ를 이용하여 나타내면

$$\frac{1}{n}\sum_{i=1}^{n} x_i = \mathrm{E}_{\theta}(\mathrm{X}_1) = \theta,\ \theta > 0$$

이로부터 <예 6.2.4>에서와 같이 모든 관측 결과에 대하여

$$\hat{\theta}^{MLE} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

(e) 파레토분포 모형 $\mathrm{Pareto}(1,\theta)$, $\theta > 0$:

$$f(x;\theta) = \theta x^{-\theta-1},\ x > 1$$

이 경우에는 $\eta = \theta$인 경우이므로 모수의 변환이 없이

$$pdf(x;\theta) = \exp\{\theta(-\log x) + \log\theta - \log x\},\ x > 1,\ \theta > 0$$

크기 n인 랜덤표본에 기초한 가능도방정식의 근 $\hat{\theta}$은

$$\frac{1}{n}\sum_{i=1}^{n}(-\log x_i) = \dot{\mathrm{A}}(\hat{\theta}) = -\frac{1}{\hat{\theta}},\ \hat{\theta} > 0$$

임을 알 수 있다. 한편 이 경우에

$$\mathrm{X}_1^{-\theta} \sim \mathrm{U}(0,1),\ \theta\log\mathrm{X}_1 \sim \mathrm{Exp}(1),\ \mathrm{E}_{\theta}(-\log\mathrm{X}_1) = -1/\theta$$

이므로 $\dot{\mathrm{A}}(\theta) = \mathrm{E}_{\theta}(-\log\mathrm{X}_1)$이고, 위의 가능도방정식과 $\mathrm{E}_{\theta}(-\log\mathrm{X}_1)$을 이용한 가능도방정식이 일치하는 것을 알 수 있다. 이로부터 모든 관측 결과에 대하여

$$\hat{\theta}^{MLE} = 1/\frac{1}{n}\sum_{i=1}^{n}\log x_i$$

이제까지의 모든 예에서는 가능도함수가 미분가능한 경우를 다루었으나, 미분 불가능하거나 불연속함수인 경우도 있다. 이러한 경우에는 가능도함수 또는 로그가능도함수의 증가, 감소를 조사하여 최대가능도 추정값을 찾아야 한다. 또한, 최대가능도 추정량이 유일하게 정해지지 않는 경우도 있다.

예 6.2.6 이중지수분포에서의 최대가능도 추정

이중지수분포 $\mathrm{DE}(\theta,1)(-\infty<\theta<+\infty)$로부터의 랜덤표본을 $\mathrm{X}_1,\cdots,\mathrm{X}_n$ $(n=2m+1)$이라고 할 때 θ의 최대가능도 추정량을 구하여라.

[풀이] 이중지수분포 $\mathrm{DE}(\theta,1)$의 확률밀도함수는

$$pdf(x;\theta)=\frac{1}{2}e^{-|x-\theta|},\ -\infty<x<+\infty$$

따라서 로그가능도함수는

$$l(\theta)=-\sum_{i=1}^{n}|x_i-\theta|-n\log 2$$

로 주어지고 이 함수는 $\theta=x_1,\cdots,\theta=x_n$에서 미분 불가능인 것을 알 수 있다.

한편 순서통계량의 관측값을 $x_{(1)}<\cdots<x_{(n)}$이라 하고 $x_{(0)}=-\infty$, $x_{(n+1)}=+\infty$이라고 할 때, $x_{(r)}\le\theta<x_{(r+1)}(r=0,\cdots,n)$인 경우에

$$l(\theta)=-\sum_{i=1}^{n}|\theta-x_{(i)}|-n\log 2=-\sum_{i=1}^{r}(\theta-x_{(i)})-\sum_{i=r+1}^{n}(x_{(i)}-\theta)-n\log 2$$

$$\therefore\ l(\theta)=(n-2r)\theta+\sum_{i=1}^{r}x_{(i)}-\sum_{i=r+1}^{n}x_{(i)}-n\log 2$$

이로부터 $n=2m+1$인 경우에 다음이 성립하는 것을 알 수 있다.

(i) $n-2r>0$ 즉 $r=0,\cdots,m$일 때 구간 $[x_{(r)},x_{(r+1)})$에서 $l(\theta)$는 증가하고,

(ii) $n-2r<0$ 즉 $r=m+1,\cdots,n$일 때 구간 $[x_{(r)},x_{(r+1)})$에서 $l(\theta)$는 감소한다.

따라서 로그가능도함수 $l(\theta)$는 $\hat{\theta}=x_{(m+1)}$에서 최대값을 갖는다.

$$\therefore\ \hat{\theta}^{MLE}=\mathrm{X}_{(m+1)}$$

예 6.2.7 균등분포에서의 최대가능도 추정

구간 $[0,\theta]$에서의 균등분포 $\mathrm{U}[0,\theta]\,(0<\theta<+\infty)$로부터의 랜덤표본을 $\mathrm{X}_1, \cdots, \mathrm{X}_n$이라고 할 때 θ의 최대가능도 추정량을 구하여라.

[풀이] 이 경우에 랜덤표본의 결합확률밀도함수는

$$pdf(x_1,\cdots,x_n;\theta)=\prod_{i=1}^{n}\frac{1}{\theta}\mathrm{I}_{[0,\theta]}(x_i)=\theta^{-n}\mathrm{I}_{(0\le \min x_i,\ \max x_i\le\theta)}$$

따라서 가능도함수는

$$L(\theta)=\theta^{-n}\mathrm{I}_{[x_{(n)},+\infty)}(\theta),\ x_{(n)}=\max_{1\le i\le n}x_i$$

이로부터 가능도함수는 $\hat{\theta}=x_{(n)}$에서 최대값을 갖는 것을 알 수 있다.

$$\therefore\ \hat{\theta}^{MLE}=\mathrm{X}_{(n)}$$

예 6.2.8 최대가능도 추정량이 유일하지 않은 경우

구간 $[\theta-1,\theta+1]$에서의 균등분포 $\mathrm{U}[\theta-1,\theta+1]\,(-\infty<\theta<+\infty)$로부터의 랜덤표본을 $\mathrm{X}_1, \cdots, \mathrm{X}_n$이라고 할 때 이들의 결합확률밀도함수는

$$pdf(x_1,\cdots,x_n;\theta)=\prod_{i=1}^{n}\frac{1}{2}\mathrm{I}_{[\theta-1,\theta+1]}(x_i)=2^{-n}\mathrm{I}_{(\theta-1\le \min x_i,\ \max x_i\le\theta+1)}$$

따라서 가능도함수는

$$L(\theta)=2^{-n}\mathrm{I}_{[x_{(n)}-1,x_{(1)}+1]}(\theta),\ x_{(1)}=\min_{1\le i\le n}x_i,\ x_{(n)}=\max_{1\le i\le n}x_i$$

이로부터 가능도함수는 구간 $[x_{(n)}-1,x_{(1)}+1]$의 모든 점에서 최대값 2^{-n}을 갖는 것을 알 수 있다. 그러므로 이 경우에는 최대가능도 추정량은 유일하게 정해지지 않으며

$$\mathrm{X}_{(n)}-1\le\hat{\theta}^{MLE}\le\mathrm{X}_{(1)}+1$$

을 만족하는 모든 통계량이 θ의 최대가능도 추정량이다. 예를 들어

$$\alpha(\mathrm{X}_{(n)}-1)+(1-\alpha)(\mathrm{X}_{(1)}+1),\ 0\le\alpha\le1$$

은 모두 θ의 최대가능도 추정량이다. 이러한 경우에는 가능한 추정량 중에서 효율성이나 해석의 용이성 등의 추가적인 판단 기준에 따라 추정량을 선택하여야 한다.

6.3 다차원 모수의 최대가능도 추정

정규분포 $N(\mu,\sigma^2)$에서 $(\mu,\sigma^2)^t$과 같이 모수가 다차원 벡터인 경우의 최대가능도 추정에 대하여 생각해보자. 다차원 모수의 최대가능도 추정의 개념은 일차원의 경우와 같으며 구체적으로는 다음과 같이 정의한다.

다차원 모수의 최대가능도 추정:

모집단 분포가 확률밀도함수 $f(x;\theta)$, $\theta=(\theta_1,\cdots,\theta_k)^t\in\Omega$ 중의 하나인 모형에서 랜덤표본 $X_1,\cdots,X_n$을 관측한 결과를 $x=(x_1,\cdots,x_n)^t$라고 할 때 다음과 같이 정의한다.

(a) 가능도함수와 로그가능도함수: 모수 벡터 $\theta=(\theta_1,\cdots,\theta_k)^t\in\Omega$의 함수로서

$$L(\theta;x)=\prod_{i=1}^{n}f(x_i;\theta),\ \theta=(\theta_1,\cdots,\theta_k)^t\in\Omega$$

$$l(\theta;x)=\log L(\theta;x)=\sum_{i=1}^{n}\log f(x_i;\theta)$$

(b) 모수 벡터의 최대가능도 추정: 가능도함수를 최대로 하는 $\hat{\theta}^{MLE}(x)$를 $\theta=(\theta_1,\cdots,\theta_k)^t$의 최대가능도 추정값이라고 한다.

$$L(\hat{\theta}^{MLE}(x);x)=\max_{\theta\in\Omega}L(\theta;x),\ \hat{\theta}^{MLE}(x)\in\Omega$$

(c) 모수 벡터 각 성분의 최대가능도 추정: $\hat{\theta}^{MLE}(x)$의 각 성분을 대응하는 $\theta=(\theta_1,\cdots,\theta_k)^t$ 성분의 최대가능도 추정값이라고 한다. 즉

$$\hat{\theta}^{MLE}(x)=(\hat{\theta}_1^{MLE}(x),\cdots,\hat{\theta}_k^{MLE}(x))^t$$

다차원 모수의 최대가능도 추정값을 구하는 과정은 다변수 함수의 최대값을 구하는 것과 마찬가지이다. 한 변수씩 단계적으로 최대값을 구해 나갈 수도 있고 또는 일차원 모수의 경우와 같이 가능도방정식을 이용하여 구할 수도 있다.

예 6.3.1 이중지수분포에서의 최대가능도 추정

이중지수분포 $DE(\mu,\sigma)(-\infty<\mu<+\infty,\sigma>0)$로부터의 랜덤표본을 $X_1,\cdots,X_n$ $(n=2m+1)$이라고 할 때 $\theta=(\mu,\sigma)^t$의 최대가능도 추정량을 구하여라.

[풀이] 이중지수분포 $DE(\mu,\sigma)$의 확률밀도함수는

$$pdf(x;\theta)=\frac{1}{2\sigma}e^{-|(x-\mu)/\sigma|},\ -\infty<x<+\infty,\ \theta=(\mu,\sigma)^t$$

따라서 로그가능도함수는

$$l(\mu,\sigma) = -\sum_{i=1}^{n}|x_i-\mu|/\sigma - n\log\sigma - n\log 2$$

로 주어지고, <예 6.2.5>로부터 이 로그가능도함수가 μ의 함수로서 중앙값 $\hat{\mu} = x_{(m+1)}$에서 최대로 되는 것을 알 수 있다. 즉 순서통계량의 관측값을 $x_{(1)} < \cdots < x_{(n)}$이라고 할 때

$$\max_{-\infty<\mu<+\infty} l(\mu,\sigma) = l(\hat{\mu},\sigma),\ \hat{\mu} = x_{(m+1)}\ (n=2m+1)$$

또한 $l(\hat{\mu},\sigma)$의 증가, 감소를 조사하면

$$\frac{\partial}{\partial\sigma}l(\hat{\mu},\sigma) = \sum_{i=1}^{n}|x_i-\hat{\mu}|/\sigma^2 - n/\sigma > 0 \Leftrightarrow \sigma < \frac{1}{n}\sum_{i=1}^{n}|x_i-\hat{\mu}|$$

따라서 $l(\hat{\mu},\sigma)$은 $\hat{\sigma} = \frac{1}{n}\sum_{i=1}^{n}|x_i-\hat{\mu}|$에서 최대가 된다.

$$\therefore \max_{\sigma>0}\max_{-\infty<\mu<+\infty} l(\mu,\sigma) = \max_{\sigma>0} l(\hat{\mu},\sigma) = l(\hat{\mu},\hat{\sigma}),$$

$$\hat{\mu} = x_{(m+1)},\ \hat{\sigma} = \frac{1}{n}\sum_{i=1}^{n}|x_i - x_{(m+1)}|$$

$$\therefore\ \hat{\theta}^{MLE} = (\hat{\mu}^{MLE},\hat{\sigma}^{MLE})^t = \left(\mathrm{X}_{(m+1)},\ \frac{1}{n}\sum_{i=1}^{n}|\mathrm{X}_i - \mathrm{X}_{(m+1)}|\right)^t$$

예 6.3.2 정규분포에서의 최대가능도 추정

정규분포 $\mathrm{N}(\mu,\sigma^2)(-\infty<\mu<+\infty, \sigma^2>0)$으로부터의 랜덤표본을 $\mathrm{X}_1, \cdots, \mathrm{X}_n$이라고 할 때 $\theta = (\mu,\sigma^2)^t$의 최대가능도 추정량을 구하여라.

[풀이] 정규분포 $\mathrm{N}(\mu,\sigma^2)$의 확률밀도함수는

$$pdf(x;\theta) = (2\pi\sigma^2)^{-1/2}\exp\left\{-\frac{1}{2}\frac{(x-\mu)^2}{\sigma^2}\right\},\ -\infty<x<+\infty$$

따라서 로그가능도함수는

$$l(\mu,\sigma^2) = -\frac{1}{2\sigma^2}\sum_{i=1}^{n}(x_i-\mu)^2 - \frac{n}{2}\log\sigma^2 - \frac{n}{2}\log 2\pi$$

로 주어지고, 이 로그가능도함수가 μ의 함수로서 표본평균 $\hat{\mu} = \bar{x}$에서 최대로 되는 것은 다음 등식에서 알 수 있다.

$$\sum_{i=1}^{n}(x_i-\mu)^2=\sum_{i=1}^{n}(x_i-\overline{x})^2+n(\overline{x}-\mu)^2$$

$$\therefore \max_{-\infty<\mu<+\infty} l(\mu,\sigma^2)=l(\hat{\mu},\sigma^2),\ \hat{\mu}=\overline{x}=\frac{1}{n}\sum_{i=1}^{n}x_i$$

또한 $\theta_2=\sigma^2$이라고 하여 $l(\hat{\mu},\sigma^2)=l(\hat{\mu},\theta_2)$의 증가, 감소를 조사하면

$$\frac{\partial}{\partial\theta_2}l(\hat{\mu},\theta_2)=\frac{1}{2\theta_2^2}\sum_{i=1}^{n}(x_i-\overline{x})^2-\frac{n}{2\theta_2}>0\Leftrightarrow\sigma^2=\theta_2<\frac{1}{n}\sum_{i=1}^{n}(x_i-\overline{x})^2$$

따라서 $l(\hat{\mu},\sigma^2)$은 $\widehat{\sigma^2}=\frac{1}{n}\sum_{i=1}^{n}(x_i-\overline{x})^2$에서 최대가 된다.

$$\therefore \max_{\sigma^2>0}\max_{-\infty<\mu<+\infty} l(\mu,\sigma^2)=\max_{\sigma^2>0} l(\hat{\mu},\sigma^2)=l(\hat{\mu},\widehat{\sigma^2}),\ \hat{\mu}=\overline{x},\ \widehat{\sigma^2}=\frac{1}{n}\sum_{i=1}^{n}(x_i-\overline{x})^2$$

$$\therefore \hat{\theta}^{MLE}=(\hat{\mu}^{MLE},\widehat{\sigma^2}^{MLE})^t=\left(\overline{X},\ \frac{1}{n}\sum_{i=1}^{n}(X_i-\overline{X})^2\right)^t$$

정리 6.3.1 **모수의 함수와 최대가능도 추정**

모수 θ의 최대가능도 추정량이 존재하고 $\eta=(\eta_1,\eta_2)^t=(g_1(\theta),g_2(\theta))^t,\ \theta\in\Omega$가 일대일 변환일 때, $\eta_1=g_1(\theta)$의 최대가능도 추정량은 다음과 같이 주어진다.

$$\widehat{\eta_1}^{MLE}=g_1(\hat{\theta}^{MLE})$$

[증명] <정리 6.2.3>으로부터 일대일 변환인

$$\eta=(\eta_1,\eta_2)^t=(g_1(\theta),g_2(\theta))^t=g(\theta),\ \theta\in\Omega$$

의 최대가능도 추정량은

$$\hat{\eta}^{MLE}=g(\hat{\theta}^{MLE})=(g_1(\hat{\theta}^{MLE}),g_2(\hat{\theta}^{MLE}))^t$$

로 주어지는 것을 알고 있다.

한편 $\eta_1=g_1(\theta)$는 다차원 모수 $\eta=(\eta_1,\eta_2)^t=(g_1(\theta),g_2(\theta))^t$의 첫 성분이므로 각 성분의 최대가능도 추정량의 정의에 따라 $\eta_1=g_1(\theta)$의 최대가능도 추정량은 $\hat{\eta}^{MLE}$의 첫 성분인

$$\widehat{\eta_1}^{MLE}=g_1(\hat{\theta}^{MLE})$$

로 주어진다.

<정리 6.3.1>을 이용하여 모수 θ의 함수인 $\eta_1=g_1(\theta)$의 최대가능도 추정값을 찾을 때에는 또 다른 함수 $\eta_2=g_2(\theta)$를 찾아

$$\eta = (\eta_1, \eta_2)^t = (g_1(\theta), g_2(\theta))^t,\ \theta \in \Omega$$

가 일대일 변환이 되도록 해야 한다.

예 6.3.3

(a) 정규분포 $\mathrm{N}(\mu, \sigma^2)(-\infty < \mu < +\infty, \sigma^2 > 0)$에서 모평균 μ의 부호를 나타내는 함수를

$$sgn(\mu) = \begin{cases} +1, & \mu > 0 \\ 0, & \mu = 0 \\ -1, & \mu < 0 \end{cases}$$

라고 하면 $\eta = (|\mu|, sgn(\mu), \sigma^2)^t$는 $\theta = (\mu, \sigma^2)^t$의 일대일 변환이다.

따라서 크기 n인 랜덤표본을 이용한 η의 최대가능도 추정량은

$$\hat{\eta}^{MLE} = (|\hat{\mu}^{MLE}|, sgn(\hat{\mu}^{MLE}), \widehat{\sigma^2}^{MLE})^t = \left(|\overline{\mathrm{X}}|, sgn(\overline{\mathrm{X}}), \frac{1}{n}\sum_{i=1}^{n}(\mathrm{X}_i - \overline{\mathrm{X}})^2\right)^t$$

이로부터 $\eta_1 = |\mu|$의 최대가능도 추정량은

$$\widehat{\eta_1}^{MLE} = |\overline{\mathrm{X}}|$$

(b) 베르누이분포 $\mathrm{Bernoulli}(p)\,(0 \le p \le 1)$의 모분산 $\sigma^2 = p(1-p)$에 대하여

$$\eta = (p(1-p), sgn(p - 1/2))^t$$

는 p의 일대일 변환이다. 따라서 크기 n인 랜덤표본을 이용한

$$\eta_1 = \sigma^2 = p(1-p)$$

의 최대가능도 추정량은 다음과 같이 주어진다.

$$\widehat{\eta_1}^{MLE} = \widehat{\sigma^2}^{MLE} = \hat{p}^{MLE}(1 - \hat{p}^{MLE}),\ \hat{p}^{MLE} = \frac{1}{n}\sum_{i=1}^{n}\mathrm{X}_i$$

다차원 모수의 경우에도 일차원의 경우와 마찬가지로 로그가능도함수의 일차편도함수를 0으로 하는 다음과 같은 가능도방정식의 근 $\hat{\theta}(x)$ 중에서 최대가능도 추정값을 찾을 수 있다.

$$\dot{l}(\theta; x) = (\partial l(\theta; x)/\partial\theta_1, \cdots, \partial l(\theta; x)/\partial\theta_k)^t = 0$$

이와 관련하여 다음의 정리들은 <정리 6.2.1>, <정리 6.2.2>를 다차원의 경우로 확장한 것이다.

예 6.3.4 다중모수 지수족으로서 정규분포 모형 $N(\mu,\sigma^2)$, $-\infty<\mu<+\infty$, $\sigma^2>0$

$$f(x;\theta)=(2\pi\sigma^2)^{-1/2}\exp\left\{-\frac{1}{2}\frac{(x-\mu)^2}{\sigma^2}\right\},\ -\infty<x<+\infty,\ \theta=(\mu,\sigma^2)^t$$

$\eta_1=\frac{\mu}{\sigma^2}$, $\eta_2=-\frac{1}{2\sigma^2}$로 모수의 변환을 하면 확률밀도함수가

$$pdf(x;\eta)=\exp\{\eta_1 x+\eta_2 x^2-A(\eta)\},\ -\infty<x<+\infty,\ -\infty<\eta_1<+\infty,\ \eta_2<0$$

$$A(\eta)=\eta_1^2/(-4\eta_2)-\{\log(-\eta_2/\pi)\}/2$$

의 꼴로 주어지고 <정리 6.3.4>의 조건이 만족되는 것을 알 수 있다.

이로부터 크기 n인 랜덤표본에 기초한 로그가능도함수는

$$l(\eta_1,\eta_2)=\eta_1\sum_{i=1}^{n}x_i+\eta_2\sum_{i=1}^{n}x_i^2-nA(\eta)$$

로 주어지고, 모수 $\theta=(\mu,\sigma^2)^t$를 이용하여 가능도방정식을 나타내면

$$E_\theta(X_1)=\frac{1}{n}\sum_{i=1}^{n}x_i,\ E_\theta(X_1^2)=\frac{1}{n}\sum_{i=1}^{n}x_i^2,\ \theta=(\mu,\sigma^2)^t,\ -\infty<\mu<+\infty,\ \sigma^2>0$$

따라서 μ, σ^2의 최대가능도 추정값을 각각 $\hat{\mu}$, $\widehat{\sigma^2}$이라고 하면

$$\hat{\mu}=\frac{1}{n}\sum_{i=1}^{n}x_i=\bar{x},\ \widehat{\sigma^2}+(\hat{\mu})^2=\frac{1}{n}\sum_{i=1}^{n}x_i^2$$

$$\therefore\ \hat{\mu}^{MLE}=\bar{X},\ \widehat{\sigma^2}^{MLE}=\frac{1}{n}\sum_{i=1}^{n}(X_i-\bar{X})^2$$

예 6.3.5 이변량 정규분포 모형

이변량 정규분포 $N(\mu_1,\mu_2;\sigma_1^2,\sigma_2^2,\rho)(-\infty<\mu_j<+\infty,\ \sigma_j^2>0(j=1,2),\ -1<\rho<1)$의 확률밀도함수는

$$f(x,y;\theta)=\frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}}e^{-\frac{1}{2}Q},\ \theta=(\mu_1,\mu_2,\sigma_1^2,\sigma_2^2,\rho)^t$$

$$Q=\frac{1}{1-\rho^2}\left\{\left(\frac{x-\mu_1}{\sigma_1}\right)^2-2\rho\left(\frac{x-\mu_1}{\sigma_1}\right)\left(\frac{y-\mu_2}{\sigma_2}\right)+\left(\frac{y-\mu_2}{\sigma_2}\right)^2\right\}$$

$$\eta_1=\frac{\mu_1}{(1-\rho^2)\sigma_1^2},\ \eta_2=\frac{\mu_2}{(1-\rho^2)\sigma_2^2},\ \eta_3=\frac{\rho}{(1-\rho^2)\sigma_1\sigma_2},$$

$$\eta_4=-\frac{1}{2(1-\rho^2)\sigma_1^2},\ \eta_5=-\frac{1}{2(1-\rho^2)\sigma_2^2}$$

로 모수의 변환을 하면 확률밀도함수가

$$pdf(x;\eta) = \exp\{\eta_1 x + \eta_2 y + \eta_3 xy + \eta_4 x^2 + \eta_5 y^2 - A(\eta)\},$$
$$-\infty < x < +\infty,\ -\infty < y < +\infty$$

의 꼴로 나타낼 수 있고, 모수의 범위는 $-\infty < \eta_j < +\infty\,(j=1,2,3)$, $\eta_j < 0\,(j=4,5)$이며 <정리 6.3.2>의 조건이 만족되는 것을 알 수 있다.

이로부터 모수 $\theta = (\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)^t$를 이용하여 크기 n인 랜덤표본에 기초한 가능도방정식을 나타내면 다음과 같이 주어진다.

$$E_\theta(X_1) = \frac{1}{n}\sum_{i=1}^{n} x_i,\ E_\theta(Y_1) = \frac{1}{n}\sum_{i=1}^{n} y_i$$

$$E_\theta(X_1 Y_1) = \frac{1}{n}\sum_{i=1}^{n} X_i Y_i,\ E_\theta(X_1^2) = \frac{1}{n}\sum_{i=1}^{n} X_i^2,\ E_\theta(Y_1^2) = \frac{1}{n}\sum_{i=1}^{n} Y_i^2$$

따라서 μ_j, $\sigma_j^2\,(j=1,2)$, ρ의 최대가능도 추정값을 각각 $\hat{\mu_j}$, $\hat{\sigma_j^2}\,(j=1,2)$, $\hat{\rho}$라고 하면

$$\hat{\mu_1} = \frac{1}{n}\sum_{i=1}^{n} x_i = \bar{x},\ \hat{\mu_2} = \frac{1}{n}\sum_{i=1}^{n} y_i = \bar{y}$$

$$\hat{\rho}\hat{\sigma_1}\hat{\sigma_2} + \hat{\mu_1}\hat{\mu_2} = \frac{1}{n}\sum_{i=1}^{n} x_i y_i,\ \hat{\sigma_1^2} + (\hat{\mu_1})^2 = \frac{1}{n}\sum_{i=1}^{n} x_i^2,\ \hat{\sigma_2^2} + (\hat{\mu_2})^2 = \frac{1}{n}\sum_{i=1}^{n} y_i^2$$

이로부터 모상관계수 ρ의 최대가능도 추정량은

$$\hat{\rho}^{MLE} = \frac{\sum_{i=1}^{n}(X_i - \overline{X})(Y_i - \overline{Y})}{\sqrt{\sum_{i=1}^{n}(X_i - \overline{X})^2}\sqrt{\sum_{i=1}^{n}(Y_i - \overline{Y})^2}}$$

예 6.3.6 **다항분포 모형** $\text{Multi}(n,(p_1,\cdots,p_k)^t),\ p_1+\cdots+p_k=1,\ p_j>0,\ j=1,\cdots,k$

$X = (X_1,\cdots,X_k)^t \sim \text{Multi}(n,(p_1,\cdots,p_k)^t)$ 일 때, X의 확률밀도함수는

$$f(x;p) = \binom{n}{x_1\ \cdots\ x_k} p_1^{x_1}\cdots p_k^{x_k},\ x_1+\cdots+x_k = n,$$
$$x_j = 0,\cdots,n\,(j=1,\cdots,k),\ p = (p_1,\cdots,p_k)^t$$

여기에서 $X_1+\cdots+X_k = n$, $p_1+\cdots+p_k = 1$이므로 이러한 종속성을 없애기 위하여

$Y_j = X_j,\ \mu_j = p_j\,(j=1,\cdots,r),\ Y=(Y_1,\cdots,Y_r)^t,\ \mu=(\mu_1,\cdots,\mu_r)^t,\ r=k-1$

이라고 하고

$$\eta_j = \log p_j/p_k\,(j=1,\cdots,r)$$

를 모수로 하여 $Y=(Y_1,\cdots,Y_r)^t$의 확률밀도함수를 나타내면

$$pdf(y;\eta) = \exp\{\eta_1 y_1 + \cdots + \eta_r y_r - nA(\eta) + S(y)\}$$

$A(\eta) = \log(1+e^{\eta_1}+\cdots+e^{\eta_r}),\ S(y) = \log\binom{n}{y_1\ \cdots\ y_r\ x_k},\ x_k = n-y_1-\cdots-y_r$

의 꼴로 나타낼 수 있고, 모수의 범위는 $-\infty<\eta_j<+\infty\,(j=1,\cdots,r)$이며 <정리 6.3.4>의 조건이 만족되는 것을 알 수 있다.

따라서 모수 $p=(p_1,\cdots,p_k)^t$를 이용하여 가능도방정식을 나타내면 다음과 같이 주어진다.

$$E_p(Y_1)=y_1,\cdots,E_p(Y_r)=y_r,\ 0<p_j(j=1,\cdots,r),\ p_1+\cdots+p_r<1$$

이로부터 $p=(p_1,\cdots,p_k)^t$의 최대가능도 추정값을 $\hat{p}=(\hat{p_1},\cdots,\hat{p_k})^t$라고 하면

$$n\hat{p_1}=y_1,\cdots,n\hat{p_r}=y_r,\ 0<\hat{p_j}\,(j=1,\cdots,r),\ \hat{p_1}+\cdots+\hat{p_r}<1$$

그러므로 <예 6.2.5>의 (a)에서와 같이 $0<x_j/n<1\,(j=1,\cdots,k)$인 경우에

$$\hat{p_j}^{MLE} = x_j/n\ \ (j=1,\cdots,k)$$

6.4 최대가능도 추정량의 점근적 성질

표본크기가 커짐에 따라 추정값이 추정대상의 참값에 가까워져야 한다는 일치성은 추정량에 요구되는 가장 기본적인 성질이다. 이러한 기본적인 성질에 추가하여 추정량의 극한분포를 안다면 그 추정량을 이용한 추정대상의 신뢰구간 제공과 같은 통계적 추론을 할 수 있다. 이 절에서는 최대가능도 추정량의 일치성에 대하여 알아보고 로그 가능도함수의 여러 가지 성질로부터 최대가능도 추정량의 극한분포를 유도할 수 있음을 알아본다.

예 6.4.1 최대가능도 추정량의 일치성과 극한분포

(a) 베르누이분포 모형 $\text{Bernoulli}(p),\ 0\le p\le 1$:

크기 n인 랜덤표본 $X_1,\ \cdots,\ X_n$을 이용한 p의 최대가능도 추정량이

$$\hat{p}_n^{MLE} = \sum_{i=1}^{n} X_i / n$$

임은 <예 6.2.2>와 <예 6.2.5>에서 밝혔다. 이는 적률이용추정량과 일치하며 <정리 6.1.1>에서와 같이 대수의 법칙으로부터 다음과 같은 일치성을 갖는 것을 알 수 있다.

$$\hat{p}_n^{MLE} \underset{n\to\infty}{\overset{P_p}{\to}} p \quad \forall p : 0 \le p \le 1, \text{ 즉}$$

$$\lim_{n\to\infty} P_p(|\hat{p}_n^{MLE} - p| \ge \epsilon) = 0 \quad \forall \epsilon > 0, \ \forall p : 0 \le p \le 1$$

또한, 중심극한정리로부터 다음과 같이 정규분포를 극한분포로 갖는 것을 알 수 있다.

$$\sqrt{n}(\hat{p}_n^{MLE} - p) \underset{n\to\infty}{\overset{d}{\to}} N(0, p(1-p))$$[96]

(b) 포아송분포 모형 $\text{Poisson}(\lambda)$, $\lambda \ge 0$:

크기 n인 랜덤표본 $X_1, \cdots, X_n$을 이용한 λ의 최대가능도 추정량이

$$\hat{\lambda}_n^{MLE} = \sum_{i=1}^{n} X_i / n$$

임은 <예 6.2.1>과 <예 6.2.5>에서 밝혔다. 이는 적률이용추정량과 일치하며 <정리 6.1.1>에서와 같이 대수의 법칙으로부터 다음과 같은 일치성을 갖는 것을 알 수 있다.

$$\hat{\lambda}_n^{MLE} \underset{n\to\infty}{\overset{P_\lambda}{\to}} \lambda \quad \forall \lambda : \lambda \ge 0$$

또한, 중심극한정리로부터 다음과 같이 정규분포를 극한분포로 갖는 것을 알 수 있다.

$$\sqrt{n}(\hat{\lambda}_n^{MLE} - \lambda) \underset{n\to\infty}{\overset{d}{\to}} N(0, \lambda)$$

(c) 지수분포 모형 $\text{Exp}(\theta)$, $\theta > 0$:

크기 n인 랜덤표본 $X_1, \cdots, X_n$을 이용한 θ의 최대가능도 추정량이

$$\hat{\theta}_n^{MLE} = \sum_{i=1}^{n} X_i / n$$

---

96) 이러한 표현은 다음과 같은 표현을 간략하게 나타낸 것이다.

$$\sqrt{n}(\hat{p}_n^{MLE} - p) \underset{n\to\infty}{\overset{d}{\to}} Z, \ Z \sim N(0, p(1-p))$$

임은 <예 6.2.4>와 <예 6.2.5>에서 밝혔다. 이는 적률이용추정량과 일치하며 <정리 6.1.1>에서와 같이 대수의 법칙으로부터 다음과 같은 일치성을 갖는 것을 알 수 있다.

$$\hat{\theta}_n^{MLE} \underset{n\to\infty}{\overset{P_\theta}{\to}} \theta \quad \forall\, \theta : \theta > 0$$

또한, 중심극한정리로부터 다음과 같이 정규분포를 극한분포로 갖는 것을 알 수 있다.

$$\sqrt{n}\,(\hat{\theta}_n^{MLE} - \theta) \underset{n\to\infty}{\overset{d}{\to}} \mathrm{N}(0, \theta^2)$$

(d) 정규분포모형 $\mathrm{N}(\mu, \sigma^2),\ -\infty < \mu < +\infty,\ \sigma^2 > 0$:

<예 6.3.4>로부터 크기 n인 랜덤표본 $\mathrm{X}_1, \cdots, \mathrm{X}_n$을 이용한 μ, σ^2의 최대가능도 추정량은

$$\hat{\mu}_n^{MLE} = \overline{\mathrm{X}},\ \hat{\sigma}_n^{2\,MLE} = \frac{1}{n}\sum_{i=1}^{n}(\mathrm{X}_i - \overline{\mathrm{X}})^2$$

이는 적률이용추정량과 일치하며 <정리 6.1.1>에서와 같이 대수의 법칙으로부터 다음과 같은 일치성을 갖는 것을 알 수 있다.

$$\hat{\mu}_n^{MLE} \underset{n\to\infty}{\overset{P_\theta}{\to}} \mu,\ \hat{\sigma}_n^{2\,MLE} \underset{n\to\infty}{\overset{P_\theta}{\to}} \sigma^2 \quad \forall\, \theta = (\mu, \sigma^2)^t : -\infty < \mu < +\infty,\ \sigma^2 > 0$$

한편 이 경우에는 <정리 4.2.2>의 표본분포에 관한 기본 정리로부터 표본크기에 관계없이

$$\sqrt{n}\,(\hat{\mu}_n^{MLE} - \mu) = \sqrt{n}\,(\overline{\mathrm{X}} - \mu) \sim \mathrm{N}(0, \sigma^2)$$

즉 이 경우에는 $\hat{\mu}_n^{MLE}$의 표본분포는 표본크기에 관계없이 정규분포이다.

또한 σ^2의 최대가능도 추정량에 대해서도 이 경우에는 <정리 4.2.2>로부터 표본크기에 관계없이 카이제곱분포로 주어지는 표본분포, 즉

$$n\hat{\sigma}_n^2/\sigma^2 \sim \chi^2(n-1)$$

임을 알고 있다. 한편 표본크기가 큰 경우에는 <예 5.3.2>로부터 다음과 같이 정규분포를 표본분포의 극한분포로 가지는 것을 알 수 있다.

$$\sqrt{n}\,(\hat{\sigma}_n^{2\,MLE} - \sigma^2) \underset{n\to\infty}{\overset{d}{\to}} \mathrm{N}(0, 2\sigma^4)$$

(e) 이변량 정규분포모형

이변량 정규분포 $\mathrm{N}(\mu_1, \mu_2; \sigma_1^2, \sigma_2^2, \rho)(-\infty < \mu_j < +\infty,\ \sigma_j^2 > 0 (j = 1,2),\ -1 < \rho < 1)$에서 크기 n인 랜덤표본을 이용한 모수의 최대가능도 추정량

은 <예 6.3.5>에서 알아보았다. 이로부터 모상관계수 ρ의 최대가능도 추정량은

$$\widehat{\rho_n}^{MLE} = \frac{\sum_{i=1}^{n}(X_i - \overline{X})(Y_i - \overline{Y})}{\sqrt{\sum_{i=1}^{n}(X_i - \overline{X})^2}\sqrt{\sum_{i=1}^{n}(Y_i - \overline{Y})^2}}$$

로 주어진다. 이는 적률이용추정량과 일치하며 <예 6.1.3>으로부터 일치성을 가질 뿐만 아니라 <예 5.3.6>, <예 5.3.7>로부터 다음과 같이 정규분포를 극한분포로 가지는 것을 알 수 있다.

$$\sqrt{n}(\widehat{\rho_n}^{MLE} - \rho) \xrightarrow[n\to\infty]{d} N(0, (1-\rho^2)^2)$$

<예 6.4.1>에서의 최대가능도 추정량은 모두 일치성을 갖고 표분분포의 극한분포가 정규분포이었다. 그러나 이 경우에는 최대가능도 추정량이 모두 적률이용추정량과 일치하는 예로서 그 성질 또한 적률이용추정량의 성질로부터 밝혀낸 것이다. 이제 일반적인 경우에도 최대가능도 추정량이 이러한 성질을 갖는지 알아보자.

첫째로 최대가능도 추정량이 일치성을 가지기 위하여는 어떤 조건들이 필요한가를 직관적으로 살펴보기로 하자. 크기 n인 랜덤표본 $X_1, \cdots, X_n$을 이용한 로그가능도함수가

$$l_n(\theta) = \sum_{i=1}^{n} \log f(X_i;\theta)$$

로서 n개의 서로 독립이고 동일한 분포를 따르는 확률변수의 합이므로, 평균 로그가능도를

$$\overline{l_n}(\theta) = \frac{1}{n}\sum_{i=1}^{n} \log f(X_i;\theta)$$

로 나타내자. 또한 최대가능도 추정량이 유일하게 정해질 수 있다는 전제하에 최대가능도 추정량을 다음과 같이[97] 나타내자.

$$\widehat{\theta_n} = \arg\max_{\theta\in\Omega} l_n(\theta) = \arg\max_{\theta\in\Omega} \overline{l_n}(\theta)$$

---

97) 여기에서 $\arg\max_{\theta\in\Omega} \overline{l_n}(\theta)$는 'argument of maximizing'의 약자로서 $\overline{l_n}(\theta)$를 최대로 하는 $\theta\in\Omega$ 값을 뜻하는 기호이다. 이 기호가 명확한 의미를 가지려면 최대로 하는 $\theta\in\Omega$의 값이 유일하게 존재하여야 하는 것이다.

여기에서 $\overline{l_n}(\theta)$는 서로 독립이고 동일한 분포를 따르는 확률변수들의 평균이므로 기댓값이 존재한다는 전제하에 모수의 참값이 θ^0라고 하면 대수의 법칙으로부터

$$\overline{l_n}(\theta)=\frac{1}{n}\sum_{i=1}^{n}\log f(\mathrm{X}_i;\theta)\underset{n\to\infty}{\overset{\mathrm{P}_{\theta^0}}{\to}}\mathrm{E}_{\theta^0}[\log f(\mathrm{X}_1;\theta)]$$

이로부터 다음과 같은 추측을 할 수 있을 것이다.

$$Q:\widehat{\theta_n}=\arg\max_{\theta\in\Omega}\overline{l_n}(\theta)\underset{n\to\infty}{\overset{\mathrm{P}_{\theta^0}}{\to}}\arg\max_{\theta\in\Omega}\mathrm{E}_{\theta^0}[\log f(\mathrm{X}_1;\theta)]\ ?$$

그런데 다음 정리에서 알 수 있듯이 $\arg\max_{\theta\in\Omega}\mathrm{E}_{\theta^0}[\log f(\mathrm{X}_1;\theta)]=\theta^0$이므로 위의 추측은 최대가능도 추정량 $\widehat{\theta_n}$이 참값 θ^0로 확률수렴하는 일치성을 뜻하는 추측이다.

정리 6.4.1 쿨백 라이블러 괴리도[98](Kullback–Leibler divergence)

확률변수 X의 분포에 대한 모형으로서 확률밀도함수의 모형 $f(x;\theta),\ \theta\in\Omega$가 다음의 두 조건을 만족한다고 하자.

$(R0)$ (식별 가능성)[99] $f(\circ\ ;\theta)=f(\circ\ ;\theta^0)\Rightarrow\theta=\theta^0$

$(R1)$ (공통의 토대) $\{x:f(x;\theta)>0\}=\mathscr{X}$로서 $\theta\in\Omega$에 의존하지 않는다.

이 때

$$KL(\theta,\theta^0)=-\mathrm{E}_{\theta^0}[\log\{f(\mathrm{X};\theta)/f(\mathrm{X};\theta^0)\}]$$

라고 하면 다음이 성립한다.

(i) $KL(\theta,\theta^0)\geq 0\quad\forall\theta\in\Omega$

(ii) $KL(\theta,\theta^0)=0\Leftrightarrow\theta=\theta^0$

[증명] 모든 실수 t에 대하여 성립하는 부등식

$$-\log t\geq -t+1$$

로부터 다음 부등식이 성립한다.

$$-\log\{f(\mathrm{X};\theta)/f(\mathrm{X};\theta^0)\}\geq -f(\mathrm{X};\theta)/f(\mathrm{X};\theta^0)+1$$

따라서 이 부등식의 양변에 θ^0일 때의 분포에 대한 기댓값을 취하고 조건 $(R1)$을 이용하면

98) <정리 6.4.1>에서의 $KL(\theta,\theta^0)$는 두 분포가 서로 다른 정도를 나타내는 측도로서 쿨백-라이블러(Kullback-Leibler) 괴리도(乖離度, divergence)라고 한다.

99) 식별 가능성의 정확한 뜻은 θ일 때의 분포와 θ^0일 때의 분포가 같으면 $\theta=\theta^0$인 것을 뜻한다.

함수 $l_n(\theta)$가 두 번 편미분 가능하고 이차편도함수들이 연속함수이며 두 조건

(순오목 단봉 로그가능도)

$$c^t \ddot{l}_n(\theta)c < 0,\ \forall c \neq 0,\ \forall \theta \in \Omega \text{이고} \lim_{\theta \to \partial(\Omega)} l_n(\theta) = -\infty$$

(기대 로그가능도의 연속성)

$$\forall \theta^0 \in \Omega,\ \mathrm{E}_{\theta^0}[\log f(\mathrm{X}_1;\theta)] \text{가 존재하고 } \theta \in \Omega \text{에 관한 연속함수}$$

이 만족될 때, 최대가능도 추정량 $\hat{\theta}_n^{MLE}$은 가능도방정식의 유일한 근이며 일치성을 갖는다. 즉

$$\dot{l}_n(\hat{\theta}_n^{MLE}) = 0,\ \hat{\theta}_n^{MLE} \underset{n \to \infty}{\overset{\mathrm{P}_\theta}{\to}} \theta,\ \forall \theta \in \Omega$$

예 6.4.2 **로지스틱분포 모형** $\mathrm{L}(\theta,1),\ -\infty < \theta < +\infty$

로지스틱분포 $\mathrm{L}(\theta,1)$의 확률밀도함수는

$$f(x;\theta) = \frac{e^{x-\theta}}{(1+e^{x-\theta})^2} = \frac{e^{-x+\theta}}{(1+e^{-x+\theta})^2},\ -\infty < x < +\infty$$

이고 로그가능도함수

$$l_n(\theta) = n\bar{x} - n\theta - 2\sum_{i=1}^{n}\log(1+e^{x_i-\theta}) = -n\bar{x} + n\theta - 2\sum_{i=1}^{n}\log(1+e^{-x_i+\theta})$$

에 대하여 순오목 단봉 로그가능도의 조건이 만족되는 것은 <예 6.2.3>에서 밝혔으며 기대 로그가능도의 연속성 조건 또한 성립하는 것을 밝힐 수 있다. 따라서 가능도방정식

$$\dot{l}_n(\theta) = n - 2\sum_{i=1}^{n} e^{-x_i+\theta}/(1+e^{-x_i+\theta}) = 0$$

의 근으로 주어지는 최대가능도 추정량 $\hat{\theta}_n^{MLE}$은 일치성을 갖는다.

예 6.4.3 **감마분포 모형** $\mathrm{Gamma}(\alpha,\beta),\ \alpha > 0,\ \beta > 0$

감마분포 $\mathrm{Gamma}(\alpha,\beta)$의 확률밀도함수는

$$f(x;\theta) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta} \mathrm{I}_{(x>0)},\ \theta = (\alpha,\beta)^t$$

이고 크기 n인 랜덤표본을 이용한 로그가능도함수는 다음과 같이 주어진다.

$$l_n(\theta) = -n\log\Gamma(\alpha) - n\alpha\log\beta + (\alpha-1)\sum_{i=1}^{n}\log x_i - \sum_{i=1}^{n}x_i/\beta,\ \theta=(\alpha,\beta)^t$$

이 경우에 확률밀도함수는 다중모수 지수족에 속하는 경우로서 <정리 6.4.2>의 조건이 만족되는 것을 알 수 있다. 한편 간략한 표현을 위하여

$$\overline{(\log x)} = n^{-1}\sum_{i=1}^{n}\log x_i,\ \bar{x} = n^{-1}\sum_{i=1}^{n}x_i,\ \Psi(\alpha) = \frac{\partial}{\partial\alpha}\log\Gamma(\alpha)$$

라고 하면 가능도방정식은 다음과 같이 주어진다.

$$\begin{cases}\partial l_n(\theta)/\partial\alpha = -n\Psi(\alpha) - n\log\beta + n\overline{(\log x)} = 0\\ \partial l_n(\theta)/\partial\beta = -n\alpha/\beta + n\bar{x}/\beta^2 = 0\end{cases}$$

따라서 이 방정식의 근으로 주어지는 최대가능도 추정량 $\widehat{\alpha_n}^{MLE}$, $\widehat{\beta_n}^{MLE}$은 일치성을 갖는다.

다음에는 최대가능도 추정량의 일치성에 추가하여 그 극한분포에 대하여 알아보자. 대수의 법칙과 중심극한정리를 이용하여 그 극한분포에 대하여 알아볼 것이므로, 최대가능도 추정량을 확률변수들의 산술평균들에 의해 표현할 수 있는지 직관적으로 생각해보자.

최대가능도 추정량을 $\widehat{\theta_n}$이라고 하고 평균 로그가능도함수를

$$\overline{l_n}(\theta) = n^{-1}l_n(\theta) = n^{-1}\sum_{i=1}^{n}\log f(\mathrm{X}_i;\theta)$$

라고 하면 최대가능도 추정량은 가능도방정식의 근이므로 적절한 조건하에서

$$0 = \overline{\dot{l}_n}(\widehat{\theta_n}) \simeq \overline{\dot{l}_n}(\theta) + \overline{\ddot{l}_n}(\theta)(\widehat{\theta_n}-\theta)$$

$$\therefore\ \sqrt{n}(\widehat{\theta_n}-\theta) \simeq (-\overline{\ddot{l}_n}(\theta))^{-1}\sqrt{n}\,\overline{\dot{l}_n}(\theta)$$

한편 대수의 법칙으로부터 적절한 조건하에서

$$-\overline{\ddot{l}_n}(\theta) = \frac{1}{n}\sum_{i=1}^{n}\left[-\frac{\partial^2}{\partial\theta^2}\log f(\mathrm{X}_i;\theta)\right] \underset{n\to\infty}{\overset{\mathrm{P}_\theta}{\to}} \mathrm{E}_\theta\left[-\frac{\partial^2}{\partial\theta^2}\log f(\mathrm{X}_1;\theta)\right]$$

따라서

$$I(\theta) = \mathrm{E}_\theta\left[-\frac{\partial^2}{\partial\theta^2}\log f(\mathrm{X}_1;\theta)\right]$$

라고 하면

$$\sqrt{n}(\widehat{\theta_n}-\theta) \simeq [I(\theta)]^{-1}\sqrt{n}\,\overline{\dot{l}_n}(\theta)$$

그런데 $\frac{\partial}{\partial\theta}\log f(\mathrm{X}_i;\theta)\,(i=1,\cdots,n)$는 서로 독립이고 동일한 분포를 따르는 확률변수이므로 중심극한정리로부터 다음과 같은 극한분포를 얻는다.

$$\sqrt{n}\left(n^{-1}\sum_{i=1}^{n}\frac{\partial}{\partial\theta}\log f(\mathrm{X}_i;\theta)-\mathrm{E}_\theta\left[\frac{\partial}{\partial\theta}\log f(\mathrm{X}_1;\theta)\right]\right)$$

$$\xrightarrow[n\to\infty]{d}\mathrm{N}\left(0,\mathrm{Var}_\theta\left[\frac{\partial}{\partial\theta}\log f(\mathrm{X}_1;\theta)\right]\right)$$

$$\therefore\ \sqrt{n}\left(\dot{\bar{l}}_n(\theta)-\mathrm{E}_\theta\left[\frac{\partial}{\partial\theta}\log\ f(\mathrm{X}_1;\theta)\right]\right)\xrightarrow[n\to\infty]{d}\mathrm{N}\left(0,\mathrm{Var}_\theta\left[\frac{\partial}{\partial\theta}\log f(\mathrm{X}_1;\theta)\right]\right)$$

한편 적절한 조건하에서 이 기댓값은

$$\begin{aligned}\mathrm{E}_\theta\left[\frac{\partial}{\partial\theta}\log f(\mathrm{X}_1;\theta)\right]&=\int_{-\infty}^{+\infty}\left\{\frac{\partial}{\partial\theta}f(x;\theta)/f(x;\theta)\right\}f(x;\theta)\,dx\\&=\int_{-\infty}^{+\infty}\frac{\partial}{\partial\theta}f(x;\theta)\,dx\\&=\frac{\partial}{\partial\theta}\int_{-\infty}^{+\infty}f(x;\theta)\,dx\\&=0\end{aligned}$$

인 것을 알 수 있으므로

$$\sqrt{n}\,\dot{\bar{l}}_n(\theta)\xrightarrow[n\to\infty]{d}\mathrm{N}\left(0,\mathrm{Var}_\theta\left[\frac{\partial}{\partial\theta}\log f(\mathrm{X}_1;\theta)\right]\right)$$

$$\therefore\ \sqrt{n}(\hat{\theta}_n-\theta)\simeq[I(\theta)]^{-1}\sqrt{n}\,\dot{\bar{l}}_n(\theta)\xrightarrow[n\to\infty]{d}\mathrm{N}\left(0,\,[I(\theta)]^{-2}\mathrm{Var}_\theta\left[\frac{\partial}{\partial\theta}\log f(\mathrm{X}_1;\theta)\right]\right)$$

따라서 적절한 조건하에서 최대가능도 추정량의 극한분포가 정규분포로 주어질 것이라고 추측할 수 있다. 이러한 성질을 점근 정규성(漸近 正規性, asymptotic normality)이라고 한다.

이러한 직관적 논의에서 분명히 해야 할 것은 잉여항의 처리, 분산의 정의와 기댓값의 계산에서 적분과 미분 순서의 교환 등에 관한 조건들이다.

최대가능도 추정량의 점근 정규성을 위한 기본 조건:

($R0$) (식별 가능성) $f(\circ\,;\theta)=f(\circ\,;\theta^0)\Rightarrow\theta=\theta^0$

($R1$) (공통의 토대) $\{x:f(x;\theta)>0\}=\mathscr{X}$로서 $\theta\in\Omega$에 의존하지 않는다.

($R2$) (열린 모수공간) 모수공간 Ω는 k 차원 공간 R^k에서의 열린집합이다.

($R3$) (미분가능한 로그가능도) 모든 관측 결과 $(x_1,\cdots,x_k)^t$, $x_i\in\mathscr{X}$ $(i=1,\cdots,n)$에

한편 <정리 6.4.4> 증명의 마지막 단계에서 알 수 있듯이 적절한 조건하에서

$$\sqrt{n}(\hat{\theta}_n^{MLE}-\theta)=[I(\theta)]^{-1}\sqrt{n}\,\bar{l}_n'(\theta)+o_n,\ o_n \xrightarrow[n\to\infty]{P_\theta} 0$$

이라는 근사식이 성립하는 것을 알 수 있다. 즉 최대가능도 추정량의 추정 오차는 $\sqrt{n}\,\bar{l}_n'(\theta)$에 따라 정해지고 그 정밀도는 $I(\theta)$가 커질수록 좋아지는 것을 알 수 있고, 이러한 의미에서 $\sqrt{n}\,\bar{l}_n'(\theta)$를 최대가능도 추정량의 추정점수를 나타내는 점수함수, $I(\theta)$를 최대가능도 추정량의 추정 정밀도를 나타내는 정보량이라고 부르는 것이다.

<예 6.4.2> 또는 <예 6.4.3>에서와 같이 최대가능도 추정량의 구체적인 형태를 모르고 가능도방정식의 근으로 주어지는 경우에는 2절에서 소개된 것과 일단계 반복법에 의하여 최대가능도 추정량을 근사하게 된다. 이러한 일단계 반복법에 의한 근사 추정량에 대하여 다음이 성립하는 것을 <정리 6.4.4>와 같은 방법으로 밝힐 수 있다.

정리 6.4.5 **일단계 반복법에 의한 최대가능도 추정량의 근사**

확률밀도함수가 $f(x;\theta),\ \theta\in\Omega$인 확률모형에서 <정리 6.4.4>의 조건 $(R0)\sim(R7)$이 만족되고, 다음 조건을 만족하는 추정량 $\hat{\theta}_n^{(0)}$이 있다고 하자.

$(R8)$ $\sqrt{n}(\hat{\theta}_n^{(0)}-\theta)$가 극한분포를 갖는다. 즉 $\sqrt{n}(\hat{\theta}_n^{(0)}-\theta)\xrightarrow[n\to\infty]{d} Z$인 확률변수 Z가 있다. 이 때 초기 추정량 $\hat{\theta}_n^{(0)}$과 가능도방정식의 일차 근사를 이용하여

$$\hat{\theta}_n^{(1)}=\hat{\theta}_n^{(0)}+[-\bar{l}_n''(\hat{\theta}_n^{(0)})]^{-1}\bar{l}_n'(\hat{\theta}_n^{(0)})$$

로 정의된 $\hat{\theta}_n^{(1)}$은 최대가능도 추정량과 같은 극한분포를 갖는다. 즉

$$\sqrt{n}(\hat{\theta}_n^{(1)}-\theta)\xrightarrow[n\to\infty]{d} N(0,[I(\theta)]^{-1})$$

예 6.4.4 **로지스틱분포 모형 $L(\theta,1),\ -\infty<\theta<+\infty$**

로지스틱분포 $L(\theta,1)$의 확률밀도함수는

$$f(x;\theta)=\frac{e^{x-\theta}}{(1+e^{x-\theta})^2}=\frac{e^{-x+\theta}}{(1+e^{-x+\theta})^2},\ -\infty<x<+\infty$$

이고 크기 n인 랜덤표본을 이용한 로그가능도함수와 그 도함수들은 다음과 같이 주어진다.

$$l_n(\theta) = n\bar{x} - n\theta - 2\sum_{i=1}^{n}\log(1+e^{x_i-\theta}) = -n\bar{x} + n\theta - 2\sum_{i=1}^{n}\log(1+e^{-x_i+\theta})$$

$$\dot{l}_n(\theta) = n - 2\sum_{i=1}^{n} e^{-x_i+\theta}/(1+e^{-x_i+\theta}),\ \ \ddot{l}_n(\theta) = -2\sum_{i=1}^{n} e^{-x_i+\theta}/(1+e^{-x_i+\theta})^2$$

이로부터 <예 6.4.2>에서 밝혔듯이 θ의 최대가능도 추정값은 가능도방정식

$$\dot{l}_n(\theta) = 0$$

의 하나뿐인 근으로 주어지고, 표본평균인 $\hat{\theta}_n^{(0)} = \overline{x_n}$와 가능도방정식의 일차 근사로부터

$$\hat{\theta}_n^{(1)} = \hat{\theta}_n^{(0)} + [-\ddot{l}_n(\hat{\theta}_n^{(0)})]^{-1}\dot{l}_n(\hat{\theta}_n^{(0)}),\ \ \hat{\theta}_n^{(0)} = \overline{x_n}$$

로 정의되는 반복법을 이용하여 최대가능도 추정값의 근사값인 $\hat{\theta}_n^{(1)}$을 구할 수 있다.

한편 로지스틱분포 $\mathrm{L}(\theta,1)$의 평균은 θ이고 분산은 <예 5.4.3>에서 밝혔듯이 $\pi^2/3$이므로 이 경우에 적률이용추정량인 $\hat{\theta}_n^{(0)} = \overline{\mathrm{X}_n}$의 극한분포는 중심극한정리로부터

$$\sqrt{n}(\hat{\theta}_n^{(0)} - \theta) \xrightarrow[n\to\infty]{d} \mathrm{N}(0,\pi^2/3)$$

또한 <예 5.4.3>에서 밝혔듯이

$$\mathrm{X}_1 - \theta \overset{d}{\equiv} \log\frac{\mathrm{U}}{1-\mathrm{U}},\ \ \frac{1}{1+e^{-(\mathrm{X}_1-\theta)}} \overset{d}{\equiv} \mathrm{U},\ \ \mathrm{U}\sim\mathrm{U}(0,1)$$

이므로 이 경우에 정보량은 다음과 같이 주어진다.

$$I(\theta) = \mathrm{E}_\theta[-\ddot{l}_1(\theta)] = 2\mathrm{E}[\mathrm{U}(1-\mathrm{U})] = 1/3$$

이 경우에 <정리 6.4.5>의 다른 조건들도 성립하는 것이 알려져 있으므로 일단계 반복법에 의한 추정량 $\hat{\theta}_n^{(1)}$은 다음의 극한분포를 갖는다.

$$\sqrt{n}(\hat{\theta}_n^{(1)} - \theta) \xrightarrow[n\to\infty]{d} \mathrm{N}(0,3)$$

예 6.4.5 **감마분포 모형 Gamma(α,β), $\alpha>0, \beta>0$**

감마분포 $\mathrm{Gamma}(\alpha,\beta)$의 확률밀도함수는

$$f(x;\theta) = \frac{1}{\Gamma(\alpha)\beta^\alpha}x^{\alpha-1}e^{-x/\beta}\mathrm{I}_{(x>0)},\ \ \theta = (\alpha,\beta)^t$$

이고 크기 n인 랜덤표본을 이용한 로그가능도함수는 다음과 같다.

$$l_n(\theta) = -n\log\Gamma(\alpha) - n\alpha\log\beta + n(\alpha-1)\overline{(\log x)} - n\bar{x}/\beta,\ \overline{(\log x)} = n^{-1}\sum_{i=1}^{n}\log x_i$$

이 경우에 확률밀도함수는 다중모수 지수족에 속하는 경우로서 <정리 6.4.4>의 조건들이 만족되는 것이 알려져 있다. 한편 <예 6.4.3>에서와 같이 간략한 표현을 위하여

$$\overline{(\log x)} = n^{-1}\sum_{i=1}^{n}\log x_i,\ \Psi(\alpha) = \frac{\partial}{\partial\alpha}\log\Gamma(\alpha),$$

$$\partial_\alpha = \frac{\partial}{\partial\alpha},\ \partial_\beta = \frac{\partial}{\partial\beta},\ \partial_{\alpha\alpha}^2 = \frac{\partial^2}{\partial\alpha^2},\ \partial_{\alpha\beta}^2 = \frac{\partial^2}{\partial\alpha\partial\beta},\ \partial_{\beta\beta}^2 = \frac{\partial^2}{\partial\beta^2}$$

라고 하면 로그가능도함수의 도함수들은 다음과 같이 주어진다.

$$\dot{l}_n(\theta) = \begin{pmatrix}\partial_\alpha l_n(\theta)\\ \partial_\beta l_n(\theta)\end{pmatrix} = \begin{pmatrix}-n\Psi(\alpha) - n\log\beta + n\overline{(\log x)}\\ -n\alpha/\beta + n\bar{x}/\beta^2\end{pmatrix}$$

$$\ddot{l}_n(\theta) = \begin{pmatrix}\partial_{\alpha\alpha}^2 l_n(\theta) & \partial_{\alpha\beta}^2 l_n(\theta)\\ \partial_{\alpha\beta}^2 l_n(\theta) & \partial_{\beta\beta}^2 l_n(\theta)\end{pmatrix} = \begin{pmatrix}-n\dot{\Psi}(\alpha) & -n/\beta\\ -n/\beta & n\alpha/\beta^2 - 2n\bar{x}/\beta^3\end{pmatrix}$$

한편 <예 6.4.3>에서 밝혔듯이 θ의 최대가능도 추정값은 가능도방정식 $\dot{l}_n(\theta) = 0$의 하나뿐인 근으로 주어지고, 가능도방정식의 일차 근사로부터 정의되는 반복법과 적률이용 추정값을 이용하여 최대가능도 추정값의 근사값인 $\hat{\theta}_n^{(1)} = (\hat{\alpha}_n^{(1)}, \hat{\beta}_n^{(1)})^t$을 다음과 같이 구할 수 있다.

$$\hat{\theta}_n^{(1)} = \hat{\theta}_n^{(0)} + [-\ddot{\bar{l}}_n(\hat{\theta}_n^{(0)})]^{-1}\dot{\bar{l}}_n(\hat{\theta}_n^{(0)}),\ \hat{\theta}_n^{(0)} = \hat{\theta}_n^{MME}$$

한편 감마분포 $\mathrm{Gamma}(\alpha,\beta)$의 평균과 분산은 각각 $\alpha\beta$, $\alpha\beta^2$이므로, $\theta = (\alpha,\beta)^t$의 적률이용 추정량 $\hat{\theta}_n^{MME} = (\hat{\alpha}_n, \hat{\beta}_n)^t$은 다음 연립방정식의 해로 주어지고 <정리 6.1.2>로부터 이 추정량은 <정리 6.4.5>의 조건 $(R8)$을 만족하는 것을 알 수 있다.

$$\begin{cases}\hat{\alpha}_n\hat{\beta}_n = \overline{\mathrm{X}_n}\\ \hat{\alpha}_n(\hat{\beta}_n)^2 = n^{-1}\sum_{i=1}^{n}(\mathrm{X}_i - \overline{\mathrm{X}_n})^2\end{cases}$$

한편 이 경우에 정보량 행렬과 그 역행렬은 각각

$$I(\theta) = \mathrm{E}_\theta[-\ddot{l}_1(\theta)] = \begin{pmatrix}\dot{\Psi}(\alpha) & 1/\beta\\ 1/\beta & \alpha/\beta^2\end{pmatrix},\ [I(\theta)]^{-1} = \frac{1}{\alpha\dot{\Psi}(\alpha) - 1}\begin{pmatrix}\alpha & -\beta\\ -\beta & \dot{\Psi}(\alpha)\beta^2\end{pmatrix}$$

로 주어지고 일단계 반복법에 의한 추정량 $\hat{\theta}_n^{(1)} = (\hat{\alpha}_n^{(1)}, \hat{\beta}_n^{(1)})^t$에 대하여

$$\sqrt{n}\,(\hat{\theta}_n^{(1)} - \theta) \xrightarrow[n\to\infty]{d} \mathrm{N}(0, [I(\theta)]^{-1})$$

이 성립한다.

즉 정사영 행렬 $\Pi_{0,1}$을 서로 직교하는 두 정사영 행렬의 합으로 분해할 수 있는 것이다.

이와 같은 정사영 행렬의 분해를 이용하면 다음 정리가 성립하는 것을 알 수 있다.

정리 6.5.3 설명변수의 직교화와 최소제곱 추정

<정리 6.5.2>의 선형회귀모형에서

$$X=(X_0,X_1),\ X_0:n\times p_0,\ X_1:n\times p_1\ (p_0+p_1=p+1)$$

$$\Pi_0=X_0(X_0^tX_0)^{-1}X_0^t,\ X_{1|0}=(\mathrm{I}-\Pi_0)X_1,\ \Pi_{1|0}=X_{1|0}(X_{1|0}^tX_{1|0})^{-1}X_{1|0}^t$$

라고 하면 다음이 성립한다.

(a)
$$X\hat{\beta}^{LSE}=X_0\hat{\beta}_0^{LSE}+X_1\hat{\beta}_1^{LSE}=X_0\hat{\gamma}_0^{LSE}+X_{1|0}\hat{\beta}_1^{LSE}$$

$$X_0\hat{\gamma}_0^{LSE}=\Pi_0\mathrm{Y},\ X_{1|0}\hat{\beta}_1^{LSE}=\Pi_{1|0}\mathrm{Y}$$

$$\hat{\beta}_0^{LSE}=\hat{\gamma}_0^{LSE}-(X_0^tX_0)^{-1}X_0^tX_1\hat{\beta}_1^{LSE}$$

(b)
$$\mathrm{Cov}(\hat{\gamma}_0^{LSE},\hat{\beta}_1^{LSE})=0$$

$$\mathrm{E}(\hat{\gamma}_0^{LSE})=\gamma_0,\ \mathrm{Var}(\hat{\gamma}_0^{LSE})=\sigma^2(X_0^tX_0)^{-1}$$

$$\mathrm{E}(\hat{\beta}_1^{LSE})=\beta_1,\ \mathrm{Var}(\hat{\beta}_1^{LSE})=\sigma^2(X_{1|0}^tX_{1|0})^{-1}$$

예 6.5.1 절편이 포함된 선형회귀모형

선형회귀모형에서 평균반응이

$$\mathrm{E}(\mathrm{Y}_i|x_{i0},x_{i1},\cdots,x_{ip})=\beta_0+\beta_1x_{i1}+\cdots+\beta_px_{ip}(i=1,\cdots,n)$$

로 가정된 경우에 $\overline{x_{\cdot j}}=(x_{1j}+\cdots+x_{nj})/n(j=1,\cdots,p)$라고 하면 평균반응을

$$\beta_0+\beta_1x_{i1}+\cdots+\beta_px_{ip}=\gamma_0+\beta_1(x_{i1}-\overline{x_{\cdot 1}})+\cdots+\beta_p(x_{ip}-\overline{x_{\cdot p}})$$

로 나타낼 수 있다. 이 경우에

$$X_0=(1,\cdots,1)^t,\ X_{1|0}=(x_{i1}-\overline{x_{\cdot 1}},\cdots,x_{ip}-\overline{x_{\cdot p}})_{1\le i\le p}$$

이므로

$$S_{jk}=\sum_{i=1}^{n}(x_{ij}-\overline{x_{\cdot j}})(x_{ik}-\overline{x_{\cdot k}}),\ S_{j\mathrm{Y}}=\sum_{i=1}^{n}(x_{ij}-\overline{x_{\cdot j}})(\mathrm{Y}_i-\overline{\mathrm{Y}})$$

라고 하면

$$X_{1|0}^t X_{1|0} = (S_{jk}),\ X_{1|0}^t \mathrm{Y} = (S_{j\mathrm{Y}})$$

임을 알 수 있다. 따라서 최소제곱 추정량은 다음과 같이 주어진다.

$$\hat{\gamma}_0 = \overline{\mathrm{Y}}, \begin{pmatrix} S_{11} \cdots S_{1p} \\ \vdots \quad\quad \vdots \\ S_{p1} \cdots S_{pp} \end{pmatrix} \begin{pmatrix} \hat{\beta}_1 \\ \vdots \\ \hat{\beta}_p \end{pmatrix} = \begin{pmatrix} S_{1\mathrm{Y}} \\ \vdots \\ S_{p\mathrm{Y}} \end{pmatrix}$$

연습문제

6.1 모평균이 μ, 모표준편차가 $\sigma(\sigma>0)$인 모집단 분포에서의 랜덤표본을 $X_1, \cdots, X_n$이라고 할 때 모집단 분포의 왜도 $\rho_3 = E\left[\left(\frac{X-\mu}{\sigma}\right)^3\right]$와 첨예도 $\rho_4 = E\left[\left(\frac{X-\mu}{\sigma}\right)^4\right] - 3$의 적률이용추정량을 구하여라.

6.2 다음 각 모형에서의 랜덤표본을 $X_1, \cdots, X_n$이라고 할 때, 각 경우에 α, β의 적률이용추정량을 구하여라.

(a) $\mathrm{Gamma}(\alpha, 2)$, $\alpha > 0$

(b) $\mathrm{Gamma}(2, \beta)$, $\beta > 0$

(c) $\mathrm{Gamma}(\alpha, \beta)$, $\alpha > 0$, $\beta > 0$

6.3 확률밀도함수가

$$f(x;\alpha) = \alpha x^{\alpha-1}\exp(-x^\alpha)I_{(0,+\infty)}(x)$$

인 와이불분포 $\mathrm{Weibull}(\alpha, 1)$, $\alpha > 0$ 모형에서의 랜덤표본을 $X_1, \cdots, X_n$이라고 할 때

$$E_\alpha(\log X_1) = \int_0^\infty (\log z)e^{-z}dz/\alpha = -0.577/\alpha$$

임[107]을 밝히고, 이로부터 $\log X_1, \cdots, \log X_n$을 이용한 α의 적률이용추정량을 구하여라.

6.4 확률밀도함수가 다음과 같이 주어지는 각 모형에서의 랜덤표본을 $X_1, \cdots, X_n$이라고 할 때, 각 경우에 θ의 적률이용추정량과 최대가능도 추정량을 구하여라.

(a) $f(x;\theta) = (3x^2/\theta^3)I_{[0,\theta]}(x)$, $\theta > 0$

(b) $f(x;\theta) = 2\theta^2 x^{-3}I_{[\theta,+\infty)}(x)$, $\theta > 0$

---

107) 로그감마함수의 일차도함수를 $\Psi(\alpha) = \frac{\partial}{\partial\alpha}\log\Gamma(\alpha)$ 라고 하면 $\int_0^\infty (\log z)e^{-z}dz = \Psi(1)$ 임을 알 수 있으며, $\Psi(\alpha)$는 다이감마(digamma)함수라고 불리우며 패키지 R을 이용하여 그 값을 계산할 수 있다.

6.5 다음 각 모형에서의 랜덤표본을 $X_1, \cdots, X_n$이라고 할 때, 각 경우에 θ의 최대가능도 추정량과 그 극한분포를 구하여라. (a)의 경우에는 그 극한분포의 분산과 적률이용추정량 극한분포의 분산을 비교하여라.

(a) $\mathrm{Beta}(\theta,1),\ \theta>0$ (b) $\mathrm{Pareto}(1,\theta),\ \theta>2$

6.6 다음 각 모형에서의 랜덤표본을 $X_1, \cdots, X_n$이라고 할 때, 각 경우에

$$\eta = P_\theta(X_1 > a)\ (a\text{는 주어진 양수})$$

의 최대가능도 추정량을 구하여라.

(a) $\mathrm{Exp}(\theta),\ \theta>0$ (b) $\mathrm{Pareto}(1,\theta),\ \theta>0$

6.7 기하분포 $\mathrm{Geo}(p),\ 0<p\le 1$에서의 랜덤표본 $X_1, \cdots, X_n$을 관측하는 대신

$$Y_i = \min\{X_i, r+1\},\ i=1,\cdots,n\ (r\text{은 주어진 자연수})$$

를 관측할 수 있을 때, $Y_1, \cdots, Y_n$을 이용한 p의 최대가능도 추정량을 구하여라.

6.8 연습문제 (6.3)에서의 $\mathrm{Weibull}(\alpha,1),\ \alpha>0$ 모형에서 α의 최대가능도 추정량은 가능도방정식의 근으로 주어지는 것을 밝히고, 이의 일단계 반복법에 의한 풀이를 설명하여라.

6.9 4장에서 소개된 일원분류모형

$$\begin{cases} X_{ij} = \mu_i + e_{ij},\ -\infty < \mu_i < +\infty \\ e_{ij} \overset{iid}{\sim} N(0,\sigma^2),\ i=1,\cdots,k;\ j=1,\cdots,n_i,\ \sigma^2>0 \end{cases}$$

에서 $\mu_1, \cdots, \mu_k$와 σ^2의 최대가능도 추정량을 구하여라.

6.10 정규분포 $N(\mu,\sigma^2),\ -\infty<\mu<+\infty,\ \sigma>0$ 모형에서의 랜덤표본 $X_1, \cdots, X_n$을 이용하여 다음 모수의 최대가능도 추정량을 구하여라.

(a) $P_{\mu,\sigma}(X_1 > \xi_\alpha) = \alpha\ (0<\alpha<1)$인 ξ_α

(b) $\eta = P_{\mu,\sigma}(X_1 > a)\ (a\text{는 주어진 수})$

6.11 연습문제 (6.10)의 (b)에서의 추정량의 극한분포를 구하여라.

6.12 다음 모형에서의 확률밀도함수들이 지수족을 이루는 것을 밝히고 <정리 6.3.4>의 조건을 만족시키는지 답하여라.

(a) $\mathrm{Beta}(\alpha,\beta),\ \alpha>0,\ \beta>0$ (b) $\mathrm{N}(\theta,\theta^2),\ 0<\theta<+\infty$

6.13 공통의 평균을 갖는 두 정규분포 $\mathrm{N}(\mu,\sigma_1^2)$, $\mathrm{N}(\mu,\sigma_2^2)$, $-\infty<\mu<+\infty$, $\sigma_1^2>0$, $\sigma_2^2>0$에서의 랜덤표본을 각각 $\mathrm{X}_1,\ \cdots,\ \mathrm{X}_m$과 $\mathrm{Y}_1,\ \cdots,\ \mathrm{Y}_n$이라고 하고 이들 랜덤표본이 서로 독립인 경우에 이들의 결합확률밀도함수가 지수족을 이루는 것을 밝히고 <정리 6.3.4>의 조건을 만족시키는지 답하여라.

6.14 확률밀도함수가

$$f(x;\mu,\sigma)=\frac{1}{\sigma}e^{-\frac{x-\mu}{\sigma}}\mathrm{I}_{[\mu,\infty)}(x)$$

로 주어지는 두 개의 모수를 갖는 지수분포 $\mathrm{Exp}(\mu,\sigma)$, $-\infty<\mu<+\infty$, $\sigma>0$ 모형에서의 랜덤표본 $\mathrm{X}_1,\ \cdots,\ \mathrm{X}_n$을 이용한 다음 모수의 최대가능도 추정량을 구하여라.

(a) $\theta=(\mu,\sigma)^t$ (b) $\eta=\mathrm{P}_{\mu,\sigma}(\mathrm{X}_1>a)$($a$는 주어진 값)

6.15 연습문제 (6.14)의 (b)에서의 추정량의 극한분포를 구하여라.

6.16 확률밀도함수가

$$f(x;\alpha,\beta)=\beta\alpha^{\beta}x^{-\beta-1}\mathrm{I}_{[\alpha,\infty)}(x)$$

로 주어지는 두 개의 모수를 갖는 파레토분포 $\mathrm{Pareto}(\alpha,\beta),\ \alpha>0,\ \beta>0$ 모형에서의 랜덤표본 $\mathrm{X}_1,\ \cdots,\ \mathrm{X}_n$을 이용한 모수 α,β의 최대가능도 추정량을 구하여라.

6.17 균등분포 $\mathrm{U}[\theta_1-\theta_2,\theta_1+\theta_2]$, $-\infty<\theta_1<+\infty$, $\theta_2>0$에서의 랜덤표본 $\mathrm{X}_1,\ \cdots,\ \mathrm{X}_n$을 이용한 모수 θ_1,θ_2의 최대가능도 추정량을 구하여라.

6.18 정규분포 $N(\mu,\sigma^2)$ 모형에서 $0 \le \mu < +\infty$, $\sigma^2 > 0$인 경우에 랜덤표본 $X_1, \cdots, X_n$을 이용한 모수 μ, σ^2의 최대가능도 추정량을 구하여라.

6.19 확률밀도함수가

$$f(x;\alpha,\beta) = \alpha\beta^{-\alpha}x^{\alpha-1}\exp(-x^{\alpha}/\beta^{\alpha})I_{(0,+\infty)}(x)$$

인 와이불분포 $\text{Weibull}(\alpha,\beta)$, $\alpha > 0$, $\beta > 0$ 모형에서의 랜덤표본을 $X_1, \cdots, X_n$이라고 할 때 모수 α, β의 최대가능도 추정량을 구하는 과정을 설명하여라. (참고: $b = 1/\beta^{\alpha}$를 이용)

6.20 확률밀도함수가

$$f(x;\mu,\sigma) = \frac{1}{\sigma}\frac{e^{(x-\mu)/\sigma}}{(1+e^{(x-\mu)/\sigma})^2}I_{(-\infty,+\infty)}(x)$$

인 로지스틱분포 $L(\mu,\sigma)$, $-\infty < \mu < +\infty$, $\sigma > 0$ 모형에서의 랜덤표본을 $X_1, \cdots, X_n$이라고 할 때 모수 μ, σ의 최대가능도 추정량을 구하는 과정을 설명하여라. (참고: $\eta_1 = 1/\sigma$, $\eta_2 = \mu/\sigma$를 이용)

6.21 <정리 6.5.3>의 (b)를 증명하여라.

6.22 회귀모형

$$\begin{cases} Y_i = \beta_0 + \beta_1 i + \beta_2 i^2 + e_i,\ i = 1,\cdots,5 \\ E(e_i) = 0,\ \text{Var}(e_i) = \sigma^2,\ \text{Cov}(e_i,e_j) = 0\ (i \neq j) \\ \beta = (\beta_0,\beta_1,\beta_2)^t \in R^3,\ \sigma^2 > 0 \end{cases}$$

에서 직교화를 통하여 다음과 같이 모형을 나타내려고 한다.

$$\begin{cases} \beta_0 + \beta_1 i + \beta_2 i^2 = \gamma_0 + \gamma_1 x_{1i} + \gamma_2 x_{2i},\ i = 1,\cdots,5 \\ \sum_{i=1}^{5} x_{1i} = 0,\ \sum_{i=1}^{5} x_{2i} = 0,\ \sum_{i=1}^{5} x_{1i}x_{2i} = 0 \end{cases}$$

(a) x_{1i}, x_{2i}를 구하여라.

(b) $\gamma_0, \gamma_1, \gamma_2$의 최소제곱 추정량을 구하여라.

(c) σ^2의 추정량을 제안하여라.