8.1 추정량 비교의 기준

모집단 분포가 확률밀도함수 $f(x;\theta)$, $\theta \in \Omega$ 중의 하나라고 모형을 설정한 경우에 랜덤표본 $X_1, \cdots, X_n$을 이용하여 모수 θ 또는 모수의 함수 $\eta = \eta(\theta)$를 추측하는 경우에 좋은 추정량이란 참값에 가까운 추정값을 제공할 수 있는 추정량일 것이다. 이러한 추정량의 성능을 측정하는 방법은 여러 가지가 있을 수 있으나 가장 보편적으로 사용되는 것은

$$E_\theta[(\hat{\eta}(X_1,\cdots,X_n)-\eta(\theta))^2]$$

으로 정의되는 평균제곱오차(平均제곱誤差, mean squared error)이며, 이를 간략히

$$MSE(\hat{\eta},\theta) = E_\theta[(\hat{\eta}-\eta(\theta))^2]$$

와 같이 나타내기로 한다.

예 8.1.1 비교가 가능한 경우

균등분포 $U[0,\theta]$, $\theta > 0$에서의 랜덤표본 $X_1, \cdots, X_n (n \geq 2)$을 이용한 θ의 추정량으로서

$$\hat{\theta}^{MLE} = X_{(n)}, \quad \hat{\theta}^{MME} = 2\overline{X}$$

의 평균제곱오차는 각각 다음과 같다.

$$MSE(\hat{\theta}^{MLE},\theta) = E_\theta(X_{(n)}-\theta)^2 = \frac{2}{(n+1)(n+2)}\theta^2$$

$$MSE(\hat{\theta}^{MME},\theta) = E_\theta(2\overline{X}-\theta)^2 = \frac{1}{3n}\theta^2$$

따라서

$$MSE(\hat{\theta}^{MLE},\theta) \leq MSE(\hat{\theta}^{MME},\theta) \quad \forall\, \theta > 0$$

일뿐만 아니라, 각 평균제곱오차가 0으로 수렴하는 속도도

$$MSE(\hat{\theta}^{MLE},\theta) \approx n^{-2}, \quad MSE(\hat{\theta}^{MME},\theta) \approx n^{-1}$$

로서 이 경우에는 최대가능도추정량이 적률이용추정량보다 좋은 추정량임을 알 수 있다.

예 8.1.2 비교가 어려운 경우

정규분포 $N(\theta,1)$, $-\infty < \theta < +\infty$에서의 랜덤표본 $X_1, \cdots, X_n$을 이용한 추정량으로서

$$\hat{\theta}^0 = 0,\ \hat{\theta}^{MLE} = \overline{\mathrm{X}}$$

의 평균제곱오차는 각각

$$MSE(\hat{\theta}^0, \theta) = \mathrm{E}_\theta (0-\theta)^2 = \theta^2,\ MSE(\hat{\theta}^{MLE}, \theta) = \mathrm{E}_\theta (\overline{\mathrm{X}}-\theta)^2 = \frac{1}{n}$$

따라서 $|\theta| < 1/\sqrt{n}$ 이면 관측 결과를 이용하지 않는 $\hat{\theta}^0 = 0$가 $\hat{\theta}^{MLE} = \overline{\mathrm{X}}$보다 더 적은 평균제곱오차를 갖는다.

그러므로 평균제곱오차의 값을 기준으로 최대가능도추정량인 $\overline{\mathrm{X}}$가 언제나 $\hat{\theta}^0 = 0$보다 좋다고 할 수는 없는 것이다. 그러나 표본크기가 증가함에 따라 평균제곱오차가 0으로 수렴하는 속도라는 기준으로 보면 $\hat{\theta}^{MLE} = \overline{\mathrm{X}}$가 $\hat{\theta}^0 = 0$보다 좋은 추정량이다.

한편 $\hat{\theta}^0 = 0$와의 비교에서 착안하여 검정 결과를 이용하는 혼합(hybrid) 추정량으로서

$$\hat{\theta}^H = \begin{cases} 0, & |\overline{\mathrm{X}}| < 1.96/\sqrt{n} \\ \overline{\mathrm{X}}, & |\overline{\mathrm{X}}| \geq 1.96/\sqrt{n} \end{cases}$$

를 생각하면 그 평균제곱오차는 표준정규분포를 따르는 확률변수 Z를 이용하여

$$\mathrm{E}_\theta(\hat{\theta}^H - \theta)^2 = n^{-1}\{(\sqrt{n}\theta)^2 \mathrm{P}(|\mathrm{Z} + \sqrt{n}\theta| < 1.96) + \mathrm{E}\,\mathrm{Z}^2 \mathrm{I}(|\mathrm{Z} + \sqrt{n}\theta| \geq 1.96)\}$$

로 나타낼 수 있다. 이러한 표현에서 평균제곱오차는 항상 $|\sqrt{n}\theta|$에 의존하는 것을 알 수 있으며 그 그래프를 그려보면 <그림 8.1.1>과 같이 주어진다. 또한 표본크기가 커짐에 따라 평균제곱오차가 0으로 수렴하는 속도가

$$MSE(\hat{\theta}^H, \theta) \approx n^{-1}$$

로서 $\hat{\theta}^{MLE} = \overline{\mathrm{X}}$의 속도와 같은 것을 알 수 있다.[114]

즉 혼합추정량 $\hat{\theta}^H$는 평균제곱오차가 0으로 수렴하는 속도라는 기준에서 $\hat{\theta}^{MLE} = \overline{\mathrm{X}}$와 거의 같은

그림 8.1.1 혼합추정량 $\hat{\theta}^H$의 평균제곱오차

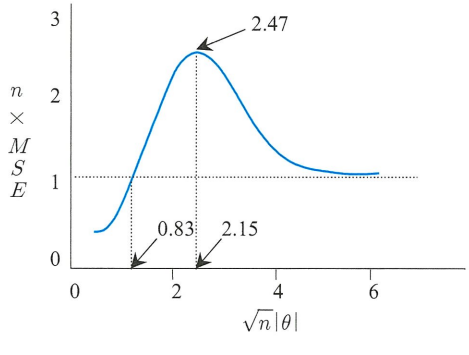

114) 표준정규분포의 확률밀도함수 ϕ와 누적분포함수 Φ에 대하여 Mill's ratio라고 불리우는 다음의 근사식이 성립하는 것이 알려져 있다.

$$x(1-\Phi(x)) \sim \phi(x),\ x \to +\infty$$

이로부터 $MSE(\hat{\theta}^H, \theta) \approx n^{-1}$임을 밝힐 수 있다.

성능을 갖는다고 할 수 있으며, <그림 8.1.1>에서 알 수 있듯이 $\theta = 0$ 근방에서는 표본평균 $\overline{X}$보다 작은 평균제곱오차를 갖는 추정량이다. 즉 평균제곱오차를 기준으로 두 추정량을 비교한다면, 표본크기가 클 때는 혼합추정량이 표본평균과 거의 같은 성능을 가지며, 표본크기가 작을 때에는 거의 모든 경우에 표본평균이 더 좋지만 혼합추정량이 좋은 경우도 있을 수 있다는 것이다.

<예 8.1.2>에서 알 수 있듯이 평균제곱오차를 기준으로 두 추정량의 비교가 어려운 경우가 많이 있다. 미지인 모수의 값의 범위에 따라 비교우위인 추정량이 바뀌므로 비교가 어려운 점이 있다. 따라서 모수의 값에 의존하지 않는 비교 기준을 고안하여 추정량을 비교하곤 한다. 이러한 비교 기준 중에서 보편적인 것으로서 다음의 최대평균제곱오차(最大平均제곱誤差, maximum MSE)와 베이지안평균제곱오차(Bayesian MSE)가 있다.

최대평균제곱오차와 베이지안평균제곱오차:

(a) 최대평균제곱오차 기준: 평균제곱오차의 최댓값인 최대평균제곱오차, 즉

$$\max_{\theta \in \Omega} \mathrm{E}_\theta[(\hat{\eta} - \eta(\theta))^2]$$

을 기준으로 $\eta = \eta(\theta)$의 추정량 $\hat{\eta}$을 비교하는 것을 뜻하며, 이를 최소로 하는 추정량 $\hat{\eta}^*$을 최소최대(最小最大, minimax)평균제곱오차 추정량이라고 한다.

$$\max_{\theta \in \Omega} \mathrm{E}_\theta[(\hat{\eta}^* - \eta(\theta))^2] = \min_{\hat{\eta}} \max_{\theta \in \Omega} \mathrm{E}_\theta[(\hat{\eta} - \eta(\theta))^2]$$

(b) 베이지안평균제곱오차 기준: 모수공간의 함수인 π에 대한 평균제곱오차의 가중평균인

$$r(\pi, \hat{\eta}) = \int_\Omega \mathrm{E}_\theta[(\hat{\eta} - \eta(\theta))^2]\pi(\theta)\, d\theta$$

를 기준으로 $\eta = \eta(\theta)$의 추정량 $\hat{\eta}$을 비교하는 것을 뜻하며, 이를 최소로 하는 추정량 $\hat{\eta}^\pi$를 사전밀도함수(事前密度函數, prior density) π에 대한 베이지안(Bayesian)평균제곱오차 추정량이라고 한다. 이 때 사전밀도함수 π는 양수 또는 0의 값을 갖는 함수이거나 확률밀도함수로서 가중치의 정도를 반영하는 함수로 선택한다.

추정대상인 $\eta = \eta(\theta)$가 양수인 경우에는 평균제곱오차 대신 평균제곱상대오차인

$$\mathrm{E}_\theta(\hat{\eta}/\eta - 1)^2$$

을 사용하여 최대평균제곱상대오차나 베이지안평균제곱상대오차를 기준으로 추정량을 비교하기도 한다.

예 8.1.3

정규분포 $\mathrm{N}(\mu,\sigma^2)$, $-\infty<\mu<+\infty$, $\sigma^2>0$에서의 랜덤표본 $\mathrm{X}_1,\cdots,\mathrm{X}_n$을 이용한 모분산의 추정량으로서

$$\widehat{\sigma_c^2}=c\sum_{i=1}^{n}(\mathrm{X}_i-\overline{\mathrm{X}})^2,\ 0<c<+\infty$$

중에서 다음에 정의된 최대평균제곱상대오차를 최소로 하는 추정량을 구하여라.

$$\max_{\theta\in\Omega}\mathrm{E}_\theta[(\widehat{\sigma_c^2}/\sigma^2-1)^2],\ \theta=(\mu,\sigma^2)^t$$

[풀이] 이 경우에는 <정리 4.2.2>로부터

$$\sum_{i=1}^{n}(\mathrm{X}_i-\overline{\mathrm{X}})^2/\sigma^2\sim\chi^2(n-1)$$

이므로 다음과 같이 평균제곱상대오차가 주어진다.

$$\begin{aligned}\mathrm{E}_\theta[(\widehat{\sigma_c^2}/\sigma^2-1)^2]&=\mathrm{E}[(c\mathrm{V}-1)^2],\ \mathrm{V}\sim\chi^2(n-1)\\&=\mathrm{E}[\{c(\mathrm{V}-(n-1))+c(n-1)-1\}^2]\\&=2(n-1)c^2+((n-1)c-1)^2\end{aligned}$$

$$\therefore\ \max_{\theta\in\Omega}\mathrm{E}_\theta[(\widehat{\sigma_c^2}/\sigma^2-1)^2]=2(n-1)c^2+((n-1)c-1)^2$$

따라서 이를 최소로 하는 추정량은 $c=1/(n+1)$일 때의 추정량으로서 다음과 같이 주어진다.

$$\widehat{\sigma^2}=\frac{1}{n+1}\sum_{i=1}^{n}(\mathrm{X}_i-\overline{\mathrm{X}})^2$$

한편 평균제곱오차를 기준으로 추정량을 비교할 때에 비교 대상인 추정량을 특정한 성질을 갖는 것으로 제한하여 비교하기도 한다. 특히[115]

$$\mathrm{E}_\theta[\hat{\eta}(\mathrm{X}_1,\cdots,\mathrm{X}_n)]=\eta(\theta),\ {}^\forall\theta\in\Omega$$

를 만족하는 추정량을 치우침 없는 추정량 또는 간략히 불편추정량(不偏推定量, unbiased estimator)이라고 하며 이들 중에서 평균제곱오차를 최소로 하는 추정량을 찾기도 한다. 이러한 불편추정량 $\hat{\eta}^{UE}$의 경우에는

$$MSE(\hat{\eta}^{UE},\theta)=\mathrm{E}_\theta[(\hat{\eta}^{UE}-\eta(\theta))^2]=\mathrm{E}_\theta[(\hat{\eta}^{UE}-\mathrm{E}_\theta\hat{\eta}^{UE})^2]=\mathrm{Var}_\theta(\hat{\eta}^{UE})$$

115) 불편추정량임을 나타내는 이러한 항등식을 간략히 $\mathrm{E}_\theta\hat{\eta}^{UE}{}^{\theta\in\Omega}\equiv\eta(\theta)$로 나타내기로 한다.

이므로, 불편추정량 중에서 분산을 최소로 하는 추정량이 이러한 비교 기준에서는 최적의 추정량이다. 불편추정량 중에서 모수 θ의 참값이 무엇이든 그 분산을 최소로 하는 추정량이 있다면 그러한 추정량을 전역최소분산불편추정량(全域最小分散不偏推定量, uniformly minimum variance unbiased estimator(UMVUE))이라고 한다.

전역최소분산불편추정량:

(i) $\mathrm{E}_\theta\hat{\eta}^{*\ \theta\in\Omega} \equiv \eta(\theta)$

(ii) $\mathrm{E}_\theta\hat{\eta}^{UE\ \theta\in\Omega} \equiv \eta(\theta)$이면 $\mathrm{Var}_\theta(\hat{\eta}^{UE}) \geq \mathrm{Var}_\theta(\hat{\eta}^{*}) \quad \forall\theta\in\Omega$

가 성립할 때 추정량 $\hat{\eta}^{*}$를 $\eta=\eta(\theta)$의 전역최소분산불편추정량이라고 하며 $\hat{\eta}^{UMVUE}$로 나타내기도 한다.

정리 8.1.1 최소분산불편추정량의 유일성

$\eta=\eta(\theta)$의 전역최소분산불편추정량의 분산이 실수이면 이러한 전역최소분산불편추정량은 하나뿐이다. 즉 $\hat{\eta}_1, \hat{\eta}_2$가 $\eta=\eta(\theta)$의 전역최소분산불편추정량이고 그 분산이 실수이면

$$\mathrm{P}_\theta(\hat{\eta}_1=\hat{\eta}_2)=1 \quad {}^\forall\theta\in\Omega$$

[증명] $\hat{\eta}_1, \hat{\eta}_2$가 모두 $\eta=\eta(\theta)$의 불편추정량이므로, $\hat{\eta}_3=(\hat{\eta}_1+\hat{\eta}_2)/2$라고 하면

$$\mathrm{E}_\theta(\hat{\eta}_3)=\mathrm{E}_\theta[(\hat{\eta}_1+\hat{\eta}_2)/2]=[\mathrm{E}_\theta(\hat{\eta}_1)+\mathrm{E}_\theta(\hat{\eta}_2)]/2=\eta(\theta),\ \theta\in\Omega$$

이다. 즉 $\hat{\eta}_3$도 불편추정량이다. 따라서 위의 성질 (ii)로부터

$$\mathrm{Var}_\theta(\hat{\eta}_3) \geq \mathrm{Var}_\theta(\hat{\eta}_1)=\mathrm{Var}_\theta(\hat{\eta}_2) \quad {}^\forall\theta\in\Omega$$

$$\therefore\ \frac{1}{4}\{\mathrm{Var}_\theta(\hat{\eta}_1)+2\mathrm{Cov}_\theta(\hat{\eta}_1,\hat{\eta}_2)+\mathrm{Var}_\theta(\hat{\eta}_2)\} \geq \mathrm{Var}_\theta(\hat{\eta}_1)=\mathrm{Var}_\theta(\hat{\eta}_2)$$

$$\therefore\ \mathrm{Cov}_\theta(\hat{\eta}_1,\hat{\eta}_2) \geq \mathrm{Var}_\theta(\hat{\eta}_1)=\mathrm{Var}_\theta(\hat{\eta}_2)$$

$$\therefore\ 0 \leq \mathrm{Var}_\theta(\hat{\eta}_1-\hat{\eta}_2)=\mathrm{Var}_\theta(\hat{\eta}_1)+\mathrm{Var}_\theta(\hat{\eta}_2)-2\mathrm{Cov}_\theta(\hat{\eta}_1,\hat{\eta}_2) \leq 0,$$

$$\text{즉 } \mathrm{Var}_\theta(\hat{\eta}_1-\hat{\eta}_2)=0$$

그런데 $\hat{\eta}_1, \hat{\eta}_2$가 모두 $\eta=\eta(\theta)$의 불편추정량이므로

$$\mathrm{E}_\theta(\hat{\eta}_1-\hat{\eta}_2)=\eta(\theta)-\eta(\theta)=0$$

따라서 <정리 1.6.4>로부터

$$\mathrm{P}_\theta(\hat{\eta}_1-\hat{\eta}_2=0)=1 \quad {}^\forall\theta\in\Omega$$

8.2 충분통계량

랜덤표본 $X_1, \cdots, X_n$을 이용하여 모수에 대한 추측을 할 때 n개의 표본 전부가 아닌 일부만으로도 추측의 정밀도가 같게 추측할 수 있다면 표본 전부 대신 그 일부만의 관측 값을 기록하고 관리하는 이점이 있을 것이다. 이러한 자료의 축약(縮約, reduction)에 대한 개념으로서 충분성(充分性, sufficiency)에 대하여 생각해보자.

예 8.2.1

서로 독립인 두 번의 베르누이 시행 Bernoulli(θ), $0<\theta<1$의 관측 결과인 $(X_1, X_2)^t$ 대신 $Y = X_1 + X_2$의 관측 결과만 있다면 이로부터 원래의 자료를 θ의 값에 무관하게 복원할 수 있을까?

[풀이] X_1, X_2는 모두 0 또는 1인 경우이므로, $Y = X_1 + X_2$의 값은 0, 1 또는 2 중의 하나이고, $Y=0$이면 $(X_1=0,\ X_2=0)$이고 $Y=2$이면 $(X_1=1,\ X_2=1)$인 것은 분명하다. 한편 $Y=1$이면 $(X_1=0,\ X_2=1)$이거나 $(X_1=1,\ X_2=0)$이므로 이들을 각각 정해진 조건부확률

$$P_\theta(X_1=0, X_2=1|Y=1),\ P_\theta(X_1=1, X_2=0|Y=1)$$

에 따라 복원해야 할 것이다. 그런데

$$P_\theta(X_1=0, X_2=1|Y=1) = \frac{P_\theta(X_1=0, X_2=1)}{P_\theta(X_1+X_2=1)} = \frac{(1-\theta)\theta}{\binom{2}{1}\theta^1(1-\theta)^{2-1}} = \frac{1}{2}$$

$$P_\theta(X_1=1, X_2=0|Y=1) = \frac{P_\theta(X_1=1, X_2=0)}{P_\theta(X_1+X_2=1)} = \frac{\theta(1-\theta)}{\binom{2}{1}\theta^1(1-\theta)^{2-1}} = \frac{1}{2}$$

이므로, 이러한 복원은 θ의 값에 무관하게 행하여질 수 있다.

<예 8.2.1>이 뜻하는 것은 미지의 성공률 $0<\theta<1$에 대한 추론을 위한 두 번의 독립적인 베르누이 시행을 관측한다면 성공의 횟수를 아는 경우에 성공과 실패가 나오는 순서의 확률은 θ에 무관하므로 θ의 추론에는 성공의 횟수만으로 충분하다는 것이다.

충분통계량:

모집단 분포가 확률밀도함수 $f(x;\theta)$, $\theta\in\Omega$ 중의 하나라고 모형을 설정한 경우에 랜덤표본 $X_1, \cdots, X_n$을 이용한 통계량 $Y=u(X_1,\cdots,X_n)$에 대하여

$$P_{\theta_1}\{(X_1,\cdots,X_n)^t\in A|Y=y\}=P_{\theta_2}\{(X_1,\cdots,X_n)^t\in A|Y=y\}\ {}^\forall A,\ {}^\forall y,\ {}^\forall\theta_1\in\Omega,\ \theta_2\in\Omega$$

일 때, 즉 $Y=u(X_1,\cdots,X_n)=y$인 조건하에서 랜덤표본 $(X_1,\cdots,X_n)^t$의 조건부확률이 미지의 모수 $\theta\in\Omega$에 의존하지 않으면 통계량 $Y=u(X_1,\cdots,X_n)$를 $\theta\in\Omega$에 관한 충분통계량(充分統計量, sufficient statistic for $\theta\in\Omega$)이라고 한다.

예 8.2.2 베르누이 독립시행에서의 충분통계량

$X_1, \cdots, X_n$이 서로 독립인 베르누이 시행 $\mathrm{Bernoulli}(\theta)$, $0<\theta<1$을 나타내는 랜덤표본일 때,

$$Y=X_1+\cdots+X_n\sim B(n,\theta)$$

이므로 $Y=X_1+\cdots+X_n=y$인 조건하에서 랜덤표본 $(X_1,\cdots,X_n)^t$의 조건부확률은 다음과 같이 주어지고, 이 조건부확률이 모수 $\theta\in\Omega$에 의존하지 않는 것을 알 수 있다.

$$P_\theta(X_1=x_1,\cdots,X_n=x_n|X_1+\cdots+X_n=y)=\frac{\prod_{i=1}^{n}\theta^{x_i}(1-\theta)^{1-x_i}}{\binom{n}{y}\theta^y(1-\theta)^{n-y}}I_{(x_1+\cdots+x_n=y)}$$

$$=\binom{n}{y}^{-1}I_{(x_1+\cdots+x_n=y)},\ {}^\forall\theta:0<\theta<1$$

따라서 $Y=X_1+\cdots+X_n$은 $\theta\in(0,1)$에 관한 충분통계량이다.

정리 8.2.1 분해 정리(分解 定理, factorization theorem)

모집단 분포가 확률밀도함수 $f(x;\theta)$, $\theta\in\Omega$ 중의 하나일 때 랜덤표본 $X_1, \cdots, X_n$을 이용한 통계량 $Y=u(X_1,\cdots,X_n)$이 $\theta\in\Omega$에 관한 충분통계량일 필요충분조건은 다음과 같은 항등식이 성립하는 함수 k_1, k_2가 존재하는 것이다.

$$\prod_{i=1}^{n}f(x_i;\theta)=k_1(u(x),\theta)k_2(x)\ {}^\forall x=(x_1,\cdots,x_n),\ {}^\forall\theta\in\Omega$$

[증명] 이 정리는 일반적으로 성립하는 것이지만 이산형의 경우만 증명하기로 한다.

(충분조건의 증명)

주어진 조건으로부터

$$P_\theta(X=x)=\prod_{i=1}^{n} f(x_i;\theta)=k_1(u(x),\theta)k_2(x) \quad {}^\forall x=(x_1,\cdots,x_n),\ {}^\forall \theta\in\Omega$$

이므로 모든 $\theta\in\Omega$와 $x=(x_1,\cdots,x_n)^t$, y에 대하여 다음이 성립한다.

$$\begin{aligned} P_\theta(X=x|Y=y)&=P_\theta(X=x,Y=u(X)=y)/P_\theta(Y=u(X)=y)\\ &=P_\theta(X=x)I_{(u(x)=y)}/\sum_{z:u(z)=y} P_\theta(X=z)\\ &=\frac{k_1(u(x),\theta)k_2(x)I_{(u(x)=y)}}{\sum_{z:u(z)=y} k_1(u(z),\theta)k_2(z)}\\ &=\frac{k_1(y,\theta)k_2(x)I_{(u(x)=y)}}{k_1(y,\theta)\sum_{z:u(z)=y} k_2(z)}\\ &=\frac{k_2(x)I_{(u(x)=y)}}{\sum_{z:u(z)=y} k_2(z)} \end{aligned}$$

즉 이 조건부확률이 모수 $\theta\in\Omega$에 의존하지 않는다. 따라서 $Y=u(X_1,\cdots,X_n)$은 $\theta\in\Omega$에 관한 충분통계량이다.

(필요조건의 증명)

$Y=u(X_1,\cdots,X_n)$가 $\theta\in\Omega$에 관한 충분통계량이라면, 모든 x, y에 관하여 조건부확률 $P_\theta(X=x|Y=y)$이 모수 $\theta\in\Omega$에 의존하지 않는다. 따라서

$$P_\theta(X=x|Y=u(x))=P(X=x|Y=u(x))=k_2(x)$$

라고 나타낼 수 있다. 또한

$$P_\theta(Y=u(x))=k_1(u(x),\theta)$$

라고 할 수 있으므로 모든 $\theta\in\Omega$와 $x=(x_1,\cdots,x_n)^t$에 대하여 다음이 성립한다.

$$P_\theta(X=x)=P_\theta(X=x,\ Y=u(X)=u(x))=P(X=x|Y=u(x))P_\theta(Y=u(x))$$

$$\therefore \prod_{i=1}^{n} f(x_i;\theta)=P(X=x|Y=u(x))P_\theta(X=x)=k_1(u(x),\theta)k_2(x)$$

예 8.2.3 Poisson(θ), $\theta>0$의 경우

포아송분포 Poisson(θ), $\theta>0$에서의 랜덤표본 $X_1, \cdots, X_n$의 결합확률밀도함수는

$$\prod_{i=1}^{n} f(x_i;\theta)=\prod_{i=1}^{n}(e^{-\theta}\theta^{x_i}/x_i!)\mathrm{I}_{\{0,1,2,\cdots\}}(x_i)$$

이므로, $e^{-n\theta}\theta^{x_1+\cdots+x_n}=k_1(x_1+\cdots+x_n,\theta)$라고 하면

$$\prod_{i=1}^{n} f(x_i;\theta)=k_1(x_1+\cdots+x_n,\theta)\prod_{i=1}^{n}(1/x_i!)\mathrm{I}_{\{0,1,2,\cdots\}}(x_i)$$

라고 할 수 있으므로 $u(\mathrm{X})=\mathrm{X}_1+\cdots+\mathrm{X}_n$이 $\theta>0$에 관한 충분통계량이다.

예 8.2.4 Exp(θ), $\theta>0$의 경우

지수분포 Exp(θ), $\theta>0$에서의 랜덤표본 $X_1, \cdots, X_n$의 결합확률밀도함수는

$$\prod_{i=1}^{n} f(x_i;\theta)=\prod_{i=1}^{n}\frac{1}{\theta}e^{-x_i/\theta}\mathrm{I}_{(0,\infty)}(x_i)=\theta^{-n}\exp\left(-\sum_{i=1}^{n}x_i/\theta\right)\prod_{i=1}^{n}\mathrm{I}_{(0,\infty)}(x_i)$$

이므로, $\theta^{-n}\exp\left(-\sum_{i=1}^{n}x_i/\theta\right)=k_1(x_1+\cdots+x_n,\theta)$ 라고 하면

$$\prod_{i=1}^{n} f(x_i;\theta)=k_1(x_1+\cdots+x_n,\theta)\prod_{i=1}^{n}\mathrm{I}_{(0,\infty)}(x_i)$$

로 나타낼 수 있으므로 $u(\mathrm{X})=\mathrm{X}_1+\cdots+\mathrm{X}_n$이 $\theta>0$에 관한 충분통계량이다.

예 8.2.5 Gamma(α,β), $\alpha>0$, $\beta>0$의 경우

감마분포 Gamma(α,β), $\alpha>0$, $\beta>0$에서의 랜덤표본 $X_1, \cdots, X_n$의 결합확률밀도함수는

$$\prod_{i=1}^{n} f(x_i;\alpha,\beta)=\prod_{i=1}^{n}\frac{1}{\Gamma(\alpha)\beta^{\alpha}}x_i^{\alpha-1}e^{-x_i/\beta}\mathrm{I}_{(0,\infty)}(x_i)$$

이므로

$$\left(\frac{1}{\Gamma(\alpha)\beta^{\alpha}}\right)^{n}\left(\prod_{i=1}^{n}x_i\right)^{\alpha-1}\exp\left(-\sum_{i=1}^{n}x_i/\beta\right)=k_1\left(\sum_{i=1}^{n}x_i,\prod_{i=1}^{n}x_i,\alpha,\beta\right)$$

라고 하면

$$\prod_{i=1}^{n} f(x_i;\alpha,\beta) = k_1\left(\sum_{i=1}^{n} x_i, \prod_{i=1}^{n} x_i, \alpha, \beta\right)\prod_{i=1}^{n} \mathrm{I}_{(0,\infty)}(x_i)$$

로 나타낼 수 있으므로

$$u(\mathrm{X}) = (\mathrm{X}_1 + \cdots + \mathrm{X}_n, \mathrm{X}_1 \cdots \mathrm{X}_n)^t$$

이 $(\alpha,\beta)^t \in (0,\infty)\times(0,\infty)$에 관한 충분통계량이다.

정리 8.2.2 다중모수 지수족에서의 충분통계량

확률밀도함수가

$$f(x;\theta) = \exp\left\{\sum_{j=1}^{k} g_j(\theta)\mathrm{T}_j(x) - \mathrm{A}(g(\theta)) + \mathrm{S}(x)\right\},\ x \in \mathscr{X};\ \theta \in \Omega$$

의 꼴로 주어지고 분포의 토대 $\mathscr{X} = \{x : f(x;\theta) > 0\}$가 모수에 따라 변하지 않는 모집단에서의 랜덤표본을 $\mathrm{X}_1, \mathrm{X}_2, \cdots, \mathrm{X}_n$라고 할 때,

$$\sum_{i=1}^{n} \mathrm{T}(\mathrm{X}_i) = \left(\sum_{i=1}^{n} \mathrm{T}_1(\mathrm{X}_i), \cdots, \sum_{i=1}^{n} \mathrm{T}_k(\mathrm{X}_i)\right)^t$$

가 $\theta \in \Omega$에 관한 충분통계량이다.

[증명] 랜덤표본 $\mathrm{X}_1, \mathrm{X}_2, \cdots, \mathrm{X}_n$의 결합확률밀도함수를

$$\prod_{i=1}^{n} f(x_i;\theta) = \exp\left\{\sum_{j=1}^{k} g_j(\theta)\sum_{i=1}^{n} \mathrm{T}_j(x_i) - n\mathrm{A}(g(\theta))\right\}\exp\left\{\sum_{i=1}^{n} \mathrm{S}(x_i)\right\},$$

$$x_i \in \mathscr{X}\ (i = 1, \cdots, n)$$

와 같이 나타낼 수 있으므로 분해정리로부터

$$\sum_{i=1}^{n} \mathrm{T}(\mathrm{X}_i) = \left(\sum_{i=1}^{n} \mathrm{T}_1(\mathrm{X}_i), \cdots, \sum_{i=1}^{n} \mathrm{T}_k(\mathrm{X}_i)\right)^t$$

가 $\theta \in \Omega$에 관한 충분통계량이다.

정리 8.2.3 충분통계량의 일대일 함수

모집단 분포가 확률밀도함수 $f(x;\theta)$, $\theta \in \Omega$ 중의 하나일 때 랜덤표본 $\mathrm{X}_1, \cdots, \mathrm{X}_n$을 이용한 통계량 $\mathrm{Y} = u(\mathrm{X}_1, \cdots, \mathrm{X}_n)$이 $\theta \in \Omega$에 관한 충분통계량일 때,

Y의 일대일 함수로 주어지는 통계량 $W = g(Y)$도 $\theta \in \Omega$에 관한 충분통계량이다.

[증명] $Y = u(X_1, \cdots, X_n)$이 $\theta \in \Omega$에 관한 충분통계량이므로 조건부확률

$$P_\theta\{(X_1, \cdots, X_n)^t \in A | Y = y\}$$

이 모든 y값에 대하여 모수 $\theta \in \Omega$에 의존하지 않는다. 그런데 $W = g(Y)$가 일대일 함수이므로 그 치역에 속하는 임의의 w 값에 대하여 $(W = w)$가 $(Y = g^{-1}(w))$에 대응한다. 따라서 $W = g(Y)$가 주어진 조건부확률

$$P_\theta\{(X_1, \cdots, X_n)^t \in A | W = w\} = P_\theta\{(X_1, \cdots, X_n)^t \in A | Y = g^{-1}(w)\}$$

도 모수 $\theta \in \Omega$에 의존하지 않는다. 즉 통계량 $W = g(Y)$도 $\theta \in \Omega$에 관한 충분통계량이다.

예 8.2.6 정규모집단의 경우

정규분포 $N(\mu, \sigma^2)$, $-\infty < \mu < +\infty$, $\sigma^2 > 0$의 확률밀도함수는

$$\begin{aligned} f(x;\mu,\sigma^2) &= (2\pi\sigma^2)^{-1/2} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\} \\ &= \exp\left\{\frac{\mu}{\sigma^2}x + \frac{-1}{2\sigma^2}x^2 - \frac{\mu^2}{2\sigma^2} - \frac{1}{2}\log(2\pi\sigma^2)\right\} \end{aligned}$$

와 같이 나타내어지고 분포의 토대는 실수 전체의 집합이므로 지수족의 경우이다. 따라서 <정리 8.2.2>로부터 랜덤표본 $X_1, \cdots, X_n$을 이용한 통계량

$$Y = \left(\sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2\right)^t$$

은 $(\mu, \sigma^2)^t \in (-\infty, +\infty) \times (0, \infty)$에 관한 충분통계량이다. 또한 Y의 일대일함수

$$\left(\overline{X}, \sum_{i=1}^n (X_i - \overline{X})^2/(n-1)\right)^t$$

도 $(\mu, \sigma^2)^t \in (-\infty, +\infty) \times (0, \infty)$에 관한 충분통계량이다.

예 8.2.7 Beta(α,1), $\alpha > 0$의 경우

베타분포 Beta(α,1), $\alpha > 0$의 확률밀도함수는

$$f(x;\alpha) = \alpha x^{\alpha-1} I_{(0,1)}(x) = \exp\{(\alpha-1)\log x + \log\alpha\} I_{(0,1)}(x)$$

와 같이 나타내어지므로 지수족의 경우이다. 따라서 <정리 8.2.2>로부터 랜덤표본 $X_1, \cdots, X_n$을 이용한 통계량

$$Y = \sum_{i=1}^{n} \log X_i$$

또는 Y의 일대일 함수인

$$\overline{(\log X)} = \frac{1}{n} \sum_{i=1}^{n} \log X_i$$

는 $\alpha > 0$에 관한 충분통계량이다.

모집단 분포의 토대가 모수에 의존하는 경우에는 <정리 8.2.2>를 적용할 수가 없으나 그 토대를 나타내는 지표함수를 고려하여 분해정리를 이용하면 충분통계량을 찾을 수 있다.

예 8.2.8 두 개의 모수를 갖는 지수분포[116]의 경우

확률밀도함수가

$$f(x;\mu,\sigma) = \frac{1}{\sigma} \exp\left(\frac{x-\mu}{\sigma}\right) I_{[\mu,\infty)}(x), \quad -\infty < \mu < +\infty, \ \sigma > 0$$

인 모집단에서의 랜덤표본 $X_1, \cdots, X_n$의 결합확률밀도함수는

$$\prod_{i=1}^{n} f(x_i;\mu,\sigma) = \frac{1}{\sigma^n} \exp\left(\frac{x_1 + \cdots + x_n - n\mu}{\sigma}\right) I_{[\mu,\infty)}\left(\min_{1 \le i \le n} x_i\right)$$

로 주어지고, 이 등식의 우변을 $k_1(x_1 + \cdots + x_n, \min_{1 \le i \le n} x_i, \mu, \sigma)$과 $k_2(x_1, \cdots, x_n) = 1$과의 곱으로 나타낼 수 있으므로 $(X_1 + \cdots + X_n, \min_{1 \le i \le n} X_i)^t$이 $(\mu,\sigma)^t \in (-\infty, +\infty) \times (0, +\infty)$에 관한 충분통계량이다.

예 8.2.9 $U[\theta_1,\theta_2]$, $-\infty < \theta_1 < \theta_2 < +\infty$의 경우

균등분포 $U[\theta_1,\theta_2]$, $-\infty < \theta_1 < \theta_2 < +\infty$에서의 랜덤표본 $X_1, \cdots, X_n$의 결합확률밀도함수는

$$\prod_{i=1}^{n} f(x_i;\theta) = \prod_{i=1}^{n} \frac{1}{\theta_2 - \theta_1} I_{[\theta_1,\theta_2]}(x_i) = (\theta_2 - \theta_1)^{-n} I_{[\theta_1 \le \min x_i, \max x_i \le \theta_2]}$$

116) 이와 같이 두 개의 모수를 갖는 지수분포를 기호로는 $\mathrm{Exp}(\mu,\sigma)$로 나타낸다.

로 주어지고, 이 등식의 우변을 $k_1(\min\limits_{1\le i\le n} x_i, \max\limits_{1\le i\le n} x_i, \theta_1, \theta_2)$과 $k_2(x_1,\cdots,x_n)=1$과의 곱으로 나타낼 수 있으므로 $(\min\limits_{1\le i\le n} \mathrm{X}_i, \max\limits_{1\le i\le n} \mathrm{X}_i)^t$이 $(\theta_1,\theta_2)^t$ $(-\infty<\theta_1<\theta_2<+\infty)$에 관한 충분통계량이다.

정리 8.2.4 최대가능도추정량과 충분통계량

모집단 분포가 확률밀도함수 $f(x;\theta)$, $\theta\in\Omega$ 중의 하나일 때 랜덤표본 X_1, …, X_n을 이용한 θ의 최대가능도추정량 $\hat{\theta}^{MLE}(\mathrm{X}_1,\cdots,\mathrm{X}_n)$이 유일하게 존재한다면 이 최대가능도추정량은 $\theta\in\Omega$에 관한 임의의 충분통계량 $\mathrm{S}=u(\mathrm{X}_1,\cdots,\mathrm{X}_n)$의 함수이다. 즉

$$\hat{\theta}^{MLE}(\mathrm{X}_1,\cdots,\mathrm{X}_n)=function(\mathrm{S})$$

[증명] 최대가능도추정량의 정의와 충분통계량 $\mathrm{S}=u(\mathrm{X}_1,\cdots,\mathrm{X}_n)$에 대한 분해정리로부터

$$\hat{\theta}^{MLE}(x_1,\cdots,x_n)=\arg\max_{\theta\in\Omega}\prod_{i=1}^{n}f(x_i;\theta)=\arg\max_{\theta\in\Omega}k_1(u(x),\theta)k_2(x)$$

$$=\arg\max_{\theta\in\Omega}k_1(u(x),\theta)$$

$$\therefore\ \mathrm{Y}=\hat{\theta}(\mathrm{X}_1,\cdots,\mathrm{X}_n)=function(u(\mathrm{X}_1,\cdots,\mathrm{X}_n))=function(\mathrm{S})$$

<정리 8.2.4>에서 유일하게 존재한다고 가정된 최대가능도추정량 $\mathrm{Y}=\hat{\theta}^{MLE}(\mathrm{X}_1,\cdots,\mathrm{X}_n)$가 추가적으로 $\theta\in\Omega$에 관한 충분통계량이라면 이는 임의의 다른 충분통계량 $\mathrm{S}=u(\mathrm{X}_1,\cdots,\mathrm{X}_n)$의 함수로 나타내어지는 충분통계량으로서 이러한 충분통계량을 최소충분통계량(最小充分統計量, minimal sufficient statistic)이라고 한다.

<예 8.2.2>부터 <예 8.2.9>까지의 모형에서의 최대가능도추정량은 모두 유일하게 존재하고 모수에 관한 충분통계량이므로 이들은 모두 모수에 관한 최소충분통계량인 것을 알 수 있다.

정리 8.2.5 충분통계량을 이용한 추정량의 개선(Rao–Blackwell 정리)

확률밀도함수가 $f(x;\theta)$, $\theta\in\Omega$ 중의 하나인 모집단에서의 랜덤표본 X_1, …, X_n을 이용한 통계량 $\mathrm{Y}=u(\mathrm{X}_1,\cdots,\mathrm{X}_n)$이 $\theta\in\Omega$에 관한 충분통계량일 때, $\eta=\eta(\theta)$

의 추정량 $\hat{\eta}$에 대하여

$$\hat{\eta}^{RB}(\mathrm{Y}) = \mathrm{E}[\hat{\eta}(\mathrm{X}_1,\cdots,\mathrm{X}_n)|\mathrm{Y}]$$

라고 정의하면 $\hat{\eta}^{RB} = \hat{\eta}^{RB}(\mathrm{Y})$는 추정량이고 다음이 성립한다.

$$MSE(\hat{\eta}^{RB},\theta) = \mathrm{E}_\theta[(\hat{\eta}^{RB}-\eta(\theta))^2] \le \mathrm{E}_\theta[(\hat{\eta}-\eta(\theta))^2] = MSE(\hat{\eta},\theta),\ {}^\forall\theta\in\Omega$$

[증명] $\mathrm{Y} = u(\mathrm{X}_1,\cdots,\mathrm{X}_n)$이 $\theta\in\Omega$에 관한 충분통계량이므로 Y가 주어진 조건 하에서 랜덤표본 $(\mathrm{X}_1,\cdots,\mathrm{X}_n)^t$의 조건부분포가 모수 $\theta\in\Omega$에 의존하지 않으므로 조건부기댓값 $\mathrm{E}_\theta[\hat{\eta}(\mathrm{X}_1,\cdots,\mathrm{X}_n)|\mathrm{Y}]$은 모수 $\theta\in\Omega$에 의존하지 않는다. 즉

$$\mathrm{E}_\theta[\hat{\eta}(\mathrm{X}_1,\cdots,\mathrm{X}_n)|\mathrm{Y}] \overset{\theta\in\Omega}{\equiv} \mathrm{E}[\hat{\eta}(\mathrm{X}_1,\cdots,\mathrm{X}_n)|\mathrm{Y}]$$

로서 $\hat{\eta}^{RB}(\mathrm{Y}) = \mathrm{E}[\hat{\eta}(\mathrm{X}_1,\cdots,\mathrm{X}_n)|\mathrm{Y}]$는 통계량이다.

한편 <정리 2.3.4>와 <정리 2.3.6>에 주어진 조건부기댓값의 성질로부터

$$\mathrm{E}[\mathrm{E}(\mathrm{V}|\mathrm{W})] = \mathrm{E}(\mathrm{V}),\ \mathrm{Var}(\mathrm{V}) = \mathrm{E}[\mathrm{Var}(\mathrm{V}|\mathrm{W})] + \mathrm{Var}[\mathrm{E}(\mathrm{V}|\mathrm{W})]$$

여기에서 V에 $\hat{\eta}$, W에 Y를 대입하면 $\mathrm{E}(\mathrm{V}|\mathrm{W}) = \mathrm{E}(\hat{\eta}|\mathrm{Y}) = \hat{\eta}^{RB}$이므로

$$\mathrm{E}_\theta[\hat{\eta}^{RB}] = \mathrm{E}_\theta[\mathrm{E}(\hat{\eta}|\mathrm{Y})] = \mathrm{E}_\theta(\hat{\eta})$$

$$\mathrm{Var}_\theta(\hat{\eta}^{RB}) = \mathrm{Var}_\theta[\mathrm{E}(\hat{\eta}|\mathrm{Y})] \le \mathrm{Var}_\theta(\hat{\eta})$$

그런데 $MSE(\hat{\eta},\theta) = \mathrm{E}_\theta[(\hat{\eta}-\eta(\theta))^2] = \mathrm{Var}_\theta(\hat{\eta}) + (\mathrm{E}_\theta\hat{\eta}-\eta(\theta))^2$이므로

$$MSE(\hat{\eta}^{RB},\theta) = \mathrm{E}_\theta[(\hat{\eta}^{RB}-\eta(\theta))^2] \le \mathrm{E}_\theta[(\hat{\eta}-\eta(\theta))^2] = MSE(\hat{\eta},\theta),\ {}^\forall\theta\in\Omega$$

예 8.2.10 $U[0,\theta],\ \theta>0$의 경우

균등분포 $U[0,\theta],\ \theta>0$에서의 랜덤표본 $\mathrm{X}_1,\ \cdots,\ \mathrm{X}_n$의 결합확률밀도함수는

$$\prod_{i=1}^n f(x_i;\theta) = \prod_{i=1}^n \frac{1}{\theta}\mathrm{I}_{[0,\theta]}(x_i) = \frac{1}{\theta^n}\mathrm{I}_{(\max x_i \le \theta)}\mathrm{I}_{(0\le \min x_i)}$$

와 같이 나타낼 수 있으므로 $\mathrm{Y} = \max_{1\le i\le n}\mathrm{X}_i$가 $\theta>0$에 관한 충분통계량이다. 그런데 $\mathrm{E}_\theta\mathrm{X}_1 = \theta/2$이므로 θ의 적률이용추정량은

$$\hat{\theta} = 2\overline{\mathrm{X}}$$

이고 이 추정량의 평균제곱오차는 다음과 같이 주어진다.

$$MSE(\hat{\theta},\theta) = \mathrm{E}_\theta(2\overline{\mathrm{X}}-\theta)^2 = 4\mathrm{Var}_\theta(\overline{\mathrm{X}}) = \frac{\theta^2}{3n}$$

한편 순서통계량을 $X_{(1)} < \cdots < X_{(n)}$이라고 하면

$$E(2\overline{X}|X_{(n)} = y) = \frac{2}{n}E(X_{(1)} + \cdots + X_{(n-1)} + X_{(n)}|X_{(n)} = y)$$

$$= \frac{2}{n}\left\{\sum_{r=1}^{n-1} E(X_{(r)}|X_{(n)} = y) + y\right\}$$

여기에서 $X_{(n)} = y$인 조건하에서 $X_{(r)}(1 \le r \le n-1)$의 확률밀도함수를 구해보면

$$pdf_{r|n}(x|y) = \frac{(n-1)!}{(r-1)!(n-r-1)!}\left(\frac{x}{y}\right)^{r-1}\left(1-\frac{x}{y}\right)^{n-r-1}\frac{1}{y}I_{(0,y)}(x)$$

$$\therefore E(X_{(r)}|X_{(n)} = y) = \int_0^y x\, pdf_{r|n}(x|y)dx = \frac{r}{n}y \quad (1 \le r \le n-1)$$

따라서 $\hat{\theta}^{RB} = E(\hat{\theta}|X_{(n)})$라고 하면

$$\hat{\theta}^{RB} = E(2\overline{X}|X_{(n)}) = \frac{2}{n}\left(\sum_{r=1}^{n-1}\frac{r}{n}X_{(n)} + X_{(n)}\right) = \frac{n+1}{n}X_{(n)}$$

이고 이 추정량의 평균제곱오차는 다음과 같이 주어진다.

$$MSE(\hat{\theta}^{RB}, \theta) = E_\theta\left(\frac{n+1}{n}X_{(n)} - \theta\right)^2$$

$$\therefore MSE(\hat{\theta}^{RB}, \theta) = \int_0^\theta\left(\frac{n+1}{n}x - \theta\right)^2\frac{1}{\theta^n}nx^{n-1}dx = \frac{\theta^2}{n(n+2)}$$

그러므로 이 경우에 <정리 8.2.5>에서 밝힌 것과 같이 충분통계량에 의한 조건부 기댓값을 취하여 얻은 통계량 $\hat{\theta}^{RB} = E(\hat{\theta}|X_{(n)})$에 대하여 다음이 성립한다.

$$MSE(\hat{\theta}^{RB}, \theta) = \frac{\theta^2}{n(n+2)} \le \frac{\theta^2}{3n} = MSE(\hat{\theta}, \theta)$$

8.3 최소분산불편추정

<정리 8.2.5>에 따라 충분통계량에 의한 조건부기댓값을 취하여 주면 주어진 추정량을 개선시키는 추정량을 얻을 수 있음을 알고 있다. 특히 주어진 추정량이 추정 대상의 불편추정량일 때, 충분통계량이 추가적으로 다음의 성질을 가지는 경우에 이러한 방법으로부터 전역최소분산불편추정량을 찾을 수 있는 것이 알려져 있다.

$$\mathrm{Var}_\theta(\hat{\eta}_1^{RB}) = MSE(\hat{\eta}_1^{RB},\theta) \le MSE(\hat{\eta}_1^{UE},\theta) = \mathrm{Var}_\theta(\hat{\eta}_1^{UE}) \ \forall\theta\in\Omega$$

그러므로 $\hat{\eta}_0^{RB}(\mathrm{Y})$와 $\hat{\eta}_1^{RB}(\mathrm{Y})$는 모두 $\eta=\eta(\theta)$의 불편추정량이다. 따라서

$$\mathrm{E}_\theta[\hat{\eta}_0^{RB}(\mathrm{Y})-\hat{\eta}_1^{RB}(\mathrm{Y})] \overset{\theta\in\Omega}{\equiv} \eta(\theta)-\eta(\theta)=0$$

이고 Y가 $\theta\in\Omega$에 관한 완비충분통계량이므로

$$\mathrm{P}_\theta[\hat{\eta}_0^{RB}(\mathrm{Y})-\hat{\eta}_1^{RB}(\mathrm{Y})=0] \overset{\theta\in\Omega}{\equiv} 1$$

$$\therefore \mathrm{Var}_\theta(\hat{\eta}_0^{RB}) = \mathrm{Var}_\theta(\hat{\eta}_1^{RB}) \le \mathrm{Var}_\theta(\hat{\eta}_1^{UE}) \ \forall\theta\in\Omega$$

따라서 (i), (ii)로부터 $\hat{\eta}_0^{RB}=\hat{\eta}_0^{RB}(\mathrm{Y})$는 $\eta=\eta(\theta)$의 전역최소분산불편추정량이다.

(b) (a)의 증명 (ii)에서 $\hat{\eta}_0^{RB}(\mathrm{Y})$의 역할을 $\delta(\mathrm{Y})$로 바꾸어 놓으면 (b)가 성립하는 것을 알 수 있다.

예 8.3.1 베르누이 독립시행에서의 완비충분통계량

$\mathrm{X}_1, \cdots, \mathrm{X}_n$이 서로 독립인 베르누이 시행 $\mathrm{Bernoulli}(\theta)$, $0<\theta<1$을 나타내는 랜덤표본일 때, $\mathrm{Y}=\mathrm{X}_1+\cdots+\mathrm{X}_n$이 $\theta\in(0,1)$에 관한 충분통계량임은 <예 8.2.2>에서 알고 있다. 한편

$$\mathrm{Y} \sim \mathrm{B}(n,\theta)$$

이므로, 다음이 성립하는 것을 알 수 있다.

$$\mathrm{E}_\theta g(\mathrm{Y}) \overset{\theta\in(0,1)}{\equiv} 0 \Rightarrow \sum_{y=0}^{n} g(y)\binom{n}{y}\theta^y(1-\theta)^{n-y} \overset{\theta\in(0,1)}{\equiv} 0$$

$$\Rightarrow \sum_{y=0}^{n} g(y)\binom{n}{y}\lambda^y \overset{\lambda>0}{\equiv} 0 \quad \left(\lambda=\frac{\theta}{1-\theta}\right)$$

$$\Rightarrow g(y)\binom{n}{y} \overset{y}{\equiv} 0 \ (\because \text{다항식 전개의 유일성})$$

$$\Rightarrow g(\mathrm{Y})=0$$

따라서 $\mathrm{Y}=\mathrm{X}_1+\cdots+\mathrm{X}_n$은 $\theta\in(0,1)$에 관한 완비충분통계량이고,

$$\mathrm{E}_\theta(\mathrm{Y}/n) \overset{\theta\in(0,1)}{\equiv} \theta$$

이므로 <정리 8.3.1>의 (b)로부터 $\mathrm{Y}/n=\sum_{i=1}^{n}\mathrm{X}_i/n$은 모비율 θ의 전역최소분산불편추정량이다.

예 8.3.2 Poisson(θ), $\theta>0$에서의 랜덤표본으로부터의 완비충분통계량

$X_1, \cdots, X_n$이 포아송분포 Poisson(θ), $\theta>0$에서의 랜덤표본일 때, $Y=X_1+\cdots+X_n$이 $\theta>0$에 관한 충분통계량임은 <예 8.2.3>에서 알고 있다. 한편

$$Y \sim \text{Poisson}(n\theta)$$

이므로, 다음이 성립하는 것을 알 수 있다.

$$\begin{aligned} E_\theta g(Y) \overset{\theta>0}{\equiv} 0 &\Rightarrow \sum_{y=0}^{\infty} g(y)\frac{e^{-n\theta}(n\theta)^y}{y!} \overset{\theta>0}{\equiv} 0 \\ &\Rightarrow \sum_{y=0}^{\infty} \frac{g(y)}{y!}\lambda^y \overset{\lambda>0}{\equiv} 0 \quad (\lambda = n\theta) \\ &\Rightarrow \frac{g(y)}{y!} \overset{y}{\equiv} 0 \quad (\because \text{멱급수 전개의 유일성}) \\ &\Rightarrow g(Y)=0 \end{aligned}$$

따라서 $Y=X_1+\cdots+X_n$은 $\theta>0$에 관한 완비충분통계량이고,

$$E_\theta(Y/n) \overset{\theta>0}{\equiv} \theta$$

이므로 <정리 8.3.1>의 (b)로부터 $Y/n=\sum_{i=1}^{n} X_i/n$은 모평균 θ의 전역최소분산 불편추정량이다.

예 8.3.3 Exp(θ), $\theta>0$에서의 랜덤표본으로부터의 완비충분통계량

$X_1, \cdots, X_n$이 지수분포 Exp(θ), $\theta>0$에서의 랜덤표본일 때, $Y=X_1+\cdots+X_n$이 $\theta>0$에 관한 충분통계량임은 <예 8.2.4>에서 알고 있다. 한편

$$Y \sim \text{Gamma}(n,\theta)$$

이므로, 다음이 성립하는 것을 알 수 있다.

$$\begin{aligned} E_\theta g(Y) \overset{\theta>0}{\equiv} 0 &\Rightarrow \int_0^{\infty} g(y)\frac{1}{\Gamma(n)\theta^n} y^{n-1}e^{-y/\theta}dy \overset{\theta>0}{\equiv} 0 \\ &\Rightarrow \int_0^{\infty} g(y)y^{n-1}e^{-\lambda y}dy \overset{\lambda>0}{\equiv} 0 \quad (\lambda = 1/\theta) \\ &\Rightarrow g(y)y^{n-1} \overset{y>0}{\equiv} 0^{118)} \quad (\because \text{라플라스 변환의 유일성}) \\ &\Rightarrow g(Y)=0 \end{aligned}$$

---

118) 정의역이 양수 전체 집합이고 적분가능한 함수 f에 대하여

$$L_f(\lambda) = \int_0^{\infty} f(x)e^{-\lambda x}dx$$

를 f의 라플라스(Laplace) 변환이라고 하며, 라플라스 변환은 함수 f와 일대일로 대응하는 것이 알려져 있다.

따라서 $Y = X_1 + \cdots + X_n$은 $\theta > 0$에 관한 완비충분통계량이고,

$$E_\theta(Y/n) \overset{\theta>0}{\equiv} \theta$$

이므로 <정리 8.3.1>의 (b)로부터 $Y/n = \sum_{i=1}^{n} X_i/n$은 모평균 θ의 전역최소분산 불편추정량이다.

<예 8.3.1>부터 <예 8.3.3>의 경우는 모두 단일모수 지수족의 경우이며 일반적으로 <정리 8.2.2>에서 다중모수 지수족의 경우에 주어진 충분통계량은 적절한 조건하에서 완비통계량임이 알려져 있다. 이러한 다중모수 지수족의 성질은 라플라스 변환의 유일성을 이용하는 것으로서 이 책의 수준을 넘으므로 그 증명은 생략하고 결과만을 소개하면 다음과 같다.

정리 8.3.2 다중모수 지수족에서의 완비충분통계량

확률밀도함수가

$$f(x;\eta) = \exp\left\{\sum_{j=1}^{k} \eta_j T_j(x) - A(\eta) + S(x)\right\},\ x \in \mathcal{X};\ \eta = (\eta_1, \cdots, \eta_k)^t \in N$$

의 꼴로 주어지고 다음 조건 (i), (ii), (iii)을 만족하는 모집단에서의 랜덤표본을 $X_1, X_2, \cdots, X_n$이라고 할 때,

$$\sum_{i=1}^{n} T(X_i) = \left(\sum_{i=1}^{n} T_1(X_i), \cdots, \sum_{i=1}^{n} T_k(X_i)\right)^t$$

가 $\eta \in N$에 관한 완비충분통계량이다.

(i) 분포의 토대 $\mathcal{X} = \{x : f(x;\eta) > 0\}$가 모수에 따라 변하지 않으며,

(ii) 모수공간 N이 k차원 공간 R^k의 열린구간다면체 $(a_1, b_1) \times \cdots \times (a_k, b_k)$를 포함하고,

(iii) 모두가 0은 아닌 어떠한 실수 $c_1, \cdots, c_k$에 대해서도 $c^t T(X) = c_1 T_1(X) + \cdots + c_k T_k(X)$는 상수가 아니다.

<정리 8.3.2>를 적용하는 경우에 지수족의 표현에 사용되는 모수 η는

$$\eta = g(\theta) = (g_1(\theta), \cdots, g_k(\theta))^t,\ \theta \in \Omega$$

와 같은 일대일 변환을 통하여 정의되는 모수이다. 즉 <정리 8.3.2>의 확률밀도함수가

$$pdf(x;\theta)=\exp\left\{\sum_{j=1}^{k}g_j(\theta)\mathrm{T}_j(x)-\mathrm{A}(g(\theta))+\mathrm{S}(x)\right\},\ x\in\mathscr{X};\ \theta\in\Omega$$

의 꼴로 모수 $\theta\in\Omega$를 이용하여 주어지는 것을 뜻한다. 따라서 조건 (ii)는

$$\{(g_1(\theta),\cdots,g_k(\theta))^t:\theta\in\Omega\}\supseteq(a_1,b_1)\times\cdots\times(a_k,b_k)$$

를 만족시키는 열린구간다면체 $(a_1,b_1)\times\cdots\times(a_k,b_k)$가 존재하는 것을 뜻한다.

예 8.3.4 정규모집단에서 랜덤표본으로부터의 완비충분통계량

정규분포 $\mathrm{N}(\mu,\sigma^2)$, $-\infty<\mu<+\infty$, $\sigma^2>0$의 확률밀도함수는

$$\begin{aligned}f(x;\mu,\sigma^2)&=(2\pi\sigma^2)^{-1/2}\exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}\\&=\exp\left\{\frac{\mu}{\sigma^2}x+\frac{-1}{2\sigma^2}x^2-\frac{\mu^2}{2\sigma^2}-\frac{1}{2}\log(2\pi\sigma^2)\right\}\end{aligned}$$

와 같이 나타내어지는 지수족의 경우이고, 분포의 토대는 실수 전체의 집합이며 조건 (iii)이 성립하는 것은 명백하고 모수공간이

$\{(\mu/\sigma^2,-1/(2\sigma^2))^t:-\infty<\mu<+\infty,\sigma^2>0\}=(-\infty,+\infty)\times(-\infty,0)$

로서 이차원의 열린구간다면체를 포함한다. 따라서 <정리 8.3.2>로부터 랜덤표본 $\mathrm{X}_1,\cdots,\mathrm{X}_n$을 이용한 통계량

$$\left(\sum_{i=1}^{n}\mathrm{X}_i,\sum_{i=1}^{n}\mathrm{X}_i^2\right)^t$$

이 $\theta=(\mu,\sigma^2)^t\in(-\infty,+\infty)\times(0,+\infty)$에 관한 완비충분통계량이다. 또한 완비충분통계량의 일대일 함수인 통계량도 완비충분통계량이므로 이들의 일대일 함수인

$$(\overline{\mathrm{X}},\mathrm{S}^2)^t=\left(\overline{\mathrm{X}},\sum_{i=1}^{n}(\mathrm{X}_i-\overline{\mathrm{X}})^2/(n-1)\right)^t$$

도 $\theta=(\mu,\sigma^2)^t\in(-\infty,+\infty)\times(0,+\infty)$에 관한 완비충분통계량이다. 또한

$$\mathrm{E}_\theta\overline{\mathrm{X}}=\mu,\ \mathrm{E}_\theta\mathrm{S}^2=\sigma^2$$

이므로 <정리 8.3.1>의 (b)로부터 표본평균 $\overline{\mathrm{X}}$와 표본분산 S^2은 각각 모평균 μ와 모분산 σ^2의 전역최소분산불편추정량이다.

예 8.3.5 제한된 모수공간을 갖는 정규모집단의 경우

제한된 모수공간을 갖는 정규분포 $\mathrm{N}(\mu, \mu^2)$, $\mu > 0$의 확률밀도함수는

$$f(x;\mu) = (2\pi\mu^2)^{-1/2}\exp\left\{-\frac{(x-\mu)^2}{2\mu^2}\right\} = \exp\left\{\frac{1}{\mu}x + \frac{-1}{2\mu^2}x^2 - \frac{1}{2} - \frac{1}{2}\log(2\pi\mu^2)\right\}$$

와 같이 나타내어지고, $\eta_1 = 1/\mu$, $\eta_2 = -1/(2\mu^2)$이라고 하면 모수공간이

$$N = \left\{(\eta_1, \eta_2)^t : \eta_2 = -\frac{1}{2}\eta_1^2,\ \eta_1 > 0\right\}$$

인 지수족에 속하는 경우이다. 이 경우에는 모수공간 N이 이차원의 열린구간다면체를 포함할 수 없는 것이 명백하므로 <정리 8.3.2>를 적용할 수가 없다. 실제로 이 경우에는

$$\mathrm{Y} = \left(\sum_{i=1}^{n}\mathrm{X}_i, \sum_{i=1}^{n}\mathrm{X}_i^2\right)^t$$

에 대하여 다음이 성립하는 것을 알 수 있다.

$$\mathrm{E}_\mu(\mathrm{Y}_2/n) = \mathrm{E}_\mu\mathrm{X}_1^2 = \mathrm{Var}_\mu(\mathrm{X}_1) + (\mathrm{E}_\mu\mathrm{X}_1)^2 = 2\mu^2$$

$$\mathrm{E}_\mu[(\mathrm{Y}_1/n)^2] = \mathrm{E}_\mu[(\overline{\mathrm{X}})^2] = \mathrm{Var}_\mu(\overline{\mathrm{X}}) + (\mathrm{E}_\mu\overline{\mathrm{X}})^2 = \left(\frac{1}{n} + 1\right)\mu^2$$

$$\therefore\ \mathrm{E}_\mu\left[\frac{1}{2n}\mathrm{Y}_2 - \frac{1}{n(n+1)}\mathrm{Y}_1^2\right] \overset{\mu>0}{\equiv} 0$$

즉 항등적으로 0이 아닌 함수 $g(\mathrm{Y}) = \frac{1}{2n}\mathrm{Y}_2 - \frac{1}{n(n+1)}\mathrm{Y}_1^2$에 대하여 그 기댓값이 항상 0인 것을 알 수 있다. 따라서 이 경우에는 $\mathrm{Y} = \left(\sum_{i=1}^{n}\mathrm{X}_i, \sum_{i=1}^{n}\mathrm{X}_i^2\right)^t$는 $\mu > 0$에 관한 완비통계량이 아니고, 표본평균 $\overline{\mathrm{X}}$가 μ의 전역최소분산불편추정량이라고 할 수 없다.

예 8.3.6 $U[0,\theta]$, $\theta > 0$에서의 랜덤표본으로부터의 완비충분통계량

$\mathrm{X}_1, \cdots, \mathrm{X}_n$이 균등분포 $U[0,\theta]$, $\theta > 0$에서의 랜덤표본일 때, $\mathrm{Y} = \max_{1 \le i \le n}\mathrm{X}_i$이 $\theta > 0$에 관한 충분통계량임은 <예 8.2.10>에서 알고 있다. 한편 $\mathrm{Y} = \max_{1 \le i \le n}\mathrm{X}_i$의 확률밀도함수는

$$pdf(y;\theta) = \frac{n}{\theta^n}y^{n-1}\mathrm{I}_{[0,\theta]}(y)$$

이므로, 적분과 미분의 관계로부터 다음이 성립하는 것을 알 수 있다.

$$E_\theta g(Y) \overset{\theta>0}{\equiv} 0 \Rightarrow \int_0^\theta g(y)\frac{n}{\theta^n}y^{n-1}dy \overset{\theta>0}{\equiv} 0 \Rightarrow g(\theta)\theta^{n-1} \overset{\theta>0}{\equiv} 0 \Rightarrow g(Y)=0$$

따라서 $Y=\max_{1\le i\le n} X_i$은 $\theta>0$에 관한 완비충분통계량이고,

$$E_\theta\left(\frac{n+1}{n}Y\right)=\frac{n+1}{n}\int_0^\theta y\frac{n}{\theta^n}y^{n-1}dy \overset{\theta>0}{\equiv} \theta$$

이므로 <정리 8.3.1>의 (b)로부터 $\frac{n+1}{n}Y=\frac{n+1}{n}\max_{1\le i\le n} X_i$은 θ의 전역최소분산불편추정량이다.

예 8.3.7 베르누이분포에서 모분산의 불편추정

$X_1, \cdots, X_n (n\ge 2)$이 서로 독립인 베르누이 시행 $\text{Bernoulli}(\theta)$, $0<\theta<1$을 나타내는 랜덤표본일 때, $Y=X_1+\cdots+X_n$이 $\theta\in(0,1)$에 관한 완비충분통계량임은 <예 8.3.1>에서 알고 있다. 이제 <정리 8.3.1>을 이용하여 모분산 $\eta=\theta(1-\theta)$의 불편추정에 대하여 생각해보자.

$$E_\theta X_1(1-X_2)=E_\theta X_1 E_\theta(1-X_2)=\theta(1-\theta)$$

이므로 $\hat{\eta}_0^{UE}=X_1(1-X_2)$는 $\eta=\theta(1-\theta)$의 불편추정량이고, <정리 8.3.1>로부터

$$\hat{\eta}_0^{RB}(Y)=E[X_1(1-X_2)|Y]$$

는 $\eta=\theta(1-\theta)$의 전역최소분산불편추정량이다. 한편 $\hat{\eta}_0^{RB}(Y)$의 구체적 형태는 다음과 같이 구할 수 있다.

$$\begin{aligned}E[X_1(1-X_2)|Y=y] &= P(X_1=1,X_2=0|X_1+X_2+\cdots+X_n=y)\\ &= \frac{P(X_1=1,X_2=0,X_3+\cdots+X_n=y-1)}{P(X_1+\cdots+X_n=y)}\\ &= \binom{n-2}{y-1}\Big/\binom{n}{y}\\ &= y(n-y)/n(n-1)\end{aligned}$$

따라서 표본비율을 $\hat{\theta}=Y/n$라고 하면

$$\hat{\eta}_0^{RB}=\frac{n}{n-1}\hat{\theta}(1-\hat{\theta})$$

예 8.3.8 포아송분포에서 모평균의 함수의 불편추정

$X_1, \cdots, X_n$이 포아송분포 $\text{Poisson}(\theta)$, $\theta > 0$에서의 랜덤표본일 때, $Y = X_1 + \cdots + X_n$이 $\theta > 0$에 관한 완비충분통계량임은 <예 8.3.2>에서 알고 있다. 이제 <정리 8.3.1>을 이용하여

$$\eta = e^{-2\theta}$$

의 불편추정에 대하여 생각해보자. <정리 8.3.1>의 (b)로부터

$$E_\theta \delta(Y) \overset{\theta > 0}{\equiv} e^{-2\theta}$$

를 만족시키는 Y의 함수 $\delta(Y)$가 있다면 $\delta(Y)$가 $\eta = e^{-2\theta}$의 전역최소분산불편추정량이다.

$$Y = X_1 + \cdots + X_n \sim \text{Poisson}(n\theta)$$

이므로 위의 항등식을 멱급수 전개식으로 나타내면 다음과 같다.

$$\sum_{y=0}^{\infty} \delta(y) \frac{e^{-n\theta}(n\theta)^y}{y!} \overset{\theta > 0}{\equiv} e^{-2\theta}$$

$$\sum_{y=0}^{\infty} \frac{\delta(y)}{y!} \lambda^y \overset{\lambda > 0}{\equiv} e^{(1-2/n)\lambda} \overset{\lambda > 0}{\equiv} \sum_{y=0}^{\infty} \frac{1}{y!} ((1-2/n)\lambda)^y$$

$$\therefore \delta(y) = (1-2/n)^y$$

따라서 $\hat{\eta}_n^{UMVUE} = (1-2/n)^{n\overline{X}}$가 $\eta = e^{-2\theta}$의 전역최소분산불편추정량이다. 참고로 표본크기 n이 큰 경우에는

$$\hat{\eta}_n^{UMVUE} = (1-2/n)^{n\overline{X}} \simeq e^{-2\overline{X}} = \hat{\eta}_n^{MLE}$$

이고 이 추정량은 $\eta = e^{-2\theta}$의 최대가능도추정량과 같은 극한분포를 갖는다. 반면에 $n = 1$인 경우에는 $\hat{\eta}_1^{UMVUE} = (-1)^{X_1}$이 되어 상식을 벗어나는 꼴의 추정량인 것을 알 수 있다. 즉 맹목적인 불편추정은 특이한 결과를 가져오기도 하는 것을 알 수 있다.

예 8.3.9 정규분포에서 신뢰도의 불편추정

$X_1, \cdots, X_n (n \geq 2)$이 정규분포 $N(\theta, 1)$, $-\infty < \theta < +\infty$에서의 랜덤표본일 때, 표본평균 $\overline{X}$가 θ에 관한 완비충분통계량인 것은 <정리 8.3.2>로부터 알 수 있다. 이제 <정리 8.3.1>을 이용하여 a에서의 신뢰도라고 불리우는

$$\eta = P_\theta(X_1 > a)$$

의 불편추정에 대하여 생각해보자.

$$\eta = \mathrm{P}_\theta(\mathrm{X}_1 > a) = \mathrm{E}_\theta \mathrm{I}_{(a,\infty)}(\mathrm{X}_1)$$

이므로 $\hat{\eta}_0^{UE} = \mathrm{I}_{(a,\infty)}(\mathrm{X}_1)$는 $\eta = \mathrm{P}_\theta(\mathrm{X}_1 > a)$의 불편추정량이고, <정리 8.3.1>로부터

$$\hat{\eta}_0^{RB}(\overline{\mathrm{X}}) = \mathrm{E}[\mathrm{I}_{(a,\infty)}(\mathrm{X}_1)|\overline{\mathrm{X}}] = \mathrm{P}(\mathrm{X}_1 > a|\overline{\mathrm{X}})$$

는 $\eta = \mathrm{P}_\theta(\mathrm{X}_1 > a)$의 전역최소분산불편추정량이다. 한편 $\hat{\eta}_0^{RB}(\overline{\mathrm{X}})$의 구체적 형태는 $\mathrm{X}_1 - \overline{\mathrm{X}}$와 $\overline{\mathrm{X}}$의 독립성을 이용하여 다음과 같이 구할 수 있다.

$$\begin{aligned}\mathrm{P}(\mathrm{X}_1 > a|\overline{\mathrm{X}} = y) &= \mathrm{P}(\mathrm{X}_1 - \overline{\mathrm{X}} > a - y|\overline{\mathrm{X}} = y)\\ &= \mathrm{P}(\mathrm{X}_1 - \overline{\mathrm{X}} > a - y)\ (\because \mathrm{X}_1 - \overline{\mathrm{X}}\text{와 } \overline{\mathrm{X}}\text{는 서로 독립})\\ &= \mathrm{P}\left(\sqrt{\frac{n-1}{n}}\,\mathrm{Z} > a - y\right),\ \mathrm{Z} \sim \mathrm{N}(0,1)\left(\because \mathrm{X}_1 - \overline{\mathrm{X}} \sim \mathrm{N}\left(0, \frac{n-1}{n}\right)\right)\end{aligned}$$

여기에서 표준정규분포의 누적분포함수를 Φ로 나타내면

$$\mathrm{P}(\mathrm{X}_1 > a|\overline{\mathrm{X}} = y) = 1 - \Phi\left(\sqrt{\frac{n}{n-1}}\,(a-y)\right)$$

따라서

$$\hat{\eta}_0^{RB} = 1 - \Phi\left(\sqrt{\frac{n}{n-1}}\,(a - \overline{\mathrm{X}})\right)$$

정리 8.3.3 **완비충분통계량과 보조통계량[119]의 독립성**

확률밀도함수가 $f(x;\theta)$, $\theta \in \Omega$ 중의 하나인 모집단에서의 랜덤표본 $\mathrm{X}_1, \cdots, \mathrm{X}_n$을 이용한 통계량 $\mathrm{Z} = v(\mathrm{X}_1, \cdots, \mathrm{X}_n)$의 분포가 모수 $\theta \in \Omega$에 의존하지 않는다면, 이러한 통계량은 $\theta \in \Omega$에 관한 완비충분통계량 $\mathrm{Y} = u(\mathrm{X}_1, \cdots, \mathrm{X}_n)$와는 서로 독립이다.

[증명] $\mathrm{Y} = u(\mathrm{X}_1, \cdots, \mathrm{X}_n)$가 $\theta \in \Omega$에 관한 충분통계량이므로, Y가 주어진 조건부확률

$$\mathrm{P}(\mathrm{Z} \in B|\mathrm{Y}) = \mathrm{P}(v(\mathrm{X}_1, \cdots, \mathrm{X}_n) \in B|\mathrm{Y})$$

은 모수 $\theta \in \Omega$에 의존하지 않는다. 또한 조건부기댓값의 성질로부터

$$\mathrm{E}_\theta[\mathrm{P}(\mathrm{Z} \in B|\mathrm{Y})] = \mathrm{E}_\theta[\mathrm{E}(\mathrm{I}_B(\mathrm{Z})|\mathrm{Y})] = \mathrm{E}_\theta \mathrm{I}_B(\mathrm{Z}) = \mathrm{P}_\theta(\mathrm{Z} \in B)\ {}^\forall\theta \in \Omega$$

---

119) <정리 8.3.3>에서의 $\mathrm{Z} = v(\mathrm{X}_1, \cdots, \mathrm{X}_n)$와 같이 모수 $\theta \in \Omega$에 의존하지 않는 분포를 갖는 통계량을 $\theta \in \Omega$에 관한 보조통계량(補助統計量, ancillary statistic)이라고 한다.

이고 $Z = v(X_1, \cdots, X_n)$의 분포가 모수 $\theta \in \Omega$에 의존하지 않으므로

$$P_\theta(Z \in B) = P(Z \in B) \ {}^{\forall}\theta \in \Omega$$

$$\therefore E_\theta[P(Z \in B|Y) - P(Z \in B)] \overset{\theta \in \Omega}{\equiv} 0$$

그런데 $Y = u(X_1, \cdots, X_n)$가 $\theta \in \Omega$에 관한 완비통계량이므로

$P(Z \in B|Y) - P(Z \in B) = 0$, 즉 $P(Z \in B|Y) = P(Z \in B)$

따라서 Z와 Y는 서로 독립이다.

<예 8.3.9>에서 알 수 있듯이 완비충분통계량이 주어진 조건하에서의 조건부기댓값을 계산할 때 완비충분통계량과 서로 독립인 보조통계량을 이용하면 그 계산이 간편해진다.

예 8.3.10 지수분포에서 신뢰도의 불편추정

$X_1, \cdots, X_n$이 지수분포 $Exp(\theta)$, $\theta > 0$에서의 랜덤표본일 때, $Y = X_1 + \cdots + X_n$이 $\theta > 0$에 관한 완비충분통계량임은 <예 8.3.3>에서 알고 있다. 이제 <정리 8.3.1>을 이용하여 a에서의 신뢰도라고 불리우는

$$\eta = P_\theta(X_1 > a) = e^{-a/\theta}$$

의 불편추정에 대하여 생각해보자.

$$\eta = P_\theta(X_1 > a) = E_\theta I_{(a,\infty)}(X_1)$$

이므로 $\hat{\eta}_0^{UE} = I_{(a,\infty)}(X_1)$는 $\eta = P_\theta(X_1 > a)$의 불편추정량이고, <정리 8.3.1>로부터

$$\hat{\eta}_0^{RB}(Y) = E[I_{(a,\infty)}(X_1)|Y] = P(X_1 > a|Y)$$

가 $\eta = P_\theta(X_1 > a)$의 전역최소분산불편추정량이다.

한편 지수분포의 대의적 정의로부터

$$(X_i)_{1 \le i \le n} \overset{d}{\equiv} (\theta Z_i)_{1 \le i \le n},\ Z_i \overset{iid}{\sim} Exp(1)\ (i = 1, \cdots, n)$$

$$\therefore \frac{X_1}{X_1 + \cdots + X_n} \overset{d}{\equiv} \frac{Z_1}{Z_1 + \cdots + Z_n},\ Z_i \overset{iid}{\sim} Exp(1)\ (i = 1, \cdots, n)$$

따라서 $X_1 / \sum_{i=1}^{n} X_i$는 $\theta > 0$에 관한 보조통계량이며 <정리 8.3.3>에 따라 완비충분통계량 $Y = \sum_{i=1}^{n} X_i$와 독립이다. $\hat{\eta}_0^{RB}(Y)$의 구체적 형태는 이러한 독립성을 이용하여 다음과 같이 구할 수 있다.

$$
\begin{aligned}
&\mathrm{P}(\mathrm{X}_1 > a|\mathrm{Y}=y)\\
&=\mathrm{P}\left(\mathrm{X}_1/\sum_{i=1}^{n}\mathrm{X}_i > a/y|\,\mathrm{Y}=y\right)\\
&=\mathrm{P}\left(\mathrm{X}_1/\sum_{i=1}^{n}\mathrm{X}_i > a/y\right)(\because\ \mathrm{X}_1/\sum_{i=1}^{n}\mathrm{X}_i\text{와 }\mathrm{Y}=\sum_{i=1}^{n}\mathrm{X}_i\text{는 서로 독립})\\
&=\mathrm{P}(\mathrm{Z} > a/y),\ \mathrm{Z}\sim\mathrm{Beta}(1,n-1)\ (\because\ \mathrm{X}_1/\sum_{i=1}^{n}\mathrm{X}_i\sim\mathrm{Beta}(1,n-1))\\
\therefore\ &\mathrm{P}(\mathrm{X}_1 > a|\mathrm{Y}=y)=\int_{a/y}^{1}\frac{\Gamma(n)}{\Gamma(1)\Gamma(n-1)}z^{1-1}(1-z)^{n-1-1}dz\,\mathrm{I}_{(a/y<1)}\\
&=(1-a/y)^{n-1}\mathrm{I}_{(a,\infty)}(y)
\end{aligned}
$$

따라서 $\eta=\mathrm{P}_\theta(\mathrm{X}_1 > a)=e^{-a/\theta}$의 전역최소분산불편추정량은

$$\hat{\eta}_0^{RB}=\left(1-\frac{a/\overline{\mathrm{X}}}{n}\right)^{n-1}\mathrm{I}_{(a/n,\infty)}(\overline{\mathrm{X}})$$

로 주어진다. 참고로 표본크기 n이 큰 경우에는

$$\hat{\eta}_n^{UMVUE}=\left(1-\frac{a/\overline{\mathrm{X}}}{n}\right)^{n-1}\mathrm{I}_{(a/n,\infty)}(\overline{\mathrm{X}})\simeq e^{-a/\overline{\mathrm{X}}}=\hat{\eta}_n^{MLE}$$

이고 이 추정량은 $\eta=e^{-a/\theta}$의 최대가능도추정량과 같은 극한분포를 갖는다.

8.4 추정량의 점근적 비교

표본크기가 커짐에 따라 추정값이 추정 대상의 참값에 가까워지는 일치성을 가진 추정량들을 비교하는 경우에 그 극한분포의 산포가 작을수록 추정 오차가 작은 것을 뜻하므로 일치추정량의 비교 기준으로서 극한분포의 분산을 흔히 사용한다.[120] 이 절에서는 이와 같은 극한분포의 분산을 이용한 추정량의 비교에 대하여 알아본다.

---

120) 크기 n인 표본에 기초한 추정량의 평균제곱오차는

$$MSE(\hat{\eta}_n,\theta)=\mathrm{E}_\theta[(\hat{\eta}_n-\eta(\theta))^2]=\mathrm{Var}_\theta(\hat{\eta}_n)+[\mathrm{E}_\theta(\hat{\eta}_n)-\eta(\theta)]^2$$

와 같이 추정량의 분산 $\mathrm{Var}_\theta(\hat{\eta}_n)$과 치우침 또는 편의(偏倚, bias)라고 불리우는

$$\mathrm{Bias}_\theta(\hat{\eta}_n)=\mathrm{E}_\theta(\hat{\eta}_n)-\eta(\theta)$$

의 제곱의 합으로 주어진다. 그런데 많은 일치추정량에 대하여 편의의 제곱 $[\mathrm{Bias}_\theta(\hat{\eta}_n)]^2$은 n^{-2}의 속도로 0에 가까워지고 분산 $\mathrm{Var}_\theta(\hat{\eta}_n)$은 n^{-1}의 속도로 0에 가까워지므로, 표본크기가 커질 때 추정량을 비교하는 경우에는 극한분포의 분산을 비교 기준으로 하는 것이다.

예 8.4.1 로지스틱분포에서의 추정량 비교

로지스틱분포 $\mathrm{L}(\theta,1)$, $-\infty<\theta<+\infty$에서 θ는 모집단의 중앙값이며 평균이기도 하다. 따라서 랜덤표본 $\mathrm{X}_1, \cdots, \mathrm{X}_n$을 이용하는 θ의 추정량으로는 표본중앙값[121] $\hat{\theta}_n^{med}=\mathrm{X}_{([(n+1)/2])}$, 표본평균 $\hat{\theta}_n^{mean}=\overline{\mathrm{X}}$ 또는 <예 6.4.2>의 최대가능도추정량 $\hat{\theta}_n^{MLE}$을 생각할 수 있다.

한편 <예 4.1.5>에 주어진 로지스틱분포의 확률밀도함수와 <예 5.3.8>에 주어진 표본분위수의 극한분포에 대한 결과로부터

$$\sqrt{n}(\hat{\theta}_n^{med}-\theta)\xrightarrow[n\to\infty]{d}\mathrm{N}(0,4)$$

이고, 중심극한정리와 <예 5.4.3>에 주어진 로지스틱분포의 분산으로부터

$$\sqrt{n}(\hat{\theta}_n^{mean}-\theta)\xrightarrow[n\to\infty]{d}\mathrm{N}(0,\pi^2/3)$$

또한 <예 6.4.4>에 주어진 최대가능도추정량의 극한분포로부터

$$\sqrt{n}(\hat{\theta}_n^{MLE}-\theta)\xrightarrow[n\to\infty]{d}\mathrm{N}(0,3)$$

따라서 표본크기가 충분히 커지는 경우에 극한분포의 분산이 작은 순서대로 효율성이 좋은 순서는 최대가능도추정량, 표본평균, 표본중앙값의 순서이다.

점근상대효율성:

두 추정량 $\hat{\theta}_n^1, \hat{\theta}_n^2$에 대하여

$$\sqrt{n}(\hat{\theta}_n^i-\theta)\xrightarrow[n\to\infty]{d}\mathrm{N}(0,\sigma_i^2(\theta))\quad(i=1,2)$$

와 같은 점근정규성이 성립할 때, 그 극한분포의 분산의 역수의 비인 $\sigma_1^{-2}(\theta)/\sigma_2^{-2}(\theta)$을 추정량 $\hat{\theta}_n^1$의 $\hat{\theta}_n^2$에 대한 점근상대효율성(漸近相對效率性, asymptotic relative efficiency)이라고 하며 기호로는 다음과 같이 나타낸다.

$$ARE(\{\hat{\theta}_n^1\},\{\hat{\theta}_n^2\})=\sigma_1^{-2}(\theta)/\sigma_2^{-2}(\theta)$$

이와 같은 점근상대효율성의 값이 커진다는 것은 표본크기가 커지면서 추정의 정밀도가 상대적으로 높아지는 것을 뜻하며, 따라서 상대적으로 추정의 정밀도가 더

121) 여기에서 $[(n+1)/2]$는 $(n+1)/2$ 이하의 가장 큰 자연수를 뜻한다. 즉 표본크기가 큰 경우에 표본중앙값은 $n=2m$이면 $\mathrm{X}_{(m)}$, $n=2m+1$이면 $\mathrm{X}_{(m+1)}$로 하기로 한다.

좋은 추정방법은 더 적은 표본크기로도 요구되는 추정오차한계를 만족시킬 수 있음을 뜻한다.

예 8.4.2 로지스틱분포에서 추정오차한계와 점근상대효율성

로지스틱분포 $\mathrm{L}(\theta,1)$, $-\infty<\theta<+\infty$에서 표본중앙값을 이용하여 θ에 관한 95% 점근신뢰구간을 구하면 다음과 같이 주어지는 것을 <예 8.4.1>로부터 알 수 있다.

$$\theta\in\left[\hat{\theta}_n^{med}-1.96\sqrt{4/n}\,,\ \hat{\theta}_n^{med}+1.96\sqrt{4/n}\right]$$

이 때 추정값과 추정대상의 차이의 한계를 나타내는 $1.96\sqrt{4/n}$을 표본중앙값의 95% 점근추정오차한계라고 한다. 따라서 표본중앙값을 이용하여 95% 점근추정오차한계를 d 이하로 하기 위하여 요구되는 표본의 크기를 n_{med}라고 하면

$$n_{med}\simeq(1.96/d)^2 4$$

마찬가지로 표본평균을 이용하여 추정하는 경우에 같은 오차한계를 달성하기 위한 표본의 크기를 n_{mean}이라고 하면

$$n_{mean}\simeq(1.96/d)^2\pi^2/3$$

따라서 이들 표본크기의 역수의 비는

$$n_{mean}^{-1}/n_{med}^{-1}\simeq 12/\pi^2\fallingdotseq 1.2=ARE(\{\hat{\theta}_n^{mean}\},\{\hat{\theta}_n^{med}\})$$

즉 표본평균의 추정 정밀도가 표본중앙값에 비하여 약 1.2배이므로 표본중앙값을 이용하면 약 1.2배의 표본 개수가 필요하게 되어 효율성이 상대적으로 떨어진다는 뜻이다.

예 8.4.3 위치모수 모형에서 중앙값의 추정

<예 8.4.1>에서와 같이 모집단 분포가 연속형이고 확률밀도함수가 $f(x-\theta)$, $-\infty<\theta<+\infty$의 꼴로서 θ에 관하여 대칭인 경우, 즉

$$f(-x)=f(x)\ \ {}^{\forall}x:-\infty<x<+\infty$$

인 모형을 생각해보자. 이러한 경우에 랜덤표본 $\mathrm{X}_1,\cdots,\mathrm{X}_n$을 이용한 θ의 추정량으로서 표본중앙값 $\hat{\theta}_n^{med}=\mathrm{X}_{([(n+1)/2])}$의 경우에는 <예 5.3.7>의 결과로부터 그 극한분포가

$$\sqrt{n}\,(\hat{\theta}_n^{med} - \theta) \xrightarrow[n\to\infty]{d} \mathrm{N}(0, 1/(4f^2(0)))$$

로 주어지고, 표본평균 $\hat{\theta}_n^{mean} = \overline{\mathrm{X}}$의 경우에는 모분산이 존재한다는 조건 하에서, 즉

$$\sigma_f^2 = \int_{-\infty}^{+\infty} x^2 f(x)\,dx < +\infty$$

라는 조건 하에서 그 극한분포가 다음과 같이 주어진다.

$$\sqrt{n}\,(\hat{\theta}_n^{mean} - \theta) \xrightarrow[n\to\infty]{d} \mathrm{N}(0, \sigma_f^2)$$

한편 최대가능도추정량의 경우에는 <정리 6.4.4>의 조건들이 만족된다면 정보량이

$$I(\theta) = \mathrm{Var}_\theta\left\{\frac{\partial}{\partial\theta}\log f(\mathrm{X}_1 - \theta)\right\} = \int_{-\infty}^{+\infty}\left(\frac{f'(x)}{f(x)}\right)^2 f(x)dx$$

로 주어지므로 이러한 정보량이 양의 실수라는 조건 하에서 그 극한분포는 다음과 같다.

$$\sqrt{n}\,(\hat{\theta}_n^{MLE} - \theta) \xrightarrow[n\to\infty]{d} \mathrm{N}(0, I_f^{-1}),\quad I_f = \int_{-\infty}^{+\infty}\left(\frac{f'(x)}{f(x)}\right)^2 f(x)dx$$

이러한 극한분포들의 분산을 모집단 분포에 따라 정리하면 <표 8.4.1>과 같이 주어지고, 이로부터 각 추정방법 간의 점근상대효율성을 정리하면 <표 8.4.2>와 같다.

표 8.4.1 표본중앙값, 표본평균, 최대가능도추정량의 극한분포의 분산

모집단 분포	$\mathrm{N}(\theta,1)$	$\mathrm{L}(\theta,1)$	$\mathrm{DE}(\theta,1)$
$(4f^2(0))^{-1}$	$\pi/2$	4	1
σ_f^2	1	$\pi^2/3$	2
I_f^{-1}	1	3	1

표 8.4.2 표본중앙값, 표본평균, 최대가능도추정량 간의 점근상대효율성

모집단 분포	$\mathrm{N}(\theta,1)$	$\mathrm{L}(\theta,1)$	$\mathrm{DE}(\theta,1)$
$ARE(\hat{\theta}_n^{mean}, \hat{\theta}_n^{med})$	$\pi/2$	$12/\pi^2$	1/2
$ARE(\hat{\theta}_n^{mean}, \hat{\theta}_n^{MLE})$	1	$9/\pi^2$	1/2
$ARE(\hat{\theta}_n^{med}, \hat{\theta}_n^{MLE})$	$2/\pi$	3/4	1

예 8.4.4 베타분포 모형 $\mathrm{Beta}(\alpha,1)$, $\alpha>0$에서 추정량의 비교

베타분포 $\mathrm{Beta}(\alpha,1)$, $\alpha>0$의 확률밀도함수는

$$f(x;\alpha)=\alpha x^{\alpha-1}\mathrm{I}_{(0,1)}(x)$$

이고 모평균이 $m_1=\alpha/(\alpha+1)$이므로 랜덤표본 $\mathrm{X}_1,\ \cdots,\ \mathrm{X}_n$을 이용한 α의 적률이용추정량은

$$\widehat{\alpha_n}^{MME}=\frac{\widehat{m_1}}{1-\widehat{m_1}}=\frac{\overline{\mathrm{X}}}{1-\overline{\mathrm{X}}}$$

로 주어지고, 그 극한분포는 <정리 6.1.2>로부터 다음과 같이 주어진다.

$$\sqrt{n}(\widehat{\alpha_n}^{MME}-\alpha)\xrightarrow[n\to\infty]{d}\mathrm{N}(0,(\dot{g}(m_1))^2\sigma^2),\ g(m_1)=\frac{m_1}{1-m_1},\ \sigma^2=\frac{\alpha}{\alpha+2}-\left(\frac{\alpha}{\alpha+1}\right)^2$$

$$\text{즉}\ \sqrt{n}(\widehat{\alpha_n}^{MME}-\alpha)\xrightarrow[n\to\infty]{d}\mathrm{N}\left(0,\frac{\alpha(\alpha+1)^2}{\alpha+2}\right)$$

한편 이 모형의 확률밀도함수는

$$f(x;\alpha)=\alpha x^{\alpha-1}\mathrm{I}_{(0,1)}(x)=\exp\{(\alpha-1)\log x+\log\alpha\}\mathrm{I}_{(0,1)}(x)$$

와 같이 나타내어지는 지수족의 경우로서 <정리 6.2.4>의 조건을 만족시키므로 α의 최대가능도추정량은 가능도방정식

$$\sum_{i=1}^{n}\log\mathrm{X}_i+\frac{n}{\alpha}=0$$

의 근으로 주어진다. 즉 α의 최대가능도추정량은

$$\widehat{\alpha_n}^{MLE}=\frac{1}{(-\log\mathrm{X})}$$

로 주어지고, 그 극한분포는 중심극한정리 또는 <정리 6.4.4>로부터 다음과 같이 주어진다.

$$\sqrt{n}(\widehat{\alpha_n}^{MLE}-\alpha)\xrightarrow[n\to\infty]{d}\mathrm{N}(0,I^{-1}(\alpha)),\ I(\alpha)=\mathrm{E}_\alpha\left[-\frac{\partial^2}{\partial\alpha^2}\log f(\mathrm{X}_1;\alpha)\right]$$

$$\text{즉}\ \sqrt{n}(\widehat{\alpha_n}^{MLE}-\alpha)\xrightarrow[n\to\infty]{d}\mathrm{N}(0,\alpha^2)$$

따라서 적률이용추정량의 최대가능도추정량에 대한 점근상대효율성은

$$ARE(\{\widehat{\alpha_n}^{MME}\},\{\widehat{\alpha_n}^{MLE}\})=\left[\frac{\alpha(\alpha+1)^2}{\alpha+2}\right]^{-1}/\alpha^{-2}=\frac{\alpha(\alpha+2)}{(\alpha+1)^2}$$

로 주어지고, 이로부터 최대가능도추정량이 적률이용추정량에 비하여 점근적으로 더 효율적임을 알 수 있다.

예 8.4.5 베타분포 모형 $\mathrm{Beta}(\alpha,1),\ \alpha>0$에서의 불편추정과 정보량 부등식

베타분포 $\mathrm{Beta}(\alpha,1),\ \alpha>0$의 확률밀도함수는

$$f(x;\alpha)=\alpha x^{\alpha-1}\mathrm{I}_{(0,1)}(x)=\exp\{(\alpha-1)\log x+\log\alpha\}\mathrm{I}_{(0,1)}(x)$$

로 나타내어지고 이는 지수족에 속하는 경우로서 <정리 8.3.2>의 조건을 만족시키므로 랜덤표본 $\mathrm{X}_1,\ \cdots,\ \mathrm{X}_n (n\geq 3)$을 이용한 통계량

$$\mathrm{Y}=\sum_{i=1}^{n}\log \mathrm{X}_i$$

는 $\alpha>0$에 관한 완비충분통계량이다. 한편

$$\mathrm{X}_i^{\alpha}\overset{iid}{\sim}\mathrm{U}(0,1)\ \ (i=1,\cdots,n)$$

이므로

$$-\alpha\log \mathrm{X}_i\overset{iid}{\sim}\mathrm{Exp}(1)\ \ (i=1,\cdots,n)\ \ \therefore\ -\alpha\sum_{i=1}^{n}\log \mathrm{X}_i\sim\mathrm{Gamma}(n,1)$$

따라서

$$\mathrm{E}_{\alpha}\left[1/\left(-\sum_{i=1}^{n}\log \mathrm{X}_i\right)\right]=\alpha\Gamma(n-1)/\Gamma(n)=\alpha/(n-1),\ \ (n\geq 2)$$

$$\mathrm{Var}_{\alpha}\left[1/\left(-\sum_{i=1}^{n}\log \mathrm{X}_i\right)\right]=\alpha^2\{\Gamma(n-2)/\Gamma(n)-1/(n-1)^2\}$$

$$=\alpha^2/\{(n-1)^2(n-2)\},\ \ (n\geq 3)$$

그러므로 <정리 8.3.1>로부터 α의 전역최소분산불편추정량은

$$\hat{\alpha}_n^{\,UMVUE}=(n-1)/\left(-\sum_{i=1}^{n}\log \mathrm{X}_i\right)$$

로 주어지고 그 분산은

$$\mathrm{Var}_{\alpha}(\hat{\alpha}_n^{\,UMVUE})=\alpha^2/(n-2)$$

로서 <정리 8.4.2>에서 주어진 정보량 부등식의 하한인 $1/[nI(\alpha)]=\alpha^2/n$보다 크지만 점근적으로는 같아지는 것을 알 수 있다. 즉

$$\lim_{n\to\infty}\mathrm{Var}_{\alpha}(\hat{\alpha}_n^{\,UMVUE})/[nI(\alpha)]^{-1}=1$$

또한 <예 8.4.4>로부터

$$\hat{\alpha}_n^{\,UMVUE}=\frac{n-1}{n}\hat{\alpha}_n^{\,MLE}$$

임을 알 수 있고, 최소분산불편추정량은 최대가능도추정량과 같은 극한분포를 갖는다. 즉

$$\sqrt{n}(\hat{\alpha}_n^{UMVUE} - \alpha) \xrightarrow[n\to\infty]{d} \mathrm{N}(0, \alpha^2)$$

이고 두 추정량은 점근적으로 같은 효율성을 갖는다.

<정리 8.4.2>로부터 일차원 모수의 경우에

$$\mathrm{Var}_\theta\left\{\sqrt{n}(\hat{\theta}_n^{UE} - \theta)\right\} \geq 1/I(\theta)$$

임을 알 수 있고, 이로부터

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow[n\to\infty]{d} \mathrm{N}(0, \sigma^2(\theta))$$

와 같이 점근정규성을 갖는 추정량의 극한분포의 분산에 대하여

$$\sigma^2(\theta) \geq 1/I(\theta)$$

일 것이라는 추측을 할 수 있다. 한편 <정리 6.4.4>로부터 최대가능도추정량의 경우에

$$\sqrt{n}(\hat{\theta}_n^{MLE} - \theta) \xrightarrow[n\to\infty]{d} \mathrm{N}(0, 1/I(\theta))$$

이 성립하므로 점근정규성을 갖는 추정량 중에서 최대가능도추정량이 최소의 극한분포 분산을 갖는 것이라고 추측할 수 있다.

이러한 추측을 핏셔의 추측(Fisher's conjecture)이라고 하며, 이러한 추측이 일반적으로는 성립하지 않으나 추가적인 균등수렴(均等收斂, uniform convergence)의 조건하에서는 성립하는 것이 알려져 있다.[124] 이러한 뜻에서 최대가능도추정량을 점근적으로 효율적인 추정량이라고 하며, 이러한 최대가능도추정량의 점근적 효율성은 다차원 모수의 함수를 추정하는 경우에도 성립하는 것이 알려져 있다.

예 8.4.6 **감마분포 모형 $\mathrm{Gamma}(\alpha,\beta)$, $\alpha>0$, $\beta>0$에서의 추정량 비교**

감마분포 $\mathrm{Gamma}(\alpha,\beta)$의 확률밀도함수는

$$f(x;\theta) = \frac{1}{\Gamma(\alpha)\beta^\alpha} x^{\alpha-1} e^{-x/\beta} \mathrm{I}_{(x>0)}, \quad \theta = (\alpha,\beta)^t$$

124) 이에 대한 상세한 논의는 참고서적 [P. J. Bickel & K. A. Doksum] Mathematical Statistics p.331~p.332에 주어져 있다.

이고 이는 다중모수 지수족에 속하는 경우로서 <정리 6.4.4>의 조건들이 만족되는 것이 알려져 있다. 이를 이용하여 <예 6.4.5>에서는 가능도방정식

$$\dot{l}_n(\theta)=\begin{pmatrix}-n\Psi(\alpha)-n\log\beta+n\overline{(\log x)}\\ -n\alpha/\beta+n\overline{x}/\beta^2\end{pmatrix}=0$$

의 근으로 주어지는 $\theta=(\alpha,\beta)^t$의 최대가능도추정량을 일단계 반복법에 의해 근사하는 방법을 소개하고 있다. 여기에서 $\overline{(\log x)}=n^{-1}\sum_{i=1}^{n}\log x_i$, $\Psi(\alpha)=\frac{\partial}{\partial\alpha}\log\Gamma(\alpha)$ 이며, 일단계 반복법에 의한 추정량 $\hat{\theta}_n^{(1)}=(\hat{\alpha}_n^{(1)},\hat{\beta}_n^{(1)})^t$은 다음과 같이 정의된다.

$$\hat{\theta}_n^{(1)}=\hat{\theta}_n^{(0)}+[-\overline{\ddot{l}_n}(\hat{\theta}_n^{(0)})]^{-1}\overline{\dot{l}_n}(\hat{\theta}_n^{(0)}),\ \ \hat{\theta}_n^{(0)}=\hat{\theta}_n^{MME}$$

여기에서 초기 추정량으로 사용되는 적률이용추정량 $\hat{\theta}_n^{MME}=(\hat{\alpha}_n,\hat{\beta}_n)^t$은 연립방정식

$$\begin{cases}\hat{\alpha}_n\hat{\beta}_n=\overline{\mathrm{X}_n}\\ \hat{\alpha}_n(\hat{\beta}_n)^2=n^{-1}\sum_{i=1}^{n}(\mathrm{X}_i-\overline{\mathrm{X}_n})^2\end{cases}$$

의 근으로 주어지고, <정리 6.1.2>로부터 그 극한분포를 다음과 같이 구할 수 있다.

$$\sqrt{n}(\hat{\theta}_n^{MME}-\theta)\xrightarrow[n\to\infty]{d}\mathrm{N}(0,\Sigma(\theta)),\ \ \Sigma(\theta)=\begin{pmatrix}2\alpha(\alpha+1) & -2(\alpha+1)\beta\\ -2(\alpha+1)\beta & (2+3/\alpha)\beta^2\end{pmatrix}$$

한편 이 경우에 정보량 행렬과 그 역행렬은 각각

$$I(\theta)=\mathrm{E}_\theta[-\ddot{l}_1(\theta)]=\begin{pmatrix}\dot{\Psi}(\alpha) & 1/\beta\\ 1/\beta & \alpha/\beta^2\end{pmatrix},\ \ I^{-1}(\theta)=\frac{1}{\alpha\dot{\Psi}(\alpha)-1}\begin{pmatrix}\alpha & -\beta\\ -\beta & \dot{\Psi}(\alpha)\beta^2\end{pmatrix}$$

로 주어지고 일단계 반복법에 의한 추정량 $\hat{\theta}_n^{(1)}=(\hat{\alpha}_n^{(1)},\hat{\beta}_n^{(1)})^t$에 대하여

$$\sqrt{n}(\hat{\theta}_n^{(1)}-\theta)\xrightarrow[n\to\infty]{d}\mathrm{N}(0,I^{-1}(\theta))$$

이 성립하며, 최대가능도추정량 $\hat{\theta}_n^{MME}=(\hat{\alpha}_n^{MME},\hat{\beta}_n^{MME})^t$의 극한분포도 이와 같다.

따라서 이 경우에 적률이용추정량의 최대가능도추정량에 대한 점근상대효율성은

$$ARE(\{\hat{\alpha}_n^{MME}\},\{\hat{\alpha}_n^{MLE}\})=[2\alpha(\alpha+1)]^{-1}/[\alpha/(\alpha\dot{\Psi}(\alpha)-1)]^{-1},$$

$$ARE(\{\hat{\beta}_n^{MME}\},\{\hat{\beta}_n^{MLE}\})=[(2+3/\alpha)\beta^2]^{-1}/[\dot{\Psi}(\alpha)\beta^2/(\alpha\dot{\Psi}(\alpha)-1)]^{-1}$$

로 주어지고, 그 값을 계산하면[125] <표 8.4.3>과 <표 8.4.4>와 같다.

표 8.4.3 $ARE(\{\hat{\alpha}_n^{MME}\},\{\hat{\alpha}_n^{MLE}\}) = \dfrac{1}{2(\alpha+1)(\alpha\dot{\Psi}(\alpha)-1)}$ 의 값

α	1/10	1/2	1	2	4	10
$ARE(\{\hat{\alpha}_n^{MME}\},\{\hat{\alpha}_n^{MLE}\})$	0.0497	0.2271	0.3876	0.5749	0.7391	0.8798

표 8.4.4 $ARE(\{\hat{\beta}_n^{MME}\},\{\hat{\beta}_n^{MLE}\}) = \dfrac{\alpha\dot{\Psi}(\alpha)}{(2\alpha+3)(\alpha\dot{\Psi}(\alpha)-1)}$ 의 값

α	1/10	1/2	1	2	4	10
$ARE(\{\hat{\beta}_n^{MME}\},\{\hat{\beta}_n^{MLE}\})$	0.3466	0.4203	0.5101	0.6356	0.7628	0.8850

이들 표에서 알 수 있듯이 이 예에서 적률이용추정량은 최대가능도추정량에 비하여 점근적으로 효율성이 낮다. 이러한 현상은 일반적으로 성립하는 것으로서 최대가능도추정량은 점근적으로 가장 효율적인 추정량임이 알려져 있다.

125) $\Psi(\alpha)$, $\dot{\Psi}(\alpha)$는 각각 다이감마(digamma), 트라이감마(trigamma) 함수라고 불리우는 함수로서 각각 로그감마함수의 일차, 이차 도함수이고 위의 표는 패키지 R에 있는 함수를 이용하여 계산한 결과이다.

연습문제

8.1 베르누이분포 Bernoulli(p), $0 \le p \le 1$에서의 랜덤표본 $X_1, \cdots, X_n$을 이용한 두 추정량

$$\hat{p}^{(0)} = \sum_{i=1}^{n} X_i/n, \quad \hat{p}^{(1)} = \frac{\sqrt{n}}{1+\sqrt{n}}\hat{p}^{(0)} + \frac{1}{1+\sqrt{n}}\frac{1}{2}$$

을 비교하려고 한다.

(a) 최대평균제곱오차 $\max_{0 \le p \le 1} E_p[(\hat{p}-p)^2]$를 기준으로 두 추정량을 비교하여라.

(b) 다음의 베이지안평균제곱오차를 기준으로 두 추정량을 비교하여라.

$$\int_0^1 E_p[(\hat{p}-p)^2] p^{\sqrt{n}-1}(1-p)^{\sqrt{n}-1} dp$$

(c) 평균제곱오차 $E_p[(\hat{p}-p)^2]$를 기준으로 $\hat{p}^{(1)}$이 $\hat{p}^{(0)}$보다 좋기 위한 p의 범위를 구하여라.

8.2 다음 각 모형에서의 랜덤표본을 $X_1, \cdots, X_n$이라고 할 때, $\theta \in \Omega$에 관한 충분통계량을 구하여라.

(a) Beta$(1,\theta)$, $\theta \in \Omega$, $\Omega = (0, +\infty)$

(b) Beta(θ,θ), $\theta \in \Omega$, $\Omega = (0, +\infty)$

8.3 다변량 정규분포 $N_k(\mu, \Sigma)$, $\mu \in R^k$, $\det(\Sigma) > 0$에서의 랜덤표본을 $X_1, \cdots, X_n$이라고 할 때 (μ, Σ)에 관한 충분통계량을 구하여라.

8.4 다음 각 모형에서의 랜덤표본을 $X_1, \cdots, X_n$이라고 할 때, $\theta = (\mu, \sigma)^t \in \Omega$에 관한 충분통계량을 구하여라.

(a) 로지스틱분포 $L(\mu, \sigma)$, $-\infty < \mu < +\infty$, $\sigma > 0$

(b) 코쉬분포 $C(\mu, \sigma)$, $-\infty < \mu < +\infty$, $\sigma > 0$

8.5 실수 전체의 집합에서의 연속형 분포를 모형으로 하는 경우에는 모수공간을

$$\Omega = \{f : f \text{는 수직선 위의 연속형 확률밀도함수}\}$$

로 나타낼 수 있다. 이러한 모형에서의 랜덤표본을 $X_1, \cdots, X_n$이라고 할 때 $f \in \Omega$에 관한 충분통계량을 구하여라.

8.6 자연수 전체의 집합에서의 이산형 분포를 모형으로 하는 경우에는 모수공간을

$$\Omega = \left\{(p_1, p_2, \cdots) : p_k \geq 0, k = 1, 2, \cdots, \sum_{k=1}^{\infty} p_k = 1\right\}$$

로 나타낼 수 있다. 이러한 모형에서의 랜덤표본을 $X_1, \cdots, X_n$이라고 할 때 $(p_1, p_2, \cdots) \in \Omega$에 관한 충분통계량을 구하여라.

8.7 두 개의 모수를 갖는 지수분포 $\mathrm{Exp}(\mu, \sigma)$, $-\infty < \mu < +\infty$, $\sigma > 0$에서의 랜덤표본을 관측할 수 없고 이들의 순서통계량 중에서 $X_{(1)} < \cdots < X_{(r)}$ $(1 \leq r < n)$만을 관측할 수 있다고 한다. 이 때 $(\mu, \sigma)^t \in R \times R_+$에 관한 충분통계량을 구하여라.

8.8 균등분포 $\mathrm{U}[-\theta, \theta]$, $\theta > 0$에서의 랜덤표본을 $X_1, \cdots, X_n$이라고 할 때 다음에 답하여라.

(a) $Y = \max_{1 \leq i \leq n} |X_i|$가 $\theta \in (0, +\infty)$에 관한 충분통계량임을 밝혀라.

(b) 랜덤표본의 순서통계량을 $X_{(1)} < \cdots < X_{(n)} (n \geq 2)$이라고 할 때,

$$\hat{\theta} = c_n (X_{(n)} - X_{(1)})$$

이 θ의 불편추정량이 되기 위한 c_n의 값을 구하여라.

(c) (a)에서의 충분통계량 $Y = \max_{1 \leq i \leq n} |X_i|$ $(n \geq 2)$에 기초한 추정량으로서 (b)에서의 불편추정량보다 더 작은 평균제곱오차를 갖는 추정량을 구하여라.

8.9 기하분포 $\mathrm{Geo}(p)$, $0 < p < 1$에서의 랜덤표본을 $X_1, \cdots, X_n (n \geq 2)$이라고 할 때, $p \in (0,1)$에 관한 완비충분통계량과 p의 전역최소분산불편추정량을 구하여라.

8.10 확률밀도함수가

$$f(x;\mu) = e^{-(x-\mu)} I_{[\mu,\infty)}(x)$$

로 주어지는 지수분포 $\mathrm{Exp}(\mu,1)$, $-\infty < \mu < +\infty$에서의 랜덤표본을 $X_1,\cdots,X_n$이라고 할 때, $\mu \in (-\infty, +\infty)$에 관한 완비충분통계량과 μ의 전역최소분산불편추정량을 구하여라.

8.11 두 개의 모수를 갖는 지수분포 $\mathrm{Exp}(\mu,\sigma)$, $-\infty < \mu < +\infty$, $\sigma > 0$에서의 랜덤표본을 $X_1, \cdots, X_n (n \geq 2)$이라고 할 때 다음에 답하여라.

(a) $(\mu,\sigma)^t \in R \times R_+$에 관한 완비충분통계량을 구하여라.

(b) μ의 전역최소분산불편추정량을 구하여라.

(c) σ의 전역최소분산불편추정량을 구하여라.

8.12 연습문제 (8.8)에서 다음에 답하여라.

(a) $S = (\min\limits_{1 \leq i \leq n} X_i, \max\limits_{1 \leq i \leq n} X_i)^t$가 $\theta \in (0, +\infty)$에 관한 완비통계량이 아님을 밝혀라.

(b) $Y = \max\limits_{1 \leq i \leq n} |X_i|$가 $\theta \in (0, +\infty)$에 관한 완비충분통계량임을 밝히고, θ의 전역최소분산불편추정량을 구하여라.

8.13 균등분포 $U[-\theta, 2\theta]$, $\theta > 0$에서 랜덤표본을 $X_1, \cdots, X_n$이라고 할 때 다음에 답하여라.

(a) $\theta \in (0, +\infty)$에 관한 최소충분통계량을 구하여라.

(b) θ의 전역최소분산불편추정량을 구하여라.

8.14 확률밀도함수가

$$f(x;\theta) = \frac{1}{\theta}, \quad x = 1,\cdots,\theta$$

로 주어지는 이산균등분포 $U\{1,\cdots,\theta\}$, $\theta \in \Omega$, $\Omega = \{1,2,\cdots\}$에서의 랜덤표본을 $X_1, \cdots, X_n$이라고 할 때 다음에 답하여라.

(a) $Y = \max_{1 \le i \le n} X_i$가 $\theta \in \Omega$에 관한 완비충분통계량임을 밝혀라.

(b) θ의 전역최소분산불편추정량을 구하여라.

8.15 정규분포 $N(\mu, \sigma^2)$, $-\infty < \mu < +\infty$, $\sigma > 0$에서의 랜덤표본을 $X_1, \cdots, X_n (n \ge 2)$이라고 할 때 $\eta = \mu/\sigma$의 전역최소분산불편추정량을 구하여라.

8.16 포아송분포 $Poisson(\theta)$, $\theta \ge 0$에서의 랜덤표본을 $X_1, \cdots, X_n$이라고 할 때

$$\eta = P_\theta(X_1 \ge r) \ (r\text{은 주어진 자연수})$$

의 전역최소분산불편추정량을 구하여라.

8.17 정규분포 $N(\mu, \sigma^2)$, $-\infty < \mu < +\infty$, $\sigma > 0$에서의 랜덤표본을 $X_1, \cdots, X_n (n \ge 2)$이라고 할 때

$$\eta = P_\theta(X_1 > a) \ (\theta = (\mu, \sigma)^t)$$

의 전역최소분산불편추정량을 구하여라.

8.18 두 개의 모수를 갖는 지수분포 $Exp(\mu,\sigma)$, $-\infty < \mu < +\infty$, $\sigma > 0$에서의 랜덤표본을 $X_1, \cdots, X_n (n \ge 2)$이라고 할 때

$$\eta = P_\theta(X_1 > a) \ (\theta = (\mu, \sigma)^t)$$

의 전역최소분산불편추정량을 구하여라.

8.19 포아송분포 $Poisson(\theta)$, $\theta \ge 0$에서의 랜덤표본을 $X_1, \cdots, X_n$이라고 할 때

$$\hat{\theta}_n^{(1)} = \sum_{i=1}^{n} X_i/n = \overline{X}, \ \hat{\theta}_n^{(2)} = \sum_{i=1}^{n} (X_i - \overline{X})^2/n$$

에 대하여 점근상대효율성 $ARE(\{\hat{\theta}_n^{(1)}\}, \{\hat{\theta}_n^{(2)}\})$을 구하여라.

8.20 정규분포 $N(\mu, \sigma^2)$, $-\infty < \mu < +\infty$, $\sigma > 0$에서의 랜덤표본을 $X_1, \cdots, X_n (n \ge 2)$이라고 할 때 다음에 답하여라.

(a) σ의 전역최소분산불편추정량 $\hat{\sigma}_n^{UMVUE}$을 구하여라.

(b) 표본표준편차 $S_n = \sqrt{\sum_{i=1}^{n}(X_i - \overline{X})^2/(n-1)}$ 의 전역최소불편추정량 $\widehat{\sigma_n}^{UMVUE}$에 대한 점근상대효율성 $ARE(\{S_n\}, \{\widehat{\sigma_n}^{UMVUE}\})$을 구하여라.

(c) σ의 불편추정량 $\widehat{\sigma_n}^{UE}$의 분산에 대한 정보량 부등식을 구하여라.

(참고: 점근상대효율성의 계산에서 다음 근사식을 사용한다. 이러한 근사식은 부록 Ⅰ의 <예 Ⅰ.3.1>과 <정리 Ⅰ.7.1>로부터 밝힐 수 있다.)

$$\Gamma(m+1) = m^{m+1/2}e^{-m}\sqrt{2\pi}(1+r_m),\ \sqrt{m}\,r_m \underset{m\to\infty}{\to} 0$$

$$(1+a/n)^n = e^a(1+R_n),\ \sqrt{n}\,R_n \underset{n\to\infty}{\to} 0$$

8.21 <정리 8.4.1>의 정보량 부등식에서 주어지는 분산의 하한은 모수의 일대일 변환에 무관한 것을 밝혀라. 즉 $\xi = g(\theta)$이고 g가 일대일이고 미분가능한 함수일 때

$$\left(\frac{\partial}{\partial\theta}E_\theta(\widehat{\eta_n})\right)^t\left[n\mathrm{Var}_\theta\left(\frac{\partial}{\partial\theta}\log f(X_1;\theta)\right)\right]^{-1}\left(\frac{\partial}{\partial\theta}E_\theta(\widehat{\eta_n})\right)$$

$$= \left(\frac{\partial}{\partial\xi}E_\xi(\widehat{\eta_n})\right)^t\left[n\mathrm{Var}_\xi\left(\frac{\partial}{\partial\xi}\log f(X_1;g^{-1}(\xi))\right)\right]^{-1}\left(\frac{\partial}{\partial\xi}E_\xi(\widehat{\eta_n})\right)$$

8.22 연습문제 (8.15)에서 $\eta = \eta(\theta)$의 불편추정량 $\widehat{\eta_n}^{UE}$의 분산에 대한 정보량 부등식을 구하고, $\eta = \eta(\theta)$의 최대가능도추정량 $\widehat{\eta_n}^{MLE}$의 극한분포를 구하여라.

8.23 연습문제 (8.17)에서 $a = 0$인 경우에 $\eta = \eta(\theta)$의 불편추정량 $\widehat{\eta_n}^{UE}$의 분산에 대한 정보량 부등식을 구하고, $\eta = \eta(\theta)$의 최대가능도추정량 $\widehat{\eta_n}^{MLE}$의 극한분포를 구하여라.

8.24 확률밀도함수가

$$f(x;\alpha,\beta) = \alpha\beta^{-\alpha}x^{\alpha-1}\exp(-x^\alpha/\beta^\alpha)I_{(0,+\infty)}(x)$$

인 와이불분포 $\mathrm{Weibull}(\alpha,\beta)$, $\alpha>0$, $\beta>0$ 모형에서의 랜덤표본을 $X_1, \cdots, X_n$이라고 할 때, <정리 6.4.3>의 조건 $(R0)\sim(R5)$가 만족되는 것을 가정하고 $\log X_i (i=1,\cdots,n)$의 적률을 이용한 추정량

$$\hat{\alpha_n}^0 = \sqrt{1.6449/S^2_{\log x}},\ S^2_{\log x} = \frac{1}{n}\sum_{i=1}^{n}(\log X_i - \overline{(\log X)})^2$$

의 최대가능도추정량 $\hat{\alpha_n}^{MLE}$에 대한 점근상대효율성을 구하여라.

8.25 <예 8.3.8>과 <예 8.3.10>에서 $\eta = \eta(\theta)$의 최대가능도추정량 $\hat{\eta_n}^{MLE}$과 전역최소분산불편추정량 $\hat{\eta_n}^{UMVUE}$에 대하여

$$\sqrt{n}(\hat{\eta_n}^{UMVUE} - \hat{\eta_n}^{MLE}) \xrightarrow[n\to\infty]{P_\theta} 0$$

임을 밝히고, $\sqrt{n}(\hat{\eta_n}^{UMVUE} - \eta)$의 극한분포를 구하여라.