2장 확률변수

- 2.1 확률변수의 정의
- 2.2 확률밀도함수 및 확률분포함수
- 2.3 결합 및 조건부 확률분포
- 2.4 기댓값
- 2.5 이산형 확률분포
- 2.6 연속형 확률분포
- 2.7 확률변수들의 함수
- 2.8 적률생성함수
- 2.9 확률생성함수

2.1 확률변수의 정의

1장에서 살펴본 표본공간 S는 수치적으로 또는 비수치적으로 표현될 수 있으나, 많은 경우 실험결과로부터 계산될 수 있는 어떤 수치적인 양이 관심의 대상이 된다. 예를 들어, 동전을 3회 독립적으로 반복하여 던졌을 경우 표본공간은 HHH, HHT, HTH, … 등으로 이루어지지만, 흔히 앞면이나 뒷면이 나오는 횟수 등 숫자로 표현할 수 있는 결과를 생각하게 된다는 것이다. 이 장에서는 표본공간 S에 정의된 사건들을 실수(real number)를 사용하여 나타내고, 1장에서 다루어진 확률을 이용하여 이 수치적 양에 대한 수리적 모형을 고려하기로 한다. 이때 실험결과를 표현하는 이 수치적 양을 **확률변수**(random variable)라고 하며, 이는 표본공간에서 정의되는 하나의 실함수(real-valued function)가 된다. 확률변수의 값은 랜덤한 실험결과에 따라 정해지므로 비결정적(non-deterministic)이지만 나올 수 있는 값들과 그 값들이 나올 가능성은 미리 생각해볼 수 있으며, 이를 이 확률변수의 **확률분포**(probability distribution)라고 한다. 어떤 확률변수든지 상응하는 확률분포를 가지며 확률분포는 여러 가지 방법으로 표현될 수 있다.

정의 2.1

확률변수 X는 표본공간 S에 정의된 실함수이다.

이제 동전을 3회 독립적으로 반복하여 던졌을 경우 관심 있는 변수로 X(=앞면이 나오는 횟수)를 생각해 보자. 이 경우 표본공간 S와 그에 대응하는 확률변수 X는 다음과 같다. 편의상 동전의 앞면은 H, 뒷면은 T로 표시한다.

S	X
HHH	3
HHT	2
HTH	2
THH	2
HTT	1
THT	1
TTH	1
TTT	0

이때 각 시행에서 동전의 앞면이 나올 확률을 p라고 하면 뒷면이 나올 확률은 $(1-p)$가 되며, 확률변수 X에 대응되는 확률분포는 원래의 표본공간 S를 고려하여 다음과

같이 구할 수 있다.

$$P(X=0) = P\{TTT\} = (1-p)^3,$$
$$P(X=1) = P\{HTT,\ THT,\ TTH\} = 3p(1-p)^2,$$
$$P(X=2) = P\{HHT,\ HTH,\ THH\} = 3p^2(1-p),$$
$$P(X=3) = P\{HHH\} = p^3.$$

엄밀한 의미에서, 표본공간 S에 정의된 확률과 변수 X에 대한 확률은 다른 표기를 사용하여야 하나 보통 혼동이 없으므로 그냥 P를 사용하기로 한다. 또한, 확률변수는 영문 대문자로 표기한다.

확률변수가 가질 수 있는 값은 앞의 예에서처럼 $\{0, 1, 2, 3\}$ 등으로 유한개(finite)일 수도 있고, $\{0, 1, 2, 3, 4, \ldots\}$ 등으로 셀 수 있는 무한개(countably infinite)일 수도 있으며, 때로 셀 수 없는 무한개(uncountably infinite)일 수도 있다. X가 어떤 특정사건이 일어날 때까지 걸리는 시간이라고 한다면 이 확률변수 X가 가질 수 있는 값의 영역은 $\{X > 0\}$으로 표현될 수 있고, 이러한 반직선은 셀 수 없이 많은 값을 포함한다. X의 범위가 유한(finite)이거나 가산무한(countably infinite)이면 이 확률변수 X는 **이산형**(discrete)이라고 하고, 범위가 실직선상의 어떤 구간인 경우 **연속형**(continuous)이라고 한다. 일반적으로 고려되는 확률변수는 이산형이거나 연속형 둘 중의 하나이지만, 둘의 혼합형인 확률변수도 있을 수 있다. 예를 들어, 확률변수 X의 범위가 $\{1, 2, (5, 10)\}$ 과 같이 유한개의 값과 실구간으로 구성되어 있으면 이는 혼합형이라고 볼 수 있다.

2.2 확률밀도함수 및 확률분포함수

이 절에서는 확률변수의 분포형태를 나타내는 데에 사용되는 **확률밀도함수**(probability density function)와 **확률분포함수**(probability distribution function)를 다루기로 한다. 이산형 확률변수의 경우 그의 분포를 나타내는 확률밀도함수 $f(x)$의 조건은 다음과 같다.

(1) 모든 실수 x에 대하여, $f(x) \geq 0$이다.

(2) 확률변수 X가 가질 수 있는 유한 또는 가산무한개의 값 $x_1, x_2, \cdots$ 에 대하여

$f(x_i) > 0$이며 $\sum_{\text{모든 } x_i} f(x_i) = 1$이다.

이산형 확률변수 X의 확률밀도함수 $f(x)$는 $P(X=x) = f(x)$를 만족하며 이를 **확률질량함수**(probability mass function)라고도 한다[2]. 반면 연속형 확률변수는 가질 수 있는 값이 셀 수 없는 무한개이기 때문에, 확률밀도함수가 가능한 값 하나하나에 확률을 부여하지 않고, 구간에 확률을 부여하게 된다. 그래서 연속형 확률변수 X의 경우 모든 실수 x에 대하여 $P(X=x) = 0$이나, 그의 확률밀도함수 $f(x)$는

(1) 모든 실수 x에 대하여, $f(x) \geq 0$

(2) $\int_{-\infty}^{\infty} f(x)dx = 1$

이라는 조건을 만족하며, $-\infty < a < b < \infty$일 때, $\int_a^b f(x)dx = P(a \leqq X \leqq b)$로 확률이 주어지게 된다.

종합하면, 확률변수 X의 확률밀도함수가 $f(x)$일 때, 변수 X가 실직선상의 어떤 집합 A(예를 들면 구간 $(a, b]$)에 속할 확률은

$$P(X \in A) = \begin{cases} \sum_{x_i \in A} f(x_i), & X\text{가 이산형인 경우} \\ \int_A f(x)dx, & X\text{가 연속형인 경우} \end{cases} \tag{2.1}$$

로 주어진다. 이와 같이 이산형 확률변수와 연속형 확률변수의 차이는 많은 경우에 합을 나타내는 방법이 Σ와 $\int$로 다를 뿐이다. 또한, 이는 변수 X가 연속형인 경우 $P(X=a) = \int_a^a f(x)dx = 0$이라는 사실과도 잘 부합된다.

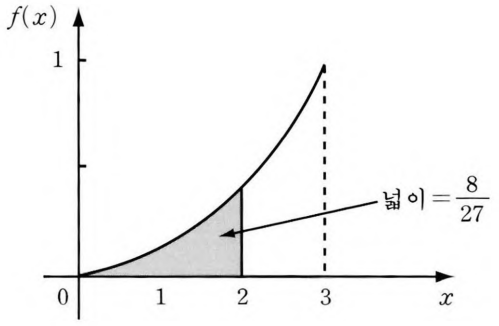
예 2.1

구간 $(0, 3)$에 정의된 함수 $f(x) = \frac{x^2}{9}$은 (1) $f(x) \geq 0$과, (2) $\int_0^3 \frac{x^2}{9}dx = 1$을 만족하므로 확률밀도함수이다. 이제 변수 X의 확률밀도함수가 $f(x)$이면, $0 < X < 2$일 확률은

2) 이 책에서는 혼동이 없는 한 연속형과 이산형 모두 확률밀도함수라는 용어를 사용하도록 하겠다.

$$P(0 < X < 2) = \int_0^2 \frac{x^2}{9} dx$$
$$= \frac{8}{27}$$

로 구해진다. 이를 그림으로 나타내면 다음과 같다.



이와 같이 연속확률변수가 어떤 구간에 들어갈 확률은 그 구간에서 확률밀도함수의 적분으로, 그림에서 보면 확률밀도함수와 x축 사이의 면적과 같아진다.

또한, 확률변수의 분포를 표현하는 다른 방법으로 확률밀도함수를 누적하여 구할 수 있는 확률분포함수가 다음과 같이 정의된다.

정의 2.2

확률변수 X에 대한 확률분포함수 $F(x)$는

$$F(x) = P(X \leq x)$$

으로 정의된다(확률분포함수는 확률변수 X가 주어진 점 x 이하인 모든 값을 가질 확률을 누적한다는 점에서 **누적분포함수**(cumulative distribution function) 또는 **누적확률분포함수**라고도 한다).

주 편의상, 확률변수 X가 확률밀도함수 $f(x)$ 또는 확률분포함수 $F(x)$를 가지는 경우 $X \sim f(x)$ 또는 $X \sim F(x)$로 표기하기로 한다.

앞에서 정의된 확률분포함수 $F(x)$가 꼭 만족해야 할 성질을 증명 없이 살펴보면 다

음 정리 2.1과 같다.

정리 2.1

함수 $F(x)$가 어떤 확률변수 X의 누적분포함수가 되는 필요충분조건은 다음과 같다.

$$\lim_{x \to -\infty} F(x) = 0$$

$$\lim_{x \to \infty} F(x) = 1$$

$$\lim_{h \to 0^+} F(x+h) = F(x)$$

$$a < b\text{이면 } F(a) \leq F(b)$$

위와 같은 확률분포함수 $F(x)$는 확률밀도함수 $f(x)$를 사용하여

$$F(x) = \begin{cases} \sum_{x_i \leq x} f(x_i), & X\text{가 이산형인 경우} \\ \int_{-\infty}^{x} f(t)dt, & X\text{가 연속형인 경우} \end{cases} \tag{2.2}$$

로 나타낼 수 있으며, 확률변수 X가 구간 $(a, b]$ 사이의 값을 가질 확률을 확률분포함수를 이용하면

$$P(a < X \leq b) = F(b) - F(a) \tag{2.3}$$

으로 표현할 수 있다.

예 2.2

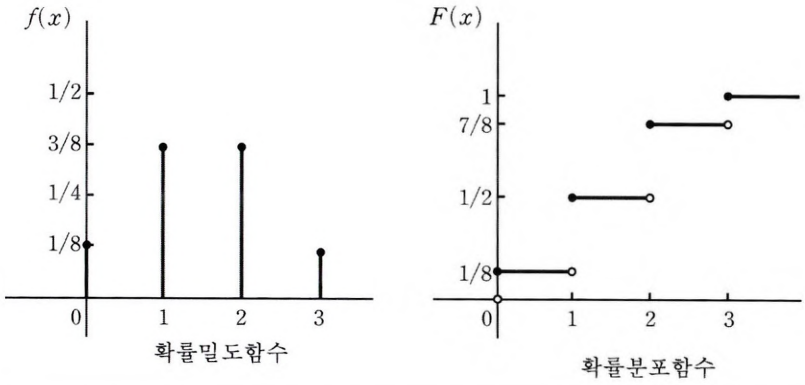
2.1절에서 소개된 예에서와 같이, 동전을 3회 독립반복하여 던졌을 경우 관심 있는 변수 X(=앞면의 수)의 확률밀도함수는 $p = 1/2$이라고 가정하면,

$$f(x) = \begin{cases} \frac{1}{8}, & x = 0\text{ 인 경우} \\ \frac{3}{8}, & x = 1\text{ 또는 }2\text{인 경우} \\ \frac{1}{8}, & x = 3\text{ 인 경우} \end{cases}$$

로 주어지고, 확률분포함수는

$$F(x)=\begin{cases}0, & x<0\\ \frac{1}{8}, & 0\le x<1\\ \frac{1}{2}, & 1\le x<2\\ \frac{7}{8}, & 2\le x<3\\ 1, & x\ge 3\end{cases}$$

로 주어지며, 그림을 통해 다음과 같이 표현된다.



예 2.3

연속형 확률변수 X의 확률밀도함수가

$$f(x)=\begin{cases}c(1+x)^{-2}, & x>0\text{인 경우}\\ 0, & x\le 0\text{인 경우}\end{cases}$$

로 주어졌을 때 상수 c의 값을 구해 보고, $P(1<X<2)$를 확률분포함수를 사용하여 계산해 보자. 먼저,

$$\int_0^\infty f(x)\,dx=\int_0^\infty c(1+x)^{-2}dx=\left.\frac{-c}{1+x}\right|_0^\infty=1$$

로부터 $c=1$이 구해지며, 이에 대한 확률분포함수는

$$F(x)=\int_{-\infty}^{x} f(t)\,dt=\int_{0}^{x}(1+t)^{-2}\,dt$$

$$=\begin{cases}1-\dfrac{1}{1+x}, & x>0\text{인 경우}\\ 0, & x\le 0\text{인 경우}\end{cases}$$

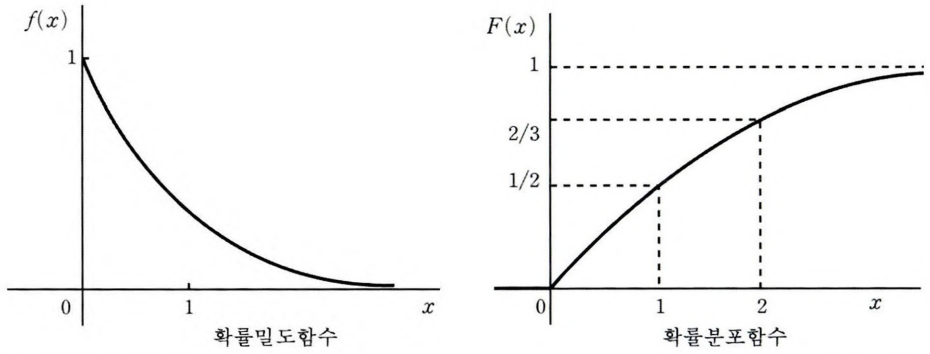
이다. 나아가,

$$P(1<X<2)=\int_{1}^{2} f(x)\,dx$$

$$=F(2)-F(1) \qquad \text{(식 (2.3)으로부터)}$$

$$=\frac{2}{3}-\frac{1}{2}=\frac{1}{6}$$

을 구할 수 있다. 이를 그래프로 표현하면 아래와 같다.



예 2.3에서와 같이 어떤 확률변수가 연속형인 경우 그의 확률밀도함수 $f(x)$와 확률분포함수 $F(x)$ 사이에는 다음 정리 2.2와 같은 관계가 성립한다.

정리 2.2

연속형확률변수 X의 확률밀도함수가 $f(x)$이고 확률분포함수가 $F(x)$이면, $f(x)=\dfrac{d}{dx}F(x)$를 만족한다.

증명 $F(x)=\int_{-\infty}^{x} f(t)\,dt$이므로 미분계산에 의하여 $f(x)=dF(x)/dx$이다. ■

예 2.4

함수 $F(x)=1-\exp(-x/\lambda)$ (단, $x>0$, λ는 양의 상수)는 정리 2.1을 만족하므로 어떤 연속형 확률변수 X의 확률분포함수가 된다. 이때 X의 확률밀도함수는

$$f(x)=\frac{d}{dx}F(x)$$
$$=\frac{1}{\lambda}\exp(-x/\lambda), \qquad x>0$$

가 된다.

2.3 결합 및 조건부 확률분포

2.3.1 결합 확률분포

앞 절에서는 관심 있는 확률변수가 하나인 경우의 분포를 생각하여 보았다. 그러나 많은 경우에 우리가 흥미를 가지는 현상은 관찰값이나 측정값들이 여러 개의 확률변수들 $X_1, X_2, \cdots, X_k$로 이루어져 있다. 가령, 어느 기계의 수명을 조사하기 위하여 반복하여 실험하였다든가, 어느 환자에 대한 건강기록을 구성하는 변수로 나이, 혈압, 몸무게 등을 생각한다든가, 아버지의 키와 아들의 키를 함께 생각한다든가 하는 경우들이다. 이처럼 여러 개의 확률변수들을 한꺼번에 고려하는 경우, 결합분포(joint distribution) 이론이 필요하게 된다. 편의상, k개의 확률변수 $X_1, X_2, \cdots, X_k$를 **확률벡터**(random vector) $\boldsymbol{X}=(X_1, X_2, \cdots, X_k)$로 표현하기도 한다. 우선 두 확률변수의 결합 확률밀도함수(joint probability density function)를 다음과 같이 정의하자.

정의 2.3

두 확률변수 X와 Y의 **결합 확률밀도함수** $f_{X,Y}(x, y)$는 X, Y가 이산형인 경우

$$f_{X,Y}(x, y)=P(X=x, Y=y)$$

로 정의되며, 연속형인 경우 이차평면상의 임의의 영역 A에 대하여,

$$P[(X, Y)\in A]=\iint_A f_{X,Y}(x, y)\,dxdy$$

를 만족하는 $f_{X,Y}(x,y)$로 정의된다.

이때 결합 확률밀도함수 $f_{X,Y}(x, y)$는 모든 실수 x, y에 대하여

(1) $f_{X,Y}(x, y) \geq 0$

(2) $\sum_{\text{모든 } x,y} \sum f_{X,Y}(x, y) = 1$, X, Y가 이산형인 경우

$\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f_{X,Y}(x, y) dxdy = 1$, X, Y가 연속형인 경우

이라는 조건들을 만족한다.

이제 두 확률변수가 이산형인 경우와 연속형인 경우의 결합 확률밀도함수의 예를 들어 보자.

예 2.5

(이산형) 4개의 빨간 공, 3개의 하얀 공, 그리고 2개의 검은 공이 들어 있는 주머니에서 3개의 공을 임의로 꺼냈을 때, X=하얀 공의 수, Y=검은 공의 수라고 하자. 이때 두 변수 X, Y의 결합 확률밀도함수는

$$f_{X,Y}(x, y) = \frac{\binom{3}{x}\binom{2}{y}\binom{4}{3-x-y}}{\binom{9}{3}}$$

$$(x = 0, 1, 2, 3; \quad y = 0, 1, 2; \quad 0 \leq x + y \leq 3)$$

으로, 아래와 같은 표로 나타낼 수 있다(다른 x, y값들에 대해서 $f_{X,Y}(x, y) = 0$이다).

Y \ X	0	1	2	3
0	4/84	18/84	12/84	1/84
1	12/84	24/84	6/84	0
2	4/84	3/84	0	0

예 2.6

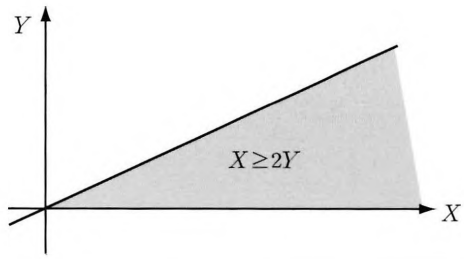
(연속형) 두 확률변수 X(=TV 시청에 보내는 시간), Y(=숙제하는 데에 보내는 시간)의 결합 확률밀도함수가

$$f_{X,Y}(x,y) = xye^{-(x+y)}, \qquad x>0, \quad y>0$$

로 주어졌다고 할 때, $X \geq 2Y$의 확률은 다음과 같이 계산된다.

$$\begin{aligned}
P(X \geq 2Y) &= \int_0^\infty \int_0^{x/2} xye^{-(x+y)}\,dydx \\
&= \int_0^\infty xe^{-x}\left[\int_0^{x/2} ye^{-y}\,dy\right]dx \\
&= \int_0^\infty xe^{-x}[1-(x/2+1)e^{-x/2}]\,dx \\
&= \int_0^\infty xe^{-x}dx - \int_0^\infty xe^{-\frac{3}{2}x}dx - \int_0^\infty \frac{x^2}{2}e^{-\frac{3}{2}x}dx \\
&= -xe^{-x}\Big|_0^\infty + \int_0^\infty e^{-x}dx - \left\{-\frac{2}{3}xe^{-\frac{3}{2}x}\Big|_0^\infty + \int_0^\infty \frac{2}{3}e^{-\frac{3}{2}x}dx\right\} \\
&\quad -\left\{-\frac{1}{3}x^2e^{-\frac{3}{2}x}\Big|_0^\infty + \int_0^\infty \frac{2}{3}xe^{-\frac{3}{2}x}dx\right\} \\
&= 1-\frac{12}{27}-\frac{8}{27} \\
&= \frac{7}{27}.
\end{aligned}$$

세 번째와 다섯 번째 등식을 얻기 위해 부분적분을 사용하였고, 여섯 번째 등식을 얻기 위해 $\lim_{x\to\infty} x^2e^{-x}=0$의 성질을 이용하였다. 위의 확률계산을 위한 적분영역을 구하기 위해 다음의 그래프를 생각할 수 있는데, 어둡게 표시된 부분이 $X \geq 2Y$에 해당하며 이것은 $\{(x,y): x>0,\ 0<y\leq x/2\}$로 쓸 수 있으므로 결합 확률밀도함수를 이 영역에서 적분하게 된다.



앞의 정의 2.3을 $k(>2)$개의 확률변수 $X_1, X_2, \cdots, X_k$ 로 확장하면 이들의 결합 확률밀도함수 $f(x_1, x_2, \cdots, x_k)$ 는 다음 두 조건을 만족한다.

(1) 모든 $(x_1, x_2, \cdots, x_k) \in R^k$ 에 대하여, $f(x_1, x_2, \cdots, x_k) \geq 0$ 이다.

(2) 이산형인 경우 $\sum_{\text{모든}(x_1, \cdots, x_k)} \cdots \sum f(x_1, x_2, \cdots, x_k) = 1$ 이며, 연속형인 경우

$$\int \cdots \int_{R^k} f(x_1, x_2, \cdots, x_k)\, dx_1 \cdots dx_k = 1 \text{이다.}$$

또한, k차원 공간상의 임의의 영역 $A \subset R^k$에 대하여, $(X_1, X_2, \cdots, X_k) \in A$ 일 확률은

$$P[(X_1, X_2, \cdots, X_k) \in A] = \begin{cases} \sum \cdots \sum_{(x_1, \cdots, x_k) \in A} f(x_1, x_2, \cdots, x_k), & \text{이산형인 경우} \\ \int \cdots \int_A f(x_1, x_2, \cdots, x_k) dx_1 \cdots dx_k, & \text{연속형인 경우} \end{cases} \tag{2.4}$$

로 주어진다.

이제, 결합 확률밀도함수 $f(x_1, x_2, \cdots, x_k)$ 에 대한 결합 확률분포함수(joint probability distribution function)는 다음과 같이 정의된다.

정의 2.4

확률변수 $X_1, X_2, \cdots, X_k$ 의 **결합 확률분포함수**는

$$F(x_1, x_2, \cdots, x_k) = P(X_1 \leq x_1, X_2 \leq x_2, \cdots, X_k \leq x_k)$$

로 정의된다.

따라서 결합 확률밀도함수를 사용하면 결합 확률분포는

$$F(x_1, x_2, \cdots, x_k) = \begin{cases} \sum \cdots \sum_{\text{모든} t_i \leq x_i} f(t_1, t_2, \cdots, t_k), & \text{이산형인 경우} \\ \int_{-\infty}^{x_k} \cdots \int_{-\infty}^{x_1} f(t_1, t_2, \cdots, t_k) dt_1 \cdots dt_k, & \text{연속형인 경우} \end{cases} \tag{2.5}$$

로 표현된다. 또한 확률벡터가 연속형인 경우, 결합 확률밀도함수와 결합 확률분포함수 사이에는

$$f(x_1, x_2, \cdots, x_k) = \frac{\partial^k}{\partial x_1 \cdots \partial x_k} F(x_1, x_2, \cdots, x_k) \tag{2.6}$$

의 관계가 성립한다. 식 (2.5)와 (2.6)은 각각 식 (2.2)와 정리 2.2에 대한 자연스러운 연장이다. 그리고 일변량 확률분포함수가 가지는 성질 정리 2.1은 이변량 확률벡터 (X_1, X_2)에 대하여 다음 정리 2.3과 같이 일반화된다.

정리 2.3

함수 $F(x_1, x_2)$가 어떤 이변량 확률벡터 (X_1, X_2)의 결합 확률분포함수가 되는 필요충분조건은 다음과 같다.

모든 x_1에 대하여 $\lim_{x_2 \to -\infty} F(x_1, x_2) = F(x_1, -\infty) = 0$

모든 x_2에 대하여 $\lim_{x_1 \to -\infty} F(x_1, x_2) = F(-\infty, x_2) = 0$

$$\lim_{x_1 \to \infty,\ x_2 \to \infty} F(x_1, x_2) = F(\infty, \infty) = 1$$

모든 $a < b$, $c < d$에 대하여 $F(b, d) - F(b, c) - F(a, d) + F(a, c) \geq 0$

모든 x_1, x_2에 대하여

$$\lim_{h \to 0^+} F(x_1, x_2 + h) = \lim_{h \to 0^+} F(x_1 + h, x_2) = F(x_1, x_2)$$

예 2.7

두 변수 X, Y의 결합 확률분포함수가

$$F_{X,Y}(x, y) = xy \qquad (0 < x < 1,\ 0 < y < 1)$$

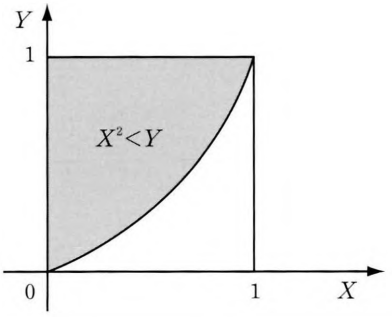
로 주어졌을 때 X, Y의 결합 확률밀도함수 $f_{X,Y}(x, y)$를 구하고 $P(X^2 < Y)$를 계산하여 보자. 앞의 식 (2.6)을 사용하면

$$\begin{aligned} f_{X,Y}(x, y) &= \frac{\partial^2}{\partial x \partial y} F_{X,Y}(x, y) \\ &= \frac{\partial^2}{\partial x \partial y} xy \\ &= 1 \qquad (0 < x < 1,\ 0 < y < 1) \end{aligned}$$

이 된다. 따라서 식 (2.4)에 의하면

$$P(X^2 < Y) = \int_0^1 \int_0^{\sqrt{y}} 1 \; dxdy$$
$$= \frac{2}{3}$$

가 된다. 예 2.6에서와 마찬가지로, 위의 확률을 계산하기 위하여 해당하는 적분영역을 아래 그림과 같이 표현할 수 있다.



예 2.8

두 변수 X, Y의 결합 확률밀도함수가

$$f_{X,Y}(x,y) = 8xy, \qquad 0 < x < y < 1$$

일 때, $F_{X,Y}(x,y)$를 계산해 보자.

$$F_{X,Y}(x,y) = \int_{-\infty}^{x} \int_{-\infty}^{y} f_{X,Y}(t_1,t_2)dt_2dt_1$$

이므로, 이를 계산하면

$$F_{X,Y}(x,y) = \begin{cases} 0, & x \le 0 \text{ 또는 } y \le 0 \\ x^2(2y^2 - x^2), & 0 < x < y < 1 \\ x^2(2 - x^2), & 0 < x < 1,\ y \ge 1 \\ y^4, & 0 < y < \min\{x,1\} \\ 1, & x \ge 1,\ y \ge 1 \end{cases}$$

이 된다.

2.3.2 주변 확률분포

두 확률변수의 결합분포에 관심이 있더라도 경우에 따라서 각 변수만의 분포를 구할 필요가 있다. 두 확률변수 X, Y의 결합 확률밀도함수가 $f_{X,Y}(x, y)$로 주어졌을 때, 두 변수 X, Y 각각의 확률밀도함수 $f_X(x)$와 $f_Y(y)$를 **주변 확률밀도함수**(marginal probability density function)라고 하며, 이들의 관계가 다음 정리 2.4와 같이 주어진다.

정리 2.4

두 확률변수 X, Y의 결합 확률밀도함수가 $f_{X,Y}(x, y)$로 주어졌을 때, X와 Y 각각의 주변 확률밀도함수 $f_X(x)$와 $f_Y(y)$는

(i) 이산형인 경우

$$f_X(x) = \sum_{\text{모든 } y} f_{X,Y}(x, y), \quad f_Y(y) = \sum_{\text{모든 } x} f_{X,Y}(x, y)$$

(ii) 연속형인 경우

$$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x, y)dy, \quad f_Y(y) = \int_{-\infty}^{\infty} f_{X,Y}(x, y)\,dx$$

로 구해진다.

증명 편의상 연속형의 경우만 다루기로 하겠으나, 이산형의 경우도 대동소이하다.

$$\begin{aligned} f_X(x) &= (d/dx)F_X(x) \\ &= (d/dx)P(X \le x, \quad -\infty < Y < \infty) \\ &= \frac{d}{dx}\left[\int_{-\infty}^{x}\int_{-\infty}^{\infty} f_{X,Y}(u, y)\,dydu\right] \\ &= \int_{-\infty}^{\infty} f_{X,Y}(x, y)\,dy \end{aligned}$$ ■

위 정리 2.4의 내용은 $k(>2)$개의 변수에 대해서도 다음과 같이 자연스럽게 확장된다. 확률변수 $X_1, X_2, \cdots, X_k$의 결합 확률밀도함수가 $f(x_1, x_2, \cdots, x_k)$일 때, $X_i(1 \le i \le k)$의 주변 확률밀도함수는

(i) 이산형인 경우

$$f_{X_i}(x_i) = \sum_{x_1} \cdots \sum_{x_{i-1}} \sum_{x_{i+1}} \cdots \sum_{x_k} f(x_1, x_2, \cdots, x_k)$$

(ii) 연속형인 경우

$$f_{X_i}(x_i) = \int \cdots \int f(x_1, x_2, \cdots, x_k) dx_1 \cdots dx_{i-1} dx_{i+1} \cdots dx_k$$

로 주어진다.

이제 확률변수들이 이산형인 경우와 연속형인 경우의 결합 확률밀도함수의 예를 들어 보고, 각 변수들의 주변 확률밀도함수를 구해 보기로 한다.

예 2.9

(이산형) 모든 눈이 나올 확률이 동일한 주사위 하나를 n회 독립적으로 던졌을 때, 변수 X_1을 주사위의 눈이 1인 횟수, 변수 X_2를 주사위의 눈이 2 또는 3인 횟수, X_3를 주사위의 눈이 4, 5 또는 6인 횟수라고 하자. 이때 확률변수 X_1, X_2, X_3 $(= n - (X_1 + X_2))$의 결합 확률밀도함수는

$$f(x_1, x_2, x_3) = \frac{n!}{x_1!\, x_2!\, x_3!} (1/6)^{x_1} (2/6)^{x_2} (3/6)^{x_3}$$

(단, $x_1 = 0, 1, \cdots, n$; $x_2 = 0, 1, \cdots, n$; $x_3 = 0, 1, \cdots, n$; $x_1 + x_2 + x_3 = n$)

으로 주어진다. 따라서 주변 확률밀도함수는

$$f(x_1) = \sum_{x_2} \sum_{x_3} f(x_1, x_2, x_3) \qquad (\text{단, } x_3 = n - (x_1 + x_2))$$

$$= \sum_{x_2 = 0}^{n - x_1} \frac{n!}{x_1!\, x_2!\, (n - x_1 - x_2)!} \left(\frac{1}{6}\right)^{x_1} \left(\frac{2}{6}\right)^{x_2} \left(\frac{3}{6}\right)^{n - x_1 - x_2}$$

$$= \frac{n!}{x_1!\, (n - x_1)!} \left(\frac{1}{6}\right)^{x_1} \sum_{x_2 = 0}^{n - x_1} \frac{(n - x_1)! \left(\frac{2}{6}\right)^{x_2} \left(\frac{3}{6}\right)^{(n - x_1) - x_2}}{x_2!\, [(n - x_1) - x_2]!}$$

$$= \frac{n!}{x_1!\, (n - x_1)!} \left(\frac{1}{6}\right)^{x_1} \sum_{x_2 = 0}^{n - x_1} \binom{n - x_1}{x_2} \left(\frac{2}{6}\right)^{x_2} \left(\frac{3}{6}\right)^{(n - x_1) - x_2}$$

$$= \binom{n}{x_1}\left(\frac{1}{6}\right)^{x_1}\left(\frac{2}{6}+\frac{3}{6}\right)^{n-x_1}$$

$$= \binom{n}{x_1}\left(\frac{1}{6}\right)^{x_1}\left(\frac{5}{6}\right)^{n-x_1}$$

마찬가지 방법으로,

$$f(x_2) = \binom{n}{x_2}\left(\frac{2}{6}\right)^{x_2}\left(\frac{4}{6}\right)^{n-x_2}$$

$$f(x_3) = \binom{n}{x_3}\left(\frac{3}{6}\right)^{x_3}\left(\frac{3}{6}\right)^{n-x_3}$$

로 구해진다.

예 2.10

(연속형) 두 확률변수 X, Y의 결합 확률밀도함수가

$$f_{X,Y}(x, y) = xye^{-(x+y)}, \quad x > 0, \quad y > 0$$

로 주어졌다. 이때 X, Y의 주변 확률밀도함수는

$$f_X(x) = \int_0^\infty xye^{-(x+y)}\,dy = xe^{-x}, \quad x > 0$$

$$f_Y(y) = \int_0^\infty xye^{-(x+y)}\,dx = ye^{-y}, \quad y > 0$$

으로 각각 구해진다.

2.3.3 조건부 확률분포

여기서는 여러 개의 확률변수들 중 어떤 몇 개의 변수값이 주어졌다는 조건하에서 나머지 변수들의 분포에 대한 이론을 다루기로 한다. 이러한 분포이론은 후에 회귀분석 등에서 필수적으로 사용된다. 또한 이는 다음 절에서 다루어질 변수들 사이의 독립개념과도 깊은 관련이 있다. 우선 두 확률변수 X와 Y의 결합 확률밀도함수를 $f_{X,Y}(x, y)$라고 하자. 이제, $X = x$가 주어졌을 때 조건부 확률변수 Y를 $Y \mid X = x$로 표기하면, $Y \mid X = x$의 조건부확률밀도함수(conditional probability density function)

$f_{Y|x}(y|x)$는 다음과 같이 정의된다(편의상 $Y|X=x$를 $Y|x$로 표기하기도 한다).

정의 2.5

$X=x$가 주어졌을 때, $Y|x$의 조건부 확률밀도함수는

$$f_{Y|X}(y|x)=\frac{f_{X,Y}(x,y)}{f_X(x)} \quad (\text{단, } f_X(x)>0)$$

으로 정의된다.

위의 정의 2.5는 1장에서 다룬 사건에 대한 조건부 확률의 정의에 부합된다. 즉,

$$P(Y=y|X=x)=\frac{P(X=x,\ Y=y)}{P(X=x)} \quad (\text{단, } P(X=x)>0)$$

이므로 위의 정의는 타당하다.

예 2.11

(예 2.5의 계속) 두 확률변수 X와 Y의 결합 확률밀도함수 $f_{X,Y}(x,y)$가 다음과 같이 주어져 있다.

Y \ X	0	1	2	3
0	4/84	18/84	12/84	1/84
1	12/84	24/84	6/84	0
2	4/84	3/84	0	0

여기에서 $X=x$가 주어지면, $Y|x$의 조건부 확률밀도함수 $f_{Y|X}(y|x)$는 다음과 같이 계산된다.

$f_{Y|X}(y|0)=\dfrac{f_{X,Y}(0,y)}{f_X(0)}$이므로,

$$f_{Y|X}(0|0)=\frac{f_{X,Y}(0,0)}{f_X(0)}=\frac{1}{5},\ f_{Y|X}(1|0)=\frac{f_{X,Y}(0,1)}{f_X(0)}=\frac{3}{5},$$

$$f_{Y|X}(2|0)=\frac{f_{X,Y}(0,2)}{f_X(0)}=\frac{1}{5}$$

$f_{Y|X}(y \mid 1) = \dfrac{f_{X,Y}(1, y)}{f_X(1)}$ 이므로,

$$f_{Y|X}(0|1) = \frac{f_{X,Y}(1, 0)}{f_X(1)} = \frac{2}{5},\quad f_{Y|X}(1|1) = \frac{f_{X,Y}(1, 1)}{f_X(1)} = \frac{8}{15},$$

$$f_{Y|X}(2|1) = \frac{f_{X,Y}(1, 2)}{f_X(1)} = \frac{1}{15}$$

$f_{Y|X}(y \mid 2) = \dfrac{f_{X,Y}(2, y)}{f_X(2)}$ 이므로,

$$f_{Y|X}(0|2) = \frac{f_{X,Y}(2, 0)}{f_X(2)} = \frac{2}{3},\quad f_{Y|X}(1|2) = \frac{f_{X,Y}(2, 1)}{f_X(2)} = \frac{1}{3},$$

$$f_{Y|X}(2|2) = \frac{f_{X,Y}(2, 2)}{f_X(2)} = 0$$

$f_{Y|X}(y \mid 3) = \dfrac{f_{X,Y}(3, y)}{f_X(3)}$ 이므로,

$$f_{Y|X}(0|3) = \frac{f_{X,Y}(3, 0)}{f_X(3)} = 1,\quad f_{Y|X}(1|3) = \frac{f_{X,Y}(3, 1)}{f_X(3)} = 0,$$

$$f_{Y|X}(2|3) = \frac{f_{X,Y}(3, 2)}{f_X(3)} = 0$$

예 2.12

두 확률변수 X와 Y의 결합 확률밀도함수 $f_{X,Y}(x, y)$가 다음과 같이 주어졌다고 하자.

$$f_{X,Y}(x, y) = x^2 e^{-x(y+1)}, \qquad x > 0, \quad y > 0$$

여기에서 $X = x$가 주어지면, $Y \mid x$의 조건부 확률밀도함수 $f_{Y|X}(y \mid x)$는 아래와 같이 계산된다.

$$\begin{aligned} f_{Y|X}(y \mid x) &= f_{X,Y}(x, y)/f_X(x) \\ &= \frac{x^2 e^{-x(y+1)}}{\displaystyle\int_0^\infty x^2 e^{-x(y+1)}\, dy} \\ &= \frac{e^{-xy}}{\displaystyle\int_0^\infty e^{-xy} dy} \end{aligned}$$

$$= \frac{e^{-xy}}{0-(-1/x)}$$

$$= xe^{-xy}, \qquad y > 0.$$

위의 정의 2.5의 내용을 $k(>2)$개의 변수에 대해 확장하면 다음과 같다. 확률변수 $X_1, X_2, \cdots, X_k$의 결합 확률밀도함수가 $f(x_1, x_2, \cdots, x_k)$ 이고, $X = x_1$, $X = x_2$, $\cdots$, $X_i = x_i (i < k)$이 주어졌을 때, $(k-i)$개의 확률변수 $X_{i+1}, \cdots, X_k$의 조건부 확률밀도함수는

$$f(x_{i+1}, \cdots, x_k \mid x_1, x_2, \cdots, x_i) = \frac{f(x_1, x_2, \cdots, x_k)}{f(x_1, x_2, \cdots, x_i)} \tag{2.7}$$

단,

(i) 이산형인 경우

$$f(x_1, \cdots, x_i) = \sum_{x_{i+1}} \cdots \sum_{x_k} f(x_1, x_2, \cdots, x_k)$$

(ii) 연속형인 경우

$$f(x_1, \cdots, x_i) = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} f(x_1, x_2, \cdots, x_k) dx_{i+1} \cdots dx_k$$

로 주어진다.

2.3.4 독립확률변수

1장에서 다루었던 사건들 사이의 독립에 대한 개념으로부터 확률변수들 간의 독립을 다음과 같이 정의한다.

정의 2.6

두 확률변수 X와 Y는 임의의 실구간 A와 B에 대하여

$$P(X \in A, Y \in B) = P(X \in A) \cdot P(Y \in B)$$

가 성립할 때 서로 **독립**(independent)이라고 한다.

그런데, $X \in A$와 $Y \in B$는 사건을 나타내므로 앞의 정의 2.6은 두 사건 사이의 독립을 옮긴 것으로 볼 수 있다. 이제 위의 정의 2.6을 확률밀도함수를 사용하여 나타내면 다음 정리와 같다.

정리 2.5

두 확률변수 X와 Y가 서로 독립일 필요충분조건은

$$f_{X,Y}(x, y) = f_X(x) \cdot f_Y(y)$$

이다.

증명 두 확률변수가 연속형인 경우만 고려하기로 한다. 임의의 실구간 A와 B에 대하여

$$\begin{aligned}\int_B \int_A f_{X,Y}(x, y)\, dxdy &= P(X \in A,\ Y \in B) \\ &= P(X \in A) \cdot P(Y \in B) \\ &= \int_A f_X(x)\, dx \cdot \int_B f_Y(y)\, dy \\ &= \int_B \int_A f_X(x) \cdot f_Y(y)\, dxdy\end{aligned}$$

가 성립할 필요충분조건은 $f_{X,Y}(x, y) = f_X(x) \cdot f_Y(y)$이다. 이산형 확률변수에 대해서는 $\int$을 Σ로 바꾸어 같은 방법의 증명이 가능하다. ■

따라서 두 확률변수가 서로 독립일 필요충분조건은 결합 확률밀도함수가 주변 확률밀도함수들의 곱의 꼴로 표현되는 것이다. 그런데 $f_{X,Y}(x, y) = f_X(x) \cdot f_Y(y)$는 $F_{X,Y}(x, y) = F_X(x) \cdot F_Y(y)$와 동등하므로(참조: 연습문제 2.34) 분포함수를 활용하여 독립여부를 가릴 수도 있다. 앞에서 주어진 예 2.7 또는 예 2.10의 경우는, 정리 2.5에 의하여 살펴보면, 두 변수 X와 Y가 서로 독립임을 알 수 있다. 그러나 예 2.11의 두 변수 X와 Y는 서로 독립이 아님을 쉽게 볼 수 있다.

예 2.13

두 변수 X, Y의 결합 확률밀도함수가

$$f_{X,Y}(x, y)=\frac{2^{x+y}e^{-4}}{x!\,y!}, \quad x, y=0, 1, 2, \cdots$$

으로 주어졌을 때, X와 Y의 주변 확률밀도함수는 각각

$$f_X(x)=\sum_y f_{X,Y}(x, y)=\frac{2^x e^{-2}}{x!}, \quad x=0, 1, 2, \cdots$$
$$f_Y(y)=\sum_x f_{X,Y}(x, y)=\frac{2^y e^{-2}}{y!}, \quad y=0, 1, 2, \cdots$$

으로 계산되므로 $f_{X,Y}(x, y)=f_X(x)\cdot f_Y(y)$가 성립한다. 따라서 X와 Y는 서로 독립이다. 만약, 두 변수 X, Y의 결합 확률밀도함수가

$$f_{X,Y}(x,y)=\begin{cases}\frac{1}{2}, & 0\le x\le y\le 2,\\ 0, & \text{다른 경우}\end{cases}$$

로 주어진다면, X와 Y의 주변 확률밀도함수는 각각

$$f_X(x)=\int_x^2 \frac{1}{2}dy=\frac{1}{2}(2-x), \quad 0\le x\le 2,$$
$$f_Y(y)=\int_0^y \frac{1}{2}dx=\frac{1}{2}y, \quad 0\le y\le 2$$

가 되어 $f_{X,Y}(x,y)=f_X(x)\cdot f_Y(y)$가 성립하지 않는다. 따라서 X와 Y는 서로 독립이 아니다.

위의 내용을 $k(>2)$개의 변수에 대해 확장하면, 확률변수 $X_1, X_2, \cdots, X_k$가 서로 독립일 필요충분조건은 이들의 결합 확률밀도함수가 k개의 주변 확률밀도함수의 곱과 같다는 것이다. 즉,

$$f(x_1, x_2, \cdots, x_k)=f_{X_1}(x_1)f_{X_2}(x_2)\cdots f_{X_k}(x_k)$$

이다. 따라서 확률밀도함수 $f(x)$를 갖는 모집단으로부터 크기가 n인 **랜덤표본**(random sample) $X_1, X_2, \cdots, X_n$을 얻었을 때 이들의 결합 확률밀도함수는

$$f(x_1, x_2, \cdots, x_n)=f(x_1)f(x_2)\cdots f(x_n) \tag{2.8}$$

으로 주어진다.

예 2.14

서로 독립인 3개의 확률변수 X_1, X_2, X_3의 공통된 확률밀도함수가 $f(x)=3x^2$, $0<x<1$이라고 하자. 이때 X_1, X_2, X_3의 결합 확률밀도함수는

$$f(x_1)f(x_2)f(x_3)=27x_1^2x_2^2x_3^2, \qquad 0<x_1,\ x_2,\ x_3<1$$

이다. 따라서, 예를 들면

$$\begin{aligned}
&P(X_1 \le 1/2,\ X_2 \le 1/2,\ X_3 \le 1/2)\\
&=\int_0^{1/2}\int_0^{1/2}\int_0^{1/2} 27x_1^2x_2^2x_3^2\,dx_1dx_2dx_3\\
&=27\int_0^{1/2} x_1^2dx_1\cdot\int_0^{1/2} x_2^2dx_2\cdot\int_0^{1/2} x_3^2dx_3\\
&=\left(\frac{1}{8}\right)^3
\end{aligned}$$

으로 계산된다.

2.4 기댓값

확률밀도함수나 확률분포함수는 확률변수의 전체적인 성격을 설명하는데, 때로 우리는 몇 개의 수치로 확률분포의 성질을 요약하고자 하기도 한다. 이러한 확률분포의 성질을 요약하는 수치들 중의 하나로 변수의 기댓값(expectation)을 생각해 보기로 한다. 기댓값은 변수의 위치를 나타내는 중요한 모수로서 평균(mean)이라고도 불리는데, 확률변수 X의 기댓값 $E(X)$는 다음과 같이 정의된다.

정의 2.7

확률변수 X의 확률밀도함수가 $f(x)$일 때 X의 **기댓값**은

$$E(X)=\begin{cases}\sum\limits_{\text{모든 } x_i} x_i f(x_i) & X\text{가 이산형인 경우}\\ \int_{-\infty}^{\infty} xf(x)dx & X\text{가 연속형인 경우}\end{cases}$$

가 된다. 단, $E(|X|) < \infty$이어야 한다. 때로는 $E(X)$의 값이 유한하지 않은 경우도 있으며, 이런 경우 기댓값(평균)이 존재하지 않는다고 말한다.

예 2.15

앞의 예 2.2에서와 같이 이산형 확률변수 X의 확률밀도함수가

$$f(x) = \begin{cases} \frac{1}{8}, & x = 0\text{인 경우} \\ \frac{3}{8}, & x = 1 \text{ 또는 } 2\text{ 인 경우} \\ \frac{1}{8}, & x = 3\text{인 경우} \end{cases}$$

로 주어졌다고 하자. 이때 X의 기댓값은

$$\begin{aligned} E(X) &= 0 \times \frac{1}{8} + 1 \times \frac{3}{8} + 2 \times \frac{3}{8} + 3 \times \frac{1}{8} \\ &= \frac{3}{2} \end{aligned}$$

으로 계산된다.

예 2.16

다음은 연속형 확률변수의 예를 들어보자. 확률변수 X의 확률밀도함수가 $f(x) = x^2/9$ (단, $0 < x < 3$)으로 주어졌을 때 X의 기댓값은

$$\begin{aligned} E(X) &= \int_0^3 \frac{x^3}{9} dx \\ &= \frac{x^4}{36}\Big|_0^3 \\ &= \frac{9}{4} \end{aligned}$$

가 된다. 또, 앞의 예 2.10에서 고려한 연속형 확률변수 X의 기댓값은

$$
\begin{aligned}
E(X) &= \int_0^\infty x f(x)\,dx \\
&= \int_0^\infty x^2 e^{-x}\,dx \\
&= -x^2 e^{-x}\,\Big|_0^\infty + \int_0^\infty 2x e^{-x}\,dx \\
&= 2
\end{aligned}
$$

로 계산된다.

정의 2.7로부터 확률변수 X의 기댓값은 X가 가지는 값들에 해당하는 확률가중을 사용한 가중평균(weighted average)이라는 것을 알 수 있다. 확률변수 X의 함수인 $g(X)$의 기댓값 $E[g(X)]$는 변수 $Y=g(X)$의 확률밀도함수를 $f_Y(y)$라 할 때,

$$
E_X[g(X)] = E_Y(Y) = \begin{cases} \sum_{\text{모든 } y_i} y_i f_Y(y_i), & \text{이산형인 경우} \\ \int_{-\infty}^{\infty} y f_Y(y)\,dy, & \text{연속형인 경우} \end{cases} \tag{2.9}
$$

가 일반적으로 성립한다(여기에서 E_X와 E_Y의 아래첨자는 기댓값 계산에 사용되는 확률변수를 표현하기 위해 사용된 것이며, 혼동이 없으면 생략하기로 한다. $Y=g(X)$일 때 $f_Y(y)$를 구하는 방법은 2.7절에서 자세히 다루기로 한다). 그런데 X의 확률밀도함수를 알고 있다면, Y의 확률밀도함수를 따로 구할 필요 없이 아래와 같이 $E[g(X)]$를 구할 수 있고, 이를 $E[g(X)]$의 정의로 사용하기도 한다.

$$
E[g(X)] = \begin{cases} \sum_{\text{모든 } x_i} g(x_i) f_X(x_i), & \text{이산형인 경우} \\ \int_{-\infty}^{\infty} g(x) f_X(x)\,dx, & \text{연속형인 경우} \end{cases} \tag{2.10}
$$

따라서 $Y=g(X)$의 기댓값을 구하는 데는 식 (2.9)와 (2.10)을 사용하는 두 가지 방법이 가능하다.

예 2.17

예 2.10에서 고려한 바와 같이 연속형 확률변수 X의 확률밀도함수가 $f_X(x)=xe^{-x}(x>0)$일 때, $g(X)=X^2+5$의 기댓값은

$$\begin{aligned}E(X^2+5)&=\int_0^\infty (x^2+5)f_X(x)dx\\&=\int_0^\infty x^3e^{-x}dx+\int_0^\infty 5xe^{-x}dx\\&=-x^3e^{-x}\Big|_0^\infty+\int_0^\infty 3x^2e^{-x}dx+\int_0^\infty 5xe^{-x}dx\\&=-x^3e^{-x}\Big|_0^\infty-3x^2e^{-x}\Big|_0^\infty+\int_0^\infty 6xe^{-x}dx+\int_0^\infty 5xe^{-x}dx\\&=11\end{aligned}$$

로 계산되는데, $Y=X^2+5$의 확률밀도함수인 $f_Y(y)$를 구할 수 있다면 이것은 $\int_{-\infty}^{\infty} yf_Y(y)dy$의 값과 같게 된다.

2.4.1 기댓값의 성질

이제 기댓값의 구체적인 성질들을 살펴보기로 하자. 우선 식 (2.9)와 (2.10)으로부터 다음의 정리 2.6을 쉽게 유도할 수 있다.

정리 2.6

확률변수 X의 함수에 대한 기댓값은, 상수 a, b, c에 대하여

$$\begin{aligned}E(c)&=c\\E(aX+b)&=aE(X)+b\end{aligned}$$

를 만족한다.

증명 편의상, 연속형을 고려하면

$$E(c)=\int_{-\infty}^{\infty} cf(x)dx=c\int_{-\infty}^{\infty} f(x)dx=c$$

$$\begin{aligned} E(aX+b) &= \int_{-\infty}^{\infty}(ax+b)f(x)dx \\ &= a\int_{-\infty}^{\infty}xf(x)dx + b\int_{-\infty}^{\infty}f(x)dx \\ &= aE(X)+b \end{aligned}$$

가 성립한다. 이산형 확률변수에 대해서는 $\int$을 Σ로 바꾸어 같은 방법의 증명이 가능하다. ■

예 2.18

앞의 예 2.2에서와 같이 이산형 확률변수 X의 확률밀도함수가

$$f(x)=\begin{cases}\frac{1}{8}, & x=0\text{인 경우}\\ \frac{3}{8}, & x=1\text{ 또는 }2\text{인 경우}\\ \frac{1}{8}, & x=3\text{인 경우}\end{cases}$$

로 주어졌다고 하자. 이때 $8X+5$의 기댓값은 $E(X)=\frac{3}{2}$이므로

$$\begin{aligned} E(8X+5) &= 8E(X)+5 \\ &= 17 \end{aligned}$$

이다.

이제 n개의 확률변수 $X_1, X_2, \cdots, X_n$의 함수 $g(X_1, X_2, \cdots, X_n)$의 기댓값 $E[g(X_1, X_2, \cdots, X_n)]$은 결합 확률밀도함수가 $f(x_1, x_2, \cdots, x_n)$일 때,

(i) 이산형인 경우

$$E[g(X_1, X_2, \cdots, X_n)] = \sum_{x_1}\cdots\sum_{x_n} g(x_1, x_2, \cdots, x_n)f(x_1, x_2, \cdots, x_n)$$

(ii) 연속형인 경우

$$\begin{aligned} &E[g(X_1, X_2, \cdots, X_n)] \\ &= \int_{-\infty}^{\infty}\cdots\int_{-\infty}^{\infty} g(x_1, x_2, \cdots, x_n)f(x_1, x_2, \cdots, x_n)\,dx_1dx_2\cdots dx_n \end{aligned} \tag{2.11}$$

이 된다. 또한 앞의 식 (2.11)로부터 유도되는, 두 개 또는 그 이상의 확률변수에 대한 기댓값의 성질들로는 다음과 같은 것들이 있다.

(1) $E(aX+bY)=aE(X)+bE(Y)$ (단, a, b는 상수)

(2) $E(a_1X_1+a_2X_2+\cdots+a_nX_n)=a_1E(X_1)+a_2E(X_2)+\cdots+a_nE(X_n)$
(단, a_i는 상수, $i=1, 2, \cdots, n$)

이와 같은 성질들은 기댓값의 선형성(linearity)을 보여주는데, 이는 Σ이나 $\int$이 선형이므로 자연스러운 결과이다. 이제 앞에서와 마찬가지로, 변환된 확률변수 $Z=g(X, Y)$의 확률밀도함수를 $f_Z(z)$라 하면,

$$E[g(X, Y)]=E(Z)=\begin{cases}\sum_{\text{모든 } z_i} z_i f_Z(z_i), & \text{이산형인 경우}\\ \int_{-\infty}^{\infty} z f_Z(z)\,dz, & \text{연속형인 경우}\end{cases}$$

가 일반적으로 성립한다.

예 2.19

예 2.11에서 $g(X, Y)=XY$를 고려하여 XY의 확률분포를 구하면

XY	0	1	2	3	4	6
확률	$\frac{51}{84}$	$\frac{24}{84}$	$\frac{9}{84}$	$\frac{0}{84}$	$\frac{0}{84}$	$\frac{0}{84}$

와 같다. 따라서,

$$\begin{aligned}&E(XY)\\&=0\times\left(\frac{51}{84}\right)+1\times\left(\frac{24}{84}\right)+2\times\left(\frac{9}{84}\right)+3\times\left(\frac{0}{84}\right)+4\times\left(\frac{0}{84}\right)+6\times\left(\frac{0}{84}\right)\\&=\frac{42}{84}\\&=\frac{1}{2}\end{aligned}$$

이 된다.

또한 연속형 결합 확률밀도함수가

$$f_{X,Y}(x, y) = e^{-x-y} \quad x > 0, \quad y > 0$$

로 주어졌을 때, $g(X, Y) = X + Y$의 기댓값은

$$\begin{aligned} E[g(X, Y)] &= \int_0^\infty \int_0^\infty (x+y)e^{-x-y}\,dxdy \\ &= \int_0^\infty e^{-y}\left(\int_0^\infty xe^{-x}\,dx\right)dy + \int_0^\infty e^{-x}\left(\int_0^\infty ye^{-y}\,dy\right)dx \\ &= 1+1 \\ &= 2 \end{aligned}$$

로 계산된다. 이는 물론 $E[g(X, Y)] = E(X) + E(Y)$ 이므로 X와 Y에 대한 주변 확률분포의 기댓값을 따로 구해 더한 것과 같은 결과를 얻게 된다.

한편 두 확률변수의 곱에 대한 기댓값에 대해서 두 확률변수가 서로 독립인 경우 다음과 같은 정리가 성립된다.

정리 2.7

두 확률변수 X와 Y가 서로 독립이면

$$E(XY) = E(X) \cdot E(Y)$$

가 성립한다. 또한, X와 Y의 함수인 $g(X)$와 $h(Y)$도 독립이며

$$E[g(X)h(Y)] = E[g(X)] \cdot E[h(Y)]$$

이다.

증명 편의상 첫 번째 증명은 두 확률변수가 모두 이산형인 경우만, 두 번째 증명은 모두 연속형인 경우만 고려한다.

$$\begin{aligned} E(XY) &= \sum_{\text{모든 } x,y} \sum xy\, f_{X,Y}(x, y) \\ &= \sum_{\text{모든 } x,y} \sum xy f_X(x) \cdot f_Y(y) \\ &= \sum_{\text{모든 } x} x f_X(x) \cdot \sum_{\text{모든 } y} y f_Y(y) \end{aligned}$$

$$= E(X) \cdot E(Y)$$

(단, 위 정리의 역은 성립하지 않는다. 참조: 연습문제 2.35) 또,

$$\begin{aligned} E[g(X)h(Y)] &= \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} g(x)h(y)f_{X,Y}(x,y)\,dxdy \\ &= \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} g(x)h(y)f_X(x)\cdot f_Y(y)\,dxdy \\ &= \int_{-\infty}^{\infty} g(x)f_X(x)dx \cdot \int_{-\infty}^{\infty} h(y)f_Y(y)\,dy \\ &= E[g(X)] \cdot E[h(Y)] \end{aligned} \tag{2.12}$$

가 성립한다. 이와 같은 결과 식 (2.12)는 마찬가지 논리에 의하여 이산형 확률변수에 대해서도 물론 성립한다. ■

2.4.2 분산과 공분산

이제, 확률변수 X의 변동을 나타내는 측도로서 X가 평균 $E(X)$로부터 흩어져 있는(또는 밀집된) 정도를 다음과 같이 $g(X) = [X - E(X)]^2$에 대한 기댓값으로 측정하고 분산(variance)이라고 정의한다. 이때 X가 그의 평균 $E(X)$로부터 멀리 떨어져 있는 경향이 많을수록 $[X - E(X)]^2$의 값도 커지는 경향이 있는데, 그런 경우 자연히 분산도 커지게 된다. 편의상 확률변수 X의 분산을 $Var(X)$ 또는 σ_X^2으로, 그리고 분산의 제곱근을 표준편차(standard deviation)라고 하고 $\sigma_X = \sqrt{Var(X)}$ 또는 $SD(X)$로 표기한다.

정의 2.8

확률변수 X의 흩어짐을 재는 데 사용되는 **분산**과 **표준편차**는

$$Var(X) = E[X - E(X)]^2$$

$$\sigma_X = \sqrt{Var(X)}$$

로 각각 정의한다.

그런데 위에 정의된 분산은 그 단위가 확률변수 X의 단위의 제곱이 된다. 가령, 변

수 X의 단위가 cm 이면 $Var(X)$의 단위는 cm^2이 된다. 이러한 점은 실제 문제에 있어서 변수 X의 흩어짐을 재는 데 비합리적이며, 따라서 분산의 제곱근으로 단위가 통일된 표준편차를 사용하여 변수의 흩어짐을 측정한다. 나아가, 확률변수 X를 그의 기댓값과 표준편차를 사용하여

$$Z=\frac{X-E(X)}{\sigma_X}$$

로 변환을 하면, Z는 평균이 0이고 분산이 1이 된다. 이러한 변환을 변수의 **표준화** (standardization)라고 한다.

한편, 확률변수 X의 분산은 $E(X)$와 $E(X^2)$을 사용하여 다음과 같이 나타낼 수도 있다.

$$\begin{aligned} Var(X) &= E[(X-E(X))^2] \\ &= E[X^2-2E(X)X+(E(X))^2] \\ &= E(X^2)-2E(X)^2+[E(X)]^2 \\ &= E(X^2)-[E(X)]^2 \end{aligned} \tag{2.13}$$

예 2.20

확률변수 X의 확률밀도함수가 $f(x)=\frac{4(1-x^3)}{3}$ $(0<x<1)$로 주어졌다. 이때

$$\begin{aligned} E(X) &= \int_0^1 \frac{4x(1-x^3)}{3}\,dx \\ &= \frac{4}{3}\left[\frac{x^2}{2}-\frac{x^5}{5}\right]_0^1 \\ &= \frac{2}{5} \end{aligned}$$

$$\begin{aligned} E(X^2) &= \int_0^1 \frac{4x^2(1-x^3)}{3}\,dx \\ &= \frac{4}{3}\left[\frac{x^3}{3}-\frac{x^6}{6}\right]_0^1 \\ &= \frac{2}{9} \end{aligned}$$

이므로, X의 분산은 식 (2.13)에 의하여

$$\begin{aligned} Var(X) &= E(X^2) - [E(X)]^2 \\ &= \frac{2}{9} - \frac{4}{25} = \frac{14}{225} \end{aligned}$$

가 된다.

이제 분산의 몇 가지 중요한 성질들을 살펴보면 다음과 같다.

정리 2.8

(1) 확률변수 X, Y에 대하여, $Y = aX + b$이면

$$Var(Y) = a^2 Var(X)$$

가 성립한다.

(2) 확률변수 $X_1, X_2, \cdots, X_n$이 서로 독립이면

$$Var\left(\sum_{i=1}^{n} X_i\right) = \sum_{i=1}^{n} Var(X_i)$$

가 성립한다.

증명 (1) $Var(Y) = E[(aX+b) - E(aX+b)]^2$

$= E[aX - E(aX)]^2$

$= a^2 Var(X)$.

(2) 편의상 $n = 2$인 경우만 고려하기로 한다. 그 이후는 수학적 귀납법을 사용하여 증명할 수 있다.

$$\begin{aligned} Var(X_1 + X_2) &= E(X_1 + X_2)^2 - [E(X_1) + E(X_2)]^2 \\ &= E(X_1^2 + 2X_1X_2 + X_2^2) \\ &\quad - [E(X_1)^2 + 2E(X_1)E(X_2) + E(X_2)^2] \\ &= E(X_1^2) - E(X_1)^2 + E(X_2^2) - E(X_2)^2 \\ &= Var(X_1) + Var(X_2) \end{aligned}$$

■

예 2.21

확률변수 X의 확률밀도함수가

$$f_X(x) = 2x, \quad 0 < x < 1$$

일 때 변수 $Y = 6X + 3$의 분산을 구해 보자.

$$E(X) = \int_0^1 x \cdot 2x dx = \frac{2}{3},$$
$$E(X^2) = \int_0^1 x^2 \cdot 2x dx = \frac{1}{2}$$

이므로,

$$Var(X) = E(X^2) - [E(X)]^2 = \frac{1}{2} - \left(\frac{2}{3}\right)^2 = \frac{1}{18}$$

이다. 따라서

$$Var(Y) = 6^2 Var(X) = 36 \cdot \frac{1}{18} = 2$$

로 주어진다.

예 2.22

두 확률변수 X와 Y의 결합 확률밀도함수가

$$f_{X,Y}(x, y) = 3e^{-3x}e^{-y}, \quad 0 < x, y < \infty$$

로 주어졌다고 하자. 이때 두 확률변수의 함수 $g(X, Y) = 3X + Y$의 분산을 구해 보자. 그런데 정리 2.4를 이용하여 구한 X와 Y의 주변 확률밀도함수는 각각 $f_X(x) = 3e^{-3x}$, $f_Y(y) = e^{-y}$이며, $f_{X,Y}(x, y) = f_X(x) \cdot f_Y(y)$이므로 X와 Y는 서로 독립이다. 따라서

$$\begin{aligned} Var(3X + Y) &= 9\,Var(X) + Var(Y) \\ &= 9 \times \left(\frac{1}{9}\right) + 1 \\ &= 2 \end{aligned}$$

가 된다.

하나의 확률변수가 흩어진 정도를 측정하는 측도로서 분산을 생각했다면, 두 확률변수 X와 Y 사이의 흩어진 관계를 측정하는 측도로서 다음과 같이 정의되는 공분산(covariance)을 생각할 수 있다. 공분산은 X와 Y가 선형적으로 함께 움직이는 정도를 표현해 주는 측도라고 생각할 수 있다.

정의 2.9

두 확률변수 X, Y의 **공분산**은

$$\begin{aligned} Cov(X, Y) &= E[(X-EX)(Y-EY)] \\ &= E(XY)-E(X)E(Y) \end{aligned}$$

로 정의된다.

위의 정의 2.9로부터,

(1) $Cov(X, X) = Var(X)$이며 (2.14)

(2) 두 확률변수 X와 Y가 서로 독립이면 $Cov(X, Y)=0$인 것도 쉽게 알 수 있다.

이제 다음의 정리들을 통하여 공분산에 대한 성질을 살펴보자.

정리 2.9

두 확률변수 X, Y의 공분산은 상수 a, b, c, d에 대하여

$$Cov(aX+b, cY+d) = ac\,Cov(X, Y)$$

과 같은 성질을 만족한다.

증명 $$\begin{aligned} Cov(aX+b, cY+d) &= E[(aX+b)(cY+d)] - E(aX+b)E(cY+d) \\ &= acE(XY) + E(adX) + E(bcY) + bd \\ &\quad - acE(X)E(Y) - E(adX) - E(bcY) - bd \\ &= ac[E(XY) - E(X)E(Y)] \\ &= ac\,Cov(X, Y) \end{aligned}$$ ■

한편, 확률변수 $X_1, X_2, \cdots, X_n$이 서로 독립인 경우 이들의 합의 분산은 각 확률변수의 분산의 합이나(참조: 정리 2.8), 일반적인 경우는 다음의 정리 2.10과 같다.

정리 2.10

확률변수 $X_1, X_2, \cdots, X_n$이 있을 때,

$$Var\left(\sum_{i=1}^{n} X_i\right) = \sum_{i=1}^{n} Var(X_i) + 2\sum\sum_{j<k} Cov(X_j, X_k)$$

가 성립한다.

증명

$$\begin{aligned} Var\left(\sum_{i=1}^{n} X_i\right) &= E\left[\left(\sum_{i=1}^{n} X_i\right)^2\right] - \left[E\left(\sum_{i=1}^{n} X_i\right)\right]^2 \\ &= E\left(\sum_{i=1}^{n} X_i^2 + 2\sum\sum_{j<k} X_j X_k\right) \\ &\quad - \left[\sum_{i=1}^{n} (E(X_i))^2 + 2\sum\sum_{j<k} E(X_i)E(X_k)\right] E(X_i)E(X_k)\Big] \\ &= \sum_{i=1}^{n} [E(X_i^2) - (E(X_i))^2] + 2\sum\sum_{j<k} [E(X_j X_k) - E(X_j)\,E(X_k)] \\ &= \sum_{i=1}^{n} Var(X_i) + 2\sum\sum_{j<k} Cov(X_j, X_k) \end{aligned}$$

■

주 공분산은 X와 Y의 선형관계에 대한 측도로서, X가 증가할 때 Y가 증가하는 경향이 있으면 양의 값을, X가 증가할 때 Y가 감소하는 경향이 있으면 음의 값을 가진다. 측정단위의 영향을 받는 공분산의 단점을 보완하기 위해 제안된 상관계수에 대한 설명은 7장에서 자세히 다루기로 한다.

2.4.3 조건부 기댓값

정의 2.5에서 확률변수 X의 값이 x로 주어졌을 때, Y의 조건부 확률밀도함수는 $f_{Y|X}(y|x) = f(x, y)/f(x)$, $f(x) > 0$으로 정의되었다. 이제 조건부 기댓값(conditional expectation)을 생각해 보자. 조건부 확률변수 $Y|X = x$의 기댓값은 $E(Y|X = x)$로 표기하고, 다음과 같이 정의한다.

정의 2.10

조건부 확률변수 $Y|X = x$의 조건부 기댓값은

$$E(Y|X=x)=\begin{cases}\sum_{\text{모든 } y_i} y_i f_{Y|x}(y_i|x) & X,\ Y\text{가 이산형인 경우}\\ \int_{-\infty}^{\infty} y f_{Y|x}(y|x)dy & X,\ Y\text{가 연속형인 경우}\end{cases}$$

로 정의된다.

예 2.23

예 2.12에서 $f_{X,Y}(x,y)=x^2e^{-x(y+1)}$ $0<x,\ y<\infty$일 때 $Y|x$의 조건부 확률밀도함수는

$$f_{Y|x}(y|x)=xe^{-xy},\quad y>0$$

으로 주어졌으며, 따라서

$$\begin{aligned}E(Y|X=x)&=\int_{-\infty}^{\infty} y f_{Y|x}(y|x)\,dy\\&=\int_0^{\infty} xye^{-xy}dy\\&=-ye^{-xy}\Big|_0^{\infty}+\int_0^{\infty} e^{-xy}dy\\&=\frac{1}{x}\end{aligned}$$

로 계산된다.

조건부 기댓값 $E(Y|X=x)$는 x에 대한 함수이므로, 이를 $g(x)=E(Y|X=x)$라고 표현할 수 있다. 이때 함수 $g(x)$의 x 대신에 확률변수 X를 사용한 $g(X)=E(Y|X)$는 역시 확률변수이다. 다음의 정리 2.11은 **이중 기댓값**(double expectation) **정리**라고 부르며, 기댓값을 계산할 때 유용하다.

정리 2.11

(이중 기댓값 정리) 두 확률변수 X, Y에 대하여

$$E[E(Y|X)]=E(Y)$$

가 성립한다.

증명 (이 성질은 $E|Y|<\infty$일 때 의미가 있음) 편의상 연속인 경우만 고려하면

$$\begin{aligned} E[E(Y|X)] &= \int_{-\infty}^{\infty} E(Y|x) f_X(x)\,dx \\ &= \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} y f_{Y|x}(y|x) f_X(x)\,dydx \\ &= \int_{-\infty}^{\infty} y \int_{-\infty}^{\infty} f(x, y)\,dxdy \\ &= \int_{-\infty}^{\infty} y f_Y(y)\,dy \\ &= E(Y) \end{aligned}$$

가 성립한다(세 번째 등식을 얻기 위해 두 적분의 순서를 바꾸게 되는데, Y의 기댓값이 존재하는 경우 적분의 순서를 바꿀 수 있다). ■

정리 2.11을 좀 더 일반화하면, 두 확률변수 X, Y와 함수 $g(x, y)$가 있을 때,

$$E[g(X, Y)] = E_X\{E[g(X, Y)|X]\}$$

가 성립한다. 단, 우변의 E_X의 아래첨자 X는 이 기댓값이 X의 확률분포를 이용하여 계산됨을 강조하기 위해 추가되었다.

예 2.24

두 변수 X, Y의 결합 확률밀도함수가

$$f_{X,Y}(x,y) = \begin{cases} \frac{1}{2}, & 0 \le x \le y \le 2, \\ 0, & \text{다른 경우} \end{cases}$$

로 주어졌다고 하자. 예 2.13에서, X와 Y의 주변 확률밀도함수가

$$f_X(x) = \int_x^2 \frac{1}{2} dy = \frac{1}{2}(2-x), \qquad 0 \le x \le 2,$$

$$f_Y(y) = \int_0^y \frac{1}{2} dx = \frac{1}{2}y, \qquad 0 \le y \le 2$$

와 같음을 보았다. $Y|X$의 조건부 확률밀도함수는 정의에 의해, $f_{Y|X}(y|x) =$

$\frac{1/2}{(2-x)/2}$, $x \le y \le 2$가 되고, 이를 이용하여 $0 \le x \le 2$일 때 $E(Y|X=x) = (2+x)/2$임을 알 수 있다. 그리고 $E(E(Y|X)) = \int_0^2 \frac{1}{2}(2+x) \times \frac{1}{2}(2-x)dx = \frac{4}{3}$이 되며, 위에서 구한 Y의 주변 확률밀도함수를 이용하면 이 값은 $E(Y)$와 같음을 쉽게 확인할 수 있다.

예 2.25

$x > 0$에서 X의 확률밀도함수가 $f_X(x) = \frac{1}{2}e^{-x/2}$와 같고, $Y|X=x$의 조건부 확률밀도함수가

$$f_{Y|X}(y|x) = \begin{cases} \frac{1}{x}, & 0 \le y \le x, \\ 0, & \text{다른 경우} \end{cases}$$

라고 할 때, $E(Y)$를 구해 보자. 주어진 조건부 확률밀도함수를 이용하면,

$E(Y|X=x) = \int_0^x y\frac{1}{x}dy = \frac{1}{2}x, x > 0$이 되고,

$$E(Y) = E(E(Y|X)) = \int_0^\infty \frac{1}{2}x \times \frac{1}{2}e^{-x/2}dx = \int_0^\infty ze^{-z}dz = 1$$

임을 알 수 있다. 여기에서 $z = \frac{x}{2}$로 치환하였고, 부분적분을 사용하였다.

다음의 정리 2.12는 두 확률변수가 독립인 경우 어느 한 변수의 기댓값이 다른 변수의 값에 관계없다는 직관적인 사실을 보여 준다.

정리 2.12

확률변수 X와 Y가 독립이면

$$E(Y|x) = E(Y), \quad E(X|y) = E(X)$$

가 성립한다.

증명 $E(Y|x) = E(Y)$와 $E(X|y) = E(X)$는 서로 대칭이므로, 첫 번째 등식만 증명하기로 한다.

$$
\begin{aligned}
E(Y|x) &= \int_{-\infty}^{\infty} y f_{Y|x}(y|x)\,dy \\
&= \int_{-\infty}^{\infty} y \frac{f_X(x) f_Y(y)}{f_X(x)}\,dy \\
&= \int_{-\infty}^{\infty} y f_Y(y)\,dy \\
&= E(Y)
\end{aligned}
$$

■

다음은 조건부 확률변수 $Y|x$의 분산에 대해 알아보기로 한다. 먼저, 그에 대한 정의는 다음과 같다.

정의 2.11

$X = x$가 주어졌을 때, 확률변수 Y의 조건부 분산(conditional variance)은

$$Var(Y|x) = E[\{Y - E(Y|x)\}^2|x]$$

로 정의된다.

주 위 정의에서

$$
\begin{aligned}
Var(Y|x) &= E[\{Y - E(Y|x)\}^2 | x] \\
&= E(Y^2|x) - [E(Y|x)]^2
\end{aligned} \tag{2.15}
$$

꼴로 표현할 수도 있다(참조: 식 (2.13)).

예 2.26

예 2.23에서 $x > 0$인 x에 대해 $Y|x$의 조건부 확률밀도함수는 $y > 0$일 때 $f_{Y|x}(y|x) = xe^{-xy}$으로, $E(Y|x) = 1/x$로 주어졌다. 그런데

$$
\begin{aligned}
E(Y^2|x) &= \int_{-\infty}^{\infty} y^2 f_{Y|x}(y|x)\,dy \\
&= \int_0^{\infty} xy^2 e^{-xy}\,dy \\
&= -y^2 e^{-xy}\Big|_0^{\infty} + \int_0^{\infty} 2ye^{-xy}\,dy \\
&= \frac{2}{x^2}
\end{aligned}
$$

이므로

$$\begin{aligned} Var(Y|x) &= E(Y^2|x) - [E(Y|x)]^2 \\ &= \frac{2}{x^2} - \left(\frac{1}{x}\right)^2 \\ &= \frac{1}{x^2} \end{aligned}$$

이 된다.

다음의 정리는 정리 2.11의 이중 기댓값 정리와 더불어 유용하게 사용되는 정리로서 조건부 기댓값을 통해 분산을 분해하는 방법을 보여 준다.

정리 2.13

두 확률변수 X, Y에 대하여

$$Var(Y) = E[Var(Y|X)] + Var[E(Y|X)]$$

가 성립한다.

증명 $$\begin{aligned} E[Var(Y|X)] &= E\{E(Y^2|X) - [E(Y|X)]^2\} \\ &= E(Y^2) - E[E(Y|X)]^2 \\ &= E(Y^2) - [E(Y)]^2 - \{E[E(Y|X)]^2 - [E(E(Y|X))]^2\} \\ &= Var(Y) - Var[E(Y|X)] \end{aligned}$$ ■

위 정리 2.13으로부터 조건부 분산과 무조건부(unconditional) 분산의 관계를 볼 수 있는데, 조건부 분산이 무조건부 분산보다 평균적으로 더 작다는 것($E(Var(Y|X) \leq Var(Y)$)을 알 수 있다. 물론 X와 Y가 서로 독립이면, $E(Y|X)$는 X에 의존하지 않으며, 따라서 $Var[E(Y|X)] = 0$이므로 두 종류의 분산은 동일하다. 또한, 조건부 기댓값, $E(Y|X)$의 분산은 확률변수, Y 자체의 분산보다 작음도 알 수 있는데 ($Var(E(Y|X)) \leq Var(Y)$), 이는 개별 개체의 산포보다 그룹별 평균의 산포가 작다는 것을 생각할 때 자명하다.

2.4.4 확률부등식

이제 확률변수의 기댓값에 근거한 몇 개의 유용한 확률부등식(probability inequality)에 대해 살펴보기로 하자.

정리 2.14

(마코프 확률부등식) 실함수 $u(x) \geq 0$라고 할 때, 확률변수 X는 임의의 상수 $c > 0$에 대하여,

$$P[u(X) \geq c] \leq \frac{E[u(X)]}{c}$$

를 만족한다.

증명 $A = \{x : u(x) \geq c\}$인 A에 대해,

$$\begin{aligned} E[u(X)] &= \int_{-\infty}^{\infty} u(x) f(x)\, dx \\ &= \int_{A} u(x) f(x)\, dx + \int_{A^c} u(x) f(x)\, dx \\ &\geq \int_{A} u(x) f(x)\, dx \\ &\geq \int_{A} c f(x)\, dx \\ &= c\, P[X \in A] \\ &= c\, P[u(X) \geq c] \end{aligned}$$

이므로 정리 2.14를 얻는다. ■

그런데 $u(x) = |x|^r$ $(r > 0)$을 택하면, 위 정리 2.14로부터 아래 (2.16)의 관계가 성립한다.

$$P[|X| \geq c] \leq \frac{E[|X|^r]}{c^r} \tag{2.16}$$

마코프(Markov) 확률부등식으로부터 유도가 가능하며 실제로 자주 활용되는 **체비셰프**(Chebyshev) **확률부등식**의 내용은 다음과 같다.

정리 2.15

(체비셰프 부등식) 확률변수 X의 평균이 μ이고 분산이 $\sigma^2 < \infty$이면, 임의의 $k > 0$에 대하여

$$P[|X-\mu| \geq k\sigma] \leq \frac{1}{k^2}$$

이 성립한다.

증명 앞의 정리 2.14에서 $u(X) = (X-\mu)^2$, $c = k^2\sigma^2$을 사용하면

$$P[(X-\mu)^2 \geq k^2\sigma^2] \leq \frac{E(X-\mu)^2}{k^2\sigma^2} = \frac{1}{k^2}$$

이 구해진다. ■

체비셰프 부등식은

$$P(|X-\mu| < k\sigma) \geq 1 - \frac{1}{k^2} \tag{2.17}$$

의 꼴로도 표현될 수 있으며, 따라서 표준편차 σ가 존재하는 경우 변수 X와 평균 μ와의 차이에 대한 확률의 한계를 제공한다. 물론, 확률분포의 형태를 아는 경우 $P(|X-\mu| < k\sigma)$의 한계를 $1-1/k^2$보다 더 정확히 구할 수도 있다. 그러나 위 부등식은 $\sigma^2 < \infty$인 모든 확률변수에 대하여 성립한다는 장점을 가짐을 유의할 필요가 있다.

예 2.27

확률변수 X의 평균이 $\mu = 25$이고 분산이 $\sigma^2 = 16$이라 하자. 이 경우 X가 17과 33 사이의 값을 가질 확률의 하한은 체비셰프 부등식에 의하여

$$\begin{aligned} P(17 \leq X \leq 33) &= P(|X-25| \leq 8) \\ &= P(|X-\mu| \leq 2\sigma) \\ &\geq 0.75 \end{aligned}$$

로 구할 수 있다.

다음의 코시－쉬바르쯔(Cauchy－Schwarz) 부등식은 뒤에 확률변수의 성질들을 증명하는 데 유용하게 활용되는데, 여기에서 일단 소개하기로 한다.

정리 2.16

(코시－쉬바르쯔 부등식) 두 확률변수 X, Y에 대해서 $E(X^2)<\infty$, $E(Y^2)<\infty$가 만족된다면,

$$[E(XY)]^2 \le E(X^2)\cdot E(Y^2)$$

이 성립한다(단, 등식은 어떤 상수 c에 대하여 $P(Y=cX)=1$인 경우에 성립함).

증명 $h(t)=E[(tX-Y)^2]=E(X^2)t^2-2E(XY)t+E(Y^2)$는 음이 아닌 이차함수이다. 이제 $h(t)>0$이면, $h(t)=0$의 해가 없어 이 이차함수의 판별식이 음이므로, $4[E(XY)]^2-4E(X^2)E(Y^2)<0$이 된다. 또 $h(t)=E[(tX-Y)^2]=0$이 $t=t_0$에서 성립하면 $E((t_0X-Y)^2)=0$이 되어야 하고, $(t_0X-Y)^2$이 항상 0 이상이므로 $P(t_0X=Y)=1$이 된다. 즉, 이 경우 좌변은 $[E(t_0X^2)]^2=t_0^2[E(X^2)]^2$이 되고 우변은 $t_0^2[E(X^2)]^2$으로 등호가 성립한다. ■

2.5 이산형 확률분포

이제 수리통계학에서 자주 사용되는 몇 가지 특정한 분포들에 대해 알아보자. 이 절에서는 일변량 변수로서 모수(parameter)들에 의해 그 성질이 결정되는 몇 가지 중요한 **이산형 확률변수**(discrete random variable)에 대해서 확률밀도함수 및 분포함수를 알아보고, 나아가 평균, 분산 등을 구해봄으로써 이 변수의 성격들을 살펴보고자 한다.

2.5.1 베르누이 분포

두 가지의 가능한 결과만을 갖는 시행(trial) 또는 실험(experiment)을 생각해 보자. 둘 중 하나를 '성공', 다른 하나를 '실패'라고 한다면 이 실험의 결과는 '성공' 또는

'실패' 중 하나로 나타난다. 이때 그 결과가 성공이면 1의 값을 가지고, 실패이면 0의 값을 가지는 확률변수 X를 베르누이(Bernoulli) 확률변수라고 하고 그 분포를 베르누이 분포라고 한다. '성공'일 확률이 p인 베르누이 확률변수 X의 확률밀도함수는

$$\begin{aligned} f(1) &= p \\ f(0) &= 1-p=q \end{aligned} \tag{2.18}$$

로 주어지고, 기댓값과 분산은 각각

$$\begin{aligned} E(X) &= 1\times p+0\times(1-p)=p \\ Var(X) &= E(X-p)^2 \\ &= (0-p)^2\times(1-p)+(1-p)^2\times p \\ &= p(1-p) \end{aligned} \tag{2.19}$$

로 구해진다.

예 2.28

표본공간 S의 부분집합인 어떤 사건 A가 있다고 하자. 이때 확률변수 X를 A에 대한 지시함수(indicator function), 즉 $s\in S$에 대하여 $X(s)=I_A(s)$라고 하면 확률변수 X는 $p=P(A)=P(X=1)$인 베르누이 분포를 따른다. 지시함수 $I_A(\cdot)$는

$$I_A(s)=\begin{cases}1, & s\in A\\ 0, & s\in A^c\end{cases}$$

와 같이 정의되는데 이를 $I(s\in A)$로 표기하기도 한다.

2.5.2 이항분포

확률변수 $X_1,\cdots,X_n$이 성공 확률이 p이며 서로 독립인 베르누이 시행(즉 $P(X_i=1)=p$, $P(X_i=0)=1-p$)으로부터 얻은 것일 때, 그들의 합으로 나타내어지는 $X=\sum_{i=1}^{n}X_i$를 이항(binomial)확률변수라 한다. 여기에서 $X=\sum_{i=1}^{n}X_i$는 n회의 독립인 베르누이 시행에서 구한 '성공'의 횟수를 나타내게 되므로 $\{0, 1, 2, \cdots, n\}$ 중 하나의 값을 갖는다. 이와 같은 변수 X의 확률밀도함수는, $q=1-p$일 때,

$$f(x)=\binom{n}{x}p^x q^{n-x} \quad (\text{단, } x=0,\ 1,\ 2,\ \cdots,\ n) \tag{2.20}$$

이며 $X\sim B(n,\ p)$로 표기한다. 만약 $0,1,\cdots,n$ 중 하나의 x에 대해 $X=x$라면, n번의 시행 중 x번의 성공과 $n-x$번의 실패가 있다는 뜻이고, 이에 상응하는 경우의 수는 n번의 시행 중 성공일 시행 x개를 정하는 것과 같으므로 $\binom{n}{x}$이다. 그중 특정한 하나의 시행결과의 열[예를 들어 $n=4, x=3$인 경우 (성공, 성공, 실패, 성공)과 같이 특정한 열]을 관찰할 확률은 $p^x q^{n-x}$이므로, $P(X=x)$는 $\binom{n}{x}p^x q^{n-x}$가 된다.

이러한 이항확률변수 $X\sim B(n,\ p)$의 기댓값과 분산은 각각

$$E(X)=E\left(\sum_{i=1}^{n}X_i\right)=\sum_{i=1}^{n}E(X_i)=np \tag{2.21}$$

$$Var(X)=Var\left(\sum_{i=1}^{n}X_i\right)=\sum_{i=1}^{n}Var(X_i)=npq \tag{2.22}$$

로 구할 수 있다.

예 2.29

어떤 주머니에 r개의 빨간 공과 w개의 하얀 공(단, $r+w=N$)이 들어 있다. 이제, n개의 공을 무작위 복원추출(sampling with replacement)하였을 때, 각 시행에서 빨간 공을 추출할 확률은 $p=r/N$로 동일하며, X를 추출된 n개의 공 가운데 빨간 공의 개수라고 하면 이의 확률밀도함수는

$$f(x)=\binom{n}{x}\left(\frac{r}{N}\right)^x\left(1-\frac{r}{N}\right)^{n-x} \quad (\text{단, } x=0,\ 1,\ 2,\ \cdots,\ n)$$

으로 주어진다.

앞의 이항확률변수는 다음과 같은 확장이 가능하다. 한 번의 실험(또는 관찰)에 있어서, $k(>2)$개의 상호배반인 사건 A_i가 관찰될 수 있는데 $\bigcup_{i=1}^{k}A_i=S$이며 $P(A_i)=p_i(i=1,\cdots,\ k)$라고 가정하자(단, S는 전체표본공간임). 이런 실험을 n회 독립 반복시행했을 때 사건 A_i가 일어날 횟수를 X_i라고 하면, $X_1,\ X_2,\ \cdots,\ X_k$의 결합 확률밀도함수는

$$f(x_1, x_2, \cdots, x_k) = \frac{n!}{x_1!\, x_2! \cdots x_k!}\, p_1^{x_1} p_2^{x_2} \cdots p_k^{x_k} \tag{2.23}$$

$$(\sum_{i=1}^{k} p_i = 1\text{이며, } x_i\text{는 } 0 \le x_i \le n,\ \sum_{i=1}^{k} x_i = n\text{을 만족하는 정수임})$$

이 된다. 만약 $\boldsymbol{X}=(X_1, X_2, \cdots, X_k)$의 관찰값이 $(x_1, x_2, \cdots, x_k)$ 라면, n번의 시행 중 x_1번의 A_1, x_2번의 A_2, $\cdots$, x_k번의 A_k가 관측된다는 뜻이고, 이에 상응하는 경우의 수는 n번의 시행을 크기가 각각 $x_1, \cdots, x_k$인 k개의 그룹으로 나누는 것과 같으므로 $\binom{n}{x_1 x_2 \cdots x_k} = \frac{n!}{x_1! x_2! \cdots x_k!}$이다. 그중 특정한 하나의 시행결과의 열을 관찰할 확률은 $p_1^{x_1} p_2^{x_2} \cdots p_k^{x_k}$이므로,

$$P((X_1, \cdots, X_k) = (x_1, \cdots, x_k)) = \frac{n!}{x_1! \cdots x_k!}\, p_1^{x_1} \cdots p_k^{x_k}$$

가 된다. 이때 확률벡터 $\boldsymbol{X}=(X_1, X_2, \cdots, X_k)$는 **다항분포**(multinomial distribution)를 따른다고 하며, $\boldsymbol{X} \sim \mathrm{MULT}(n, p_1, p_2, \cdots, p_k)$로 표기한다. 다항분포의 응용은 5장의 적합도 검정에서 자세히 다루어진다.

예 2.30

5번의 동일한 게임으로 구성된 어떤 시합(예를 들면 5세트로 구성된 테니스 경기나 야구의 한국시리즈)이 있어서, 두 선수 A, B 중 누구든지 먼저 3게임을 이기면 시합이 끝난다고 하자. 또, 선수 A가 n번의 게임을 할 경우 이기는 횟수는 $B(n, \frac{1}{2})$를 따른다고 하자. 즉, 매 게임에서 선수 A가 이길 확률은 1/2이고 게임 결과는 서로 독립이다. 편의상 무승부는 고려하지 않도록 하고, 이 시합에서 선수 A가 이기는 횟수 X에 대한 기댓값을 구해 보기로 한다. 먼저, 이 시합이 끝나기 위해 필요한 게임의 수 N은 확률변수로서 3, 4, 또는 5의 값을 가지며 그 확률밀도함수는

$$f_N(n) = \binom{n-1}{2}\left(\frac{1}{2}\right)^{n-1} \qquad (n = 3, 4, 5)$$

가 된다. 이제 정리 2.11을 이용하면

$$\begin{aligned} E(X) &= E_N[E(X|N)] = E_N[(N-3)\times\frac{1}{2} + 3\times\frac{1}{2}] \\ &= E_N\left(\frac{N}{2}\right) = \sum_{n=3}^{5} \frac{n}{2} f_N(n) \\ &= 2.0625 \end{aligned}$$

가 된다.

예 2.31

$(X_1, X_2, X_3) \sim \mathrm{MULT}(n, p_1, p_2, p_3)$라고 하자. 이때 $X_1 \sim B(n, p_1)$, $X_2 \sim B(n, p_2)$ 그리고 $X_2 | X_1 = x_1 \sim B(n-x_1, p)$, $p = p_2/(1-p_1)$이다. 이제 정리 2.11을 이용하면

$$\begin{aligned} E(X_1 X_2) &= E[E(X_1 X_2 | X_1)] \\ &= E[X_1 E(X_2 | X_1)] \\ &= E\left[\frac{X_1(n-X_1)p_2}{1-p_1}\right] \\ &= \left[\frac{p_2}{1-p_1}\right][nE(X_1) - E(X_1^2)] \\ &= n(n-1)p_1 p_2. \end{aligned}$$

따라서

$$\begin{aligned} Cov(X_1, X_2) &= E(X_1 X_2) - (EX_1)(EX_2) \\ &= n(n-1)p_1 p_2 - (np_1)(np_2) \\ &= -np_1 p_2 \end{aligned}$$

로 구해진다.

2.5.3 포아송 분포

시간이 지남에 따라 일어나는 어떤 특정한 사건 A(예를 들면, 어떤 고속도로 구간에서 일어나는 '대형사고', 어떤 전화교환대에 걸려오는 전화, 어떤 주유소에 주유를 위한 차량의 도착 등)의 발생횟수의 분포를 고려해 보자. 여기에서 사건 A의 발생횟수에 대해 다음과 같은 세 가지 성질이 성립한다고 가정한다.

(1) $\lim_{h \to 0} P(\text{길이가 } h\text{인 구간 내에서 사건 } A\text{가 1회 일어남})/h = \lambda$,

(2) $\lim_{h \to 0} P(\text{길이가 } h\text{인 구간 내에서 사건 } A\text{가 2회 이상 일어남})/h = 0$,

(3) 서로 겹치지 않는 두 구간 내에서 사건 A의 발생횟수는 서로 독립이다.

이제 주어진 시간 $t > 0$에 대하여 확률변수 $X(t)$를 구간 $[0, t]$ 내에서 사건 A가

발생하는 횟수라고 하면 $X(t)$의 확률밀도함수는 아래와 같이 유도된다. 우선, 논리의 전개를 위하여 구간 $[0, t]$를 n개의 길이가 같은 구간으로 아래와 같이 나눈다.



$P(X(t)=x)=P(X(t)=x$이고 각 부분구간에서 1회 이하의 사건 A가 발생)
$+P(X(t)=x$이고 최소한 1개의 부분구간에서 2회 이상의 사건 A가 발생)

이 될 수 있으므로

$$P(X(t)=x)=P(x\text{ 개의 부분구간에서 꼭 1회씩 사건 }A\text{가 발생하고 나머지 }(n-x)\text{개 부분구간에서는 발생하지 않음})$$
$$+P(X(t)=x\text{이고 최소한 1개 구간에서 사건 }A\text{가 2회 이상 발생함})$$

이다. $n\to\infty$에 따라 $\frac{t}{n}$보다 0으로 더 빨리 수렴하는 것을 $o\left(\frac{t}{n}\right)$로 표기하면, 하나의 부분구간에서 꼭 1회의 사건 A가 발생하는 확률은 가정에 의해 $\frac{\lambda t}{n}+o\left(\frac{t}{n}\right)$이 되므로 $P(x$개의 부분구간에서 꼭 1회씩 사건 A가 발생하고 나머지 $(n-x)$개 부분구간에서는 발생하지 않음)은

$$\binom{n}{x}\left[\frac{\lambda t}{n}+o\left(\frac{t}{n}\right)\right]^x\left[1-\frac{\lambda t}{n}-o\left(\frac{t}{n}\right)\right]^{n-x}$$

이 된다. 그리고 이것은 부분구간의 개수가 커짐에 따라 $\frac{\exp(-\lambda t)(\lambda t)^x}{x!}$으로 수렴한다(참조: 정리 2.17의 증명).

한편,

$$\begin{aligned}
&P[X(t)=x\text{이고 최소한 1개구간에서 사건 }A\text{가 2회 이상 발생함}]\\
&\le P[\text{최소한 1개의 부분구간에서 2회 이상 발생함}]\\
&=P[\bigcup_{i=1}^{n} i\text{번째 부분구간에서 2회 이상 발생함}]\\
&\le \sum_{i=1}^{n} P[i\text{번째 부분구간에서 2회 이상 발생함}]\\
&=n\cdot o\left(\frac{t}{n}\right)
\end{aligned}$$

는 부분구간의 개수가 커짐에 따라 0으로 수렴한다. $P(X(t)=x)$는 부분구간의 개수에 상관없이 같은 값을 가지므로, $n\to\infty$ 일 때의 극한값을 $P(X(t)=x)$로 볼 수 있다. 즉, 확률변수 $X(t)$의 확률밀도함수는

$$f(x)=\exp(-\lambda t)(\lambda t)^x/x!, \qquad x=0,\ 1,\ 2,\ \cdots$$

과 같이 주어진다. 만약 $t=1$이라면,

$$f(x)=\frac{\exp(-\lambda)\lambda^x}{x!}, \qquad x=0,\ 1,\ 2,\ \cdots \tag{2.24}$$

이 되는데, 확률변수 X가 식 (2.24)와 같은 확률밀도함수를 가지면 이를 모수가 λ인 포아송(Poisson) 확률변수라고 하고 $X\sim \mathrm{POI}(\lambda)$로 표기한다. 사건 A가 위에서 언급된 세 가지 성질을 만족하면서 일어나는 경우 우리는 사건 A의 발생이 발생률 λ인 포아송 확률과정을 따른다고 말한다. 포아송 확률과정을 따르는 사건이 단위 시간에 발생하는 횟수는 $\mathrm{POI}(\lambda)$를 따르게 되고, 시간구간 $(t_1,t_2]$에서 발생하는 횟수는 $\mathrm{POI}(\lambda(t_2-t_1))$을 따르게 된다.

$X\sim \mathrm{POI}(\lambda)$의 기댓값은

$$\begin{aligned} E(X)&=\sum_{x=0}^{\infty} x\,\frac{\exp(-\lambda)\lambda^x}{x!} \\ &=\lambda\exp(-\lambda)\sum_{x=1}^{\infty}\frac{\lambda^{x-1}}{(x-1)!} \\ &=\lambda \end{aligned} \tag{2.25}$$

가 되며, 분산은

$$\begin{aligned} E[X(X-1)]&=\sum_{x=0}^{\infty} x(x-1)\frac{\exp(-\lambda)\lambda^x}{x!} \\ &=\exp(-\lambda)\sum_{x=2}^{\infty}\frac{\lambda^x}{(x-2)!} \\ &=\lambda^2\exp(-\lambda)\sum_{k=0}^{\infty}\frac{\lambda^k}{k!}=\lambda^2 \end{aligned}$$

으로부터 $E(X^2)=\lambda^2+\lambda$를 이용하면,