$$\begin{aligned} Var(X) &= E(X^2) - [E(X)]^2 \\ &= \lambda^2 + \lambda - \lambda^2 \\ &= \lambda \end{aligned} \tag{2.26}$$

로 주어진다. 여기에서 포아송 분포의 평균과 분산이 동일함을 알 수 있다.

예 2.32

어떤 전화교환대에서 매분 평균적으로 2건의 통화가 이루어진다고 한다. 통화횟수가 포아송 확률과정을 따른다는 가정하에, 3분 동안에 5건 이상의 통화가 이루어질 확률을 구해 보면 다음과 같다. 확률변수 X를 3분 동안에 걸려온 통화횟수라고 하면 이는 포아송 확률변수이며, $\lambda = E(X) = 6$이다. 따라서

$$\begin{aligned} P(X \geq 5) &= 1 - P(X \leq 4) \\ &= 1 - \sum_{x=0}^{4} \frac{6^x e^{-6}}{x!} \\ &= 1 - 0.285 \\ &= 0.715 \end{aligned}$$

이다.

포아송 분포에 의한 이항분포의 근사

다음의 정리는 포아송 분포와 이항분포의 근사관계를 이해하는 데 도움이 된다.

정리 2.17

확률변수 X가 $B(n, p)$ 분포를 따른다고 하자. 이때 n이 커짐에 따라 p가 0으로 수렴하되 $np = \lambda$를 만족하면, $x = 0, 1, 2, \cdots$ 에 대해서

$$\lim_{n\to\infty} \binom{n}{x} p^x (1-p)^{n-x} = \frac{\exp(-\lambda)\lambda^x}{x!}$$

이 성립한다.

증명 $\lim_{n\to\infty} \binom{n}{x} p^x (1-p)^{n-x} = \lim_{n\to\infty} \binom{n}{x} \left(\frac{\lambda}{n}\right)^x \left(1 - \frac{\lambda}{n}\right)^{n-x}$

$$= \lim_{n\to\infty} \frac{n!}{x!(n-x)!} \lambda^x \left(\frac{1}{n}\right)^x \left(1-\frac{\lambda}{n}\right)^{-x} \left(1-\frac{\lambda}{n}\right)^n$$

$$= \frac{\lambda^x}{x!} \lim_{n\to\infty} \frac{n!}{(n-x)!(n-\lambda)^x} \cdot \left(1-\frac{\lambda}{n}\right)^n$$

이다. 한편, $n\to\infty$에 따라 $(1-(\lambda/n))^n \to \exp(-\lambda)$이므로

$$\frac{n!}{(n-x)!(n-\lambda)^x} \to 1$$

이 성립함을 보이면 된다. 그런데, $n \to \infty$에서

$$\frac{n!}{(n-x)!(n-\lambda)^x} = \frac{n!}{(n-x)!n^x(1-\lambda/n)^x}$$

$$= \frac{n(n-1)\cdots(n-x+1)}{n^x(1-\lambda/n)^x}$$

$$= 1\times(1-\frac{1}{n})\times(1-\frac{2}{n})\times\cdots\times(1-\frac{x-1}{n})\times(1-\lambda/n)^{-x}$$

$$\to 1$$

이다. ■

예 2.33

일반적으로 위의 근사방법은 $n > 100$, $p < 0.01$인 경우 λ가 np에 가까울 때 효과적으로 이용할 수 있다. 예를 들어 $n = 50$, $p = 0.02$, $n = 100$, $p = 0.01$일 때와 $n = 200$, $p = 0.005$일 때, 이항분포와 포아송 분포($\lambda = np = 1$)에 의한 근사를 확률밀도함수를 통해 비교해 보면 다음 표와 같다. 같은 $\lambda = np$값을 갖는 경우에 n이 커질수록 이항분포의 확률이 포아송 분포의 확률과 더 가까워짐을 확인할 수 있다.

x	$B(50,0.02)$	$B(100,0.01)$	$B(200,0.005)$	POI(1)
0	0.364170	0.366032	0.366958	0.367879
1	0.371601	0.369730	0.368802	0.367879
2	0.185801	0.184856	0.184401	0.183940
3	0.060670	0.060999	0.061158	0.061313
4	0.014548	0.014942	0.015136	0.015328
5	0.002732	0.002898	0.002982	0.003066
	0.999522	0.999466	0.999436	0.999405

이와 같이 성공확률이 작으면서 서로 독립인 베르누이 확률변수들을 많이 더한 결과인 이항분포에 대한 포아송 근사방법의 타당성은 포아송 분포를 활용하는 데 도움을 준다. 가령, 어떤 고속도로 구간에서 1년 동안에 발생하는 교통사고의 횟수를 고려한다고 하자. 이 경우 많은 차량이 그 고속도로 구간을 통과할 것이고(n이 큼), 통과하는 각 차량의 사고 여부는 서로 독립이며 사고가 일어날 확률은 매우 작다고(p가 작음) 볼 수 있다. 그러므로 이항분포의 포아송 근사에 의하여 교통사고의 횟수에 대한 포아송 확률모형의 사용이 타당해 보인다.

주 이와 같이 포아송 분포에의 접근방법은 몇 개의 가정으로부터 시작하는 것과 정리 2.17에서와 같이 이항분포의 근사에 의한 두 가지 방법이 가능하다.

2.5.4 기하분포

'성공' 확률이 p인 베르누이 시행을 독립적으로 반복할 때, 첫 번째 '성공'이 일어날 때까지 걸리는 시행횟수를 X라고 하면 확률변수 X의 확률밀도함수는

$$f(x) = p(1-p)^{x-1} \quad (\text{단, } x = 1, 2, \cdots) \tag{2.27}$$

이 되며, 이를 기하(geometric)확률밀도함수라고 한다. 식 (2.27)은 $(x-1)$회의 실패 이후 1회의 성공으로 이루어진 서로 독립인 베르누이 시행이므로 자명한 결과이다. 편의상 $X \sim \mathrm{GEO}(p)$로 표기하기로 한다. 이제, X의 기댓값은

$$\begin{aligned} E(X) &= \sum_{x=1}^{\infty} xpq^{x-1} \quad (\text{단, } p+q=1) \\ &= \sum_{x=1}^{\infty} p\frac{d}{dq}q^x \\ &= p\frac{d}{dq}\sum_{x=1}^{\infty} q^x \\ &= p\frac{d}{dq}\frac{q}{(1-q)} \\ &= p(1-q)^{-2} \\ &= \frac{1}{p} \end{aligned} \tag{2.28}$$

이며(수렴하는 멱급수는 각 항별로 미분이 가능하다), 같은 방법으로

$$
\begin{aligned}
E(X(X+1)) &= \sum_{x=1}^{\infty} x(x+1)pq^{x-1} \\
&= p\sum_{x=1}^{\infty} \frac{d^2}{dq^2} q^{x+1} \\
&= p\frac{d^2}{dq^2} \sum_{x=1}^{\infty} q^{x+1} \\
&= p\frac{d^2}{dq^2} \{(1-q)^{-1} q^2\} \\
&= \frac{2}{p^2}
\end{aligned}
$$

이다. 따라서

$$
E(X^2) = \frac{2}{p^2} - \frac{1}{p} = \frac{1+q}{p^2}
$$

를 구할 수 있으므로, 분산은

$$
\begin{aligned}
Var(X) &= E(X^2) - (EX)^2 \\
&= \frac{1+q}{p^2} - \left(\frac{1}{p}\right)^2 \\
&= \frac{1-p}{p^2}
\end{aligned}
\tag{2.29}
$$

로 계산된다.

예 2.34

매주 발행되는 어떤 복권의 당첨확률이 0.001이고, 복권이 당첨되는 사건들은 독립이라고 하자. 어떤 복권구입자가 매주 이 복권을 산다면, 처음 당첨될 때까지 소요되는 구매 횟수 X의 확률밀도함수는 $f(x) = 0.001(1-0.001)^{x-1} (x = 1,2,\cdots)$이 되며 $E(X) = 1/0.001 = 1000$, $Var(X) = (1-0.001)/(0.001)^2 = 999000$이다.

한편, 기하확률변수는 아래 정리 2.18에서 표현되는 바와 같은 **무기억성**(memory-less property)을 갖는다.

정리 2.18

$X \sim \mathrm{GEO}(p)$이면, 임의의 자연수 j, k에 대하여,

$$P(X > j+k \mid X > j) = P(X > k)$$

가 성립한다.

증명 $P(X > k) = \sum_{j=k+1}^{\infty} p(1-p)^{j-1} = (1-p)^k \sum_{l=1}^{\infty} p(1-p)^{l-1} = (1-p)^k$ 이므로,

$$\begin{aligned} P(X > j+k \mid X > j) &= \frac{P(X > j+k)}{P(X > j)} \\ &= \frac{(1-p)^{j+k}}{(1-p)^j} \\ &= (1-p)^k \\ &= P(X > k). \end{aligned}$$ ■

위 정리 2.18에서 $X \sim \mathrm{GEO}(p)$이면 임의의 자연수 j, k에 대하여

$$P(X > j+k) = P(X > j) \times P(X > k)$$

가 성립함을 알 수 있다. 무기억성에 대한 구체적인 설명은 2.6절에 나올 지수분포에서 다루기로 한다.

2.5.5 음이항분포

'성공' 확률이 p인 베르누이 시행을 독립적으로 반복할 때 r개의 '성공'을 얻을 때까지 필요한 시행횟수를 X라고 하면, 확률변수 X의 확률밀도함수는

$$f(x; r, p) = \binom{x-1}{r-1} p^r (1-p)^{x-r} \qquad (x = r,\ r+1,\ \cdots) \tag{2.30}$$

이며, 이를 음이항(negative binomial) 확률밀도함수라고 한다. 편의상 $X \sim NB(r, p)$로 표기한다. 정해진 상수 $r \le n$에 대해 $X \sim NB(r, p)$이고 $Y \sim B(n, p)$인 경우, $X \le n$이라면 n번의 베르누이 시행에서 성공이 r번이거나 그 이상이었음을 의미하므로,

$$P(X \le n) = P(Y \ge r) = \sum_{k=r}^{n} \binom{n}{k} p^k q^{n-k}$$

이 성립한다(단, $p+q=1$). 실제로 '$X \le n$'은 'r개의 성공을 거두는데 n 이하의 시행횟수가 필요한' 사건이며, '$Y \ge r$'은 'n개의 시행에서 r개 이상의 성공을 거두는' 사건이므로 위 등식은 직관적으로 받아들여진다(확률변수 X의 이름을 음이항 확률변수라고 하는 것은 위의 관계식으로부터 유래한다). 또한, $X_1, X_2, \cdots, X_r$을 서로 독립인 $GEO(p)$라고 하면 이들은 베르누이 독립시행에서 첫 번째 성공이 나올 때까지의 시행횟수들이므로 그 합인 $X = X_1 + X_2 + \cdots + X_r$는 음이항 확률변수임을 쉽게 알 수 있다. 따라서 $X \sim NB(r, p)$의 평균과 분산은

$$\begin{aligned} E(X) &= r\,E(X_1) \\ &= \frac{r}{p} \end{aligned} \tag{2.31}$$

$$\begin{aligned} Var(X) &= r\,Var(X_1) \\ &= \frac{rq}{p^2} \quad (\text{단, } p+q=1) \end{aligned} \tag{2.32}$$

로 구할 수 있다.

예 2.35

7회의 동일한 게임으로 구성된 경기에서 두 개의 팀 A와 B가 겨루게 되었다고 하자. 4회를 먼저 이기는 팀이 우승을 하게 되고, 어떤 팀이든지 먼저 4회를 이기면 경기는 더 이상 계속되지 않고 종료된다. 이제 A팀이 각 게임에서 이길 확률을 0.7이라고 할 때 경기가 5회에서 종료될 확률을 구해 보자. A팀이 5회째 게임에서 4번째 승리를 거둘 사건을 $A5$ 그리고 B팀이 5회째 게임에서 4번째 승리를 거둘 사건을 $B5$라고 하자. 그러면 $P(A5)$는 $NB(4,0.7)$을 따르는 확률변수가 5의 값을 가질 확률과 같으므로 $P(A5) = \binom{4}{3}(0.7)^4(0.3) = 0.28812$이고 $P(B5)$도 비슷하게 $P(B5) = \binom{4}{3}(0.3)^4(0.7) = 0.02268$로 계산되므로, 경기가 5회에서 종료될 확률은 $0.28812 + 0.02268 = 0.3108$이다.

2.5.6 초기하분포

어떤 주머니에 r개의 빨간 공과 w개의 하얀 공(단, $r+w=N$)이 들어 있다. 이제, n개의 공을 무작위 비복원추출(sampling without replacement)하였을 때, X를 빨간 공의 개수라고 하면 확률변수 X의 확률밀도함수는

$$f(x)=\frac{\binom{r}{x}\binom{N-r}{n-x}}{\binom{N}{n}},\ x=\max(0,\ n-N+r),\cdots,\ \min(r,\ n) \tag{2.33}$$

이며, 이를 초기하(hypergeometric) 확률밀도함수라고 하고 $X\sim \mathrm{HYP}(n,\ N,\ r)$로 표기한다. 여기서, $x>r$인 경우 $\binom{r}{x}=0$이고, $x<n-N+r$인 경우 $\binom{N-r}{n-x}=0$이므로 위의 확률밀도함수를 $x=0,\cdots,n$ 에 대해서 정의해도 무방하다. 물론, 위의 실험에서 추출방법이 복원추출(sampling with replacement)인 경우는 이항분포를 따른다(참조: 예 2.29). 이러한 초기하 확률변수 $X\sim \mathrm{HYP}(n,\ N,\ r)$의 기댓값은

$$\begin{aligned}E(X)&=\sum_{x=0}^{n} x\frac{\binom{r}{x}\binom{N-r}{n-x}}{\binom{N}{n}}=n\frac{r}{N}\sum_{x=1}^{n}\frac{\binom{r-1}{x-1}\binom{N-r}{n-x}}{\binom{N-1}{n-1}}\\&=n\frac{r}{N}\sum_{y=0}^{n-1}\frac{\binom{r-1}{y}\binom{N-1-r+1}{n-1-y}}{\binom{N-1}{n-1}}\\&=n\frac{r}{N}\end{aligned} \tag{2.34}$$

이고, 이때 마지막 등식은 $\dfrac{\binom{r-1}{y}\binom{N-1-r+1}{n-1-y}}{\binom{N-1}{n-1}}$이 $\mathrm{HYP}(n-1,N-1,r-1)$의 확률밀도함수임을 이용하여 얻는다. 또한,

$$E[X(X-1)]=\sum_{x=0}^{n} x(x-1)\frac{\binom{r}{x}\binom{N-r}{n-x}}{\binom{N}{n}}$$

$$= n(n-1)\frac{r(r-1)}{N(N-1)}\sum_{x=2}^{n}\frac{\binom{r-2}{x-2}\binom{N-r}{n-x}}{\binom{N-2}{n-2}}$$

$$= n(n-1)\frac{r(r-1)}{N(N-1)}\sum_{y=0}^{n-2}\frac{\binom{r-2}{y}\binom{N-2-r+2}{n-2-y}}{\binom{N-2}{n-2}}$$

$$= n(n-1)\frac{r(r-1)}{N(N-1)}$$

이므로 분산은

$$Var(X) = E(X^2) - [E(X)]^2 = E[X(X-1)] + E(X) - [E(X)]^2 \qquad (2.35)$$

$$= n(n-1)\frac{r(r-1)}{N(N-1)} + n\frac{r}{N} - n^2\frac{r^2}{N^2}$$

$$= n\frac{r}{N}\left[(n-1)\frac{r-1}{N-1} + 1 - \frac{nr}{N}\right]$$

$$= \frac{nr}{N}\left[\frac{(N-r)(N-n)}{N(N-1)}\right]$$

으로 주어진다. $p = \frac{r}{N}$으로 정의한다면 위의 분산은 $np(1-p)\left(\frac{N-n}{N-1}\right)$로 쓸 수 있으며, 복원추출의 결과로 얻어지는 이항분포의 분산인 $np(1-p)$에 $\left(\frac{N-n}{N-1}\right)$이 곱해진 꼴이다. $\left(\frac{N-n}{N-1}\right)$은 비복원추출의 결과로 인해 모집단이 유한집합이 되기 때문에 나타나는 항이므로 유한모집단 수정항(finite population correction term)이라고 한다.

그런데 $X \sim \mathrm{HYP}(n, N, r)$일 때, $N \to \infty$, $r \to \infty$, $r/N \to p$이면

$$\lim_{N\to\infty,\, r\to\infty,\, r/N\to p}\frac{\binom{r}{x}\binom{N-r}{n-x}}{\binom{N}{n}} = \binom{n}{x}p^x(1-p)^{n-x}$$

이 성립한다. 따라서 $N(=r+w)$과 r이 충분히 큰 경우, 초기하분포의 근사에 이항분포를 활용할 수 있다.

예 2.36

어떤 상자에 100개의 전자제품이 포장되어 있다. 한 구입자가 이 상자에 10개의 부

품을 비복원 랜덤추출하여 불량품의 상태를 조사하려고 한다. 실제로 100개들이 상자 속에 30개의 불량품이 있을 때, 2개 이하의 불량품이 나올 확률을 구해 보자. X='불량품의 개수'라 하면 $X \sim \mathrm{HYP}(10, 100, 30)$이므로

$$P(X \le 2) = \sum_{x \le 2} \frac{\binom{30}{x}\binom{70}{10-x}}{\binom{100}{10}}$$
$$= 0.372857$$

이 된다. 이제, 이항확률분포에 의한 근삿값은

$$P(X \le 2) = \sum_{x \le 2} \binom{10}{x} (0.3)^x (0.7)^{10-x}$$
$$= 0.382783$$

로 비교적 정확한 값이 구해진다.

2.6 연속형 확률분포

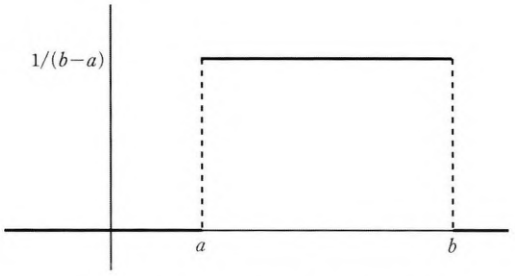
2.5절에서는 이산형 확률변수의 몇 가지 분포를 알아보았다. 이 절에서는 역시 일변량 변수들로서 모수(parameter)들에 의해 그 성질이 결정되는 **연속형 확률변수**(continuous random variable)에 대해 살펴보기로 하자. 몇 가지 중요한 확률변수에 대하여 확률분포함수를 구하고 평균, 분산 등을 통해 각 변수의 성격들을 알아본다. 2.2절에서 이미 언급되었으나 다시 한 번 연속형 확률변수를 정의하면 이는 다음과 같다.

정의 2.12

확률변수 X가 임의의 실수 x에 대하여 $P(X=x)=0$을 만족하면 **연속형 확률변수**라고 한다.

2.6.1 균일분포

확률변수 X가 실구간 (a, b)상에 균일(uniform)하게 분포되어 있을 때 그의 확률밀도함수는



▸ **그림 2.1** ◂ $U(a, b)$의 확률밀도함수

$$f(x)=\begin{cases}1/(b-a), & a \le x \le b\text{인 경우}\\ 0, & \text{그 외의 경우}\end{cases} \tag{2.36}$$

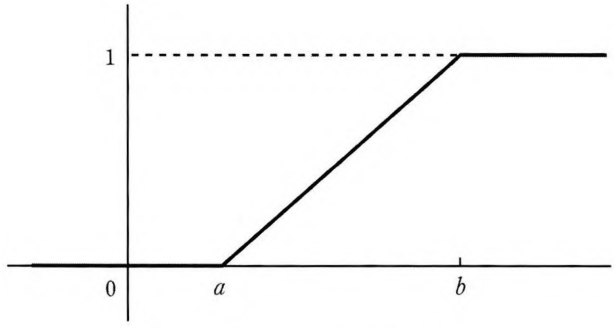
으로 주어지며 $X \sim U(a, b)$로 표기하기로 한다(참조: 그림 2.1). 예를 들어 컴퓨터 모의실험으로 0과 1 사이에서 난수(random number)를 생성하는 경우, 컴퓨터는 $U(0,1)$의 확률분포에서 숫자를 뽑아내게 되며, 이 경우 0과 1 사이의 난수는 $U(0,1)$을 따른다고 할 수 있다.

또한 $X \sim U(a, b)$의 확률분포함수는

$$F(x)=\int_{-\infty}^{x} f(y)dy=\int_{-\infty}^{x}\frac{1}{b-a}I_{(a,b)}(y)dy$$

$$=\begin{cases}0, & x < a\text{인 경우}\\ (x-a)/(b-a), & a \le x < b\text{인 경우}\\ 1, & x \ge b\text{인 경우}\end{cases}$$

로 계산된다(참조: 그림 2.2). 여기에서 $I_{(a,b)}(x)$는 예 2.28에서 정의된 지시함수이다.



▸ **그림 2.2** ◂ $U(a, b)$의 확률분포함수

나아가 균일확률변수 $X \sim U(a, b)$의 기댓값과 분산은 다음과 같이 구해진다.

$$\begin{aligned} E(X) &= \int_a^b \frac{x}{b-a}\, dx \\ &= \frac{b+a}{2} \end{aligned} \tag{2.37}$$

$$\begin{aligned} Var(X) &= E(X^2) - (EX)^2 \\ &= \int_a^b \frac{x^2}{b-a}\, dx - \{(b+a)/2\}^2 \\ &= \frac{(b-a)^2}{12} \end{aligned} \tag{2.38}$$

2.6.2 지수분포

포아송 확률과정을 고려했을 때, 특정한 사건 A가 일어나고 다음에 또 다시 같은 사건이 일어날 때까지 걸리는 시간 W는 음이 아닌 값을 가지는 연속형 확률변수이다. 이제, 단위구간에서의 평균발생횟수가 λ인 포아송과정을 고려하면, 도착간격시간(interarrival time) W의 확률분포함수는 $w > 0$인 w에 대하여,

$$\begin{aligned} F(w) &= P(W \le w) \\ &= 1 - P[\text{구간 } [0, w) \text{에서 사건 } A\text{가 일어나지 않음}] \\ &= 1 - \exp(-\lambda w) \end{aligned}$$

가 되므로, 이를 미분하면 W의 확률밀도함수는 $f_W(w) = \lambda \exp(-\lambda w),\ w > 0$가 된다. 이 도착간격시간의 확률분포를 지수분포라고 하는데, $\theta = 1/\lambda$이라고 모수변환을 하여 구한 지수 확률밀도함수는

$$f(x) = \frac{1}{\theta} \exp(-x/\theta)\ \ (x > 0) \tag{2.39}$$

로 주어지며 편의상 $X \sim \mathrm{EXP}(\theta)$로 표기한다. 이때 X의 확률분포함수는

$$\begin{aligned} F(x) &= \int_0^x \frac{\exp(-t/\theta)}{\theta}\, dt \\ &= 1 - \exp(-x/\theta) \end{aligned}$$

이다.

참주 때로 $X \sim \mathrm{EXP}(\theta)$의 확률밀도함수를 $f(x) = \theta \exp(-\theta x),\ x > 0$로 정의하는 책들도 있다. 흔히 신뢰성이론이나 생존모형, 보험계리모형 등에서 이렇게 표현하곤 한다.

$X \sim \mathrm{EXP}(\theta)$의 기댓값과 분산은 각각

$$\begin{aligned} E(X) &= \int_0^\infty x \frac{1}{\theta} \exp(-x/\theta)\, dx \\ &= -x \exp(-x/\theta)\Big|_0^\infty + \int_0^\infty \exp(-x/\theta)\, dx \\ &= -\theta \exp(-x/\theta)\Big|_0^\infty \\ &= \theta \end{aligned} \tag{2.40}$$

$$\begin{aligned} Var(X) &= \int_0^\infty x^2 \frac{1}{\theta} \exp(-x/\theta)\, dx - \theta^2 \\ &= -x^2 \exp(-x/\theta)\Big|_0^\infty + \int_0^\infty 2x \exp(-x/\theta)\, dx - \theta^2 \\ &= 0 + 2\theta \int_0^\infty \frac{x}{\theta} \exp(-x/\theta)\, dx - \theta^2 \\ &= 2\theta E(X) - \theta^2 \\ &= 2\theta^2 - \theta^2 = \theta^2 \end{aligned} \tag{2.41}$$

으로 구해진다.

참주 단위구간 내에서의 평균발생횟수가 λ인 포아송 과정의 사건 사이 소요시간의 평균값은 $\theta = \frac{1}{\lambda}$이 됨을 보았다. 이것은 포아송 확률변수에서 모수인 평균 λ가 크면 특정 사건의 발생횟수가 평균적으로 많아지는 반면, 특정 사건 사이의 소요시간은 평균적으로 작아진다는 것을 뜻한다. 그러므로, 발생횟수의 평균인 포아송 분포의 모수 λ와 도착간격시간의 평균인 지수분포의 모수 θ는 역의 관계를 가지고 있다.

예 2.37

어떤 화학물질에서 α-입자가 10초당 평균 5개씩 포아송 과정을 따라 발생한다고 하자. 이때 첫 번째 입자가 발생될 때까지 걸리는 시간 X가 5초 이상일 확률을 구해

보자. 초당 발생될 α - 입자의 수의 기댓값은 $\lambda = 1/2$이므로 X의 확률밀도함수는

$$f_X(x) = (1/2)e^{-x/2}, \quad x \geq 0$$

이 된다. 따라서

$$\begin{aligned} P(X \geq 5) &= \int_5^{\infty} (1/2)\, e^{-x/2} dx \\ &= e^{-5/2} \\ &= 0.08208 \end{aligned}$$

이 된다.

이산형 확률변수 중에서 기하확률변수가 무기억 성질을 갖는 것처럼 연속형 확률변수 중에서는 지수확률변수가 동일한 성질을 지닌다.

정리 2.19

$X \sim \mathrm{EXP}(\theta)$이면, 양의 실수 a와 t에 대해서,

$$P(X > a+t \mid X > a) = P(X > t)$$

가 성립한다.

증명 $P(X > a+t \mid X > a) = \dfrac{P(X > a+t,\ X > a)}{P(X > a)}$

$$\begin{aligned} &= \frac{P(X > a+t)}{P(X > a)} \\ &= \frac{\exp\{-(a+t)/\theta\}}{\exp\{-a/\theta\}} \\ &= P(X > t) \end{aligned}$$

■

위 정리의 의미를 살펴보자. 가령, 확률변수 X가 어떤 기계부품의 수명이라고 하면, $P(X > a+t \mid X > a)$는 시점 a에서 기계부품의 고장이 없을 때, 최소한 시간 t 만큼 더 고장이 없을 사건에 대한 확률을 뜻한다. 따라서 정리 2.19의 무기억 성질은 변수 X가 시점 a에서 그동안 기계부품의 고장이 없었다는 조건을 '기억'하지 않고, 앞

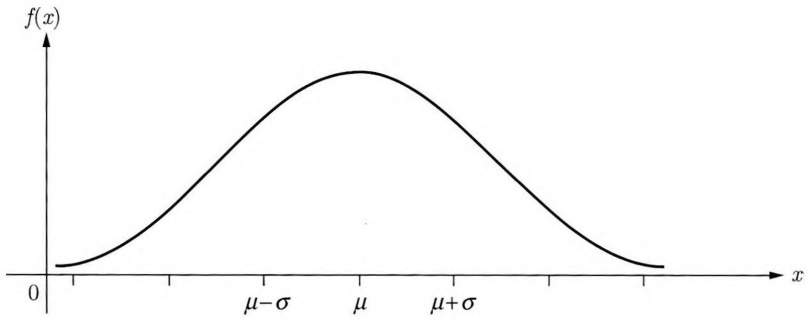
으로 시간 t만큼 더 고장이 없을 것만 고려한다는 것을 뜻하는 것으로, a시간만큼 일한 기계부품이 앞으로 t시간만큼 더 작동하는 확률이나 새 기계부품이 앞으로 t시간만큼 더 작동하는 확률이나 같다는 것이다.

2.6.3 정규분포

통계적 방법에서 가장 많이 이용되는 확률분포를 들라면 그것은 단연 정규분포일 것이다. 그 이유는 후에 다룰 중심극한정리 등을 통해 설명되겠으며, 여기서는 먼저 정규분포의 확률밀도함수를 제시하고 그의 성질을 알아보기로 한다. 확률변수 X의 확률밀도함수가

$$f(x)=\frac{1}{\sqrt{2\pi}\,\sigma}\exp[-(x-\mu)^2/2\sigma^2] \quad (-\infty<x<\infty) \qquad (2.42)$$

로 주어지면 X가 정규분포(normal distribution)를 따른다고 하며 $X\sim N(\mu,\ \sigma^2)$으로 표기하기로 한다(참조: 그림 2.3). 아래의 그림에서 보는 바와 같이 정규분포의 확률밀도함수는 모든 실수 값에서 0보다 큰 값을 가지면서 평균을 중심으로 대칭인 종 모양(bell-shaped)을 하고 있으며, 그 오목성이 $\mu\pm\sigma$에서 바뀌게 된다.



▸ 그림 2.3 ◂ $X\sim N(\mu,\ \sigma^2)$의 확률밀도함수

이와 같은 정규확률변수의 중요한 특징 중의 하나는 선형변환을 하여도 역시 정규분포를 따른다는 점이다. $X\sim N(\mu,\ \sigma^2)$일 때, 선형변환된 확률변수 $Y=aX+b$, $(a>0,\ b$는 상수)의 분포는 다음과 같이 구해진다.

$$\begin{aligned}F_Y(y)&=P(Y\le y)\\&=P(aX+b\le y)\end{aligned}$$

$$= P\left[X \le \frac{y-b}{a}\right]$$
$$= \int_{-\infty}^{\frac{y-b}{a}} \frac{1}{\sqrt{2\pi}\,\sigma} \exp[-(x-\mu)^2/2\sigma^2]\,dx$$
$$= \int_{-\infty}^{y} \frac{1}{\sqrt{2\pi}\,a\sigma} \exp\{-[t-(a\mu+b)]^2/(2a^2\sigma^2)\}\,dt \quad (\because \frac{t-b}{a} = x\text{로 변환})$$

따라서 Y의 확률밀도함수는

$$f_Y(y) = (d/dy)\,F_Y(y)$$
$$= \frac{1}{\sqrt{2\pi}\,a\sigma} \exp\{-[y-(a\mu+b)]^2/(2a^2\sigma^2)\}$$

이므로 $Y \sim N(a\mu+b,\ a^2\sigma^2)$임을 알 수 있다. $a<0$일 때 $Y \sim N(a\mu+b,\ a^2\sigma^2)$가 되는 것도 비슷하게 확인할 수 있다. 여기서, $Z=(X-\mu)/\sigma$라는 표준화 변환을 하면 Z의 확률밀도함수는

$$f_Z(z) = \frac{1}{\sqrt{2\pi}} \exp(-z^2/2) \qquad (-\infty < z < \infty) \tag{2.43}$$

로 주어진다. 이는 **표준정규분포**(standard normal distribution) $N(0,\ 1)$의 확률밀도함수이며 통상적으로 $\phi(z)$로 표기한다. 또한 $\phi(z)$가 확률밀도함수의 조건을 만족하는가를 알아보면 식 (2.43)으로부터 $\phi(z)>0$임은 자명하다. 그런데,

$$I = \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}}\, e^{-z^2/2}\,dz$$

이라 놓으면,

$$I^2 = \frac{1}{2\pi}\left[\int_{-\infty}^{\infty} e^{-x^2/2}\,dx\right]\left[\int_{-\infty}^{\infty} e^{-y^2/2}\,dy\right]$$
$$= \frac{1}{2\pi}\int_{-\infty}^{\infty}\int_{-\infty}^{\infty} \exp\left(-\frac{x^2+y^2}{2}\right)dx\,dy$$

이다. 여기에서 극좌표 변환 $x=r\cos\theta$, $y=r\sin\theta$을 활용하면,

$$|J| = r(\sin^2\theta + \cos^2\theta) = r$$

이 되므로,

$$
\begin{aligned}
I^2 &= \frac{1}{2\pi}\int_0^{2\pi}\int_0^{\infty} r\exp(-r^2/2)dr\,d\theta \\
&= \frac{1}{2\pi}\int_0^{2\pi}\int_0^{\infty} \exp(-t)dt\,d\theta \text{ (단, } t=r^2/2) \\
&= \frac{1}{2\pi}\int_0^{2\pi} d\theta \\
&= 1
\end{aligned}
$$

이므로 $I=\int_{-\infty}^{\infty}\phi(z)\,dz=1$을 만족하여 $\phi(z)$가 확률밀도함수임을 확인할 수 있다.
이제, 정규확률변수 $X\sim N(\mu,\ \sigma^2)$의 평균과 분산은

$$
\begin{aligned}
E(X) &= \int_{-\infty}^{\infty} x\frac{1}{\sqrt{2\pi}\,\sigma}\exp\left[-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right]dx \\
&= \int_{-\infty}^{\infty}(\mu+\sigma z)\,\phi(z)\,dz \ (\because \frac{x-\mu}{\sigma}=z\text{로 변환}) \\
&= \mu\int_{-\infty}^{\infty}\phi(z)\,dz+\sigma\int_{-\infty}^{\infty} z\,\phi(z)\,dz \\
&= \mu
\end{aligned}
$$

$\int_{-\infty}^{\infty} z\phi(z)dz$는 $z\phi(z)$가 적분 가능한 기함수이므로 0이 된다. 그리고,

$$
\begin{aligned}
E(X^2) &= \int_{-\infty}^{\infty} x^2\frac{1}{\sqrt{2\pi}\,\sigma}\exp\left[-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right]dx \\
&= \int_{-\infty}^{\infty}(\mu+\sigma z)^2\,\phi(z)\,dz \\
&= \mu^2\int_{-\infty}^{\infty}\phi(z)\,dz+2\mu\sigma\int_{-\infty}^{\infty} z\,\phi(z)\,dz+\sigma^2\int_{-\infty}^{\infty} z^2\,\phi(z)\,dz \\
&= \mu^2+\sigma^2 \ \left(\because \int_{-\infty}^{\infty} z^2\,\phi(z)\,dz = \int_{-\infty}^{\infty}[\phi''(z)+\phi(z)]\,dz=1\right)
\end{aligned}
$$

이므로

$$
\begin{aligned}
Var(X) &= E(X^2)-[E(X)]^2 \\
&= \sigma^2
\end{aligned}
\tag{2.44}
$$

으로 구할 수 있다. 여기에서 $\int_{-\infty}^{\infty}\phi''(z)dz=\frac{d^2}{dz^2}\int_{-\infty}^{\infty}\phi(z)dz=0$이 된다.

또한, 표준정규확률변수의 누적확률분포함수는

$$\begin{aligned}\Phi(x) &= P(Z \le x) \\ &= \int_{-\infty}^{x} \phi(t)\,dt\end{aligned} \tag{2.45}$$

로 표현하며, 값이 부록 〈표 3〉에 계산되어 있다. 또한 확률밀도함수 $\phi(x)$가 0에 대하여 대칭이므로 누적확률분포함수는

$$\Phi(x) = 1 - \Phi(-x) \tag{2.46}$$

를 만족함을 알 수 있다.

정리 2.20

$X \sim N(\mu, \sigma^2)$이면, X의 확률분포함수는

$$F(x) = \Phi\left(\frac{x-\mu}{\sigma}\right)$$

로 나타내진다.

증명 $F(x) = P(X \le x)$

$$= P\left(\frac{X-\mu}{\sigma} \le \frac{x-\mu}{\sigma}\right)$$

$$= \Phi\left(\frac{x-\mu}{\sigma}\right) \quad (\because (X-\mu)/\sigma \sim N(0, 1)\text{이므로})$$

가 성립한다. ■

예 2.38

확률변수 X가 $N(25, 16)$을 따른다고 하자. 이때 X가 20과 35 사이에 있을 확률은

$$\begin{aligned}P(20 \le X \le 35) &= P\left[\frac{20-25}{4} \le \frac{X-25}{4} \le \frac{35-25}{4}\right] \\ &= \Phi(2.5) - \Phi(-1.25) \\ &= 0.9938 - 0.1056 \\ &= 0.8882\end{aligned}$$

로 구할 수 있다.

또한, $P(|X-25| \le c) = 0.9$ 를 만족하는 상수 c는

$$\begin{aligned} P(|X-25| \le c) &= P\left[-\frac{c}{4} \le \frac{X-25}{4} \le \frac{c}{4}\right] \\ &= \Phi\left(\frac{c}{4}\right) - \Phi\left(-\frac{c}{4}\right) \\ &= 0.90 \end{aligned}$$

으로부터 $c/4 = 1.645$이므로 $c = 6.58$로 계산된다.

2.6.4 이변량 정규분포

일변량 정규분포를 '다변량 정규분포'로 연장함에 있어 가장 간단한 경우인 이변량 정규분포(bivariate normal distribution)를 살펴보자. 다변량 정규분포는 7장의 회귀분석 등을 포함한 많은 통계적 방법에서 매우 중요한 역할을 한다.

이변량 정규확률벡터 (X, Y)의 결합 확률밀도함수는

$$\begin{aligned} f_{X,Y}(x, y) &= \frac{1}{2\pi\sigma_X\sigma_Y\sqrt{1-\rho^2}} \\ &\times \exp\left\{-\frac{1}{2(1-\rho^2)}\left[\left(\frac{x-\mu_X}{\sigma_X}\right)^2 - 2\rho\frac{x-\mu_X}{\sigma_X}\frac{y-\mu_Y}{\sigma_Y} + \left(\frac{y-\mu_Y}{\sigma_Y}\right)^2\right]\right\} \end{aligned} \tag{2.47}$$

$$-\infty < x,\ y < \infty,\ -\infty < \mu_X,\ \mu_Y < \infty,\ 0 < \sigma_X,\ \sigma_Y < \infty,\ -1 < \rho < 1$$

으로 주어지며, 이러한 경우에 $(X, Y) \sim BVN(\mu_X, \mu_Y, \sigma_X, \sigma_Y, \rho)$로 표기하기로 한다. 위의 결합 확률밀도함수에서 모수벡터$(\mu_X, \mu_Y, \sigma_X, \sigma_Y, \rho)$의 의미는 다음 정리 2.21에서 밝혀진다.

정리 2.21

이변량 정규확률벡터 $(X, Y) \sim BVN(\mu_X, \mu_Y, \sigma_X, \sigma_Y, \rho)$의 평균과 분산 그리고 공분산은

$$E(X) = \mu_X, \quad E(Y) = \mu_Y$$

$$Var(X) = {\sigma_X}^2, \quad Var(Y) = {\sigma_Y}^2, \quad Cov(X, Y) = \rho\sigma_X\sigma_Y$$

으로 주어진다.

증명 뒤 2.8절에 나오는 결합 적률생성함수를 사용하여 증명할 수 있으며, 연습문제로 남기도록 한다. ■

나아가, 이변량 정규분포의 주변분포는 다음의 정리와 같이 주어진다.

정리 2.22

이변량 확률벡터 (X, Y)가 $BVN(\mu_X, \mu_Y, \sigma_X, \sigma_Y, \rho)$ 분포를 가지면 X와 Y의 주변 확률분포는 $X \sim N(\mu_X, {\sigma_X}^2)$, $Y \sim N(\mu_Y, {\sigma_Y}^2)$으로 일변량 정규분포를 따른다.

증명 $f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x, y)\,dy$에서 식 (2.47)에 $v = (y - \mu_Y)/\sigma_Y$로 변환하면

$$f_X(x) = \int_{-\infty}^{\infty} \frac{1}{2\pi\sigma_X\sqrt{1-\rho^2}} \exp\left\{-\frac{1}{2}\left(\frac{x-\mu_X}{\sigma_X}\right)^2 - \frac{1}{2(1-\rho^2)}\left(v - \rho\left(\frac{x-\mu_X}{\sigma_X}\right)\right)^2\right\} dv$$

가 되며, 다시 $\dfrac{v - \rho(x-\mu_X)/\sigma_X}{\sqrt{(1-\rho^2)}} = w$라는 변환을 시도하면

$$f_X(x) = \frac{1}{\sqrt{2\pi}\,\sigma_X} \exp\left\{-\frac{1}{2}\left(\frac{x-\mu_X}{\sigma_X}\right)^2\right\}$$

을 구할 수 있다. Y의 주변 확률밀도함수도 마찬가지 방법으로 구할 수 있다. ■

그런데 위의 식 (2.47)과 정리 2.22로부터 정규확률벡터 (X, Y)는 $Cov(X, Y) = 0$이면 결합 확률밀도함수가 주변 확률밀도함수의 곱의 꼴로 표현되므로 X와 Y가 서로 독립임을 알 수 있다. 이러한 사실은 정규확률변수의 경우 특별히 성립하는 것이며, 일반적으로는 성립하지 않는다는 것에 주의하자.

이제 $X = x$가 주어졌을 때, Y의 조건부 확률밀도함수는

$$f_{Y|x}(y\,|\,x) = \frac{f_{X,Y}(x, y)}{f_X(x)} \quad \text{(식 (2.47)과 정리 2.22를 이용하여)}$$

$$= \frac{1}{\sqrt{2\pi}\,\sigma_Y\sqrt{1-\rho^2}} \exp\left\{-\frac{1}{2{\sigma_Y}^2(1-\rho^2)}\left[y - \mu_Y - \frac{\rho\sigma_Y}{\sigma_X}(x-\mu_X)\right]^2\right\} \quad (2.48)$$

으로 주어진다. 이는 평균과 분산이 각각

$$E(Y|x) = \mu_Y + \rho \frac{\sigma_Y}{\sigma_X}(x - \mu_X)$$
$$Var(Y|x) = \sigma_Y{}^2(1-\rho^2) \tag{2.49}$$

인 정규확률변수의 확률밀도함수이므로 $Y|X=x \sim N(\mu_Y + \rho\frac{\sigma_Y}{\sigma_X}(x-\mu_X),$ $\sigma_Y^2(1-\rho^2))$가 된다. 만약 $\rho=0$이면 $Y|X=x$의 분포는 Y의 주변분포와 같고, ρ의 절댓값이 커질수록 그 분산은 Y의 주변분포의 분산에 비해 점점 줄어들어 $\rho=\pm 1$이 되면 분산이 0인 퇴화분포(degenerate distribution)가 됨을 알 수 있다. 또, $\rho > 0$ 일 때 x의 값이 평균보다 크다면 Y의 평균이 μ_Y보다 커지고, x의 값이 평균보다 작다면 Y의 평균이 μ_Y보다 작아질 것이다. ρ가 X와 Y의 상관계수이므로 이와 같은 결과는 자명하다. 이와 연관된 내용들은 7장의 회귀분석에서 자세히 다루어질 것이다.

2.6.5 감마분포

여기서는 지수분포 등의 여러 가지 분포를 포함하는 분포족(familiy of distributions)인 감마분포(gamma distribution)에 대해 알아보려고 한다. 우선, 이에 필요한 감마함수의 정의는 다음과 같다.

정의 2.13

$\Gamma(k)$로 표기되는 감마함수는

$$\Gamma(k) = \int_0^\infty t^{k-1}e^{-t}dt \qquad (k>0)$$

이다.

이와 같이 정의된 감마함수는

$$\Gamma(1) = \int_0^\infty e^{-t}dt = 1$$

이 되며, 다음과 같은 성질들을 가지고 있다.

$$\begin{aligned}&\text{(i)}\ \ \Gamma(k)=(k-1)\Gamma(k-1) \quad (k>1)\\ &\text{(ii)}\ \ \Gamma(n)=(n-1)! \qquad\quad (n\text{은 자연수})\\ &\text{(iii)}\ \ \Gamma\left(\frac{1}{2}\right)=\sqrt{\pi}\end{aligned} \tag{2.50}$$

감마함수의 성질로부터 유래되는 감마확률변수 X의 확률밀도함수는 양수인 θ와 k에 대해,

$$f(x;k,\theta)=\frac{1}{\theta^k\Gamma(k)}x^{k-1}\exp(-x/\theta), \qquad x>0 \tag{2.51}$$

으로 주어지며 $X\sim \mathrm{GAM}(k,\theta)$로 표기하도록 한다. 확률변수 $X\sim \mathrm{GAM}(k,\theta)$의 기댓값과 분산은 아래와 같이 구해진다. 먼저, 기댓값은

$$\begin{aligned}E(X)&=\frac{1}{\theta^k\Gamma(k)}\int_0^\infty x^{(1+k)-1}\exp(-x/\theta)\,dx\\ &=\frac{\theta^{1+k}\Gamma(k+1)}{\theta^k\Gamma(k)}\int_0^\infty\frac{1}{\theta^{1+k}\Gamma(k+1)}x^{(1+k)-1}\exp(-x/\theta)\,dx\\ &=\frac{\theta^{1+k}\Gamma(k+1)}{\theta^k\Gamma(k)}=k\theta\end{aligned} \tag{2.52}$$

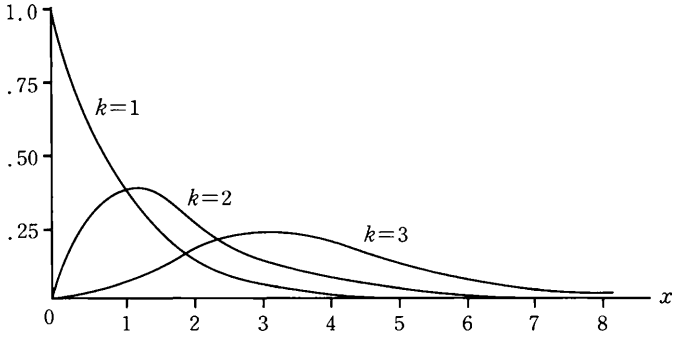
이다. 마찬가지 방법으로,

$$E(X^2)=k(1+k)\theta^2$$

을 구할 수 있으며, 따라서 분산은

$$Var(X)=k(k+1)\theta^2-(k\theta)^2=k\theta^2 \tag{2.53}$$

이다. 위의 감마분포에서 모수 k는 분포의 모양을 특징짓는 모수(형태모수, shape parameter)이며, $k=1$인 경우는 모수가 θ인 지수분포에 해당된다.



▸ 그림 2.4 ◂ $X \sim \mathrm{GAM}(1, k)$의 확률밀도함수

2.6.6 베타분포

구간 $(0, 1)$상의 연속형 확률변수의 분포를 표현하는 데 사용될 수 있는 베타분포(beta distribution)에 대해 다루어 보자. 먼저, 이에 필요한 베타함수의 정의는 다음과 같다.

정의 2.14

$\mathrm{B}(a, b)$로 표기되는 **베타함수**(beta function)는 $a > 0$, $b > 0$에서

$$\mathrm{B}(a, b) = \int_0^1 x^{a-1}(1-x)^{b-1}\,dx$$

로 정의된다.

베타함수의 성질로부터 유래되는 베타확률변수 X의 확률밀도함수는

$$f(x; a, b) = \frac{1}{\mathrm{B}(a, b)}\, x^{a-1}(1-x)^{b-1} \quad (0 < x < 1) \tag{2.54}$$

로 주어지며 $X \sim BETA(a, b)$로 표기한다. $X \sim BETA(a, b)$의 평균과 분산은 아래와 같이 구해진다. $k > -a$인 k에 대하여,

$$\begin{aligned} E(X^k) &= \frac{1}{\mathrm{B}(a, b)} \int_0^1 x^{k+a-1}(1-x)^{b-1}\,dx \\ &= \frac{\mathrm{B}(a+k, b)}{\mathrm{B}(a, b)} = \frac{\Gamma(a+k)\,\Gamma(b)}{\Gamma(a+b+k)} \cdot \frac{\Gamma(a+b)}{\Gamma(a)\,\Gamma(b)} \\ &= \frac{\Gamma(a+k)\,\Gamma(a+b)}{\Gamma(a)\,\Gamma(a+b+k)} \end{aligned} \tag{2.55}$$

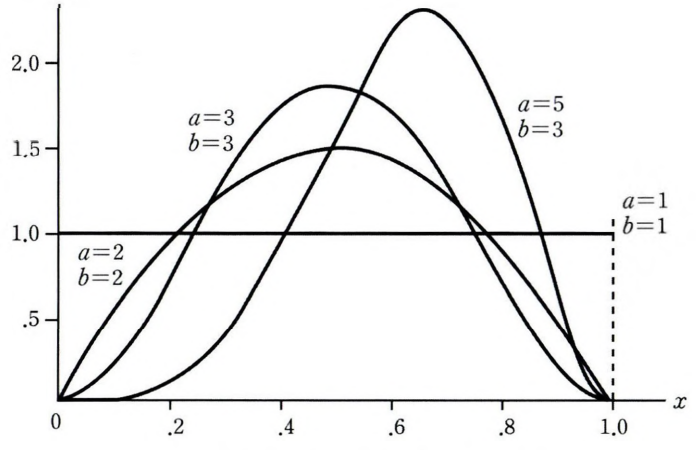
이므로

$$E(X) = \frac{\Gamma(a+1)\,\Gamma(a+b)}{\Gamma(a)\,\Gamma(a+b+1)} = \frac{a}{a+b} \tag{2.56}$$

$$Var(X) = E(X^2) - [E(X)]^2 = \frac{\Gamma(a+2)\,\Gamma(a+b)}{\Gamma(a)\,\Gamma(a+b+2)} - \left(\frac{a}{a+b}\right)^2 = \frac{(a+1)a}{(a+b+1)(a+b)} - \left(\frac{a}{a+b}\right)^2 = \frac{ab}{(a+b+1)(a+b)^2} \tag{2.57}$$

로 계산된다(위의 기댓값을 계산하는 과정에서는 $\mathrm{B}(a,\,b) = \frac{\Gamma(a)\,\Gamma(b)}{\Gamma(a+b)}$를 이용하였다. 연습문제 2.56 참조).

그림 2.5에서 확인할 수 있듯이 베타분포는 모수 a, b의 값에 따라 구간 $(0,\,1)$상에 여러 가지 분포형태를 포함한다($a=1,\,b=1$인 경우에는 $U(0,1)$이 된다). 적절한 변환을 이용하면, 베타분포는 임의의 유한구간(finite interval) 내의 값을 갖는 변수에 대한 확률모형으로 활용될 수 있다.



▸ **그림 2.5** ◂ $X \sim BETA(a,\,b)$의 확률밀도함수

2.6.7 그 외의 연속형 확률분포들

앞에서 다룬 확률분포들 외에도 자주 쓰이는 몇 가지 연속형 확률변수들로 다음과

같은 것들이 있다.

공학(engineering)분야에서 물체의 장력측정 등에 사용되는 와이블(Weibull) 확률변수의 확률밀도함수는 $\beta > 0, \theta > 0$에서,

$$f(x;\theta, \beta) = \frac{\beta}{\theta^{\beta}} x^{\beta-1} \exp\{-(x/\theta)^{\beta}\}, \quad x > 0 \tag{2.58}$$

로 주어진다. 여기에서 모수 β는 마치 감마분포에서의 모수 k와 같이 분포의 형태(shape)를 결정짓는다. 특히, $\beta = 2$인 경우 랄리(Rayleigh) 분포라고 한다.

또한, 생의학(biomedical)이나 보험계리(actuarial science) 등의 분야에서 자주 사용되는 파레토(Pareto) 확률변수의 확률밀도함수는 $\theta > 0, k > 0$일 때,

$$f(x;\theta, k) = \frac{k}{\theta}\left(1 + \frac{x}{\theta}\right)^{-(k+1)}, \quad x > 0 \tag{2.59}$$

으로 주어진다. 여기서는 모수 k가 분포의 형태를 결정짓는다. 파레토 분포나 와이블 분포는 정규분포에 비해 꼬리가 두꺼우며, 이 성질 때문에 보험 손해액 등 꼬리가 두꺼운 자료를 모형화하는 데에 자주 사용된다.

변수의 성격을 설명할 때 예로 자주 활용되는 코시(Cauchy) 분포의 확률밀도함수는 $\beta > 0, \alpha \in \mathbb{R}$ 일 때,

$$f(x;\alpha, \beta) = \frac{1}{\pi\beta\{1 + [(x-\alpha)/\beta]^2\}}, \quad -\infty < x < \infty \tag{2.60}$$

이다. 코시 확률밀도함수는 α에 대하여 대칭임에도 불구하고 평균과 그 이상의 적률이 존재하지 않는다. 적률이란 $E(X^k)$과 같은 형태의 기댓값으로 확률분포의 형태를 결정짓는 데에 중요한 역할을 하는 모수이다. 더 자세한 것은 2.8절에서 다루기로 한다. 이 외에도 대수정규(lognormal), 이중지수(double exponential), 로지스틱(logistic) 등의 분포가 있으나 여기서는 생략하기로 한다.

2.7 확률변수들의 함수

확률모형을 사용하여 변수들의 성질을 규명할 때, 때로는 실험에서 얻은 확률변수 X의 관찰값이 연구자의 궁극적인 목적이 아닐 수도 있고 다른 연구자가 X의 함수인

$Y=g(X)$에 관심이 있게 될 수도 있다. 예를 들어 두 확률변수 X와 Y를 구했을 때 그들의 합 $Z=g(X, Y)=X+Y$에 흥미를 가질 수도 있으며, 온도를 섭씨(X)로 쟀는데 이를 화씨($Y=9X/5+32$)로 변화시키는 것과 같은 측정단위의 변화도 생각할 수 있다. 특히 4장 이후에서 다루게 될 통계적 추론에서는 실험에서 얻은 확률변수들의 함수의 분포를 알아야 하며, 이를 위해서라도 그 일반적인 방법을 알아둘 필요가 있다. 그런데 확률변수의 함수 또는 변환된 확률변수의 분포를 직접 구하는 것은 대부분의 경우 비효율적이다. 그러므로 여기서는 원래의 확률밀도함수를 활용하여 변환된 변수의 확률밀도함수를 구하는 방법을 다루기로 한다.

2.7.1 누적분포함수를 이용한 방법

확률변수 X가 이산형인 경우에는 직접 대입하는 방법으로 $Y=g(X)$의 확률밀도함수를 구할 수 있다. 즉, X의 가능한 값들이 $x_1, x_2, \cdots$라고 하고, 그에 상응하는 Y의 값들을 $y_1=g(x_1), y_2=g(x_2), \cdots$라고 했을 때

$$f_Y(y_j)=P(Y=y_j)=P(g(X)=y_j)$$
$$=\sum_{\{i:\, g(x_i)=y_j\}} P(X=x_i)=\sum_{\{i:\, g(x_i)=y_j\}} f_X(x_i)$$

가 된다. 또한 Y의 확률분포함수로부터 식 (2.3)을 활용하여 확률밀도함수를 구하는 방법도 가능하다.

이제 연속형 확률변수 X가 누적분포함수 $F_X(x)$를 가지며 X의 함수인 $Y=g(X)$에 관심이 있다고 하자. 영역 $\{Y=g(X)\le y\}$를 $\{X\in R_y\}$ (단, $R_y=\{x: g(x)\le y\}$)로 표현하면 Y의 누적분포함수는

$$F_Y(y)=P(g(X)\le y)=P(X\in R_y)$$

가 성립한다. $P(X\in R_y)$는 X의 분포함수로부터 계산할 수 있으며, 이를 통해 $F_Y(y)$를 구할 수 있다. 예를 들어 R_y가 어떤 구간 $[x_1, x_2]$로 표현된다고 하자. 물론 x_i는 y에 의존한다. 이때 X가 연속형 확률변수이며 확률밀도함수가 $f_X(x)$이면 $Y=g(X)$의 확률분포함수는 $F_Y(y)=\int_{x_1}^{x_2} f_X(x)\,dx=F_X(x_2)-F_X(x_1)$이 되며, Y의 확률밀도함수 $f_Y(y)$는 $F_Y(y)$를 미분함으로써 구해진다.

예 2.39

확률변수 X의 확률밀도함수가 $f_X(x)$일 때, $Y=9X/5+32$의 확률밀도함수를 구해 보자(이 변환은 섭씨로 측정한 온도 X를 화씨로 변환하는 경우에 해당한다). Y의 확률분포함수는

$$\begin{aligned} F_Y(y) &= P(Y \le y) \\ &= P\left(X \le \frac{5(y-32)}{9}\right) \\ &= F_X\left(\frac{5(y-32)}{9}\right) \end{aligned}$$

이다. 따라서 정리 2.2에 의하여,

$$\begin{aligned} f_Y(y) &= \frac{d}{dy} F_Y(y) \\ &= \frac{5}{9} f_X\left(\frac{5(y-32)}{9}\right) \end{aligned}$$

가 된다.

예 2.40

변수 X의 확률밀도함수가 $f_X(x)$일 때, $Y=X^2$의 확률밀도함수를 구해 보자. Y의 확률분포함수는

$$\begin{aligned} F_Y(y) &= P(Y \le y) \\ &= P(X^2 \le y) \\ &= P(-\sqrt{y} \le X \le \sqrt{y}) \\ &= F_X(\sqrt{y}) - F_X(-\sqrt{y}) \end{aligned}$$

이므로,

$$\begin{aligned} f_Y(y) &= \frac{d}{dy}\left[F_X(\sqrt{y}) - F_X(-\sqrt{y})\right] \\ &= \frac{1}{2\sqrt{y}}\left[f_X(\sqrt{y}) + f_X(-\sqrt{y})\right] \end{aligned}$$

이다. 특별히 $X \sim N(0,1)$이라면, $f_X(\sqrt{y}) = f_X(-\sqrt{y}) = \frac{1}{\sqrt{2\pi}} e^{-y/2}$이므로 $f_Y(y) = \frac{1}{\sqrt{2\pi}} y^{-1/2} e^{-y/2}$, $y > 0$이며 Y는 GAM$(\frac{1}{2}, 2)$, 즉 자유도가 1인 카이제곱분포가 된다. 카이제곱분포에 대한 본격적인 내용은 3.2.1절에서 다루어진다.

예 2.41

확률변수 X가 $U(0, 1)$ 분포를 가졌을 때, $Y = -\lambda \ln X$ $(\lambda > 0)$의 확률밀도함수를 구해 보자. Y의 확률분포함수는

$$\begin{aligned} F_Y(y) &= P(Y \le y) \\ &= P(-\lambda \ln X \le y) \\ &= P(\ln X \ge -y/\lambda) \\ &= P[X \ge \exp(-y/\lambda)] \\ &= 1 - \exp(-y/\lambda) \end{aligned}$$

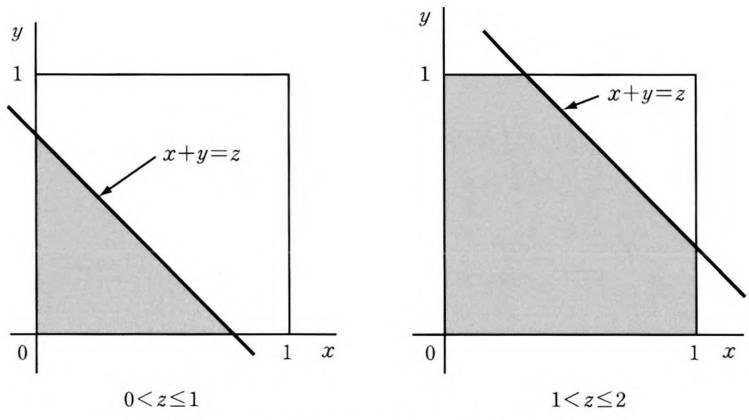
이다. $y/\lambda > 0$이므로 $\exp(-y/\lambda) < 1$이 됨을 유의하자. 따라서

$$\begin{aligned} f_Y(y) &= \frac{d}{dy} F_Y(y) \\ &= \frac{1}{\lambda} \exp(-y/\lambda) \end{aligned}$$

이다. 이는 모수가 λ인 지수 확률변수의 확률밀도함수이다.

예 2.42

독립인 두 확률변수 X와 Y가 $U(0, 1)$분포를 가질 때, $Z = X + Y$의 확률밀도함수를 구해 보자. 그런데 $f(x, y) = 1(0 < x, y < 1)$이므로 Z의 확률분포함수는 $F_Z(z) = P(X + Y \le z) = \iint_{\{(x,y) : x+y \le z\}} f(x,y)dxdy$로 구해진다. 이때 적분의 영역 $\{(x,y) : x + y \le z\}$는 아래 그림 2.6과 같이 구해지므로,



▸ **그림 2.6** ◂ $x+y \le z$의 영역

$$F_Z(z)=\begin{cases}0, & z \le 0\\ \displaystyle\int_0^z\int_0^{z-y} 1dxdy = z^2/2, & 0 < z \le 1\\ \displaystyle 1-\int_{z-1}^1\int_{z-y}^1 1dxdy = 1-(2-z)^2/2, & 1 < z \le 2\\ 1, & z \ge 2\end{cases}$$

로 구할 수 있다. 따라서, Z의 확률밀도함수는

$$f_Z(z)=\begin{cases}z, & 0 < z \le 1\\ 2-z, & 1 < z \le 2\\ 0, & \text{그 외의 경우}\end{cases}$$

으로 주어진다.

다음은 앞의 예들에 대한 내용의 일부를 정리한 것이다.

정리 2.23

확률변수 X의 확률밀도함수가 $f_X(x)$일 때 $Y=g(X)$라는 변환을 고려하자. 단, g는 $A=\{x: f_X(x)>0\}$ 에서 $B=\{y: f_Y(y)>0\}$ 으로의 1 : 1 함수이며, 그의 역함수를 $x=g^{-1}(y)$라고 한다. 만일 B상에서 $dg^{-1}(y)/dy \neq 0$이라면 Y의 확률밀도함수는

$$f_Y(y)=f_X(g^{-1}(y))\,|dg^{-1}(y)/dy| \quad y \in B$$

로 주어진다.

증명 $y=g(x)$가 1 : 1이므로 함수 $g(x)$는 단조증가이거나 단조감소이다. 단조증가인 경우를 고려하면, $g(x)\le y$일 필요충분조건은 $x\le g^{-1}(y)$이다. 따라서

$$F_Y(y)=P[g(X)\le y]=P[X\le g^{-1}(y)]=F_X(g^{-1}(y))$$

이고 $dg^{-1}(y)/dy>0$이므로 (g가 단조증가이면 g^{-1}도 단조증가)

$$f_Y(y)=(d/dy)F_X(g^{-1}(y))=f_X(g^{-1}(y))\,|dg^{-1}(y)/dy|$$

이다. 단조감소인 경우의 증명도 마찬가지 방법을 사용할 수 있다. ■

앞의 예 2.39에서는 $g^{-1}(y)=\frac{5}{9}(y-32)$, 예 2.41에서는 $g^{-1}(y)=\exp(-y/\lambda)$와 같은 1 : 1 함수가 존재하므로 확률변수 $Y=g(X)$의 확률밀도함수를 정리 2.23을 활용하여 구해도 되며, 결과는 동일하다. 한편, 예 2.40에서는 $g(x)$가 1 : 1 함수가 아니므로 정리 2.23을 직접적으로 사용할 수는 없으나, 정의역을 $g(x)$가 1 : 1이 되는 몇 개의 영역으로 나누어 고려하면 정리의 내용을 활용할 수 있다.

2.7.2 결합변환

여기서는 앞에서 다룬 확률변수의 변환을 좀 더 일반화시켰을 경우에 대하여 고려하기로 하자. 먼저, n차원 확률벡터 $\boldsymbol{X}=(X_1,\cdots,X_n)$의 변환된 $k\le n$개의 확률변수 $Y_1=g_1(X_1,\cdots,X_n),\cdots,Y_k=g_k(X_1,\cdots,X_n)$가 있다고 하자(편의상, 이와 같은 변환을 $\boldsymbol{Y}=g(\boldsymbol{X})$로 표기한다). 이제, 확률벡터 $\boldsymbol{X}=(X_1,\cdots,X_n)$의 결합 확률밀도함수가 $f_{X_1,\cdots,X_n}(x_1,\cdots,x_n)$일 때, k차원 확률벡터 $\boldsymbol{Y}=(Y_1,\cdots,Y_k)$의 결합 확률밀도함수를 구하고자 한다. 우선 $k=n$인 이산형 확률벡터의 결합변환에 대해 고려해 보자. $k<n$인 경우에는 $n-k$개의 새로운 변수들을 추가해서 n차원에서 n차원으로의 변환을 고려하여 $Y_1,\cdots,Y_n$의 결합분포를 구한 다음, $Y_1,\cdots,Y_k$의 주변분포를 구하면 된다.

정리 2.24

이산형 확률벡터 $\boldsymbol{X}$의 확률밀도함수를 $f(\boldsymbol{x})$라고 했을 때, $\boldsymbol{Y}=g(\boldsymbol{X})$가 1 : 1 변환이면 확률벡터 $\boldsymbol{Y}$의 결합 확률밀도함수는

$$f_{\boldsymbol{Y}}(y_1, y_2, \cdots, y_n) = f_{\boldsymbol{X}}(x_1, x_2, \cdots, x_n)$$

이다. 단, $x_1, x_2, \cdots, x_n$는 $\boldsymbol{y} = g(\boldsymbol{x})$의 해로서 $y_1, y_2, \cdots, y_n$에 의존함.

증명 $\boldsymbol{Y} = g(\boldsymbol{X})$가 1 : 1 변환이므로 자명하다. ■

정리 2.24에서, 만일 $\boldsymbol{Y} = g(\boldsymbol{X})$가 1 : 1 변환이 아니면, X의 전체영역을 몇 개의 겹치지 않는 부분영역 $A_1, A_2, \cdots$로 나누어 각 영역 A_j상에서 $\boldsymbol{y} = g(\boldsymbol{x})$가 유일해 $\boldsymbol{x} = \boldsymbol{x}_j = (x_{1j}, \cdots, x_{nj})$를 갖도록 하여

$$\begin{aligned} f_Y(y_1, \cdots, y_n) &= P(g(\boldsymbol{X}) = \boldsymbol{y}) \\ &= \sum_j P(g(\boldsymbol{X}) = \boldsymbol{y}, \boldsymbol{X} \in A_j) \\ &= \sum_j P(X_1 = x_{1j}, \cdots, X_k = x_{nj}) \\ &= \sum_j f_X(x_{1j}, \cdots, x_{nj}) \end{aligned}$$

의 형태로 구할 수 있다.

예 2.43

X_1, X_2의 결합 확률밀도함수가 다음과 같이 주어져 있다고 하자.

(x_1, x_2)	(0,0)	(0,1)	(1,0)	(1,1)
$f_{X_1, X_2}(x_1, x_2)$	1/4	1/4	1/4	1/4

이제 변환된 확률변수

$$Y_1 = g_1(X_1, X_2) = X_1 + X_2 \text{와 } Y_2 = g_2(X_1, X_2) = X_1 X_2$$

의 결합 확률밀도함수를 구해 보자. 이때 $g(x_1, x_2) = (0,0)$이거나 $g(x_1, x_2) = (2,1)$이 되는 (x_1, x_2)는 하나씩이지만 $g(x_1, x_2) = (1,0)$으로 만드는 (x_1, x_2)는 $(0,1)$과 $(1,0)$ 두 개이므로 (Y_1, Y_2)의 결합 확률밀도함수는 다음과 같이 구해진다.

$$f_{Y_1, Y_2}(0,0) = f_{X_1, X_2}(0,0) = 1/4$$

$$f_{Y_1,\,Y_2}(1,0) = f_{X_1,\,X_2}(0,1) + f_{X_1,\,X_2}(1,0) = 1/2$$
$$f_{Y_1,\,Y_2}(2,1) = f_{X_1,\,X_2}(1,1) = 1/4$$

예 2.44

X_1, X_2, X_3의 결합 확률밀도함수가 다음과 같이 주어졌다고 하자.

$(x_1,\ x_2,\ x_3)$	(0,0,0)	(0,0,1)	(0,1,1)	(1,0,1)	(1,1,0)	(1,1,1)
$f_{X_1,\,X_2,\,X_3}(x_1,\ x_2,\ x_3)$	3/8	1/8	1/8	1/8	1/8	1/8

이제 변환된 확률변수

$$Y_1 = g_1(X_1, X_2, X_3) = X_1 + X_2 + X_3 \text{과}$$
$$Y_2 = g_1(X_1, X_2, X_3) = |X_3 - X_2|$$

의 결합 확률밀도함수는 다음과 같이 구해진다. 이 변환 역시 예 2.43에서와 같이 1 : 1 변환이 아님을 유의하자.

$$f_{Y_1,\,Y_2}(0,0) = f_{X_1,X_2,X_3}(0,0,0) = 3/8$$
$$f_{Y_1,\,Y_2}(1,1) = f_{X_1,X_2,X_3}(0,0,1) = 1/8$$
$$f_{Y_1,\,Y_2}(2,0) = f_{X_1,X_2,X_3}(0,1,1) = 1/8$$
$$f_{Y_1,\,Y_2}(2,1) = f_{X_1,X_2,X_3}(1,0,1) + f_{X_1,X_2,X_3}(1,1,0) = 2/8$$
$$f_{Y_1,\,Y_2}(3,0) = f_{X_1,X_2,X_3}(1,1,1) = 1/8$$

이제, 위에서 다룬 이산형 확률벡터가 아닌 n차원 연속형 확률벡터의 결합변환에 대해 고려해 보자. $A = \{(x_1, \cdots, x_n) : f_{X_1,\cdots,X_n}(x_1, \cdots, x_n) > 0\}$라고 표기하자. $k < n$이면, $n-k$개의 적절한 새로운 변수들 $Y_{k+1} = g_{k+1}(X_1, \cdots, X_n), \cdots, Y_n = g_n(X_1, \cdots, X_n)$을 선택하여 추가함으로써 n차원에서 n차원으로의 함수 $y_1 = g_1(x_1, \cdots, x_n), \cdots, y_{k+1} = g_{k+1}(x_1, \cdots, x_n), \cdots, y_n = g_n(x_1, \cdots, x_n)$을 고려하여 $Y_1, \cdots, Y_n$의 결합분포를 구하게 된다. 나아가 $Y_1, \cdots, Y_n$의 결합분포로부터

$Y_1, \cdots, Y_k$의 주변분포를 구할 수 있다.

연속형 확률변수에 대한 결합변환은 앞서 사용한 역함수의 미분값을 여러 개의 변수의 경우로 일반화한 자코비안(Jacobian)을 사용할 수 있다. n개의 변수의 변환인 $\boldsymbol{y} = g(\boldsymbol{x})$가 $\boldsymbol{x} = (x_1, x_2, \cdots, x_n)$이라는 유일해를 가질 때 자코비안($J$)은 아래와 같은 $n \times n$ 편미분행렬의 행렬값(determinant)이다.

$$J = \begin{vmatrix} \frac{\partial x_1}{\partial y_1} & \frac{\partial x_1}{\partial y_2} & \cdots & \frac{\partial x_1}{\partial y_n} \\ \frac{\partial x_2}{\partial y_1} & \frac{\partial x_2}{\partial y_2} & \cdots & \frac{\partial x_2}{\partial y_n} \\ \vdots & \vdots & \vdots & \vdots \\ \frac{\partial x_n}{\partial y_1} & \frac{\partial x_n}{\partial y_2} & \cdots & \frac{\partial x_n}{\partial y_n} \end{vmatrix} \tag{2.61}$$

위와 같은 내용을 가지고 n개의 확률변수에 대한 결합변환의 분포이론을 정리하면 다음과 같다.

정리 2.25

n개의 연속형 확률변수로 구성되어 있는 확률벡터 $\boldsymbol{X} = (X_1, X_2, \cdots, X_n)$에 대하여 $Y_i = g_i(\boldsymbol{X})$, $i = 1, 2, \cdots, n$ 이라는 결합변환된 확률변수들을 고려하자. $\boldsymbol{X}$는 결합 확률밀도함수 $f_{\boldsymbol{X}}(x_1, x_2, \cdots, x_n)$를 갖는데 전체영역 A상에서 이 확률밀도함수는 양(> 0)의 값을 가진다. 또, $(g_1, \cdots, g_n)$은 A상에 정의된 $1:1$ 변환이며 유일해 $x_i = h_i(y_1, \cdots, y_n), i = 1, \cdots, n$을 갖는다고 가정한다. 이제 자코비안 J가 변환의 범위에서 0이 아니면, 확률벡터 $\boldsymbol{Y}$의 결합 확률밀도함수는

$$f_{\boldsymbol{Y}}(y_1, y_2, \cdots, y_n) = f_{\boldsymbol{X}}(h_1(y_1, \cdots, y_n), \cdots, h_n(y_1, \cdots, y_n)) \, |J|$$

이다.

증명 정리 2.23의 증명방법을 n개의 확률변수로 확장하는 기법이 필요한데, 여기서는 생략하기로 한다. ■

예 2.45

X_1과 X_2가 서로 독립이고 평균이 $\lambda = 1$인 지수 확률변수라고 하면, 이들의 결합 확률밀도함수는 $f(x_1, x_2) = \exp(-x_1 - x_2),\ x_1 > 0,\ x_2 > 0$이 된다. 이제 결합변환된 두 변수 $Y_1 = X_1$과 $Y_2 = X_1 + X_2$를 고려하자. $(y_1, y_2) = g(x_1, x_2)$의 유일해는 $x_1 = h_1(y_1, y_2) = y_1,\ x_2 = h_2(y_1, y_2) = y_2 - y_1$이므로

$$J = \begin{vmatrix} 1 & 0 \\ -1 & 1 \end{vmatrix} = 1$$

이며, 결합 확률밀도함수는

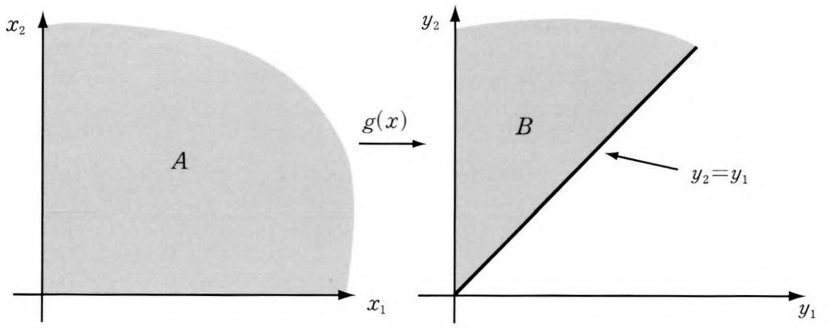
$$f_{Y_1, Y_2}(y_1, y_2) = f_{X_1, X_2}(y_1, y_2 - y_1)\,|J| = \exp(-y_2)$$

(단, $0 < y_1 < y_2 < \infty$)이다. 그러므로 Y_1과 Y_2의 주변 확률밀도함수는

$$f_{Y_1}(y_1) = \int_{y_1}^{\infty} \exp(-y_2)dy_2 = \exp(-y_1),\quad y_1 > 0$$

$$f_{Y_2}(y_2) = \int_{0}^{y_2} \exp(-y_2)dy_1 = y_2\exp(-y_2),\quad y_2 > 0$$

이 된다. 적분의 영역에 대해서는 다음 그림 2.7을 참조하면 된다.



▸ **그림 2.7** ◂ $(y_1, y_2) = (x_1, x_1 + x_2)$ 변환에 의한 영역

이제, 지수 확률변수 X_1, X_2에 대해 결합변환된 두 변수 $Y_1 = X_1 - X_2$와 $Y_2 = X_1 + X_2$를 고려하여 보자. $(y_1, y_2) = g(x_1, x_2)$의 유일해는

$$x_1 = h_1(y_1, y_2) = (y_1 + y_2)/2,\quad x_2 = h_2(y_1, y_2) = (y_2 - y_1)/2$$

이므로, 행렬값은

$$J=\begin{vmatrix} \frac{1}{2} & \frac{1}{2} \\ -\frac{1}{2} & \frac{1}{2} \end{vmatrix}=\frac{1}{2}$$

이며, Y_1과 Y_2의 결합 확률밀도함수는

$$f_{Y_1,\,Y_2}(y_1,\,y_2)=f_{X_1,\,X_2}\left(\frac{y_1+y_2}{2},\ \frac{y_2-y_1}{2}\right)|J|=\frac{\exp(-y_2)}{2}$$

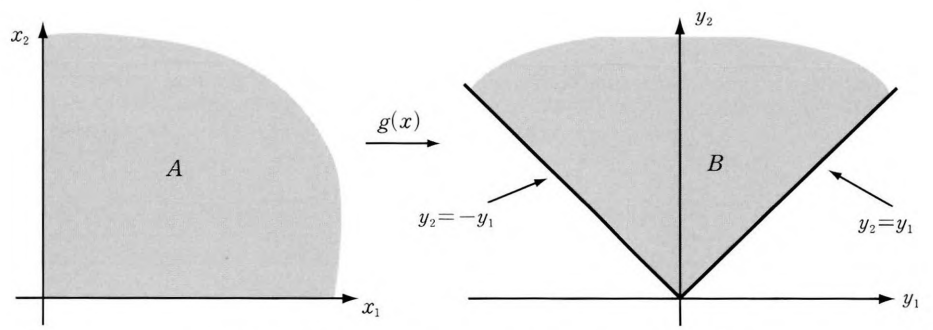
(단, $x_1=\dfrac{y_1+y_2}{2}>0$과 $x_2=\dfrac{y_2-y_1}{2}>0$으로부터 $-y_2<y_1<y_2,\ y_2>0$)이다.
그러므로 주변 확률밀도함수는

$$f_{Y_1}(y_1)=\begin{cases}\displaystyle\int_{-y_1}^{\infty}\frac{\exp(-y_2)}{2}\,dy_2, & y_1<0\\ \displaystyle\int_{y_1}^{\infty}\frac{\exp(-y_2)}{2}\,dy_2, & y_1>0\end{cases}$$

$$=\begin{cases}\exp(y_1)/2, & y_1<0\\ \exp(-y_1)/2, & y_1>0\end{cases}$$

$$f_{Y_2}(y_2)=\int_{-y_2}^{y_2}\frac{\exp(-y_2)}{2}dy_1=y_2\exp(-y_2),\qquad y_2>0$$

가 된다. 변수 Y_2의 주변 확률밀도함수는 앞부분에서 구한 것과 일치함을 볼 수 있다(적분의 영역에 대해서는 그림 2.8 참조).



▸ **그림 2.8** ◂ $(y_1,\,y_2)=(x_1-x_2,\ x_1+x_2)$의 변환에 의한 영역

예 2.46

확률변수 X_1과 X_2가 표준정규분포를 따르며 서로 독립이라 하고, 결합변환된 두 변수 $Y_1 = X_1 + X_2$와 $Y_2 = X_1/X_2$을 고려하자. 그런데, $(y_1, y_2) = g(x_1, x_2)$의 유일해는

$$x_1 = h_1(y_1, y_2) = \frac{y_1 y_2}{1+y_2}, \quad x_2 = h_2(y_1, y_2) = \frac{y_1}{1+y_2}$$

이므로 행렬값은

$$J = \begin{vmatrix} \dfrac{y_2}{1+y_2} & \dfrac{y_1}{(1+y_2)^2} \\ \dfrac{1}{1+y_2} & \dfrac{-y_1}{(1+y_2)^2} \end{vmatrix} = -\frac{y_1(y_2+1)}{(1+y_2)^3} = -\frac{y_1}{(1+y_2)^2}$$

이며, Y_1과 Y_2의 결합 확률밀도함수는

$$\begin{aligned} f_{Y_1, Y_2}(y_1, y_2) &= \frac{|y_1|}{(1+y_2)^2}\frac{1}{2\pi}\exp\left\{-\frac{1}{2}\left[\frac{(y_1 y_2)^2}{(1+y_2)^2} + \frac{y_1^2}{(1+y_2)^2}\right]\right\} \\ &= \frac{1}{2\pi}\frac{|y_1|}{(1+y_2)^2}\exp\left[-\frac{1}{2}\frac{(1+y_2^2)y_1^2}{(1+y_2)^2}\right] \end{aligned}$$

가 된다. 물론 Y_1은 두 독립인 표준정규 확률변수의 합이므로 $N(0, 2)$분포를 따르며, Y_2의 확률밀도함수는 다음과 같이 구할 수 있다.

$$\begin{aligned} f_{Y_2}(y_2) &= \int_{-\infty}^{\infty} f_{Y_1, Y_2}(y_1, y_2)\, dy_1 \\ &= \frac{1}{2\pi}\frac{1}{(1+y_2)^2}\int_{-\infty}^{\infty} |y_1| \exp\left[-\frac{1}{2}\frac{(1+y_2^2)y_1^2}{(1+y_2)^2}\right] dy_1 \\ &= \frac{1}{2\pi}\frac{1}{(1+y_2)^2}\, 2\int_0^{\infty} y_1 \exp\left[-\frac{1}{2}\frac{(1+y_2^2)y_1^2}{(1+y_2)^2}\right] dy_1. \end{aligned}$$

여기서,

$$u = \frac{(1+y_2^2)}{2(1+y_2)^2} y_1^2$$

이라 하면,

$$du = \frac{(1+y_2^2)}{(1+y_2)^2} y_1 dy_1$$

이므로

$$f_{Y_2}(y_2) = \frac{1}{2\pi} \times \frac{1}{(1+y_2)^2} \times \frac{(1+y_2)^2}{1+y_2^2} \times 2\int_0^\infty e^{-u} du$$

$$= \frac{1}{\pi} \frac{1}{1+y_2^2}, \qquad -\infty < y_2 < \infty$$

을 구할 수 있다. 이는 코시 확률밀도함수이며, 따라서 서로 독립인 두 표준정규 확률변수의 비는 코시 분포를 따름을 알 수 있다.

합성곱 형식(convolution formula)

서로 독립인 두 확률변수 X, Y의 합 $Z = X + Y$의 분포는 다음의 정리를 활용하면 쉽게 구할 수 있다.

정리 2.26

서로 독립인 두 확률변수 X, Y의 확률밀도함수가 각각 $f_X(x)$, $f_Y(y)$일 때, 두 변수의 합 $Z = X + Y$의 확률밀도함수는 다음과 같이 주어진다.

(1) 두 변수 X, Y가 이산형인 경우: $f_Z(z) = \sum_{\text{모든 } x} f_X(x) f_Y(z-x)$

(2) 두 변수 X, Y가 연속형인 경우: $f_Z(z) = \int_{-\infty}^{\infty} f_X(x) f_Y(z-x)\, dx$

증명 편의상 연속인 경우만 고려하면 다음과 같다. $Z = X + Y$의 확률분포함수는, 이중기댓값 정리에 의하여

$$P(Z \le z) = \int_{-\infty}^{\infty} P(X + Y \le z \mid X = x) f_X(x)\, dx$$

$$= \int_{-\infty}^{\infty} P(x + Y \le z) f_X(x)\, dx$$

$$= \int_{-\infty}^{\infty} F_Y(z-x) f_X(x)\, dx$$

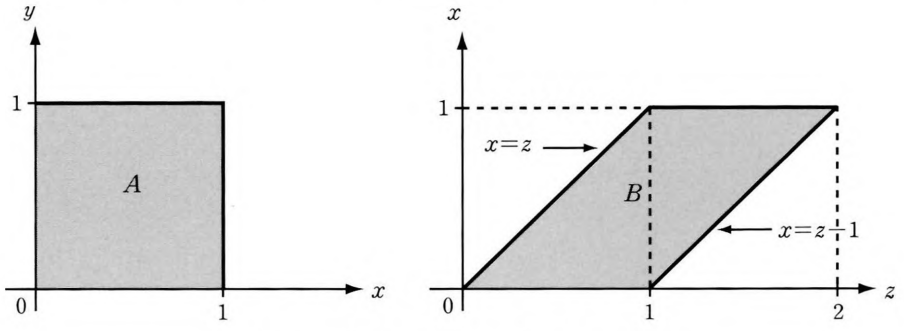
로 주어진다. 두 번째 등식은 X와 Y가 독립이므로 성립한다. 따라서 $Z=X+Y$의 확률밀도함수는

$$\begin{aligned} f(z) &= \frac{dF_Z(z)}{dz} \\ &= \frac{d}{dz}\left[\int_{-\infty}^{\infty} F_Y(z-x) f_X(x)\, dx\right] \\ &= \int_{-\infty}^{\infty} \frac{dF_Y(z-x)}{dz} f_X(x)\, dx \\ &= \int_{-\infty}^{\infty} f_X(x) f_Y(z-x)\, dx \end{aligned}$$

가 된다. ■

예 2.47

서로 독립인 확률변수 X와 Y가 공통분포 $U(0, 1)$을 가졌다고 할 때 $Z=X+Y$의 확률밀도함수를 구해 보자. 이 문제는 누적분포함수를 이용하여 풀 수도 있고(예 2.42) 결합변환을 활용하거나 정리 2.26을 이용할 수도 있다.



▸ **그림 2.9** ◂ $(x,y)\to(z=x+y,\ x)$ 변환에 의한 영역

우선, 결합변환을 이용하여 Z의 확률밀도함수를 구해 보자. $U=X$라 놓고 (X, Y)에서 (Z, U)로의 변환을 고려하면, $(z,u)=g(x,y)$의 유일해는 $x=h_1(z,u)=u$, $y=h_2(z,u)=z-u$이므로

$$J=\begin{vmatrix} 0 & 1 \\ 1 & -1 \end{vmatrix} = -1$$

이 되며

$$f_{Z,U}(z,u) = f_{X,Y}(u, z-u)|J| = 1, \quad 0 < u < 1, u < z < 1+u$$

이다. 주어진 z에 대해 $\max\{0, z-1\} < u < \min\{1, z\}$일 때 $f_{Z,U}(z,u) > 0$이므로

$$f_Z(z) = \begin{cases} \int_0^z du = z, & 0 < z \le 1 \\ \int_{z-1}^1 du = 2-z, & 1 < z \le 2 \\ 0, & \text{그 외} \end{cases}$$

가 된다.

이제, 정리 2.26을 사용해 보자. $0 \le Z \le 2$임을 주지하여 적분의 영역에 주의할 필요가 있으며(참조: 그림 2.9), 지시함수의 사용은 예 2.28과 동일하다.

$$\begin{aligned} f_Z(z) &= \int_{-\infty}^{\infty} f_Y(z-x) f_X(x)\, dx \\ &= \int_{-\infty}^{\infty} I_{(0,1)}(z-x)\, I_{(0,1)}(x)\, dx \\ &= \int_{-\infty}^{\infty} \{I_{(0,z)}(x)\, I_{(0,1)}(z) + I_{(z-1,1)}(x)\, I_{[1,2)}(z)\}\, dx \\ &= I_{(0,1)}(z) \int_0^z dx + I_{[1,2)}(z) \int_{z-1}^1 dx \\ &= z\, I_{(0,1)}(z) + (2-z)\, I_{[1,2)}(z) \\ &= \begin{cases} z, & 0 < z \le 1 \\ 2-z, & 1 < z \le 2 \\ 0, & \text{그 외} \end{cases} \end{aligned}$$

로 앞에서 구한 식과 같아진다.

2.8 적률생성함수

확률변수의 적률(moment)은 분포형태를 결정짓는 데 매우 중요한 역할을 한다. 분포의 특징을 설명하는 평균이나 분산은 물론 여기에서 다룰 왜도, 첨도 등도 역시 적률의 함수이다. 여기서는 이러한 적률을 생성하는 함수에 대해 알아보기로 한다. 이는 확률변수의 형태를 결정지으며, 확률변수들의 합에 대한 분포를 알아내는 데 매우 유용하다.

정의 2.15

확률변수 X의 함수 $g(X)=X^r$에 대한 기댓값

$$\mu_r{}' = E[X^r]$$

을 X의 **r차 적률**(r^{th} moment)이라고 하며,

$$\mu_r = E[(X-\mu)^r]$$

을 평균 $\mu=E(X)$에 대한 X의 **r차 중심적률**(r^{th} central moment)이라 정의한다.

이와 같이 정의된 중심적률 중에서 μ_3은 확률밀도함수의 비대칭성을 재는 척도로서 **왜도**(skewness)라고 하며, μ_4는 꼬리의 두께를 재는 척도로서 **첨도**(kurtosis)라고 한다. 그런데 왜도는 측정단위에 의존하므로 σ^3으로 나누는 변환을 통하여 단위를 없앤 μ_3/σ^3을 왜도계수라고 한다. 첨도의 경우도 σ^4으로 나누어 단위에 의존하지 않게 하는데 여기에서 3을 뺀 μ_4/σ^4-3을 첨도계수라고 한다. 이때 3을 빼는 이유는 정규분포의 경우 μ_4/σ^4의 값이 항상 3이 되기 때문인데, 이로써 첨도를 비교하는 데에 있어서 정규분포가 기준이 될 수 있다. 한편, 만약 k차 적률이 존재하면 k보다 작은 차수의 적률은 항상 존재하게 된다.

적률 이외에 분포형태를 특정 짓는 몇 가지의 척도를 소개하면 다음과 같다. 우선, 확률변수 X의 q번째 **분위수**(quantile)는 $F_X(\zeta)\geq q$를 만족하는 가장 작은 ζ로 정의되며 ζ_q로 표기하기로 한다. 특별히 분위수 중에서 $q=0.5$인 경우를 **중위수**(median)라고 하며 $\text{med}(X)$로 표기하기로 한다. 또 확률밀도함수 $f_X(x)$의 값을 최대화하는 x값을 **최빈값**(mode)이라 하는데, 이것은 이미 소개된 평균이나 중위수와 함께 확률변수 X의 확률밀도함수의 위치를 대표하는 값으로 활용될 수 있다.

주 때로 μ_3/σ^3과 μ_4/σ^4을 각각 왜도와 첨도라고 하기도 하며 μ_4/σ^4-3은 정규분포의 첨도를 초과하는 정도를 나타내기 때문에 초과첨도(excess kurtosis)라고 하기도 한다. q번째 분위수는 $(100q)$번째 백분위수(percentile)라고도 한다.

이제, 확률변수 X의 특별한 함수꼴에 대한 기댓값으로 나타내지는 적률생성함수(moment generating function)를 정의하도록 하자.

정의 2.16

어떤 $h > 0$에 대하여 $-h < t < h$를 만족하는 모든 t에서 $E(e^{tX}) < \infty$일 때,

$$M_X(t) = E[\exp(tX)]$$

를 확률변수 X의 **적률생성함수**라고 한다.

예 2.48

이항확률변수 $X \sim B(n, p)$의 적률생성함수는 다음과 같다.

$$M_X(t) = E(e^{tX}) = \sum_{x=0}^{n} e^{tx} \binom{n}{x} p^x (1-p)^{n-x} = \sum_{x=0}^{n} \binom{n}{x} (pe^t)^x (1-p)^{n-x}$$
$$= (1-p+pe^t)^n.$$

여기에서 마지막 등식은 이항정리를 이용하여 얻었다.

예 2.49

지수 확률변수 $X \sim \mathrm{EXP}(\lambda)$의 적률생성함수는 다음과 같다.

$$M_X(t) = E(e^{tX}) = \int_0^{\infty} \exp(tx) \cdot \left(\frac{1}{\lambda}\right) \exp(-x/\lambda)\, dx$$
$$= \int_0^{\infty} \left(\frac{1}{\lambda}\right) \exp\{(t-1/\lambda)x\}\, dx$$
$$= \frac{1}{\lambda t - 1} \cdot [\exp\{(t-1/\lambda)x\}]_0^{\infty}$$
$$= \frac{1}{\lambda t - 1} \cdot \left[\lim_{x \to \infty} \exp\{(t-1/\lambda)x\} - 1\right]$$
$$= \frac{1}{1-\lambda t}, \qquad t < \frac{1}{\lambda}.$$

$t \geq \frac{1}{\lambda}$이면 적분이 유한하지 않아서 $E(e^{tX})$가 정의될 수 없다. 그러나 $\frac{1}{\lambda}$이 양의 값을 가지므로 정의 2.16에 의해 지수 확률분포의 적률생성함수는 존재한다.

예 2.50

표준정규 확률변수 $Z \sim N(0,1)$의 적률생성함수는 다음과 같다. 이 경우 $E(e^{tX})$는 모든 실수값 t에서 존재한다.

$$\begin{aligned} M_Z(t) &= \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} \exp(tz)\exp(-z^2/2)\,dz \\ &= \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} \exp\{-(z-t)^2/2 + t^2/2\}\,dz \\ &= \exp(t^2/2) \end{aligned}$$

예 2.51

감마확률변수 $X \sim \mathrm{GAM}(k, \theta)$의 적률생성함수는 다음과 같다.

$$\begin{aligned} M_X(t) &= \int_0^{\infty} \exp(tx) \frac{1}{\theta^k \Gamma(k)} x^{k-1} \exp(-x/\theta)\,dx \\ &= \frac{1}{\theta^k \Gamma(k)} \int_0^{\infty} x^{k-1} \exp\{(t-1/\theta)x\}\,dx \\ &\quad (u = -(t-1/\theta)x \text{라는 변환을 하면}) \\ &= (1/\theta - t)^{-k} \frac{1}{\theta^k \Gamma(k)} \int_0^{\infty} u^{k-1} \exp(-u)\,du \\ &= (1-\theta t)^{-k}, \qquad t < 1/\theta. \end{aligned}$$

이제 적률생성함수의 성질들을 살펴보고 그에 대한 활용을 고려하기로 한다. 먼저, 다음 정리 2.27은 적률생성함수가 이름 그대로 적률을 계산하는 데 쉽게 사용될 수 있음을 보여 주는데, 적률생성함수의 $t=0$에서의 r차 미분값이 r차 적률과 동일하다는 것이다.

정리 2.27

확률변수 X의 적률생성함수를 $M_X(t)$라고 하면,

$$M_X^{(r)}(0) = E(X^r)$$

이 성립한다.

증명 $r=1$, 2인 경우에 대해서만 증명하기로 한다. 먼저, $r=1$인 경우,

$$\begin{aligned} M_X^{(1)}(0) &= \frac{d}{dt}\int_{-\infty}^{\infty} \exp(tx) f_X(x)\,dx \Big|_{t=0} \\ &= \int_{-\infty}^{\infty} \frac{d}{dt}\exp(tx)\Big|_{t=0} f_X(x)\,dx \\ &= \int_{-\infty}^{\infty} x f_X(x)\,dx \\ &= E(X) \end{aligned}$$

가 성립한다. 다음으로, $r=2$인 경우에는

$$\begin{aligned} M_X^{(2)}(0) &= \frac{d^2}{dt^2}\int_{-\infty}^{\infty} \exp(tx) f_X(x)\,dx \Big|_{t=0} \\ &= \int_{-\infty}^{\infty} \frac{d^2}{dt^2}\exp(tx)\Big|_{t=0} f_X(x)\,dx \\ &= \int_{-\infty}^{\infty} x^2 \exp(tx)\Big|_{t=0} f_X(x)\,dx \\ &= E(X^2) \end{aligned}$$

이 마찬가지로 성립한다. 위의 결과를 얻기 위해서는 미분과 적분의 순서를 바꾸어야 하는데, 이 경우와 같이 적률생성함수가 존재하면 그 순서를 바꿀 수 있음이 알려져 있다. ■

예 2.52

적률생성함수를 활용한 이항확률변수 $X \sim B(n, p)$의 평균과 분산은 다음과 같이 계산된다. 예 2.48로부터 $M_X(t) = (1-p+pe^t)^n$이므로

$$\begin{aligned} M_X{}^{(1)}(t) &= n(q+pe^t)^{n-1} \cdot pe^t \quad (\text{단, } p+q=1) \\ M_X{}^{(2)}(t) &= n(q+pe^t)^{n-1} \cdot pe^t + pe^t \cdot n(n-1)(q+pe^t)^{n-2} pe^t \end{aligned}$$

이고,

$$M_X{}^{(1)}(0) = n(q+p)^{n-1} p$$

$$= np$$
$$= E(X)$$

$$M_X{}^{(2)}(0) = n(q+p)^{n-1} \cdot p + pn(n-1)(q+p)^{n-2}p$$
$$= np + p^2 n(n-1)$$
$$= E(X^2)$$

이 된다. 그러므로

$$Var(X) = np + p^2 n(n-1) - (np)^2$$
$$= np - np^2$$
$$= np(1-p)$$

이다.

다음의 정리는 확률변수의 분포형태가 적률생성함수에 의하여 유일하게 결정됨을 보여 준다. 이러한 사실은 분포의 형태가 적률에 의해 표현된다는 점으로 미루어 짐작될 수 있다. 증명은 이 책의 수준에서 벗어나므로 증명 없이 받아들이기로 한다.

정리 2.28

확률변수 X와 Y가 같은 적률생성함수를 가지면 두 확률변수는 같은 확률밀도함수를 가진다.

예 2.53

$X \sim \mathrm{EXP}(\lambda)$이면, $M_X(t) = \dfrac{1}{1-\lambda t}$, $t < \dfrac{1}{\lambda}$이다. 그런데, $Y = aX$의 적률생성함수는

$$M_Y(t) = E(e^{taX}) = \int_0^\infty \exp(tax)\left(\frac{1}{\lambda}\right)\exp(-x/\lambda)\,dx$$
$$= \int_0^\infty \left(\frac{1}{\lambda}\right)\exp\{(ta - 1/\lambda)x\}\,dx$$
$$= \frac{1}{1-\lambda a t}, \qquad t < \frac{1}{\lambda a}.$$

이 된다(예 2.49 참조). 이는 모수가 $a\lambda$인 지수 확률변수의 적률생성함수이며, 따라서 $Y \sim \mathrm{EXP}(a\lambda)$이다. 이와 같은 결과는 물론 변수변환을 활용해서도 쉽게 얻을 수 있다.

예 2.54

확률변수 X가 표준정규분포 $N(0,1)$을 따른다고 한다. 여기에서 $Y = X^2$의 분포를 구해 보자.

$$\begin{aligned} M_Y(t) &= E(e^{tY}) = E(e^{tX^2}) \\ &= \int_{-\infty}^{\infty} \exp(tx^2) \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) dx \\ &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} \exp\left[-\frac{1}{2}x^2(1-2t)\right] dx \\ &= (1-2t)^{-1/2} \frac{1}{\sqrt{2\pi} \cdot (1-2t)^{-1/2}} \int_{-\infty}^{\infty} \exp\left[-\frac{1}{2}x^2(1-2t)\right] dx \\ &= (1-2t)^{-1/2}, \qquad t < 1/2. \end{aligned}$$

마지막 등식은 $\frac{1}{\sqrt{2\pi} \cdot (1-2t)^{-1/2}} \exp\left[-\frac{1}{2}x^2(1-2t)\right]$가 $N(0,(1-2t)^{-1})$의 확률밀도함수임을 이용하여 얻을 수 있다. Y의 적률생성함수가 $\mathrm{GAM}(1/2, 2)$ 분포, 즉 자유도가 1인 카이제곱분포의 그것과 같으므로 정리 2.28에 의하여 Y는 자유도가 1인 카이제곱분포를 따른다.

예 2.55

확률변수 X가 $\mathrm{GAM}(k, \theta)$ 분포를 따른다고 하자. 이제 $Y = 2X/\theta$의 분포를 구해 보자. 그런데, $t < 1/2$에서

$$\begin{aligned} M_Y(t) &= E(e^{tY}) \\ &= E\left[\exp\left(\frac{2t}{\theta}X\right)\right] \\ &= \left(\frac{1}{1-\theta(2t/\theta)}\right)^k \end{aligned}$$

$$= (1-2t)^{-2k/2},$$

이므로 $Y = \frac{2X}{\theta}$는 자유도가 $2k$인 카이제곱분포를 가진다(예 2.51 참조).

● 독립확률변수들의 합의 분포

통계모형의 사용에 있어서 많은 경우 여러 개의 독립인 확률변수들의 합의 꼴로 표현되는 통계량에 관심이 있게 된다. 그러한 경우 유용하게 사용할 수 있도록 확률변수들의 선형변환과 합에 대한 적률생성함수의 활용을 살펴보기로 하자. 이에 대한 내용은 다음 정리 2.29와 같다.

정리 2.29

(1) 확률변수 X의 적률생성함수가 $M_X(t)$이면, 확률변수 $Y = aX + b$의 적률생성함수는 $M_Y(t) = e^{bt} M_X(at)$이다.

(2) 확률변수 $X_i (i = 1, 2, \cdots, n)$가 서로 독립이고 각각 적률생성함수 $M_{X_i}(t)$를 가진다고 할 때 $Y = X_1 + X_2 + \cdots + X_n$의 적률생성함수는 $M_Y(t) = M_{X_1}(t) M_{X_2}(t) \cdots M_{X_n}(t)$로 주어진다.

증명 (1) $M_Y(t) = E(e^{tY}) = E[e^{t(aX+b)}]$

$$= e^{bt} E(e^{atX}) = e^{bt} M_X(at)$$

(2) $M_Y(t) = E(e^{tY}) = E(e^{tX_1} e^{tX_2} \cdots e^{tX_n})$

$$= E(e^{tX_1}) E(e^{tX_2}) \cdots E(e^{tX_n}) (\because e^{tX}\text{가 서로 독립이므로})$$

$$= M_{X_1}(t) M_{X_1}(t) \cdots M_{X_n}(t)$$ ■

이제 정리 2.28과 정리 2.29의 (2)를 이용하면 통계이론에 자주 사용되는 몇 가지 중요한 분포들을 비교적 쉽게 구할 수 있다. 이는 적률생성함수의 유용성을 잘 보여준다.

예 2.56

$X_1, \cdots, X_n$ 이 서로 독립이고 성공률이 p로 같은 베르누이 확률변수라고 하자(즉, $P(X_i = 1) = p,\ P(X_i = 0) = 1 - p,\ i = 1, \cdots, n$).

$$M_{X_i}(t) = pe^t + q \qquad (p + q = 1)$$

이므로, $Y = X_1 + \cdots + X_n$이라고 하면

$$\begin{aligned} M_Y(t) &= \prod_{i=1}^{n} M_{X_i}(t) \\ &= (pe^t + q)^n \end{aligned}$$

이 되며, 이는 이항확률변수 $B(n, p)$의 적률생성함수이다. 따라서 $Y \sim B(n, p)$이다.

예 2.57

$X_1, \cdots, X_n$ 이 서로 독립이며 $X_i (i = 1, \cdots, n)$는 각각 평균이 λ_i인 포아송 분포를 따른다고 하자.

$$\begin{aligned} M_{X_i}(t) &= E(e^{tX_i}) \\ &= \sum_{x=0}^{\infty} e^{tx} \frac{\exp(-\lambda_i)\lambda_i^x}{x!} \\ &= \exp(-\lambda_i) \sum_{x=0}^{\infty} \frac{(\lambda_i e^t)^x}{x!} \\ &= \exp\{\lambda_i(e^t - 1)\} \end{aligned}$$

이므로, $Y = X_1 + \cdots + X_n$이라고 하면

$$\begin{aligned} M_Y(t) &= \prod_{i=1}^{n} M_{X_i}(t) \\ &= \exp\left\{\sum_{i=1}^{n} \lambda_i(e^t - 1)\right\} \end{aligned}$$

이 되며, 이는 평균이 $\sum_{i=1}^{n} \lambda_i$인 포아송 확률변수의 적률생성함수이다. 따라서 $Y \sim \mathrm{POI}\left(\sum_{i=1}^{n} \lambda_i\right)$이다.

예 2.58

$X_1, \cdots, X_n$이 서로 독립이며 $X_i (i = 1, \cdots, n)$는 모두 평균이 λ인 지수분포를 따른다고 하자. 이제

$$M_{X_i}(t) = \frac{1}{1-\lambda t}, \qquad t < \frac{1}{\lambda}$$

이므로(참조: 예 2.49), $Y = X_1 + \cdots + X_n$이라고 하면

$$\begin{aligned} M_Y(t) &= \prod_{i=1}^{n} M_{X_i}(t) \\ &= \left(\frac{1}{1-\lambda t}\right)^n, \qquad t < \frac{1}{\lambda} \end{aligned}$$

이며, 이는 $\mathrm{GAM}(n, \lambda)$ 확률변수의 적률생성함수이다. 그러므로 $Y \sim \mathrm{GAM}(n, \lambda)$이다.

예 2.59

$X_1, \cdots, X_n$이 서로 독립이며 $X_i \sim N(\mu_i, \sigma_i^2)$이라고 하자. 예 2.50에서 $Z \sim N(0,1)$일 때 $M_Z(t) = e^{t^2/2}$임을 보였고, $X \sim N(\mu, \sigma^2)$이면 그 적률생성함수는

$$\begin{aligned} M_X(t) &= \int_{-\infty}^{\infty} e^{tx} \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx \\ &= \int_{-\infty}^{\infty} e^{t(\mu+\sigma z)} \frac{1}{\sqrt{2\pi}} e^{-z^2/2} dz \qquad \left(z = \frac{x-\mu}{\sigma}\right) \\ &= e^{\mu t} M_Z(\sigma t) = e^{\mu t + \frac{1}{2}\sigma^2 t^2} \end{aligned}$$

이 된다. $Y = \sum_{i=1}^{n} a_i X_i$라고 하면 $E(e^{t(aX)}) = E(e^{atX}) = e^{a\mu t + \sigma^2 a^2 t^2/2}$으로부터

$$\begin{aligned} M_Y(t) &= \prod_{i=1}^{n} M_{a_i X_i}(t) \\ &= \exp\left(\sum_{i=1}^{n} a_i \mu_i t + \frac{1}{2}\sum_{i=1}^{n} a_i^2 \sigma_i^2 t^2\right) \end{aligned}$$

이 되며 이는 $N\left(\sum_{i=1}^{n} a_i\mu_i,\ \sum_{i=1}^{n} a_i^2\sigma_i^2\right)$ 확률변수의 적률생성함수이다. 따라서 $Y \sim N\left(\sum_{i=1}^{n} a_i\mu_i, \sum_{i=1}^{n} a_i^2\sigma_i^2\right)$이다.

결합 적률생성함수

앞에서 정의된 적률생성함수는 k개의 확률변수들 $X_1, \cdots, X_k$의 결합분포로 아래와 같이 확장될 수 있다.

정의 2.17

확률벡터 $\boldsymbol{X} = (X_1, \cdots, X_k)$의 **결합 적률생성함수**(joint moment generating function)는 다음과 같이 정의된다.

$$M_X(\boldsymbol{t}) = E\left[\exp\left(\sum_{i=1}^{k} t_i X_i\right)\right]$$

단, $\boldsymbol{t} = (t_1, \cdots, t_k)$이고 $i = 1, \cdots, n$에 대해 $-h_i < t_i < h_i$에서

$$E\left[\exp\left(\sum_{i=1}^{k} t_i X_i\right)\right] < \infty$$

이 되는 $h_i > 0$들이 존재한다.

결합 적률생성함수의 성질은 앞에서 소개된 일변량 확률변수의 적률생성함수와 비슷하다. 우선, 결합 적률생성함수 $M_X(\boldsymbol{t})$를 t_i, t_j에 관하여 각각 r, s번 미분한 결과에 $t_1 = \cdots = t_k = 0$을 대입함으로써 $E(X_i^r X_j^s)$을 구할 수 있다. 나아가, 주변(marginal) 적률생성함수를 결합 적률생성함수로부터 구할 수 있다. 예를 들어, 두 확률변수 X, Y의 결합 적률생성함수가 $M_{X,Y}(t_1, t_2)$라고 하면, X와 Y 각각의 적률생성함수는

$$M_X(t_1) = M_{X,Y}(t_1, 0),\quad M_Y(t_2) = M_{X,Y}(0, t_2) \tag{2.62}$$

로 주어진다.

정리 2.30

두 확률변수 X와 Y가 서로 독립일 필요충분조건은 결합 적률생성함수가 각각의 적률생성함수의 곱과 같다는 것이다. 즉,

$$M_{X,Y}(t_1, t_2) = M_X(t_1) \cdot M_Y(t_2)$$

이면 X와 Y는 독립이고, 그 역도 성립한다.

증명 두 확률변수가 서로 독립일 필요충분조건은 결합 확률밀도함수가 주변 확률밀도함수들의 곱(참조: 정리 2.5)이라는 사실로부터 자명해진다. ■

예 2.60

확률벡터 $\boldsymbol{X} = (X_1, X_2, X_3) \sim \text{MULT}(n, p_1, p_2, p_3)$라고 하자. 이때 X_i는 $B(n, p_i)$ 확률변수이다($i = 1, 2, 3$) (참조: 예 2.9). 여기서는 (X_1, X_2, X_3)의 결합 적률생성함수를 사용하여 주변 적률생성함수를 구해 보기로 하자. 먼저, $\boldsymbol{X} = (X_1, X_2, X_3)$의 결합 적률생성함수는

$$\begin{aligned} M_X(\boldsymbol{t}) &= E\left[\exp\left(\sum_{i=1}^{3} t_i X_i\right)\right] \\ &= \sum_{\text{모든 } x_1, x_2, x_3} \sum \sum \\ &= (p_1 e^{t_1} + p_2 e^{t_2} + p_3 e^{t_3})^n \end{aligned}$$

(단, $p_1 + p_2 + p_3 = 1$)으로 주어진다. 따라서 X_i의 주변 적률생성함수는

$$\begin{aligned} M_{X_1}(t_1) &= M_{X_1, X_2, X_3}(t_1, 0, 0) \\ &= (p_1 e^{t_1} + 1 - p_1)^n \end{aligned}$$

이 되며, 이로부터 $X_1 \sim B(n, p_1)$임을 알 수 있다.

2.9 확률생성함수

이산형 확률변수 X가 음이 아닌 정수값 $0, 1, 2, \cdots$를 가질 수 있다고 하자. 이때 확률변수 X의 성질을 파악하는 데에 다음과 같이 정의되는 확률생성함수(probability generating function)를 이용할 수 있다. 편의상 $P(X=j)=p_j$로 표기하자.

정의 2.18

이산형 확률변수 X의 **확률생성함수**는

$$G_X(s)=E(s^X)=\sum_{j=0}^{\infty}p_j s^j$$

로 정의된다.

이와 같이 정의된 확률생성함수 $G_X(s)$는 $|s|\le 1$에 대하여 다음과 같은 성질들을 가진다. 아래의 성질 3으로부터 확률생성함수라는 이름이 유래하는 것으로 여겨진다.

1. $E(X)=G_X'(1)=\dfrac{d}{ds}G_X(s)\Big|_{s=1}$
2. 서로 독립인 확률변수 X와 Y의 합인 $Z=X+Y$의 확률생성함수는 $G_Z(s)=G_X(s)\times G_Y(s)$이다.
3. $P(X=k)=(1/k!)\dfrac{d^k}{ds^k}G_X(s)\Big|_{s=0}$

예 2.61

$B(n, p)$의 확률생성함수는 베르누이(p)의 확률생성함수가 $G(s)=q+ps$이므로 성질 2를 이용하여 $(q+ps)^n$으로 구해진다(단, $p+q=1$). 또한 평균이 λ인 포아송 확률변수의 확률생성함수는 $G_X(s)=\sum_{j=0}^{\infty}\exp(-\lambda)(s\lambda)^j/j!=\exp(\lambda s-\lambda)$으로 구해진다.

이와 같은 확률생성함수는