17 모분포 $N(0,1)$로부터 랜덤표본 $X_1, X_2, \cdots, X_{50}$을 얻었다고 할 때,

(1) $P(X_1 - X_2 < 2)$을 계산하라.

(2) $P(X_1 + X_2 < 2)$을 계산하라.

(3) $P({X_1}^2 + \cdots + X_{50}^2 < 60)$을 계산하라.

(4) $P(40 < {X_1}^2 + \cdots + X_{50}^2 < 60)$을 계산하라.

(5) $P({X_1}^2 + \cdots + X_{50}^2 < 50 + c) = 0.9$를 만족하는 상수 c를 구하라.

18 $X_1, X_2, \cdots, X_{30}$이 $U(0,1)$로부터의 랜덤표본이라고 할 때, $P(4/9 < \overline{X}_{30} < 5/9)$를 근사계산하라.

19 평균이 3인 지수분포로부터 얻은 크기가 30인 표본의 평균을 $\overline{X}_{30}$이라고 할 때, $P(\overline{X}_{30} < 4)$를 근사계산하라.

20 자유도가 50인 카이제곱분포로부터 얻은 크기가 100인 랜덤표본의 평균을 $\overline{X}_{100}$이라고 할 때, 중심극한정리를 이용하여 $P(49 < \overline{X}_{100} < 51)$를 근사계산하라.

21 이항확률변수 $X \sim B(100, 1/4)$에서 $P(X > 30)$의 값을 중심극한정리를 활용하여 근사계산하라. 연속성 수정을 한 경우와 하지 않은 경우를 모두 구해서 비교해 보라.

22 $X_1, X_2, \cdots, X_{25}$이 평균이 $\lambda = 1/5$인 포아송 분포로부터 얻은 랜덤표본이라고 할 때, $P(3 < \sum_{i=1}^{25} X_i < 7)$를 근사계산하라.

23 서로 독립인 랜덤표본 $X_1, X_2, \cdots, X_n$과 $Y_1, Y_2, \cdots, Y_n$이 각각 평균이 μ_1, μ_2이고 분산은 σ^2으로 같다고 하자. 이때

$$\frac{(\overline{X}_n - \overline{Y}_n) - (\mu_1 - \mu_2)}{\sigma\sqrt{2/n}}$$

의 극한분포를 구하라.

24 모분포가 코시 분포인 경우 중심극한정리의 성립여부를 말하고, 그 이유를 설명하라.

25 어떤 주머니에 숫자 1, 2, 3, 4가 적힌 네 개의 공이 들어 있다. 이제 무작위로 두 개의 공을 비복원으로 추출해서 공에 적힌 숫자를 (X_1, X_2)라고 할 때,

(1) 순서통계량 $(X_{(1)}, X_{(2)})$의 결합 확률밀도함수를 구하라.

(2) $X_{(2)} - X_{(1)}$의 확률밀도함수를 구하라.

(3) 표본평균 $(X_1 + X_2)/2$의 확률밀도함수를 구하라.

26 서로 독립인 두 개의 확률변수 X와 Y의 확률밀도함수가 $f_X(x) = 2x,\ 0 < x < 1$, $f_Y(y) = 3y^2,\ 0 < y < 1$로 주어졌을 때, $U = \max(X, Y)$와 $V = \min(X, Y)$의 결합 확률밀도함수를 구하라.

27 $X_1, X_2, \cdots, X_n$이 $U(0, \theta)$로부터의 랜덤표본이라고 할 때,

(1) $X_{(1)}$과 $X_{(n)}$의 결합 확률밀도함수를 구하라.

(2) 표본범위 $X_{(n)} - X_{(1)}$의 분포를 구하라.

28 $X_1, X_2, \cdots, X_n$이 $U(0,1)$로부터의 랜덤표본일 때, k번째 순서통계량 $X_{(k)}$는 베타분포 $B(k, n-k+1)$을 따름을 보여라.

29 $X_1, X_2, \cdots, X_n$이 $\mathrm{EXP}(\lambda),\ \lambda > 0$로부터 얻은 랜덤표본이라고 할 때,

(1) $X_{(1)}$의 확률밀도함수를 구하라.

(2) $X_{(n)}$의 확률밀도함수를 구하라.

(3) $n = 2r + 1$이라고 가정하고, 표본중위수 $X_{(r)}$의 확률밀도함수를 구하라.

30 모확률분포가 $F(x)$인 k번째의 순서통계량 $X_{(k)}$의 누적확률분포는

$$G_k(x_{(k)}) = \sum_{j=k}^{n} \frac{n!}{j!(n-j)!} \left[F(x_{(k)})\right]^j \left[1 - F(x_{(k)})\right]^{n-j}$$

이 됨을 보여라. 이는 이산형, 연속형 모두에 대해 성립한다.

31 확률변수 X의 확률밀도함수가 $f_X(x)=\dfrac{1}{(x+1)^2}$, $x>0$으로 주어졌을 때, $Y=nX_{(1)}$이 EXP(1)로 분포수렴함을 보여라.

32 $X_1, X_2, \cdots, X_n$은 성공확률이 p인 베르누이 분포에서 뽑은 랜덤표본이고, $Y_n=\sum_{i=1}^{n} X_i$로 정의된다. $n\to\infty$에서 $np=\lambda$(λ는 어떤 양수)로 고정된다고 가정할 때, 적률생성함수의 극한을 이용하여 Y_n이 $POI(\lambda)$로 분포수렴함을 보여라.

33 평균이 1인 지수분포로부터 랜덤표본 $X_1, X_2, \cdots, X_n$을 얻었다. $\sqrt{n}(\sqrt{\overline{X}_n}-1)$의 극한분포를 구하라.

34 평균과 분산이 각각 μ와 $\sigma^2<\infty$인 확률밀도함수 $f(x)$로부터 랜덤표본 $X_1, X_2, \cdots, X_n$을 얻었다.

(1) $\sqrt{n}(\overline{X}_n^2-\mu^2)\xrightarrow{d} N(0, 4\mu^2\sigma^2)$임을 보여라. 단, $\mu\neq 0$.

(2) (1)에서 $\mu=0$인 경우에 대해 설명하라.

4장 추정

- 4.1 적률추정법
- 4.2 최대가능도 추정법
- 4.3 추정의 기준
- 4.4 최소분산 비편향추정량
- 4.5 추정량의 점근적 성질
- 4.6 구간추정
- 4.7 베이즈 추정

이 장에서 다룰 추정이론(estimation theory)은 다음 5장에서 다룰 검정이론(testing theory)과 함께 통계적 추론(statistical inference)의 가장 중요한 분야로 여겨진다. 먼저 추정론의 개요를 살펴보면 다음과 같다. 연구나 관찰의 대상인 확률변수 X의 확률분포를 $P_\theta(x)$, $\theta \in \Omega$로 표현하자. 물론 확률분포 $P_\theta(x), \theta \in \Omega$를 확률밀도함수 $f(x;\theta)$, $\theta \in \Omega$로도 표현할 수 있다. 일반적으로 미지의 모수 θ를 제외하고는 확률분포의 유형이 결정되어 있다고 가정하기로 하자. 모수모형(parametric model)이라고 불리는 이런 경우에 모수 θ는 $\theta = (\theta_1, \theta_2, \cdots, \theta_k)$로 표현되는 벡터일 수도 있으며, Ω는 모수가 가질 수 있는 값의 집합, 즉 모수공간을 뜻한다. 이제 확률분포 $P_\theta(x)$, $\theta \in \Omega$로부터 크기가 n인 랜덤표본 $X_1, X_2, \cdots, X_n$을 얻었다고 하자(편의상 $X = (X_1, X_2, \cdots, X_n)$으로 표기한다). 이때 우리가 관심이 있는 문제는 확률분포 $P_\theta(x), \theta \in \Omega$를 특징짓는 모수 θ 또는 θ의 함수인 $g(\theta)$의 추정이다(예: $g(\theta) = e^\theta$, $g(\theta) = \theta^2$ 등). 많은 경우에 우리는 모수인 θ 자체에 흥미를 가지게 되지만, 일반성을 잃지 않기 위하여 모수의 함수인 $g(\theta)$의 추정에 대해 고려하기로 한다.

$g(\theta)$에 대한 추정방법에는 크게 표본에 근거한 통계량 $T(X) = T(X_1, X_2, \cdots, X_n)$을 사용하여 하나의 값으로 $g(\theta)$를 추정하는 **점추정**(point estimation)과, 두 개의 통계량 $T_1(X) = T_1(X_1, X_2, \cdots, X_n)$과 $T_2(X) = T_2(X_1, X_2, \cdots, X_n)$을 사용하여 구간 $[T_1(X), T_2(X)]$에 $g(\theta)$가 포함될 확률을 고려하는 **구간추정**(interval estimation)의 두 가지 방법이 있다. 두 가지 방법 가운데 좀 더 많은 정보를 제공할 수 있다는 이유로 흔히 구간추정이 선호되지만, 추정이론의 많은 부분은 점추정에 관한 것이다. 그 이유는 일반적으로 구간추정은 점추정값에 오차한계를 더해놓은 꼴로 표현되므로, 좋은 점추정량을 찾는 것이 좋은 구간추정을 가능케 하기 때문이다. 이러한 맥락에서, 이 장의 많은 부분도 점추정의 이론을 다루는 데 할애될 것이다.

점추정의 과정에는, 기본적인 접근방법을 정하는 것과 또 주어진 기준에 의해 여러 가지 가능한 추정방법 중에서 가장 뛰어난 것을 선택하는 두 가지 요소가 들어있다. 여기에서는 기본적인 접근방법으로서, 적률과 가능도의 원리를 고려할 것이며 추정량의 선택기준으로는 평균제곱오차(mean square error)의 최소화를 사용할 것이다. 평균제곱오차를 기준으로 추정량을 선택함에 있어서는 비편향추정량들 중에서 분산을 최소화하는 최소분산 비편향추정량을 주로 다루게 된다. 그리고 구간추정에서는 추축변량(pivotal quantity)을 사용하는 방법을 다루고, 마지막 절에서는 베이즈(Bayes) 추정방법을 고려하도록 한다. 이제 추정에 필요한 추정량을 정의하면 다음과 같다.

정의 4.1

미지의(unknown) 모수를 포함하지 않는 랜덤표본 $X_1, X_2, \cdots, X_n$ 의 함수를 통계량(statistic)이라고 한다. 나아가, 모수 θ의 함수 $g(\theta)$를 추정하기 위해 사용되는 통계량 $T(X) = T(X_1, \cdots, X_n)$을 $g(\theta)$의 **추정량**(estimator)이라고 하며, 주어진 표본값 $X_1 = x_1, X_2 = x_2, \cdots, X_n = x_n$을 대입해서 구해진 추정량의 특정값, $T(x) = T(x_1, x_2, \cdots, x_n)$ 을 **추정값**(estimate)이라고 한다.

주 모수 θ와 그의 추정량을 구별하기 편리하도록, 많은 경우에 추정량을 $\hat{\theta}_n$ 또는 $\hat{\theta}$으로 표기하기로 한다. $\hat{\theta}_n$에서 첨자 n은 추정량을 구하는 데 사용된 표본의 크기가 n임을 강조하기 위해 쓴 것이다.

예 4.1

$X_1, X_2, \cdots, X_n$을 $N(\mu, \sigma^2)$으로부터 얻은 랜덤표본이라고 하자. 모평균 μ와 모분산 σ^2을 추정하고자 할 때, 표본평균

$$\hat{\mu} = T_1(X_1, X_2, \cdots, X_n) = \frac{\sum_{i=1}^{n} X_i}{n}$$

와 표본분산

$$\hat{\sigma}^2 = T_2(X_1, X_2, \cdots, X_n) = \frac{\sum_{i=1}^{n} (X_i - \overline{X}_n)^2}{n-1}$$

을 추정량으로 사용할 수 있으며, 표본이 주어졌을 때 그들의 값

$$T_1(x_1, x_2, \cdots, x_n) = \frac{\sum_{i=1}^{n} x_i}{n}, \quad T_2(x_1, x_2, \cdots, x_n) = \frac{\sum_{i=1}^{n} (x_i - \overline{x}_n)^2}{n-1}$$

을 추정값이라 한다.

모수를 추정하는 데 있어서 가능한 여러 가지 접근방법들 중에, 적률(moment)을

사용하는 방법과 가능도원리(likelihood principle)를 사용하는 방법을 우선 고려해 보자. 그 외에도 선형모형의 모수추정에 많이 사용되는 최소제곱추정법(least square method)이 있으나, 이는 6장의 분산분석과 7장의 회귀분석에서 별도로 다루기로 한다.

4.1 적률추정법

모수벡터 $\boldsymbol{\theta} = (\theta_1, \cdots, \theta_k)$를 갖는 확률분포에서 $X_1, \cdots, X_n$ 의 표본을 뽑는다고 하자. 2.8절에서 모분포의 r차 적률(rth population moment)을

$$\mu_r{}' = E(X^r) \tag{4.1}$$

으로, r차 표본적률(rth sample moment)을

$$m_r{}' = \frac{\sum_{i=1}^{n} X_i^r}{n} \tag{4.2}$$

으로 표기하기로 했었다. 일반적으로 모적률 $\mu_r{}'$은 모수벡터 $\boldsymbol{\theta} = (\theta_1, \theta_2, \cdots, \theta_k)$의 함수이므로 k개의 연립방정식

$$m_j{}' = \mu_j{}' (\theta_1, \theta_2, \cdots, \theta_k) , \qquad j = 1, 2, \cdots, k$$

를 풀면 해 $(\hat{\theta}_1, \hat{\theta}_2, \cdots, \hat{\theta}_k)$를 구할 수 있을 것이며, 이를 $(\theta_1, \cdots, \theta_k)$에 대한 적률추정량이라고 한다. 이는 대수의 법칙에 의하여 r차 모적률이 존재할 때, r차 표본적률이 r차 모적률로 표본의 크기가 커짐에 따라 확률적으로 수렴한다는 사실에 기초한 방법으로서, n이 크다면 표본적률이 확률적으로 모적률에 매우 가깝게 되므로 표본적률을 이용하여 모적률을 추정하는 것은 합리적인 방법이라고 할 수 있다. 이에 대한 몇 가지 예를 들어보자.

예 4.2

$X_1, X_2, \cdots, X_n$ 을 $N(\mu, \sigma^2)$으로부터 얻은 랜덤표본이라고 할 때, μ와 σ^2을 적률을 사용하는 방법으로 추정해 보자. 추정할 모수가 두 개이므로 1, 2차 표본적률을

구하여 1, 2차 모적률과 같다고 놓는다. 즉,

$$m_1' = \frac{\sum_{i=1}^{n} X_i}{n}$$
$$= \mu_1'(\mu, \sigma^2) = \mu$$
$$m_2' = \frac{\sum_{i=1}^{n} X_i^2}{n}$$
$$= \mu_2'(\mu, \sigma^2) = \sigma^2 + \mu^2$$

의 연립방정식을 풀면 다음과 같은 추정량을 구할 수 있다.

$$\hat{\mu} = \frac{\sum_{i=1}^{n} X_i}{n}$$
$$\hat{\sigma}^2 = m'_2 - (\hat{\mu})^2 = \sum_{i=1}^{n} \frac{X_i^2}{n} - (\sum_{i=1}^{n} \frac{X_i}{n})^2$$
$$= \frac{1}{n}(\sum_{i=1}^{n} X_i^2 - n(\overline{X}_n)^2) = \frac{\sum_{i=1}^{n} (X_i - \overline{X}_n)^2}{n}.$$

예 4.3

$X_1, X_2, \cdots, X_n$ 을 GAM(k, θ)로부터 얻은 랜덤표본이라고 하자. 1, 2차 표본적률과 모수벡터 (k, θ)에 대한 두 개의 방정식

$$m_1' = \frac{\sum_{i=1}^{n} X_i}{n}$$
$$= \mu_1'(k, \theta) = k\theta$$
$$m_2' = \frac{\sum_{i=1}^{n} X_i^2}{n}$$
$$= \mu_2'(k, \theta) = k\theta^2 + k^2\theta^2$$

을 풀면, (k, θ)에 대한 추정량

$$\hat{\theta} = (\frac{\sum_{i=1}^{n} X_i^2}{n} - \overline{X}_n^2)/\overline{X}_n = \frac{\sum_{i=1}^{n}(X_i - \overline{X}_n)^2}{n\overline{X}_n},$$

$$\hat{k} = \frac{\overline{X}_n}{\hat{\theta}} = \frac{n(\overline{X}_n)^2}{\sum_{i=1}^{n}(X_i - \overline{X}_n)^2}$$

을 구할 수 있다.

이와 같이 적률을 사용하여 추정량을 구하는 방법은 비교적 그 과정이 간단하나 때로는 유일하지 않은 경우도 있다(연습문제 4.3 참조).

4.2 최대가능도 추정법

성공률이 p인 베르누이 분포에서 크기가 10인 랜덤표본을 뽑는다고 가정해 보자. 또, 이 분포의 성공률은 0.1이거나 0.9 둘 중에 하나라는 것을 알고 있으며, 관측된 표본을 통해 성공률을 추정하려고 한다고 가정하자. 만약 10개의 관측치의 합이 8이었다면 성공률을 0.1이라고 하는 것이 좋을까, 아니면 0.9라고 하는 것이 좋을까? 이 경우 성공률을 0.9로 추정하는 데에 별다른 이견이 없을 것이다. 그렇다면 우리는 왜 0.9를 0.1보다 선호하게 된 것일까? 아마도 0.9가 참일 경우 합이 8인 관측치를 얻을 확률이 0.1이 참일 경우보다 높기 때문일 것이다. 이러한 생각이 가능도원리를 사용하는 최대가능도 추정법의 간단한 예라고 할 수 있다.

확률변수 $X_1, X_2, \cdots, X_n$의 결합 확률밀도함수가 $f(x_1, x_2, \cdots, x_n ; \theta)$라고 하자. 결합 확률밀도함수 $f(x_1, x_2, \cdots, x_n ; \theta)$는 고정된 모수 θ에 대하여 $(x_1, x_2, \cdots, x_n)$의 함수로 사용된다. 그러나 반대로 $f(x_1, x_2, \cdots, x_n ; \theta)$를 관측치 $X_1 = x_1, X_2 = x_2, \cdots, X_n = x_n$이 주어졌을 때 모수 $\theta(\in \Omega)$의 함수로 생각해 볼 수도 있다. 즉, 다음과 같이

$$L(\theta) = L(\theta ; x_1, x_2, \cdots, x_n) = f(x_1, x_2, \cdots, x_n ; \theta)$$

로 표기하고 이를 $X_1, X_2, \cdots, X_n$의 **가능도함수**(likelihood function)라고 한다. 다

시 말하면, 가능도함수 $L(\theta)$는 주어진 자료 $(x_1, x_2, \cdots, x_n)$에 대하여, $(x_1, x_2, \cdots, x_n)$이 얻어질 가능성을 모수 θ에 대한 함수로 나타낸 것이라고 할 수 있다. 특정한 θ의 값과 $x_1, \cdots, x_n$이 주어진 상태에서 확률밀도함수와 가능도함수는 같은 함수값을 갖는다. 그러나 예를 들어 $y = x^2 + z$를 $f(x) = x^2 + z$와 같이 x의 함수로 볼 수도 있고, $g(z) = x^2 + z$처럼 z의 함수로 볼 수도 있지만 $f(x)$와 $g(z)$는 다른 함수이듯이, 가능도함수와 확률밀도함수는 함수로서는 서로 다르며, 특히 가능도함수는 θ의 함수이므로 확률밀도함수가 아니라는 점을 유의하자.

이제 확률변수 $X_1, X_2, \cdots, X_n$이 서로 독립적이고 X_i가 확률밀도함수 $f_i(x_i ; \theta)$를 갖는다고 하면, $X_1, X_2, \cdots, X_n$의 결합 확률밀도함수는

$$\prod_{i=1}^{n} f_i(x_i ; \theta) = f_1(x_1 ; \theta) f_2(x_2 ; \theta) \cdots f_n(x_n ; \theta)$$

이며, 가능도함수는

$$\begin{aligned} L(\theta ; x_1, x_2, \cdots, x_n) &= \prod_{i=1}^{n} f_i(x_i ; \theta) \\ &= f_1(x_1 ; \theta) f_2(x_2 ; \theta) \cdots f_n(x_n ; \theta) \end{aligned}$$

로 나타내어진다. 따라서 $X_1, X_2, \cdots, X_n$이 확률밀도함수 $f(x ; \theta)$로부터의 랜덤표본이라고 하면 $f_i(x_i;\theta) = f(x_i;\theta)$ 이므로, 가능도함수는

$$L(\theta ; x_1, x_2, \cdots, x_n) = \prod_{i=1}^{n} f(x_i ; \theta) \tag{4.3}$$

가 된다. 이제 모수를 추정하는 방법으로 가능도함수를 최대화하는 통계량에 대한 정의는 다음과 같다.

정의 4.2

랜덤표본의 가능도함수 $L(\theta ; x_1, x_2, \cdots, x_n)$을 최대화하는 θ의 값을 $\hat{\theta} = \hat{\theta}(x_1, x_2, \cdots, x_n) \in \Omega$라고 할 때, $\hat{\theta} = \hat{\theta}(X_1, X_2, \cdots, X_n)$을 모수 θ의 **최대가능도 추정량**(maximum likelihood estimator)이라고 한다.

이러한 최대가능도 추정량의 의미는 '실제로 관측된' 자료가 얻어질 확률을 가장 높게

만드는(즉, 주어진 관측값을 가장 잘 설명하는) θ의 값을 모수 θ의 추정량으로 삼는 것이다. 이제, 몇 개의 예들을 살펴봄으로써 그 의미를 분명히 하자.

예 4.4

$X_1, X_2, \cdots, X_5$가 서로 독립인 베르누이(p) 확률변수라고 하자. 이때 $Y=\sum_{i=1}^{5} X_i$는 $B(5, p)$ 분포를 따르며, Y의 확률밀도함수는 몇 가지 다른 p에 대해서 다음과 같이 주어진다.

Y \ p	0.1	0.2	0.3	0.4	0.5	0.6	0.7	0.8	0.9	1.0
0	0.59050	0.32768	0.16807	0.07776	0.03125	0.01024	0.00243	0.00032	0.00005	0.0
1	0.32800	0.40960	0.36015	0.25920	0.15625	0.07680	0.02835	0.00640	0.00045	0.0
2	0.07290	0.20480	0.30870	0.34560	0.31250	0.23040	0.13230	0.05120	0.00810	0.0
3	0.00810	0.05120	0.13230	0.23040	0.31250	0.34560	0.30870	0.20480	0.07290	0.0
4	0.00045	0.00640	0.02835	0.07680	0.15625	0.25920	0.36015	0.40960	0.32800	0.0
5	0.00005	0.00032	0.00243	0.01024	0.03125	0.07776	0.16807	0.32768	0.59050	1.0

그런데 가능도함수는 $Y=y$로 주어졌을 때 모수 p에 대한 함수이므로 위의 표를 가로로 읽어서 구할 수 있다. 가령 $Y=3$이 주어지면, 위 가능도함수표에서 $Y=3$인 행을 살펴보아 $p=0.6$에서 가능도가 0.34560으로 최대가 되는 것을 알 수 있다. 따라서 최대가능도 추정값은 0.6이다. 반면, $Y=1$이라면 0.2가 최대가능도 추정값이 된다. 두 경우를 비교해 보면, p가 성공률이므로 Y의 값이 1보다는 3으로 클 때 p도 클 것이라고 추측하는 것이 합리적이다. 물론 p에 대하여 0과 1 사이의 모든 값을 고려하여야 하나 편의상 생략하였다.

그런데 가능도함수 $L(\theta\,; x_1, x_2, \cdots, x_n)$을 최대화하는 θ의 값을 찾는 문제는 로그가능도함수

$$\log L(\theta\,; x_1, x_2, \cdots, x_n) = \log \prod_{i=1}^{n} f_i(x_i\,; \theta) \qquad (4.4)$$
$$= \sum_{i=1}^{n} \log f_i(x_i\,; \theta)$$

를 최대화하는 θ를 찾는 것과 같다. 왜냐하면, 로그함수가 단조증가함수이므로 $L(\theta)$

를 최대로 만드는 θ의 값에서 $\log L(\theta)$도 최대가 되고, 그 반대도 성립하기 때문이다. 뿐만 아니라, 랜덤표본의 가능도함수는 주변 확률밀도함수의 곱으로 표현되는데, 여기에 로그를 취하면 각 주변 확률밀도함수에 로그를 취한 것의 합이 되므로 미분을 통해 최댓값을 찾는 계산이 훨씬 쉬워질 수 있다. 이런 이유로, 최대가능도 추정량을 찾을 때 로그가능도함수를 많이 이용한다. 또한, 많은 경우에 로그가능도함수를 최대화하는 문제는

$$\frac{d}{d\theta}\log L(\theta\,;x_1,\,x_2,\,\cdots,\,x_n)=0$$

의 해를 구하는 문제로 귀착된다(물론 위의 식을 만족하는 값이 곧 로그가능도함수를 최대화한다는 보장은 없으며, 엄밀한 의미에서의 최대화 여부를 2차 미분 등을 통해서 가려야 한다). 참고로, 우리가 사용하는 log는 다른 설명이 없는 한 자연로그이다.

예 4.5

$X_1,\,X_2,\,\cdots,\,X_n$을 $\mathrm{EXP}(\theta)$에서 추출된 랜덤표본이라고 할 때, θ의 최대가능도 추정량을 구해 보자. 이 표본의 가능도함수는 $x_i>0,\ i=1,\cdots,n$일 때

$$\begin{aligned}L(\theta;x_1,\,x_2,\,\cdots,\,x_n)&=\prod_{i=1}^{n}f(x_i;\theta)\\&=(\frac{1}{\theta})^n\exp(-\sum_{i=1}^{n}x_i/\theta)\end{aligned}$$

가 되며, 로그가능도함수는

$$\log L(\theta\,;x_1,\,x_2,\,\cdots,\,x_n)=-n\log\theta-\sum_{i=1}^{n}x_i/\theta$$

가 된다. 이를 θ에 대해 미분하면 $\frac{d}{d\theta}\log L(\theta)=-\frac{n}{\theta}+\sum_{i=1}^{n}x_i/\theta^2$이고, 이를 0으로 만드는 θ의 값은 $\overline{x}_n$이다. $\theta=\overline{x}_n$일 때의 이차 미분값은 0보다 작으므로 이 값에서 로그가능도함수가 최대가 된다. 즉, θ의 최대가능도 추정량은 $\overline{X}_n$이다.

예 4.6

$X_1,\,X_2,\,\cdots,\,X_n$을 포아송(λ) 분포로부터 구한 랜덤표본이라고 하자. 이때 가능도함

수는

$$L(\lambda\,;x_1,\,x_2,\,\cdots,\,x_n)=\prod_{i=1}^{n}f(x_i\,;\lambda)$$
$$=\frac{\exp(-n\lambda)\lambda^{\Sigma x_i}}{\prod_{i=1}^{n}x_i!}$$

이며, 따라서 로그가능도함수는

$$\log L(\lambda\,;x_1,\,x_2,\,\cdots,\,x_n)=-n\lambda+\sum_{i=1}^{n}x_i\log\lambda-\log\left(\prod_{i=1}^{n}x_i!\right)$$

이다. 그런데,

$$\frac{d}{d\lambda}\log L(\lambda\,;x_1,\,x_2,\,\cdots,\,x_n)=-n+\sum_{i=1}^{n}\frac{x_i}{\lambda}=0$$

을 만족하는 $\hat{\lambda}=\bar{x}_n$은

$$\frac{d^2}{d\lambda^2}\log L(\lambda\,;x_1,\,x_2,\,\cdots,\,x_n)|_{\lambda=\bar{x}_n}=-\sum_{i=1}^{n}\frac{x_i}{\lambda^2}|_{\lambda=\bar{x}_n}=-\frac{n}{\bar{x}_n}<0$$

을 만족시키므로($\bar{x}_n>0$을 가정) 가능도함수를 최대화하는 최대가능도 추정량은 $\bar{X}_n$이다($\bar{x}_n=0$의 경우는 예 4.10 참조).

주 경우에 따라서 2차 미분을 확인하지 않아도 극값에서 가능도함수가 최대가 됨이 쉽게 보여질 수 있다. 위의 포아송 예제에서 $\lambda\to0$에서 $\log L(\theta)\to-\infty$이고, $\lambda\to\infty$에서 $\log L(\theta)\to-\infty$이면서 극값은 단 하나만 존재하므로 그 극값이 함수를 최대로 만드는 값일 수밖에 없음을 알 수 있다.

그런데 정의 4.2는 모수가 두 개 이상인 벡터 $\theta=(\theta_1,\,\theta_2,\cdots,\,\theta_k)$로 표현되는 경우에도 성립한다. 이러한 경우, k개의 연립방정식

$$\frac{d}{d\theta_i}\log L(\theta_1,\,\theta_2,\cdots,\,\theta_k)=0,\;\;i=1,\;2,\;\cdots,\;k$$

을 풀어서 구한 해가 로그가능도함수를 최대화하는지의 여부를 가려 최대가능도 추정

량 $(\hat{\theta}_1, \hat{\theta}_2, \cdots, \hat{\theta}_k)$을 구할 수 있다.

예 4.7

$X_1, X_2, \cdots, X_n$을 $N(\mu, \sigma^2)$으로부터 얻은 랜덤표본이라고 하자. 이때 가능도함수는

$$L(\mu, \sigma^2 ; x_1, x_2, \cdots, x_n) = \prod_{i=1}^{n} f(x_i ; \mu, \sigma^2)$$
$$= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left[-\sum_{i=1}^{n} (x_i - \mu)^2 / 2\sigma^2 \right]$$

이며, 따라서 로그가능도함수는

$$\log L(\mu, \sigma^2 ; x_1, x_2, \cdots, x_n) = -(n/2)\log(2\pi\sigma^2) - \sum_{i=1}^{n} (x_i - \mu)^2 / 2\sigma^2$$

이다. 이 로그가능도함수를 최대화하는 (μ, σ^2)값은

$$\frac{d}{d\mu} \log L(\mu, \sigma^2 ; x_1, x_2, \cdots, x_n) = \sum_{i=1}^{n} \frac{(x_i - \mu)}{\sigma^2} = 0$$

$$\frac{d}{d\sigma^2} \log L(\mu, \sigma^2 ; x_1, x_2, \cdots, x_n) = -\frac{n}{2\sigma^2} + \frac{\sum_{i=1}^{n} (x_i - \mu)^2}{2\sigma^4} = 0$$

의 두 연립방정식의 해를 구하고, 이들이 로그가능도함수를 최대화함을 2차 미분을 사용하여 확인함으로써 구할 수 있다. 이렇게 구한 최대가능도 추정량은

$$(\hat{\mu}, \hat{\sigma}^2) = \left(\overline{X}_n, \sum_{i=1}^{n} (X_i - \overline{X}_n)^2 / n \right)$$

이 된다. 로그가능도함수의 2차 미분은 2×2 행렬이 되므로 이 행렬이 주어진 극값에서 음정치행렬인지 확인하여 함수가 최댓값을 가지는지 확인할 수 있지만, 다음과 같은 방법을 사용할 수도 있다. $\sum_{i=1}^{n} (x_i - \mu)^2 = \sum_{i=1}^{n} (x_i - \overline{x}_n)^2 + n(\overline{x}_n - \mu)^2$이므로, $\mu \neq \overline{x}_n$라면 $\sum_{i=1}^{n} (x_i - \mu)^2 > \sum_{i=1}^{n} (x_i - \overline{x}_n)^2$가 된다. 그러므로 임의의 σ^2의 값에서 $\log L(\mu, \sigma^2)$가 $\hat{\mu} = \overline{x}_n$에서 최대화됨을 알 수 있다. μ를 $\overline{x}_n$으로 치환하고 나면

$\log L(\bar{x}_n, \sigma^2)$는 $n^{-1}\sum_{i=1}^{n}(x_i - \bar{x}_n)^2$에서 최대가 된다. 그러므로 $(\hat{\mu}, \hat{\sigma}^2)$에서 로그가능도함수가 최대가 된다.

예 4.8

$X_1, X_2, \cdots, X_n$을 로지스틱 분포로부터 얻은 랜덤표본이라고 하자. 로지스틱 확률밀도함수는 $f(x;\theta) = \dfrac{\exp\{-(x-\theta)\}}{(1+\exp\{-(x-\theta)\})^2}$, $-\infty < x < \infty$, $-\infty < \theta < \infty$ 이므로 로그가능도함수는

$$\log L(\theta) = \sum_{i=1}^{n} \log f(x_i;\theta) = n\theta - n\bar{x}_n - 2\sum_{i=1}^{n} \log(1+\exp(-(x_i-\theta)))$$

가 된다. $\dfrac{d}{d\theta}\log L(\theta) = n - 2\sum_{i=1}^{n}\dfrac{\exp(-(x_i-\theta))}{1+\exp(-(x_i-\theta))} = 0$의 해는 간단한 폐쇄형이 존재하지 않으나, $\dfrac{d}{d\theta}\log L(\theta)$이 θ에 대해 단조감소하며($\dfrac{d^2}{d\theta^2}\log L(\theta) < 0$) θ가 $-\infty$로 갈 때 n으로 그리고 θ가 $+\infty$로 갈 때 $-n$으로 접근하므로 유일해를 가진다는 것을 알 수 있다. 그리고 이 해는 수치적 방법을 통해 구할 수 있다.

가능도함수가 미분 가능하면 위의 예제들에서와 같은 방법으로 최대가능도 추정량을 구할 수 있으나, 가능도함수가 언제나 미분 가능한 것은 아니며, 따라서 최대가능도 추정량이 언제나 가능도함수의 미분과정을 통해서만 구해지는 것은 아니다. 다음의 예를 살펴보자.

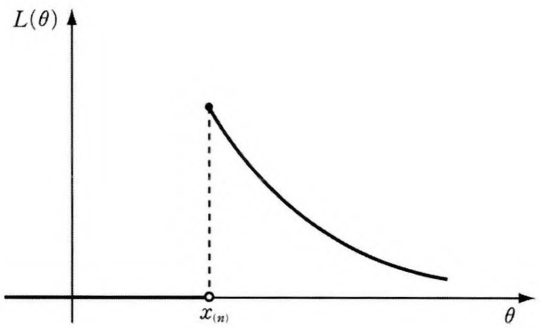
예 4.9

$X_1, X_2, \cdots, X_n$을 $U(0, \theta)$로부터 얻은 랜덤표본이라고 하자. 이때 가능도함수는

$$L(\theta\,;x_1, x_2, \cdots, x_n) = \prod_{i=1}^{n} f(x_i;\theta)$$
$$= \begin{cases} \dfrac{1}{\theta^n}, & 0 \le x_i \le \theta \text{인 경우} \\ 0, & \text{그 외의 경우} \end{cases}$$

이 되며, 모든 θ에 대해 연속이 아니므로 모수 θ에 대하여 미분 가능하지 않다. 이 경우, 미분을 하는 대신 가능도함수의 형태를 살펴보면 쉽게 최대가능도 추정량을 구

할 수 있다.



이제 최대가능도 추정량이 표본최댓값 $X_{(n)}$인 것은 위 그래프로부터 자명하다.

또한, 최대가능도 추정량이 언제나 존재한다는 보장은 없으며 유일하지 않을 수도 있다.

예 4.10

$X_1, X_2, \cdots, X_n$을 $\lambda > 0$인 포아송(λ) 분포로부터 구한 랜덤표본이라고 하자. 예 4.6에서

$$\frac{d}{d\lambda} \log L(\lambda\,; x_1, x_2, \cdots, x_n) = -n + \sum_{i=1}^{n} \frac{x_i}{\lambda} = 0$$

이고, $\bar{x}_n > 0$일 때 λ의 최대가능도 추정량이 $\bar{X}_n$임을 보였다. 그런데 랜덤표본에서 얻은 관측치 $\bar{x}_n$의 값이 공교롭게도 0이었다고 하자. 이 경우 로그가능도함수의 1차 미분은 항상 음의 값을 가지게 되는데, λ값의 범위는 개구간이므로 최대가능도 추정량은 존재하지 않는다.

예 4.11

$X_1, X_2, \cdots, X_n$을 $U[\theta - 1, \theta + 1]$로부터 얻은 랜덤표본이라고 하자. 이때 가능도함수는

$$L(\theta\,;x_1,x_2,\cdots,x_n)=\prod_{i=1}^{n}\frac{1}{2}I_{[\theta-1,\theta+1]}(x_i)=2^{-n}I_{[\theta-1\le x_{(1)},x_{(n)}\le\theta+1]}$$
$$=2^{-n}I_{[x_{(n)}-1,x_{(1)}+1]}(\theta)$$

이 되고, 이 함수는 구간 $[x_{(n)}-1,x_{(1)}+1]$의 모든 점에서 최댓값 2^{-n}을 가지므로 구간 $[X_{(n)}-1,X_{(1)}+1]$ 내의 모든 점이 최대가능도 추정량이 된다. 즉, 최대가능도 추정량이 유일하지 않다.

예 4.12

3가지 타입의 개체들로 구성된 모집단에서 크기가 n인 랜덤표본을 추출했을 때, 다음의 Hardy-Weinberg 모형을 고려하자.

$$(N_1,N_2,N_3)\sim \mathrm{MULT}(n,p_1,p_2,p_3).$$

여기에서 $p_1=\theta^2$, $p_2=2\theta(1-\theta)$, $p_3=(1-\theta)^2$, $0<\theta<1$이다. 이때, θ의 최대가능도 추정량을 구해 보자. $N_1=n_1$, $N_2=n_2$, $N_3=n_3$이 주어졌을 때 이 랜덤표본의 가능도함수는

$$L(\theta)=\frac{n!}{n_1!n_2!n_3!}\theta^{2n_1}(2\theta(1-\theta))^{n_2}(1-\theta)^{2n_3}$$

이 되며, 로그가능도함수는

$$\log L(\theta)=\log\frac{n!}{n_1!\,n_2!\,n_3!}+2n_1\log\theta+n_2\log 2\theta+n_2\log(1-\theta)+2n_3\log(1-\theta)$$

가 된다. 이를 미분하면,

$$\frac{d}{d\theta}\log L(\theta)=\frac{2n_1}{\theta}+\frac{n_2}{\theta}-\frac{n_2}{1-\theta}-\frac{2n_3}{1-\theta}$$

이고 $n_1\neq n$이고 $n_3\neq n$인 경우 이 1차 미분은 $\theta=\dfrac{2n_1+n_2}{2n}$에서 0의 값을 가진다. 2차 미분이 $\dfrac{d^2}{d\theta^2}\log L(\theta)=-\dfrac{2n_1+n_2}{\theta^2}-\dfrac{n_2+2n_3}{(1-\theta)^2}<0$이므로, θ의 최대가능도 추정량은 $n_1\neq n$이고 $n_3\neq n$일 때, $\hat{\theta}=\dfrac{2N_1+N_2}{2n}$이 된다. (단, $n=N_1+N_2+N_3$이다.)

최대가능도 추정량의 불변성

최대가능도 추정량의 장점 중의 하나는, 다음의 정리에서 나타나는 불변성 원리(invariance property)이다. θ를 추정하는 어떤 추정량이 $T(X)$일 때 θ^2의 추정량이 $T(X)^2$이 되고, $\theta+c$(c는 상수)의 추정량이 $T(X)+c$가 되는 등, θ의 함수 $g(\theta)$의 추정량이 $g(T(X))$가 되는 성질을 불변성 원리라고 한다. 이는 상당히 논리적이고 직관적인 성질로서, 최대가능도 추정량의 경우 이 원리가 성립하기 때문에 θ의 추정량을 얻고 나면 다른 어떤 함수 $g(\theta)$에 대해서도 다시 복잡한 계산을 거치지 않고 쉽게 추정량을 구할 수 있다. 최대가능도 추정량을 얻기 위해서는 일반적으로 미분의 과정을 거쳐야 하므로, 미분을 쉽게 만드는 모수를 선택하여 추정량을 구한 다음, 다른 형태의 모수에 대한 추정량은 불변성 원리를 이용하여 구하면 된다. 예를 들어 정규분포에서 얻어진 랜덤표본으로 표준편차 σ의 최대가능도 추정량을 구할 때, σ^2을 모수로 두는 것이 미분이 좀 더 쉽다고 한다면 σ^2의 최대가능도 추정량을 먼저 구하고, 여기에 제곱근을 취하여 σ의 최대가능도 추정량을 구할 수 있다.

정리 4.1

(최대가능도 추정량의 불변성) $X_1, \cdots, X_n$을 확률밀도함수 $f(x;\theta)$, $\theta \in \Omega$를 갖는 분포에서 얻은 랜덤표본이라고 하자. $\hat{\theta}_n$이 모수 θ의 최대가능도 추정량이면, θ의 함수인 $g(\theta)$에 대하여, $g(\hat{\theta}_n)$이 $g(\theta)$의 최대가능도 추정량이 된다.

증명 $\eta = g(\theta)$ 라고 놓자. 불변성 원리는 일반적인 함수 g에 대해 성립하나, 여기에서는 증명의 편의를 위하여 g를 일대일 함수라고 가정하도록 하자. θ를 모수로 하는 표본의 가능도함수를 $L(\theta)$라고 하고 η를 모수로 하는 표본의 가능도함수를 $L^*(\eta)$라고 하자. 그러면,

$$L^*(g(\theta)) = L^*(\eta) = \prod_{i=1}^{n} f(x_i; g^{-1}(\eta)) = L(g^{-1}(\eta)) = L(\theta)$$

이고,

$$\max_{\eta \in g(\Omega)} L^*(\eta) = \max_{\eta \in g(\Omega)} L(g^{-1}(\eta)) = \max_{\theta \in \Omega} L(\theta)$$

이므로

$$L^*(\hat{\eta}) = \max_{\eta \in g(\Omega)} L^*(\eta) = \max_{\theta \in \Omega} L(\theta) = L(\hat{\theta}_n) = L^*(g(\hat{\theta}_n))$$

이 되어, $\hat{\eta} = g(\hat{\theta}_n)$이다. ■

예 4.13

앞의 예 4.7에서 σ^2의 최대가능도 추정량으로 $\widehat{\sigma^2} = \sum_{i=1}^{n} (X_i - \overline{X}_n)^2/n$을 구하였다. 이제, $g(\sigma^2) = \sigma$의 최대가능도 추정량은 불변성에 의하여 $g(\widehat{\sigma^2}) = \hat{\sigma}$가 된다.

예 4.14

$X_1, X_2, \cdots, X_n$을 EXP(λ)로부터 얻은 랜덤표본이라고 하자. 이때 로그가능도함수는

$$\log L(\lambda\,;\, x_1, x_2, \cdots, x_n) = -n \log \lambda - \sum_{i=1}^{n} x_i/\lambda$$

가 되며, 따라서

$$\frac{d}{d\lambda} \log L(\lambda\,;\, x_1, x_2, \cdots, x_n) = -n/\lambda + \sum_{i=1}^{n} x_i/\lambda^2 = 0$$

으로부터 최대가능도 추정량 $\hat{\lambda} = \overline{X}_n$를 얻게 된다. 만약 이 분포에서 나온 확률변수가 1보다 클 확률을 추정하는 데에 관심이 있다면, $g(\lambda) = P(X \geq 1) = \exp(-1/\lambda)$에 대한 추정량이 필요하고, 이것의 최대가능도 추정량은 불변성에 의하여 $g(\hat{\lambda}) = \exp(-1/\overline{X}_n)$ 이 된다.

주 최대가능도 추정량의 불변성은 모수가 2개 이상인 경우로도 확장 가능하여, $\hat{\theta} = (\hat{\theta}_1, \hat{\theta}_2, \cdots, \hat{\theta}_k)$가 모수벡터 $\theta = (\theta_1, \theta_2, \cdots, \theta_k)$의 최대가능도 추정량이면, $g(\hat{\theta}_1, \hat{\theta}_2, \cdots, \hat{\theta}_k)$도 $g(\theta_1, \theta_2, \cdots, \theta_k)$의 최대가능도 추정량이 된다.

4.3 추정의 기준

추정의 기준을 다룸에 있어서, 표본의 함수인 추정량이 확률변수임을 재차 확인할 필요가 있다. 어떤 확률변수도 상응하는 확률분포를 가지므로 추정량도 그의 확률분포가 있고, 확률분포를 살피는 것은 추정량의 성격을 파악하는 데 도움이 된다. 아래의 예를 보자.

예 4.15

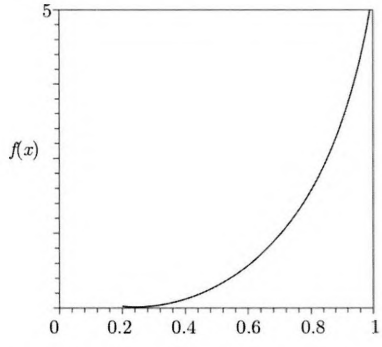
$X_1, X_2, \cdots, X_n$을 $U(0, \theta)$로부터 얻은 랜덤표본이라고 하자. 이때 모수 θ의 최대가능도 추정량은 표본최댓값 $X_{(n)}$이다(참조: 예 4.9). 추정량 $X_{(n)}$의 확률밀도함수는 $\theta = 1$, $n = 5$인 경우

$$\begin{aligned} F_{X_{(5)}}(x) &= P(X_{(5)} \le x) \\ &= P(X_1 \le x, X_2 \le x, \cdots, X_5 \le x) \\ &= \{P(X \le x)\}^5 \\ &= \{F_X(x)\}^5 \\ &= x^5, \quad 0 < x < 1 \end{aligned}$$

이므로,

$$f(x) = 5x^4 \quad (0 < x < 1)$$

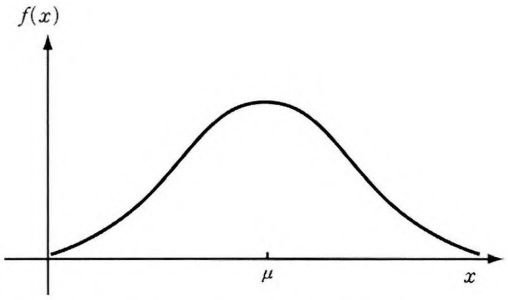
로서 다음 그림과 같이 주어진다. 두 번째 등식은 표본최댓값이 x보다 작으면 모든 관측값들이 x보다 작아야 하고, 모든 관측값들이 x보다 작으면 표본최댓값도 x보다 작다는 성질을 이용하여 얻는다.



▸ **그림 4.1** ◂ 추정량 $X_{(n)}$의 확률밀도함수

예 4.16

$X_1, X_2, \cdots, X_n$을 $N(\mu, \sigma^2)$으로부터 얻은 랜덤표본이라고 하자. 모평균 μ를 표본평균 $\overline{X}_n$로 추정할 때 추정량 $\overline{X}_n$의 확률분포는 모수(모평균)에 중심을 둔 $N(\mu, \sigma^2/n)$ 분포를 따른다. 즉, 추정량 $\overline{X}_n$의 확률밀도함수는 다음 그림과 같이 주어진다.



▸ **그림 4.2** ◂ 추정량 $\overline{X}_n$의 확률밀도함수

위의 두 예에서 보면, 예 4.15에서는 최대가능도 추정량 $X_{(n)}$이 모수 $\theta = 1$의 근방에 있을 확률은 높지만 $\theta = 1$에 대하여 비대칭적인 분포를 갖고 있는 반면에 예 4.16에서는 추정량 $\overline{X}_n$이 모수 μ에 대해 대칭이며, 또한 그 근방에 있을 확률이 높다는 것을 알 수 있다.

모수의 함수인 $g(\theta)$의 추정에서(물론 $g(\theta) = \theta$인 경우를 포함), 우리가 원하는 바는 추정량 $T(X) = T(X_1, X_2, \cdots, X_n)$이 추정하고자 하는 $g(\theta)$에 '가까운' 것이다. 추정량이 언제나 추정대상인 $g(\theta)$와 같은 값을 가진다면 제일 좋겠지만, 추정량은 확률변수로서 표본에 따라 값이 달라지므로 언제나 $g(\theta)$의 값을 가질 수는 없다. 대신 추정량이 $g(\theta)$에 가까운 값을 제공한다면 그것으로 훌륭한 추정량이라고 할 것이다. 그렇다면 "가깝다"라는 것을 어떻게 정의할 수 있을까? 이것은 사용하는 기준(criterion)에 따라 다르게 결정될 것이다. 몇 가지 가능한 기준의 예로는

1. 절대오차(absolute error)

$$| T(X) - g(\theta) |,$$

2. 제곱오차(squared error)

$$(T(X)-g(\theta))^2,$$

또는

3. $w(\theta)$로 가중값을 준 가중제곱오차(weighted squared error)

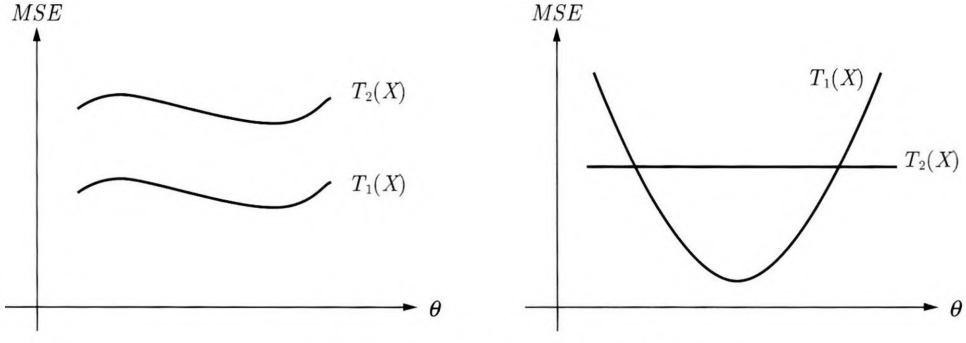
$$(T(X)-g(\theta))^2 w(\theta)$$

등을 들 수 있는데, 이들을 흔히 **손실함수**(loss function)라고 한다. 그러나 위의 손실함수들은 확률변수이기 때문에 이들을 최소화하는 추정량 $T(X)$를 찾아내는 것은 불가능하며, 따라서 위 손실함수의 기댓값(long term average)을 기준으로 삼는다. 일반적으로, 제곱오차의 기댓값인 **평균제곱오차**(Mean Square Error, MSE)

$$MSE = E(T(X)-g(\theta))^2 \tag{4.5}$$

이 추정의 기준으로 많이 사용되며, 여기에서도 이 MSE를 기준으로 삼도록 한다. 이 기준하에서 우리가 원하는 추정량은 평균제곱오차를 최소화하는 $T(X)$가 된다.

그런데 평균제곱오차는 모수 θ에 대한 함수이기 때문에 이를 최소화하는 추정량을 찾는 것이 항상 가능하지는 않다. 다음 그림을 보자. $g(\theta)$에 대한 두 개의 추정량 $T_1(X)$와 $T_2(X)$에 대한 평균제곱오차를 구하였을 때, 그림 4.3의 첫 번째 경우에서는



▸ **그림 4.3** ◂ 두 추정량의 평균제곱오차(MSE) 비교

$T_1(X)$의 평균제곱오차가 $T_2(X)$의 그것보다 모든 θ값에 대하여 작으므로 우리는 $T_1(X)$를 선호하게 되지만, 두 번째 경우에서는 θ의 값에 따라 평균제곱오차를 작게 만드는 추정량이 달라져 어떤 추정량을 사용해야 할지 명확하지 않게 된다. 이와 같이 평균제곱오차를 모든 $\theta \in \Omega$에 대하여 균일하게 최소화하는 추정량 $T(X)$는 일반적으로 존재하지 않는다. 예를 들어, θ를 추정하기 위한 어떤 추정량이 $T(X) \equiv \theta_0$(어떤

정해진 상수)이라고 하자. 즉, 표본에서 어떤 값을 관측하든 추정값을 θ_0으로 하겠다는 뜻이다. 만약 미지의 모수값이 실제로 θ_0이라면, 이 추정량의 평균제곱오차는 0이 되며, $\theta = \theta_0$에서 이것보다 더 작은 평균제곱오차를 갖는 추정량은 없다. 그러나 이러한 표본과 무관한 추정방법은 θ가 θ_0로부터 멀리 떨어져 있을수록 평균제곱오차를 크게 만들 것이며 매우 비과학적이고 비상식적인 방법이 된다. 따라서 이러한 비과학적인 추정량들을 고려대상에서 제외하는 것이 합리적일 것이다. 이런 편협된 부적절한 추정량들을 제외하는 하나의 방법으로 아래에 정의된 비편향추정량(unbiased estimator)들의 집합을 고려하고, 그 안에서 평균제곱오차를 최소화하는 추정방법을 찾을 수 있다. 자세한 방법은 다음 절에서 다루어진다.

정의 4.3

$T(X)$를 $g(\theta)$의 추정량이라고 할 때, $E[T(X)] - g(\theta)$를 $T(X)$의 **편향**(bias)이라고 하며 $E[T(X)] = g(\theta)$(즉 편향 $= 0$)이면 $T(X)$를 $g(\theta)$의 **비편향추정량**이라고 한다. 추정량 $T(X)$의 분산은 $E[T(X) - E[T(X)]]^2$이다.

즉, 비편향추정량은 그 기댓값이 추정하고자 하는 모수와 같기 때문에, 추정대상을 과대추정하거나 과소추정하는 경향이 없이 평균적으로 목표치를 잘 맞추고 있다는 뜻이 된다.

예 4.17

$X_1, X_2, \cdots, X_{10}$을 $N(\mu, \sigma_0^2)$ (σ_0^2은 알려진 값)으로부터 얻은 랜덤표본이라 할 때, $T_1(X) = \overline{X}_{10}$와 $T_2(X) = (X_1 + X_2)/2$는 $E[T_1(X)] = E[T_2(X)] = \mu$이므로 모두 모평균 μ의 비편향추정량이다.

예 4.18

앞의 예 4.9에서 고려한, $U(0, \theta)$에서의 θ의 추정량 $X_{(n)}$에 대해 생각해 보자. 이 분포에서 나오는 X의 값은 모두 0에서 θ 사이에 있으므로 표본최댓값 $X_{(n)}$도 θ보다 클 수 없다. θ보다 작을 수는 있으나 클 수는 없으므로 그 기댓값은 당연히 θ보다 작게 된다. 즉, 표본최댓값은 비편향추정량이 아니다. 표본최댓값의 기댓값은

$$E(X_{(n)}) = \int_0^\theta t \frac{nt^{n-1}}{\theta^n} dt$$

$$= \frac{nt^{n+1}}{(n+1)\theta^n}\Big|_0^\theta$$

$$= \frac{n}{n+1}\theta$$

으로 예상한 바와 같이 θ보다 작다. 따라서,

$$T_1(X) = \left(\frac{n+1}{n}\right) X_{(n)}$$

이라고 하면

$$E(T_1(X)) = \frac{n+1}{n} \cdot \frac{n}{n+1} \cdot \theta = \theta$$

이므로 $T_1(X)$은 θ의 비편향추정량이다.

그런데 추정의 기준이 되는 평균제곱오차(MSE)는 다음 정리와 같이 분산과 편향(bias)의 제곱의 합으로 구성할 수 있다.

정리 4.2

모수의 함수 $g(\theta)$의 추정량 $T(X)$의 평균제곱오차(MSE)는

$$\text{MSE} = Var(T(X)) + (\text{bias})^2$$

을 만족한다.

증명 $\text{MSE} = E[T(X) - g(\theta)]^2$

$$= E[\{T(X) - E(T(X))\} + \{E(T(X)) - g(\theta)\}]^2$$
$$= E\{T(X) - E(T(X))\}^2 + \{E(T(X)) - g(\theta)\}^2$$
$$+ 2E\{T(X) - E(T(X))\}\{E(T(X)) - g(\theta)\}$$
$$= Var(T(X)) + [E(T(X)) - g(\theta)]^2$$
$$+ 2\{E(T(X)) - g(\theta)\}\{E(T(X)) - E(T(X))\}$$

$$= Var(T(X)) + (\text{bias})^2 \qquad \blacksquare$$

정리 4.2에 의하면, 평균제곱오차를 기준으로 추정하는 데에는 분산과 편향의 두 요소가 존재함을 알 수 있다. 즉, 평균제곱오차를 작게 하는 추정량은 편향의 절댓값과 분산, 둘 다 작은 값을 가져야 한다는 것이다. 나아가 비편향추정량들만의 집합을 고려할 때는, 평균제곱오차를 최소화하는 추정량을 구하기 위해 분산을 (가능하면 모든 θ에 대하여 균일하게) 최소화하는 추정량을 구하면 된다.

과대 또는 과소추정하는 경향이 없도록 비편향추정량을 사용하기로 하는 경우에도, 때로는 여러 개의 비편향추정량이 존재하기 때문에 그중에 가장 좋은 것을 골라야 하며, 그러기 위해 평균제곱오차를 비교해야 하는데, 이때 다음의 정의에서와 같이 분산의 비(variance ratio)를 이용하면 편리하다.

정의 4.4

$T_1(X)$와 $T_2(X)$가 $g(\theta)$의 비편향추정량일 때 그 분산의 비, 즉 $\dfrac{Var[T_2(X)]}{Var[T_1(X)]}$를 추정량 $T_1(X)$의 $T_2(X)$에 대한 **상대효율**(relative efficiency)이라고 한다.

$T_1(X)$의 분산이 $T_2(X)$의 분산보다 작으면 평균제곱오차의 기준에 따라 $T_1(X)$가 더 좋은 추정량이며, 이때 $T_1(X)$의 $T_2(X)$에 대한 상대효율은 1보다 큰 값을 갖게 된다.

예 4.19

위의 예 4.17에서, $T_1(X) = \overline{X}_{10}$와 $T_2(X) = (X_1 + X_2)/2$의 분산은 각각 $Var(T_1(X)) = \sigma_0^2/10$, $Var(T_2(X)) = \sigma_0^2/2$이다. 따라서 추정량 $T_2(X)$의 $T_1(X)$에 대한 상대효율은 $2/10 = 0.2$이며, $T_2(X)$가 $T_1(X)$보다 효율이 낮은 추정량임을 알 수 있다.

예 4.20

예 4.18에서 $U(0, \theta)$의 θ에 대한 비편향추정량으로 고려한

$$\hat{\theta} = T_1(X) = \left(\frac{n+1}{n}\right) X_{(n)}$$

의 확률밀도함수는

$$f_{T_1}(t) = \left(\frac{n}{n+1}\right)^n \times \frac{nt^{n-1}}{\theta^n}, \qquad 0 < t < \left(\frac{n+1}{n}\right)\theta$$

이다. 이제 반대로 표본최솟값 $X_{(1)}$에 근거한 θ의 비편향추정량을 고려해 보자.

$$f_{X_{(1)}}(t\,;\theta) = \frac{n}{\theta}\left(1-\frac{t}{\theta}\right)^{n-1}, \qquad 0 < t < \theta$$

이므로

$$E(X_{(1)}) = \int_0^\theta \frac{nt}{\theta}\left(1-\frac{t}{\theta}\right)^{n-1} dt$$

$$= \left(\frac{1}{n+1}\right)\theta$$

가 되고, θ의 비편향추정량으로

$$T_2(X) = (n+1)X_{(1)}$$

을 생각할 수 있다. 이제 두 추정량 $T_1(X)$와 $T_2(X)$의 분산을 비교해 보면

$$E(T_1^2) = \int_0^{(n+1)\theta/n} \left(\frac{n}{n+1}\right)^n \times \frac{nt^{n+1}}{\theta^n}\, dt = \frac{(n+1)^2}{n(n+2)}\theta^2$$

이므로

$$Var(T_1(X)) = E(T_1(X)^2) - [\,E(T_1(X))\,]^2$$

$$= \frac{(n+1)^2}{n(n+2)}\theta^2 - \theta^2$$

$$= \frac{\theta^2}{n(n+2)}$$

이다. 마찬가지 방법으로

$$Var(T_2(X)) = \frac{n\theta^2}{n+2}$$

이 계산된다. 따라서

$$\frac{Var(T_2(X))}{Var(T_1(X))} = \frac{n\theta^2/(n+2)}{\theta^2/n(n+2)} = n^2$$

이 되어 $n > 1$일 때 $T_2(X)$에 비해 $T_1(X)$가 더 좋은 효율을 가졌다고 할 수 있으며, 표본의 크기가 크면 $T_1(X)$의 효율이 $T_2(X)$에 비해 훨씬 높아진다.

여기에서 상대효율의 실질적인 의미를 살펴보자. $T_1(X)$와 $T_2(X)$가 $g(\theta)$의 비편향 추정량이고, $Var(T_1(X)) = \nu_1/n$, $Var(T_2(X)) = \nu_2/n$라고 하면 $T_1(X)$의 $T_2(X)$에 대한 상대효율은 ν_2/ν_1이 된다. 그런데 두 추정방법이 같은 분산을 갖기 위한 표본의 크기를 n_1, n_2라고 하면 $\nu_1/n_1 = \nu_2/n_2$로부터 $\nu_2/\nu_1 = n_2/n_1$의 관계를 얻게 된다. 즉, 상대효율이 같은 분산을 갖기 위한 표본크기의 비로 해석될 수 있다는 것을 말한다.

두 개의 주어진 비편향추정량은 이와 같이 상대효율로 비교할 수 있으나, 비편향추정량은 여러 개 존재할 수 있고 모든 비편향추정량을 한꺼번에 고려하기는 어렵다. 그렇다면 어떻게 효율이 가장 높은 비편향추정량을 찾을 수 있을까?

$T^*(X)$를 $g(\theta)$의 비편향추정량이라고 할 때, $g(\theta)$의 모든 비편향추정량 $T(X)$에 대하여

$$\frac{Var(T^*(X))}{Var(T(X))} \leq 1 \tag{4.6}$$

이 성립하면 $T^*(X)$는 100%의 효율이 있다고 말한다. 이제 우리가 원하는 바는 100% 효율을 가지는 비편향추정량, 즉 최소분산 비편향추정량을 찾는 것이다.

4.4 최소분산 비편향추정량

이제 비편향추정량들 중에서 평균제곱오차, 즉 이 경우에는 분산을 최소화하는 최소분산 비편향추정량(Minimum Variance Unbiased Estimator, MVUE)에 대해 다루기로 한다.

정의 4.5

확률변수 $X_1, X_2, \cdots, X_n$ 의 결합 확률밀도함수가 $f(x_1, x_2, \cdots, x_n; \theta)$ 라고 하자. 함수 $g(\theta)$의 추정량 $T^*(X)$가 다음의 조건 (1), (2)를 만족시키면 이를 $g(\theta)$의 **최소분산 비편향추정량**(Minimum Variance Unbiased Estimator, MVUE)이라고 한다.

(1) $T^*(X)$는 $g(\theta)$의 비편향추정량이다(즉 $E[T^*(X)] = g(\theta)$).

(2) $g(\theta)$의 임의의 비편향추정량 $T(X)$에 대해서

$$Var(T^*(X)) \leq Var(T(X))$$

를 만족한다.

$g(\theta)$의 최소분산 비편향추정량을 구하는 데는 다음의 두 가지 방법이 가능하다. 하나는 $g(\theta)$의 비편향추정량 $T(X)$의 분산이 적절한 조건하에서 비편향추정량이 가질 수 있는 분산의 하한값인 '크래머-라오 하한값(Cramer-Rao lower bound)'을 갖는지 확인하는 방법이고, 다른 하나는 완비 충분통계량을 활용하여 라오-블랙웰(Rao-Blackwell)의 정리와 레만-쉐페(Lehmann-Scheffé)의 정리를 사용하는 방법이다.

● 크래머-라오의 방법

우선, 역사적으로 먼저 나왔던 크래머-라오 방법에 대해서 논하기로 하겠다. 크래머-라오의 정보부등식(Cramer-Rao's information inequality)은 적절한 조건하에서 비편향추정량이 가질 수 있는 분산의 하한값을 제공하고 있으며, 이 하한값을 크래머-라오 하한값(Cramer-Rao lower bound)이라고 한다. 어떠한 비편향추정량도 이보다 작은 분산을 가질 수 없다는 뜻으로, 어떤 비편향추정량이 주어진 조건하에서 이 하한값을 분산으로 가지면 이 추정량이 최소분산 비편향추정량이 된다. 단, 이 방법으로 최소분산 비편향추정량의 유일성을 보이기는 어렵다.

우선 정보부등식에 사용되는 **피셔의 정보**(Fisher's information) $I(\theta)$는 확률변수 X의 확률밀도함수가 $f(x;\theta)$일 때 다음과 같이 정의된다.

$$I(\theta) = E[(\frac{\partial}{\partial\theta}\log f(X;\theta))^2] \tag{4.7}$$

예 4.21

$X \sim N(\mu, \sigma_0^2)$ (σ_0^2은 알려진 값)이라고 할 때, 확률밀도함수는

$$f(x\,;\mu) = (\sqrt{2\pi}\,\sigma_0)^{-1}\exp\left[-(x-\mu)^2/2\sigma_0^2\right]$$

이며, 따라서

$$\begin{aligned} I(\mu) &= E\left[(\partial/\partial\mu)\log f(X\,;\mu)\right]^2 \\ &= E\left[\frac{X-\mu}{\sigma_0^2}\right]^2 \\ &= \frac{1}{\sigma_0^2} \end{aligned}$$

로 주어진다.

위의 예 4.21에서 주목할 바는, 우선 σ_0^2가 크면 클수록 하나의 관찰값 X가 모평균 μ에 대하여 가지는 정보는 작아진다는 점과, $I(\mu)$가 μ의 값에 의존하지 않는다는 사실이다. $X \sim N(\mu, \sigma_1^2)$, $Y \sim N(\mu, \sigma_2^2)$이고, $\sigma_1^2 < \sigma_2^2$ 이라고 하자. μ를 추정하기 위해 X나 Y를 이용할 수 있다면, X를 쓰는 것이 더 나을 것이다. 왜냐하면 X의 분산이 작기 때문에 관측값이 μ에 가까이 있을 확률이 더 높기 때문이다. 이와 같이 정규분포의 경우 분산이 작으면 관측값이 모평균에 대하여 가지는 정보가 커진다는 것이 타당해 보인다. 또한 관측값이 모평균에 대하여 가지는 정보는 모평균의 위치에 의존하지 않는데, 이는 모평균이 어디에 있든지 관측값이 모평균과 가까이 있을 확률이 분산에만 의존한다는 것으로, 정규분포의 형태적 특성을 생각할 때 당연한 일이 될 것이다.

예 4.22

X가 '성공' 확률이 p인 베르누이 확률변수라고 하자. 그러면,

$$f_X(x\,;p) = p^x(1-p)^{1-x}, \qquad (x=0,\,1,\;\; 0<p<1)$$
$$\log f_X(X\,;p) = X\log p + (1-X)\log(1-p)$$

이므로

$$\frac{\partial \log f_X(X;p)}{\partial p} = \frac{X}{p} - \frac{1-X}{1-p} = \frac{(X-p)}{p(1-p)}$$

가 된다. 따라서 피셔의 정보는

$$I(p) = E\left[\frac{\partial \log f_X(X;p)}{\partial p}\right]^2$$
$$= \frac{E(X-p)^2}{p^2(1-p)^2} = \frac{1}{p(1-p)}$$

로 계산된다. 여기에서 p가 1/2일 때 피셔의 정보가 가장 작음을 알 수 있다. 베르누이(p) 분포의 분산은 $p(1-p)$로서, 피셔의 정보는 분산의 역수이므로, 정규분포와 마찬가지로 분산이 작은 베르누이 확률변수가 그 평균에 대한 정보를 더 많이 가지고 있다고 할 수 있다.

이제, $X_1, X_2, \cdots, X_n$이 확률밀도함수가 $f(x;\theta)$, $\theta \in \Omega$인 분포로부터 얻은 랜덤표본이라고 하자. 그러면 $g(\theta)$의 비편향추정량 $T(X) = T(X_1, X_2, \cdots, X_n)$의 분산에 대한 부등식은 다음과 같이 주어진다.

정리 4.3

정보부등식(Information Inequality): 우선 확률밀도함수 $f(x;\theta)$와 통계량 $T(X)$에 대해 다음과 같은 가정을 한다.

(1) 모수가 다르면 확률밀도함수가 다르다. 즉, $\theta \neq \theta'$이면 $f(x;\theta) \neq f(x;\theta')$.

(2) 집합 $A = \{x : f(x;\theta) > 0\}$는 모수 θ에 의존하지 않으며, 모든 $x \in A$, $\theta \in \Omega$에 대하여 $\log f(x;\theta)$는 θ에 대해 두 번 미분 가능하고 도함수가 연속이다.

(3) 통계량 $T(X)$가 모든 $\theta \in \Omega$에 대하여 $E(T(X)) < \infty$이면,

$$\frac{\partial}{\partial \theta}\int_{-\infty}^{\infty}\cdots\int_{-\infty}^{\infty} T(x_1, \cdots, x_n)\prod_{i=1}^{n} f(x_i;\theta)\,dx_1 \cdots dx_n$$
$$= \int_{-\infty}^{\infty}\cdots\int_{-\infty}^{\infty} T(x_1, \cdots, x_n)\frac{\partial}{\partial \theta}\prod_{i=1}^{n} f(x_i;\theta)\,dx_1 \cdots dx_n$$

이다.

이제 모든 $\theta \in \Omega$에 대하여 $Var(T(X)) < \infty$, $E(T(X)) = g(\theta)$, $0 < I(\theta) < \infty$라고 하면, $g(\theta)$는 미분 가능하며

$$Var(T(X)) \geq \frac{[g'(\theta)]^2}{nI(\theta)}$$

이 성립한다.

증명 $T(X) = T(X_1, X_2, \cdots, X_n)$은 $g(\theta)$의 비편향추정량이므로,

$$\begin{aligned} g'(\theta) &= \frac{\partial}{\partial\theta} g(\theta) = \frac{\partial}{\partial\theta} \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} T(x_1, \cdots, x_n) \prod_{i=1}^{n} f(x_i;\theta)\, dx_1 \cdots dx_n \\ &= \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} T(x_1, \cdots, x_n) \frac{\partial}{\partial\theta} \left[\prod_{i=1}^{n} f(x_i;\theta) \right] dx_1 \cdots dx_n \\ &= \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} T(x_1, \cdots, x_n) \frac{\partial}{\partial\theta} \left[\prod_{i=1}^{n} f(x_i;\theta) \right] dx_1 \cdots dx_n \\ &\quad - g(\theta) \frac{\partial}{\partial\theta} \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} \prod_{i=1}^{n} f(x_i;\theta)\, dx_1 \cdots dx_n \end{aligned}$$

$$\left(\because \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} \prod_{i=1}^{n} f(x_i;\theta)\, dx_1 \cdots dx_n = 1 \text{이므로} \right.$$

$$\left. \frac{\partial}{\partial\theta} \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} \prod_{i=1}^{n} f(x_i;\theta)\, dx_1 \cdots dx_n = 0 \right)$$

$$\begin{aligned} &= \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} [\, T(x_1, \cdots, x_n) - g(\theta)\,] \frac{\partial}{\partial\theta} \left[\prod_{i=1}^{n} f(x_i;\theta) \right] dx_1 \cdots dx_n \\ &= \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} [\, T(x_1, \cdots, x_n) - g(\theta)\,] \left[\frac{\partial}{\partial\theta} \log \prod_{i=1}^{n} f(x_i;\theta) \right] \\ &\qquad \times \prod_{i=1}^{n} f(x_i;\theta)\, dx_1 \cdots dx_n \\ &= E\left[(\, T(X) - g(\theta)) \left(\frac{\partial}{\partial\theta} \log \prod_{i=1}^{n} f(X_i;\theta) \right) \right] \end{aligned}$$

이 성립한다. 이제 코시-쉬바르츠 정리에 의하여,

$$[g'(\theta)]^2 \le E\left[\left\{T(X)-g(\theta)\right\}^2\right]\cdot E\left[\left(\frac{\partial}{\partial\theta}\log\prod_{i=1}^{n}f(X_i;\theta)\right)^2\right]$$
$$= Var(T(X))\times E\left[\left(\frac{\partial}{\partial\theta}\log\prod_{i=1}^{n}f(X_i;\theta)\right)^2\right]$$

또는

$$Var(T(X)) \ge \frac{[g'(\theta)]^2}{E\left[\left(\frac{\partial}{\partial\theta}\log\prod_{i=1}^{n}f(X_i;\theta)\right)^2\right]}$$

이 성립한다. 그런데,

$$E\left[\frac{\partial}{\partial\theta}\log f(X_i;\theta)\right] = \int_{-\infty}^{\infty}\left[\frac{\partial}{\partial\theta}\log f(x;\theta)\right]f(x;\theta)\,dx$$
$$= \int_{-\infty}^{\infty}\frac{\partial}{\partial\theta}f(x;\theta)\,dx = \frac{\partial}{\partial\theta}\int_{-\infty}^{\infty}f(x;\theta)\,dx$$
$$= \frac{\partial}{\partial\theta}(1) = 0$$

이므로

$$E\left[\left(\frac{\partial}{\partial\theta}\log\prod_{i=1}^{n}f(X_i;\theta)\right)^2\right] = E\left[\left(\sum_{i=1}^{n}\frac{\partial}{\partial\theta}\log f(X_i;\theta)\right)^2\right]$$
$$= \sum_{i=1}^{n}\sum_{j=1}^{n}E\left[\left(\frac{\partial}{\partial\theta}\log f(X_i;\theta)\right)\left(\frac{\partial}{\partial\theta}\log f(X_j;\theta)\right)\right]$$
$$= nE\left[\left(\frac{\partial}{\partial\theta}\log f(X;\theta)\right)^2\right]$$

에 의하여 부등식의 결과가 얻어진다. 마지막 등식은 i와 j가 서로 다를 때 X_i와 X_j가 독립이므로

$$E\left[\left(\frac{\partial}{\partial\theta}\log f(X_i;\theta)\right)\left(\frac{\partial}{\partial\theta}\log f(X_j;\theta)\right)\right]$$
$$= E\left[\frac{\partial}{\partial\theta}\log f(X_i;\theta)\right]E\left[\frac{\partial}{\partial\theta}\log f(X_j;\theta)\right]$$

임을 이용하였다. ■

$T(X)$가 θ의 비편향추정량이라고 하면, 위 정리 4.3으로부터,

$$Var(T(X)) \geq \frac{1}{nI(\theta)} \tag{4.8}$$

을 얻을 수 있다. 그러므로 어떤 비편향추정량 $T(X)$가 $Var(T(X)) = 1/nI(\theta)$을 만족한다면, 이 추정량은 비편향추정량 가운데 가장 작은 분산을 갖는 것이고, 때문에 이를 θ의 최소분산 비편향추정량(Minimum Variance Unbiased Estimator)이라고 한다.

예 4.23

$X_1, X_2, \cdots, X_n$을 포아송(λ) 분포로부터 구한 랜덤표본이라고 하자. 우선 피셔의 정보 $I(\lambda)$를 계산하면 다음과 같다.

$$\begin{aligned} I(\lambda) &= E\left[\frac{\partial}{\partial \lambda}\log f(X;\lambda)\right]^2 \\ &= E\left[-1+\frac{X}{\lambda}\right]^2 \\ &= E\left[\frac{X-\lambda}{\lambda}\right]^2 \\ &= \frac{1}{\lambda} \end{aligned}$$

그런데 $Var(\overline{X}_n) = \lambda/n$이므로 식 (4.8)에 의하여 표본평균 $\overline{X}_n$는 최소분산 비편향추정량이다.

예 4.24

$X_1, X_2, \cdots, X_n$을 $N(\mu, \sigma^2)$으로부터 얻은 랜덤표본이라고 하자. 이때 피셔의 정보는 $I(\mu) = 1/\sigma^2$이고, $Var(\overline{X}_n) = \sigma^2/n$이므로, 역시 식 (4.8)에 의해서 $\overline{X}_n$는 최소분산 비편향추정량이다.

주 위와 같은 크래머-라오 방법의 사용에는 몇 가지 유의할 점이 있다. 우선, 정보부등식이 제공하는 분산의 하한값을 갖지 않더라도 최소분산 비편향추정량이 될 수 있다는 점이다. 즉, 정보부등식의 하한이 너무 작아서 그 값을 갖는 추정량이 없을 경우 어떤 비편향

추정량이 정보부등식이 제공하는 분산의 하한값을 갖지 않더라도 가장 뛰어난 추정량이 될 수 있다. 또한 정보부등식이 성립하는 가정들을 어기는 경우 정보부등식에서 주어지는 분산의 하한값보다 더 작은 분산을 가지는 비편향추정량도 존재할 수 있다(참조: 연습문제 4.26).

● 완비충분 통계량 방법

최소분산 비편향추정량을 구하는 두 번째 방법으로 완비충분 통계량의 활용을 다루어 보기로 한다. 우선, 충분통계량(sufficient statistic)의 정의는 다음과 같다.

정의 4.6

확률벡터 $\boldsymbol{X}=(X_1, X_2, \cdots, X_n)$의 결합 확률밀도함수가 $f(x_1,\cdots,x_n;\theta_1,\cdots,\theta_k)$일 때 $\boldsymbol{S}(\boldsymbol{X})=(S_1(\boldsymbol{X}),\cdots, S_l(\boldsymbol{X}))$를 l개 통계량의 벡터라고 하자. 이때 조건부 확률변수 $(X_1, X_2, \cdots, X_n)\,|\,\boldsymbol{S}(\boldsymbol{X})$의 분포가 모수 $\theta=(\theta_1, \theta_2,\cdots, \theta_k)$에 의존하지 않으면 통계량 $\boldsymbol{S}(\boldsymbol{X})$를 **결합 충분통계량**(jointly sufficient statistic)이라고 한다. 일변량의 경우($l=1$)에는 $S(\boldsymbol{X})$가 θ의 **충분통계량**이라고 한다.

위 정의는, 일단 충분통계량의 값이 주어지면 표본의 결합분포는 모수에 의존하지 않으므로 표본이 더 이상 모수에 대한 아무런 정보를 가지고 있지 않다는 것을 의미한다. 표본이 모수의 추정에 사용되는 이유는 확률변수 $X_1,\cdots,X_n$ 각각은 모수의 함수가 아니지만 그 분포가 모수에 의존하기 때문인데, 이제 충분통계량의 값이 알려지면 표본의 조건부 분포가 모수에 의존하지 않으므로 모수추정에 이용될 근거를 잃어버리게 되며, 모수추정과 관계없는 정보만이 남는다는 것이다. 따라서 $(X_1, X_2, \cdots, X_n)$이 관찰되었을 때, 모수 θ에 대한 정보는 모두 충분통계량 $\boldsymbol{S}(\boldsymbol{X})$에 포함되어 있다고 할 수 있다. 이것은 자료의 축소(data reduction)를 가능하게 하는데, 모수 θ의 추정이 목적이라면 대규모 자료를 모두 저장할 필요가 없이 충분통계량만 가지고도 같은 효율을 갖는 추정값을 얻을 수 있기 때문이다.

예 4.25

$X_1, X_2, \cdots, X_n$을 베르누이(p)로부터 구한 랜덤표본이라고 할 때 $S=\sum_{i=1}^{n} X_i$의 확률밀도함수는

$$f(s;p)=\binom{n}{s}p^s(1-p)^{n-s} \qquad (s=0,\,1,\cdots,\,n)$$

로 주어진다. 여기에서 $S=\sum_{i=1}^{n}X_i$가 p에 대한 충분통계량임을 보이고자 한다. $S(=\sum_{i=1}^{n}X_i)=s$의 값이 주어졌을 때, $X_1,\ X_2,\ \cdots,\ X_n$의 조건부 확률밀도함수는

$$\begin{aligned} f(x_1,\,x_2,\cdots,x_n|\,s) &= P(X_1=x_1,\cdots,\,X_n=x_n|\,S=s) \\ &= \frac{P(X_1=x_1,\cdots,\,X_n=x_n,\,S=s)}{P(S=s)} \\ &= \begin{cases} \dfrac{P(X_1=x_1,\cdots,\,X_n=x_n)}{P(S=s)}, & s=\sum_{i=1}^{n}x_i \\ 0, & \text{그 외의 경우} \end{cases} \end{aligned}$$

이다. 예를 들어 $n=3$이고 $x_1=1, x_2=0, x_3=1$이라면 $s=2$일 때 $P(X_1=1,\ X_2=0,\ X_3=1,\ S=2)=P(X_1=1,\ X_2=0,\ X_3=1)$이지만 $s=1$이라면 $P(X_1=1,\ X_2=0,\ X_3=1,\ S=1)=0$이 된다. $S\sim B(n,p)$임을 이용하여,

$$\begin{aligned} f(x_1,\,x_2,\cdots,x_n|\,s) &= \frac{f(x_1,\,x_2,\cdots,x_n;p)}{f_S(s;p)}, \quad s=\sum_{i=1}^{n}x_i \\ &= \frac{p^s(1-p)^{n-s}}{\binom{n}{s}p^s(1-p)^{n-s}}, \quad s=\sum_{i=1}^{n}x_i \\ &= \frac{1}{\binom{n}{s}}, \quad s=\sum_{i=1}^{n}x_i \end{aligned}$$

이 되며, 이는 모수 p에 의존하지 않으므로 $S=\sum_{i=1}^{n}X_i$는 p의 충분통계량이다.

주 $(S_1,\cdots,\,S_l)$이 결합 충분통계량이면 $(S_1,\cdots,\,S_l)$의 1 : 1 함수도 역시 결합 충분통계량이다. 즉, $(S_1,\cdots,\,S_l)$이 표본이 갖는 모수에 대한 정보를 모두 갖고 있다면 그의 1 : 1 함수도 그 정보를 모두 갖고 있다는 것이다.

주 정의 4.6과 그 이하 설명에서 $l>1$인 경우 $\boldsymbol{S}$를 이용하여 $(S_1,\cdots,\,S_l)$을 나타내고, $\boldsymbol{X}$를 이용하여 $(X_1,\cdots,X_n)$를 나타내는 등 굵은 문자체로 벡터를 표현하였으나, 이후 혼동이 없다면 굳이 굵은 문자체를 쓰지 않고 S와 X 등을 사용하도록 하겠다.

이와 같은 충분통계량은 모수모형$(P_\theta(x), \theta \in \Omega)$에 있어서 모수에 대한 모든 정보를 가지고 있기 때문에, 자료의 축소(reduction)라는 실제적인 의미뿐 아니라 최소분산 비편향추정량을 찾는 데 중요한 역할을 한다. 그러나 주어진 통계량 $S(X)$가 '충분'한가의 여부를 위의 정의에 의해 파악하는 것은 조건부 확률밀도함수를 구하는 복잡한 과정을 필요로 하며, 다음의 인수분해 정리(factorization theorem)를 사용하면 보다 간단히 확인할 수 있다. 인수분해 정리를 통해 주어진 통계량의 충분성을 확인할 수 있을 뿐만 아니라 어떤 통계량이 충분통계량일지를 결합 확률밀도함수로부터 찾을 수 있다.

정리 4.4

(인수분해 정리) $X_1, X_2, \cdots, X_n$ 의 결합 확률밀도함수가 $f(x_1, x_2, \cdots, x_n ; \theta)$일 때 $S(X) = (S_1(X), \cdots, S_k(X))$ 를 k개의 통계량이라고 하자. 이때 S가 결합 충분통계량일 필요충분조건은 결합 확률밀도함수가 s와 θ만의 함수인 g와, $(x_1, x_2, \cdots, x_n)$만의 함수인 h와의 곱의 꼴로 다음과 같이 나타내어지는 것이다.

$$f(x_1, x_2, \cdots, x_n ; \theta) = g(s(x) ; \theta) \times h(x_1, x_2, \cdots, x_n)$$

증명 여기에서는 이산형인 경우에 대해서 증명하여 본다. S가 결합 충분통계량이고, S의 확률밀도함수를 $f_S(s;\theta)$로 표기하면,

$$\begin{aligned} f(x_1, x_2, \cdots, x_n ; \theta) &= f_S(s ; \theta) f_{X|S}(x_1, x_2, \cdots, x_n \mid s) \\ &= g(s ; \theta) h(x_1, x_2, \cdots, x_n) \end{aligned}$$

와 같이 나타내어진다. 왜냐하면, 충분성의 정의에 의해 조건부 확률밀도함수 $f_{X|s}$는 모수 θ에 의존하지 않기 때문이다. 역으로 $f(x_1, x_2, \cdots, x_n;\theta) = g(s;\theta)$ $h(x_1, x_2, \cdots, x_n)$라고 하면, S의 확률밀도함수는 $f_S(s ; \theta) = P(S = s ; \theta) = \sum f(x_1, \cdots, x_n ; \theta) = \sum g(s ; \theta) h(x_1, x_2, \cdots, x_n) = g(s ; \theta) \sum h(x_1, x_2, \cdots, x_n) = g(s;\theta) c(x)$의 꼴로 표현된다(단, $\sum$은 $s(x_1, x_2, \cdots, x_n) = s$를 만족하는 $x_1, x_2, \cdots, x_n$에 대한 합임). 따라서 $S = s$가 주어졌을 때, $X_1, X_2, \cdots, X_n$의 조건부 확률밀도함수

$$f(x_1, x_2, \cdots, x_n | s) = \frac{f(x_1, x_2, \cdots, x_n; \theta)}{f_S(s; \theta)}$$
$$= h(x_1, x_2, \cdots, x_n)/c(x)$$

는 모수 θ에 의존하지 않으므로 S는 결합 충분통계량이다. ■

예 4.26

$X_1, X_2, \cdots, X_n$을 베르누이(p)로부터 구한 랜덤표본이라고 하면, 이들의 결합 확률밀도함수는

$$f(x_1, x_2, \cdots, x_n; p) = p^{\sum_{i=1}^{n} x_i} (1-p)^{n - \sum_{i=1}^{n} x_i} \prod_{i=1}^{n} I_{\{0,1\}}(x_i)$$

이다. 따라서 $S = \sum_{i=1}^{n} X_i$일 때,

$$h(x_1, x_2, \cdots, x_n) = \begin{cases} 1, & x_i = 0, 1, \quad i = 1, \cdots, n \\ 0, & \text{그 외의 경우} \end{cases}$$

과

$$g(s; p) = p^{\sum_{i=1}^{n} x_i} (1-p)^{n - \sum_{i=1}^{n} x_i} = p^s (1-p)^{n-s}$$

를 택하면

$$f(x_1, x_2, \cdots, x_n; p) = g(s; p) h(x_1, x_2, \cdots, x_n)$$

의 꼴로 표현할 수 있다. 그러므로 $\sum_{i=1}^{n} X_i$는 충분통계량이다.

예 4.27

$X_1, X_2, \cdots, X_n$을 $U(\theta_1, \theta_2)$로부터 구한 랜덤표본이라고 하면 이들의 결합 확률밀도함수는

$$f(x_1, \cdots, x_n; \theta_1, \theta_2) = \prod_{i=1}^{n} \frac{1}{\theta_2 - \theta_1} I_{(\theta_1, \theta_2)}(x_i)$$

$$= \frac{1}{(\theta_2-\theta_1)^n}\prod_{i=1}^{n} I_{(\theta_1,\theta_2)}(x_i)$$

$$= \frac{1}{(\theta_2-\theta_1)^n}\, I_{(\theta_1, x_{(n)})}(x_{(1)})\, I_{[x_{(1)},\theta_2)}(x_{(n)})$$

으로 주어진다. 왜냐하면 모든 X_i들이 구간 (θ_1,θ_2)에 포함된다는 것은, 그것의 표본최솟값이 θ_1보다 크거나 같고, 표본최댓값이 θ_2보다 작거나 같다는 것과 동치이기 때문이다. 물론 표본최댓값이 표본최솟값보다 크거나 같음을 만족해야 함은 자명한 사실이다. 따라서 결합 확률밀도함수는 $x_{(1)}$과 $x_{(n)}$을 통해서만 $x_1, x_2, \cdots, x_n$ 에 의존하므로 $h(x_1, x_2, \cdots, x_n)=1$ 이라고 하면, 정리 4.4에 의하여 표본최솟값 $X_{(1)}$과 표본최댓값 $X_{(n)}$은 결합 충분통계량이 된다.

예 4.28

$X_1, X_2, \cdots, X_n$ 이 $N(\mu, \sigma^2)$으로부터 구한 랜덤표본이라고 할 때 이들의 결합 확률밀도함수는

$$f(x_1, x_2, \cdots, x_n; \mu, \sigma^2) = (\sqrt{2\pi}\,\sigma)^{-n}\exp\left[-\frac{\sum_{i=1}^{n}(x_i-\mu)^2}{2\sigma^2}\right]$$

으로 주어진다. 그런데 이는

$$f(x_1, x_2, \cdots, x_n; \mu, \sigma^2) = (\sqrt{2\pi}\,\sigma)^{-n}\exp\left[-\frac{\sum_{i=1}^{n}x_i^2 - 2\mu\sum_{i=1}^{n}x_i + n\mu^2}{2\sigma^2}\right]$$

와 같이 표현되므로, 위 정리 4.4로부터 $S_1=\sum_{i=1}^{n}X_i$와 $S_2=\sum_{i=1}^{n}X_i^2$은 결합 충분통계량이다. 나아가 S_1과 S_2의 1 : 1 함수인 $\overline{X}_n$과 $\sum_{i=1}^{n}(X_i-\overline{X}_n)^2$도 역시 결합 충분통계량이다.

예 4.29

$X_1, X_2, \cdots, X_n$ 이 확률밀도함수가 $f(x;\theta)$인 연속분포로부터의 랜덤표본이라고 하

면, 순서통계량은 결합 충분통계량이다. 왜냐하면, 주어진 $x_{(1)}, x_{(2)}, \cdots, x_{(n)}$ 에 대하여 $(X_1, X_2, \cdots, X_n)$ 이 가질 수 있는 값은 $n!$ 개의 벡터 $(x_{(i_1)}, x_{(i_2)}, \cdots, x_{(i_n)})$ 이며, 이들은 대칭이기에 각각 조건부확률 $1/n!$을 가지므로 모수 θ에 의존하지 않기 때문이다. 여기에서 $(i_1, i_2, \cdots, i_n)$는 $(1, 2, \cdots, n)$의 순열(permutation)이다.

충분통계량의 의미는 모수에 대한 정보를 잃지 않고 자료를 축소하는 데 있었다. 그 의미를 생각해 보면, 표본이 가지고 있는 모수에 대한 정보를 고스란히 가지고 있는 통계량은 모두 충분통계량이 될 수 있다. 즉, 충분통계량은 유일하지 않다는 것이다. 가령 $X_1, X_2, \cdots, X_n$이 $N(\mu, \sigma^2)$으로부터의 랜덤표본일 때 예 4.28에서 보듯이 $(\overline{X}_n, S_n^2)$이 (μ, σ^2)에 대한 충분통계량이지만, 예 4.29에서처럼 순위통계량 $X_{(1)}, X_{(2)}, \cdots, X_{(n)}$도 충분통계량이며, 표본 $X_1, X_2, \cdots, X_n$ 자체는 당연히 충분통계량이다. 많은 충분통계량 가운데 어떤 통계량을 사용하면 좋을지 결정해야 하는 경우, 자료의 축소라는 충분통계량의 의미를 생각할 때, 모수에 관한 정보를 잃지 않으면서 자료를 가장 많이 축소시키는 충분통계량을 선호하게 된다. 즉, 모수의 추정에 필요 없는 정보를 가장 적게 가지고 있는 충분통계량이 좋다는 것이다. 그러한 충분통계량을 **최소충분통계량**(minimal sufficient statistic)이라고 하는데, 이를 수리적으로 표현하자면, 어떤 충분통계량 S가 임의의 다른 충분통계량의 함수일 때 이 S가 최소 충분통계량이 된다. S가 다른 충분통계량 U의 함수이면 U의 값을 알 때 S를 계산할 수 있고, 즉 U의 정보만 가지고 S를 알 수 있기에 U가 적어도 S보다 크거나 같은 정보량을 갖는다고 할 수 있다. S와 U가 모두 충분통계량이라고 했으므로, S는 모수에 관한 정보를 모두 갖고 있으면서 자료를 더 많이 축소시킨다고 할 수 있다. 앞의 예에서 $(\overline{X}_n, S_n^2)$는 주어진 충분통계량 $(X_1, X_2, \cdots, X_n)$ 또는 $(X_{(1)}, X_{(2)}, \cdots, X_{(n)})$는 물론이고 다른 임의의 충분통계량의 함수이므로 최소 충분통계량이다. 이에 대한 증명이나 최소 충분통계량을 찾는 일반적인 방법은 생략하기로 한다.

나아가, 모수에 대한 모든 정보를 갖고 있는 충분통계량을 활용하는 추정 방법의 원리는 다음의 라오-블랙웰 정리에서 드러난다.

정리 4.5

(라오-블랙웰 정리) 모수의 함수 $g(\theta)$에 대하여 S가 충분통계량이고, $T(X)$가 그의 한 비편향추정량이라고 하자. 이때 $\delta(S) = E(T(X) \mid S)$ 라고 하면 $\delta(S)$도

역시 $g(\theta)$의 비편향추정량이며, 모든 θ에 대하여

$$\begin{aligned} Var(\delta(S)) &= E\left[(\delta(S)-g(\theta))^2\right] \\ &\le E\left[(T(X)-g(\theta))^2\right] \\ &= Var(T(X)) \end{aligned}$$

가 성립한다.

증명 우선, S의 충분성에 의하여 $\delta(S)$는 모수 θ에 의존하지 않으므로 그 자체로 추정량이 될 수 있으며, 이중기댓값 정리에 의하면 $E(\delta(S)) = E(T(X)) = g(\theta)$ 이므로 $\delta(S)$는 $g(\theta)$의 비편향추정량이다. 한편, 정리 2.13에서 $Y = T(X)$, $X = S$라고 놓으면,

$$\begin{aligned} Var(T(X)) &= E(Var(T(X)|S)) + Var(E(T(X)|S)) \\ &= E[E((T(X)-\delta(S))^2|S)] + Var(\delta(S)) \\ &\ge Var(\delta(S)) \end{aligned}$$

가 성립한다. 이때 등호는 $Var(T(X)\,|\,S) = 0$, 즉 $T(X) = \delta(S)$인 경우에 성립하게 된다. ■

위 정리의 내용은 어떤 비편향추정량 $T(X)$가 존재하면 충분통계량 S에 대한 조건부 기댓값 $E[T(X)|S]$ 역시 비편향추정량이며, $T(X)$보다 작거나 같은 분산을 가진다는 것이다. 따라서 비편향추정량 가운데 가장 작은 분산을 가지는 추정량을 찾음에 있어서 그 후보를 충분통계량의 함수 꼴로 국한시킬 수 있다는 의미를 가지고 있다.

예 4.30

$X_1, X_2, \cdots, X_n$을 베르누이(p)로부터 구한 랜덤표본이라고 하자. 이 경우 X_1은 모수 p에 대한 비편향추정량이다. 이제 충분통계량인 $S = \sum_{i=1}^{n} X_i$가 주어졌을 때, X_1의 조건부 확률분포를 살펴봄으로써 이보다 작은 분산을 갖는 비편향추정량을 찾아보자. X_1의 조건부 분포는

$$P\left(X_1=0 \,\middle|\, \sum_{i=1}^{n} X_i = s\right) = \frac{P\left(X_1=0,\ \sum_{i=1}^{n} X_i = s\right)}{P\left(\sum_{i=1}^{n} X_i = s\right)}$$

$$= \frac{P\left(X_1=0,\ \sum_{i=2}^{n} X_i = s\right)}{P\left(\sum_{i=1}^{n} X_i = s\right)}$$

$$= \frac{P(X_1=0)\,P\left(\sum_{i=2}^{n} X_i = s\right)}{P\left(\sum_{i=1}^{n} X_i = s\right)}$$

$$= \frac{(1-p)\cdot\binom{n-1}{s}p^s(1-p)^{n-1-s}}{\binom{n}{s}p^s(1-p)^{n-s}}$$

$$= \frac{n-s}{n},$$

$$P\left(X_1=1 \,\middle|\, \sum_{i=1}^{n} X_i = s\right) = \frac{P\left(X_1=1,\ \sum_{i=1}^{n} X_i = s\right)}{P\left(\sum_{i=1}^{n} X_i = s\right)}$$

$$= \frac{P\left(X_1=1,\ \sum_{i=2}^{n} X_i = s-1\right)}{P\left(\sum_{i=1}^{n} X_i = s\right)}$$

$$= \frac{P(X_1=1)\cdot P\left(\sum_{i=2}^{n} X_i = s-1\right)}{P\left(\sum_{i=1}^{n} X_i = s\right)}$$

$$= \frac{p\cdot\binom{n-1}{s-1}p^{s-1}(1-p)^{n-1-s+1}}{\binom{n}{s}p^s(1-p)^{n-s}}$$

$$= \frac{s}{n}$$

으로 구해지는데, 예상했던 바와 같이 조건부 확률변수 $X_1 \left| \sum_{i=1}^{n} X_i = s \right.$ 의 분포가 모수 p에 의존하지 않는다. 위 확률을 이용하면

$$E\left(X_1 \left| \sum_{i=1}^{n} X_i = s \right. \right) = 0 \times (1 - \frac{s}{n}) + 1 \times \frac{s}{n} = \frac{s}{n}$$

이며, $E(T(X)|S) = S/n$ 는 p의 새로운 비편향추정량이 된다. 라오-블랙웰 정리에 의하면 이것은 X_1보다 분산이 작거나 같은데, 실제로 X_1의 분산은 $p(1-p)$이며 $E(T(X)|S) = \sum_{i=1}^{n} X_i/n$의 분산은 $p(1-p)/n$이다.

앞의 라오-블랙웰 정리를 이용하면 충분통계량의 함수로서의 비편향추정량이 유일한 경우 그것이 바로 최소분산 비편향추정량이 됨을 알 수 있다. 어떤 충분통계량 S가 있어서 이 충분통계량의 함수로서의 비편향추정량이 $\delta^*(S)$로 유일하다고 해 보자. 또, 이 $\delta^*(S)$보다 더 좋은 비편향추정량이 있는지 확인하기 위해 어떤 비편향추정량 $T(X)$를 가정하자. 만약 $T(X)$가 S의 함수가 아니라면, 라오-블랙웰 정리에 의해 $E(T(X)|S)$가 더 좋은 비편향추정량이 될 것이고, 그것은 가정된 유일성에 의해 $\delta^*(S)$와 같게 된다. 만약 $T(X)$가 S의 함수라면 그 자체가 $\delta^*(S)$와 같을 수밖에 없다. 즉, $\delta^*(S)$가 모든 비편향추정량 중에 가장 분산이 작은 추정량이 된다.

이제 이 유일성(uniqueness)을 다루는 데 있어 중요한 도구가 되는 '완비성(completeness)'에 대해 살펴보자.

정의 4.7

랜덤표본 $X_1, \cdots, X_n$으로부터 계산된 통계량 $S = S(X_1, \cdots, X_n)$에 대하여, $E(g(S)) = 0$을 모든 $\theta \in \Omega$에 대해 만족하는 θ에 무관한 함수 g가 $g(\cdot) \equiv 0$ 뿐이라면, S를 **완비통계량**(complete statistic)이라고 한다. 만약 S가 θ에 대한 충분통계량이라면, 이를 완비 **충분통계량**이라고 한다.

예 4.31

$X_1, X_2, \cdots, X_n$ 을 베르누이(p)로부터 구한 랜덤표본이라고 하자. 이 경우, 예를 들어 $X_1 - X_2$는 완비통계량이 아니다. 왜냐하면, $E(X_1 - X_2) = 0$이지만 $X_1 - X_2$가

항상 0인 것은 아니기 때문이다. 이제 $T=\sum_{i=1}^{n} X_i$가 완비통계량임을 보이고자 한다. 그런데 $T\sim B(n, p)$이므로

$$E[g(T)] = \sum_{t=0}^{n} g(t)\binom{n}{t}p^t(1-p)^{n-t}$$
$$= (1-p)^n \sum_{i=0}^{n} g(t)\binom{n}{t}\left(\frac{p}{1-p}\right)^t$$

이다.

그러므로 $E[g(T)]=0$이 모든 $0<p<1$에 대하여 성립한다는 것은

$$\sum_{t=0}^{n} g(t)\binom{n}{t}\left(\frac{p}{1-p}\right)^t = 0$$

을 의미한다. 그런데 위 식의 좌변은 $p/(1-p)$에 대한 다항식이며, 다항식이 $\frac{p}{1-p}$의 값에 상관없이 0이 되기 위해서는 $p/(1-p)$에 대한 모든 계수가 0이 되어야 한다. 즉, $g(t)\equiv 0$이다.

예 4.32

$X_1, X_2, \cdots, X_n$을 $U(0, \theta)$로부터 구한 랜덤표본이라고 하자. 이때 표본최대통계량 $X_{(n)}$은 완비통계량인 것이 다음과 같이 보여진다. 예 4.18에서와 같이 $f_{X_{(n)}}(y)=\frac{ny^{n-1}}{\theta^n}$, $0<y<\theta$이므로,

$$E[g(X_{(n)})] = \frac{n}{\theta^n}\int_0^{\theta} g(y)y^{n-1}dy$$

이다. 따라서 $\theta>0$인 모든 θ에 대하여 $E[g(X_{(n)})]=0$이라는 것은

$$\int_0^{\theta} g(y)y^{n-1}dy = 0$$

과 동등하다. 이제 위 식의 양변을 θ에 대하여 미분하면 $g(\theta)\theta^{n-1}=0$이 모든 $\theta>0$에 대하여 성립하는 것을 뜻하고, 이는 $g(\cdot)\equiv 0$과 같다. 즉, $X_{(n)}$은 완비통계량이며, 동시에 충분통계량이기도 하므로 θ에 대한 완비 충분통계량이다.

추정의 이론에 있어서 완비성의 의미를 살펴보면 다음과 같다. $S(X)$가 완비통계량이면 $S(X)$의 서로 다른 두 함수가 같은 기댓값을 가지지 못한다. 즉, $E[g_1(S(X))] = g(\theta)$, $E[g_2(S(X))] = g(\theta)$로 서로 같다고 하면, $E[g_1(S(X)) - g_2(S(X))] = 0$이 되고 완비성에 의해 $g_1(S(X)) = g_2(S(X))$가 되므로 완비통계량의 함수로서의 비편향추정량은 유일하게 된다. 따라서 어떤 비편향추정량이 또한 완비 충분통계량의 함수이면 라오-블랙웰 정리에 의하여 이는 유일한(unique) 최소분산 비편향추정량이 되는 것이다. 다음의 정리 4.6은 최소분산 비편향추정량을 구함에 있어서 완비 충분통계량의 활용을 보여 준다.

정리 4.6

(레만-쉐페 정리) 모수 θ에 대하여 S가 완비 충분통계량이고, $T(X)$가 $g(\theta)$의 비편향추정량이라고 하자. 이때 $\delta(S) = E(T(X) \mid S)$는 $g(\theta)$의 유일한 최소분산 비편향추정량(MVUE)이다.

증명 먼저, $\delta(S)$는 이중기댓값 정리에 의하여 $g(\theta)$의 비편향추정량이다. 이제 임의의 비편향추정량 $\eta(X_1, \cdots, X_n)$을 생각해 보자. 이것이 통계량 S의 함수라면 $\delta^*(S) = \eta(X, \cdots, X_n)$으로 표기하자. 그러면 모든 θ에 대해 $E[\delta(S) - \delta^*(S)] = 0$이고 $\delta(S) - \delta^*(S)$가 S의 함수이므로, 완비성에 의해 $P[\delta(S) = \delta^*(S)] \equiv 1$이 성립한다. $\eta(X_1, \cdots, X_n)$이 S의 함수가 아니라면 라오-블랙웰 정리에 의해 $E(\eta(X_1, \cdots, X_n)|S)$가 $\eta(X_1, \cdots, X_n)$보다 분산이 더 작은 비편향추정량이 되고 이것은 S의 함수이므로 $\delta(S)$와 동일하게 된다. 따라서 $\delta(S)$가 $g(\theta)$의 유일한 최소분산 비편향추정량이다. ■

주 위의 정리 4.6은 모수 θ에 대하여 S가 완비 충분통계량이고, $E(S(X)) = g(\theta)$이면 $S(X)$가 $g(\theta)$의 유일한 최소분산 비편향추정량(MVUE)이라는 것을 의미한다. 그러므로 모수 θ에 대한 최소분산 비편향추정량을 찾기 위해서는 (i) 완비 충분통계량의 함수 가운데 비편향추정량을 찾거나, (ii) 다루기 쉬운 비편향추정량을 골라서 완비 충분통계량으로 조건부 기댓값을 취하면 된다.

예 4.33

$X_1, X_2, \cdots, X_n$ 을 $U(0, \theta)$로부터 구한 랜덤표본이라고 하자. 표본최댓값 $X_{(n)}$이 완비 충분통계량임은 이미 보였다(참조: 예 4.27과 4.32). 그런데 예 4.18로부터 $E[(n+1)X_{(n)}/n] = \theta$이므로

$$\frac{(n+1)X_{(n)}}{n}$$

은 모수 θ의 유일한 최소분산 비편향추정량이다.

이와 같이 완비 충분통계량의 존재는 점추정에 매우 유용한 역할을 하는 반면, 통계량의 완비충분성(특히 완비성)에 대한 입증은 때로 복잡한 계산과정을 수반한다. 그러나 다음에 정의되는 **지수족**(exponential family)에 대해서는 완비충분성이 보장되며, 더구나 자주 사용되는 많은 확률분포가 지수족에 속하므로 이를 쉽게 활용할 수 있다.

정의 4.8

확률밀도함수가 적절한 함수 $a,\ b,\ c_i,\ t_i (i = 1, \cdots, k)$에 대하여,

$$f(x;\theta) = a(\theta)b(x)\exp\left[\sum_{i=1}^{k} c_i(\theta)t_i(x)\right],\ -\infty < x < \infty$$

$\theta = (\theta_1, \cdots, \theta_k)$로 표현되면 이를 k개의 모수 $\theta_1, \cdots, \theta_k$를 가진 지수족에 속한다고 한다. 여기에서 집합 $\{x : f(x;\theta) > 0\}$은 모수 θ에 의존하지 않는다.

예 4.34

'성공' 확률이 p인 베르누이 확률변수 X의 확률밀도함수는

$$\begin{aligned} f(x;p) &= p^x(1-p)^{1-x}, \qquad x = 0, 1 \\ &= (1-p)\exp\left[x \cdot \log\left(\frac{p}{1-p}\right)\right] \end{aligned}$$

로 표현되므로

$$a(p) = 1-p,\ b(x) = 1,\ c(p) = \log\left(\frac{p}{1-p}\right),\ t(x) = x$$

로 잡을 수 있으며, $\{x : f(x;p) > 0\}$은 $\{0,1\}$로서 모수에 의존하지 않는다. 따라서 베르누이 분포는 모수가 하나인 지수족에 속한다.

포아송 확률변수 $X \sim \mathrm{POI}(\lambda)$의 확률밀도함수는

$$f(x;\lambda) = \frac{e^{-\lambda}\lambda^x}{x!}, \quad x = 0, 1, 2, \cdots$$
$$= e^{-\lambda}\frac{1}{x!}\exp(x\log\lambda)$$

로 표현되므로

$$a(\lambda) = e^{-\lambda},\ b(x) = \frac{1}{x!},\ c(\lambda) = \log\lambda,\ t(x) = x$$

로 잡으면 지수족에 속함을 알 수 있다. $\{x : f(x;\lambda) > 0\} = \{0, 1, 2, \cdots\}$로 모수에 의존하지 않는다.

또한 정규확률변수 $X \sim N(\mu, \sigma^2)$의 확률밀도함수도

$$f(x;\mu,\sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}}\exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right]$$
$$= \frac{1}{\sqrt{2\pi\sigma^2}}\exp\left(-\frac{\mu^2}{2\sigma^2}\right)\exp\left(-\frac{1}{2\sigma^2}x^2 + \frac{\mu}{\sigma^2}x\right)$$

단, $a(\mu,\sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}}\exp\left(-\frac{\mu^2}{2\sigma^2}\right)$, $b(x) = 1$,

$$c_1(\mu,\sigma^2) = -\frac{1}{2\sigma^2},\ c_2(\mu,\sigma^2) = \frac{\mu}{\sigma^2},\ t_1(x) = x^2,\ t_2(x) = x$$

로 표현되므로 지수족에 속한다. 여기에서 $\{x : f(x;\mu,\sigma^2) > 0\}$은 실수 전체이므로 모수에 의존하지 않는다.

이외에도 지수족에 속하는 확률분포들로는 지수분포, 베타분포, 감마분포, 음이항분포 등이 있다. 그러나 $U(0,\theta)$ 분포나, 확률밀도함수가 $f(x;\theta) = \exp(-(x-\theta))$, $\theta < x < \infty$인 이동지수(shifted exponential)분포와 같이 $f(x;\theta) > 0$인 x값의 영역이 모수 θ에 의존하는 경우 이들은 지수족에 속하지 않는다. 한편, 지수족에 대해서는 다음의 정리 4.7에 의하여 완비충분성이 갖추어지므로 최소분산 비편향추정량을 구하는

나 정리 4.7의 증명은 매우 복잡하므로 여기에서는 생략하기로 한다).

정리 4.7

지수족에 속하는 확률밀도함수 $f(x;\theta)=a(\theta)b(x)\exp\left[\sum_{i=1}^{k}c_i(\theta)t_i(x)\right]$ 로부터 랜덤표본 $X_1, X_2, \cdots, X_n$ 을 얻었다면, 통계량 $S_1=\sum_{i=1}^{n}t_1(X_i), \cdots, S_k=\sum_{i=1}^{n}t_k(X_i)$는 모수 $\theta_1, \cdots, \theta_k$ 에 대한 결합 완비 충분통계량이다.

정리 4.7에 의하면 $(S_1, \cdots, S_k)$ 의 함수로 만들어지는 $(\theta_1, \cdots, \theta_k)$ 의 비편향 추정량은 $(\theta_1, \cdots, \theta_k)$ 의 최소분산 비편향추정량이 된다.

주 완비 충분통계량의 1:1 함수도 완비 충분통계량이 된다.

예 4.35

$X_1, X_2, \cdots, X_n$ 을 베르누이(p)로부터 구한 랜덤표본이라고 하면 결합 확률밀도함수는

$$f(x_1, x_2, \cdots, x_n; p)=p^{\sum_{i=1}^{n}x_i}(1-p)^{n-\sum_{i=1}^{n}x_i} \qquad (x_i=0, 1, \quad 0<p<1)$$

이며, 예 4.34와 정리 4.7에 의하여 $S=\sum_{i=1}^{n}X_i$는 모수 p에 대한 완비 충분통계량이다(정리 4.7을 사용하지 않고도 이미 예 4.26과 4.31에서 충분성과 완비성을 보였다). 이제 $Var(X)=p(1-p)$에 대한 최소분산 비편향추정량을 구하고자 한다. 이에 완비 충분통계량의 함수인 $\overline{X}_n(1-\overline{X}_n)$을 시도해 보면

$$\begin{aligned}E[\overline{X}_n(1-\overline{X}_n)] &= E(\overline{X}_n)-E(\overline{X}_n^{\,2})\\ &= p-[p^2+Var(\overline{X}_n)]\\ &= p-p^2-\frac{p(1-p)}{n}\\ &= p(1-p)\left[1-\frac{1}{n}\right]\end{aligned}$$

이 되므로, $\dfrac{\overline{X}_n(1-\overline{X}_n)}{\left[1-\dfrac{1}{n}\right]}=\dfrac{n\overline{X}_n(1-\overline{X}_n)}{n-1}$ 는 완비 충분통계량의 함수이면서 비편향추정량이므로 $Var(X)=p(1-p)$의 최소분산 비편향추정량이다.

예 4.36

$X_1, X_2, \cdots, X_n$을 $\mathrm{POI}(\lambda)$ 분포로부터 구한 랜덤표본이라고 하면, 이들의 결합 확률밀도함수는

$$\prod_{i=1}^{n} f(x_i;\lambda)=\frac{\exp(-n\lambda)\lambda^{\sum_{i=1}^{n}x_i}}{\prod_{i=1}^{n}x_i!}, \qquad (x_i=0, 1, 2, \cdots)$$

가 되고, 예 4.34와 정리 4.7에 의하여 $\sum_{i=1}^{n} X_i$은 완비 충분통계량이며 그의 $1:1$ 함수인 $\overline{X}_n$도 완비 충분통계량이다. 이제 모수 λ에 대한 추정량으로 표본평균 $\overline{X}_n$를 사용한다면, $E(\overline{X}_n)=\lambda$이므로 이는 최소분산 비편향추정량이 된다.

예 4.37

$X_1, X_2, \cdots, X_n$이 $N(\mu, \sigma^2)$으로부터 구한 랜덤표본이라고 할 때 이들의 결합 확률밀도함수는

$$f(x_1, x_2, \cdots, x_n;\mu, \sigma^2)=(2\pi\sigma^2)^{-n/2}\exp\left(-\sum_{i=1}^{n}(x_i-\mu)^2/2\sigma^2\right)$$

로 주어진다. 그런데 $\sum_{i=1}^{n}(x_i-\mu)^2=\sum_{i=1}^{n}x_i^2-2\mu\sum_{i=1}^{n}x_i+n\mu^2$으로 표현되므로

$$\begin{aligned} &f(x_1, x_2, \cdots, x_n;\mu, \sigma^2)\\ &\quad=(2\pi\sigma^2)^{-n/2}\exp\left(-\sum_{i=1}^{n}x_i^2/2\sigma^2+(\mu/\sigma^2)\sum_{i=1}^{n}x_i-n\mu^2/2\sigma^2\right)\end{aligned}$$

으로 나타낼 수 있다. 따라서 예 4.34와 정리 4.7로부터 $S_1=\sum_{i=1}^{n}X_i$와 $S_2=$

$\sum_{i=1}^{n} X_i^2$은 각각 결합 완비 충분통계량이다. 이들의 함수인 표본평균 $\overline{X}_n$와 표본분산 $\sum_{i=1}^{n}(X_i-\overline{X}_n)^2/(n-1)$은 $E(\overline{X}_n)=\mu$, $E\left(\sum_{i=1}^{n}(X_i-\overline{X}_n)^2/(n-1)\right)=\sigma^2$으로 μ와 σ^2의 비편향추정량이므로, 이들은 최소분산 비편향추정량이다. 또한 만일 모평균 μ의 값이 알려져 있다면, 모수의 숫자 $k=1$이고 $\sum_{i=1}^{n}(X_i-\mu)^2$은 완비 충분통계량이며 $E\left(\sum_{i=1}^{n}(X_i-\mu)^2/n\right)=\sigma^2$이므로 $\sum_{i=1}^{n}(X_i-\mu)^2/n$이 모분산 σ^2의 최소분산 비편향추정량이 된다. 이 경우 모분산 σ^2의 최대가능도 추정량도 $\sum_{i=1}^{n}(X_i-\mu)^2/n$이므로 두 추정량이 동일하지만, 모평균 μ를 모르는 경우에는 σ^2의 최대가능도 추정량이 $\sum_{i=1}^{n}(X_i-\overline{X}_n)^2/n$이 되어, 최소분산 비편향추정량 $\sum_{i=1}^{n}(X_i-\overline{X}_n)^2/(n-1)$과 다름을 볼 수 있다.

나아가, 완비 충분통계량의 성질을 나타내는 바수(Basu)의 정리를 살펴보자.

정리 4.8

(바수 정리) 통계량 $S=(S_1,\cdots,S_k)$가 모수 $\theta=(\theta_1,\cdots,\theta_k)$에 대한 결합 완비 충분통계량이라고 하자. 이때 어떤 통계량 T의 분포가 모수 $\theta=(\theta_1,\cdots,\theta_k)$에 의존하지 않으면, S와 T는 서로 독립이다.

증명 이산형인 경우를 고려하자. $f_T(t)$, $f_S(s;\theta)$, 그리고 $f(t|s)$를 각각 T, S의 확률밀도함수와 $S=s$일 때 T의 조건부 확률밀도함수라고 하면,

$$\begin{aligned} E_\theta[f_T(t)-f(t|S)] &= f_T(t)-\sum_s f(t|s)f(s;\theta) \\ &= f_T(t)-\sum_s f(s,t;\theta) \\ &= f_T(t)-f_T(t) \\ &= 0 \end{aligned}$$

이 성립한다. S의 충분성에 의해 $f_T(t)-f(t|S)$는 θ에 의존하지 않고 S의 완비성에 의하여 모든 s에 대해 $f(t|s)=f_T(t)$가 성립하므로 S와 T는 서로 독

립이다. 연속형 확률변수에 대해서도 마찬가지 방법으로 증명될 수 있다. ■

위의 정리에서와 같이 확률밀도함수가 θ에 의존하지 않는 통계량 T를 θ에 대한 보조통계량(ancillary statistic)이라고 한다. 바수의 정리를 이용하면, 두 통계량의 독립을 보이는 데 있어서 때로는 두 통계량의 복잡한 결합분포를 구하지 않아도 된다는 장점이 있다. 다음의 예를 살펴보자.

예 4.38

$X_1, \cdots, X_n$을 $N(\mu, \sigma^2)$로부터의 랜덤표본일 때, $\widehat{\sigma^2} = \sum_{i=1}^{n}(X_i - \overline{X}_n)^2/n$과 $\hat{\mu} = \overline{X}_n$를 생각해 보자. 고정된 σ^2에 대하여 표본평균 $\overline{X}_n$은 μ에 대한 완비 충분통계량이고, $\frac{n\widehat{\sigma^2}}{\sigma^2}$은 $\chi^2(n-1)$ 분포를 따르며 이는 μ에 의존하지 않는다. 즉, $\frac{n\widehat{\sigma^2}}{\sigma^2}$은 μ에 대한 보조통계량이 되고, 바수의 정리 4.8에 따라 $\hat{\mu} = \overline{X}_n$와 $\widehat{\sigma^2} = \sum_{i=1}^{n}(X_i - \overline{X}_n)^2/n$은 서로 독립이다.

4.5 추정량의 점근적 성질

앞에서 다루었던 추정량의 비편향성 또는 최소분산성 등은 고정된 표본의 크기(n)에 대해 정의된 성질들이었다. 여기에서는 표본의 크기가 커짐에 따라 가지는 추정량의 점근적(asymptotic) 성질에 대해 살펴보기로 한다. 즉, 점점 더 많은 관측치를 갖는 표본을 뽑는다고 가정하고 궁극에는 어떤 일이 일어날 것인지에 대해 살펴보는 것이다.

정의 4.9

모수의 함수 $g(\theta)$의 추정량 $T_n(X) = T(X_1, X_2, \cdots, X_n)$이, 임의의 $\varepsilon > 0$에 대하여

$$\lim_{n\to\infty} P(|T_n(X) - g(\theta)| \le \varepsilon) = 1$$

을 만족하면 추정량 $T_n(X)$는 **일치성**(consistency)이 있다고 한다.