정의 4.9는 표본의 크기가 커짐에 따라 $T_n(X)$가 $g(\theta)$에 확률적으로 수렴한다는 것으로(참조: 정의 3.5), 표본의 크기가 매우 클 때, 추정량 $T_n(X)$로부터 계산된 추정값은 높은 확률로 참모수값에 매우 가까이 있다는 뜻이다.

예 4.39

$X_1, X_2, \cdots, X_n$을 평균이 μ이고 분산이 $\sigma^2 < \infty$인 확률분포로부터 얻은 랜덤표본이라고 하자. 모평균 μ의 추정량으로서 표본평균 $T_n(X) = \overline{X}_n$가 일치성이 있음은 정리 3.12의 대수의 법칙에서 이미 보여졌다.

예 4.40

$X_1, X_2, \cdots, X_n$을 $U(0, \theta)$로부터 얻은 랜덤표본이라고 하자. 이때 최대가능도추정량은 표본최댓값 $X_{(n)}$이다(참조: 예 4.9). 이제 모수 θ의 추정량 $X_{(n)}$의 일치성에 대해 살펴보기로 한다. 임의의 $\varepsilon > 0$에 대하여,

$$\begin{aligned} P[\,|X_{(n)} - \theta| \le \varepsilon\,] &= P[\,\theta - \varepsilon \le X_{(n)} \le \theta\,] \\ &= \int_{\theta-\varepsilon}^{\theta} \frac{n(x_{(n)})^{n-1}}{\theta^n}\, dx_{(n)} \\ &= \frac{(x_{(n)})^n}{\theta^n}\Bigg|_{\theta-\varepsilon}^{\theta} \\ &= 1 - \left[\frac{\theta-\epsilon}{\theta}\right]^n \end{aligned}$$

이 성립한다. $0 < \varepsilon < \theta$이면 n이 커질 때 $\left(\frac{\theta-\varepsilon}{\theta}\right)^n \to 0$이므로 $P[\,|X_{(n)} - \theta| \le \varepsilon\,] \to 1$이 되고, $\varepsilon \ge \theta$이면 모든 n에 대해 $P[\,|X_{(n)} - \theta| \le \varepsilon\,] = 1$이 된다. 그러므로 표본최댓값 $X_{(n)}$은 θ의 일치추정량이다.

다음의 정리는 추정량이 일치성을 가질 조건을 평균제곱오차(MSE)를 이용하여 표현하고 있다.

정리 4.9

$T_n(X)$를 $g(\theta)$의 추정량이라고 할 때, 모든 $\theta \in \Omega$에 대하여

$$\lim_{n\to\infty} E[T_n(X)-g(\theta)]^2 = 0$$

이 성립하면, $T_n(X)$는 일치성이 있다.

증명 식 (2.16)의 확률부등식에 의하면, $X = T_n(X)-g(\theta)$, $r=2$, $c=\varepsilon$으로 놓을 때

$$P[\,|T_n(X)-g(\theta)| \le \varepsilon\,] \ge 1-\frac{E[T_n(X)-g(\theta)]^2}{\varepsilon^2}$$

이 성립하므로 일치성이 성립한다. ■

참고 그런데 $\mathrm{MSE}(T_n) = Var(T_n)+[E(T_n)-g(\theta)]^2$이므로 T_n이 $g(\theta)$의 비편향추정량인 경우 $\lim_{n\to\infty} Var(T_n)=0$이 성립하면, 정리 4.9로부터, 추정량 T_n의 일치성이 보장된다.

예 4.41

$X_1, X_2, \cdots, X_n$을 $\mathrm{EXP}(\lambda)$로부터 얻은 랜덤표본이라고 하자. 이때 λ의 추정량으로 $\overline{X}_n$는 비편향추정량이며 $\lim_{n\to\infty}\mathrm{MSE}(\overline{X}_n) = \lim_{n\to\infty} Var(\overline{X}_n)=0$이므로 $\overline{X}_n$는 일치성이 있다. 한편, $nX_{(1)} \sim \mathrm{EXP}(\lambda)$이므로(참조: 예 3.14), $nX_{(1)}$은 λ의 비편향추정량이다. 하지만 $\epsilon < \lambda$인 $\epsilon > 0$에 대해 $P(|nX_{(1)}-\lambda| \le \epsilon) = e^{-1}(e^{\epsilon/\lambda}-e^{-\epsilon/\lambda})$으로 n이 커질 때 1로 수렴하지 않으므로 일치추정량이 아니다.

정리 4.10

T_n이 모수 θ의 일치추정량이라고 하자. 만일 $g(x)$가 θ에서 연속인 함수이면 $g(T_n)$은 $g(\theta)$의 일치추정량이다.

증명 $g(x)$가 θ에서 연속이므로, 임의의 $\varepsilon > 0$에 대하여 $|x-\theta| < \delta$이면 $|g(x)-g(\theta)| < \varepsilon$을 만족하는 $\delta > 0$가 존재한다. 그러므로

$$\lim_{n\to\infty} P[\,|\,g(T_n)-g(\theta)\,|\le \varepsilon\,] \ge \lim_{n\to\infty} P[\,|\,T_n-\theta\,|<\delta\,]=1$$

로부터 $g(T_n)$의 일치성이 구해진다. ■

다음의 정리는 추정량의 일치성을 보이기 위해 유용한 것으로, 증명은 연습문제로 남기기로 한다.

정리 4.11

T_n이 모수 θ_1의 일치추정량이고, S_n이 모수 θ_2의 일치추정량이라고 하자. 그러면 $c_n\to c$이고 $d_n\to d$인 실수열 c_n과 d_n에 대해, $c_nT_n+d_nS_n \xrightarrow{p} c\theta_1+d\theta_2$이고, $T_n/S_n \xrightarrow{p} \theta_1/\theta_2$, $\theta_2\neq 0$, $T_nS_n \xrightarrow{p} \theta_1\theta_2$이다.

예 4.42

3장에서 살펴본 예 3.7에서, 모분산 $g(p)=p(1-p)$는 모수 p의 연속함수이며, 표본비율 p_n은 모비율 p로 확률적으로 수렴한다. 따라서 정리 4.10에 의하여 $g(p_n)=p_n(1-p_n)$도 역시 모분산 $g(p)=p(1-p)$의 일치추정량이다.

예 4.43

$X_1, X_2, \cdots, X_n$이 분산이 유한인 분포에서 뽑힌 랜덤표본이라고 할 때, 표본분산

$$S^2=\sum_{i=1}^{n}(X_i-\overline{X}_n)^2/(n-1)$$

은 모분산 σ^2의 일치추정량이다. 왜냐하면 $S^2=\frac{n}{n-1}\times\frac{1}{n}\sum_{i=1}^{n}X_i^2-\frac{n}{n-1}\overline{X}_n^2$으로 쓸 수 있고, 대수의 법칙에 의해 $\frac{1}{n}\sum_{i=1}^{n}X_i^2 \xrightarrow{p} E(X^2)$, $\overline{X}_n \xrightarrow{p} E(X)$이며 $\frac{n}{n-1}\to 1$이므로 정리 4.11에 의해 $S^2 \xrightarrow{p} E(X^2)-(E(X))^2=\sigma^2$이다. 이제, $g(S^2)=\sqrt{S^2}=S$는 $g(\cdot)$가 연속함수이므로 $g(\sigma^2)=\sqrt{\sigma^2}=\sigma$의 일치추정량이다.

최대가능도 추정량은 불변성 원리와 같이 다루기 편리한 성질도 가지고 있지만, 때로 복잡한 형태를 갖게 되어 직접적으로 일치성을 입증하기 어려운 경우도 있고 심지어 폐쇄형(closed-form)으로 존재하지 않아서 수치적으로밖에 구할 수 없는 경우도 있다. 이럴 때는 최대가능도 추정량에 근거를 둔 구간추정을 하거나 검정을 하는 데에 어려움이 발생할 수 있는데, 적절한 정칙조건이 만족되는 경우에는 점근적 성질을 이용하면 편리하다. 적절한 조건하에서 최대가능도 추정량은 일치성을 가질 뿐 아니라 점근적으로 정규분포를 따르기 때문에 쉽게 근사적 구간추정과 검정을 할 수 있게 된다. 이제, 이러한 최대가능도 추정량의 점근적 성질에 대해 간단히 다루어 보자.

$X_1, \cdots, X_n$이 확률밀도함수 $f(x;\theta)$를 갖는 확률분포로부터의 랜덤표본이고 $\hat{\theta}_n$이 θ의 최대가능도 추정량이라고 하자. 로그가능도함수 (4.4)의 θ에 대한 1차 도함수는 $\hat{\theta}_n$에서 0이 되므로 $\sum_{i=1}^{n} \frac{d}{d\theta} \log f(x_i;\theta)\Big|_{\theta=\hat{\theta}_n} = 0$이며, 대수의 법칙에 의해

$$\frac{1}{n}\sum_{i=1}^{n} \frac{d}{d\theta} \log f(X_i;\theta) \xrightarrow{p} E\left(\frac{d}{d\theta} \log f(X;\theta)\right) \tag{4.9}$$

가 성립한다(단, 우변의 기댓값이 존재한다는 조건이 있을 때). 그런데 식 (4.9)의 왼쪽과 오른쪽을 0으로 하는 해는 각각 최대가능도 추정량 $\hat{\theta}_n$과 모수의 참값인 θ_0이다(참조: 연습문제 4.51). 따라서 적절한 조건에서 $\hat{\theta}_n$이 θ_0으로 수렴할 것으로 기대할 수 있다(여기에서 '적절한 조건'이란 모수의 값이 달라지면 확률밀도함수가 달라지고, 확률밀도함수가 0이 아닌 집합이 모수에 의존하지 않으며, 모수공간이 열려 있고, 로그가능도함수가 두 번 미분 가능하며, 그리고 모수에 대한 미분과 기댓값을 취하기 위한 적분의 순서를 바꿀 수 있는 것을 말한다. 이 책의 수준에서는 θ에 대해 여러 번 미분 가능한 지수족의 경우 이 조건이 만족된다고 간주할 수 있다). 다음의 정리는 적절한 조건이 만족될 때, 최대가능도 추정량이 모수의 일치추정량이 됨을 말하고 있다. 엄밀한 증명은 이 책의 수준을 넘으므로 생략하기로 한다.

정리 4.12

$X_1, X_2, \cdots, X_n$이 확률밀도함수 $f(x;\theta)$를 갖는 랜덤표본일 때 적절한 조건하에서 최대가능도 추정량 $\hat{\theta}_n$은 θ의 일치추정량이다. 즉, $\hat{\theta}_n \xrightarrow{p} \theta$이다.

나아가, 최대가능도 추정량이 가지는 점근적 정규성을 살펴보겠다. 가능도함수를

$L(\theta)$, 로그가능도함수를 $l(\theta)=\log L(\theta)$라고 하고, $L(\theta)=\prod_{i=1}^{n} f(X_i;\theta)$로 $L(\theta)$가 확률변수 X_i들의 함수로서 그 자체가 확률변수라고 생각하자. 그러면 $l(\theta)=\sum_{i=1}^{n}\log f(X_i;\theta)$는 서로 독립이고 분포가 같은 n개의 확률변수의 합으로 표현된다. 모수의 참값이 θ_0일 때, 로그가능도함수를 미분한 $l'(\theta)$를 θ_0에서 테일러 전개하여 $\hat{\theta}_n$을 대입하고 처음 두 항만을 취하면 $l'(\hat{\theta}_n)\approx l'(\theta_0)+l''(\theta_0)(\hat{\theta}_n-\theta_0)$로 나타낼 수 있다. $\hat{\theta}_n$이 θ_0의 일치추정량이므로 n이 커질 때 두 값이 확률적으로 매우 가까우므로 테일러 전개에서 고차항들은 무시할 수 있는 값일 것이다. $l'(\hat{\theta}_n)=0$이므로,

$$\hat{\theta}_n-\theta_0\approx -\frac{l'(\theta_0)}{l''(\theta_0)}$$

과 같은 근사식을 얻을 수 있고, 이로부터

$$\sqrt{n}(\hat{\theta}_n-\theta_0)\approx \frac{\frac{1}{\sqrt{n}}l'(\theta_0)}{-\frac{1}{n}l''(\theta_0)}$$

을 얻는다. 그런데 적절한 조건하에서 대수의 법칙에 의해

$$-\frac{1}{n}l''(\theta_0)=-\frac{1}{n}\sum_{i=1}^{n}\frac{d^2}{d\theta^2}\log f(X_i;\theta)\Big|_{\theta=\theta_0}\xrightarrow{p}-E\left(\frac{d^2}{d\theta^2}\log f(X;\theta)\Big|_{\theta=\theta_0}\right)=I(\theta_0)$$

이며 $\frac{1}{\sqrt{n}}l'(\theta_0)\xrightarrow{d}N(0,I(\theta_0))$이 성립한다(참조: 연습문제 4.52, 4.53). 여기에서 $I(\theta_0)$은 4.3절에서 정의된 피셔의 정보를 θ_0에서 측정한 값이다. 이제 정리 3.15의 슬럿츠키 정리를 이용하면 다음과 같은 최대가능도 추정량의 점근적 정규성을 보일 수 있다.

정리 4.13

$X_1, X_2, \cdots, X_n$이 확률밀도함수 $f(x;\theta)$를 갖는 랜덤표본이고 모수의 참값이 θ_0일 때, 적절한 조건하에서 최대가능도 추정량 $\hat{\theta}_n$에 대해

$$\sqrt{n}(\hat{\theta}_n-\theta_0)\xrightarrow{d}N\left(0,\frac{1}{I(\theta_0)}\right)$$

이 성립한다.

예 4.44

$X_1, \cdots, X_n$이 EXP(θ)에서 관측되는 랜덤표본이라고 하자. θ의 최대가능도 추정량은

$$l(\theta; x_1, \cdots, x_n) = -n\log\theta - \frac{\sum_{i=1}^{n} x_i}{\theta}, \quad l'(\theta) = -\frac{n}{\theta} + \frac{\sum_{i=1}^{n} x_i}{\theta^2}$$

으로부터 $\hat{\theta}_n = \overline{X}_n$이고, $\frac{\partial^2}{\partial\theta^2}\log f(x;\theta) = \frac{1}{\theta^2} - \frac{2x}{\theta^3}$ 이므로 $I(\theta) = E_\theta\left(\frac{2X}{\theta^3} - \frac{1}{\theta^2}\right)$ $= \frac{1}{\theta^2}$이다. 그러므로 정리 4.13에 의해,

$$\sqrt{n}\,(\overline{X}_n - \theta) \xrightarrow{d} N(0, \theta^2)$$

가 되고, 이것은 중심극한정리에서 얻는 결과와 동일하다.

4.6 구간추정

지금까지 비편향성(unbiasedness), 적률(moments), 가능도(likelihood) 등의 기준하에서 모수 또는 모수의 함수에 대한 최적추정량들을 고려하였으나 이들은 점추정 문제여서 통계적 정확도(statistical accuracy)를 표현하지 못한다는 결점이 있다. 예를 들면, 포아송(λ)의 경우 모수 λ의 추정량으로서 표본평균 $\overline{X}_n$는 좋은 추정량이지만 정확성에 관한 아무런 정보를 포함하고 있지 않다. 표본평균은 확률변수이므로, 실제 관측된 자료로부터 계산된 표본평균의 값이 정확히 모수와 같을 것으로 생각할 수는 없다. 그렇다면 이 값은 모수로부터 어느 정도 떨어져 있을까? 이러한 정보를 포함하도록 추정결과를 제시하는 방법이 구간추정이며, 구간추정에서는 랜덤표본 X_1, X_2, $\cdots$, X_n에 근거하여 모수에 대한 신뢰구간을 정의하고 그 구간 내에 모수가 포함될 확률로써 통계적 정확도를 표현할 것이다.

정의 4.10

랜덤표본 X_1, X_2, $\cdots$, X_n의 확률밀도함수가 $f(x;\theta)$, $\theta \in \Omega$라고 하자. 확률구

간 $[L(X_1, X_2, \cdots, X_n), U(X_1, X_2, \cdots, X_n)]$이, $0 < \alpha < 1$에 대하여

$$P[L(X_1, X_2, \cdots, X_n) \leq \theta \leq U(X_1, X_2, \cdots, X_n)] = 1 - \alpha$$

를 만족시키면 이를 모수 θ의 $100(1-\alpha)\%$ **신뢰구간**(confidence interval)이라고 한다. 또한 $L(X_1, X_2, \cdots, X_n)$과 $U(X_1, X_2, \cdots, X_n)$을 각각 신뢰구간의 **하한**(lower limit)과 **상한**(upper limit)이라고 한다.

정의 4.10에서 구한 신뢰구간은 표본에 따라 그 결과가 달라지는 확률구간(random interval)이다. 따라서 $(1-\alpha)$는 랜덤표본 $X_1, X_2, \cdots, X_n$의 구체적인 관찰값이 주어지기 이전에 해당하는 확률이다. 즉, 수많은 랜덤표본을 뽑아서 각 표본에 대해 같은 방법으로 신뢰구간을 구하면, 구해진 많은 신뢰구간들 가운데 $100(1-\alpha)\%$ 만큼의 신뢰구간들이 모수를 포함하게 된다는 뜻이다. 이제 크기 n의 표본을 직접 관측했다고 가정하자. 주어진 관찰값 $x = (x_1, \cdots, x_n)$을 $U(X_1, \cdots, X_n)$과 $L(X_1, \cdots, X_n)$에 대입하면 두 개의 고정된 값이 계산될 것이다. 그러면, $[L(x_1, \cdots, x_n), U(x_1, \cdots, x_n)]$은 고정된 구간이 된다. 그리고 모수 θ는 구간 $[L(x_1, \cdots, x_n), U(x_1, \cdots, x_n)]$에 포함되거나 되지 않거나 둘 중의 하나일 뿐이다(이는 점추정에 있어서 추정량과 추정값의 차이와 같다). 즉, 이 고정된 구간이 모수를 포함하게 되는 확률이 $1-\alpha(0 < \alpha < 1)$가 될 수 없다는 것이다. 우리가 관측한 표본에 의해 계산된 신뢰구간은 모수를 포함할 수도 있지만 포함하지 않을 수도 있다. 운이 나쁜 경우에는 모수와 동떨어진 구간을 얻을 수도 있으나, 이러한 구간을 얻을 확률을 $100\alpha\%$로 한정시키게 된다. α가 매우 작은 값, 예를 들어 0.01이라면 우리의 신뢰구간이 '성공'일 확률이 99%라는 것이다. 확률 $1-\alpha$는 **신뢰계수**(confidence coefficient) 또는 **신뢰도**(confidence level)라고 한다. 또한 때로는 신뢰구간이 실직선상의 반구간이 되는 수도 있으며, 이를 다음과 같이 정의한다.

정의 4.11

랜덤표본 $X_1, X_2, \cdots, X_n$의 확률밀도함수가 $f(x;\theta)$, $\theta \in \Omega$라고 하자. 통계량 $L(X_1, X_2, \cdots, X_n)$이 $0 < \alpha < 1$에 대하여

$$P[L(X_1, X_2, \cdots, X_n) \leq \theta] = 1 - \alpha$$

를 만족시키면 $[L(X_1, X_2, \cdots, X_n), +\infty)$를 모수 θ의 $100(1-\alpha)\%$ **단측 하**

한신뢰구간이라고 한다. 또, 통계량 $U(X_1, X_2, \cdots, X_n)$이 $0 < \alpha < 1$에 대하여

$$P[\theta \leq U(X_1, X_2, \cdots, X_n)] = 1 - \alpha$$

를 만족시키면 $(-\infty, U(X_1, X_2, \cdots, X_n)]$를 모수 θ의 $100(1-\alpha)\%$ **단측 상 한신뢰구간**이라고 한다.

예 4.45

$X_1, X_2, \cdots, X_n$을 $N(\mu, 25)$로부터 얻은 랜덤표본이라고 하자. 이때 $L(X_1, X_2, \cdots, X_n) = \overline{X}_n - \frac{10}{\sqrt{n}}$, $U(X_1, X_2, \cdots, X_n) = \overline{X}_n + \frac{10}{\sqrt{n}}$ 이라고 하면, $[L(X_1, X_2, \cdots, X_n), U(X_1, X_2, \cdots, X_n)]$은 확률구간이 되고, 이는 곧 모평균 μ에 대한 신뢰도가

$$\begin{aligned} & P[L(X_1, X_2, \cdots, X_n) \leq \mu \leq U(X_1, X_2, \cdots, X_n)] \\ &= P\left[\overline{X}_n - \frac{10}{\sqrt{n}} \leq \mu \leq \overline{X}_n + \frac{10}{\sqrt{n}}\right] \\ &= P\left[\left|\frac{\sqrt{n}(\overline{X}_n - \mu)}{5}\right| \leq 2\right] \\ &= \Phi(2) - \Phi(-2) \\ &= 0.9544 \end{aligned}$$

인 신뢰구간이다.

그런데 신뢰구간을 구하는 방법으로는 **추축변량**(pivotal quantity)을 사용하는 방법과 추축변량을 구하기 힘든 경우에 사용되는 일반적인 접근방법을 생각할 수 있다. 먼저 추축변량의 사용에 대해 알아보기로 한다. 이 방법은 특히 랜덤표본이 따르는 분포가 연속형일 때 신뢰구간을 구하는 데 유용하다.

정의 4.12

랜덤표본 $X_1, X_2, \cdots, X_n$의 분포가 확률밀도함수 $f(x;\theta)$, $\theta \in \Omega$를 따른다고 하자. 이때 표본과 모수 θ의 함수인 확률변량 $T(X_1, X_2, \cdots, X_n; \theta)$의 분포가 모수 θ에 의존하지 않으면 이를 **추축변량**이라고 한다.

예 4.46

$X_1, X_2, \cdots, X_n$이 $N(\mu, \sigma^2)$에서의 랜덤표본이고 $S_n^2 = \sum_{i=1}^{n}(X_i - \overline{X}_n)^2/(n-1)$일 때, $\sqrt{n}(\overline{X}_n - \mu)/S_n$의 분포는 $t(n-1)$로 모수 (μ, σ^2)에 의존하지 않으므로 추축변량이다.

추축변량을 활용하여 모수의 신뢰구간을 구하는 방법은 다음과 같다. $T = T(X_1, \cdots, X_n ; \theta)$가 추축변량이면, 고정된 $0 < \alpha < 1$에 대하여 $P(t_1 < T < t_2) = 1 - \alpha$를 만족하는 t_1, t_2를 구한다. T의 분포가 모수에 의존하지 않으므로 t_1과 t_2는 α의 값이 주어지면 상수값이 될 것이다. 다음으로 부등식 $t_1 < T(x_1, \cdots, x_n ; \theta) < t_2$를 $L(x_1, \cdots, x_n) < \theta < U(x_1, \cdots, x_n)$의 꼴로 바꿔쓸 수 있다면,

$$P(L(X_1, \cdots, X_n) < \theta < U(X_1, \cdots, X_n)) = 1 - \alpha$$

가 되므로 $[L(X_1, \cdots, X_n),\ U(X_1, \cdots, X_n)]$은 θ에 대한 $100(1-\alpha)\%$ 신뢰구간이 된다. 그런데 추축변량이 언제나 존재한다든가 또는 유일하다는 보장은 없고, 사용하는 추축변량에 따라 서로 다른 신뢰구간들을 얻게 된다. 따라서 우리가 구한 신뢰구간의 성능을 가늠하고 비교하는 기준이 필요하게 되며, 고정된 신뢰도에 대하여 신뢰구간의 길이 등을 그 기준으로 사용할 수 있다.

이제 정규분포로부터 구한 랜덤표본에 근거하여 모수들의 신뢰구간을 구해본다.

정규분포의 모평균에 대한 신뢰구간

$X_1, X_2, \cdots, X_n$을 $N(\mu, \sigma^2)$으로부터의 랜덤표본이라고 하고, 모평균 μ에 대한 신뢰구간을 구해 보자. 이 경우, 모분산 σ^2이 알려져 있으면 변량 $\sqrt{n}(\overline{X}_n - \mu)/\sigma$의 분포는 $N(0, 1)$으로서 모수 (μ, σ^2)에 의존하지 않으므로 추축변량이다. 따라서

$$\begin{aligned} & P\left[-z_{\alpha/2} \le \frac{\sqrt{n}(\overline{X}_n - \mu)}{\sigma} \le z_{\alpha/2} \right] \\ &= P\left[\overline{X}_n - z_{\alpha/2}\frac{\sigma}{\sqrt{n}} \le \mu \le \overline{X}_n + z_{\alpha/2}\frac{\sigma}{\sqrt{n}} \right] \\ &= 1 - \alpha \end{aligned}$$

에 의하여 모평균 μ에 대한 $100(1-\alpha)\%$ 신뢰구간

$$\left[\overline{X}_n - z_{\alpha/2}\frac{\sigma}{\sqrt{n}},\ \overline{X}_n + z_{\alpha/2}\frac{\sigma}{\sqrt{n}} \right] \tag{4.10}$$

을 구할 수 있다(z_α는 표준정규분포의 임계값(critical value)으로서, $100(1-\alpha)\%$ 백분위수이다). 그러나 모분산 σ^2이 알려져 있지 않은 경우에는, 위의 구간 (4.10)이 모르는 모수인 σ^2의 값에 의존하기 때문에 사용할 수 없다. 따라서 σ^2를 $S_n^2 = \sum_{i=1}^{n}(X_i - \overline{X}_n)^2/(n-1)$으로 추정한 추축변량 $\sqrt{n}(\overline{X}_n - \mu)/S_n$이 자유도가 $(n-1)$인 t 분포를 가지는 점을 이용하여 다음과 같이 구할 수 있다.

$$\begin{aligned} & P\left[-t_{\alpha/2}(n-1) \le \frac{\sqrt{n}(\overline{X}_n - \mu)}{S_n} \le t_{\alpha/2}(n-1) \right] \\ &= P\left[\overline{X}_n - t_{\alpha/2}(n-1)\frac{S_n}{\sqrt{n}} \le \mu \le \overline{X}_n + t_{\alpha/2}(n-1)\frac{S_n}{\sqrt{n}} \right] \\ &= 1-\alpha \end{aligned}$$

에 의하여 모평균 μ에 대한 $100(1-\alpha)\%$ 신뢰구간

$$\left[\overline{X}_n - t_{\alpha/2}(n-1)\frac{S_n}{\sqrt{n}},\ \overline{X}_n + t_{\alpha/2}(n-1)\frac{S_n}{\sqrt{n}} \right] \tag{4.11}$$

이 구해진다($t_\alpha(n)$은 자유도가 n인 t 분포의 임계값으로서, $100(1-\alpha)\%$ 백분위수이다).

이와 같이 구한 신뢰구간의 의미를 다시 한 번 살펴보기로 하자. 관찰값이 $X_1 = x_1$, $X_2 = x_2$, $\cdots$, $X_n = x_n$으로 주어지면, 이들의 평균을 $\overline{x}_n$라고 했을 때, 식 (4.10)의 신뢰구간은 $[\overline{x}_n - z_{\alpha/2}(\sigma/\sqrt{n}),\ \overline{x}_n + z_{\alpha/2}(\sigma/\sqrt{n})]$의 값이 알려진 구간이 된다. 이는 $\overline{x}_n$에 대해 대칭이며, 구간의 길이는 모분산 σ^2이 작을수록 또 표본의 크기 n이 커질수록 짧아짐을 볼 수 있다. 실제로 위에서 구한 신뢰구간 (4.10)과 (4.11)은 주어진 신뢰도에 대하여 구간의 길이를 가장 짧게 하는 최적성도 가지고 있다. 그런데 어떤 주어진 표본에 대해 모수(여기에서는 모평균)의 신뢰구간은 그 모수를 포함하거나 포함하지 않거나 둘 중의 하나이다. 즉, 모수는 고정된 숫자이므로, 고정된 구간이 모수를 90% 포함하거나 하는 일은 없다. 그러나 독립된 여러 개의 표본에 근거하여 모수의 $100(1-\alpha)\%$ 신뢰구간들을 구해 보면 그 신뢰구간들의 $100(1-\alpha)\%$ 정도가 모수를 포함한다. 가령, 100개의 독립표본에 근거하여 모수 θ에 대한 100개의 90% 신

뢰구간들을 구하면 그들 중 약 90개 정도에 모수가 포함된다. 이는 성공확률이 $p=0.9$인 베르누이 시행을 독립적으로 100회 반복시행했을 때 얻는 성공횟수와 동일한 개념이다. 따라서 신뢰구간의 신뢰도에 대해서는 상대도수(relative frequency)에 의한 해석이 가능하다. 이와 같은 내용은 이 책에서 구하는 모든 신뢰구간(다음 절에서 다룰 베이즈 신뢰구간 제외)에 해당된다.

정규분포의 모분산에 대한 신뢰구간

$X_1, X_2, \cdots, X_n$을 $N(\mu, \sigma^2)$으로부터의 랜덤표본이라고 할 때, 모분산 σ^2에 대한 신뢰구간을 구해 보기로 하자. 이때에는, 장애모수인 모평균 μ를 아는 경우와 그렇지 않은 경우가 있다. 모평균 μ가 알려진 경우에는 $\sum_{i=1}^{n}(X_i-\mu)^2/\sigma^2$이 자유도가 n인 카이제곱분포를 따르는 추축변량인 점에 근거하여 σ^2에 대한 신뢰구간을 다음과 같이 구할 수 있다.

$$
\begin{aligned}
& P\left[\chi^2_{1-\alpha/2}(n) \le \frac{\sum_{i=1}^{n}(X_i-\mu)^2}{\sigma^2} \le \chi^2_{\alpha/2}(n)\right] \\
&= P\left[\frac{\sum_{i=1}^{n}(X_i-\mu)^2}{\chi^2_{\alpha/2}(n)} \le \sigma^2 \le \frac{\sum_{i=1}^{n}(X_i-\mu)^2}{\chi^2_{1-\alpha/2}(n)}\right] \\
&= 1-\alpha
\end{aligned}
$$

이므로

$$
\left[\frac{\sum_{i=1}^{n}(X_i-\mu)^2}{\chi^2_{\alpha/2}(n)}, \quad \frac{\sum_{i=1}^{n}(X_i-\mu)^2}{\chi^2_{1-\alpha/2}(n)}\right] \tag{4.12}
$$

이 모분산 σ^2에 대한 $100(1-\alpha)\%$ 신뢰구간이 된다.

한편, 모평균 μ가 알려지지 않은 경우에는 μ를 표본평균 $\overline{X}_n$로 추정한 통계량 $(n-1)S_n^2/\sigma^2 = \sum_{i=1}^{n}(X_i-\overline{X}_n)^2/\sigma^2$이 자유도가 $n-1$인 카이제곱분포를 따르는 추축변량인 점에 근거하여 다음과 같이 구할 수 있다. 카이제곱분포는 대칭이 아니나 양쪽 꼬리부분에서 $\alpha/2$씩의 확률을 고려하면,

$$P\left[\chi^2_{1-\alpha/2}(n-1) \le \frac{\sum_{i=1}^{n}(X_i-\overline{X}_n)^2}{\sigma^2} \le \chi^2_{\alpha/2}(n-1)\right]$$
$$= P\left[\frac{\sum_{i=1}^{n}(X_i-\overline{X}_n)^2}{\chi^2_{\alpha/2}(n-1)} \le \sigma^2 \le \frac{\sum_{i=1}^{n}(X_i-\overline{X}_n)^2}{\chi^2_{1-\alpha/2}(n-1)}\right]$$
$$= 1-\alpha$$

가 성립한다($\chi^2_\alpha(n)$은 자유도가 n인 χ^2분포의 임계값으로서 $100(1-\alpha)\%$ 백분위수이다). 따라서,

$$\left[\frac{\sum_{i=1}^{n}(X_i-\overline{X}_n)^2}{\chi^2_{\alpha/2}(n-1)}, \quad \frac{\sum_{i=1}^{n}(X_i-\overline{X}_n)^2}{\chi^2_{1-\alpha/2}(n-1)}\right] \tag{4.13}$$

가 모분산 σ^2에 대한 $100(1-\alpha)\%$ 신뢰구간이 된다.

두 정규분포의 모평균의 차이에 대한 신뢰구간

독립인 두 개의 랜덤표본 $X_1, X_2, \cdots, X_n$과 $Y_1, Y_2, \cdots, Y_m$의 분포가 각각 $N(\mu_X, \sigma_X^2)$과 $N(\mu_Y, \sigma_Y^2)$일 때, 두 모평균의 차이 $\mu_X-\mu_Y$에 대한 신뢰구간을 구하는 방법에 대해서 논해보자. 표본평균의 차이 $(\overline{X}_n-\overline{Y}_m)$는 $N(\mu_X-\mu_Y, \sigma_X^2/n+\sigma_Y^2/m)$ 분포를 따른다. 두 모평균 각각의 값이 아닌 차이에만 관심이 있으므로 $\mu_X-\mu_Y$를 하나의 모수로 취급하고, 일표본인 경우와 마찬가지로 σ_X^2과 σ_Y^2을 아는 경우와 그렇지 않은 경우를 나누어 고려하기로 한다.

경우 1 모분산 σ_X^2과 σ_Y^2을 아는 경우:

표본평균의 차이를 표준화한 변량

$$Z=\frac{(\overline{X}_n-\overline{Y}_m)-(\mu_X-\mu_Y)}{\sqrt{\sigma_X^2/n+\sigma_Y^2/m}}$$

는 표준정규분포 $N(0, 1)$을 따르므로 $\mu_X-\mu_Y$의 추정에서 추축변량으로 사용될 수 있다. 따라서,

$$P\left[-z_{\alpha/2} \le \frac{(\overline{X}_n - \overline{Y}_m) - (\mu_X - \mu_Y)}{\sqrt{\sigma_X^2/n + \sigma_Y^2/m}} \le z_{\alpha/2} \right]$$

$$= P\left[(\overline{X}_n - \overline{Y}_m) - z_{\alpha/2}\sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}} \le \mu_X - \mu_Y \right.$$

$$\left. \le (\overline{X}_n - \overline{Y}_m) + z_{\alpha/2}\sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}} \right]$$

$$= 1 - \alpha$$

로부터 모평균의 차 $\mu_X - \mu_Y$에 대한 $100(1-\alpha)\%$ 신뢰구간은

$$\left[(\overline{X}_n - \overline{Y}_m) - z_{\alpha/2}\sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}},\quad (\overline{X}_n - \overline{Y}_m) + z_{\alpha/2}\sqrt{\frac{\sigma_X^2}{n} + \frac{\sigma_Y^2}{m}} \right] \qquad (4.14)$$

으로 주어진다.

경우 2 모분산 σ_X^2과 σ_Y^2을 모르는 경우:

우선, $\sigma_X^2 = \sigma_Y^2 (= \sigma^2)$인 경우에는 공통 모분산 σ^2에 대한 추정방법으로 합동추정량 (pooled estimator)

$$S_p^{\,2} = \frac{(n-1)S_X^2 + (m-1)S_Y^2}{n+m-2}$$

을 사용한다(단, $S_X^2 = \sum_{i=1}^{n}(X_i - \overline{X}_n)^2/(n-1)$, $S_Y^2 = \sum_{i=1}^{m}(Y_i - \overline{Y}_m)^2/(m-1)$). 합동추정량 S_p^2은 S_X^2과 S_Y^2의 하나의 가중평균으로서 σ^2의 비편향추정량이 되며, 가중평균형태의 추정량 가운데 가장 분산이 작음을 보일 수 있다.

이제,

$$T = \frac{(\overline{X}_n - \overline{Y}_m) - (\mu_X - \mu_Y)}{S_p\sqrt{1/n + 1/m}}$$

로 정의하면 $\dfrac{(n+m-2)S_p^2}{\sigma^2}$이 자유도가 $n+m-2$인 카이제곱분포를 따르고 $\overline{X}_n - \overline{Y}_m$와 S_p^2이 독립이라는 사실을 이용하여 T의 분포가 $t(n+m-2)$임을 보일 수 있고, 따라서 T는 추축변량이 된다. 그러므로,

$$P\left[-t_{\alpha/2}(n+m-2) \le \frac{(\overline{X}_n-\overline{Y}_m)-(\mu_X-\mu_Y)}{S_p\sqrt{1/n+1/m}} \le t_{\alpha/2}(n+m-2)\right]$$
$$= P\left[(\overline{X}_n-\overline{Y}_m)-t_{\alpha/2}(n+m-2)\,S_p\sqrt{1/n+1/m} \le \mu_X-\mu_Y \right.$$
$$\left. \le (\overline{X}_n-\overline{Y}_m)+t_{\alpha/2}(n+m-2)\,S_p\sqrt{1/n+1/m}\right]$$
$$= 1-\alpha$$

로부터 모평균의 차 $\mu_X-\mu_Y$에 대한 $100(1-\alpha)\%$ 신뢰구간은

$$\left[(\overline{X}_n-\overline{Y}_m)-t_{\alpha/2}(n+m-2)\,S_p\sqrt{1/n+1/m}\,,\right.$$
$$\left.(\overline{X}_n-\overline{Y}_m)+t_{\alpha/2}(n+m-2)\,S_p\sqrt{1/n+1/m}\right] \tag{4.15}$$

로 주어진다.

한편, $\sigma_X^2 \neq \sigma_Y^2$인 경우에는 σ_X^2과 σ_Y^2을 각각 S_X^2과 S_Y^2로 추정한 형태의 변량 $T=\dfrac{\overline{X}_n-\overline{Y}_m-(\mu_X-\mu_Y)}{\sqrt{S_X^2/n+S_Y^2/m}}$를 생각할 수 있으나, 그 정확한 분포는 구할 수 없다. 유력한 방법들 중에 웰치(Welch)에 의해 제안된 방법은 T의 분포를 자유도가

$$\frac{(S_X{}^2/n+S_Y{}^2/m)^2}{\left[(S_X{}^2/n)^2/(n-1)\right]+\left[(S_Y{}^2/m)^2/(m-1)\right]} \tag{4.16}$$

인 t 분포로 근사하여 이로부터 신뢰구간을 구하게 된다.

● 두 정규분포의 모분산의 비에 대한 신뢰구간

두 개의 독립인 랜덤표본 $X_1, X_2, \cdots, X_n$과 $Y_1, Y_2, \cdots, Y_m$의 분포가 각각 $N(\mu_X, \sigma_X^2)$과 $N(\mu_Y, \sigma_Y^2)$이라고 할 때, 두 모분산의 비 σ_X^2/σ_Y^2에 대한 신뢰구간을 모평균을 아는 경우와 그렇지 않은 경우로 나누어 고려해 보자.

경우 1 모평균 μ_X와 μ_Y를 아는 경우:

서로 독립인 확률변량 $\sum_{i=1}^{n}(X_i-\mu_X)^2/\sigma_X^2$과 $\sum_{i=1}^{m}(Y_i-\mu_Y)^2/\sigma_Y^2$가, 각각 자유도가 n과 m인 카이제곱분포를 따르는 점에 근거하여 다음을 알 수 있다.

$$\frac{\sum_{i=1}^{n}(X_i-\mu_X)^2/(n\sigma_X^2)}{\sum_{i=1}^{m}(Y_i-\mu_Y)^2/(m\sigma_Y^2)} \sim F(n,m). \tag{4.17}$$

F 분포도 카이제곱분포와 같이 대칭이 아니지만, 대칭인 분포에서와 마찬가지로 양쪽 꼬리부분에서 $\alpha/2$씩의 확률을 고려하면

$$P\left[F_{1-\alpha/2}(n,m) \le \frac{\widetilde{S_X^2}/\sigma_X^2}{\widetilde{S_Y^2}/\sigma_Y^2} \le F_{\alpha/2}(n,m)\right] = 1-\alpha$$

가 만족된다(단, $\widetilde{S_X^2}=\sum_{i=1}^{n}(X_i-\mu_X)^2/n$, $\widetilde{S_Y^2}=\sum_{i=1}^{m}(Y_i-\mu_Y)^2/m$). $F_\alpha(n,m)$은 자유도가 (n,m)인 F 분포의 임계값으로서 $100(1-\alpha)\%$ 백분위수이다. 이제, 모분산의 비 σ_X^2/σ_Y^2에 대한 $100(1-\alpha)\%$ 신뢰구간은

$$\left[\left(\frac{\widetilde{S_X^2}}{\widetilde{S_Y^2}}\right)F_{1-\alpha/2}(m,n),\ \left(\frac{\widetilde{S_X^2}}{\widetilde{S_Y^2}}\right)F_{\alpha/2}(m,n)\right] \tag{4.18}$$

이 된다. 식 (4.18)에서 $F_\alpha(n,m)=(F_{1-\alpha}(m,n))^{-1}$의 성질을 이용하였다.

경우 2 모평균 μ_X와 μ_Y를 모르는 경우:

$\sum_{i=1}^{n}(X_i-\mu_X)^2/\sigma_X^2$과 $\sum_{i=1}^{m}(Y_i-\mu_Y)^2/\sigma_Y^2$에서 μ_X와 μ_Y를 각각 표본평균 $\overline{X}_n$과 $\overline{Y}_m$으로 추정한 확률변수 $\sum_{i=1}^{n}(X_i-\overline{X}_n)^2/\sigma_X^2$과 $\sum_{i=1}^{m}(Y_i-\overline{Y}_m)^2/\sigma_Y^2$을 생각했을 때, 이들이 서로 독립이고 각각 자유도가 $(n-1)$과 $(m-1)$인 카이제곱분포를 따르는 점에 근거하여 다음과 같이 구할 수 있다. 즉,

$$\frac{S_X^2/\sigma_X^2}{S_Y^2/\sigma_Y^2} \sim F(n-1,\ m-1) \tag{4.19}$$

에 의하여(단, $S_X^2=\sum_{i=1}^{n}(X_i-\overline{X}_n)^2/(n-1)$, $S_Y^2=\sum_{i=1}^{m}(Y_i-\overline{Y}_m)^2/(m-1)$),

$$P\left[F_{1-\alpha/2}(n-1, m-1) \le \frac{S_X^2/\sigma_X^2}{S_Y^2/\sigma_Y^2} \le F_{\alpha/2}(n-1, m-1) \right]$$
$$= 1-\alpha$$

이므로, 모분산의 비 σ_X^2/σ_Y^2에 대한 신뢰도 $100(1-\alpha)\%$ 신뢰구간은

$$\left[\left(\frac{S_X^2}{S_Y^2}\right) F_{1-\alpha/2}(m-1, n-1),\ \left(\frac{S_X^2}{S_Y^2}\right) F_{\alpha/2}(m-1, n-1) \right] \tag{4.20}$$

이 된다.

근사신뢰구간

앞 절에서 다루어진 신뢰구간은 모분포의 정규성을 전제로 하였다. 그러나 모분포가 정규분포를 따르지 않더라도 중심극한정리를 사용하여 모수에 대한 신뢰구간을 근사적으로 다음과 같이 구할 수 있다.

랜덤표본 $X_1, X_2, \cdots, X_n$의 분포의 평균과 분산이 각각 μ, σ^2이라고 할 때 모평균 μ에 대한 신뢰구간을 고려해 보자. 이 경우, 표본분산의 제곱근인 S_n이 σ로 수렴한다는 사실(참조: 예 4.43)과 중심극한정리, 그리고 슬럿츠키의 정리(정리 3.15)에 의해, 표본의 크기가 커짐에 따라 확률변량

$$Z_n = \frac{\sqrt{n}\,(\overline{X}_n - \mu)}{S_n}$$

의 분포는 표준정규분포 $N(0, 1)$로 수렴한다. 따라서 이를 활용한 신뢰계수가 $1-\alpha$인 모평균 μ에 대한 근사신뢰구간은

$$P\left[-z_{\alpha/2} \le Z_n \le z_{\alpha/2} \right]$$
$$= P\left[\overline{X}_n - z_{\alpha/2} \cdot \frac{S_n}{\sqrt{n}} \le \mu \le \overline{X}_n + z_{\alpha/2} \cdot \frac{S_n}{\sqrt{n}} \right]$$
$$\fallingdotseq 1-\alpha$$

에 의하여

$$\left[\overline{X}_n - z_{\alpha/2} \cdot \frac{S_n}{\sqrt{n}},\quad \overline{X}_n + z_{\alpha/2} \cdot \frac{S_n}{\sqrt{n}} \right] \tag{4.21}$$

으로 주어진다. 물론, 모분산 σ^2이 알려진 경우에는 식 (4.21)에서 S_n 대신 σ를 사용

하면 된다.

예 4.47

모분포가 포아송(λ)일 때 랜덤표본 $X_1, X_2, \cdots, X_n$에 근거하여 모평균 λ에 대한 95% 근사신뢰구간을 구해본다. 표본의 크기가 커질 때 대수의 법칙에 따라 표본평균 $\overline{X}_n$는 λ에 확률적으로 수렴하고 중심극한정리에 따라 $\dfrac{\sqrt{n}(\overline{X}_n-\lambda)}{\sqrt{\lambda}}$는 표준정규분포로 수렴하므로, 슬럿츠키의 정리에 의해

$$Z_n=\frac{\sqrt{n}(\overline{X}_n-\lambda)}{\sqrt{\overline{X}_n}}$$

의 분포도 표준정규분포 $N(0, 1)$로 수렴한다. 따라서 식 (4.21)과 마찬가지로, 모수 λ에 대한 95%의 근사신뢰구간

$$\left[\overline{X}_n-1.96\sqrt{\frac{\overline{X}_n}{n}},\quad \overline{X}_n+1.96\sqrt{\frac{\overline{X}_n}{n}}\right]$$

를 구할 수 있다.

예 4.48

$X_1, X_2, \cdots, X_n$이 베르누이(p)로부터의 랜덤표본일 때, 모수 p에 대한 신뢰구간을 중심극한정리를 이용하여 다음과 같이 근사적으로 구할 수 있다. $\hat{p}=\overline{X}_n$로 추정하면 $\hat{p}$가 p로 확률적으로 수렴하고 $\dfrac{\hat{p}-p}{\sqrt{p(1-p)/n}}$이 표준정규분포로 분포수렴하므로, 슬럿츠키의 정리에 의해 $\dfrac{\hat{p}-p}{\sqrt{\hat{p}(1-\hat{p})/n}}$도 표준정규분포로 분포수렴한다. 이를 이용하면 $\hat{p}\pm z_{\alpha/2}\sqrt{\hat{p}(1-\hat{p})/n}$이 p의 $100(1-\alpha)\%$ 근사신뢰구간이 된다.

두 독립인 랜덤표본 $X_1, X_2, \cdots, X_n$과 $Y_1, Y_2, \cdots, Y_m$의 분포가 각각 μ_X, σ_X^2 그리고 μ_Y, σ_Y^2의 평균과 분산을 가질 때, 두 모평균의 차 $\mu_X-\mu_Y$에 대한 신뢰구간을 구해 보자. $N=n+m$이라고 하고, n과 m이 커짐에 따라 $n/N\to c_1$이고 $m/N\to c_2$라고 가정하자. 그러면 $c_1+c_2=1$이 된다. 중심극한정리에 의해, n과 m이 커질 때

$\frac{\overline{X}_n-\mu_X}{\sigma_X/\sqrt{n}} \xrightarrow{d} N(0,1)$이고 $\frac{\overline{Y}_m-\mu_Y}{\sigma_Y/\sqrt{m}} \xrightarrow{d} N(0,1)$이다. 그러면, $\sqrt{N}(\overline{X}_n-\mu_X)=\sqrt{N/n}\,\sqrt{n}(\overline{X}_n-\mu_X) \xrightarrow{d} N(0,\sigma_X^2/c_1)$이 되고 비슷하게, $\sqrt{N}(\overline{Y}_m-\mu_Y) \xrightarrow{d} N(0,\sigma_Y^2/c_2)$이 성립한다. 따라서

$$\frac{\sqrt{N}(\overline{X}_n-\overline{Y}_m-(\mu_X-\mu_Y))}{\sqrt{\sigma_X^2/c_1+\sigma_Y^2/c_2}} \xrightarrow{d} N(0,1) \tag{4.22}$$

이 된다. 또, S_X^2와 S_Y^2이 각각 σ_X^2와 σ_Y^2의 일치추정량이므로

$$\frac{\sqrt{\sigma_X^2/c_1+\sigma_Y^2/c_2}}{\sqrt{N}\sqrt{S_X^2/n+S_Y^2/m}} \xrightarrow{p} 1$$

이 성립하기에 슬럿츠키의 정리를 사용하면

$$T_n=\frac{(\overline{X}_n-\overline{Y}_m)-(\mu_X-\mu_Y)}{\sqrt{S_X^2/n+S_Y^2/m}} \xrightarrow{d} N(0,1)$$

이 된다. 따라서 이를 활용한 신뢰도 $100(1-\alpha)\%$ 근사신뢰구간은

$$\begin{aligned}
&P\left[-z_{\alpha/2} \le T_n \le z_{\alpha/2}\right] \\
&= P\Big[(\overline{X}_n-\overline{Y}_m)-z_{\alpha/2}\sqrt{S_X^2/n+S_Y^2/m} \le \mu_X-\mu_Y \le \\
&\qquad (\overline{X}_n-\overline{Y}_m)+z_{\alpha/2}\sqrt{S_X^2/n+S_Y^2/m}\Big] \\
&\fallingdotseq 1-\alpha
\end{aligned}$$

에 의하여

$$\left[(\overline{X}_n-\overline{Y}_m)-z_{\alpha/2}\sqrt{\frac{S_X^2}{n}+\frac{S_Y^2}{m}},\ (\overline{X}_n-\overline{Y}_m)+z_{\alpha/2}\sqrt{\frac{S_X^2}{n}+\frac{S_Y^2}{m}}\right] \tag{4.23}$$

으로 주어진다.

예 4.49

$X_1, X_2, \cdots, X_n$이 베르누이(p_X), 그리고 $Y_1, Y_2, \cdots, Y_m$이 베르누이(p_Y)로부터 얻은 랜덤표본이라고 하자. 모비율의 차 p_X-p_Y에 대한 신뢰도 $100(1-\alpha)\%$ 근사

신뢰구간은 다음과 같이 구해진다. 모비율 p_X와 p_Y를 각각 표본비율 $\hat{p}_X = \overline{X}_n$와 $\hat{p}_Y = \overline{Y}_m$로 추정하면, (4.22)에서,

$$\frac{(\hat{p}_X - \hat{p}_Y) - (p_X - p_Y)}{\sqrt{p_X(1-p_X)/n + p_Y(1-p_Y)/m}} \xrightarrow{d} N(0,1)$$

를 얻는다. $\hat{p}_X$와 $\hat{p}_Y$가 p_X와 p_Y의 일치추정량이므로 분모에 있는 p_X와 p_Y 대신 추정량을 대입하면 $\frac{(\hat{p}_X - \hat{p}_Y) - (p_X - p_Y)}{\sqrt{\hat{p}_X(1-\hat{p}_X)/n + \hat{p}_Y(1-\hat{p}_Y)/m}} \xrightarrow{d} N(0,1)$를 얻고 이를 이용한 $p_X - p_Y$에 대한 $100(1-\alpha)\%$ 근사신뢰구간은

$$\left[(\hat{p}_X - \hat{p}_Y) - z_{\alpha/2}\sqrt{\frac{\hat{p}_X(1-\hat{p}_X)}{n} + \frac{\hat{p}_Y(1-\hat{p}_Y)}{m}}, \right.$$
$$\left. (\hat{p}_X - \hat{p}_Y) + z_{\alpha/2}\sqrt{\frac{\hat{p}_X(1-\hat{p}_X)}{n} + \frac{\hat{p}_Y(1-\hat{p}_Y)}{m}} \right]$$

으로 구해진다.

표본의 크기

모분산 σ^2이 알려진 경우에 모평균 μ의 추정량 $\hat{\mu} = \overline{X}$에 대한 $100(1-\alpha)\%$ 오차한계를 d 이하로 하려면, 표본크기 n은

$$z_{\alpha/2}\frac{\sigma}{\sqrt{n}} \le d, \text{ 즉 } n \ge (z_{\alpha/2}\sigma/d)^2$$

을 만족해야 함을 알 수 있다. 물론, 이는 μ에 대한 $100(1-\alpha)\%$ 신뢰구간의 길이가 $2d$ 이하이도록 하는 것과 마찬가지이다. 이는 모집단의 분포가 정규분포인 경우에는 정확한 것이고, 표본크기가 큰 경우에는 임의의 모집단에 대하여 근사적으로 적용될 수 있다.

또한, 표본크기가 큰 경우에 모비율 p의 추정량인 표본비율 $\hat{p}$의 $100(1-\alpha)\%$ 오차한계는 $z_{\alpha/2}\sqrt{p(1-p)/n}$으로 주어지므로, $100(1-\alpha)\%$ 오차한계를 d 이하로 하려면 필요한 표본의 크기는

$$z_{\alpha/2}\sqrt{p(1-p)/n} \le d \text{ 즉, } n \ge p(1-p)(z_{\alpha/2}/d)^2$$

이다. 그러나 이 방법을 이용하여 표본크기를 정하는 것은 모비율을 추정하기 위한 표본을 뽑기 전에 모비율의 값인 p를 미리 알아야 한다는 문제점이 있다. p에 대한 정보가 전혀 없는 경우에는 $p(1-p)$를 최대로 만드는 p값인 $1/2$를 대입하여, $n \geq \frac{1}{4}(z_{\alpha/2}/d)^2$로 표본의 크기를 구할 수 있다. 이 방법은 보수적인 방법으로서, 이렇게 표본의 크기를 구하면 모비율의 참값이 어떤 값이든 상관없이 오차한계가 d 이하가 된다. 만약 예전 자료에서의 추정값 등에 의해 p에 대한 적당한 값의 범위를 알고 있다면 그 중에 가장 $1/2$에 가까운 값을 대입하여 표본의 크기를 구할 수 있다.

4.7 베이즈 추정

어떤 제조업체로부터 기계부품을 오랜 기간 동안 수입해 오는 회사에서 정기적으로 수입제품의 성능을 점검한다고 하자. 이 제품의 성능의 측정값은 확률밀도함수가 $f(x;\mu)$인 분포를 따르고 μ는 그 평균이며 우리는 이 평균에 관심이 있다. 그런데 오랜 거래기간 동안의 경험에 의하면 성능의 측정값의 평균 μ는 $N(100, 3^2)$의 분포를 따른다는 사전 정보가 있다고 하자. 모수 μ가 어떤 범위에 들어가는 값이라는 것 이상의 사전 정보가 있다면 이를 모수의 추정에 활용하는 것은 바람직하다고 볼 수 있다. 그러나 지금까지의 추정방법은 모수의 값을 고정된 것으로 생각하기 때문에 이러한 사전 정보를 사용할 수 없다. 랜덤표본 $X_1, X_2, \cdots, X_n$의 확률밀도함수가 $f(x;\theta)$, $\theta \in \Omega$이고 θ가 어떤 범위에 들어가는 값($\theta \in \Omega$)이라는 것 이상의 정보가 존재할 때, 베이지안(Bayesian) 방법은 이러한 사전정보를 사용하여 θ를 추정하게 된다.

베이지안 통계(Bayesian Statistics)는 통계학에서 큰 부분을 차지하는 방법론으로서, 모수 θ를 확률변수로 생각하여 그에 대한 사전정보를 활용할 수 있게 한다. 이 절에서는 베이지안 추정의 기본적인 접근방법에 대해 다루어 보도록 하겠다. 베이즈 추정량(Bayesian estimator)의 기본 아이디어는 베이즈 정리를 통해 알아볼 수 있다. 정리 1.3에서 다루었던 베이즈 정리를 다시 살펴보면, 사건 $B_1, B_2, \cdots, B_k$가 상호배반이며 $\bigcup_{i=1}^{k} B_i = S$일 때 사건 A가 일어났다는 조건하에서 사건 B_j가 일어날 확률은

$$P(B_j \mid A) = \frac{P(B_j)P(A \mid B_j)}{\sum_{i=1}^{k} P(B_i)P(A \mid B_i)}$$

로 주어진다. 이 정리는 $B_1, B_2, \cdots$의 무한열에 대해서도 성립한다. 이 베이즈 정리를 이 절에서의 목적에 맞게 표현하면 다음과 같이 될 수 있다. 두 확률변수 X와 Y에 대하여 $f_X(x)$, $f_Y(y)$가 각각의 주변 확률밀도함수, $f_{X|Y}(x|y)$가 $Y=y$가 주어졌을 때 X의 조건부 확률밀도함수이고 $f_{X,Y}(x,y)$가 결합 확률밀도함수일 때,

$$f_{Y|X}(y|x)=\frac{f_{X,Y}(x,y)}{f_X(x)}=\frac{f_{X,Y}(x,y)}{\int_{-\infty}^{\infty}f_{X,Y}(x,y)dy}$$
$$=\frac{f_{X|Y}(x|y)f_Y(y)}{\int_{-\infty}^{\infty}f_{X|Y}(x|y)f_Y(y)dy}.$$

이제, 확률밀도함수 $f(x;\theta)$, $\theta\in\Omega$를 갖는 확률변수 X를 생각해 보자. 이전까지는 θ를 미지의 상수로 간주하였지만 베이즈 추정에서는 이를 Ω 위에서 정의되는 확률변수 Θ의 한 실현값으로 볼 것이다. 확률변수 X의 한 실현값을 x로 표현하듯이, 확률변수 Θ의 한 실현값이 θ가 된다. Θ의 확률밀도함수를 $\pi(\theta)$로 표기하자. 이를 θ의 **사전 확률밀도함수**(prior probability density function)라고 한다. Θ의 실현값인 θ가 주어졌을 때, X의 확률밀도함수는 θ의 값이 주어진 조건부 확률밀도함수가 되고, $f(x\mid\theta)$로 나타낸다. 확률변수 X와 모수 θ의 결합 확률밀도함수는

$$f(x,\theta)=\pi(\theta)\,f(x\mid\theta)$$

가 되고 랜덤표본 $X_1, X_2, \cdots, X_n$과 θ의 결합 확률밀도함수는

$$f(x_1, x_2, \cdots, x_n, \theta)=\pi(\theta)\prod_{i=1}^{n}f(x_i\mid\theta)$$

가 된다. θ의 사전 확률밀도함수에서 '사전'의 의미는 표본을 관측하기 전이라는 것이고, θ에 대한 사전 정보가 이를 통해 반영된다. 이제 표본이 관측되고 나면, θ에 대한 사전 믿음(prior belief)을 표본에서 얻은 정보를 반영하여 수정하는 것이 합리적일 것이다. 그렇다면 표본 정보를 어떻게 반영할 수 있을까? θ에 대하여 가지고 있던 사전 정보에 표본이 갖고 있는 정보를 더하여 θ에 대한 사후(posterior) 정보를 얻기 위해 다음과 같이 베이즈 정리를 사용하게 된다.

랜덤표본 $X_1=x_1, \cdots, X_n=x_n$이 주어졌을 때 θ의 조건부 확률밀도함수는

$$k(\theta \mid x_1, x_2, \cdots, x_n) = \frac{\pi(\theta)\prod_{i=1}^{n} f(x_i \mid \theta)}{\int_{-\infty}^{\infty}\left[\prod_{i=1}^{n} f(x_i \mid \theta)\right]\pi(\theta)d\theta}$$

로 주어지며, 이를 모수 θ의 **사후 확률밀도함수**(posterior probability density function)라고 한다. 만약 θ의 분포가 이산형이라면 적분 대신 합의 기호로 표현될 것이다.

예 4.50

$X_1, \cdots, X_n$이 동전던지기와 같은 베르누이(θ)에서 나온 랜덤표본이라고 하면,

$$f(x_1, \cdots, x_n|\theta) = \theta^{\sum_{i=1}^{n} x_i}(1-\theta)^{n-\sum_{i=1}^{n} x_i}, \quad x \in \{0, 1\}$$

이 된다. 만약 이 동전이 앞면과 뒷면이 나올 확률이 동일한 동전일 가능성이 높긴 하지만 이 정보가 정확하지는 않아서 θ가 0.5일 가능성이 가장 높고 0.5로부터 멀어질수록 가능성이 낮아진다고 가정해 보자. 이러한 사전정보를 반영하는 한 가지 방법으로 다음과 같은 θ의 사전분포를 생각할 수 있다.

$$\pi(\theta) = 6\theta(1-\theta), \quad 0 < \theta < 1.$$

이는 $BETA(2, 2)$ 분포의 확률밀도함수로서, 그 형태가 우리가 원하는 내용을 반영하면서 상당히 간단하고 다루기 쉬운 확률밀도함수이므로 사전분포로서 적당해 보인다. 사후 확률밀도함수를 구하기 위해 $\int_{-\infty}^{\infty}\left[\prod_{i=1}^{n} f(x_i \mid \theta)\right]\pi(\theta)d\theta$를 계산해 보자.

$$\begin{aligned}
\int_{-\infty}^{\infty} f(x_1, \cdots, x_n|\theta)\pi(\theta)d\theta &= \int_0^1 \theta^{n\bar{x}_n}(1-\theta)^{n-n\bar{x}_n} 6\theta(1-\theta)d\theta \\
&= 6\int_0^1 \theta^{n\bar{x}_n+1}(1-\theta)^{1+n(1-\bar{x}_n)}d\theta \\
&= 6\frac{\Gamma(n\bar{x}_n+2)\Gamma(n-n\bar{x}_n+2)}{\Gamma(n+4)} \\
&= 6\frac{(n\bar{x}_n+1)!(n-n\bar{x}_n+1)!}{(n+3)!}
\end{aligned}$$

이므로,

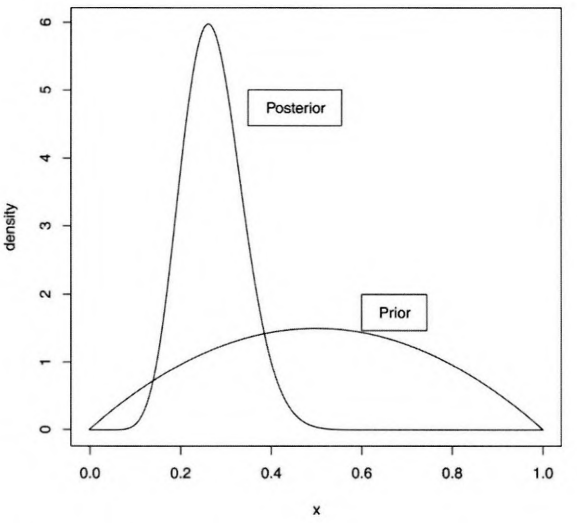
$$k(\theta|x_1,\cdots,x_n)=\frac{\Gamma(n+4)}{\Gamma(n\bar{x}_n+2)\Gamma(n-n\bar{x}_n+2)}\theta^{n\bar{x}_n+1}(1-\theta)^{n-n\bar{x}_n+1}$$

가 되어 θ의 사후분포는 $BETA(n\bar{x}_n+2,\ n-n\bar{x}_n+2)$가 된다.

만약 θ가 $0<\theta<1$이라는 것 외에 사전정보가 전혀 없는 경우 사전분포를 균일분포 $U(0,1)$로 잡을 수 있고, 이 경우 사후분포는

$$k(\theta|x_1,\cdots,x_n)=\frac{\Gamma(n+2)\theta^{n\bar{x}_n}(1-\theta)^{n-n\bar{x}_n}}{\Gamma(n\bar{x}_n+1)\Gamma(n-n\bar{x}_n+1)}$$

가 되어 $BETA(n\bar{x}_n+1,\ n-n\bar{x}_n+1)$이 된다.



▸ **그림 4.4** ◂ 예 4.50에서의 사전분포와 사후분포($n=40,\ \bar{x}_n=0.25$일 때)

사후분포의 산포는 θ에 대한 추정의 정확도에 대해 정보를 줄 수 있다. 그림 4.4에서 자료가 어느 정도의 정보를 더해주는지 사전분포와 사후분포의 확률밀도함수를 비교함으로써 알 수 있다.

예 4.51

알려진 상수 α, β에 대하여 θ의 사전분포가 $\Theta \sim \mathrm{GAM}(\alpha,\beta)$라고 하고 $X_1,\cdots,X_n$이 $\mathrm{POI}(\theta)$에서 나온 랜덤표본이라고 하면, $X_1,\cdots,X_n$과 Θ의 결합 확률밀도함수는

$$\prod_{i=1}^{n} f(x_i \mid \theta)\times\pi(\theta) = \frac{\theta^{\sum x_i}e^{-n\theta}}{x_1!\cdots x_n!}\times\frac{\theta^{\alpha-1}e^{-\theta/\beta}}{\Gamma(\alpha)\beta^{\alpha}},$$
$$\theta>0,\ x_i=0,1,2,\cdots,\ \text{for } i=1,\cdots,n$$

이 된다. 사후 확률밀도함수를 구하기 위해 $\int_{-\infty}^{\infty}\left[\prod_{i=1}^{n} f(x_i\mid\theta)\right]\pi(\theta)\,d\theta$를 계산해 보자.

$$\int_0^{\infty}\frac{\theta^{\sum x_i}e^{-n\theta}}{x_1!\cdots x_n!}\times\frac{\theta^{\alpha-1}e^{-\theta/\beta}}{\Gamma(\alpha)\beta^{\alpha}}d\theta$$
$$=\frac{1}{x_1!\cdots x_n!\Gamma(\alpha)\beta^{\alpha}}\int_0^{\infty}\theta^{\alpha+\sum x_i-1}e^{-\theta(n+\frac{1}{\beta})}d\theta$$
$$=\frac{\Gamma(\alpha+\sum x_i)}{x_1!\cdots x_n!\Gamma(\alpha)\beta^{\alpha}(n+\frac{1}{\beta})^{\alpha+\sum x_i}}$$

가 되므로 사후 확률밀도함수는

$$k(\theta\mid x_1,\cdots,x_n)=\frac{\dfrac{\theta^{\sum x_i}e^{-n\theta}}{x_1!\cdots x_n!}\times\dfrac{\theta^{\alpha-1}e^{-\theta/\beta}}{\Gamma(\alpha)\beta^{\alpha}}}{\dfrac{\Gamma(\alpha+\sum x_i)}{x_1!\cdots x_n!\Gamma(\alpha)\beta^{\alpha}(n+\frac{1}{\beta})^{\alpha+\sum x_i}}}$$
$$=\frac{\theta^{\alpha+\sum x_i-1}e^{-\theta(n+\frac{1}{\beta})}}{\Gamma(\alpha+\sum x_i)(n+\frac{1}{\beta})^{-\alpha-\sum x_i}}$$

가 되어 사후분포가 $\mathrm{GAM}(\alpha+\sum x_i,\ (n+\frac{1}{\beta})^{-1})$을 따르게 된다.

위 예제에서 보듯이, 베이지안 추정을 위해 θ의 사후 확률분포를 구하는 것은 보통 긴 계산을 필요로 한다. 하지만 $\int_{-\infty}^{\infty}\left[\prod_{i=1}^{n} f(x_i\mid\theta)\right]\pi(\theta)\,d\theta$를 따로 계산할 필요가

없음을 인식한다면 과정이 조금은 간단해진다. 실제로,

$$k(\theta \mid x_1, x_2, \cdots, x_n) = \frac{\pi(\theta)\prod_{i=1}^{n} f(x_i \mid \theta)}{\int_{-\infty}^{\infty}\left[\prod_{i=1}^{n} f(x_i \mid \theta)\right]\pi(\theta)\,d\theta}$$

에서 분모는 θ에 의존하지 않고, 사후 확률밀도함수는 $x_1, \cdots, x_n$만의 함수와 θ를 포함하는 부분의 곱으로 표현될 수 있다. 즉, 이 예제에서는 $x_1, \cdots, x_n$의 함수 $c(x_1, \cdots, x_n)$에 대해

$$k(\theta | x_1, \cdots, x_n) = c(x_1, \cdots, x_n) \times \theta^{\alpha + \sum x_i - 1} e^{-\theta(n + \frac{1}{\beta})}$$

이고, 이는 확률밀도함수이므로 θ에 대해 적분했을 때 그 값이 1이어야 한다. 즉, $c(x_1, \cdots, x_n)$이 $\dfrac{1}{\Gamma(\alpha + \sum x_i)(n + \frac{1}{\beta})^{-\alpha - \sum x_i}}$이어야만 하므로, 사후 확률분포가 $\mathrm{GAM}(\alpha + \sum x_i,\ (n + \frac{1}{\beta})^{-1})$임을 쉽게 알 수 있다. 일반적으로,

$$k(\theta | x_1, \cdots, x_n) \propto \pi(\theta) f(x_1, \cdots, x_n | \theta)$$

가 성립하므로 이를 이용하면 사후 확률밀도함수를 보다 간편하게 계산할 수 있다.

베이지안 방법으로 모수를 추정하는 경우, 사전분포를 어떻게 결정하느냐에 대한 중요한 문제를 먼저 해결해야 한다. 만약 θ에 대한 사전 정보가 전혀 없다면 균일분포와 같이 평평한(flat) 사전분포를 사용할 수 있다. θ에 대한 어떤 사전 정보가 있는 경우에는 그 정보를 잘 표현해 줄 수 있는 분포를 골라야 한다. 이때 계산을 쉽게 해 주는 사전분포를 택하는 것이 하나의 방법이 될 것이다. 이를 위해 소위 켤레 사전분포(conjugate prior distribution)를 사용할 수 있다. 많은 경우, 켤레 사전분포의 모수를 변화시킴으로써 우리가 가지고 있는 θ에 대한 사전 정보를 적절히 설명할 수 있는 분포를 찾을 수 있다.

정의 4.13

확률밀도함수 $f(x|\theta)$, $\theta \in \Omega$에 대해 사후분포가 사전분포와 같은 분포족에 들어가게 하는 사전분포의 모임을 $f(x|\theta)$에 대한 **켤레 사전분포족**(conjugate family of prior distributions)이라고 한다.

위의 예제들에서 베타 분포족이 베르누이(또는 이항) 분포에 대한 켤레 사전분포족

이고, 감마 분포족이 포아송 분포에 대한 켤레 사전분포족임을 알 수 있다. 켤레 사전분포족을 사용하였기 때문에 사후분포가 상대적으로 쉽게 계산되었다. 켤레 사전분포족을 사용하면 사후분포가 같은 분포족에 들어가기 때문에 자료를 통해 사전 정보를 업데이트 하는 것이 모수를 업데이트 하는 형태를 띠게 된다.

베이지안 방법에서 θ에 대한 정보는 사후 확률분포에 모두 담겨 있다고 할 수 있다. 지금까지 사후 확률분포를 구하는 것을 다루었으므로, 이제는 이 사후 확률분포를 이용하여 어떻게 추정량을 얻을 것인지에 대해 생각해 보자.

θ는 확률변수 Θ의 한 실현값이므로 θ에 대한 추정은 확률변수의 실현값을 예측하는 문제가 된다. 어떤 확률변수의 실현값을 예측(predict)하려고 할 때, 우리는 예측값과 실제 관측값이 최대한 비슷하기를 원할 것이다. 이를 위해, 예측값과 실제 관측값이 얼마나 가까운지를 측정할 수 있는 방법이 필요한데 이는 적절한 손실함수(loss function)를 정의함으로써 가능하다. 손실함수 $L(\theta, u(x_1, \cdots, x_n))$은 θ값과 그에 대한 추정값 $u(x_1, \cdots, x_n)$ 사이의 거리를 재는 측도로서, 차이의 심각도를 나타내는 함수라고 할 수 있다. 가장 일반적으로 사용되는 것은 제곱오차(squared error) 손실함수이지만 절대오차(absolute error) 손실함수나 0-1 손실함수 등을 생각할 수도 있다. 제곱오차 손실함수를 사용하는 경우 추정값이 모수의 참값에서 멀어질수록 그 차이의 심각도가 커지게 된다. 이 손실함수의 값을 최소화하는 $u(x_1, \cdots, x_n)$ 을 θ에 대한 추정값으로 사용하면 좋을텐데, θ는 Θ의 하나의 실현값이므로 모든 가능한 θ의 값과 그 확률분포를 고려해야 할 것이다. 그래서 베이즈 추정방법은 다음과 같이 손실함수의 기댓값을 최소화하는 $u(x_1, \cdots, x_n)$을 고르게 되고, 기댓값을 구할 때는 θ의 사후 확률분포를 사용한다:

$$E(L(\Theta, u(x_1, \cdots, x_n))|x_1, \cdots, x_n)$$
$$= \int_{-\infty}^{\infty} L(\theta, u(x_1, \cdots, x_n))k(\theta|x_1, \cdots, x_n)d\theta$$

여기에서 Θ의 분포는 연속으로 가정하였다.

정의 4.14

손실함수 L이 주어졌을 때의 베이즈 추정량은

$$E[L(\Theta, u(x_1, \cdots, x_n))|x_1, \cdots, x_n) = \int_{-\infty}^{\infty} L(\theta, u(x_1, \cdots, x_n))k(\theta|x_1, \cdots, x_n)d\theta$$

를 최소화하는 $u(x_1, \cdots, x_n)$에 대응되는 $u(X_1, \cdots, X_n)$이다.

표기의 편의상 $X=(X_1,\cdots,X_n)$, $x=(x_1,\cdots,x_n)$으로 쓰도록 하자. 위에서 구한 손실함수의 기댓값은 x의 함수이므로 X의 결합 확률밀도함수, $f(x)=\int \pi(\theta)f(x|\theta)d\theta$를 가지고 다시 기댓값을 취하면, $g(\theta|x)f(x)=f(x|\theta)\pi(\theta)$이므로

$$\begin{aligned} E(E(L(\Theta,u(X))|X=x)) &= \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} L(\theta,u(x))g(\theta|x)d\theta\, f(x)dx \\ &= \int_{-\infty}^{\infty}\int_{-\infty}^{\infty} L(\theta,u(x))f(x|\theta)dx\pi(\theta)d\theta \\ &= \int_{-\infty}^{\infty} R(\theta,u)\pi(\theta)d\theta \end{aligned}$$

로 쓸 수 있다. 여기에서 $R(\theta,u)=E[L(\theta,u(X_1,\cdots,X_n))|\theta]$는 위험함수(risk function)라고 불리며, X에 대한 손실함수의 기댓값이다. 이는 주어진 θ의 값에서 θ와 추정값 사이의 평균거리 개념이라고 할 수 있다. $E[E(L(\Theta,u(X))|X=x)]$를 위험함수의 평균값, 즉 기대위험(expected risk)이라고 하면, 베이즈 추정량 $u(X_1,\cdots,X_n)$은 모든 x의 값에서 $\int_{-\infty}^{\infty} L(\theta,u(x))k(\theta|x)d\theta$를 최소화하므로 기대위험을 최소화하는 통계량이 된다. 특히, 손실함수가 제곱오차인 경우 위험함수는 평균제곱오차(MSE)가 되고, 베이즈 추정량은 평균제곱오차의 θ에 대한 기댓값을 최소로 만드는 추정량이다.

제곱오차 손실함수를 사용하는 경우 베이즈 추정량이 사후 확률분포의 평균이고, 절대오차 손실함수를 사용하는 경우 베이즈 추정량이 사후 확률분포의 중앙값임을 어렵지 않게 확인할 수 있다. 위의 논리는 추정하고자 하는 것이 θ의 함수, 말하자면 $g(\theta)$인 경우에 대해서도 쉽게 확장된다.

예 4.52

예 4.50에서와 같이 X_1, X_2, $\cdots$, X_n이 베르누이(p)로부터의 랜덤표본이고 모수 p의 사전 확률밀도함수가 $\pi(p)=6p(1-p)$, $0<p<1$로 주어진다고 하자. 예 4.50에서 본 것과 같이 p의 사후 확률분포는 $BETA(n\bar{x}_n+2, n-n\bar{x}_n+2)$가 된다. 제곱오차 손실함수를 사용한다면 p에 대한 베이즈 추정량은 사후 확률분포의 평균값인 $\dfrac{n\bar{X}_n+2}{n+4}=\dfrac{\sum X_i+2}{n+4}$이다. 이 문제에 있어서 최대가능도 추정량, 적률 추정량, 그

리고 최소분산 비편향추정량은 모두 $\frac{\sum X_i}{n}$인 데 반해, 베이즈 추정량은 기존의 추정량의 분모에 4, 분자에 2를 더한 꼴이다. 말하자면, 4번의 가상적인 추가 시행이 있었고 그중에 2번은 성공, 2번은 실패였다고 가정하는 것으로 생각할 수 있다. 이는 기존의 추정량을 $\frac{1}{2}$쪽으로 약간 기울이는 효과를 가져오는데, 때로 매우 유용하다. $0 < p < 1$을 가정했으므로 우리는 p가 0이거나 1의 값은 가질 수 없다는 것을 알고 있다. 그렇지만 만약 p가 아주 작은 값이면, n번의 시행 중에 성공이 한 번도 나오지 않는 경우가 생길 수 있다. 이런 경우 기존의 추정량은 p의 추정값으로 p가 가질 수 없는 값인 0을 제공하게 되지만, 베이즈 추정량은 $2/(n+4)$를 추정값으로 제공하므로 보다 합리적이라고 할 수 있다.

예 4.53

$X_1, X_2, \cdots, X_n$을 베르누이(p)로부터 구한 랜덤표본이고, 모수 p의 사전분포가 $BETA(\alpha,\beta)$라고 하자. 모수 p의 사후 확률밀도함수는

$$k(p \mid x_1, \cdots, x_n) \propto \pi(p)\, f(x_1, \cdots, x_n \mid p) \propto p^{\sum_{i=1}^{n} x_i + \alpha - 1} (1-p)^{n - \sum_{i=1}^{n} x_i + \beta - 1}$$

로부터 $BETA\ (\sum_{i=1}^{n} x_i + \alpha, n - \sum_{i=1}^{n} x_i + \beta)$이다. 따라서 제곱오차를 사용한 모수 p에 대한 베이즈 추정량은 사후분포의 평균인 $\hat{p} = \frac{\sum_{i=1}^{n} X_i + \alpha}{n + \alpha + \beta}$가 된다. 나아가,

$$\hat{p} = \frac{\sum_{i=1}^{n} X_i + \alpha}{n + \alpha + \beta} = \frac{n}{n + \alpha + \beta}\left(\overline{X}_n\right) + \frac{\alpha + \beta}{n + \alpha + \beta}\left(\frac{\alpha}{\alpha + \beta}\right)$$

로 표현될 수 있으며, 이를 통해 베이즈 추정량이 사전분포의 평균 $\frac{\alpha}{\alpha+\beta}$와 표본평균 $\overline{X}_n$의 가중평균임을 알 수 있다. n이 커질 때, 사전분포의 평균은 매우 작은 가중치를 갖게 되고 대부분의 가중치는 표본평균이 갖는다. 반면에 n이 작다면, 사전분포의 평균이 갖는 가중치가 상대적으로 클 것이다. 표본의 크기가 클수록 자료에서 얻는 정보에 보다 많이 의존하게 되고, 표본이 작으면 추정에 대한 사전 정보의 영향력이 상대적으로 클 것이므로 이는 매우 합리적인 성질이라고 할 수 있다.

예 4.54

$X_1, X_2, \cdots, X_n$을 $N(\mu, \sigma^2)$으로부터 얻은 랜덤표본이라고 하자. 모분산 σ^2은 알려져 있을 때, μ의 사전 확률밀도함수가 $N(\mu_0, \sigma_0^2)$, 즉

$$\pi(\mu) = \frac{1}{\sqrt{2\pi}\,\sigma_0} \exp\left[-\frac{1}{2}\left(\frac{\mu-\mu_0}{\sigma_0}\right)^2\right]$$

이라고 하면, $X_1, X_2, \cdots, X_n$과 μ의 결합 확률밀도함수는

$$\begin{aligned} f(x, \mu) &= \frac{1}{\sqrt{2\pi}\,\sigma_0} \exp\left[-\frac{1}{2}\left(\frac{\mu-\mu_0}{\sigma_0}\right)^2\right] \\ &\times \frac{1}{(2\pi)^{n/2}\,\sigma^n} \exp\left[-\frac{1}{2}\sum_{i=1}^{n}\left(\frac{x_i-\mu}{\sigma}\right)^2\right] \\ &\propto \exp\left(-\frac{1}{2}(\frac{\mu-\mu_0}{\sigma_0})^2 - \frac{1}{2}\frac{\sum_{i=1}^{n}(x_i-\mu)^2}{\sigma^2}\right) \\ &\propto \exp\{-\frac{1}{2}S(\mu)\} \end{aligned}$$

의 꼴이 된다. 단,

$$S(\mu) = \frac{\sigma^2+\sigma_0^2 n}{\sigma_0^2\sigma^2}\left[\mu - \frac{\sigma^2\mu_0 + \sigma_0^2 n\,\bar{x}_n}{\sigma^2+\sigma_0^2 n}\right]^2$$

이다. 따라서 μ의 사후 확률밀도함수는

$$\begin{aligned} k(\mu \mid x) &= \frac{f(x, \mu)}{\int_{-\infty}^{\infty} f(x, \mu)\, d\mu} \\ &= \frac{\exp[-(1/2)S(\mu)]}{\int_{-\infty}^{\infty} \exp[-(1/2)S(\mu)]\, d\mu} \\ &= \frac{\exp\left[-\frac{\sigma^2+\sigma_0^2 n}{2\sigma_0^2\sigma^2}\left[\mu - \frac{\sigma^2\mu_0+\sigma_0^2 n\,\bar{x}_n}{\sigma^2+\sigma_0^2 n}\right]^2\right]}{\sqrt{\frac{2\pi\sigma^2\sigma_0^2}{\sigma^2+\sigma_0^2 n}}} \end{aligned}$$

이 되는데, 이는 평균이 $\frac{\sigma^2\mu_0+\sigma_0^2 n\bar{x}_n}{\sigma^2+\sigma_0^2 n}$이고 분산이 $\frac{\sigma_0^2\sigma^2}{\sigma^2+\sigma_0^2 n}$인 정규분포의 확률밀도함수이다. 즉, 정규 사전분포는 정규분포에 대한 켤레 사전분포족임을 알 수 있다. 제곱오차를 사용한 μ의 베이즈 추정량은 이 사후 확률분포의 평균인

$$E(\mu \mid X) = \frac{\sigma^2\mu_0+\sigma_0^2 n\overline{X}_n}{\sigma^2+\sigma_0^2 n}$$
$$= \frac{\delta}{1+\delta}\mu_0 + \frac{1}{1+\delta}\overline{X}_n$$

이고(단, $\delta = \sigma^2/n\sigma_0^2$), 이는 사전분포의 평균 μ_0와 표본평균 $\overline{X}_n$의 가중평균이다. 여기에서 μ_0와 $\overline{X}_n$에 대한 가중치는 표본의 크기 n과 사전분포의 분산 σ_0^2에 의해 결정되는데, 그 타당성을 음미해 볼 필요가 있다. 표본의 크기가 커질 때 $\overline{X}_n$의 가중치가 커지고, 사전 정보가 모호할수록(μ의 사전분포의 분산이 클수록) $\overline{X}_n$의 가중치가 커진다. 만약 사전분포의 분산이 매우 크거나 표본의 크기가 아주 크다면 베이즈 추정량은 $\overline{X}_n$와 거의 같아지고 사전분포의 분산이 매우 작다면 베이즈 추정량은 사전분포의 평균과 거의 같아질 것이다.

한편, 고정된 α에 대하여

$$\int_l^u k(\theta \mid x_1, \cdots, x_n)\, d\theta = 1-\alpha$$

를 만족하는 $[l, u] = [l(x_1, \cdots, x_n),\ u(x_1, \cdots, x_n)]$을 모수 θ에 대한 $100(1-\alpha)\%$ **베이즈 신뢰구간**(credible interval)이라고 한다. 베이즈 신뢰구간의 의미는 θ가 이 구간에 들어갈 확률이 $1-\alpha$가 된다는 것으로, 사전분포를 가정하지 않는 신뢰구간의 의미와 사뭇 다르다. 베이즈 신뢰구간에 대해 '상대도수적' 의미를 부여하는 것은 타당하지 않다.

베이즈 신뢰구간을 구할 때 같은 α의 값을 가진다면 가장 짧은 구간을 구하는 것이 자연스럽다. 이러한 생각으로부터 나온 것이 **최고 사후밀도**(highest posterior density, HPD) 구간인데, 이것은 $[l, u] = \{\theta : g(\theta \mid x_1, \cdots, x_n) \geq c\}$의 형태를 가지며, c의 값은 $\int_l^u k(\theta \mid x_1, \cdots, x_n)\, d\theta = 1-\alpha$를 만족하면서 가장 큰 값으로 찾으면

된다.

예 4.55

$X_1, X_2, \cdots, X_n$을 $N(\mu, \sigma^2)$으로부터 얻은 랜덤표본이고 모분산 σ^2은 알려져 있으며, μ의 사전 확률밀도함수는 $N(\mu_0, \sigma_0^2)$라 가정하자. 예 4.54에서처럼 사후분포는

$$\Theta|(X_1 = x_1, \cdots, X_n = x_n) \sim N(\frac{\sigma^2\mu_0 + \sigma_0^2 n\,\overline{x}_n}{\sigma^2 + \sigma_0^2 n},\ \frac{\sigma_0^2\sigma^2}{\sigma^2 + \sigma_0^2 n})$$

이고, θ에 대한 95% 베이즈 신뢰구간(HPD)은

$$\frac{\sigma^2\mu_0 + \sigma_0^2 n\,\overline{x}_n}{\sigma^2 + \sigma_0^2 n} \pm 1.96 \times \sqrt{\frac{\sigma_0^2\sigma^2}{\sigma^2 + \sigma_0^2 n}}$$

이 된다.

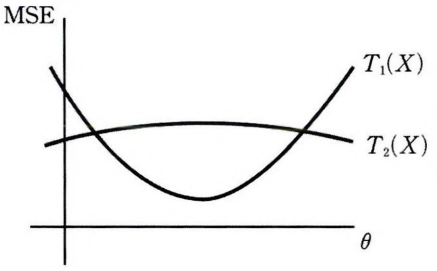
최소분산 비편향추정량을 구할 때, 평균제곱오차를 최소로 만드는 추정량을 일반적으로 찾을 수 없기 때문에 비편향추정량 가운데에서 평균제곱오차를 최소로 만드는 최소분산 비편향추정량을 찾았었다. 평균제곱오차를 최소로 만드는 추정량을 일반적으로 찾을 수 없는 한 가지 이유는 평균제곱오차가 모수에 의존하기 때문이라고 할 수 있는데, 제곱오차를 사용하는 베이즈 추정량은 θ에 대해 평균제곱오차(MSE)의 기댓값을 취함으로써 평균제곱오차가 θ에 의존하는 것을 방지하였다고 볼 수 있다. 평균제곱오차가 θ에 의존하지 않게 되면, 그 값으로 추정량을 비교하여 이를 최소로 하는 추정량을 찾는 절차가 쉬워진다. 이외에, 평균제곱오차가 모수 θ에 의존하지 않도록 하는 방법으로, 평균제곱오차의 모든 가능한 모수 θ의 영역에서의 최댓값을 고려하여 이 최댓값을 최소화하는 추정방법을 생각할 수 있다. 즉, 가능한 시나리오 중에서 가장 나쁜 시나리오를 골라 이 때의 손실을 최소로 만드는 추정량을 고르는 것이다.

이에 대한 내용을 간략히 소개하면, 모수의 함수 $g(\theta)$의 추정량 $T^*(X)$가 모든 가능한 모수 θ의 영역에서 임의의 다른 추정량 $T(X)$에 대하여

$$\max_\theta MSE(T^*(X)) \le \max_\theta MSE(T(X))$$

을 만족할 때, $T^*(X)$를 θ의 **미니맥스**(minimax) 추정량이라고 한다. 다음의 그림에서 $g(\theta)$에 대한 두 개의 추정량 $T_1(X)$와 $T_2(X)$에 대한 평균제곱오차를 비교하면,

$T_1(X)$가 대부분의 θ 영역에서 $T_2(X)$보다 더 작은 평균제곱오차를 가지고 있으나 $\max_\theta MSE(T_1(X)) \geq \max_\theta MSE(T_2(X))$이므로 $T_2(X)$가 미니맥스 추정량이 된다.



연습문제 4장

01 $X_1, X_2, \cdots, X_n$이 $U(\mu-\sqrt{3}\sigma, \mu+\sqrt{3}\sigma)$로부터 구한 랜덤표본이라고 하자. 이때 적률을 이용하여 μ와 σ를 추정하라.

02 $X_1, X_2, \cdots, X_n$이 확률밀도함수 $f_X(x;\theta)=(\theta+1)x^\theta$, $0<x<1$로부터의 랜덤표본이라고 할 때, 적률을 이용한 θ의 추정량이 $(2\overline{X}_n-1)/(1-\overline{X}_n)$이 됨을 보여라.

03 랜덤표본 $X_1, X_2, \cdots, X_n$의 모분포가 평균이 λ인 포아송 분포라고 한다. 이때 모수 λ에 대한 적률추정량을 일차 또는 이차적률을 사용하여 구하고, 따라서 적률추정량이 유일하지 않음을 보여라.

04 $X_1, X_2, \cdots, X_n$이 $U(0, \theta)$로부터의 랜덤표본이라고 할 때, 적률을 이용한 θ의 추정량을 구하고 최대가능도 추정량과 비교하라.

05 랜덤표본 $X_1, X_2, \cdots, X_n$의 모분포가 평균이 λ인 포아송 분포라고 한다.

(1) 적률추정방법에 의하여 $g(\lambda)=1/\lambda$를 추정하라.

(2) 최대가능도방법에 의하여 $g(\lambda)=1/\lambda$를 추정하라.

06 $X_1, X_2, \cdots, X_n$이 확률밀도함수 $f(x;\theta_1, \theta_2)=(1/\theta_2)\exp(-(x-\theta_1)/\theta_2)$, $x>\theta_1$, $\theta_2>0$으로부터의 랜덤표본이라고 할 때, 모수 θ_1과 θ_2의 최대가능도 추정량을 구하라.

07 확률변수 X의 분포가 $P(X=1)=\theta^2$, $P(X=2)=2\theta(1-\theta)$, $P(X=3)=(1-\theta)^2$ (단, $0<\theta<1$)이라고 하자. 이제 세 개의 관찰값 2, 2, 3을 얻었을 때 모수 θ의 최대가능도 추정값을 구하라.

08 확률벡터 $(X_1, X_2, \cdots, X_k)$가 모수가 $(n, p_1, p_2, \cdots, p_k)$인 다항분포를 따른다고 하자. 이때, 모수 $(p_1, p_2, \cdots, p_k)$의 최대가능도 추정량이 $(X_1/n, X_2/n, \cdots, X_k/n)$이 됨을 보여라.

09 서로 독립인 두 확률변수 $X \sim B(n, p)$와 $Y \sim B(m, p)$의 공통된 '성공' 확률 p의 최대가능도 추정량을 구하라.

10 $X_1, X_2, \cdots, X_n$이 $U(\theta-1/2,\ \theta+1/2)$로부터의 랜덤표본이라고 할 때 가능도함수를 구하고, 이에 근거하여 θ의 최대가능도 추정량이 유일하지 않음을 보여라.

11 $E(X^2) < \infty$일 때 $E(X-a)^2$는 상수 a의 값이 $E(X)$일 때 최소화됨을 보여라.

12 $X_1, X_2, \cdots, X_n$은 $f_X(x;\theta) = \dfrac{3\theta^3}{x^4}$ $(\theta < x < \infty)$로부터의 랜덤표본이다.

(1) 적률추정법을 사용하여 θ의 추정량을 구하라.

(2) θ의 최대가능도 추정량을 구하라.

(3) (1)과 (2)의 추정량의 평균제곱오차를 비교하라.

13 $X_1, X_2, \cdots, X_n$을 확률밀도함수 $f(x;\theta)$로부터 얻은 랜덤표본이라고 하자. 이때 어떤 상수 θ_0에 대하여 $T(X) = \theta_0$가 모수 θ의 비편향추정량이 아님을 보여라.

14 $X_1, X_2, \cdots, X_n$이 평균이 μ이고 분산이 σ^2인 분포로부터 얻은 랜덤표본이라고 할 때 모평균 μ가 알려져 있다면, $(1/n)\sum_{i=1}^{n}(X_i-\mu)^2$이 σ^2의 비편향추정량임을 보여라.

15 $X \sim U(0, \theta)$일 때 θ^2의 비편향추정량을 구하라.

16 $X_1, X_2, \cdots, X_n$이 $U(-\theta, \theta)$, $\theta > 0$로부터 얻은 랜덤표본이라고 할 때 $c(X_{(n)} - X_{(1)})$이 모수 θ의 비편향추정량이 되기 위한 상수 c의 값을 구하라.

17 $f(x;\theta) = 1/\theta$, $0 \le x \le \theta$, $\hat{\theta} = cX$가 θ의 비편향추정량이 되는 상수 c의 값을 구하라.

18 $X_1, X_2, \cdots, X_n$이 정규분포 $N(\mu, \sigma^2)$으로부터 추출한 랜덤표본이라고 하자. $cS = c\sqrt{\dfrac{\sum (X_i - \overline{X}_n)^2}{n-1}}$이 σ의 비편향추정량이 되도록 상수 c의 값을 구하라(힌트: $Y = (n-1)(S^2/\sigma^2)$이 카이제곱분포를 따르는 확률변수임을 이용하여 $E(\sqrt{Y})$을 구하라).

19 $X \sim$ 베르누이(p)일 때, p에 대한 추정량으로 $T_1(X) = X$와 $T_2(X) = 1/2$을 고려하였다.

(1) $T_1(X)$와 $T_2(X)$의 비편향성을 점검하라.

(2) $T_1(X)$와 $T_2(X)$의 평균제곱오차를 비교하라.

20 $X_1, X_2, \cdots, X_n$이 EXP(λ)로부터 얻은 랜덤표본이라고 하자. 모수 λ에 대한 추정량으로 $\hat{\lambda}_1 = \overline{X}_n$과 $\hat{\lambda}_2 = n\overline{X}_n/(n+1)$을 비교할 때,

(1) $\hat{\lambda}_1$과 $\hat{\lambda}_2$의 분산을 구하라.

(2) $\hat{\lambda}_1$과 $\hat{\lambda}_2$의 평균제곱오차를 구하라.

21 모수 θ에 대한 n개의 서로 독립인 비편향추정량 $\hat{\theta}_i (i = 1, 2, \cdots, n)$이 존재하며 $Var(\hat{\theta}_i) = \sigma_i^2$이라고 한다. 이들을 이용한 결합추정량 $\sum_{i=1}^{n} a_i \hat{\theta}_i$ (단, $\sum_{i=1}^{n} a_i = 1$)를 고려하자.

(1) 결합추정량 $\sum_{i=1}^{n} a_i \hat{\theta}_i$는 비편향추정량임을 보여라.

(2) $Var\left(\sum_{i=1}^{n} a_i \hat{\theta}_i\right)$는 $a_i = (1/\sigma_i^2)/\sum_{j=1}^{n}(1/\sigma_j^2)$일 때 최소화됨을 $n = 2$인 경우에 대해 증명하라.

22 모수 θ를 추정함에 있어 두 개의 독립인 비편향추정량 $\hat{\theta}_1$과 $\hat{\theta}_2$을 사용할 수 있고, $Var(\hat{\theta}_1) = 4\,Var(\hat{\theta}_2)$이라고 한다. 이제 $\hat{\theta}_1$과 $\hat{\theta}_2$의 선형결합꼴인 $\hat{\theta} = a_1\hat{\theta}_1 + a_2\hat{\theta}_2$를 θ의 추정량으로 택할 때, $E(\hat{\theta}) = \theta$를 만족시키는 비편향성의 조건하에서, 분산을 최소화하는 상수 a_1과 a_2를 구하라.

23 X_1, X_2, X_3이 $f_X(x;\theta)=(1/\theta)\exp(-x/\theta)$, $x>0$으로부터 얻은 랜덤표본이라고 하자. 모수 θ를 추정함에 있어 $(X_1+2X_2+X_3)/4$의 $\overline{X}_3$에 대한 효율을 구하라.

24 X_1, X_2, $\cdots$, X_n이 평균이 $k\theta$이고 분산이 $k\theta^2$인 감마분포로부터 추출된 크기 n인 랜덤표본이라고 하자.

(1) 적률추정법을 사용하여 k와 θ의 추정량을 구하라.

(2) k와 θ의 최대가능도 추정량을 찾아보고, 여기에서 파생하는 어려움에 대하여 논하라.

(3) k의 값이 알려져 있을 때 θ의 비편향추정량의 분산이 가질 수 있는 하한값을 결정하라.

25 X_1, X_2, $\cdots$, X_n이 베르누이(p)로부터 얻은 랜덤표본이라고 하자.

(1) 분산 $p(1-p)$에 대한 비편향추정량의 크래머-라오 하한값을 구하라.

(2) 분산 $p(1-p)$에 대한 최소분산 비편향추정량을 구하라.

(3) p^2에 대한 최소분산 비편향추정량을 구하라.

26 X_1, X_2, $\cdots$, X_n을 확률밀도함수 $U(0,\theta)$로부터 얻은 랜덤표본이라고 하자.

(1) 식 (4.7)의 피셔의 정보를 이용하여 $\dfrac{1}{nI(\theta)}$를 계산하라.

(2) θ에 대한 비편향추정량 $[(n+1)/n]X_{(n)}$의 분산이 (1)에서 계산한 하한값보다 작음을 보이고, 정리 4.3과 관련하여 이에 대한 적절한 설명을 하여라.

27 크기가 2인 랜덤표본 X_1, X_2가 확률밀도함수 $f_X(x;\theta)=(1/\theta)\exp(-x/\theta)$, $x>0$로부터 추출되었다고 하자.

(1) $Y_1=X_1+X_2$가 θ에 대한 충분통계량임을 보여라.

(2) $Y_1=X_1+X_2$와 $Y_2=X_2$의 결합 확률밀도함수를 구하라.

(3) Y_2는 θ의 비편향추정량이며 분산 θ^2을 가짐을 보여라.

(4) $Y_1=y_1$이 주어져 있을 때 Y_2의 조건부 확률밀도함수가 θ를 포함하지 않음을 보여라.

28 $X \sim \mathrm{POI}(\lambda)$일 때, $g(\lambda) = P(X=0) = \exp(-\lambda)$라고 하자.

(1) $\exp(-X)$는 $g(\lambda)$의 비편향추정량인가?

(2) 함수 u가 다음과 같이 정의될 때, $u(X)$는 $g(\lambda)$의 비편향추정량이 됨을 보여라.

$$u(x) = \begin{cases} 1, & x = 0 \\ 0, & x = 1, 2, \cdots \end{cases}$$

(3) $g(\lambda)$의 두 추정량 $\exp(-X)$와 $u(X)$의 평균제곱오차를 비교하라.

29 모분포 $N(0, \sigma^2)$으로부터 1개의 관찰값 X를 얻었다고 하자.

(1) σ^2에 대한 충분통계량을 구하라.

(2) σ^2의 비편향추정량을 구하라.

(3) 모표준편차 σ의 최대가능도 추정량을 구하라.

30 $X_1, X_2, \cdots, X_n$이 $f_X(x;\theta) = \exp(-(x-\theta))$ $(\theta < x < \infty)$로부터의 랜덤표본이라고 할 때, 표본최솟값 $X_{(1)}$이 충분통계량임을 보여라.

31 $X_1, X_2, \cdots, X_n$이 $U(0, \theta)$, $\theta > 0$로부터 얻은 랜덤표본이라고 하자.

(1) $Y = X_{(n)}$이 θ에 대한 완비 충분통계량임을 보여라.

(2) $E(X_{(n)}) \neq \theta$임을 보여라.

(3) θ에 대한 최소분산 비편향추정량을 구하라.

32 $X_1, X_2, \cdots, X_n$이 $f(x) = 1/(\theta_2 - \theta_1)$, $\theta_1 < x < \theta_2$로부터 얻은 랜덤표본이라고 하자.

(1) $(X_{(1)}, X_{(n)})$이 (θ_1, θ_2)에 대한 완비 충분통계량임을 보여라.

(2) $(\theta_1 + \theta_2)/2$에 대한 최소분산 비편향추정량을 구하라.

33 $X_1, X_2, \cdots, X_n \sim N(\mu, \mu^2)$일 때 $(\overline{X}_n, S^2)$이 완비성이 없음을 보여라.

34 $X_1, X_2, \cdots, X_n$이 $f(x;\theta)=\theta x^{\theta-1}$, $(0<x<1,\ \theta>0)$로부터 얻은 랜덤표본이라고 하자.

(1) 모수의 값 $\theta=1/2$, $\theta=1$, $\theta=2$ 각각에 대하여 모확률밀도함수 $f(x;\theta)$를 그려 보라.

(2) θ의 적률추정량을 구하고 이 추정량이 θ에 대한 완비충분통계량의 함수가 아님을 보여라.

(3) θ의 최대가능도 추정량을 구하라.

(4) $1/\theta$의 최소분산 비편향추정량을 구하라(힌트: $E[-\log X]=1/\theta$).

(5) θ의 최소분산 비편향추정량을 구하라.

35 $X_1, X_2, \cdots, X_n$이 기하확률밀도함수 $f(x;p)=p(1-p)^{x-1}$, $(0<p<1,\ x=1,\ 2,\ 3,\cdots)$로부터 얻은 랜덤표본이라고 하자.

(1) 적률추정방법에 의하여 p를 추정하라.

(2) p의 최대가능도 추정량을 구하라.

(3) $E(X_1)$의 최대가능도 추정량을 구하라.

(4) p의 비편향추정량에 대한 크래머-라오 하한값을 구하라.

36 모분포 $N(\mu, \sigma^2)$으로부터 랜덤표본 $X_1, X_2, \cdots, X_n$을 얻었다고 할 때, $P(X>0)$의 최대가능도 추정량을 구하라.

37 모수벡터 $(\theta_1, \cdots, \theta_k)$에 대한 최대가능도 추정량 $(\hat{\theta}_1, \cdots, \hat{\theta}_k)$는 결합 충분통계량 $(S_1, \cdots, S_k)$의 함수임을 보여라.

38 $T_n(X)$가 모수 θ의 비편향추정량일 때, 모든 $\theta \in \Omega$에 대해 $\lim_{n\to\infty} Var(T_n(X))=0$이면 $T_n(X)$는 일치성을 가짐을 보여라(힌트: 체비세프 정리를 사용할 것).

39 $X_1, X_2, \cdots, X_n$이 $f(x;\theta)=e^{-(x-\theta)}$, $x>\theta$로부터 얻은 랜덤표본이라고 하자.

(1) θ의 최대가능도 추정량을 구하라.

(2) 95백분위수의 최대가능도 추정량을 구하라.

40 $X_1, X_2, \cdots, X_{16}$이 $N(\mu, \mu^2)$로부터 구한 랜덤표본이라고 하자. 적절한 추축변량을 구하고, 그에 근거하여 모수 μ에 대한 90% 신뢰구간을 구하라.

41 주사위에서 6이 나올 확률을 변경하기 위해 주사위를 조작하였다. 이 조작된 주사위에서 6이 나올 확률이 p라고 하자. 여기에서 99%의 신뢰도를 가지고 p의 추정량과 p 사이의 최대오차가 0.02가 되게 하려면 얼마나 많은 횟수의 주사위를 던져야 하겠는가?

42 어느 모집단에서 무작위추출한 $n = 500$명의 유권자 중에서 K씨를 지지하는 사람수는 154명이었다. K씨를 지지하는 유권자의 비율 p에 대한 95% 근사신뢰구간을 구하라.

43 $X_1, X_2, \cdots, X_{16}$이 $N(\mu, \sigma^2)$으로부터 구한 랜덤표본이라고 하자.

(1) 모분산 $\sigma^2 = 9$이며 표본평균이 $\overline{X}_{16} = 18.5$일 때, 모평균 μ에 대한 90% 신뢰구간을 구하라.

(2) 또한 (1)의 자료에 근거하여 모평균 μ에 대한 90% 단측신뢰상한을 구하라.

44 $X_1, X_2, \cdots, X_n$이 $f(x;\theta) = \theta \exp(-\theta x)$ $(\theta > 0,\ x > 0)$로부터 구한 랜덤표본이라고 하자.

(1) θ에 대한 90% 신뢰구간을 구하라.

(2) θ^2에 대한 90% 신뢰구간을 구하라.

(3) $\exp(-\theta) = P(X > 1)$에 대한 90% 신뢰구간을 구하라.

45 $X_1, X_2, \cdots, X_n$이 $U(\theta - 1/2,\ \theta + 1/2)$로부터 구한 랜덤표본이라고 하자. 이때

(1) 확률구간 $[X_{(1)}, X_{(n)}]$이 모수 θ를 포함할 확률을 구하라.

(2) 모수 θ에 대한 95% 근사신뢰구간을 구하라.

46 두 개의 관찰값 X_1과 X_2를 모분포 $N(\mu, 1)$로부터 얻을 때,

(1) $P(X_{(1)} < \mu < X_{(2)}) = 1 - \alpha$를 만족하는 α를 계산하라.

(2) $X_2 - \mu$가 추축변량인 점을 이용하여 신뢰도가 (1)에서 구한 $1 - \alpha$와 같은 신뢰구간을 구하고, 그 길이를 $[X_{(1)}, X_{(2)}]$와 비교하라.

47 $X_1, X_2, \cdots, X_n$과 $Y_1, Y_2, \cdots, Y_m$이 각각 $\mathrm{EXP}(\theta_1)$과 $\mathrm{EXP}(\theta_2)$로부터 구한 서로 독립인 랜덤표본이라고 하자.

(1) $(\theta_2/\theta_1)(\overline{X}_n/\overline{Y}_m) \sim F(2n, 2m)$임을 보여라.

(2) θ_2/θ_1에 대한 90% 신뢰구간을 구하라.

48 두 개의 독립인 랜덤표본 $X_1, X_2, \cdots, X_n$과 $Y_1, Y_2, \cdots, Y_m$의 모분포가 각각 $N(\mu_X, \sigma^2)$과 $N(\mu_Y, \sigma^2)$이라고 할 때, 두 모평균의 차이에 대한 $100(1-\alpha)\%$ 신뢰구간을 유도하라(단, 공통분산 σ^2은 알려지지 않았음).

49 $X_1, X_2, \cdots, X_n$이 $U(0, \theta)$로부터 구한 랜덤표본이라고 하자. 이때 충분통계량 $X_{(n)}$에 근거하여 모수 θ에 대한 $100(1-\alpha)\%$ 신뢰구간을 유도하라.

50 모분포 $N(\mu, \sigma^2)$으로부터 랜덤표본 $X_1, X_2, \cdots, X_n$을 얻었다고 할 때, 모수벡터 (μ, σ^2)의 $100(1-\alpha)\%$ '동시' 신뢰영역을 구하라.

51 $X_1, X_2, \cdots, X_n$이 확률밀도함수 $f(x;\theta)$를 갖는 확률분포로부터의 랜덤표본이라고 하자. 식 (4.9)에서와 같이, 모수의 참값인 $\theta = \theta_0$에서 $E\left(\frac{d}{d\theta}\log f(X;\theta)\right) = 0$이 성립하는 것을 보여라.

52 $X_1, X_2, \cdots, X_n$이 확률밀도함수 $f(x;\theta)$를 갖는 확률분포로부터의 랜덤표본일 때, 로그가능도함수를 $l(\theta)$로 표시하자. 모수의 참값이 θ_0일 때 $-\frac{1}{n}l''(\theta_0)$은 피셔의 정보, $I(\theta_0)$로 확률수렴함을 확인하기 위해, 적절한 조건하에서 다음을 보여라.

$$E\left(\frac{d}{d\theta}\log f(X;\theta)\Big|_{\theta=\theta_0}\right)^2 = -E\left(\frac{d^2}{d\theta^2}\log f(X;\theta)\Big|_{\theta=\theta_0}\right)$$

53 $X_1, X_2, \cdots, X_n$이 확률밀도함수 $f(x;\theta)$를 갖는 확률분포로부터의 랜덤표본일 때, 로그가능도함수를 $l(\theta)$로 표시하자. 모수의 참값이 θ_0일 때 적절한 조건하에서 $\frac{1}{\sqrt{n}} l'(\theta_0) \xrightarrow{d} N(0, I(\theta_0))$이 성립함을 보여라.

54 베이즈 추정량이 충분통계량의 함수임을 보여라(힌트: 인수분해 정리를 사용할 것).

55 $X_1, \cdots, X_n$이 베르누이(θ)에서 나온 랜덤표본이고 Θ는 다음 표와 같은 사전분포를 따른다고 하자. θ의 사후 확률분포를 구하라.

θ	0.25	0.5	0.75
$\pi(\theta)$	0.25	0.5	0.25

56 $X_1, \cdots, X_n$이 $N(\mu, \frac{1}{\theta})$(μ는 알려진 상수)에서 나온 랜덤표본이고 $\Theta \sim \mathrm{GAM}(\alpha, \beta)$ (α, β는 알려진 상수)일 때, θ의 사후 확률분포를 구하라.

57 $X_1, \cdots, X_n$이 $\mathrm{EXP}(\frac{1}{\theta})$에서 나온 랜덤표본이고 $\Theta \sim \mathrm{EXP}(\frac{1}{\beta})$ (β는 알려진 상수)일 때, 제곱오차를 사용한 θ의 베이즈 추정량을 구하라.

58 $X_1, \cdots, X_n$이 베르누이(θ)에서 나온 랜덤표본이고 Θ의 사전분포가 $\mathrm{BETA}(\alpha, \beta)$라고 하자. $n = 40$, $\sum_{i=1}^{n} x_i = 15$, $\alpha = \beta = 2$일 때, θ에 대한 94.3% 베이즈 신뢰구간(HPD)을 구하라.

5장 가설검정

- 5.1 검정의 기본 요소
- 5.2 최강력 검정법
- 5.3 일반화 가능도비 검정법
- 5.4 이표본 검정법

통계적 추론은 앞 장에서 다루었던 추정문제와 이 장에서 다룰 가설검정(hypothesis testing)의 문제로 나누어진다. 추정이론에서는 가능한 모수의 값(또는 값들)을 제공하는 데에 목적이 있었지만 검정이론에서는 모집단의 성질에 대한 어떤 가설을 받아들일 것인지 아니면 기각할 것인지를 결정하는 데에 목적이 있다.

과학적 실험이나 연구관찰 등을 통해 얻어진 자료에 근거하여 통계적 추론을 함에 있어서 가능한 모수의 값의 범위를 알아내기 원하기보다 몇 개의 가능한 가설에 대한 검정을 하고자 하는 경우가 있다. 예를 들면 어떤 병을 치료하는 데 있어서 기존방법과 새로운 방법 사이 효과의 차이 여부라든가, 어떤 기계 부품의 평균수명이 얼마 이상이라든가 등의 가설에 대해, 이를 받아들일 것인지 기각할 것인지의 결정을 표본자료에 근거하여 내리려는 것이다.

이 장에서는 연구대상이 되는 현상에 대한 가설이나 이론 등에 대한 타당성을 다루는 통계적 가설검정의 일반적인 방법들을 다루어 보겠다. 나아가, 이들을 흔히 접하게 되는 검정문제에 응용하여 보기로 한다. 점추정에서와 마찬가지로 확률밀도함수 $f(x;\theta)$로부터 랜덤표본 $X_1, X_2, \cdots, X_n$을 얻는 경우를 주로 고려하겠으며, 검정의 대상이 되는 통계적 가설은 표본이 추출된 모집단의 분포에 관한 것이 될 것이다.

5.1 검정의 기본 요소

이 절에서는 통계적 가설검정에서 사용되는 몇 가지 중요한 개념들을 소개한다. 이들은 후에 분산분석이나 회귀분석 등에서도 활용된다. 우선 통계적 가설에 대한 정의는 다음과 같다.

정의 5.1

관심 있는 모집단의 성질에 대한 단정이나 추측 등의 표현(statement)을 **통계적 가설**(statistical hypothesis)이라고 한다. 흔히 이러한 가설은 모집단의 성질을 나타내는 확률변수의 분포에 대한 표현으로 나타난다. 어떤 가설이 확률분포를 완전히 결정하면 이를 **단순가설**(simple hypothesis)이라고 하고, 그렇지 않은 경우를 **복합가설**(composite hypothesis)이라고 한다.

예 5.1

$X_1, X_2, \cdots, X_n$이 정규분포 $N(\mu, \sigma^2)$으로부터 구한 랜덤표본이라고 하고, 모분포의 성격을 표시하는 모수벡터 (μ, σ^2)에 대한 가설을 고려해 보자. 예를 들어, $(\mu, \sigma^2) = (0,1)$이라는 가설을 생각한다면, 이 가설이 참이라고 가정했을 때 랜덤표본이 뽑힌 모집단의 분포는 $N(0,1)$이 된다. 이 가설은 모집단의 분포를 완전하게 결정짓게 되므로 단순가설이다. 반면, $\mu > \mu_0$와 같은 형태의 가설은 복합가설이 되는데, 이는 이 가설이 참이라고 가정하더라도 모수가 여전히 여러 가지 다른 값을 가질 수 있어서 모집단의 분포가 하나로 결정되지 않기 때문이다.

통계적 가설검정에는 언제나 두 개의 상반되는 가설이 등장한다. 하나는 **귀무가설**(null hypothesis)이라고 하고 다른 하나는 **대립가설**(alternative hypothesis)이라고 한다. 귀무가설은 흔히 지금까지 알려져 있는 사실 또는 주장으로서 특별한 사유가 없다면 일반적으로 받아들이게 되는 가설이고, 대립가설은 지금까지 알려져 있는 것과 다른 주장으로서 이를 뒷받침할 증거가 있어야만 받아들이게 되는 가설이다. 그런데 통계실험이나 관찰 등을 하는 대부분의 경우에 새로운 사실이나 결과 등을 입증할 통계적 증거를 찾는 것이 그 목적이므로, 실험자 또는 연구자가 보이고자 하는 바는 대립가설이 된다. 즉, 통계적 가설검정에서는 기존의 사실을 **귀무가설**(null hypothesis)로 하고 연구자가 보이고자 하는 연구가설을 **대립가설**(alternative hypothesis)로 택하여 귀무가설을 기각할만한 증거가 있는지를 실험 또는 관찰 등을 통해 얻은 통계자료에 근거하여 찾아보는 것이 일반적인 방법이다. 이 책에서는 귀무가설을 H_0 그리고 대립가설을 H_1으로 표기하기로 한다.

이 장에서 하고자 하는 바는 주어진 자료가 귀무가설에 대한 반증이 되는지 아닌지를 구별하여 귀무가설을 기각하거나 기각하지 않는 결정을 내리는 데에 사용할 수 있는 좋은 검정법을 찾는 것이다. 물론 표본에 근거하여 귀무가설과 대립가설 중에 하나를 택하는 어떤 방법도 언제나 옳은 결론에 이르기를 기대하지는 않으나, 우리가 여기에서 원하는 바는 옳은 결론을 내리는 빈도가 높은, 즉 잘못된 결정을 내릴 확률이 작은 검정법을 추구하고자 함이다. 잘못된 결정을 내릴 확률이 작은 검정법을 찾기 위해서, 다음과 같이 기각영역을 설정하여 오류의 확률을 계산하게 된다.

주어진 랜덤표본 $X_1, X_2, \cdots, X_n$에 근거하여 통계적 가설에 대한 증거를 살펴볼 때 사용되는 통계량을 **검정통계량**(test statistic)이라고 하며, 귀무가설을 기각하게 되

는 검정통계량의 값을 가지는 표본공간의 부분집합을 **기각영역**(rejection region 또는 critical region)이라고 한다.

예 5.2

$X_1, X_2, \cdots, X_{25}$가 정규분포 $N(\mu, 10^2)$으로부터 구한 랜덤표본이라 하고, 귀무가설 $H_0 : \mu = 100$과 대립가설 $H_1 : \mu = 105$를 고려해 보자. 이 두 가설은 모두 단순가설이다. 이때 검정통계량으로는 모평균 μ에 대한 완비 충분통계량이며 최대가능도 추정량, 적률추정량, 최소분산 비편향추정량인 $\overline{X}_{25}$를, 기각영역으로는 표본공간의 부분집합인 $\{(x_1, x_2, \cdots, x_{25}) : \overline{x}_{25} \geq c\}$를 (단, c는 상수) 생각할 수 있다. 대립가설에 주어진 모평균 값이 귀무가설에 주어진 모평균의 값보다 크므로 표본평균이 클 때 귀무가설을 기각하는 것이 합리적이다. 기각영역은 $\{\overline{x}_{25} \geq c\}$로 줄여서 표현하기도 한다. 다른 문제에서도 마찬가지이다.

통계적 가설검정에서는 모집단의 실제 상태를 모르면서 표본에서 주어지는 정보에 근거해 귀무가설을 기각하거나 기각하지 않는 결정을 하게 되므로, 두 가지 종류의 오류가 발생할 수 있다. 실제로는 귀무가설이 참인데 기각하게 되는 **제1종 오류**(type 1 error)와 귀무가설이 참이 아닌데 기각하지 않게 되는 **제2종 오류**(type 2 error)가 그것이다. 이를 표로 나타내면 〈표 5.1〉과 같다.

표 5.1 가설검정에 수반되는 두 가지 오류

	H_0가 참(true)	H_1이 참(true)
H_0를 기각하지 않음	올바른 결정	제2종 오류
H_0를 기각함	제1종 오류	올바른 결정

우리가 추구하는 검정방법은 랜덤표본에 의존하므로 같은 모집단에 동일한 검정방법을 사용한다고 하더라도 언제나 같은 결론에 이르지는 않는다. 그렇기에 언제나 올바른 결정을 내린다는 것은 불가능하므로, 오류를 범할 확률을 최소화하는 검정방법을 모색하고자 한다. 오류에는 두 가지 종류가 있으므로 두 종류의 오류를 범할 확률을 모두 고려해야 한다. 귀무가설 H_0가 참인데 귀무가설을 기각하는, 제1종 오류를 범할 확률

$$P(\text{제1종 오류}) = P(H_0\text{를 기각함} \mid H_0) \tag{5.1}$$

을 **유의수준**(significance level)이라고 하며 α로 표기한다. 기각영역을 C로, 귀무가설하에서 $X_1, X_2, \cdots, X_n$의 결합 확률밀도함수를 $f(x_1, x_2, \cdots, x_n \mid H_0)$로 표기하면, 이 검정의 유의수준은

$$P[(X_1, X_2, \cdots, X_n) \in C \mid H_0]$$
$$= \begin{cases} \int \cdots \int_C f(x_1, x_2, \cdots, x_n \mid H_0)\, dx_1\, dx_2 \cdots\, dx_n, & \text{연속형} \\ \sum_{(x_1, x_2 \cdots, x_n) \in C} \cdots \sum f(x_1, x_2, \cdots, x_n \mid H_0), & \text{이산형} \end{cases}$$

으로 계산된다. 또한 귀무가설 H_0이 참이 아닌데 귀무가설을 기각하지 않는, 제2종 오류를 범할 확률

$$P(\text{제2종 오류}) = P(H_0\text{를 기각하지 않음} \mid H_1) \tag{5.2}$$

을 β로 표기한다. 여기에서 두 가지 종류의 오류를 '제1종'과 '제2종'으로 나누는 것은 일반적인 방법이며, α와 β도 오류를 범할 확률을 표시하기 위해 일반적으로 사용되는 문자들이다.

예 5.3

우리나라를 비롯한 많은 나라들에서 무죄추정의 원칙이 법정 피고인에게 적용된다. 피의자가 범죄를 저질렀다는 증거가 밝혀질 때까지는 무죄임을 가정하는 것이다. 피고인이 법정에 서게 되면 검찰 측에서는 이 사람이 죄가 있음을 밝히기 위해 증거를 모아 제시하게 되고, 이 증거들이 피고인이 범죄를 저질렀다는 충분한 증거가 된다고 인정되면 유죄가 선고된다. 만약, 이 증거들이 범죄의 충분한 증거가 되지 못한다면 무죄가 선고될 것이다. 피의자에게 무죄가 선고된다는 것은 일반적으로, 법정이 범죄에 대한 충분한 증거를 발견하지 못했다는 뜻이지 피의자가 무죄라는 것에 대한 증거가 있다는 뜻은 아니다. 이 예제에서 제1종 오류는 피의자가 실제로 무죄인데 유죄를 선고하여 복역하게 하는 것이고, 제2종 오류는 피의자가 실제로 유죄인데 무죄를 선고하여 풀어주는 것이다.

예 5.3과 비슷한 상황이 통계적 가설검정에도 적용된다. 귀무가설과 대립가설을 설

정한 다음, 표본을 통해 귀무가설에 대한 충분한 반증을 찾기 전까지는 귀무가설이 참이라고 가정한다. 왜냐하면 귀무가설과 대립가설은 처음 설정에서부터 비대칭적 관계이며, 충분한 증거가 발견되기 전까지는 대립가설이 옳다고 여기지 않을 것이기 때문이다. 또, 귀무가설에 대한 충분한 반증을 찾지 못해 기각하지 못하게 된 경우, 이것은 표본으로부터 귀무가설이 맞다는 증거를 찾았다는 뜻이 아니라 귀무가설이 틀렸다는 충분한 증거를 찾지 못했다는 뜻이 된다. 이러한 맥락에서 '귀무'가설이라는 용어를 사용하는데, 귀무가설을 기각하지 못하게 되면 기존의 상태로 돌아간다는 의미이다.

귀무가설과 대립가설의 비대칭성에 따라 제1종 오류와 제2종 오류도 다르게 취급된다. 위의 법정 예제에서 제1종 오류를 범하면, 특히 무기징역이나 사형과 같이 극단적인 선고가 나오는 경우 매우 심각하고 비극적인 결과를 가져오게 된다. 물론 제2종 오류도 위험하지만 제1종 오류는 매우 작은 확률을 갖도록 통제되어야 할 것이다. 이것은 조금 극단적인 예이지만, 통계적 가설검정에서 제1종 오류를 일반적으로 더 '중요시'하는 것이 사실이다. 제1종 오류를 범하게 되면 지금까지 믿어온 일반적 믿음(귀무가설)이 참임에도 불구하고 새로운 변화(대립가설)를 인정하게 되므로 불필요한 대처를 하게 된다. 또, 연구자가 증명하고자 하는 주장이 대립가설이기 때문에 제1종 오류를 범할 확률이 크면 연구의 결과가 다른 사람들로부터 신뢰를 받기 어렵다. 그래서 제1종 오류를 범할 확률, 즉 유의수준이 항상 작은 값이 되도록 관리한다.

가설검정에서도 추정이론에서 고려했던 바와 같은 맥락에서 다음과 같이 손실함수를 고려할 수 있다. $L(H_i ; H_j)$를 가설 H_j가 실제로 참인데 H_i를 받아들였을 때의 손실이라고 하고 다음과 같이 정의하자.

$$\begin{aligned} L(H_i ; H_j) &= 0, \ i = j\text{인 경우} \\ &= 1, \ i \neq j\text{인 경우} \ (i, j = 0, 1) \end{aligned}$$

즉, 옳은 결정을 내렸을 때는 손실이 0이고 틀린 결정을 내렸을 때는 손실이 1이라는 것이다. 이러한 손실함수에 기댓값을 취하면,

$$E[L(H_1 ; H_0)] = P[\text{제1종 오류}]$$
$$E[L(H_0 ; H_1)] = P[\text{제2종 오류}]$$

가 됨을 알 수 있다.

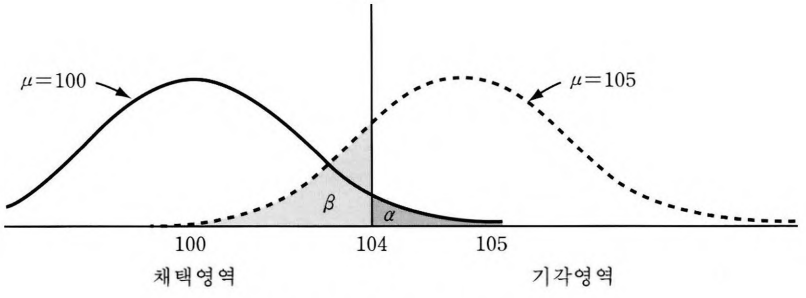
예 5.4

(예 5.2의 계속) 앞의 예 5.2에서 기각영역을 $\{(x_1, x_2, \cdots, x_{25}) : \bar{x}_{25} \geq 104\}$라고 가정하자. 이때 제1종 오류를 범할 확률 α와 제2종 오류를 범할 확률 β는 각각 다음과 같이 계산된다.

$$\begin{aligned}
\alpha &= P(\text{제1종 오류}) \\
&= P(H_0\text{를 기각} \mid H_0) \\
&= P(\bar{X}_{25} \geq 104 \mid \mu = 100) \\
&= P\left[\frac{\sqrt{25}(\bar{X}_{25} - 100)}{10} \geq \frac{\sqrt{25}(104-100)}{10} \,\middle|\, \mu = 100\right] \\
&= 1 - \Phi(2) \\
&= 0.0228
\end{aligned}$$

$$\begin{aligned}
\beta &= P(\text{제2종 오류}) \\
&= P(H_0\text{를 기각하지 않음} \mid H_1) \\
&= P(\bar{X}_{25} < 104 \mid \mu = 105) \\
&= P\left[\frac{\sqrt{25}(\bar{X}_{25} - 105)}{10} < \frac{\sqrt{25}(104-105)}{10} \,\middle|\, \mu = 105\right] \\
&= \Phi(-0.5) \\
&= 0.3085
\end{aligned}$$

단, Φ는 표준정규분포의 누적확률분포함수이다. 이와 같은 계산은 통계량 $\bar{X}_{25}$의 확률밀도함수를 통해 다음 그림 5.1과 같이 표현된다.



▸ 그림 5.1 ◂ $\bar{X}_{25}$의 확률밀도함수

이제 랜덤표본 $X_1, X_2, \cdots, X_n$을 얻은 모집단의 분포가 모수 θ에 의해 특징지어질 때, 검정력함수를 아래와 같이 정의한다.

정의 5.2

귀무가설 H_0에 대한 기각영역이 C인 검정의 **검정력함수**(power function)는

$$\pi(\theta) = P[(X_1, X_2, \cdots, X_n) \in C \mid \theta]$$

즉, 귀무가설을 기각하는 확률로 정의된다.

검정력함수는 모수 θ의 참값이 무엇이냐에 따라 다른 값을 가지게 되므로 θ의 함수이고, 주어진 θ에서의 검정력함수의 값 $\pi(\theta)$를 이 θ에서의 검정력(power)이라고 한다. 검정력은 귀무가설을 기각할 확률이므로 θ가 대립가설에 속하는 값이면 검정력이 큰 것이 좋고 θ가 귀무가설에 속하는 값이면 검정력이 작은 것이 좋다. 주어진 θ가 대립가설에 속하고 이 대립가설이 단순가설인 경우, 검정력은 제2종 오류를 범할 확률 β를 1에서 뺀 $1-\beta$와 동일하다. 또한, 모수 θ가 단순귀무가설 H_0에서의 값 θ_0을 가질 때 검정력은 유의수준 α와 같다. 즉, $\pi(\theta_0) = \alpha$이다. 이와 같은 검정력함수는 마치 평균제곱오차가 점추정의 기준이 되었던 것처럼, 유의수준이 고정되었을 때 검정방법의 성능을 결정하는 기준이 된다.

예 5.5

(예 5.4의 계속) 앞의 예 5.4에서 기각영역을 $\{(x_1, x_2, \cdots, x_{25}) : \bar{x}_{25} \geq 104\}$라고 했을 때 검정력을 $\mu = 105$인 점에서 구해 보았다. 이제 $\mu > 100$인 모든 점에 대해서 검정력을 구해 보자. 이는 μ에 대한 함수로서 다음과 같이 구해진다.

$$\begin{aligned}\pi(\mu) &= P(\bar{X}_{25} \geq 104 \mid \mu) \\ &= P\left[\frac{\sqrt{25}\,(\bar{X}_{25} - \mu)}{10} \geq \frac{\sqrt{25}\,(104-\mu)}{10} \,\middle|\, \mu\right] \\ &= 1 - \Phi\left(\frac{104-\mu}{2}\right).\end{aligned}$$

이를 그림으로 표현하면 다음의 그림 5.2와 같다.