원본 1쪽 4.1 통계량의 확률분포(표본분포)

[정의] 랜덤표본(random sample)과 통계량(statistic)

모집단의 확률밀도함수(또는 확률질량함수)를 $f(x;\theta), \theta \in \Omega$라 하자. 이 모집단에서 얻은 $X_1, \ldots, X_n$이 서로 독립이고 동일한 분포 $f(x;\theta)$를 따르면 **랜덤표본**이라고 한다.

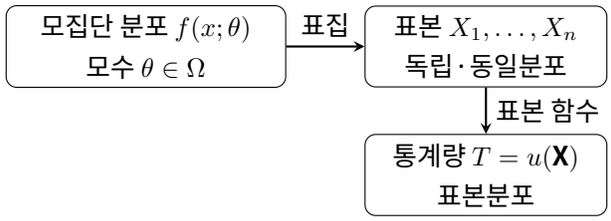
- **통계량** $T = u(X_1, \ldots, X_n)$은 표본의 함수이며, 미지의 모수 θ를 함수에 직접 포함하지 않는다. 표본값이 주어지면 통계량의 관측값 $u(x_1, \ldots, x_n)$이 결정된다.
- $X_1, \ldots, X_n$은 확률변수이므로 T도 확률변수이다. 따라서 T가 갖는 확률분포가 **표본분포(sampling distribution)**이며 모집단 분포 및 표본크기 n에 의존할 수 있다.
- **모수(parameter)**는 모집단을 기술하는 수이다. Ω는 가능한 모수값 전체의 집합인 **모수공간(parameter space)**이다.

[참고사항] 랜덤표본과 관측값의 구분

X_i는 i번째 랜덤표본이라는 확률변수이며, x_i는 표본을 얻은 뒤 관측한 고정된 값이다. 즉 $x_i = 100$ 같은 관측값 자체는 확률변수가 아니다.

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i, \qquad S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2$$

는 통계량이다. 반면 $\bar{X} - \mu$ 또는 $\bar{X}/\sigma^2$처럼 미지의 모수를 직접 넣은 식은, 그 모수가 주어지지 않은 일반적 상황에서는 통계량이 아니다. **원본 필기의 관계도 정서**



원본의 정의 및 X_i와 x_i의 구분을 모두 살리고, 표본-통계량-표본분포 사이의 관계를 필기 도식 대신 활자 도식으로 표현했다.

원본 2쪽 손글씨 정서

4.1 확률표본, 모수와 통계량

모집단과 표본의 관계. 모집단은 확률밀도(또는 확률질량)함수 $f(x;\theta)$로 나타내고, θ는 미지의 모수이다. 모집단에서 독립적으로 동일한 분포를 따라 추출한 표본을 $X_1,\dots,X_n \overset{\text{iid}}{\sim} f(x;\theta)$라 한다.

> **통계량의 뜻.** $T = u(X_1,\dots,X_n)$은 표본의 함수이고 미지 모수를 식에 직접 포함하지 않아야 한다. 표본이 추출되기 전에는 확률변수, 수치가 관측된 후에는 통계량의 관측값이 된다.

대표 통계량

$$\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i, \qquad \sum_{i=1}^{n} X_i = n\bar{X},$$

$$S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i-\bar{X})^2, \qquad X_{(1)} = \min(X_1,\dots,X_n),$$

$$X_{(n)} = \max(X_1,\dots,X_n).$$

표본평균과 표본분산, 최솟값 · 최댓값은 모두 통계량이다. 표본분포는 이러한 통계량의 확률분포이며, 통계량의 분포는 모집단 분포와 표본크기에 따라 달라진다.

> **정리.** $\bar{X}$는 관측한 X_i로 계산할 수 있다. $\bar{X}-\mu$처럼 미지 모수 μ가 직접 들어가면 일반적으로 통계량이 아니다. 단, 모수가 주어진 상수로 지정된 가설하의 검정통계량은 별도로 다룬다.

원본 3쪽 4.1 랜덤표본과 통계량 예제

[예 4.1.1] 랜덤표본을 이용하는 조사

(a) 공정의 불량률 조사. (b) 하천 오염도 조사: 단위 부피당 부유생물의 수.

[예 4.1.2] 베르누이 표본으로 불량률 추정

$X_1, \ldots, X_n \overset{\text{iid}}{\sim} \text{Bernoulli}(p)$로 놓고

$$\widehat{p} = \frac{1}{n}\sum_{i=1}^{n} X_i, \qquad K = \sum_{i=1}^{n} X_i \sim \text{Bin}(n, p).$$

따라서 표본분포는

$$P\left(\widehat{p} = \frac{k}{n}\right) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, \ldots, n.$$

$$E(\widehat{p}) = p, \qquad \text{Var}(\widehat{p}) = \frac{p(1-p)}{n}.$$

표본 크기가 커질수록 분산이 감소하여 $\widehat{p}$가 p 주변에 집중한다.

[예 4.1.3] 정규 모집단의 표본

$X_1, \ldots, X_n \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$이고

$$\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i, \qquad S^2 = \frac{1}{n-1}\sum_{i=1}^{n} (X_i - \overline{X})^2.$$

(1) 두 통계량의 표본분포는 무엇인가?

(2) $X_i - \mu$는 통계량인가? 미지 모수 μ를 포함하므로 일반적으로 통계량이 아니다.

(3) 순서대로 정렬한 $X_{(1)} < \cdots < X_{(n)}$도 표본의 함수이므로 각각 통계량이다(연속형일 때 동점 확률 0).

원본 4쪽 표본평균과 표본분산의 성질

[정리] 표본평균과 표본분산의 기대값 · 분산

$X_1, \ldots, X_n \overset{\text{iid}}{\sim} f(x)$, $E(X_i) = \mu$, $\mathrm{Var}(X_i) = \sigma^2$이며, 네 번째 중심적률 $\mu_4 = E[(X_i - \mu)^4] < \infty$라 하자.

$$\overline{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i, \qquad S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X}_n)^2.$$

$$\boxed{E(\overline{X}_n) = \mu, \qquad \mathrm{Var}(\overline{X}_n) = \frac{\sigma^2}{n}.}$$

$$\boxed{E(S^2) = \sigma^2, \qquad \mathrm{Var}(S^2) = \frac{1}{n}\left(\mu_4 - \frac{n-3}{n-1}\sigma^4\right), \quad n > 1.}$$

원본 손글씨의 핵심 풀이

표본이 독립이므로

$$\mathrm{Var}(\overline{X}_n) = \mathrm{Var}\left(\frac{1}{n}\sum_i X_i\right) = \frac{1}{n^2}\sum_i \mathrm{Var}(X_i) = \frac{\sigma^2}{n}.$$

그리고 다음 항등식을 사용한다.

$$\sum_{i=1}^{n}(X_i - \overline{X}_n)^2 = \sum_{i=1}^{n}(X_i - \mu)^2 - n(\overline{X}_n - \mu)^2.$$

양변에 기대값을 적용하면

$$(n-1)E(S^2) = n\sigma^2 - n \cdot \frac{\sigma^2}{n} = (n-1)\sigma^2.$$

원본 필기의 정규곡선 그림은 표본평균의 분포가 모집단보다 좁아지는 현상($\sigma/\sqrt{n}$)을 뜻한다.

원본 5쪽 표본평균 및 표본분산의 성질과 필기 곡선

$X_1, \dots, X_n \overset{\text{iid}}{\sim} f$ 이고 $EX_i = \mu$, $\mathrm{Var}(X_i) = \sigma^2$, $\mu_4 = E(X_i - \mu)^4 < \infty$ 라 둔다. **표본평균의 평균·분산**

$$E\bar{X} = \frac{1}{n}\sum_i EX_i = \mu, \qquad \mathrm{Var}(\bar{X}) = \frac{1}{n^2}\sum_i \mathrm{Var}(X_i) = \frac{\sigma^2}{n}.$$

불편표본분산의 증명

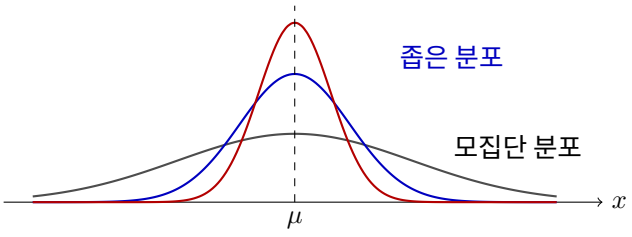
$$\sum_i (X_i - \bar{X})^2 = \sum_i (X_i - \mu)^2 - n(\bar{X} - \mu)^2.$$

$$E\sum_i (X_i - \bar{X})^2 = n\sigma^2 - n\frac{\sigma^2}{n} = (n-1)\sigma^2, \qquad E(S^2) = \sigma^2, \quad S^2 = \frac{\sum_i (X_i - \bar{X})^2}{n-1}.$$

표본분산의 분산: 원본 공식

$$\boxed{\mathrm{Var}(S^2) = \frac{1}{n}\left(\mu_4 - \frac{n-3}{n-1}\sigma^4\right), \quad n > 1.}$$

정규모집단이면 $\mu_4 = 3\sigma^4$ 이므로 $\mathrm{Var}(S^2) = 2\sigma^4/(n-1)$ 이다. **필기 곡선 복원: 평균 중심에서 표본평균 분포가 더 집중됨**



[검산·보충] 그림은 설명용 개념도이며 동일한 모집단과 표본평균의 분포를 일반적으로 정규분포라고 뜻하는 것은 아니다.
표본평균의 분산은 σ^2/n.

원본 6쪽 4.2 대표적인 표본분포 — 카이제곱분포

모집단이 정규분포를 따를 때 표본평균과 표본분산의 표본분포를 구하기 위해 χ^2, t, F분포를 사용한다.

(1) 카이제곱분포의 정의

서로 독립인 $Z_1, \ldots, Z_r \overset{\text{iid}}{\sim} N(0,1)$에 대하여

$$Y = Z_1^2 + \cdots + Z_r^2 \sim \chi^2(r).$$

이 분포의 밀도는

$$f_Y(y) = \frac{1}{2^{r/2}\Gamma(r/2)} y^{r/2-1} e^{-y/2}, \quad y > 0.$$

카이제곱분포는 감마분포의 특별한 형태로,

$$\chi^2(r) = \text{Gamma}\left(\text{shape } r/2,\ \text{scale } 2\right).$$

자유도(degrees of freedom)는 r이다.

표본분산과의 연결

정규표본 $X_1, \ldots, X_n \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$이면

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1).$$

원본 필기의 MGF 계산 과제

$Z \sim N(0,1)$일 때 $Y = Z^2$의 적률생성함수는 $t < 1/2$에서

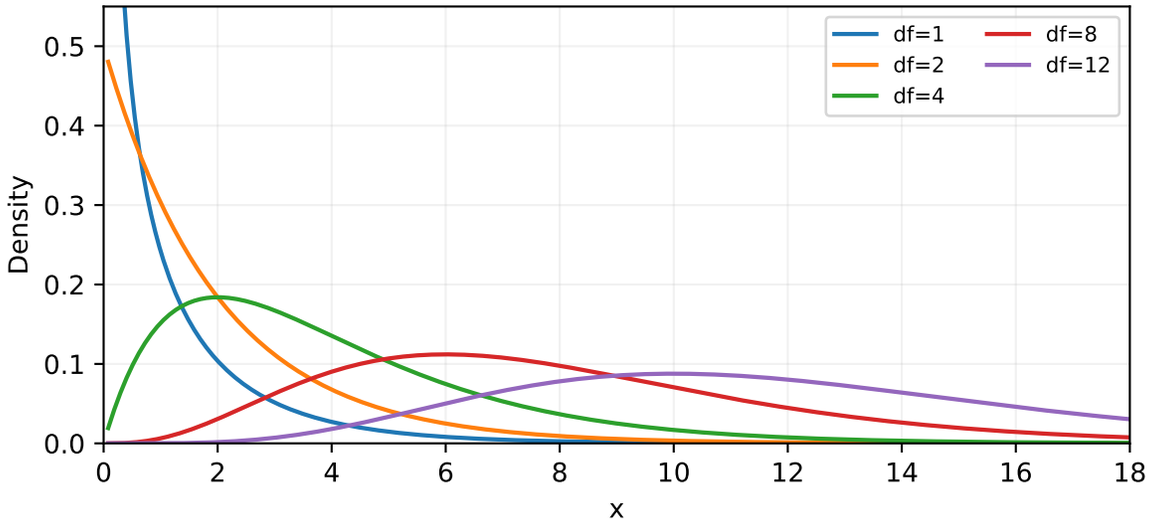
$$M_Y(t) = E(e^{tZ^2}) = \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-(1-2t)z^2/2}\, \mathrm{d}z = (1-2t)^{-1/2}.$$

독립인 r개의 제곱의 합에 대해

$$M_{\sum Z_i^2}(t) = (1-2t)^{-r/2}.$$

4.2 카이제곱분포의 성질 — 정리 4.2.1

원본의 자유도별 카이제곱분포 곡선을 다시 그림.



$X \sim \chi^2(r)$ 이면

$$E(X) = r, \qquad \mathrm{Var}(X) = 2r, \qquad M_X(t) = (1-2t)^{-r/2}\ (t < 1/2).$$

원본 정리 4.2.1 — 합의 성질

$X \sim \chi^2(r_1)$ 과 $Y \sim \chi^2(r_2)$ 가 독립이면 $X + Y \sim \chi^2(r_1 + r_2)$ 이다. **증명(적률생성함수)**

독립성에 의해

$$M_{X+Y}(t) = M_X(t) M_Y(t) = (1-2t)^{-(r_1+r_2)/2}.$$

이는 자유도 $r_1 + r_2$ 인 카이제곱분포의 MGF와 일치한다. 자유도가 커질수록 밀도의 최빈값이 오른쪽으로 이동하며 비대칭성이 줄어든다.

원본 8쪽 손글씨 정서

정규제곱의 MGF와 감마분포의 합

1. 표준정규 제곱의 분포. $Z \sim N(0,1)$에서 $Y = Z^2$로 두면

$$\begin{aligned} M_Y(t) &= \mathsf{E}(e^{tZ^2}) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-(1/2 - t)z^2}\, dz \\ &= (1-2t)^{-1/2}, \quad t < \tfrac{1}{2}. \end{aligned}$$

이는 $\chi^2(1)$의 적률생성함수이다. $Z_1, \dots, Z_r \overset{\text{iid}}{\sim} N(0,1)$이면

$$M_{\sum Z_i^2}(t) = \prod_{i=1}^{r} M_{Z_i^2}(t) = (1-2t)^{-r/2},$$

따라서 $\sum Z_i^2 \sim \chi^2(r)$이다. **2. 감마분포와 MGF.** $X \sim \mathrm{Gamma}(\alpha, \beta)$, β를 척도모수로 정의하면

$$M_X(t) = (1 - \beta t)^{-\alpha}, \quad t < 1/\beta.$$

3. 서로 독립인 감마변수의 합. $X_i \sim \mathrm{Gamma}(\alpha_i, \beta)$이고 척도가 같다면

$$M_{\sum_i X_i}(t) = \prod_i (1-\beta t)^{-\alpha_i} = (1-\beta t)^{-\sum_i \alpha_i}.$$

그러므로 $\sum_i X_i \sim \mathrm{Gamma}(\sum_i \alpha_i, \beta)$.

> **정규표본에서의 활용.** $X_i \sim N(\mu, \sigma^2)$이면 $Z_i = (X_i - \mu)/\sigma \sim N(0,1)$이고 $\sum Z_i^2 \sim \chi^2(n)$이다. 평균을 추정하는 데 자유도 한 개가 사용되면 잔차 제곱합의 자유도는 $n-1$이 된다.

원본 9쪽 [정리 4.2.2] 정규모집단 표본통계량

$X_1, \ldots, X_n \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$라 하고

$$\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i, \qquad S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X})^2.$$

다음이 성립한다.

1. $\overline{X} \sim N(\mu, \sigma^2/n)$.
2. $\overline{X}$와 S^2는 서로 독립이다.
3. $(n-1)S^2/\sigma^2 \sim \chi^2(n-1)$.

[증명 4.2.2] 표본평균의 MGF

정규 확률변수의 적률생성함수는

$$M_X(t) = \exp\left(\mu t + \frac{\sigma^2 t^2}{2}\right).$$

독립성을 이용하면

$$\begin{aligned} M_{\overline{X}}(t) &= \prod_{i=1}^{n} M_{X_i}(t/n) \\ &= \prod_{i=1}^{n} \exp\left(\frac{\mu t}{n} + \frac{\sigma^2 t^2}{2n^2}\right) \\ &= \exp\left(\mu t + \frac{\sigma^2 t^2}{2n}\right). \end{aligned}$$

따라서 $\overline{X} \sim N(\mu, \sigma^2/n)$이다.

다음 증명으로의 연결

$\overline{X}$와 잔차 벡터 $(X_1 - \overline{X}, \ldots, X_n - \overline{X})$가 정규분포의 선형변환이라는 점을 이용하면 평균과 분산의 독립성을 증명할 수 있다.

원본 10쪽 정규표본에서 $\bar{X}$와 S^2의 독립성 증명 (1)

$X_1, \ldots, X_n \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$라 하고 $R_i = X_i - \bar{X}$라 놓는다. $S^2 = (n-1)^{-1}\sum R_i^2$이므로 $\bar{X}$와 잔차벡터 $(R_1, \ldots, R_n)$의 독립성을 증명하면 충분하다. **원본 필기: 결합 적률생성함수(MGF)의 인수분해**

$s, t_1, \ldots, t_n \in \mathbb{R}$, $\bar{t} = n^{-1}\sum_i t_i$라 놓는다. 그러면

$$
\begin{aligned}
s\bar{X} + \sum_{i=1}^{n} t_i (X_i - \bar{X}) &= \sum_{i=1}^{n} \left(\frac{s}{n} + t_i - \bar{t} \right) X_i . \\
M_{\bar{X},\mathbf{R}}(s, \mathbf{t}) &= E \exp\left[s\bar{X} + \sum_i t_i R_i \right] \\
&= \prod_{i=1}^{n} E \exp\left[\left(\frac{s}{n} + t_i - \bar{t} \right) X_i \right] \\
&= \exp\left\{ \mu s + \frac{\sigma^2}{2} \sum_{i=1}^{n} \left(\frac{s}{n} + t_i - \bar{t} \right)^2 \right\} .
\end{aligned}
$$

여기서 $\sum_i (t_i - \bar{t}) = 0$이므로 교차항이 사라지고,

$$
\sum_{i=1}^{n} \left(\frac{s}{n} + t_i - \bar{t} \right)^2 = \frac{s^2}{n} + \sum_{i=1}^{n} (t_i - \bar{t})^2 .
$$

따라서

$$
M_{\bar{X},\mathbf{R}}(s, \mathbf{t}) = \underbrace{\exp\left(\mu s + \frac{\sigma^2 s^2}{2n} \right)}_{M_{\bar{X}}(s)} \underbrace{\exp\left(\frac{\sigma^2}{2} \sum_i (t_i - \bar{t})^2 \right)}_{M_{\mathbf{R}}(\mathbf{t})} .
$$

결합 MGF가 두 주변 MGF의 곱으로 분해된다. 그러므로

$$
\boxed{\bar{X} \perp\!\!\!\perp (R_1, \ldots, R_n) \quad \Longrightarrow \quad \bar{X} \perp\!\!\!\perp S^2 .}
$$

원본의 다변량 MGF 전개와 $\sum_i (t_i - \bar{t}) = 0$을 이용한 교차항 소거 단계를 복원했다. 이 결론은 정규모집단의 성질이며 일반 모집단에 무조건 성립하는 정리는 아니다.

원본 11쪽 손글씨 정서

정규표본에서 S^2의 카이제곱 분포 (2)

분산분해 항등식

$$\sum_{i=1}^{n}(X_i-\mu)^2=\sum_{i=1}^{n}(X_i-\bar X)^2+n(\bar X-\mu)^2.$$

$Z_i=(X_i-\mu)/\sigma$이고 표준정규 벡터를 직교변환하여 $Y_1,\dots,Y_n$을 얻으면

$$Y_1=\frac{\sqrt{n}(\bar X-\mu)}{\sigma},\qquad \sum_{i=2}^{n}Y_i^2=\frac{\sum_{i=1}^{n}(X_i-\bar X)^2}{\sigma^2}.$$

$Y_1,\dots,Y_n$은 서로 독립인 $N(0,1)$이다. 따라서

$$\boxed{\frac{(n-1)S^2}{\sigma^2}=\sum_{i=2}^{n}Y_i^2\sim\chi^2(n-1)}.$$

세 가지 결론 (정리 4.2.2).

$$\begin{aligned}&\bar X\sim N(\mu,\sigma^2/n),\\ &\bar X \text{ 와 } S^2 \text{ 는 서로 독립},\\ &(n-1)S^2/\sigma^2\sim\chi^2(n-1).\end{aligned}$$

검산. $Q\sim\chi^2(n-1)$의 기대값과 분산을 이용하면

$$\mathsf{E}\,S^2=\sigma^2,\qquad \mathsf{Var}(S^2)=\frac{2\sigma^4}{n-1},$$

앞서 일반 모집단의 표본분산 공식에 $\mu_4=3\sigma^4$를 대입한 결과와 일치한다.

4.2 (2) Student의 t 분포

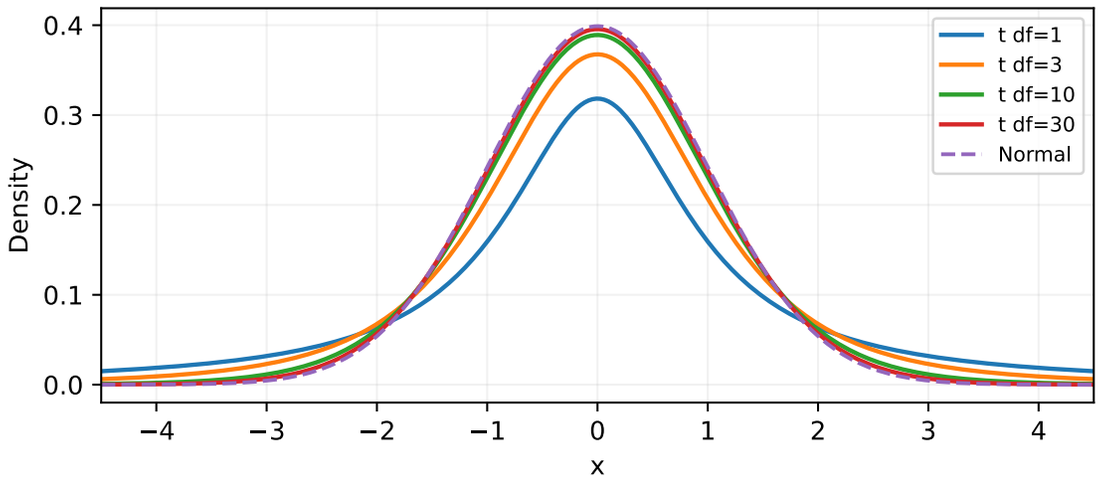
$Z \sim N(0,1), V \sim \chi^2(r)$가 서로 독립이면

$$\boxed{T = \frac{Z}{\sqrt{V/r}} \sim t(r).}$$

밀도는

$$f_T(t) = \frac{\Gamma((r+1)/2)}{\sqrt{r\pi}\,\Gamma(r/2)} \left(1 + \frac{t^2}{r}\right)^{-(r+1)/2}, \quad -\infty < t < \infty.$$

자유도별 t 분포와 표준정규분포의 비교



정규모평균의 t 통계량

$X_i \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$이면 $Z = \sqrt{n}(\overline{X} - \mu)/\sigma \sim N(0,1), V = (n-1)S^2/\sigma^2 \sim \chi^2(n-1)$이고 독립이다.

$$\boxed{\frac{\overline{X} - \mu}{S/\sqrt{n}} \sim t(n-1).}$$

t분포는 0에 대칭이며 자유도가 커지면 정규분포로 수렴한다. 평균은 $r > 1$일 때 0, 분산은 $r > 2$일 때 $r/(r-2)$이다.

원본 13쪽 손글씨 정서

t분포 밀도의 변수변환 유도

서로 독립인 $Z \sim N(0,1)$과 $V \sim \chi^2(\nu)$에 대해

$$T = \frac{Z}{\sqrt{V/\nu}} \sim t(\nu).$$

1단계: 결합확률밀도

$$f_{Z,V}(z,v) = \frac{e^{-z^2/2}}{\sqrt{2\pi}} \cdot \frac{v^{\nu/2-1}e^{-v/2}}{2^{\nu/2}\Gamma(\nu/2)}, \quad v>0.$$

2단계: 변수변환 $t = z/\sqrt{v/\nu},\ u = v$이면 $z = t\sqrt{u/\nu}$이므로

$$\left|\frac{\partial(z,v)}{\partial(t,u)}\right| = \sqrt{\frac{u}{\nu}}.$$

3단계: u를 적분

$$\begin{aligned} f_T(t) &= \int_0^\infty f_{Z,V}\left(t\sqrt{u/\nu}, u\right)\sqrt{u/\nu}\,du \\ &= \frac{1}{\sqrt{\nu\pi}\,2^{(\nu+1)/2}\Gamma(\nu/2)} \int_0^\infty u^{(\nu+1)/2-1} e^{-u(1+t^2/\nu)/2}\,du \\ &= \boxed{\frac{\Gamma((\nu+1)/2)}{\sqrt{\nu\pi}\,\Gamma(\nu/2)}\left(1+\frac{t^2}{\nu}\right)^{-(\nu+1)/2}}. \end{aligned}$$

적분은 감마적분 $\int_0^\infty u^{a-1}e^{-bu}\,du = \Gamma(a)/b^a$를 이용한다. 분자는 $\Gamma((\nu+1)/2)$이며 분모에 $\sqrt{\nu\pi}$가 있다는 점을 확인한다.

원본 14쪽 t분포의 성질과 모평균 구간추정

t분포의 성질

- 자유도가 달라도 원점 0을 중심으로 대칭이다.
- 자유도가 커지면 표준정규분포에 수렴한다.
- $r = 1$이면 코시분포이다. 이때 평균이 존재하지 않는다.

평균 · 분산 [원본 예제]

$X \sim t(r)$이면

$$E(X) = 0 \quad (r > 1), \qquad \mathrm{Var}(X) = \frac{r}{r-2} \quad (r > 2).$$

[정리 4.2.3] 정규모집단의 모평균 구간추정

$X_1, \ldots, X_n \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$, σ^2가 미지일 때

$$T = \frac{\overline{X} - \mu}{S/\sqrt{n}} \sim t(n-1).$$

$t_{1-\alpha/2,n-1}$을 $t(n-1)$분포의 오른쪽 누적확률 $1-\alpha/2$ 분위수라 하면,

$$P\left(-t_{1-\alpha/2,n-1} \le \frac{\overline{X} - \mu}{S/\sqrt{n}} \le t_{1-\alpha/2,n-1}\right) = 1 - \alpha.$$

부등식을 μ에 대해 정리하여 모평균의 $100(1-\alpha)$% 신뢰구간은

$$\boxed{\left[\overline{X} - t_{1-\alpha/2,n-1}\frac{S}{\sqrt{n}},\quad \overline{X} + t_{1-\alpha/2,n-1}\frac{S}{\sqrt{n}}\right].}$$

원본 손글씨의 양쪽 꼬리 표기 $\alpha/2$는 구간의 양 끝에 같은 확률을 배분한다는 뜻이다.

원본 15쪽 손글씨 정서

t분포 평균과 분산의 유도

$T = Z/\sqrt{V/\nu}$이고 $Z \perp V$, $Z \sim N(0,1)$, $V \sim \chi^2(\nu)$이다. **평균.** 분포가 0을 중심으로 대칭이므로 $\nu > 1$에서 $\mathsf{E}\,T = 0$이다. $\nu \le 1$이면 평균이 존재하지 않는다. **분산.** $\nu > 2$이면 독립성으로

$$\begin{aligned}\mathsf{E}(T^2) &= \mathsf{E}(Z^2)\,\mathsf{E}\left(\frac{\nu}{V}\right) = \nu\,\mathsf{E}(V^{-1}) \\ &= \frac{\nu}{2^{\nu/2}\Gamma(\nu/2)}\int_0^\infty v^{\nu/2-2}e^{-v/2}\,dv \\ &= \frac{\nu}{2}\frac{\Gamma(\nu/2-1)}{\Gamma(\nu/2)} = \frac{\nu}{\nu-2}.\end{aligned}$$

따라서

$$\boxed{\mathsf{E}\,T = 0\ (\nu>1), \qquad \mathsf{Var}\,T = \frac{\nu}{\nu-2}\ (\nu>2).}$$

표본분산을 사용한 표준화. 모집단의 σ 대신 표본표준편차 S를 쓰면

$$\frac{\bar X - \mu}{S/\sqrt{n}} = \frac{\sqrt{n}(\bar X-\mu)/\sigma}{\sqrt{[(n-1)S^2/\sigma^2]/(n-1)}} \sim t(n-1).$$

필기 보충. $\nu \to \infty$이면 $V/\nu \xrightarrow{P} 1$이고 $T \xrightarrow{d} N(0,1)$. 작은 자유도일수록 분모의 랜덤성으로 꼬리가 두껍다.

원본 16쪽 모평균의 t 신뢰구간: 피벗·수치예제와 꼬리 그림

$X_1, \dots, X_n \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$이고 μ, σ^2가 모두 미지이다. 표본평균과 표본분산을 $\bar{X}, S^2$로 쓰면

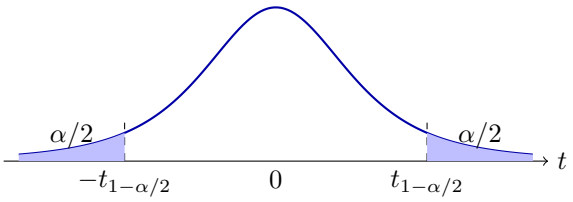
$$Z = \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \sim N(0,1), \qquad V = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2_{n-1}, \quad Z \perp V.$$

따라서 피벗 $T = Z/\sqrt{V/(n-1)} = \sqrt{n}(\bar{X} - \mu)/S \sim t_{n-1}$. **신뢰도 $1-\alpha$의 중앙구간**

$$P\left(-t_{1-\alpha/2,n-1} \le \frac{\sqrt{n}(\bar{X} - \mu)}{S} \le t_{1-\alpha/2,n-1}\right) = 1 - \alpha.$$

$$\boxed{I(\boldsymbol{X}) = \left[\bar{X} - t_{1-\alpha/2,n-1}\frac{S}{\sqrt{n}},\ \bar{X} + t_{1-\alpha/2,n-1}\frac{S}{\sqrt{n}}\right].}$$

원본의 좌우 $\alpha/2$ 꼬리 그림 복원



원본의 95% 신뢰구간 수치 확인

원본 필기: $n = 100$, $\bar{x} = 10$, $s^2 = 4$이므로 $s = 2$, $t_{0.975;99} \simeq 1.984$. 따라서

$$10 \pm 1.984\frac{2}{\sqrt{100}} = 10 \pm 0.3968 \quad \Longrightarrow \quad \boxed{[9.6032,\ 10.3968]}.$$

[검산·보충] 원본에는 $s^2 = 4$가 쓰여 있으므로 표준오차에 대입할 값은 $s = 2$이다. 그래프는 중앙구간과 양쪽 꼬리확률을 나타낸 개념도다.

원본 17쪽 [정리 4.2.4] 정규모집단 모분산의 구간추정

$X_1, \ldots, X_n \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$라 하자. 표본분산은

$$S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X})^2$$

이고 다음이 성립한다.

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1).$$

모분산 σ^2의 신뢰구간 유도

$\chi^2_{p,\nu}$를 자유도 ν인 카이제곱분포의 p 분위수라 할 때

$$P\left(\chi^2_{\alpha/2,n-1} \le \frac{(n-1)S^2}{\sigma^2} \le \chi^2_{1-\alpha/2,n-1}\right) = 1-\alpha.$$

부등식 양변을 역수로 바꾸고 양수인 $(n-1)S^2$를 곱하면

$$\boxed{\left[\frac{(n-1)S^2}{\chi^2_{1-\alpha/2,n-1}},\quad \frac{(n-1)S^2}{\chi^2_{\alpha/2,n-1}}\right].}$$

이는 모분산 σ^2의 $100(1-\alpha)\%$ 신뢰구간이다.

(3) F분포 [예 4.2.4]

독립인 $V_1 \sim \chi^2(r_1)$와 $V_2 \sim \chi^2(r_2)$에 대해

$$F = \frac{V_1/r_1}{V_2/r_2} \sim F(r_1, r_2).$$

두 정규모집단의 모분산을 비교하거나 분산분석에서 사용하는 표본분포이다.

원본 18쪽 손글씨 정서

정규모분산 신뢰구간의 변형과 F분포 준비

$Q = (n-1)S^2/\sigma^2 \sim \chi^2(n-1)$. **1. 카이제곱 분위수 부등식**

$$\mathsf{P}\left(\chi^2_{\alpha/2,n-1} \le \frac{(n-1)S^2}{\sigma^2} \le \chi^2_{1-\alpha/2,n-1}\right) = 1-\alpha.$$

2. 양변의 역수를 취할 때 부등호 순서를 주의

$$\boxed{\frac{(n-1)S^2}{\chi^2_{1-\alpha/2,n-1}} \le \sigma^2 \le \frac{(n-1)S^2}{\chi^2_{\alpha/2,n-1}}}.$$

3. 독립인 두 정규표본의 분산비

$$\frac{(n_1-1)S_1^2}{\sigma_1^2} \sim \chi^2(n_1-1), \qquad \frac{(n_2-1)S_2^2}{\sigma_2^2} \sim \chi^2(n_2-1).$$

두 표본이 서로 독립이면 위 두 카이제곱 변수도 서로 독립이다. 따라서

$$\boxed{\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1-1, n_2-1)}.$$

가설검정 적용. $H_0 : \sigma_1^2 = \sigma_2^2$ 아래에서 S_1^2/S_2^2는 $F(n_1-1, n_2-1)$을 따른다. 평균이 미지인 표본에서 분모 자유도는 각각 표본크기보다 1 작다.

원본 19쪽 F 분포의 역수·분위수 관계

원본 손글씨: 카이제곱분포에서 F 분포로

$V_1 \sim \chi^2(r_1)$, $V_2 \sim \chi^2(r_2)$가 서로 독립이라 하자.

$$X = \frac{V_1/r_1}{V_2/r_2} \sim F(r_1, r_2).$$

역수 취하면

$$\frac{1}{X} = \frac{V_2/r_2}{V_1/r_1} \sim F(r_2, r_1).$$

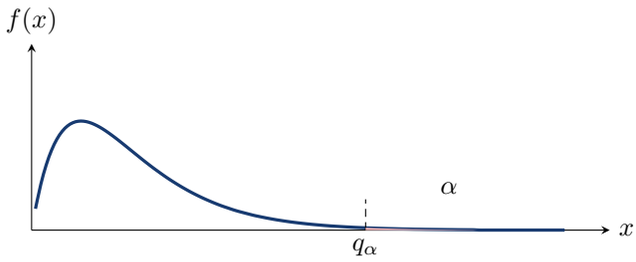
즉 **분자와 분모의 자유도가 서로 교환**된다. **원본 필기의 우측꼬리 그림과 대수적 유도**

$F_{r_1,r_2}(x)$는 누적분포함수, $q_\alpha(r_1, r_2)$는 $P\{X > q_\alpha(r_1, r_2)\} = \alpha$인 상위꼬리 분위수로 정의하자.

$$\begin{aligned} \alpha = P\{X > q_\alpha(r_1, r_2)\} &= P\left\{\frac{1}{X} < \frac{1}{q_\alpha(r_1, r_2)}\right\} \\ &= F_{r_2,r_1}\left(\frac{1}{q_\alpha(r_1, r_2)}\right). \end{aligned}$$

따라서 연속성으로부터

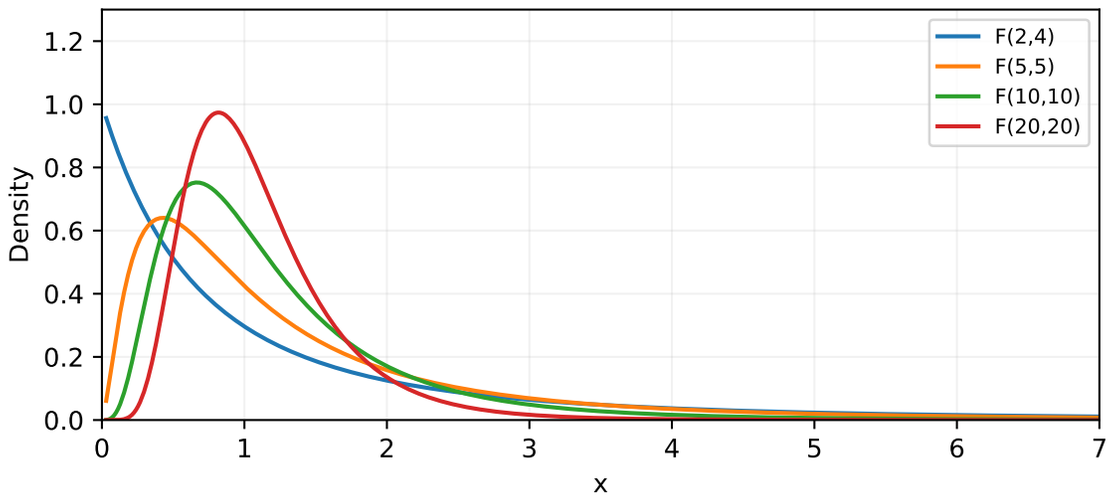
$$\boxed{q_\alpha(r_1, r_2) = \frac{1}{q_{1-\alpha}(r_2, r_1)}.}$$



원본이 사용한 것은 상위꼬리 확률 α의 분위수 표기이다. 아래쪽 누적확률의 분위수와 혼동하지 않도록 표기 정의를 먼저 명시했다.

4.2 F분포의 성질 — 정리 4.2.5

$U \sim \chi^2(r_1), V \sim \chi^2(r_2)$가 독립이면 $F = (U/r_1)/(V/r_2) \sim F(r_1, r_2)$이다. **원본의 자유도별 F분포 곡선**



정리 4.2.5

$$F \sim F(r_1, r_2) \implies \frac{1}{F} \sim F(r_2, r_1).$$

$$E(F) = \frac{r_2}{r_2 - 2} \quad (r_2 > 2), \qquad \mathrm{Var}(F) = \frac{2r_2^2(r_1 + r_2 - 2)}{r_1(r_2 - 2)^2(r_2 - 4)} \quad (r_2 > 4).$$

기댓값의 유도

$$E(F) = \frac{r_2}{r_1} E(U) E(V^{-1}) = \frac{r_2}{r_1} \cdot r_1 \cdot \frac{1}{r_2 - 2} = \frac{r_2}{r_2 - 2}.$$

F 분포는 양의 구간에 지지집합을 가지며 오른쪽으로 긴 꼬리를 갖는다.

정리 4.2.6 — 두 정규모집단에서 모분산의 비교

원문 복원: 두 독립 정규모집단에서 얻은 표본 $X_{ij} \sim N(\mu_i, \sigma_i^2)$ $(j = 1, \dots, n_i, i = 1, 2)$에 대해

$$\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1), \qquad S_i^2 = \frac{1}{n_i - 1}\sum_{j=1}^{n_i}(X_{ij} - \overline{X}_i)^2.$$

각 $V_i = (n_i - 1)S_i^2/\sigma_i^2 \sim \chi^2(n_i - 1)$가 독립이므로 정의에 의해 성립한다. **모분산 비율의 구간추정**

$R = \sigma_1^2/\sigma_2^2$, $F_0 = S_1^2/S_2^2$라고 두면 $F_0/R \sim F(\nu_1, \nu_2)$이다. $F_{q;\nu_1,\nu_2}$는 누적확률 q의 분위수로 정의한다.

$$\Pr\left(\frac{S_1^2/S_2^2}{F_{1-\alpha/2;\nu_1,\nu_2}} \le R \le \frac{S_1^2/S_2^2}{F_{\alpha/2;\nu_1,\nu_2}} \right) = 1 - \alpha.$$

원본 필기: 등분산 검정과 두 평균의 검정

$H_0 : \sigma_1^2 = \sigma_2^2$에서 $S_1^2/S_2^2 \sim F(\nu_1, \nu_2)$. 두 모분산을 같다고 가정할 수 있으면 결합표본분산

$$S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$$

을 이용해 $H_0 : \mu_1 = \mu_2$에 대한 t 통계량을 구성할 수 있다. 등분산 가정이 성립하지 않으면 일반적으로 Welch 검정을 쓴다.

원문 대조·교정 기록 원본의 정리 번호 4.2.6과 F분포 공식, 모분산비의 구간추정 및 필기의 두 표본 검정 연결을 보존.

원본 22쪽 4.3 순서통계량(Order Statistics)

모집단 분포가 연속형일 때, 랜덤표본 $X_1, \dots, X_n$의 관측값을 크기순으로 정렬하여 얻는 확률변수의 분포를 다룬다.

[정의] 순서통계량

랜덤표본을 정렬하면

$$X_{(1)} \le X_{(2)} \le \cdots \le X_{(n)}.$$

연속형 모집단에서는 값이 같을 확률이 0이므로 부등호를 $<$로 쓸 수 있다.

$$X_{(1)} = \min(X_1, \dots, X_n), \qquad X_{(n)} = \max(X_1, \dots, X_n).$$

순서통계량은 표본의 함수이므로 모두 통계량이다.

중요한 유도: 결합밀도

$X_1, \dots, X_n \overset{\text{iid}}{\sim} f(x)$이고 F는 누적분포함수라고 하자. 주어진 순서가 결정되는 영역마다 원래 결합밀도 $\prod_i f(x_i)$를 합하면

$$\boxed{f_{X_{(1)},\dots,X_{(n)}}(x_1, \dots, x_n) = n! \prod_{i=1}^{n} f(x_i), \quad x_1 < \cdots < x_n.}$$

그 밖의 영역에서 밀도는 0이다.

원본 참고 문구: 일대일이 아닌 변수변환

변환이 일대일이 아니면, 역변환이 정의되는 서로 겹치지 않는 영역 $A_1, \dots, A_k$로 표본공간을 나누고 각 영역의 야코비안을 고려한 밀도들을 더해야 한다.

$$f_Y(y) = \sum_{j=1}^{k} f_X\left(h_j(y)\right) \left|\det Dh_j(y)\right|.$$

원본 23쪽 손글씨 정서

순서통계량: 순열 영역의 분할

$X_1, X_2, X_3 \overset{\text{iid}}{\sim} U(0,1)$라 하자. $X_{(1)} < X_{(2)} < X_{(3)}$는 오름차순으로 정렬한 표본이다. 연속형이므로 동률이 생길 확률은 0이다. **원본 손글씨의 영역 분할** 표본공간 $(0,1)^3$은 다음 여섯 개의 영역으로 분할된다.

$$
\begin{aligned}
A_1 &= \{x_1 < x_2 < x_3\}, & A_2 &= \{x_1 < x_3 < x_2\},\\
A_3 &= \{x_2 < x_1 < x_3\}, & A_4 &= \{x_2 < x_3 < x_1\},\\
A_5 &= \{x_3 < x_1 < x_2\}, & A_6 &= \{x_3 < x_2 < x_1\}.
\end{aligned}
$$

각 영역은 정렬한 동일한 (u,v,w), $u<v<w$에 대응한다. **야코비안.** 각 영역의 정렬 변환은 좌표의 순열이므로 야코비안 행렬은 순열행렬이며 절댓값은 1이다.

$$
f_{X_{(1)},X_{(2)},X_{(3)}}(u,v,w) = 3!\, f(u)f(v)f(w), \quad u<v<w.
$$

균등분포이면 $f(x)=1$ $(0<x<1)$이므로

$$
\boxed{f_{X_{(1)},X_{(2)},X_{(3)}}(u,v,w) = 6, \quad 0<u<v<w<1}.
$$

확률 검산. 영역 $0<u<v<w<1$의 부피는 $1/6$이다. 따라서 밀도 6을 적분하면 확률 1이 된다.

정리 4.3.1 — 순서통계량의 결합확률밀도함수

$X_1, \dots, X_n$이 연속밀도 f를 갖는 독립동일분포 표본이고 순서통계량이 $X_{(1)} < \cdots < X_{(n)}$이라 하자.

$$\boxed{f_{X_{(1)},\dots,X_{(n)}}(x_1,\dots,x_n) = \begin{cases} n!\prod_{i=1}^{n} f(x_i), & x_1 < \cdots < x_n, \\ 0, & \text{그 외.} \end{cases}}$$

[원본 증명] 표본공간의 $n!$개 순열영역

연속표본이므로 서로 같은 관측값이 나타날 확률은 0이다. 원래 표본공간은 관측값의 크기순서에 의해 서로 겹치지 않는 $n!$개의 영역으로 나뉜다. 각 영역의 결합밀도는 동일한 $\prod_i f(x_i)$이고 순열의 야코비안은 1이다. 이들을 합하면 $n!$을 곱한 밀도가 된다. **[예제 4.3.1] 세 개의 독립 지수표본**

$X_1, X_2, X_3 \overset{\text{iid}}{\sim} \mathrm{Exp}(1)$일 때 원본에서 열거한 여섯 영역은

A_1	$X_1 < X_2 < X_3$	A_4	$X_2 < X_3 < X_1$
A_2	$X_1 < X_3 < X_2$	A_5	$X_3 < X_1 < X_2$
A_3	$X_2 < X_1 < X_3$	A_6	$X_3 < X_2 < X_1$

이므로 세 순서통계량의 결합밀도는

$$\boxed{g(x_1,x_2,x_3) = 6e^{-(x_1+x_2+x_3)}\mathbf{1}_{\{0<x_1<x_2<x_3\}}}.$$

원문 대조·교정 기록 원본의 여섯 순열영역을 생략하지 않고 복원. 밀도의 계수 $3! = 6$도 확인.

정리 4.3.1의 증명 마무리와 정리 4.3.2

순서통계량의 결합확률밀도

$X_1, \dots, X_n$ 이 연속밀도 f 의 독립 표본이면, 모든 순열에 대한 영역분할이 $n!$개이고 각 정렬변환의 Jacobian 절댓값이 1이므로

$$\boxed{f_{X_{(1)},\dots,X_{(n)}}(x_1,\dots,x_n) = n! \prod_{i=1}^{n} f(x_i) \mathbf{1}_{\{x_1 < \cdots < x_n\}}.}$$

원본의 $n = 3$ 사례에서 $3! f(x_1) f(x_2) f(x_3)$ 가 $x_1 < x_2 < x_3$ 에서의 밀도이다. **정리 4.3.2(a) — r 번째 순서통계량의 주변밀도**

$$\boxed{f_{X_{(r)}}(x) = \frac{n!}{(r-1)!(n-r)!} F(x)^{r-1} [1 - F(x)]^{n-r} f(x).}$$

$X_{(r)} \in [x, x + dx]$ 를 위해 $r - 1$ 개가 x 보다 작고 $n - r$ 개가 x 보다 커야 한다. **정리 4.3.2(b) — $X_{(r)}, X_{(s)}$ 의 결합밀도 ($r < s$)**

$$\begin{aligned} f_{r,s}(u,v) = {} & \frac{n!}{(r-1)!(s-r-1)!(n-s)!} F(u)^{r-1} \\ & \times [F(v) - F(u)]^{s-r-1} [1 - F(v)]^{n-s} f(u) f(v), \qquad u < v. \end{aligned}$$

원문 대조·교정 기록 원본 25쪽은 정리 4.3.1 결합밀도 증명의 마지막 문단에서 정리 4.3.2 주변밀도로 넘어감. 두 부분을 모두 복원.

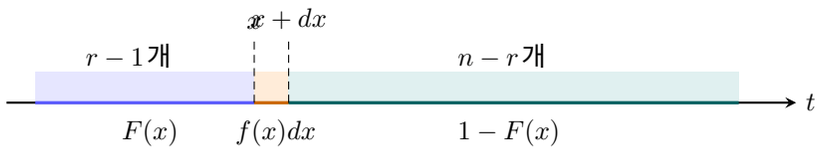
원본 26쪽 r번째 순서통계량의 밀도 — 경우의 수와 그림 해설

서로 독립이고 연속형 분포 f, F를 따르는 $X_1, \dots, X_n$의 순서통계량 $X_{(r)}$를 생각한다. $X_{(r)}$가 $[x, x+dx]$에 놓이려면

1. 관측값 가운데 정확히 $r-1$개가 x보다 작다: 대략 $F(x)^{r-1}$.
2. r번째 관측값 하나가 $[x, x+dx]$에 놓인다: 대략 $f(x)\,dx$.
3. 나머지 $n-r$개는 x보다 크다: 대략 $[1-F(x)]^{n-r}$.

해당 관측값들의 배치 수는 $n!/[(r-1)!(n-r)!]$이므로

$$\boxed{f_{X_{(r)}}(x) = \frac{n!}{(r-1)!(n-r)!}[F(x)]^{r-1}[1-F(x)]^{n-r} f(x).}$$



두 순서통계량의 결합밀도(원본 그래프의 세 영역)

$1 \le r < s \le n$, $u < v$이면

$$\begin{aligned} f_{X_{(r)},X_{(s)}}(u,v) = \frac{n!}{(r-1)!(s-r-1)!(n-s)!} \\ \times [F(u)]^{r-1}[F(v)-F(u)]^{s-r-1} \\ \times [1-F(v)]^{n-s} f(u) f(v). \end{aligned}$$

이는 표본을 $(-\infty, u)$, (u, v), (v, ∞)로 나누고 각 구간의 관측값 개수를 세어서 얻는다.

증명 — 직접적인 방법

원본 항목 순서통계량의 주변분포를 직접 계산하는 방법. **원본에서 이어지는 식**

$$f_{X_{(r)}}(x) = \frac{n!}{(r-1)!(n-r)!}[F(x)]^{r-1}[1-F(x)]^{n-r}f(x).$$

이는 $X_1, \ldots, X_n$이 연속형 분포 F를 갖는 독립표본일 때 성립한다. **풀이 보충 — 누적분포함수로 직접 유도**

$$P\{X_{(r)} \le x\} = \sum_{k=r}^{n} \binom{n}{k} [F(x)]^k [1-F(x)]^{n-k}.$$

양변을 x로 미분하고 이항계수 항을 정리하면 위의 주변밀도 공식을 얻는다.

정서/검산 메모 원본 27쪽에는 '증명 직접적 방법'이라는 제목만 있고, 계산식은 없었습니다. 아래 유도는 보충 내용입니다.

예 4.3.2 — 균등분포의 순서통계량

원문 $X_1, \dots, X_n \overset{\text{iid}}{\sim} U(0,1)$. **(a)** $X_{(r)}$ **의 분포**

밀도 $f(x) = 1$, 누적분포함수 $F(x) = x\ (0 < x < 1)$ 이다. 순서통계량의 밀도 공식을 대입하면

$$f_{X_{(r)}}(x) = \frac{n!}{(r-1)!(n-r)!}\,[F(x)]^{r-1}[1-F(x)]^{n-r} f(x).$$

따라서

$$f_{X_{(r)}}(x) = \frac{n!}{(r-1)!(n-r)!} x^{r-1}(1-x)^{n-r}, \qquad 0 < x < 1.$$

베타함수의 정규화 상수는

$$\frac{1}{B(r, n-r+1)} = \frac{\Gamma(n+1)}{\Gamma(r)\Gamma(n-r+1)}.$$

$\boxed{X_{(r)} \sim \text{Beta}(r, n-r+1).}$ **(b) 표본범위**

$$R = X_{(n)} - X_{(1)}, \qquad X_1, \dots, X_n \text{ 독립동일분포.}$$

정서/검산 메모 원본의 이 페이지에는 (b)의 표본범위 정의까지만 적혀 있습니다. 이어지는 결합밀도 및 분포 유도는 원본 다음 페이지의 내용을 참조합니다.

원본 29쪽 손글씨 정서

균등표본 범위 $R = X_{(n)} - X_{(1)}$의 밀도

$X_1, \dots, X_n \overset{\text{iid}}{\sim} U(0,1)$, $n \geq 2$. **1단계: 최솟값과 최댓값의 결합밀도**

$$f_{X_{(1)}, X_{(n)}}(u, v) = n(n-1)(v-u)^{n-2}, \quad 0 < u < v < 1.$$

2단계: 변수변환

$$U = X_{(1)}, \qquad R = X_{(n)} - X_{(1)}, \qquad V = U + R.$$

야코비안은

$$\left| \frac{\partial(u, v)}{\partial(u, r)} \right| = \begin{vmatrix} 1 & 0 \\ 1 & 1 \end{vmatrix} = 1.$$

변환 후의 지지집합은 $0 < r < 1, 0 < u < 1 - r$이다. **3단계: u의 적분**

$$\begin{aligned} f_R(r) &= \int_0^{1-r} n(n-1) r^{n-2} \, du \\ &= \boxed{n(n-1) r^{n-2}(1-r)}, \qquad 0 < r < 1. \end{aligned}$$

따라서 $R \sim \text{Beta}(n-1, 2)$이며 $\mathrm{E}\, R = (n-1)/(n+1)$이다.

> **원본 필기의 주의점.** $X_{(1)}$과 $X_{(n)}$은 독립이 아니므로 각각의 주변밀도를 곱해서 범위의 밀도를 구하면 안 된다.

예 4.3.3 — 지수분포의 순서통계량

$X_1, \dots, X_n \overset{\text{iid}}{\sim} \text{Exp}(1)$ 이고 $f(x) = e^{-x}\mathbf{1}_{(0,\infty)}(x)$ 라고 하자.

$$f_{X_{(1)},\dots,X_{(n)}}(x_1, \dots, x_n) = n!\,\exp\left(-\sum_{j=1}^{n} x_j\right), \quad 0 < x_1 < \cdots < x_n.$$

원본의 변수변환은 다음과 같다.

$$Z_1 = nX_{(1)}, \qquad Z_j = (n-j+1)(X_{(j)} - X_{(j-1)})\ (j = 2, \dots, n).$$

역변환은

$$X_{(j)} = \sum_{k=1}^{j} \frac{Z_k}{n-k+1} \quad (j = 1, \dots, n).$$

그 지지집합은 $z_1, \dots, z_n > 0$ 이며, 삼각형 야코비안 행렬에 의해

$$\left|\frac{\partial(x_{(1)}, \dots, x_{(n)})}{\partial(z_1, \dots, z_n)}\right| = \prod_{k=1}^{n} \frac{1}{n-k+1} = \frac{1}{n!}.$$

아울러 $\sum_{j=1}^{n} x_{(j)} = \sum_{k=1}^{n} z_k$ 이므로

$$f_{Z_1,\dots,Z_n}(z_1, \dots, z_n) = \prod_{k=1}^{n} e^{-z_k}\mathbf{1}_{(0,\infty)}(z_k).$$

$$\boxed{Z_1, \dots, Z_n \overset{\text{iid}}{\sim} \text{Exp}(1).}$$

정서/검산 메모 원본 30쪽의 변수변환, 지지집합 및 야코비안 계산을 정서하고 최종 결론까지 연결했습니다.

원본 31쪽 손글씨 정서

지수표본 순서통계량의 결합밀도와 간격

$X_1, \dots, X_n \overset{\text{iid}}{\sim} \text{Exp}(1)$이라 하자. $0 < x_1 < \cdots < x_n$에서

$$f_{X_{(1)},\dots,X_{(n)}}(x_1, \dots, x_n) = n! e^{-\sum_i x_i}.$$

간격을 $D_1 = X_{(1)}$, $D_j = X_{(j)} - X_{(j-1)}$ $(j \geq 2)$라 두면

$$X_{(j)} = D_1 + \cdots + D_j, \quad \left| \frac{\partial(x_1, \dots, x_n)}{\partial(d_1, \dots, d_n)} \right| = 1.$$

$$\sum_{j=1}^{n} X_{(j)} = nD_1 + (n-1)D_2 + \cdots + D_n.$$

따라서

$$\begin{aligned} f_{D_1,\dots,D_n}(d_1, \dots, d_n) &= n! e^{-nd_1 - (n-1)d_2 - \cdots - d_n} \\ &= \prod_{j=1}^{n} (n-j+1) e^{-(n-j+1)d_j}, \quad d_j > 0. \end{aligned}$$

곱 형태로 분해되므로 간격들은 **서로 독립**이며 $D_j \sim \text{Exp}(n-j+1)$이다.

> **일반 발생률 λ.** $X_i \sim \text{Exp}(\lambda)$이면 $D_j \sim \text{Exp}((n-j+1)\lambda)$이다. 분포 표기는 발생률(rate)과 척도(scale)를 구별해야 한다.

정리 4.3.3 — 확률적분변환

X가 연속분포함수 F를 갖고 F가 엄격히 증가한다면

$$\boxed{U = F(X) \sim U(0,1).}$$

거꾸로 $U \sim U(0,1)$이면 $F^{-1}(U)$는 분포함수 F를 갖는다. 일반적인 연속 F에는 일반화 역함수를 쓴다. **증명 (원본 필기 정리)**

$0 < u < 1$에 대하여

$$\begin{aligned} P(U \le u) &= P\{F(X) \le u\} \\ &= P\{X \le F^{-1}(u)\} \\ &= F\{F^{-1}(u)\} = u. \end{aligned}$$

따라서 $F_U(u) = u$이며 U는 $U(0,1)$을 따른다. **예: 역변환법**

$U \sim U(0,1)$이면 지수분포 Exp(λ)의 표본은

$$X = -\frac{1}{\lambda}\log(1-U)$$

로 만들 수 있다.

원본 33쪽 확률적분변환: 지수·로지스틱분포 예제

원본 필기 ① 지수분포에서 균등분포로

$Y \sim \mathrm{Exp}(1)$일 때 $f_Y(y) = e^{-y}$ $(y > 0)$이고

$$F_Y(y) = P(Y \le y) = \int_0^y e^{-t}\,dt = 1 - e^{-y}.$$

$U = F_Y(Y) = 1 - e^{-Y}$라 두면 $0 < u < 1$에 대해

$$\begin{aligned} P(U \le u) &= P(1 - e^{-Y} \le u) = P(Y \le -\log(1-u)) \\ &= 1 - e^{\log(1-u)} = u. \end{aligned}$$

따라서 $U \sim U(0,1)$이다. 역으로 $U \sim U(0,1)$이면

$$\boxed{Y = F_Y^{-1}(U) = -\log(1-U) \sim \mathrm{Exp}(1).}$$

원본 필기 ② 균등난수로 여러 지수표본 생성

$U_1, \dots, U_n \overset{\text{iid}}{\sim} U(0,1)$일 때

$$Y_i = -\log(1-U_i), \quad i = 1, \dots, n$$

는 서로 독립인 표준 지수분포 표본이 된다. 일반 발생률 λ의 경우에는 $Y_i = -\lambda^{-1}\log(1-U_i)$. **원본 하단의 로지스틱분포 기록**

원본에는 로지스틱밀도 $f(x) = e^x/(1+e^x)^2$도 적혀 있다. 이 밀도의 분포함수는

$$F_L(x) = \frac{e^x}{1+e^x} = \frac{1}{1+e^{-x}}, \quad x \in \mathbb{R}.$$

따라서 $U \sim U(0,1)$에 대하여

$$\boxed{F_L^{-1}(U) = \log\frac{U}{1-U} \sim \mathrm{Logistic}(0,1).}$$

지수분포의 역함수와 별도로, 원본에 있던 로지스틱밀도를 복원했다. 두 분포의 역변환 공식을 혼동하지 않도록 구별했다.

원본 34쪽 정규분포 역변환과 로지스틱분포의 역함수

원본 필기 ① 누적분포함수와 역함수의 단조성

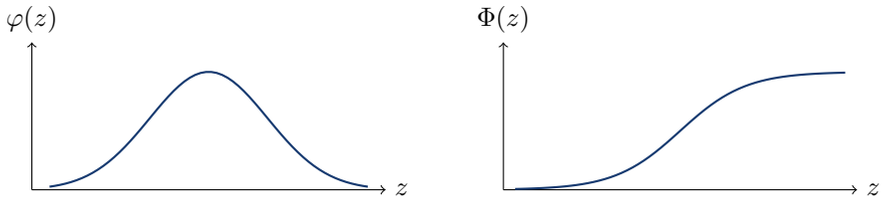
연속이고 엄격히 증가하는 누적분포함수 F에 대해 $x_1 < x_2$이면 $F(x_1) < F(x_2)$이다. 따라서 $0 < u < 1$에 대해 역함수 $F^{-1}(u)$를 정의한다. **원본 필기 ② 정규분포와 균등분포의 관계**

$Z \sim N(0,1)$, Φ는 표준정규분포 CDF일 때

$$U = \Phi(Z) \sim U(0,1), \qquad Z = \Phi^{-1}(U) \sim N(0,1).$$

일반 정규분포는

$$\boxed{X = \mu + \sigma \Phi^{-1}(U) \sim N(\mu, \sigma^2), \quad \sigma > 0.}$$



원본 필기 ③ 로지스틱분포의 역누적분포함수

원본 손글씨에는 다음 로지스틱 CDF와 역함수 계산도 나온다:

$$F_L(y) = \frac{e^y}{1+e^y}, \qquad u = \frac{e^y}{1+e^y} \iff e^y = \frac{u}{1-u}.$$

따라서

$$\boxed{F_L^{-1}(u) = \log \frac{u}{1-u}, \quad 0 < u < 1.}$$

이는 정규분포의 Φ^{-1}과 다른 함수다. $U \sim U(0,1)$일 때 $\log\{U/(1-U)\}$는 로지스틱분포를 따른다.

기존 정서본에 없는 원본의 로지스틱 CDF와 로그오즈(log-odds) 역변환을 복원했다.

연속형 변수의 순서통계량과 극한분포

원본 과제 연속형 변수의 순서발생(지수분포, 정규분포, 로지스틱 분포).

- 순서통계량의 대표적인 분포에서 순서에 따른 밀도를 확인한다.
- **Chapter 5.4 (모의실험을 이용한 근사)**와 연결한다.

관련 공식 — 보충

독립이고 동일한 연속분포 F에 대해

$$F_{X_{(n)}}(x) = [F(x)]^n, \qquad F_{X_{(1)}}(x) = 1 - [1 - F(x)]^n.$$

이 식들은 극댓값 및 극솟값의 정확한 유한 표본분포를 계산할 때 출발점이 된다.

Chapter 5. 표본분포의 근사

5.1 극한분포와 중심극한정리

확률변수열 X_n의 누적분포함수를 F_n이라 하고 Z의 누적분포함수를 F라 하자. F의 모든 연속점에서

$$F_n(z) = P(X_n \le z) \longrightarrow F(z)$$

이면 X_n은 Z로 **분포수렴**한다고 하며 $X_n \xrightarrow{d} Z$로 적는다. **원본 예제 5.2.3 — 균등분포 최대값**

$X_1, \dots, X_n \overset{\text{iid}}{\sim} U(0,1)$, $Y_n = \max_i X_i$이면

$$F_{Y_n}(y) = y^n \quad (0 < y < 1).$$

$V_n = n(1 - Y_n)$으로 놓으면 $v \ge 0$에서

$$P(V_n \le v) = 1 - P(Y_n < 1 - v/n) = 1 - (1 - v/n)^n \to 1 - e^{-v}.$$

따라서

$$\boxed{n(1 - Y_n) \xrightarrow{d} \text{Exp}(1).}$$

원본 37쪽 손글씨 정서

균등분포 표본최댓값의 극한분포

$X_1, \dots, X_n \overset{\text{iid}}{\sim} U(0,1)$이고 $M_n = X_{(n)} = \max(X_1, \dots, X_n)$이라 하자. $0 < x < 1$에서

$$F_{M_n}(x) = \mathsf{P}(M_n \le x) = \prod_{i=1}^{n} \mathsf{P}(X_i \le x) = x^n.$$

비퇴화한 극한을 얻으려면 $V_n = n(1 - M_n)$을 생각한다. $0 < v < n$에서

$$\begin{aligned} \mathsf{P}(V_n \le v) &= \mathsf{P}\left(n(1 - M_n) \le v\right) \\ &= \mathsf{P}\left(M_n \ge 1 - \frac{v}{n}\right) \\ &= 1 - \left(1 - \frac{v}{n}\right)^n. \end{aligned}$$

$v > 0$을 고정하면 $(1 - v/n)^n \to e^{-v}$이므로

$$F_{V_n}(v) \longrightarrow \begin{cases} 0, & v \le 0, \\ 1 - e^{-v}, & v > 0. \end{cases}$$

따라서 $\boxed{V_n \xrightarrow{d} \mathsf{Exp}(1)}$이다.

> **필기의 극한식 확인.** $\lim_{n\to\infty}(1 + a/n)^n = e^a$. $M_n \to 1$은 확률수렴하지만 $n(1 - M_n)$은 지수분포로 분포수렴한다. 두 결론은 서로 모순되지 않는다.

원본 38쪽 적률생성함수의 극한과 중심극한정리

적률생성함수 수렴 정리

$X_1, X_2, \ldots$의 적률생성함수를 $M_1(t), M_2(t), \ldots$라 하자. 원점 주위의 열린구간에서 $M_n(t) \to M(t)$이고, $M(t)$가 어떤 확률분포 F의 적률생성함수라면 $X_n \xrightarrow{d} X$ ($X \sim F$)이다.

[정리 5.1.1] 중심극한정리(CLT)

$X_1, \ldots, X_n$이 서로 독립이고 같은 분포를 따르며

$$E(X_i) = \mu, \qquad \mathrm{Var}(X_i) = \sigma^2 \in (0, \infty)$$

라 하자. 이때

$$Z_n = \frac{\sum_{i=1}^{n} X_i - n\mu}{\sigma\sqrt{n}} = \frac{\sqrt{n}(\overline{X}_n - \mu)}{\sigma} \xrightarrow{d} N(0,1).$$

즉 모든 실수 z에 대하여

$$\lim_{n\to\infty} P(Z_n \le z) = \Phi(z).$$

원본 필기의 표준화

$$Y_i = \frac{X_i - \mu}{\sigma}, \quad E(Y_i) = 0, \quad \mathrm{Var}(Y_i) = 1, \quad Z_n = \frac{1}{\sqrt{n}} \sum_{i=1}^{n} Y_i.$$

적률생성함수가 원점 주변에서 존재하면

$$M_{Y_i}(t) = 1 + \frac{t^2}{2} + o(t^2), \quad M_{Z_n}(t) = \left[M_Y\left(\frac{t}{\sqrt{n}}\right) \right]^n \to e^{t^2/2}.$$

일반적인 CLT는 MGF의 존재를 반드시 요구하지 않는다는 점에 주의한다.

원본 39쪽 손글씨 정서

중심극한정리 증명: MGF의 출발점

$X_1, \dots, X_n$은 평균 μ, 분산 $0 < \sigma^2 < \infty$인 iid 표본이다. 표준화한 확률변수를

$$Y_i = \frac{X_i - \mu}{\sigma}, \qquad \mathsf{E}\, Y_i = 0, \quad \mathsf{Var}\, Y_i = 1$$

이라 두면 $Z_n = (Y_1 + \cdots + Y_n)/\sqrt{n}$이다. **정규분포의 MGF는** $M_{N(0,1)}(t) = e^{t^2/2}$이다. 이를 극한으로 얻는 것이 필기의 목표다. **테일러 전개.** $M_Y(t)$가 원점 근처에서 존재하면

$$M_Y(h) = 1 + h\,\mathsf{E}\, Y + \frac{h^2}{2}\,\mathsf{E}\, Y^2 + o(h^2) = 1 + \frac{h^2}{2} + o(h^2).$$

독립성에 의해

$$M_{Z_n}(t) = \left[M_Y\left(\frac{t}{\sqrt{n}}\right) \right]^n = \left[1 + \frac{t^2}{2n} + o(n^{-1}) \right]^n.$$

> **조건 주의.** MGF를 쓰는 이 전개는 원점 주변에서 MGF가 유한하다는 추가 가정이 필요하다. 일반적인 중심극한정리는 유한한 분산만으로 성립하며, 그 경우에는 특성함수 등으로 증명한다.

원본 40쪽 손글씨 정서

중심극한정리 증명: 표준화와 극한

앞 페이지의 $Y_i = (X_i - \mu)/\sigma$, $Z_n = n^{-1/2}\sum_i Y_i$를 사용한다.

$$Z_n = \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma}, \qquad M_{Z_n}(t) = \left[M_Y(t/\sqrt{n})\right]^n .$$

$M_Y(h) = 1 + h^2/2 + o(h^2)$이면

$$M_{Z_n}(t) = \left[1 + \frac{t^2}{2n} + o(n^{-1})\right]^n ,$$
$$\log M_{Z_n}(t) = n \log\left[1 + \frac{t^2}{2n} + o(n^{-1})\right] \longrightarrow \frac{t^2}{2}.$$

따라서 $M_{Z_n}(t) \to e^{t^2/2}$이고 MGF 유일성과 연속성 정리로

$$\boxed{\frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \xrightarrow{d} N(0,1)}.$$

필기 보충. 정규모집단에서는 $\bar{X} \sim N(\mu, \sigma^2/n)$이므로 모든 n에 대해 정확하다. 비정규 모집단에서는 일반적으로 $n \to \infty$에서의 극한분포만 정규이다.

중심극한정리 — 적률생성함수 증명 마무리

X_i가 독립동일분포이고 $E(X_i)=\mu$, $\mathrm{Var}(X_i)=\sigma^2\in(0,\infty)$라 하자.

$$Z_n=\frac{\sqrt{n}(\bar{X}_n-\mu)}{\sigma}=\frac{1}{\sqrt{n}}\sum_{i=1}^{n}\frac{X_i-\mu}{\sigma}.$$

$Y_i=(X_i-\mu)/\sigma$에 대하여 $M_Y(t)$가 0의 근방에서 존재하면

$$M_Y(t)=1+\frac{t^2}{2}+o(t^2)\qquad(t\to 0).$$

따라서

$$\begin{aligned}M_{Z_n}(t)&=\left[M_Y\left(\frac{t}{\sqrt{n}}\right)\right]^n\\&=\left[1+\frac{t^2}{2n}+o(n^{-1})\right]^n\to e^{t^2/2}.\end{aligned}$$

이는 $N(0,1)$의 적률생성함수이므로

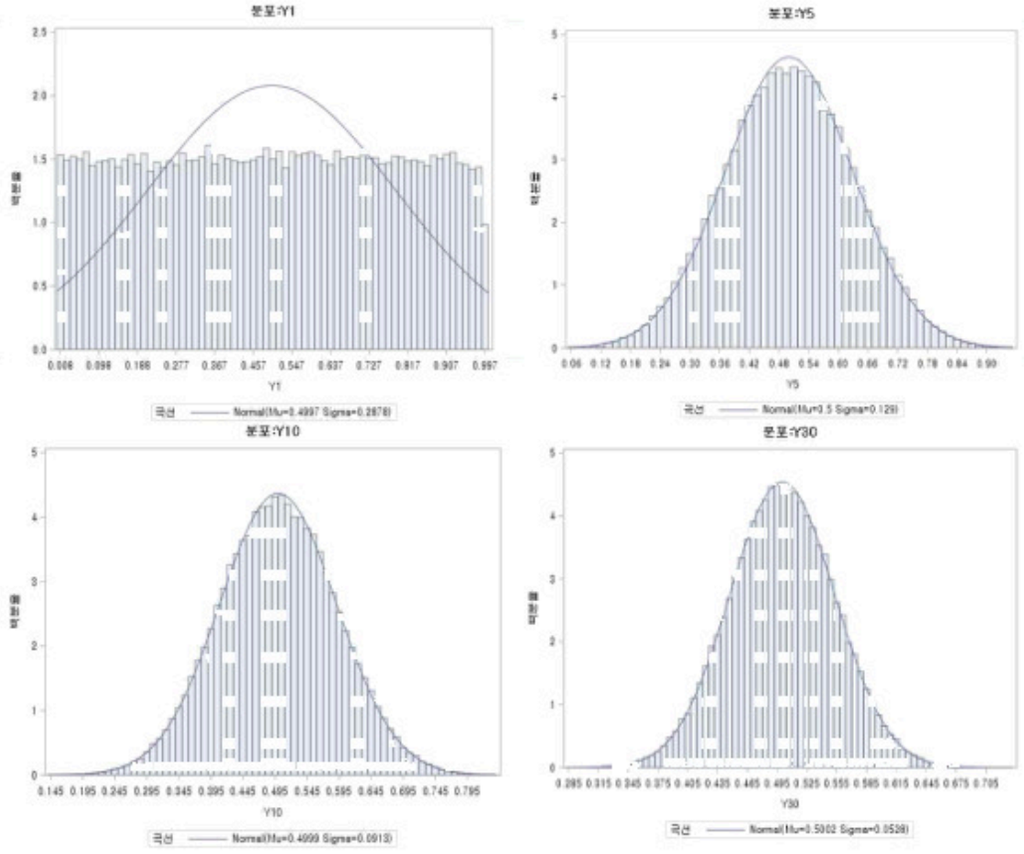
$$\boxed{Z_n\xrightarrow{d}N(0,1).}$$

중심극한정리의 중요한 점 (원본)

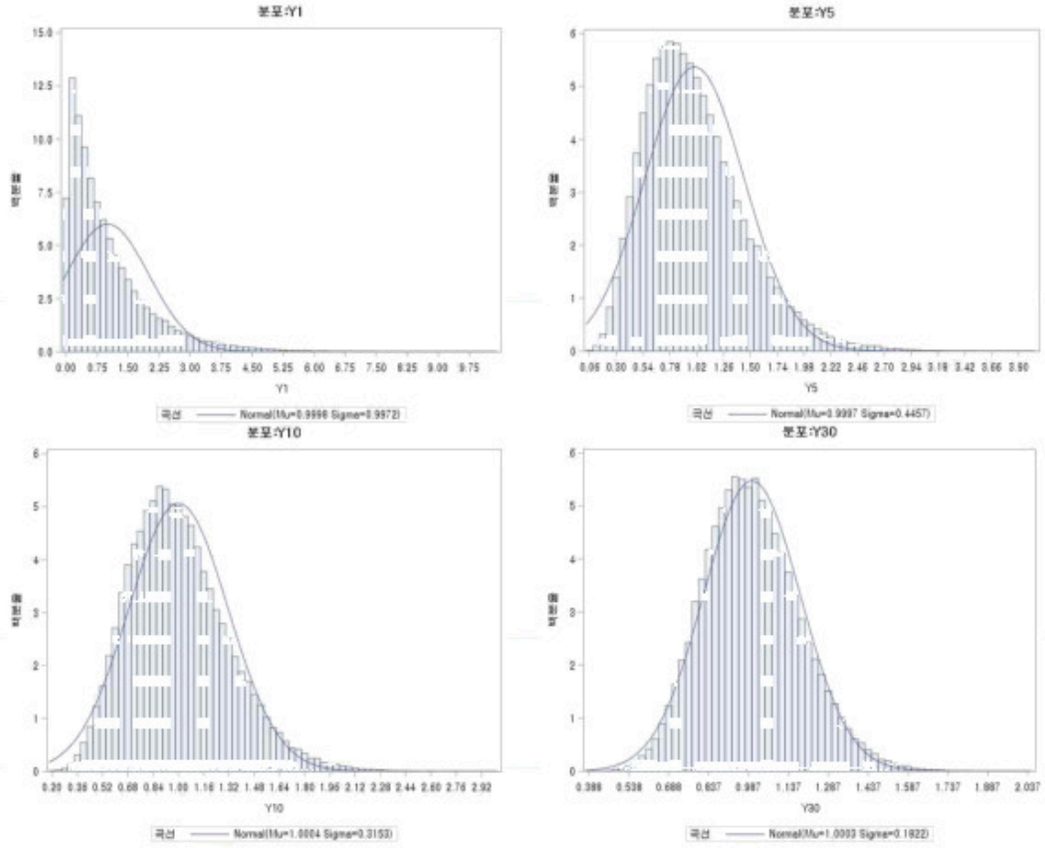
모집단이 정규분포가 아니더라도 유한한 분산을 가진 독립표본의 표본평균은 표본크기가 커지면 근사적으로 정규분포한다. 근사 정도는 모집단의 왜도와 표본크기에 영향을 받는다.

- U(0, 1)에서 100000번 난수 발생후 표본평균에 대한 히스토그램

(표본크기 n=1, 5, 10, 30인 표본의 표본평균의 분포)



- EXP(1)에서 100000번 난수 발생후 표본평균에 대한 히스토그램



중심극한정리의 근사 — 이항모형 예제

모집단의 분포가 균등분포와 같이 대칭이면 비교적 작은 n에서도 정규근사가 좋은 경우가 많다. 지수분포처럼 오른쪽으로 긴 꼬리를 가지면 더 큰 n이 필요할 수 있다. **예제: 이항변수의 정규근사**

$X_1, \ldots, X_n \overset{\text{iid}}{\sim} \text{Bernoulli}(p)$라면 $X = \sum_i X_i \sim \text{Bin}(n, p)$이고

$$E(X) = np, \quad \text{Var}(X) = np(1-p).$$

중심극한정리에 따라

$$\boxed{\frac{X - np}{\sqrt{np(1-p)}} \overset{\text{approx}}{\sim} N(0,1).}$$

정규분포함수 Φ를 쓰면

$$P(a \le X \le b) \approx \Phi\left(\frac{b + 0.5 - np}{\sqrt{np(1-p)}}\right) - \Phi\left(\frac{a - 0.5 - np}{\sqrt{np(1-p)}}\right).$$

원본에서 강조한 점

이산확률변수를 연속정규분포로 근사할 때는 **연속성 보정**(0.5)을 사용할 수 있다.

정서/검수 메모 원본의 정규근사 도식과 $P(a \le X \le b)$ 계산을 조판했습니다. 연속성 보정은 이해를 위한 보충입니다.

원본 44쪽 5.2 확률수렴 — 수렴의 정의와 큰 수의 법칙

[정리 5.2.1] 확률수렴의 정의

확률변수열 $X_1, X_2, \ldots$와 상수 c에 대하여

$$X_n \xrightarrow{p} c \quad \Longleftrightarrow \quad \lim_{n\to\infty} P(|X_n - c| \geq \varepsilon) = 0 \qquad (\forall \varepsilon > 0).$$

즉 표본 크기가 커질수록 X_n이 c에서 ε 이상 벗어날 확률이 0으로 간다.

[정리 5.2.2] 대수의 법칙(Law of Large Numbers)

$X_1, \ldots, X_n$이 서로 독립이고 동일한 분포를 따르며 $E|X_i| < \infty$일 때

$$\boxed{\overline{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i \xrightarrow{p} \mu = E(X_i).}$$

원본 필기: 체비쇼프 부등식을 이용한 증명

분산이 유한한 경우 $\mathrm{Var}(X_i) = \sigma^2$라 하면

$$P(|\overline{X}_n - \mu| \geq \varepsilon) \leq \frac{\mathrm{Var}(\overline{X}_n)}{\varepsilon^2} = \frac{\sigma^2}{n\varepsilon^2} \longrightarrow 0.$$

따라서 $\overline{X}_n \xrightarrow{p} \mu$이다. 이 증명은 유한분산을 가정하는 경우의 약한 대수의 법칙이다.

원본 45쪽 다차원 확률수렴과 대수의 법칙

[정의] 다차원 확률수렴

$X_n = (X_{n1}, \dots, X_{nk})^\top$과 $c = (c_1, \dots, c_k)^\top$에 대해

$$X_n \xrightarrow{p} c \quad \Longleftrightarrow \quad P(\|X_n - c\| \geq \varepsilon) \longrightarrow 0 \qquad (\forall \varepsilon > 0).$$

$\|\cdot\|$는 유클리드 노름이다. k가 고정되어 있을 때 각 좌표의 확률수렴과 동치이다.

[정리 5.2.4] 다차원 대수의 법칙

서로 독립이고 동일한 분포를 따르는 다차원 확률변수

$$X_i = (X_{i1}, \dots, X_{ik})^\top, \qquad E(X_i) = \mu = (\mu_1, \dots, \mu_k)^\top$$

에 대해 각 좌표의 기대값이 존재하면

$$\frac{1}{n}\sum_{i=1}^{n} X_i \xrightarrow{p} E(X_i) = \mu.$$

[예제 5.2.4] 표본 적률 벡터

$E|X|^k < \infty$라면

$$\left(\frac{1}{n}\sum_i X_i, \frac{1}{n}\sum_i X_i^2, \dots, \frac{1}{n}\sum_i X_i^k \right) \xrightarrow{p} \big(E(X), E(X^2), \dots, E(X^k)\big).$$

따라서 적절한 모멘트 함수가 연속이면 표본적률에 대입하여 만든 추정량의 일치성을 확인할 수 있다.

원본 46쪽 [정리 5.2.5, 5.2.6] 연속함수의 확률수렴

[정리 5.2.5] 연속함수의 확률수렴

$X_n \xrightarrow{p} c$이고 함수 g가 c에서 연속이면

$$\boxed{g(X_n) \xrightarrow{p} g(c).}$$

다차원 확률변수열에서도 동일하게 성립한다.

원본 예제: 표본분산의 일치성

$X_i \overset{\text{iid}}{\sim} f, EX_i = \mu, EX_i^2 < \infty$라 하자. $\overline{X}_n \xrightarrow{p} \mu, \overline{X^2}_n = n^{-1}\sum_i X_i^2 \xrightarrow{p} E(X_i^2)$이므로

$$\frac{1}{n}\sum_i (X_i - \overline{X}_n)^2 = \overline{X^2}_n - \overline{X}_n^2 \xrightarrow{p} E(X_i^2) - \mu^2 = \sigma^2.$$

또한 $n/(n-1) \to 1$이므로 $S^2 \xrightarrow{p} \sigma^2$이다.

[정리 5.2.6] 확률수렴의 사칙연산

$X_n \xrightarrow{p} a, Y_n \xrightarrow{p} b$이면

$$X_n \pm Y_n \xrightarrow{p} a \pm b, \qquad X_n Y_n \xrightarrow{p} ab,$$
$$\frac{X_n}{Y_n} \xrightarrow{p} \frac{a}{b} \qquad (b \neq 0).$$

이는 연속함수 정리의 직접적인 결과이다.

원본 47쪽 확률수렴과 평균제곱수렴

[예 5.2.5] 표본분산과 표본표준편차

$X_1, \dots, X_n \overset{\text{iid}}{\sim} f$이고 $EX_i^2 < \infty$라 하면

$$\overline{X}_n \xrightarrow{p} \mu, \quad S_n^2 = \frac{1}{n-1}\sum_i (X_i - \overline{X}_n)^2 \xrightarrow{p} \sigma^2, \quad S_n \xrightarrow{p} \sigma.$$

[정리 5.2.7] 평균제곱수렴으로부터 확률수렴

$\mathsf{Var}(X_n) \to 0$이고 $E(X_n) \to a$이면 $X_n \xrightarrow{p} a$이다.

$$P(|X_n - a| \ge \varepsilon) \le \frac{E[(X_n - a)^2]}{\varepsilon^2} = \frac{\mathsf{Var}(X_n) + [E(X_n) - a]^2}{\varepsilon^2} \longrightarrow 0.$$

[예 5.2.6] 균등분포 표본의 최댓값

$X_i \overset{\text{iid}}{\sim} U(0,1)$이고 $M = X_{(n)}$이면

$$f_M(x) = n x^{n-1} \mathbf{1}_{(0,1)}(x), \quad E(M) = \frac{n}{n+1}, \quad \mathsf{Var}(M) = \frac{n}{(n+1)^2(n+2)}.$$

$E(M) \to 1$이고 $\mathsf{Var}(M) \to 0$이므로 $M \xrightarrow{p} 1$이다.

원본 48쪽 손글씨 정서

표본분산의 일치성

$X_i \overset{\text{iid}}{\sim} f$, $\mathsf{E}\, X_i = \mu$, $\mathrm{Var}\, X_i = \sigma^2 < \infty$이고

$$S_n^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - \bar{X})^2 = \frac{1}{n}\sum_i X_i^2 - (\bar{X})^2.$$

약대수의 법칙으로

$$\frac{1}{n}\sum_i X_i^2 \xrightarrow{P} \mathsf{E}(X^2), \qquad \bar{X} \xrightarrow{P} \mu.$$

연속사상정리에 의해 $(\bar{X})^2 \xrightarrow{P} \mu^2$이고, Slutsky 정리로

$$S_n^2 \xrightarrow{P} \mathsf{E}(X^2) - \mu^2 = \sigma^2.$$

분모가 $n-1$인 불편표본분산은

$$S^2 = \frac{n}{n-1} S_n^2 \xrightarrow{P} \sigma^2$$

이므로 역시 일치추정량이다.

> **원본 손글씨의 비교.** $\mathsf{E}(S^2) = \sigma^2$는 불편성, $S^2 \xrightarrow{P} \sigma^2$는 일치성이다. 두 성질은 정의가 다르며 하나가 다른 하나를 자동으로 의미하지 않는다.

원본 49쪽 5.3 극한분포의 계산 — Slutsky 정리

[정리 5.3.1] Slutsky's Theorem

$X_n \xrightarrow{d} Z$, $Y_n \xrightarrow{p} c$ (c는 상수)이면

$$X_n + Y_n \xrightarrow{d} Z + c, \qquad X_n Y_n \xrightarrow{d} cZ,$$
$$\frac{X_n}{Y_n} \xrightarrow{d} \frac{Z}{c} \quad (c \neq 0).$$

원본 필기: 모분산을 추정한 표본평균의 극한분포

$X_i \overset{\text{iid}}{\sim} f$, $E(X_i) = \mu$, $\mathrm{Var}(X_i) = \sigma^2 \in (0, \infty)$이라 하자.

$$\frac{\sqrt{n}(\overline{X}_n - \mu)}{\sigma} \xrightarrow{d} N(0,1)$$

이고 일치적인 표준편차 추정량 $S_n \xrightarrow{p} \sigma$를 대입하면

$$\boxed{\frac{\sqrt{n}(\overline{X}_n - \mu)}{S_n} \xrightarrow{d} N(0,1).}$$

S_n 대신 σ를 대입해도 극한분포가 변하지 않는다는 것이 Slutsky 정리의 핵심 활용이다.

[예 5.3.1] 스튜던트화 표본평균

큰 표본에서는

$$\left[\overline{X}_n - z_{1-\alpha/2}\frac{S_n}{\sqrt{n}}, \quad \overline{X}_n + z_{1-\alpha/2}\frac{S_n}{\sqrt{n}}\right]$$

이 μ의 근사 $100(1-\alpha)\%$ 신뢰구간이다.

예 5.3.2 — 표본분산의 극한분포

$$S_n^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \bar{X})^2, \qquad \mu = E(X),\ \sigma^2 = \mathsf{Var}(X).$$

항등식 $\sum_i (X_i - \bar{X})^2 = \sum_i (X_i - \mu)^2 - n(\bar{X} - \mu)^2$ 를 이용하면

$$\sqrt{n}(S_n^2 - \sigma^2) = \frac{n}{n-1}\sqrt{n}\left[\frac{1}{n}\sum_{i=1}^{n}(X_i-\mu)^2 - \sigma^2\right] - \frac{n}{n-1}\sqrt{n}(\bar{X}-\mu)^2 + \frac{\sqrt{n}}{n-1}\sigma^2.$$

원본 필기의 극한 판정:

$$\frac{n}{n-1} \to 1, \quad \frac{\sqrt{n}}{n-1}\sigma^2 \to 0, \quad \sqrt{n}(\bar{X}-\mu)^2 = \big[\sqrt{n}(\bar{X}-\mu)\big](\bar{X}-\mu) \xrightarrow{P} 0.$$

$Y_i = (X_i - \mu)^2$ 라고 두면 $E(Y_i) = \sigma^2$ 이고

$$\mathsf{Var}(Y_i) = E[(X_i-\mu)^4] - \sigma^4 = \mu_4 - \sigma^4.$$

따라서 $\mu_4 < \infty$ 일 때 중심극한정리와 Slutsky 정리에 의하여

$$\boxed{\sqrt{n}(S_n^2 - \sigma^2) \xrightarrow{d} N(0, \mu_4 - \sigma^4).}$$

정서/검산 메모 원본의 $\sqrt{n}(\bar{X}-\mu)^2$ 항이 소멸하는 이유를 확률수렴으로 명시했습니다.

원본 51쪽 [정리 5.3.3] 일차 델타방법(Delta Method)

$X_n \in \mathbb{R}^k$, $\theta \in \mathbb{R}^k$, $\sqrt{n}(X_n - \theta) \xrightarrow{d} Z$이고 $g : \mathbb{R}^k \to \mathbb{R}$이 θ에서 미분 가능하며 미분값 $\nabla g(\theta)$가 존재하면

$$\boxed{\sqrt{n}\{g(X_n) - g(\theta)\} \xrightarrow{d} \nabla g(\theta)^\top Z.}$$

특히 $Z \sim N_k(0, \Sigma)$이면 극한분포는

$$N\big(0, \nabla g(\theta)^\top \Sigma \nabla g(\theta)\big).$$

원본 필기: 일변량 근사 유도

Taylor 전개를 적용하면

$$g(X_n) = g(\theta) + g'(\theta)(X_n - \theta) + o_p(|X_n - \theta|),$$

따라서

$$\sqrt{n}\{g(X_n) - g(\theta)\} = g'(\theta)\sqrt{n}(X_n - \theta) + o_p(1).$$

예: 정규모평균의 함수

$X_i \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$에서 $g(x) = x^2$라고 하자.

$$\sqrt{n}(\overline{X}_n^2 - \mu^2) \xrightarrow{d} N(0, 4\mu^2\sigma^2), \qquad \mu \neq 0.$$

$\mu = 0$이면 일차 도함수가 0이므로 이차 델타방법을 적용해야 한다.

원본 52쪽 손글씨 정서

일차 델타방법: 정규표본, 지수표본

$\sqrt{n}(T_n-\theta)\xrightarrow{d}N(0,\tau^2)$이고 $g'(\theta)$가 존재한다면

$$\sqrt{n}\{g(T_n)-g(\theta)\}\xrightarrow{d}N(0,\tau^2[g'(\theta)]^2).$$

1. 정규표본 평균에 적용. $X_i\overset{\text{iid}}{\sim}N(\mu,\sigma^2)$이면 $\sqrt{n}(\bar X-\mu)\sim N(0,\sigma^2)$. $g(x)=x^2$라면

$$\sqrt{n}(\bar X^2-\mu^2)\xrightarrow{d}N(0,4\mu^2\sigma^2),\qquad \mu\neq 0.$$

$\mu=0$에서는 일차 도함수가 0이므로 이차 델타방법이 필요하다. **2. 지수표본 평균에 적용.** $X_i\overset{\text{iid}}{\sim}\mathrm{Exp}(\text{율 }\lambda)$이면 $\mu=1/\lambda$, $\sigma^2=1/\lambda^2$. $g(x)=\log x$에서 $g'(\mu)=1/\mu=\lambda$이므로

$$\boxed{\sqrt{n}(\log\bar X-\log\mu)\xrightarrow{d}N(0,1)}.$$

> **척도 정의 주의.** 원본의 지수분포 표기가 평균(척도) θ이면 $\mu=\theta$로 대체해야 한다. 율 $\lambda=1/\theta$와 혼동하면 분산이 잘못된다.

원본 53쪽 손글씨 정서

$\log \bar{X}$의 극한분포: 지수표본 검산

$X_1, \dots, X_n \overset{\text{iid}}{\sim}$ Exp(평균 θ), $\theta > 0$로 정의하자. 이때

$$\mathrm{E}\, X = \theta, \qquad \mathrm{Var}\, X = \theta^2, \qquad \bar{X} \sim \text{Gamma}(n, \text{척도 } \theta/n).$$

중심극한정리로

$$\sqrt{n}(\bar{X} - \theta) \xrightarrow{d} N(0, \theta^2).$$

$g(x) = \log x$의 도함수는 $g'(\theta) = 1/\theta$이므로

$$\boxed{\sqrt{n}\{\log \bar{X} - \log \theta\} \xrightarrow{d} N(0,1)}.$$

검산. $\theta = 1$이면 $\sqrt{n} \log \bar{X} \xrightarrow{d} N(0,1)$이다. $\theta \neq 1$이면 $\log \theta$를 빼지 않으면 중심이 발산하므로 같은 결론을 쓸 수 없다.

> **필기의 정확분포와 근사분포 구분.** $\bar{X}$ 자체는 감마분포를 정확히 따르지만 $\log \bar{X}$의 정규분포는 $n \to \infty$의 극한이다. 해당 평균 · 분산의 정의를 명시하여 파라미터화 혼동을 방지했다.

예 5.3.5 — 표본표준편차의 극한분포

원문 인쇄 제목: 표본표준편차의 극한분포. $S_n^2 = (n-1)^{-1}\sum_i (X_i - \overline{X})^2$, $S_n = \sqrt{S_n^2}$. $EX = \mu$, $\mathrm{Var}(X) = \sigma^2 > 0$, $\mu_4 = E(X-\mu)^4 < \infty$ 라 하자. 일반적인 중심극한정리 및 Slutsky 정리에서

$$\sqrt{n}(S_n^2 - \sigma^2) \xrightarrow{d} N(0, \mu_4 - \sigma^4).$$

$g(v) = \sqrt{v}$, $g'(\sigma^2) = 1/(2\sigma)$를 델타방법에 적용하면

$$\boxed{\sqrt{n}(S_n - \sigma) \xrightarrow{d} N\left(0, \frac{\mu_4 - \sigma^4}{4\sigma^2}\right).}$$

특히 정규모집단에서는 $\mu_4 = 3\sigma^4$이므로 극한분산은 $\sigma^2/2$이다. **원본 필기 예제 — 지수표본** $T_n = \log \overline{X}$

$X_i \overset{\text{iid}}{\sim}$ Exp(평균 θ)이고 $\theta > 0$라 하면 $EX_i = \theta$, $\mathrm{Var}(X_i) = \theta^2$이다.

$$\sqrt{n}(\overline{X} - \theta) \xrightarrow{d} N(0, \theta^2), \quad (\log x)'_{x=\theta} = \theta^{-1}.$$

따라서

$$\boxed{\sqrt{n}(\log \overline{X} - \log \theta) \xrightarrow{d} N(0, 1).}$$

주의

지수분포를 발생률 λ로 표시하면 $\theta = 1/\lambda$이므로 중심값은 $-\log \lambda$이다.

원본 55쪽 손글씨 정서

베르누이 표본의 델타방법

$X_i \overset{\text{iid}}{\sim}$ Bernoulli(p)이고 $T_n = \bar{X}$라 하자.

$$\sqrt{n}(\bar{X} - p) \xrightarrow{d} N(0, p(1-p)).$$

$g(p) = p(1-p)$라면

$$g'(p) = 1 - 2p, \qquad g''(p) = -2.$$

$p \neq 1/2$에서는 일차 델타방법으로

$$\sqrt{n}\{\bar{X}(1-\bar{X}) - p(1-p)\} \xrightarrow{d} N\big(0, (1-2p)^2 p(1-p)\big)\,.$$

반면 $p = 1/2$에서는 $g'(1/2) = 0$이므로 1차 근사가 퇴화한다.

> **미리 보는 결론.** $g(x) = x(1-x)$는 $1/2$를 중심으로 $g(x) = 1/4 - (x-1/2)^2$이므로
>
> $$n\left[\bar{X}(1-\bar{X}) - \tfrac{1}{4}\right] = -n(\bar{X} - \tfrac{1}{2})^2 \xrightarrow{d} -\tfrac{1}{4}\chi^2(1).$$

원본 56쪽 이차 델타방법(Second-Order Delta Method)

[정리] 이차 델타방법

$\sqrt{n}(Y_n - \theta) \xrightarrow{d} N(0, \sigma^2)$이고 $g'(\theta) = 0$, $g''(\theta) \neq 0$이라 하자. 적절한 정칙조건에서

$$\boxed{n\{g(Y_n) - g(\theta)\} \xrightarrow{d} \frac{g''(\theta)\sigma^2}{2}\chi^2(1).}$$

원본 손글씨의 Taylor 전개

$$g(Y_n) - g(\theta) = g'(\theta)(Y_n - \theta) + \frac{1}{2}g''(\theta)(Y_n - \theta)^2 + o_p((Y_n - \theta)^2).$$

$g'(\theta) = 0$이므로 n을 곱하면

$$n\{g(Y_n) - g(\theta)\} = \frac{1}{2}g''(\theta)\{\sqrt{n}(Y_n - \theta)\}^2 + o_p(1).$$

[예제] 베르누이 표본과 이차 델타방법

$X_i \overset{\text{iid}}{\sim}$ Bernoulli(p)이고 $\overline{X}_n$은 표본비율이라 하자. $g(p) = p(1-p)$이면

$$g'(p) = 1 - 2p, \quad g''(p) = -2, \quad \sqrt{n}(\overline{X}_n - p) \xrightarrow{d} N(0, p(1-p)).$$

$p = 1/2$일 때 $g'(p) = 0$이므로

$$\boxed{n\left\{\overline{X}_n(1-\overline{X}_n) - \frac{1}{4}\right\} \xrightarrow{d} -\frac{1}{4}\chi^2(1).}$$

원본에는 $p = 1/2$인 경우 일차 델타방법을 사용할 수 없다는 점이 강조되어 있다.

원본 57쪽 손글씨 정서

이차 델타방법의 유도

$\sqrt{n}(T_n-\theta)\xrightarrow{d} Z$이고 $g'(\theta)=0$, $g''(\theta)\neq 0$라 하자. 이차 테일러 전개로

$$g(T_n)=g(\theta)+\frac{g''(\theta)}{2}(T_n-\theta)^2+o_P((T_n-\theta)^2).$$

따라서

$$\begin{aligned} n\{g(T_n)-g(\theta)\} &= \frac{g''(\theta)}{2}\left[\sqrt{n}(T_n-\theta)\right]^2+o_P(1)\\ &\xrightarrow{d} \frac{g''(\theta)}{2}Z^2. \end{aligned}$$

만약 $Z\sim N(0,\tau^2)$이면 $Z^2\sim \tau^2\chi^2(1)$이므로

$$\boxed{n\{g(T_n)-g(\theta)\}\xrightarrow{d}\frac{g''(\theta)\tau^2}{2}\chi^2(1)}.$$

베르누이 예제. $\theta=p=1/2$, $\tau^2=p(1-p)=1/4$, $g(p)=p(1-p)$, $g''(p)=-2$이므로 극한분포는 $-\chi^2(1)/4$이다.

> **속도 차이.** $g'(\theta)\neq 0$에서는 $\sqrt{n}$ 배율, $g'(\theta)=0$에서는 일반적으로 n 배율이 필요하다.

5.4 모의실험을 이용한 근사

정리 5.4.1 — 난수를 이용한 적분 근사

$U_1, \ldots, U_n \overset{\text{iid}}{\sim} U(0,1)$, g가 $[a,b]$에서 적분가능하다고 하자. $X_i = a + (b-a)U_i$로 정의하면

$$\frac{b-a}{n}\sum_{i=1}^{n} g(X_i) \xrightarrow{P} \int_a^b g(x)\,dx.$$

풀이 보충

$E[g(X_i)] = (b-a)^{-1}\int_a^b g(x)\,dx$이므로, $E|g(X_i)| < \infty$에서 큰수의 법칙을 이용한다. **원본의 예제 지시**

예 5.4.3 로지스틱 분포의 분산 — 원본에 취소 표시 및 '교재 2개' 메모가 있음.

예 5.4.5 표본비율의 극한분포를 이용한 원주율 π의 계산 — 원본에 취소 표시가 있음.

원본 59쪽 손글씨 정서

몬테카를로 방법: 적분을 표본평균으로

$U_1, \dots, U_n \overset{\text{iid}}{\sim} U(0,1)$이고 g가 적분가능하다면

$$\mathsf{E}[g(U)] = \int_0^1 g(u)\,du.$$

대수의 법칙에 의해

$$\boxed{\frac{1}{n}\sum_{i=1}^{n} g(U_i) \xrightarrow{P} \int_0^1 g(u)\,du}.$$

구간 변환. $X_i = a + (b-a)U_i \sim U(a,b)$이면

$$\int_a^b g(x)\,dx \approx \frac{b-a}{n}\sum_{i=1}^{n} g(X_i).$$

필기의 제곱 적분 예. $g(u) = u^2$인 경우 $\int_0^1 u^2\,du = 1/3$이므로

$$\widehat{I}_n = \frac{1}{n}\sum_{i=1}^{n} U_i^2 \xrightarrow{P} \frac{1}{3}.$$

$\mathsf{E}(U^4) = 1/5$이므로 $\mathsf{Var}(U^2) = 1/5 - (1/3)^2 = 4/45$이며

$$\mathsf{Var}(\widehat{I}_n) = \frac{4}{45n}.$$

> **중심극한정리.** $g(U)$의 분산이 유한하면 몬테카를로 오차의 크기는 통상 $1/\sqrt{n}$이며 $\sqrt{n}(\widehat{I}_n - I) \xrightarrow{d} N(0, \mathsf{Var}(g(U)))$이다.

Chapter 6. 추정(Estimation)

추정이론(estimation theory)은 검정이론(testing theory)과 함께 통계적 추론(statistical inference)의 핵심이다. 관찰하는 확률변수의 분포를 $f(x;\theta)$, $\theta \in \Omega$라 하자. 미지 모수 θ는 벡터일 수 있으며 Ω는 모수공간이다. **원본의 점추정과 구간추정**

$X_1, \ldots, X_n$이 표본이라면 관심 대상은 미지 모수 θ 또는 모수함수 $g(\theta)$다.

- **점추정(Point Estimation):** 통계량 $T(X_1, \ldots, X_n)$을 이용하여 하나의 값으로 모수를 추정한다.
- **구간추정(Interval Estimation):** 통계량 두 개로 정의한 구간 $[T_1(\mathbf{X}), T_2(\mathbf{X})]$이 모수를 포함할 확률을 제어하여 추정한다.

필기된 모평균 구간추정의 예

정규모집단에서 분산이 알려져 있으면 $\overline{X} \pm z_{1-\alpha/2}\sigma/\sqrt{n}$을 쓰고, 분산이 미지이면 $\overline{X} \pm t_{n-1,1-\alpha/2}S/\sqrt{n}$을 쓴다. **원본의 핵심 설명**

구간추정은 하나의 점이 아니라 오차한계와 불확실성을 나타내므로 더 많은 정보를 주지만, 많은 구간추정은 좋은 점추정량에 오차한계를 더하는 형태로 나타난다. 따라서 좋은 점추정량을 찾는 것이 중요하다.

원문 대조·교정 기록 모수모형, 모수공간, 점추정/구간추정의 정의와 해당 필기, 원본 말미의 점추정 중요성 설명을 포함.

원본 61 쪽 대표적인점추정방법·추정량의평가

원본의점추정방법네가지

- 적률이용추정법 (Methods of Moments)
- 최대가능도추정법 (Maximum Likelihood, ML)
- Bayes 추정법
- 최소제곱추정법 (Least Squares, LS)

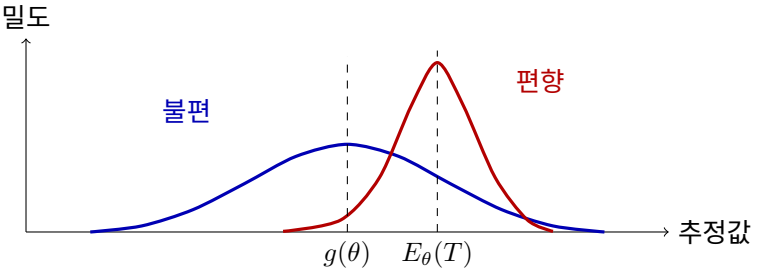
점추정량의평가

- 평균제곱오차: $\mathrm{MSE}_\theta(T) = E_\theta[(T-g(\theta))^2] = \mathrm{Var}_\theta(T) + \mathrm{Bias}_\theta(T)^2$.
- 최소분산불편추정량 (UMVUE): 불편추정량가운데모든모수에서분산이최소인추정량.
- Rao–Cramér 정보부등식 (Cramér–Rao lower bound): 정칙조건에서불편추정량의분산하한.
- 충분통계량·완비통계량을이용하는방법.

[정의] 점추정량과점추정치

모수 θ 의함수 $g(\theta)$ 를추정하기위해사용하는표본의함수 $T(\boldsymbol{X})$ 를 **점추정량 (point estimator)** 이라한다. 관측값 $\boldsymbol{x}$ 를대입하여얻는 $T(\boldsymbol{x})$ 를 **점추정치 (point estimate)** 라고한다.

원본필기그림: 불편·편향추정량의비교



검산·보충: 원본손그림은추정량의분포중심이참값과다른경우편향이있다는점을보여준다. 그림의수치·곡선은설명용이다.

6.1 적률을 이용한 추정법(Methods of Moments)

모집단 평균 $\mu = E(X)$를 표본평균 $\overline{X}$로 추정하는 사고를 일반적인 적률로 확장한다. **모적률과 표본적률**

r차 원점적률과 대응하는 표본적률은

$$\boxed{\mu_r' = E(X^r), \qquad m_r = \frac{1}{n}\sum_{i=1}^{n} X_i^r, \quad r = 1, 2, \dots}.$$

모수 $\theta = g(\mu_1', \dots, \mu_k')$를 적률의 함수로 표현할 수 있으면 이에 표본적률을 대입해 $\widehat{\theta}_{\text{MM}} = g(m_1, \dots, m_k)$를 구한다. 여러 모수의 경우에는 $m_r = E_{\hat{\theta}}(X^r)$의 연립방정식을 풀어 추정한다. **[예제 6.1.1] 모평균과 모분산의 적률추정량**

$$\mu = E(X) = \mu_1', \qquad \sigma^2 = E(X^2) - \{E(X)\}^2 = \mu_2' - (\mu_1')^2.$$

표본적률을 대입하면

$$\boxed{\widehat{\mu}_{\text{MM}} = m_1 = \overline{X}, \qquad \widehat{\sigma^2}_{\text{MM}} = m_2 - m_1^2 = \frac{1}{n}\sum_{i=1}^{n}(X_i - \overline{X})^2}.$$

이는 분모가 n인 모분산의 적률추정량으로, 분모가 $n-1$인 불편표본분산 S^2와 구별해야 한다.

원문 대조·교정 기록 원본의 모적률·표본적률 정의, 일반 대응 함수 및 원본 예제 6.1.1의 적률추정량 둘 다 복원.

6.1 적률추정량의 예제

Gamma(α,β) 모형 (형상 α, 척도 β)

$E(X)=\alpha\beta$, $\mathrm{Var}(X)=\alpha\beta^2$ 이므로

$$m_1=\bar X=\alpha\beta,\quad m_2-m_1^2=\alpha\beta^2.$$

따라서 $v_m=n^{-1}\sum_i(X_i-\bar X)^2$ 라 놓으면

$$\boxed{\hat\alpha_{\mathrm{MM}}=\frac{\bar X^2}{v_m},\qquad \hat\beta_{\mathrm{MM}}=\frac{v_m}{\bar X}.}$$

예제 6.1.2 — $N(\mu,\sigma^2)$의 적률추정

$$\hat\mu=\bar X,\qquad \hat\sigma^2=\overline{X^2}-(\bar X)^2.$$

예제 6.1.3 — 상관계수의 적률추정

$\rho=\{E(XY)-E(X)E(Y)\}/(\sigma_X\sigma_Y)$에 표본적률을 대입하면

$$\boxed{\hat\rho=\frac{\sum_i(X_i-\bar X)(Y_i-\bar Y)}{\sqrt{\sum_i(X_i-\bar X)^2}\sqrt{\sum_i(Y_i-\bar Y)^2}}.}$$

원본 64쪽 손글씨 정서

모상관계수의 적률추정량

두 확률변수 X, Y의 상관계수는

$$\rho = \frac{\mathrm{Cov}(X,Y)}{\sqrt{\mathrm{Var}(X)\,\mathrm{Var}(Y)}} = \frac{\mathsf{E}(XY) - \mathsf{E}(X)\,\mathsf{E}(Y)}{\sqrt{[\mathsf{E}(X^2) - (\mathsf{E}\,X)^2][\mathsf{E}(Y^2) - (\mathsf{E}\,Y)^2]}}.$$

모집단 적률을 각각 표본적률로 대체하면

$$\begin{aligned}\widehat{\rho} &= \frac{n^{-1}\sum_i X_i Y_i - \bar{X}\bar{Y}}{\sqrt{\left[n^{-1}\sum_i X_i^2 - \bar{X}^2\right]\left[n^{-1}\sum_i Y_i^2 - \bar{Y}^2\right]}} \\ &= \boxed{\frac{\sum_i (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_i (X_i - \bar{X})^2 \sum_i (Y_i - \bar{Y})^2}}}.\end{aligned}$$

용어. 이것은 표본상관계수(피어슨 상관계수)이며, 두 변수가 서로 독립임을 일반적으로 의미하지는 않는다. $\rho = 0$은 무상관성을 뜻한다.

> **필기 보충.** 분자와 분모에 모두 $1/n$이 들어가므로 약분된다. $1/(n-1)$로 표본공분산과 분산을 정의해도 상관계수의 최종식은 동일하다.

정리 6.1.1 — 적률이용추정량의 확률수렴

$X_1, \dots, X_n$이 독립동일분포이고 필요한 적률이 존재하며 $\theta = g(\mu'_1, \dots, \mu'_k)$를 연속함수 g로 나타낼 수 있다고 하자. 그러면

$$\hat{\theta}_{\text{MM}} = g(m_1, \dots, m_k) \xrightarrow{P} g(\mu'_1, \dots, \mu'_k) = \theta.$$

증명 — 큰수의 법칙과 연속함수 정리

큰수의 법칙에서

$$m_r = \frac{1}{n}\sum_{i} X_i^r \xrightarrow{P} E(X^r) = \mu'_r \quad (r = 1, \dots, k).$$

따라서 연속사상정리에 의하여 $\hat{\theta}_{\text{MM}} \xrightarrow{P} \theta$. **추정량의 일치성 (Consistency)**

모든 $\varepsilon > 0$에 대하여

$$\lim_{n \to \infty} P_\theta\big(|\hat{\theta}_n - \theta| \geq \varepsilon\big) = 0$$

이면 $\hat{\theta}_n$은 θ의 일치추정량이다. **예제 6.1.4 — 모분산 적률추정량**

$$\hat{\sigma}^2_m = \frac{1}{n}\sum_{i}(X_i - \bar{X})^2 = \frac{1}{n}\sum_{i} X_i^2 - \bar{X}^2 \xrightarrow{P} E(X^2) - \mu^2 = \sigma^2.$$

원본 66쪽 손글씨 정서

모분산 적률추정량의 일치성

모분산의 적률추정량은

$$\widehat{\sigma^2}_{\mathrm{MM}} = \frac{1}{n}\sum_{i=1}^{n}(X_i - \bar{X})^2 = \frac{1}{n}\sum_i X_i^2 - \bar{X}^2.$$

$\mathsf{E}(X^2) < \infty$일 때 대수의 법칙으로

$$\frac{1}{n}\sum_i X_i^2 \xrightarrow{P} \mathsf{E}(X^2), \qquad \bar{X} \xrightarrow{P} \mu.$$

따라서

$$\widehat{\sigma^2}_{\mathrm{MM}} \xrightarrow{P} \mathsf{E}(X^2) - \mu^2 = \sigma^2.$$

그런데 왜 편향이 있는가?

$$\mathsf{E}\,\widehat{\sigma^2}_{\mathrm{MM}} = \frac{n-1}{n}\sigma^2, \qquad \mathrm{Bias} = -\frac{\sigma^2}{n}.$$

편향은 $n \to \infty$에서 사라진다. 즉 유한표본에서 편향이 있어도 일치적일 수 있다.

> **모멘트 조건.** 이 일치성 논증에는 $\mathsf{E}(X^2) < \infty$가 필요하다. 표본분산의 정확한 분산식을 계산하려면 4차 모멘트가 추가로 필요하다.

원본 67쪽 손글씨 정서

편향추정량과 불편추정량의 비교

$X_i \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$에서 모분산 추정량 두 개를 비교하자.

$$\widehat{\sigma^2}_{\text{MM}} = \frac{1}{n}\sum_i (X_i - \bar{X})^2, \qquad S^2 = \frac{1}{n-1}\sum_i (X_i - \bar{X})^2.$$

기대값을 계산하면

$$\mathsf{E}\,\widehat{\sigma^2}_{\text{MM}} = \frac{n-1}{n}\sigma^2, \qquad \mathsf{E}(S^2) = \sigma^2.$$

따라서 첫 추정량은 아래로 편향되고 두 번째는 불편이다. **MSE 비교.** 정규표본에서 $\mathrm{Var}(S^2) = 2\sigma^4/(n-1)$이므로

$$\begin{aligned}
\mathrm{MSE}(S^2) &= \frac{2\sigma^4}{n-1}, \\
\mathrm{MSE}(\widehat{\sigma^2}_{\text{MM}}) &= \left(\frac{n-1}{n}\right)^2 \frac{2\sigma^4}{n-1} + \left(\frac{\sigma^2}{n}\right)^2 = \frac{(2n-1)\sigma^4}{n^2}.
\end{aligned}$$

원본 손글씨의 그래프 의미. 추정량의 기대값이 참모수와 일치하면 불편이지만, 불편성이 반드시 MSE 최소를 의미하지 않는다. MSE는 분산과 편향 제곱의 합이다.

6.2 최대가능도 추정법 (Maximum Likelihood Estimation)

정의 — 결합확률밀도함수와 가능도함수

$X_1, \ldots, X_n$이 서로 독립이고 모수 $\theta \in \Omega$를 갖는 밀도(또는 질량함수) $f(x;\theta)$를 따른다면, 결합분포는

$$f(x_1, \ldots, x_n; \theta) = \prod_{i=1}^{n} f(x_i; \theta).$$

관측값 **x** $= (x_1, \ldots, x_n)$이 주어지면 이를 θ**의 함수**로 생각한다.

$$\boxed{L(\theta; \mathbf{x}) = \prod_{i=1}^{n} f(x_i; \theta), \qquad \theta \in \Omega.}$$

- 표본 $x_1, \ldots, x_n$이 고정된 상태에서 가능도 L을 변화시키는 것은 모수 θ이다.
- 결합밀도와 가능도는 수식의 값은 같지만, **함수로 보는 대상**이 다르다.
- 가능도는 일반적으로 모수 θ에 대한 확률밀도함수가 아니다.

최대가능도 추정의 출발점

$$\hat{\theta}_{\mathrm{ML}} \in \operatorname*{argmax}_{\theta \in \Omega} L(\theta; \mathbf{x}).$$

정서/검산 메모 원본의 결합밀도/가능도의 정의와 해석을 조판했습니다. 마지막 argmax 표기는 요약 보충입니다.

원본 69쪽 손글씨 정서

최대가능도추정법: 정의와 베르누이 예제

$X_1, \dots, X_n$이 서로 독립이고 밀도 또는 질량함수가 $f(x;\theta)$이면 결합함수는

$$f(x_1, \dots, x_n; \theta) = \prod_{i=1}^{n} f(x_i; \theta).$$

관측값 $x_1, \dots, x_n$을 고정하고 이를 θ의 함수로 보면 **가능도함수** $L(\theta; x) = \prod_{i=1}^{n} f(x_i;\theta)$를 얻는다. **베르누이 예제.** $X_i \overset{\text{iid}}{\sim} \text{Bernoulli}(p)$, $0 \le p \le 1$라 하자. $s = \sum_i x_i$이면

$$L(p) = p^{s}(1-p)^{n-s}, \qquad \ell(p) = s\log p + (n-s)\log(1-p).$$

내부 $0 < p < 1$에서

$$\ell'(p) = \frac{s}{p} - \frac{n-s}{1-p} = 0 \quad \Longrightarrow \quad \widehat{p} = \frac{s}{n} = \bar{x}.$$

또 $\ell''(p) = -s/p^2 - (n-s)/(1-p)^2 \le 0$이므로 최대점이다.

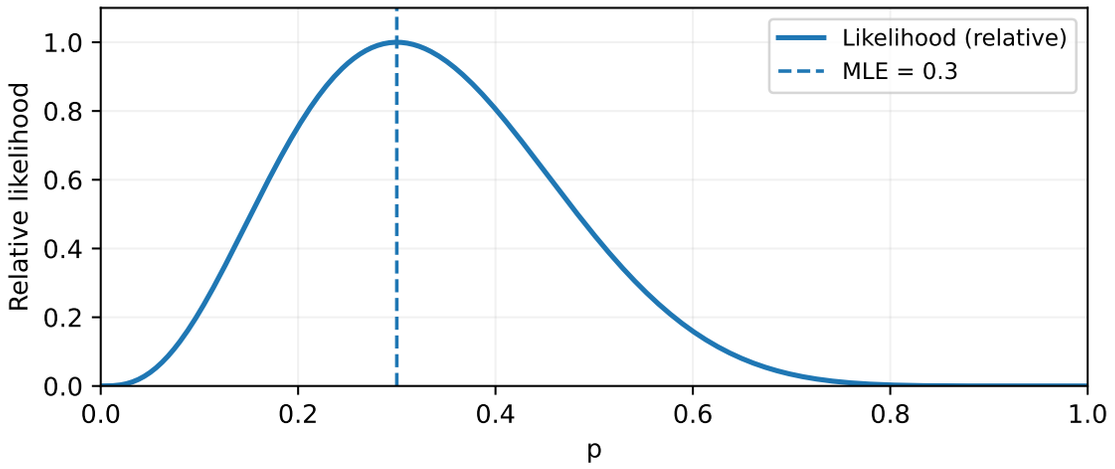
> **경계해 확인.** $s = 0$이면 $\widehat{p} = 0$, $s = n$이면 $\widehat{p} = 1$이다. 이 경우 미분방정식만으로는 경계의 MLE를 찾을 수 없으므로 모수공간 $[0,1]$에서 직접 가능도를 비교한다.

Bernoulli 표본의 가능도곡선과 MLE

원본 조건: $X_1, \dots, X_{10} \overset{\text{iid}}{\sim} \text{Bernoulli}(p)$, $\sum_i x_i = 3$.

$$L(p; \mathbf{x}) = p^3 (1-p)^7 \quad (0 \le p \le 1).$$

원본의 Bernoulli 가능도그래프를 다시 그림



로그가능도와 일차 도함수는

$$\ell(p) = 3 \log p + 7 \log(1-p), \qquad \ell'(p) = \frac{3}{p} - \frac{7}{1-p}.$$

$\ell'(p) = 0$에서 $\widehat{p} = 3/10 = 0.3$이다. 또한 $\ell''(p) = -3/p^2 - 7/(1-p)^2 < 0$이므로 전역 최대점이다.

$$\boxed{\widehat{p}_{\text{ML}} = \frac{1}{n} \sum_{i=1}^{n} X_i = 0.3.}$$

정의 — 최대가능도추정량

$$\widehat{\theta}_{\text{ML}}(\mathbf{x}) = \operatorname*{argmax}_{\theta \in \Theta} L(\theta; \mathbf{x}).$$

원문 대조·교정 기록 원본의 $n = 10$, 성공횟수 3, 최대점 $p = 0.3$과 가능도곡선을 함께 복원.

ML 추정량을 유도하는 방법

(1) 로그가능도함수의 미분이 가능한 경우

로그가능도함수 $\ell(\theta;\mathbf{x}) = \log L(\theta;\mathbf{x})$에 대해 1차 미분을 0으로 놓고 해를 찾는다.

$$\frac{\partial}{\partial\theta}\ell(\theta;\mathbf{x}) = 0.$$

이 방정식의 해가 로그가능도함수를 **최대화하는지는 따로 확인해야 한다**. 원본에는 '최대와 미분을 구분'하라는 취지의 설명이 있다. **(2) 로그가능도함수의 미분이 불가능한 경우**

절댓값·경계가 포함된 모형 등에서는 도함수가 없는 점을 포함하여, 모수 θ에 따른 L의 증가·감소와 모수공간의 경계를 직접 조사한다. **예제: Poisson 모형**

$X_i \overset{\text{iid}}{\sim} \text{Poisson}(\theta)$이면

$$\ell(\theta) = \Big(\sum_i x_i\Big)\log\theta - n\theta - \sum_i \log(x_i!).$$

$$\ell'(\theta) = \frac{\sum_i x_i}{\theta} - n = 0 \quad\Rightarrow\quad \hat\theta = \bar{x}.$$

정서/검산 메모 원본 71쪽의 두 가지 접근법과 '미분=0이 항상 최대는 아님'이라는 주의를 정리했습니다. Poisson 식은 이해를 돕는 보충입니다.

6.2.1 — 로그가능도함수의 미분과 가능도방정식

가능도방정식: $\ell(\theta;\mathbf{x}) = \log L(\theta;\mathbf{x})$로 놓고 $\ell'(\theta;\mathbf{x}) = 0$의 해를 최대점 후보로 검토한다. 경계점과 지지집합이 모수에 의존하는 경우에는 미분만으로 MLE를 결정할 수 없다. **예제 6.2.1 — Poisson 표본의 MLE**

$X_i \overset{\text{iid}}{\sim} \text{Poisson}(\theta)$, $\theta > 0$일 때

$$L(\theta) = \frac{\theta^{\sum_i X_i}\exp(-n\theta)}{\prod_i X_i!}, \quad \ell'(\theta) = \frac{\sum_i X_i}{\theta} - n.$$

내부 최대점 후보는 $\boxed{\widehat{\theta} = \overline{X}}$. 단, 표본이 전부 0인 경우 $\theta > 0$ 열린 공간에서는 최대값이 달성되지 않고 $\theta \downarrow 0$에서 상한에 접근한다. $\theta \geq 0$으로 확장하면 $\widehat{\theta} = 0$이다. **원본 필기 예제 — $U(0,\theta)$: 미분방정식의 한계**

$X_i \overset{\text{iid}}{\sim} U(0,\theta)$, $M = X_{(n)}$이면

$$L(\theta;\mathbf{x}) = \theta^{-n}\mathbf{1}_{\{\theta \geq M\}}, \quad \theta > 0.$$

$\theta < M$에서는 $L = 0$이고 $\theta \geq M$에서는 θ^{-n}이 엄격히 감소하므로

$$\boxed{\widehat{\theta}_{\text{ML}} = M = X_{(n)}}.$$

이 예제는 $\ell'(\theta) = 0$에서 해를 찾는 방법이 적용되지 않음을 보여 준다.

원문 대조·교정 기록 원본의 가능도방정식, Poisson 예제, Uniform 예제 및 경계 최대점 스케치를 수식으로 복원.

원본 73쪽 손글씨 정서

지수표본의 MLE: 척도모수 θ

$X_1, \dots, X_n \overset{\text{iid}}{\sim} \text{Exp}(\text{평균} \cdot \text{척도}\ \theta)$, $\theta > 0$이며

$$f(x;\theta) = \frac{1}{\theta} e^{-x/\theta}, \qquad x > 0.$$

결합가능도와 로그가능도는

$$L(\theta) = \theta^{-n} \exp\left(-\frac{\sum x_i}{\theta}\right), \qquad \ell(\theta) = -n \log\theta - \frac{\sum x_i}{\theta}.$$

일계 조건은

$$\ell'(\theta) = -\frac{n}{\theta} + \frac{\sum x_i}{\theta^2} = 0$$
$$\Longleftrightarrow \quad \boxed{\widehat{\theta} = \bar{x}}.$$

이 점에서

$$\ell''(\widehat{\theta}) = \frac{n}{\widehat{\theta}^2} - \frac{2\sum x_i}{\widehat{\theta}^3} = -\frac{n}{\widehat{\theta}^2} < 0$$

이므로 내부 최대점이다.

원본의 경계논의. $\sum x_i > 0$일 때 $\theta \downarrow 0$이면 $\ell(\theta) \to -\infty$, $\theta \to \infty$이면 $\ell(\theta) \to -\infty$. 따라서 내부 임계점이 전체 최대점이다. 모든 $x_i = 0$은 연속 지수모형에서 확률 0인 특수경우다.

정리 6.2.1 — 로그가능도함수의 엄격한 오목성과 MLE

원본의 가정: 열린 모수구간 Ω_0에서 $\ell(\theta) = \log L(\theta; \mathbf{x})$이 두 번 미분가능하고 $\ell''(\theta) < 0$이며 내부점 $\widehat{\theta}$에서 $\ell'(\widehat{\theta}) = 0$이면, $\widehat{\theta}$는 그 구간에서 유일한 최대가능도추정량이다. **원본 필기의 증명 — Taylor 전개**

임의의 $\theta \neq \widehat{\theta}$에 대해 그 사이의 θ^*가 존재하여

$$\begin{aligned}\ell(\theta) &= \ell(\widehat{\theta}) + \ell'(\widehat{\theta})(\theta - \widehat{\theta}) + \frac{1}{2}\ell''(\theta^*)(\theta - \widehat{\theta})^2 \\ &< \ell(\widehat{\theta}).\end{aligned}$$

따라서 $\widehat{\theta} = \arg\max_{\theta \in \Omega_0} \ell(\theta)$이다. (원본 손글씨의 Taylor 이차항에는 $1/2$가 생략되어 있어 보충.) **원본 예제 — $\mathrm{Beta}(\alpha, 1)$의 MLE**

$X_i \overset{\text{iid}}{\sim} \mathrm{Beta}(\alpha, 1)$, $\alpha > 0$,

$$f(x; \alpha) = \alpha x^{\alpha - 1} \mathbf{1}_{(0,1)}(x), \qquad L(\alpha) = \alpha^n \prod_{i=1}^{n} x_i^{\alpha - 1}.$$

$$\ell(\alpha) = n \log \alpha + (\alpha - 1) \sum_i \log x_i, \quad \ell'(\alpha) = \frac{n}{\alpha} + \sum_i \log x_i.$$

$$\boxed{\widehat{\alpha}_{\mathrm{ML}} = -\frac{n}{\sum_i \log X_i}}, \qquad \ell''(\alpha) = -\frac{n}{\alpha^2} < 0.$$

원본 75쪽 손글씨 정서

지수분포 모수화에 따른 MLE의 차이

지수분포의 발생률을 $\lambda > 0$으로 쓰면

$$f(x;\lambda) = \lambda e^{-\lambda x}\mathbf{1}_{x>0}, \qquad \mathsf{E}\,X = 1/\lambda.$$

발생률 λ의 최대가능도추정량.

$$\ell(\lambda) = n\log\lambda - \lambda\sum_i x_i, \qquad \ell'(\lambda) = \frac{n}{\lambda} - \sum_i x_i.$$

따라서 $\widehat{\lambda} = n/(\sum_i x_i) = 1/\bar{x}$이고

$$\ell''(\lambda) = -n/\lambda^2 < 0.$$

척도 $\theta = 1/\lambda$의 추정량은 MLE 불변성에 의해

$$\boxed{\widehat{\theta} = 1/\widehat{\lambda} = \bar{x}}.$$

원본 필기 정리. $n/\sum x_i$와 $\bar{x}$는 서로 모순된 결과가 아니다. 전자는 발생률 λ, 후자는 평균 · 척도 θ에 대한 MLE이다.

원본 76 쪽 Remark: 순오목함수 (strictly concave function)

[정리 6.2.1] 에서의조건

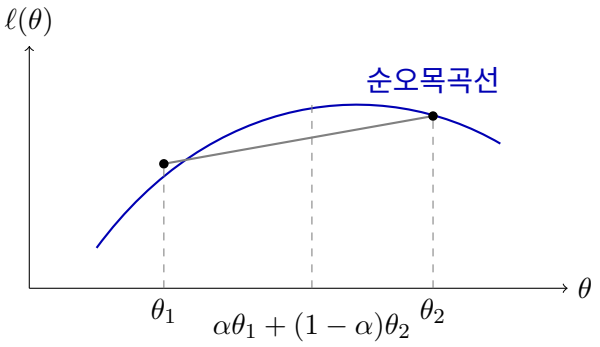
로그가능도함수 $\ell(\theta)$ 가다음을만족한다면, ℓ 이순오목 (strictly concave) 임을보이는충분조건이된다.

$$\ell''(\theta) < 0, \qquad \theta \in \Omega_0.$$

순오목함수의정의

서로다른 θ_1, θ_2 와 $0 < \alpha < 1$ 에대하여

$$\ell\big(\alpha\theta_1 + (1-\alpha)\theta_2\big) > \alpha\ell(\theta_1) + (1-\alpha)\ell(\theta_2).$$



- 로그가능도함수가순오목이고 $\ell'(\hat{\theta}) = 0$ 을만족하는내부해가있다면그해는 **유일한전역최대점**, 즉 ML 추정값이다.
- 다만가능도방정식은복잡하여해의닫힌형태가존재하지않을수있다. 이때수치적인방법을활용한다.

검산·보충: 미분가능하고 $\ell''(\theta) < 0$ 라면 ℓ' 은엄격히감소한다. 따라서 $\ell'(\theta) = 0$ 의해가있다면최대하나뿐이다. 존재여부와경계는별도로확인한다.

원본 77 쪽 로지스틱위치모형의 ML 가능도방정식

원본손글씨: 로지스틱분포의위치모수추정

독립표본 $X_1, \dots, X_n \overset{\text{iid}}{\sim} \text{Logistic}(\theta, 1)$ 에서 $\theta \in \mathbb{R}$ 은위치모수이다.

$$f(x;\theta) = \frac{e^{x-\theta}}{(1+e^{x-\theta})^2} = \frac{e^{\theta-x}}{(1+e^{\theta-x})^2}, \quad -\infty < x < \infty.$$

가능도와로그가능도

$$L(\theta; \boldsymbol{x}) = \prod_{i=1}^{n} \frac{e^{\theta-x_i}}{(1+e^{\theta-x_i})^2},$$

$$\ell(\theta) = n\theta - \sum_{i=1}^{n} x_i - 2\sum_{i=1}^{n} \log(1+e^{\theta-x_i}).$$

가능도방정식

$$\ell'(\theta) = n - 2\sum_{i=1}^{n} \frac{e^{\theta-x_i}}{1+e^{\theta-x_i}} = 0.$$

정리하면

$$\boxed{\sum_{i=1}^{n} \frac{1}{1+e^{x_i-\hat\theta}} = \frac{n}{2}}.$$

유일성과최대점판정

$$\ell''(\theta) = -2\sum_{i=1}^{n} \frac{e^{\theta-x_i}}{(1+e^{\theta-x_i})^2} < 0.$$

따라서로그가능도는순오목하며가능도방정식의해는유일하다. $\ell'(\theta)$ 는 $\theta \to -\infty$ 일때 $n > 0$, $\theta \to \infty$ 일때 $-n < 0$ 으로수렴하므로내부해도존재한다.

검산·보충: 일반적으로 $\hat\theta$ 에단순한닫힌식이없으므로뉴턴–랩슨등수치해법을이용한다. 위두등식은서로동치이며원본손글씨의부호를확인해일관되게표기했다.

정리 6.2.2 — 순오목함수에서 ML 추정량의 유일성

원본 가능도방정식이 폐쇄형으로 풀리지 않더라도 ML 추정량의 유일성을 판정할 수 있다. **정리의 조건**
수직선 위의 열린구간 Ω_0에서 $\ell(\theta)$가 두 번 미분가능하고 ℓ''가 연속이라고 하자.

$$\boxed{\ell''(\theta) < 0 \quad (\forall \theta \in \Omega_0), \qquad \lim_{\theta \to \partial\Omega_0} \ell(\theta) = -\infty.}$$

그러면 $\ell'(\hat\theta) = 0$의 근이 존재하며 유일하다. 그 점이 ML 추정량이다. **원본 증명에 적힌 논리**
서로 다른 두 최대점 $\hat\theta_1, \hat\theta_2$가 있다고 가정하면

$$\ell\left(\frac{\hat\theta_1 + \hat\theta_2}{2}\right) > \frac{\ell(\hat\theta_1) + \ell(\hat\theta_2)}{2} = \max_{\theta \in \Omega_0} \ell(\theta),$$

이는 최대값의 정의와 모순이다. **원본 필기의 곡률 확인**
원본에는 로그가능도 예시의 이계도함수가 다음 음수 형태로 기록되어 있다.

$$\ell''(\theta) = -2\sum_{i=1}^{n} \frac{e^{x_i+\theta}}{(1+e^{x_i+\theta})^2} < 0.$$

정서/검산 메모 원본의 '엄격한 오목성 ⇒ 유일한 최대점' 증명과 이계미분 메모를 정서했습니다.

원본 79 쪽 수치적인방법에의한 ML 추정

필요성

가능도방정식 $\ell'(\theta)=0$ 의근이존재하는것은알지만구체적인풀이가어려워해를폐쇄적인형태로표현할수없는경우가있다. **[예제 6.2.3] 로지스틱분포에서 ML 추정**

앞쪽의로지스틱위치모형은로그가능도에지수함수항들이결합되어있어해를수치적으로구한다. **일단계반복법: Newton–Raphson method**

최대화후보의방정식 $g(\theta)=\ell'(\theta)=0$ 을푼다. 현추정값 θ_r 근처에서 g 를 Taylor 전개한다.

$$g(\theta)\approx g(\theta_r)+(\theta-\theta_r)g'(\theta_r).$$

$g(\theta)=0$ 으로두면

$$0\approx g(\theta_r)+(\theta-\theta_r)g'(\theta_r),\qquad \theta\approx\theta_r-\frac{g(\theta_r)}{g'(\theta_r)}.$$

$g=\ell'$ 을대입하면원본의반복식이나온다.

$$\boxed{\hat\theta_{r+1}=\hat\theta_r-\frac{\ell'(\hat\theta_r)}{\ell''(\hat\theta_r)}=\hat\theta_r+[-\ell''(\hat\theta_r)]^{-1}\ell'(\hat\theta_r).}$$

반복과종료

초기값 $\hat\theta_0$ 를정한뒤 $r=0,1,2,\ldots$ 순서로계산하고, 변화량 $|\hat\theta_{r+1}-\hat\theta_r|$ 이충분히작아지면종료한다.

검산·보충: 원본손글씨의'$g(\theta)=\ell'(\theta)$', $g(\theta)\approx g(\theta_0)+(\theta-\theta_0)g'(\theta_0)$ 를빠짐없이반영했다. 분모 $\ell''(\hat\theta_r)=0$ 인경우등에는반복식이바로적용되지않는다.

원본 80 쪽 뉴턴–랩슨법: 현재점검과접선교점

원본필기: Step 1 과 Step 2

Step 1. 현재추정값 $\widehat{\theta}_r$ 에서 $g(\widehat{\theta}_r) = 0$ 인지확인한다. 만족하면반복을종료한다. 여기서 $g(\theta) = \ell'(\theta)$ 는점수함수이다.

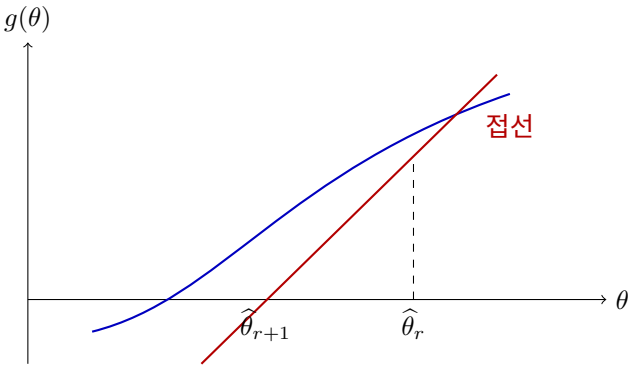
Step 2. $g(\widehat{\theta}_r) \neq 0$ 이면일차 Taylor 근사로

$$0 \approx g(\widehat{\theta}_r) + g'(\widehat{\theta}_r)(\theta - \widehat{\theta}_r)$$

를풀어새후보를얻는다.

$$\boxed{\widehat{\theta}_{r+1} = \widehat{\theta}_r - [g'(\widehat{\theta}_r)]^{-1} g(\widehat{\theta}_r)}$$

스칼라값이면 $\widehat{\theta}_{r+1} = \widehat{\theta}_r - g(\widehat{\theta}_r)/g'(\widehat{\theta}_r)$ 이다.



검산·보충: 원본에는 '제약이있는최대가능도추정' 이라는제목이없다. 이페이지는 Newton 반복의 Step 1–2 와접선그림이다. 다변수에서는 $[g'(\widehat{\theta}_r)]^{-1}$ 를 Hessian 의역행렬로해석한다.

[정리 6.2.3] 모수의 일대일 변환과 최대가능도추정

MLE의 변환 불변성

θ의 최대가능도추정량을 $\widehat{\theta}_{\mathrm{ML}}$이라 하고 새로운 모수 $\tau = g(\theta)$가 일대일 변환일 때,

$$\boxed{\widehat{\tau}_{\mathrm{ML}} = g(\widehat{\theta}_{\mathrm{ML}})}.$$

[원본 증명] 재매개화된 가능도함수

일대일성이 있으므로 $\theta = g^{-1}(\tau)$이고 $L_\tau(\tau; \mathbf{x}) = L_\theta(g^{-1}(\tau); \mathbf{x})$이다. 따라서

$$\arg\max_{\tau} L_\tau(\tau; \mathbf{x}) = g\left(\arg\max_{\theta} L_\theta(\theta; \mathbf{x})\right) = g(\widehat{\theta}_{\mathrm{ML}}).$$

원본 예: 정규모집단의 분산과 표준편차

$\sigma^2 > 0$의 MLE가 $\widehat{\sigma^2}_{\mathrm{ML}}$이면 일대일 함수 $g(t) = \sqrt{t}$에 의하여

$$\boxed{\widehat{\sigma}_{\mathrm{ML}} = \sqrt{\widehat{\sigma^2}_{\mathrm{ML}}}}.$$

불변성은 최대가능도에 대한 성질이며 불편성 여부와 별개다.

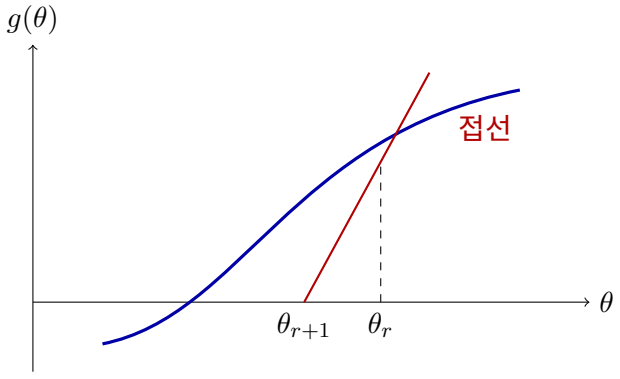
원문 대조·교정 기록 원본 정리 6.2.3의 설명, 일대일 변환의 증명 및 표준편차 예를 빠짐없이 복원.

원본 82 쪽 제안한알고리즘: 접선의근을반복계산

원본손글씨의절차

• **Step 1.** 현재값 θ_r 에서점수함수가 0 인지확인한다: $g(\theta_r)=\ell'(\theta_r)=0$ 이면종료한다. • **Step 2.** 그렇지않으면현재점에서접선을그려접선과수평축의교점을다음근삿값으로잡는다.

$$\boxed{\theta_{r+1}=\theta_r-\frac{g(\theta_r)}{g'(\theta_r)}.}$$



기하학적해석과적용

$g(\theta_r)$ 는현재점의함수값이고 $g'(\theta_r)$ 는접선의기울기이다. 따라서해당기울기로수평축까지내려가근을갱신한다.

검산·보충: 최대가능도문제에서는 $g=\ell'$ 로놓아야한다. $\ell''<0$ 인구간이라도초기값에따라큰도약이생길수있으므로실제계산에는수렴여부를점검한다.

원본 83 쪽 MLE 불변성예제와지수분포에서의 ML 추정

[예제] Bernoulli 표본과 odds 추정

$X_1, \dots, X_n \sim \text{Bernoulli}(p)$, $0 \le p \le 1$, 추정대상 $\eta(p) = p/(1-p)$. Bernoulli 모수의 ML 추정량은 $\hat{p} = \bar{X}$ 이므로 불변성에의해

$$\boxed{\hat{\eta} = \frac{\bar{X}}{1-\bar{X}} \quad (0 \le \bar{X} < 1).}$$

$\bar{X} = 1$ 이면 $p = 1$ 에서 η 가유한하게정의되지않으므로유한한추정값이없다. **[예제 6.2.4] 지수분포에서 ML 추정**

원본은 θ 를지수분포의 **척도 (scale)** 로사용한다.

$$X_1, \dots, X_n \overset{\text{iid}}{\sim} \text{Exp}(\theta), \quad f(x;\theta) = \frac{1}{\theta} e^{-x/\theta}, \quad x > 0, \quad \theta > 0.$$

$$L(\theta; \boldsymbol{x}) = \theta^{-n} \exp\left(-\frac{\sum_{i=1}^{n} x_i}{\theta} \right), \qquad \ell(\theta) = -n \log \theta - \frac{\sum_i x_i}{\theta}.$$

미분과최대점판정

$$\ell'(\theta) = -\frac{n}{\theta} + \frac{\sum_i x_i}{\theta^2} = 0 \quad \Longrightarrow \quad \boxed{\hat{\theta} = \bar{X}}.$$

$$\ell''(\theta) = \frac{n}{\theta^2} - \frac{2\sum_i x_i}{\theta^3}, \qquad \ell''(\bar{X}) = -\frac{n}{\bar{X}^2} < 0.$$

검산·보충: 원본필기의 $\ell''(\theta) < 0$ 표기는모든 $\theta > 0$ 에서성립하지않는다. 음수임을보일곳은 $\theta = \hat{\theta}$ 이므로여기서대입해판정했다.

원본 84 쪽 지수분포의모수변환과 ML 불변성

원본손글씨: 발생률 (rate) 모수로바꾸기

앞쪽예제에서척도모수가 θ 였다면발생률 $\lambda = 1/\theta$ 를도입한다.

$$f(x;\lambda) = \lambda e^{-\lambda x}, \quad x > 0, \quad \lambda > 0.$$

따라서

$$L(\lambda;\boldsymbol{x}) = \lambda^n e^{-\lambda \sum_i x_i}, \qquad \ell(\lambda) = n\log\lambda - \lambda\sum_{i=1}^{n} x_i.$$

미분과최대점

$$\ell'(\lambda) = \frac{n}{\lambda} - \sum_i x_i = 0 \quad \Longrightarrow \quad \boxed{\hat{\lambda}_{\mathsf{ML}} = \frac{n}{\sum_i X_i} = \frac{1}{\bar{X}}}.$$

$$\ell''(\lambda) = -\frac{n}{\lambda^2} < 0, \qquad \lambda > 0.$$

즉, 로그가능도는전체구간에서순오목이며위값이유일한최대화점이다. **ML 추정량의불변성확인**

$$\theta = \frac{1}{\lambda} \quad \Longrightarrow \quad \hat{\theta}_{\mathsf{ML}} = \frac{1}{\hat{\lambda}_{\mathsf{ML}}} = \frac{1}{n}\sum_{i=1}^{n} X_i = \bar{X}.$$

검산·보충: 서로다른모수화에서도같은분포족을표현하므로추정결과가일치한다. 원본에서섞여쓰인 θ(척도), λ(발생률) 표기를구분했다.

원본 85 쪽 제 7 장·제 9 장: 가설검정 Part 1

검정이론

모집단성질에관한가설을표본을통해받아들일지또는기각할지를결정한다. 예를들어두방법의효과차이, 진통제의평균효과발현시간이 30 분보다작은지, 초등학교 6 학년남학생의키평균이과거 150cm 와같은지등을검정한다.

[정의] 통계적가설 (statistical hypothesis)

관심있는모집단특성에관한단정이나추측을통계적가설이라한다. 확률모형 $f(x;\theta)$ 에서미지의모수 θ 에대한부분집합으로표현할수있다.

- **단순가설 (simple hypothesis):** 모형의확률분포를하나로완전히특정하는가설. 예: 분산이이미주어진정규모형에서 $H_0 : \mu = 30$.
- **복합가설 (composite hypothesis):** 확률분포를하나로특정하지않는가설. 예: $H_1 : \mu < 30$, $H_1 : \mu \neq 30$ 또는두평균에대해 $\mu_1 = \mu_2$ 이더라도공통분산등다른모수가알려지지않은경우.

원본의표본·모집단관계

모집단 $X \sim f(x;\theta)$ 에서독립인표본 $X_1, \ldots, X_n$ 을뽑아, 관측결과를이용해가설에관한결정규칙을구성한다.

> **검산·보충:** 원본의진통제·학생키사례와단순가설/복합가설구분을모두반영했다. 두가설의단순성은모든모수가특정되는지에달려있다.

평균에 대한 가설검정: 필기 예제

원본: 표본평균 $T(X_1, \ldots, X_n) = \bar{X} = (1/n)\sum_i X_i$의 모분포와 가설을 구분한다. **모평균이 알려진 경우 및 미지의 경우**

- 가설 사례 1: $\mu = 0$, $\sigma^2 = 1$이면 $X_i \overset{\text{iid}}{\sim} N(0, 1)$.
- 가설 사례 2: $\mu = 0$, $\sigma^2 > 0$이면 $X_i \overset{\text{iid}}{\sim} N(0, \sigma^2)$.
- 가설 사례 3: $\mu > 0$, $\sigma^2 = 1$이면 $X_i \overset{\text{iid}}{\sim} N(\mu, 1)$, $\mu > 0$.

메모에 적힌 평균 가설의 형태

$X_i \overset{\text{iid}}{\sim} N(\mu, 10^2)$인 예시에서는

$$\mu = 30, \qquad \mu < 30, \qquad \mu \neq 30, \qquad \mu = 35$$

처럼 귀무가설과 대립가설의 조건을 달리 설정할 수 있다.

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right).$$

정서/검산 메모 이 원본 페이지는 사례를 나열한 필기이며, 각 사례의 구체적인 유의수준이나 기각역까지는 적혀 있지 않습니다.

원본 87 쪽 단순·복합가설, 귀무가설과대립가설

[예제] 정규분포모수벡터에관한가설

$X_1, \ldots, X_n \sim N(\mu, \sigma^2)$ 인모형에서 $\theta = (\mu, \sigma^2)$ 에관한가설을고려한다. • $(\mu, \sigma^2) = (0, 1)$ 이라는가설이참이면모집단의분포가 $N(0, 1)$ 로완전히결정된다. 즉 **단순가설** (simple hypothesis) 이다. • $\mu > \mu_0$ 이라는가설은여러모수값을허용하므로 **복합가설** (composite hypothesis) 이다. **[정의] 귀무가설 (null hypothesis, H_0)**

현재까지알려진사실또는주장으로, 특별한이유가없으면일반적으로받아들이며, 표본에서뚜렷한반증이있을때기각하려는가설이다. 예: 두약의효과에차이가없다, 키의평균이 150 이다. **[정의] 대립가설 (alternative hypothesis, H_1)**

지금까지알려져있는것과다른주장으로, 이를뒷받침하는증거가있어야받아들이는가설이다. 예: 두약의효과가다르다, 키의평균이 150 보다크다. **원본손글씨예시**

$$H_0 : \mu = 30 \qquad \text{vs.} \qquad H_1 : \mu < 30.$$

통계적가설검정

기존가설을귀무가설, 연구자가확인하려는가설을대립가설로두고표본자료를이용하여귀무가설을기각할근거가있는지판단한다. 검정을통해귀무가설을 기각하거나 기각하지못함을결정하며, 기각하지못했다는사실만으로 H_0 가참이라고입증되는것은아니다.

7.1 검정통계량, 기각역과 예제 7.1.1

[정의] 검정통계량과 기각역

검정통계량(test statistic)은 표본 $X_1, \dots, X_n$으로부터 가설의 기각 여부를 판단할 때 사용하는 함수 $T(\mathbf{X})$다. 귀무가설을 기각하는 관측값들의 부분집합을 기각역(rejection region) C라 하며 C^c를 비기각역이라고 한다. **[원본 예제 7.1.1] 진통제가 더 빨리 작용하는가?**

기존 진통제의 진통 효과가 나타나기까지의 시간이 평균 30분, 표준편차 5분인 정규모형이라고 하자. 새 진통제의 평균 작용 시간이 더 짧은지 $n = 100$명으로 조사한다.

$$H_0 : \mu = 30 \quad \text{vs} \quad H_1 : \mu < 30, \qquad \overline{X} \sim N\left(\mu, \frac{25}{100}\right).$$

작은 $\overline{X}$가 대립가설을 지지하므로 $C = \{\overline{X} < c\}$의 좌측 기각역을 사용한다. 관측 평균이 29분보다 짧을 귀무가설 하 확률은

$$\begin{aligned} P_{30}(\overline{X} < 29) &= P\left(\frac{\overline{X} - 30}{5/\sqrt{100}} < -2\right) \\ &= \Phi(-2) \approx \boxed{0.02275 \simeq 0.023}. \end{aligned}$$

이후 유의수준 α를 정하고 $P_{30}(\overline{X} < c) \le \alpha$가 되도록 임계값 c를 선택한다. 비기각은 귀무가설이 참임을 증명하지는 않는다.

원문 대조·교정 기록 원본 예제의 30분, 표준편차 5분, 표본크기 100, 좌측기각 방향, 관측값 29분과 확률 0.023을 원문 순서대로 복원.

원본 89 쪽 가설검정예제 7.1.1 의해석과기각역

앞쪽예제의연속

평균이 30 분인상황에서 100 명을관찰해표본평균이 29 분미만으로나올가능성이 100 번중약 2–3 번이라고하자 (원본강의노트에제시된수치). 이는 H_0 아래에서보기드문결과이다.

$$H_0 : \mu = 30 \qquad \text{vs.} \qquad H_1 : \mu < 30.$$

- 관찰된통계량이 29 분보다작을때 p-값이약 0.023 이라면 5% 유의수준에서 H_0 를기각한다. • 반대로 p-값이 0.5 라면같은값이하가약 50 번나타날수있다는뜻이므로귀무가설에반하는증거가약하다. **기각역과채택역 (비기각역)**

검정규칙을 $\bar{X} < 29$ 일때귀무가설을기각하도록정했다면

$$C = \{(x_1, \ldots, x_n) : \bar{x} < 29\}, \qquad C^c = \{\bar{x} \geq 29\}.$$

가설검정에서오류가생기는이유

통계적결론은관찰표본에근거하므로오류확률을 0 으로만들수있는것은아니다. 귀무가설이참일때기각하는오류와거짓일때기각하지못하는오류를각각구분한다.

검산·보충: 원본에표시된 $\bar{X} = 28.5, 29.03$ 은예시관측값으로제시되어있으며, p-값이임계값에가까울수있다는점을강조한표시이다. 0.023 은원본예제에서주어진값으로, 모표준편차의정확한수치가이페이지에적혀있지않아독립산출했다고주장하지않는다.

원본 90 쪽 제 1 종오류·제 2 종오류, 검정력

모집단에서표본을추출해통계량으로결정

$$X_1, \dots, X_n \overset{\text{iid}}{\sim} f(x;\theta), \qquad T = T(X_1, \dots, X_n).$$

예: $H_0 : \theta = \theta_0$ 대 $H_1 : \theta > \theta_0$. **원본결정표의정서**

행동	H_0 가참	H_0 가거짓
H_0 기각	제 1 종오류	올바른결정
H_0 기각하지않음	올바른결정	제 2 종오류

오류확률과검정력

$$\alpha = P(H_0 \text{ 기각} \mid H_0 \text{ 참}), \qquad \beta = P(H_0 \text{ 기각하지않음} \mid H_1 \text{ 참}).$$

$$\boxed{\text{검정력 (power)} = 1 - \beta = P(H_0 \text{ 기각} \mid H_1 \text{ 참}).}$$

원본필기에서강조한세가지

(1) 모든상황에서 $\alpha = \beta = 0$ 인완전한결정이일반적으로가능한것은아니다. (2) 유의수준을낮추면다른조건이같을때 제 2 종오류가커질수있다. (3) 유의수준이정해져있을때가능한검정들중검정력을크게만드는것이최강력검정의목표다.

검산·보충: 모수에따라 $\beta(\theta)$ 와검정력 $\pi(\theta)$ 는달라질수있으므로복합대립가설에서는 검정력함수로구분한다.

유의수준(Significance Level)과 예제 7.1.2

[정의] 유의수준

귀무가설이 참일 때 기각하는 제1종 오류 확률의 최대 허용 한계가 유의수준이다.

$$\boxed{\sup_{\theta \in \Theta_0} P_\theta(\mathbf{X} \in C) \le \alpha.}$$

[예제 7.1.2] 7.1.1의 진통제 검정 계속

$X_i \sim N(\mu, 5^2)$, $n = 100$, $H_0 : \mu = 30$ 대 $H_1 : \mu < 30$이고 $\overline{X}$가 작을수록 기각한다.

(1) $C = \{\overline{X} < 29\}$이면

$$P_{30}(C) = \Phi\left(\frac{29 - 30}{5/\sqrt{100}}\right) = \Phi(-2) \approx 0.02275 < 0.05.$$

따라서 크기가 0.05보다 작은 보수적인 기각역이다.

(2) 크기를 0.05로 만들려면 $z_{0.05} = -1.64485$를 사용해서

$$\boxed{c = 30 - 1.64485\left(\frac{5}{10}\right) \approx 29.1776}.$$

따라서 $C_{0.05} = \{\overline{X} < 29.1776\}$을 사용한다.

동일 수준에서 더 효율적인 기각역을 찾는 문제

유의수준 α를 만족하는 기각역은 많다. 그중 제2종 오류 확률을 작게 하려면 대립가설 아래 기각확률, 즉 검정력(power)을 높여야 한다. 이는 뒤에 도입되는 검정력함수와 최강력검정의 동기이다.

예제 7.1.2 — 진통제의 모평균 단측검정 풀이

원본 92쪽은 바로 앞 예제 7.1.1–7.1.2를 이어서 계산한다. 기존 진통제의 효과 발현시간이 평균 30, 모표준편차 5이고 표본크기는 100이다.

$$X_i \overset{\text{iid}}{\sim} N(\mu, 5^2), \quad H_0 : \mu = 30 \text{ vs } H_1 : \mu < 30, \quad \overline{X} \sim N\left(\mu, \frac{25}{100}\right).$$

원본의 두 가지 기각역

(1) $C_1 = \{\overline{X} < 29\}$이면

$$P_{30}(C_1) = \Phi\left(\frac{29-30}{5/10}\right) = \Phi(-2) \approx 0.0228 < 0.05.$$

(2) 정확히 유의수준 $\alpha = 0.05$를 이용하려면

$$c = 30 + z_{0.05}\frac{5}{\sqrt{100}} = 30 - 1.64485(0.5) = 29.1776,$$

따라서 $C_2 = \{\overline{X} < 29.1776\}$을 쓴다.

검정력함수로의 연결

참 평균이 μ일 때 C_2에 대한 검정력은

$$\boxed{\pi(\mu) = P_\mu(\overline{X} < 29.1776) = \Phi\left(\frac{29.1776-\mu}{0.5}\right)}.$$

$\pi(30) \approx 0.05$이고, $\mu < 30$에서는 더 작은 평균일수록 기각확률이 커진다.

원문 대조·교정 기록 이전 정서본의 $n = 20, \sigma^2 = 2$는 원본 92쪽에 없는 설정으로 확인되어 삭제. 원본의 $n = 100, \sigma = 5, \mu_0 = 30$으로 복원.

7.1 검정력함수(power function) — 정의와 예제 7.1.1

모수 θ에 따른 귀무가설 기각확률을 검정력함수라 한다. 기각역 C에 대하여

$$\boxed{\gamma(\theta) = P_\theta\big((X_1,\dots,X_n)\in C\big).}$$

θ가 귀무가설 영역에 있으면 제1종 오류의 확률, 대립가설 영역에 있으면 검정력이다. **예제 7.1.1(계속) — 수치 검정력**

$$H_0 : \mu = 30 \qquad \text{대} \qquad H_1 : \mu < 30.$$

$X_i \overset{\text{iid}}{\sim} N(\mu, 5^2)$, $n = 100$으로 $C = \{\overline{X} < 29\}$를 사용한다면 $\overline{X} \sim N(\mu, 5^2/100)$이고

$$\begin{aligned}\gamma(\mu) &= P_\mu(\overline{X} < 29) = \Phi\left(\frac{29-\mu}{5/10}\right)\\ &= \boxed{\Phi(58-2\mu)}.\end{aligned}$$

따라서

$$\gamma(30) = \Phi(-2) \approx 0.02275, \qquad \gamma(28.5) = \Phi(1) \approx 0.84134.$$

제2종 오류는 $\beta(\mu) = 1-\gamma(\mu)$이므로

$$\boxed{\gamma(28.5) = 1-\beta(28.5)}.$$

원문 대조·교정 기록 원본 93쪽의 $\gamma(\mu)=\Phi(58-2\mu)$, $\mu=28.5$, 제2종 오류와의 관계를 수치 검산.

검정력함수와 제2종 오류 — 원본 필기 계산 복원

$X_1, \dots, X_{100} \overset{\text{iid}}{\sim} N(\mu, 25)$, $H_0 : \mu = 30$ 대 $H_1 : \mu < 30$이다. 표본평균의 표준편차는 $5/\sqrt{100} = 0.5$이다. **(1) 첫 기각역** $C_1 = \{\overline{X} < 29\}$

$$\gamma_1(\mu) = P_\mu(\overline{X} < 29) = \Phi\left(\frac{29-\mu}{0.5}\right) = \Phi(58 - 2\mu).$$

귀무가설 아래 $\gamma_1(30) = \Phi(-2) \approx 0.0228$. 참값이 $\mu = 28.5$인 경우

$$\boxed{\gamma_1(28.5) = \Phi(1) \approx 0.8413}, \qquad \beta_1(28.5) \approx 0.1587.$$

(2) 수준 0.05**의 기각역** $C_2 = \{\overline{X} < 29.1775\}$

$$\gamma_2(\mu) = \Phi(58.355 - 2\mu), \qquad \gamma_2(30) \approx 0.05.$$

참값 $\mu = 28.5$에서

$$\boxed{\gamma_2(28.5) = \Phi(1.355) \approx 0.9122}, \qquad \beta_2(28.5) \approx 0.0878.$$

검산: 두 기각역 비교

	C_1	C_2
제1종 오류 확률 ($\mu = 30$)	0.0228	0.0500
검정력 ($\mu = 28.5$)	0.8413	0.9122
제2종 오류 확률 ($\mu = 28.5$)	0.1587	0.0878

두 번째 기각역은 더 넓으므로 대립가설에서 검정력이 높다. 원본 필기의 '제2종 오류 15.9%와 8.8%' 비교와 일치한다.

원본 95 쪽 [예제 7.1.2–7.1.3] 기각역과검정력함수

원본모형·가설

$$X_1, \dots, X_{100} \overset{\text{iid}}{\sim} N(\mu, 5^2), \qquad H_0 : \mu = 30 \text{ 대 } H_1 : \mu < 30.$$

표본평균의표준편차는 $5/10 = 0.5$ 이다.

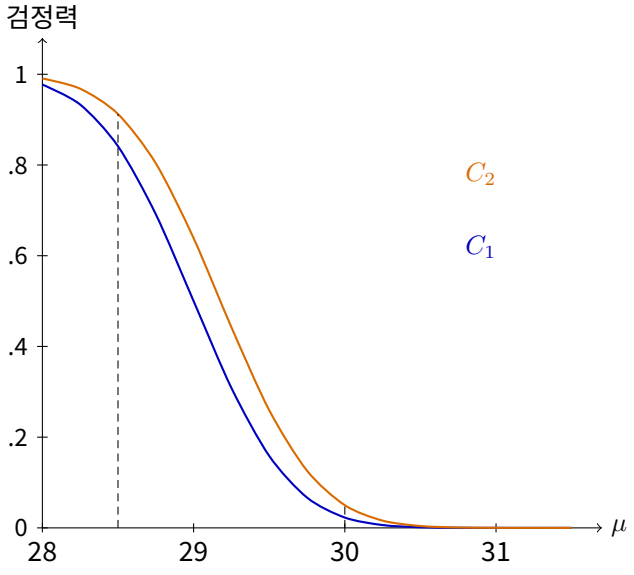
두기각역의비교

$$C_1 = \{\bar{X} \le 29\}, \quad C_2 = \{\bar{X} \le 29.1775\},$$

$$\gamma_1(\mu) = P_\mu(C_1) = \Phi(58 - 2\mu), \qquad \gamma_2(\mu) = P_\mu(C_2) = \Phi(58.355 - 2\mu).$$

$\mu = 30$ 에서는각각 $\Phi(-2) \approx 0.0228$ 과 $\Phi(-1.645) \approx 0.05$ 가된다. 후자가유의수준 0.05 에서기각확률을최대한사용한다.

원본의검정력비교그래프복원



원본수치 $\mu = 28.5$ 에서검산

$$\gamma_1(28.5) = \Phi(1) = 0.8413, \qquad \gamma_2(28.5) = \Phi(1.355) \approx 0.912.$$

검산·보충: 원본의두검정력곡선과 $\mu = 28.5$ 수치를복원했다. 개념도에서 C_2 곡선이 C_1 보다위에위치한다.

검정의 제1종·제2종 오류와 검정력

원본 필기는 평균 모수에 관한 한쪽 검정의 두 분포와 채택역/기각역을 그림으로 비교한다.

$$H_0 : \mu = 30, \qquad H_1 : \mu = 28.5, \qquad \bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right).$$

H_0에서 정한 기각역을 C라 하면

$$\alpha = P_{\mu=30}(\bar{X} \in C), \qquad \beta(28.5) = P_{\mu=28.5}(\bar{X} \notin C).$$

따라서 대립가설이 참일 때의 검정력은

$$\pi(28.5) = P_{\mu=28.5}(\bar{X} \in C) = 1 - \beta(28.5).$$

정서/검산 메모 원본의 두 겹친 곡선과 오류 영역을 활자 수식과 개략도로 다시 표시했습니다. 그림은 분포의 상대적 위치를 나타낸 개념도입니다.

검정력과 제2종 오류 — 예제 7.1.4

원본 도입: 검정력이란 대립가설이 참일 때 귀무가설을 기각할 확률이다. 같은 유의수준에서 검정력이 가장 큰 검정을 선호한다. **원본 예제 — 포아송 표본의 좌측단측검정**

$X_1, \dots, X_{100} \overset{\text{iid}}{\sim} \text{Poisson}(\theta)$에서

$$H_0 : \theta = 0.1 \qquad \text{vs} \qquad H_1 : \theta < 0.1.$$

$T = \sum_i X_i \sim \text{Poisson}(100\theta)$. 작은 T에서 기각하며, H_0에서는 $T \sim \text{Poisson}(10)$이다.

$$P_{0.1}(T \le 4) = e^{-10} \sum_{j=0}^{4} \frac{10^j}{j!} \approx 0.029253,$$

$$P_{0.1}(T \le 5) = e^{-10} \sum_{j=0}^{5} \frac{10^j}{j!} \approx 0.067086.$$

유의수준 $\alpha = 0.05$의 임의화 검정

$T \le 4$이면 반드시 기각하고, $T = 5$이면 확률 γ로 기각한다.

$$\gamma = \frac{0.05 - P_{0.1}(T \le 4)}{P_{0.1}(T = 5)} \approx 0.5484.$$

따라서 $\varphi(T) = 1\,(T \le 4), \gamma\,(T = 5), 0\,(T \ge 6)$인 검정은 크기가 정확히 0.05이다.

[예제 7.1.4] 포아송 평균의 좌측검정 — 원본 도수표 복원

$X_1,\dots,X_{100} \overset{\text{iid}}{\sim} \text{Pois}(\theta)$, $H_0:\theta=0.1$ 대 $H_1:\theta<0.1$, 유의수준 $\alpha=0.05$. 원본 필기에서는 이산분포 때문에 경계에서 임의화한다.
표본합과 귀무분포

$$\boxed{T=\sum_{i=1}^{100}X_i \sim \text{Pois}(100\theta), \quad T \mid H_0 \sim \text{Pois}(10).}$$

대립가설 방향에서는 관측한 T가 작을수록 H_0를 기각한다. **[원본] 누적확률표 — 직접 검산**

t	0	1	2	3	4	5	6
$P_{0.1}(T\le t)$	.000045	.000499	.002769	.010336	.029253	.067086	.130141

$P_{0.1}(T\le 4)=0.029253<0.05<P_{0.1}(T\le 5)=0.067086$이므로 경계는 $T=5$이다.

$$\gamma=\frac{0.05-P_{0.1}(T\le 4)}{P_{0.1}(T=5)}=\frac{0.05-0.0292526881}{0.0378332748}\approx\boxed{0.548388}.$$

검정함수

$$\varphi(t)=\begin{cases}1, & t\le 4,\\ \gamma, & t=5,\\ 0, & t\ge 6.\end{cases}\qquad E_{0.1}\varphi(T)=0.05.$$

원문 대조·교정 기록 원본 손글씨의 누적도수표와 경계 임의화를 복원함. 원본의 0.029, 0.067은 반올림값이므로 γ는 원확률로 계산. $100\sum_i X_i$가 아닌 $\sum_i X_i$가 표본합이다.

원본 99 쪽 가설검정과정·기각역·임의화검정

가설검정과정 (원본정의)

모집단분포 $f(x;\theta)$ 와모수공간 Ω 를두고, 서로다른두모수집합으로나눈다.

$$H_0 : \theta \in \Omega_0 \qquad \text{vs.} \qquad H_1 : \theta \in \Omega_1, \quad \Omega_0 \cup \Omega_1 = \Omega.$$

랜덤표본 $X_1, \dots, X_n$ 의관찰결과로대립가설을지지할충분한근거가있는지를판단하는과정이다. **유의수준과기각역**

잘못하여귀무가설을기각하는확률의최대허용한계를 α 라한다. 기각역

$$C_\alpha = \{(x_1, \dots, x_n) : H_0 \text{ 를기각할관찰값}\}$$

에대하여검정의크기를제어하려면

$$\boxed{\sup_{\theta \in \Omega_0} P_\theta\big((X_1, \dots, X_n) \in C_\alpha\big) \le \alpha}.$$

의사결정과정과임의화검정

- $X \in C_\alpha$ 이면기각하고 $X \notin C_\alpha$ 이면기각하지않는다. • 검정함수 $\phi(x)$ 는귀무가설을기각할확률을나타낸다.

$$\phi(x) = \begin{cases} 1, & \text{반드시기각,} \\ \gamma \in (0,1), & \text{확률 } \gamma \text{ 로기각,} \\ 0, & \text{기각하지않음.} \end{cases}$$

제 2 종오류를작게하는기준

α 이하인검정들은많으므로허용된유의수준아래에서가능한한큰검정력 (즉작은제 2 종오류) 을갖는기각역을선택한다.

검산·보충: 원본에있던'$\sup_{\theta\in\Omega_0}$' 을명확히표기했다. 보통유의수준이 α 라는표현에는크기 $\le \alpha$ 도포함한다.

[Note] Power function — 비임의화 검정

원본 정의: 기각역 C_α의 비임의화 검정함수를 $\varphi(\mathbf{x}) = \mathbf{1}_{\{\mathbf{x}\in C_\alpha\}}$라 하면

$$\gamma(\theta) = E_\theta[\varphi(X_1,\ldots,X_n)] = P_\theta\{(X_1,\ldots,X_n)\in C_\alpha\}.$$

1. 귀무가설 $\theta\in\Omega_0$에서

$$\gamma(\theta)\le\alpha \quad (\theta\in\Omega_0), \qquad \sup_{\theta\in\Omega_0}\gamma(\theta)\le\alpha.$$

기각역을 가능한 한 크게 하되, 귀무가설 아래 제1종 오류의 최대확률이 유의수준 α를 넘지 않도록 정한다. 검정의 크기가 정확히 α이면 $\sup_{\Omega_0}\gamma(\theta)=\alpha$이다. **2. 대립가설 $\theta\in\Omega_1$에서**

$$\gamma(\theta) = P_\theta(\text{기각}) = 1 - P_\theta(\text{기각하지 않음}) = 1-\beta(\theta).$$

여기서 $\beta(\theta)$는 제2종 오류 확률이다. 대립가설이 단순할 때 그 점에서의 검정력은 $1-\beta$이다. **원본의 중요한 결론**

귀무가설 아래 제1종 오류 확률을 통제하면서, 대립가설 아래에서 귀무가설을 기각할 확률을 크게 하는 검정을 찾는다.

예제 7.1.5, 7.1.6 — 복합귀무가설의 검정

예제 7.1.5 — 정규모형의 왼쪽 단측검정

원본 조건: $X_1,\dots,X_{100}\sim N(\mu,5^2)$, $H_0:\mu\ge 30$ 대 $H_1:\mu<30$. $\overline{X}\sim N(\mu,25/100)$이고 작은 표본평균에서 기각한다.

$$Z=\frac{\overline{X}-30}{5/\sqrt{100}}=2(\overline{X}-30),\qquad C_\alpha=\{Z\le z_\alpha\}.$$

$\mu\ge 30$에서 기각확률이 최대인 경계는 $\mu=30$이므로 $\sup_{\mu\ge 30}P_\mu(C_\alpha)=\alpha$이다. **예제 7.1.6 — Poisson 모형의 왼쪽 단측검정**

원본 조건: $X_1,\dots,X_n\overset{\text{iid}}{\sim}\text{Poisson}(\theta)$, $H_0:\theta\ge 0.1$ 대 $H_1:\theta<0.1$. $T=\sum_i X_i\sim\text{Poisson}(n\theta)$로 두면 작은 T에서 기각하는 검정을 쓴다. $P_\theta(T\le k)$는 θ가 증가함에 따라 감소하므로 $\sup_{\theta\ge 0.1}P_\theta(T\le k)=P_{0.1}(T\le k)$이다. **보충**

Poisson은 이산형이므로 기각확률을 정확히 α로 맞추려면 경계값에서 임의화할 수 있다(앞선 예제 7.1.4).

원문 대조·교정 기록 원본 101쪽에 제시된 두 예제의 가설 및 모형을 복원. 계산은 보충.

9. 검정의 비교 — 최강력(MP)과 전역최강력(UMP)

왜 최강력 검정을 찾는가?

모집단에 관한 가설이 참인지 항상 맞히는 검정은 표본만으로 구성하기 어렵다. 표본크기가 주어졌다면 제1종 오류와 제2종 오류를 일반적으로 동시에 최소화할 수 없다. 그래서 **제1종 오류 확률을 α 이하로 제한한 뒤 대립가설 아래 기각확률을 최대화**한다. **먼저 두 단순가설을 비교**

$H_0 : \theta = \theta_0$ 대 $H_1 : \theta = \theta_1$ 에서 검정함수 φ의 크기와 검정력은

$$E_{\theta_0}\varphi(X) \le \alpha, \qquad \pi_\varphi(\theta_1) = E_{\theta_1}\varphi(X).$$

같은 수준의 검정 중 $\pi_\varphi(\theta_1)$를 최대화하는 검정을 최강력(Most Powerful, MP) 검정이라 한다. **대립가설이 복합가설인 경우**

$H_1 : \theta \in \Theta_1$ 이면 모든 $\theta \in \Theta_1$ 에서 동시에 검정력을 최대화하는 검정이 있을 때 이를 전역최강력(UMP) 검정이라고 한다. 이러한 검정이 언제나 존재하는 것은 아니다. **원본 강의의 전개 순서**

단순가설의 MP 검정을 먼저 Neyman–Pearson 정리로 구성한 뒤, 그 기각역이 대립모수에 의존하지 않는 경우를 이용하여 단측 UMP 검정으로 확장한다.

원문 대조·교정 기록 원본의 '두 오류를 동시에 최소화할 수 없음'과 '유의수준을 고정하고 검정력을 최대화한다'는 동기 및 전개 순서를 복원.

가설검정 강의 필기 — 모수적 확률모형

원본 페이지에 적힌 내용:

$$\boxed{X \sim f(x;\theta).}$$

여기서 X는 관측 확률변수, θ는 모수, $f(\cdot;\theta)$는 모수 θ에 의해 지정되는 확률질량함수 또는 확률밀도함수이다.

정서/검산 메모 원본 103쪽에는 위 한 줄의 필기 외에 추가 수식이 없습니다. 인쇄 원문이 없는 공백은 채우지 않았습니다.

최강력 검정(Most Powerful Test)과 원본 이산확률표

[정의] 최강력 검정

단순가설 $H_0:\theta=\theta_0$ 대 $H_1:\theta=\theta_1$에 대하여 $E_{\theta_0}\varphi(X)\le\alpha$를 만족하는 모든 검정 중에서 $E_{\theta_1}\varphi(X)$를 최대화하는 검정 φ^*를 수준 α의 최강력 검정이라 한다. **[원본 예제] 유의수준 0.05의 최강력 검정**

x	1	2	3	4	5	6
$f(x;\theta_0)$	.01	.02	.02	.05	.10	.80
$f(x;\theta_1)$	.03	.05	.15	.10	.00	.67
$f_0(x)/f_1(x)$	.3333	.4000	.1333	.5000	∞	1.1940

Neyman–Pearson 정리에 의해 $f_1(x)/f_0(x)$가 큰 관측값을 먼저 기각역에 포함한다. 크기순서는 $x=3,1,2,4,6,5$이고,

$$\boxed{C=\{1,2,3\}},\quad P_{\theta_0}(C)=.01+.02+.02=.05.$$

대립가설 아래 검정력은

$$\boxed{P_{\theta_1}(C)=.03+.05+.15=.23.}$$

$f_1(5)=0$인 곳에서 $f_0/f_1=\infty$로 표기한다. 원본 표의 $x=6$ 가능도비 $0.80/0.67\approx1.1940$과 두 행의 합이 각각 1임을 확인했다.

원문 대조·교정 기록 원본에 인쇄된 6열 확률표를 완전히 복원하고, 크기 0.05의 MP 기각역과 검정력 0.23을 재계산.

유의수준 $\alpha = 0.05$의 기각역 비교 — 원본 필기표

앞쪽 인쇄 확률표에서 $x = 1, 2, 3, 4, 5, 6$의 H_0 아래 확률은 $.01, .02, .02, .05, .10, .80$, H_1 아래 확률은 $.03, .05, .15, .10, 0, .67$이다. **[원본의 여덟 기각역 비교]**

검정	기각역 C	$P_{\theta_0}(C)$	$P_{\theta_1}(C)$
C_1	$\{1\}$	0.01	0.03
C_2	$\{2\}$	0.02	0.05
C_3	$\{3\}$	0.02	0.15
C_4	$\{4\}$	0.05	0.10
C_5	$\{1, 2\}$	0.03	0.08
C_6	$\{1, 3\}$	0.03	0.18
C_7	$\{2, 3\}$	0.04	0.20
C_8	$\{1, 2, 3\}$	0.05	0.23

모든 기각역은 크기가 0.05 이하이며, 이 중에서 C_8의 검정력이 가장 크다. 또한 Neyman–Pearson 정리에서 $f_1(x)/f_0(x)$를 큰 순서대로 선택하면 $\{3, 1, 2\}$가 된다.

$$\boxed{C_{\text{MP}} = \{1, 2, 3\}, \quad \alpha = 0.05, \quad \text{검정력} = 0.23.}$$

원본 하단에는 관측값이 $x = 5$일 때 비기각역에 속한다는 설명이 있다. $x = 3$이면 H_0를 기각한다.

Date

정리 9.1.2 — 단순가설의 최강력 검정(Neyman–Pearson)

$H_0:\theta=\theta_0$ 대 $H_1:\theta=\theta_1$에서 가능도비를

$$LR(\mathbf{x};\theta_1,\theta_0)=\frac{f(\mathbf{x}\mid\theta_1)}{f(\mathbf{x}\mid\theta_0)}$$

라고 정의한다. 유의수준 α의 최강력 검정함수는

$$\varphi^*(\mathbf{x})=\begin{cases}1, & LR>k,\\ \gamma, & LR=k,\\ 0, & LR<k,\end{cases}\qquad 0\le\gamma\le 1,\quad E_{\theta_0}\varphi^*(X)=\alpha.$$

원본 예제 — $X\sim\text{Binomial}(8,p)$**,** $p_0=.3$**,** $p_1=.5$

$$H_0:p=.3,\quad H_1:p=.5,\qquad LR(x)=\frac{(.5/.3)^x(.5/.7)^{8-x}}{1}.$$

x	원본 $L(.3)$	원본 $L(.5)$	원본 LR	직접 재계산 LR
0	.0576	.0039	.0677	.0678
1	.1977	.0313	.1583	.1581
2	.2965	.1094	.3690	.3689
3	.2541	.2188	.8611	.8608
4	.1361	.2734	2.0088	2.0086
5	.0467	.2188	4.6852	4.6866
6	.0100	.1094	10.9400	10.9354
7	.0012	.0313	26.0833	25.5160
8	.0001	.0039	39.0000	59.5374

가능도비는 x에 대해 증가하므로 최강력 검정은 x가 클 때 기각한다. **검산 주의:** 원본 표의 LR은 반올림된 열을 나눈 값으로 추정되며, 특히 $x=8$의 39.0000은 정확한 이항확률의 비 59.5374와 다르다. 원본 값은 삭제하지 않고 재계산 값을 함께 기재한다.

원문 대조·교정 기록 원본 정리 9.1.2, 임의화 γ, 이항 $n=8$의 9행 표 전부 복원. 마지막 행 오류 직접 확인.

[원본 필기] 이항분포 단순가설의 NP 최강력 검정

앞쪽 예제의 설정은 $X=\sum_{i=1}^{8}X_i\sim\text{Bin}(8,p)$, $H_0:p=0.3$, $H_1:p=0.5$, $\alpha=0.05$이다. 원본의 비율 $L(p_1)/L(p_0)$을 따른다. **가능도비와 기각 방향**

$$\frac{L(p_1;x)}{L(p_0;x)}=\left(\frac{1-p_1}{1-p_0}\right)^{8}\left(\frac{p_1(1-p_0)}{p_0(1-p_1)}\right)^{x}.$$

$p_1>p_0$이면 두 번째 괄호가 1보다 크므로 x가 큰 경우 기각한다. 원본 필기의 기각함수는 다음과 같이 경계에서 임의화한다. **원본 수치와 독립 검산**

$$\begin{aligned}P_{.3}(X\ge 6)&=0.01129221,\\ P_{.3}(X=5)&=0.04667544,\\ P_{.3}(X\ge 5)&=0.05796765>0.05.\end{aligned}$$

따라서 $X\ge 6$에서 항상 기각하고 $X=5$에서는 확률 γ로 기각하여 정확한 크기 0.05를 맞춘다.

$$\boxed{\gamma=\frac{.05-.01129221}{.04667544}\approx 0.829297}.$$

$$\varphi^{*}(x)=\begin{cases}1, & x\ge 6,\\ 0.829297, & x=5,\\ 0, & x\le 4.\end{cases}$$

원문 대조·교정 기록 원본 108쪽의 $0.0113, 0.058, 0.829$ 계산을 복원해 검산했다. 통계량은 $X\sim\text{Bin}(8,p)$이며 $n=10$으로 바꾸지 않음.

[Proof 9.1.2] Neyman–Pearson 보조정리의 증명

원본 머리말: [pf $9.1.2$] 및 이어지는 [예제 $9.1.2$] Poisson. **정리의 비교 대상**

$H_0 : f = f_0$ 대 $H_1 : f = f_1$ 에서 검정함수 φ_* 를 가능도비 f_1/f_0 가 클수록 기각하도록 정하자. 즉 $f_1 > kf_0$ 에서 1, $f_1 < kf_0$ 에서 0, 경계에서는 필요에 따라 임의화한다. **핵심 부등식**

같은 크기 이하의 임의의 경쟁 검정 φ 에 대해

$$(\varphi_*(x) - \varphi(x))(f_1(x) - kf_0(x)) \geq 0$$

가 각 x 에서 성립한다. 이를 적분 또는 합하면

$$E_1\varphi_* - E_1\varphi \geq k(E_0\varphi_* - E_0\varphi) \geq 0.$$

따라서 φ_* 는 유의수준 α 에서 가장 강력한(MP) 검정이다. **다음 예제 안내**

원본 다음 장에서 Poisson(θ) 모형의 두 단순가설에 대해 이 보조정리를 적용한다.

원본 110쪽 손글씨 정서

Neyman–Pearson 보조정리의 검정함수

확률밀도(질량) $f_0(x)$와 $f_1(x)$에 대하여 두 단순가설 $H_0: f = f_0$, $H_1: f = f_1$을 검정한다. **가능도비 기반 검정함수**

$$\phi^*(x) = \begin{cases} 1, & f_1(x) > k f_0(x), \\ \gamma(x), & f_1(x) = k f_0(x), \\ 0, & f_1(x) < k f_0(x). \end{cases}$$

$0 \le \gamma(x) \le 1$을 이용하여 $\mathsf{E}_0\,\phi^*(X) = \alpha$가 되게 선택한다. **결론.** 같은 크기 이하인 어떤 다른 검정 ϕ에 대해서도

$$\boxed{\mathsf{E}_1\,\phi(X) \le \mathsf{E}_1\,\phi^*(X)}.$$

증명의 핵심 부호관계

$$[\phi^*(x) - \phi(x)]\,[f_1(x) - k f_0(x)] \ge 0$$

이므로 이를 적분하고 $\mathsf{E}_0\,\phi \le \mathsf{E}_0\,\phi^*$를 이용한다.

> **원본의 k와 경계값.** 우도비 f_1/f_0가 큰 영역을 먼저 기각역에 넣는다. $f_0(x) = 0$이면서 $f_1(x) > 0$인 곳에서는 당연히 기각한다.

[예제 9.1.2] 포아송 단순가설의 Neyman–Pearson 검정

원본: $X_1,\dots,X_n \overset{\text{iid}}{\sim} \text{Pois}(\theta)$, $H_0:\theta=0.1$ 대 $H_1:\theta=0.05$. 원본 필기의 수치 예시는 $n=100$이다. **가능도비의 단조성**

$$L(\theta;\mathbf{x})=\frac{\theta^{\sum_i x_i}e^{-n\theta}}{\prod_i x_i!},\qquad \frac{L(0.05;\mathbf{x})}{L(0.1;\mathbf{x})}=e^{0.05n}\left(\frac{1}{2}\right)^{\sum_i x_i}.$$

충분통계량은 $\boxed{T=\sum_{i=1}^{n}X_i\sim\text{Pois}(n\theta)}$이다. $T=n\sum_i X_i$가 아니다. 가능도비는 T가 증가할수록 감소하므로 좌측 기각이다. **[원본] $n=100$, $\alpha=.05$의 임의화 검정**

H_0 아래 $T\sim\text{Pois}(10)$이고

$$P_0(T\le 4)=0.0292526881,$$
$$P_0(T=5)=0.0378332748,$$
$$\gamma=\frac{0.05-0.0292526881}{0.0378332748}=\boxed{0.54838795}.$$
$$\varphi^*(t)=\begin{cases}1, & t\le 4,\\ \gamma, & t=5,\\ 0, & t\ge 6.\end{cases}$$

임의화하지 않고 $T\le 4$에서 기각하면 크기는 약 0.02925로 0.05보다 작다. 경계 임의화로 정확히 0.05가 된다.

원문 대조·교정 기록 원본 필기의 포아송 우도비, 좌측 꼬리, $n=100$, 경계 5를 보존. 필기 속 γ 근삿값은 원확률로 독립 검산.

예제 9.2.1 — 정규모형에서의 MP 검정

$X_1, \dots, X_n \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$, σ^2 는 알려졌다고 하자.

$$H_0 : \mu = \mu_0, \qquad H_1 : \mu = \mu_1 \ (\mu_1 > \mu_0).$$

우도비는

$$\frac{L(\mu_1)}{L(\mu_0)} = \exp\left[\frac{\mu_1 - \mu_0}{\sigma^2} \sum_{i} X_i - \frac{n(\mu_1^2 - \mu_0^2)}{2\sigma^2} \right]$$

이므로 $\sum_i X_i$, 또는 $\bar{X}$ 가 클수록 H_1 에 유리하다.

$$\boxed{C = \left\{ \bar{X} > \mu_0 + z_{1-\alpha} \frac{\sigma}{\sqrt{n}} \right\}.}$$

예제 9.2.2 — 지수모형에서의 MP 검정

$X_i \overset{\text{iid}}{\sim} \text{Exp}(\lambda)$ (발생률 λ)에서

$$\frac{L(\lambda_1)}{L(\lambda_0)} = \left(\frac{\lambda_1}{\lambda_0} \right)^{n} e^{-(\lambda_1 - \lambda_0) \sum_i X_i}.$$

따라서 $\lambda_1 > \lambda_0$ 이면 작은 $\sum_i X_i$ 에 대해 기각한다.

원본 113쪽 최강력검정 예제: 정규·지수모형

원본 왼쪽: 정규분포, 알려진 분산

$X_i \overset{\text{iid}}{\sim} N(\mu, \sigma_0^2)$, σ_0^2는 알려져 있고 $H_0 : \mu = \mu_0$ 대 $H_1 : \mu = \mu_1 > \mu_0$.

$$\frac{L(\mu_1)}{L(\mu_0)} = \exp\left[\frac{n(\mu_1 - \mu_0)}{\sigma_0^2}\left(\bar{X} - \frac{\mu_0 + \mu_1}{2}\right)\right].$$

이 비는 $\bar{X}$에 대해 증가하므로 Neyman–Pearson 검정의 기각역은 $\bar{X} > k^*$이며

$$P_{\mu_0}(\bar{X} > k^*) = \alpha \quad \Longrightarrow \quad \boxed{k^* = \mu_0 + z_{1-\alpha}\frac{\sigma_0}{\sqrt{n}}}.$$

원본 오른쪽: 지수분포, 척도(평균) θ

$X_i \overset{\text{iid}}{\sim}$ Exp(척도 θ), $f(x;\theta) = \theta^{-1}e^{-x/\theta}$, $x > 0$. $H_0 : \theta = \theta_0$ 대 $H_1 : \theta = \theta_1 < \theta_0$.

$$\frac{L(\theta_1)}{L(\theta_0)} = \left(\frac{\theta_0}{\theta_1}\right)^n \exp\left[\left(\frac{1}{\theta_0} - \frac{1}{\theta_1}\right)\sum_i X_i\right].$$

$\theta_1 < \theta_0$이므로 $\frac{1}{\theta_0} - \frac{1}{\theta_1} < 0$: **작은** $T = \sum X_i$**에서 기각**한다.

$$\frac{2T}{\theta_0} \sim \chi^2(2n) \quad (H_0), \qquad \boxed{C^* = \left\{\frac{2\sum_i X_i}{\theta_0} < \chi^2_{\alpha;2n}\right\}}.$$

[검산·보충] 종전 정서본은 척도 θ를 발생률 λ로 바꾸면서 원본의 대립가설 방향을 보존하지 못했다. 이번에는 척도모수와 좌측 기각역을 원본대로 복원했다.

전역 최강력검정(Uniformly Most Powerful Test; UMP)

[원본 정의] 복합가설의 UMP 검정

$H_0 : \theta \in \Theta_0$, $H_1 : \theta \in \Theta_1$에 대한 검정함수 φ^*가 유의수준 α의 UMP 검정이라는 것은

$$\sup_{\theta \in \Theta_0} E_\theta[\varphi^*(X)] \le \alpha$$

이고, 같은 수준의 모든 검정 φ와 모든 $\theta \in \Theta_1$에 대하여

$$\boxed{E_\theta[\varphi^*(X)] \ge E_\theta[\varphi(X)]}.$$

을 만족한다는 뜻이다. 즉 복합 대립가설 아래 모든 모수값에 대해 최강력인 하나의 검정이다. **원본의 UMP 유도 절차 — Neyman–Pearson 확장**

Step 1. $H_0 : \theta = \theta_0$ 대 $H_1 : \theta = \theta_1$의 단순가설을 잡고 Neyman–Pearson 정리로 α 수준의 최강력 검정 $\varphi^*_{\theta_1}$를 구한다.

Step 2. **그 기각역이 θ_1 선택에 의존하지 않는지** 확인한다. 모든 $\theta_1 \in \Theta_1$에 대해 같은 기각역이 최강력이면 공통 검정이 UMP이다.

Step 3. H_0가 복합이면 귀무가설 전체에 대해 크기가 α 이하인지 별도로 검산한다.

원본은 이러한 UMP 검정이 주로 하나의 모수에 대한 단측 검정에서 등장한다고 설명한다. 모든 양측검정에 UMP 검정이 존재하는 것은 아니다.

원문 대조·교정 기록 원본의 UMP 정의, 두 가지 최적 조건, NP 정리에서 시작하는 Step 1–2 구조와 단측검정 주의를 복원.

원본 115쪽 복합가설의 균일최강력(UMP) 검정: Step 1–3

복합귀무가설과 검정 크기

$H_0 : \theta \le \theta_0$ 대 $H_1 : \theta > \theta_0$에서 검정함수 $\phi(X) \in [0,1]$의 크기는

$$\sup_{\theta \le \theta_0} E_\theta\{\phi(X)\} \le \alpha.$$

크기 α의 다른 모든 검정 ψ에 대해 $E_\theta\phi^*(X) \ge E_\theta\psi(X)$가 모든 $\theta > \theta_0$에서 성립하면 ϕ^*를 UMP라 한다. **Step 1. 경계의 단순가설에 Neyman–Pearson 정리 적용**

고정된 $\theta_1 > \theta_0$에 대해 $H_0 : \theta = \theta_0$ 대 $H_1 : \theta = \theta_1$의 MP 검정을 구한다.

$$\phi^*(x) = \begin{cases} 1, & L(\theta_1;x)/L(\theta_0;x) > k, \\ \gamma, & L(\theta_1;x)/L(\theta_0;x) = k, \\ 0, & L(\theta_1;x)/L(\theta_0;x) < k. \end{cases}$$

Step 2. 모든 대립모수에서 공통의 기각역인지 확인

위 기각역 C^*의 형태가 θ_1에 의존하지 않고, H_0 경계의 제약을 만족한다면 모든 $\theta_1 > \theta_0$에 대한 MP 검정이 동일하므로 **UMP 후보**다. **Step 3. 크기 조건 검증**

$$\sup_{\theta \le \theta_0} E_\theta\phi^*(X) \le \alpha.$$

예를 들어 기각확률 $\pi_\phi(\theta) = E_\theta\phi^*(X)$가 θ에 대해 단조증가하면 $\sup_{\theta\le\theta_0}\pi_\phi(\theta) = \pi_\phi(\theta_0) = \alpha$이다. 따라서 UMP임이 성립한다.

[검산·보충] 원본 필기의 중심은 경계 단순가설의 MP 검정, 대립모수와 무관한 기각역, 귀무모수 전체에서의 크기 검증이라는 **3단계 UMP 절차**다.

9.2 UMP 검정과 단측가설의 예제

정규모형

$X_i \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$에서 σ^2를 알고

$$H_0 : \mu \le \mu_0, \qquad H_1 : \mu > \mu_0$$

이면 검정통계량 $\sqrt{n}(\bar{X} - \mu_0)/\sigma$에 대한 상측 기각역은 $\mu_1 > \mu_0$ 전체에서 같으며

$$\boxed{\bar{X} > \mu_0 + z_{1-\alpha}\frac{\sigma}{\sqrt{n}}}$$

일 때 기각하는 검정이 UMP이다. **지수모형**

$X_i \overset{\text{iid}}{\sim} \text{Exp}(\lambda)$에서 $H_0 : \lambda \le \lambda_0$ 대 $H_1 : \lambda > \lambda_0$를 검정하면 $\sum_i X_i$가 작을 때 기각한다. 경계 λ_0에서

$$2\lambda_0 \sum_{i=1}^{n} X_i \sim \chi^2(2n)$$

이므로 왼쪽 임계값을 사용할 수 있다.

원본 117쪽 손글씨 정서

검정력함수: 정규모평균의 오른쪽 꼬리 검정

$X_1, \dots, X_n \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$, σ는 알려진 값이다. $H_0 : \mu \le \mu_0$ 대 $H_1 : \mu > \mu_0$를 기각역

$$C = \left\{ \bar{X} > \mu_0 + z_{1-\alpha} \frac{\sigma}{\sqrt{n}} \right\}$$

으로 검정하자. 일반 모수 μ에서 $\bar{X} \sim N(\mu, \sigma^2/n)$이므로

$$\begin{aligned} \pi(\mu) &= \mathsf{P}_\mu(X \in C) = \mathsf{P}_\mu\left(\frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} > \frac{\sqrt{n}(\mu_0 - \mu)}{\sigma} + z_{1-\alpha} \right) \\ &= \boxed{1 - \Phi\left(z_{1-\alpha} - \frac{\sqrt{n}(\mu - \mu_0)}{\sigma} \right)}. \end{aligned}$$

검정력 곡선의 특징

- $\pi(\mu_0) = \alpha$이고 $\mu > \mu_0$이면 $\pi(\mu) > \alpha$이다.
- μ가 커질수록 $\pi(\mu)$는 증가한다.
- n이 증가하면 고정된 $\mu > \mu_0$에서 검정력이 증가한다.

> 원본 그래프의 가로축은 참모수 μ, 세로축은 $\pi(\mu)$이다. H_0가 복합가설이므로 크기는 $\sup_{\mu \le \mu_0} \pi(\mu) = \pi(\mu_0) = \alpha$로 계산한다.

정규모평균 UMP 검정 — 원본 전체 검정력표 및 곡선

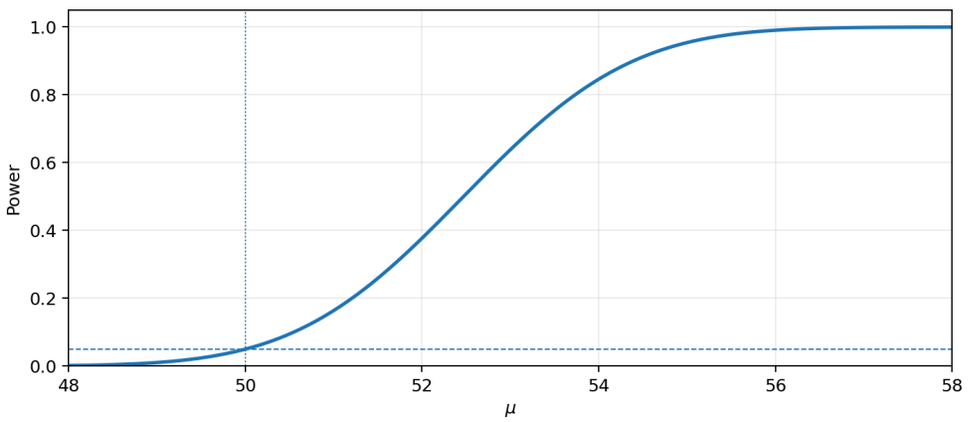
$X_1, \dots, X_{16} \overset{\text{iid}}{\sim} N(\mu, 36)$, $H_0 : \mu \le 50$ 대 $H_1 : \mu > 50$, $\alpha = 0.05$이다. $\overline{X}$의 표준편차는 $6/\sqrt{16} = 1.5$다.

$$\boxed{C = \{\overline{X} > 52.47\}}, \qquad \boxed{\gamma(\mu) = P_\mu(\overline{X} > 52.47) = \Phi\left(\frac{2(\mu - 52.47)}{3}\right)}.$$

원본 표 21개 항목 — 독립 검산값(소수 넷째 자리)

μ	z	$\gamma(\mu)$	μ	z	$\gamma(\mu)$
48.0	-2.98	0.0014	53.5	0.69	0.7539
48.5	-2.65	0.0041	54.0	1.02	0.8461
49.0	-2.31	0.0104	54.5	1.35	0.9120
49.5	-1.98	0.0239	55.0	1.69	0.9542
50.0	-1.65	0.0498	55.5	2.02	0.9783
50.5	-1.31	0.0945	56.0	2.35	0.9907
51.0	-0.98	0.1635	56.5	2.69	0.9964
51.5	-0.65	0.2589	57.0	3.02	0.9987
52.0	-0.31	0.3770	57.5	3.35	0.9996
52.5	0.02	0.5080	58.0	3.69	0.9999
53.0	0.35	0.6381			

$\gamma(50) \approx 0.05$이며 $\gamma(54) \approx 0.8461$, $\gamma(56) \approx 0.9906$이다. 오른쪽 대립가설에서 검정력은 μ의 증가함수다. **원본 검정력 그래프 — 활자·벡터로 새로 그림**



원문 대조·교정 기록 원본 118쪽의 21행 표와 곡선을 복원. 원본 인쇄 표는 검정력을 소수 둘째 자리로 반올림하며 이 표는 계산 정확성을 위해 넷째 자리까지 표시.

정규모평균 단측 UMP 검정 — 검정력의 직접 계산

원본 예제는 $X_1, \dots, X_{16} \overset{\text{iid}}{\sim} N(\mu, 36)$와 $H_0 : \mu \le 50$ 대 $H_1 : \mu > 50$의 검정이다. **기각함수**

$\overline{X}$의 표준편차가 $6/\sqrt{16} = 1.5$이므로 수준 0.05의 비임의화 UMP 검정은

$$\varphi^*(\mathbf{x}) = \begin{cases} 1, & \bar{x} > 50 + 1.645 \times 1.5 \approx 52.47, \\ 0, & \text{그 밖의 경우.} \end{cases}$$

검정력함수

$$\gamma^*(\mu) = P_\mu(\overline{X} > 52.47) = 1 - \Phi\left(\frac{52.47 - \mu}{1.5}\right) = \Phi\left(\frac{2(\mu - 52.47)}{3}\right).$$

원본 필기의 세 검산값

μ	49.5	52	54
검정력 $\gamma^*(\mu)$	0.0239	0.3770	0.8461

원본의 손글씨에서는 각각 약 $0.02, 0.38, 0.85$로 적혀 있다. 경계모수 $\mu = 50$에서는 검정력이 약 $0.0498 \approx 0.05$이다. μ가 대립방향으로 커지면 기각확률이 증가한다.

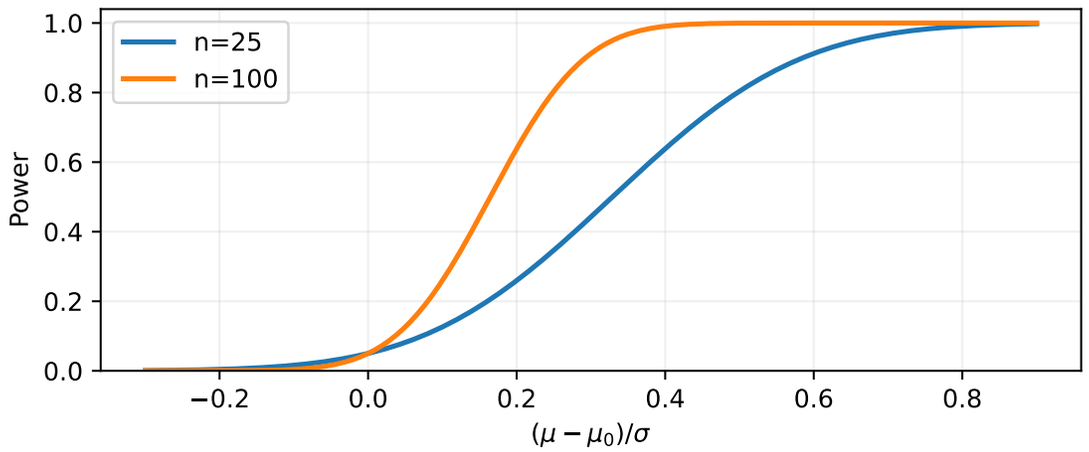
예제 9.2.4 및 예제 9.2.2(계속)

예제 9.2.4 — 지수모형의 단측 UMP 검정

원본 인쇄 가설: $H_0 : \theta \geq \theta_0$ 대 $H_1 : \theta < \theta_0$ (원문의 θ는 지수모형의 모수). 주의: 지수분포의 발생률인지 척도인지에 따라 기각 부등호가 반대가 된다. 발생률 모수화 $f(x;\theta) = \theta e^{-\theta x}$를 택하면 $H_1 : \theta < \theta_0$ 아래에서는 $\sum X_i$가 클수록 기각하고, 척도 모수화에서는 반대이다. 원본의 모수화에 맞춰 해석해야 한다. **예제 9.2.2(계속) — 표본크기별 검정력 비교**

$X_i \sim N(\mu, \sigma_0^2)$, $H_0 : \mu \leq \mu_0$ 대 $H_1 : \mu > \mu_0$에서 상측 유의수준 α 검정의 검정력은

$$\boxed{\pi_n(\mu) = 1 - \Phi\left(z_{1-\alpha} - \frac{\sqrt{n}(\mu - \mu_0)}{\sigma_0} \right).}$$



원본 그림처럼 $n = 100$의 검정력 곡선이 $n = 25$보다 대립가설 영역에서 빨리 1에 가까워진다. $\mu = \mu_0$에서 검정력은 α이다.

원문 대조·교정 기록 원본의 지수분포 예제와 $n = 25, 100$ 검정력 비교그림을 동시에 복원. 곡선은 공식을 이용해 다시 그림.

원본 121 쪽 [예제 9.2.4] 지수분포에서단측 UMP 검정

원본가설: 척도 (scale) 모수 θ

$X_1, \dots, X_n \overset{\text{iid}}{\sim} \text{Exp}(\theta)$ 이고

$$f(x;\theta) = \frac{1}{\theta} e^{-x/\theta} \mathbf{1}_{(0,\infty)}(x), \quad \theta > 0.$$

$$H_0 : \theta \geq \theta_0 \qquad \text{대} \qquad H_1 : \theta < \theta_0.$$

합 $T = \sum_i X_i$ 는 Gamma(n, θ) 를따른다.

Step 1. 경계 $\theta = \theta_0$ 의최강력검정

$\theta_1 < \theta_0$ 를고정하면가능도비

$$\frac{L(\theta_1)}{L(\theta_0)} = \left(\frac{\theta_0}{\theta_1}\right)^n \exp\left[-T\left(\frac{1}{\theta_1} - \frac{1}{\theta_0}\right)\right]$$

는 T 에대해엄격히감소한다. 그러므로 T **가작을때기각**한다.

Step 2. 유의수준및기각역

경계에서 $2T/\theta_0 \sim \chi^2_{2n}$ 이므로

$$\boxed{\varphi^*(\boldsymbol{x}) = \mathbf{1}\left\{T \leq \frac{\theta_0}{2}\chi^2_{2n,\alpha}\right\}.}$$

여기서 $\chi^2_{2n,\alpha}$ 는 **아래꼬리누적확률** α **분위수**이다. 이검정의크기는 α 이다.

Step 3. 검정력과 UMP 판정

$$\pi(\theta) = P_\theta\left(\frac{2T}{\theta} \leq \frac{\theta_0}{\theta}\chi^2_{2n,\alpha}\right) = F_{\chi^2_{2n}}\left(\frac{\theta_0}{\theta}\chi^2_{2n,\alpha}\right).$$

θ 가작을수록검정력이증가한다. 기각역이어떤 $\theta_1 < \theta_0$ 를택해도동일하므로단측복합대립가설에대해 UMP 이다.

검산·보충: 원본의 $H_0 : \theta \geq \theta_0$ 와 $H_1 : \theta < \theta_0$ 및 척도모수를그대로복원했다. 기존파일의발생률모수·우측검정은이예제에해당하지 않는다.

예제 9.2.2(계속) — 표본크기에 따른 검정력

원본 필기: $X_1, \ldots, X_n \sim N(\mu, \sigma^2)$, $H_0 : \mu \le \mu_0$ 대 $H_1 : \mu > \mu_0$. **검정함수와 기각역**

$$\varphi(\mathbf{x}) = \begin{cases} 1, & \overline{x} > \mu_0 + \dfrac{\sigma z_{1-\alpha}}{\sqrt{n}}, \\ 0, & \text{otherwise.} \end{cases}$$

검정력 계산

$$\begin{aligned} \pi_n(\mu) &= P_\mu\left(\overline{X} > \mu_0 + \frac{\sigma z_{1-\alpha}}{\sqrt{n}}\right) \\ &= 1 - \Phi\left(z_{1-\alpha} - \frac{\sqrt{n}(\mu - \mu_0)}{\sigma}\right). \end{aligned}$$

표본크기의 효과

$\mu > \mu_0$가 고정된 대립가설에서 n이 증가하면 $\sqrt{n}(\mu - \mu_0)/\sigma$가 커지고 $\pi_n(\mu)$는 1에 가까워진다.

표준화된 효과 $(\mu - \mu_0)/\sigma$	$n = 25$	$n = 100$
0	0.050	0.050
0.2	0.260	0.639
0.4	0.639	0.991

원문 대조·교정 기록 원본 122쪽의 검정함수와 표본크기에 따른 검정력 비교를 복원. 표의 값은 $\alpha = 0.05$에서 보충 계산.

[정리 9.2.1] 단일모수 지수족과 UMP 단측검정

원본의 확률모형은

$$f(x;\theta)=\exp\{g(\theta)T(x)-B(\theta)+S(x)\},\qquad \theta\in\Theta$$

의 단일모수 지수족이고, $g(\theta)$가 θ에 관해 **증가함수**라고 가정한다. **귀무가설과 대립가설**

$H_0:\theta\le\theta_0$ 대 $H_1:\theta>\theta_0$에 대해서 표본합 $W=\sum_{i=1}^{n}T(X_i)$는 모수의 증가에 따라 큰 관측값이 더 유리해지는 단조가능도비 통계량이다. **원본의 UMP 검정함수**

$$\boxed{\varphi(\mathbf{x})=\begin{cases}1, & W>c,\\ \gamma, & W=c,\\ 0, & W<c.\end{cases}}$$

c,γ를 $E_{\theta_0}\varphi=\alpha$가 되도록 정할 수 있으면 수준 α의 UMP 검정이다. 연속형 분포에서는 일반적으로 경계 $W=c$의 확률이 0이므로 임의화가 필요하지 않다. **보충: 가능도비 단조성 검산**

$\theta_1>\theta_0$이면

$$\frac{L(\theta_1)}{L(\theta_0)}=\exp\{[g(\theta_1)-g(\theta_0)]W-n[B(\theta_1)-B(\theta_0)]\}$$

는 W의 증가함수다. Neyman–Pearson 정리에서 공통 기각역 $W>c$를 얻으므로 UMP임을 확인한다.

원문 대조·교정 기록 원본의 단일모수 지수족 명시형식, g 증가 조건, 검정함수 세 구간, NP 정리로의 연결을 복원.

예제 9.2.3 — Poisson, Normal, Exponential

원문 인쇄 제목: “[예제 9.2.3] Poisson, Normal, Exponential”. 다음은 단측 UMP 검정의 보충 정리다. **1. Poisson(θ) 표본**

$T = \sum_i X_i \sim$ Poisson$(n\theta)$. $H_0 : \theta \le \theta_0$ 대 $H_1 : \theta > \theta_0$에서는 T가 클수록 우도가 대립가설에 유리하며, T의 상측꼬리 기각역이 UMP이다. 반대쪽 단측검정은 하측꼬리를 사용한다. **2. Normal(μ, σ^2) 표본 (σ^2 알려짐)**

$H_0 : \mu \le \mu_0$ 대 $H_1 : \mu > \mu_0$에서 표본평균 $\overline{X}$가 크면 기각한다.

$$C_\alpha = \left\{ \frac{\sqrt{n}(\overline{X} - \mu_0)}{\sigma} \ge z_{1-\alpha} \right\}.$$

3. Exponential(λ) 표본 (λ: 발생률)

$L(\lambda; \mathbf{x}) = \lambda^n e^{-\lambda \sum x_i}$ 이다. $H_0 : \lambda \le \lambda_0$ 대 $H_1 : \lambda > \lambda_0$에서는 $T = \sum_i X_i$가 작을수록 기각한다. **요점**

이 모형들은 표본합에 대한 단조가능도비(MLR)를 갖는다. 단측 가설에서는 Neyman–Pearson 보조정리 및 Karlin–Rubin 유형의 논리로 UMP 검정을 구성할 수 있다.

예제 9.2.5, 9.2.6 — 정규모집단의 양측검정

원문 주제: 양측 대립가설에서 UMP 검정의 부존재(Nonexistence of UMP test).

$$X_1, \ldots, X_n \overset{\text{iid}}{\sim} N(\mu, 1), \qquad H_0 : \mu = \mu_0 \quad \text{vs} \quad H_1 : \mu \neq \mu_0.$$

왜 UMP가 일반적으로 존재하지 않는가?

$\mu_1 > \mu_0$인 단순 대립가설에 대한 가장 강력한 유의수준 α 검정은 $\overline{X}$의 상측꼬리를 기각한다. 반면 $\mu_2 < \mu_0$인 단순 대립가설에 대한 가장 강력한 검정은 하측꼬리를 기각한다. 두 대립가설 모두에 동시에 가장 강력한 동일한 비임의화 검정은 존재할 수 없다. **하지만 일반적인 양측검정은 가능하다**

$$Z = \sqrt{n}(\overline{X} - \mu_0), \qquad C_\alpha = \{|Z| > z_{1-\alpha/2}\}.$$

이는 수준 α의 양측 z검정이며, 이 정규모형에서는 불편검정 부류에서 UMPU인 검정이지만, **모든 검정 중 UMP는 아니다**.

원문 대조·교정 기록 원본 125쪽의 두 예제 번호, 가설 $\mu \neq \mu_0$, UMP 부존재를 유지. 증명은 보충.

원본 126 쪽 [예제 9.2.5, 9.2.6] 양측검정에서 UMP 의부존재

원본가설: 정규분포의양측모평균검정

$X_1, \ldots, X_n \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$ 이고 σ 는주어졌다고하자.

$$H_0 : \mu = \mu_0 \qquad \text{대} \qquad H_1 : \mu \neq \mu_0.$$

양측대립가설은 $\mu > \mu_0$ 와 $\mu < \mu_0$ 를모두포함한다.

서로다른방향의최강력검정

우측대립가설 $\mu > \mu_0$ 에는

$$\varphi_R(\boldsymbol{x}) = \mathbf{1}\left\{ \bar{X} > \mu_0 + z_{1-\alpha} \frac{\sigma}{\sqrt{n}} \right\}.$$

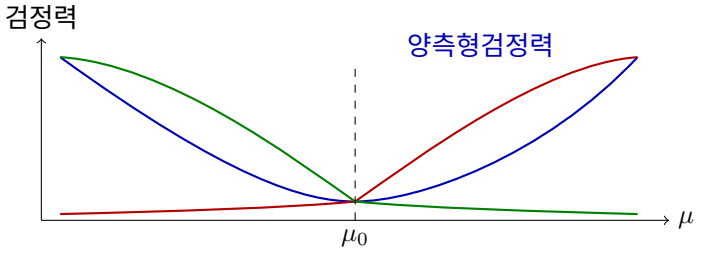
좌측대립가설 $\mu < \mu_0$ 에는

$$\varphi_L(\boldsymbol{x}) = \mathbf{1}\left\{ \bar{X} < \mu_0 - z_{1-\alpha} \frac{\sigma}{\sqrt{n}} \right\}.$$

Neyman–Pearson 보조정리에따라각각의단측대립가설에서는이와같은방향이최강력이다. 그러나이두최강력기각역은서로같지않다.

결론: 일반적으로양측 UMP 검정이존재하지않음

동일한크기 α 의검정하나가 $\mu > \mu_0$ 와 $\mu < \mu_0$ 양쪽에서 **동시에**모든다른검정보다높은검정력을가질수는없다.



검산·보충: 그림은두단측기각역의검정력방향을설명하는개념도이며, 원본의요점은 양측대립가설전체에대한 UMP 검정의부존재이다.

7.2 최대가능도비 검정법(Likelihood Ratio Test)

원본 도입: 양측가설이나 장애모수(nuisance parameter)가 있는 복합가설에서는 단순 Neyman–Pearson 최강력검정만으로 해결하기 어렵다. 그러므로 제한모형과 전체모형의 최대가능도를 비교한다. **귀무가설과 대립가설**

$$H_0 : \theta \in \Omega_0, \qquad H_1 : \theta \in \Omega_1, \qquad \Omega_0 \cap \Omega_1 = \varnothing, \quad \Omega_0 \cup \Omega_1 = \Omega.$$

$\widehat{\theta}$는 Ω에서의 MLE, $\widehat{\theta}_0$는 Ω_0에서의 제한 MLE이다. **원본의 정의 — 큰 값에서 기각하도록 정의한 비**

$$\boxed{\lambda(\mathbf{x}) = \frac{\max_{\theta\in\Omega} L(\theta;\mathbf{x})}{\max_{\theta\in\Omega_0} L(\theta;\mathbf{x})} = \frac{L(\widehat{\theta})}{L(\widehat{\theta}_0)} \geq 1.}$$

$$C_\alpha = \{\mathbf{x} : \lambda(\mathbf{x}) \geq c_\alpha\}, \qquad 2\{\ell(\widehat{\theta}) - \ell(\widehat{\theta}_0)\} \geq k_\alpha.$$

유의수준 조건

$$\boxed{\sup_{\theta\in\Omega_0} P_\theta(\mathbf{X} \in C_\alpha) \leq \alpha.}$$

원본의 표기는 상한을 α로 조정하는 방식이다. 표본공간이 이산이면 임의화 없이 정확한 등호를 얻지 못할 수 있다.

원문 대조·교정 기록 원본은 “전체최대/제한최대”의 비를 사용하며 큰 값에서 기각. 반대 역수 관례를 섞지 않도록 복원.

원본 128쪽 손글씨 정서

가능도비 검정(Likelihood Ratio Test, LRT)

복합가설 $H_0 : \theta \in \Theta_0$ 대 $H_1 : \theta \in \Theta \setminus \Theta_0$를 검정한다. 전체 모수공간 Θ에서의 최대가능도와 귀무가설 공간 Θ_0에서의 최대가능도를 비교한다.

$$\boxed{\Lambda(x) = \frac{\sup_{\theta \in \Theta_0} L(\theta; x)}{\sup_{\theta \in \Theta} L(\theta; x)}} \quad (0 \le \Lambda \le 1).$$

기각규칙: $\Lambda(x)$가 작으면 귀무가설에서 자료를 설명하기 상대적으로 어려우므로 H_0를 기각한다. 동등하게 $-2\log\Lambda(x)$가 클 때 기각한다. **계산 순서**

1. Θ와 Θ_0를 분명히 쓴다.
2. 제한 없는 최대가능도추정량 $\hat\theta$를 구한다.
3. 제한된 최대가능도추정량 $\hat\theta_0$를 구한다.
4. $\Lambda = L(\hat\theta_0)/L(\hat\theta)$를 계산하고 기각역을 정한다.

> 원본의 그림은 귀무모형의 최댓값과 전체모형의 최댓값 비교를 보여 준다. 일부 교재는 $1/\Lambda$를 가능도비로 정의하므로 그 경우 부등호 방향이 반대다.

가능도비의 성질 — 원본 정의에 맞춘 복원

원본이 사용한 가능도비는 전체 모수공간에서 최대화한 가능도를 분자로 두므로

$$\boxed{\lambda(\mathbf{x}) = \frac{\sup_{\theta\in\Omega} L(\theta;\mathbf{x})}{\sup_{\theta\in\Omega_0} L(\theta;\mathbf{x})} \geq 1.}$$

$\lambda(\mathbf{x}) \approx 1$인 경우

귀무가설 아래의 최대가능도와 전체 모수공간에서의 최대가능도가 비슷하다. 전체 MLE와 제한 MLE도 자료를 거의 비슷하게 설명하므로 H_0를 기각하기 어렵다. **$\lambda(\mathbf{x}) \gg 1$인 경우**

귀무가설 아래의 최대가능도가 전체 최대가능도보다 매우 작다. 전체 모형은 관측자료를 훨씬 잘 설명하므로 H_0를 기각할 증거가 강하다.

$$\boxed{C_\alpha = \{\mathbf{x} : \lambda(\mathbf{x}) \geq c_\alpha\}}, \qquad 2\log\lambda = 2\{\ell(\widehat{\theta}) - \ell(\widehat{\theta}_0)\}.$$

다음 예제 7.2.1 연결

$X_i \overset{\text{iid}}{\sim} N(\mu,\sigma^2)$에서 모평균 가설 $H_0 : \mu = \mu_0$ 대 $H_1 : \mu \neq \mu_0$를 검정한다. σ^2를 아는 경우와 모르는 경우의 제한·전체 MLE를 구분한다.

원문 대조·교정 기록 이전 정서본은 $\Lambda \leq 1$ 역수 관례였으나, 원본 127·129쪽은 $\lambda \geq 1$ 정의와 큰 값에서 기각함. 원문 표기대로 통일.

원본 130 쪽 [예제 7.2.1] 정규모형의양측가능도비검정

$$X_1, \ldots, X_n \overset{\text{iid}}{\sim} N(\mu, \sigma^2), \qquad H_0 : \mu = \mu_0 \text{ vs. } H_1 : \mu \neq \mu_0.$$

1. $\sigma^2 = \sigma_0^2$ 가알려진경우

$$L(\mu; \boldsymbol{x}) = \left(\frac{1}{\sqrt{2\pi}\sigma_0}\right)^n \exp\left[-\frac{1}{2\sigma_0^2}\sum_i (x_i - \mu)^2\right].$$

대립가설을포함한전체모형에서 $\hat{\mu} = \bar{x}$, H_0 아래서는 $\mu = \mu_0$ 이므로원본의 **큰값일수록기각하는**가능도비는

$$\boxed{\Lambda(\boldsymbol{x}) = \frac{L(\bar{x})}{L(\mu_0)} = \exp\left(\frac{n(\bar{x} - \mu_0)^2}{2\sigma_0^2}\right).}$$

$$\Lambda > c \quad \Longleftrightarrow \quad \left|\frac{\sqrt{n}(\bar{X} - \mu_0)}{\sigma_0}\right| > z_{1-\alpha/2}.$$

2. σ^2 가알려져있지않은경우

전체모형의 $\hat{\mu} = \bar{x}$, $\hat{\sigma}^2 = n^{-1}\sum_i (x_i - \bar{x})^2$ 이고, 귀무가설아래서는 $\hat{\sigma}_0^2 = n^{-1}\sum_i (x_i - \mu_0)^2$ 이다.

$$\Lambda = \frac{L(\hat{\mu}, \hat{\sigma}^2)}{L(\mu_0, \hat{\sigma}_0^2)} = \left(\frac{\sum_i (x_i - \mu_0)^2}{\sum_i (x_i - \bar{x})^2}\right)^{n/2}.$$

분산분해 $\sum_i (x_i - \mu_0)^2 = \sum_i (x_i - \bar{x})^2 + n(\bar{x} - \mu_0)^2$ 을사용하면

$$\boxed{\Lambda = \left(1 + \frac{t^2}{n-1}\right)^{n/2}}, \qquad t = \frac{\sqrt{n}(\bar{X} - \mu_0)}{S}, \quad S^2 = \frac{\sum_i (X_i - \bar{X})^2}{n-1}.$$

검산·보충: 따라서 Λ 가큰경우에기각하는검정은양측 t_{n-1} 검정과동치이다. 가능도비의정의는원본과같이전체최대가능도/제약최대가능도를사용했다.

원본 131쪽 손글씨 정서

정규모평균의 t검정과 가능도비 검정 연결

$X_i \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$에서 μ, σ^2가 미지이고 $H_0 : \mu = \mu_0$를 검정하자. 제약 없는 최대가능도추정량은

$$\hat{\mu} = \bar{X}, \qquad \hat{\sigma}^2 = \frac{1}{n}\sum_i (X_i - \bar{X})^2.$$

귀무가설 아래에서는 $\mu = \mu_0$로 고정하므로

$$\hat{\sigma}_0^2 = \frac{1}{n}\sum_i (X_i - \mu_0)^2 = \hat{\sigma}^2 + (\bar{X} - \mu_0)^2.$$

가능도비는

$$\Lambda = \left(\frac{\hat{\sigma}^2}{\hat{\sigma}_0^2}\right)^{n/2} = \left[1 + \frac{n(\bar{X} - \mu_0)^2}{\sum_i (X_i - \bar{X})^2}\right]^{-n/2}.$$

$T = \sqrt{n}(\bar{X} - \mu_0)/S$라 두면

$$\Lambda = \left(1 + \frac{T^2}{n-1}\right)^{-n/2}.$$

따라서 Λ가 작다는 것은 $|T|$가 크다는 뜻이다. H_0 아래에서 $T \sim t(n-1)$이므로 유의수준 α의 양측 LRT는

$$\boxed{|T| > t_{1-\alpha/2,\,n-1} \text{ 이면 기각}}.$$

> 이는 유한 표본에서 정확한 결과로, 큰 표본에서의 Wilks 근사와 구분한다.

예제 7.2.2 — Normal LRT: One-sided test

원본 가설: $H_0 : \mu \le \mu_0$ 대 $H_1 : \mu > \mu_0$. $X_1, \dots, X_n \sim N(\mu, \sigma^2)$, σ^2 는 알려진 것으로 두고 가능도비 검정을 유도한다. **전체 및 제한 최대가능도추정량**

$$\widehat{\mu} = \overline{X}, \qquad \widehat{\mu}_0 = \min(\overline{X}, \mu_0).$$

따라서

$$\Lambda(\mathbf{x}) = \frac{L(\widehat{\mu}_0; \mathbf{x})}{L(\widehat{\mu}; \mathbf{x})} = \begin{cases} 1, & \overline{X} \le \mu_0, \\ \exp\{-n(\overline{X} - \mu_0)^2/(2\sigma^2)\}, & \overline{X} > \mu_0. \end{cases}$$

기각역

가능도비가 작은 때 기각하므로 $\overline{X}$ 가 클 때 기각한다.

$$\boxed{C_\alpha = \left\{ \frac{\sqrt{n}(\overline{X} - \mu_0)}{\sigma} > z_{1-\alpha} \right\}.}$$

합성귀무가설에서 기각확률의 최댓값은 경계 $\mu = \mu_0$ 에서 달성한다.

원본 133쪽 손글씨 정서

정규모평균의 단측 LRT: 제약된 최대가능도추정량

$X_i \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$, σ^2는 알려져 있다. $H_0 : \mu \le \mu_0$ 대 $H_1 : \mu > \mu_0$를 검정한다. **전체 최대가능도추정량** $\hat{\mu} = \bar{X}$. 귀무모수집합에서의 최대가능도추정량은

$$\hat{\mu}_0 = \begin{cases} \bar{X}, & \bar{X} \le \mu_0, \\ \mu_0, & \bar{X} > \mu_0. \end{cases}$$

따라서

$$\Lambda = \frac{L(\hat{\mu}_0)}{L(\bar{X})} = \begin{cases} 1, & \bar{X} \le \mu_0, \\ \exp[-n(\bar{X}-\mu_0)^2/(2\sigma^2)], & \bar{X} > \mu_0. \end{cases}$$

Λ가 작은 영역은 $\bar{X}$가 큰 영역이다. 유의수준 α를 적용하면

$$\boxed{\bar{X} > \mu_0 + \frac{\sigma}{\sqrt{n}} z_{1-\alpha}}.$$

원본의 분기형 Λ 그래프는 $\bar{X} \le \mu_0$에서 값이 1이고, $\bar{X} > \mu_0$에서는 $\bar{X}$가 증가할수록 감소한다. 제약이 있는 최대가능도추정량은 단순히 $\bar{X}$를 무조건 넣어서는 안 된다.

원본 134 쪽 지수분포의양측가능도비검정 (원본복원)

원본: 척도모수지수모형및양측가설

$$X_1,\dots,X_n \overset{\text{iid}}{\sim} \text{Exp}(\theta), \quad f(x;\theta)=\theta^{-1}e^{-x/\theta},\ x>0,$$

$$H_0:\theta=\theta_0 \qquad \text{대} \qquad H_1:\theta\neq\theta_0.$$

가능도와 MLE 는

$$L(\theta)=\theta^{-n}e^{-n\bar{X}/\theta}, \qquad \widehat{\theta}=\bar{X}.$$

원본의가능도비 $\Lambda = L(\widehat{\theta})/L(\theta_0)$

$$\Lambda=\left(\frac{\theta_0}{\bar{X}}\right)^{n}\exp\left(n\frac{\bar{X}}{\theta_0}-n\right).$$

$W=\bar{X}/\theta_0$ 라고놓으면

$$\boxed{\Lambda=\{We^{1-W}\}^{-n}.}$$

양측기각역과분포

$h(w)=we^{1-w}$ 는 $w=1$ 에서최대이고 $w\to 0$ 또는 $w\to\infty$ 에서 0 으로간다. 따라서 Λ **가클때기각**하며, $W<a$ 또는 $W>b$ 꼴의 **양측기각역**이생긴다.

$$\boxed{\frac{2\sum_i X_i}{\theta_0}=2nW \overset{H_0}{\sim} \chi^2_{2n}.}$$

크기가 α 인 정확한 LRT 의 $a<1<b$ 는

$$P_{\theta_0}(W\le a)+P_{\theta_0}(W\ge b)=\alpha, \qquad ae^{1-a}=be^{1-b}$$

로결정된다. 두꼬리확률이반드시각각 $\alpha/2$ 가되는것은아니다.

검산·보충: 원본은명백히 $H_1:\theta\neq\theta_0$ 인양측문제이며척도 θ 의 MLE 가 $\bar{X}$ 이다. 발생률모수및단측검정으로바뀌었던이전정서본은 이페이지의원문과일치하지않는다.

원본 135쪽 베르누이 모형의 양측 가능도비: 원본의 역수 방향

$X_i \overset{\text{iid}}{\sim} \text{Bernoulli}(p)$, $H_0 : p = p_0$ 대 $H_1 : p \neq p_0$, $T = \sum_i X_i$ 및 $\hat{p} = T/n = \bar{X}$.

$$L(p) = p^T(1-p)^{n-T}, \qquad \sup_{p\in(0,1)} L(p) = \hat{p}^T(1-\hat{p})^{n-T}.$$

원본 정의: 전체 최대가능도 / 제한 최대가능도

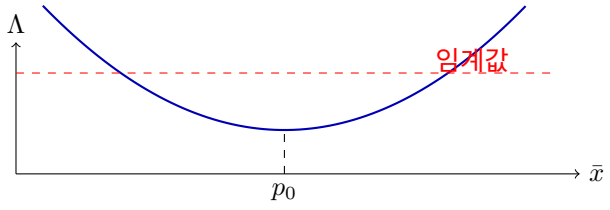
$$\boxed{\Lambda(\bar{x}) = \frac{L(\hat{p})}{L(p_0)} = \left(\frac{\bar{x}}{p_0}\right)^{n\bar{x}} \left(\frac{1-\bar{x}}{1-p_0}\right)^{n(1-\bar{x})} \geq 1.}$$

$g(y) = \Lambda(y)$로 두면

$$\log g(y) = ny \log \frac{y}{p_0} + n(1-y) \log \frac{1-y}{1-p_0},$$

$$\frac{\mathrm{d}}{\mathrm{d}y} \log g(y) = n \log \frac{y(1-p_0)}{p_0(1-y)} \begin{cases} < 0, & y < p_0, \\ = 0, & y = p_0, \\ > 0, & y > p_0. \end{cases}$$

따라서 Λ는 p_0에서 최소값 1을 갖는 U자형 함수이며, $\bar{X}$ **가 작거나 클 때 기각**한다.



[검산·보충] 이전 정서본에 적힌 $L(p_0)/L(\hat{p})$는 원본 Λ의 역수다. 같은 검정이라도 역수 정의라면 기각 부등식이 반대다. 원본처럼 $\Lambda \geq c$로 표시했다.

양측 복합가설에서의 LRT — 큰 표본 검정

원문 항목: (1) 정규모집단 분산의 양측검정, (2) Binomial 비율의 양측검정, (3) 점근분포의 필요성. **정규모형의 분산 검정**

$X_i \sim N(\mu, \sigma^2)$이고 $H_0 : \sigma^2 = \sigma_0^2$ 대 $H_1 : \sigma^2 \neq \sigma_0^2$를 고려한다. μ가 미지이면 $\widehat{\mu} = \overline{X}$이며,

$$\widehat{\sigma}^2 = \frac{1}{n}\sum_i (X_i - \overline{X})^2$$

가 비제약 MLE이다. 제한 MLE에서는 $\sigma^2 = \sigma_0^2$로 놓고 가능도를 최대화한다. **Binomial 모형의 양측검정**

$X \sim \mathrm{Bin}(n, p)$, $H_0 : p = p_0$ 대 $H_1 : p \neq p_0$에서

$$\widehat{p} = X/n, \quad \Lambda = \frac{p_0^X (1-p_0)^{n-X}}{\widehat{p}^{\,X}(1-\widehat{p})^{n-X}}.$$

$X = 0, n$에서의 0^0은 연속극한에 따른 관례로 해석한다. **점근성의 의미**

검정통계량이 복잡하므로 정칙조건에서 $-2\log\Lambda \xrightarrow{d} \chi^2_1$을 활용한다. 모수가 경계에 있거나 정칙조건이 깨지면 이 근사를 무조건 적용하지 않는다.

원문 대조·교정 기록 원본의 정규분산/이항비율 두 예와 LRT 점근성 필요성 항목을 조판.

7.3 최대가능도비 검정법의 근사

[원본 정리 7.3.1] 단순가설에서 LRT의 극한분포

모형 $f(x;\theta)$가 MLE의 점근정규성 정칙조건을 만족하고, $H_0:\theta=\theta_0$에서 모수차원이 k라 하자. 원본에서 쓰는 큰 값에서 기각하는 비는

$$\lambda(\mathbf{x})=\frac{L(\widehat{\theta};\mathbf{x})}{L(\theta_0;\mathbf{x})}\geq 1.$$

H_0가 참일 때 θ_0가 모수공간의 내부점이고 통상적인 정칙조건이 성립하면

$$\boxed{2\{\ell(\widehat{\theta})-\ell(\theta_0)\}=2\log\lambda\xrightarrow{d}\chi^2_k}.$$

그러므로 표본크기가 큰 경우 근사 수준 α의 LRT 기각역은

$$\boxed{C_\alpha=\{\mathbf{x}:2\{\ell(\widehat{\theta})-\ell(\theta_0)\}\geq\chi^2_{k,1-\alpha}\}}.$$

원본 로그가능도 그래프의 해석

원본의 Figure 1은 로그가능도함수의 최고점 $\ell(\widehat{\theta})$와 귀무가설에서의 값 $\ell(\theta_0)$ 사이 수직 거리로 검정통계량을 설명한다. 차이가 클수록 H_0가 자료를 설명하기 어렵다. **모수공간의 경계와 비정칙 사례**

θ_0가 모수공간 경계에 있거나 식별가능성 조건이 깨지는 경우에는 χ^2_k 근사를 바로 적용할 수 없다. 복합 귀무가설에서는 전체 모수차원과 제한 모수차원의 차이를 보통 자유도로 사용한다.

원문 대조·교정 기록 원본의 로그가능도비 부호와 기각 방향을 127·129쪽에서 정의한 $\lambda\geq 1$ 관례에 맞춤.

원본 138쪽 이항 LRT, 점근 카이제곱과 Taylor 전개

원본 왼쪽: 이항분포 가능도비에서 Pearson 통계량으로

$T=\sum_i X_i \sim \mathrm{Bin}(n,p)$, $H_0: p=p_0$ 대 $H_1: p\neq p_0$, $\hat p = T/n$.

$$\Lambda = \frac{L(\hat p)}{L(p_0)}, \qquad 2\log\Lambda = 2n\left[\hat p\log\frac{\hat p}{p_0} + (1-\hat p)\log\frac{1-\hat p}{1-p_0}\right].$$

H_0 아래에서 $\hat p \to p_0$이고, 로그함수를 p_0에서 2차 전개하면

$$2\log\Lambda = \frac{n(\hat p-p_0)^2}{p_0(1-p_0)} + o_p(1) = \frac{(T-np_0)^2}{np_0(1-p_0)} + o_p(1) \xrightarrow{d} \chi^2_1.$$

관측값 두 칸(성공 T, 실패 $n-T$)과 귀무기댓값(np_0, $n(1-p_0)$)으로 계산하는 Pearson 통계량과 점근적으로 일치한다. **원본 오른쪽: 일반 로그가능도의 2차 Taylor 전개**

$\ell_n(\theta)=\sum_i \log f(X_i;\theta)$, 내부 최대점 $\hat\theta$에서 $\ell_n'(\hat\theta)=0$.

$$\ell_n(\theta_0) = \ell_n(\hat\theta) + \frac{1}{2}\ell_n''(\widetilde\theta)(\theta_0-\hat\theta)^2.$$

따라서

$$2\log\Lambda = 2\{\ell_n(\hat\theta)-\ell_n(\theta_0)\} = -\ell_n''(\widetilde\theta)(\hat\theta-\theta_0)^2.$$

정칙성과 H_0 아래에서

$$-\frac{1}{n}\ell_n''(\widetilde\theta) \xrightarrow{p} I(\theta_0), \qquad \sqrt{n}(\hat\theta-\theta_0) \xrightarrow{d} N(0, I(\theta_0)^{-1}).$$

따라서 $2\log\Lambda \xrightarrow{d} \chi^2_1$이다.

[검산·보충] 원본은 $\Lambda = L(\hat\theta)/L(\theta_0) \geq 1$을 정의한다. 통계량은 $2\log\Lambda$이다.

원본 139쪽 지수모형 LRT 및 다항분포 Pearson χ^2

1. 지수모형의 양측 가능도비

$X_i \overset{\text{iid}}{\sim} \text{Exp}(\text{척도 } \theta)$, $H_0 : \theta = \theta_0$ 대 $H_1 : \theta \neq \theta_0$, $\hat{\theta} = \bar{X}$.

$$\Lambda = \frac{L(\hat{\theta})}{L(\theta_0)} = \left(\frac{\theta_0}{\bar{X}}\right)^n \exp\left(\frac{n\bar{X}}{\theta_0} - n\right).$$

$\bar{X}$가 θ_0에서 멀어질수록 가능도비가 커지며, 정칙 조건 아래서

$$\boxed{2\log\Lambda = 2n\left(\frac{\bar{X}}{\theta_0} - 1 - \log\frac{\bar{X}}{\theta_0}\right) \xrightarrow{d} \chi^2(1)}.$$

원본의 또 다른 접근은 $\sqrt{n}(\bar{X} - \theta_0)/\theta_0 \to_d N(0,1)$을 사용하는 것이다. **2. 원본 오른쪽: k개 범주를 가진 다항표본**

$(N_1, \ldots, N_k) \sim \text{Multinomial}(n; p_1, \ldots, p_k)$, $\sum_i N_i = n$, $\sum_i p_i = 1$. 원본의 관측·확률·기댓값 표는 다음과 같다.

구분	1번 범주	$\cdots$	k번 범주
관측도수	N_1	$\cdots$	N_k
귀무 확률	p_1	$\cdots$	p_k
귀무 기대도수	np_1	$\cdots$	np_k

Pearson 카이제곱 통계량은

$$\boxed{X_P^2 = \sum_{j=1}^{k} \frac{(N_j - np_j)^2}{np_j} \xrightarrow{d} \chi^2_{k-1}} \qquad (H_0;\ p_j > 0 \text{ 고정}).$$

특히 $k = 2$이면 $N_2 = n - N_1$, $p_2 = 1 - p_1$이어서

$$X_P^2 = \frac{(N_1 - np_1)^2}{np_1(1-p_1)} \xrightarrow{d} \chi^2_1.$$

[검산·보충] 이전 정서본은 원본의 지수모형 LRT와 다항표를 이항검정·지수 MLE의 일반적 설명으로 바꿨다. 원본의 두 주제 모두 복원했다.

정리 7.3.1 — 증명 핵심 구조

$\theta \in \mathbb{R}$이고 귀무가설 $H_0 : \theta = \theta_0$이 참이라고 하자. 로그가능도 ℓ_n의 최대점 $\hat{\theta}$에서 $\ell_n'(\hat{\theta}) = 0$이라면 Taylor 전개에 의해

$$\ell_n(\theta_0) = \ell_n(\hat{\theta}) + \tfrac{1}{2}\ell_n''(\tilde{\theta})(\theta_0 - \hat{\theta})^2$$

인 $\tilde{\theta}$가 존재한다.

$$-2\log\Lambda = -\ell_n''(\tilde{\theta})(\hat{\theta} - \theta_0)^2.$$

정칙조건 아래

$$-\frac{1}{n}\ell_n''(\tilde{\theta}) \xrightarrow{P} I(\theta_0), \qquad \sqrt{n}(\hat{\theta} - \theta_0) \xrightarrow{d} N(0, I(\theta_0)^{-1}).$$

따라서 Slutsky 정리로

$$-2\log\Lambda \xrightarrow{d} \chi^2(1).$$

정서/검수 메모 원본 140쪽은 “Proof [7.3.1]” 표지만 있습니다. 본 증명은 교재의 LRT 정리를 이해하기 위한 **추가 풀이**로 표시합니다.

원본 141 쪽 One-sample Binomial LRT (계속) / 지수분포예제

원본인쇄: One-sample Binomial LRT (계속)

$X \sim \mathrm{Bin}(n,p)$, $H_0: p = p_0$ 대 $H_1: p \neq p_0$ 에서 $\widehat{p} = X/n$ 이다. 전체최대가능도/제약최대가능도비율은

$$\Lambda(X) = \frac{(X/n)^X (1 - X/n)^{n-X}}{p_0^X (1-p_0)^{n-X}},$$

$X = 0$ 또는 n 이면 0^0 은연속적인극한값 1 로해석한다. 원본에서이어지는 LRT 는

$$2 \log \Lambda(X) = 2 \left[X \log \frac{X}{np_0} + (n-X) \log \frac{n-X}{n(1-p_0)} \right].$$

H_0 에서충분한정칙조건아래점근적으로 χ^2_1 을따른다.

원본하단 [예제] 지수분포양측가설

$$X_1, \ldots, X_n \overset{\text{iid}}{\sim} \mathrm{Exp}(\theta), \qquad H_0: \theta = \theta_0 \text{ 대 } H_1: \theta \neq \theta_0.$$

다음페이지로이어지는문제를위해원래가설과모형을함께남긴다. 척도모수지수분포라면가능도 $L(\theta) = \theta^{-n} \exp(-\sum_i X_i/\theta)$ 를사용한다.

검산·보충: 이페이지의원본에는앞쪽이항모형의 “계속” 표제와다음지수분포예제의 양측가설이함께있다. 기존정서본에서는아래예제설정이누락돼있었다.

독립 두 집단 비율 비교와 다항분포 카이제곱 검정

원본 예제 — 두 집단의 모비율 비교

$X \sim \text{Bin}(n, p_X)$, $Y \sim \text{Bin}(m, p_Y)$가 독립이고

$$H_0 : p_X = p_Y \qquad \text{vs} \qquad H_1 : p_X \neq p_Y .$$

$\widehat{p}_X = X/n$, $\widehat{p}_Y = Y/m$, 귀무가설 아래 결합추정량 $\widehat{p} = (X+Y)/(n+m)$로 놓으면

$$\boxed{Z = \frac{\widehat{p}_X - \widehat{p}_Y}{\sqrt{\widehat{p}(1-\widehat{p})(1/n + 1/m)}} \dot{\sim} N(0,1), \qquad Z^2 \dot{\sim} \chi^2_1 .}$$

원본 참고 — 다항분포에서 Pearson 카이제곱 검정과 LR 검정

$(X_1, \ldots, X_k) \sim \text{Multinomial}(n; p_1, \ldots, p_k)$에서 $H_0 : p_j = p_{j0}$를 검정하면

$$X^2 = \sum_{j=1}^{k} \frac{(X_j - np_{j0})^2}{np_{j0}} \dot{\sim} \chi^2_{k-1},$$

$$G^2 = 2\sum_{j=1}^{k} X_j \log\left(\frac{X_j}{np_{j0}}\right) \dot{\sim} \chi^2_{k-1}.$$

$X_j = 0$인 항은 $0 \log 0 = 0$으로 해석한다. 관측도수의 셀이 충분히 크다는 통상적인 근사조건이 필요하다.

원본 143 쪽 다항분포의가능도비검정과 Wilks 근사

원본손글씨의모형과가설

k 개범주에대한관측도수를 $x_1, \dots, x_k$ 라하고 $\sum_{i=1}^{k} x_i = n$ 이라하자.

$$\Omega = \left\{ (p_1, \dots, p_k) : p_i > 0,\ \sum_{i=1}^{k} p_i = 1 \right\}, \qquad H_0 : p_i = p_{i0}, \quad i = 1, \dots, k.$$

전체가능도와제한가능도

$$L(\boldsymbol{p}; \boldsymbol{x}) = \frac{n!}{x_1! \cdots x_k!} \prod_{i=1}^{k} p_i^{x_i}, \qquad \hat{p}_i = \frac{x_i}{n}.$$

$$L(\hat{\boldsymbol{p}}) = \frac{n!}{x_1! \cdots x_k!} \prod_{i=1}^{k} \left(\frac{x_i}{n} \right)^{x_i},$$

$$L(\boldsymbol{p}_0) = \frac{n!}{x_1! \cdots x_k!} \prod_{i=1}^{k} p_{i0}^{x_i}.$$

가능도비및검정통계량

원본필기의가능도비방향을유지하여

$$\Lambda(\boldsymbol{x}) = \frac{L(\hat{\boldsymbol{p}})}{L(\boldsymbol{p}_0)} = \prod_{i=1}^{k} \left(\frac{x_i}{n p_{i0}} \right)^{x_i}.$$

따라서

$$\boxed{2 \log \Lambda = 2 \sum_{i=1}^{k} x_i \log \left(\frac{x_i}{n p_{i0}} \right) \xrightarrow{d} \chi^2_{k-1}.}$$

이는귀무가설아래큰표본에서얻는점근분포이며, 큰값일수록귀무가설을기각한다.

검산·보충: $x_i = 0$ 인항은 $0 \log 0 := 0$ 으로처리한다. 귀무가설의모든 $p_{i0} > 0$ 이고범주수 k 가고정된큰표본근사라는조건을명시했다. $x_i = 0$ 이면경계에서의최대화는모수공간의폐포 (또는상한) 로이해한다.

가능도비 검정의 필기 증명 및 주사위의 공정성

원본 머리말: (1) $k=2$의 경우, (2) LRT 유도

복합가설의 가능한 모수 공간 차원에 따라 $-2\log\Lambda_n$의 점근 자유도가 결정된다. 일반적인 정칙조건에서 차원이 k인 모형과 k_0차원 귀무모형이면 자유도는 $k-k_0$이다. 원본은 해당 증명을 참고 항목으로 제시한다. **원본 표 — 주사위의 공정성**

눈	1	2	3	4	5	6
관찰횟수	12	10	9	8	13	8

모든 눈이 공정하게 나올 귀무가설 $H_0: p_1=\cdots=p_6=1/6$에서 전체 시행 수는 $n=60$, 각 기대도수 $E_j=10$이다.

$$\begin{aligned} X^2 &= \sum_{j=1}^{6}\frac{(O_j-E_j)^2}{E_j} \\ &= \frac{(12-10)^2+(10-10)^2+(9-10)^2+(8-10)^2+(13-10)^2+(8-10)^2}{10} \\ &= \boxed{2.20}. \end{aligned}$$

점근적으로 자유도 5인 카이제곱분포에 따르므로 $\alpha=0.05$에서 $\chi^2_{5,0.95}\approx 11.070$보다 작다. 따라서 H_0를 기각하지 않는다.

원문 대조·교정 기록 원본의 주사위 표와 앞쪽 “(1) k=2, (2) LRT 유도” 표기를 모두 복원. 이전 정서본은 주사위 예제를 삭제했음.

주사위의 공정성 검정 — 6개 범주

원본 표의 **한 주사위** 관측 도수는 다음과 같다.

눈	1	2	3	4	5	6	합계
관찰횟수	12	10	9	8	13	8	60
기대횟수	10	10	10	10	10	10	60

귀무가설

$H_0: p_1 = \cdots = p_6 = 1/6$. 공정한 주사위의 경우 각 기대도수는 $60/6 = 10$이다. **Pearson 카이제곱 검정통계량**

$$\begin{aligned} X^2 &= \sum_{i=1}^{6} \frac{(O_i - 10)^2}{10} \\ &= \frac{4 + 0 + 1 + 4 + 9 + 4}{10} = \boxed{2.20}. \end{aligned}$$

가능도비 검정통계량

$$G^2 = 2\sum_{i=1}^{6} O_i \log \frac{O_i}{10} \approx \boxed{2.1601}.$$

모수를 추정하지 않은 단순귀무가설이므로 자유도는 $6 - 1 = 5$. 두 값 모두 $\chi^2_{5,0.95}$보다 작아 5%에서 기각하지 않는다.

정서/검수 메모 원본의 실제 도수 (12,10,9,8,13,8)을 수기로 대조했습니다. 이전 '동질성 검정' 설명을 **공정성 적합도 검정**으로 바로잡았습니다.

정리 7.3.2 — 장애모수가 있는 경우의 가능도비 검정

원문 복원: 원본 146쪽은 주사위 예제가 아니라 복합가설의 가능도비 통계량의 점근분포를 기술한다. **가설과 제한·비제한 추정량**

$$H_0 : \theta \in \Omega_0 \quad \text{vs} \quad H_1 : \theta \in \Omega_1 .$$

$\widehat{\theta}$는 전체 모수공간 Ω에서의 MLE, $\widehat{\theta}_0$는 귀무가설에 제한된 공간 Ω_0에서의 MLE이다. $k = \dim \Omega$, $k_0 = \dim \Omega_0$라 하자. **정리 — Wilks의 점근 카이제곱 분포**

통상적인 정칙조건과 H_0의 적절한 내부점 조건에서

$$\boxed{2\{\ell(\widehat{\theta}) - \ell(\widehat{\theta}_0)\} = -2\log \Lambda_n \xrightarrow{d} \chi^2_{k-k_0}.}$$

여기서 $\Lambda_n = L(\widehat{\theta}_0)/L(\widehat{\theta})$이다. **유의수준 α의 점근 기각역**

$$C_\alpha = \left\{ \mathbf{x} : \; 2\{\ell(\widehat{\theta}) - \ell(\widehat{\theta}_0)\} \geq \chi^2_{k-k_0,\,1-\alpha} \right\}.$$

원본은 이 정리의 증명을 생략한다. 경계모수나 특이모형에는 위의 자유도를 무조건 적용할 수 없다.

원문 대조·교정 기록 원본 146쪽의 정리 번호, 복합가설, 자유도 $k - k_0$, 제한 MLE, 점근 기각역을 복원. 앞서 잘못 배치된 주사위 계산은 이 페이지에서 삭제했습니다.

사건 발생건수의 Poisson 적합도 검정

원본 예제: 사건의 발생건수가 포아송분포를 따르는지 검정한다. 표본크기는 $n = 250$이고, 표본평균은 $\bar{x} = 3.84$이다. **관측값과 적합된 기대도수**

발생건수	0	1	2	3	4	5	$6+$
관측횟수	6	20	36	50	52	40	46
적합확률	.021	.082	.158	.203	.195	.150	.191
기대도수	5.4	20.6	39.5	50.7	48.7	37.4	47.7

$H_0: X \sim$ Poisson(λ)이며 모수는 $\hat{\lambda} = 3.84$로 추정하였다. **Pearson 검정통계량**

$$X^2 = \sum_{j=1}^{7} \frac{(O_j - E_j)^2}{E_j} \approx \boxed{0.87}.$$

범주 7개, 포아송 모수 1개를 자료로부터 추정했으므로 자유도는 $7 - 1 - 1 = 5$이다. 따라서 5% 수준에서 포아송 적합성을 기각할 근거가 없다. **이어지는 예제 7.3.3**

원본 다음 항목은 분할표에서 독립성 검정(LR 검정과 Pearson 카이제곱 검정)이다.

원본 148 쪽 포아송모형의범주확률추정과적합도검정

원본필기: 포아송의사건발생확률

$X \sim \text{Poisson}(\theta)$ 이고 $\theta > 0$ 이면

$$p_k(\theta) = P_\theta(X = k) = \frac{e^{-\theta}\theta^k}{k!}, \quad k = 0, 1, 2, \ldots.$$

원본에적힌구체적인값은 $\theta = 3$ 일때

$$p_0(3) = e^{-3}, \qquad p_1(3) = 3e^{-3}.$$

일반적인 θ 에대해서는

$$\boxed{p_0(\theta) = e^{-\theta}, \qquad p_1(\theta) = \theta e^{-\theta}.}$$

원본의 plug-in 추정과최대가능도추정량

표본 $X_1, \ldots, X_n \overset{\text{iid}}{\sim} \text{Poisson}(\theta)$ 일때로그가능도방정식을풀면

$$\widehat{\theta}_{\text{ML}} = \bar{X}.$$

따라서모수불변성에의해

$$\widehat{p}_{0,\text{ML}} = e^{-\bar{X}}, \qquad \widehat{p}_{1,\text{ML}} = \bar{X}e^{-\bar{X}}.$$

원본하단의 Pearson 카이제곱메모

사건발생수를 k 개범주로집계하여관측도수 O_j 와기대도수 $E_j = n\widehat{p}_j$ 를얻으면

$$\boxed{X^2 = \sum_{j=1}^{k} \frac{(O_j - E_j)^2}{E_j}.}$$

검정통계량은일반적인정칙조건아래 χ^2_{k-1-r} 로근사한다. 여기서 r 은자료로추정한독립적인모수수이다 (포아송평균을추정하면 $r = 1$). 기대도수가충분히작으면범주를합쳐야한다.

검산·보충: 원본은임의화하는 포아송단측 NP 검정이아니라 $P(X = 0), P(X = 1)$ 의추정과카이제곱적합도검정에관한필기이다. 원문과무관했던단측검정내용을제거했다.

8.1 추정량 비교의 기준

원본 요지: 좋은 추정량은 추정 대상 $g(\theta)$에 가까운 값을 산출하는 추정량이다. 단 추정량 $T(X)$의 관측값은 표본에 따라 달라지므로 모든 경우에 참값과 일치하도록 만들 수 없다. **손실함수(Loss function)**

추정량에 수반되는 손실을 $L(\theta, T)$로 평가한다. 원본의 대표 예는 다음과 같다.

- 절대오차: $L_1(\theta, T) = |T - g(\theta)|$.
- 제곱오차: $L_2(\theta, T) = [T - g(\theta)]^2$.
- 가중제곱오차: $L_3(\theta, T) = w(\theta)[T - g(\theta)]^2$, $w(\theta) > 0$.

표본에 따라 손실도 달라지므로, 실현되기 전의 손실을 반드시 최소화할 수는 없다. 이를 대신하여 위험함수 $R(\theta, T) = E_\theta[L(\theta, T)]$를 사용한다. **평균제곱오차(MSE)**

제곱오차손실에 대한 위험함수는

$$\begin{aligned} \mathrm{MSE}_\theta(T) &= E_\theta[(T - g(\theta))^2] \\ &= \mathrm{Var}_\theta(T) + \{E_\theta(T) - g(\theta)\}^2. \end{aligned}$$

따라서 MSE는 추정량의 분산과 편향을 함께 반영한다.

원문 대조·교정 기록 원본의 절대오차·제곱오차·가중제곱오차 목록과 추정량 비교의 도입 설명을 복원했습니다.

정의 — 평균제곱오차(MSE), 편향, 불편추정량

$g(\theta)$의 추정량 $\widehat{g}$에 대해

$$\boxed{\mathrm{MSE}_\theta(\widehat{g}) = E_\theta[(\widehat{g} - g(\theta))^2] = \mathrm{Var}_\theta(\widehat{g}) + \{E_\theta\widehat{g} - g(\theta)\}^2.}$$

편향은 $\mathrm{Bias}_\theta(\widehat{g}) = E_\theta\widehat{g} - g(\theta)$이다. 모든 θ에서 편향 0이면 불편추정량이며, 그 경우 MSE는 분산이다. **원본 예제 8.1.1 — $U(0,\theta)$: MME와 MLE의 MSE**

$X_i \overset{\text{iid}}{\sim} U(0,\theta)$이고 $E(X) = \theta/2$, $\mathrm{Var}(X) = \theta^2/12$이다.

$$\widehat{\theta}_{\mathrm{MM}} = 2\overline{X}, \qquad \widehat{\theta}_{\mathrm{ML}} = X_{(n)} = M.$$

적률추정량은 불편이므로

$$\boxed{\mathrm{MSE}(2\overline{X}) = 4\,\mathrm{Var}(\overline{X}) = \frac{\theta^2}{3n}.}$$

M의 평균과 분산은

$$E(M) = \frac{n\theta}{n+1}, \qquad \mathrm{Var}(M) = \frac{n\theta^2}{(n+1)^2(n+2)}.$$

따라서

$$\begin{aligned}\mathrm{MSE}(M) &= \mathrm{Var}(M) + \mathrm{Bias}(M)^2 \\ &= \frac{n\theta^2}{(n+1)^2(n+2)} + \frac{\theta^2}{(n+1)^2} = \boxed{\frac{2\theta^2}{(n+1)(n+2)}}.\end{aligned}$$

$n = 1, 2$에서는 두 MSE가 같고 $n \geq 3$에서는 MLE의 MSE가 더 작다.

원문 대조·교정 기록 원본 MSE와 Bias 정의, 불편추정량 성질 및 원본에 시작된 균등분포 MME vs MLE의 계산을 완성.

원본 151쪽 손글씨 정서

불편추정량의 평균제곱오차: 표본최댓값 예제

$X_1, \dots, X_n \overset{\text{iid}}{\sim} U(0, \theta)$이고 $M = X_{(n)} = \max_i X_i$이다. 원본은 M의 편향을 보정한 추정량의 MSE를 비교한다. **최댓값의 분포와 모멘트**

$$F_M(m) = \left(\frac{m}{\theta}\right)^n, \quad f_M(m) = \frac{n m^{n-1}}{\theta^n}, \quad 0 < m < \theta.$$

$$\mathsf{E}(M) = \frac{n}{n+1}\theta, \quad \mathsf{E}(M^2) = \frac{n}{n+2}\theta^2, \quad \mathsf{Var}(M) = \frac{n\theta^2}{(n+1)^2(n+2)}.$$

불편보정 추정량 $\tilde{\theta} = (n+1)M/n$이면

$$\mathsf{E}(\tilde{\theta}) = \theta, \qquad \mathsf{MSE}(\tilde{\theta}) = \mathsf{Var}(\tilde{\theta}) = \boxed{\frac{\theta^2}{n(n+2)}}.$$

MLE M**의 MSE**

$$\mathsf{MSE}(M) = \mathsf{Var}(M) + \{\mathsf{E}(M) - \theta\}^2 = \boxed{\frac{2\theta^2}{(n+1)(n+2)}}.$$

> 두 추정량 모두 일치추정량이다. 불편성만으로 MSE가 항상 작은 것은 아니다. 두 식을 비교하면 $n > 1$에서 보정한 $\tilde{\theta}$의 MSE가 더 작다.

원본 152 쪽 편향추정량과불편추정량의 MSE 비교

원본필기: 베르누이모형

$X_1, \ldots, X_n \overset{\text{iid}}{\sim} \text{Bernoulli}(p)$ 이고추정대상은 $g(p) = p$ 이다. 원본은다음의두추정량을비교한다.

1. **상수추정량** $\widehat{p}_c = 0.6$:
$$E_p(\widehat{p}_c) = 0.6, \quad \text{Bias}_p(\widehat{p}_c) = 0.6 - p, \quad \boxed{\text{MSE}_p(\widehat{p}_c) = (0.6-p)^2}.$$
2. **표본평균** $\widehat{p}_{\text{ML}} = \bar{X}$:
$$E_p(\bar{X}) = p, \quad \text{Bias}_p(\bar{X}) = 0, \quad \boxed{\text{MSE}_p(\bar{X}) = \frac{p(1-p)}{n}}.$$

원본그래프: 어느 MSE 가작은가?

$0 \le p \le 1$ 에서 p 가 0.6 에가까울때상수추정량의 MSE 는작다. 멀리벗어난구간에서는 $\bar{X}$ 의 MSE 가더작을수있다.

$$\text{MSE}_p(\widehat{p}_c) \le \text{MSE}_p(\bar{X}) \iff (0.6-p)^2 \le \frac{p(1-p)}{n}.$$

원본하단: 균등분포표본최댓값의편향보정

별도의예제로 $X_1, \ldots, X_n \overset{\text{iid}}{\sim} U(0, \theta)$, $\widehat{\theta}_{\text{ML}} = X_{(n)}$ 이면

$$E_\theta(X_{(n)}) = \frac{n}{n+1}\theta, \quad \text{Bias}_\theta(X_{(n)}) = -\frac{\theta}{n+1}.$$

불편추정량은

$$\boxed{\widehat{\theta}_{\text{unb}} = \frac{n+1}{n} X_{(n)}, \qquad E_\theta(\widehat{\theta}_{\text{unb}}) = \theta.}$$

검산·보충: 기존정서본에추가돼있던일반적인수축추정량공식은원본의예제가아니다. 원본의 $\widehat{p} = 0.6$, $\bar{X}$, 균등표본최댓값보정사례를복원했다.

8.1 예제 — MSE 기준에서 일률적인 최적 추정량은 없는 경우

원본 인쇄 예제: $X_1, \ldots, X_n \overset{\text{iid}}{\sim} \text{Bernoulli}(p)$, 불량률 p의 추정량 $\widehat{p} = \overline{X}$, 상수 추정량 $\widetilde{p} = 0.6$을 비교한다. **두 추정량의 평균제곱오차**

$$\text{MSE}_p(\widehat{p}) = \frac{p(1-p)}{n}, \qquad \text{MSE}_p(\widetilde{p}) = (0.6 - p)^2.$$

p가 0.6 부근이면 상수 추정량의 MSE가 더 작을 수 있다. 반면 p가 0.6에서 멀어지면 상수 추정량의 편향이 크게 작용한다. **원본의 중요한 구분**

- 균등분포 모형에서는 특정 조건 아래 MLE의 MSE가 적률추정량보다 작을 수 있다.
- Bernoulli 모형에서는 **모든** $p \in (0,1)$**에서 MSE가 가장 작은 추정량**을 찾는 것이 일반적으로 쉽지 않다.
- 이를 피하기 위해 원본은 **불편추정량의 부류**로 탐색 범위를 제한하고, 그 안에서 분산을 비교하는 접근을 제시한다.

보충 — 상수 추정량의 한계

$\widetilde{p} = 0.6$은 특정 p에서 작은 MSE를 보일 수 있지만 일반적으로 불편추정량은 아니다. $\overline{X}$는 모든 p에서 불편이다.

원문 대조·교정 기록 원본의 $\widetilde{p} = 0.6$ 예제와 “불편추정량 부류로 한정”하는 논의를 복원. 이전 페이지의 일반적인 선형추정량 비교 설명을 대체했습니다.

추정량의 효율성과 UMVUE

불편추정량 중에서 어떤 추정량이 효율적인가?

추정 대상이 $\eta(\theta)$이고 $E_\theta T_1 = E_\theta T_2 = \eta(\theta)$라면 두 추정량의 MSE는 각각 분산과 같으므로

$$\mathrm{MSE}_\theta(T_j) = \mathrm{Var}_\theta(T_j), \qquad j = 1, 2.$$

불편추정량이 무수히 많더라도 그 전체 부류 중에서 분산이 가장 작은 추정량을 찾는 것이 목표다. **[원본 정의] Uniformly Minimum Variance Unbiased Estimator**

표본 $\mathbf{X} = (X_1, \ldots, X_n)$가 모수 $\theta \in \Omega$의 결합밀도 $f(\mathbf{x}; \theta)$를 따르고 $\eta(\theta)$를 추정한다. 통계량 T가 다음 두 조건을 만족하면 $\eta(\theta)$의 전역 최소분산 불편추정량(UMVUE)이다.

(1) **불편성:** $E_\theta[T] = \eta(\theta)$ for every $\theta \in \Omega$.

(2) **전역 최소분산:** 동일한 $\eta(\theta)$의 임의의 불편추정량 T^*에 대하여

$$\boxed{\mathrm{Var}_\theta(T) \le \mathrm{Var}_\theta(T^*) \quad (\forall \theta \in \Omega).}$$

왜 '전역(uniformly)'인가?

어떤 특정한 모수값에서만 분산이 작아서는 충분하지 않다. **모수공간의 모든 값에서** 다른 불편추정량보다 분산이 크지 않아야 한다. 이후에는 정보부등식이나 완비충분통계량으로 이를 확인한다.

원문 대조·교정 기록 원본의 두 조건, 모든 불편추정량과 모든 θ에 대한 전역 최소성, MSE와 분산의 관계를 복원.

정리 8.1.1 — 최소분산불편추정량의 유일성

원본 예제: 포아송분포의 불편추정량

$X_1, \ldots, X_n \overset{\text{iid}}{\sim} \text{Poisson}(\theta)$ 이면

$$\widehat{\theta}_1 = \overline{X}, \qquad E_\theta(\overline{X}) = \theta.$$

서로 다른 표본통계량으로도 같은 모수 θ의 불편추정량을 구성할 수 있다. 따라서 **불편성만으로는 최적성이 보장되지 않는다.** **정리 8.1.1 (원본)**

$\widehat{\eta}_1, \widehat{\eta}_2$가 모두 $\eta(\theta)$의 UMVUE이고 각 분산이 유한하다고 하자. 그러면

$$\boxed{P_\theta\{\widehat{\eta}_1 = \widehat{\eta}_2\} = 1 \quad \text{for every } \theta.}$$

증명 보충 — 두 UMVUE의 분산 비교

두 추정량은 같은 최소분산 v_θ를 갖는다. $\widetilde{\eta} = (\widehat{\eta}_1 + \widehat{\eta}_2)/2$도 불편이다. 그런데

$$\text{Var}(\widetilde{\eta}) = \frac{v_\theta + \text{Cov}(\widehat{\eta}_1, \widehat{\eta}_2)}{2} \le v_\theta.$$

최소분산의 정의에 의해 등호이고, 따라서 $\text{Cov}(\widehat{\eta}_1, \widehat{\eta}_2) = v_\theta$이다. 그러므로

$$\text{Var}(\widehat{\eta}_1 - \widehat{\eta}_2) = 2v_\theta - 2v_\theta = 0.$$

두 추정량의 기댓값도 같으므로 그 차는 거의 확실하게 0이다.

원문 대조·교정 기록 원본 155쪽의 포아송 불편추정 예시와 “UMVUE의 유일성” 정리 및 증명을 복원했습니다. 이전 정서본에는 이 정리가 빠져 있었습니다.

최소분산불편추정량(UMVUE)의 정의

정의 — Uniformly Minimum Variance Unbiased Estimator

$T(X)$가 $g(\theta)$의 불편추정량이고 임의의 다른 불편추정량 $U(X)$와 모든 $\theta \in \Theta$에 대해

$$\boxed{\mathrm{Var}_\theta(T) \le \mathrm{Var}_\theta(U)}$$

이면 T는 $g(\theta)$의 UMVUE이다. **정의의 의미**

- 모든 모수값 θ에서 동시에 분산이 최소이다.
- 추정대상은 θ 자체일 수도 있고 함수 $g(\theta)$일 수도 있다.
- 불편성만으로 UMVUE임을 보장할 수는 없다.

관련 정리

Cramér–Rao 하한에 도달하는 불편추정량이 존재하면 통상적인 정칙조건 아래 그 추정량은 UMVUE이다. 충분통계량에 대한 조건부기댓값과 Lehmann–Scheffé 정리도 UMVUE를 찾는 방법이다.

정서/검수 메모 원본의 정의 · 비교 방향 · 최소분산에 관한 주의사항을 조판했습니다.

8.1 — UMVUE를 어떻게 찾을 것인가?

원본 설명: 불편추정량의 분산 하한을 찾는 방법과 충분·완비통계량의 성질을 사용하는 방법을 구별한다. **1. Cramér–Rao 방법**

정칙조건에서 $g(\theta)$의 불편추정량 T는

$$\mathrm{Var}_\theta(T) \geq \frac{\{g'(\theta)\}^2}{I_n(\theta)}.$$

T의 분산이 모든 θ에서 이 하한과 같으면, 그 T는 최소분산불편추정량이다. 그러나 **하한을 달성하는 추정량이 항상 존재하지는 않는다. 2. 충분통계량과 완비성의 활용**

불편추정량 U가 있고 S가 충분통계량이면 $E(U \mid S)$는 불편성을 유지하며 분산이 커지지 않는다(Rao–Blackwell). S가 완비충분통계량이면 이 조건부기대값은 UMVUE이다(Lehmann–Scheffé). **정의 — Fisher 정보**

한 관측치의 점수함수는 $U_\theta(X) = \partial_\theta \log f(X;\theta)$이고

$$I_1(\theta) = E_\theta[U_\theta(X)^2] = -E_\theta[\partial_\theta^2 \log f(X;\theta)]$$

이다. 두 번째 등식은 적절한 정칙조건에서 성립한다. 독립동일분포 표본에서는 $I_n(\theta) = nI_1(\theta)$이다.

원문 대조·교정 기록 원본에 적힌 “UMVUE 탐색의 두 방법”, 정보부등식의 의미, Fisher 정보의 정의를 복원했습니다.

원본 158쪽 손글씨 정서

점수함수와 Fisher 정보: 정규 · 베르누이 예제

점수함수 $U(\theta;X)=\partial_\theta \log f(X;\theta)$이고 $\mathsf{E}_\theta\, U(\theta;X)=0$을 만족하는 정칙 모형에서

$$I(\theta)=\mathsf{E}_\theta[U(\theta;X)^2]=-\,\mathsf{E}_\theta\left[\frac{\partial^2}{\partial\theta^2}\log f(X;\theta)\right].$$

정규모형. $X\sim N(\mu,\sigma^2)$이고 σ^2가 알려져 있을 때

$$U(\mu;X)=\frac{X-\mu}{\sigma^2},\qquad I(\mu)=\frac{1}{\sigma^2}.$$

n개 독립 표본이면 $I_n(\mu)=n/\sigma^2$. **베르누이모형.** $X\sim \text{Bernoulli}(p)$에서

$$U(p;X)=\frac{X}{p}-\frac{1-X}{1-p}=\frac{X-p}{p(1-p)},\quad I(p)=\frac{1}{p(1-p)}.$$

효율성. 두 모형의 평균 추정량은 각각 $\mathrm{Var}(\bar X)=\sigma^2/n$, $\mathrm{Var}(\bar X)=p(1-p)/n$이므로 아래의 Cramér–Rao 하한에 도달한다.

> 원본에서 점수의 평균이 0이 되는 과정은 $\partial_\theta\int f(x;\theta)dx=0$에서 출발한다.

원본 159쪽 손글씨 정서

Fisher 정보 항등식: 미분과 적분의 교환

정칙성 조건 아래서 $\int f(x;\theta)\,dx = 1$이고 미분과 적분의 순서를 교환할 수 있다면

$$0 = \frac{\partial}{\partial\theta}\int f(x;\theta)dx = \int \frac{\partial f}{\partial\theta}(x;\theta)\,dx.$$

점수함수 $U = \partial_\theta \log f = f_\theta/f$이므로

$$\boxed{\mathsf{E}_\theta\, U = \int \frac{f_\theta}{f} f\,dx = 0}.$$

한 번 더 미분하여 $\partial_\theta U = f_{\theta\theta}/f - (f_\theta/f)^2$이므로

$$\begin{aligned}\mathsf{E}_\theta\left[\frac{\partial U}{\partial\theta}\right] &= \int\left\{f_{\theta\theta} - \frac{f_\theta^2}{f}\right\}dx \\ &= -\,\mathsf{E}_\theta(U^2).\end{aligned}$$

따라서

$$\boxed{I(\theta) = \mathsf{Var}_\theta(U) = -\,\mathsf{E}_\theta\left[\partial_\theta^2 \log f(X;\theta)\right]}.$$

> 원본의 미분 전개는 표본의 지지집합이 모수에 의존하지 않고, 적분 · 미분 교환이 가능한 경우에만 그대로 정당화된다. 예를 들어 $U(0,\theta)$는 지지집합이 θ에 의존하므로 통상적 정보항등식에 주의해야 한다.

원본 160쪽 손글씨 정서

Cramér–Rao 하한의 유도

$T(X)$가 $g(\theta)$의 불편추정량이라 하자. $\mathsf{E}_\theta\, T = g(\theta)$, $U = \partial_\theta \log f(X;\theta)$라고 쓰면

$$\mathsf{Cov}_\theta(T, U) = \mathsf{E}_\theta(TU) = \frac{\partial}{\partial \theta}\, \mathsf{E}_\theta\, T = g'(\theta).$$

Cauchy–Schwarz 부등식에 의해

$$\{g'(\theta)\}^2 = \mathsf{Cov}(T,U)^2 \le \mathsf{Var}(T)\,\mathsf{Var}(U) = \mathsf{Var}(T) I_n(\theta).$$

따라서

$$\boxed{\mathsf{Var}_\theta(T) \ge \frac{\{g'(\theta)\}^2}{I_n(\theta)}}.$$

$i.i.d.$ 표본에서 $I_n(\theta) = n I_1(\theta)$이다. **평등 성립 조건.** Cauchy–Schwarz 등호 조건에 따라 $T - g(\theta)$가 점수 U와 거의 확실히 비례해야 한다. **예제: 포아송 평균.** $X_i \overset{\text{iid}}{\sim} \text{Poisson}(\theta)$에서 $I_n(\theta) = n/\theta$, $g(\theta) = \theta$이므로

$$\mathsf{Var}(\hat\theta) \ge \theta / n.$$

$\bar X$는 분산이 정확히 θ/n이므로 하한에 도달한다.

> 이 하한은 정칙성 조건이 충족되는 불편추정량에 대한 것이다. 편향추정량이나 지지집합이 모수에 의존하는 모형에 동일 식을 무조건 적용하면 안 된다.

8.1 정보부등식의 예제

원본 항목 (1): 정규분포 $X \sim N(\mu, \sigma_0^2)$

σ_0^2가 알려져 있을 때 $X_1, \ldots, X_n$의 μ에 대한 Fisher 정보는 $I_n(\mu) = n/\sigma_0^2$이다.

$$\mathrm{Var}(\widehat{\mu}) \geq \frac{\sigma_0^2}{n}, \qquad \mathrm{Var}(\overline{X}) = \frac{\sigma_0^2}{n}.$$

따라서 $\overline{X}$는 하한을 달성한다. **원본 항목 (2): Bernoulli**(p)

$$I_n(p) = \frac{n}{p(1-p)}, \qquad \mathrm{Var}(\widehat{p}) \geq \frac{p(1-p)}{n}.$$

$\overline{X}$는 불편이고 분산이 이 하한과 같다. **원본 항목 (3): Beta**$(\alpha, 1)$

밀도 $f(x;\alpha) = \alpha x^{\alpha-1}$, $0 < x < 1$, $\alpha > 0$이면

$$\ell(\alpha) = n \log \alpha + (\alpha - 1) \sum_i \log X_i, \quad I_n(\alpha) = \frac{n}{\alpha^2}.$$

α의 불편추정량에 대한 하한은 α^2/n이다. 예를 들어 $S = -\sum_i \log X_i \sim \mathrm{Gamma}(n, \text{rate } \alpha)$이므로 $n > 2$에서

$$E\left(\frac{n-1}{S}\right) = \alpha, \qquad \mathrm{Var}\left(\frac{n-1}{S}\right) = \frac{\alpha^2}{n-2} > \frac{\alpha^2}{n}.$$

원문 대조·교정 기록 원본 161쪽의 정규·베르누이·베타 세 예제 모두를 복원했습니다. 베타 예제의 비교식은 직접 계산했습니다.

정리 8.4.1 — 정보부등식(Cramér–Rao Inequality)

원본 정리: 정칙조건을 만족하는 표본모형 $f(x;\theta)$과 모수함수 $\eta(\theta)$의 불편추정량 $\widehat{\eta}$에 대하여

$$\boxed{\mathrm{Var}_\theta(\widehat{\eta}) \geq \frac{\left\{\frac{d}{d\theta}E_\theta(\widehat{\eta})\right\}^2}{nI_1(\theta)} = \frac{\{\eta'(\theta)\}^2}{nI_1(\theta)}.}$$

여기서 $I_1(\theta) = E_\theta\{[\partial_\theta \log f(X;\theta)]^2\}$이다. **원본에 적힌 가정**

- 단일 모수의 정칙모형이며 모수의 공통 지지집합이 θ에 의존하지 않음.
- 적분과 미분의 순서를 바꿀 수 있고 정보량이 존재함.
- $\widehat{\eta}$의 분산이 유한하며 $E_\theta\widehat{\eta} = \eta(\theta)$.

증명 보충

전체 점수함수 $U_n = \sum_i \partial_\theta \log f(X_i;\theta)$라고 두면 $E_\theta U_n = 0$, $\mathrm{Var}(U_n) = nI_1(\theta)$이다. 미분과 적분을 교환하면

$$\mathrm{Cov}_\theta(\widehat{\eta}, U_n) = E_\theta(\widehat{\eta}U_n) = \frac{d}{d\theta}E_\theta\widehat{\eta} = \eta'(\theta).$$

Cauchy–Schwarz 부등식 $\mathrm{Cov}(A,B)^2 \leq \mathrm{Var}(A)\,\mathrm{Var}(B)$를 적용하면 위 하한을 얻는다.

원문 대조·교정 기록 원본 162쪽의 [Thm 8.4.1] 제목, 가정, 하한식, 증명을 복구. 기존 정서본의 “Note 1” 제목은 163쪽에 대응.

정보부등식의 Note 1 · Note 2 및 포아송 예제

Note 1 — 불편추정량이 CR 하한을 달성하면 UMVUE

$\widehat{\eta}$가 $\eta(\theta)$의 불편추정량이면 $\mathrm{Var}_\theta(\widehat{\eta}) \geq \{\eta'(\theta)\}^2/[nI_1(\theta)]$이다. 모든 θ에서 등호를 달성하면 그 분산은 모든 불편추정량 중 최소이므로 UMVUE이다. **원본 포아송 예제**

$X_1, \ldots, X_n \sim \mathrm{Poisson}(\theta)$, $\theta > 0$에서 $\ell(\theta) = \sum_i X_i \log\theta - n\theta - \sum_i \log(X_i!)$이고

$$U_n = \frac{\sum_i X_i}{\theta} - n, \qquad I_n(\theta) = \frac{n}{\theta}.$$

$\overline{X}$는 θ의 불편추정량이고 $\mathrm{Var}(\overline{X}) = \theta/n = 1/I_n(\theta)$이므로 하한을 달성한다. **Note 2 — Fisher 정보를 계산하는 다른 방법**

정칙조건에서

$$I_1(\theta) = E\Big[(\partial_\theta \log f(X;\theta))^2\Big] = -E\big[\partial_\theta^2 \log f(X;\theta)\big]\,.$$

이 등식은 $\int f(x;\theta)\,dx = 1$을 두 번 미분하여 얻는다.

Cramér–Rao 부등식으로 UMVUE를 찾을 때의 두 가지 문제

원본의 두 문제점: (a) 지지집합이 모수에 의존하면 $\partial_\theta E_\theta T$와 $\int T\partial_\theta f$를 교환하지 못할 수 있다. (b) 어떤 불편추정량도 Cramér–Rao 하한에 도달하지 못하는 경우가 있다. **원본 예제 — $U(0,\theta)$에서 정칙성의 실패**

$X\sim U(0,\theta)$이면 $f(x;\theta)=1/\theta\ (0<x<\theta)$이다. $E_\theta[X]=\theta/2$이므로

$$\frac{d}{d\theta}E_\theta X=\frac{1}{2},\quad \int_0^\theta x\frac{\partial}{\partial\theta}\frac{1}{\theta}\,dx=-\frac{1}{2}.$$

지지집합의 경계항 $\theta f(\theta;\theta)=1$을 빠뜨렸기 때문에 차이가 생긴다. 따라서 표준 CRLB의 정칙성 가정을 이 모형에 무조건 적용해서는 안 된다.
원본 예제 8.4.5 — Beta$(\alpha,1)$

$X_i\overset{\text{iid}}{\sim}$ Beta$(\alpha,1)$의 밀도 $f(x;\alpha)=\alpha x^{\alpha-1}\ (0<x<1)$에서

$$\ell(\alpha)=n\log\alpha+(\alpha-1)\sum_i\log X_i,\quad I_n(\alpha)=\frac{n}{\alpha^2}.$$

$g(\alpha)=\alpha$의 CRLB는 α^2/n이다. $Y=-\sum_i\log X_i\sim$ Gamma$(n,\text{rate }\alpha)$이므로

$$\widehat{\alpha}_{\mathsf{ML}}=\frac{n}{Y},\qquad \widehat{\alpha}_{\mathsf{U}}=\frac{n-1}{Y}\quad (n>1).$$

$$E\widehat{\alpha}_{\mathsf{U}}=\alpha,\qquad \mathsf{Var}(\widehat{\alpha}_{\mathsf{U}})=\frac{\alpha^2}{n-2}\quad (n>2),$$

이는 하한 α^2/n보다 크다. 완비충분통계량 Y의 함수이므로 이 불편추정량은 UMVUE이다.

원문 대조·교정 기록 원본의 Uniform 정칙성 실패, Beta 예제 8.4.5, CRLB 미도달, Rao–Blackwell·Lehmann–Scheffé 언급을 복원·검산.

8.2 충분통계량(Sufficient Statistic)

UMVUE를 찾는 두 번째 방법

원본은 정보부등식을 이용하는 방법에 이어 **충분통계량과 완비통계량의 성질을 사용하는 방법**을 소개한다. **[정의] 충분통계량**

모집단의 분포가 $f(x;\theta)$, $\theta \in \Omega$인 모수모형이며 랜덤표본 $\mathbf{X} = (X_1, \ldots, X_n)$에 대한 통계량이 $Y = u(\mathbf{X})$라 하자.

$$\boxed{\mathcal{L}_\theta(\mathbf{X} \mid Y = y)\text{가 모수 } \theta\text{에 의존하지 않으면 } Y\text{는 충분통계량이다.}}$$

Y가 주어졌을 때 전체 표본의 조건부분포에 모수에 대한 추가 정보가 없다는 뜻이다. Y는 표본의 모수 관련 정보를 요약한다. **원본 필기의 정규분포 예**

$X_i \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$일 때, σ^2가 알려지면 $\sum_i X_i$는 μ의 충분통계량이다. μ, σ^2 모두 미지이면

$$\left(\sum_i X_i, \sum_i X_i^2\right) \longleftrightarrow (\overline{X}, S^2)$$

은 고정된 $n \geq 2$에서 서로 일대일로 대응하는 충분통계량이다. **Rao–Blackwell 정리로의 연결**

조건부분포의 모수 비의존성 때문에 불편추정량 $U(\mathbf{X})$의 조건부기댓값 $E_\theta(U \mid Y)$를 모수 없이 Y의 함수로 계산할 수 있다.

원문 대조·교정 기록 앞선 정서본에서 생략된 원본의 8.2 절 제목 및 충분통계량의 조건부분포 정의를 복원.

8.2 충분통계량: 자료의 축약과 원본 예제

충분통계량 T의 값이 주어지면 전체 표본 **X**의 조건부분포가 미지의 모수 θ에 의존하지 않는다. 따라서 원본에서 강조한 것처럼 모수 추정 시 전체 자료를 보관하지 않고 T만으로 정보를 축약(data reduction)할 수 있다. **[예제 8.2.2] 베르누이 표본 (원본의 생략 항목)**

$X_i \overset{\text{iid}}{\sim} \text{Bernoulli}(p)$이면

$$L(p;\mathbf{x}) = p^{\sum_i x_i}(1-p)^{n-\sum_i x_i}$$

이므로 $T = \sum_i X_i$는 p의 충분통계량이다. **[원본 필기] 포아송 분포에서의 충분통계량**

$X_i \overset{\text{iid}}{\sim} \text{Poisson}(\theta)$이면

$$\begin{aligned} f(\mathbf{x};\theta) &= \prod_{i=1}^{n} \frac{e^{-\theta}\theta^{x_i}}{x_i!} \\ &= \underbrace{e^{-n\theta}\theta^{\sum_i x_i}}_{g_\theta(T)} \underbrace{\prod_{i=1}^{n}(x_i!)^{-1}}_{h(\mathbf{x})}, \end{aligned}$$

$T = \sum_i X_i$가 충분통계량임을 인수분해정리로 확인한다. 원본에 표시된 'sufficient'의 예제는 이 Poisson 분해에 해당한다. **정규모형과의 연결**

$X_i \sim N(\mu, \sigma^2)$에서 σ^2가 알려지면 $\overline{X}$는 μ의 충분통계량이고, 둘 다 미지이면 $(\sum_i X_i, \sum_i X_i^2)$가 충분통계량이다.

원문 대조·교정 기록 원본 166쪽의 베르누이 예제(생략 표시), 포아송 표본의 곱 분해 및 자료축약 설명을 복원. 이전 정서본의 정규예제만 있던 문제를 교정.

원본 167쪽 손글씨 정서

다변량 추정과 충분통계량의 정의

확률표본 $X=(X_1,\dots,X_n)$의 밀도함수가 $f(x;\theta)$일 때, 통계량 $T(X)$가 모수 θ에 대해 충분하다는 것은 $T=t$가 주어졌을 때 X의 조건부분포가 θ에 의존하지 않는다는 뜻이다. **Neyman–Fisher 인수분해 정리**

$$\boxed{f(x;\theta)=g_\theta(T(x))h(x)}.$$

이렇게 쓸 수 있으면 T는 충분통계량이다(적절한 공통 지배측도 아래). **예제: 정규표본.** $X_i \overset{\text{iid}}{\sim} N(\mu,\sigma^2)$이고 μ,σ^2 모두 미지일 때

$$\begin{aligned} f(x;\mu,\sigma^2) &= (2\pi\sigma^2)^{-n/2}\exp\left[-\frac{1}{2\sigma^2}\sum_{i}(x_i-\mu)^2\right] \\ &= (2\pi\sigma^2)^{-n/2}\exp\left[-\frac{\sum_i x_i^2 - 2\mu\sum_i x_i + n\mu^2}{2\sigma^2}\right]. \end{aligned}$$

따라서 $T=(\sum_i X_i,\sum_i X_i^2)$ 또는 이와 일대일 대응하는 $(\bar X, S^2)$는 (μ,σ^2)에 대한 충분통계량이다($n\ge 2$).

> 원본의 $X=(X_1,\dots,X_n)$에서 $Y=T(X)$로 정보를 압축하는 그림은 전체자료 대신 T만으로 모수에 관한 우도정보를 표현할 수 있다는 의미이다.

정리 8.2.1 — 충분통계량의 인수분해정리

원본 도입: 통계량을 주었을 때 표본의 조건부분포를 직접 계산하여 모수에 의존하지 않는지 확인하는 방법은 복잡하다. 이를 대체하는 쉬운 판정법이 인수분해정리이다. **정리(Factorization theorem)**

$X_1, \ldots, X_n$의 결합밀도(또는 결합질량) $f(\mathbf{x};\theta)$가 공통 지지집합을 갖는 모형에서, 통계량 $T = u(\mathbf{X})$가 θ에 대한 충분통계량일 필요충분조건은

$$\boxed{f(\mathbf{x};\theta) = k_1(T(\mathbf{x});\theta)\, k_2(\mathbf{x})}$$

로 인수분해되는 것이다. 여기서 k_2는 θ에 의존하지 않으며 k_1의 관측자료에 대한 의존성은 T를 통해서만 나타난다. **원본 필기의 주의**

- 원본 필기는 “모수와 자료가 분리되는 곳”을 찾도록 강조한다.
- 충분통계량의 함수 $k_1(T;\theta)$에 들어간 모수의 형태가 핵심이며 $k_2(\mathbf{x})$에는 모수가 남아 있으면 안 된다.
- 그림이나 예시에서 사용하는 다른 함수를 여기의 k_1, k_2와 혼동하지 않는다.

베르누이 표본의 예시(보충)

$X_i \sim$ Bernoulli(p)이면

$$f(\mathbf{x};p) = p^{\sum_i x_i}(1-p)^{n-\sum_i x_i} \prod_i \mathbf{1}_{\{0,1\}}(x_i).$$

따라서 $T = \sum_i X_i$는 p의 충분통계량이다.

원문 대조·교정 기록 원본 168쪽의 조건부분포 설명, 정리 8.2.1, 인수분해식 및 필기 강조점을 복원.

원본 169쪽 손글씨 정서

충분통계량 예제: 이항 · 지수 · 정규모형

1. 베르누이. $X_i \overset{\text{iid}}{\sim} \text{Bernoulli}(p)$일 때

$$f(x;p) = \prod_i p^{x_i}(1-p)^{1-x_i} = p^{\sum_i x_i}(1-p)^{n-\sum_i x_i}.$$

따라서 $T = \sum_i X_i$가 p의 충분통계량이다. **2. 지수분포(발생률).** $X_i \overset{\text{iid}}{\sim} \text{Exp}(\lambda)$이면

$$f(x;\lambda) = \lambda^n e^{-\lambda \sum_i x_i} \prod_i \mathbf{1}_{x_i > 0}.$$

따라서 $T = \sum_i X_i$가 λ의 충분통계량이다. **3. 정규모형.** $X_i \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$에서 σ^2가 알려져 있으면

$$f(x;\mu) = C(x)\exp\left(\frac{\mu}{\sigma^2}\sum_i x_i - \frac{n\mu^2}{2\sigma^2}\right).$$

따라서 $T = \sum_i X_i$는 μ의 충분통계량이다. σ^2까지 미지인 경우에는 $\sum X_i^2$도 필요하다.

> 충분통계량은 유일하지 않다. T에 일대일 함수를 적용해도 동일한 정보를 담는다. 표본 크기 n은 알려진 설계상수로 취급한다.

예제 8.2.5 — Gamma 모형과 정규모형의 충분통계량

원본 인쇄 항목: (1) Gamma(α,β)**,** (2) $X_1,\dots,X_n \sim N(\mu,\sigma^2)$**. (1) Gamma 모형**

척도모수 β를 쓰면

$$f(x;\alpha,\beta)=\frac{x^{\alpha-1}e^{-x/\beta}}{\Gamma(\alpha)\beta^{\alpha}},\quad x>0.$$

독립표본에 대한 가능도에서 모수에 의존하는 항은

$$L(\alpha,\beta;\mathbf{x})\propto\frac{\exp\{(\alpha-1)\sum_i\log x_i-(1/\beta)\sum_i x_i\}}{\Gamma(\alpha)^n\beta^{n\alpha}}.$$

따라서 (α,β)가 모두 미지이면 $\left(\sum_i\log X_i,\sum_i X_i\right)$가 충분통계량이다. α를 알면 $\sum_i X_i$**,** β를 알면 $\sum_i\log X_i$만으로도 충분하다. **(2) 정규모형**

$$L(\mu,\sigma^2;\mathbf{x})\propto(\sigma^2)^{-n/2}\exp\left\{-\frac{\sum_i X_i^2-2\mu\sum_i X_i+n\mu^2}{2\sigma^2}\right\}.$$

μ,σ^2가 모두 미지이면 $\left(\sum_i X_i,\sum_i X_i^2\right)$가 충분통계량이다.

원문 대조·교정 기록 기존의 “정리 8.2.1 인수분해정리”라는 제목은 원본 170쪽의 제목이 아님. 원문의 Gamma·정규 예제 두 항목을 복원하고 인수분해 계산을 보충.

인수분해정리 예제 — Gamma·정규분포

Gamma(α,β)에서 β를 아는 경우

독립표본의 밀도를 형상 α, 척도 β로 쓰면

$$f(x;\alpha,\beta)=\frac{x^{\alpha-1}e^{-x/\beta}}{\Gamma(\alpha)\beta^{\alpha}},\quad x>0.$$

β가 알려지고 α가 미지일 때 결합밀도의 α 의존 항은

$$\exp\left[(\alpha-1)\sum_i \log X_i - n\log\Gamma(\alpha) - n\alpha\log\beta\right]$$

이므로 $T=\sum_i \log X_i$가 충분통계량이다. **정규분포 예제**

$X_i \overset{\text{iid}}{\sim} N(\mu,\sigma^2)$에서 σ^2를 알면

$$L(\mu)\propto \exp\left[\frac{\mu}{\sigma^2}\sum_i X_i - \frac{n\mu^2}{2\sigma^2}\right]$$

이므로 $\sum_i X_i$가 μ에 대한 충분통계량이다.

정서/검수 메모 원본의 Gamma 및 Normal 모델에 대한 인수분해정리 적용을 조판했습니다.

정리 8.2.2 — 다중모수 지수족의 충분통계량

원본 정리: 공통 지지집합이 모수에 의존하지 않는 모집단의 밀도가

$$f(x;\theta)=\exp\left\{\sum_{j=1}^{k}\eta_j(\theta)T_j(x)-A(\theta)+S(x)\right\}$$

꼴이라 하자. 독립표본 $X_1,\dots,X_n$의 결합밀도는

$$\exp\left\{\sum_{j=1}^{k}\eta_j(\theta)\sum_{i=1}^{n}T_j(X_i)-nA(\theta)+\sum_{i=1}^{n}S(X_i)\right\}.$$

따라서 인수분해정리에 의하여

$$\boxed{T(\mathbf{X})=\left(\sum_i T_1(X_i),\dots,\sum_i T_k(X_i)\right)}$$

는 θ에 대한 충분통계량이다. **원본 정규분포 예제**

$X_i \overset{\text{iid}}{\sim} N(\mu,\sigma^2)$에서 μ,σ^2가 모두 미지이면

$$L(\mu,\sigma^2;\mathbf{x})=(2\pi\sigma^2)^{-n/2}\exp\left[-\frac{1}{2\sigma^2}\left(\sum_i x_i^2-2\mu\sum_i x_i+n\mu^2\right)\right].$$

따라서 $\left(\sum_i X_i,\sum_i X_i^2\right)$가 공동 충분통계량이다.

원본 173쪽 손글씨 정서

정규표본에서 두 모수의 충분통계량

$X_1, \dots, X_n \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$, $\sigma^2 > 0$. 우도함수는

$$L(\mu, \sigma^2; x) = (2\pi\sigma^2)^{-n/2} \exp\left[-\frac{1}{2\sigma^2}\sum_i (x_i - \mu)^2\right].$$

제곱합을 전개하면

$$\sum_i (x_i - \mu)^2 = \sum_i x_i^2 - 2\mu\sum_i x_i + n\mu^2.$$

자료가 들어가는 두 위치는 $T_1 = \sum_i X_i$, $T_2 = \sum_i X_i^2$뿐이다. 따라서 인수분해 정리에 의해

$$\boxed{T(X) = \left(\sum_i X_i, \sum_i X_i^2\right) \text{ 는 } (\mu, \sigma^2)\text{에 충분}}.$$

표본평균과 표본분산으로 표현

$$\sum_i X_i = n\bar{X}, \quad \sum_i X_i^2 = (n-1)S^2 + n\bar{X}^2.$$

따라서 $n \geq 2$에서 $(\bar{X}, S^2)$도 충분통계량이다.

> 원본 필기에서 $T(X)$를 두 성분으로 만든 것은 정규분포의 미지모수가 두 개이기 때문이다. 성분 개수와 모수 차원의 관계는 모형마다 다를 수 있으므로 “모수 수만큼만 충분통계량이 존재”라고 일반화하지 않는다.

원본 174쪽 손글씨 정서

조건부분포로 확인하는 충분통계량의 뜻

$T(X)$가 충분하다는 것을 직관적으로 이해하기 위해 자료의 통계량에 대한 조건부분포를 살펴보자. **예제: 두 베르누이 관측값.** $X_1, X_2 \overset{\text{iid}}{\sim} \text{Bernoulli}(p)$이고 $T = X_1 + X_2$이다. $T = 1$인 경우에 가능한 자료는 $(1,0)$과 $(0,1)$이며

$$\mathsf{P}_p((X_1, X_2) = (1,0) \mid T = 1) = \frac{p(1-p)}{2p(1-p)} = \frac{1}{2}.$$

다른 경우도 $1/2$이므로 T를 안 뒤 남는 배열정보는 p에 의존하지 않는다. **일반적인 독립 베르누이 표본**

$$\mathsf{P}_p(X = x \mid T = t) = \binom{n}{t}^{-1}, \qquad \sum_i x_i = t.$$

가능한 $\binom{n}{t}$개의 배열이 같은 조건부확률을 갖는다. **인수분해에 따른 확인**

$$f(x; p) = p^{T(x)}(1-p)^{n-T(x)} \quad (x_i \in \{0,1\}),$$

이며 오른쪽에서 자료는 $T(x)$로만 나타난다.

> 원본의 $p(X = x \mid Y = y)$ 관련 필기를 분자 $\mathsf{P}(X = x, T = y)$, 분모 $\mathsf{P}(T = y)$의 비로 정리했다. 조건부분포에서 모수가 소거되는 것이 핵심이다.

정리 8.2.3 — 충분통계량의 일대일 함수

원본 정리: $T = T(X_1, \ldots, X_n)$가 모수 θ에 관한 충분통계량이고 $W = h(T)$가 T의 일대일 함수이면 W도 충분통계량이다. **증명 — 조건부분포 관점**

h가 일대일이면 $T = h^{-1}(W)$로 복원할 수 있다. 따라서 W를 알았을 때의 표본 조건부분포는 T를 알았을 때의 조건부분포와 동일하다. 후자는 θ에 의존하지 않으므로 W도 충분통계량이다. **인수분해정리를 이용한 설명**

원래 결합밀도가 $f(\mathbf{x};\theta) = g_\theta(T(\mathbf{x}))h_0(\mathbf{x})$로 나타나면

$$f(\mathbf{x};\theta) = g_\theta(h^{-1}(W(\mathbf{x})))h_0(\mathbf{x}),$$

따라서 W도 인수분해정리의 충분성 조건을 만족한다. **원본 필기의 정규분포 예제**

$X_i \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$에서 둘 다 미지일 때

$$T = \left(\sum_i X_i, \sum_i X_i^2\right) \longleftrightarrow W = (\overline{X}, S^2)$$

는 고정된 $n \geq 2$에서 서로 일대일로 변환된다. 따라서 두 통계량 벡터는 모두 (μ, σ^2)의 충분통계량이다.

모집단 지지집합이 모수에 의존할 때의 충분통계량

원본 도입: 모집단분포의 토대(지지집합)가 모수에 의존하면 통계량의 충분성을 판단할 때 지지집합을 주의해야 한다. **예제 8.2.8 — 지지집합이 미지구간에 의존하는 모형**

$X_1, \dots, X_n$이 $U(\theta_1, \theta_2)$ $(\theta_1 < \theta_2)$의 독립표본이면

$$\begin{aligned} f(\mathbf{x}; \theta_1, \theta_2) &= (\theta_2 - \theta_1)^{-n} \prod_{i=1}^{n} \mathbf{1}_{(\theta_1, \theta_2)}(x_i) \\ &= (\theta_2 - \theta_1)^{-n} \mathbf{1}_{\{\theta_1 < X_{(1)} \le X_{(n)} < \theta_2\}}. \end{aligned}$$

따라서 $T = (X_{(1)}, X_{(n)})$은 (θ_1, θ_2)에 대한 충분통계량이다. 표본의 나머지 좌표는 가능도에서 모수의 지지조건에 더 들어가지 않는다. **예제 8.2.9 — $U(\theta_1, \theta_2)$의 대안 표현**

$U(0, \theta)$로 제한한 경우에는 최댓값 $M = X_{(n)}$만으로 충분하다.

$$L(\theta; \mathbf{x}) = \theta^{-n} \mathbf{1}_{\{0 < X_{(1)},\, X_{(n)} < \theta\}}, \qquad T(\mathbf{X}) = X_{(n)}.$$

원문 대조·교정 기록 원본 176쪽의 “지지집합 의존” 경고, 2모수 균등분포 예제 및 최댓값에 관한 필기를 복원.

원본 177 쪽 [정리 8.2.4] ML 추정량과충분통계량

원본인쇄정리

모집단밀도가 $f(x;\theta)$ ($\theta \in \Omega$) 이고독립표본 $X_1, \dots, X_n$ 을이용한 θ 의 ML 추정량 $\widehat{\theta}_{\mathrm{ML}}$ 이유일하게존재한다면, **임의의충분통계량** $S = u(X_1, \dots, X_n)$ 의함수로표현할수있다.

$$\boxed{\widehat{\theta}_{\mathrm{ML}} = g(S).}$$

원본필기증명: 인수분해정리활용

S 가충분통계량이면결합가능도는

$$L(\theta; \boldsymbol{x}) = a_\theta(u(\boldsymbol{x}))\, h(\boldsymbol{x})$$

로인수분해된다. 여기서 $h(\boldsymbol{x})$ 는 θ 를포함하지않는다. 고정된자료 $\boldsymbol{x}$ 에대해 L 을최대화하는일은 $a_\theta(S)$ 를최대화하는것과같다. 최대화값이유일하면그위치는 S 에의해서만결정되므로 $\widehat{\theta}_{\mathrm{ML}} = g(S)$ 이다.

원본다음예제: 포아송 $e^{-\theta}$ 의추정

$X_1, \dots, X_n \overset{\text{iid}}{\sim} \mathrm{Pois}(\theta)$ 에서

$$L(\theta) = e^{-n\theta}\theta^{\sum_i X_i} \Big/ \prod_i X_i!, \quad S = \sum_i X_i \text{ 는충분통계량이다.}$$

로그가능도미분을통해 $\widehat{\theta}_{\mathrm{ML}} = S/n = \bar{X}$ 이다. 추정대상이

$$\eta(\theta) = P_\theta(X = 0) = e^{-\theta}$$

라면 MLE 불변성으로

$$\boxed{\widehat{\eta}_{\mathrm{ML}} = e^{-\bar{X}}.}$$

검산·보충: 이전정서본의지수분포발생률 λ 예시는원본하단의포아송 $\eta(\theta) = e^{-\theta}$ 예제를대신하지못한다. 원본의정리, 필기증명, 예제도입을함께복원했다.

충분통계량 — Minimal Sufficient Statistic

정의 — 최소충분통계량

충분통계량 T가 다른 모든 충분통계량 S의 함수로 나타나면 T를 **최소충분통계량**이라 한다. 즉 $T = h(S)$이다. **모수와 관련된 표본의 정보**

최소충분통계량은 충분성을 잃지 않는 범위에서 표본을 가장 많이 요약한다. 단순히 통계량의 차원이 작다는 것만으로 최소충분성을 단정할 수는 없다. **정규모형 예제**

$X_i \sim N(\mu, \sigma^2)$에서 σ를 알면 $\sum_i X_i$는 최소충분통계량이다. 두 모수가 모두 미지이면 $(\sum_i X_i, \sum_i X_i^2)$가 최소충분통계량이다. **우도비 판정법 (보충)**

적절한 정칙조건 아래 표본 x, y에 대해 $f_\theta(x)/f_\theta(y)$가 θ에 의존하지 않을 필요충분조건이 $T(x) = T(y)$라면 T는 최소충분통계량이다.

정서/검수 메모 원본의 최소충분 정의와 Normal 예제 필기를 조판했습니다.

정리 8.2.5 — 충분통계량을 이용한 추정량 개선(Rao–Blackwell)

$X_1, \ldots, X_n$의 분포가 모수 θ를 포함하고, $Y = u(X_1, \ldots, X_n)$가 θ의 충분통계량이라고 하자. $\widehat{\eta}$가 $\eta(\theta)$의 불편추정량이면

$$\boxed{\widehat{\eta}^{RB}(Y) = E_\theta[\widehat{\eta}(X_1, \ldots, X_n) \mid Y]}$$

는 Y의 함수로서 모수를 알 필요 없이 계산할 수 있고, 역시 불편추정량이다. **(1) 불편성의 증명**

$$E_\theta[\widehat{\eta}^{RB}(Y)] = E_\theta[E_\theta(\widehat{\eta} \mid Y)] = E_\theta\widehat{\eta} = \eta(\theta).$$

(2) 분산과 평균제곱오차 감소

전분산법칙으로

$$\mathrm{Var}(\widehat{\eta}) = E_\theta\,\mathrm{Var}(\widehat{\eta} \mid Y) + \mathrm{Var}(E_\theta(\widehat{\eta} \mid Y))\,.$$

그러므로

$$\boxed{\mathrm{Var}(\widehat{\eta}^{RB}) \le \mathrm{Var}(\widehat{\eta}).}$$

두 추정량이 불편이므로 $\mathrm{MSE}(\widehat{\eta}^{RB}) \le \mathrm{MSE}(\widehat{\eta})$. 등호는 $\widehat{\eta}$가 거의 확실하게 Y의 함수인 경우다. **충분성의 역할**

충분통계량의 조건부분포가 모수에 의존하지 않으므로 $E_\theta(\widehat{\eta} \mid Y)$를 관측된 Y만의 함수로 계산할 수 있다.

원본 180쪽 손글씨 정서

Rao–Blackwell 정리와 조건부기대값

$\delta(X)$가 $g(\theta)$의 불편추정량이고 $T(X)$가 충분통계량이라 하자. 새 추정량을

$$\delta^*(T) = \mathsf{E}[\delta(X) \mid T]$$

로 정의한다. 조건부기대값의 반복법칙으로

$$\mathsf{E}_\theta\, \delta^*(T) = \mathsf{E}_\theta\, \delta(X) = g(\theta).$$

또한 전체분산법칙에서

$$\mathsf{Var}_\theta(\delta) = \mathsf{Var}_\theta(\mathsf{E}[\delta \mid T]) + \mathsf{E}_\theta[\mathsf{Var}(\delta \mid T)]$$

이므로

$$\boxed{\mathsf{Var}_\theta(\delta^*) \le \mathsf{Var}_\theta(\delta)}.$$

등호 조건. $\mathsf{Var}(\delta \mid T) = 0$이 거의 확실히 성립할 때 등호가 된다. **예제: 베르누이.** $X_i \overset{\text{iid}}{\sim} \text{Bernoulli}(p)$이고 $T = \sum_i X_i$라면

$$\mathsf{E}(X_1 \mid T) = T/n = \bar{X}, \quad \mathsf{Var}(X_1) = p(1-p), \quad \mathsf{Var}(\bar{X}) = p(1-p)/n.$$

> 원본의 점선 그래프는 조건부 평균을 취하면 추정량의 불필요한 변동성이 줄어드는 것을 뜻한다. 수식을 통해 정리의 정확한 적용 조건을 확인한다.

Rao–Blackwell 정리의 증명 연결 — 예제 8.2.10

원본 인쇄 구성: [증명] 후에 $X_1, \ldots, X_n \sim U(0,\theta)$ 예제가 과제로 제시되어 있다. **Rao–Blackwell 부등식의 증명**

U가 $g(\theta)$의 불편추정량이고 S가 충분통계량이라고 하자. $\delta(S) = E(U \mid S)$는 충분성에 따라 모수에 의존하지 않는 통계량으로 나타낼 수 있다.

$$E\delta(S) = EU = g(\theta), \qquad \mathrm{Var}(U) = E\{\mathrm{Var}(U \mid S)\} + \mathrm{Var}\{E(U \mid S)\}.$$

따라서 $\mathrm{Var}\,\delta(S) \le \mathrm{Var}(U)$이다. **예제 8.2.10 — $U(0,\theta)$의 불편추정량 개선 (보충 풀이)**

$M = X_{(n)}$이면 $f_M(m;\theta) = nm^{n-1}/\theta^n$ $(0 < m < \theta)$이므로 $EM = n\theta/(n+1)$이다. 따라서

$$\widehat{\theta} = \frac{n+1}{n} M \quad \text{는} \quad E\widehat{\theta} = \theta.$$

또 $U = 2X_1$은 불편추정량이고

$$E(X_1 \mid M = m) = \frac{1}{n} m + \frac{n-1}{n}\frac{m}{2} = \frac{n+1}{2n} m,$$

따라서 $E(2X_1 \mid M) = (n+1)M/n$이다. M은 완비충분통계량이므로 이 추정량은 UMVUE이다.

원문 대조·교정 기록 원본의 [증명] 및 균등분포 예제 8.2.10을 복원하고 표시된 Report 문제의 풀이를 보충.

원본 182쪽 손글씨 정서

포아송분포에서 $e^{-\theta}$의 불편추정량

$X_i \overset{\text{iid}}{\sim} \text{Poisson}(\theta)$이며 목표 모수함수는 $g(\theta) = \mathsf{P}_\theta(X=0) = e^{-\theta}$이다. 원본의 첫 추정량은

$$\delta(X) = \mathbf{1}_{\{X_1=0\}}, \qquad \mathsf{E}_\theta\,\delta(X) = e^{-\theta}.$$

$T = \sum_i X_i \sim \text{Poisson}(n\theta)$는 θ에 대한 완비충분통계량이다. $T=t$가 주어지면 $X_1 \mid T=t \sim \text{Binomial}(t, 1/n)$이므로

$$\delta^*(T) = \mathsf{E}[\mathbf{1}_{\{X_1=0\}} \mid T] = \mathsf{P}(X_1=0 \mid T) = \boxed{\left(1-\frac{1}{n}\right)^{T}}.$$

$\mathsf{E}[(1-1/n)^T] = \exp\{n\theta[(1-1/n)-1]\} = e^{-\theta}$로 불편성을 직접 확인할 수 있다. **결론.** $\delta^*(T)$는 Lehmann–Scheffé 정리에 따라 $e^{-\theta}$의 UMVUE이다.

> $n=1$의 경우는 0^T를 $T=0$에서 1, $T>0$에서 0으로 해석한다. 원본 빨간 계산은 조건부 이항분포의 성공확률을 이용한 Rao–Blackwell 과정이다.

원본 183쪽 손글씨 정서

포아송의 UMVUE 검산: 기댓값과 분산

앞 쪽에서 얻은 $\delta^*(T) = (1-1/n)^T$를 $a = 1-1/n$으로 간단히 쓴다. $T \sim \text{Poisson}(n\theta)$의 확률생성함수는

$$G_T(s) = \mathsf{E}(s^T) = \exp\{n\theta(s-1)\}.$$

따라서

$$\mathsf{E}[\delta^*(T)] = G_T(a) = e^{-\theta}, \quad \mathsf{E}[\delta^*(T)^2] = G_T(a^2).$$

$a^2 - 1 = -2/n + 1/n^2$이므로

$$G_T(a^2) = \exp\left(-2\theta + \frac{\theta}{n}\right).$$

결국

$$\boxed{\mathsf{Var}(\delta^*(T)) = e^{-2\theta}(e^{\theta/n} - 1)}.$$

원래 추정량 $\delta(X) = \mathbf{1}_{\{X_1=0\}}$의 분산은

$$\mathsf{Var}(\delta) = e^{-\theta}(1 - e^{-\theta}).$$

Rao–Blackwell 정리에 따라 새 추정량의 분산이 원래 추정량보다 크지 않다.

> 원본 필기의 $\mathsf{E}[a^{2T}]$ 계산은 $G_T(a^2)$에 a^2를 b정확히 대입c해야 한다. a를 대입하면 제곱의 기댓값이 아니라 평균을 다시 구하는 오류가 된다.

원본 184쪽 손글씨 정서

조건부기대값을 활용한 불편추정량 개선

$\delta(X)$가 $g(\theta)$의 불편추정량이고 $T(X)$가 충분통계량이라면

$$\delta^*(T) = \mathsf{E}(\delta \mid T)$$

또한 불편추정량이다. 더 나아가 제곱손실에서

$$\mathsf{E}[(\delta - g(\theta))^2] = \mathsf{E}[(\delta - \delta^*)^2] + \mathsf{E}[(\delta^* - g(\theta))^2],$$

왜냐하면 $\mathsf{E}[(\delta - \delta^*)(\delta^* - g(\theta))] = 0$이기 때문이다. 따라서 δ^*의 평균제곱오차가 더 작거나 같다. **포아송 모형에서 평균의 개선** $X_i \overset{\text{iid}}{\sim} \text{Poisson}(\theta)$에 대해 $\delta = X_1$을 쓰면

$$\delta^* = \mathsf{E}(X_1 \mid \textstyle\sum_j X_j) = \frac{1}{n}\sum_j X_j = \bar{X}.$$

$$\mathsf{MSE}(X_1) = \theta, \qquad \mathsf{MSE}(\bar{X}) = \frac{\theta}{n}.$$

> 원본의 $\hat\theta$와 $\mathsf{E}(\hat\theta \mid T)$를 비교하는 계산은 조건부기대값의 직교투영 성질로도 해석할 수 있다.

8.2 — 충분하지 않은 통계량에서 출발한 Rao–Blackwell 개선

원본 질문: $Y = u(X_1, \ldots, X_n)$가 충분통계량이 아닐 때는 어떻게 추정량을 개선하는가? **원본 필기 예제: 정규표본**

$X_1, X_2 \overset{\text{iid}}{\sim} N(\mu, 1)$에서 $Y = X_1$은 μ의 불편추정량이지만 충분통계량이 아니다. 이때 $S = X_1 + X_2$는 μ에 대한 충분통계량이다. **Rao–Blackwell 개선 추정량**

결합정규분포의 조건부기대값 공식을 이용하면

$$\begin{aligned} E_\mu[X_1 \mid S] &= E(X_1) + \frac{\mathrm{Cov}(X_1, S)}{\mathrm{Var}(S)}(S - E(S)) \\ &= \mu + \frac{1}{2}(S - 2\mu) = \frac{X_1 + X_2}{2} = \overline{X}. \end{aligned}$$

따라서 $\overline{X}$는 불편이면서

$$\mathrm{Var}_\mu(\overline{X}) = \frac{1}{2} < 1 = \mathrm{Var}_\mu(X_1)$$

을 만족한다. 정보량을 더 많이 보존하는 충분통계량에 조건부기대값을 취한 결과이다. **주의**

$Y = X_1$에 대하여 $E(Y \mid Y) = Y$는 개선이 아니다. 충분통계량 S를 조건부기대값의 조건으로 사용해야 한다.

8.3 완비성을 이용한 UMVUE 찾는 방법

원문 구조: 충분통계량을 이용하면 불편추정량의 분산을 개선할 수 있지만, 그렇게 얻은 추정량의 유일성은 완비성에 의해 보장한다. **정리 8.2.5 — Rao–Blackwell 정리의 역할**

S가 충분통계량이고 $U(X)$가 $g(\theta)$의 임의의 불편추정량일 때

$$\delta(S) = E_\theta[U(X) \mid S], \quad E_\theta[\delta(S)] = g(\theta), \quad \mathrm{Var}_\theta(\delta(S)) \le \mathrm{Var}_\theta(U).$$

정의 — 완비통계량과 완비충분통계량(CSS)

통계량 S에 대해 모든 $\theta \in \Theta$에서 $E_\theta[h(S)] = 0$이면 $P_\theta\{h(S) = 0\} = 1$이 성립할 때 S를 **완비**라 한다. 충분하면서 완비이면 **완비충분통계량**이다. **원본에서 제기하는 질문**

충분통계량으로 조건부기대값을 취했을 때, 서로 다른 불편추정량에서 출발해도 같은 결과가 나오는가? 완비충분통계량일 경우 그 값은 거의 확실하게 유일하다. **연결 정리**

이 유일성과 Rao–Blackwell 정리를 결합하면 Lehmann–Scheffé 정리를 얻는다(이후 원본 193쪽에 이어짐).

원문 대조·교정 기록 원본 186쪽의 새로운 절 제목, Rao–Blackwell 소개, 완비·완비충분통계량의 정의를 복원했습니다. 기존 균등분포 최대값 증명은 이 페이지 내용이 아니므로 대체했습니다.

원본 187쪽 손글씨 정서

완비성(completeness)의 정의와 예제

통계량 $T(X)$의 분포가 $\{P_\theta^T : \theta \in \Theta\}$일 때

$$\mathsf{E}_\theta\, h(T) = 0 \quad \forall \theta \in \Theta \quad \Longrightarrow \quad \mathsf{P}_\theta\{h(T) = 0\} = 1 \quad \forall \theta$$

가 성립하면 T는 완비통계량이다. **예제: 포아송표본합.** $T = \sum_i X_i \sim \mathsf{Poisson}(n\theta)$, $\theta > 0$.

$$0 = \mathsf{E}_\theta\, h(T) = e^{-n\theta} \sum_{t=0}^{\infty} h(t) \frac{(n\theta)^t}{t!}.$$

모든 $\theta > 0$에서 우변이 0이면 멱급수의 유일성으로 $h(t) = 0$ $(t = 0, 1, 2, \ldots)$이므로 T는 완비하다. **불편추정량의 유일성.** $g_1(T), g_2(T)$가 모두 같은 $g(\theta)$의 불편추정량이면 $\mathsf{E}_\theta[g_1(T) - g_2(T)] = 0$이다. 완비성에 의해 $g_1(T) = g_2(T)$가 거의 확실히 성립한다.

> 완비성은 “표본의 정보가 충분하다”와 다른 성질이다. Lehmann–Scheffé 정리는 완비성과 충분성을 함께 이용한다.

원본 188쪽 손글씨 정서

지수분포 표본합의 완비충분성

$X_i \overset{\text{iid}}{\sim} \text{Exp}(\lambda)$이고 $f(x;\lambda) = \lambda e^{-\lambda x}\mathbf{1}_{x>0}$ ($\lambda > 0$)이다. 표본의 결합밀도는

$$f(x;\lambda) = \lambda^n \exp(-\lambda \textstyle\sum_i x_i) \prod_i \mathbf{1}_{x_i>0}.$$

따라서 $T = \sum_i X_i$는 인수분해 정리에 의해 충분통계량이다. $T \sim \text{Gamma}(n, \text{rate } \lambda)$이고

$$f_T(t;\lambda) = \frac{\lambda^n}{\Gamma(n)} t^{n-1} e^{-\lambda t}, \qquad t > 0.$$

만약 모든 $\lambda > 0$에서 $\mathsf{E}_\lambda\, h(T) = 0$이면

$$\int_0^\infty h(t) t^{n-1} e^{-\lambda t}\, dt = 0 \qquad \forall \lambda > 0.$$

라플라스 변환의 유일성(적절한 적분가능성 아래)에 따라 $h(t) = 0$ 거의 어디서나. 따라서 T는 완비하다.

> 원본의 $T = \sum X_i$와 $\lambda^n \exp(-\lambda T)$가 결합밀도에서 나타나는 것이 핵심이다. 정률모수(rate)인지 척도모수(scale)인지 표기한다.

8.3 예제 — 완비충분통계량의 확인

예 8.3.1: 베르누이 표본

$X_1, \dots, X_n \overset{\text{iid}}{\sim} \text{Bernoulli}(p), 0 < p < 1$이면 $T = \sum_i X_i \sim \text{Bin}(n, p)$가 충분통계량이다. 모든 $p \in (0,1)$에서 $E_p[g(T)] = 0$라면

$$\sum_{t=0}^{n} g(t) \binom{n}{t} p^t (1-p)^{n-t} = 0 \qquad (\forall p \in (0,1)).$$

좌변은 p에 관한 Bernstein 기저다항식의 선형결합이므로 $g(0) = \cdots = g(n) = 0$. 따라서 T는 완비충분통계량이다. **예 8.3.6: $U(0,\theta)$의 최대순서통계량**

$X_i \overset{\text{iid}}{\sim} U(0,\theta), \theta > 0$, $M = X_{(n)}$이면

$$f_M(m;\theta) = \frac{n m^{n-1}}{\theta^n} \mathbf{1}_{(0,\theta)}(m).$$

모든 $\theta > 0$에 대해 $E_\theta[h(M)] = 0$이면

$$\int_0^\theta h(m) m^{n-1}\, dm = 0 \quad \forall \theta > 0.$$

이를 θ로 미분하면 $h(\theta)\theta^{n-1} = 0$이므로 $h(M) = 0$ 거의 확실하게 성립한다. M은 θ의 충분통계량이기도 하므로 완비충분통계량이다.

원문 대조·교정 기록 원본 189쪽의 베르누이 및 $U(0,\theta)$ 완비충분통계량 예제를 복원했습니다. 기존 Lehmann–Scheffé 설명은 원본 193쪽에서 다룹니다.

Uniform$(0,\theta)$ — 충분통계량과 순서통계량 분포

원본 필기: $X_1,\dots,X_n \overset{\text{iid}}{\sim} U(0,\theta)$, $\theta>0$에서 $Y=X_{(n)}$를 쓴다. **(1) 결합밀도의 인수분해**

$$f(\mathbf{x};\theta)=\prod_{i=1}^{n}\frac{1}{\theta}\mathbf{1}_{(0,\theta)}(x_i)=\theta^{-n}\mathbf{1}_{\{0<x_{(1)}\}}\mathbf{1}_{\{x_{(n)}<\theta\}}.$$

인수분해정리에 따라 최댓값 $Y=X_{(n)}$은 θ의 충분통계량이다. **(2) 최댓값의 밀도**

$0<y<\theta$에서

$$F_Y(y)=P(X_1\le y,\dots,X_n\le y)=\left(\frac{y}{\theta}\right)^n.$$

따라서

$$\boxed{f_Y(y;\theta)=\frac{n}{\theta}\left(\frac{y}{\theta}\right)^{n-1}\mathbf{1}_{(0,\theta)}(y).}$$

원본 필기의 두 계산은 충분성과 순서통계량의 밀도 공식에 대응한다.

완비충분통계량: 반례 및 정규모집단 사례

(1) 위치가 이동한 균등분포

$$X_1, \dots, X_n \overset{\text{iid}}{\sim} U\left(\theta - \frac{1}{2}, \theta + \frac{1}{2}\right), \quad \theta \in \mathbb{R}.$$

가능도함수는 다음 구간에서 1이다.

$$L(\theta; \mathbf{x}) = \prod_i \mathbf{1}\{\theta - \tfrac{1}{2} < x_i < \theta + \tfrac{1}{2}\} = \mathbf{1}\{x_{(n)} - \tfrac{1}{2} < \theta < x_{(1)} + \tfrac{1}{2}\}.$$

그러므로 $Y = (X_{(1)}, X_{(n)})$는 θ에 대한 충분통계량이다. 하지만 표본범위 $R = X_{(n)} - X_{(1)}$의 분포는 위치모수 θ와 무관하다.

$$E_\theta(R) = \frac{n-1}{n+1}, \qquad E_\theta\left[R - \frac{n-1}{n+1}\right] = 0.$$

$R - (n-1)/(n+1)$는 영함수가 아니므로 Y는 완비가 아니다. **(2)** $X_i \sim N(\mu, \mu^2)$ **반례 메모**

원본에 쓰인 후보 통계량은 $\left(\sum_i X_i, \sum_i X_i^2\right)$ 및 $(\bar{X}, S^2)$이다. 완비성 검토는 모수공간과 영기댓값 함수의 정의를 정확히 고정해야 한다.

정서/검산 메모 원본의 두 예시를 구분하고, 균등위치분포 반례에 대한 증명을 완결했습니다.

완비성 반례 — 영기댓값 함수의 확인

원본에서 이어진 식:

$$E_\theta[g(Y)] = 0 \quad \text{이면서} \quad P_\theta(g(Y) \neq 0) > 0 \text{ 인 함수를 찾는다.}$$

원본은

$$\boxed{g(X) = S^2 - \frac{n}{n+1}\bar{X}^2}$$

꼴의 후보를 필기하고 있다. **대조 시 주의사항**

이 식이 정말 영기댓값을 갖는지는 **모형과 S^2의 분모 정의**에 의존한다. 원본 앞 페이지의 $N(\mu, \mu^2)$ 모형에서 S^2가 통상의 불편표본분산($n-1$로 나눈 분산)이라면

$$E_\mu(S^2) = \mu^2, \qquad E_\mu(\bar{X}^2) = \mu^2 + \frac{\mu^2}{n} = \frac{n+1}{n}\mu^2,$$

따라서 실제로

$$E_\mu\left[S^2 - \frac{n}{n+1}\bar{X}^2\right] = 0.$$

정서/검산 메모 원본의 간단한 필기에 정의와 계산을 보충해, 계수 $n/(n+1)$의 의미를 검산했습니다.

추정론에서 완비성의 의미 — Lehmann–Scheffé 정리

원본 설명: 완비통계량의 함수로서 불편추정량의 유일성

$Y = u(X_1, \ldots, X_n)$가 완비통계량이라고 하자. $g_1(Y)$, $g_2(Y)$가 동일한 모수함수 $\eta(\theta)$의 불편추정량이면

$$E_\theta[g_1(Y) - g_2(Y)] = 0 \quad (\forall \theta \in \Theta).$$

완비성에 따라 $P_\theta\{g_1(Y) = g_2(Y)\} = 1$이다. 즉 완비통계량의 함수인 불편추정량은 거의 확실하게 유일하다. **정리 8.3.1 (Lehmann–Scheffé)**

Y가 θ의 완비충분통계량이고 $T(X)$가 $\eta(\theta)$의 임의의 불편추정량이면

$$\boxed{\delta(Y) = E_\theta[T(X) \mid Y] \text{는 } \eta(\theta)\text{의 유일한 UMVUE이다.}}$$

증명 보충

Rao–Blackwell 정리에 의하여 $\delta(Y)$는 불편이고 임의의 불편추정량보다 분산이 크지 않다. Y의 서로 다른 불편함수 δ_1, δ_2가 있다면 그 차의 기댓값이 모든 θ에서 0이므로 완비성에 의해 둘이 거의 확실하게 같다.

원문 대조·교정 기록 원본 193쪽의 완비성 해석 및 정리 8.3.1을 복원했습니다. 이전 정서본의 Basu 정리는 원본 206쪽에 해당하므로 이 페이지에서 제외했습니다.

원본 194쪽 손글씨 정서

완비성이 불편추정량의 유일성을 보장하는 이유

T가 완비통계량이고 $g_1(T), g_2(T)$가 모두 $g(\theta)$의 불편추정량이라고 하자. 그러면

$$\mathsf{E}_\theta\{g_1(T) - g_2(T)\} = g(\theta) - g(\theta) = 0 \quad \forall \theta.$$

완비성에 의해 $g_1(T) = g_2(T)$가 거의 확실하게 성립한다. **Rao–Blackwell과의 결합** 임의의 불편추정량 $\delta(X)$를 충분통계량 T에 관해 조건화하면

$$\delta^*(T) = \mathsf{E}[\delta(X) \mid T], \quad \mathsf{E}\,\delta^* = g(\theta), \quad \mathsf{Var}(\delta^*) \le \mathsf{Var}(\delta).$$

T가 추가로 완비하면 모든 불편추정량을 조건화한 값이 동일하므로 δ^*는 유일한 UMVUE이다. **Lehmann–Scheffé 정리**

$$\boxed{T \text{ 완비충분}, \quad \delta(T) \text{ 불편} \implies \delta(T) \text{는 UMVUE.}}$$

> 원본의 그래프는 불편추정량의 평균이 동일한 목표 $g(\theta)$를 따르면서 분산이 달라질 수 있음을 뜻한다. 완비성만 있고 충분성이 없으면 이 정리를 그대로 쓸 수 없다.

증명 8.3.1 — Lehmann–Scheffé 정리와 예제

Y가 완비충분통계량이고, T가 $\eta(\theta)$의 불편추정량이면

$$\delta(Y) = E_\theta(T \mid Y), \qquad E_\theta \delta(Y) = \eta(\theta).$$

Rao–Blackwell 정리에 의해

$$\mathrm{Var}_\theta(\delta(Y)) \le \mathrm{Var}_\theta(T).$$

만약 $\delta_1(Y), \delta_2(Y)$가 모두 불편하면

$$E_\theta[\delta_1(Y) - \delta_2(Y)] = 0 \quad (\forall \theta),$$

완비성으로부터 $\delta_1(Y) = \delta_2(Y)$가 거의 확실하게 성립한다. **완비충분통계량으로 UMVUE 찾기**

(1) Y의 함수 중 불편추정량을 직접 찾거나, (2) 쉬운 불편추정량 T를 조건부기댓값 $E(T \mid Y)$로 바꾼다. **예 8.3.7 — Bernoulli 표본**

$X_i \overset{\text{iid}}{\sim} B(1,p)$, $Y = \sum_i X_i \sim \mathrm{Bin}(n,p)$는 완비충분통계량이다.

$$E(Y) = np, \qquad \boxed{\hat{p} = Y/n = \bar{X} \quad (\text{UMVUE}).}$$

또한 $g(p) = p(1-p)$에 대해

$$E\left[\frac{Y(n-Y)}{n(n-1)}\right] = p(1-p), \quad n > 1,$$

이 역시 Y의 불편함수이므로 UMVUE이다.

정서/검산 메모 원본의 p, $p(1-p)$ 예제를 각각 정리하고 불편성을 계산했습니다.

원본 196쪽 손글씨 정서

포아송 표본의 θ^2 UMVUE 직접 검산

$X_i \overset{\text{iid}}{\sim} \text{Poisson}(\theta)$에서 $T = \sum_i X_i \sim \text{Poisson}(n\theta)$이다. 확률생성함수 $G_T(s) = \exp\{n\theta(s-1)\}$에 두 번 미분하면

$$\mathsf{E}[T(T-1)] = G_T''(1) = (n\theta)^2.$$

따라서

$$\boxed{\hat{g}(T) = \frac{T(T-1)}{n^2}, \qquad \mathsf{E}\,\hat{g} = \theta^2.}$$

T는 완비충분통계량이므로 $\hat{g}$는 θ^2의 UMVUE이다. **단순히 $\bar{X}^2$는 왜 안 되는가?**

$$\mathsf{E}(\bar{X}^2) = \mathsf{Var}(\bar{X}) + \{\mathsf{E}(\bar{X})\}^2 = \frac{\theta}{n} + \theta^2.$$

$\bar{X}^2$는 θ^2에 대해 상향편향되어 있다. 이를 보정하면

$$\bar{X}^2 - \frac{\bar{X}}{n} = \frac{T^2 - T}{n^2} = \frac{T(T-1)}{n^2}.$$

> 원본의 T와 T^2 모멘트 계산을 기댓값, 분산, 불편보정의 순서로 다시 배열했다.

예 8.3.6 — $U(0,\theta)$의 UMVUE

$X_1,\dots,X_n \overset{\text{iid}}{\sim} U(0,\theta)$, $Y = X_{(n)}$는 θ에 대한 완비충분통계량이다.

$$f_Y(y) = \frac{n}{\theta^n} y^{n-1}, \qquad 0 < y < \theta.$$

(1) θ 추정

$$E(Y) = \int_0^\theta y \frac{n}{\theta^n} y^{n-1}\, dy = \frac{n}{n+1}\theta.$$

따라서

$$\boxed{\delta_1(Y) = \frac{n+1}{n} X_{(n)} \quad \text{은 } \theta\text{의 UMVUE.}}$$

(2) θ^2 추정

$$E(Y^2) = \int_0^\theta y^2 \frac{n}{\theta^n} y^{n-1}\, dy = \frac{n}{n+2}\theta^2.$$

$$\boxed{\delta_2(Y) = \frac{n+2}{n} X_{(n)}^2 \quad \text{은 } \theta^2\text{의 UMVUE.}}$$

원본 아래쪽의 메모

완비충분통계량(CSS)을 찾는 과정은 모형에 따라 복잡해질 수 있으며, 특정 분포에서는 상대적으로 쉽게 구할 수 있다.

정리 8.3.2 — 다중모수 지수족의 완비충분통계량

모집단 확률밀도함수가

$$f(x \mid \boldsymbol{\eta}) = \exp\Big\{\sum_{j=1}^{k} \eta_j T_j(x) - A(\boldsymbol{\eta}) + S(x)\Big\}$$

인 지수족을 따르고, (1) 지지집합이 모수에 의존하지 않으며, (2) 자연모수공간이 $\mathbb{R}^k$의 열린 집합을 포함하고, (3) 자연통계량이 비퇴화 조건을 만족한다고 하자. 그러면

$$\boxed{T(\mathbf{X}) = \left(\sum_{i=1}^{n} T_1(X_i), \dots, \sum_{i=1}^{n} T_k(X_i)\right)}$$

는 자연모수에 대한 완비충분통계량이다. **예 8.3.4, 8.3.5 — 정규모집단**

$$f(x;\mu,\sigma^2) = \frac{1}{\sqrt{2\pi}\sigma}\exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right].$$

전개하면

$$\log f(x;\mu,\sigma^2) = \frac{\mu}{\sigma^2}x - \frac{1}{2\sigma^2}x^2 - \frac{\mu^2}{2\sigma^2} - \log(\sqrt{2\pi}\sigma).$$

자연모수 $\eta_1 = \mu/\sigma^2$, $\eta_2 = -1/(2\sigma^2)$이고

$$T(\mathbf{X}) = \left(\sum_i X_i, \sum_i X_i^2\right)$$

가 완비충분통계량이다. ($\sigma^2 > 0$, $\mu \in \mathbb{R}$가 모두 미지인 완전한 정규족.)

정서/검산 메모 원본의 지수족 조건과 정규밀도 전개를 활자화했습니다.

원본 199쪽 손글씨 정서

정규모형의 충분통계량과 완비성 주의

$X_i \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$에서 μ, σ^2 모두 미지이면

$$T(X) = \left(\sum_i X_i, \sum_i X_i^2 \right)$$

가 충분통계량이다. **자연모수 형태**

$$f(x;\mu,\sigma^2) = h(x)\exp\left\{ \eta_1 \sum_i x_i + \eta_2 \sum_i x_i^2 - A(\eta) \right\},$$

$\eta_1 = \mu/\sigma^2, \eta_2 = -1/(2\sigma^2)$. 자연모수공간은 $\eta_1 \in \mathbb{R}, \eta_2 < 0$으로 내부가 열린 집합이다. 정칙 전지수족의 완비성 정리에 따라 위 자연충분통계량은 완비하다. **평균과 분산이 알려진 경우의 구별**

- σ^2 알려짐, μ 미지: $\sum_i X_i$가 충분통계량.
- μ 알려짐, σ^2 미지: $\sum_i (X_i - \mu)^2$가 충분통계량.
- 두 모수 모두 미지: $(\sum_i X_i, \sum_i X_i^2)$를 사용.

> 원본의 결합밀도에 나타나는 제곱합을 인수분해하는 과정에서 고정된 모수와 미지 모수를 정확하게 구분해야 한다.

예제 8.4.5 — Beta$(\alpha, 1)$에서 UMVUE 찾기

원본 모형: $X_1, \ldots, X_n \overset{\text{iid}}{\sim} \text{Beta}(\alpha, 1)$, 밀도

$$f(x;\alpha) = \alpha x^{\alpha-1}, \quad 0 < x < 1, \quad \alpha > 0.$$

이는 $\exp\{(\alpha-1)\log x + \log\alpha\}$ 꼴의 일모수 지수족이다. **충분·완비통계량**

$V_i = -\log X_i$로 두면 $V_i \sim \text{Exp}(\text{rate}\ \alpha)$이므로

$$S = \sum_{i=1}^{n} V_i = -\sum_i \log X_i \sim \text{Gamma}(n, \text{rate}\ \alpha).$$

S는 이 정칙 일모수 지수족의 완비충분통계량이다. $g(\alpha) = 1/\alpha$**의 UMVUE**

$$E_\alpha(V_i) = \frac{1}{\alpha}, \qquad \boxed{\widehat{1/\alpha} = \frac{S}{n} = -\frac{1}{n}\sum_i \log X_i.}$$

S/n은 완비충분통계량의 불편함수이므로 UMVUE이다. $g(\alpha) = \alpha$**의 UMVUE**

$n > 1$에서 $E_\alpha(S^{-1}) = \alpha/(n-1)$이므로

$$\boxed{\widehat{\alpha} = \frac{n-1}{-\sum_i \log X_i}.}$$

이는 완비충분통계량의 불편함수이며 UMVUE이다. $n > 2$에서는 분산이 $\alpha^2/(n-2)$이다.

원문 대조·교정 기록 원본의 Beta$(\alpha, 1)$ 모형, $-\log X_i$ 지수변환, $1/\alpha$와 α의 추정 대상을 복원했습니다. 기존의 $U(0,\theta)$ 예제는 원문과 다른 내용이어서 바로잡았습니다.

감마변환을 이용한 불편추정량

원본 메모는 $U = -\alpha \sum_{i=1}^{n} \log X_i \sim \text{Gamma}(n, 1)$인 변수를 사용한다. 감마분포의 밀도는

$$f_U(u) = \frac{u^{n-1} e^{-u}}{\Gamma(n)}, \qquad u > 0.$$

$n > 1$이면

$$E\left(\frac{1}{U}\right) = \frac{1}{\Gamma(n)} \int_0^\infty u^{n-2} e^{-u}\, du = \frac{\Gamma(n-1)}{\Gamma(n)} = \frac{1}{n-1}.$$

원본의 추정량은

$$\delta(\mathbf{X}) = \frac{n-1}{-\sum_{i=1}^{n} \log X_i} = \frac{\alpha(n-1)}{U}.$$

따라서

$$\boxed{E_\alpha[\delta(\mathbf{X})] = \alpha.}$$

정서/검산 메모 원본의 감마 적분, 감마함수 비율 및 불편성 계산을 순서대로 정리했습니다.

앞 페이지 추정량의 분산과 CRLB 비교

$U = -\alpha \sum_i \log X_i \sim \text{Gamma}(n, 1)$, $n > 2$라 하자.

$$E\left(\frac{1}{U^2}\right) = \frac{1}{\Gamma(n)} \int_0^\infty u^{n-3} e^{-u}\, du = \frac{\Gamma(n-2)}{\Gamma(n)} = \frac{1}{(n-1)(n-2)}.$$

그러므로

$$\text{Var}\left(\frac{1}{U}\right) = \frac{1}{(n-1)(n-2)} - \frac{1}{(n-1)^2} = \frac{1}{(n-1)^2(n-2)}.$$

$$\delta = \frac{\alpha(n-1)}{U} = \frac{n-1}{-\sum_i \log X_i}$$

에 대해

$$\boxed{\text{Var}_\alpha(\delta) = \frac{\alpha^2}{n-2}.}$$

원본에 제시된 Cramér–Rao 하한은

$$\text{CRLB} = \frac{1}{nI(\alpha)} = \frac{\alpha^2}{n}.$$

$\alpha^2/(n-2) > \alpha^2/n$이므로, 이 불편추정량은 일반적으로 CRLB와 같지 않다.

정서/검산 메모 원본 필기의 역감마 적분과 분산공식을 분모 괄호까지 검산했습니다.

예제 8.3.8 — 포아송 모형에서 $e^{-2\theta}$의 UMVUE

원본 추정 대상: $X_1, \dots, X_n \overset{\text{iid}}{\sim} \text{Poisson}(\theta)$이고 $g(\theta) = e^{-2\theta}$를 추정한다. **기초 불편추정량과 완비충분통계량**

$n \geq 2$에서 $U = \mathbf{1}_{\{X_1=0,\, X_2=0\}}$는 $EU = e^{-2\theta}$이다. $T = \sum_{i=1}^{n} X_i \sim \text{Poisson}(n\theta)$는 θ의 완비충분통계량이다. **조건부기대값으로 Rao–Blackwell 개선**

$T = t$가 주어지면 $(X_1, \dots, X_n)$은 Multinomial$(t; 1/n, \dots, 1/n)$을 따른다. 따라서

$$\begin{aligned} E[U \mid T = t] &= P(X_1 = X_2 = 0 \mid T = t) \\ &= \left(1 - \frac{2}{n}\right)^{t}. \end{aligned}$$

$$\boxed{\widehat{g}_{\text{UMVUE}} = \left(1 - \frac{2}{n}\right)^{\sum_i X_i} \qquad (n \geq 2).}$$

검산하면 $E[a^T] = e^{n\theta(a-1)}$이고 $a = 1 - 2/n$이므로 $E\widehat{g} = e^{-2\theta}$이다. **원본 주의: 분산 비교**

U와 $E(U \mid T)$는 둘 다 불편이지만, Rao–Blackwell 정리에 따라 후자의 분산이 더 작거나 같다. 이는 최대가능도추정량 $e^{-2\overline{X}}$과는 일반적으로 다른 통계량이다.

원문 대조·교정 기록 기존 정서본이 $e^{-2\theta}$ 대신 $e^{-\theta}$의 UMVUE로 변경한 심각한 추정대상 오류 수정.

정의 — 보조통계량(Ancillary statistic)

통계량 $Z = v(X_1, \ldots, X_n)$의 분포가 모수 θ에 의존하지 않으면 Z를 보조통계량이라 한다. **예 1:** $X_i \overset{\text{iid}}{\sim} N(\mu, 1)$

$$Z_1 = X_1 - X_2 \sim N(0, 2), \qquad Z_2 = X_1 - \bar{X} \sim N\left(0, \frac{n-1}{n}\right).$$

따라서 둘 다 μ에 대한 보조통계량이다. 또한

$$\frac{X_1 - X_2}{\sqrt{2}} \sim N(0, 1), \qquad \sqrt{\frac{n}{n-1}}(X_1 - \bar{X}) \sim N(0, 1).$$

예 2: $X_i \overset{\text{iid}}{\sim} \text{Exp}(\theta)$

원본의 통계량

$$\boxed{Z = \frac{X_1}{X_1 + \cdots + X_n}}$$

은 척도모수 θ에 의존하지 않는 Beta$(1, n-1)$ 분포를 따르므로

$$\boxed{E_\theta(Z) = \frac{1}{n}.}$$

정서/검산 메모 원본에서 시작만 된 $E(Z)$ 계산에 지수변수의 감마–디리클레 성질을 적용했습니다.

정리 8.3.3 — Basu 정리: 완비충분통계량과 보조통계량의 독립성

원문 정리: 모형 $f(x;\theta)$의 독립 표본 $X_1,\dots,X_n$에서 $Y=u(X_1,\dots,X_n)$가 완비충분통계량(CSS), $Z=v(X_1,\dots,X_n)$가 보조통계량(ancillary)이면 Y와 Z는 독립이다. **정의 — 보조통계량**

Z의 분포가 모든 θ에 대해 같으면 Z는 보조통계량이다. **증명**

보조통계량의 임의 사건 $A=\{Z\in B\}$를 고정한다. 충분성에 의해 조건부 확률 $h(Y)=P_\theta(A\mid Y)$는 θ에 의존하지 않는 Y의 함수로 선택할 수 있다. 보조성에 의해 $P_\theta(A)=c_B$도 θ와 무관하다.

$$E_\theta[h(Y)-c_B]=P_\theta(A)-c_B=0 \qquad \text{모든 } \theta.$$

Y가 완비이므로 $h(Y)=c_B$가 거의 확실하게 성립한다. 즉

$$P_\theta(Z\in B\mid Y)=P_\theta(Z\in B),$$

따라서 Y와 Z는 독립이다. **예제 — 정규표본의 평균과 잔차 관련 통계량**

$X_i\sim N(\mu,\sigma^2)$에서 σ^2를 아는 위치모형이라면 $\overline{X}$는 μ에 대한 완비충분통계량이다. 위치에 불변인 잔차들의 함수는 보조통계량이므로 $\overline{X}$와 독립이다.

원본 207쪽 손글씨 정서

정규모형에서 누적확률의 UMVUE

$X_i \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$이고 σ^2가 알려져 있다. 고정된 $a \in \mathbb{R}$에 대해

$$g(\mu) = \mathsf{P}_\mu(X_1 \le a) = \Phi\left(\frac{a-\mu}{\sigma}\right)$$

를 추정한다. $\delta(X) = \mathbf{1}_{\{X_1 \le a\}}$는 불편추정량이다. 충분통계량 $\bar X$에 관해 조건화하자. 결합정규성으로

$$X_1 \mid \bar X = \bar x \sim N\left(\bar x, \sigma^2\left(1 - \frac{1}{n}\right)\right).$$

따라서 $n \ge 2$에서

$$\boxed{\delta^*(\bar X) = \mathsf{P}(X_1 \le a \mid \bar X) = \Phi\left(\frac{a - \bar X}{\sigma\sqrt{1-1/n}}\right).}$$

이는 불편이며, 알려진 σ^2의 정규위치족에서는 $\bar X$가 완비충분통계량이므로 $g(\mu)$의 UMVUE이다.

> 원본에서 조건부 분산을 $\sigma^2(1-1/n)$으로 계산하는 단계가 핵심이다. $n=1$이면 조건부분포가 퇴화하므로 $\mathbf{1}_{\{X_1\le a\}}$를 그대로 사용한다.

예제 8.3.9–8.3.10 — 신뢰도 함수의 추정

원본 문제: 정규분포와 지수분포에서 $g(\theta) = P_\theta(X_1 > a)$ 형태의 **신뢰도(reliability)**를 추정한다. **예제 8.3.9: 정규모형에서 신뢰도**

$X_1, \ldots, X_n \overset{\text{iid}}{\sim} N(\mu, \sigma^2)$, σ^2는 알려져 있다. $g(\mu) = P_\mu(X_1 > a) = \Phi((\mu - a)/\sigma)$이며, $\overline{X}$는 완비충분통계량이다. $n \geq 2$에서 $X_1 \mid \overline{X} \sim N(\overline{X}, \sigma^2(1 - 1/n))$이므로

$$\boxed{\widehat{g}_{\text{UMVUE}} = E[\mathbf{1}_{\{X_1 > a\}} \mid \overline{X}] = \Phi\left(\frac{\overline{X} - a}{\sigma\sqrt{1 - 1/n}} \right).}$$

예제 8.3.10: 지수모형에서 신뢰도

$X_i \overset{\text{iid}}{\sim} \text{Exp}(\text{rate } \lambda)$, $a \geq 0$이면 $g(\lambda) = e^{-\lambda a}$. $S = \sum_i X_i$는 완비충분통계량이다. $X_1 / S \mid S \sim \text{Beta}(1, n-1)$이므로 $n \geq 2$에서

$$\boxed{\widehat{g}_{\text{UMVUE}} = E[\mathbf{1}_{\{X_1 > a\}} \mid S] = \left(1 - \frac{a}{S}\right)^{n-1} \mathbf{1}_{\{S > a\}}.}$$

두 공식 모두 조건부기대값을 이용했으므로 불편이며 Lehmann–Scheffé 정리에 의해 UMVUE이다.

원문 대조·교정 기록 원본 208쪽의 두 “신뢰도의 추정” 예제 제목을 복원하고 해당 풀이를 보충했습니다. 이전 정규분포의 MLE 설명은 원문과 다른 주제였습니다.

3. 추정량에서 대표본 이론

6.4 ML 추정량의 접근적 성질

표본크기 n이 커짐에 따라 최대가능도추정량이 모수에 가까워지는 성질을 **일치성**, 적절히 정규화한 추정량이 극한정규분포를 갖는 성질을 **점근정규성**이라고 한다. **정의 — 일치성 (Consistency)**

모수 θ의 추정량 $\hat{\theta}_n$이 모든 $\varepsilon > 0$에 대해

$$\boxed{P_\theta(|\hat{\theta}_n - \theta| > \varepsilon) \to 0}$$

을 만족하면 일치추정량이다. **예제 — $N(\mu, \sigma^2)$의 표본평균**

$$E(\bar{X}) = \mu, \quad \mathrm{Var}(\bar{X}) = \sigma^2/n.$$

Chebyshev 부등식에서

$$P(|\bar{X} - \mu| > \varepsilon) \le \frac{\sigma^2}{n\varepsilon^2} \to 0.$$

따라서 $\bar{X} \xrightarrow{P} \mu$이다.

정서/검수 메모 원본의 MLE 접근적 성질, 일치성의 정의와 정규모형 예제를 조판했습니다.

원본 210쪽 일치성의 반례: $U(0,\theta)$ 최대값과 지수표본 최소값

원본 왼쪽: 균등표본 최댓값 $M_n = X_{(n)}$

$X_i \overset{\text{iid}}{\sim} U(0,\theta)$ $(\theta > 0)$, $F_{M_n}(x) = (x/\theta)^n$ $(0 < x < \theta)$.

$$f_{M_n}(x) = \frac{nx^{n-1}}{\theta^n}, \qquad EM_n = \frac{n}{n+1}\theta \neq \theta.$$

$0 < \varepsilon < \theta$일 때

$$P_\theta(|M_n - \theta| \geq \varepsilon) = P(M_n \leq \theta - \varepsilon) = \left(1 - \frac{\varepsilon}{\theta}\right)^n \longrightarrow 0.$$

$\varepsilon \geq \theta$인 경우에도 왼쪽 확률은 0으로 수렴한다. 따라서 **최댓값 M_n은 편향되어 있지만 일치추정량**이다. **원본 오른쪽: 지수분포의 $nX_{(1)}$**

원본 예제 4.3.3에서 $X_i \overset{\text{iid}}{\sim}$ Exp(척도 θ), $\hat{\theta}_2 = nX_{(1)}$라 놓는다.

$$P(X_{(1)} > x) = P(X_1 > x, \ldots, X_n > x) = e^{-nx/\theta}, \quad x \geq 0.$$

따라서 $X_{(1)} \sim$ Exp(척도 θ/n)이고

$$nX_{(1)} \sim \text{Exp(척도 } \theta), \qquad E\hat{\theta}_2 = \theta, \quad \text{Var}(\hat{\theta}_2) = \theta^2.$$

$P(|\hat{\theta}_2 - \theta| > \varepsilon) > 0$은 n에 의존하지 않는다.

즉 $nX_{(1)}$**는 불편하지만 일치하지 않는다**.

체비쇼프 부등식의 상한 θ^2/ε^2이 0으로 가지 않는 것만으로 비일치성을 증명하지는 못한다.

위처럼 분포가 모든 n에 대해 같음을 확인해야 한다.

[검산·보충] 기존 정서본에 누락된 $nX_{(1)}$ 예제를 복원했다.

원본 211 쪽 | 지수분포추정량의일치성·연속함수의일치성

[원본예제] $X_1, \ldots, X_n \overset{\text{iid}}{\sim} \text{Exp}(\theta)$

원본필기의 $\text{Exp}(\theta)$ 는평균·척도모수 $\theta > 0$ 인지수분포를뜻한다.

$$E_\theta(X_i) = \theta, \qquad \text{Var}_\theta(X_i) = \theta^2, \qquad \widehat{\theta}_n = \overline{X}_n.$$

$$P_\theta(|\overline{X}_n - \theta| \geq \varepsilon) \leq \frac{\text{Var}(\overline{X}_n)}{\varepsilon^2} = \frac{\theta^2}{n\varepsilon^2} \longrightarrow 0.$$

따라서 $\overline{X}_n \xrightarrow{p} \theta$. 체비쇼프부등식에의한일치성증명이다. **[원본정의] 일치추정량의연속함수**

$\widehat{\eta}_n \xrightarrow{p} \eta(\theta)$ 이고 g 가 $\eta(\theta)$ 에서연속이면,

$$g(\widehat{\eta}_n) \xrightarrow{p} g\{\eta(\theta)\}.$$

즉, $g(\widehat{\eta}_n)$ 은 $g\{\eta(\theta)\}$ 의일치추정량이다.

[풀이보충 / 검산]
원본에서생략한증명은 연속함수정리 *(continuous mapping theorem)* 이다. 예를들어 $\widehat{\theta}_n = \overline{X}_n$ 이 θ 에일치하면 $e^{-\overline{X}_n} \xrightarrow{p} e^{-\theta}$ 이다. 분모에추정량이있는함수는극한점에서분모가 0 이아닌지도확인해야한다.

원본 212 쪽 | 표본분산의일치성·ML 추정량의점근적성질

[원본예제 4.43] S^2 의일치성

$X_1, \ldots, X_n$ 이평균 μ, 분산 $\sigma^2 < \infty$ 인독립동일분포표본이면

$$S^2 = \frac{1}{n-1}\sum_{i=1}^{n}(X_i - \overline{X}_n)^2 = \frac{n}{n-1}\left\{\frac{1}{n}\sum_{i=1}^{n}X_i^2 - \overline{X}_n^2\right\}.$$

큰수의법칙으로 $n^{-1}\sum X_i^2 \xrightarrow{p} E(X^2)$, $\overline{X}_n \xrightarrow{p} E(X)$ 이고 $n/(n-1) \to 1$ 이다. 따라서

$$S^2 \xrightarrow{p} E(X^2) - [E(X)]^2 = \sigma^2.$$

또 $S = \sqrt{S^2} \xrightarrow{p} \sigma$ (연속함수정리). **2. ML 추정량의점근적성질**

- ML 추정량은불변성원리처럼편리한성질을가진다.
- 단순한모형에서는일치성과점근정규성을직접증명하기쉽지만, 로지스틱분포처럼최대화방정식에닫힌해가없는경우수치적방법이필요하다.
- 적절한정칙조건에서 ML 추정량은일치하고점근적으로정규분포를따른다.
- 따라서정규근사를이용한구간추정과가설검정을구성할수있다.

[풀이보충 / 검산]
S^2 의일치성에는정규분포가정이필요하지않다. $E(X^2) < \infty$ 면충분하다. 이페이지에서표본분산을 $1/(n-1)$ 로정의했음을주의한다.

원본 213 쪽 | [원본예제 6.4.1] ML 추정량의일치성과극한분포

예시모형

$$X_1, \ldots, X_n \text{ 독립동일분포: } \quad \text{Bernoulli}(p), \quad \text{Poisson}(\mu), \quad \text{Exp}(\theta).$$

단순한모형에서는보통일치성의정의와중심극한정리로 ML 추정량의극한분포를직접확인할수있다.

[풀이보충 / 검산]

(1) 베르누이: $\widehat{p} = \overline{X}, \widehat{p} \xrightarrow{p} p$ 이고 $0 < p < 1$ 이면

$$\sqrt{n}(\widehat{p} - p) \xrightarrow{d} N\{0, p(1-p)\}.$$

(2) 포아송: $\widehat{\mu} = \overline{X}, \widehat{\mu} \xrightarrow{p} \mu$ 이고

$$\sqrt{n}(\widehat{\mu} - \mu) \xrightarrow{d} N(0, \mu).$$

(3) 지수분포 (평균모수): $\widehat{\theta} = \overline{X}, \widehat{\theta} \xrightarrow{p} \theta$ 이고

$$\sqrt{n}(\widehat{\theta} - \theta) \xrightarrow{d} N(0, \theta^2).$$

이는모수별 $\text{Var}(X)$ 와중심극한정리에따른결과이다.

[원본] 로지스틱위치모형에서의문제

$X_1, \ldots, X_n \overset{\text{iid}}{\sim} L(\theta, 1)$ 인경우 ML 추정량은통상유일하지만간단한닫힌형태로표현되지않아수치적인최적화가필요하다. 이때일반적인 ML 추정량일치성·점근정규성이론을활용한다.

원본 214 쪽 | [원본정리 6.4.2] 최대가능도추정량의일치성

확률밀도 (또는확률질량) 함수 $f(x;\theta)$ 를갖는표본 $X_1,\dots,X_n$ 에대해적절한조건하에서 ML 추정량 $\widehat{\theta}_n$ 은모수의일치추정량이다:

$$\widehat{\theta}_n \xrightarrow{p} \theta_0, \qquad \lim_{n\to\infty} P_{\theta_0}(|\widehat{\theta}_n-\theta_0|\ge\varepsilon)=0 \quad (\varepsilon>0).$$

[원본필기] 정칙조건의개략

1. 서로다른모수가서로구별되는확률모형을제공한다 (식별가능성).
2. 밀도의지지집합이모수에의존하지않는등우도비교에필요한조건을둔다.
3. 로그우도함수의미분가능성과기대·미분교환등의정칙조건을둔다.

[원본증명스케치] 점수함수의방정식

내부해에서 $\widehat{\theta}_n$ 은점수방정식을만족한다.

$$U_n(\widehat{\theta}_n)=\sum_{i=1}^{n}\frac{\partial}{\partial\theta}\log f(X_i;\theta)\Big|_{\theta=\widehat{\theta}_n}=0.$$

큰수의법칙의직관에따라

$$\frac{1}{n}U_n(\theta)\xrightarrow{p}E_{\theta_0}\left[\frac{\partial}{\partial\theta}\log f(X;\theta)\right].$$

[풀이보충 / 검산]
$E_{\theta_0}[\partial_\theta \log f(X;\theta)]$ 는일반적으로 $\theta=\theta_0$ 에서 0 이된다. 그러나 점수방정식과보통의대수의법칙만으로일치성이자동증명되지는않는다. 해의식별성과균등수렴등추가조건이필요하다.

원본 215 쪽 | ML 추정량일치성의직관적증명과예제

[원본] 정규화한로그우도의대수의법칙

$$\bar{\ell}_n(\theta) = \frac{1}{n}\sum_{i=1}^{n} \log f(X_i;\theta) \xrightarrow{p} m(\theta) := E_{\theta_0}[\log f(X;\theta)].$$

$\bar{\ell}_n(\theta)$ 를최대화하는값이 $\widehat{\theta}_n$, 극한함수 $m(\theta)$ 를유일하게최대화하는값이참모수 θ_0 이면 $\widehat{\theta}_n \to \theta_0$ 를기대할수있다.

$$\widehat{\theta}_n = \arg\max_{\theta\in\Omega} \bar{\ell}_n(\theta), \qquad \theta_0 = \arg\max_{\theta\in\Omega} m(\theta).$$

[원본예제 6.4.2] $L(\theta,1)$, $\mathrm{Exp}(\theta)$

로지스틱위치모형과지수분포에서 ML 추정량의일치성을확인하는문제이다.

[풀이보충 / 검산]

왜참모수가극대점인가? 밀도 f_{θ_0}, f_θ 에대해

$$m(\theta_0) - m(\theta) = E_{\theta_0}\log\frac{f_{\theta_0}(X)}{f_\theta(X)} = D_{\mathrm{KL}}(f_{\theta_0}\|f_\theta) \geq 0.$$

모형이식별가능하면등호는보통 $\theta = \theta_0$ 일때만성립한다. 정확한일치성정리에는 균등대수의법칙과최대값의안정성조건등이추가로요구된다.

원본 216 쪽 | [원본정리 6.4.4] ML 추정량의점근적정규성

$X_1, \ldots, X_n$ 이밀도 $f(x;\theta)$ 에서추출된 iid 표본이고참모수가 θ_0 일때, 적절한정칙조건에서

$$\sqrt{n}(\widehat{\theta}_n - \theta_0) \xrightarrow{d} N\left(0, \frac{1}{I(\theta_0)}\right).$$

여기서 $I(\theta_0)$ 는 관측치 *1* 개당 *Fisher* 정보이다.

$$I(\theta_0) = E_{\theta_0}\left[\left\{\frac{\partial}{\partial\theta}\log f(X;\theta_0)\right\}^2\right] = -E_{\theta_0}\left[\frac{\partial^2}{\partial\theta^2}\log f(X;\theta_0)\right].$$

[원본 Proof] 증명개요

로그우도 $\ell_n(\theta) = \sum_i \log f(X_i;\theta)$ 의점수방정식은

$$\ell_n'(\widehat{\theta}_n) = 0.$$

참모수부근에서이를테일러전개하고, 중심극한정리·큰수의법칙·Slutsky 정리를적용한다 (다음원본 217 쪽).

[풀이보충 / 검산]
이결과는모든모형에서무조건성립하지않는다. 경계모수, 식별실패, 지지집합의모수의존등이있으면다른극한분포가나타날수있다.

점근정규성의 유도 — 최대가능도추정량

표본 $X_1, \dots, X_n$의 로그가능도를 $\ell_n(\theta) = \sum_i \log f(X_i;\theta)$라 한다. MLE가 내부에 있고 정칙조건 아래 $\ell_n'(\widehat{\theta}_n) = 0$이면, 참값 θ_0 근처에서 Taylor 전개로

$$0 = \ell_n'(\theta_0) + (\widehat{\theta}_n - \theta_0)\ell_n''(\theta_n^*)$$

를 얻는다 (θ_n^*는 두 값 사이). 따라서

$$\sqrt{n}(\widehat{\theta}_n - \theta_0) = \frac{n^{-1/2}\ell_n'(\theta_0)}{-n^{-1}\ell_n''(\theta_n^*)}.$$

점수함수, CLT와 대수의 법칙

정칙조건에서 $s_i = \partial_\theta \log f(X_i;\theta_0)$는 $Es_i = 0$, $\mathrm{Var}(s_i) = I(\theta_0)$를 만족한다. CLT와 LLN으로

$$\frac{1}{\sqrt{n}}\ell_n'(\theta_0) \xrightarrow{d} N(0, I(\theta_0)), \qquad -\frac{1}{n}\ell_n''(\theta_n^*) \xrightarrow{P} I(\theta_0).$$

Slutsky 정리에 의해

$$\boxed{\sqrt{n}(\widehat{\theta}_n - \theta_0) \xrightarrow{d} N\left(0, \frac{1}{I(\theta_0)}\right).}$$

원본 예제 — 척도모수 $\mathrm{Exp}(\theta)$

$f(x;\theta) = \theta^{-1}e^{-x/\theta}\mathbf{1}_{(0,\infty)}(x)$이면 $\widehat{\theta}_n = \overline{X}$, $E(X) = \theta$, $\mathrm{Var}(X) = \theta^2$이다.

$$\partial_\theta \log f = -\frac{1}{\theta} + \frac{x}{\theta^2}, \quad I(\theta) = \frac{1}{\theta^2}, \quad \boxed{\sqrt{n}(\overline{X} - \theta) \xrightarrow{d} N(0, \theta^2)}.$$

원본 218 쪽 | [원본예제] 지수·베르누이모형의극한분포

(1) 지수분포 (평균모수 θ)

$$X_1, \ldots, X_n \overset{\text{iid}}{\sim} \text{Exp}(\theta), \qquad \eta(\theta) = \theta.$$

$\widehat{\theta}_{\text{ML}} = \overline{X}$ 이므로

$$\sqrt{n}(\widehat{\theta}_{\text{ML}} - \theta) \xrightarrow{d} N(0, \theta^2).$$

(2) 베르누이모형

$$X_1, \ldots, X_n \overset{\text{iid}}{\sim} \text{Bernoulli}(p), \quad 0 < p < 1, \qquad \widehat{p}_{\text{ML}} = \overline{X}.$$

- 관심모수 $\eta(p) = p$ 이면
$$\sqrt{n}(\widehat{p} - p) \xrightarrow{d} N\{0, p(1-p)\}.$$
- 관심모수 $\eta(p) = p/(1-p)$ 이면 ML 불변성에의해 $\widehat{\eta} = \overline{X}/(1-\overline{X})$ 이다 ($\overline{X} < 1$ 인경우).

[풀이보충 / 검산]
델타방법에서 $g(p) = p/(1-p)$, $g'(p) = 1/(1-p)^2$ 이므로

$$\sqrt{n}\left\{\frac{\overline{X}}{1-\overline{X}} - \frac{p}{1-p}\right\} \xrightarrow{d} N\left(0, \frac{p}{(1-p)^3}\right).$$

표본에서모든 $X_i = 1$ 인경우표본오즈가무한대가될수있으나, $0 < p < 1$ 이면그확률 $p^n \to 0$ 이다.

원본 219 쪽 | 8.4 추정량의점근적비교·로지스틱분포

[원본] 분산을통한추정량비교

일치추정량들을비교할때극한분포의분산을주된기준으로삼는다. **[원본예제 8.4.1] 로지스틱위치모형** $L(\theta, 1)$

$$f(x;\theta) = \frac{\exp(-x+\theta)}{\{1+\exp(-x+\theta)\}^2}, \qquad -\infty < x < \infty.$$

원본에서비교한세추정량은

(i) 표본평균 $\widehat{\theta}_1 = \overline{X}_n$

(ii) 최대가능도추정량 $\widehat{\theta}_2 = \widehat{\theta}_{\mathrm{ML}}$

(iii) 표본중앙값 $\widehat{\theta}_3 = \widehat{\theta}_{\mathrm{MED}}$.

[풀이보충 / 검산]

세추정량은정칙조건하에서일치하고서로다른점근분산을갖는다.

$$\sqrt{n}(\overline{X}_n - \theta) \xrightarrow{d} N\left(0, \frac{\pi^2}{3}\right), \quad \sqrt{n}(\widehat{\theta}_{\mathrm{ML}} - \theta) \xrightarrow{d} N(0, 3),$$

$$\sqrt{n}(\widehat{\theta}_{\mathrm{MED}} - \theta) \xrightarrow{d} N(0, 4).$$

이들의유도와효율성비교는다음두페이지에서정리한다.

원본 220쪽 표본분위수의 극한분포 및 로지스틱 위치추정

원본 상단: 표본분위수의 점근분포

F가 $q_\alpha = F^{-1}(\alpha)$에서 미분 가능하고 $f(q_\alpha) > 0$일 때, $\alpha \in (0,1)$에 대하여

$$\sqrt{n}\left(X_{(\lceil n\alpha \rceil)} - q_\alpha\right) \xrightarrow{d} N\left(0, \frac{\alpha(1-\alpha)}{f(q_\alpha)^2}\right).$$

특히 중앙값($\alpha = 1/2$)의 점근분산은 $1/[4f(m)^2]$이다. **원본 예제: 위치모수 θ의 로지스틱 분포**

$F(x;\theta) = \{1 + e^{-(x-\theta)}\}^{-1}$, $f(x;\theta) = e^{-(x-\theta)}/\{1+e^{-(x-\theta)}\}^2$. **(i) 표본평균.** 평균 θ, 분산 $\pi^2/3$이므로

$$\sqrt{n}(\bar{X} - \theta) \xrightarrow{d} N\left(0, \frac{\pi^2}{3}\right).$$

(ii) 최대가능도 추정량. $U = F(X;\theta) \sim U(0,1)$을 이용하면

$$\frac{\partial}{\partial\theta}\log f(X;\theta) = 2U - 1, \qquad I(\theta) = E(2U-1)^2 = \frac{1}{3}.$$

$$\sqrt{n}(\hat{\theta}_{\mathsf{ML}} - \theta) \xrightarrow{d} N(0, I(\theta)^{-1}) = N(0,3).$$

(iii) 표본중앙값. $m = \theta$이고 $f(\theta;\theta) = 1/4$이므로

$$\sqrt{n}(\hat{\theta}_{\mathsf{MED}} - \theta) \xrightarrow{d} N\left(0, \frac{1}{4(1/4)^2}\right) = N(0,4).$$

원본 결과 비교

$$\boxed{\text{점근분산:}\quad \mathsf{ML} = 3 < \mathsf{mean} = \pi^2/3 \approx 3.290 < \mathsf{median} = 4.}$$

[검산·보충] 원본 상단의 표본분위수 정리를 복원했다. 수치 비교에서는 추정량의 점근분산에 공통으로 붙는 $1/n$을 제외했다.

원본 221 쪽 | [원본정의] ARE: 점근상대효율성

두추정량 $\widehat{\theta}_1, \widehat{\theta}_2$ 가

$$\sqrt{n}(\widehat{\theta}_i - \theta) \xrightarrow{d} N\{0, \sigma_i^2(\theta)\}, \qquad i = 1, 2,$$

를만족할때, 원본에서사용하는정의는

$$\mathrm{ARE}(\widehat{\theta}_1, \widehat{\theta}_2) = \frac{\sigma_2^2(\theta)}{\sigma_1^2(\theta)}.$$

$\mathrm{ARE} > 1$ 이면동일한목표정밀도에대해 $\widehat{\theta}_1$ 이 $\widehat{\theta}_2$ 보다효율적이며, 더적은표본이필요함을뜻한다. **[원본필기] 로지스틱위치모형에적용**

$\widehat{\theta}_1 = \overline{X}_n, \widehat{\theta}_2 = \widehat{\theta}_{\mathrm{ML}}$ 이면

$$\mathrm{ARE}(\overline{X}_n, \widehat{\theta}_{\mathrm{ML}}) = \frac{3}{\pi^2/3} = \frac{9}{\pi^2} \approx 0.912 < 1.$$

순서를바꾸면

$$\mathrm{ARE}(\widehat{\theta}_{\mathrm{ML}}, \overline{X}_n) = \frac{\pi^2}{9} \approx 1.097 > 1.$$

[풀이보충 / 검산]
$\mathrm{ARE}(\widehat{\theta}_{\mathrm{MED}}, \widehat{\theta}_{\mathrm{ML}}) = 3/4 = 0.75$. 분산의비를 어떤추정량을첫번째인자로놓는지에따라거꾸로쓰므로기호의정의를먼저확인해야 한다.

원본 222 쪽 | [원본예제] 포아송추정과로지스틱분포의표본크기

[원본] 포아송 $g(\theta) = P_\theta(X=0) = e^{-\theta}$

$X_1, \ldots, X_n \overset{\text{iid}}{\sim} \text{Poisson}(\theta)$ 이면 $\widehat{\theta} = \overline{X}_n$, 관심모수 $g(\theta) = e^{-\theta}$ 에대한 ML 추정량은 $\widehat{g} = e^{-\overline{X}_n}$ 이다.

[풀이보충 / 검산]

중심극한정리와델타방법에의해

$$\sqrt{n}(e^{-\overline{X}_n} - e^{-\theta}) \xrightarrow{d} N\{0, \theta e^{-2\theta}\}.$$

따라서 $\widehat{g} \pm 1.96\sqrt{\overline{X}_n e^{-2\overline{X}_n}/n}$ 은대표적인점근 95% 신뢰구간 (끝점은필요시 $[0,1]$ 로제한) 이다.

[원본예제 8.4.2] 로지스틱분포의추정오차한계와 ARE

앞의로지스틱위치모형에서 MLE·평균·중앙값의점근분산은각각 3, $\pi^2/3$, 4 이다. 동일한신뢰수준·오차한계 d 에필요한표본크기를비교한다 (다음페이지).

원본 223 쪽 [예제 8.4.2] 로지스틱추정량비교와오차한계

원본필기의세추정량

로지스틱위치모형에서위치모수 θ 를추정하는 ML, 표본평균, 표본중앙값의대표본근사를비교한다. 각추정량 $\widehat{\theta}$ 에대해

$$\widehat{\theta} \pm 1.96\sqrt{\frac{V}{n}}$$

가근사 95% 신뢰구간이다. 원본의비교값은

추정량	점근분산 V	오차한계
ML	3	$1.96\sqrt{3/n}$
표본평균 $\bar{X}$	$\pi^2/3$	$1.96\sqrt{\pi^2/(3n)}$
표본중앙값	4	$1.96\sqrt{4/n}$

원본의표본크기비율

오차한계가 d 이하가되려면 $n \geq 1.96^2 V/d^2$ 를만족하면된다. ML 과비교하여

$$\frac{n_{\text{med}}}{n_{\text{ML}}} \approx \frac{4}{3} = 1.333, \qquad \frac{n_{\text{mean}}}{n_{\text{ML}}} \approx \frac{\pi^2}{9} = 1.097.$$

원본하단: 포아송 $g(\theta) = P(X=0)$ 의점근분포

$X_i \overset{\text{iid}}{\sim} \text{Pois}(\theta)$ 이고 $\widehat{\theta} = \bar{X}$ 이면, $g(\theta) = e^{-\theta}$ 에대한 ML 추정량은 $g(\widehat{\theta}) = e^{-\bar{X}}$ 이다.

$$\sqrt{n}(\bar{X} - \theta) \xrightarrow{d} N(0, \theta),$$

$$\boxed{\sqrt{n}\{e^{-\bar{X}} - e^{-\theta}\} \xrightarrow{d} N(0, \theta e^{-2\theta}).}$$

이것은델타방법 $g'(\theta) = -e^{-\theta}$ 를이용한결과이다.

원본하단의다음과제

Beta$(\alpha, 1)$ 의적률추정량과 ML 추정량을비교하는문제는원본 224 쪽에이어진다.

검산·보충: 원본하단에적힌포아송사례를별도계산으로복원했다. 원본의로지스틱표본크기비율 $4/3$ 및 $\pi^2/9$ 도검산했다.

원본 224 쪽 | [원본예제 8.4.4·8.4.5] $\mathrm{Beta}(\alpha,1)$ 추정량비교

[원본과제] $\widehat{\alpha}_{\mathrm{MM}}$, $\widehat{\alpha}_{\mathrm{ML}}$

$X_1,\dots,X_n \overset{\text{iid}}{\sim} \mathrm{Beta}(\alpha,1)$, $\alpha>0$ 이고

$$f(x;\alpha)=\alpha x^{\alpha-1}\mathbf{1}_{(0,1)}(x),\quad EX=\frac{\alpha}{\alpha+1},\quad \mathrm{Var}(X)=\frac{\alpha}{(\alpha+1)^2(\alpha+2)}.$$

[풀이보충 / 검산]

적률추정: $\overline{X}=\alpha/(\alpha+1)$ 을풀어

$$\widehat{\alpha}_{\mathrm{MM}}=\frac{\overline{X}}{1-\overline{X}}.$$

최대가능도추정: $\ell(\alpha)=n\log\alpha+(\alpha-1)\sum_i\log X_i$ 이므로

$$\ell'(\alpha)=\frac{n}{\alpha}+\sum_i\log X_i=0\quad\Longrightarrow\quad\widehat{\alpha}_{\mathrm{ML}}=-\frac{n}{\sum_i\log X_i}.$$

극한분포: 델타방법과 $I(\alpha)=1/\alpha^2$ 에의해

$$\sqrt{n}(\widehat{\alpha}_{\mathrm{MM}}-\alpha)\xrightarrow{d}N\left(0,\frac{\alpha(\alpha+1)^2}{\alpha+2}\right),$$

$$\sqrt{n}(\widehat{\alpha}_{\mathrm{ML}}-\alpha)\xrightarrow{d}N(0,\alpha^2).$$

따라서

$$\mathrm{ARE}(\widehat{\alpha}_{\mathrm{MM}},\widehat{\alpha}_{\mathrm{ML}})=\frac{\alpha(\alpha+2)}{(\alpha+1)^2}<1.$$

원본에서 “생략–정리해볼것” 으로표시된항목에풀이를새로보충하였다.